

Cours de finance quantitative (M1)

Pricing, volatilité, calibration, couverture, taux et allocation

Version étendue (objectif : ~120 pages)

Document pédagogique “from ground up”

Résumé

Ce document est un cours complet (niveau Master 1 finance) reliant, de manière progressive, les briques théoriques nécessaires à la modélisation des marchés (processus stochastiques), au pricing et à la couverture d'options (Black–Scholes, martingales, mesure risque-neutre), à la construction et la calibration d'une surface de volatilité implicite (Heston, sauts, SABR, volatilité “rough”), ainsi qu'à la prise de décision en gestion (courbe des taux, optimisation de portefeuille de type Markowitz, risk parity, réduction dimensionnelle par ACP).

Le fil conducteur est systématiquement le même :

- 1) **Pourquoi cette notion existe en finance** (problème économique, instrument, risque).
- 2) **Modélisation mathématique** (définitions, hypothèses, limites).
- 3) **Dérivations détaillées** (pas de “magie”) pour relier le modèle à une formule exploitable.
- 4) **Numérique et pratique** (stabilité, calibration, erreurs, arbitrage).

Chaque chapitre contient des définitions formelles, des explications intuitives, des exemples chiffrés, et un encadré “Ce que le jury doit retenir”.

Table des matières

1	Architecture du cours & notations	1
1.1	Le fil conducteur : de la donnée de marché à la décision	1
1.2	Notations standard (taux, spot, forward, discount)	1
1.3	Probabilités : espace, filtration, martingales (sans measure theory lourde)	2
I	Calcul stochastique & pricing (socle indispensable)	4
2	Brownien et intégrale stochastique	5
2.1	Pourquoi un Brownien en finance ?	5
2.2	Définition formelle et propriétés clés	5
2.2.1	Intuition : marche aléatoire et limite	5
2.2.2	Moments simples	6
2.3	Intégrale stochastique d'Itô	6
2.3.1	Construction (idée) par approximations simples	6
2.3.2	Isométrie d'Itô : le “Pythagore” du bruit	6
2.3.3	Martingales associées	6
2.4	Limites et ce que le Brownien ne capture pas	7
3	Variation quadratique et lemme d'Itô	8
3.1	Variation quadratique : la quantité qui remplace la dérivée	8
3.1.1	Exemples fondamentaux	8
3.2	La règle $(dW)^2 = dt$ et ses conséquences	9
3.3	Dérivation détaillée du lemme d'Itô (1D)	9
3.3.1	Preuve (pas à pas, niveau M1)	9
3.4	Version multidimensionnelle (utilité pratique)	9
3.5	Exemples classiques en finance	10
3.6	Limites et hypothèses	10
4	Pricing risque-neutre, réplication et PDE de Black–Scholes	11
4.1	Le problème financier	11
4.2	Modèle Black–Scholes (hypothèses)	11
4.3	Dérivation PDE par portefeuille de couverture	11
4.3.1	Portefeuille auto-financé	12
4.3.2	Choix du hedge : annuler le risque instantané	12
4.4	Mesure risque-neutre et prix comme espérance	12
4.4.1	Idée de Girsanov (sans preuves lourdes)	13
4.4.2	Feynman–Kac : PDE $\leftrightarrow$ espérance	13
4.5	Limites du cadre Black–Scholes	13

5	Changement de mesure & numéraires : pourquoi $\mathbb{Q}$ n'est pas une "astuce"	15
5.1	Mesure physique $\mathbb{P}$ vs mesure de pricing	15
5.1.1	Deux questions différentes	15
5.1.2	Le rôle de la prime de risque	15
5.2	Numéraire et principe de martingale	16
5.2.1	Définition	16
5.2.2	Théorème (version utilisable en M1)	16
5.3	Girsanov (intuition + formule)	16
5.3.1	Intuition : absorber un drift	16
5.3.2	Énoncé (cas 1D)	16
5.3.3	Application à Black–Scholes	17
5.4	Forward measure : quand un forward devient une martingale	17
5.4.1	Forward price et numéraire	17
5.4.2	À quoi ça sert concrètement ?	17
5.5	Limites : marchés incomplets et non-unicité de $\mathbb{Q}$	17
6	Options vanilles : formule de Black–Scholes et greeks	19
6.1	Payoffs européens et parité put–call	19
6.2	Distribution lognormale sous $\mathbb{Q}$	19
6.3	Dérivation détaillée de la formule Black–Scholes (par espérance)	19
6.3.1	Étape 1 : calcul de $\mathbb{Q}(S_T > K)$	20
6.3.2	Étape 2 : calcul de $\mathbb{E}^{\mathbb{Q}}[S_T \mathbb{1}_{S_T > K}]$	20
6.3.3	Formule finale	21
6.4	Greeks : définitions, calculs et interprétation	21
6.4.1	Delta et gamma (les plus importants pour le hedging)	22
6.4.2	Vega (sensibilité à la volatilité)	22
6.4.3	Theta et rho	22
6.5	Limites pratiques des greeks BS	22
7	Volatilité implicite : définition, inversion numérique et stabilité	24
7.1	Pourquoi introduire la volatilité implicite ?	24
7.2	Définition formelle	24
7.2.1	Existence et unicité : monotonie en σ	24
7.3	Inversion numérique : bisection, Newton, et pièges	25
7.3.1	Méthode de dichotomie (bisection)	25
7.3.2	Méthode de Newton	25
7.3.3	Heuristiques d'initialisation	25
7.3.4	Pseudo-code d'un Newton sécurisé	25
7.4	Stabilité : quand l'implied vol devient "mauvais" numériquement	26
II	Surface de volatilité & calibration (cœur "quant")	27
8	Surface d'implied volatility : construction, smile/skew et arbitrage	28
8.1	Pourquoi une surface existe-t-elle ? (smile, skew)	28
8.2	Coordonnées de la surface : strike, moneyness, delta	28
8.3	No-arbitrage : contraintes simples et intuition	28
8.3.1	Arbitrage en strike : convexité des prix	29
8.3.2	Arbitrage en maturité : monotonie de la valeur temps	29
8.4	Interpolation et lissage : le minimum viable	29

9	Calibration : principe général, métriques d'erreur et choix numériques	30
9.1	Le problème : faire coller un modèle à la surface	30
9.2	Prix vs volatilité implicite : que minimiser ?	30
9.2.1	Calibration en prix	30
9.2.2	Calibration en volatilité implicite	31
9.2.3	Pondération par vega : une justification simple	31
9.3	Contraintes, bornes et identifiabilité	31
9.4	Optimisation : méthodes et compromis	31
9.4.1	Gradient vs derivative-free	31
9.4.2	Multi-start et minima locaux	31
9.4.3	Complexité	32
10	Optimisation numérique pour la calibration : stabilité, régularisation, contraintes	33
10.1	Du problème général au cas "moindres carrés"	33
10.1.1	Formulation	33
10.1.2	Gradient et matrice Jacobienne	33
10.2	Levenberg–Marquardt : un compromis robuste	34
10.2.1	Le pas de Gauss–Newton	34
10.2.2	Régularisation de Levenberg	34
10.2.3	Choix adaptatif de λ	34
10.3	Contraintes : rendre l'optimisation "légale"	34
10.3.1	Bornes et transformations	34
10.3.2	Exemple : condition de Feller (Heston)	35
10.4	Identifiabilité et échelles : pourquoi "tout fitter" est impossible	35
10.4.1	Un paramètre "faible" est invisible	35
10.4.2	Choix d'échelle : prix vs IV	35
10.5	Diagnostics : savoir quand une calibration est mauvaise	35
10.5.1	Erreurs structurées	35
10.5.2	Sensibilités de paramètres	36
11	Modèle de Heston : volatilité stochastique, pricing par fonction caractéristique, FFT	37
11.1	Pourquoi Heston ?	37
11.2	Définition du modèle (sous mesure risque-neutre)	37
11.2.1	Interprétation financière des paramètres	37
11.2.2	Condition de Feller (positivité de la variance)	38
11.3	Passage à la log-dynamique	38
11.4	Fonction caractéristique : dérivation via l'ansatz affine	38
11.4.1	Étape 1 : équation de Kolmogorov backward	38
11.4.2	Étape 2 : générateur du couple (X, v)	38
11.4.3	Étape 3 : insérer l'ansatz et obtenir des ODE	39
11.4.4	Forme fermée (résultat standard)	39
11.5	Pricing européen via inversion de Fourier	39
11.6	Carr–Madan : FFT pour pricer beaucoup de strikes à la fois	40
11.6.1	Idée principale	40
11.7	Illustration numérique : skew typique généré par Heston	40
11.8	Calibration Heston : objectifs et pièges	40

12 Diffusions à sauts : Merton et Bates	42
12.1 Pourquoi ajouter des sauts ?	42
12.2 Processus de Poisson composé (rappel)	42
12.3 Modèle de Merton (jump diffusion) sous $\mathbb{Q}$	42
12.4 Pricing : mélange de Black–Scholes (intuition et formule)	43
12.5 Fonction caractéristique (utile pour FFT)	43
12.6 Bates : Heston + sauts	43
12.7 Limites et extensions	44
13 SABR : dynamique, formule de Hagan et calibration	45
13.1 Pourquoi SABR ?	45
13.2 Dynamique SABR (sur le forward)	45
13.2.1 Interprétation des paramètres	45
13.3 Objectif : une formule rapide d'IV (Hagan)	45
13.4 Formule de Hagan (Black vol) : expression et lecture	46
13.5 Cas ATM : limite $K \rightarrow F$	46
13.6 Calibration SABR (pratique)	46
13.6.1 Pourquoi fixer β ?	46
13.7 Limites et extensions	47
14 Volatilité “rough” et modèles de type Volterra	48
14.1 Motivation empirique : la volatilité est très irrégulière	48
14.2 Brownien fractionnaire : définition et intuition	48
14.3 Représentation Volterra : ramener du rough à du Brownien	48
14.4 Exemple : modèle rBergomi (esprit)	49
14.5 Numérique : simulation et approximation markovienne	49
14.5.1 Simulation directe (coût élevé)	49
14.5.2 Approximation markovienne (somme d'exponentielles)	49
14.6 Limites et ce qu'il faut retenir	49
15 Réseaux de neurones et calibration accélérée : surrogates et inversion	51
15.1 Pourquoi des réseaux en calibration ?	51
15.2 Rappel minimal : perceptron multicouche (MLP)	51
15.2.1 Forward pass	51
15.3 Apprentissage supervisé : loss et objectif	51
15.4 Backprop : la règle de la chaîne (idée)	52
15.5 Génération de dataset synthétique (la clé en quant)	52
15.6 Surrogate direct vs inverse : avantages et limites	52
15.6.1 Surrogate direct	52
15.6.2 Surrogate inverse	53
15.7 Overfitting et validation	53
III Couverture discrète & reinforcement learning	54
16 Hedging discret : PnL, coûts de transaction et mesures de risque	55
16.1 Pourquoi le hedging discret est un vrai sujet ?	55
16.2 Définition du PnL d'une stratégie de couverture	55
16.2.1 Auto-financement sans coûts	55
16.2.2 Avec coûts de transaction proportionnels	56
16.3 Erreur de couverture et intuition	56
16.4 Mesures de risque pour évaluer une stratégie	56

16.4.1	Variance / MSE	56
16.4.2	Value-at-Risk et CVaR	56
16.4.3	Utilité exponentielle (approche économique)	57
16.5	Ce qui change quand on introduit une stratégie “apprenante”	57
17	MDP pour la couverture et algorithmes RL tabulaires	58
17.1	Pourquoi formuler le hedging comme un MDP ?	58
17.2	Définition d’un MDP (Markov Decision Process)	58
17.2.1	État, action et reward pour le hedging	58
17.3	Valeurs : V^π et Q^π	58
17.4	Équations de Bellman	59
17.5	Apprentissage TD : le cœur du RL	59
17.5.1	SARSA (on-policy)	59
17.5.2	Expected SARSA	59
17.5.3	Q-learning (off-policy)	59
17.6	On-policy vs off-policy : pourquoi c’est important ?	59
17.7	Importance sampling : corriger le biais off-policy	60
18	DQN : Q-learning avec réseaux (design, stabilité, extensions)	61
18.1	Pourquoi DQN ?	61
18.2	Objectif : minimiser une loss TD	61
18.3	Replay buffer : pourquoi on le fait	61
18.4	Target network : pourquoi on le fait	61
18.5	Exploration : epsilon-greedy	62
18.6	Pseudo-code DQN (version minimale)	62
18.7	Stabilité : la “deadly triad”	62
18.7.1	Trucs pratiques (niveau M1)	62
18.8	Actions continues : limites de DQN	62
18.9	Design du reward en hedging (le point non négociable)	63
IV	Courbe des taux : discounting, forwards, calibration	64
19	Discount factors, taux spot et forwards : dérivations claires	65
19.1	Pourquoi une courbe des taux ?	65
19.2	Discount factor, taux zéro, taux forward : définitions	65
19.2.1	Relations entre y et f	65
19.3	Forward simple sur une période	66
19.4	Bootstrapping (idée) : construire $P(0, T)$ à partir d’instruments liquides	66
19.5	Interpolation : point sensible	66
20	Modèles paramétriques : Nelson–Siegel et Nelson–Siegel–Svensson	67
20.1	Pourquoi des modèles paramétriques ?	67
20.2	Nelson–Siegel (NS) : formule et interprétation	67
20.2.1	Lecture “level / slope / curvature”	67
20.2.2	Rôle de τ	68
20.3	Nelson–Siegel–Svensson (NSS)	68
20.4	Calibration (moindres carrés)	68
20.5	Limites et usage pratique	68

V	Allocation de portefeuille & gestion du risque (décision d'investissement)	70
21	Markowitz : moyenne-variance, min-variance, max Sharpe	71
21.1	Pourquoi Markowitz ?	71
21.2	Cadre : vecteur de rendements et matrice de covariance	71
21.3	Problème moyenne-variance (forme contrainte)	71
21.3.1	Dérivation par multiplicateurs de Lagrange (détaillée)	72
21.3.2	Frontière efficiente	72
21.4	Portefeuille de variance minimale globale (GMV)	72
21.5	Max Sharpe (portefeuille tangentiel)	73
21.6	Contraintes, estimation risk, robustesse	73
22	Risk parity et risk budgeting : dérivations et intuition	74
22.1	Pourquoi risk parity ?	74
22.2	Volatilité de portefeuille et contributions	74
22.2.1	Somme des contributions	74
22.3	Risk parity (budgets égaux)	74
22.4	Cas particulier : actifs non corrélés	75
22.5	Résolution numérique : idées d'algorithmes	75
22.6	Limites	75
23	ACP (PCA), eigen-portfolios et modèles factoriels	76
23.1	Pourquoi PCA en finance ?	76
23.2	Décomposition spectrale de la covariance	76
23.2.1	Variance expliquée	76
23.3	Réduction de dimension : approximation à m facteurs	76
23.4	Eigen-portfolios	77
23.5	Shrinkage et régularisation via PCA	77
24	Rebalancing, coûts de transaction et exécution : du modèle à la réalité	78
24.1	Pourquoi le rebalancing est un problème non trivial ?	78
24.2	Mesure du turnover	78
24.3	Modèles de coûts	78
24.3.1	Coûts proportionnels	78
24.3.2	Impact quadratique (stylisé)	78
24.4	Rebalancing périodique vs seuil	79
24.4.1	Périodique	79
24.4.2	Seuil (band rebalancing)	79
24.5	Optimisation "cost-aware" (idée)	79
24.6	Lien avec le hedging d'options	79
VI	Exercices guidés (avec solutions) : consolider les notions	80
25	Feuille 1 : Brownien, Itô et Black-Scholes	81
25.1	Exercice 1 — incréments browniens et moments	81
25.2	Exercice 2 — variation quadratique : calcul guidé	81
25.3	Exercice 3 — résoudre le GBM par Itô	82
25.4	Exercice 4 — retrouver la formule de Black-Scholes	83

26	Feuille 2 : volatilité implicite, surface et calibration (Heston/SABR)	85
26.1	Exercice 1 — densité risque-neutre et convexité	85
26.2	Exercice 2 — inversion de la volatilité implicite (Newton sécurisé)	85
26.3	Exercice 3 — condition de Feller et interprétation	86
26.4	Exercice 4 — SABR : calcul ATM	86
27	Feuille 3 : courbe des taux, optimisation de portefeuille et risque	88
27.1	Exercice 1 — bootstrapping minimal (zéro-coupons)	88
27.2	Exercice 2 — Markowitz (2 actifs) : solution fermée	88
27.3	Exercice 3 — risk parity à deux actifs	89
28	Feuille 4 : méthodes numériques (Monte Carlo, greeks, PDE) — exercices	90
28.1	Exercice 1 — Monte Carlo : erreur en $1/\sqrt{M}$	90
28.2	Exercice 2 — réduction de variance : variable de contrôle	91
28.3	Exercice 3 — greeks par bump & revalue : choisir le bon epsilon	91
28.4	Exercice 4 — PDE : schéma implicite et stabilité	92
28.5	Exercice 5 — option américaine : algorithme de Longstaff–Schwartz (LSM)	92
28.6	Exercice 6 — FFT (Carr–Madan) : choisir la grille et éviter l’aliasing	93
28.7	Exercice 7 — quasi-Monte Carlo : quand et pourquoi cela aide	94
28.8	Exercice 8 — greeks Monte Carlo : méthode pathwise vs likelihood ratio	95
29	Feuille 5 : risk management (VaR, ES/CVaR, backtesting)	96
29.1	Exercice 1 — VaR et ES historiques sur un échantillon	96
29.2	Exercice 2 — VaR paramétrique sous normalité	97
29.3	Exercice 3 — backtesting : test de Kupiec (couverture inconditionnelle)	97
VII	Annexes	98
A	Méthodes de pricing : arbre binomial, Monte Carlo, PDE	99
A.1	Arbre binomial (Cox–Ross–Rubinstein)	99
A.1.1	Discrétisation du sous-jacent	99
A.1.2	Probabilité risque-neutre	99
A.1.3	Pricing européen	99
A.1.4	Options américaines	100
A.2	Monte Carlo (pricing comme espérance)	100
A.2.1	Principe	100
A.2.2	Erreur statistique	100
A.2.3	Réduction de variance (outils classiques)	100
A.2.4	American options : régression (LSMC)	100
A.3	PDE et différences finies	100
A.3.1	Schéma explicite (idée)	101
A.3.2	American options : condition de complémentarité	101
B	Payoffs : options vanilles et stratégies (graphes)	102
B.1	Call et put	102
B.2	Straddle et strangle	102
B.3	Spreads et structures à risque borné	102
B.4	Table mémo	102
C	Glossaire & carte des notions	106
C.1	Glossaire (définitions ultra-courtes)	106
C.2	Carte rapide : où chaque brique est utilisée	106

Table des figures

1.1	Architecture conceptuelle : comment les briques théoriques s'enchaînent.	1
5.1	Lecture opérationnelle : $\mathbb{P}$ pour prévoir, une mesure de martingale ($\mathbb{Q}$, $\mathbb{Q}^T$, etc.) pour pricer, en fonction du numéraire.	18
11.1	Smile de volatilité implicite générée par un modèle de Heston (exemple numérique).	41
20.1	Exemple de courbe Nelson–Siegel (paramètres illustratifs).	69
28.1	Illustration qualitative : MC décroît en $M^{-1/2}$; quasi-MC peut faire mieux sur des payoffs réguliers et une faible dimension effective.	94
B.1	Payoff d'un call européen.	102
B.2	Payoff d'un put européen.	104
B.3	Straddle : long call + long put, même strike.	104
B.4	Strangle : long put OTM + long call OTM.	104
B.5	Bull call spread : long call strike bas, short call strike haut (gain borné).	105
B.6	Butterfly (calls) : payoff positif autour du strike central, borné.	105

Chapitre 1

Architecture du cours & notations

1.1 Le fil conducteur : de la donnée de marché à la décision

En finance de marché, on peut schématiser une grande partie des problèmes quantitatifs en une chaîne logique :

- a) **Observation** : on collecte des prix (actions, taux, options) et on les convertit en quantités plus stables (rendements, volatilité implicite, facteurs de courbe).
- b) **Modélisation** : on postule une dynamique aléatoire pour les sous-jacents (par exemple une diffusion, ou une diffusion avec sauts), et on choisit un cadre de valorisation (absence d'arbitrage).
- c) **Pricing & couverture** : on calcule des prix théoriques d'options, et des sensibilités (*greeks*) pour gérer le risque.
- d) **Calibration** : on ajuste les paramètres du modèle pour qu'il reproduise les prix observés, typiquement via la surface de volatilité implicite.
- e) **Décision** : on transforme ces informations (prix, risques, courbe des taux) en décisions de trading, de couverture ou d'allocation.




FIGURE 1.1 – Architecture conceptuelle : comment les briques théoriques s’enchaînent.

Ce cours suit exactement ce flux : fig. 1.1 n’est pas un “diagramme joli” ; c’est un *plan de bataille* pour comprendre pourquoi on introduit Brownien, Itô, la mesure risque-neutre, les modèles de volatilité, puis des méthodes de couverture et enfin l’allocation.

1.2 Notations standard (taux, spot, forward, discount)

On travaille sur un horizon $[0, T]$. Les notations ci-dessous seront utilisées de façon cohérente tout au long du document.

Symbole	Nom	Commentaire
S_t	<i>spot</i>	Prix du sous-jacent (action/indice) au temps t .
K	strike	Prix d'exercice d'une option.
T	maturité	Date d'échéance d'un produit dérivé.
r_t	taux court	Taux instantané (modélisation possible, ou approximé constant).
r	taux constant	Hypothèse simplificatrice fréquente pour dériver Black-Scholes.
q	taux de dividende	Dividend yield continu (ou taux de repo) pour un indice.
B_t	compte sans risque	$B_t = \exp(\int_0^t r_u du)$ si taux continu.
$P(0, T)$	discount factor	Valeur aujourd'hui d'1 euro certain à T .
$F_{0,T}$	forward	Prix forward à 0 pour livraison à T (sous hypothèses).
σ	volatilité	Écart-type instantané (Black-Scholes) ou paramètre de diffusion.
$\sigma_{\text{imp}}(K, T)$	vol implicite	Volatilité Black-Scholes qui reproduit un prix de marché.

1.3 Probabilités : espace, filtration, martingales (sans measure theory lourde)

Définition 1.1 (Cadre probabiliste). On note $(\Omega, \mathcal{F}, (\mathcal{F}_t)_{t \in [0, T]}, \mathbb{P})$ un espace probabilisé filtré :

- Ω est l'ensemble des scénarios possibles ;
- $\mathcal{F}$ est la collection des événements observables ;
- $(\mathcal{F}_t)$ représente l'information disponible au temps t (on dit *filtration*) ;
- $\mathbb{P}$ est la probabilité “physique” (ou “historique”) décrivant la réalité statistique.

Intuition : $\mathcal{F}_t$ contient tout ce qu'un trader *peut savoir* au temps t (prix passés, news arrivées avant t , etc.). Un processus (X_t) est *adapté* si X_t est connu à l'instant t (donc X_t est $\mathcal{F}_t$ -mesurable).

Définition 1.2 (Martingale). Un processus (M_t) est une *martingale* (sous $\mathbb{P}$) si, pour $s \leq t$,

$$\mathbb{E}[M_t | \mathcal{F}_s] = M_s.$$

Intuition : une martingale est un “jeu équitable” : le meilleur prédictor du futur (conditionnellement à l'information) est le présent. Dans un marché sans arbitrage, une idée clé est que les *prix actualisés* deviennent des martingales sous une probabilité particulière (la mesure risque-neutre), ce qui est l'outil central du pricing.

Exemple 1.1 (Prix forward sous taux et dividendes constants). Supposons qu'un actif ne verse pas de dividende ($q = 0$) et que l'on puisse emprunter/prêter au taux r constant. Un contrat forward paye $S_T - F_{0,T}$ à maturité. En l'absence d'arbitrage, on peut répliquer le payoff en :

- achetant 1 unité de l'actif aujourd'hui, coût S_0 ;
- finançant cet achat par emprunt au taux r (donc on doit $S_0 e^{rT}$ à T).

À maturité, la position vaut $S_T - S_0 e^{rT}$. Pour qu'un forward ait prix initial nul, il faut $F_{0,T} = S_0 e^{rT}$. Si l'actif verse un dividende continu q , la réplcation donne $F_{0,T} = S_0 e^{(r-q)T}$.

Ce que le jury doit retenir.

- Le cours est organisé comme une chaîne : données $\rightarrow$ modèle $\rightarrow$ pricing/greeks $\rightarrow$ calibration $\rightarrow$ couverture et décision.
- Les notations S_t , K , T , r , q , $P(0, T)$ et $\sigma_{\text{imp}}(K, T)$ doivent être sues *sans hésiter*.
- Une martingale formalise l'idée d'un "prix juste" : pas de dérive prédictible une fois l'information prise en compte.

Première partie

Calcul stochastique & pricing (socle
indispensable)

Chapitre 2

Brownien et intégrale stochastique

2.1 Pourquoi un Brownien en finance ?

Le premier problème est de modéliser l'incertitude sur un prix S_t . En pratique, les rendements sur des pas de temps courts ont :

- une part imprévisible (news, flux, surprises) ;
- une agrégation de très nombreux micro-chocs ;
- des propriétés proches d'une somme de petits incréments.

Le *mouvement brownien* est un modèle canonique pour représenter un bruit continu, analogue à une limite de marche aléatoire.

2.2 Définition formelle et propriétés clés

Définition 2.1 (Mouvement brownien standard). Un processus $(W_t)_{t \geq 0}$ est un *mouvement brownien standard* (adapté à $(\mathcal{F}_t)$) si :

- $W_0 = 0$;
- les incréments sont indépendants : pour $0 \leq t_0 < t_1 < \dots < t_n$, les variables $W_{t_{k+1}} - W_{t_k}$ sont indépendantes ;
- les incréments sont stationnaires et gaussiens :

$$W_t - W_s \sim \mathcal{N}(0, t - s) \quad \text{pour } 0 \leq s < t;$$

- les trajectoires sont continues (presque sûrement).

2.2.1 Intuition : marche aléatoire et limite

Considérons une marche aléatoire discrète :

$$X_n = \sum_{k=1}^n \varepsilon_k, \quad \varepsilon_k \in \{-1, +1\} \text{ i.i.d. avec } \mathbb{P}(\varepsilon_k = 1) = \mathbb{P}(\varepsilon_k = -1) = \frac{1}{2}.$$

On a $\mathbb{E}[X_n] = 0$ et $\text{Var}(X_n) = n$. En temps continu, on redéfinit $t = n\Delta t$ et on rescale :

$$W_t^{(\Delta t)} = \sqrt{\Delta t} X_{t/\Delta t}.$$

Quand $\Delta t \rightarrow 0$, on peut montrer (idée du théorème central limite fonctionnel) que $W^{(\Delta t)}$ converge en loi vers un Brownien W . Ce qui compte ici : *la somme de petits chocs indépendants finit par ressembler à un bruit gaussien continu.*

2.2.2 Moments simples

Du fait de la loi $\mathcal{N}(0, t)$:

$$\mathbb{E}[W_t] = 0, \quad \text{Var}(W_t) = t, \quad \text{Cov}(W_s, W_t) = \min(s, t).$$

La covariance $\min(s, t)$ encode une mémoire simple : le chemin jusqu'à s est commun aux deux, puis les incréments après s sont indépendants.

2.3 Intégrale stochastique d'Itô

En finance, on manipule souvent des quantités du type “*exposition* $\times$ *bruit*”. Exemple : $dS_t = \sigma S_t dW_t$ signifie que l'incrément de prix est proportionnel au niveau S_t (effet multiplicatif) et au bruit dW_t . Pour donner un sens mathématique à $\int_0^T H_t dW_t$, il faut définir une intégrale qui respecte la nature très irrégulière du Brownien.

2.3.1 Construction (idée) par approximations simples

On commence par les processus en escalier :

$$H_t = \sum_{k=0}^{n-1} H_{t_k} \mathbb{1}_{(t_k, t_{k+1}]}(t), \quad 0 = t_0 < \dots < t_n = T,$$

avec H_{t_k} mesurable par rapport à $\mathcal{F}_{t_k}$ (donc “connu” au début de l'intervalle). On définit alors

$$\int_0^T H_t dW_t \triangleq \sum_{k=0}^{n-1} H_{t_k} (W_{t_{k+1}} - W_{t_k}).$$

L'idée : sur chaque intervalle, on gèle H au début (convention d'Itô), puis on multiplie par l'incrément de Brownien.

Ensuite, pour des processus plus généraux (par exemple continus, ou carrés-intégrables), on prend une limite en L^2 .

2.3.2 Isométrie d'Itô : le “Pythagore” du bruit

Théorème 2.1 (Isométrie d'Itô (forme simple)). *Si H est adapté et vérifie $\mathbb{E} \left[\int_0^T H_t^2 dt \right] < \infty$, alors*

$$\mathbb{E} \left[\left(\int_0^T H_t dW_t \right)^2 \right] = \mathbb{E} \left[\int_0^T H_t^2 dt \right].$$

À quoi ça sert ? Cette formule est fondamentale pour :

- contrôler la variance d'une stratégie de couverture (car les termes en dW créent l'aléa) ;
- prouver que certains processus sont des martingales ;
- analyser numériquement des schémas de simulation (erreur quadratique).

2.3.3 Martingales associées

Une conséquence importante : si H est adapté et intégrable,

$$M_t = \int_0^t H_s dW_s$$

est une martingale (sous $\mathbb{P}$). Intuition : l'intégrale accumule un bruit centré ; conditionnellement au passé, l'espérance des futurs incréments est nulle.

Exemple 2.1 (Intégrale d’une constante). Pour $H_t \equiv \sigma$, on obtient

$$\int_0^T \sigma \, dW_t = \sigma(W_T - W_0) = \sigma W_T \sim \mathcal{N}(0, \sigma^2 T).$$

La variance est $\sigma^2 T$, ce qui est cohérent avec l’isométrie d’Itô : $\mathbb{E}[(\int_0^T \sigma \, dW)^2] = \int_0^T \sigma^2 \, dt = \sigma^2 T$.

2.4 Limites et ce que le Brownien ne capture pas

Le Brownien est *continu* et *gaussien*. Or les marchés réels présentent :

- des queues plus épaisses que la normale (kurtosis) ;
- des sauts (annonces macro, gaps) ;
- de la volatilité stochastique et clustering ;
- parfois des corrélations de volatilité à court terme non triviales (“roughness”).

Ces phénomènes motivent les modèles enrichis étudiés plus tard (sauts, Heston, SABR, rough volatility).

Ce que le jury doit retenir.

- Un Brownien W_t est la limite naturelle d’une marche aléatoire rescalée ; c’est le “bruit de base” des modèles continus.
- L’intégrale d’Itô $\int H_t \, dW_t$ est définie en gelant H au début de chaque intervalle.
- L’isométrie d’Itô donne directement la variance : c’est l’outil de contrôle du risque des termes stochastiques.
- Le Brownien ne capture ni sauts ni volatilité variable : d’où les modèles de volatilité (Partie II).

Chapitre 3

Variation quadratique et lemme d'Itô

3.1 Variation quadratique : la quantité qui remplace la dérivée

Un point choc (mais essentiel) : un Brownien est continu mais *n'est pas dérivable*. Pour faire du calcul différentiel, on a besoin d'un concept qui mesure la “rugosité” d'un chemin. C'est le rôle de la *variation quadratique*.

Définition 3.1 (Variation quadratique). Soit (X_t) un processus continu. Pour une partition $\pi = \{0 = t_0 < \dots < t_n = T\}$, posez

$$V^{(2)}(X; \pi) = \sum_{k=0}^{n-1} (X_{t_{k+1}} - X_{t_k})^2.$$

Si, quand le pas de la partition $|\pi| = \max_k (t_{k+1} - t_k) \rightarrow 0$, la quantité $V^{(2)}(X; \pi)$ converge en probabilité vers une limite, on appelle cette limite la *variation quadratique* et on la note

$$[X]_T.$$

3.1.1 Exemples fondamentaux

Proposition 3.1 (Variation quadratique du Brownien). *Pour un Brownien standard (W_t) ,*

$$[W]_T = T.$$

Intuition : sur un petit intervalle Δt , on a $\Delta W \sim \mathcal{N}(0, \Delta t)$ donc typiquement $(\Delta W)^2$ est de l'ordre Δt . En sommant n termes de taille Δt sur $[0, T]$, on obtient une quantité de taille T .

Proposition 3.2 (Processus de variation finie). *Si A_t est un processus de variation finie (par exemple $A_t = \int_0^t a_s ds$ avec a intégrable), alors*

$$[A]_T = 0.$$

À quoi ça sert ? Cela sépare deux “types” d'incrémentes :

- les incréments de type dt (variation finie) ;
- les incréments de type dW (rugosité), dont le carré donne aussi du dt via la variation quadratique.

3.2 La règle $(dW)^2 = dt$ et ses conséquences

Dans les calculs heuristiques d'Itô, on utilise les ordres de grandeur :

$$\Delta W = O(\sqrt{\Delta t}), \quad (\Delta W)^2 = O(\Delta t), \quad (\Delta t)^2 = o(\Delta t), \quad \Delta t \Delta W = o(\Delta t).$$

En langage de différentiels :

$$(dW_t)^2 = dt, \quad dt dW_t = 0, \quad (dt)^2 = 0.$$

Ces règles ne sont pas de la magie : elles viennent exactement de la variation quadratique.

3.3 Dérivation détaillée du lemme d'Itô (1D)

Théorème 3.1 (Lemme d'Itô (1D)). *Soit (X_t) solution de l'équation différentielle stochastique*

$$dX_t = a(t, X_t) dt + b(t, X_t) dW_t,$$

et soit $f(t, x)$ une fonction $C^{1,2}$ (une dérivée en t , deux en x). Alors le processus $Y_t = f(t, X_t)$ vérifie

$$dY_t = \frac{\partial f}{\partial t}(t, X_t) dt + \frac{\partial f}{\partial x}(t, X_t) dX_t + \frac{1}{2} \frac{\partial^2 f}{\partial x^2}(t, X_t) (dX_t)^2,$$

avec la règle $(dX_t)^2 = b(t, X_t)^2 dt$. En développant :

$$df(t, X_t) = \left(\frac{\partial f}{\partial t} + a \frac{\partial f}{\partial x} + \frac{1}{2} b^2 \frac{\partial^2 f}{\partial x^2} \right) dt + b \frac{\partial f}{\partial x} dW_t.$$

3.3.1 Preuve (pas à pas, niveau M1)

On considère une partition $0 = t_0 < \dots < t_n = T$ et on note $\Delta X_k = X_{t_{k+1}} - X_{t_k}$, $\Delta t_k = t_{k+1} - t_k$. Sur chaque intervalle, on fait un Taylor à l'ordre 2 en x et à l'ordre 1 en t :

$$f(t_{k+1}, X_{t_{k+1}}) - f(t_k, X_{t_k}) = f_t(t_k, X_{t_k}) \Delta t_k + f_x(t_k, X_{t_k}) \Delta X_k + \frac{1}{2} f_{xx}(t_k, X_{t_k}) (\Delta X_k)^2 + \text{reste}.$$

Le reste contient des termes d'ordre $(\Delta t_k)^2$, $\Delta t_k \Delta X_k$, et $(\Delta X_k)^3$ (plus précisément, il est $o(\Delta t_k) + o((\Delta X_k)^2)$). Or $\Delta X_k \approx a \Delta t_k + b \Delta W_k$. Donc :

$$(\Delta X_k)^2 = a^2 (\Delta t_k)^2 + 2ab \Delta t_k \Delta W_k + b^2 (\Delta W_k)^2.$$

Quand on somme sur k et que $|\pi| \rightarrow 0$:

- $\sum a^2 (\Delta t_k)^2 \rightarrow 0$ (car $(\Delta t)^2$ est négligeable) ;
- $\sum 2ab \Delta t_k \Delta W_k \rightarrow 0$ en probabilité (ordre $\Delta t^{3/2}$) ;
- $\sum b^2 (\Delta W_k)^2 \rightarrow \int_0^T b(t, X_t)^2 dt$ grâce à $[W]_T = T$.

Ainsi, le seul terme d'ordre 1 qui survit dans $(\Delta X_k)^2$ est $b^2 (\Delta W)^2 \sim b^2 \Delta t$, d'où le fameux $\frac{1}{2} f_{xx} b^2 dt$. En passant à la limite, on obtient l'identité différentielle.

3.4 Version multidimensionnelle (utilité pratique)

Théorème 3.2 (Itô multidimensionnel (énoncé)). *Soit $X_t \in \mathbb{R}^d$ solution de*

$$dX_t = a(t, X_t) dt + \Sigma(t, X_t) dW_t,$$

où $W_t \in \mathbb{R}^m$ est un Brownien m -dimensionnel et Σ est une matrice $d \times m$. Pour $f(t, x)$ de classe $C^{1,2}$,

$$df(t, X_t) = \frac{\partial f}{\partial t} dt + \nabla f^\top dX_t + \frac{1}{2} \text{Tr}(\Sigma \Sigma^\top \nabla^2 f) dt.$$

À quoi ça sert ? Dès qu'on modélise plusieurs facteurs (spot + variance, taux + volatilité, etc.), c'est cette version qui s'applique.

3.5 Exemples classiques en finance

Exemple 3.1 (Logarithme d’une diffusion multiplicative). Supposons S_t tel que

$$dS_t = \mu S_t dt + \sigma S_t dW_t.$$

On pose $X_t = \log S_t$ et $f(s) = \log s$. On a $f'(s) = 1/s$ et $f''(s) = -1/s^2$. Par Itô :

$$d \log S_t = \frac{1}{S_t} dS_t + \frac{1}{2} \left(-\frac{1}{S_t^2} \right) (dS_t)^2.$$

Or $(dS_t)^2 = \sigma^2 S_t^2 dt$. Donc

$$d \log S_t = \mu dt + \sigma dW_t - \frac{1}{2} \sigma^2 dt = \left(\mu - \frac{1}{2} \sigma^2 \right) dt + \sigma dW_t.$$

Conclusion : $\log S_t$ est une gaussienne (donc S_t est lognormale), base de Black–Scholes.

Exemple 3.2 (Exponentielle martingale). Pour un Brownien W_t et une constante θ , définissons

$$M_t = \exp\left(\theta W_t - \frac{1}{2} \theta^2 t\right).$$

Avec $f(t, w) = \exp(\theta w - \frac{1}{2} \theta^2 t)$, Itô donne

$$dM_t = \theta M_t dW_t,$$

donc M_t est une martingale (car son drift est nul). Ce type de construction est au cœur des changements de mesure (Girsanov) utilisés en pricing risque-neutre.

3.6 Limites et hypothèses

Le lemme d’Itô s’applique aux *semi-martingales* (dont les diffusions classiques). Il ne s’applique pas directement à certains modèles “rough” construits avec un Brownien fractionnaire ($H \neq 1/2$) : on y revient en Partie II.

Ce que le jury doit retenir.

- La variation quadratique est la clé qui remplace la dérivée : $[W]_T = T$.
- Les règles $dt dW = 0$ et $(dW)^2 = dt$ sont la traduction calculatoire de la variation quadratique.
- Le lemme d’Itô ajoute un terme $\frac{1}{2} f_{xx} b^2 dt$: c’est le point qui distingue calcul stochastique et calcul classique.
- En finance, il explique pourquoi une diffusion multiplicative mène à une loi lognormale (log de S_t gaussien).

Chapitre 4

Pricing risque-neutre, réplication et PDE de Black–Scholes

4.1 Le problème financier

Une option est un contrat qui dépend d'un sous-jacent S_T à maturité. Le problème est de déterminer un prix “juste” aujourd'hui V_0 :

- **Objectif** : éviter l'arbitrage (pas de profit sans risque et sans capital).
- **Entrées** : dynamique du sous-jacent, taux, dividendes, payoff.
- **Sorties** : prix V_t et sensibilités (greeks) pour couvrir.

Deux philosophies coexistent mais sont en fait équivalentes (en marchés complets) :

- a) *Réplication* : construire un portefeuille auto-financé qui reproduit le payoff.
- b) *Risque-neutre* : calculer une espérance sous une probabilité $\mathbb{Q}$ où les actifs actualisés sont des martingales.

4.2 Modèle Black–Scholes (hypothèses)

On suppose :

- un marché **frictionless** (pas de coûts, pas de contraintes) ;
- possibilité de trader en continu ;
- taux sans risque constant r et dividend yield constant q ;
- sous-jacent diffusif :

$$dS_t = (r - q)S_t dt + \sigma S_t dW_t^{\mathbb{Q}}.$$

La présence de $r - q$ dans le drift sous $\mathbb{Q}$ sera justifiée ci-dessous. Sous la probabilité historique $\mathbb{P}$, on écrirait plutôt $dS_t = \mu S_t dt + \sigma S_t dW_t^{\mathbb{P}}$ avec μ inconnu et variable ; la magie du risque-neutre est de l'éliminer du pricing.

4.3 Dérivation PDE par portefeuille de couverture

Soit $V(t, S)$ le prix d'une option européenne (fonction suffisamment régulière). Appliquons Itô à $V(t, S_t)$:

$$dV = \frac{\partial V}{\partial t} dt + \frac{\partial V}{\partial S} dS + \frac{1}{2} \frac{\partial^2 V}{\partial S^2} (dS)^2.$$

Or $(dS)^2 = \sigma^2 S^2 dt$ (car $(dW)^2 = dt$), donc

$$dV = \left(\frac{\partial V}{\partial t} + (r - q)S \frac{\partial V}{\partial S} + \frac{1}{2} \sigma^2 S^2 \frac{\partial^2 V}{\partial S^2} \right) dt + \sigma S \frac{\partial V}{\partial S} dW^{\mathbb{Q}}.$$

4.3.1 Portefeuille auto-financé

Considérons un portefeuille

$$\Pi_t = V(t, S_t) - \Delta_t S_t,$$

c'est-à-dire : *long* une option, *short* Δ_t actions. Son différentiel est

$$d\Pi = dV - \Delta dS \quad (\text{auto-financement : on ajuste } \Delta \text{ en réinvestissant dans le portefeuille}).$$

Substitution :

$$d\Pi = \left(\frac{\partial V}{\partial t} + (r - q)S \frac{\partial V}{\partial S} + \frac{1}{2} \sigma^2 S^2 \frac{\partial^2 V}{\partial S^2} \right) dt + \sigma S \frac{\partial V}{\partial S} dW - \Delta((r - q)S dt + \sigma S dW).$$

Regroupons :

$$d\Pi = \left(\frac{\partial V}{\partial t} + (r - q)S \frac{\partial V}{\partial S} + \frac{1}{2} \sigma^2 S^2 \frac{\partial^2 V}{\partial S^2} - \Delta(r - q)S \right) dt + \sigma S \left(\frac{\partial V}{\partial S} - \Delta \right) dW.$$

4.3.2 Choix du hedge : annuler le risque instantané

Choisissons

$$\Delta = \frac{\partial V}{\partial S}.$$

Alors le terme en dW disparaît :

$$d\Pi = \left(\frac{\partial V}{\partial t} + \frac{1}{2} \sigma^2 S^2 \frac{\partial^2 V}{\partial S^2} \right) dt.$$

Le portefeuille est (instantanément) *sans risque*. En absence d'arbitrage, un actif sans risque doit rapporter le taux sans risque :

$$d\Pi = r\Pi dt = r(V - S \frac{\partial V}{\partial S}) dt.$$

On obtient la PDE de Black-Scholes :

$$\boxed{\frac{\partial V}{\partial t} + \frac{1}{2} \sigma^2 S^2 \frac{\partial^2 V}{\partial S^2} + (r - q)S \frac{\partial V}{\partial S} - rV = 0}$$

avec condition terminale $V(T, S) = \text{payoff}(S)$.

À quoi ça sert ? La PDE donne :

- un cadre de valorisation (prix cohérents sans arbitrage) ;
- une façon de calculer V (analyse/PDE ou méthode numérique) ;
- la stratégie de couverture $\Delta = \partial_S V$.

4.4 Mesure risque-neutre et prix comme espérance

La PDE est un objet analytique. En finance, on préfère souvent une formule d'espérance :

$$V_0 = \mathbb{E}^{\mathbb{Q}} \left[e^{-\int_0^T r_u du} \text{payoff}(S_T) \right].$$

Avec r constant : $V_0 = e^{-rT} \mathbb{E}^{\mathbb{Q}}[\text{payoff}(S_T)]$.

4.4.1 Idée de Girsanov (sans preuves lourdes)

Sous la probabilité historique $\mathbb{P}$:

$$\frac{dS_t}{S_t} = \mu dt + \sigma dW_t^{\mathbb{P}}.$$

On définit le *prix du risque* (market price of risk)

$$\lambda = \frac{\mu - (r - q)}{\sigma}.$$

Il existe une nouvelle probabilité $\mathbb{Q}$ telle que

$$dW_t^{\mathbb{Q}} = dW_t^{\mathbb{P}} + \lambda dt$$

est un Brownien sous $\mathbb{Q}$. En remplaçant, on obtient

$$\frac{dS_t}{S_t} = (r - q) dt + \sigma dW_t^{\mathbb{Q}}.$$

Conclusion : sous $\mathbb{Q}$, le drift “physique” μ disparaît au profit de $r - q$.

4.4.2 Feynman–Kac : PDE $\leftrightarrow$ espérance

Théorème 4.1 (Feynman–Kac (version utile ici)). *Considérons la PDE*

$$\frac{\partial V}{\partial t} + \mathcal{L}V - rV = 0, \quad V(T, \cdot) = g(\cdot),$$

où $\mathcal{L}$ est le générateur de la diffusion S_t sous $\mathbb{Q}$. Alors la solution s’écrit

$$V(t, S_t) = \mathbb{E}^{\mathbb{Q}} \left[\exp \left(- \int_t^T r du \right) g(S_T) \mid \mathcal{F}_t \right].$$

Intuition : la PDE impose exactement que le processus actualisé $e^{-\int_0^t r du} V(t, S_t)$ soit une martingale, ce qui force sa valeur actuelle à être l’espérance conditionnelle de sa valeur terminale actualisée.

Exemple 4.1 (Prix d’un zéro-coupon en taux constant). Un zéro-coupon paye 1 à T . Sous taux constant r , sa valeur est

$$P(0, T) = e^{-rT}.$$

Ce résultat se retrouve :

- par réplication (placer 1 euro à r) ;
- par Feynman–Kac : $V_0 = \mathbb{E}^{\mathbb{Q}}[e^{-rT} \cdot 1] = e^{-rT}$.

4.5 Limites du cadre Black–Scholes

Les hypothèses qui “cassent” en pratique :

- volatilité constante σ (les marchés ont une surface $\sigma_{\text{imp}}(K, T)$) ;
- trading continu sans coûts (en réalité hedging discret + coûts) ;
- distribution lognormale (sous-estime les queues et l’asymétrie) ;
- marché complet (dès qu’on ajoute des facteurs non tradables, la réplication parfaite peut échouer).

Ces limites motivent la calibration de surfaces et des modèles plus riches (Partie II) et le hedging discret/risk-aware (Partie III).

Ce que le jury doit retenir.

- La PDE Black–Scholes vient d’un portefeuille *option* – Δ *actions* avec $\Delta = \partial_S V$.
- En absence d’arbitrage, un portefeuille sans risque doit croître au taux r : cela force la PDE.
- La mesure risque-neutre $\mathbb{Q}$ remplace le drift μ par $r - q$ et permet une formule d’espérance.
- PDE et espérance sont deux faces de la même pièce (Feynman–Kac).

Chapitre 5

Changement de mesure & numéraires : pourquoi $\mathbb{Q}$ n'est pas une “astuce”

Ce chapitre approfondit la mécanique derrière la mesure risque-neutre. En M1, on voit souvent apparaître $\mathbb{Q}$ comme une “mesure magique” qui permet d'écrire $V_0 = \mathbb{E}^{\mathbb{Q}}[\text{payoff actualisé}]$. L'objectif ici est de comprendre précisément :

- a) *ce qui change* quand on passe de $\mathbb{P}$ à $\mathbb{Q}$;
- b) *pourquoi* ce changement est nécessaire (absence d'arbitrage) ;
- c) *comment* choisir un numéraire adapté (zéro-coupon, money-market, forward measure) ;
- d) *quelles limites* : marchés incomplets, risques non couvrables, choix non-unique de mesure.

5.1 Mesure physique $\mathbb{P}$ vs mesure de pricing

5.1.1 Deux questions différentes

- **Prévision (statistique)** : “Quelle est la distribution future de S_T ?” $\Rightarrow$ on travaille naturellement sous $\mathbb{P}$ (mesure “réelle”).
- **Valorisation (absence d'arbitrage)** : “Quel est le prix aujourd'hui d'un payoff $g(S_T)$?” $\Rightarrow$ on veut un prix cohérent avec la possibilité de couverture/ réplication.

Le point clé : *le prix d'un dérivé n'est pas l'espérance sous $\mathbb{P}$* , car un prix doit incorporer l'actualisation et la rémunération du risque. Dans un marché complet (comme Black-Scholes), l'absence d'arbitrage force un prix unique, et ce prix s'écrit comme une espérance sous une mesure de martingale.

5.1.2 Le rôle de la prime de risque

Sous $\mathbb{P}$, la dynamique d'un sous-jacent risqué (avec dividendes continus q) s'écrit typiquement

$$\frac{dS_t}{S_t} = \mu dt + \sigma dW_t^{\mathbb{P}}.$$

Le paramètre μ *n'est pas* observable de manière stable à partir des prix instantanés : il mélange anticipation et prime de risque. En revanche, les options liquides révèlent principalement *la distribution risque-neutre* et donc la volatilité implicite, beaucoup plus stable à court terme.

5.2 Numéraire et principe de martingale

5.2.1 Définition

Définition 5.1 (Numéraire). Un *numéraire* N_t est un actif strictement positif utilisé comme unité de compte. On exprime les prix relatifs $\tilde{X}_t = X_t/N_t$.

Exemples :

- **Money-market** $B_t = \exp(\int_0^t r_u du)$ (compte bancaire).
- **Zéro-coupon** $P(t, T)$ comme numéraire (utile pour produits de taux).
- **Actif risqué** S_t comme numéraire (utile pour certains changements de mesure en FX).

5.2.2 Théorème (version utilisable en M1)

Théorème 5.1 (Principe de martingale associé à un numéraire). *Supposons absence d'arbitrage. Alors, pour un numéraire N_t , il existe une mesure $\mathbb{Q}^N$ telle que*

$$\frac{X_t}{N_t} \text{ est une martingale sous } \mathbb{Q}^N$$

pour tout actif admissible X (ou au moins pour la classe de payoffs considérés). En particulier, le prix à t d'un payoff X_T s'écrit

$$X_t = N_t \mathbb{E}^{\mathbb{Q}^N} \left[\frac{X_T}{N_T} \mid \mathcal{F}_t \right].$$

À quoi ça sert ?

- Choisir le bon numéraire simplifie souvent les calculs (par exemple, sous la *forward measure*, un forward devient une martingale).
- Cela clarifie que “la mesure de pricing” dépend d'un choix d'unité de compte.

5.3 Girsanov (intuition + formule)

5.3.1 Intuition : absorber un drift

Dans un modèle de diffusion, changer de mesure revient à *modifier le drift* du Brownien. On garde la même volatilité, mais on “décale” le mouvement aléatoire pour que des prix actualisés deviennent martingales.

5.3.2 Énoncé (cas 1D)

Soit $W_t^{\mathbb{P}}$ un Brownien sous $\mathbb{P}$ et soit un processus adapté (θ_t) . Définissons la densité de Radon–Nikodym

$$\frac{d\mathbb{Q}}{d\mathbb{P}} \Big|_{\mathcal{F}_T} = \exp \left(- \int_0^T \theta_u dW_u^{\mathbb{P}} - \frac{1}{2} \int_0^T \theta_u^2 du \right).$$

Alors, sous $\mathbb{Q}$, le processus

$$W_t^{\mathbb{Q}} := W_t^{\mathbb{P}} + \int_0^t \theta_u du$$

est un Brownien.

Lecture financière : θ est le *prix du risque* (market price of risk) : il relie la dérive réelle μ au drift risque-neutre $r - q$.

5.3.3 Application à Black–Scholes

Sous $\mathbb{P}$: $dS_t = \mu S_t dt + \sigma S_t dW_t^{\mathbb{P}}$. On veut sous $\mathbb{Q}$: $dS_t = (r - q)S_t dt + \sigma S_t dW_t^{\mathbb{Q}}$. En identifiant :

$$dW_t^{\mathbb{Q}} = dW_t^{\mathbb{P}} + \theta dt, \quad \text{avec } \theta = \frac{\mu - (r - q)}{\sigma}.$$

On voit explicitement : passer à $\mathbb{Q}$ retire la prime de risque $\mu - (r - q)$.

Exemple 5.1 (Mini-exemple chiffré). Prenons $\mu = 10\%$, $r = 3\%$, $q = 1\%$, $\sigma = 20\%$. Alors $\theta = \frac{0.10 - (0.03 - 0.01)}{0.20} = \frac{0.08}{0.20} = 0.4$. Sous $\mathbb{Q}$, le Brownien “avance” en moyenne de $-0.4 dt$ par rapport à celui sous $\mathbb{P}$. Ce n’est pas une correction “petite” : cela illustre pourquoi un prix ne peut pas être une espérance sous $\mathbb{P}$.

5.4 Forward measure : quand un forward devient une martingale

5.4.1 Forward price et numéraire

Le *forward* de maturité T (sur action avec dividendes continus) vaut

$$F(t, T) = S_t \exp((r - q)(T - t)).$$

Sous la mesure $\mathbb{Q}$ associée au money-market, $F(t, T)$ n’est pas forcément une martingale car il contient explicitement la croissance à $r - q$.

Si l’on prend comme numéraire le zéro-coupon $P(t, T)$, on travaille sous la T -forward measure $\mathbb{Q}^T$. Dans ce cadre, des quantités exprimées en unités de $P(t, T)$ deviennent martingales. Pour un produit dont le payoff est payé à T , cela simplifie :

$$V_t = P(t, T) \mathbb{E}^{\mathbb{Q}^T}[\text{payoff} \mid \mathcal{F}_t].$$

5.4.2 À quoi ça sert concrètement ?

- En **taux**, beaucoup d’instruments payent à une date précise (swaplets, caplets). La forward measure évite des termes d’actualisation complexes.
- En **FX**, choisir comme numéraire l’actif domestique vs étranger clarifie le drift du taux de change.

5.5 Limites : marchés incomplets et non-unicité de $\mathbb{Q}$

Dès qu’un modèle contient des risques non tradables (volatilité stochastique, sauts, illiquidité), la réplication parfaite échoue : le marché devient *incomplet*. Alors :

- il peut exister une *infinité* de mesures de martingale ;
- le prix n’est plus unique sans un critère additionnel (préférence, risque, minimal martingale measure, entropie minimale, etc.).

Dans la pratique, la calibration à la surface d’options sélectionne implicitement une mesure de pricing “compatible” avec les prix.

Ce que le jury doit retenir.

- $\mathbb{P}$ répond à “que va-t-il se passer ?” ; $\mathbb{Q}$ répond à “combien ça vaut sans arbitrage ?”.
- Un numéraire N_t définit une mesure $\mathbb{Q}^N$ telle que X_t/N_t est une martingale.
- Girsanov montre explicitement que changer de mesure modifie le drift : $\theta = (\mu - (r - q))/\sigma$ en BS.
- En marché incomplet, $\mathbb{Q}$ n’est plus unique : la calibration et/ou un critère de risque complète la théorie.




FIGURE 5.1 – Lecture opérationnelle : $\mathbb{P}$ pour prévoir, une mesure de martingale ($\mathbb{Q}$, $\mathbb{Q}^T$, etc.) pour pricer, en fonction du numéraire.

Chapitre 6

Options vanilles : formule de Black–Scholes et greeks

6.1 Payoffs européens et parité put–call

Définition 6.1 (Call/Put européens). À maturité T , avec strike K :

$$\text{Call} : (S_T - K)^+ = \max(S_T - K, 0), \quad \text{Put} : (K - S_T)^+ = \max(K - S_T, 0).$$

Proposition 6.1 (Parité put–call (avec dividendes continus)). Pour des options européennes de même K, T ,

$$C_0 - P_0 = S_0 e^{-qT} - K e^{-rT}.$$

Intuition : un call et un put diffèrent exactement d'un forward. En effet, $\text{Call} - \text{Put} = S_T - K$ (vérifier cas par cas), donc en actualisant : $C_0 - P_0 = \text{PV}(S_T) - \text{PV}(K) = S_0 e^{-qT} - K e^{-rT}$.

6.2 Distribution lognormale sous $\mathbb{Q}$

Sous Black–Scholes et sous la mesure risque-neutre :

$$\frac{dS_t}{S_t} = (r - q)dt + \sigma dW_t^{\mathbb{Q}}.$$

En appliquant Itô à $\log S_t$ (voir section 3.5) :

$$d \log S_t = \left((r - q) - \frac{1}{2} \sigma^2 \right) dt + \sigma dW_t^{\mathbb{Q}}.$$

En intégrant de 0 à T :

$$\log S_T = \log S_0 + \left((r - q) - \frac{1}{2} \sigma^2 \right) T + \sigma W_T^{\mathbb{Q}}.$$

Comme $W_T^{\mathbb{Q}} \sim \mathcal{N}(0, T)$, on obtient

$$\log S_T \sim \mathcal{N} \left(\log S_0 + \left((r - q) - \frac{1}{2} \sigma^2 \right) T, \sigma^2 T \right).$$

6.3 Dérivation détaillée de la formule Black–Scholes (par espérance)

Le prix d'un call européen est

$$C_0 = e^{-rT} \mathbb{E}^{\mathbb{Q}} \left[(S_T - K)^+ \right].$$

On utilise l'identité $(S_T - K)^+ = S_T \mathbb{1}_{S_T > K} - K \mathbb{1}_{S_T > K}$:

$$C_0 = e^{-rT} \left(\mathbb{E}^{\mathbb{Q}}[S_T \mathbb{1}_{S_T > K}] - K \mathbb{Q}(S_T > K) \right).$$

On va calculer séparément les deux termes.

6.3.1 Étape 1 : calcul de $\mathbb{Q}(S_T > K)$

Définissons

$$Y = \log S_T.$$

On sait que $Y \sim \mathcal{N}(m, s^2)$ avec

$$m = \log S_0 + \left((r - q) - \frac{1}{2}\sigma^2 \right) T, \quad s = \sigma\sqrt{T}.$$

Alors

$$\mathbb{Q}(S_T > K) = \mathbb{Q}(\log S_T > \log K) = \mathbb{Q}\left(\frac{Y - m}{s} > \frac{\log K - m}{s}\right).$$

Si $Z = \frac{Y - m}{s} \sim \mathcal{N}(0, 1)$, on obtient

$$\mathbb{Q}(S_T > K) = 1 - \Phi\left(\frac{\log K - m}{s}\right) = \Phi\left(\frac{m - \log K}{s}\right).$$

En développant :

$$\frac{m - \log K}{s} = \frac{\log(S_0/K) + \left((r - q) - \frac{1}{2}\sigma^2 \right) T}{\sigma\sqrt{T}} \triangleq d_2.$$

Donc

$$\mathbb{Q}(S_T > K) = \Phi(d_2).$$

6.3.2 Étape 2 : calcul de $\mathbb{E}^{\mathbb{Q}}[S_T \mathbb{1}_{S_T > K}]$

On écrit $S_T = e^Y$. On veut $\mathbb{E}[e^Y \mathbb{1}_{Y > \log K}]$ où Y est gaussien. Une astuce standard consiste à *compléter le carré*.

La densité de Y est

$$f_Y(y) = \frac{1}{s\sqrt{2\pi}} \exp\left(-\frac{(y - m)^2}{2s^2}\right).$$

Alors

$$\mathbb{E}[e^Y \mathbb{1}_{Y > \log K}] = \int_{\log K}^{\infty} e^y f_Y(y) dy = \int_{\log K}^{\infty} \frac{1}{s\sqrt{2\pi}} \exp\left(y - \frac{(y - m)^2}{2s^2}\right) dy.$$

Regardons l'exposant :

$$y - \frac{(y - m)^2}{2s^2} = -\frac{1}{2s^2}((y - m)^2 - 2s^2 y).$$

On réécrit le terme en y :

$$(y - m)^2 - 2s^2 y = y^2 - 2my + m^2 - 2s^2 y = y^2 - 2(m + s^2)y + m^2.$$

Complétons le carré :

$$y^2 - 2(m + s^2)y + m^2 = (y - (m + s^2))^2 - (m + s^2)^2 + m^2.$$

Donc

$$y - \frac{(y-m)^2}{2s^2} = -\frac{(y-(m+s^2))^2}{2s^2} + \frac{(m+s^2)^2 - m^2}{2s^2}.$$

Or

$$\frac{(m+s^2)^2 - m^2}{2s^2} = \frac{2ms^2 + s^4}{2s^2} = m + \frac{1}{2}s^2.$$

Ainsi

$$\exp\left(y - \frac{(y-m)^2}{2s^2}\right) = \exp\left(m + \frac{1}{2}s^2\right) \cdot \exp\left(-\frac{(y-(m+s^2))^2}{2s^2}\right).$$

On obtient

$$\mathbb{E}[e^Y \mathbb{1}_{Y > \log K}] = \exp\left(m + \frac{1}{2}s^2\right) \int_{\log K}^{\infty} \frac{1}{s\sqrt{2\pi}} \exp\left(-\frac{(y-(m+s^2))^2}{2s^2}\right) dy.$$

Mais l'intégrale est une probabilité gaussienne : si $Y' \sim \mathcal{N}(m+s^2, s^2)$, alors

$$\int_{\log K}^{\infty} f_{Y'}(y) dy = \mathbb{Q}(Y' > \log K) = \Phi\left(\frac{(m+s^2) - \log K}{s}\right).$$

On définit

$$d_1 = \frac{(m+s^2) - \log K}{s} = \frac{\log(S_0/K) + \left((r-q) + \frac{1}{2}\sigma^2\right)T}{\sigma\sqrt{T}}.$$

Donc

$$\mathbb{E}^{\mathbb{Q}}[S_T \mathbb{1}_{S_T > K}] = \exp\left(m + \frac{1}{2}s^2\right) \Phi(d_1).$$

Enfin, $\exp(m + \frac{1}{2}s^2) = \mathbb{E}[e^Y] = \mathbb{E}[S_T] = S_0 e^{(r-q)T}$ sous $\mathbb{Q}$. Ainsi

$$\mathbb{E}^{\mathbb{Q}}[S_T \mathbb{1}_{S_T > K}] = S_0 e^{(r-q)T} \Phi(d_1).$$

6.3.3 Formule finale

On injecte dans C_0 :

$$C_0 = e^{-rT} \left(S_0 e^{(r-q)T} \Phi(d_1) - K \Phi(d_2) \right) = S_0 e^{-qT} \Phi(d_1) - K e^{-rT} \Phi(d_2).$$

$$C_0 = S_0 e^{-qT} \Phi(d_1) - K e^{-rT} \Phi(d_2), \quad d_{1,2} = \frac{\log(S_0/K) + (r-q \pm \frac{1}{2}\sigma^2)T}{\sigma\sqrt{T}}.$$

Et par parité put-call :

$$P_0 = K e^{-rT} \Phi(-d_2) - S_0 e^{-qT} \Phi(-d_1).$$

6.4 Greeks : définitions, calculs et interprétation

Définition 6.2 (Greeks principaux). Pour une option de prix $V(S, t; \theta)$ (où θ regroupe les paramètres), on définit :

$$\Delta = \frac{\partial V}{\partial S}, \quad \Gamma = \frac{\partial^2 V}{\partial S^2}, \quad \text{Vega} = \frac{\partial V}{\partial \sigma}, \quad \Theta = \frac{\partial V}{\partial t}, \quad \rho = \frac{\partial V}{\partial r}.$$

6.4.1 Delta et gamma (les plus importants pour le hedging)

Pour un call BS :

$$\Delta_{\text{call}} = e^{-qT} \Phi(d_1), \quad \Delta_{\text{put}} = e^{-qT} (\Phi(d_1) - 1).$$

Interprétation : Δ est la quantité d’actions à short/long pour neutraliser le risque instantané dW . C’est le hedge “de premier ordre”.

La densité normale standard est $\varphi(x) = \frac{1}{\sqrt{2\pi}} \exp(-x^2/2)$. On obtient

$$\Gamma = \frac{\partial \Delta}{\partial S} = \frac{e^{-qT} \varphi(d_1)}{S \sigma \sqrt{T}}.$$

Interprétation : Γ mesure la variation de Δ quand S bouge. Un portefeuille “gamma” important nécessite de rebalancer souvent.

6.4.2 Vega (sensibilité à la volatilité)

Pour call ou put :

$$\text{Vega} = \frac{\partial V}{\partial \sigma} = S_0 e^{-qT} \varphi(d_1) \sqrt{T}.$$

Interprétation : vega est maximale à la monnaie et augmente avec $\sqrt{T}$. Elle est cruciale pour l’inversion de volatilité implicite (Newton) et la calibration.

6.4.3 Theta et rho

Les expressions explicites existent, mais ce qui compte surtout en pratique :

- Θ capture l’érosion temporelle : à paramètres fixes, un call perd de la valeur quand T diminue (sauf effets particuliers).
- ρ mesure l’effet du taux sur la valeur actualisée du strike.

Exemple 6.1 (Exemple chiffré simple). Prenons $S_0 = 100$, $K = 100$, $T = 1$, $r = 3\%$, $q = 0$, $\sigma = 20\%$. Alors

$$d_1 = \frac{\log(1) + (0.03 + 0.5 \cdot 0.2^2)}{0.2} = \frac{0.03 + 0.02}{0.2} = 0.25, \quad d_2 = d_1 - 0.2 = 0.05.$$

Avec $\Phi(0.25) \approx 0.5987$ et $\Phi(0.05) \approx 0.5199$:

$$C_0 \approx 100 \cdot 0.5987 - 100e^{-0.03} \cdot 0.5199 \approx 59.87 - 50.44 \approx 9.43.$$

Delta call ≈ 0.5987 . Gamma $\approx \frac{\varphi(0.25)}{100 \cdot 0.2} \approx \frac{0.3867}{20} \approx 0.0193$. Vega $\approx 100 \varphi(0.25) \sqrt{1} \approx 38.67$ (par unité de volatilité, i.e. pour σ en absolu).

6.5 Limites pratiques des greeks BS

Les greeks Black–Scholes sont *modèle-dépendants*. Deux sources d’erreur dominantes :

- la volatilité n’est pas constante : la vraie sensibilité est à la surface $\sigma_{\text{imp}}(K, T)$;
- hedging discret et coûts : même un Δ parfait instantanément ne garantit pas un PnL neutre à horizon fini.

Ce que le jury doit retenir.

- Sous Black–Scholes, $\log S_T$ est normal : cela permet une dérivation par espérance sans résoudre la PDE.
- Formule call : $C_0 = S_0 e^{-qT} \Phi(d_1) - K e^{-rT} \Phi(d_2)$, avec $d_1 - d_2 = \sigma \sqrt{T}$.
- $\Delta = \partial_S V$ est la quantité d’actions pour neutraliser le risque instantané ; Γ mesure la courbure et le besoin de rebalancing.
- Vega est centrale pour la volatilité implicite et la calibration.

Chapitre 7

Volatilité implicite : définition, inversion numérique et stabilité

7.1 Pourquoi introduire la volatilité implicite ?

Les desks options ne quotent pas directement des prix en euros sur chaque strike/maturité, car :

- les niveaux de spot et de taux changent, ce qui déforme les prix ;
- les options ITM/OTM ont des prix très différents, peu comparables ;
- la volatilité est un paramètre plus “stable” et plus parlant (niveau de risque).

On convertit donc un prix de marché en une *volatilité implicite* : la volatilité BS qui reproduit ce prix.

7.2 Définition formelle

Définition 7.1 (Volatilité implicite). Soit $C_{\text{mkt}}(K, T)$ un prix de call observé (après ajustements éventuels). La *volatilité implicite* $\sigma_{\text{imp}}(K, T)$ est la solution (si elle existe) de

$$C_{\text{mkt}}(K, T) = \text{BS}_{\text{call}}(S_0, K, r, q, T; \sigma_{\text{imp}}).$$

De même pour un put.

7.2.1 Existence et unicité : monotonie en σ

En Black–Scholes, pour un call ou put européen,

$$\frac{\partial V}{\partial \sigma} = \text{Vega} > 0$$

(sauf limites dégénérées). Donc $V(\sigma)$ est strictement croissant en σ : si un prix mkt est compatible avec l’intervalle des prix BS, la solution est unique.

Remarque 7.1 (Bornes de non-arbitrage (rappel utile)). Pour un call européen (avec dividendes continus), les bornes simples sont

$$\max(0, S_0 e^{-qT} - K e^{-rT}) \leq C_0 \leq S_0 e^{-qT}.$$

Si un prix observé viole ces bornes, l’“implied vol” n’existe pas (ou signale un problème de données).

7.3 Inversion numérique : bisection, Newton, et pièges

On veut résoudre l'équation $f(\sigma) = \text{BS}(\sigma) - C_{\text{mkt}} = 0$.

7.3.1 Méthode de dichotomie (bisection)

Principe : si f est continue et monotone, on encadre la racine dans $[\sigma_{\min}, \sigma_{\max}]$. On itère :

$$\sigma_{\text{mid}} = \frac{\sigma_{\min} + \sigma_{\max}}{2},$$

et on remplace l'intervalle par la moitié qui contient le changement de signe. **Avantage :** robuste (converge toujours). **Inconvénient :** convergence linéaire (plus lente).

7.3.2 Méthode de Newton

Principe : linéariser f autour de σ_n :

$$f(\sigma) \approx f(\sigma_n) + f'(\sigma_n)(\sigma - \sigma_n).$$

On impose $f(\sigma_{n+1}) \approx 0$, donc

$$\sigma_{n+1} = \sigma_n - \frac{f(\sigma_n)}{f'(\sigma_n)} = \sigma_n - \frac{\text{BS}(\sigma_n) - C_{\text{mkt}}}{\text{Vega}(\sigma_n)}.$$

Avantage : convergence quadratique près de la solution. **Inconvénient :** peut diverger si l'initialisation est mauvaise ou si Vega est très petite.

7.3.3 Heuristiques d'initialisation

Un choix typique :

- commencer à $\sigma_0 = 20\%$ ou $\sigma_0 = \sqrt{\frac{2|\log(S_0/K)|}{T}}$ (ordre de grandeur) ;
- borner σ dans $[\sigma_{\min}, \sigma_{\max}]$ (par exemple $[10^{-4}, 5]$ en absolu) ;
- combiner Newton avec bisection ("safeguarded Newton") : si Newton sort de l'intervalle, on fait une étape de bisection.

7.3.4 Pseudo-code d'un Newton sécurisé

Listing 7.1 – Newton sécurisé pour volatilité implicite (pseudo-code).

```
1  Input: price C_mkt, initial sigma0, bounds [a,b]
2  for n = 1..Nmax:
3      C = BS_price(sigma)
4      v = BS_vega(sigma)
5      if abs(C - C_mkt) < tol: break
6      sigma_new = sigma - (C - C_mkt)/max(v, v_floor)
7      if sigma_new < a or sigma_new > b:
8          sigma_new = 0.5*(a+b) # fallback: bisection
9      # update bracket using monotonicity
10     if BS_price(sigma_new) > C_mkt: b = sigma_new else a = sigma_new
11     sigma = sigma_new
12  return sigma
```

7.4 Stabilité : quand l’implié vol devient “mauvais” numériquement

La difficulté majeure vient de Vega :

$$\text{Vega} = S_0 e^{-qT} \varphi(d_1) \sqrt{T}.$$

Donc Vega est petite :

- pour des maturités très courtes ($\sqrt{T}$) ;
- pour des options très ITM/OTM (car $\varphi(d_1)$ devient minuscule).

Dans ces zones, un écart de prix minuscule correspond à une variation énorme de σ : l’inversion est *mal conditionnée*. Il faut donc :

- contrôler la qualité des prix (bid/ask, erreurs) ;
- préférer des métriques robustes (ex. travailler en prix plutôt qu’en IV pour la calibration, ou pondérer par vega) ;
- utiliser des bornes et des méthodes robustes.

Exemple 7.1 (Illustration de mal-conditionnement). Considérons une option très OTM : $S_0 = 100$, $K = 200$, $T = 0.05$ (environ 12 jours), $r = q = 0$. Le prix est très proche de 0 ; deux feeds peuvent donner $C_{\text{mkt}} = 0.0005$ ou 0.0010 . Ces deux prix correspondent à des volatilités implicites très différentes, car la courbe $C(\sigma)$ est quasi plate près de 0. Conclusion : l’implié vol “explose” en bruit.

Ce que le jury doit retenir.

- La volatilité implicite est définie par inversion de Black–Scholes ; elle n’est pas une volatilité “réelle”.
- Unicité : $\text{BS}(\sigma)$ est croissante en σ car $\text{Vega} > 0$.
- Newton : $\sigma_{n+1} = \sigma_n - (\text{BS}(\sigma_n) - C_{\text{mkt}}) / \text{Vega}(\sigma_n)$, rapide mais fragile.
- Zones dangereuses : très court terme et extrêmes strikes (vega faible) $\Rightarrow$ inversion mal conditionnée.

Deuxième partie

Surface de volatilité & calibration
(cœur “quant”)

Chapitre 8

Surface d'impliéd volatility : construction, smile/skew et arbitrage

8.1 Pourquoi une surface existe-t-elle ? (smile, skew)

Dans Black–Scholes, une seule volatilité σ suffit pour tous les strikes et maturités. En réalité, si l'on calcule $\sigma_{\text{imp}}(K, T)$ pour chaque option cotée, on observe :

- un **smile** (vol plus élevée loin de la monnaie) ;
- un **skew** (asymétrie : vol plus forte pour puts OTM sur indices actions) ;
- une dépendance à la maturité (*term structure*).

Ces phénomènes reflètent des caractéristiques réelles des rendements : asymétrie (crashes plus violents), queues épaisses, volatilité stochastique, sauts, et effets d'offre/demande (couverture des investisseurs).

8.2 Coordonnées de la surface : strike, moneyness, delta

Plusieurs axes sont utilisés en pratique :

- **Strike** K : naturel mais peu comparable quand S_0 change.
- **Log-moneyness** $k = \log(K/F_{0,T})$: centré sur le forward $F_{0,T}$, plus stable.
- **Delta** : on indexe la smile par la delta BS (ex. 25-delta put/call), pratique pour FX.

Définition 8.1 (Forward et log-moneyness). Sous taux/dividendes constants, le forward est $F_{0,T} = S_0 e^{(r-q)T}$. On définit souvent

$$k = \log \left(\frac{K}{F_{0,T}} \right).$$

La monnaie correspond à $k = 0$ (i.e. $K = F_{0,T}$).

8.3 No-arbitrage : contraintes simples et intuition

Une surface n'est pas qu'un interpolateur : elle doit éviter de créer des opportunités d'arbitrage. Deux familles d'arbitrages sont classiques : **butterfly** (en strike) et **calendar** (en maturité).

8.3.1 Arbitrage en strike : convexité des prix

Fixons T . Le prix d'un call $C(K, T)$ comme fonction de K doit vérifier :

- C décroît en K (un strike plus haut vaut moins cher) ;
- C est convexe en K (car c'est une espérance d'une fonction convexe du strike).

Formellement, si C est deux fois dérivable en K :

$$\frac{\partial C}{\partial K} \leq 0, \quad \frac{\partial^2 C}{\partial K^2} \geq 0.$$

De plus, la densité risque-neutre $f_{S_T}(K)$ est donnée par :

$$\frac{\partial^2 C}{\partial K^2}(K, T) = e^{-rT} f_{S_T}(K).$$

À quoi ça sert ? Cette identité relie directement la smile aux probabilités risque-neutres : un skew “put” reflète une masse de probabilité plus importante dans les scénarios de baisse.

8.3.2 Arbitrage en maturité : monotonie de la valeur temps

À strike fixé, un call européen ne doit pas décroître avec la maturité (hors effets de taux négatifs et dividendes particuliers). Sur la surface en volatilité, une condition pratique (pas toujours suffisante) est :

$$w(K, T) \triangleq \sigma_{\text{imp}}(K, T)^2 T \quad (\text{variance totale}) \quad \text{doit être croissante en } T.$$

Intuition : plus de temps $\Rightarrow$ plus d'incertitude cumulée (variance totale).

8.4 Interpolation et lissage : le minimum viable

On a des IV sur une grille (quelques strikes et maturités). Pour pricer des options non cotées, il faut interpoler. Le piège : une interpolation naïve en σ peut créer de l'arbitrage. Une pratique robuste consiste à travailler en variance totale $w = \sigma^2 T$:

- interpolation (souvent linéaire) en T sur w ;
- interpolation en strike (cubic spline, SVI, etc.) avec contraintes de convexité si possible.

Exemple 8.1 (Interpolation linéaire en maturité sur la variance totale). Supposons à un strike donné K :

$$\sigma_{\text{imp}}(K, T_1) = 20\%, \quad T_1 = 0.5, \quad \sigma_{\text{imp}}(K, T_2) = 18\%, \quad T_2 = 1.$$

Alors $w_1 = 0.2^2 \cdot 0.5 = 0.02$ et $w_2 = 0.18^2 \cdot 1 = 0.0324$. À $T = 0.75$, interpolation linéaire :

$$w(0.75) = w_1 + \frac{0.75 - 0.5}{1 - 0.5}(w_2 - w_1) = 0.02 + 0.5(0.0124) = 0.0262.$$

Donc $\sigma_{\text{imp}}(K, 0.75) = \sqrt{w(0.75)/0.75} \approx \sqrt{0.03493} \approx 18.7\%$.

Ce que le jury doit retenir.

- La surface $\sigma_{\text{imp}}(K, T)$ résume smile/skew/term structure observés.
- Les quotes peuvent se faire en K , log-moneyness ou delta : il faut savoir passer de l'un à l'autre.
- No-arbitrage (intuition) : en strike, les calls sont décroissants et convexes ; en maturité, la variance totale $w = \sigma^2 T$ doit typiquement croître.
- Interpoler en variance totale est souvent plus stable qu'interpoler en volatilité.

Chapitre 9

Calibration : principe général, métriques d'erreur et choix numériques

9.1 Le problème : faire coller un modèle à la surface

Un modèle (Black–Scholes, Heston, SABR, etc.) dépend de paramètres θ . La calibration consiste à choisir θ pour minimiser un écart entre :

- les prix/IV du modèle,
- et les prix/IV observés sur le marché.

Définition 9.1 (Problème de calibration (forme générique)). Soit une grille d'options $(K_i, T_i)_{i=1}^N$ avec prix de marché P_i^{mkt} . On cherche

$$\theta^* \in \arg \min_{\theta \in \Theta} \sum_{i=1}^N w_i \ell(P_i^{\text{model}}(\theta) - P_i^{\text{mkt}}),$$

où ℓ est une fonction de perte (souvent $\ell(x) = x^2$) et w_i des pondérations.

À quoi ça sert ? Sans calibration, un modèle est un exercice académique. Avec calibration, il devient un outil opérationnel :

- pricer des options illiquides (interpolation/extrapolation cohérente) ;
- extraire des paramètres interprétables (skew via ρ , vol-of-vol via ξ , etc.) ;
- générer des scénarios et mesurer des risques (VaR/CVaR) ;
- construire des stratégies (hedging, relative value).

9.2 Prix vs volatilité implicite : que minimiser ?

Deux choix usuels :

9.2.1 Calibration en prix

$$\min_{\theta} \sum_i w_i (P_i^{\text{model}}(\theta) - P_i^{\text{mkt}})^2.$$

Avantage : cohérent économiquement (euros). **Inconvénient** : les options ATM valent beaucoup plus cher que les OTM $\Rightarrow$ elles dominent la loss.

9.2.2 Calibration en volatilité implicite

On convertit prix en IV et on minimise

$$\min_{\theta} \sum_i w_i (\sigma_i^{\text{model}}(\theta) - \sigma_i^{\text{mkt}})^2.$$

Avantage : met toutes les options sur une échelle comparable. **Inconvénient :** nécessite une inversion (voir chapitre 7) et devient instable quand vega est faible.

9.2.3 Pondération par vega : une justification simple

Un argument classique : un petit écart de volatilité correspond à un écart de prix

$$\Delta P \approx \text{Vega} \cdot \Delta \sigma.$$

Donc minimiser des erreurs de volatilité revient à minimiser des erreurs de prix *pondérées* :

$$(\Delta \sigma)^2 \approx \frac{(\Delta P)^2}{\text{Vega}^2}.$$

Une pondération naturelle est donc $w_i \propto \text{Vega}_i^2$ (ou l'inverse selon convention) pour équilibrer.

9.3 Contraintes, bornes et identifiabilité

Les paramètres ont souvent des contraintes structurelles :

- volatilités et variances positives ;
- intensité de sauts $\lambda \geq 0$;
- corrélation $\rho \in [-1, 1]$;
- conditions de positivité (ex. Feller en Heston).

Identifiabilité : certains paramètres sont difficiles à estimer sur certaines grilles. Exemple : à très court terme, la vol-of-vol est peu informée ; à long terme, l'intensité de jumps peut être confondue avec la vol stochastique. C'est un point crucial : une calibration “parfaite” en loss peut produire des paramètres non robustes.

9.4 Optimisation : méthodes et compromis

9.4.1 Gradient vs derivative-free

- **Gradient-based** (Newton, quasi-Newton L-BFGS) : rapide si la loss est lisse et si on peut calculer des dérivées (ou approx par différences finies).
- **Derivative-free** (Nelder–Mead, CMA-ES, differential evolution) : robuste sur surfaces irrégulières mais plus coûteux.

9.4.2 Multi-start et minima locaux

Les calibrations non linéaires ont souvent plusieurs minima locaux. Une pratique “sérieuse” :

- lancer l'optimisation depuis plusieurs points initiaux (multi-start) ;
- imposer des bornes réalistes ;
- choisir le meilleur minimum au sens économique (et pas seulement la loss).

9.4.3 Complexité

Chaque évaluation de $P_i^{\text{model}}(\theta)$ peut coûter cher (intégrales, FFT, Monte Carlo). La calibration est donc souvent dominée par *le coût du pricing*. C'est exactement la motivation des surrogates (chapitre sur réseaux de neurones).

Exemple 9.1 (Calibration impossible : une seule σ pour deux smiles). Supposons deux prix observés à la même maturité :

$$\sigma_{\text{imp}}(K_1, T) = 15\%, \quad \sigma_{\text{imp}}(K_2, T) = 25\%.$$

Le modèle Black–Scholes avec une σ constante ne peut pas matcher simultanément les deux : il produira une unique σ . La calibration donnera un compromis (“best fit”) qui reflète la limite du modèle.

Ce que le jury doit retenir.

- La calibration est une optimisation : choisir θ pour que le modèle reproduise les prix/IV de marché.
- Choix crucial : minimiser en prix (échelle euros) ou en IV (échelle comparable mais inversion instable).
- Les pondérations (souvent via vega) ne sont pas du détail : elles déterminent *ce que* la calibration cherche à bien reproduire.
- Les contraintes et l’identifiabilité conditionnent la robustesse : une calibration “qui fit” peut être économiquement absurde si non contrainte.

Chapitre 10

Optimisation numérique pour la calibration : stabilité, régularisation, contraintes

La calibration est, en pratique, un problème d'optimisation non linéaire sous contraintes. Sur le papier, "minimiser une erreur" semble simple ; en réalité, les difficultés viennent de :

- **l'ill-conditioning** (Vega faible, paramètres peu identifiables) ;
- **les contraintes** (positivité, bornes, stabilité du modèle) ;
- **le bruit numérique** (intégrales oscillantes, FFT, discrétisation) ;
- **les minima locaux**.

Ce chapitre explicite les outils standards pour rendre une calibration reproductible.

10.1 Du problème général au cas "moindres carrés"

10.1.1 Formulation

Écrivons une erreur vecteur $r(\theta) \in \mathbb{R}^m$ (les *résidus*) telle que

$$r_i(\theta) = \begin{cases} P_i^{\text{model}}(\theta) - P_i^{\text{mkt}} & \text{si l'on calibre en prix,} \\ \sigma_i^{\text{model}}(\theta) - \sigma_i^{\text{mkt}} & \text{si l'on calibre en IV.} \end{cases}$$

Les pondérations se mettent naturellement dans une matrice diagonale $W = \text{diag}(w_1, \dots, w_m)$. Le problème devient un **moindres carrés pondéré** :

$$\min_{\theta \in \Theta} \Phi(\theta) \triangleq \frac{1}{2} \|W r(\theta)\|^2 = \frac{1}{2} \sum_{i=1}^m w_i^2 r_i(\theta)^2.$$

10.1.2 Gradient et matrice Jacobienne

Notons $J(\theta) \in \mathbb{R}^{m \times p}$ la Jacobienne des résidus :

$$(J(\theta))_{i,j} = \frac{\partial r_i}{\partial \theta_j}(\theta).$$

Par la règle de dérivation d'une norme quadratique :

$$\nabla \Phi(\theta) = J(\theta)^\top W^\top W r(\theta).$$

Le Hessien exact contient des dérivées secondes. L'approximation "Gauss-Newton" consiste à négliger ces termes :

$$\nabla^2 \Phi(\theta) \approx J(\theta)^\top W^\top W J(\theta).$$

Intuition : quand les résidus sont petits (bonne calibration), les dérivées secondes pèsent peu.

10.2 Levenberg–Marquardt : un compromis robuste

10.2.1 Le pas de Gauss–Newton

Autour de θ , on linéarise $r(\theta + \Delta) \approx r(\theta) + J\Delta$. Alors

$$\Phi(\theta + \Delta) \approx \frac{1}{2} \|W(r + J\Delta)\|^2.$$

Minimiser ce quadratique en Δ donne le système normal :

$$(J^\top W^\top W J) \Delta = -J^\top W^\top W r.$$

Si $J^\top W^\top W J$ est mal conditionnée (fréquent !), le pas devient instable.

10.2.2 Régularisation de Levenberg

Levenberg–Marquardt ajoute un terme λI :

$$(J^\top W^\top W J + \lambda I) \Delta = -J^\top W^\top W r.$$

- si $\lambda \rightarrow 0$, on retrouve Gauss–Newton (rapide près du minimum) ;
- si $\lambda \rightarrow +\infty$, on se rapproche d’une descente de gradient (plus stable, mais lente).

10.2.3 Choix adaptatif de λ

L’heuristique standard :

- proposer Δ avec un certain λ ;
- si $\Phi(\theta + \Delta)$ diminue suffisamment, accepter et *réduire* λ ;
- sinon, refuser et *augmenter* λ .

C’est ce mécanisme qui rend LM très robuste en calibration.

Listing 10.1 – Levenberg–Marquardt (schéma pédagogique)

```
1 input: theta0, lambda0>0
2 theta <- theta0 ; lambda <- lambda0
3 repeat:
4   r <- residuals(theta)
5   J <- jacobian(theta)
6   solve: (J' W' W J + lambda I) Delta = - J' W' W r
7   if Phi(theta+Delta) < Phi(theta):
8     theta <- theta + Delta
9     lambda <- lambda / 2
10  else:
11    lambda <- 2 * lambda
12 until convergence
13 output: theta
```

10.3 Contraintes : rendre l’optimisation "légale"

10.3.1 Bornes et transformations

Beaucoup de paramètres doivent rester dans un domaine : $\kappa > 0$, $\theta > 0$, $\xi > 0$, $\rho \in (-1, 1)$. Deux stratégies :

- **optimisation bornée** (L-BFGS-B, trust-region) ;
- **reparamétrisation** sans contrainte.

Exemples de reparamétrisation :

$$\kappa = e^a, \quad \theta = e^b, \quad \xi = e^c, \quad \rho = \tanh(d).$$

Alors on optimise sur $(a, b, c, d) \in \mathbb{R}^4$.

10.3.2 Exemple : condition de Feller (Heston)

Dans Heston, la variance suit un processus de type CIR. Pour éviter que v_t touche trop souvent 0, on impose souvent (pas toujours strictement nécessaire numériquement) la **condition de Feller** :

$$2\kappa\theta \geq \xi^2.$$

Cette contrainte couple les paramètres et rend l'optimisation plus difficile. Une manière simple de l'imposer via reparamétrisation est, par exemple,

$$2\kappa\theta = \xi^2 + e^u \quad (u \in \mathbb{R}),$$

ce qui garantit automatiquement l'inégalité.

10.4 Identifiabilité et échelles : pourquoi "tout fitter" est impossible

10.4.1 Un paramètre "faible" est invisible

Si une direction de paramètres change très peu les prix, le problème est quasi-plat : $J^\top J$ a une petite valeur propre, donc le pas d'optimisation explose. Typiquement :

- la corrélation ρ est surtout identifiée par le skew court terme ;
- κ et θ peuvent se compenser sur des maturités limitées ;
- ξ est mal identifié si la surface est presque plate.

Conséquence pratique : calibrer sur trop peu de maturités rend certains paramètres non identifiables.

10.4.2 Choix d'échelle : prix vs IV

En calibrant en prix, les options ITM (plus chères) dominent la loss. En calibrant en IV, on compare des quantités homogènes, mais on introduit le problème d'inversion (vega faible). Une alternative utile est de calibrer en *prix normalisés* :

$$r_i(\theta) = \frac{P_i^{\text{model}}(\theta) - P_i^{\text{mkt}}}{\max(\text{tick}, \text{Vega}_i \sigma_i)}.$$

Ce type de normalisation limite l'impact disproportionné d'une option peu informative.

10.5 Diagnostics : savoir quand une calibration est mauvaise

10.5.1 Erreurs structurées

Une calibration "mauvaise" n'est pas forcément une grosse MSE. Ce qui compte est la *structure* des erreurs :

- si toutes les maturités sont sous-primées en même temps : erreur de taux/dividendes ;
- si le skew est mal reproduit : corrélation/vol-of-vol mal identifiées ;
- si seules les ailes sont mauvaises : modèle trop léger en queues (sauts/roughness manquants).

Un diagnostic utile consiste à tracer r_i en fonction de $k = \log(K/F)$ et T .

10.5.2 Sensibilités de paramètres

Le Jacobien J est aussi une information économique : $\frac{\partial \sigma_{\text{imp}}}{\partial \rho} < 0$ sur indices (skew put) est attendu. Si la calibration produit des sensibilités incohérentes, c'est souvent un signe d'instabilité numérique.

Ce que le jury doit retenir.

- La calibration est un moindres carrés non linéaire : résidus $r(\theta)$, Jacobienne $J(\theta)$.
- Gauss–Newton est rapide mais instable si $J^\top J$ est mal conditionnée.
- Levenberg–Marquardt stabilise via $(J^\top J + \lambda I)$ avec λ adaptatif.
- Les contraintes (positivité, bornes, Feller, $\rho \in (-1, 1)$) se gèrent par optimisation bornée ou reparamétrisation.
- Une “bonne” calibration n’est pas juste une petite loss : les erreurs doivent être économiquement plausibles.

Chapitre 11

Modèle de Heston : volatilité stochastique, pricing par fonction caractéristique, FFT

11.1 Pourquoi Heston ?

La surface de volatilité implicite des indices actions présente souvent un skew marqué : les puts OTM sont chers (IV élevée), ce qui traduit (i) une probabilité risque-neutre de baisse plus importante, (ii) une aversion au risque de crash, et (iii) une dynamique où la volatilité augmente quand le spot baisse (*leverage effect*). Le modèle de Heston est l'un des plus utilisés car :

- il introduit une volatilité *stochastique* (variance aléatoire) ;
- il permet de générer un skew via une corrélation négative spot/variance ;
- il reste suffisamment tractable : pricing européen via fonction caractéristique (semi-fermé).

11.2 Définition du modèle (sous mesure risque-neutre)

Définition 11.1 (Modèle de Heston). Sous la mesure risque-neutre $\mathbb{Q}$, on modélise le spot et la variance instantanée par :

$$\begin{aligned}dS_t &= (r - q)S_t dt + \sqrt{v_t} S_t dW_t^{(1)}, \\dv_t &= \kappa(\theta - v_t) dt + \xi \sqrt{v_t} dW_t^{(2)}, \\d\langle W^{(1)}, W^{(2)} \rangle_t &= \rho dt,\end{aligned}$$

où $\kappa > 0$ (vitesse de retour à la moyenne), $\theta > 0$ (variance de long terme), $\xi > 0$ (vol-of-vol) et $\rho \in [-1, 1]$ (corrélation).

11.2.1 Interprétation financière des paramètres

- θ : niveau “normal” de variance à long terme (donc vol de long terme $\sqrt{\theta}$).
- κ : vitesse de mean-reversion ; plus κ est grand, plus v_t revient vite vers θ .
- ξ : intensité des chocs sur la variance (plus ξ est grand, plus la variance bouge vite).
- ρ : corrélation spot/variance. Sur indices, on observe souvent $\rho < 0$: quand S baisse, v monte, ce qui génère un skew put (IV plus élevée pour strikes bas).

11.2.2 Condition de Feller (positivité de la variance)

Proposition 11.1 (Condition de Feller). *Pour le processus de Cox–Ingersoll–Ross (CIR) ci-dessus, une condition suffisante pour éviter que v_t touche zéro est*

$$2\kappa\theta \geq \xi^2.$$

Intuition : $\kappa\theta$ contrôle la force de rappel vers un niveau positif, tandis que ξ contrôle la force des chocs qui peuvent pousser v_t vers zéro. Quand ξ est trop grand, le bruit domine et la variance peut heurter 0. En pratique, on peut calibrer même si Feller n'est pas strictement vérifiée, mais cela peut rendre certaines intégrales plus instables.

11.3 Passage à la log-dynamique

On pose $X_t = \log S_t$. Par Itô (comme dans section 3.5) :

$$dX_t = \left((r - q) - \frac{1}{2}v_t \right) dt + \sqrt{v_t} dW_t^{(1)}.$$

Le couple (X_t, v_t) est un processus *affine* : c'est cette structure qui rend la fonction caractéristique calculable.

11.4 Fonction caractéristique : dérivation via l'ansatz affine

On veut pricer des options européennes. Une voie efficace est de calculer la fonction caractéristique de X_T :

$$\phi(u) = \mathbb{E}^{\mathbb{Q}} \left[e^{iuX_T} \mid X_0 = \log S_0, v_0 \right].$$

Dans un modèle affine, on cherche une solution de la forme

$$\phi(u) = \exp \left(A(T; u) + B(T; u) v_0 + iu \log S_0 \right),$$

où A et B sont à déterminer.

11.4.1 Étape 1 : équation de Kolmogorov backward

Considérons la fonction

$$f(t, x, v) = \mathbb{E}^{\mathbb{Q}} \left[e^{iuX_T} \mid X_t = x, v_t = v \right].$$

Elle vérifie une PDE backward (Feynman–Kac) :

$$\frac{\partial f}{\partial t} + \mathcal{L}f = 0, \quad f(T, x, v) = e^{iux},$$

où $\mathcal{L}$ est le générateur de (X_t, v_t) .

11.4.2 Étape 2 : générateur du couple (X, v)

À partir des SDE :

$$dX = \left((r - q) - \frac{1}{2}v \right) dt + \sqrt{v} dW^{(1)}, \quad dv = \kappa(\theta - v)dt + \xi\sqrt{v} dW^{(2)},$$

et $d\langle W^{(1)}, W^{(2)} \rangle = \rho dt$. Le générateur est (résultat standard de calcul d'Itô en 2D) :

$$\mathcal{L}f = \left((r - q) - \frac{1}{2}v \right) \frac{\partial f}{\partial x} + \kappa(\theta - v) \frac{\partial f}{\partial v} + \frac{1}{2}v \frac{\partial^2 f}{\partial x^2} + \rho\xi v \frac{\partial^2 f}{\partial x \partial v} + \frac{1}{2}\xi^2 v \frac{\partial^2 f}{\partial v^2}.$$

Les trois termes de second ordre viennent des variations quadratiques : $(dX)^2 = v dt$, $(dv)^2 = \xi^2 v dt$, et $dX dv = \rho\xi v dt$.

11.4.3 Étape 3 : insérer l'ansatz et obtenir des ODE

On pose

$$f(t, x, v) = \exp\left(A(\tau) + B(\tau)v + iux\right), \quad \tau = T - t.$$

On calcule les dérivées :

$$\frac{\partial f}{\partial x} = iuf, \quad \frac{\partial^2 f}{\partial x^2} = -(u^2)f, \quad \frac{\partial f}{\partial v} = Bf, \quad \frac{\partial^2 f}{\partial v^2} = B^2f, \quad \frac{\partial^2 f}{\partial x \partial v} = iuBf.$$

On calcule aussi $\frac{\partial f}{\partial t} = -A'(\tau)f - B'(\tau)vf$ (car $\tau = T - t$).

On remplace dans la PDE $\frac{\partial f}{\partial t} + \mathcal{L}f = 0$, puis on divise par f . On obtient une identité de la forme

$$0 = \text{termes constants en } v + \text{termes proportionnels à } v.$$

Comme cela doit être vrai pour tout v , on identifie séparément :

$$A'(\tau) = \kappa\theta B(\tau) + (r - q)iu,$$

$$B'(\tau) = \frac{1}{2}(u^2 + iu) + (\rho\xi iu - \kappa)B(\tau) + \frac{1}{2}\xi^2 B(\tau)^2.$$

La seconde équation est une équation de Riccati. Avec conditions terminales $A(0) = 0$ et $B(0) = 0$ (puisque $f(T, x, v) = e^{iux}$), on peut résoudre explicitement et obtenir la formule fermée de $\phi(u)$.

11.4.4 Forme fermée (résultat standard)

On définit

$$d = \sqrt{(\rho\xi iu - \kappa)^2 + \xi^2(u^2 + iu)}, \quad g = \frac{\kappa - \rho\xi iu - d}{\kappa - \rho\xi iu + d}.$$

Alors une écriture usuelle est

$$A(T; u) = (r - q)iuT + \frac{\kappa\theta}{\xi^2} \left((\kappa - \rho\xi iu - d)T - 2 \log \left(\frac{1 - ge^{-dT}}{1 - g} \right) \right),$$

$$B(T; u) = \frac{\kappa - \rho\xi iu - d}{\xi^2} \cdot \frac{1 - e^{-dT}}{1 - ge^{-dT}}.$$

Donc

$$\phi(u) = \exp\left(A(T; u) + B(T; u)v_0 + iu \log S_0\right).$$

Remarque 11.1 (Stabilité numérique). Il existe plusieurs écritures équivalentes de $\phi(u)$. Certaines peuvent souffrir de problèmes de branche de la racine carrée complexe ou de logarithme (“Heston trap”). En pratique numérique, on choisit une implémentation stable (“Little Heston trap” ou variantes). Pour un cours M1, l’essentiel est de comprendre : *la structure affine mène à une solution exponentielle avec une Riccati*.

11.5 Pricing européen via inversion de Fourier

À partir de $\phi(u)$, on peut pricer un call européen de strike K . Une représentation classique est :

$$C_0 = S_0 e^{-qT} P_1 - K e^{-rT} P_2,$$

où P_1 et P_2 sont des “probabilités” calculées par intégrales de Fourier. L’idée est proche de la récupération d’une CDF à partir d’une fonction caractéristique : pour une variable X , on peut reconstruire $\mathbb{P}(X \leq x)$ via une intégrale impliquant $\mathbb{E}[e^{iuX}]$.

Sans entrer dans tous les détails techniques, une forme standard est :

$$P_2 = \frac{1}{2} + \frac{1}{\pi} \int_0^\infty \Re \left(\frac{e^{-iu \log K} \phi(u)}{iu} \right) du,$$

et P_1 est obtenu avec un décalage complexe (lié au terme S_T dans le payoff).

Le point important : le pricing devient une *intégrale 1D*.

11.6 Carr–Madan : FFT pour pricer beaucoup de strikes à la fois

Quand on calibre, on doit pricer des centaines d'options. Faire une intégrale par strike peut être trop lent. Carr–Madan propose une astuce :

- on “amortit” le call pour qu’il soit intégrable en strike ;
- on prend la transformée de Fourier en log-strike ;
- on utilise une FFT pour obtenir une grille de prix en $O(N \log N)$.

11.6.1 Idée principale

On note $k = \log K$ et $C(k) = C(K)$. Le call n’est pas intégrable en k (il croît comme S pour $k \rightarrow -\infty$). On choisit $\alpha > 0$ et on définit le call amorti

$$c_\alpha(k) = e^{\alpha k} C(k).$$

Sous des conditions raisonnables, c_α devient intégrable. On considère sa transformée de Fourier

$$\hat{c}_\alpha(u) = \int_{-\infty}^\infty e^{iuk} c_\alpha(k) dk.$$

Carr–Madan montre qu’on peut exprimer $\hat{c}_\alpha(u)$ directement à partir de la fonction caractéristique ϕ . Puis, par inversion (et FFT), on récupère $C(k)$ sur une grille de k .

11.7 Illustration numérique : skew typique généré par Heston

Pour fixer les idées, voici une smile obtenue sous un jeu de paramètres raisonnable ($S_0 = 100$, $r = 2\%$, $q = 0$, $T = 1$ an, $v_0 = \theta = 0.04$, $\kappa = 1.5$, $\xi = 0.3$, $\rho = -0.7$). On calcule d’abord les prix Heston par intégrale de Fourier, puis on les reconvertit en volatilités implicites BS.

On observe un skew : les strikes bas (puts OTM) ont une IV plus élevée. Dans Heston, ce skew est principalement piloté par ρ (corrélacion spot/variance) et ξ (vol-of-vol).

11.8 Calibration Heston : objectifs et pièges

En pratique, on calibre $\theta = (\kappa, \theta, \xi, \rho, v_0)$ (parfois on fixe $v_0 = \theta$ ou on ajoute un paramètre de risque). Les pièges classiques :

- **Minima locaux** : multi-start quasi obligatoire.
- **Trade-offs** : κ et θ peuvent compenser ξ sur certaines grilles.
- **Données** : bid/ask et erreurs d’IV (surtout extrêmes strikes) peuvent dominer.
- **Instabilités** : intégrales oscillantes, choix du cutoff, paramètre d’amortissement en FFT.




FIGURE 11.1 – Smile de volatilité implicite générée par un modèle de Heston (exemple numérique).

Ce que le jury doit retenir.

- Heston ajoute une variance stochastique v_t de type CIR : mean-reversion (κ, θ) , vol-of-vol (ξ) , corrélation (ρ) .
- La structure affine permet une fonction caractéristique explicite via un ansatz exponentiel et une Riccati.
- Les prix européens se calculent par intégrales de Fourier ; Carr–Madan + FFT accélère le pricing multi-strikes.
- Le skew actions vient surtout de $\rho < 0$; la calibration est une optimisation non convexe avec contraintes.

Chapitre 12

Diffusions à sauts : Merton et Bates

12.1 Pourquoi ajouter des sauts ?

Même avec volatilité stochastique, certains phénomènes sont difficiles à reproduire :

- **gaps** de marché (annonces, overnight) ;
- **smile court terme** très prononcé : à très courte maturité, la diffusion seule donne une densité trop “fine” ;
- **queues épaisses** : plus d’événements extrêmes que la gaussienne.

Les modèles à sauts ajoutent une composante rare mais significative.

12.2 Processus de Poisson composé (rappel)

Définition 12.1 (Poisson et sauts multiplicatifs). Soit (N_t) un processus de Poisson d’intensité $\lambda > 0$: $\mathbb{P}(N_t = n) = e^{-\lambda t}(\lambda t)^n/n!$. On considère des tailles de saut i.i.d. (J_k) , et le processus de saut multiplicatif

$$\prod_{k=1}^{N_t} J_k.$$

Dans le modèle de Merton, on pose souvent $J_k = e^{Y_k}$ avec $Y_k \sim \mathcal{N}(\mu_J, \delta_J^2)$.

12.3 Modèle de Merton (jump diffusion) sous $\mathbb{Q}$

Définition 12.2 (Merton jump diffusion). Sous $\mathbb{Q}$:

$$\frac{dS_t}{S_{t-}} = (r - q - \lambda \kappa_J)dt + \sigma dW_t + (J - 1)dN_t,$$

où $J = e^Y$ est le multiplicateur de saut et

$$\kappa_J \triangleq \mathbb{E}[J - 1] = \mathbb{E}[e^Y - 1] = e^{\mu_J + \frac{1}{2}\delta_J^2} - 1.$$

Pourquoi le terme $-\lambda \kappa_J$? Parce qu’en moyenne, les sauts ajoutent une dérive : en un petit dt , on a $\mathbb{P}(dN_t = 1) \approx \lambda dt$ et sinon 0, donc l’espérance instantanée du terme de saut est $\lambda \mathbb{E}[J - 1]dt = \lambda \kappa_J dt$. On le soustrait pour conserver le drift risque-neutre $(r - q)$ pour S_t .

12.4 Pricing : mélange de Black–Scholes (intuition et formule)

Conditionnellement au nombre de sauts $N_T = n$, la somme des logs de sauts est gaussienne (somme de gaussiennes), donc $\log S_T$ reste gaussien conditionnellement à n . On obtient donc un mélange de lois lognormales, et un mélange de prix Black–Scholes.

Proposition 12.1 (Prix de call Merton comme somme de BS). *Soit $C_{BS}(S_0, K, r, q, T, \sigma_n)$ un call BS avec une volatilité effective σ_n . Alors*

$$C_0^{\text{Merton}} = \sum_{n=0}^{\infty} \frac{e^{-\lambda T} (\lambda T)^n}{n!} C_{BS}(S_0, K, r, q, T, \sigma_n),$$

où $\sigma_n^2 = \sigma^2 + \frac{n\delta_J^2}{T}$ et où le forward est ajusté par la moyenne des sauts (effet de μ_J).

Intuition : chaque terme correspond au scénario “il y a eu n sauts”. En pratique, la somme est tronquée à un $n_{\max}$ raisonnable (car la probabilité de beaucoup de sauts est faible).

12.5 Fonction caractéristique (utile pour FFT)

Le modèle de Merton est aussi très commode en Fourier. La fonction caractéristique de $\log S_T$ factorise en :

$$\phi(u) = \phi_{\text{diffusion}}(u) \cdot \phi_{\text{sauts}}(u),$$

avec

$$\phi_{\text{sauts}}(u) = \exp\left(\lambda T (\mathbb{E}[e^{iuY}] - 1)\right).$$

Pour $Y \sim \mathcal{N}(\mu_J, \delta_J^2)$,

$$\mathbb{E}[e^{iuY}] = \exp\left(iu\mu_J - \frac{1}{2}u^2\delta_J^2\right).$$

Donc

$$\phi_{\text{sauts}}(u) = \exp\left(\lambda T \left(\exp\left(iu\mu_J - \frac{1}{2}u^2\delta_J^2\right) - 1\right)\right).$$

Cela rend Carr–Madan (FFT) très efficace.

12.6 Bates : Heston + sauts

Définition 12.3 (Modèle de Bates (idée)). Le modèle de Bates combine :

- une variance stochastique à la Heston ;
- des sauts multiplicatifs à la Merton.

On garde la dynamique de v_t de Heston et on ajoute un terme $(J-1)dN_t$ dans dS_t/S_{t-} , avec correction de drift $-\lambda\kappa_J$.

Pourquoi c’est utile ? Heston explique bien le skew “structurel” via ρ . Les sauts expliquent souvent une partie du smile court terme et des queues extrêmes. Bates combine les deux.

Exemple 12.1 (Impact qualitatif sur la smile courte maturité). À maturité très courte, un modèle diffusif produit une distribution de $\log S_T$ très concentrée (variance $\propto T$). Ajouter des sauts injecte une probabilité non négligeable de mouvements de grande amplitude même pour T petit, ce qui augmente la valeur des options très OTM : la smile court terme remonte.

12.7 Limites et extensions

- Les sauts de Merton sont gaussiens en log : cela peut être trop simple.
- L'intensité λ peut être stochastique.
- Les sauts peuvent être asymétriques (ex. double exponentielle de Kou).

Ce que le jury doit retenir.

- Les sauts capturent gaps et queues épaisses ; ils sont cruciaux pour la smile très court terme.
- Merton : diffusion + Poisson composé, avec correction de drift $-\lambda\kappa_J$ pour rester risque-neutre.
- Le prix européen est un mélange de Black-Scholes (conditionnel au nombre de sauts) ou via fonction caractéristique/FFT.
- Bates = Heston + sauts : skew + queues.

Chapitre 13

SABR : dynamique, formule de Hagan et calibration

13.1 Pourquoi SABR ?

En taux et en FX, les marchés aiment :

- une paramétrisation *simple* par maturité (smile par “tenor”) ;
- un modèle flexible qui reproduit des smiles très variées ;
- une formule d’approximation rapide de la volatilité implicite.

SABR (Stochastic Alpha Beta Rho) répond à ces besoins.

13.2 Dynamique SABR (sur le forward)

Définition 13.1 (Modèle SABR). On modélise un forward F_t (par exemple un taux forward ou un taux swap) et sa volatilité instantanée α_t :

$$\begin{aligned}dF_t &= \alpha_t F_t^\beta dW_t^{(1)}, \\d\alpha_t &= \nu \alpha_t dW_t^{(2)}, \\d\langle W^{(1)}, W^{(2)} \rangle_t &= \rho dt,\end{aligned}$$

avec paramètres $\beta \in [0, 1]$, $\nu > 0$ et $\rho \in [-1, 1]$.

13.2.1 Interprétation des paramètres

- β : élasticité de la volatilité au niveau du forward.
 - $\beta = 1$: modèle lognormal (type Black) : $dF/F = \alpha dW$.
 - $\beta = 0$: modèle normal (type Bachelier) : $dF = \alpha dW$.
- α_0 : niveau initial de vol (“ATM level”).
- ν : vol-of-vol (à quel point α_t bouge).
- ρ : corrélation entre mouvements de F et de la vol α (contrôle l’asymétrie/skew).

13.3 Objectif : une formule rapide d’IV (Hagan)

SABR n’admet pas de formule fermée simple pour les prix d’options européennes (sauf cas particuliers). Hagan et al. proposent une approximation asymptotique directe pour la volatilité implicite, très utilisée en pratique pour calibrer et interpoler des smiles.

13.4 Formule de Hagan (Black vol) : expression et lecture

On note K le strike, T la maturité, F le forward initial F_0 et α le niveau initial α_0 . Définissons :

$$z = \frac{\nu}{\alpha} (FK)^{\frac{1-\beta}{2}} \log\left(\frac{F}{K}\right), \quad \chi(z) = \log\left(\frac{\sqrt{1-2\rho z + z^2} + z - \rho}{1-\rho}\right).$$

Alors l'approximation de Hagan pour la volatilité implicite lognormale (Black) est :

$$\sigma_{\text{Hagan}}(F, K) = \frac{\nu \log(F/K)}{\chi(z)} \cdot \frac{\alpha}{(FK)^{\frac{1-\beta}{2}}} \cdot [1 + \text{correction}(T)],$$

où la correction en temps (ordre T) vaut :

$$\text{correction}(T) = \left(\frac{(1-\beta)^2}{24} \frac{\alpha^2}{(FK)^{1-\beta}} + \frac{\rho\beta\nu\alpha}{4(FK)^{\frac{1-\beta}{2}}} + \frac{2-3\rho^2}{24} \nu^2 \right) T.$$

Lecture financière :

- Le facteur $\alpha/(FK)^{(1-\beta)/2}$ donne le niveau de vol en fonction du niveau de taux (effet CEV).
- Le ratio $\nu \log(F/K)/\chi(z)$ encode l'asymétrie et la courbure de la smile via ρ et ν .
- La correction en T ajoute l'effet du temps sur la smile.

Remarque 13.1 (Pourquoi $\chi(z)$?). Le terme $\chi(z)$ apparaît en résolvant (à l'ordre asymptotique) une équation de diffusion et en effectuant un changement de variable qui “linearise” la dynamique. Le ratio $\frac{z}{\chi(z)}$ est proche de 1 quand z est petit, et corrige le comportement hors ATM.

13.5 Cas ATM : limite $K \rightarrow F$

Quand $K \rightarrow F$, on a $\log(F/K) \rightarrow 0$ et donc $z \rightarrow 0$. On utilise l'expansion $\chi(z) \sim z$ pour obtenir la formule ATM :

$$\sigma_{\text{ATM}} = \frac{\alpha}{F^{1-\beta}} \left[1 + \left(\frac{(1-\beta)^2}{24} \frac{\alpha^2}{F^{2-2\beta}} + \frac{\rho\beta\nu\alpha}{4F^{1-\beta}} + \frac{2-3\rho^2}{24} \nu^2 \right) T \right].$$

À quoi ça sert ? L'ATM donne une contrainte forte sur α (niveau), tandis que les strikes OTM contraignent surtout ρ et ν (skew et convexité).

13.6 Calibration SABR (pratique)

En pratique, on calibre SABR *maturité par maturité* :

- on fixe souvent β (ex. 0.5 ou 0.0 selon conventions et régime de taux) ;
- on ajuste (α, ρ, ν) pour fitter 3 quotes (ATM, 25Δ put, 25Δ call) ou plus.

13.6.1 Pourquoi fixer β ?

Parce que β est difficile à identifier avec peu de points, et parce qu'il contrôle une dimension “structurelle” du marché (relation niveau-vol). Fixer β stabilise fortement la calibration.

Exemple 13.1 (Mini-procédure de calibration (idée)). Supposons qu'on dispose, à une maturité T , de trois IV :

$$\sigma_{\text{ATM}}, \quad \sigma_{25\Delta \text{ put}}, \quad \sigma_{25\Delta \text{ call}}.$$

On fixe β , puis on cherche (α, ρ, ν) qui minimisent l'erreur quadratique entre ces trois valeurs et la formule de Hagan. On peut initialiser α par la formule ATM, puis ajuster ρ (skew) et ν (courbure).

13.7 Limites et extensions

- Hagan est une approximation : elle peut devenir mauvaise pour très longues maturités ou paramètres extrêmes.
- Quand les taux sont proches de zéro ou négatifs, la formulation lognormale (Black) peut poser problème : on préfère parfois une volatilité normale (Bachelier) ou des adaptations.
- Des extensions : SABR déplacé (shifted), ou modèles multi-facteurs.

Ce que le jury doit retenir.

- SABR modélise un forward F_t avec une vol stochastique α_t lognormale ; β contrôle la dépendance niveau-vol.
- La formule de Hagan donne une approximation directe de la volatilité implicite : rapide pour la calibration.
- α fixe le niveau (ATM), ρ le skew, ν la courbure (vol-of-vol).
- Limites : approximation, régime de taux bas/négatif, stabilité hors ATM.

Chapitre 14

Volatilité “rough” et modèles de type Volterra

14.1 Motivation empirique : la volatilité est très irrégulière

Depuis les années 2010, de nombreuses études empiriques suggèrent que la volatilité réalisée ou certaines proxies (log-vol) ont une régularité plus faible que celle d’un Brownien. Une manière de quantifier cela est via l’exposant de Hurst H :

- $H = 1/2$: Brownien classique (rugosité “standard”).
- $H < 1/2$: trajectoires plus rugueuses, mémoire négative à court terme (*rough*).

En pratique, on estime souvent $H \simeq 0.1$ pour la volatilité.

14.2 Brownien fractionnaire : définition et intuition

Définition 14.1 (Brownien fractionnaire (fBM)). Un Brownien fractionnaire $(W_t^H)_{t \geq 0}$ d’exposant $H \in (0, 1)$ est un processus gaussien centré tel que

$$\mathbb{E}[W_t^H W_s^H] = \frac{1}{2} (t^{2H} + s^{2H} - |t - s|^{2H}).$$

Propriétés importantes :

- W^H a des incréments stationnaires, mais *pas indépendants* si $H \neq 1/2$.
- La variance de l’incrément est $\text{Var}(W_t^H - W_s^H) = |t - s|^{2H}$. Donc les incréments sont d’ordre $|t - s|^H$.

Remarque 14.1 (Pourquoi Itô “ne marche pas” directement). Pour $H \neq 1/2$, W^H n’est pas une semi-martingale. Le calcul d’Itô (basé sur la variation quadratique finie et sur les semi-martingales) ne s’applique pas tel quel. On doit utiliser d’autres outils (intégrales de Young, Malliavin, rough paths), trop avancés pour ce cours.

14.3 Représentation Volterra : ramener du rough à du Brownien

Une idée clé (très utilisée) est de représenter W^H comme une intégrale contre un Brownien standard :

$$W_t^H = \int_0^t K_H(t, s) dW_s,$$

où $K_H(t, s)$ est un *noyau Volterra* (triangulaire : $s < t$) qui encode la mémoire. Pour le rough case $H < 1/2$, un comportement typique est

$$K_H(t, s) \approx (t - s)^{H - \frac{1}{2}} \quad \text{quand } s \uparrow t,$$

ce qui amplifie les effets à très court terme et rend les trajectoires plus rugueuses.

14.4 Exemple : modèle rBergomi (esprit)

Définition 14.2 (rBergomi (forme simplifiée)). Un prototype de modèle rough est :

$$\begin{aligned} dS_t &= (r - q)S_t dt + \sqrt{v_t} S_t dW_t^{(1)}, \\ v_t &= \xi_0(t) \exp\left(\eta W_t^H - \frac{1}{2}\eta^2 t^{2H}\right), \end{aligned}$$

où W_t^H est un fBM construit à partir d'un Brownien standard et η contrôle l'amplitude.

Intuition :

- $\xi_0(t)$ est la *courbe de variance forward* (niveau moyen de variance par maturité) ;
- la partie exponentielle rend v_t lognormal (positif) ;
- $H < 1/2$ rend les chocs de volatilité très rugueux, ce qui reproduit mieux certaines smiles court terme.

14.5 Numérique : simulation et approximation markovienne

Le pricing rough est souvent fait par Monte Carlo, car pas de CF simple. Le défi : simuler W_t^H efficacement.

14.5.1 Simulation directe (coût élevé)

Si l'on simule un vecteur gaussien corrélé de taille n (grille de temps), le coût naïf est $O(n^2)$. Pour de la calibration, c'est trop lent.

14.5.2 Approximation markovienne (somme d'exponentielles)

Une astuce importante : approximer le noyau $K_H(t, s)$ par une somme d'exponentielles :

$$K_H(t, s) \approx \sum_{j=1}^m w_j e^{-\lambda_j(t-s)}.$$

Pourquoi c'est utile ? Parce que chaque terme exponentiel peut être généré par une équation markovienne auxiliaire (type OU), ce qui transforme le modèle rough en un modèle multi-facteur markovien (dimension m), plus facile à simuler et parfois calibrer.

Exemple 14.1 (Idée d'état auxiliaire). Définissez des processus

$$Y_t^{(j)} = \int_0^t e^{-\lambda_j(t-s)} dW_s.$$

Alors $Y_t^{(j)}$ satisfait

$$dY_t^{(j)} = -\lambda_j Y_t^{(j)} dt + dW_t,$$

ce qui est markovien. On peut reconstruire W_t^H comme combinaison linéaire des $Y^{(j)}$.

14.6 Limites et ce qu'il faut retenir

- Les modèles rough améliorent le fit du smile court terme, mais sont plus difficiles à calibrer et simuler.
- Pour un praticien M1, l'essentiel est de comprendre la motivation (rugosité empirique) et les conséquences (Itô non applicable directement, simulation plus coûteuse).

Ce que le jury doit retenir.

- Rough volatility : la volatilité semble avoir une régularité $H < 1/2$ (très rugueuse) à court terme.
- Le Brownien fractionnaire W^H n'est pas une semi-martingale si $H \neq 1/2$: Itô classique ne s'applique pas tel quel.
- Une représentation Volterra $W_t^H = \int_0^t K(t,s)dW_s$ permet de travailler avec un Brownien standard.
- Numériquement, l'approximation markovienne (somme d'exponentielles) est une stratégie clé pour rendre le problème tractable.

Chapitre 15

Réseaux de neurones et calibration accélérée : surrogates et inversion

15.1 Pourquoi des réseaux en calibration ?

Dans les modèles riches (Heston, Bates, rough), pricer une option peut nécessiter :

- une intégrale oscillante (Fourier) ;
- une FFT (grille) ;
- ou du Monte Carlo (souvent coûteux).

La calibration (chapitre chapter 9) requiert des centaines/milliers d'évaluations. Même si un pricing unitaire prend 5 ms, la calibration peut prendre plusieurs secondes ou minutes.

Un réseau de neurones peut servir de :

- **surrogate direct** : $\theta \mapsto \sigma_{\text{imp}}(K, T)$ (ou prix) ;
- **surrogate inverse** : surface $\mapsto \theta$ (approximation d'inversion) ;
- **initialiseur** : fournir un bon point de départ pour une calibration classique.

15.2 Rappel minimal : perceptron multicouche (MLP)

Définition 15.1 (Couche affine + non-linéarité). Une couche prend une entrée $x \in \mathbb{R}^d$ et produit

$$h = \varphi(Wx + b),$$

où W est une matrice, b un biais, et φ une non-linéarité (ReLU, tanh, etc.). Un réseau MLP empile plusieurs couches.

15.2.1 Forward pass

Si le réseau a L couches, on calcule

$$h^{(0)} = x, \quad h^{(\ell)} = \varphi_{\ell}(W_{\ell}h^{(\ell-1)} + b_{\ell}), \quad \ell = 1, \dots, L,$$

et la sortie $\hat{y} = h^{(L)}$.

15.3 Apprentissage supervisé : loss et objectif

On dispose d'un dataset $\{(x_i, y_i)\}_{i=1}^n$. Dans notre contexte :

- x_i = paramètres du modèle + caractéristiques du contrat (ex. K, T, S_0, r, q),

— y_i = prix ou volatilité implicite.

Définition 15.2 (Loss quadratique (MSE)).

$$\mathcal{L}(\theta_{\text{NN}}) = \frac{1}{n} \sum_{i=1}^n \|\hat{y}_i - y_i\|^2,$$

où θ_{NN} désigne les poids/biais du réseau.

À quoi ça sert ? Minimiser $\mathcal{L}$ revient à approximer la fonction inconnue $x \mapsto y$. Si le réseau généralise, on obtient un pricing quasi-instantané.

15.4 Backprop : la règle de la chaîne (idée)

Le réseau est une composition de fonctions. Pour une couche : $h = \varphi(z)$ avec $z = Wx + b$. La dérivée de la loss par rapport aux paramètres suit la règle de la chaîne :

$$\frac{\partial \mathcal{L}}{\partial W} = \frac{\partial \mathcal{L}}{\partial z} \frac{\partial z}{\partial W}.$$

La backprop calcule ces gradients efficacement en remontant de la sortie vers l'entrée.

Exemple 15.1 (Mini-exemple (une couche)). Supposons $\hat{y} = wx$ (scalaire) et $\mathcal{L} = \frac{1}{2}(\hat{y} - y)^2$. Alors

$$\frac{\partial \mathcal{L}}{\partial w} = (\hat{y} - y) \cdot x.$$

C'est exactement un cas de règle de la chaîne : dérivée de la loss times dérivée de la sortie.

15.5 Génération de dataset synthétique (la clé en quant)

Pour pricer, on sait générer des données de façon *contrôlée* :

- 1) tirer des paramètres θ dans un domaine réaliste (ex. Heston) ;
- 2) tirer des contrats (K, T) sur une grille ;
- 3) calculer des prix/IV via le modèle “exact” (FFT/intégrale/MC) ;
- 4) entraîner le réseau sur ces couples.

Attention : si le domaine de paramètres est trop large, le réseau aura du mal. Si le domaine est trop étroit, il ne généralisera pas hors de cette zone. C'est un vrai choix de design.

15.6 Surrogate direct vs inverse : avantages et limites

15.6.1 Surrogate direct

$$(\theta, K, T) \mapsto \sigma_{\text{imp}}.$$

Avantage : bien posé (fonction bien définie), facile à entraîner. **Usage :** accélérer la calibration classique (on minimise une loss mais avec le réseau au lieu du pricing exact).

15.6.2 Surrogate inverse

$$\{\sigma_{\text{imp}}(K_i, T_i)\}_{i=1}^N \mapsto \theta.$$

Problème : l'inversion n'est pas toujours unique. Deux jeux de paramètres peuvent générer des smiles proches sur une grille limitée. Cela crée une ambiguïté : le réseau peut “moyenner” des solutions.

Solutions possibles :

- prédire une distribution (incertitude) plutôt qu'un point ;
- imposer des régularisations et contraintes ;
- utiliser l'inverse NN seulement comme initialisation, puis raffiner par calibration exacte.

15.7 Overfitting et validation

Un réseau peut apprendre “par cœur” le dataset synthétique sans généraliser. Bonnes pratiques :

- split train/validation/test ;
- early stopping ;
- normalisation des inputs ;
- contrôle de la complexité (nombre de couches/neurones).

Exemple 15.2 (Toy surrogate pour Black–Scholes). On peut entraîner un réseau à approximer $C_{\text{BS}}(S, K, T, r, q, \sigma)$. Même si la formule est fermée, l'exercice montre :

- comment choisir des entrées (features) ;
- comment normaliser (ex. log-moneyness) ;
- comment évaluer l'erreur relative/absolue.

Ce que le jury doit retenir.

- Les réseaux servent surtout à accélérer la calibration : remplacer un pricing coûteux par une approximation rapide.
- Surrogate direct ($\theta \rightarrow \text{prix/IV}$) est mieux posé que l'inverse (surface $\rightarrow \theta$), souvent non-unique.
- Dataset synthétique : c'est un avantage majeur en quant, mais le domaine de paramètres doit être choisi intelligemment.
- Risque principal : sur-généralisation ou sous-généralisation ; la validation est obligatoire.

Troisième partie

Couverture discrète & reinforcement learning

Chapitre 16

Hedging discret : PnL, coûts de transaction et mesures de risque

16.1 Pourquoi le hedging discret est un vrai sujet ?

En théorie Black–Scholes, on hedge en continu et sans coûts : la réplication est parfaite. En pratique :

- on hedge à des fréquences finies (minute, heure, jour) ;
- chaque trade coûte (bid/ask, commissions, impact) ;
- la volatilité et la dynamique sont mal spécifiées.

Donc même un “delta hedging” produit un *PnL aléatoire*. La question devient : **quelle stratégie minimise le risque (ou maximise l’utilité) compte tenu des coûts ?**

16.2 Définition du PnL d’une stratégie de couverture

Supposons qu’on *vende* une option européenne de payoff $g(S_T)$ (donc on est short). On reçoit V_0 au départ. On hedge avec le sous-jacent et un compte cash.

On fixe des dates $0 = t_0 < t_1 < \dots < t_N = T$. Notons :

- $S_i = S_{t_i}$;
- Δ_i la position en sous-jacent détenue sur $(t_i, t_{i+1}]$;
- B_i le montant en cash au temps t_i (placé au taux r entre les dates).

La valeur du portefeuille de hedge au temps t_i est :

$$\Pi_i = \Delta_i S_i + B_i.$$

16.2.1 Auto-financement sans coûts

Sans coûts, la stratégie est auto-financée si, lors du rebalancing, l’achat/vente de sous-jacent est financé par le cash :

$$B_{i+1} = B_i e^{r\Delta t_i} - (\Delta_{i+1} - \Delta_i) S_{i+1}, \quad \Delta t_i = t_{i+1} - t_i.$$

Au temps final, on liquide le sous-jacent et on paie le payoff. Le PnL (profit net) pour le vendeur d’option est :

$$\text{PnL} = V_0 e^{rT} + \sum_{i=0}^{N-1} \Delta_i (S_{i+1} - S_i) e^{r(T-t_{i+1})} - g(S_T),$$

où on a exprimé les gains de trading en valeur à T (actualisation inverse).

16.2.2 Avec coûts de transaction proportionnels

Un modèle simple : chaque variation de position coûte une fraction c du notionnel :

$$\text{coût}_i = c S_{i+1} |\Delta_{i+1} - \Delta_i|.$$

Alors l'équation de cash devient

$$B_{i+1} = B_i e^{r\Delta t_i} - (\Delta_{i+1} - \Delta_i) S_{i+1} - c S_{i+1} |\Delta_{i+1} - \Delta_i|.$$

Ces coûts rendent le rebalancing fréquent potentiellement destructeur : on veut un compromis *risque vs coûts*.

16.3 Erreur de couverture et intuition

Même si Δ_i est le delta BS évalué au temps t_i , le hedge n'est plus parfait car :

- la delta est recalculée à des dates discrètes (on manque la convexité entre deux dates) ;
- la volatilité implicite utilisée peut bouger ;
- des coûts s'accumulent.

Une approximation classique (sous BS, sans coûts) est que l'erreur de couverture est liée à Γ :

$$\text{PnL} \approx \frac{1}{2} \sum_{i=0}^{N-1} \Gamma_{t_i} (S_{i+1} - S_i)^2.$$

En moyenne, $(S_{i+1} - S_i)^2 \approx \sigma^2 S_i^2 \Delta t_i$, ce qui suggère que la variance du PnL décroît avec le pas de temps, mais pas forcément linéairement.

16.4 Mesures de risque pour évaluer une stratégie

16.4.1 Variance / MSE

On peut minimiser

$$\min \text{Var}(\text{PnL}) \quad \text{ou} \quad \min \mathbb{E}[\text{PnL}^2].$$

C'est naturel si on veut “stabiliser” le résultat, mais ça traite symétriquement gains et pertes.

16.4.2 Value-at-Risk et CVaR

Définition 16.1 (VaR et CVaR (niveau α)). Pour une perte $L = -\text{PnL}$:

$$\text{VaR}_\alpha(L) = \inf\{\ell : \mathbb{P}(L \leq \ell) \geq \alpha\}.$$

La CVaR (aussi appelée Expected Shortfall) est

$$\text{CVaR}_\alpha(L) = \mathbb{E}[L \mid L \geq \text{VaR}_\alpha(L)].$$

Intuition :

- VaR : seuil de perte à ne pas dépasser avec probabilité α .
- CVaR : perte moyenne dans le pire $(1 - \alpha)\%$ des cas (plus sensible aux queues).

16.4.3 Utilité exponentielle (approche économique)

Une autre approche : maximiser l'espérance d'utilité, par exemple utilité exponentielle $U(x) = -\exp(-\gamma x)$, ce qui pénalise fortement les grandes pertes.

Exemple 16.1 (Comparaison qualitative). Une stratégie qui gagne souvent un peu mais perd rarement beaucoup peut avoir :

- une variance faible,
- mais une CVaR très mauvaise.

En gestion des risques, la CVaR est souvent plus pertinente car elle regarde explicitement la queue de distribution.

16.5 Ce qui change quand on introduit une stratégie “apprenante”

Le delta hedging est une règle analytique dérivée d'un modèle. Mais si le modèle est imparfait et si on ajoute des coûts, on peut vouloir *apprendre* une politique $\Delta_i = \pi(\text{état}_i)$ qui :

- réduit les coûts (moins de rebalancing),
- contrôle une mesure de risque (variance, CVaR),
- et reste raisonnable économiquement.

C'est précisément là qu'intervient la formulation MDP et le RL (chapitres suivants).

Ce que le jury doit retenir.

- Le hedging discret transforme un problème “déterministe” (réplication) en un problème de *contrôle sous incertitude* : le PnL devient aléatoire.
- Les coûts de transaction rendent la fréquence de rebalancing centrale : plus souvent = moins de risque diffusif, mais plus de coûts.
- Les objectifs pertinents ne se limitent pas à la variance : VaR/CVaR ou utilité peuvent mieux refléter la contrainte du risque extrême.
- Une stratégie apprenante cherche une politique $\Delta = \pi(\text{état})$ optimale pour un critère donné.

Chapitre 17

MDP pour la couverture et algorithmes RL tabulaires

17.1 Pourquoi formuler le hedging comme un MDP ?

Une stratégie de hedging discret prend des décisions séquentielles : à chaque date, on observe un état du marché et on choisit une action (nouvelle delta). Cela ressemble exactement à un problème de contrôle en temps discret.

17.2 Définition d'un MDP (Markov Decision Process)

Définition 17.1 (MDP). Un MDP est un quintuplet $(\mathcal{S}, \mathcal{A}, P, R, \gamma)$ où :

- $\mathcal{S}$: ensemble des états ;
- $\mathcal{A}$: ensemble des actions ;
- $P(s'|s, a)$: probabilité de transition ;
- $R(s, a, s')$: récompense (ou coût) ;
- $\gamma \in (0, 1]$: facteur d'actualisation (en finance de hedging court, on peut prendre $\gamma = 1$).

17.2.1 État, action et reward pour le hedging

Un choix typique :

- état s_t : $(t, S_t, v_t, \Delta_t, \dots)$ ou des features comme moneyness, temps restant, greeks.
- action a_t : nouvelle position Δ_{t+} (ou ajustement $\Delta_{t+} - \Delta_t$).
- reward : négatif des coûts et du risque. Par exemple :

$$r_t = -\text{coûts}_t - \lambda \cdot (\text{risque}_t),$$

où λ règle le compromis.

17.3 Valeurs : V^π et Q^π

Définition 17.2 (Fonctions valeur). Pour une politique $\pi(a|s)$:

$$V^\pi(s) = \mathbb{E}^\pi \left[\sum_{t=0}^T \gamma^t r_t \middle| s_0 = s \right], \quad Q^\pi(s, a) = \mathbb{E}^\pi \left[\sum_{t=0}^T \gamma^t r_t \middle| s_0 = s, a_0 = a \right].$$

À quoi ça sert ?

- V^π mesure la performance future d'une politique.
- Q^π permet de choisir l'action optimale : $\pi^*(s) = \arg \max_a Q^*(s, a)$.

17.4 Équations de Bellman

Théorème 17.1 (Bellman (policy evaluation)). *Pour une politique π :*

$$Q^\pi(s, a) = \mathbb{E} \left[r + \gamma \mathbb{E}_{a' \sim \pi(\cdot|s')} [Q^\pi(s', a')] \mid s, a \right].$$

Théorème 17.2 (Bellman optimalité). *La fonction optimale Q^* vérifie :*

$$Q^*(s, a) = \mathbb{E} \left[r + \gamma \max_{a'} Q^*(s', a') \mid s, a \right].$$

Intuition : le futur optimal, c'est “récompense immédiate + meilleur futur possible”.

17.5 Apprentissage TD : le cœur du RL

On n'a pas accès à la vraie transition P ni aux vraies espérances. On observe des trajectoires (s_t, a_t, r_t, s_{t+1}) et on met à jour des estimations de Q .

Définition 17.3 (Erreur TD). Pour une transition :

$$\delta_t = r_t + \gamma \hat{V}(s_{t+1}) - \hat{V}(s_t).$$

Pour Q :

$$\delta_t = r_t + \gamma \hat{Q}(s_{t+1}, a_{t+1}) - \hat{Q}(s_t, a_t).$$

17.5.1 SARSA (on-policy)

SARSA met à jour avec l'action réellement prise au temps suivant :

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha \left[r_t + \gamma Q(s_{t+1}, a_{t+1}) - Q(s_t, a_t) \right].$$

C'est *on-policy* : on apprend la valeur de la politique effectivement suivie (avec exploration).

17.5.2 Expected SARSA

On remplace $Q(s_{t+1}, a_{t+1})$ par son espérance sous la politique :

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha \left[r_t + \gamma \mathbb{E}_{a' \sim \pi} [Q(s_{t+1}, a')] - Q(s_t, a_t) \right].$$

Moins de variance, parfois plus stable.

17.5.3 Q-learning (off-policy)

Q-learning vise directement Q^* :

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha \left[r_t + \gamma \max_{a'} Q(s_{t+1}, a') - Q(s_t, a_t) \right].$$

C'est *off-policy* : on peut explorer avec une politique ϵ -greedy tout en évaluant le greedy optimal.

17.6 On-policy vs off-policy : pourquoi c'est important ?

- On-policy : plus stable si l'environnement dépend fortement de la politique (rare en hedging, mais possible via impact).
- Off-policy : plus efficace en données (on peut réutiliser des trajectoires générées par d'autres politiques).

17.7 Importance sampling : corriger le biais off-policy

Supposons qu'on a des données générées sous une politique de comportement $b(a|s)$, mais qu'on veut évaluer une autre politique $\pi(a|s)$. On introduit des poids

$$w_t = \frac{\pi(a_t|s_t)}{b(a_t|s_t)}.$$

Intuition : si une action est rare sous b mais probable sous π , il faut augmenter son poids.

Remarque 17.1 (Variance). Les ratios peuvent exploser si b met très peu de masse là où π en met beaucoup, ce qui crée une variance énorme. En RL pratique, c'est une difficulté majeure : on stabilise via clipping, régularisation, ou politiques proches.

Exemple 17.1 (Mini-exemple de mise à jour Q-learning). Supposons $\gamma = 1$, $\alpha = 0.1$. On observe (s, a, r, s') avec $r = -0.5$ (coût), et $\max_{a'} Q(s', a') = 2.0$. Si $Q(s, a) = 1.0$ alors

$$Q(s, a) \leftarrow 1.0 + 0.1(-0.5 + 2.0 - 1.0) = 1.0 + 0.1(0.5) = 1.05.$$

Le Q augmente car l'état futur promet un bon reward, malgré un coût immédiat.

Ce que le jury doit retenir.

- Un MDP formalise le hedging discret : état (marché + position), action (ajuster la hedge), reward (PnL/coûts/risque).
- Bellman relie Q d'aujourd'hui à "reward + futur" ; TD learning approxime cela à partir de trajectoires.
- SARSA (on-policy) apprend la politique suivie ; Q-learning (off-policy) apprend l'optimal greedy.
- Importance sampling corrige le biais off-policy mais peut exploser en variance.

Chapitre 18

DQN : Q-learning avec réseaux (design, stabilité, extensions)

18.1 Pourquoi DQN ?

Les méthodes tabulaires supposent que l'espace d'états $\mathcal{S}$ est petit et discret. En hedging réel, l'état contient des variables continues (spot, temps, vol, etc.) : impossible de stocker une table $Q(s, a)$.

DQN (Deep Q-Network) approxime $Q(s, a)$ par un réseau de neurones $Q_\theta(s, a)$.

18.2 Objectif : minimiser une loss TD

Pour Q-learning, l'équation de Bellman optimalité suggère :

$$Q^*(s, a) \approx r + \gamma \max_{a'} Q^*(s', a').$$

On définit une *cible* (target) :

$$y = r + \gamma \max_{a'} Q_{\theta^-}(s', a'),$$

où θ^- sont des paramètres *gelés* (target network). Puis on minimise la loss quadratique

$$\mathcal{L}(\theta) = \mathbb{E} \left[(Q_\theta(s, a) - y)^2 \right].$$

On fait une descente de gradient stochastique sur des minibatches.

18.3 Replay buffer : pourquoi on le fait

- Les transitions (s_t, a_t, r_t, s_{t+1}) sont corrélées dans le temps.
- La descente de gradient suppose des données i.i.d. (idéalement).

On stocke donc des transitions dans une mémoire (buffer), puis on échantillonne aléatoirement des minibatches. Cela réduit la corrélation et améliore la stabilité.

18.4 Target network : pourquoi on le fait

Sans target network, la cible y dépend de θ lui-même : on essaie de poursuivre une cible mouvante, ce qui peut diverger. On introduit donc θ^- mis à jour lentement (copie périodique ou moyenne exponentielle). C'est une astuce de stabilisation essentielle.

18.5 Exploration : epsilon-greedy

On choisit l'action :

$$a = \begin{cases} \text{action aléatoire} & \text{avec probabilité } \epsilon, \\ \arg \max_a Q_\theta(s, a) & \text{avec probabilité } 1 - \epsilon. \end{cases}$$

En hedging, l'exploration doit être contrôlée (on ne veut pas de positions absurdes) : on borne les actions (delta min/max) et on peut explorer autour d'un delta "baseline".

18.6 Pseudo-code DQN (version minimale)

Listing 18.1 – DQN (version minimale, pseudo-code).

```
1 Initialize Q_theta and target Q_theta_minus = Q_theta
2 Initialize replay buffer D
3
4 for episode = 1..E:
5     reset environment -> state s
6     for t = 1..T:
7         with prob epsilon choose random action a
8         else a = argmax_a Q_theta(s,a)
9         step -> (r, s_next)
10        store (s,a,r,s_next) in D
11        sample minibatch from D
12        y = r + gamma * max_a' Q_theta_minus(s_next, a')
13        minimize (Q_theta(s,a) - y)^2 over minibatch
14        every K steps: theta_minus <- theta
15        s <- s_next
```

18.7 Stabilité : la “deadly triad”

Il y a trois ingrédients qui, combinés, rendent l'apprentissage instable :

- **fonction approximatrice** (réseau de neurones) ;
- **bootstrapping** (cible dépend d'une estimation) ;
- **off-policy** (données générées par une autre politique).

DQN contient les trois : d'où la nécessité de replay buffer + target network + autres techniques.

18.7.1 Trucs pratiques (niveau M1)

- **clipping des rewards** ou normalisation : évite des gradients explosifs.
- **Double DQN** : réduit le biais d'optimisme du max en séparant sélection et évaluation.
- **Dueling architecture** : sépare valeur d'état et avantage d'action (utile si beaucoup d'actions similaires).

18.8 Actions continues : limites de DQN

Dans le hedging, l'action naturelle Δ est continue. DQN suppose un ensemble discret d'actions. Solution : discretiser Δ (ex. 41 niveaux entre -1 et $+1$), mais cela :

- augmente la taille de l'espace d'actions ;
- impose une granularité artificielle.

Extensions possibles :

- **DDPG/TD3** : actor-critic pour actions continues.
- **SAC** : ajoute entropie, souvent très stable.

18.9 Design du reward en hedging (le point non négociable)

Un reward mal défini donne une stratégie mauvaise mais “optimale” pour la mauvaise métrique. Exemples :

- reward = PnL brut : le modèle peut prendre du risque extrême.
- reward = $-\text{PnL}^2$: minimise variance, mais ignore CVaR.
- reward = $-\text{coûts} - \lambda \cdot \text{risque}$: compromis explicite.

En pratique, on doit décider : *qu’est-ce qu’on veut optimiser ?* (stabilité, drawdown, tail risk, etc.).

Exemple 18.1 (Reward simple risk-aware). À chaque pas :

$$r_t = -cS_t|\Delta_t - \Delta_{t-}| - \lambda(\Delta_t S_t)^2,$$

où le premier terme pénalise le turnover (coûts) et le second pénalise une exposition directionnelle trop grande. Ce n’est pas universel, mais illustre la logique : reward = coût + pénalité de risque.

Ce que le jury doit retenir.

- DQN approxime $Q(s, a)$ par un réseau et apprend via une loss TD $(Q_\theta - y)^2$.
- Replay buffer (dé-corrélation) et target network (cible stable) sont essentiels pour éviter la divergence.
- DQN discretise les actions : pour actions continues, on préfère des méthodes actor-critic (DDPG/TD3/SAC).
- Le design du reward est *le* point critique : on optimise ce qu’on code, pas ce qu’on souhaite implicitement.

Quatrième partie

Courbe des taux : discounting, forwards, calibration

Chapitre 19

Discount factors, taux spot et forwards : dérivations claires

19.1 Pourquoi une courbe des taux ?

Pour pricer des dérivés (options, swaps, forwards), il faut :

- actualiser des cashflows futurs ;
- parfois projeter des taux forwards (pour coupons flottants) ;
- être cohérent avec les instruments liquides du marché.

La courbe des taux est l'objet qui relie toutes ces opérations.

19.2 Discount factor, taux zéro, taux forward : définitions

Définition 19.1 (Discount factor). Le discount factor $P(0, T)$ est la valeur aujourd'hui d'1 euro certain à la date T :

$$P(0, T) = \text{PV}_0(1 \text{ payé à } T).$$

Définition 19.2 (Taux zéro (spot) continûment composé). Le taux spot $y(0, T)$ est défini par

$$P(0, T) = e^{-y(0, T)T} \iff y(0, T) = -\frac{1}{T} \log P(0, T).$$

Définition 19.3 (Forward instantané). Le forward instantané $f(0, T)$ est

$$f(0, T) = -\frac{\partial}{\partial T} \log P(0, T).$$

19.2.1 Relations entre y et f

Partant de $\log P(0, T) = -\int_0^T f(0, u) \, du$, on obtient

$$y(0, T) = \frac{1}{T} \int_0^T f(0, u) \, du.$$

Donc :

- f est la “densité” de taux ;
- y est une moyenne de f sur $[0, T]$.

19.3 Forward simple sur une période

Définition 19.4 (Forward simple entre T_1 et T_2). Le taux forward simple $F(0; T_1, T_2)$ (avec année fraction $\tau = T_2 - T_1$) est défini par

$$(1 + \tau F(0; T_1, T_2)) = \frac{P(0, T_1)}{P(0, T_2)}.$$

Donc

$$F(0; T_1, T_2) = \frac{1}{\tau} \left(\frac{P(0, T_1)}{P(0, T_2)} - 1 \right).$$

Dérivation (arbitrage) : acheter un zéro-coupon T_2 et vendre un T_1 crée un cashflow nul aujourd'hui et déterministe sur $[T_1, T_2]$, ce qui définit un taux forward sans arbitrage.

19.4 Bootstrapping (idée) : construire $P(0, T)$ à partir d'instruments liquides

Le bootstrapping consiste à :

- prendre des instruments courts (dépôts, OIS) pour obtenir $P(0, T)$ aux petites maturités ;
- utiliser des swaps (ou OIS swaps) pour étendre aux maturités plus longues.

L'idée essentielle : chaque instrument donne une équation linéaire en discount factors inconnus. On les résout séquentiellement en avançant en maturité.

Exemple 19.1 (Forward à partir de deux taux zéro). Supposons $y(0, 1) = 3\%$ et $y(0, 2) = 3.5\%$ (continu). Alors

$$P(0, 1) = e^{-0.03} \approx 0.9704, \quad P(0, 2) = e^{-0.07} \approx 0.9324.$$

Le forward simple sur $[1, 2]$ ($\tau = 1$) est :

$$F(0; 1, 2) = \frac{P(0, 1)}{P(0, 2)} - 1 \approx \frac{0.9704}{0.9324} - 1 \approx 0.0408 = 4.08\%.$$

19.5 Interpolation : point sensible

On observe $P(0, T)$ ou $y(0, T)$ sur une grille. Pour pricer, on doit interpoler. Bonnes pratiques :

- interpoler sur $\log P(0, T)$ (qui est souvent plus lisse) ;
- éviter des forwards négatifs non voulus ;
- utiliser des interpolations monotones/convexes si on veut préserver l'absence d'arbitrage (plus avancé).

Ce que le jury doit retenir.

- $P(0, T)$ est l'objet de base : tout le reste (taux spot, forwards) en découle.
- $y(0, T) = -(1/T) \log P(0, T)$ et $f(0, T) = -\partial_T \log P(0, T)$: y est une moyenne de f .
- Le forward simple sur $[T_1, T_2]$ vérifie $(1 + \tau F) = P(0, T_1)/P(0, T_2)$.
- Bootstrapping = résoudre séquentiellement des équations d'instruments liquides pour obtenir les discount factors.

Chapitre 20

Modèles paramétriques : Nelson–Siegel et Nelson–Siegel–Svensson

20.1 Pourquoi des modèles paramétriques ?

Une courbe bootstrapée donne des points $(T_i, P(0, T_i))$ ou $(T_i, y(0, T_i))$. Pour :

- obtenir une courbe lisse (et des forwards stables),
- extrapoler raisonnablement au-delà des points,
- résumer la forme de la courbe par quelques facteurs,

on utilise des modèles paramétriques.

20.2 Nelson–Siegel (NS) : formule et interprétation

Définition 20.1 (Nelson–Siegel (sur taux zéro)). Le taux zéro continûment composé est modélisé par

$$y(T) = \beta_0 + \beta_1 \frac{1 - e^{-T/\tau}}{T/\tau} + \beta_2 \left(\frac{1 - e^{-T/\tau}}{T/\tau} - e^{-T/\tau} \right),$$

avec paramètres $(\beta_0, \beta_1, \beta_2, \tau)$ et $T > 0$.

20.2.1 Lecture “level / slope / curvature”

Définissons les fonctions de base :

$$\ell(T) = 1, \quad s(T) = \frac{1 - e^{-T/\tau}}{T/\tau}, \quad c(T) = \frac{1 - e^{-T/\tau}}{T/\tau} - e^{-T/\tau}.$$

Alors

$$y(T) = \beta_0 \ell(T) + \beta_1 s(T) + \beta_2 c(T).$$

- β_0 (level) : comme $\lim_{T \rightarrow \infty} s(T) = 0$ et $\lim_{T \rightarrow \infty} c(T) = 0$, on a $\lim_{T \rightarrow \infty} y(T) = \beta_0$. Donc β_0 fixe le niveau long terme.
- β_1 (slope) : $s(0^+) = 1$, donc $y(0^+) \approx \beta_0 + \beta_1$. β_1 affecte surtout le court terme.
- β_2 (curvature) : $c(0^+) = 0$ et $c(T)$ est en cloche (maximum vers $T \approx \tau$). Donc β_2 ajuste la courbure au moyen terme.

20.2.2 Rôle de τ

Le paramètre τ positionne la zone de courbure : plus τ est grand, plus le “hump” se déplace vers les maturités longues.

20.3 Nelson–Siegel–Svensson (NSS)

Définition 20.2 (NSS). NSS ajoute un second terme de courbure :

$$y(T) = \beta_0 + \beta_1 s(T; \tau_1) + \beta_2 c(T; \tau_1) + \beta_3 c(T; \tau_2),$$

avec deux paramètres d’échelle τ_1, τ_2 .

Cela permet de fitter des courbes avec deux bosses (rare mais utile en pratique).

20.4 Calibration (moindres carrés)

On observe des taux y_i^{mkt} aux maturités T_i . On minimise :

$$\min_{\beta, \tau} \sum_{i=1}^n w_i \left(y(T_i; \beta, \tau) - y_i^{\text{mkt}} \right)^2.$$

Note : si τ est fixé, la calibration en β est un problème linéaire (régression), car y est linéaire en β . On peut donc :

- grid-search sur τ ,
- et pour chaque τ , résoudre un least squares en β .

C’est une stratégie très robuste (évite une optimisation non linéaire complète).

Exemple 20.1 (Illustration : forme NS avec paramètres simples). Prenons (en continuement composé) :

$$\beta_0 = 3\%, \quad \beta_1 = -2\%, \quad \beta_2 = 3\%, \quad \tau = 1.5.$$

On obtient une courbe qui démarre sous 3% (car $\beta_1 < 0$) puis remonte et se stabilise vers 3%.

20.5 Limites et usage pratique

- NS/NSS sont empiriques : ce ne sont pas des modèles “d’absence d’arbitrage” au sens strict.
- Les forwards dérivés peuvent être sensibles (car $f = -\partial_T \log P$ amplifie le bruit).
- Malgré cela, NS/NSS sont très utilisés comme *résumé factoriel* et pour des interpolations stables.

Ce que le jury doit retenir.

- Nelson–Siegel modélise $y(T)$ avec 4 paramètres : β_0 (niveau long), β_1 (pente court), β_2 (courbure moyen), τ (échelle).
- NSS ajoute un second terme de courbure pour plus de flexibilité.
- Calibration robuste : grid sur τ puis least squares en β (car linéaire en β à τ fixé).
- Limite : pas un modèle strictement arbitrage-free ; prudence sur les forwards dérivés.




FIGURE 20.1 – Exemple de courbe Nelson–Siegel (paramètres illustratifs).

Cinquième partie

Allocation de portefeuille & gestion du risque (décision d'investissement)

Chapitre 21

Markowitz : moyenne–variance, min-variance, max Sharpe

21.1 Pourquoi Markowitz ?

Un desk ou un gérant doit transformer des anticipations (rendements, risques, corrélations) en allocations w . Markowitz propose un cadre simple :

- le rendement est résumé par son espérance ;
- le risque est résumé par la variance ;
- on optimise un compromis rendement/risque.

C'est un modèle de base, mais il structure énormément de raisonnements en gestion.

21.2 Cadre : vecteur de rendements et matrice de covariance

Définition 21.1 (Rendements et portefeuille). Soit $R \in \mathbb{R}^n$ le vecteur de rendements (sur un horizon donné). On note

$$\mu = \mathbb{E}[R] \in \mathbb{R}^n, \quad \Sigma = \text{Cov}(R) \in \mathbb{R}^{n \times n}.$$

Pour des poids $w \in \mathbb{R}^n$ (somme à 1), le rendement du portefeuille est

$$R_p = w^\top R,$$

avec

$$\mathbb{E}[R_p] = w^\top \mu, \quad \text{Var}(R_p) = w^\top \Sigma w.$$

Hypothèses :

- μ et Σ existent et sont stables ;
- la variance est une mesure adéquate du risque ;
- pas de non-linéarités (options), pas de coûts (dans la version de base).

21.3 Problème moyenne–variance (forme contrainte)

Une formulation canonique :

$$\min_w \quad w^\top \Sigma w \quad \text{s.c.} \quad \begin{cases} w^\top \mu = m, \\ w^\top \mathbb{1} = 1. \end{cases}$$

On cherche la variance minimale pour un rendement cible m .

21.3.1 Dérivation par multiplicateurs de Lagrange (détaillée)

On forme le Lagrangien :

$$\mathcal{L}(w, \lambda, \nu) = w^\top \Sigma w - \lambda(w^\top \mu - m) - \nu(w^\top \mathbb{1} - 1).$$

Condition du premier ordre en w :

$$\nabla_w \mathcal{L} = 2\Sigma w - \lambda\mu - \nu\mathbb{1} = 0.$$

Donc

$$w = \frac{1}{2}\Sigma^{-1}(\lambda\mu + \nu\mathbb{1}).$$

On peut réabsorber le $\frac{1}{2}$ dans λ, ν et écrire

$$w = \Sigma^{-1}(a\mu + b\mathbb{1}),$$

pour certains scalaires a, b .

Imposons les contraintes. Définissons trois scalaires utiles :

$$A = \mathbb{1}^\top \Sigma^{-1} \mathbb{1}, \quad B = \mathbb{1}^\top \Sigma^{-1} \mu, \quad C = \mu^\top \Sigma^{-1} \mu.$$

Alors

$$\mathbb{1}^\top w = aB + bA = 1, \quad \mu^\top w = aC + bB = m.$$

C'est un système linéaire en (a, b) :

$$\begin{pmatrix} B & A \\ C & B \end{pmatrix} \begin{pmatrix} a \\ b \end{pmatrix} = \begin{pmatrix} 1 \\ m \end{pmatrix}.$$

Son déterminant vaut $D = AC - B^2$ (positif si Σ définie positive et μ non colinéaire à $\mathbb{1}$). On obtient

$$a = \frac{Bm - Am}{D}, \quad b = \frac{C - Bm}{D}.$$

Donc la solution explicite est

$$w(m) = \Sigma^{-1} \left(\frac{Bm - Am}{D} \mu + \frac{C - Bm}{D} \mathbb{1} \right).$$

21.3.2 Frontière efficiente

On peut aussi obtenir la variance minimale associée à m :

$$\sigma_p^2(m) = w(m)^\top \Sigma w(m) = \frac{Am^2 - 2Bm + C}{D}.$$

C'est une parabole en (σ, m) : la frontière efficiente.

21.4 Portefeuille de variance minimale globale (GMV)

Si on enlève la contrainte de rendement (on ne fixe que $w^\top \mathbb{1} = 1$), on obtient :

$$w^{\text{GMV}} = \frac{\Sigma^{-1} \mathbb{1}}{\mathbb{1}^\top \Sigma^{-1} \mathbb{1}} = \frac{\Sigma^{-1} \mathbb{1}}{A}.$$

C'est le portefeuille le moins risqué possible (sous la mesure variance) parmi ceux investis à 100%.

21.5 Max Sharpe (portefeuille tangentiel)

Si on a un actif sans risque de taux r_f , on veut maximiser le ratio de Sharpe

$$SR(w) = \frac{w^\top \mu - r_f}{\sqrt{w^\top \Sigma w}} \quad \text{avec } w^\top \mathbb{1} = 1.$$

Le portefeuille tangentiel (sans contrainte long-only) est proportionnel à :

$$w_{\text{tan}} \propto \Sigma^{-1}(\mu - r_f \mathbb{1}).$$

Puis on normalise pour que la somme fasse 1.

21.6 Contraintes, estimation risk, robustesse

Les deux gros problèmes en pratique :

- **contraintes** : long-only, limites de poids, exposition sectorielle, etc. $\Rightarrow$ optimisation quadratique (QP) sans solution fermée.
- **estimation** : μ est très bruité, Σ aussi (surtout en grande dimension). Les poids Markowitz deviennent instables et extrêmes.

Solutions usuelles :

- shrinkage de covariance (Ledoit–Wolf), factor models ;
- robust optimization (pénaliser l'incertitude sur μ) ;
- privilégier des portefeuilles moins sensibles à μ (min-variance, risk parity).

Exemple 21.1 (Deux actifs : calcul explicite). Supposons deux actifs avec

$$\mu = \begin{pmatrix} 6\% \\ 10\% \end{pmatrix}, \quad \Sigma = \begin{pmatrix} 0.04 & 0.01 \\ 0.01 & 0.09 \end{pmatrix}.$$

On cherche le GMV :

$$\Sigma^{-1} = \frac{1}{0.04 \cdot 0.09 - 0.01^2} \begin{pmatrix} 0.09 & -0.01 \\ -0.01 & 0.04 \end{pmatrix} = \frac{1}{0.0035} \begin{pmatrix} 0.09 & -0.01 \\ -0.01 & 0.04 \end{pmatrix}.$$

Alors

$$\Sigma^{-1} \mathbb{1} = \frac{1}{0.0035} \begin{pmatrix} 0.08 \\ 0.03 \end{pmatrix}, \quad A = \mathbb{1}^\top \Sigma^{-1} \mathbb{1} = \frac{0.11}{0.0035}.$$

Donc

$$w_{\text{GMV}} = \frac{1}{0.11} \begin{pmatrix} 0.08 \\ 0.03 \end{pmatrix} \approx \begin{pmatrix} 72.7\% \\ 27.3\% \end{pmatrix}.$$

Ce que le jury doit retenir.

- Markowitz résume le risque par la variance : $\text{Var}(R_p) = w^\top \Sigma w$.
- L'optimisation min-variance pour un rendement cible m a une solution fermée via Lagrange ; la frontière efficiente est $\sigma^2(m) = (Am^2 - 2Bm + C)/D$.
- GMV : $w_{\text{GMV}} = \Sigma^{-1} \mathbb{1} / (\mathbb{1}^\top \Sigma^{-1} \mathbb{1})$.
- En pratique, estimation risk et contraintes dominant : d'où shrinkage, factor models, risk parity.

Chapitre 22

Risk parity et risk budgeting : dérivations et intuition

22.1 Pourquoi risk parity ?

Markowitz dépend fortement de μ (rendements attendus), très bruités. Risk parity propose une alternative :

- on ignore (ou on réduit) le rôle de μ ;
- on construit un portefeuille où chaque actif contribue “également” au risque.

C’est souvent plus stable out-of-sample.

22.2 Volatilité de portefeuille et contributions

Soit $\sigma_p = \sqrt{w^\top \Sigma w}$ la volatilité du portefeuille. La *contribution marginale* au risque du poids w_i est :

$$\frac{\partial \sigma_p}{\partial w_i} = \frac{(\Sigma w)_i}{\sigma_p}.$$

Définition 22.1 (Risk contribution). La contribution au risque de l’actif i est

$$\text{RC}_i = w_i \frac{\partial \sigma_p}{\partial w_i} = w_i \frac{(\Sigma w)_i}{\sigma_p}.$$

22.2.1 Somme des contributions

On a :

$$\sum_{i=1}^n \text{RC}_i = \frac{1}{\sigma_p} \sum_i w_i (\Sigma w)_i = \frac{w^\top \Sigma w}{\sigma_p} = \sigma_p.$$

Donc les contributions s’additionnent exactement à la volatilité du portefeuille.

22.3 Risk parity (budgets égaux)

Risk parity “pur” impose

$$\text{RC}_1 = \dots = \text{RC}_n = \frac{\sigma_p}{n}.$$

Plus généralement, on fixe des budgets $b_i > 0$ avec $\sum b_i = 1$ et on impose :

$$\text{RC}_i = b_i \sigma_p.$$

En remplaçant :

$$w_i(\Sigma w)_i = b_i w^\top \Sigma w.$$

C'est un système non linéaire en w .

22.4 Cas particulier : actifs non corrélés

Si Σ est diagonale, $\Sigma = \text{diag}(\sigma_1^2, \dots, \sigma_n^2)$, alors $(\Sigma w)_i = \sigma_i^2 w_i$. La condition RC égal s'écrit :

$$w_i \frac{\sigma_i^2 w_i}{\sigma_p} = \frac{\sigma_p}{n} \implies w_i^2 \sigma_i^2 = \frac{\sigma_p^2}{n}.$$

Donc $w_i \propto 1/\sigma_i$. **Conclusion** : en l'absence de corrélations, risk parity = inverse-volatility.

Exemple 22.1 (Deux actifs non corrélés). Actif 1 : $\sigma_1 = 10\%$, actif 2 : $\sigma_2 = 20\%$. Alors $w_1 : w_2 = 1/0.1 : 1/0.2 = 2 : 1$. Donc $w_1 = 2/3$, $w_2 = 1/3$. Les deux contributions au risque sont égales (par construction).

22.5 Résolution numérique : idées d'algorithmes

On peut résoudre risk parity via :

— **optimisation** : minimiser une loss mesurant l'écart aux budgets, par exemple

$$\min_w \sum_i (\text{RC}_i - b_i \sigma_p)^2 \quad \text{s.c.} \quad w_i \geq 0, \quad \sum w_i = 1.$$

— **log-weights** : poser $w_i = \exp(x_i) / \sum_j \exp(x_j)$ pour imposer $w_i > 0$ et réduire le problème aux x .

— **méthodes itératives** : mise à jour multiplicative des poids selon l'écart des contributions.

Remarque 22.1 (Trade-off corrélations). Quand les actifs sont corrélés, l'inverse-volatility n'est plus vrai. Un actif très corrélé aux autres peut contribuer beaucoup au risque même avec un petit poids. Risk parity ajuste implicitement les poids pour répartir le risque de corrélation.

22.6 Limites

- dépend toujours de Σ (donc estimation risk sur la covariance) ;
- ignore μ : peut sous-investir des actifs à forte prime de risque ;
- peut concentrer dans des actifs très peu volatils mais très corrélés à un facteur latent.

D'où l'usage de "risk budgeting" par classes d'actifs ou facteurs.

Ce que le jury doit retenir.

- Contribution au risque : $\text{RC}_i = w_i(\Sigma w)_i / \sigma_p$; la somme vaut σ_p .
- Risk parity : imposer $\text{RC}_i = b_i \sigma_p$ (budgets de risque).
- Cas non corrélé : $w_i \propto 1/\sigma_i$ (inverse-volatility).
- En pratique : résolution numérique + dépendance à l'estimation de la covariance.

Chapitre 23

ACP (PCA), eigen-portfolios et modèles factoriels

23.1 Pourquoi PCA en finance ?

Quand on a beaucoup d'actifs (n grand), estimer Σ est difficile. PCA (Analyse en Composantes Principales) aide à :

- comprendre les facteurs de risque dominants ;
- réduire la dimension (approximer Σ par quelques facteurs) ;
- construire des portefeuilles exposés à des facteurs (eigen-portfolios).

23.2 Décomposition spectrale de la covariance

Théorème 23.1 (Décomposition). *Si Σ est symétrique définie positive, alors*

$$\Sigma = V\Lambda V^\top,$$

où V est orthogonale ($V^\top V = I$) et $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$ avec $\lambda_1 \geq \dots \geq \lambda_n > 0$.

Les vecteurs colonnes v_k de V sont les directions principales (eigenvectors). Les λ_k mesurent la variance portée par chaque composante.

23.2.1 Variance expliquée

La part de variance expliquée par le facteur k est

$$\frac{\lambda_k}{\sum_{j=1}^n \lambda_j}.$$

En finance actions, on observe souvent :

- λ_1 très dominant (facteur “marché”) ;
- quelques facteurs sectoriels/styles ;
- beaucoup de petits facteurs (bruit/idiosyncratique).

23.3 Réduction de dimension : approximation à m facteurs

On approxime

$$\Sigma \approx \sum_{k=1}^m \lambda_k v_k v_k^\top.$$

Cela revient à un modèle factoriel :

$$R \approx \mu + BF + \varepsilon,$$

où $F \in \mathbb{R}^m$ sont les facteurs, B les loadings, et ε l'idiosyncratique.

23.4 Eigen-portfolios

Un eigen-portfolio associé au facteur k est un portefeuille proportionnel à v_k . Si on prend $w = v_k$ (normalisé), alors

$$\text{Var}(w^\top R) = v_k^\top \Sigma v_k = \lambda_k.$$

Donc v_1 est le portefeuille de variance maximale sous contrainte $\|w\| = 1$.

Exemple 23.1 (PCA sur 3 actifs (schéma)). Supposons que la covariance a une première valeur propre très grande. Alors le premier eigenvector est proche de $(1, 1, 1)/\sqrt{3}$: tous les actifs bougent ensemble (facteur commun). Le second et le troisième représentent des spreads (long certains actifs, short d'autres).

23.5 Shrinkage et régularisation via PCA

Une technique pratique :

- garder les m premières composantes (structure) ;
- remplacer le reste par une variance moyenne (bruit).

On obtient une covariance “plus stable” et inversible, utile pour Markowitz.

Remarque 23.1 (Danger : instabilité des vecteurs propres). Les eigenvectors estimés sont très sensibles au bruit, surtout quand les valeurs propres sont proches. Donc “trader” les eigen-portfolios de petits facteurs peut être extrêmement instable.

Ce que le jury doit retenir.

- PCA diagonalise la covariance : $\Sigma = V\Lambda V^\top$; les λ_k donnent la variance par facteur.
- On peut approximer Σ par m facteurs dominants : réduction de dimension et stabilité.
- Les eigen-portfolios (v_k) donnent des expositions directes aux facteurs de risque.
- Attention : les petits facteurs (petites λ) sont souvent dominés par le bruit d'estimation.

Chapitre 24

Rebalancing, coûts de transaction et exécution : du modèle à la réalité

24.1 Pourquoi le rebalancing est un problème non trivial ?

Un portefeuille optimal théorique suppose qu'on peut :

- ajuster instantanément les poids,
- sans coûts,
- sans impact sur les prix.

En réalité, chaque rebalancing crée :

- du turnover (volume tradé),
- des coûts explicites (commissions) et implicites (spread, impact),
- des contraintes opérationnelles (liquidité, lots, contraintes réglementaires).

Donc on doit optimiser *avec* les coûts.

24.2 Mesure du turnover

Entre deux dates, le turnover peut être approximé par

$$\text{TO} = \sum_{i=1}^n |w_i^{\text{new}} - w_i^{\text{old}}|.$$

Plus le turnover est grand, plus les coûts sont élevés.

24.3 Modèles de coûts

24.3.1 Coûts proportionnels

Simple :

$$\text{coût} = c \sum_i |\Delta q_i| \cdot \text{prix}_i,$$

où Δq_i est la variation de quantité.

24.3.2 Impact quadratique (stylisé)

Pour refléter que de gros ordres coûtent plus que proportionnellement :

$$\text{coût} \approx \sum_i \left(c_1 |\Delta q_i| + c_2 (\Delta q_i)^2 \right).$$

Cela incite à lisser l'exécution.

24.4 Rebalancing périodique vs seuil

24.4.1 Périodique

On rebalancera toutes les semaines/mois. Avantage : simple. Inconvénient : on trade même quand les poids ont peu dérivé.

24.4.2 Seuil (band rebalancing)

On rebalancera seulement si

$$|w_i^{\text{drift}} - w_i^{\text{target}}| > \epsilon_i.$$

Avantage : réduit le turnover. Inconvénient : plus complexe à analyser ; risque de dérive.

Exemple 24.1 (Intuition). Si le portefeuille cible est 60/40 actions/obligations et que le marché bouge peu, un rebalancing hebdo crée des coûts inutiles. Une règle à seuil attend que l'écart dépasse, par exemple, 2% avant de trader.

24.5 Optimisation “cost-aware” (idée)

On peut modifier l'objectif Markowitz en ajoutant une pénalité de turnover :

$$\min_w \quad w^\top \Sigma w - \lambda w^\top \mu + \eta \sum_i |w_i - w_i^{\text{old}}|,$$

ou une pénalité quadratique $\eta \|w - w^{\text{old}}\|^2$ (plus facile numériquement). Cela produit des allocations plus “lentes” et plus réalistes.

24.6 Lien avec le hedging d'options

La logique est identique :

- hedging = rebalancing d'une position Δ ;
- coûts de transaction = pénalité sur la variation de Δ ;
- compromis risque/coût = choix d'une fréquence ou d'un contrôle optimal.

C'est exactement ce qui motive les stratégies RL “risk-aware” (Partie III).

Ce que le jury doit retenir.

- Sans coûts, on rebalance “tout le temps” ; avec coûts, on cherche un compromis risque vs turnover.
- Turnover $\sum |\Delta w_i|$ est un proxy simple du coût.
- Modèles de coûts : proportionnels (spread) et quadratiques (impact) ; ils changent la solution optimale.
- Band rebalancing et pénalités de turnover sont des outils pratiques pour rendre un modèle allocable.

Sixième partie

**Exercices guidés (avec solutions) :
consolider les notions**

Chapitre 25

Feuille 1 : Brownien, Itô et Black–Scholes

Ce chapitre propose une série d'exercices *corrigés*. L'objectif n'est pas de piéger, mais de forcer la maîtrise opérationnelle : passer d'une intuition ("le bruit est en $\sqrt{t}$ ") à un calcul concret.

25.1 Exercice 1 — incréments browniens et moments

Exemple 25.1 (Énoncé). Soit $(W_t)_{t \geq 0}$ un Brownien standard.

- a) Calculer $\mathbb{E}[W_t]$ et $\text{Var}(W_t)$.
- b) Pour $0 \leq s < t$, calculer la loi de $W_t - W_s$ et $\text{Cov}(W_s, W_t)$.
- c) Montrer que $\mathbb{E}[W_s W_t] = s$.

Solution

- a) Par définition, $W_t \sim \mathcal{N}(0, t)$, donc $\mathbb{E}[W_t] = 0$ et $\text{Var}(W_t) = t$.
- b) Les incréments sont stationnaires et indépendants : $W_t - W_s \sim \mathcal{N}(0, t - s)$ et il est indépendant de $\mathcal{F}_s$. Pour la covariance, écrire $W_t = W_s + (W_t - W_s)$, d'où

$$\text{Cov}(W_s, W_t) = \text{Cov}(W_s, W_s) + \text{Cov}(W_s, W_t - W_s) = \text{Var}(W_s) + 0 = s.$$

- c) Comme $\mathbb{E}[W_s] = 0$ et $\mathbb{E}[W_t] = 0$,

$$\mathbb{E}[W_s W_t] = \text{Cov}(W_s, W_t) = s.$$

Ce que le jury doit retenir.

- $W_t \sim \mathcal{N}(0, t) \Rightarrow$ échelle $\sqrt{t}$.
- $W_t = W_s + (W_t - W_s)$, avec incrément indépendant : outil de base pour covariances.

25.2 Exercice 2 — variation quadratique : calcul guidé

Exemple 25.2 (Énoncé). Soit une partition uniforme $0 = t_0 < t_1 < \dots < t_n = T$ avec $t_k = k\Delta t$. Définissons $Q_n = \sum_{k=0}^{n-1} (W_{t_{k+1}} - W_{t_k})^2$.

- a) Calculer $\mathbb{E}[Q_n]$.
- b) Calculer $\text{Var}(Q_n)$.
- c) Conclure que $Q_n \rightarrow T$ en probabilité.

Solution

Les incréments $\Delta W_k \triangleq W_{t_{k+1}} - W_{t_k}$ sont i.i.d. $\mathcal{N}(0, \Delta t)$.

a) $\mathbb{E}[(\Delta W_k)^2] = \text{Var}(\Delta W_k) = \Delta t$, donc

$$\mathbb{E}[Q_n] = \sum_{k=0}^{n-1} \Delta t = n\Delta t = T.$$

b) Pour une gaussienne centrée $X \sim \mathcal{N}(0, \sigma^2)$, on a $\mathbb{E}[X^4] = 3\sigma^4$. Donc $\text{Var}(X^2) = \mathbb{E}[X^4] - \mathbb{E}[X^2]^2 = 3\sigma^4 - \sigma^4 = 2\sigma^4$. Ici $\sigma^2 = \Delta t$, donc $\text{Var}((\Delta W_k)^2) = 2(\Delta t)^2$. Par indépendance :

$$\text{Var}(Q_n) = \sum_{k=0}^{n-1} 2(\Delta t)^2 = 2n(\Delta t)^2 = 2T\Delta t \xrightarrow{n \rightarrow \infty} 0.$$

c) Comme $\mathbb{E}[Q_n] = T$ et $\text{Var}(Q_n) \rightarrow 0$, on a $Q_n \rightarrow T$ en L^2 , donc en probabilité.

25.3 Exercice 3 — résoudre le GBM par Itô

Exemple 25.3 (Énoncé). Sous $\mathbb{Q}$, supposons

$$\frac{dS_t}{S_t} = (r - q) dt + \sigma dW_t^{\mathbb{Q}}.$$

- a) Appliquer Itô à $\log S_t$ et en déduire une expression explicite de S_T .
- b) En déduire la loi de $\log S_T$.
- c) Calculer $\mathbb{E}^{\mathbb{Q}}[S_T]$ et vérifier qu'on retrouve le forward.

Solution

a) Pour $f(S) = \log S$, on a $f'(S) = 1/S$ et $f''(S) = -1/S^2$. Par Itô :

$$d \log S_t = \frac{1}{S_t} dS_t + \frac{1}{2} \left(-\frac{1}{S_t^2} \right) (dS_t)^2.$$

Or $(dS_t)^2 = (\sigma S_t)^2 dt = \sigma^2 S_t^2 dt$. Donc

$$d \log S_t = (r - q) dt + \sigma dW_t^{\mathbb{Q}} - \frac{1}{2} \sigma^2 dt = \left((r - q) - \frac{1}{2} \sigma^2 \right) dt + \sigma dW_t^{\mathbb{Q}}.$$

En intégrant :

$$\log S_T = \log S_0 + \left((r - q) - \frac{1}{2} \sigma^2 \right) T + \sigma W_T^{\mathbb{Q}}.$$

Donc

$$S_T = S_0 \exp \left(\left((r - q) - \frac{1}{2} \sigma^2 \right) T + \sigma W_T^{\mathbb{Q}} \right).$$

b) Comme $W_T^{\mathbb{Q}} \sim \mathcal{N}(0, T)$, on a

$$\log S_T \sim \mathcal{N} \left(\log S_0 + \left((r - q) - \frac{1}{2} \sigma^2 \right) T, \sigma^2 T \right).$$

c) Par propriété de la lognormale, si $Y \sim \mathcal{N}(m, s^2)$ alors $\mathbb{E}[e^Y] = e^{m + \frac{1}{2}s^2}$. Ici, $m = \log S_0 + \left((r - q) - \frac{1}{2} \sigma^2 \right) T$ et $s^2 = \sigma^2 T$. Donc

$$\mathbb{E}^{\mathbb{Q}}[S_T] = \mathbb{E}^{\mathbb{Q}}[e^{\log S_T}] = \exp \left(m + \frac{1}{2} s^2 \right) = S_0 e^{(r-q)T} = F_{0,T}.$$

25.4 Exercice 4 — retrouver la formule de Black–Scholes

Exemple 25.4 (Énoncé). On considère un call européen C_0 de maturité T et strike K . En utilisant la loi de $\log S_T$ sous $\mathbb{Q}$, montrer que

$$C_0 = S_0 e^{-qT} \Phi(d_1) - K e^{-rT} \Phi(d_2) \quad \text{avec} \quad d_1 = \frac{\log(S_0/K) + (r - q + \frac{1}{2}\sigma^2)T}{\sigma\sqrt{T}}, \quad d_2 = d_1 - \sigma\sqrt{T}.$$

Solution (détaillée)

Le prix risque-neutre est

$$C_0 = \mathbb{E}^{\mathbb{Q}}[e^{-rT}(S_T - K)^+].$$

On sépare :

$$C_0 = e^{-rT} \mathbb{E}^{\mathbb{Q}}[S_T \mathbb{1}_{\{S_T > K\}}] - e^{-rT} K \mathbb{Q}(S_T > K).$$

Posons $X \triangleq \log S_T$; alors $X \sim \mathcal{N}(m, s^2)$ avec

$$m = \log S_0 + \left((r - q) - \frac{1}{2}\sigma^2 \right) T, \quad s = \sigma\sqrt{T}.$$

La condition $S_T > K$ est $X > \log K$.

— Pour la probabilité :

$$\mathbb{Q}(S_T > K) = \mathbb{Q}(X > \log K) = \Phi\left(\frac{m - \log K}{s}\right) = \Phi(d_2),$$

où l'on vérifie que

$$d_2 = \frac{\log(S_0/K) + (r - q - \frac{1}{2}\sigma^2)T}{\sigma\sqrt{T}}.$$

— Pour l'espérance tronquée $\mathbb{E}[S_T \mathbb{1}_{\{S_T > K\}}] = \mathbb{E}[e^X \mathbb{1}_{\{X > \log K\}}]$, on utilise un calcul standard de gaussienne complétée au carré. Écrivons la densité de X :

$$f(x) = \frac{1}{s\sqrt{2\pi}} \exp\left(-\frac{(x - m)^2}{2s^2}\right).$$

Alors

$$\mathbb{E}[e^X \mathbb{1}_{\{X > \log K\}}] = \int_{\log K}^{\infty} e^x f(x) dx.$$

On combine les exponentielles et on complète le carré :

$$e^x \exp\left(-\frac{(x - m)^2}{2s^2}\right) = \exp\left(-\frac{(x - (m + \frac{1}{2}s^2))^2}{2s^2}\right) \exp\left(m + \frac{1}{2}s^2\right).$$

Donc

$$\mathbb{E}[e^X \mathbb{1}_{\{X > \log K\}}] = \exp\left(m + \frac{1}{2}s^2\right) \Phi\left(\frac{m + s^2 - \log K}{s}\right).$$

Or $\exp(m + \frac{1}{2}s^2) = \mathbb{E}[S_T] = S_0 e^{(r-q)T}$ et

$$\frac{m + s^2 - \log K}{s} = \frac{\log(S_0/K) + (r - q + \frac{1}{2}\sigma^2)T}{\sigma\sqrt{T}} = d_1.$$

Finalement

$$\mathbb{E}[S_T \mathbb{1}_{\{S_T > K\}}] = S_0 e^{(r-q)T} \Phi(d_1).$$

En remplaçant dans la formule du prix :

$$C_0 = e^{-rT} \left(S_0 e^{(r-q)T} \Phi(d_1) - K \Phi(d_2) \right) = S_0 e^{-qT} \Phi(d_1) - K e^{-rT} \Phi(d_2).$$

Ce que le jury doit retenir.

- La formule BS se déduit d’une espérance risque-neutre + loi lognormale.
- Le “truc” technique est la complétion du carré pour intégrer e^x contre une densité gaussienne.

Chapitre 26

Feuille 2 : volatilité implicite, surface et calibration (Heston/SABR)

26.1 Exercice 1 — densité risque-neutre et convexité

Exemple 26.1 (Énoncé). Fixons une maturité T . On rappelle la relation de Breeden–Litzenberger :

$$\frac{\partial^2 C}{\partial K^2}(K, T) = e^{-rT} f_{S_T}(K).$$

- a) Expliquer pourquoi la convexité de $C(K, T)$ en K est une condition de non-arbitrage.
- b) Proposer une approximation discrète de $\frac{\partial^2 C}{\partial K^2}$ à partir de prix de calls observés sur une grille de strikes.
- c) Comment vérifier qualitativement, à partir de la densité, la présence d'un skew "put" ?

Solution

- a) Un call est une espérance de $(S_T - K)^+$, qui est convexe en K . L'espérance conserve la convexité : si C n'est pas convexe, on peut construire un butterfly statique (combinaison linéaire de calls) avec payoff positif mais prix négatif $\Rightarrow$ arbitrage.
- b) Sur strikes équidistants K_{i-1}, K_i, K_{i+1} , une seconde différence finie :

$$\frac{\partial^2 C}{\partial K^2}(K_i) \approx \frac{C(K_{i+1}) - 2C(K_i) + C(K_{i-1}))}{(\Delta K)^2}.$$

- c) Un skew put sur indices correspond à une queue gauche plus lourde en $\mathbb{Q}$: la densité a plus de masse pour des S_T bas. Qualitativement, cela se traduit par des calls très OTM (grands K) relativement bon marché et des puts OTM (petits K) chers ; via la relation ci-dessus, la densité est plus asymétrique vers la gauche.

26.2 Exercice 2 — inversion de la volatilité implicite (Newton sécurisé)

Exemple 26.2 (Énoncé). On observe un prix de call C^{mkt} . On veut l'IV σ telle que $C^{\text{BS}}(\sigma) = C^{\text{mkt}}$.

- a) Écrire l'itération de Newton.
- b) Expliquer pourquoi Newton peut diverger pour des options très OTM.
- c) Proposer un schéma "robuste" combinant bisection et Newton.

Solution

- $\sigma_{n+1} = \sigma_n - \frac{C^{\text{BS}}(\sigma_n) - C^{\text{mkt}}}{\text{Vega}(\sigma_n)}$.
- Quand l'option est très OTM ou très proche de maturité, Vega est faible. La division par un petit nombre amplifie l'erreur, et l'approximation linéaire de Newton est mauvaise $\Rightarrow$ saut trop grand.
- Encadrer σ dans un intervalle $[\sigma_{\min}, \sigma_{\max}]$ (ex. $[10^{-4}, 5]$). À chaque itération, faire un pas de Newton ; s'il sort de l'intervalle ou n'améliore pas l'erreur, remplacer par une bisection. Ce schéma converge toujours (bisection), tout en restant rapide quand Newton est bien conditionné.

26.3 Exercice 3 — condition de Feller et interprétation

Exemple 26.3 (Énoncé). Dans Heston : $dv_t = \kappa(\theta - v_t)dt + \xi\sqrt{v_t}dW_t$.

- Rappeler la condition de Feller.
- Pour $(\kappa, \theta, \xi) = (2, 0.04, 0.6)$, la condition est-elle satisfaite ?
- Que se passe-t-il numériquement si v_t touche 0 ?

Solution

- $2\kappa\theta \geq \xi^2$.
- $2\kappa\theta = 2 \cdot 2 \cdot 0.04 = 0.16$ et $\xi^2 = 0.36 \Rightarrow$ non.
- Si v_t approche 0, la diffusion $\xi\sqrt{v_t}$ s'éteint mais le terme de drift peut réinjecter. En simulation discrète, on peut obtenir des valeurs négatives si l'on n'est pas prudent (Euler naïf) ; d'où l'usage de schémas adaptés (full truncation, QE, réflexion) et/ou reparamétrisations.

26.4 Exercice 4 — SABR : calcul ATM

Exemple 26.4 (Énoncé). Dans la formule de Hagan, l'IV ATM (au premier ordre) s'écrit

$$\sigma_{\text{ATM}} \approx \frac{\alpha}{F^{1-\beta}} \left(1 + \left(\frac{(1-\beta)^2}{24} \frac{\alpha^2}{F^{2-2\beta}} + \frac{\rho\beta\nu\alpha}{4F^{1-\beta}} + \frac{2-3\rho^2}{24} \nu^2 \right) T \right).$$

Pour $F = 100$, $\beta = 0.5$, $\alpha = 0.2$, $\nu = 0.6$, $\rho = -0.3$, $T = 1$:

- Calculer le terme principal $\alpha/F^{1-\beta}$.
- Évaluer la correction en T (ordre de grandeur).

Solution

- $F^{1-\beta} = 100^{0.5} = 10$, donc terme principal $0.2/10 = 0.02$ (soit 2%).
- On calcule séparément les trois contributions dans la parenthèse :

$$\begin{aligned} \frac{(1-\beta)^2}{24} \frac{\alpha^2}{F^{2-2\beta}} &= \frac{0.25}{24} \frac{0.04}{100^1} \approx \frac{0.25}{24} \cdot 0.0004 \approx 4.2 \times 10^{-6}, \\ \frac{\rho\beta\nu\alpha}{4F^{1-\beta}} &= \frac{-0.3 \cdot 0.5 \cdot 0.6 \cdot 0.2}{4 \cdot 10} \approx \frac{-0.018}{40} \approx -4.5 \times 10^{-4}, \\ \frac{2-3\rho^2}{24} \nu^2 &= \frac{2-3 \cdot 0.09}{24} \cdot 0.36 = \frac{1.73}{24} \cdot 0.36 \approx 0.02595. \end{aligned}$$

La correction est dominée par le terme en ν^2 : environ +2.6% en relatif. Donc $\sigma_{\text{ATM}} \approx 0.02 \times (1 + 0.026) \approx 0.0205$ (2.05%).

Ce que le jury doit retenir.

- L'IV de marché encode une densité risque-neutre ; les contraintes d'arbitrage sont des contraintes de convexité/monotonie.
- Newton pour l'IV est rapide mais doit être sécurisé (vega faible).
- Dans Heston, Feller est une contrainte de robustesse ; dans SABR, l'expansion de Hagan permet des calculs quasi fermés.

Chapitre 27

Feuille 3 : courbe des taux, optimisation de portefeuille et risque

27.1 Exercice 1 — bootstrapping minimal (zéro-coupons)

Exemple 27.1 (Énoncé). On observe des taux zéro-coupon (compounded en continu) :

$$R(0, 1) = 3\%, \quad R(0, 2) = 3.5\%, \quad R(0, 3) = 4\%.$$

- a) Calculer les discount factors $P(0, T)$ pour $T = 1, 2, 3$.
- b) Calculer le forward (continu) $f(1, 2)$ tel que $P(0, 2) = P(0, 1)e^{-f(1, 2)(2-1)}$.

Solution

- a) En continu, $P(0, T) = e^{-R(0, T)T}$. Donc $P(0, 1) = e^{-0.03} \approx 0.9704$, $P(0, 2) = e^{-0.035 \cdot 2} = e^{-0.07} \approx 0.9324$, $P(0, 3) = e^{-0.04 \cdot 3} = e^{-0.12} \approx 0.8869$.
- b) On impose $P(0, 2) = P(0, 1)e^{-f(1, 2)}$. Donc $f(1, 2) = \log\left(\frac{P(0, 1)}{P(0, 2)}\right) = \log\left(\frac{0.9704}{0.9324}\right) \approx 0.0399$ (3.99%).

27.2 Exercice 2 — Markowitz (2 actifs) : solution fermée

Exemple 27.2 (Énoncé). Deux actifs avec rendements espérés $\mu = (8\%, 4\%)$ et covariance

$$\Sigma = \begin{pmatrix} 0.04 & 0.01 \\ 0.01 & 0.01 \end{pmatrix}.$$

On cherche le portefeuille de variance minimale sous contrainte $w_1 + w_2 = 1$.

- a) Résoudre par Lagrangien.
- b) Calculer la variance du portefeuille optimal.

Solution

On minimise $w^\top \Sigma w$ sous $\mathbb{1}^\top w = 1$. Lagrangien : $\mathcal{L}(w, \lambda) = w^\top \Sigma w - \lambda(\mathbb{1}^\top w - 1)$. Condition du premier ordre : $2\Sigma w - \lambda \mathbb{1} = 0$, donc

$$w = \frac{\lambda}{2} \Sigma^{-1} \mathbb{1}.$$

Imposer $\mathbb{1}^\top w = 1$ donne

$$\frac{\lambda}{2} \mathbb{1}^\top \Sigma^{-1} \mathbb{1} = 1 \quad \Rightarrow \quad \lambda = \frac{2}{\mathbb{1}^\top \Sigma^{-1} \mathbb{1}}.$$

Donc

$$w^{\text{MV}} = \frac{\Sigma^{-1} \mathbb{1}}{\mathbb{1}^\top \Sigma^{-1} \mathbb{1}}.$$

Calculons Σ^{-1} : déterminant $0.04 \cdot 0.01 - 0.01^2 = 0.0004 - 0.0001 = 0.0003$.

$$\Sigma^{-1} = \frac{1}{0.0003} \begin{pmatrix} 0.01 & -0.01 \\ -0.01 & 0.04 \end{pmatrix} = \begin{pmatrix} 33.33 & -33.33 \\ -33.33 & 133.33 \end{pmatrix}.$$

Alors $\Sigma^{-1} \mathbb{1} = (0, 100)^\top$ et $\mathbb{1}^\top \Sigma^{-1} \mathbb{1} = 100$. Donc $w = (0, 1)$: tout sur l'actif 2 (beaucoup moins risqué). Variance : $w^\top \Sigma w = 0.01$.

27.3 Exercice 3 — risk parity à deux actifs

Exemple 27.3 (Énoncé). Deux actifs non corrélés de volatilités $\sigma_1 = 20\%$ et $\sigma_2 = 10\%$. En risk parity (sans levier), on veut des contributions au risque égales.

- Trouver les poids w_1, w_2 .
- Donner l'intuition économique.

Solution

Si la corrélation est nulle, la volatilité du portefeuille est

$$\sigma_p = \sqrt{(w_1 \sigma_1)^2 + (w_2 \sigma_2)^2}.$$

La contribution marginale au risque de l'actif i vaut (ici)

$$\text{RC}_i \propto w_i \sigma_i^2.$$

L'égalité des contributions impose $w_1 \sigma_1^2 = w_2 \sigma_2^2$. Donc

$$\frac{w_1}{w_2} = \frac{\sigma_2^2}{\sigma_1^2} = \frac{0.1^2}{0.2^2} = \frac{1}{4}.$$

Avec $w_1 + w_2 = 1$, on obtient $w_1 = 0.2$ et $w_2 = 0.8$.

Intuition : risk parity met plus de poids sur l'actif moins risqué pour équilibrer les contributions. Ce n'est pas "min-variance" : la contrainte d'égalité des contributions est une préférence de diversification du risque.

Ce que le jury doit retenir.

- Bootstrapping : $P(0, T) = e^{-R(0, T)T}$ (continu) ; les forwards se déduisent par ratios de discount.
- Markowitz : la solution min-variance a une forme fermée via $\Sigma^{-1} \mathbb{1}$.
- Risk parity : égaliser des contributions revient souvent à surpondérer les actifs moins volatils.

Chapitre 28

Feuille 4 : méthodes numériques (Monte Carlo, greeks, PDE) — exercices

Cette feuille vise à relier les méthodes numériques des annexes à des calculs concrets. L'idée centrale : *toute* méthode numérique est un compromis entre biais (erreur systématique) et variance (bruit), et ce compromis se pilote par la discrétisation (pas de temps/grille) et le budget de calcul (nombre de trajectoires, taille de grille).

28.1 Exercice 1 — Monte Carlo : erreur en $1/\sqrt{M}$

Exemple 28.1 (Énoncé). On veut estimer $V_0 = \mathbb{E}[e^{-rT}g(S_T)]$ par Monte Carlo. On simule M trajectoires i.i.d. et on calcule

$$\hat{V}_0 = \frac{1}{M} \sum_{m=1}^M e^{-rT} g(S_T^{(m)}).$$

- a) Montrer que $\hat{V}_0$ est un estimateur sans biais de V_0 .
- b) Exprimer $\text{Var}(\hat{V}_0)$ en fonction de $\text{Var}(e^{-rT}g(S_T))$.
- c) Dédire un intervalle de confiance asymptotique à 95%.

Solution

- a) Par linéarité de l'espérance et i.i.d. :

$$\mathbb{E}[\hat{V}_0] = \frac{1}{M} \sum_{m=1}^M \mathbb{E}[e^{-rT}g(S_T^{(m)})] = \mathbb{E}[e^{-rT}g(S_T)] = V_0.$$

- b) Si $Y = e^{-rT}g(S_T)$, alors $\hat{V}_0 = \frac{1}{M} \sum_{m=1}^M Y^{(m)}$. Donc $\text{Var}(\hat{V}_0) = \text{Var}(Y)/M$.
- c) Par TCL : $\sqrt{M}(\hat{V}_0 - V_0) \Rightarrow \mathcal{N}(0, \text{Var}(Y))$. Un IC 95% est

$$\hat{V}_0 \pm 1.96 \frac{\hat{\sigma}_Y}{\sqrt{M}},$$

où $\hat{\sigma}_Y^2$ est la variance empirique des $Y^{(m)}$.

Ce que le jury doit retenir.

- Monte Carlo a une convergence lente mais robuste : erreur typique $\propto 1/\sqrt{M}$.
- Doubler la précision (diviser l'erreur par 2) demande environ $4\times$ plus de scénarios.

28.2 Exercice 2 — réduction de variance : variable de contrôle

Exemple 28.2 (Énoncé). On price un call européen dans Black–Scholes par Monte Carlo. On connaît aussi le prix exact C_{BS} . On propose une variable de contrôle : $Z = (S_T - K)^+$ simulé, et un contrôle $Z_0 = C_{BS}e^{rT}$ (valeur non actualisée). On définit

$$\hat{V}_{cv} = e^{-rT} (\bar{Z} - \beta(\bar{Z} - Z_0)) = e^{-rT} ((1 - \beta)\bar{Z} + \beta Z_0).$$

- Montrer que l'estimateur est sans biais pour tout β .
- Trouver β^* qui minimise la variance (en fonction de $\text{Var}(Z)$).
- Interpréter économiquement.

Solution

- $\mathbb{E}[\bar{Z}] = \mathbb{E}[Z] = C_{BS}e^{rT} = Z_0$. Donc $\mathbb{E}[\hat{V}_{cv}] = e^{-rT}((1 - \beta)Z_0 + \beta Z_0) = e^{-rT}Z_0 = C_{BS}$.
- Ici, la variable de contrôle est exactement le payoff du call, donc $\bar{Z} - Z_0$ a moyenne nulle. On a

$$\text{Var}(\hat{V}_{cv}) = e^{-2rT} (1 - \beta)^2 \text{Var}(\bar{Z}) = e^{-2rT} (1 - \beta)^2 \frac{\text{Var}(Z)}{M}.$$

Le minimum est atteint pour $\beta^* = 1$: variance nulle.

- C'est volontairement "trop beau" : si on connaît C_{BS} , on n'a pas besoin de MC. Le message : une bonne variable de contrôle est un produit *proche* du payoff dont on connaît le prix. En pratique : contrôle via le prix BS avec une volatilité proche, via des greeks, ou via des approximations rapides.

28.3 Exercice 3 — greeks par bump & revalue : choisir le bon epsilon

Exemple 28.3 (Énoncé). On estime le delta par différences finies :

$$\hat{\Delta} = \frac{\hat{V}(S_0 + \varepsilon) - \hat{V}(S_0 - \varepsilon)}{2\varepsilon}.$$

- Expliquer pourquoi ε trop petit *augmente* le bruit.
- Expliquer pourquoi ε trop grand *biais* l'estimation.
- Donner une règle de choix d'ordre de grandeur.

Solution

- Les deux estimations Monte Carlo ont une variance $\propto 1/M$. La différence au numérateur a donc un bruit typique de taille $\propto 1/\sqrt{M}$. En divisant par 2ε , la variance de $\hat{\Delta}$ se comporte comme $\propto 1/(M\varepsilon^2)$. Donc $\varepsilon \downarrow 0$ fait *exploser* la variance.
- L'approximation par différences finies suppose une linéarité locale : $V(S_0 + \varepsilon) = V(S_0) + \varepsilon V'(S_0) + O(\varepsilon^2)$. Le biais de la différence centrée est en $O(\varepsilon^2)$.
- On choisit ε pour équilibrer variance ($\propto 1/(M\varepsilon^2)$) et biais ($\propto \varepsilon^2$). Cela suggère $\varepsilon \propto M^{-1/4}$ (règle de pouce). En pratique : commencer par $\varepsilon \approx 10^{-3}S_0$ et tester la stabilité.

28.4 Exercice 4 — PDE : schéma implicite et stabilité

Exemple 28.4 (Énoncé). Considérons la PDE de Black–Scholes en S et t . On discrétise t par pas Δt et S par un pas ΔS .

- Expliquer qualitativement pourquoi un schéma *explicite* peut être instable si Δt est trop grand.
- Expliquer pourquoi un schéma *implicite* est plus stable mais demande de résoudre un système linéaire.
- Donner l’intuition de Crank–Nicolson (moyenne explicite/implicite).

Solution

- La PDE contient un terme de diffusion $\frac{1}{2}\sigma^2 S^2 \frac{\partial^2 V}{\partial S^2}$. Comme pour l’équation de la chaleur, un schéma explicite impose une condition CFL du type $\Delta t \lesssim c(\Delta S)^2$ (ici avec un facteur dépendant de S). Sinon, l’erreur numérique s’amplifie à chaque pas de temps.
- Le schéma implicite “met” les inconnues au temps futur dans le terme de diffusion. Il est généralement inconditionnellement stable, mais il impose de résoudre un système tridiagonal à chaque pas (coût mais contrôlable).
- Crank–Nicolson prend la moyenne : moitié explicite, moitié implicite. Il est d’ordre 2 en temps (plus précis) mais peut osciller si les conditions aux bords sont mal gérées ; on le stabilise parfois par *Rannacher* (quelques pas implicites puis CN).

Ce que le jury doit retenir.

- MC : variance $\propto 1/M$; pour gagner un chiffre significatif, il faut beaucoup de scénarios.
- Réduction de variance : antithétiques, contrôles, stratification, quasi-MC (souvent plus rentable que d’augmenter M).
- Greeks : différences finies = compromis biais/variance ; méthode pathwise/LR quand possible.
- PDE : explicite = condition CFL ; implicite = stable mais système linéaire ; CN = précision/stabilité intermédiaire.

28.5 Exercice 5 — option américaine : algorithme de Longstaff–Schwartz (LSM)

Exemple 28.5 (Énoncé). On veut pricer un put américain de maturité T et strike K sur un sous-jacent suivant Black–Scholes. On simule M trajectoires $S_{t_0}, S_{t_1}, \dots, S_{t_N}$, où $t_N = T$.

- Expliquer la difficulté spécifique d’une option américaine (comparée à l’européenne) en termes d’*exercice optimal*.
- Décrire l’algorithme LSM : backward induction et régression de la valeur de continuation.
- Donner une base de fonctions (features) simple pour approximer l’espérance conditionnelle (ex. polynômes de Laguerre ou polynômes en S).

Solution (pas à pas)

- Pour un américain, à chaque date t_k on choisit entre : exercer maintenant : $g(S_{t_k})$ ou continuer : $\mathbb{E}[e^{-r\Delta t} V_{k+1} \mid \mathcal{F}_{t_k}]$. La frontière d’exercice (ensemble des S où l’exercice est optimal) est inconnue *a priori*.
- LSM approxime la valeur de continuation par une régression sur les trajectoires simulées. Schéma :

- i) Initialiser à maturité : $V_N^{(m)} = g(S_{t_N}^{(m)})$.
- ii) Pour $k = N - 1, \dots, 1$:
 - Considérer les trajectoires *dans la monnaie* (pour un put : $S_{t_k}^{(m)} < K$).
 - Calculer les cashflows actualisés au pas suivant : $Y^{(m)} = e^{-r\Delta t} V_{k+1}^{(m)}$.
 - Régression : approximer $\mathbb{E}[Y \mid S_{t_k}] \approx \sum_j a_j \phi_j(S_{t_k})$.
 - Décision : exercer si $g(S_{t_k}^{(m)}) \geq \widehat{\text{cont}}(S_{t_k}^{(m)})$, sinon continuer.
 - Mettre à jour $V_k^{(m)}$ en conséquence.
- iii) Le prix est la moyenne des cashflows au temps 0 : $V_0 \approx \frac{1}{M} \sum_m e^{-rt_{\tau^{(m)}}} g(S_{\tau^{(m)}}^{(m)})$, où $\tau^{(m)}$ est le temps d'exercice simulé.
- c) Bases classiques : $\phi_0(S) = 1$, $\phi_1(S) = S$, $\phi_2(S) = S^2$ (simple mais peut être instable), ou bases de Laguerre (souvent plus stables) :

$$L_0(x) = 1, \quad L_1(x) = 1 - x, \quad L_2(x) = 1 - 2x + \frac{1}{2}x^2, \quad x = S/K.$$

Ce que le jury doit retenir.

- Américain = optimisation de stopping : exercice vs continuation à chaque date.
- LSM : on remonte dans le temps en régressant la continuation sur les trajectoires (approximation de $\mathbb{E}[\cdot \mid S]$).
- Qualité dépend de (i) la base de régression, (ii) le nombre de trajectoires, (iii) la discrétisation temporelle.

28.6 Exercice 6 — FFT (Carr–Madan) : choisir la grille et éviter l’aliasing

Exemple 28.6 (Énoncé). Dans Carr–Madan, on price un call via une transformée de Fourier du prix amorti. On utilise une grille en fréquence $u_j = j \Delta u$ et une grille en log-strike $k_m = k_{\min} + m \Delta k$ avec la relation $\Delta u \Delta k = 2\pi/N$.

- a) Expliquer l’intuition derrière le paramètre d’amortissement $\alpha > 0$ (pourquoi on multiplie par $e^{\alpha k}$).
- b) Expliquer qualitativement le phénomène d’*aliasing* quand la grille en k est trop courte.
- c) Donner deux règles pratiques pour choisir $(N, \Delta u, k_{\min})$.

Solution (intuitions pratiques)

- a) Le payoff d’un call n’est pas intégrable sur $k = \log K$: la transformée diverge. On amortit en considérant un prix modifié $\tilde{C}(k) = e^{\alpha k} C(k)$. Pour α assez grand, $\tilde{C}$ devient intégrable et la Fourier est bien définie.
- b) L’FFT suppose une périodisation implicite : on reconstruit une fonction périodique de période $N\Delta k$. Si la vraie fonction n’est pas quasi nulle aux bords, les “copies” se recollent et créent des erreurs (aliasing), typiquement des oscillations et des prix négatifs dans les ailes.
- c) Règles de pouce :
 - prendre N une puissance de 2 (efficacité FFT) et suffisamment grand (ex. $N \geq 2^{10}$) ;
 - choisir Δu petit pour bien intégrer les oscillations (meilleure précision) ;

- choisir $k_{\min}$ et la largeur $N\Delta k$ pour couvrir une large plage de strikes (ex. de $K \approx 0.05F$ à $K \approx 20F$) ;
- tester la stabilité en faisant varier α et la largeur de grille : un modèle sain donne des prix quasi inchangés.

28.7 Exercice 7 — quasi-Monte Carlo : quand et pourquoi cela aide

Exemple 28.7 (Énoncé). On remplace les tirages pseudo-aléatoires uniformes par une suite à faible discrédance (Sobol, Halton) puis on transforme en gaussiennes (inverse de la CDF Φ ou Box–Muller).

- Expliquer pourquoi, pour une intégrale $I = \int_{[0,1]^d} f(u) du$, l'erreur quasi-MC peut être meilleure que $1/\sqrt{M}$ quand f est régulière.
- En pricing, pourquoi parle-t-on d'une *dimension effective* souvent plus faible que $d = N$ (nombre de pas de temps) ?
- Donner une intuition de la technique *Brownian bridge* pour réduire la dimension effective.

Solution (intuition + points pratiques)

- Les suites à faible discrédance couvrent l'hypercube plus uniformément que des tirages i.i.d. Pour des fonctions assez régulières, l'erreur d'intégration est liée à la discrédance via l'inégalité de Koksma–Hlawka (idée : "bonne couverture" $\times$ "variation" de f). Cela peut donner, dans les cas favorables, une convergence proche de $O((\log M)^d/M)$, donc plus rapide que $1/\sqrt{M}$.
- Dans un MC discretisé, on croit intégrer en dimension $d = N$ (un uniforme/gaussienne par pas), mais souvent le payoff dépend surtout de quelques "facteurs" : niveau du spot à maturité, moyenne, ou quelques combinaisons. Les contributions des pas tardifs peuvent être dominantes ; les pas très fins apportent peu. C'est ce qu'on appelle la *dimension effective*.
- Brownian bridge réordonne la construction de la trajectoire : on simule d'abord W_T , puis les points intermédiaires conditionnellement. On "met" la variance la plus importante sur les premières dimensions de la suite Sobol, ce qui réduit la dimension effective et améliore l'efficacité quasi-MC.




FIGURE 28.1 – Illustration qualitative : MC décroît en $M^{-1/2}$; quasi-MC peut faire mieux sur des payoffs réguliers et une faible dimension effective.

28.8 Exercice 8 — greeks Monte Carlo : méthode pathwise vs likelihood ratio

Exemple 28.8 (Énoncé). On veut estimer le delta d'un payoff européen $g(S_T)$ en Black–Scholes.

a) (Pathwise) En supposant g dérivable, montrer formellement que

$$\Delta = \frac{\partial V_0}{\partial S_0} = \mathbb{E} \left[e^{-rT} g'(S_T) \frac{\partial S_T}{\partial S_0} \right].$$

b) Dans Black–Scholes, exprimer $\frac{\partial S_T}{\partial S_0}$.

c) (Likelihood ratio) Expliquer le principe : dériver la *densité* plutôt que le payoff, utile quand g n'est pas dérivable (digitals).

Solution

a) Si on peut permuter dérivation et espérance (hypothèses de domination), alors

$$V_0 = \mathbb{E}[e^{-rT} g(S_T(S_0, \omega))] \Rightarrow \frac{\partial V_0}{\partial S_0} = \mathbb{E} \left[e^{-rT} g'(S_T) \frac{\partial S_T}{\partial S_0} \right].$$

C'est la méthode *pathwise* : on dérive trajectoire par trajectoire.

b) Sous BS : $S_T = S_0 \exp((r - q - \frac{1}{2}\sigma^2)T + \sigma W_T)$, donc

$$\frac{\partial S_T}{\partial S_0} = \exp((r - q - \frac{1}{2}\sigma^2)T + \sigma W_T) = \frac{S_T}{S_0}.$$

Donc une estimation MC pathwise est

$$\hat{\Delta}_{\text{pw}} = \frac{1}{M} \sum_{m=1}^M e^{-rT} g'(S_T^{(m)}) \frac{S_T^{(m)}}{S_0}.$$

c) La méthode *likelihood ratio* écrit $V_0 = \int g(x) f(x; S_0) dx$ et dérive f :

$$\frac{\partial V_0}{\partial S_0} = \int g(x) \frac{\partial f}{\partial S_0}(x; S_0) dx = \mathbb{E} \left[e^{-rT} g(S_T) \frac{\partial}{\partial S_0} \log f(S_T; S_0) \right].$$

Elle ne demande pas g' et marche pour des payoffs non lisses, mais peut avoir plus de variance.

Chapitre 29

Feuille 5 : risk management (VaR, ES/CVaR, backtesting)

Cette feuille complète le cours en rendant *calculables* des notions de risque utilisées en pratique : quantile (VaR), queue moyenne (ES/CVaR), et validation par backtesting. Les objectifs pédagogiques :

- savoir **définir** correctement VaR et ES (ce n'est pas la même chose) ;
- comprendre les **hypothèses** implicites (stationnarité, normalité...) ;
- savoir **vérifier** une méthode (exceedances et tests simples).

29.1 Exercice 1 — VaR et ES historiques sur un échantillon

Exemple 29.1 (Énoncé). On observe 20 rendements journaliers (en %) :

$\{-1.5, -0.7, 0.2, 0.1, 0.4, -2.1, 0.3, 1.0, -0.3, 0.6, -0.9, 0.2, 0.8, -1.1, 0.5, -0.4, 0.1, 0.2, -0.6, 0.7\}$.

On considère la perte $L = -R$ (donc une perte est positive).

- Calculer la VaR historique à 95% (sur cet échantillon discret).
- Calculer l'ES (Expected Shortfall) historique à 95%.
- Expliquer pourquoi l'ES est plus sensible aux queues que la VaR.

Solution

- Trier les pertes (c.-à-d. les $-R$). Les plus grandes pertes correspondent aux rendements les plus négatifs : $-2.1, -1.5, -1.1, \dots$ Avec $n = 20$, le quantile 95% correspond à environ le rang $\lceil 0.95n \rceil = 19$ pour les pertes (convention discrète). Ici, une façon simple : la VaR 95% est la **deuxième** plus grande perte (car 5% de 20 = 1 observation dans la queue). Donc $\text{VaR}_{0.95} \approx 1.5\%$ ou 2.1% selon la convention d'interpolation ; l'important est d'énoncer la règle choisie.
- L'ES 95% est la moyenne des pertes au-delà de la VaR. Sur 20 observations, la queue 5% contient environ 1 observation : l'ES devient alors (presque) la pire perte, soit $\approx 2.1\%$. Si l'on prend 2 observations de queue pour stabiliser (méthode pratique), l'ES est la moyenne de 2.1% et 1.5%, soit 1.8%.
- La VaR ne regarde que le *seuil* (un quantile) : elle ignore la gravité au-delà. L'ES moyenne la queue : elle “voit” si les scénarios extrêmes deviennent plus sévères.

29.2 Exercice 2 — VaR paramétrique sous normalité

Exemple 29.2 (Énoncé). On suppose un P&L journalier $X \sim \mathcal{N}(\mu, \sigma^2)$.

- a) Exprimer la VaR à niveau α d'une perte $L = -X$.
- b) Pour $\mu = 0$ et $\sigma = 1\%$, donner la VaR 99%.
- c) Quelles limites de cette hypothèse pour des rendements actions ?

Solution

- a) $L = -X$ est normal de moyenne $-\mu$ et variance σ^2 . La VaR à niveau α est le quantile :

$$\text{VaR}_\alpha = F_L^{-1}(\alpha) = -\mu + \sigma z_\alpha,$$

où z_α est le quantile de la loi normale standard.

- b) $z_{0.99} \approx 2.33$, donc $\text{VaR}_{0.99} \approx 2.33\%$.
- c) Les rendements ont souvent des queues plus épaisses et de l'asymétrie ; la normalité sous-estime les pertes extrêmes. De plus, σ varie dans le temps (volatilité conditionnelle), ce que la VaR normale stationnaire ne capture pas.

29.3 Exercice 3 — backtesting : test de Kupiec (couverture inconditionnelle)

Exemple 29.3 (Énoncé). On produit chaque jour une VaR 99% sur un portefeuille. Sur $N = 250$ jours, on observe $x = 6$ dépassements (jours où la perte réalise $> \text{VaR}$).

- a) Sous le modèle correct, quelle est la loi de x ?
- b) Écrire le taux empirique $\hat{p} = x/N$ et le comparer à $p = 1 - 0.99 = 0.01$.
- c) Donner l'intuition du test : que signifie "trop de dépassements" ?

Solution

- a) Si chaque jour la probabilité de dépassement vaut $p = 0.01$ et est indépendante, alors $x \sim \text{Bin}(N, p)$.
- b) $\hat{p} = 6/250 = 2.4\%$, supérieur à 1% : cela suggère une VaR trop optimiste.
- c) Trop de dépassements signifie que la VaR est sous-calibrée (elle sous-estime les queues), ou que les hypothèses (indépendance, stationnarité) sont fausses.

Ce que le jury doit retenir.

- VaR = quantile : seuil de perte ; ES/CVaR = moyenne de la queue : sévérité au-delà du seuil.
- Historique : simple, peu d'hypothèses, mais instable en petite taille et aveugle aux régimes futurs.
- Paramétrique normale : rapide, mais risque de sous-estimer les queues et d'ignorer la vol variable.
- Backtesting : compter les dépassements et comprendre ce qu'ils impliquent sur la calibration du risque.

Septième partie

Annexes

Annexe A

Méthodes de pricing : arbre binomial, Monte Carlo, PDE

Cette annexe synthétise des méthodes de pricing complémentaires. L'objectif n'est pas de remplacer des cours de numérique, mais de donner une vue claire des principes, des formules de base, et des pièges.

A.1 Arbre binomial (Cox–Ross–Rubinstein)

A.1.1 Discrétisation du sous-jacent

On discrétise $[0, T]$ en N pas de taille $\Delta t = T/N$. À chaque pas, le prix monte ou baisse :

$$S_{k+1} = \begin{cases} uS_k & \text{avec probabilité } p, \\ dS_k & \text{avec probabilité } 1 - p, \end{cases}$$

avec typiquement

$$u = e^{\sigma\sqrt{\Delta t}}, \quad d = e^{-\sigma\sqrt{\Delta t}} = \frac{1}{u}.$$

A.1.2 Probabilité risque-neutre

L'absence d'arbitrage impose que l'espérance risque-neutre du sous-jacent croisse à $(r - q)$:

$$\mathbb{E}^{\mathbb{Q}}[S_{k+1} \mid S_k] = e^{(r-q)\Delta t} S_k.$$

Donc

$$pu + (1 - p)d = e^{(r-q)\Delta t} \implies p = \frac{e^{(r-q)\Delta t} - d}{u - d}.$$

Condition de no-arbitrage : $d < e^{(r-q)\Delta t} < u$ (sinon $p \notin (0, 1)$).

A.1.3 Pricing européen

On calcule les payoffs au temps T sur les noeuds de l'arbre, puis on remonte par récurrence :

$$V_k(S) = e^{-r\Delta t} \left(pV_{k+1}(uS) + (1 - p)V_{k+1}(dS) \right).$$

À $k = 0$, on obtient V_0 .

A.1.4 Options américaines

Pour une option américaine, on compare à chaque noeud :

$$V_k(S) = \max\left(g(S), e^{-r\Delta t}(pV_{k+1}(uS) + (1-p)V_{k+1}(dS))\right).$$

C'est une condition d'exercice anticipé.

Exemple A.1 (Pourquoi l'américaine est plus difficile ?). Pour un call sur action sans dividende ($q = 0$), il n'est jamais optimal d'exercer tôt : l'américaine = l'europpéenne. Pour un put, exercer tôt peut être optimal : l'option américaine vaut plus. Le binomial capture cet effet via le max noeud par noeud.

A.2 Monte Carlo (pricing comme espérance)

A.2.1 Principe

Sous $\mathbb{Q}$:

$$V_0 = \mathbb{E}^{\mathbb{Q}} \left[e^{-rT} g(S_T) \right].$$

Monte Carlo approxime cette espérance par une moyenne empirique :

$$\hat{V}_0 = \frac{1}{M} \sum_{m=1}^M e^{-rT} g(S_T^{(m)}),$$

où $S_T^{(m)}$ sont des scénarios simulés.

A.2.2 Erreur statistique

Par le TCL :

$$\sqrt{M} (\hat{V}_0 - V_0) \Rightarrow \mathcal{N}(0, \sigma_g^2),$$

donc l'erreur décroît comme $1/\sqrt{M}$. C'est lent : doubler la précision demande $\times 4$ scénarios.

A.2.3 Réduction de variance (outils classiques)

- **antithétiques** : utiliser Z et $-Z$.
- **control variate** : utiliser une variable H de prix connu, corrélée au payoff.
- **stratification** : mieux répartir les tirages.

Exemple A.2 (Control variate avec Black–Scholes). Si on price un payoff compliqué mais corrélé à un call vanilla, on peut utiliser le call BS comme contrôle : cela réduit fortement la variance.

A.2.4 American options : régression (LSMC)

Monte Carlo direct ne gère pas l'exercice anticipé. Longstaff–Schwartz approxime la valeur de continuation par régression : on simule des trajectoires, puis on estime $\mathbb{E}[V_{t+1}|S_t]$ via une base de fonctions (polynômes). C'est un outil standard.

A.3 PDE et différences finies

Pour une diffusion, le prix $V(t, S)$ satisfait une PDE (ex. Black–Scholes). On peut résoudre numériquement via différences finies :

- schéma explicite (simple mais condition de stabilité) ;
- implicite (stable mais résout un système linéaire) ;
- Crank–Nicolson (ordre 2 en temps, compromis).

A.3.1 Schéma explicite (idée)

On discrétise t et S et on approxime les dérivées par des différences. Le schéma explicite avance V dans le temps via une formule directe. Il est conditionnellement stable (condition CFL).

A.3.2 American options : condition de complémentarité

L'américaine impose

$$V(t, S) \geq g(S), \quad \frac{\partial V}{\partial t} + \mathcal{L}V - rV \leq 0, \quad (V - g) \left(\frac{\partial V}{\partial t} + \mathcal{L}V - rV \right) = 0.$$

Numériquement, cela devient un problème de type obstacle (LCP), résolu par méthodes projetées.

Ce que le jury doit retenir.

- Binomial CRR : discretise S en up/down ; la probabilité risque-neutre p vient de l'absence d'arbitrage.
- Options américaines : backward induction avec $V = \max(\text{exercice}, \text{continuation})$.
- Monte Carlo : prix = moyenne des payoffs actualisés ; erreur $\sim 1/\sqrt{M}$, d'où l'importance de la réduction de variance.
- PDE/FD : alternative déterministe ; indispensable pour américaines via obstacle.

Annexe B

Payoffs : options vanilles et stratégies (graphes)

Cette annexe sert de “mémoire visuelle”. On représente le payoff à maturité en fonction de S_T . Les axes sont volontairement simplifiés (pas de prime payée) : on veut voir la structure.

B.1 Call et put




FIGURE B.1 – Payoff d’un call européen.

B.2 Straddle et strangle

B.3 Spreads et structures à risque borné

B.4 Table mémo

Stratégie	Composition	Intuition
Call	$(S_T - K)^+$	Exposition haussière convexe.
Put	$(K - S_T)^+$	Protection baisse.

Straddle	Call + Put (même K)	Pari sur forte volatilité (mouvement dans un sens ou l'autre).
Strangle	Put OTM + Call OTM	Volatilité, mais plus "large" (coût souvent plus faible).
Call spread	Long call bas, short call haut	Exposition haussière à gain borné.
Butterfly	Long/short/long calls	Cible une zone de prix (pari sur faible vol autour du centre).

Ce que le jury doit retenir.

- Visualiser les payoffs est indispensable : c'est la manière la plus rapide de vérifier une intuition.
- Straddle/strangle sont des paris directionnellement neutres mais volatils.
- Les spreads et butterflies bornent le risque (et le gain) : ce sont des outils de structuration.




FIGURE B.2 – Payoff d'un put européen.




FIGURE B.3 – Straddle : long call + long put, même strike.




FIGURE B.4 – Strangle : long put OTM + long call OTM.




FIGURE B.5 – Bull call spread : long call strike bas, short call strike haut (gain borné).




FIGURE B.6 – Butterfly (calls) : payoff positif autour du strike central, borné.

Annexe C

Glossaire & carte des notions

C.1 Glossaire (définitions ultra-courtes)

Terme	Définition (1 ligne)
Arbitrage	Stratégie à profit certain sans risque et sans investissement net.
Mesure risque-neutre $\mathbb{Q}$	Probabilité sous laquelle les prix actualisés sont des martingales.
Brownien	Bruit continu gaussien à incréments indépendants.
Itô	Calcul différentiel adapté aux semi-martingales ; règle $(dW)^2 = dt$.
Greeks	Dérivées du prix d'option (sensibilités).
Volatilité implicite	σ BS qui reproduit un prix de marché.
Smile/Skew	Variation de l'IV selon le strike ; asymétrie.
Heston	Modèle à variance stochastique CIR corrélée au spot.
SABR	Modèle stochastique sur forward avec élasticité β .
Jump diffusion	Diffusion + sauts (Poisson composé).
Carr–Madan	Pricing via transformée de Fourier amortie et FFT.
Hedging	Construction d'un portefeuille pour réduire le risque d'un payoff.
PnL	Profit and Loss : résultat financier d'une stratégie.
MDP	Modèle de décision séquentielle (états, actions, rewards).
SARSA / Q-learning	Algorithmes RL basés sur Bellman/TD.
DQN	Q-learning où Q est approximé par un réseau de neurones.
Discount factor	$P(0, T)$: valeur actuelle d'1 euro à T .
Forward	Taux ou prix impliqué par les discount factors (absence d'arbitrage).
Nelson–Siegel	Paramétrisation level/slope/curvature d'une courbe de taux.
Markowitz	Optimisation moyenne-variance via μ et Σ .
Risk parity	Allocation égalisant les contributions au risque.
PCA	Diagonalisation de Σ pour extraire des facteurs principaux.

C.2 Carte rapide : où chaque brique est utilisée

Brique	Où elle intervient
Brownien / Itô	Base de Black–Scholes, Heston, diffusion de taux ; simulation MC.
Mesure risque-neutre	Formule d'espérance des prix, pricing sans μ , calibration cohérente.

Greeks	Couverture (delta/gamma/vega), sensibilités de calibration et risk management.
Vol implicite / surface	Calibration : comparaison modèle vs marché ; arbitrage en strike/maturité.
Heston / sauts / SABR	Modèles pour reproduire smile/skew ; pricing via Fourier ; calibration.
Rough vol	Smile court terme et rugosité de la volatilité ; simulation plus difficile.
RL hedging	Optimisation du PnL discret sous coûts/risque ; approche MDP.
Courbe des taux	Discounting et forwards : base de tous les prix en taux/FX.
Markowitz / RP / PCA	Décision allocation : construire des portefeuilles robustes et comprendre les risques.

Ce que le jury doit retenir.

- Le glossaire doit être connu : c’est le vocabulaire minimal pour parler finance quantitative proprement.
- La carte des notions montre la cohérence : chaque brique sert ailleurs (pas de chapitre “isolé”).

Bibliographie indicative

Bibliographie

- [1] S. E. Shreve, *Stochastic Calculus for Finance I & II*, Springer.
- [2] T. Björk, *Arbitrage Theory in Continuous Time*, Oxford University Press.
- [3] J. Gatheral, *The Volatility Surface: A Practitioner's Guide*, Wiley.
- [4] P. Wilmott, *Paul Wilmott Introduces Quantitative Finance*, Wiley.
- [5] P. Glasserman, *Monte Carlo Methods in Financial Engineering*, Springer.
- [6] S. Heston, “A Closed-Form Solution for Options with Stochastic Volatility with Applications to Bond and Currency Options”, *Review of Financial Studies*, 1993.
- [7] R. Merton, “Option Pricing When Underlying Stock Returns Are Discontinuous”, *Journal of Financial Economics*, 1976.
- [8] P. Hagan, D. Kumar, A. Lesniewski, D. Woodward, “Managing Smile Risk”, Wilmott Magazine, 2002.
- [9] R. Rebonato, *Interest-Rate Option Models*, Wiley.
- [10] P. Carr, D. Madan, “Option Valuation Using the Fast Fourier Transform”, *Journal of Computational Finance*, 1999.
- [11] J. Gatheral, T. Jaisson, M. Rosenbaum, “Volatility is rough”, *Quantitative Finance*, 2018.
- [12] R. Sutton, A. Barto, *Reinforcement Learning: An Introduction*, MIT Press.