

Finance quantitative — Préliminaires probabilistes

Base de révisions *interview-ready* (preuves + dérivations + sanity checks)

Version notes (sans Q/R) (December 17, 2025)

But. On veut une base compacte mais complète, au niveau *Quant Researcher interview* : définitions propres, hypothèses explicites, mini-preuves et dérivations qu'on peut refaire au tableau, sanity checks systématiques, et blocs de *questions d'entretien* (réponse attendue + piège).

Fil directeur. Un modèle = un espace probabilisé $(\Omega, \mathcal{F}, \mathbb{P})$, une information (tribu/filtration), et des variables/processus mesurables. Dès qu'on change de mesure ($\mathbb{P} \rightarrow \mathbb{Q}$), qu'on conditionne, ou qu'on fait passer une limite, on veut savoir exactement quelles hypothèses garantissent que l'objet est bien défini.

Version *sans exercices* : uniquement du contenu interview-relevant (preuves, pièges, sanity checks, Q/R).

Contents

1	Pourquoi ces prérequis ? (modèle, information, pricing)	1
2	Espaces probabilisés, tribus, mesures	2
3	Variables aléatoires, lois, densités, Radon–Nikodym	7
4	Transformations, Jacobien, lois images	9
5	Conditionnement et espérance conditionnelle	11
6	Convergences, outils de contrôle, LLN/CLT	14
7	Espaces L^p et Hilbert L^2 : projection, régression, Kalman	20
8	Algèbre linéaire utile (PSD/PD, Cholesky, Schur, Woodbury)	22
9	Gaussiennes : univariée (CF/MGF, Stein, queues)	24
10	Gaussiennes multivariées, conditionnement, PCA	26
11	Filtrations et martingales : langage de l’information	29

1 Pourquoi ces prérequis ? (modèle, information, pricing)

Intuition

On va manipuler des objets comme $\mathbb{E}[X]$, $\mathbb{E}[X \mid \mathcal{F}_t]$, des densités, des lois, des limites, et des phrases du type « *le prix actualisé est une martingale sous $\mathbb{Q}$* ». Si les bases sont floues, tu te retrouves à *réciter* au lieu de *raisonner* : en entretien, on veut te voir préciser les hypothèses et dérouler un raisonnement sans zones grises.

Dans la pratique. La probabilité, ce n'est pas du folklore : c'est ce qui rend explicite ce que tu sais (information), ce que tu ne sais pas (aléa), et ce que tu postules (modèle). Un mauvais usage du conditionnement, c'est du *look-ahead bias* déguisé.

Définitions

Définition 1.1 (Information et non-anticipation). Une information à une date t est modélisée par une tribu $\mathcal{F}_t$. Une décision D_t est **non anticipative** si elle est $\mathcal{F}_t$ -mesurable. Une famille $(\mathcal{F}_t)_{t \geq 0}$ croissante (au sens $\mathcal{F}_s \subseteq \mathcal{F}_t$ si $s \leq t$) est une **filtration**.

Résultats et preuves

Proposition 1.1 (Ce qu'on veut savoir justifier en pricing). Dans un modèle $(\Omega, \mathcal{F}, (\mathcal{F}_t), \mathbb{Q})$ avec un numéraire $B_t > 0$, si l'actif actualisé $\tilde{S}_t := S_t/B_t$ est une $\mathbb{Q}$ -martingale, alors pour un payoff H intégrable :

$$V_t = B_t \mathbb{E}^{\mathbb{Q}} \left[\frac{H}{B_T} \mid \mathcal{F}_t \right]$$

est un prix cohérent (au sens « pas d'arbitrage ») et non anticipatif.

Proof. L'objet $\mathbb{E}^{\mathbb{Q}}[H/B_T \mid \mathcal{F}_t]$ est par définition $\mathcal{F}_t$ -mesurable : V_t dépend uniquement de l'information à t . La cohérence intertemporelle vient de la propriété de tour :

$$\mathbb{E}^{\mathbb{Q}} \left[\mathbb{E}^{\mathbb{Q}} \left[\frac{H}{B_T} \mid \mathcal{F}_t \right] \mid \mathcal{F}_s \right] = \mathbb{E}^{\mathbb{Q}} \left[\frac{H}{B_T} \mid \mathcal{F}_s \right] \quad (s \leq t).$$

Le langage précis (filtration, martingale, conditionnement) est détaillé en §11. □

Sanity checks

Sanity check. Chaque fois que tu écris $\mathbb{E}[\cdot]$ ou $\mathbb{P}(\cdot)$, tu dois savoir : (i) sur quel espace Ω tu travailles, (ii) quelle est la tribu (quels événements sont mesurables), (iii) quelle est la mesure (quels poids tu mets sur les scénarios).

Sanity check. Un prix à t doit être $\mathcal{F}_t$ -mesurable. Si ta formule dépend d'une variable non $\mathcal{F}_t$ -mesurable, tu as de l'anticipation cachée.

Blocs Q/R d'entretien déplacés en annexe (voir Annexe Q/R).

Mini-synthèse

- Un modèle = $(\Omega, \mathcal{F}, \mathbb{P})$ + information (tribu/filtration) + variables mesurables.
- Le conditionnement formalise « meilleure prédiction donnée l'information ».
- Changer de mesure ($\mathbb{P} \rightarrow \mathbb{Q}$) change les prix *et* les espérances.
- En finance : prix = espérance conditionnelle sous $\mathbb{Q}$ d'un payoff actualisé.

2 Espaces probabilisés, tribus, mesures

Intuition

Une tribu $\mathcal{F}$ encode *ce que tu acceptes comme événement mesurable* (donc ce sur quoi tu peux conditionner), et une mesure $\mathbb{P}$ encode *comment tu pondères* ces événements. La stabilité par unions *dénombrables* et la σ -additivité ne sont pas des détails : elles sont exactement ce qui rend les passages à la limite corrects (§6).

Définitions

Définition 2.1 (Espace probabilisé). Un **espace probabilisé** est un triplet $(\Omega, \mathcal{F}, \mathbb{P})$ où :

- Ω est l'ensemble des issues (scénarios) ;
- $\mathcal{F} \subseteq \mathcal{P}(\Omega)$ est une **tribu** ;
- $\mathbb{P} : \mathcal{F} \rightarrow [0, 1]$ est une **mesure de probabilité** avec $\mathbb{P}(\Omega) = 1$.

Définition 2.2 (Tribu / σ -algèbre). Une famille $\mathcal{F} \subseteq \mathcal{P}(\Omega)$ est une **tribu** si :

- (i) $\Omega \in \mathcal{F}$;
- (ii) $A \in \mathcal{F} \Rightarrow A^c \in \mathcal{F}$;
- (iii) $(A_n)_{n \geq 1} \subset \mathcal{F} \Rightarrow \bigcup_{n \geq 1} A_n \in \mathcal{F}$.

Définition 2.3 (Tribu engendrée). Si $\mathcal{G} \subseteq \mathcal{P}(\Omega)$, on note $\sigma(\mathcal{G})$ la plus petite tribu contenant $\mathcal{G}$:

$$\sigma(\mathcal{G}) := \bigcap \{ \mathcal{F}' : \mathcal{F}' \text{ tribu et } \mathcal{G} \subseteq \mathcal{F}' \}.$$

Définition 2.4 (Boréliens). Sur $\mathbb{R}$, la **tribu borélienne** $\mathcal{B}(\mathbb{R})$ est la plus petite tribu contenant tous les intervalles ouverts.

Définition 2.5 (Produit de tribus). Si $(\Omega_1, \mathcal{F}_1)$ et $(\Omega_2, \mathcal{F}_2)$ sont mesurables, la **tribu produit** est

$$\mathcal{F}_1 \otimes \mathcal{F}_2 := \sigma(\{A \times B : A \in \mathcal{F}_1, B \in \mathcal{F}_2\}).$$

Définition 2.6 (Complétion). Soit $(\Omega, \mathcal{F}, \mathbb{P})$. On appelle **complétion** de $\mathcal{F}$ pour $\mathbb{P}$ la tribu

$$\overline{\mathcal{F}}^{\mathbb{P}} := \sigma(\mathcal{F} \cup \{N \subseteq A : A \in \mathcal{F}, \mathbb{P}(A) = 0\}).$$

Le triplet $(\Omega, \overline{\mathcal{F}}^{\mathbb{P}}, \mathbb{P})$ est **complet** : tout sous-ensemble d'un nul est mesurable.

Définition 2.7 (Mesure σ -finie). Une mesure μ sur $(\Omega, \mathcal{F})$ est **σ -finie** s'il existe une suite $(E_n)_{n \geq 1} \subseteq \mathcal{F}$ telle que $\Omega = \bigcup_{n \geq 1} E_n$ et $\mu(E_n) < \infty$ pour tout n .

Définition 2.8 (Algèbre de parties et pré-mesure). Une famille $\mathcal{A} \subseteq \mathcal{P}(\Omega)$ est une **algèbre** si $\Omega \in \mathcal{A}$, si $A \in \mathcal{A} \Rightarrow A^c \in \mathcal{A}$ et si $A, B \in \mathcal{A} \Rightarrow A \cup B \in \mathcal{A}$ (donc aussi $A \cap B \in \mathcal{A}$). Une application $\mu_0 : \mathcal{A} \rightarrow [0, \infty]$ est une **pré-mesure** si elle est σ -additive sur $\mathcal{A}$: pour toute suite disjointe $(A_n) \subset \mathcal{A}$ telle que $\bigcup_n A_n \in \mathcal{A}$,

$$\mu_0\left(\bigcup_{n \geq 1} A_n\right) = \sum_{n \geq 1} \mu_0(A_n).$$

Définition 2.9 (π -système et λ -système). Une famille $\Pi \subseteq \mathcal{P}(\Omega)$ est un **π -système** si elle est stable par intersections finies. Une famille $\Lambda \subseteq \mathcal{P}(\Omega)$ est un **λ -système** (système de Dynkin) si :

- (i) $\Omega \in \Lambda$;
- (ii) si $A, B \in \Lambda$ et $A \subseteq B$, alors $B \setminus A \in \Lambda$;
- (iii) si $A_n \uparrow A$ avec $A_n \in \Lambda$, alors $A \in \Lambda$.

Définition 2.10 (Indépendance de tribus). Deux tribus $\mathcal{F}_1, \mathcal{F}_2$ sont **indépendantes** si

$$\forall A \in \mathcal{F}_1, \forall B \in \mathcal{F}_2, \quad \mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B).$$

Résultats et preuves

Proposition 2.1 (Conséquences immédiates). *Si $\mathcal{F}$ est une tribu, alors $\emptyset \in \mathcal{F}$ et $\mathcal{F}$ est stable par intersections dénombrables.*

Proof. $\emptyset = \Omega^c \in \mathcal{F}$. Puis $\cap_{n \geq 1} A_n = (\cup_{n \geq 1} A_n^c)^c$ et on conclut. $\square$

Proposition 2.2 (Continuité croissante/décroissante des mesures). *Soit μ une mesure sur $(\Omega, \mathcal{F})$ et (A_n) une suite de mesurables.*

- Si $A_n \uparrow A$, alors $\mu(A_n) \uparrow \mu(A)$.
- Si $A_n \downarrow A$ et $\mu(A_1) < \infty$, alors $\mu(A_n) \downarrow \mu(A)$.

Proof. Si $A_n \uparrow A$, poser $B_1 = A_1$ et $B_n = A_n \setminus A_{n-1}$ pour $n \geq 2$. Alors les B_n sont disjoints, $\cup_{n \geq 1} B_n = A$, et $\mu(A_n) = \sum_{k=1}^n \mu(B_k)$. Par σ -additivité, $\mu(A) = \sum_{k \geq 1} \mu(B_k)$, donc $\mu(A_n) \uparrow \mu(A)$. Si $A_n \downarrow A$ et $\mu(A_1) < \infty$, appliquer le cas croissant à $A_n^c \uparrow A^c$ et utiliser $\mu(A_n) = \mu(A_1) - \mu(A_n^c)$. $\square$

Théorème 2.1 (Théorème π - λ). *Si Π est un π -système et si Λ est un λ -système tel que $\Pi \subseteq \Lambda$, alors $\sigma(\Pi) \subseteq \Lambda$.*

Proof. Notons $\lambda(\Pi)$ le plus petit λ -système contenant Π (intersection de tous les λ -systèmes contenant Π). Comme $\Pi \subseteq \Lambda$ et Λ est un λ -système, on a $\lambda(\Pi) \subseteq \Lambda$. Il suffit donc de montrer que $\lambda(\Pi)$ est une σ -algèbre (alors elle contient $\sigma(\Pi)$ par minimalité).

Étape 1 : intersections avec le générateur. Fixons $C \in \Pi$ et définissons

$$\Lambda^{(C)} := \{A \in \lambda(\Pi) : A \cap C \in \lambda(\Pi)\}.$$

On vérifie que $\Lambda^{(C)}$ est un λ -système :

- $\Omega \in \Lambda^{(C)}$ car $\Omega \cap C = C \in \lambda(\Pi)$;
- si $A, B \in \Lambda^{(C)}$ et $A \subseteq B$, alors $(B \setminus A) \cap C = (B \cap C) \setminus (A \cap C) \in \lambda(\Pi)$;
- si $A_n \uparrow A$ avec $A_n \in \Lambda^{(C)}$, alors $(A_n \cap C) \uparrow (A \cap C)$ et donc $A \cap C \in \lambda(\Pi)$.

De plus, $\Pi \subseteq \Lambda^{(C)}$ car si $A \in \Pi$, alors $A \cap C \in \Pi$ (π -système) donc $A \cap C \in \lambda(\Pi)$. Par minimalité de $\lambda(\Pi)$, on a donc $\Lambda^{(C)} = \lambda(\Pi)$. Conclusion : pour tout $A \in \lambda(\Pi)$ et tout $C \in \Pi$, $A \cap C \in \lambda(\Pi)$.

Étape 2 : $\lambda(\Pi)$ est stable par intersections finies. Fixons maintenant $A \in \lambda(\Pi)$ et considérons

$$\Lambda_A := \{B \in \lambda(\Pi) : A \cap B \in \lambda(\Pi)\}.$$

Comme ci-dessus, Λ_A est un λ -système. Par l'étape 1, pour tout $C \in \Pi$ on a $A \cap C \in \lambda(\Pi)$, donc $\Pi \subseteq \Lambda_A$. Par minimalité, $\Lambda_A = \lambda(\Pi)$, d'où : pour tous $A, B \in \lambda(\Pi)$, $A \cap B \in \lambda(\Pi)$.

Étape 3 : une λ -famille stable par intersections finies est une σ -algèbre. Soit (A_n) une suite dans $\lambda(\Pi)$. Définir $C_1 = A_1$ et $C_n = A_n \setminus \bigcup_{k=1}^{n-1} A_k$. Par récurrence, $\bigcup_{k=1}^{n-1} A_k \in \lambda(\Pi)$ et $C_n \in \lambda(\Pi)$ (stabilité par différence). Les C_n sont disjoints et $\cup_n C_n = \cup_n A_n$. La stabilité d'un λ -système par unions croissantes donne $\cup_n A_n \in \lambda(\Pi)$. Donc $\lambda(\Pi)$ est stable par unions dénombrables et par compléments : c'est une σ -algèbre. $\square$

Corollaire 2.1 (Unicité d'une mesure à partir d'un π -système (version σ -finie)). *Soient μ et ν deux mesures σ -finies sur $(\Omega, \mathcal{F})$ et Π un π -système tel que $\sigma(\Pi) = \mathcal{F}$. Si elles coïncident sur Π , alors $\mu = \nu$ sur $\mathcal{F}$.*

Proof. Par σ -finitude, il existe $(A_n), (B_n)$ dans $\mathcal{F}$ tels que $\Omega = \cup_n A_n = \cup_n B_n$ avec $\mu(A_n) < \infty$ et $\nu(B_n) < \infty$. Poser $C_n = \cup_{k=1}^n A_k$, $D_n = \cup_{k=1}^n B_k$ et $E_n = C_n \cap D_n$. Alors $E_n \uparrow \Omega$ et $\mu(E_n), \nu(E_n) < \infty$.

Fixons n . Considérer les mesures finies $\mu_n(F) = \mu(F \cap E_n)$ et $\nu_n(F) = \nu(F \cap E_n)$ sur $\mathcal{F}$, et le π -système $\Pi_n = \{A \cap E_n : A \in \Pi\}$ (stable par intersections finies). On a $\sigma(\Pi_n) = \{F \cap E_n : F \in \mathcal{F}\}$

et $\mu_n = \nu_n$ sur Π_n . Comme μ_n et ν_n sont finies, l'ensemble $\Lambda_n = \{G \in \sigma(\Pi_n) : \mu_n(G) = \nu_n(G)\}$ est un λ -système : la différence $B \setminus A$ est licite car on ne fait pas $+\infty - \infty$. Par π - λ , $\Lambda_n = \sigma(\Pi_n)$, donc

$$\forall F \in \mathcal{F}, \quad \mu(F \cap E_n) = \nu(F \cap E_n).$$

Enfin, pour tout $F \in \mathcal{F}$, on a $F \cap E_n \uparrow F$ et la continuité croissante (2.2) donne $\mu(F) = \lim_n \mu(F \cap E_n) = \lim_n \nu(F \cap E_n) = \nu(F)$. $\square$

Proposition 2.3 (Indépendance $\Rightarrow$ factorisation des espérances). *Si $\mathcal{F}_1 \perp\!\!\!\perp \mathcal{F}_2$ et si X est bornée $\mathcal{F}_1$ -mesurable, Y bornée $\mathcal{F}_2$ -mesurable, alors*

$$\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y].$$

Proof. Pour $X = \mathbf{1}_A$ et $Y = \mathbf{1}_B$, c'est la définition : $\mathbb{E}[\mathbf{1}_A \mathbf{1}_B] = \mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B)$. On étend aux fonctions simples positives par linéarité, puis aux fonctions bornées par approximation et convergence dominée. $\square$

Mesure produit et intégrales itérées (Tonelli/Fubini). Dans la pratique, on veut (i) construire une mesure sur un produit (loi jointe, indépendance) et (ii) justifier l'opération « intégrer puis intégrer » (marginalisation d'une densité jointe, calcul d'une espérance via une densité conditionnelle). La brique technique derrière « on définit sur des rectangles puis on étend » est l'extension de Carathéodory.

Théorème 2.2 (Extension de Carathéodory (pré-mesure $\rightarrow$ mesure)). *Soit $\mathcal{A}$ une algèbre de parties de Ω et μ_0 une pré-mesure sur $\mathcal{A}$. Supposons μ_0 σ -finie : il existe $(E_n) \subseteq \mathcal{A}$ tel que $\Omega = \cup_n E_n$ et $\mu_0(E_n) < \infty$. Alors il existe une mesure μ sur $\sigma(\mathcal{A})$ telle que $\mu|_{\mathcal{A}} = \mu_0$. Cette extension est unique parmi les mesures σ -finies sur $\sigma(\mathcal{A})$.*

Preuve (guidée). (1) Construire une mesure extérieure. Définir, pour tout $E \subseteq \Omega$,

$$\mu^*(E) := \inf \left\{ \sum_{n \geq 1} \mu_0(A_n) : E \subseteq \bigcup_{n \geq 1} A_n, A_n \in \mathcal{A} \right\}.$$

Alors $\mu^*(\emptyset) = 0$, μ^* est croissante, et elle est sous-additive dénombrable (concaténer des recouvrements).

(2) *Ensembles de Carathéodory.* On dit que $E \subseteq \Omega$ est μ^* -mesurable si pour tout $B \subseteq \Omega$,

$$\mu^*(B) = \mu^*(B \cap E) + \mu^*(B \cap E^c).$$

Notons $\mathcal{M}$ l'ensemble de ces E . On vérifie :

- $\mathcal{M}$ est une tribu (stabilité par complément ; stabilité par unions dénombrables en utilisant la sous-additivité et un passage à la limite sur les unions finies) ;
- la restriction $\mu := \mu^*|_{\mathcal{M}}$ est une mesure sur $\mathcal{M}$ (additivité sur unions disjointes en itérant l'identité de Carathéodory).

(3) $\mathcal{A} \subseteq \mathcal{M}$ et extension. Soit $A \in \mathcal{A}$. L'inégalité $\leq$ dans la condition de Carathéodory est vraie pour tout A par sous-additivité : $B \subseteq (B \cap A) \cup (B \cap A^c)$. Pour l'inégalité $\geq$, partir d'un recouvrement $B \subseteq \cup_n A_n$ avec $A_n \in \mathcal{A}$ et remarquer que $B \cap A \subseteq \cup_n (A_n \cap A)$ et $B \cap A^c \subseteq \cup_n (A_n \cap A^c)$. Comme $\mathcal{A}$ est stable par intersections et compléments, $A_n \cap A$ et $A_n \cap A^c$ sont dans $\mathcal{A}$ et $\mu_0(A_n) = \mu_0(A_n \cap A) + \mu_0(A_n \cap A^c)$. En sommant et en prenant l'infimum sur les recouvrements, on obtient l'inégalité inverse : $A \in \mathcal{M}$.

Il reste à voir que μ prolonge μ_0 sur $\mathcal{A}$. On a toujours $\mu^*(A) \leq \mu_0(A)$ (recouvrement trivial). Réciproquement, si $A \subseteq \cup_n A_n$ avec $A_n \in \mathcal{A}$, définir $B_1 = A_1$ et $B_n = A_n \setminus \cup_{k < n} A_k$ (union finie,

donc $B_n \in \mathcal{A}$) : les B_n sont disjoints et $A \subseteq \cup_n B_n$. Alors les ensembles $A \cap B_n \in \mathcal{A}$ sont disjoints et $\cup_n (A \cap B_n) = A \in \mathcal{A}$, donc par σ -additivité de μ_0 ,

$$\mu_0(A) = \sum_{n \geq 1} \mu_0(A \cap B_n) \leq \sum_{n \geq 1} \mu_0(B_n) \leq \sum_{n \geq 1} \mu_0(A_n).$$

En prenant l'infimum sur les recouvrements, $\mu_0(A) \leq \mu^*(A)$, donc $\mu^*(A) = \mu_0(A)$. Ainsi μ prolonge μ_0 sur $\mathcal{A}$ et, comme $\sigma(\mathcal{A}) \subseteq \mathcal{M}$ (tribu contenant $\mathcal{A}$), on a bien une mesure sur $\sigma(\mathcal{A})$.

(4) *Unicité.* Si ν est une autre extension σ -finie de μ_0 sur $\sigma(\mathcal{A})$, alors $\nu = \mu$ sur $\mathcal{A}$. Comme $\mathcal{A}$ est un π -système et $\sigma(\mathcal{A})$ est engendrée par $\mathcal{A}$, l'unicité suit de 2.1. $\square$

Théorème 2.3 (Mesure produit (existence et unicité)). *Soient $(\Omega_1, \mathcal{F}_1, \mu)$ et $(\Omega_2, \mathcal{F}_2, \nu)$ deux espaces mesurés avec μ et ν σ -finies. Alors il existe une unique mesure $\mu \otimes \nu$ sur $(\Omega_1 \times \Omega_2, \mathcal{F}_1 \otimes \mathcal{F}_2)$ telle que*

$$\forall A \in \mathcal{F}_1, \forall B \in \mathcal{F}_2, \quad (\mu \otimes \nu)(A \times B) = \mu(A)\nu(B).$$

Proof. Noter $\mathcal{A}$ l'algèbre des unions finies disjointes de rectangles mesurables $A \times B$. Définir μ_0 sur $\mathcal{A}$ par additivité : si $E = \bigsqcup_{i=1}^m (A_i \times B_i)$ (union disjointe), poser $\mu_0(E) = \sum_{i=1}^m \mu(A_i)\nu(B_i)$. Cette définition est cohérente : deux décompositions disjointes admettent un raffinement commun en rectangles d'intersection, ce qui force les sommes à coïncider par additivité finie de μ et ν .

Sur $\mathcal{A}$, la σ -additivité quand l'union reste dans $\mathcal{A}$ se réduit à l'additivité finie (une union disjointe dénombrable qui est une union finie ne peut avoir qu'un nombre fini de termes non vides). Donc μ_0 est une pré-mesure.

Comme μ et ν sont σ -finies, il existe $C_n \in \mathcal{F}_1$ et $D_n \in \mathcal{F}_2$ avec $C_n \uparrow \Omega_1$, $D_n \uparrow \Omega_2$, $\mu(C_n) < \infty$ et $\nu(D_n) < \infty$. Alors $C_n \times D_m$ recouvre $\Omega_1 \times \Omega_2$ et $\mu_0(C_n \times D_m) = \mu(C_n)\nu(D_m) < \infty$: μ_0 est σ -finie.

Appliquer Carathéodory (2.2) : μ_0 s'étend en une mesure $\mu \otimes \nu$ sur $\sigma(\mathcal{A}) = \mathcal{F}_1 \otimes \mathcal{F}_2$. L'unicité parmi les mesures σ -finies est donnée par 2.2. $\square$

Théorème 2.4 (Tonelli (fonction mesurable positive)). *Soient μ et ν σ -finies, et $f : \Omega_1 \times \Omega_2 \rightarrow [0, \infty]$ mesurable. Alors les applications $x \mapsto \int_{\Omega_2} f(x, y) \nu(dy)$ et $y \mapsto \int_{\Omega_1} f(x, y) \mu(dx)$ sont mesurables et*

$$\int_{\Omega_1 \times \Omega_2} f \, d(\mu \otimes \nu) = \int_{\Omega_1} \left(\int_{\Omega_2} f(x, y) \nu(dy) \right) \mu(dx) = \int_{\Omega_2} \left(\int_{\Omega_1} f(x, y) \mu(dx) \right) \nu(dy),$$

avec la convention $+\infty$ autorisée.

Proof. Pour $f = \mathbf{1}_{A \times B}$, c'est la définition de $\mu \otimes \nu$. Par linéarité, c'est vrai pour les fonctions simples positives $f = \sum_k a_k \mathbf{1}_{E_k}$. Pour un $f \geq 0$ mesurable général, choisir des simples $f_n \uparrow f$. Par convergence monotone (6.8), on a $\int f_n \, d(\mu \otimes \nu) \uparrow \int f \, d(\mu \otimes \nu)$ et, pour tout x , $\int f_n(x, \cdot) \, d\nu \uparrow \int f(x, \cdot) \, d\nu$. On conclut en appliquant encore la convergence monotone à l'intégrale en x . La mesurabilité des intégrales itérées vient du passage à la limite de fonctions mesurables (cas simple). $\square$

Théorème 2.5 (Fubini (fonction intégrable)). *Soient μ et ν σ -finies, et $f : \Omega_1 \times \Omega_2 \rightarrow \mathbb{R}$ mesurable telle que $\int |f| \, d(\mu \otimes \nu) < \infty$. Alors, pour μ -p.p. x , la fonction $y \mapsto f(x, y)$ est intégrable et la fonction $x \mapsto \int f(x, y) \nu(dy)$ est dans $L^1(\mu)$; de même en inversant les rôles. De plus,*

$$\int f \, d(\mu \otimes \nu) = \int_{\Omega_1} \left(\int_{\Omega_2} f(x, y) \nu(dy) \right) \mu(dx) = \int_{\Omega_2} \left(\int_{\Omega_1} f(x, y) \mu(dx) \right) \nu(dy).$$

Proof. Écrire $f = f^+ - f^-$ avec $f^\pm \geq 0$. L'hypothèse $\int |f| < \infty$ implique $\int f^+ < \infty$ et $\int f^- < \infty$. Appliquer Tonelli (2.4) à f^+ et f^- : les intégrales itérées de $f^\pm$ sont finies (p.p.) et l'égalité vaut. Soustraire donne le résultat pour f . $\square$

Exemple 2.1 (Sans intégrabilité absolue, l'ordre peut changer). Sur $(0, 1)^2$, poser $f(x, y) = \frac{x^2 - y^2}{(x^2 + y^2)^2}$ (et $f(0, 0) = 0$). Pour $y > 0$,

$$\int_0^1 f(x, y) dx = -\left[\frac{x}{x^2 + y^2}\right]_0^1 = -\frac{1}{1 + y^2},$$

donc

$$\int_0^1 \left(\int_0^1 f(x, y) dx \right) dy = -\int_0^1 \frac{1}{1 + y^2} dy = -\frac{\pi}{4}.$$

Dans l'autre sens,

$$\int_0^1 f(x, y) dy = \left[\frac{y}{x^2 + y^2}\right]_0^1 = \frac{1}{1 + x^2},$$

donc

$$\int_0^1 \left(\int_0^1 f(x, y) dy \right) dx = \frac{\pi}{4}.$$

Ce n'est pas une contradiction : $\iint_{(0,1)^2} |f| = +\infty$ (singularité en $(0, 0)$), donc Fubini ne s'applique pas.

Proposition 2.4 (Boréliens sur un produit euclidien). On a $\mathcal{B}(\mathbb{R}^d) = \mathcal{B}(\mathbb{R})^{\otimes d}$, où $\mathcal{B}(\mathbb{R})^{\otimes d} := \mathcal{B}(\mathbb{R}) \otimes \cdots \otimes \mathcal{B}(\mathbb{R})$. En particulier $\mathcal{B}(\mathbb{R}^2) = \mathcal{B}(\mathbb{R}) \otimes \mathcal{B}(\mathbb{R})$.

Proof. Pour $\mathcal{B}(\mathbb{R})^{\otimes d} \subseteq \mathcal{B}(\mathbb{R}^d)$: les projections $\pi_i : \mathbb{R}^d \rightarrow \mathbb{R}$ sont continues, donc boréliennes, et un pavé $A_1 \times \cdots \times A_d$ s'écrit $\cap_i \pi_i^{-1}(A_i)$. Donc la tribu engendrée par les pavés est incluse dans $\mathcal{B}(\mathbb{R}^d)$.

Pour l'inclusion inverse : les pavés ouverts à bords rationnels forment une base dénombrable de la topologie produit. Tout ouvert est union dénombrable de tels pavés, donc appartient à $\mathcal{B}(\mathbb{R})^{\otimes d}$. Comme $\mathcal{B}(\mathbb{R}^d)$ est engendrée par les ouverts, on a $\mathcal{B}(\mathbb{R}^d) \subseteq \mathcal{B}(\mathbb{R})^{\otimes d}$. $\square$

Piège. Tonelli s'utilise pour $f \geq 0$ (les intégrales peuvent valoir $+\infty$). Fubini demande $\int |f| < \infty$: sans intégrabilité absolue, l'ordre d'intégration peut changer la valeur (exemple ci-dessus).

Ce qui n'est *pas* une tribu (contre-exemples)

Exemple 2.2 (Manque de stabilité par complément). Sur $\Omega = \{1, 2, 3\}$, la famille $\mathcal{A} = \{\emptyset, \{1\}, \Omega\}$ n'est pas une tribu car $\{1\}^c = \{2, 3\} \notin \mathcal{A}$.

Exemple 2.3 (Stable par unions finies mais pas dénombrables). Sur $\Omega = \mathbb{R}$, la famille des unions *finies* d'intervalles est stable par complément et union finie, mais pas par union dénombrable (on ne peut pas reconstruire tous les boréliens).

Sanity checks

Sanity check. « Stable par union finie » ne suffit pas : les limites passent via des unions dénombrables (continuité des mesures, Borel–Cantelli, etc.).

Sanity check. Complétion : si $A \in \mathcal{F}$ et $\mathbb{P}(A) = 0$, alors *tout* $N \subseteq A$ doit devenir mesurable dans $\overline{\mathcal{F}}^{\mathbb{P}}$. C'est la bonne tribu quand on travaille « à égalité p.s. près ».

Sanity check. Si tu échanges l'ordre de deux intégrales, dis explicitement si tu es en Tonelli ($f \geq 0$) ou en Fubini ($\int |f| < \infty$). Sinon tu risques un $+\infty - \infty$ masqué.

Blocs Q/R d'entretien déplacés en annexe (voir Annexe Q/R).

Mini-synthèse

- $\mathcal{F}$ encode l'information ; σ -additivité + unions dénombrables = passage à la limite.
- $\sigma(\mathcal{G})$: construction minimale et rigoureuse.
- Produit $\mathcal{F}_1 \otimes \mathcal{F}_2$: σ -algèbre engendrée par les rectangles.
- $\pi-\lambda$: outil pour étendre une propriété d'un générateur à $\sigma(\cdot)$.
- Compléter une tribu ajoute tous les sous-ensembles des $\mathbb{P}$ -nuls.
- Carathéodory : définir une pré-mesure puis l'étendre à $\sigma(\mathcal{A})$.
- Mesure produit + Tonelli/Fubini : justifier $\iint = \int(f)$ et la marginalisation.

3 Variables aléatoires, lois, densités, Radon–Nikodym

Intuition

Une variable aléatoire est une application *mesurable* : elle transforme un scénario ω en un réel sans créer d'événements « non observables ». Sa loi est une mesure sur l'espace d'arrivée : on pousse $\mathbb{P}$ par X (pushforward). Parler de densité, c'est parler d'une dérivée de mesure par rapport à Lebesgue : c'est une hypothèse (absolue continuité), pas un droit. Radon–Nikodym est la version générale de « densité » : dériver une mesure par rapport à une autre.

Définitions

Définition 3.1 (Variable aléatoire). Soit $(\Omega, \mathcal{F}, \mathbb{P})$. Une **variable aléatoire** réelle est une application $X : \Omega \rightarrow \mathbb{R}$ **mesurable** :

$$\forall B \in \mathcal{B}(\mathbb{R}), \quad X^{-1}(B) \in \mathcal{F}.$$

Définition 3.2 (Loi comme mesure image (pushforward)). La **loi** de X est la mesure μ_X sur $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ définie par

$$\mu_X(B) = \mathbb{P}(X \in B) = \mathbb{P}(X^{-1}(B)).$$

On note aussi $\mu_X = \mathbb{P} \circ X^{-1}$ et $\mathcal{L}(X) = \mu_X$.

Définition 3.3 (Densité : continu, discret, mixte). Soit λ la mesure de Lebesgue sur $\mathbb{R}$. On dit que X est **(absolument) continue** si $\mu_X \ll \lambda$; alors il existe f_X telle que

$$\forall B \in \mathcal{B}(\mathbb{R}), \quad \mu_X(B) = \int_B f_X(x) \, dx,$$

et f_X est une **densité**. On dit que X est **discrète** si μ_X est une somme d'atomes sur un ensemble dénombrable. On dit que X est **mixte** si μ_X a une partie atomique et une partie absolument continue.

Définition 3.4 (Intégrabilité, variance, covariance). X est **intégrable** si $\mathbb{E}[|X|] < \infty$. Si $X \in L^2$, $\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2]$. Si $X, Y \in L^2$, $\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])]$.

Résultats et preuves

Proposition 3.1 (Propriétés d'une fonction de répartition). La CDF $F_X(x) = \mathbb{P}(X \leq x)$ est croissante, continue à droite, et vérifie $\lim_{x \rightarrow -\infty} F_X(x) = 0$, $\lim_{x \rightarrow +\infty} F_X(x) = 1$.

Proof. Les événements $\{X \leq x\}$ sont croissants en x , donc F_X est croissante. Pour $x_n \downarrow x$, on a $\{X \leq x_n\} \downarrow \{X \leq x\}$ et la continuité décroissante (2.2) donne $F_X(x_n) \downarrow F_X(x)$: c'est la continuité à droite. Les limites $\pm\infty$ viennent de $\{X \leq x\} \uparrow \emptyset$ quand $x \rightarrow -\infty$ et $\{X \leq x\} \uparrow \Omega$ quand $x \rightarrow +\infty$. $\square$

Théorème 3.1 (LOTUS). Soit $g : \mathbb{R} \rightarrow \mathbb{R}$ borélienne telle que $\mathbb{E}[|g(X)|] < \infty$. Alors

$$\mathbb{E}[g(X)] = \int_{\mathbb{R}} g(x) \mu_X(\mathrm{d}x).$$

Si μ_X admet une densité f_X , alors $\mathbb{E}[g(X)] = \int_{\mathbb{R}} g(x) f_X(x) \mathrm{d}x$.

Proof. Pour une fonction simple $g = \sum_k a_k \mathbf{1}_{B_k}$,

$$\mathbb{E}[g(X)] = \sum_k a_k \mathbb{P}(X \in B_k) = \sum_k a_k \mu_X(B_k) = \int g \, \mathrm{d}\mu_X.$$

Pour $g \geq 0$, approximer par une suite croissante de fonctions simples et conclure par convergence monotone. Pour g intégrable, écrire $g = g^+ - g^-$. $\square$

Théorème 3.2 (Radon–Nikodym : énoncé (σ -fini)). Soient μ et ν deux mesures σ -finies sur $(\Omega, \mathcal{F})$. Si $\nu \ll \mu$, alors il existe une fonction mesurable $f \geq 0$ telle que

$$\forall A \in \mathcal{F}, \quad \nu(A) = \int_A f \, \mathrm{d}\mu.$$

On note $f = \frac{\mathrm{d}\nu}{\mathrm{d}\mu}$ (unique μ -p.s.).

Preuve guidée (ce qu'on veut savoir refaire). **(0) Réduction σ -finie $\rightarrow$ finie.** Comme μ est σ -finie, il existe (E_n) mesurables tels que $\Omega = \cup_n E_n$ et $\mu(E_n) < \infty$. Poser aussi $F_n = E_n \cap G_n$ où (G_n) est une décomposition σ -finie pour ν (donc $\nu(F_n) < \infty$). Sur chaque F_n , on applique la version finie (ci-dessous) à $\mu_n := \mu|_{F_n}$ et $\nu_n := \nu|_{F_n}$: on obtient f_n tel que $\nu_n(A) = \int_A f_n \, \mathrm{d}\mu_n$. Alors $f := \sum_{n \geq 1} f_n \mathbf{1}_{F_n}$ convient sur Ω (les F_n recouvrent Ω).

(1) Cas discret (preuve complète, intuition béton). Si Ω est dénombrable, une mesure μ est déterminée par les masses $\mu(\{\omega\})$. Si $\nu \ll \mu$, alors $\mu(\{\omega\}) = 0 \Rightarrow \nu(\{\omega\}) = 0$, et on peut définir

$$f(\omega) = \begin{cases} \nu(\{\omega\})/\mu(\{\omega\}) & \text{si } \mu(\{\omega\}) > 0, \\ 0 & \text{sinon.} \end{cases}$$

Pour tout $A \subseteq \Omega$,

$$\int_A f \, \mathrm{d}\mu = \sum_{\omega \in A} f(\omega) \mu(\{\omega\}) = \sum_{\omega \in A} \nu(\{\omega\}) = \nu(A).$$

Donc $f = \mathrm{d}\nu/\mathrm{d}\mu$.

(2) Cas fini (idée constructive). On veut une fonction f telle que, pour tout A , $\nu(A)$ soit une intégrale contre μ . Le point technique est que l'égalité doit tenir *sur tous les ensembles* (pas seulement en moyenne). Une construction standard (mais plus longue) consiste à :

- considérer, pour $t \in \mathbb{Q}$, la mesure signée $\nu - t\mu$ et appliquer le théorème de décomposition de Hahn pour obtenir une région où $\nu \geq t\mu$ sur tous les sous-ensembles ;
- définir $f(\omega) = \sup\{t \in \mathbb{Q} : \omega \text{ est dans la partie positive de } \nu - t\mu\}$;
- montrer que $\nu(A) = \int_A f \, \mathrm{d}\mu$ en encadrant $\nu(A)$ par des intégrales de simples fonctions (on utilise la continuité des mesures et l'approximation monotone).

À retenir en entretien : la dérivée RN est une densité au sens « $\nu = f \cdot \mu$ » ; et on peut raisonner comme en discret sur de petites régions, puis passer à la limite. $\square$

Encadré interview : pourquoi c'est utile. RN formalise « ν a une densité par rapport à μ ». Le cas clé en finance est le changement de mesure :

$$\mathbb{Q} \ll \mathbb{P}, \quad L := \frac{d\mathbb{Q}}{d\mathbb{P}} \quad \Rightarrow \quad \mathbb{E}^{\mathbb{Q}}[X] = \mathbb{E}^{\mathbb{P}}[LX].$$

C'est la brique de base avant Girsanov.

Proposition 3.2 (Changement de mesure : formule d'espérance). *Soient $\mathbb{P}$ et $\mathbb{Q}$ deux probabilités sur $(\Omega, \mathcal{F})$ avec $\mathbb{Q} \ll \mathbb{P}$. Poser $L := \frac{d\mathbb{Q}}{d\mathbb{P}}$. Alors, pour toute v.a. X intégrable sous $\mathbb{Q}$,*

$$\mathbb{E}^{\mathbb{Q}}[X] = \mathbb{E}^{\mathbb{P}}[LX].$$

Proof. Par RN, pour tout $A \in \mathcal{F}$, $\mathbb{Q}(A) = \int_A L d\mathbb{P}$. Pour une fonction simple $X = \sum_k a_k \mathbf{1}_{A_k}$, on a

$$\mathbb{E}^{\mathbb{Q}}[X] = \sum_k a_k \mathbb{Q}(A_k) = \sum_k a_k \int_{A_k} L d\mathbb{P} = \mathbb{E}^{\mathbb{P}}[LX].$$

On conclut par approximation de X par des fonctions simples et convergence dominée. $\square$

Proposition 3.3 (Formule de Bayes (changement de mesure & conditionnement)). *Soit $\mathcal{G} \subseteq \mathcal{F}$ une sous-tribu. Supposons $\mathbb{Q} \ll \mathbb{P}$ et posons $L = \frac{d\mathbb{Q}}{d\mathbb{P}}$. Pour toute v.a. X intégrable sous $\mathbb{Q}$,*

$$\mathbb{E}^{\mathbb{Q}}[X | \mathcal{G}] = \frac{\mathbb{E}^{\mathbb{P}}[LX | \mathcal{G}]}{\mathbb{E}^{\mathbb{P}}[L | \mathcal{G}]} \quad \text{sur } \{\mathbb{E}^{\mathbb{P}}[L | \mathcal{G}] > 0\}.$$

Proof. Poser $Z = \mathbb{E}^{\mathbb{P}}[LX | \mathcal{G}]$ et $W = \mathbb{E}^{\mathbb{P}}[L | \mathcal{G}]$. Sur $\{W > 0\}$, définir $Y = Z/W$; alors Y est $\mathcal{G}$ -mesurable. Pour tout $A \in \mathcal{G}$, par la propriété caractéristique de l'espérance conditionnelle et 3.2,

$$\mathbb{E}^{\mathbb{Q}}[X \mathbf{1}_A] = \mathbb{E}^{\mathbb{P}}[LX \mathbf{1}_A] = \mathbb{E}^{\mathbb{P}}[Z \mathbf{1}_A].$$

De même, $\mathbb{E}^{\mathbb{Q}}[Y \mathbf{1}_A] = \mathbb{E}^{\mathbb{P}}[LY \mathbf{1}_A] = \mathbb{E}^{\mathbb{P}}[WY \mathbf{1}_A] = \mathbb{E}^{\mathbb{P}}[Z \mathbf{1}_A]$. Donc $\mathbb{E}^{\mathbb{Q}}[Y \mathbf{1}_A] = \mathbb{E}^{\mathbb{Q}}[X \mathbf{1}_A]$ pour tout $A \in \mathcal{G}$, ce qui caractérise $Y = \mathbb{E}^{\mathbb{Q}}[X | \mathcal{G}]$. $\square$

Sanity checks

Sanity check. Dire « X a une densité » signifie $\mu_X \ll \lambda$ (Lebesgue). Une CDF n'est pas forcément dérivable ; une loi peut être discrète ou mixte.

Sanity check. Sous $\mathbb{Q} \ll \mathbb{P}$, $L = d\mathbb{Q}/d\mathbb{P}$ doit être positif et vérifier $\mathbb{E}^{\mathbb{P}}[L] = 1$. Sinon ce n'est pas une densité de probabilité.

Blocs Q/R d'entretien déplacés en annexe (voir Annexe Q/R).

Mini-synthèse

- V.a. = application mesurable ; loi = mesure image $\mathbb{P} \circ X^{-1}$.
- Densité $\Leftrightarrow$ absolue continuité (pas « dériver la CDF » par défaut).
- LOTUS : calculer $\mathbb{E}[g(X)]$ dans l'espace de la loi.
- RN : notion générale de densité, clé du changement de mesure $\mathbb{P} \rightarrow \mathbb{Q}$.

4 Transformations, Jacobien, lois images

Intuition

Quand on passe de X à $Y = g(X)$, on pousse une mesure : $\mu_Y = \mu_X \circ g^{-1}$. Si X a une densité, la densité de Y se déduit d'un changement de variable. Les erreurs classiques : oublier la valeur absolue du Jacobien, oublier le support, ou oublier que g n'est pas injective.

Définitions

Définition 4.1 (Loi image). Soit $g : \mathbb{R}^d \rightarrow \mathbb{R}^m$ mesurable et X une v.a. dans $\mathbb{R}^d$. La loi de $Y = g(X)$ est $\mu_Y = \mu_X \circ g^{-1}$: pour tout borélien B , $\mu_Y(B) = \mu_X(g^{-1}(B))$.

Définition 4.2 (Jacobien). Si $g : \mathbb{R}^d \rightarrow \mathbb{R}^d$ est $\mathcal{C}^1$, son Jacobien en x est $J_g(x) = (\partial g_i / \partial x_j)_{i,j}$.

Résultats (avec preuves)

Théorème 4.1 (Changement de variable (1D, monotone)). Soit X une v.a. à densité f_X sur $\mathbb{R}$. Soit $g : \mathbb{R} \rightarrow \mathbb{R}$ de classe $\mathcal{C}^1$, strictement monotone, et posons $Y = g(X)$. Alors Y admet une densité

$$f_Y(y) = f_X(g^{-1}(y)) |(g^{-1})'(y)| \mathbf{1}_{y \in g(\mathbb{R})}.$$

Proof. Supposons g strictement croissante (sinon, même preuve avec valeur absolue). Alors $F_Y(y) = \mathbb{P}(Y \leq y) = \mathbb{P}(X \leq g^{-1}(y)) = \int_{-\infty}^{g^{-1}(y)} f_X(x) dx$. En dérivant : $f_Y(y) = f_X(g^{-1}(y))(g^{-1})'(y)$ sur $g(\mathbb{R})$, et 0 hors support. $\square$

Théorème 4.2 (Changement de variable (multivarié)). Soit X une v.a. dans $\mathbb{R}^d$ à densité f_X . Soit $g : \mathbb{R}^d \rightarrow \mathbb{R}^d$ un $\mathcal{C}^1$ -difféomorphisme et $Y = g(X)$. Alors Y admet une densité

$$f_Y(y) = f_X(g^{-1}(y)) |\det J_{g^{-1}}(y)| \mathbf{1}_{y \in g(\mathbb{R}^d)}.$$

Proof. Pour tout borélien B ,

$$\mathbb{P}(Y \in B) = \mathbb{P}(X \in g^{-1}(B)) = \int_{g^{-1}(B)} f_X(x) dx.$$

Par la formule de changement de variables (diffeomorphisme), on obtient $\int_{g^{-1}(B)} f_X(x) dx = \int_B f_X(g^{-1}(y)) |\det J_{g^{-1}}(y)| dy$, ce qui identifie la densité de Y . $\square$

Exemples interview (dérivations)

Lognormale : $Y = \exp(X)$ avec $X \sim \mathcal{N}(m, s^2)$

On a $g(x) = e^x$, $g^{-1}(y) = \log y$ (sur $y > 0$) et $(g^{-1})'(y) = 1/y$. Donc, pour $y > 0$,

$$f_Y(y) = \frac{1}{y s \sqrt{2\pi}} \exp\left(-\frac{(\log y - m)^2}{2s^2}\right).$$

Moments (LOTUS, 3.1) :

$$\mathbb{E}[Y^k] = \mathbb{E}[e^{kX}] = \exp\left(km + \frac{1}{2}k^2s^2\right) \quad (k \in \mathbb{R}).$$

Sanity check. Le support est $(0, \infty)$. Oublier le facteur $1/y$ produit une « densité » qui ne s'intègre pas à 1.

χ^2 : somme de carrés de gaussiennes

Si $Z_1, \dots, Z_k$ sont i.i.d. $\mathcal{N}(0, 1)$, alors $Q = \sum_{i=1}^k Z_i^2$ suit une loi $\chi^2(k)$. Un calcul utile en entretien est la MGF :

$$M_Q(t) = \mathbb{E}[e^{tQ}] = \prod_{i=1}^k \mathbb{E}[e^{tZ_i^2}] = (1 - 2t)^{-k/2} \quad (t < 1/2),$$

où $\mathbb{E}[e^{tZ^2}] = (1 - 2t)^{-1/2}$ se calcule en complétant le carré dans l'intégrale gaussienne.

Ratio de deux normales centrées : Cauchy

Si Z_1, Z_2 sont i.i.d. $\mathcal{N}(0, 1)$ et $T = Z_1/Z_2$, alors T suit une loi de Cauchy standard :

$$f_T(t) = \frac{1}{\pi(1+t^2)}.$$

Idée propre. Le vecteur (Z_1, Z_2) est invariant par rotation : l'angle est uniforme, et $T = \tan(\Theta)$.

Sanity checks

Sanity check. Une densité doit être ≥ 0 et intégrer à 1 sur son support. Si ta « densité » ne s'intègre pas à 1, c'est presque toujours un Jacobien oublié ou un support mal géré.

Sanity check. En dimension d , le facteur est $|\det J_{g^{-1}}(y)|$ (valeur absolue). Un déterminant négatif ou un oubli de valeur absolue ne change pas une mesure : il change ton signe et casse la normalisation.

Pièges Jacobien (ce qui casse un raisonnement)

Piège. Si g n'est pas injective (ex : $Y = X^2$), la densité de Y est une *somme* sur les antécédents : $f_Y(y) = \sum_{x:g(x)=y} f_X(x) |1/g'(x)|$ sur le support. Oublier un antécédent donne une densité non normalisée.

Piège. Le support ne se devine pas : il se déduit de $g(\text{supp } X)$ et/ou de la contrainte $y = g(x)$. En multivarié, il faut vérifier l'injectivité sur le domaine considéré.

Blocs Q/R d'entretien déplacés en annexe (voir Annexe Q/R).

Mini-synthèse

- Loi image : $\mu_{g(X)} = \mu_X \circ g^{-1}$.
- 1D monotone : $f_Y(y) = f_X(g^{-1}(y)) |(g^{-1})'(y)|$ sur le support.
- Multivarié : $f_Y(y) = f_X(g^{-1}(y)) |\det J_{g^{-1}}(y)|$ (diffeomorphisme).
- Pièges : non-injectivité $\Rightarrow$ somme sur les antécédents ; support ; valeur absolue.

5 Conditionnement et espérance conditionnelle

Intuition

Conditionner, c'est « résumer l'information disponible ». Une tribu $\mathcal{G}$ encode ce que tu sais, et $\mathbb{E}[X \mid \mathcal{G}]$ remplace X par un objet $\mathcal{G}$ -mesurable qui a les mêmes intégrales sur les événements de $\mathcal{G}$. En entretien, on attend : (i) la définition caractéristique, (ii) l'existence via Radon-Nikodym, (iii) les propriétés (tour, sortir le mesurable, Jensen conditionnel).

Définitions

Définition 5.1 (Probabilité conditionnelle (sur un événement)). Si $B \in \mathcal{F}$ avec $\mathbb{P}(B) > 0$, on pose $\mathbb{P}(A \mid B) = \mathbb{P}(A \cap B)/\mathbb{P}(B)$.

Piège. Conditionner sur $\{Y = y\}$ en continu est délicat : typiquement $\mathbb{P}(Y = y) = 0$. Le bon langage est $\mathbb{E}[\cdot \mid \sigma(Y)]$ (toujours défini pour les intégrables) et, quand elle existe, une densité conditionnelle (version régulière).

Définition 5.2 (Espérance conditionnelle (propriété caractéristique)). Soit $\mathcal{G} \subseteq \mathcal{F}$ une sous-tribu et X intégrable. Une v.a. Y est une version de $\mathbb{E}[X | \mathcal{G}]$ si :

- (i) Y est $\mathcal{G}$ -mesurable ;
- (ii) pour tout $A \in \mathcal{G}$, $\int_A Y \, d\mathbb{P} = \int_A X \, d\mathbb{P}$.

Remarque 5.1. L'espérance conditionnelle est unique $\mathbb{P}$ -p.s. : si Y et Y' vérifient la définition, alors $\mathbb{P}(Y = Y') = 1$.

Existence via Radon–Nikodym (preuve guidée)

Théorème 5.1 (Existence de $\mathbb{E}(X | \mathcal{G})$). Si X est intégrable, alors $\mathbb{E}[X | \mathcal{G}]$ existe.

Proof. Définir une mesure signée finie sur $\mathcal{G}$ par $\nu(A) := \int_A X \, d\mathbb{P}$. Si $\mathbb{P}(A) = 0$, alors $\nu(A) = 0$, donc $\nu \ll \mathbb{P}|_{\mathcal{G}}$. Par Radon–Nikodym (3.2), il existe une v.a. $\mathcal{G}$ -mesurable Y telle que $\nu(A) = \int_A Y \, d\mathbb{P}$ pour tout $A \in \mathcal{G}$. C'est exactement la définition de $\mathbb{E}[X | \mathcal{G}]$. $\square$

Propriétés (preuves courtes)

Proposition 5.1 (Linéarité). Si X, Y sont intégrables et $a, b \in \mathbb{R}$, alors $\mathbb{E}[aX + bY | \mathcal{G}] = a\mathbb{E}[X | \mathcal{G}] + b\mathbb{E}[Y | \mathcal{G}]$.

Proof. Les deux côtés sont $\mathcal{G}$ -mesurables. Pour tout $A \in \mathcal{G}$, intégrer et utiliser la linéarité de l'intégrale :

$$\int_A (a\mathbb{E}[X | \mathcal{G}] + b\mathbb{E}[Y | \mathcal{G}]) \, d\mathbb{P} = a \int_A X \, d\mathbb{P} + b \int_A Y \, d\mathbb{P} = \int_A (aX + bY) \, d\mathbb{P}.$$

$\square$

Proposition 5.2 (« Sortir ce qui est mesurable »). Si Z est bornée et $\mathcal{G}$ -mesurable, et X intégrable, alors

$$\mathbb{E}[ZX | \mathcal{G}] = Z \mathbb{E}[X | \mathcal{G}].$$

Proof. Le membre de droite est $\mathcal{G}$ -mesurable. Pour tout $A \in \mathcal{G}$, $\int_A Z \mathbb{E}[X | \mathcal{G}] \, d\mathbb{P} = \int_A ZX \, d\mathbb{P}$ par la propriété caractéristique appliquée à ZX . $\square$

Proposition 5.3 (Tour (itération)). Si $\mathcal{H} \subseteq \mathcal{G} \subseteq \mathcal{F}$ et X est intégrable, alors

$$\mathbb{E}[\mathbb{E}[X | \mathcal{G}] | \mathcal{H}] = \mathbb{E}[X | \mathcal{H}].$$

Proof. Le membre de gauche est $\mathcal{H}$ -mesurable. Pour $A \in \mathcal{H} \subseteq \mathcal{G}$, $\int_A \mathbb{E}[\mathbb{E}[X | \mathcal{G}] | \mathcal{H}] \, d\mathbb{P} = \int_A \mathbb{E}[X | \mathcal{G}] \, d\mathbb{P} = \int_A X \, d\mathbb{P}$. $\square$

Théorème 5.2 (Jensen conditionnel). Si $\varphi : \mathbb{R} \rightarrow \mathbb{R}$ est convexe et si $X, \varphi(X)$ sont intégrables, alors

$$\varphi(\mathbb{E}[X | \mathcal{G}]) \leq \mathbb{E}[\varphi(X) | \mathcal{G}] \quad \mathbb{P}\text{-p.s.}$$

Proof. Par convexité, φ est supremum de ses supports affines : $\varphi(x) = \sup_i (a_i x + b_i)$. Alors $\varphi(\mathbb{E}[X | \mathcal{G}]) = \sup_i (a_i \mathbb{E}[X | \mathcal{G}] + b_i) \leq \sup_i \mathbb{E}[a_i X + b_i | \mathcal{G}] \leq \mathbb{E}[\sup_i (a_i X + b_i) | \mathcal{G}] = \mathbb{E}[\varphi(X) | \mathcal{G}]$. $\square$

Proposition 5.4 (Décomposition de la variance (loi de la variance totale)). Si $X \in L^2$, alors

$$\text{Var}(X) = \mathbb{E}[\text{Var}(X | \mathcal{G})] + \text{Var}(\mathbb{E}[X | \mathcal{G}]), \quad \text{Var}(X | \mathcal{G}) := \mathbb{E}[(X - \mathbb{E}[X | \mathcal{G}])^2 | \mathcal{G}].$$

Proof. Écrire la décomposition orthogonale $X = (X - \mathbb{E}[X | \mathcal{G}]) + \mathbb{E}[X | \mathcal{G}]$. En développant $(X - \mathbb{E}[X])^2$ et en utilisant la tour (5.3) et le fait que $\mathbb{E}[X - \mathbb{E}[X | \mathcal{G}] | \mathcal{G}] = 0$, on obtient

$$\mathbb{E}[(X - \mathbb{E}[X])^2] = \mathbb{E}\left[\mathbb{E}\left[(X - \mathbb{E}[X | \mathcal{G}])^2 | \mathcal{G}\right]\right] + \mathbb{E}\left[(\mathbb{E}[X | \mathcal{G}] - \mathbb{E}[X])^2\right].$$

□

Proposition 5.5 (Décomposition de la covariance). *Si $X, Y \in L^2$, alors*

$$\text{Cov}(X, Y) = \mathbb{E}[\text{Cov}(X, Y | \mathcal{G})] + \text{Cov}(\mathbb{E}[X | \mathcal{G}], \mathbb{E}[Y | \mathcal{G}]),$$

où $\text{Cov}(X, Y | \mathcal{G}) := \mathbb{E}[(X - \mathbb{E}[X | \mathcal{G}]) (Y - \mathbb{E}[Y | \mathcal{G}]) | \mathcal{G}]$.

Proof. Développer $(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])$ en ajoutant/soustrayant les espérances conditionnelles, puis utiliser $\mathbb{E}[X - \mathbb{E}[X | \mathcal{G}] | \mathcal{G}] = 0$ et la tour. □

Conditionnement par une variable : $\mathcal{G} = \sigma(Y)$

Théorème 5.3 (Doob–Dynkin). *Si Z est $\sigma(Y)$ -mesurable, alors il existe une fonction borélienne g telle que $Z = g(Y)$ $\mathbb{P}$ -p.s.*

Preuve guidée (lecture « générateur »). La tribu $\sigma(Y)$ est engendrée par la famille $\{\{Y \in (-\infty, t]\} : t \in \mathbb{R}\}$. On commence par $Z = \mathbf{1}_{\{Y \leq t\}}$: on peut prendre $g(u) = \mathbf{1}_{\{u \leq t\}}$. Par linéarité, toute fonction simple de Y s'écrit $g(Y)$. Pour un Z $\sigma(Y)$ -mesurable général, on peut approximer Z point par point par une suite de fonctions simples $\sigma(Y)$ -mesurables (par exemple via quantification dyadique et troncature), et construire g comme limite pointwise de fonctions boréliennes. □

Remarque 5.2. On écrit souvent $\mathbb{E}[X | Y]$ pour $\mathbb{E}[X | \sigma(Y)]$. Le 5.3 justifie l'écriture $\mathbb{E}[X | Y] = g(Y)$ (pour une certaine fonction g).

Densités conditionnelles et formule de Bayes

Supposons que (X, Y) admet une densité jointe $f_{X,Y}$ sur $\mathbb{R}^2$. La densité marginale est $f_Y(y) = \int_{\mathbb{R}} f_{X,Y}(x, y) dx$. Quand $f_Y(y) > 0$, la densité conditionnelle est

$$f_{X|Y}(x | y) = \frac{f_{X,Y}(x, y)}{f_Y(y)},$$

et pour toute fonction g intégrable,

$$\mathbb{E}[g(X) | Y = y] = \int_{\mathbb{R}} g(x) f_{X|Y}(x | y) dx.$$

Sanity checks

Sanity check. $\mathbb{E}[X | \mathcal{G}]$ est une variable aléatoire $\mathcal{G}$ -mesurable (pas un scalaire, sauf tribu triviale).

Sanity check. Toujours vérifier l'intégrabilité : $\mathbb{E}[X | \mathcal{G}]$ n'existe que si $\mathbb{E}[|X|] < \infty$. En L^2 , on gagne l'interprétation « projection » (§7).

Blocs Q/R d'entretien déplacés en annexe (voir Annexe Q/R).

Mini-synthèse

- Définition caractéristique : intégrales sur $A \in \mathcal{G}$.
- Existence via RN sur $\nu(A) = \int_A X \, d\mathbb{P}$.
- Propriétés clés : linéarité, sortir le mesurable, tour, Jensen conditionnel.
- $\mathbb{E}[X \mid Y]$ est une v.a. $\sigma(Y)$ -mesurable, donc $g(Y)$.
- En continu : $Y = y$ est souvent proba zéro ; utiliser densités conditionnelles ou $\sigma(Y)$.

6 Convergences, outils de contrôle, LLN/CLT

Intuition

En finance, on mélange trois besoins : (i) des limites de distributions (CLT, approximations), (ii) des garanties probabilistes (convergence en probabilité, bornes de risque), (iii) des garanties fortes (p.s.) quand on manipule des trajectoires. La règle d'or : *ne jamais échanger limite et espérance sans un théorème + hypothèses*.

Définitions

Définition 6.1 (Convergence p.s., en probabilité, en loi, dans L^p). Soit (X_n) et X .

- $X_n \rightarrow X$ **presque sûrement** (p.s.) si $\mathbb{P}(\{\omega : X_n(\omega) \rightarrow X(\omega)\}) = 1$.
- $X_n \rightarrow X$ **en probabilité** si $\forall \varepsilon > 0, \mathbb{P}(|X_n - X| > \varepsilon) \rightarrow 0$.
- $X_n \rightarrow X$ **en loi** si $\mathbb{E}[\varphi(X_n)] \rightarrow \mathbb{E}[\varphi(X)]$ pour toute fonction continue bornée φ .
- $X_n \rightarrow X$ dans L^p ($p \geq 1$) si $\mathbb{E}[|X_n - X|^p] \rightarrow 0$.

Résultats (implications & contre-exemples)

Proposition 6.1 (Chaîne d'implications). Pour $p \geq 1$:

$$X_n \rightarrow X \text{ dans } L^p \Rightarrow X_n \rightarrow X \text{ en probabilité} \Rightarrow X_n \rightarrow X \text{ en loi}.$$

De plus, $X_n \rightarrow X$ p.s. $\Rightarrow X_n \rightarrow X$ en probabilité.

Proof. Si $X_n \rightarrow X$ dans L^p , Markov sur $|X_n - X|^p$ donne $\mathbb{P}(|X_n - X| > \varepsilon) \leq \mathbb{E}[|X_n - X|^p]/\varepsilon^p \rightarrow 0$. Si $X_n \rightarrow X$ p.s., alors $\mathbf{1}_{\{|X_n - X| > \varepsilon\}} \rightarrow 0$ p.s. et est dominée par 1, donc $\mathbb{P}(|X_n - X| > \varepsilon) = \mathbb{E}[\mathbf{1}_{\{|X_n - X| > \varepsilon\}}] \rightarrow 0$ par DCT (6.9). Enfin, la convergence en probabilité implique la convergence en loi (6.2). $\square$

Théorème 6.1 (Théorème d'application continue). Si $X_n \xrightarrow{\mathcal{L}} X$ et si $g : \mathbb{R} \rightarrow \mathbb{R}$ est continue, alors $g(X_n) \xrightarrow{\mathcal{L}} g(X)$.

Proof. Pour toute fonction continue bornée φ , la composée $\varphi \circ g$ est continue bornée. Donc $\mathbb{E}[\varphi(g(X_n))] \rightarrow \mathbb{E}[\varphi(g(X))]$ par définition de la convergence en loi. $\square$

Proposition 6.2 (Convergence en probabilité $\Rightarrow$ convergence en loi). Si $X_n \xrightarrow{\mathbb{P}} X$, alors $X_n \xrightarrow{\mathcal{L}} X$.

Proof. Soit φ continue bornée. Comme $X_n \rightarrow X$ en probabilité, on a $\varphi(X_n) \rightarrow \varphi(X)$ en probabilité.

Étape clé : extraire une sous-suite p.s. Pour $k \geq 1$, choisir n_k tel que $\mathbb{P}(|\varphi(X_{n_k}) - \varphi(X)| > 1/k) \leq 2^{-k}$. Alors $\sum_k \mathbb{P}(|\varphi(X_{n_k}) - \varphi(X)| > 1/k) < \infty$ et Borel–Cantelli 1 (6.11) donne $|\varphi(X_{n_k}) - \varphi(X)| \rightarrow 0$ p.s.

Conclure sur les espérances. Comme φ est bornée, DCT (6.9) donne $\mathbb{E}[\varphi(X_{n_k})] \rightarrow \mathbb{E}[\varphi(X)]$. Comme toute sous-suite admet une sous-sous-suite dont les espérances convergent vers $\mathbb{E}[\varphi(X)]$, la suite entière $\mathbb{E}[\varphi(X_n)]$ converge vers $\mathbb{E}[\varphi(X)]$. C'est exactement $X_n \xrightarrow{\mathcal{L}} X$. $\square$

Exemple 6.1 (En loi mais pas en probabilité). Si $X_n \sim \mathcal{N}(0, 1)$ i.i.d., alors X_n converge en loi vers $\mathcal{N}(0, 1)$, mais ne converge pas en probabilité vers une constante : $\mathbb{P}(|X_n| > 1) = \mathbb{P}(|X_1| > 1)$ ne tend pas vers 0.

Exemple 6.2 (En probabilité mais pas p.s. (Borel–Cantelli)). Sur un espace supportant des événements indépendants (A_n) avec $\mathbb{P}(A_n) = 1/n$, poser $X_n = \mathbf{1}_{A_n}$. Alors $\mathbb{P}(|X_n - 0| > \varepsilon) = \mathbb{P}(A_n) = 1/n \rightarrow 0$, donc $X_n \rightarrow 0$ en probabilité. Mais $\sum_n \mathbb{P}(A_n) = \infty$ et l'indépendance implique $\mathbb{P}(A_n \text{ i.o.}) = 1$: pas de convergence p.s.

Outils de contrôle (preuves courtes)

Proposition 6.3 (Inégalité de Markov). Si $X \geq 0$ et $a > 0$, alors $\mathbb{P}(X \geq a) \leq \mathbb{E}[X]/a$.

Proof. $X \geq a \mathbf{1}_{\{X \geq a\}}$, donc $\mathbb{E}[X] \geq a\mathbb{P}(X \geq a)$. $\square$

Proposition 6.4 (Inégalité de Tchebychev). Si $X \in L^2$ et $a > 0$, alors $\mathbb{P}(|X - \mathbb{E}[X]| \geq a) \leq \text{Var}(X)/a^2$.

Proof. Appliquer Markov à $(X - \mathbb{E}[X])^2$. $\square$

Théorème 6.2 (Jensen). Si φ est convexe et X intégrable, alors $\varphi(\mathbb{E}[X]) \leq \mathbb{E}[\varphi(X)]$.

Proof. Il existe une droite support $x \mapsto ax + b$ telle que $\varphi(x) \geq ax + b$ et égalité en $x = \mathbb{E}[X]$. Donc $\varphi(\mathbb{E}[X]) = a\mathbb{E}[X] + b \leq \mathbb{E}[aX + b] \leq \mathbb{E}[\varphi(X)]$. $\square$

Théorème 6.3 (Hölder). Si $p, q > 1$ et $1/p + 1/q = 1$, alors pour $X \in L^p$ et $Y \in L^q$,

$$\mathbb{E}[|XY|] \leq \|X\|_p \|Y\|_q.$$

Proof. Young : $uv \leq u^p/p + v^q/q$ pour $u, v \geq 0$. Appliquer à $u = |X|/\|X\|_p$ et $v = |Y|/\|Y\|_q$, puis prendre l'espérance. $\square$

Théorème 6.4 (Minkowski). Pour $p \geq 1$, $\|X + Y\|_p \leq \|X\|_p + \|Y\|_p$.

Proof. Pour $p > 1$, écrire $|X + Y|^p = |X + Y| |X + Y|^{p-1}$ et appliquer Hölder avec $q = p/(p-1)$, puis diviser par $\mathbb{E}[|X + Y|^p]^{(p-1)/p}$. Le cas $p = 1$ est immédiat. $\square$

Concentration non-asymptotique (MGF, sub-gaussien, Hoeffding, Bernstein)

Intuition. On veut des bornes *non asymptotiques* : pour n fixé, contrôler $\mathbb{P}(\bar{X}_n - \mathbb{E}[X] \geq \varepsilon)$. La recette typique est : Markov sur e^{tS} (méthode de Chernoff) + indépendance (factorisation de la MGF) + optimisation en t .

Définition 6.2 (Variable sub-gaussienne). Une variable X est **sub-gaussienne** de paramètre σ^2 si

$$\forall t \in \mathbb{R}, \quad \mathbb{E}[\exp(t(X - \mathbb{E}[X]))] \leq \exp\left(\frac{\sigma^2 t^2}{2}\right).$$

Proposition 6.5 (Sub-gaussien $\Rightarrow$ borne de queue). Si X est sub-gaussienne de paramètre σ^2 , alors pour tout $x > 0$,

$$\mathbb{P}(X - \mathbb{E}[X] \geq x) \leq \exp\left(-\frac{x^2}{2\sigma^2}\right), \quad \mathbb{P}(|X - \mathbb{E}[X]| \geq x) \leq 2 \exp\left(-\frac{x^2}{2\sigma^2}\right).$$

Proof. Pour $t > 0$, Markov donne $\mathbb{P}(X - \mathbb{E}[X] \geq x) = \mathbb{P}(e^{t(X - \mathbb{E}[X])} \geq e^{tx}) \leq e^{-tx} \mathbb{E}[e^{t(X - \mathbb{E}[X])}]$. Par sub-gaussianité, c'est $\leq \exp(-tx + \sigma^2 t^2/2)$. Optimiser en t (minimum en $t = x/\sigma^2$) donne la borne unilatérale. La borne bilatérale vient de l'union $\{|X - \mathbb{E}[X]| \geq x\} \subseteq \{X - \mathbb{E}[X] \geq x\} \cup \{X - \mathbb{E}[X] \leq -x\}$. $\square$

Lemme 6.1 (Lemme de Hoeffding). *Si $X \in [a, b]$ p.s., alors $X - \mathbb{E}[X]$ est sub-gaussienne et, pour tout $t \in \mathbb{R}$,*

$$\mathbb{E}[e^{t(X - \mathbb{E}[X])}] \leq \exp\left(\frac{t^2(b - a)^2}{8}\right).$$

Proof. Poser $m = \mathbb{E}[X]$, $M(t) = \mathbb{E}[e^{t(X - m)}]$ et $\psi(t) = \log M(t)$. On calcule $M'(t) = \mathbb{E}[(X - m)e^{t(X - m)}]$ et donc

$$\psi'(t) = \frac{M'(t)}{M(t)} = \mathbb{E}_t[X - m],$$

où $\mathbb{E}_t$ est l'espérance sous la mesure inclinée de densité proportionnelle à $e^{t(X - m)}$. De même,

$$\psi''(t) = \text{Var}_t(X) \leq \frac{(b - a)^2}{4},$$

car sous toute mesure supportée sur $[a, b]$, on a $\text{Var}(X) \leq \mathbb{E}[(X - \frac{a+b}{2})^2] \leq ((b - a)/2)^2$. Comme $\psi(0) = \psi'(0) = 0$, on intègre deux fois : pour $t \geq 0$, $\psi(t) = \int_0^t (t - s)\psi''(s) ds \leq t^2(b - a)^2/8$ (et idem pour $t \leq 0$ par symétrie). Exponentier donne le résultat. $\square$

Théorème 6.5 (Inégalité de Hoeffding). *Soient $X_1, \dots, X_n$ indépendantes avec $X_i \in [a_i, b_i]$ p.s. Alors, pour $S_n = \sum_{i=1}^n (X_i - \mathbb{E}[X_i])$ et tout $x > 0$,*

$$\mathbb{P}(S_n \geq x) \leq \exp\left(-\frac{2x^2}{\sum_{i=1}^n (b_i - a_i)^2}\right).$$

Proof. Pour $t > 0$, Markov donne $\mathbb{P}(S_n \geq x) \leq e^{-tx} \mathbb{E}[e^{tS_n}]$. Par indépendance, $\mathbb{E}[e^{tS_n}] = \prod_i \mathbb{E}[e^{t(X_i - \mathbb{E}[X_i])}]$. Par Hoeffding (6.1), chaque facteur est $\leq \exp(t^2(b_i - a_i)^2/8)$, donc

$$\mathbb{P}(S_n \geq x) \leq \exp\left(-tx + \frac{t^2}{8} \sum_{i=1}^n (b_i - a_i)^2\right).$$

Optimiser en t (min en $t = 4x/\sum_i (b_i - a_i)^2$) donne le résultat. $\square$

Lemme 6.2 (Lemme de Bernstein (MGF pour variables bornées)). *Si X est centrée, $\mathbb{E}[X] = 0$, et $|X| \leq b$ p.s., alors pour tout $t \in (0, 3/b)$,*

$$\log \mathbb{E}[e^{tX}] \leq \frac{t^2 \mathbb{E}[X^2]}{2(1 - tb/3)}.$$

Proof. Pour $u \in \mathbb{R}$ avec $|u| < 3$, on a $e^u = 1 + u + \sum_{k \geq 2} u^k/k! \leq 1 + u + \sum_{k \geq 2} |u|^k/k!$. Or pour $k \geq 2$, $k! = 2 \cdot 3 \cdot 4 \cdots k \geq 2 \cdot 3^{k-2}$, donc

$$\sum_{k \geq 2} \frac{|u|^k}{k!} \leq \sum_{k \geq 2} \frac{|u|^k}{2 \cdot 3^{k-2}} = \frac{u^2}{2} \sum_{j \geq 0} \left(\frac{|u|}{3}\right)^j = \frac{u^2}{2(1 - |u|/3)}.$$

Avec $u = tX$ et $tb < 3$, on obtient $e^{tX} \leq 1 + tX + \frac{t^2 X^2}{2(1 - tb/3)}$. Prendre l'espérance et utiliser $\mathbb{E}[X] = 0$ donne $\mathbb{E}[e^{tX}] \leq 1 + \frac{t^2 \mathbb{E}[X^2]}{2(1 - tb/3)}$. Enfin $\log(1 + v) \leq v$ conclut. $\square$

Théorème 6.6 (Inégalité de Bernstein (variables bornées)). Soient $X_1, \dots, X_n$ indépendantes, centrées, avec $|X_i| \leq b$ p.s. Poser $V = \sum_{i=1}^n \mathbb{E}[X_i^2]$ et $S_n = \sum_{i=1}^n X_i$. Alors pour tout $x > 0$,

$$\mathbb{P}(S_n \geq x) \leq \exp\left(-\frac{x^2}{2(V + bx/3)}\right).$$

Proof. Pour $t \in (0, 3/b)$, Markov donne $\mathbb{P}(S_n \geq x) \leq e^{-tx} \mathbb{E}[e^{tS_n}]$. Par indépendance et 6.2,

$$\log \mathbb{E}[e^{tS_n}] = \sum_{i=1}^n \log \mathbb{E}[e^{tX_i}] \leq \frac{t^2}{2(1 - tb/3)} \sum_{i=1}^n \mathbb{E}[X_i^2] = \frac{t^2 V}{2(1 - tb/3)}.$$

Donc $\mathbb{P}(S_n \geq x) \leq \exp\left(-tx + \frac{t^2 V}{2(1 - tb/3)}\right)$. Prendre $t = \frac{x}{V + bx/3}$ (qui vérifie $tb/3 < 1$) donne la borne annoncée. $\square$

Théorèmes d'échange (MCT/DCT) et « quand ça casse »

Théorème 6.7 (Fatou). Si $X_n \geq 0$, alors $\mathbb{E}[\liminf_n X_n] \leq \liminf_n \mathbb{E}[X_n]$.

Proof. Poser $Y_k = \inf_{n \geq k} X_n$; alors $Y_k \uparrow \liminf_n X_n$. Par convergence monotone (6.8), $\mathbb{E}[Y_k] \uparrow \mathbb{E}[\liminf_n X_n]$ et comme $Y_k \leq X_n$ pour $n \geq k$, $\mathbb{E}[Y_k] \leq \inf_{n \geq k} \mathbb{E}[X_n]$; passer à la limite donne Fatou. $\square$

Théorème 6.8 (Convergence monotone (MCT)). Si $0 \leq X_n \uparrow X$ p.s., alors $\mathbb{E}[X_n] \uparrow \mathbb{E}[X]$ (éventuellement $+\infty$).

Proof. Appliquer Fatou à X_n et à $X - X_n \geq 0$. On obtient $\mathbb{E}[X] \leq \liminf_n \mathbb{E}[X_n]$ et $\limsup_n \mathbb{E}[X_n] \leq \mathbb{E}[X]$. $\square$

Théorème 6.9 (Convergence dominée (DCT)). Si $X_n \rightarrow X$ p.s. et s'il existe $Y \in L^1$ tel que $|X_n| \leq Y$ p.s. pour tout n , alors $X \in L^1$ et $\mathbb{E}[X_n] \rightarrow \mathbb{E}[X]$.

Proof. Par domination, $|X| \leq Y$ donc $X \in L^1$. Appliquer Fatou à $Y \pm X_n \geq 0$ et utiliser la linéarité de l'espérance. $\square$

Exemple 6.3 (DCT ne s'applique pas : domination absente). Sur $[0, 1]$ avec Lebesgue, poser $X_n = n \mathbf{1}_{[0, 1/n]}$. Alors $X_n \rightarrow 0$ p.s., mais $\mathbb{E}[X_n] = 1$ pour tout n .

Uniforme intégrabilité (Vitali) : au-delà de DCT

Définition 6.3 (Uniforme intégrabilité). Une famille $(X_n) \subset L^1$ est **uniformément intégrable** (UI) si

$$\lim_{K \rightarrow \infty} \sup_n \mathbb{E}[|X_n| \mathbf{1}_{\{|X_n| > K\}}] = 0.$$

Proposition 6.6 (Domination $\Rightarrow$ UI). Si $|X_n| \leq Y$ p.s. pour un $Y \in L^1$, alors (X_n) est UI.

Proof. Pour tout K , $|X_n| \mathbf{1}_{\{|X_n| > K\}} \leq Y \mathbf{1}_{\{Y > K\}}$. Donc $\sup_n \mathbb{E}[|X_n| \mathbf{1}_{\{|X_n| > K\}}] \leq \mathbb{E}[Y \mathbf{1}_{\{Y > K\}}] \rightarrow 0$ par DCT. $\square$

Proposition 6.7 (Borne $L^{1+\varepsilon} \Rightarrow$ UI). S'il existe $\varepsilon > 0$ tel que $\sup_n \mathbb{E}[|X_n|^{1+\varepsilon}] < \infty$, alors (X_n) est UI.

Proof. Pour $K > 0$, $|X_n| \mathbf{1}_{\{|X_n| > K\}} \leq |X_n|^{1+\varepsilon} / K^\varepsilon$. Donc $\mathbb{E}[|X_n| \mathbf{1}_{\{|X_n| > K\}}] \leq \mathbb{E}[|X_n|^{1+\varepsilon}] / K^\varepsilon$, et le membre de droite tend vers 0 uniformément en n . $\square$

Théorème 6.10 (Vitali : UI + proba $\Rightarrow L^1$). Si (X_n) est UI et si $X_n \xrightarrow{\mathbb{P}} X$, alors $X \in L^1$ et

$$\mathbb{E}[|X_n - X|] \longrightarrow 0.$$

En particulier, $\mathbb{E}[X_n] \rightarrow \mathbb{E}[X]$.

Preuve guidée. Fixer $K > 0$ et poser $T_K(x) = \text{sign}(x) \min(|x|, K)$ (troncature). Alors

$$|X_n - X| \leq |T_K(X_n) - T_K(X)| + |X_n| \mathbf{1}_{\{|X_n| > K\}} + |X| \mathbf{1}_{\{|X| > K\}}.$$

Prendre l'espérance :

$$\mathbb{E}[|X_n - X|] \leq \mathbb{E}[|T_K(X_n) - T_K(X)|] + \mathbb{E}[|X_n| \mathbf{1}_{\{|X_n| > K\}}] + \mathbb{E}[|X| \mathbf{1}_{\{|X| > K\}}].$$

Le premier terme tend vers 0 quand $n \rightarrow \infty$ car $T_K(X_n) - T_K(X) \rightarrow 0$ en probabilité et est borné par $2K$ (même argument de sous-suite p.s. que dans 6.2, puis DCT).

Pour contrôler le dernier terme, extraire une sous-suite $X_{n_j} \rightarrow X$ p.s. (possible car $X_n \rightarrow X$ en probabilité). Par Fatou,

$$\mathbb{E}[|X| \mathbf{1}_{\{|X| > K\}}] \leq \liminf_{j \rightarrow \infty} \mathbb{E}[|X_{n_j}| \mathbf{1}_{\{|X_{n_j}| > K\}}] \leq \sup_n \mathbb{E}[|X_n| \mathbf{1}_{\{|X_n| > K\}}].$$

Comme (X_n) est UI, choisir K grand pour rendre les deux termes de queue $\leq \varepsilon$. Puis choisir n grand pour rendre le premier terme $\leq \varepsilon$. On obtient $\mathbb{E}[|X_n - X|] \leq 3\varepsilon$ pour n assez grand, donc convergence dans L^1 . $\square$

Dans la pratique. DCT est un cas particulier : domination $\Rightarrow$ UI (6.6), et convergence p.s. $\Rightarrow$ en probabilité. En entretien, UI est le bon mot-clef quand on veut échanger limite/espérance sans domination uniforme.

Borel–Cantelli, LLN, CLT, Slutsky, delta method

Théorème 6.11 (Borel–Cantelli 1). Si $\sum_n \mathbb{P}(A_n) < \infty$, alors $\mathbb{P}(A_n \text{ i.o.}) = 0$.

Proof. Pour N fixé, $\mathbb{P}(\cup_{n \geq N} A_n) \leq \sum_{n \geq N} \mathbb{P}(A_n) \rightarrow 0$. Comme $\{A_n \text{ i.o.}\} = \cap_N \cup_{n \geq N} A_n$, la continuité décroissante donne 0. $\square$

Théorème 6.12 (Borel–Cantelli 2 (version indépendante)). Si (A_n) sont indépendants et $\sum_n \mathbb{P}(A_n) = \infty$, alors $\mathbb{P}(A_n \text{ i.o.}) = 1$.

Proof. Par indépendance, $\mathbb{P}(\cap_{n \geq N} A_n^c) = \prod_{n \geq N} (1 - \mathbb{P}(A_n))$. Or $\log(1 - x) \leq -x$, donc le produit tend vers 0 ; conclure comme ci-dessus. $\square$

Théorème 6.13 (Loi faible des grands nombres (WLLN)). Si (X_i) sont i.i.d., $\mathbb{E}[X_1] = m$ et $\text{Var}(X_1) < \infty$, alors

$$\bar{X}_n := \frac{1}{n} \sum_{i=1}^n X_i \xrightarrow[n \rightarrow \infty]{\mathbb{P}} m.$$

Proof. $\text{Var}(\bar{X}_n) = \text{Var}(X_1)/n$ et Tchebychev donne la convergence en probabilité. $\square$

Théorème 6.14 (Loi forte des grands nombres (SLLN, version variance finie)). Si (X_i) sont i.i.d., $\mathbb{E}[X_1] = m$ et $\text{Var}(X_1) < \infty$, alors

$$\bar{X}_n \xrightarrow[n \rightarrow \infty]{p.s.} m.$$

Preuve guidée (niveau entretien). Poser $S_n = \sum_{i=1}^n (X_i - m)$. **(1) Dyadiques.** Par Tchebychev,

$$\mathbb{P}\left(\left|\frac{S_{2^k}}{2^k}\right| > \varepsilon\right) \leq \frac{\text{Var}(S_{2^k})}{\varepsilon^2 2^{2k}} = \frac{2^k \text{Var}(X_1)}{\varepsilon^2 4^k} = \frac{\text{Var}(X_1)}{\varepsilon^2 2^k}.$$

La série en k converge, donc par Borel–Cantelli 1 (6.11) on a $S_{2^k}/2^k \rightarrow 0$ p.s.

(2) Entre dyadiques. Pour passer de 2^k à tout n , on contrôle les oscillations $\max_{2^k \leq j \leq 2^{k+1}} |S_j - S_{2^k}|$ via une inégalité maximale (type Kolmogorov/Doob). L'idée est que $(S_{2^k+j} - S_{2^k})_{0 \leq j \leq 2^k}$ est une martingale (différences indépendantes), donc

$$\mathbb{P}\left(\max_{2^k \leq j \leq 2^{k+1}} \frac{|S_j|}{j} > \varepsilon\right)$$

est sommable en k , ce qui permet une seconde application de Borel–Cantelli. On conclut que $S_n/n \rightarrow 0$ p.s., donc $\bar{X}_n \rightarrow m$ p.s. $\square$

Théorème 6.15 (Théorème central limite (Lindeberg–Lévy)). *Si (X_i) sont i.i.d. avec $\mathbb{E}[X_1] = m$ et $\text{Var}(X_1) = \sigma^2 \in (0, \infty)$, alors*

$$\frac{\sqrt{n}(\bar{X}_n - m)}{\sigma} \xrightarrow[n \rightarrow \infty]{\mathcal{L}} \mathcal{N}(0, 1).$$

Preuve guidée (fonction caractéristique). Poser $Z_i = (X_i - m)/\sigma$ et $S_n = \frac{1}{\sqrt{n}} \sum_{i=1}^n Z_i$. Noter $\varphi(t) = \mathbb{E}[e^{itZ_1}]$. Le fait que $\mathbb{E}[Z_1] = 0$ et $\mathbb{E}[Z_1^2] = 1$ implique $\varphi(t) = 1 - \frac{1}{2}t^2 + o(t^2)$ quand $t \rightarrow 0$ (développement de e^{itZ_1} et contrôle via $\mathbb{E}[Z_1^2]$). Alors $\varphi_{S_n}(t) = \varphi(t/\sqrt{n})^n \rightarrow e^{-t^2/2}$, donc $S_n \Rightarrow \mathcal{N}(0, 1)$. $\square$

Théorème 6.16 (Slutsky). *Si $X_n \xrightarrow{\mathcal{L}} X$ et $Y_n \xrightarrow{\mathbb{P}} c$, alors $X_n + Y_n \xrightarrow{\mathcal{L}} X + c$ et $X_n Y_n \xrightarrow{\mathcal{L}} cX$.*

Preuve (guidée). On montre d'abord la convergence jointe $(X_n, Y_n) \xrightarrow{\mathcal{L}} (X, c)$. Soit $\varphi : \mathbb{R}^2 \rightarrow \mathbb{R}$ continue bornée et posons $M_\varphi = \sup_{(x,y)} |\varphi(x, y)| < \infty$. On décompose

$$\mathbb{E}[\varphi(X_n, Y_n)] - \mathbb{E}[\varphi(X, c)] = \underbrace{\mathbb{E}[\varphi(X_n, Y_n) - \varphi(X_n, c)]}_{(*)} + \underbrace{\mathbb{E}[\varphi(X_n, c)] - \mathbb{E}[\varphi(X, c)]}_{(**)}.$$

Le terme $(**)$ $\rightarrow 0$ car $x \mapsto \varphi(x, c)$ est continue bornée et $X_n \Rightarrow X$.

Pour $(*)$, on utilise que (X_n) est *tendue* : comme $X_n \Rightarrow X$, pour tout $\varepsilon > 0$ on peut choisir M tel que $\sup_n \mathbb{P}(|X_n| > M) \leq \varepsilon$ (prendre M grand pour X , puis ajuster pour un nombre fini de n). Sur le compact $[-M, M] \times [c-1, c+1]$, φ est uniformément continue, donc il existe $\delta > 0$ tel que

$$|x| \leq M, |y - c| \leq \delta \Rightarrow |\varphi(x, y) - \varphi(x, c)| \leq \varepsilon.$$

Alors

$$|\varphi(X_n, Y_n) - \varphi(X_n, c)| \leq \varepsilon + 2M_\varphi \mathbf{1}_{\{|X_n| > M\} \cup \{|Y_n - c| > \delta\}}.$$

En prenant l'espérance :

$$|(*)| \leq \varepsilon + 2M_\varphi (\mathbb{P}(|X_n| > M) + \mathbb{P}(|Y_n - c| > \delta)) \xrightarrow[n \rightarrow \infty]{} \varepsilon + 2M_\varphi \varepsilon,$$

puis $\varepsilon \downarrow 0$ donne $(*) \rightarrow 0$. Donc $\mathbb{E}[\varphi(X_n, Y_n)] \rightarrow \mathbb{E}[\varphi(X, c)]$: convergence jointe.

Enfin, appliquer le théorème d'application continue (6.1) aux fonctions continues $g_1(x, y) = x + y$ et $g_2(x, y) = xy$ donne les deux convergences annoncées. $\square$

Théorème 6.17 (Delta method (version scalaire)). *Si $\sqrt{n}(\theta_n - \theta) \xrightarrow{\mathcal{L}} \mathcal{N}(0, \sigma^2)$ et si g est dérivable en θ , alors*

$$\sqrt{n}(g(\theta_n) - g(\theta)) \xrightarrow{\mathcal{L}} \mathcal{N}(0, (g'(\theta))^2 \sigma^2).$$

Proof. Taylor : $g(\theta_n) = g(\theta) + g'(\theta)(\theta_n - \theta) + o(\theta_n - \theta)$. Multiplier par $\sqrt{n}$ et conclure par Slutsky (6.16). $\square$

Sanity checks

Sanity check. CLT : la normalisation est $\sqrt{n}$; une variance limite qui dépend de n signale une erreur d'échelle.

Sanity check. DCT/MCT : si tu veux passer la limite dans une espérance, identifie explicitement domination intégrable (DCT) ou monotonie + positivité (MCT). Sinon, cherche un contre-exemple « pic qui se resserre ».

Sanity check. Non-asymptotique vs asymptotique : Hoeffding/Bernstein (6.5–6.6) donnent des bornes valables pour n fini ; CLT donne une approximation de loi quand $n \rightarrow \infty$. En entretien, dire quel régime tu utilises.

Blocs Q/R d'entretien déplacés en annexe (voir Annexe Q/R).

Mini-synthèse

- $L^p \Rightarrow$ proba $\Rightarrow$ loi ; p.s. $\Rightarrow$ proba.
- Markov/Tchebychev/Jensen : bornes via moments.
- Hölder/Minkowski : structure des normes L^p .
- Concentration : Chernoff + (sub-gaussien, Hoeffding, Bernstein) pour des bornes non-asymptotiques.
- Fatou/MCT/DCT : outils *justifiant* les échanges limite/espérance.
- Uniforme intégrabilité (Vitali) : échanger limite/espérance sans dominateur commun.
- LLN/CLT + Slutsky/delta : outillage asymptotique interview.

7 Espaces L^p et Hilbert L^2 : projection, régression, Kalman

Intuition

Les espaces L^p mesurent des tailles d'erreur : L^1 pour l'erreur moyenne absolue, L^2 pour l'erreur quadratique. En entretien, L^2 est central car il donne un langage géométrique : produit scalaire, projection orthogonale, donc une interprétation propre de l'espérance conditionnelle comme « meilleure prédiction ».

Définitions

Définition 7.1 (L^p). Pour $p \geq 1$, on note $L^p(\Omega, \mathcal{F}, \mathbb{P})$ l'ensemble des classes de v.a. (égales p.s.) telles que $\mathbb{E}[|X|^p] < \infty$. La norme est $\|X\|_p = \mathbb{E}[|X|^p]^{1/p}$.

Définition 7.2 (Espace de Hilbert L^2). L^2 est muni du produit scalaire

$$\langle X, Y \rangle := \mathbb{E}[XY], \quad \|X\|_2 = \sqrt{\langle X, X \rangle}.$$

Définition 7.3 (Sous-espace $L^2(\mathcal{G})$). On note $L^2(\mathcal{G})$ l'ensemble des v.a. $Z \in L^2$ qui sont $\mathcal{G}$ -mesurables. C'est un sous-espace vectoriel de L^2 (et il est fermé).

Résultats (avec preuves)

Théorème 7.1 (Théorème de projection orthogonale). *Soit $(\mathcal{H}, \langle \cdot, \cdot \rangle)$ un espace de Hilbert et $V \subseteq \mathcal{H}$ un sous-espace fermé. Alors pour tout $x \in \mathcal{H}$, il existe un unique $\Pi_V(x) \in V$ tel que*

$$\|x - \Pi_V(x)\| = \inf_{v \in V} \|x - v\|,$$

et $x - \Pi_V(x) \perp V$.

Preuve (guidée mais complète). Existence. Soit $d = \inf_{v \in V} \|x - v\|$. Choisir $(v_n) \subset V$ telle que $\|x - v_n\| \downarrow d$. L'identité du parallélogramme donne

$$\|v_n - v_m\|^2 = 2\|x - v_n\|^2 + 2\|x - v_m\|^2 - 4\|x - \frac{v_n + v_m}{2}\|^2.$$

Comme $\frac{v_n + v_m}{2} \in V$, on a $\|x - \frac{v_n + v_m}{2}\| \geq d$, donc $\|v_n - v_m\| \rightarrow 0$: (v_n) est Cauchy et converge vers $v^* \in V$ (fermeture). Par continuité, $\|x - v^*\| = d$.

Orthogonalité. Pour $v \in V$, la fonction $\phi(t) = \|x - (v^* + tv)\|^2$ est minimale en 0. En développant, $\phi'(0) = -2\langle x - v^*, v \rangle = 0$, donc orthogonalité.

Unicité. Si v^*, w^* minimisent, alors $x - v^* \perp V$ et $x - w^* \perp V$. Donc $\|v^* - w^*\|^2 = \langle v^* - w^*, v^* - w^* \rangle = \langle x - w^* - (x - v^*), v^* - w^* \rangle = 0$. $\square$

Théorème 7.2 (Espérance conditionnelle = projection L^2). *Si $X \in L^2$ et $\mathcal{G} \subseteq \mathcal{F}$, alors $\mathbb{E}[X | \mathcal{G}]$ est la projection orthogonale de X sur $L^2(\mathcal{G})$:*

$$\mathbb{E}[X | \mathcal{G}] = \Pi_{L^2(\mathcal{G})}(X).$$

Proof. Soit $Y = \mathbb{E}[X | \mathcal{G}]$. Pour toute $Z \in L^2(\mathcal{G})$ bornée, la propriété caractéristique donne $\mathbb{E}[(X - Y)Z] = 0$. Par densité des bornées dans $L^2(\mathcal{G})$, on a $X - Y \perp L^2(\mathcal{G})$. Par unicité de la projection, $Y = \Pi_{L^2(\mathcal{G})}(X)$. $\square$

Lien direct avec régression linéaire et Kalman

Soient $X \in L^2$ et un vecteur $Y \in \mathbb{R}^d$ de variables dans L^2 . La meilleure approximation *linéaire* de X par Y est la projection sur $V = \{a^\top Y : a \in \mathbb{R}^d\} \subseteq L^2$. Les équations normales s'écrivent :

$$\mathbb{E}[(X - a^\top Y)Y] = 0 \quad \Leftrightarrow \quad \text{Cov}(Y)a = \text{Cov}(Y, X).$$

Si $\text{Cov}(Y)$ est inversible, $a^* = \text{Cov}(Y)^{-1} \text{Cov}(Y, X)$.

Kalman (lecture entretien). Dans un modèle linéaire-gaussien, les estimations du filtre de Kalman sont des projections L^2 successives sur l'information disponible. Les identités de Schur/Woodbury (§8) expliquent les mises à jour numériques stables.

Kalman : équations de mise à jour (forme covariance et information). On considère un prior $X \sim \mathcal{N}(m, P)$ et une observation

$$Y = HX + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, R) \text{ indépendante de } X.$$

Alors $X | (Y = y)$ est gaussienne et la mise à jour s'écrit avec

$$S := HPH^\top + R, \quad K := PH^\top S^{-1} \quad (\text{gain}).$$

La moyenne et la covariance a posteriori sont

$$m^+ = m + K(y - Hm), \quad P^+ = P - PH^\top S^{-1}HP.$$

Le terme $PH^\top S^{-1}HP$ est une forme quadratique qui vient d'un complément de Schur (conditionnelle gaussienne, §10).

Forme de Joseph (stabilité numérique). La covariance peut aussi s'écrire

$$P^+ = (I - KH)P(I - KH)^\top + K R K^\top,$$

ce qui rend la symétrie/PSD explicite (utile quand l'arithmétique flottante casse légèrement la symétrie). En effet, comme $K = PH^\top S^{-1}$ on a $KS = PH^\top$ donc $KSK^\top = PH^\top S^{-1}HP$ et l'expansion de Joseph redonne $P - PH^\top S^{-1}HP$.

Forme information (Woodbury). En inversant (utile si on maintient des précisions), Woodbury donne

$$(P^+)^{-1} = P^{-1} + H^\top R^{-1}H, \quad (P^+)^{-1}m^+ = P^{-1}m + H^\top R^{-1}y.$$

Sanity checks

Sanity check. Dans L^2 , « meilleure prédiction » signifie minimiser $\mathbb{E}[(X - Z)^2]$ parmi les Z $\mathcal{G}$ -mesurables. Ce n'est pas la même notion que minimiser $\mathbb{E}[|X - Z|]$ (où une médiane apparaît).

Sanity check. Régression : vérifier les dimensions de $\text{Cov}(Y)$ ($d \times d$) et de $\text{Cov}(Y, X)$ ($d \times 1$). Une inversion sur le mauvais objet est un piège classique.

Blocs Q/R d'entretien déplacés en annexe (voir Annexe Q/R).

Mini-synthèse

- L^p : classes modulo égalité p.s., norme $\|\cdot\|_p$.
- L^2 est un Hilbert : produit scalaire $\langle X, Y \rangle = \mathbb{E}[XY]$.
- Théorème de projection : existence/unicité sur tout sous-espace fermé.
- $\mathbb{E}[X \mid \mathcal{G}]$ = projection sur $L^2(\mathcal{G})$, donc minimisation MSE.
- Régression/Kalman : projection sur un sous-espace (linéaire) + identités matricielles.

8 Algèbre linéaire utile (PSD/PD, Cholesky, Schur, Woodbury)

Intuition

En quant, *presque tout* passe par des matrices : covariances, corrélations, régressions, PCA, Kalman, Markowitz. Le niveau entretien : savoir *quand* une matrice est inversible/Cholesky, manipuler des blocs (Schur), et reconnaître Woodbury (mise à jour de covariance) sans panique.

Définitions

Définition 8.1 (PSD/PD). Une matrice symétrique $A \in \mathbb{R}^{d \times d}$ est **semi-définie positive** (PSD) si $x^\top A x \geq 0$ pour tout $x \in \mathbb{R}^d$. Elle est **définie positive** (PD) si $x^\top A x > 0$ pour tout $x \neq 0$.

Définition 8.2 (Cholesky). Si A est PD, il existe une unique matrice triangulaire inférieure L à diagonale strictement positive telle que $A = LL^\top$ (décomposition de Cholesky).

Résultats (avec preuves courtes)

Proposition 8.1 (PSD/PD et valeurs propres). *Pour A symétrique, A est PSD (resp. PD) si et seulement si toutes ses valeurs propres sont ≥ 0 (resp. > 0).*

Proof. Diagonaliser $A = U\Lambda U^\top$ (U orthogonale) : $x^\top Ax = \sum_i \lambda_i y_i^2$ avec $y = U^\top x$. $\square$

Théorème 8.1 (Complément de Schur : positivité et inverse par blocs). *Soit*

$$M = \begin{pmatrix} A & B \\ B^\top & C \end{pmatrix},$$

avec $A \in \mathbb{R}^{p \times p}$ inversible. Le complément de Schur de A est $S := C - B^\top A^{-1} B$. Alors :

- M est PD $\Leftrightarrow A$ est PD et S est PD ;
- si A et S sont inversibles, alors

$$M^{-1} = \begin{pmatrix} A^{-1} + A^{-1} B S^{-1} B^\top A^{-1} & -A^{-1} B S^{-1} \\ -S^{-1} B^\top A^{-1} & S^{-1} \end{pmatrix}.$$

Proof. Factoriser

$$M = \begin{pmatrix} I & 0 \\ B^\top A^{-1} & I \end{pmatrix} \begin{pmatrix} A & 0 \\ 0 & S \end{pmatrix} \begin{pmatrix} I & A^{-1} B \\ 0 & I \end{pmatrix}.$$

La PD est préservée par congruence via des matrices inversibles triangulaires ; on obtient le critère. Pour l'inverse, inverser la factorisation et développer. $\square$

Théorème 8.2 (Woodbury (Sherman–Morrison–Woodbury)). *Si $A \in \mathbb{R}^{n \times n}$ est inversible, $U \in \mathbb{R}^{n \times k}$, $C \in \mathbb{R}^{k \times k}$ inversible, $V \in \mathbb{R}^{k \times n}$, et si $A + UCV$ est inversible, alors*

$$(A + UCV)^{-1} = A^{-1} - A^{-1} U (C^{-1} + V A^{-1} U)^{-1} V A^{-1}.$$

Proof. Appliquer 8.1 à la matrice par blocs $\begin{pmatrix} A & U \\ -V & C^{-1} \end{pmatrix}$ et identifier le complément de Schur. $\square$

Théorème 8.3 (Matrix determinant lemma). *Sous les hypothèses de 8.2,*

$$\det(A + UCV) = \det(A) \det(C) \det(C^{-1} + V A^{-1} U).$$

En particulier (rang 1), si $u \in \mathbb{R}^n$ et $v \in \mathbb{R}^n$, alors $\det(A + uv^\top) = \det(A)(1 + v^\top A^{-1} u)$.

Proof. Considérer la matrice par blocs $M = \begin{pmatrix} A & U \\ -V & C^{-1} \end{pmatrix}$. En appliquant la factorisation de Schur (8.1) au bloc A , on obtient $\det(M) = \det(A) \det(C^{-1} + V A^{-1} U)$. D'autre part, en appliquant la même factorisation au bloc C^{-1} , on obtient $\det(M) = \det(C^{-1}) \det(A + UCV)$. En identifiant et en multipliant par $\det(C)$, on obtient la formule. $\square$

Où ça sert (lecture entretien)

- **Conditionnelle gaussienne.** Le complément de Schur est la covariance conditionnelle (§10).
- **Kalman.** Woodbury donne la mise à jour « a priori + observation » sans inverser de grosses matrices.
- **Log-vraisemblance gaussienne.** det-lemma : mise à jour de log det pour des covariances « diagonale + faible rang » (factor models, Kalman).
- **Simulation gaussienne.** Cholesky : $X = m + LZ$ avec $Z \sim \mathcal{N}(0, I)$.

Sanity checks

Sanity check. Une covariance doit être PSD : $x^\top \Sigma x = \text{Var}(x^\top X) \geq 0$. Si tu obtiens une matrice non PSD, soit l'estimation est mauvaise, soit tu as un bug numérique (symétrisation/clipping).

Sanity check. Cholesky requiert PD, pas seulement PSD. Si Σ est singulière : jitter εI , shrinkage, ou factorisation par valeurs propres.

Blocs Q/R d'entretien déplacés en annexe (voir Annexe Q/R).

Mini-synthèse

- PSD/PD : test par valeurs propres ou formes quadratiques.
- Cholesky : $A = LL^\top$ si A PD ; simulation et résolution stable.
- Schur : PD et inversion par blocs ; covariance conditionnelle.
- Woodbury : inverse après mise à jour de faible rang ; cœur de Kalman.
- Determinant lemma : log det sous mise à jour de faible rang.
- Pratique : matrices mal conditionnées $\Rightarrow$ régulariser (shrinkage/jitter).

9 Gaussiennes : univariée (CF/MGF, Stein, queues)

Intuition

La normale est centrale pour trois raisons interview : (i) stabilité par somme (et CLT), (ii) calculs fermés (MGF/CF, conditionnement gaussien), (iii) bornes de queue propres (lecture sub-gaussienne).

Définitions

Définition 9.1 (Normale univariée). $X \sim \mathcal{N}(m, \sigma^2)$ si X admet la densité

$$f_X(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-m)^2}{2\sigma^2}\right).$$

Définition 9.2 (MGF et CF). La MGF est $M_X(t) = \mathbb{E}[e^{tX}]$ (quand elle existe autour de 0). La fonction caractéristique est $\varphi_X(t) = \mathbb{E}[e^{itX}]$ (toujours définie).

Résultats (avec preuves)

Proposition 9.1 (MGF/CF de la normale). Si $X \sim \mathcal{N}(m, \sigma^2)$, alors

$$M_X(t) = \exp\left(mt + \frac{1}{2}\sigma^2 t^2\right), \quad \varphi_X(t) = \exp\left(imt - \frac{1}{2}\sigma^2 t^2\right).$$

Proof. Calcul direct en complétant le carré :

$$\mathbb{E}[e^{tX}] = \int_{\mathbb{R}} e^{tx} \frac{1}{\sigma\sqrt{2\pi}} e^{-(x-m)^2/(2\sigma^2)} dx = e^{mt + \sigma^2 t^2/2} \int_{\mathbb{R}} \frac{1}{\sigma\sqrt{2\pi}} e^{-(x-(m+\sigma^2 t))^2/(2\sigma^2)} dx.$$

L'intégrale vaut 1. Remplacer t par it donne la CF. □

Proposition 9.2 (Somme de normales indépendantes). Si $X \sim \mathcal{N}(m_1, \sigma_1^2)$ et $Y \sim \mathcal{N}(m_2, \sigma_2^2)$ indépendantes, alors $X + Y \sim \mathcal{N}(m_1 + m_2, \sigma_1^2 + \sigma_2^2)$.

Proof. Sous indépendance, $M_{X+Y}(t) = M_X(t)M_Y(t)$ et on reconnaît une MGF gaussienne. $\square$

Théorème 9.1 (Lemme de Stein). *Si $X \sim \mathcal{N}(m, \sigma^2)$ et f est dérivable avec $\mathbb{E}[|f'(X)|] < \infty$ et $\mathbb{E}[|(X - m)f(X)|] < \infty$, alors*

$$\mathbb{E}[(X - m)f(X)] = \sigma^2 \mathbb{E}[f'(X)].$$

Proof. Par changement de variable, se ramener à $m = 0, \sigma = 1$. La densité est $\phi(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}$ et $\phi'(x) = -x\phi(x)$. Alors

$$\mathbb{E}[Xf(X)] = \int x f(x) \phi(x) dx = - \int f(x) \phi'(x) dx = \left[-f(x) \phi(x) \right]_{-\infty}^{+\infty} + \int f'(x) \phi(x) dx.$$

Les hypothèses assurent que le terme de bord est nul, donc $\mathbb{E}[Xf(X)] = \mathbb{E}[f'(X)]$. Remettre l'échelle donne le résultat. $\square$

Bornes de queue (lecture sub-gaussienne)

Si $Z \sim \mathcal{N}(0, 1)$, alors pour $x > 0$:

$$\mathbb{P}(Z \geq x) \leq \exp(-x^2/2)$$

par Chernoff : $\mathbb{P}(Z \geq x) = \mathbb{P}(e^{tZ} \geq e^{tx}) \leq e^{-tx} \mathbb{E}[e^{tZ}] = \exp(-tx + t^2/2)$, minimisée en $t = x$. Une asymptotique plus fine (Mills ratio) est

$$\mathbb{P}(Z \geq x) \sim \frac{1}{x\sqrt{2\pi}} e^{-x^2/2} \quad (x \rightarrow \infty).$$

Proposition 9.3 (Mills ratio : bornes explicites). *Pour $x > 0$, si $\phi(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}$ et $\bar{\Phi}(x) = \mathbb{P}(Z \geq x)$, alors*

$$\frac{x}{1+x^2} \phi(x) \leq \bar{\Phi}(x) \leq \frac{1}{x} \phi(x).$$

Proof. On a $\phi'(t) = -t\phi(t)$, donc par intégration par parties :

$$\bar{\Phi}(x) = \int_x^\infty \phi(t) dt = \int_x^\infty \frac{-\phi'(t)}{t} dt = \left[\frac{\phi(t)}{t} \right]_x^\infty - \int_x^\infty \frac{\phi(t)}{t^2} dt = \frac{\phi(x)}{x} - \int_x^\infty \frac{\phi(t)}{t^2} dt.$$

Comme le terme intégral est ≥ 0 , on obtient $\bar{\Phi}(x) \leq \phi(x)/x$. De plus, pour $t \geq x$ on a $1/t^2 \leq 1/x^2$, donc $\int_x^\infty \frac{\phi(t)}{t^2} dt \leq \frac{1}{x^2} \int_x^\infty \phi(t) dt = \bar{\Phi}(x)/x^2$. En réinjectant, $\bar{\Phi}(x) \geq \frac{\phi(x)}{x} - \frac{\bar{\Phi}(x)}{x^2}$, soit $(1 + 1/x^2)\bar{\Phi}(x) \geq \phi(x)/x$, donc $\bar{\Phi}(x) \geq \frac{x}{1+x^2} \phi(x)$. $\square$

Sanity checks

Sanity check. La MGF gaussienne existe pour tout $t \in \mathbb{R}$; pour des lois lourdes (Cauchy), la MGF n'existe pas. Ne pas utiliser une MGF sans vérifier qu'elle existe.

Sanity check. Stein : les hypothèses sont là pour tuer le terme de bord en intégration par parties. Dire « IBP » sans discuter ce terme est un piège.

Blocs Q/R d'entretien déplacés en annexe (voir Annexe Q/R).

Mini-synthèse

- MGF/CF gaussiennes : calcul par complétion du carré.
- Somme indépendante : stabilité via MGF.
- Stein : $\mathbb{E}[(X - m)f(X)] = \sigma^2 \mathbb{E}[f'(X)]$ (IBP).
- Bornes de queue : Chernoff, Mills ratio (bornes + asymptotique).
- Corrélation nulle $\nRightarrow$ indépendance en général.

10 Gaussiennes multivariées, conditionnement, PCA

Intuition

Le cas multivarié est le langage natif des covariances et des facteurs. Deux choses sont *must-have* en entretien : (i) la formule de la conditionnelle gaussienne (deux dérivations), (ii) PCA/whitening et les pièges de l'estimation de covariance.

Définitions

Définition 10.1 (Normale multivariée). Un vecteur $X \in \mathbb{R}^d$ suit une loi $\mathcal{N}(m, \Sigma)$ si sa densité est

$$f_X(x) = \frac{1}{(2\pi)^{d/2} \det(\Sigma)^{1/2}} \exp\left(-\frac{1}{2}(x - m)^\top \Sigma^{-1}(x - m)\right),$$

où Σ est symétrique PD.

Proposition 10.1 (Transformation linéaire). Si $X \sim \mathcal{N}(m, \Sigma)$ et A est une matrice, b un vecteur, alors $AX + b \sim \mathcal{N}(Am + b, A\Sigma A^\top)$.

Proof. Par fonction caractéristique : $\varphi_{AX+b}(t) = e^{it^\top b} \varphi_X(A^\top t)$ et on reconnaît une gaussienne. $\square$

Proposition 10.2 (Distance de Mahalanobis et χ^2). Si $X \sim \mathcal{N}(m, \Sigma)$ avec Σ PD, alors

$$Q := (X - m)^\top \Sigma^{-1}(X - m) \sim \chi_d^2.$$

Proof. Whitening : poser $Z = \Sigma^{-1/2}(X - m)$, alors $Z \sim \mathcal{N}(0, I_d)$. Donc $Q = \|Z\|_2^2 = \sum_{i=1}^d Z_i^2$ et, comme les Z_i sont indépendantes $\mathcal{N}(0, 1)$, la somme suit χ_d^2 . $\square$

Dans la pratique. Le terme quadratique $(x - m)^\top \Sigma^{-1}(x - m)$ et $\log \det(\Sigma)$ sont les deux objets qui apparaissent dans la log-vraisemblance gaussienne. En filtre de Kalman, le *résidu normalisé* (innovation) se contrôle souvent via un test χ^2 (« gating »).

Log-vraisemblance et estimation (niveau entretien)

Proposition 10.3 (Log-vraisemblance gaussienne (échantillon i.i.d.)). Soient $x_1, \dots, x_n \in \mathbb{R}^d$ i.i.d. selon $\mathcal{N}(m, \Sigma)$ avec Σ PD. Alors, à constante additive près,

$$\ell(m, \Sigma) = -\frac{n}{2} \log \det(\Sigma) - \frac{1}{2} \sum_{i=1}^n (x_i - m)^\top \Sigma^{-1}(x_i - m).$$

Proof. Écrire la densité gaussienne, prendre le produit puis le logarithme. $\square$

Proposition 10.4 (MLE gaussien : moyenne et covariance). Sous les hypothèses de 10.3, le MLE de m est $\hat{m} = \bar{x} := \frac{1}{n} \sum_{i=1}^n x_i$. Le MLE de Σ est

$$\hat{\Sigma}_{\text{MLE}} = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(x_i - \bar{x})^\top.$$

Preuve guidée. (1) Optimisation en m pour Σ fixé. Développer $\sum_i (x_i - m)^\top \Sigma^{-1} (x_i - m)$ et dériver en m : $\nabla_m \sum_i (x_i - m)^\top \Sigma^{-1} (x_i - m) = -2\Sigma^{-1} \sum_i (x_i - m)$. L'annulation donne $\sum_i (x_i - \hat{m}) = 0$, donc $\hat{m} = \bar{x}$.

(2) Optimisation en Σ via la précision $J = \Sigma^{-1}$. Poser $S = \sum_i (x_i - \bar{x})(x_i - \bar{x})^\top$. Alors, à constante près,

$$\ell(\bar{x}, \Sigma) = \frac{n}{2} \log \det(J) - \frac{1}{2} \text{tr}(JS).$$

On utilise les identités de calcul matriciel $\nabla_J \log \det(J) = J^{-1}$ et $\nabla_J \text{tr}(JS) = S$. L'annulation du gradient donne $(n/2)J^{-1} - (1/2)S = 0$, donc $J^{-1} = S/n$, i.e. $\hat{\Sigma}_{\text{MLE}} = S/n$. $\square$

Définition 10.2 (Wishart (définition opérationnelle)). Si $Z_1, \dots, Z_n$ sont i.i.d. $\mathcal{N}(0, \Sigma)$, la matrice

$$W := \sum_{i=1}^n Z_i Z_i^\top$$

est appelée **Wishart** de paramètres (Σ, n) . Elle est PSD et encode la statistique « somme de carrés » multivariée.

Proposition 10.5 (Moments et rang (covariance empirique)). Avec W comme ci-dessus, $\mathbb{E}[W] = n\Sigma$ et $\text{rank}(W) \leq \min(d, n)$ p.s. En particulier, si $n < d$, W (donc la covariance empirique) est singulière : pas de Cholesky.

Proof. Par linéarité, $\mathbb{E}[W] = \sum_i \mathbb{E}[Z_i Z_i^\top] = n \mathbb{E}[Z_1 Z_1^\top] = n\Sigma$. Le rang est au plus la somme des rangs : chaque $Z_i Z_i^\top$ est de rang ≤ 1 , donc $\text{rank}(W) \leq n$ (et aussi $\leq d$). $\square$

Piège. En gaussien, MLE de Σ utilise le facteur $1/n$ (pas $1/(n-1)$). Le facteur $1/(n-1)$ correspond à l'estimateur sans biais de la covariance, pas au maximiseur de vraisemblance.

Conditionnement : deux dérivations

Considérons la partition

$$\begin{pmatrix} X \\ Y \end{pmatrix} \sim \mathcal{N}\left(\begin{pmatrix} m_X \\ m_Y \end{pmatrix}, \begin{pmatrix} \Sigma_{XX} & \Sigma_{XY} \\ \Sigma_{YX} & \Sigma_{YY} \end{pmatrix}\right),$$

avec Σ_{YY} inversible.

Théorème 10.1 (Conditionnelle gaussienne). La loi de $X \mid Y = y$ est gaussienne :

$$X \mid (Y = y) \sim \mathcal{N}\left(m_X + \Sigma_{XY} \Sigma_{YY}^{-1} (y - m_Y), \Sigma_{XX} - \Sigma_{XY} \Sigma_{YY}^{-1} \Sigma_{YX}\right).$$

Dérivation 1 : complétion du carré (densité jointe). Écrire la densité jointe en exponentielle quadratique :

$$f_{X,Y}(x, y) \propto \exp\left(-\frac{1}{2} \begin{pmatrix} x - m_X \\ y - m_Y \end{pmatrix}^\top \Sigma^{-1} \begin{pmatrix} x - m_X \\ y - m_Y \end{pmatrix}\right).$$

Inverser Σ par blocs (8.1) : le bloc en haut à gauche de Σ^{-1} est $(\Sigma_{XX} - \Sigma_{XY} \Sigma_{YY}^{-1} \Sigma_{YX})^{-1}$. En regroupant les termes en x , on obtient une forme

$$(x - \mu(y))^\top \Sigma_{X|Y}^{-1} (x - \mu(y)) + (\text{terme indépendant de } x),$$

avec $\mu(y) = m_X + \Sigma_{XY} \Sigma_{YY}^{-1} (y - m_Y)$ et $\Sigma_{X|Y} = \Sigma_{XX} - \Sigma_{XY} \Sigma_{YY}^{-1} \Sigma_{YX}$. Donc la densité conditionnelle en x est gaussienne avec ces paramètres. $\square$

Dérivation 2 : projection L^2 + Schur. Dans un vecteur gaussien, le meilleur prédicteur L^2 de X par Y est linéaire. La projection linéaire (§7) donne

$$\mathbb{E}[X | Y] = m_X + A(Y - m_Y), \quad A = \Sigma_{XY} \Sigma_{YY}^{-1}.$$

La covariance du résidu vaut

$$\text{Cov}(X - \mathbb{E}[X | Y]) = \Sigma_{XX} - A \Sigma_{YX} = \Sigma_{XX} - \Sigma_{XY} \Sigma_{YY}^{-1} \Sigma_{YX},$$

qui est un complément de Schur, donc PSD. $\square$

Proposition 10.6 (Indépendance $\Leftrightarrow$ covariance nulle (cas gaussien)). *Si (X, Y) est gaussien (jointement), alors X et Y sont indépendants si et seulement si $\text{Cov}(X, Y) = 0$.*

Proof. Si indépendants, covariance nulle (général). Si $\text{Cov}(X, Y) = 0$, la covariance est bloc-diagonale, donc la fonction caractéristique du joint se factorise, donc indépendance. $\square$

PCA, whitening, cleaning (niveau interview)

Si Σ est une covariance PSD, on diagonalise $\Sigma = U \Lambda U^\top$ (valeurs propres décroissantes). La PCA consiste à projeter sur les premiers vecteurs propres : $Z = U^\top(X - m)$, et $\text{Cov}(Z) = \Lambda$.

Whitening. Poser $W = \Lambda^{-1/2} U^\top$ (sur les valeurs propres positives) : alors $W(X - m)$ est centré et a covariance I . En pratique, on clippe ou on tronque les petites valeurs propres (bruit).

Estimation de covariance : pièges et shrinkage. Quand d est du même ordre que n , la covariance empirique est mal conditionnée. Un remède interview-friendly : shrinkage $\hat{\Sigma}_\alpha = (1 - \alpha)\hat{\Sigma} + \alpha T$ (cible T diagonale ou factor model), avec α choisi pour stabiliser.

Sanity checks

Sanity check. La covariance conditionnelle $\Sigma_{X|Y} = \Sigma_{XX} - \Sigma_{XY} \Sigma_{YY}^{-1} \Sigma_{YX}$ doit être PSD. Une matrice non symétrique ou avec valeurs propres négatives (hors bruit numérique) signale une erreur d'algèbre.

Sanity check. PCA : les variances expliquées sont les valeurs propres. Une « PCA » avec valeurs propres négatives signale une covariance non PSD.

Blocs Q/R d'entretien déplacés en annexe (voir Annexe Q/R).

Mini-synthèse

- Gaussien multivarié : densité quadratique avec Σ PD.
- Mahalanobis : $(X - m)^\top \Sigma^{-1} (X - m) \sim \chi_d^2$ (whitening).
- Conditionnelle : moyenne affine et covariance = complément de Schur.
- Gaussien : indépendance $\Leftrightarrow$ covariance nulle.
- PCA : $\Sigma = U \Lambda U^\top$; modes de risque = vecteurs propres.
- Log-vraisemblance/MLE/Wishart : $\log \det(\Sigma) +$ forme quadratique ; rang singulier si $n < d$.
- Pratique : estimation covariance fragile $\Rightarrow$ shrinkage/clipping/low-rank.

11 Filtrations et martingales : langage de l'information

Intuition

Une filtration formalise « ce que je sais à chaque date ». Une martingale formalise « pas de drift prévisible » : la meilleure prédiction de demain, donnée l'information d'aujourd'hui, c'est aujourd'hui. En finance : *sous* $\mathbb{Q}$, les prix actualisés sont des martingales ; le pricing devient une espérance conditionnelle.

Définitions

Définition 11.1 (Filtration, adaptation). Une **filtration** est une famille $(\mathcal{F}_t)_{t \geq 0}$ de tribus croissante : $\mathcal{F}_s \subseteq \mathcal{F}_t$ si $s \leq t$. Un processus (X_t) est **adapté** si X_t est $\mathcal{F}_t$ -mesurable pour tout t .

Définition 11.2 (Temps d'arrêt). Un temps aléatoire $\tau : \Omega \rightarrow [0, \infty]$ est un **temps d'arrêt** si

$$\forall t \geq 0, \quad \{\tau \leq t\} \in \mathcal{F}_t.$$

Définition 11.3 (Martingale / sous-martingale). Un processus adapté (M_t) est une **martingale** si :

- (i) M_t est intégrable pour tout t ;
- (ii) pour $s \leq t$, $\mathbb{E}[M_t | \mathcal{F}_s] = M_s$ p.s.

Une **sous-martingale** vérifie $\mathbb{E}[M_t | \mathcal{F}_s] \geq M_s$.

Résultats et preuves

Théorème 11.1 (Optional stopping (version bornée, temps discret)). *Soit $(M_k)_{k=0}^n$ une martingale et τ un temps d'arrêt borné (valeurs dans $\{0, \dots, n\}$). Alors $\mathbb{E}[M_\tau] = \mathbb{E}[M_0]$.*

Proof. Écrire $M_\tau = \sum_{k=0}^n M_k \mathbf{1}_{\{\tau \geq k\}}$. Comme $\{\tau \geq k\} \in \mathcal{F}_k$ et $\mathbb{E}[M_n | \mathcal{F}_k] = M_k$, on a

$$\mathbb{E}[M_k \mathbf{1}_{\{\tau \geq k\}}] = \mathbb{E}[\mathbb{E}[M_n | \mathcal{F}_k] \mathbf{1}_{\{\tau \geq k\}}] = \mathbb{E}[M_n \mathbf{1}_{\{\tau \geq k\}}].$$

En sommant, $\mathbb{E}[M_\tau] = \mathbb{E}[M_n]$. Enfin $\mathbb{E}[M_n] = \mathbb{E}[M_0]$ en prenant l'espérance dans $\mathbb{E}[M_n | \mathcal{F}_0] = M_0$. $\square$

Théorème 11.2 (Inégalité de Doob (énoncé utile)). *Soit $(M_k)_{k=0}^n$ une sous-martingale non négative. Alors, pour tout $\lambda > 0$,*

$$\lambda \mathbb{P}\left(\max_{0 \leq k \leq n} M_k \geq \lambda\right) \leq \mathbb{E}[M_n].$$

Proof. Poser $\tau = \inf\{k \leq n : M_k \geq \lambda\}$ (temps d'arrêt borné). Sur $\{\tau \leq n\}$, $M_\tau \geq \lambda$. Appliquer optional stopping à $M_{k \wedge \tau}$ et obtenir $\mathbb{E}[M_n] \geq \mathbb{E}[M_\tau] \geq \lambda \mathbb{P}(\tau \leq n)$. $\square$

Théorème 11.3 (Azuma–Hoeffding (différences bornées)). *Soit $(M_k)_{k=0}^n$ une martingale. Supposons qu'il existe des constantes $(c_k)_{k=1}^n$ telles que*

$$\forall k \in \{1, \dots, n\}, \quad |M_k - M_{k-1}| \leq c_k \text{ p.s.}$$

Alors, pour tout $x > 0$,

$$\mathbb{P}(M_n - M_0 \geq x) \leq \exp\left(-\frac{x^2}{2 \sum_{k=1}^n c_k^2}\right), \quad \mathbb{P}(|M_n - M_0| \geq x) \leq 2 \exp\left(-\frac{x^2}{2 \sum_{k=1}^n c_k^2}\right).$$

Proof. Poser $D_k = M_k - M_{k-1}$. Par propriété de martingale, $\mathbb{E}[D_k \mid \mathcal{F}_{k-1}] = 0$, et $D_k \in [-c_k, c_k]$ p.s. En appliquant le lemme de Hoeffding *conditionnellement* à $\mathcal{F}_{k-1}$, on obtient pour tout $t \in \mathbb{R}$:

$$\mathbb{E}\left[e^{tD_k} \mid \mathcal{F}_{k-1}\right] \leq \exp\left(\frac{t^2 c_k^2}{2}\right),$$

car ici $b - a = 2c_k$ donc $(b - a)^2/8 = c_k^2/2$. En itérant avec la propriété de tour,

$$\mathbb{E}\left[e^{t(M_n - M_0)}\right] = \mathbb{E}\left[\exp\left(t \sum_{k=1}^n D_k\right)\right] \leq \exp\left(\frac{t^2}{2} \sum_{k=1}^n c_k^2\right).$$

Donc, pour $t > 0$, Markov donne $\mathbb{P}(M_n - M_0 \geq x) \leq \exp\left(-tx + \frac{t^2}{2} \sum_{k=1}^n c_k^2\right)$. Optimiser en t (min en $t = x / \sum c_k^2$) donne la borne unilatérale. La borne bilatérale vient comme d'habitude de l'union sur $\pm(M_n - M_0)$. $\square$

Pont vers le pricing (sans Girsanov)

On retient la phrase opérationnelle :

- sous une mesure risque-neutre $\mathbb{Q}$ associée à un numéraire B_t , les actifs actualisés $\tilde{S}_t = S_t/B_t$ sont des martingales ;
- donc le prix d'un payoff H s'écrit $V_t = B_t \mathbb{E}^{\mathbb{Q}}[H/B_T \mid \mathcal{F}_t]$ (1.1).

Le théorème fondamental de l'asset pricing (existence de $\mathbb{Q}$) et Girsanov (construction dynamique) ne sont pas prouvés ici, mais les objets probabilistes manipulés (filtration, conditionnement, martingale, arrêt) sont les briques.

Sanity checks

Sanity check. Martingale = intégrabilité + conditionnement. Si M_t n'est pas intégrable, $\mathbb{E}[M_t \mid \mathcal{F}_s]$ peut ne pas exister : la définition ne fait plus sens.

Sanity check. Optional stopping : « vrai » sous hypothèses. Une version trop générale (« pour tout temps d'arrêt ») est fautive : en entretien, donne une version bornée/sûre.

Sanity check. Azuma–Hoeffding (11.3) : l'hypothèse clé est le contrôle des *incrémentes* $|M_k - M_{k-1}|$. Sans borne, la concentration peut disparaître et il faut d'autres outils (Bernstein/Freedman).

Blocs Q/R d'entretien déplacés en annexe (voir Annexe Q/R).

Mini-synthèse

- Filtration = information croissante ; adapté = mesurable à l'information.
- Temps d'arrêt : l'événement $\{\tau \leq t\}$ est observable à t .
- Martingale : espérance conditionnelle constante (fair game).
- Optional stopping : vrai sous hypothèses (borné est le standard entretien).
- Azuma/Doob : contrôler déviations et maxima via incréments/espérance.
- Prix sous $\mathbb{Q}$: espérance conditionnelle d'un payoff actualisé.

Interview Pack — Partie II (core)

Instruments, payoffs, absence d'arbitrage, actualisation & courbe des taux

Notes d'entretien quant (buy-side/sell-side)

Version : 17 décembre 2025

Table des matières

1	Payoffs et produits	1
1.1	Avant-propos	1
	Avant-propos : prérequis, notations, objectifs	2
1.2	Fondations : payoffs et absence d'arbitrage	3
1.3	Contrats à terme et options : le vocabulaire minimal	3
1.4	Options digitales (binaires) : le bloc élémentaire	4
1.5	Gap options et digitals « modulées »	5
1.6	Options barrières : dépendance au franchissement	5
1.7	Options asiatiques : dépendance à une moyenne	7
1.8	Lookbacks : dépendance au maximum/minimum	8
1.9	Forward-start, cliquet, et payoffs « par resets »	8
1.10	Chooser et compound options (mention)	9
1.11	Options multi-actifs : corrélation, baskets, spreads	9
1.12	FX options et quanto : deux taux et un ajustement	9
1.13	Options de taux : caplets, floorlets, swaptions (aperçu)	10
1.14	Le principe « Lego » : linéarité du pricing	10
1.15	Stratégies « stock + options »	11
1.16	Spreads directionnels : bull, bear, risk reversal	12
1.17	Straddles, strangles : stratégies de volatilité	13
1.18	Wings : butterfly, condor	13
1.19	Mode microscope : formules clés et lectures	14
1.20	Pièges classiques / erreurs fréquentes	14
1.21	Checklist — savoir refaire sans regarder	15
2	Absence d'arbitrage et relations statiques	16
2.1	Avant-propos	16
2.2	Bornes d'absence d'arbitrage et relations statiques	17
2.3	Des calls comme « base » de payoffs convexes	17
2.4	Breeden–Litzenberger : extraire la densité implicite	18
2.5	Application : variance swap (aperçu « strips d'options »)	18
2.6	Mode microscope : parité, densité et réplication statique	19
2.7	Pièges classiques / erreurs fréquentes	20
2.8	Checklist — savoir refaire sans regarder	20
3	Pricing discret et mesure risque-neutre	21
3.1	Avant-propos	21
3.2	Mesure risque-neutre : l'idée, sans technique	22

3.3	Binomial $\rightarrow$ Black–Scholes : dérivation pas à pas	22
3.4	Le modèle binomial (CRR) : réplication en temps discret	22
3.5	De l'arbre à la diffusion : limite vers Black–Scholes	23
3.6	Mode microscope : arbre binomial, réplication et mesure risque-neutre	24
3.7	Pièges classiques / erreurs fréquentes	24
3.8	Checklist — savoir refaire sans regarder	24
4	Construction de courbes : bootstrap	25
4.1	Avant-propos	25
4.2	Introduction	26
4.3	Méthodologie	28
4.4	Défis techniques et résultats numériques	30
4.5	Mode microscope : facteurs d'actualisation et bootstrap instrument par instrument	33
4.6	Pièges classiques / erreurs fréquentes	33
4.7	Checklist — savoir refaire sans regarder	34
5	Nelson–Siegel–Svensson : modèle et calibration	35
5.1	Avant-propos	35
5.2	La méthode Nelson–Siegel et l'extension de Svensson	36
5.3	Reproduction de la courbe de la BCE	37
5.4	Conclusion	38
5.5	Mode microscope : NSS, forwards et calibration	38
5.6	Pièges classiques / erreurs fréquentes	39
5.7	Checklist — savoir refaire sans regarder	39
6	Synthèse quant (Partie II) : arbitrage statique, discret, courbe	40
6.1	Idée centrale (ce que tu dois être capable d'expliquer en 60 secondes)	40
6.2	Cadre mathématique (propre, standard)	40
6.3	Discret : binomial (ce qu'on attend en entretien)	41
6.4	Courbe des taux : bootstrap (et ce qui compte en pratique)	41
6.5	NSS : calibration stable (réflexes)	41
6.6	Implémentation (checklist)	41
6.7	Pitfalls (ce qui fait perdre des points)	42
6.8	Sanity checks (3–6 rapides)	42

Chapitre 1

Payoffs et produits

Idée centrale. Les options se ramènent à une fonction de payoff Φ (souvent de S_T) ; la linéarité des prix et la lecture « forme du payoff $\rightarrow$ exposition au risque » structurent tout (spreads, digitals, exotiques).

Cadre mathématique.

- **Payoff.** Contrat européen : flux $\Phi(S_T)$; profit = payoff – prix (actualisé).
- **Linéarité.** $\Phi = \sum_i a_i \Phi_i \Rightarrow V_0(\Phi) = \sum_i a_i V_0(\Phi_i)$ (absence d'arbitrage).
- **Forward.** $F_0(T) = S_0 e^{(r-q)T}$ (cash-and-carry) ; brique pour put-call parity et diagnostics.
- **Shape.** Convexité $\Rightarrow$ sensibilité à la volatilité ; discontinuités $\Rightarrow$ sensibilité aux queues ; path-dependence $\Rightarrow$ Monte Carlo/PDE.

Intuition marché / interprétation. En desk, un payoff est à la fois « contrat » et « diagnostic » : il dit quelles sources de risque dominant et quelle famille de modèles/méthodes est crédible (réplication statique vs dynamique, MC, arbres).

Implémentation.

- Implémenter Φ comme fonction vectorisée (numpy) et composer des stratégies (spreads/butterfly) via combinaisons linéaires.
- Tracer payoff/profit et vérifier les pentes/cassures (lecture instantanée du risque).

Tests / sanity checks.

- Linéarité : $V(\Phi_1 + \Phi_2) \approx V(\Phi_1) + V(\Phi_2)$ sur un univers de prix cohérents.
- Forward : si $F_0^{mkt}(T)$ viole $S_0 e^{(r-q)T}$ au-delà du bid-ask, arbitrage (test de cohérence).
- Payoff : limites $S_T \rightarrow 0$ et $S_T \rightarrow \infty$ (croissance, bornes) ; continuité/convexité quand attendu.

Pont vers pratique quant. Pont quant : structuration (réplication statique), risk (lecture delta/gamma/vega au niveau payoff), calibration (arbitrage statique), et pricing numérique des exotiques (MC/PDE) motivé par la dépendance au chemin.

1.1 Avant-propos

1.1.1 Objectifs pédagogiques

- Identifier la variable pertinente (souvent S_T) et lire un payoff comme une fonction Φ .
- Reconnaître les payoffs standards (forward, call, put) et leurs variantes usuelles (spreads, wings, digitals).
- Savoir décomposer une stratégie en combinaison linéaire de payoffs simples.
- Faire le lien entre *forme* du payoff et *méthode de pricing* (continu/discret, path-dependent, dimension).

1.1.2 Pré-requis

- Calcul élémentaire (fonctions, dérivation, convexité) et représentations graphiques.

- Notion de facteur d'actualisation $P(0, T)$ et de taux sans risque r (revu en détail dans chapitre 4).

1.1.3 Plan du chapitre

1. Payoffs élémentaires et vocabulaire (maturité, strike, moneyness).
2. Produits (actions, forwards, options vanilles) puis exotiques typiques (digital, barrière, asiatique).
3. Combinaisons d'options et lecture des profils de risque (spreads, straddles, wings).

Intuition de marché. Dans la pratique, la forme d'un payoff sert de *spécification contractuelle* et de *diagnostic* : un payoff convexe signale une sensibilité forte à la volatilité, un payoff discontinu signale une sensibilité à la queue/distribution, et un payoff dépendant du chemin dicte souvent une méthode de pricing par simulation.

Résumé

Ces notes donnent un **cours complet et progressif** sur les options, destiné à des étudiants de M1 en finance quantitative (niveau mathématiques post-prépa). L'objectif est double : (i) **savoir définir** les principaux types d'options (vanilles, exercice anticipé, exotiques), (ii) **savoir expliquer** d'où viennent les formules de pricing et les méthodes numériques usuelles.

Le fil conducteur est toujours le même :

- écrire clairement le **payoff** et identifier les **variables pertinentes** (spot, moyenne, maximum, franchissement de barrière, etc.) ;
- utiliser l'**absence d'arbitrage** pour obtenir des **bornes** et des **relations** (parité call-put, convexité, monotonie) ;
- introduire la **mesure risque-neutre** puis dériver, pas à pas, le **pricing des vanilles** (binomial $\rightarrow$ Black-Scholes) ;
- comprendre quelles options ont une **formule fermée** et lesquelles nécessitent Monte Carlo, PDE, arbres ou réplication statique ;
- ouvrir vers la **volatilité stochastique** (modèle de Heston) et comprendre ce que cela change (deux facteurs, smile, incomplétude).

Avant-propos : prérequis, notations, objectifs

Prérequis. Calcul différentiel et intégral, probabilité de base (espérance, variance, conditionnement), notion de loi normale. On supposera connus les concepts financiers élémentaires : actualisation, taux sans risque, absence d'arbitrage. Le calcul stochastique (Itô) est rappelé au moment où il est utilisé.

Notations. On travaille sur un espace probabilisé filtré $(\Omega, \mathcal{F}, (\mathcal{F}_t)_{t \in [0, T]}, \mathbb{P})$. Le sous-jacent (action) est S_t ; le taux sans risque est constant r ; on autorise un **dividend yield** constant q (on peut prendre $q = 0$ si besoin). La maturité est T et le strike est K . La fonction payoff est notée Φ . On note $(x)^+ := \max(x, 0)$.

Objectifs pédagogiques. À la fin, vous devez pouvoir :

- reconnaître et tracer les payoffs des options usuelles (vanilles, digitals, barrières, Asians, lookbacks, spreads) ;
- établir les relations d'absence d'arbitrage (bornes, parité call-put, convexité/monotonie) ;
- dériver le pricing dans le modèle binomial puis en continu (Black-Scholes) ;
- expliquer pourquoi et comment on passe d'une **réplication** à une **espérance risque-neutre** ;
- comprendre ce qui change avec l'exercice anticipé (American/Bermudan) ;
- savoir situer les méthodes de pricing des exotiques (PDE, MC, arbres, réplication statique) ;
- formuler le modèle de Heston et expliquer, qualitativement, comment il génère un smile et pourquoi il est plus réaliste que Black-Scholes.

1.2 Fondations : payoffs et absence d'arbitrage

On part de l'objet le plus concret : une fonction payoff $\Phi(S_T)$ (ou, plus généralement, un payoff dépendant du chemin). Deux idées structurent tout le pricing :

- **linéarité** : le prix d'une combinaison de payoffs est la combinaison des prix ;
- **absence d'arbitrage** : elle impose des bornes et des relations (parité call-put, convexité).

Dans ce chapitre, on construit d'abord le vocabulaire (forwards, calls, puts), puis on enrichit avec des familles de produits et des stratégies.

1.3 Contrats à terme et options : le vocabulaire minimal

1.3.1 Forward/future (sans convexité ici)

Un **forward** de maturité T et prix de livraison K a payoff

$$\Phi_{\text{fwd}}(S_T) = S_T - K.$$

Sous absence d'arbitrage, et en présence d'un taux sans risque r et d'un dividend yield q , la valeur au temps 0 d'un forward est

$$V_0^{\text{fwd}} = S_0 e^{-qT} - K e^{-rT}.$$


Le **forward price** (le K qui rend le contrat de valeur initiale nulle) vaut

$$F_0(T) = S_0 e^{(r-q)T}.$$

1.3.2 Options vanilles (européennes)

Définition 1.1 (Call et put européens). Un **call** européen de strike K et maturité T a payoff $\Phi(S_T) = (S_T - K)^+$. Un **put** européen a payoff $\Phi(S_T) = (K - S_T)^+$.

Graphes de payoff.



1.3.3 Payoff vs profit

Le **payoff** est ce qui est reçu à l'échéance. Le **profit** (ou P&L) tient compte du **prix payé à l'origine** et de l'actualisation :

$$\text{profit} = \text{payoff} - \text{prix actualisé}.$$

1.4 Options digitales (binaires) : le bloc élémentaire

1.4.1 Deux digitales standards


Définition 1.2 (Cash-or-nothing et asset-or-nothing). Le **cash-or-nothing call** paie 1 si $S_T > K$:

$$\Phi(S_T) = \mathbf{1}_{\{S_T > K\}}.$$

L'**asset-or-nothing call** paie S_T si $S_T > K$:

$$\Phi(S_T) = S_T \mathbf{1}_{\{S_T > K\}}.$$

Graphes de payoff.



1.4.2 Pricing en Black–Scholes

Sous $\mathbb{Q}$ (modèle BS), on obtient :

$$\text{cash digital call : } D_0^{\text{cash}} = e^{-rT} \Phi(d_2), \quad \text{asset digital call : } D_0^{\text{asset}} = S_0 e^{-qT} \Phi(d_1),$$

où, pour un strike K ,

$$d_1 = \frac{\ln(S_0/K) + (r - q + \frac{1}{2}\sigma^2)T}{\sigma\sqrt{T}}, \quad d_2 = d_1 - \sigma\sqrt{T}.$$

1.4.3 Lien fondamental : dérivée en strike et réplication par spreads

Le call est décroissant en strike. Sous des hypothèses de régularité,

$$\frac{\partial C_0(K)}{\partial K} = -e^{-rT} \mathbb{Q}(S_T > K).$$

En particulier, en BS :

$$\frac{\partial C_0(K)}{\partial K} = -e^{-rT} \Phi(d_2).$$

Interprétation : une digitale (cash-or-nothing) se réplique par un **vertical spread très serré** :


$$\frac{C_0(K) - C_0(K + \varepsilon)}{\varepsilon} \approx e^{-rT} \mathbf{1}_{\{S_T > K\}} \quad (\varepsilon \downarrow 0, \text{ au sens approprié}).$$

1.5 Gap options et digitals « modulées »

Définition 1.3 (Gap call). Une gap call possède deux strikes : un strike de déclenchement K_2 et un strike d'exercice K_1 :

$$\Phi(S_T) = (S_T - K_1) \mathbf{1}_{\{S_T > K_2\}}.$$

Graphique (profil en S_T).



Pricing. Sous $\mathbb{Q}$, $V_0 = e^{-rT} \mathbb{E}_{\mathbb{Q}}[(S_T - K_1) \mathbf{1}_{\{S_T > K_2\}}]$. En BS, on peut exprimer ce prix comme une combinaison d'asset digital et de cash digital (car $(S_T - K_1) \mathbf{1}_{\{S_T > K_2\}} = S_T \mathbf{1}_{\{S_T > K_2\}} - K_1 \mathbf{1}_{\{S_T > K_2\}}$).

1.6 Options barrières : dépendance au franchissement

1.6.1 Définitions (up/down, in/out)

On fixe une barrière B et le temps d'atteinte

$$\tau_B = \inf\{t \in [0, T] : S_t \in \mathcal{B}\},$$

où $\mathcal{B} = \{B\}$ (barrière simple) et la condition « up » ou « down » dépend du côté à franchir. Deux familles principales :

- **knock-out (KO)** : l'option est annulée si $\tau_B \leq T$;
- **knock-in (KI)** : l'option n'existe que si $\tau_B \leq T$.

1.6.2 Payoff et parité KI/KO

Pour un payoff vanille $\Phi(S_T)$:


$$\Phi_{\text{KO}} = \Phi(S_T) \mathbf{1}_{\{\tau_B > T\}}, \quad \Phi_{\text{KI}} = \Phi(S_T) \mathbf{1}_{\{\tau_B \leq T\}}.$$

Relation fondamentale :

$$\Phi_{\text{KI}} + \Phi_{\text{KO}} = \Phi_{\text{vanilla}}.$$

1.6.3 Graphique : intuition (exemple up-and-out call)

Le payoff exact dépend du chemin, mais on peut dessiner un « profil » en S_T en gardant en tête la condition « si la barrière n'a pas été touchée ».



1.6.4 Pricing : trois routes standards

- **Formules fermées (BS, monitoring continu)** : via principe de réflexion sur $\ln S_t$.
- **PDE avec condition au bord** : $V(t, B) = 0$ pour une KO (et condition terminale à T).
- **Monte Carlo** : nécessite une correction de franchissement (Brownian bridge), sinon on sous-estime l'événement « touch ».

1.6.5 Une formule compacte (exemple : call down-and-out, idée « images »)

Dans le modèle BS (avec $q = 0$ pour alléger), certaines KO ont une formule courte :

$$C_{\text{DO}} = C_{\text{vanilla}}(S_0, K) - \left(\frac{B}{S_0}\right)^{2\lambda-2} C_{\text{vanilla}}\left(\frac{B^2}{S_0}, K\right), \quad \lambda = \frac{r}{\sigma^2} + \frac{1}{2}.$$

Cette écriture illustre l'idée : un prix barrière est « vanille moins image réfléchie ». Les formules exactes dépendent des cas (B vs K , dividendes, etc.).

1.6.6 Correction Brownian bridge (Monte Carlo)

Si l'on simule S_t sur une grille $t, t+h$, on doit approximer la probabilité de franchissement entre deux dates. Pour une barrière B et un GBM, une formule classique est :

$$\mathbb{P}(\text{hit sur } (t, t+h) \mid S_t, S_{t+h}) = \exp\left(-\frac{2}{\sigma^2 h} \ln \frac{S_t}{B} \cdot \ln \frac{S_{t+h}}{B}\right),$$

à utiliser avec soin (conditions selon le type de barrière et la direction).

1.7 Options asiatiques : dépendance à une moyenne

1.7.1 Deux variantes usuelles


On fixe des dates d'observation $0 < t_1 < \dots < t_n = T$ et une moyenne arithmétique

$$A_T := \frac{1}{n} \sum_{i=1}^n S_{t_i}.$$

Deux payoffs fréquents :

$$\text{Average price : } (A_T - K)^+, \quad \text{Average strike : } (S_T - A_T)^+.$$

Graphique (variable pertinente : A_T).



1.7.2 Pricing : pourquoi il n'y a (souvent) pas de formule fermée

Sous BS, S_t est lognormal, mais A_T (moyenne arithmétique d'un lognormal) ne l'est pas. On utilise donc :

- **Monte Carlo** (souvent avec réduction de variance) ;
- **approximations** (moment matching, lognormal approximations) ;
- **PDE** en dimension 2, état (S_t, A_t) (utile surtout en 1D et si l'on veut des greeks stables).

1.7.3 Cas important : moyenne géométrique (prix quasi-fermé)

Définissons la moyenne géométrique discrète

$$G_T := \left(\prod_{i=1}^n S_{t_i} \right)^{1/n} = \exp \left(\frac{1}{n} \sum_{i=1}^n \ln S_{t_i} \right).$$

Sous BS, le vecteur $(\ln S_{t_1}, \dots, \ln S_{t_n})$ est gaussien, donc la moyenne est gaussienne :

$$\ln G_T \sim \mathcal{N}(m_G, v_G),$$

avec m_G, v_G calculables explicitement (moyenne/covariance des $\ln S_{t_i}$). Ainsi G_T est lognormal et le prix du call géométrique

$$C_0^{\text{geo}} = e^{-rT} \mathbb{E}_{\mathbb{Q}}[(G_T - K)^+]$$

se calcule comme un call sur une variable lognormale :

$$C_0^{\text{geo}} = e^{-rT} \left(e^{m_G + \frac{1}{2}v_G} \Phi(d_1^G) - K \Phi(d_2^G) \right), \quad d_1^G = \frac{m_G - \ln K + v_G}{\sqrt{v_G}}, \quad d_2^G = d_1^G - \sqrt{v_G}.$$

Remarque 1.1 (Control variate (pratique)). Le prix arithmétique se calcule souvent par Monte Carlo en utilisant le prix géométrique comme **control variate** : on simule (A_T, G_T) conjointement, on corrige la

moyenne via la différence (prix géométrique simulé) vs (prix géométrique exact).

1.8 Lookbacks : dépendance au maximum/minimum

1.8.1 Définitions et payoffs


On note le maximum et le minimum sur $[0, T]$:

$$M_T := \max_{0 \leq t \leq T} S_t, \quad m_T := \min_{0 \leq t \leq T} S_t.$$

Exemples :

$$\text{Fixed-strike lookback call : } (M_T - K)^+, \quad \text{Floating-strike lookback call : } (S_T - m_T)^+.$$

Graphique (variable pertinente : M_T).



1.8.2 Pricing : idée (principe de réflexion)

Dans BS, $\ln S_t$ est un brownien avec drift. Le maximum d'un brownien a une loi explicite via le principe de réflexion : cela permet des formules fermées pour certains lookbacks. En pratique, en Monte Carlo, il faut aussi corriger les extrêmes entre deux dates (Brownian bridge).

1.9 Forward-start, cliquet, et payoffs « par resets »

1.9.1 Forward-start

Un forward-start call fixe son strike à une date future t_0 : typiquement $K = \alpha S_{t_0}$. Le payoff est

$$\Phi = (S_T - \alpha S_{t_0})^+.$$

Sous BS, l'homogénéité du payoff et l'indépendance des incréments permettent une réduction : on ramène le pricing à un call standard sur un ratio, ce qui donne une formule fermée (à connaître au moins qualitativement).

1.9.2 Cliquet (ratchet) : addition de rendements capés/floorés

Une structure cliquet additionne des rendements périodiques, souvent capés et floorés, par exemple :

$$\Phi = \sum_{i=1}^n \min(\max(R_i, F), C), \quad R_i = \frac{S_{t_i}}{S_{t_{i-1}}} - 1.$$

Ce sont des options **fortement path-dependent**. Pricing : Monte Carlo (souvent avec antithétiques + control variates), parfois PDE en dimension augmentée si structure simple.

1.10 Chooser et compound options (mention)

1.10.1 Chooser

Une chooser option permet au détenteur de choisir à une date t_0 entre un call et un put (mêmes K, T). Le payoff est

$$\Phi = \max((S_T - K)^+, (K - S_T)^+) \quad \text{avec décision à } t_0.$$

La valorisation s'écrit comme un problème d'arrêt/choix optimal; en BS, il existe une formule utilisant des normales (souvent vue comme exercice avancé).

1.10.2 Compound (option sur option)

Exemple : call sur call (strike K_1 exercisable à t_0 , sur un call de strike K_2 maturité T). En BS, on obtient des formules à base de lois normales bivariées. En pratique, ces produits se priceront aussi par arbre/PDE.

1.11 Options multi-actifs : corrélation, baskets, spreads

1.11.1 Option d'échange (Margrabe)

Deux actifs $S^{(1)}$ et $S^{(2)}$ (sans dividendes ici pour alléger). Une option d'échange paie :

$$\Phi = (S_T^{(1)} - S_T^{(2)})^+.$$

Dans un modèle lognormal corrélé, il existe une formule fermée (Margrabe) analogue à Black-Scholes, avec une volatilité effective égale à la volatilité du ratio $S^{(1)}/S^{(2)}$.

Graphique (payoff en 2D).



1.11.2 Baskets et worst-of/best-of

Exemples :

$$\text{basket call : } \left(\sum_{i=1}^d w_i S_T^{(i)} - K \right)^+, \quad \text{worst-of put : } \left(K - \min_i S_T^{(i)} \right)^+.$$

En général, pas de formule fermée : Monte Carlo (avec copule/corrélation), ou approximations (lognormal de panier, expansions).

1.11.3 Spreads (ex. Kirk) et corrélation

Un spread option paie par exemple $(S_T^{(1)} - S_T^{(2)} - K)^+$. La corrélation influence fortement la valeur : plus la corrélation est élevée, plus la dispersion du spread diminue, et plus l'option tend à baisser.

1.12 FX options et quanto : deux taux et un ajustement

1.12.1 Garman-Kohlhagen (Black-Scholes FX)

Pour un taux de change X_t (devise domestique par unité étrangère), on note :

$$r_d \text{ (taux domestique),} \quad r_f \text{ (taux étranger).}$$

Sous $\mathbb{Q}$ domestique, le modèle est

$$\frac{dX_t}{X_t} = (r_d - r_f)dt + \sigma dW_t.$$

Les formules call/put sont celles de Black–Scholes avec $r = r_d$ et « dividende » $q = r_f$.

1.12.2 Quanto : drift adjustment

Un payoff « quanto » dépend d'un actif étranger S_t mais est payé en domestique à un taux de change fixé (ou couvert). Le pricing se fait par changement de numéraire/mesure et introduit un **quanto adjustment** : le drift sous la mesure de pricing dépend de la corrélation entre l'actif étranger et le FX.

1.13 Options de taux : caplets, floorlets, swaptions (aperçu)

1.13.1 Caplet / floorlet

Un caplet sur un taux forward $L(T_i, T_{i+1})$ paie à T_{i+1} :

$$\Phi = \delta (L(T_i, T_{i+1}) - K)^+,$$

où δ est l'année fraction. Sous le modèle de Black (lognormal du forward), le prix s'écrit :

$$\text{Caplet}_0 = P(0, T_{i+1}) \delta \left(F_0 \Phi(d_1) - K \Phi(d_2) \right),$$

avec $F_0 = L(0, T_i, T_{i+1})$ et

$$d_1 = \frac{\ln(F_0/K) + \frac{1}{2}\sigma^2 T_i}{\sigma \sqrt{T_i}}, \quad d_2 = d_1 - \sigma \sqrt{T_i}.$$

1.13.2 Swaption (Black 76)

Une payer swaption paie à l'exercice T_0 :

$$\Phi = A(T_0) (S(T_0) - K)^+,$$

où $S(T_0)$ est le taux swap forward et $A(T_0)$ l'annuité. Sous Black 76 (lognormal de S), on obtient une formule identique à un call sur le taux swap, multipliée par l'annuité.

Combinaisons d'options : stratégies, profils de risque, pricing

Les stratégies (spreads, straddles, collars, *wings*, etc.) servent à **sculpter un profil de payoff** et à cibler un scénario de marché. Le message clé est que la tarification suit les mêmes règles de construction :

- si une stratégie est une somme (pondérée) de payoffs élémentaires, son prix est la somme (pondérée) des prix ;
- les contraintes d'absence d'arbitrage se lisent souvent comme des *inégalités* sur ces combinaisons.

On en profite aussi pour relier ces constructions à des notions vues ensuite : convexité et densité risque-neutre.

1.14 Le principe « Lego » : linéarité du pricing

Si un payoff s'écrit comme une combinaison linéaire de payoffs,

$$\Phi = \sum_{j=1}^m w_j \Phi_j,$$

alors, sous absence d'arbitrage, le prix est la même combinaison :

$$V_0 = \sum_{j=1}^m w_j V_0^{(j)}.$$


C'est la raison pour laquelle les stratégies (spreads, straddles, collars) sont des objets **simples à pricer** dès qu'on sait pricer les vanilles.

1.15 Stratégies « stock + options »

1.15.1 Covered call

Structure : long action + short call(K). Payoff :

$$\Phi(S_T) = S_T - (S_T - K)^+ = \min(S_T, K).$$




Intuition : on **cappe** le gain au-dessus de K en échange de la prime du call.

1.15.2 Protective put

Structure : long action + long put(K). Payoff :

$$\Phi(S_T) = S_T + (K - S_T)^+ = \max(S_T, K).$$



Intuition : on **floor** la valeur à K (assurance).

1.15.3 Collar

Structure : long action + long put(K_1) + short call(K_2), avec $K_1 < K_2$. Payoff :

$$\Phi(S_T) = \min(\max(S_T, K_1), K_2).$$


Prix : $V_0 = S_0 + P_0(K_1) - C_0(K_2)$ (en pratique, on choisit souvent K_1, K_2 pour rendre le coût proche de zéro).

1.16 Spreads directionnels : bull, bear, risk reversal

1.16.1 Bull call spread

Structure : long call(K_1) + short call(K_2), $K_1 < K_2$. Payoff :

$$\Phi(S_T) = (S_T - K_1)^+ - (S_T - K_2)^+.$$




Prix : $V_0 = C_0(K_1) - C_0(K_2)$.

1.16.2 Bear put spread

Structure : long put(K_2) + short put(K_1), $K_1 < K_2$. Payoff :

$$\Phi(S_T) = (K_2 - S_T)^+ - (K_1 - S_T)^+.$$



Prix : $V_0 = P_0(K_2) - P_0(K_1)$.

1.16.3 Risk reversal (profil skew)

Structure typique (equity) : short put OTM + long call OTM. Exemple :

$$\Phi(S_T) = -(K_1 - S_T)^+ + (S_T - K_2)^+, \quad K_1 < K_2.$$


Interprétation : on « vend » de la protection downside (put) et on finance une participation upside (call).

1.17 Straddles, strangles : stratégies de volatilité

1.17.1 Straddle

Structure : long call(K) + long put(K). Payoff :

$$\Phi(S_T) = |S_T - K|.$$




Straddle = pari sur de grands mouvements (vega positive, gamma positive autour de K).

1.17.2 Strangle

Structure : long put(K_1) + long call(K_2), $K_1 < K_2$. Payoff :

$$\Phi(S_T) = (K_1 - S_T)^+ + (S_T - K_2)^+.$$




Strangle = straddle moins cher (OTM), mais nécessite un mouvement plus grand pour être ITM.

1.18 Wings : butterfly, condor

1.18.1 Butterfly (call butterfly)

Structure : $+C(K_1) - 2C(K_2) + C(K_3)$, $K_1 < K_2 < K_3$.

$$\Phi(S_T) = (S_T - K_1)^+ - 2(S_T - K_2)^+ + (S_T - K_3)^+.$$



Prix : $V_0 = C_0(K_1) - 2C_0(K_2) + C_0(K_3)$.

1.18.2 Condor

Structure : $+C(K_1) - C(K_2) - C(K_3) + C(K_4)$, $K_1 < K_2 < K_3 < K_4$. Payoff : plateau (gain borné) avec zone centrale plus large qu'une butterfly.

1.19 Mode microscope : formules clés et lectures

1.19.1 Le forward (cash-and-carry) : dérivation pas à pas

Hypothèses. On suppose un taux sans risque constant r et, si besoin, un rendement de dividende continu q . On suppose qu'il est possible d'emprunter/prêter au taux r et de traiter le sous-jacent sans friction (idéalisation).

Dérivation (réplication). Considérons un forward de maturité T et de strike K , payoff $S_T - K$. Construisons un portefeuille qui réplique ce payoff :

- acheter 1 sous-jacent aujourd'hui (coût S_0) ;
- financer l'achat en empruntant S_0 au taux r .

Sous dividende continu q , la valeur *en forward* de l'actif porte le facteur $e^{(r-q)T}$. Le strike d'un forward de valeur nulle aujourd'hui est donc

$$F_0(T) = S_0 e^{(r-q)T}, \quad K = F_0(T).$$

Interprétation. r augmente le forward (coût de financement), q le diminue (bénéfice de portage via dividendes).

Sanity check. Si $q = r$, alors $F_0(T) = S_0$: portage neutre, pas d'effet financier à différer l'achat.

Exemple jouet. Exemple jouet : $S_0 = 100$, $r = 2\%$, $q = 0.5\%$, $T = 1$ donne $F_0 \approx 100 e^{0.015} \approx 101.51$.

1.19.2 Combinaisons linéaires : lecture graphique et prix

Idée clé. Si $\Phi = \sum_i a_i \Phi_i$ alors, sous absence d'arbitrage, $V(\Phi) = \sum_i a_i V(\Phi_i)$.

Intuition de marché. C'est la base des stratégies en vanilles : spreads, butterflies, wings. On peut tout de suite lire (i) le profil de risque et (ii) le prix comme combinaison de prix liquides.

1.20 Pièges classiques / erreurs fréquentes

- Confondre variable de payoff (S_T) et variable de pricing (temps t , état S_t).

- Oublier l'actualisation : comparer des flux à des dates différentes sans $P(0, T)$.
- Signes : long/short option, payoff $(x)^+$, et interprétation du strike.
- Sur-interpréter : un payoff « neutre » n'est pas forcément neutre en greeks.

1.21 Checklist — savoir refaire sans regarder

- Tracer rapidement un payoff et lire pentes/cassures.
- Décomposer spreads/butterflies/straddles en calls/puts.
- Retrouver $F_0(T) = S_0 e^{(r-q)T}$ et construire l'arbitrage si le marché dévie.
- Dire si un payoff est convexe/discontinu/path-dependent et ce que cela implique pour le pricing.
- Produire un mini-exemple numérique (ordre de grandeur) pour vérifier un prix.

Chapitre 2

Absence d'arbitrage et relations statiques

Idée centrale. Traduire « pas d'arbitrage » en contraintes vérifiables sur les prix : bornes, parité call-put, monotonie/convexité en strike, et (sous hypothèses) densité risque-neutre implicite.

Cadre mathématique.

- **Dominance.** Payoff $\Phi \geq 0$ p.s. $\Rightarrow$ prix ≥ 0 ; si $\Phi_1 \geq \Phi_2$ alors $V(\Phi_1) \geq V(\Phi_2)$.
- **Parité.** $C_0(K) - P_0(K) = S_0 e^{-qT} - K e^{-rT}$ (européennes).
- **Static arbitrage.** Pour $K \mapsto C_0(K)$: décroissante, convexe ; spreads/butterflies $\Rightarrow$ contraintes linéaires.
- **Breeden–Litzenberger.** Si régulier, $\partial_{KK} C_0(K) = e^{-rT} f_{S_T}^{\mathbb{Q}}(K)$.

Intuition marché / interprétation. Ces contraintes sont le premier « data QC » d'un desk : les violations viennent de quotes bruitées, bid-ask, dividendes/funding mal modélisés, ou erreurs d'alignement (maturités, taux, forward).

Implémentation.

- Construire un check statique : sur chaque maturité, tester parité, monotonie et convexité (en tenant compte du bid-ask).
- Nettoyage : projeter une surface de prix sur l'ensemble « convexe + monotone » (convex regression / QP).

Tests / sanity checks.

- Parité : résidu $C - P - (S_0 e^{-qT} - K e^{-rT})$ doit être compatible bid-ask.
- Spreads : $C(K_1) - C(K_2)$ borné par $(K_2 - K_1) e^{-rT}$; butterflies ≥ 0 .
- Densité implicite : $\partial_{KK} C$ non négative (diagnostic de convexité).

Pont vers pratique quant. Pont quant : construction/cleaning de surfaces (implied vol), calibration (imposer non-arbitrage), et extraction de distributions risque-neutres (pricing/risk, stress).

2.1 Avant-propos

2.1.1 Objectifs pédagogiques

- Transformer l'idée « pas d'arbitrage » en contraintes quantitatives sur les prix.
- Démontrer et utiliser la parité call-put (avec ou sans dividendes).
- Relier *forme* en strike K (monotonie/convexité) et absence d'arbitrage statique.
- Comprendre comment une surface de prix encode une densité risque-neutre (idée de Breeden–Litzenberger).

2.1.2 Pré-requis

- Chapitre chapitre 1 (payoffs et combinaisons linéaires).
- Actualisation élémentaire : un euro certain à T vaut $P(0, T)$ aujourd'hui (formalisé en chapitre 4).

2.1.3 Plan du chapitre

1. Bornes d'arbitrage (call/put), monotonie, convexité.
2. Parité call-put : preuves par arbitrage, par réplication, et via la mesure risque-neutre.
3. Densité risque-neutre et réplication statique (Breedon-Litzenberger, payoffs convexes).

Sanity check. Un prix de call en fonction du strike K doit être décroissant et convexe. Si ce n'est pas le cas, on peut construire un portefeuille de calls/forwards dont le payoff est partout ≥ 0 mais de prix négatif.

2.2 Bornes d'absence d'arbitrage et relations statiques

2.2.1 Bornes élémentaires

Pour un call européen :

$$0 \leq C_0 \leq S_0 e^{-qT}.$$

Pour un put :

$$0 \leq P_0 \leq K e^{-rT}.$$

2.2.2 Parité call-put (démonstration par arbitrage)

Proposition 2.1 (Parité call-put). *Sous absence d'arbitrage, pour des options européennes (même K , même T) :*

$$C_0 - P_0 = S_0 e^{-qT} - K e^{-rT}.$$

Démonstration. Considérons deux portefeuilles :

$$\Pi_A = \text{call}(K, T) + K e^{-rT} \text{ (zéro-coupon)}, \quad \Pi_B = \text{put}(K, T) + \text{action prépayée}.$$

À l'échéance, pour tout S_T ,

$$(S_T - K)^+ + K = (K - S_T)^+ + S_T.$$

Donc Π_A et Π_B ont le même payoff et doivent avoir le même prix au temps 0. □

2.2.3 Monotonie et convexité en strike

Un call est **décroissant** en K et **convexe** en K . Ces propriétés permettent de détecter des **arbitrages statiques** sur une surface de prix.

2.3 Des calls comme « base » de payoffs convexes

2.3.1 Une identité de décomposition (niveau M1)

Soit $g : \mathbb{R}_+ \rightarrow \mathbb{R}$ deux fois dérivable, avec une croissance raisonnable. On démontre l'identité (intégration par parties) :

$$g(S) = g(0) + g'(0)S + \int_0^\infty (S - K)^+ g''(K) dK. \quad (2.1)$$

Démonstration. Fixons $S \geq 0$. Comme $(S - K)^+ = 0$ dès que $K > S$, l'intégrale se réduit à

$$\int_0^\infty (S - K)^+ g''(K) dK = \int_0^S (S - K) g''(K) dK.$$

On intègre par parties sur $[0, S]$ (hypothèse $g \in C^2$) avec $u(K) = S - K$ et $v'(K) = g''(K)$:

$$\begin{aligned} \int_0^S (S - K) g''(K) dK &= \left[(S - K) g'(K) \right]_0^S + \int_0^S g'(K) dK \\ &= (0 \cdot g'(S) - S g'(0)) + (g(S) - g(0)) \\ &= g(S) - g(0) - S g'(0). \end{aligned}$$

En réarrangeant, on obtient bien (2.1). $\square$

Intuition : $(S - K)^+$ est une **brique convexe** ; en superposant des calls sur tous les strikes, on reconstruit la convexité de g .

Remarque 2.1 (Version puts/calls). On peut aussi écrire une formule centrée au forward F en séparant puts (pour $K < F$) et calls (pour $K > F$). C'est cette version qui est utilisée pour les variance swaps.

2.3.2 Conséquence : pricing par intégrale de calls

En prenant l'espérance risque-neutre et l'actualisation, on obtient formellement :

$$V_0(g) = e^{-rT} \mathbb{E}_{\mathbb{Q}}[g(S_T)] = e^{-rT} g(0) + g'(0) S_0 e^{-qT} + \int_0^\infty C_0(K) g''(K) dK,$$

où $C_0(K)$ est le prix du call européen de strike K et maturité T . On voit apparaître un fait crucial : **un continuum de calls en strike contient énormément d'information** sur la loi de S_T sous $\mathbb{Q}$.

2.4 Breeden–Litzenberger : extraire la densité implicite

2.4.1 Dérivation pas à pas

On part de la représentation :

$$C_0(K) = e^{-rT} \mathbb{E}_{\mathbb{Q}}[(S_T - K)^+].$$

On dérive par rapport à K (heuristiquement) :

$$\frac{\partial}{\partial K} (S_T - K)^+ = -\mathbf{1}_{\{S_T > K\}},$$

d'où

$$\frac{\partial C_0(K)}{\partial K} = -e^{-rT} \mathbb{Q}(S_T > K).$$

En dérivant une seconde fois :

$$\frac{\partial^2 C_0(K)}{\partial K^2} = e^{-rT} f_{S_T}^{\mathbb{Q}}(K),$$

où $f_{S_T}^{\mathbb{Q}}$ est la densité risque-neutre.

Remarque 2.2 (Pourquoi c'est central). Une surface de call $K \mapsto C_0(K)$ (à maturité fixée) détermine la loi risque-neutre de S_T . Ainsi, l'**implied volatility smile** encode une distribution implicite.

2.5 Application : variance swap (aperçu « strips d'options »)

2.5.1 Idée

Le payoff d'un variance swap est (grossièrement) la variance réalisée de $\ln S_t$. Le résultat clé est qu'un payoff de type « log contract » se réplique statiquement par un portefeuille de puts/calls sur tous les strikes.

2.5.2 Formule standard (à connaître au moins qualitativement)

En notant F le forward à maturité T , une approximation classique de la variance fair strike est :

$$K_{\text{var}} \approx \frac{2}{T} \left(\int_0^F \frac{P_0(K)}{K^2} dK + \int_F^\infty \frac{C_0(K)}{K^2} dK \right),$$

où $P_0(K)$ et $C_0(K)$ sont les prix des puts et calls de maturité T . Cette formule explique pourquoi le smile/skew a un impact direct sur les produits de volatilité.

2.6 Mode microscope : parité, densité et réplication statique

2.6.1 Parité call–put : trois preuves complémentaires

Énoncé. Pour une maturité T et un strike K , on note $C_0(K, T)$ et $P_0(K, T)$ les prix du call/put européens. Sous dividende continu q et taux r (constants pour simplifier l'écriture), la parité s'écrit

$$C_0(K, T) - P_0(K, T) = S_0 e^{-qT} - K e^{-rT}. \quad (2.2)$$

Preuve 1 (par payoffs, réplication statique). Observer que, pour tout S_T ,

$$(S_T - K)^+ - (K - S_T)^+ = S_T - K.$$

Le membre de droite est le payoff d'un forward (long) de strike K . En actualisant (ou via chapitre 1), le prix du forward vaut $S_0 e^{-qT} - K e^{-rT}$, d'où (2.2).

Preuve 2 (arbitrage). Si (2.2) est violée, on achète le portefeuille sous-évalué et on vend le sur-évalué : le payoff final est identique, donc le gain initial est certain (arbitrage).

Preuve 3 (mesure risque-neutre). Sous $\mathbb{Q}$, $V_0 = e^{-rT} \mathbb{E}^\mathbb{Q}[X_T]$. En appliquant à $X_T = (S_T - K)^+ - (K - S_T)^+ = S_T - K$ et en utilisant $\mathbb{E}^\mathbb{Q}[S_T] = S_0 e^{(r-q)T}$, on retrouve (2.2).

Sanity check. Quand K augmente, C baisse et P monte ; la différence $C - P$ doit donc baisser linéairement avec K , ce qui est exactement le terme $-K e^{-rT}$ dans (2.2).

2.6.2 Breeden–Litzenberger : de la surface de calls à une densité

Hypothèses. On suppose que $K \mapsto C_0(K, T)$ est deux fois dérivable (au sens distributionnel si besoin) et que l'échange dérivée/espérance est licite.

Dérivation pas à pas. Écrire le call comme espérance actualisée :

$$C_0(K, T) = e^{-rT} \mathbb{E}^\mathbb{Q}[(S_T - K)^+] = e^{-rT} \int_K^{+\infty} (s - K) f_{S_T}^\mathbb{Q}(s) ds.$$

On dérive une fois (Leibniz) :

$$\partial_K C_0(K, T) = -e^{-rT} \int_K^{+\infty} f_{S_T}^\mathbb{Q}(s) ds = -e^{-rT} \mathbb{Q}(S_T \geq K).$$

Puis une seconde fois :

$$\partial_{KK} C_0(K, T) = e^{-rT} f_{S_T}^\mathbb{Q}(K). \quad (2.3)$$

Interprétation. (2.3) dit : la convexité en strike *encode* une densité risque-neutre. En pratique, un call-spread discret approxime $\partial_K C$ (digitale) et une butterfly approxime $\partial_{KK} C$ (densité).

2.6.3 Payoffs convexes et strip de calls

Si Φ est convexe et suffisamment régulière, on peut écrire (heuristique utile) :

$$\Phi(s) = \Phi(0) + \Phi'(0)s + \int_0^{+\infty} (s - K)^+ \Phi''(dK),$$

où Φ'' est interprétée comme une mesure (cas non C^2).

Intuition de marché. Base des *static hedges* : on approxime un payoff exotique (convexe) par un portefeuille de vanilles en strike.

2.7 Pièges classiques / erreurs fréquentes

- Oublier le dividende (ou le « carry ») dans la parité call–put.
- Confondre densité risque-neutre et densité historique : (2.3) parle de $\mathbb{Q}$.
- Obtenir une « densité » négative via $\partial_{KK}C$: signe d'arbitrage statique ou de bruit numérique.
- Discrétiser en strike sans contrôler l'effet du pas (call-spreads/butterflies très bruités).

2.8 Checklist — savoir refaire sans regarder

- Démontrer la parité call–put et l'utiliser pour passer call $\leftrightarrow$ put.
- Justifier monotonie/convexité des prix en strike.
- Dériver Breeden–Litzenberger et l'interpréter (digitale, densité).
- Expliquer/deriver la réplication statique d'un payoff convexe par strip de calls.
- Faire un sanity-check (signes, limites $K \rightarrow 0$ / $\rightarrow \infty$) sur une formule.

Chapitre 3

Pricing discret et mesure risque-neutre

Idée centrale. Le modèle binomial est la première implémentation complète de « pricing sans arbitrage » : réplication, mesure risque-neutre, et backward induction. Il sert de prototype pour arbres, Bermudans, et convergence vers Black-Scholes.

Cadre mathématique.

- **Dynamique.** Sur un pas Δt : $S_{t+\Delta t} = S_t u$ ou $S_t d$.
- **No-arbitrage.** Condition : $d < e^{(r-q)\Delta t} < u$.
- **Probabilité RN.** $p^* = \frac{e^{(r-q)\Delta t} - d}{u - d}$; prix : $V_t = e^{-r\Delta t} \mathbb{E}^{\mathbb{Q}^*}[V_{t+\Delta t} | \mathcal{F}_t]$.
- **Hedge.** $\Delta = (V^u - V^d)/(S^u - S^d)$; cash pour fermer la réplication.

Intuition marché / interprétation. Le discret met en évidence ce qui est « structurel » (numéraire + martingale) vs ce qui est « modèle » (choix u, d). Il montre aussi les limites : hedging discret, frictions, incomplétude dès qu'on ajoute des sources de risque (sauts/vol stoch).

Implémentation.

- Implémenter un arbre CRR (vectorisé) : backward induction, et extraction de Δ à chaque nœud.
- Extensions industrielles : Bermudan (max avec valeur d'exercice), barrières (états absorbants), calibrage simple.

Tests / sanity checks.

- Test no-arbitrage : vérifier $p^* \in (0, 1)$.
- Convergence : prix CRR $\rightarrow$ Black-Scholes quand $N \uparrow$ (pas $\Delta t \downarrow$).
- Limites : $T \downarrow 0$ et $\sigma \downarrow 0$ (prix $\rightarrow$ intrinsic).

Pont vers pratique quant. Pont quant : base des méthodes numériques (arbres), pricing de produits à exercice anticipé, et compréhension opérationnelle du changement de mesure et des greeks (deltas de réplication).

3.1 Avant-propos

3.1.1 Objectifs pédagogiques

- Mettre en place un modèle discret simple (arbre binomial) et en déduire un prix.
- Construire explicitement une réplication (delta + cash) et en tirer la probabilité risque-neutre.
- Comprendre la logique « martingale actualisée » qui anticipe la partie continue (Black-Scholes).

3.1.2 Pré-requis

- Chapitres chapitre 1–chapitre 2.
- Notion de taux sans risque constant sur un pas Δt (on reviendra sur $P(0, T)$ en chapitre 4).

3.1.3 Plan du chapitre

1. Modèle à un pas : condition d'absence d'arbitrage et réplication.
2. Mesure risque-neutre et formule de pricing comme espérance actualisée.
3. Généralisation multi-pas (CRR) et lecture « convergence » vers le continu.

Intuition de marché. Le discret sert souvent de *prototype industriel* : robustesse, contrôle, calibrage simple, et intuition de couverture. Il préfigure aussi des méthodes numériques (arbres, schémas) quand les formules fermées n'existent pas.

3.2 Mesure risque-neutre : l'idée, sans technique

Dans un marché sans arbitrage et suffisamment « bien posé », il existe une mesure $\mathbb{Q}$ telle que

$$V_0 = e^{-rT} \mathbb{E}_{\mathbb{Q}}[\Phi]$$

pour tout payoff Φ *répliquable*.

3.3 Binomial $\rightarrow$ Black–Scholes : dérivation pas à pas

Le binomial est la version « temps discret » la plus pédagogique de l'absence d'arbitrage : on réplique explicitement le payoff sur un pas, puis on itère. Deux messages à retenir :

- la **probabilité risque-neutre** q^* n'est pas une hypothèse statistique : elle vient de la réplication ;
- quand le pas Δt devient petit, l'arbre converge vers une diffusion et on retrouve Black–Scholes.

On déroule d'abord le modèle CRR, puis on explique la limite vers le temps continu.

3.4 Le modèle binomial (CRR) : réplication en temps discret

3.4.1 Un pas de temps : deux états possibles

On se donne un pas Δt . Sur l'intervalle $[t, t + \Delta t]$, on suppose que le sous-jacent suit :

$$S_{t+\Delta t} = \begin{cases} uS_t & (\text{état up}), \\ dS_t & (\text{état down}), \end{cases} \quad 0 < d < u.$$

Le compte sans risque (numéraire) est $B_t = e^{rt}$, donc $B_{t+\Delta t} = e^{r\Delta t} B_t$.

3.4.2 Réplication d'un payoff sur une période

Considérons une option de payoff $V_{t+\Delta t} = \Phi(S_{t+\Delta t})$. On note :

$$V^{(u)} := \Phi(uS_t), \quad V^{(d)} := \Phi(dS_t).$$

On cherche un portefeuille auto-finançant

$$\Pi_t = \Delta S_t + bB_t$$

tel que $\Pi_{t+\Delta t} = V_{t+\Delta t}$ dans les deux états :

$$\Delta u S_t + b e^{r\Delta t} B_t = V^{(u)}, \quad \Delta d S_t + b e^{r\Delta t} B_t = V^{(d)}.$$

En soustrayant, on obtient la **delta discrète** :

$$\Delta = \frac{V^{(u)} - V^{(d)}}{(u - d)S_t}.$$

Le coefficient b se déduit ensuite, et en particulier le prix $V_t = \Pi_t$ s'écrit :

$$V_t = e^{-r\Delta t} \left(q^* V^{(u)} + (1 - q^*) V^{(d)} \right), \quad q^* := \frac{e^{r\Delta t} - d}{u - d}. \quad (3.1)$$

3.4.3 Condition d'absence d'arbitrage

Le modèle binomial est sans arbitrage si et seulement si

$$d < e^{r\Delta t} < u.$$

Dans ce cas $q^* \in (0, 1)$ et s'interprète comme une probabilité.

Remarque 3.1 (Probabilité risque-neutre). La formule (3.1) dit exactement :

$$V_t = e^{-r\Delta t} \mathbb{E}_{\mathbb{Q}}[V_{t+\Delta t} \mid \mathcal{F}_t],$$

où, sous $\mathbb{Q}$, la probabilité d'état up vaut q^* . Le drift historique « réel » n'apparaît pas : le prix est déterminé par la réplication.

3.4.4 Arbre à n périodes : backward induction

En itérant sur n périodes (maturité $T = n\Delta t$), on obtient :

$$V_0 = e^{-rT} \mathbb{E}_{\mathbb{Q}}[\Phi(S_T)]$$

et on calcule numériquement V_0 par **backward induction**. Cette méthode vaut aussi pour l'exercice anticipé (options américaines) en remplaçant l'espérance conditionnelle par un max :

$$V_{t_k} = \max \left(\Phi(S_{t_k}), e^{-r\Delta t} \mathbb{E}_{\mathbb{Q}}[V_{t_{k+1}} \mid \mathcal{F}_{t_k}] \right).$$

3.5 De l'arbre à la diffusion : limite vers Black-Scholes

3.5.1 Choix CRR et ordre de grandeur

Le choix classique Cox-Ross-Rubinstein est :

$$u = e^{\sigma\sqrt{\Delta t}}, \quad d = e^{-\sigma\sqrt{\Delta t}}.$$

Quand $\Delta t \rightarrow 0$, les variations relatives sont d'ordre $\sqrt{\Delta t}$ et la volatilité σ devient le paramètre de fluctuation instantanée.

3.5.2 Limite continue sous $\mathbb{Q}$

On montre (convergence faible) que l'arbre converge vers le mouvement brownien géométrique :

$$dS_t = (r - q)S_t dt + \sigma S_t dW_t^{\mathbb{Q}}. \quad (3.2)$$

La représentation risque-neutre devient alors :

$$V_0 = e^{-rT} \mathbb{E}_{\mathbb{Q}}[\Phi(S_T)].$$

3.6 Mode microscope : arbre binomial, réplication et mesure risque-neutre

3.6.1 Modèle à un pas : calcul complet

Cadre. Sur un pas Δt , l'actif passe de S_0 à

$$S_1 = \begin{cases} S_0 u & (\text{up}), \\ S_0 d & (\text{down}), \end{cases} \quad u > d > 0.$$

Le cash évolue comme $B_1 = B_0(1 + R)$ (ou $B_1 = B_0 e^{r\Delta t}$).

Absence d'arbitrage (condition). On doit avoir $d < 1 + R < u$.

Réplication (système linéaire). Soit un payoff $H(S_1)$, avec $H_u = H(S_0 u)$ et $H_d = H(S_0 d)$. On cherche Δ et b tels que

$$\Delta S_0 u + b(1 + R) = H_u, \quad \Delta S_0 d + b(1 + R) = H_d.$$

Soustraction :

$$\Delta S_0(u - d) = H_u - H_d \quad \Rightarrow \quad \Delta = \frac{H_u - H_d}{S_0(u - d)}.$$

Puis $b = \frac{H_d - \Delta S_0 d}{1 + R}$ et $V_0 = \Delta S_0 + b$.

Mesure risque-neutre. On re-écrit

$$V_0 = \frac{1}{1 + R} (p H_u + (1 - p) H_d), \quad p = \frac{(1 + R) - d}{u - d} \in (0, 1).$$

p est choisi pour que $S/(1 + R)$ soit une martingale.

Sanity check. Si $H(S) = S$ (payoff linéaire), alors $V_0 = S_0$ et on vérifie bien $S_0 = \frac{1}{1 + R} (p S_0 u + (1 - p) S_0 d)$.

Exemple jouet. Exemple jouet : $S_0 = 100$, $u = 1.1$, $d = 0.9$, $R = 2\%$ et un call $K = 100$. $H_u = 10$, $H_d = 0$, $p = (1.02 - 0.9)/(1.1 - 0.9) = 0.6$, donc $V_0 = (1/1.02)(0.6 \cdot 10) = 5.882$.

3.6.2 Lien avec CRR

Dans CRR, $u = e^{\sigma\sqrt{\Delta t}}$ et $d = e^{-\sigma\sqrt{\Delta t}}$. Alors $p = \frac{e^{r\Delta t} - d}{u - d}$.

3.7 Pièges classiques / erreurs fréquentes

- Oublier $d < 1 + R < u$: sinon p *notin* $[0, 1]$ (signe d'arbitrage).
- Confondre probabilités historiques et p risque-neutre : p est une construction de pricing.
- Mélanger dates et actualisation : tout prix au temps 0 doit être actualisé par $1 + R$.

3.8 Checklist — savoir refaire sans regarder

- Résoudre la réplication à un pas et en déduire V_0 .
- Retrouver p et réécrire V_0 comme espérance actualisée.
- Vérifier/justifier la condition d'absence d'arbitrage.
- Calculer un exemple numérique (call/put) et vérifier les ordres de grandeur.

Chapitre 4

Construction de courbes : bootstrap

Idée centrale. Construire une courbe d'actualisation cohérente avec les instruments de marché : obtenir $P(0, T)$ (ou $R(0, T)$) par bootstrap, puis en déduire forwards et greeks de taux.

Cadre mathématique.

- **Objets.** DF $P(0, T)$, taux zéro $R(0, T)$, forwards $F(0; T_1, T_2)$; conventions (day count, compounding).
- **Principe.** Résoudre séquentiellement : chaque nouvel instrument ajoute une inconnue (un DF) et une équation de $PV=0$.
- **Arbitrage.** DF décroissants (taux positifs) n'est pas garanti; on impose cohérence via choix d'interpolation et contrôles.

Intuition marché / interprétation. La courbe est une infrastructure : une petite incohérence produit des PV/greeks instables et des arbitrages numériques. En pratique, multi-curve (OIS discounting, CSA) et conventions dominent le « théorique ».

Implémentation.

- Implémenter un bootstrap séquentiel avec solveur 1D (bissection/Newton); interpoler en log-DF ou taux continus.
- Repricing systématique de tous les instruments d'entrée (contrôle qualité).

Tests / sanity checks.

- Reprice : PV des instruments d'entrée ≈ 0 (dans le bid-ask / tolérance).
- DF : $P(0, T) \in (0, 1]$ et non croissant; forwards plausibles (pas de spikes non justifiés).
- Sensibilité : perturbation d'un quote $\Rightarrow$ variation locale des DF (stabilité).

Pont vers pratique quant. Pont quant : pricing/risk de produits taux (swaps, swaptions), calcul de DV01/CS01, calibration de modèles (Hull-White, HJM) et stress tests de courbe.

4.1 Avant-propos

4.1.1 Objectifs pédagogiques

- Comprendre la relation entre prix, facteurs d'actualisation $P(0, T)$, taux zéro-coupon et forwards.
- Réaliser un bootstrap instrument par instrument (dépôt/FRA/swap si présents) et contrôler la cohérence.
- Discuter interpolation/extrapolation et les points de vigilance (conventions, accrual, day count).

4.1.2 Pré-requis

- Actualisation et absence d'arbitrage (chapitres chapitre 1–chapitre 2).
- Algèbre élémentaire et lecture d'équations linéaires simples.

4.1.3 Plan du chapitre

1. Définitions : $P(0, T)$, taux zéro-coupon, forward rates, conventions.
2. Bootstrap : dépôts puis instruments plus longs (FRA/swaps) et résolution itérative.
3. Interpolation et qualité de courbe (lissage, stabilité, contraintes).

Intuition de marché. La courbe est une *brique transversale* : toute valorisation (options, swaptions, crédit) repose sur $P(0, T)$. Une courbe incohérente produit des arbitrages numériques (PV absurdes) et des greeks instables.

Résumé

Résumé. Ce chapitre présente les techniques de construction de courbes des taux d'intérêt dans le cadre de la valorisation des instruments financiers, en mettant l'accent sur deux approches : la méthode du bootstrap et le modèle de Nelson–Siegel–Svensson. La courbe des taux est un outil essentiel pour l'évaluation théorique des actifs financiers et la gestion de portefeuille. On analyse les défis techniques liés à la construction de courbes, notamment la gestion des dates de paiements, l'extrapolation des données de marché, et la sélection d'instruments financiers en fonction de leur liquidité. On compare également ces résultats aux courbes de taux publiées par la Banque Centrale Européenne (BCE).

Mots-clés – Courbe des taux, Bootstrap, Nelson–Siegel, Svensson, Zéro-coupon, Valorisation d'actifs, Instruments financiers, Modélisation, Finance quantitative, Marchés financiers.

4.2 Introduction

La courbe des taux d'intérêt est un outil fondamental en finance, illustrant la relation entre les taux d'intérêt et les échéances des titres de dette. Elle fournit une représentation graphique du rendement de divers instruments financiers, tels que les obligations, en fonction de leur maturité.




FIGURE 4.1 – Exemple d'une courbe des taux.

Toutefois, il n'existe pas une unique courbe des taux sur les marchés financiers, mais plusieurs, chacune étant spécifique à une catégorie d'instruments. Parmi les courbes les plus couramment utilisées, on distingue :

- la courbe des taux des obligations d'État, qui reflète les rendements des obligations émises par les gouvernements et est souvent considérée comme une référence pour les taux sans risque ;
- la courbe des taux des obligations indexées sur l'inflation, qui ajuste les rendements en fonction de l'inflation, permettant d'évaluer les anticipations de marché en matière d'inflation future ;
- la courbe des taux des swaps, utilisée pour estimer les coûts de financement à long terme et les prévisions de taux d'intérêt, à partir des taux swaps négociés sur les marchés.

Ces courbes jouent un rôle crucial dans diverses applications, allant de la prévision économique à la gestion de portefeuille, en passant par la valorisation théorique d'instruments financiers comme les obligations et les produits dérivés. Ce chapitre se concentre sur ce dernier aspect, dans l'optique de construire un outil générique destiné à la valorisation des actifs financiers, avec un accent particulier sur la courbe des taux zéro-coupon.

La courbe zéro-coupon, qui représente les rendements des obligations zéro-coupon en fonction de leur échéance, est essentielle pour la valorisation théorique des instruments financiers dans un contexte sans arbitrage. Elle peut être obtenue par deux approches distinctes :

- **Approche directe (explicite)** : elle consiste à utiliser directement les taux zéro-coupon cotés sur les marchés financiers, comme ceux des obligations d'État, généralement publiés par les banques centrales ;
- **Approche indirecte (implicite)** : elle permet de déduire les taux zéro-coupon à partir des prix de marché des instruments financiers, nécessitant l'utilisation de méthodes mathématiques et algorithmiques spécifiques.

Il est fondamental d'adapter la courbe des taux à la classe d'actifs étudiée, en prenant en compte des caractéristiques telles que la qualité de crédit, la devise, et les maturités concernées. Bien que certaines courbes des taux soient fournies par des acteurs du marché, elles ne couvrent pas toujours tous les instruments financiers, en particulier ceux des marchés OTC (*Over-The-Counter*). Cela justifie la nécessité d'un outil de

construction de courbes des taux capable de générer des courbes adaptées à chaque instrument ou portefeuille à valoriser.

Dans la pratique de marché, on doit construire des courbes de taux adaptées à des usages variés (valorisation, gestion de portefeuille, calculs réglementaires, etc.). On se place donc dans l'optique de concevoir un outil de construction de courbes suffisamment générique pour couvrir des portefeuilles hétérogènes (assureurs, banques, gestionnaires de fonds, etc.). L'outil doit être extensible, performant en temps de calcul, capable de traiter différents types de données de marché, et flexible dans la génération de courbes continues avec des propriétés analytiques bien définies.

4.3 Méthodologie

On distingue deux approches fondamentales pour la construction des courbes des taux d'intérêt : l'approche directe et l'approche indirecte.

Dans l'approche directe, les données d'entrée comprennent des taux d'intérêt associés à des maturités, désignées sous le terme *tenors*, obtenues à partir de cotations de marché ou de fournisseurs de données (Bloomberg, Reuters, etc.). Un outil de construction de courbes fournit alors une interface permettant de construire une courbe continue en appliquant diverses méthodes d'interpolation, telles que la méthode linéaire sur les taux d'intérêt, les facteurs d'actualisation, ou encore les logarithmes des taux d'intérêt ou des facteurs d'actualisation, ainsi que des méthodes plus avancées comme l'interpolation cubique. En outre, il est possible de calibrer le modèle de Nelson–Siegel ou son extension, le modèle de Svensson.

Bien que cette première approche soit essentielle et disponible dans plusieurs outils commerciaux (par exemple SimCorp Dimension), sa mise en œuvre est relativement simple. Par conséquent, l'accent est mis sur l'exploration et l'analyse des méthodes liées à l'approche indirecte, qui consiste à construire une courbe des taux de manière implicite à partir des cotations de marché.

Concernant l'approche indirecte, deux des méthodes les plus couramment utilisées pour la construction des courbes des taux sont examinées : la méthode du bootstrap et le modèle de Nelson–Siegel. Les données d'entrée incluent des cotations d'instruments financiers tels que les titres de créances négociables, les obligations, les forwards, les futures et les swaps de taux. Il est crucial de noter que l'outil permet de construire une courbe de taux à partir d'un seul type d'instrument ou d'une combinaison des différents types d'instruments mentionnés.

Cette fonctionnalité est particulièrement significative, car elle permet de générer la courbe des taux swap, laquelle est implicitement liée aux taux de dépôts pour le court terme, aux contrats forwards et/ou futures de taux d'intérêt pour le moyen terme, ainsi qu'aux swaps de taux d'intérêt pour le long terme. Face à l'utilisation croissante des OIS (*Overnight Index Swap*) et à l'émergence de nouveaux taux de référence alignés sur les taux overnight (SOFR, STR), cette capacité d'adaptation est essentielle.

Les courbes des taux sont généralement exprimées en taux continus, ce qui facilite les démarches mathématiques et uniformise les notations vis-à-vis des différents types d'instruments. En effet, les titres de créances négociables sont souvent exprimés en taux simples, tandis que les obligations le sont en taux composés. Un outil de construction de courbes fournit une interface permettant d'obtenir directement des courbes en taux simples et en taux composés.

Notons par T la date de maturité d'un titre, par t l'instant présent, et par $P(t; T)$ et $r_s(t; T)$ le prix et le taux zéro-coupon (taux spot) en continu à l'instant t et d'échéance T , respectivement. Le facteur d'actualisation est défini par :

$$df(t; T) = e^{-r_s(t; T)(T-t)}. \quad (1)$$

La différence $T - t$ représente la fraction d'année comprise entre les dates t et T . Cette fraction dépend de la convention de jours appliquée pour la construction de la courbe des taux et peut différer des conventions utilisées pour les instruments fournis en entrée.

4.3.1 La méthode du bootstrap

La méthode dite *bootstrap* consiste à construire une courbe des taux zéro-coupon à partir des cotations de marché d'un ensemble d'instruments financiers. Le principe de cette approche repose sur l'utilisation des taux associés aux maturités courtes pour estimer les taux des maturités plus longues. Cependant, l'application de cette méthode varie en fonction du type d'instruments considérés.

Pour les titres de créances négociables, cotés principalement en termes de taux d'intérêt, on distingue généralement deux types de cotations :

- le taux d'escompte (ou taux précompté, *bank discount rate*) :

$$y_a(t; T) := \frac{M - P(t; T)}{M} \frac{1}{T - t}, \quad (2)$$

où M représente la valeur de remboursement ;

- le taux *in fine* (ou taux du marché monétaire, *money market rate*) :

$$y_m(t; T) := \frac{M - P(t; T)}{P(t; T)} \frac{1}{T - t}. \quad (3)$$

Dans les deux cas, en partant de la valeur temps de l'argent, nous avons :

$$P(t; T) := M \times df(t; T), \quad (4)$$

où $P(t; T)$ est le prix actualisé. Le taux zéro-coupon continu correspondant est alors donné par :

$$r_s(t; T) = -\frac{1}{T - t} \log\left(\frac{P(t; T)}{M}\right). \quad (5)$$

Connaître le prix $P(t; T)$ d'un titre de créance permet d'en déduire directement le taux zéro-coupon implicite. Pour les obligations, on utilise principalement les obligations à coupons, plus liquides que les obligations zéro-coupon. Considérons une obligation de prix $P(t; T)$ (*dirty price*), versant un coupon C aux dates $T_1 < T_2 < \dots < T_{N-1} < T_N = T$ (avec $T_1 > t$) et une valeur de remboursement M . Le prix de l'obligation est alors donné par :

$$P(t; T) = \sum_{n=1}^N C e^{-r_s(t; T_n) (T_n - t)} + M e^{-r_s(t; T) (T - t)}. \quad (6)$$

De cette relation, on peut obtenir le taux zéro-coupon $r_s(t; T)$ de maturité T :

$$r_s(t; T) = -\frac{1}{T - t} \log\left(\frac{P(t; T) - \sum_{n=1}^{N-1} C e^{-r_s(t; T_n) (T_n - t)}}{C + M}\right). \quad (7)$$

Pour les contrats *forward* et *futures* de taux d'intérêt, l'approche est légèrement différente. Supposons un contrat avec date de *fixing* $T_1 > t$ et date d'échéance $T_2 = T$. Le taux du contrat est noté $f(t; T_1, T_2)$ et le facteur d'actualisation associé est défini par :

$$df(t; T_1, T_2) = \begin{cases} \frac{1}{1 + f(t; T_1, T_2) (T_2 - T_1)} & \text{(taux simple),} \\ \frac{1}{\left(1 + \frac{f(t; T_1, T_2)}{m}\right)^m (T_2 - T_1)} & \text{(taux composé),} \\ e^{-f(t; T_1, T_2) (T_2 - T_1)} & \text{(taux continu).} \end{cases} \quad (8)$$

En supposant l'absence d'opportunité d'arbitrage (AOA), nous avons la relation :

$$df(t; T) = df(t; T_1) \times df(t; T_1, T_2), \quad (9)$$

qui permet de déduire le taux zéro-coupon continu :

$$r_s(t; T) = -\frac{1}{T - t} \log(df(t; T_1) df(t; T_1, T_2)). \quad (10)$$

Pour les *futures*, la cotation est exprimée en prix (égal à $100 - f(t; T_1, T_2) \times 100$) et le taux du contrat doit, le cas échéant, être ajusté pour tenir compte de la convexité. Cet ajustement n'est cependant pas toujours nécessaire lorsque la durée de vie du contrat est inférieure à deux ans.

Enfin, pour les swaps de taux, la méthode est similaire à celle des obligations. Les swaps étant cotés au

pair, le taux zéro-coupon peut être exprimé en fonction du taux swap $swp(t; T)$ et des dates de règlement $T_0, T_1, \dots, T_N = T$ comme suit :

$$r_s(t; T) = -\frac{1}{T-t} \log \left(\frac{1 - \sum_{n=1}^{N-1} \Delta_n swp(t; T) e^{-r_s(t; T_n) (T_n - t)}}{1 + \Delta_N swp(t; T)} \right), \quad (11)$$

où $\Delta_n = T_n - T_{n-1}$.

En pratique, il n'est pas toujours possible de trouver des instruments ayant des paiements parfaitement synchronisés au cours de leur durée de vie. La méthode du bootstrap est donc souvent couplée à une méthode d'interpolation, permettant d'estimer les taux zéro-coupon pour des dates intermédiaires non traitées directement. Cette interpolation assure également une continuité de la courbe des taux et garantit une régularité suffisante pour un usage économique et financier.

4.4 Défis techniques et résultats numériques

4.4.1 Gestion des dates de paiement

L'un des principaux défis dans la construction d'une courbe des taux est la gestion correcte des dates de paiement des flux de trésorerie. Ces dates dépendent de plusieurs facteurs : le calendrier du marché, la convention de base (*day count convention*) et la convention de paiement (*settlement date convention*). De plus, les dates de maturité fournies par les utilisateurs ne sont généralement pas exprimées sous forme de dates précises mais en termes de *tenors* (jours, mois, années). L'exactitude des dates de paiement est cruciale, car un décalage dans les dates des paiements se traduit par un décalage équivalent sur la courbe des taux obtenue.

Afin de simplifier cette gestion pour les utilisateurs, une interface permet de générer automatiquement les dates de paiement en fonction des choix de calendrier, de convention de base et de convention de paiement. Une bibliothèque de calendriers de marché et de conventions de base est disponible, regroupant les options les plus courantes. Concernant les conventions de paiement, l'outil prend en charge les quatre principales conventions utilisées sur le marché : *following*, *modified following*, *preceding* et *modified preceding*.

4.4.2 Méthode du bootstrap et extrapolation

La méthode classique de bootstrap repose sur l'hypothèse que pour déterminer le taux zéro-coupon à une échéance T_n , les taux zéro-coupon nécessaires ont des maturités comprises entre T_1 et T_{n-1} et peuvent être obtenus par interpolation sur l'intervalle $[T_{i-1}, T_i]$, $1 \leq i \leq n-1$. Cependant, dans la pratique, les instruments disponibles ne respectent pas toujours cette condition : il arrive que certaines dates de paiement se situent dans l'intervalle (T_{n-1}, T_n) .

Dans ce cas, une solution naïve serait d'extrapoler la courbe en utilisant le taux à T_{n-1} , mais cette approche introduit une forte dépendance à la position des nœuds d'extrapolation, rendant la courbe instable. Pour atténuer cette dépendance, une alternative fondée sur l'optimisation suppose la courbe constante sur l'intervalle $(T_{n-1}, T_n]$ et résout le problème (de type Newton) à chaque étape pour déterminer le taux zéro-coupon à l'échéance T_n .

Tenors	Taux Swap	Fréquence
1M	1,8%	Mensuelle
3M	2,0%	Trimestrielle
6M	2,2%	Bisannuelle
12M	2,5%	Annuelle
2Y	3,0%	Trimestrielle
5Y	4,0%	Trimestrielle

TABLE 4.1 – Données d'entrée pour la construction d'une courbe de taux swap. Source.

Comme illustré dans le tableau ci-dessus, l'extrapolation est nécessaire pour certains tenors intermédiaires tels que 15, 18 et 21 mois pour le taux zéro-coupon de 2 ans, ainsi que pour d'autres tenors intermédiaires pour

le taux zéro-coupon de 5 ans. La figure 4.2 présente la courbe des taux obtenue à l'aide de cette méthode modifiée.




FIGURE 4.2 – Courbe des taux zéro-coupon obtenue avec la méthode bootstrap modifiée.

4.4.3 Méthode du bootstrap et cas des tenors multiples

Lorsque les données en entrée contiennent des instruments avec des échéances identiques (tenors multiples), se pose la question du choix des instruments à utiliser. Ce choix est crucial, car les instruments diffèrent souvent par leur liquidité, influençant ainsi la courbe des taux via la prime de liquidité. Un algorithme de sélection basé sur une minimisation d'erreur peut être utilisé : pour chaque échéance, l'instrument choisi est celui qui minimise l'erreur d'approximation des prix pour les instruments de même maturité.

Instrument	Tenor	Taux (%)	Intérêt	Fréquence
Deposit	1W	0,2062	Simple	A
Deposit	1M	0,2963	Simple	A
Deposit	2M	0,4282	Simple	A
Deposit	3M	0,5805	Simple	A
Deposit	6M	0,50435	Simple	A
Futures	6M	0,5600	Composé	Q
Futures	9M	0,6000	Composé	Q
Futures	12M	0,6300	Composé	Q
Futures	15M	0,6550	Composé	Q
Futures	18M	0,6500	Composé	Q
Futures	21M	0,6700	Composé	Q
Futures	2Y	0,6600	Composé	Q
Swaps	2Y	0,6490	Composé	S
Swaps	3Y	0,7550	Composé	S
Swaps	4Y	0,9560	Composé	S
Swaps	5Y	1,1960	Composé	S

TABLE 4.2 – Données d'entrée pour la construction d'une courbe de taux swap avec instruments multiples. Source.

Dans ce tableau, on constate que deux instruments existent pour les tenors de 6 mois et 2 ans. L'algorithme sélectionne le dépôt pour 6 mois et le swap pour 2 ans, comme le montre la figure 4.3.




FIGURE 4.3 – Courbe des taux zéro-coupon obtenue avec la méthode de sélection des instruments.

4.5 Mode microscope : facteurs d'actualisation et bootstrap instrument par instrument

4.5.1 Définitions utiles (et conversions)

Facteur d'actualisation. $P(0, T)$ est le prix aujourd'hui d'un zéro-coupon payant 1 à T .

Taux zéro-coupon. Selon convention :

- capitalisation continue : $P(0, T) = \exp(-R(0, T)T)$;
- capitalisation simple : $P(0, T) = \frac{1}{1 + R^{simp}(0, T)T}$.

On privilégie la convention continue pour la lisibilité des dérivations.

Forward rate. Pour $0 < T_1 < T_2$, le taux forward simple $F(0; T_1, T_2)$ (sur l'année fractionnaire δ) vérifie :

$$1 + \delta F(0; T_1, T_2) = \frac{P(0, T_1)}{P(0, T_2)}.$$

Sanity check. Toujours vérifier : $P(0, 0) = 1$; $P(0, T) > 0$; et, si les taux sont « normaux », $P(0, T)$ décroît en T .

4.5.2 Bootstrap : dépôts puis swaps (schéma type)

Dépôt. Un dépôt à maturité T (accrual δ) cote un taux $L(0, T)$. Sous compounding simple :

$$P(0, T) = \frac{1}{1 + \delta L(0, T)}.$$

Swap par (cas simplifié). Un swap payer-fixe / recevoir-flottant de maturité T_n et taux fixe par $S(0, T_n)$ a valeur nulle à l'origine. Dans un cadre mono-courbe simplifié, on obtient l'équation :

$$1 - P(0, T_n) = S(0, T_n) \sum_{i=1}^n \delta_i P(0, T_i).$$

Si $P(0, T_1), \dots, P(0, T_{n-1})$ sont déjà connus, on isole $P(0, T_n)$:

$$P(0, T_n) = \frac{1 - S(0, T_n) \sum_{i=1}^{n-1} \delta_i P(0, T_i)}{1 + S(0, T_n) \delta_n}.$$

Exemple jouet. Exemple jouet : dépôts donnent $P(0, 0.5) = 0.98$. Un swap 1 an ($\delta_1 = \delta_2 = 0.5$) cote $S = 4\%$. Alors $P(0, 1) = \frac{1 - 0.04 \cdot 0.5 \cdot 0.98}{1 + 0.04 \cdot 0.5} \approx 0.961$.

Intuition de marché. Le bootstrap est une résolution *triangulaire* : chaque instrument apporte une équation, et on avance maturité par maturité. C'est robuste, mais sensible aux conventions (day count, calendrier, accrual).

4.6 Pièges classiques / erreurs fréquentes

- Oublier les conventions : δ (day count) et dates exactes sont au cœur des équations.
- Mélanger simple/continu sans conversion explicite.
- Interpoler directement les taux (plutôt que $\ln P$) et obtenir des $P(0, T)$ non monotones.
- Utiliser un instrument (swap) avec une équation incohérente (mauvais signe, mauvais accrual).

4.7 Checklist — savoir refaire sans regarder

- Convertir $P(0, T) \leftrightarrow R(0, T)$ et $P(0, T_1), P(0, T_2) \rightarrow F(0; T_1, T_2)$.
- Faire un bootstrap itératif (dépôt puis swap) et contrôler $P(0, T) > 0$.
- Expliquer l'impact des conventions (accrual/day count) sur les équations.
- Faire un exemple jouet de bout en bout et vérifier la cohérence.

Chapitre 5

Nelson–Siegel–Svensson : modèle et calibration

Idée centrale. NSS est un paramétrage lisse de la courbe des taux : un fit compact (quelques paramètres) pour interpoler/extrapoler $y(T)$ et les forwards, utile pour risk et scénarios.

Cadre mathématique.

- **Forme.** Niveau + pente + 1–2 composantes de courbure ; dépend de paramètres d'échelle τ .
- **Calibration.** Problème non linéaire (moindres carrés) : choix de la cible (prix, taux, forwards) et pondérations.
- **Contraintes.** Plausibilité ($P(0, T) > 0$), régularité, stabilité (identifiabilité des τ).

Intuition marché / interprétation. Un fit paramétrique est un compromis : lisse et stable, mais pas « arbitrage-free » par construction. Les extrapolations (long terme) sont sensibles aux contraintes et à l'initialisation.

Implémentation.

- Implémenter une NLLS avec bornes (sur τ) et régularisation légère ; initialiser via une courbe bootstrap.
- Calculer $P(0, T)$ via intégration du taux instantané / log-DF, puis repricer les instruments (boucle QC).

Tests / sanity checks.

- Reprice : erreur de calibration dans les tolérances (bid-ask / pondérations).
- Sensibilité : stress des quotes $\Rightarrow$ paramètres et forwards stables (pas de sur-réaction).
- Limites : comportement $T \rightarrow 0$ et $T \rightarrow \infty$ (pas d'explosion / signe absurde).

Pont vers pratique quant. Pont quant : génération de scénarios de courbe (stress macro), compression de risque (facteurs niveau/pente/courbure), et initialisation/regularisation de calibrations plus riches.

5.1 Avant-propos

5.1.1 Objectifs pédagogiques

- Introduire un paramétrage lisse de courbe (Nelson–Siegel–Svensson) et comprendre sa forme.
- Interpréter les paramètres (niveau, pente, courbures) et leurs effets sur $y(T)$ et $f(T)$.
- Mettre en place une calibration (objectif, régularisation simple, stabilité numérique).

5.1.2 Pré-requis

- Chapitre chapitre 4 (définitions de $P(0, T)$ et des taux dérivés).
- Minimisation numérique élémentaire (au moins l'idée « minimiser une somme des carrés »).

5.1.3 Plan du chapitre

1. Forme NSS et passage « taux $\rightarrow$ forward ».
2. Calibration : choix de l'objectif (prix vs rendements), contraintes et initialisation.
3. Interprétation économique et contrôles (limites, régularité, extrapolation).

Sanity check. Un paramétrage doit rester *plausible* : $P(0, T) > 0$, pas d'explosion sur le long terme, et une forme de courbe interprétable (niveau, pente, bosse) compatible avec les données.

5.2 La méthode Nelson–Siegel et l'extension de Svensson

Le modèle de Nelson–Siegel est un modèle paramétrique permettant de construire une courbe des taux régulière en reproduisant les mouvements observés sur l'ensemble de la courbe, plutôt que de simplement interpoler les taux d'intérêt. Ce modèle, introduit en 1987 par Nelson et Siegel, propose que la structure par terme complète de la courbe des taux forward instantanés puisse être modélisée par :

$$F(t; T) := \beta_0 + \beta_1 e^{-\frac{T-t}{\tau_1}} + \beta_2 \left(\frac{T-t}{\tau_1} \right) e^{-\frac{T-t}{\tau_1}}, \quad (12)$$

où $\beta_0, \beta_1, \beta_2$ et τ_1 sont des paramètres. Une étude menée par Roncalli, utilisant l'analyse en composantes principales (ACP), a montré que les facteurs β_1 et β_2 expliquent plus de 98% de la variance totale.

En utilisant la relation entre les taux zéro-coupon et les taux forward instantanés

$$r_s(t; T) := \frac{1}{T-t} \int_t^T F(t; s) ds, \quad (13)$$

le taux zéro-coupon pour toute maturité $T > t$ est donné par :

$$r_s(t; T) = \beta_0 + \beta_1 \frac{1 - e^{-\frac{T-t}{\tau_1}}}{\frac{T-t}{\tau_1}} + \beta_2 \left(\frac{1 - e^{-\frac{T-t}{\tau_1}}}{\frac{T-t}{\tau_1}} - e^{-\frac{T-t}{\tau_1}} \right). \quad (14)$$

Empiriquement, les paramètres sont interprétés comme suit :

- β_0 : niveau moyen de la courbe (généralement plat) ;
- β_1 : facteur de pente, influençant les inversions de la courbe autour d'un point ;
- β_2 : facteur de courbure ;
- τ_1 : paramètre d'échelle.

Les paramètres du modèle sont obtenus par calibration en minimisant la fonction objectif :

$$E_{\text{NS}}(N; \beta, \tau_1) := \left(\sum_{n=1}^N (e_n^{\text{NS}}(\beta; \tau_1))^2 \right)^{\frac{1}{2}}. \quad (15)$$

Pour une approche directe (où les données d'entrée sont des taux zéro-coupon), l'erreur individuelle est définie par :

$$e_n^{\text{NS}}(\beta; \tau_1) := r_s^{\text{NS}}(t; T_n) - r_s(t; T_n). \quad (16)$$

L'optimisation est linéaire par rapport à $\beta = (\beta_0, \beta_1, \beta_2)$ et non linéaire par rapport à τ_1 . Une méthode classique consiste à fixer τ_1 , puis à résoudre pour β via une régression des moindres carrés ordinaires (MCO). Le paramètre τ_1 est ensuite ajusté par itérations successives jusqu'à convergence.

Dans une approche indirecte (où les données d'entrée incluent des instruments comme les obligations ou les swaps), les erreurs individuelles prennent des formes plus complexes, par exemple :

- pour les titres de créances négociables :

$$e_n^{\text{NS}}(\beta; \tau_1) := r_s^{\text{NS}}(t; T_n) + \frac{1}{T_n - t} \log \left(\frac{P(t; T_n)}{M} \right), \quad (17)$$

— pour les swaps de taux :

$$e_n^{\text{NS}}(\beta; \tau_1) := r_s^{\text{NS}}(t; T_n) + \frac{1}{T_n - t} \log \left(\frac{1 - \sum_{k=1}^{N-1} \Delta_k \text{swp}(t; T_n) e^{-r_s(t; T_k) (T_k - t)}}{1 + \Delta_N \text{swp}(t; T_n)} \right). \quad (18)$$

Ces erreurs non linéaires requièrent l'utilisation de méthodes de moindres carrés non linéaires, elles-mêmes itératives.

Cependant, le modèle de Nelson–Siegel présente certaines limitations : il ne parvient pas toujours à reproduire toutes les formes de courbes de taux observées sur les marchés financiers, en particulier celles comportant plusieurs bosses ou creux. Pour pallier ces limitations, Svensson [?] a proposé une extension en ajoutant deux nouveaux paramètres β_3 et τ_2 :

$$F(t; T) = \beta_0 + \beta_1 e^{-\frac{T-t}{\tau_1}} + \beta_2 \left(\frac{T-t}{\tau_1} \right) e^{-\frac{T-t}{\tau_1}} + \beta_3 \left(\frac{T-t}{\tau_2} \right) e^{-\frac{T-t}{\tau_2}}. \quad (19)$$

Le taux zéro-coupon correspondant est alors :

$$r_s(t; T) = \beta_0 + \beta_1 \frac{1 - e^{-\frac{T-t}{\tau_1}}}{\frac{T-t}{\tau_1}} + \beta_2 \left(\frac{1 - e^{-\frac{T-t}{\tau_1}}}{\frac{T-t}{\tau_1}} - e^{-\frac{T-t}{\tau_1}} \right) + \beta_3 \left(\frac{1 - e^{-\frac{T-t}{\tau_2}}}{\frac{T-t}{\tau_2}} - e^{-\frac{T-t}{\tau_2}} \right). \quad (20)$$

L'ajout des paramètres β_3 et τ_2 offre une plus grande flexibilité, permettant de modéliser des courbes présentant plusieurs bosses. Le processus de calibration suit une démarche similaire à celle du modèle de Nelson–Siegel, mais nécessite l'optimisation de six paramètres au lieu de quatre. Cette extension a été adoptée par plusieurs banques centrales.

Contrairement à la méthode du bootstrap, qui requiert une interpolation pour obtenir une courbe continue, le modèle de Nelson–Siegel–Svensson génère une courbe régulière, sans nécessiter d'interpolation supplémentaire.

5.3 Reproduction de la courbe de la BCE

Enfin, nous validons l'implémentation du modèle de Nelson–Siegel–Svensson (NSS) en reproduisant la courbe des taux de la Banque Centrale Européenne (BCE) pour les obligations notées AAA du 27 mars 2024. Les paramètres calibrés pour le modèle NSS sont indiqués dans le tableau 5.1, et la courbe des taux obtenue est montrée dans la figure 5.1. Pour comparaison, le modèle Nelson–Siegel standard est également calibré.

Paramètre	β_0	β_1	β_2	β_3	τ
Valeur	0.0180	-0.0230	0.0041	0.0031	0.680

TABLE 5.1 – Paramètres calibrés pour le modèle NSS à partir des données BCE.




FIGURE 5.1 – Courbe des taux de la BCE (en bleu) et courbe NSS (en rouge) obtenue à partir des données obligataires du 27 mars 2024.

5.4 Conclusion

Ce chapitre a exploré la construction de courbes des taux d'intérêt, en mettant en évidence l'importance de ces courbes dans la valorisation des instruments financiers. On a présenté les deux approches fondamentales : l'approche directe, qui utilise des taux zéro-coupon cotés sur le marché, et l'approche indirecte, qui repose sur des méthodes telles que la méthode du bootstrap et le modèle de Nelson–Siegel.

Un outil de construction de courbes des taux, conçu pour être flexible et adaptable, permet de générer des courbes adaptées à divers types d'instruments et à différentes conditions de marché. Cette capacité d'adaptation est cruciale dans un environnement financier en constante évolution, où la gestion efficace des risques et la conformité réglementaire sont des enjeux majeurs.

En prolongement, on pourrait explorer des méthodes d'optimisation supplémentaires, notamment en intégrant des modèles stochastiques avancés et des techniques d'apprentissage automatique, afin d'améliorer encore la précision et l'efficacité de la construction des courbes des taux d'intérêt.

5.5 Mode microscope : NSS, forwards et calibration

5.5.1 Forme NSS et limites

Rappel (notation). On paramètre souvent un taux zéro-coupon (ou un rendement) $y(T)$ par

$$y(T) = \beta_0 + \beta_1 \frac{1 - e^{-T/\tau_1}}{T/\tau_1} + \beta_2 \left(\frac{1 - e^{-T/\tau_1}}{T/\tau_1} - e^{-T/\tau_1} \right) + \beta_3 \left(\frac{1 - e^{-T/\tau_2}}{T/\tau_2} - e^{-T/\tau_2} \right).$$

Limites utiles.

- Quand $T \rightarrow \infty$, les exponentielles s'éteignent et $y(T) \rightarrow \beta_0$ (niveau long terme).
- Quand $T \downarrow 0$, $(1 - e^{-T/\tau})/(T/\tau) \rightarrow 1$, donc $y(0^+) \approx \beta_0 + \beta_1$.

Sanity check. Des τ extrêmes (très petits ou très grands) signalent souvent une instabilité numérique ou un sur-ajustement.

5.5.2 Du taux $y(T)$ au forward instantané $f(T)$

Identité clé. En convention continue, $P(0, T) = \exp(-Ty(T))$. Le forward instantané est $f(T) = -\partial_T \ln P(0, T) = y(T) + Ty'(T)$.

Dérivation pas à pas. $\ln P(0, T) = -Ty(T)$. Donc

$$f(T) = -\partial_T \ln P(0, T) = -\partial_T (-Ty(T)) = y(T) + Ty'(T).$$

Sous NSS, on dérive terme à terme (fonctions explicites) : on obtient une expression analytique de $f(T)$.

Exemple jouet. Exemple jouet : si $y(T) \equiv y_0$ constant, alors $f(T) = y_0$ (courbe plate).

5.5.3 Calibration : objectif, contraintes, stabilité

Objectif. On peut calibrer sur des rendements $y^{mkt}(T_i)$:

$$\min_{\theta} \sum_i w_i (y(T_i; \theta) - y^{mkt}(T_i))^2, \quad \theta = (\beta_0, \beta_1, \beta_2, \beta_3, \tau_1, \tau_2),$$

ou sur des prix (via $P(0, T)$).

Contraintes. $\tau_1, \tau_2 > 0$; en pratique on borne aussi ces paramètres.

Intuition de marché. NSS sert souvent à lisser une courbe issue d'un bootstrap bruité. Le compromis est clair : trop flexible $\Rightarrow$ sur-ajustement ; trop rigide $\Rightarrow$ biais.

5.6 Pièges classiques / erreurs fréquentes

- Calibrer sur des rendements sans contrôler les conventions (continu vs simple) : mismatch systématique.
- Sur-ajuster : courbe ondulante, forwards instables (mauvais pour greeks/stress tests).
- Mauvaise initialisation : convergence vers un minimum local.
- Oublier les contraintes $\tau > 0$ et des bornes numériques raisonnables.

5.7 Checklist — savoir refaire sans regarder

- Écrire NSS et en déduire ses limites $T \rightarrow 0$ et $T \rightarrow \infty$.
- Passer de $y(T)$ à $P(0, T)$ puis à $f(T)$.
- Monter une calibration LS (sur rendements ou prix) avec contraintes simples.
- Faire un sanity-check : $P(0, T) > 0$, pas d'explosion, paramètres interprétables.

Chapitre 6

Synthèse quant (Partie II) : arbitrage statique, discret, courbe

6.1 Idée centrale (ce que tu dois être capable d'expliquer en 60 secondes)

Un prix sans arbitrage est une **valeur actuelle** : à maturité fixée, une option est un *fonctionnel convexe* du strike et encode une **densité risque-neutre** ; sur la courbe, tout se ramène à des **discount factors** cohérents. Le discret (binomial) est le laboratoire : **réplication** $\Rightarrow$ mesure martingale $\Rightarrow$ prix.

6.2 Cadre mathématique (propre, standard)

6.2.1 Numéraire, actualisation, mesure

Numéraire cash $B_t = \exp\left(\int_0^t r_s ds\right)$ (ou taux constant $r : B_t = e^{rt}$). En absence d'arbitrage (marché raisonnable), il existe une mesure $\mathbb{Q}$ telle que les prix actualisés soient des martingales :

$$\frac{S_t}{B_t} \text{ est une } \mathbb{Q}\text{-martingale} \quad (\text{ajuster par } q \text{ si dividendes}).$$

$$\text{Pricing général : } V_0 = \mathbb{E}^{\mathbb{Q}}\left[\frac{\Phi}{B_T}\right].$$

6.2.2 Surface de call $C(K, T)$ et arbitrage statique

En strike K (maturité T fixée). Conditions minimales (continu) :

$$0 \leq C(K) \leq S_0, \quad C'(K) \leq 0, \quad C''(K) \geq 0, \quad \lim_{K \rightarrow \infty} C(K) = 0,$$

et borne intrinsèque : $C(K) \geq (S_0 e^{-qT} - K e^{-rT})^+$.

En maturité T (strike K fixé). Monotonie (calendar spread) : $T_1 < T_2 \Rightarrow C(K, T_1) \leq C(K, T_2)$ en single-curve sans frictions. En pratique, on vérifie aussi la cohérence des forwards (carry) et des conventions de dividendes.

Breeden–Litzenberger (densité). Sous régularité :

$$\partial_{KK} C(K, T) = e^{-rT} f_{S_T}^{\mathbb{Q}}(K), \quad \partial_K C(K, T) = -e^{-rT} \mathbb{Q}(S_T > K).$$

Donc **convexité** $\Leftrightarrow$ densité ≥ 0 .

6.3 Discret : binomial (ce qu'on attend en entretien)

6.3.1 Risque-neutre et réplication

Un pas : $S_T \in \{S_0 u, S_0 d\}$, $B_T = 1 + r$. Absence d'arbitrage : $d < 1 + r < u$ et

$$p^* = \frac{(1+r) - d}{u - d}, \quad \mathbb{E}^{\mathbb{Q}} \left[\frac{S_T}{B_T} \right] = S_0.$$

Réplication : pour payoff Φ_u, Φ_d ,

$$\Delta = \frac{\Phi_u - \Phi_d}{S_0(u - d)}, \quad \beta = \frac{u\Phi_d - d\Phi_u}{(u - d)(1 + r)}.$$

6.3.2 Américaines : lecture Snell

En discret, américaine = enveloppe de Snell : valeur = max(exercice, continuation) par backward induction.
Message d'entretien : **arbre** = robuste, rapide, *frontière* visible.

6.4 Courbe des taux : bootstrap (et ce qui compte en pratique)

6.4.1 Objets

Discount factors $P(0, T)$, zéro-rates $R(0, T)$ via $P(0, T) = e^{-R(0, T)T}$, forwards :

$$F(0; T_1, T_2) = \frac{P(0, T_1)}{P(0, T_2)} \quad (\text{continu : } f(0, t) = -\partial_t \ln P(0, t)).$$

6.4.2 Bootstrap (par swaps)

Parité (single-curve) : $PV_{\text{float}} = PV_{\text{fix}}$. Avec accruals α_k et dates T_k :

$$S^{\text{par}} \sum_{k=1}^n \alpha_k P(0, T_k) = 1 - P(0, T_n),$$

et si $P(0, T_1), \dots, P(0, T_{n-1})$ connus, on isole $P(0, T_n)$ (récurrence).

Multi-curve (post-2008). Discounting souvent OIS ; projection des cashflows via courbe(s) IBOR. En entretien : citer **basis**, conventions, et que « un seul r » est une approximation.

6.5 NSS : calibration stable (réflexes)

Paramétrisation : niveau long terme, pente, courbures, échelles τ_1, τ_2 . Bonnes pratiques :

- calibrer sur **prix** (ou sur vols/yields selon usage), avec poids (liquidité) ;
- contraindre τ (bornes) et régulariser (pénaliser oscillations du forward) ;
- diagnostiquer : discount factor décroissant, forwards plausibles, sensibilité des params.

6.6 Implémentation (checklist)

6.6.1 Tests d'arbitrage en strike (différences finies)

```
import numpy as np

def check_call_static_arbitrage(K, C):
```

```

K = np.asarray(K); C = np.asarray(C)
order = np.argsort(K)
K, C = K[order], C[order]
mono = np.all(np.diff(C) <= 1e-10)          # decreasing in K
# discrete convexity: second differences >= 0 on uniform-ish grid
d2 = C[:-2] - 2*C[1:-1] + C[2:]
convex = np.all(d2 >= -1e-10)
return mono, convex

```

6.6.2 Bootstrap (récurrence simple)

```

def bootstrap_discount_from_par_swap(alpha, S_par, P_prev):
    # alpha: accruals for fixed leg up to T_n (length n)
    # P_prev: discount factors P(0, T_1..T_{n-1})
    # solve: S_par * sum_{k=1}^n alpha_k P_k = 1 - P_n
    alpha = np.asarray(alpha)
    P_prev = np.asarray(P_prev)
    rhs = 1.0 - S_par * np.sum(alpha[:-1] * P_prev)
    P_n = rhs / (1.0 + S_par * alpha[-1])
    return P_n

```

6.7 Pitfalls (ce qui fait perdre des points)

- Confondre **forward price** F_0 (contrat à valeur nulle) et **valeur** d'un forward existant.
- Oublier dividendes/ q (carry) dans put-call parity et dans le drift sous $\mathbb{Q}$.
- Construire une courbe qui viole $P(0, T)$ décroissante (ou forward explosif) à cause de poids/quotes incohérentes.
- Sur-ajuster NSS : excellent fit, mauvais forward (oscillations), instabilité des paramètres.

6.8 Sanity checks (3–6 rapides)

- $P(0, 0) = 1$, $P(0, T)$ décroissant, $0 < P(0, T) \leq 1$ (en taux positifs).
- $C(K)$ décroissant et convexe ; limites $K \rightarrow 0$ et $K \rightarrow \infty$.
- Densité extraite ≥ 0 et intègre à 1 (numérique : approx).
- Forward rate cohérent avec les quotes (repricing error).

Interview Pack — Partie III (core)

Fondations stochastiques (variation quadratique $\rightarrow$ Itô)

Table des matières

1	Variation quadratique	1
1.1	Avant-propos : pourquoi la variation quadratique est le vrai « début » du calcul stochastique	1
1.2	Introduction : pourquoi un nouveau calcul ?	2
1.3	Préliminaires : probabilités, temps continu, ordres de grandeur	3
1.4	Variation quadratique : définition, exemples, propriétés	4
1.5	Mode microscope : pourquoi $[W]_t = t$?	9
1.6	Pièges classiques / erreurs fréquentes	9
1.7	Checklist — savoir refaire sans regarder	9
2	Intégrale et lemme d'Itô (version canonique)	11
2.1	Avant-propos : construire l'intégrale d'Itô et la formule d'Itô	11
2.2	Intégrale d'Itô : motivation et construction (niveau cours)	12
2.3	Du crochet au lemme d'Itô : dérivation pas à pas	16
2.4	Applications en finance quantitative	20
2.5	Annexes techniques (preuves et compléments)	24
2.6	Mode microscope : construire Itô et dériver la formule	26
2.7	Pièges classiques / erreurs fréquentes	27
2.8	Checklist — savoir refaire sans regarder	27
3	Toolbox entretien : martingales, changements de mesure, identités	28
3.1	Idée centrale	28
3.2	Identities à connaître (et à utiliser)	28
3.3	Girsanov (multi-dim, version « desk-ready »)	29
3.4	Changement de numéraire (résumé)	29
3.5	Localisation : comment sauver une preuve	29
3.6	Arrêts : optional sampling (ce qu'il faut dire proprement)	30
3.7	Local time et Itô–Tanaka (utile sur digitals/barrières)	30
3.8	Dambis–Dubins–Schwarz (time change : « trick »)	30
3.9	Sanity checks de calcul stochastique	30
3.10	Implémentation : deux checks rapides (simulation)	30
3.11	Pièges classiques (interview)	30
4	Applications entretien : Girsanov, Feynman–Kac, simulation	31
4.1	Girsanov : passer du drift historique au drift risque-neutre	31
4.2	Feynman–Kac : PDE $\leftrightarrow$ espérance conditionnelle	32
4.3	Simulation : Euler, biais, diagnostics	32
4.4	Ce qu'on te demandera (format entretien)	32

Chapitre 1

Variation quadratique

Idée centrale. La variation quadratique est l'objet qui distingue « trajectoires lisses » et « diffusives » : elle explique le terme d'Itô et relie directement modèles diffusions et données (variance réalisée).

Cadre mathématique.

- **Définition.** Sur une partition π de $[0, t]$: $[X]_t = \lim_{\|\pi\| \rightarrow 0} \sum_{[u,v] \in \pi} (X_v - X_u)^2$ (au sens précisé).
- **Brownien.** $[W]_t = t$; processus de variation finie $\Rightarrow [X]_t = 0$.
- **Covariation.** $[X, Y]_t = \frac{1}{4}([X + Y]_t - [X - Y]_t)$ (polarisation) ; clé pour Itô multidimensionnel.

Intuition marché / interprétation. En pratique, $[X]_t$ est *mesurable* (via haute fréquence) alors que la variance instantanée ne l'est pas. Les pièges viennent du bruit microstructure et du choix de pas.

Implémentation.

- Estimer la variance réalisée : $\sum (\Delta \log S)^2$ avec choix de sampling (5min/1min) ; variantes robustes (sub-sampling).
- Diagnostiquer microstructure : la variance réalisée explose quand le pas devient trop petit (signature plot).

Tests / sanity checks.

- Signature plot : RV vs fréquence doit se stabiliser sur une zone (sinon bruit).
- Scaling Brownien : $\text{Var}(\Delta W) \propto \Delta t$; vérifier numériquement sur simulation.
- Additivité : $[X]_{t+s} - [X]_t$ dépend des incréments sur $(t, t+s]$ (check de mise en œuvre).

Pont vers pratique quant. Pont quant : realized vol/variance swaps, construction de greeks de variance, calibrations (vol local/stoch) et fondation technique de l'intégrale/lemme d'Itô.

1.1 Avant-propos : pourquoi la variation quadratique est le vrai « début » du calcul stochastique

Jusqu'ici, on a surtout fait du *pricing* à partir de relations d'absence d'arbitrage et de raisonnements discrets (arbre binomial, réplication à dates fixes, etc.). Pour passer au temps continu, on veut pouvoir écrire des dynamiques du type

$$dS_t = \mu_t dt + \sigma_t dW_t$$

et manipuler des différentielles *sans* faire d'erreurs de calcul.

1.1.1 Pourquoi ce chapitre est un pivot

L'idée centrale est simple mais radicale : une trajectoire de brownien est continue, mais *pas* suffisamment régulière pour que le calcul différentiel classique fonctionne. Ce n'est pas un détail technique : c'est exactement ce qui force l'apparition du terme $\frac{1}{2}f''$ dans la formule d'Itô, et donc (plus tard) dans la PDE de Black-Scholes.

Interprétation marché. Dans la pratique de marché, la variation quadratique est la quantité qui se *mesure* : la somme des carrés des rendements à haute fréquence (variance réalisée) estime l'intégrale de la variance instantanée. C'est le lien direct entre « modèle diffusive » et « données ».

1.1.2 Objectifs pédagogiques (niveau granulaire)

- Comprendre la définition via partitions, et distinguer clairement convergence en probabilité vs presque sûre.
- Savoir expliquer pourquoi une trajectoire lisse a un crochet nul, tandis que le brownien a $[W]_t = t$.
- Construire la covariation $[X, Y]$ et savoir utiliser la polarisation.
- Faire le lien financier : variance réalisée, ordre de grandeur, et premier check de cohérence.

1.1.3 Pré-requis

- Probabilités de base : espérance, variance, moments gaussiens, indépendance.
- Convergences : en probabilité et (au moins intuitivement) presque sûre.
- Brownien : incréments indépendants centrés, $\text{Var}(W_t - W_s) = t - s$.

1.1.4 Plan du chapitre (ce que l'on veut savoir refaire)

1. Définition de $[X]_t$ et décodage de ce que signifie « passer à la limite » sur des partitions.
2. Deux cas pivot : variation finie $\Rightarrow$ crochet nul, brownien $\Rightarrow [W]_t = t$.
3. Covariation, règles de calcul, et interprétation « variance cumulée ».

Sanity check. Si on retient une seule phrase : *pour un brownien, les incréments sont d'ordre $\sqrt{\Delta t}$, donc leurs carrés sont d'ordre Δt et s'accumulent.*

Résumé

Ces notes construisent, *from ground up*, les deux objets qui rendent le calcul stochastique possible : la *variation quadratique* et le *lemme (formule) d'Itô*. L'objectif est double : (i) comprendre précisément *pourquoi* les règles de calcul usuelles échouent pour le mouvement brownien, (ii) voir comment l'apparition d'une limite non nulle de sommes de carrés d'incrémentes (la variation quadratique) engendre naturellement le terme en dérivée seconde dans Itô.

1.2 Introduction : pourquoi un nouveau calcul ?

1.2.1 Le problème : le brownien n'est pas dérivable

En finance quantitative, on modélise typiquement un prix S_t (ou son log) en temps continu, et l'on manipule des différentielles. Exemple canonique :

$$dS_t = \mu S_t dt + \sigma S_t dW_t,$$

où W est un mouvement brownien. Dès que W intervient, la tentation est d'utiliser les règles usuelles de calcul différentiel (règle de la chaîne, produit, etc.). Le cœur du sujet est : *cela ne marche pas*, car une trajectoire de brownien est continue mais **presque sûrement nulle part dérivable**.

1.2.2 Un paradoxe qui force à changer les règles

Regardons $f(x) = x^2$ et $X_t = W_t$. Si l'on appliquait la règle de la chaîne classique à W_t^2 , on obtiendrait formellement

$$d(W_t^2) \stackrel{?}{=} 2W_t dW_t.$$

En intégrant de 0 à t :

$$W_t^2 \stackrel{?}{=} 2 \int_0^t W_s dW_s.$$

Mais le membre de droite est (dans le calcul d'Itô) une martingale centrée, donc son espérance est nulle, tandis que $\mathbb{E}[W_t^2] = t$. Il *manque un terme* qui explique la croissance moyenne de W_t^2 .

1.2.3 Message central

Le terme manquant vient du fait que les incréments browniens sont d'ordre $\sqrt{\Delta t}$: lorsque l'on développe une fonction à l'ordre 2, le terme en $(\Delta W)^2$ n'est *pas* négligeable, car $(\Delta W)^2$ est d'ordre Δt et s'accumule.

Cette accumulation est codée par un objet d'analyse de trajectoires : la **variation quadratique** (ou *crochet*) $[W]_t$. Pour le brownien, $[W]_t = t$. C'est ce fait, et uniquement ce fait, qui engendre le **terme de correction** $\frac{1}{2}f''$ dans la formule d'Itô.

1.2.4 Objectifs pédagogiques

- Savoir définir la variation quadratique à partir de sommes de carrés d'incréments le long de partitions.
- Comprendre pourquoi $[f]_t = 0$ pour une fonction régulière (variation finie) mais $[W]_t = t$ pour le brownien.
- Voir comment le *crochet* $[X]_t$ remplace les termes « $(dX_t)^2$ » et conduit à la formule d'Itô.
- Savoir faire des calculs concrets : $d(W_t^2)$, $d(\log S_t)$, règle du produit, covariation, etc.

1.3 Préliminaires : probabilités, temps continu, ordres de grandeur

1.3.1 Cadre probabiliste et filtration

On travaille sur un espace probabilisé $(\Omega, \mathcal{F}, \mathbb{P})$ muni d'une filtration $(\mathcal{F}_t)_{t \geq 0}$ (information disponible à la date t). Un processus $(X_t)_{t \geq 0}$ est *adapté* si X_t est $\mathcal{F}_t$ -mesurable pour tout t .

Remarque 1.1. L'intuition financière : $\mathcal{F}_t$ représente tout ce que le marché « sait » à l'instant t . Une stratégie de trading admissible doit être adaptée (pas d'anticipation).

1.3.2 Mouvement brownien : définition et quelques conséquences

Définition 1.1 (Mouvement brownien standard). Un processus $(W_t)_{t \geq 0}$ est un *mouvement brownien standard* (relatif à $(\mathcal{F}_t)$) si :

1. $W_0 = 0$ p.s. ;
2. (W_t) a des trajectoires continues ;
3. pour $0 \leq s < t$, l'incrément $W_t - W_s$ est gaussien $\mathcal{N}(0, t - s)$;
4. les incréments sur des intervalles disjoints sont indépendants ;
5. (adaptation) W_t est $\mathcal{F}_t$ -mesurable.

Deux faits structurants (qui seront utilisés en permanence) :

- **Ordre de grandeur.** Si h est petit, alors $\Delta W := W_{t+h} - W_t \sim \mathcal{N}(0, h)$, donc typiquement $|\Delta W| = \mathcal{O}(\sqrt{h})$.
- **Rugosité.** Cette échelle $\sqrt{h}$ est trop grande pour permettre une dérivée au sens classique : un quotient $\Delta W/h$ explose en général quand $h \rightarrow 0$.

1.3.3 Partitions, maillage et sommes le long d'une trajectoire

Soit $T > 0$ fixé. Une partition de $[0, T]$ est un ensemble

$$\Pi = \{0 = t_0 < t_1 < \dots < t_n = T\}.$$

Son *maillage* est $|\Pi| := \max_i(t_{i+1} - t_i)$. Pour un processus X , on note $\Delta_i X := X_{t_{i+1}} - X_{t_i}$.

1.3.3.1 Raffinement, suites de partitions, et ce que signifie « $|\Pi| \rightarrow 0$ »

Dans tout ce chapitre, les limites sont *toujours* prises le long d'une suite de partitions $(\Pi_n)_{n \geq 1}$ dont le maillage tend vers 0. Il est utile d'avoir en tête deux cas-types :

- **Partitions dyadiques.** $\Pi_n = \{kT2^{-n} : k = 0, \dots, 2^n\}$, qui sont emboîtées ($\Pi_n \subset \Pi_{n+1}$) et très pratiques pour des preuves presque sûres.
- **Partitions arbitraires.** On ne suppose pas que Π_{n+1} raffine Π_n : seule la condition $|\Pi_n| \rightarrow 0$ est imposée.

Définition 1.2 (Raffinement). On dit que Π' *raffine* Π (notation $\Pi \subset \Pi'$) si tout point de Π appartient à Π' . Une suite (Π_n) est *de plus en plus fine* si $\Pi_n \subset \Pi_{n+1}$ et $|\Pi_n| \rightarrow 0$.

Piège classique. La limite $\lim_{|\Pi| \rightarrow 0} \sum (\Delta X)^2$ peut (i) ne pas exister, ou (ii) dépendre du choix des partitions, si X est un processus continu arbitraire. Dans le cadre standard des *semi-martingales* (diffusions, Itô, etc.), la variation quadratique est bien définie (au sens *en probabilité*).

1.3.4 Rappels : développement de Taylor

Si $f : \mathbb{R} \rightarrow \mathbb{R}$ est C^2 , alors pour x et $x + \Delta x$:

$$f(x + \Delta x) = f(x) + f'(x)\Delta x + \frac{1}{2}f''(x)(\Delta x)^2 + r(\Delta x),$$

où le reste $r(\Delta x)$ est d'ordre $o((\Delta x)^2)$ quand $\Delta x \rightarrow 0$.

De même, si $f(t, x)$ est $C^{1,2}$ (une dérivée en t , deux en x), on peut écrire un Taylor à deux variables à l'ordre 2 (nous le ferons explicitement lors de la preuve d'Itô).

1.3.5 Heuristique utile : « $dW \sim \sqrt{dt}$ »

L'identité « $dW_t \sim \sqrt{dt}$ » n'a pas de sens au sens classique, mais elle guide correctement les ordres :

$$\Delta W = \mathcal{O}(\sqrt{\Delta t}), \quad (\Delta W)^2 = \mathcal{O}(\Delta t), \quad (\Delta W)^3 = \mathcal{O}((\Delta t)^{3/2}).$$

Conséquence cruciale : dans un Taylor, les termes en $(\Delta W)^2$ s'accumulent à l'échelle Δt et **ne doivent pas être jetés**.

1.4 Variation quadratique : définition, exemples, propriétés

1.4.1 Définition à partir de sommes de carrés

Définition 1.3 (Variation quadratique (définition séquentielle)). Soit $(X_t)_{t \in [0, T]}$ un processus à trajectoires continues. Pour $t \in [0, T]$ et une partition $\Pi = \{0 = t_0 < \dots < t_n = t\}$ de $[0, t]$, on pose

$$Q_t(X; \Pi) := \sum_{i=0}^{n-1} (\Delta_i X)^2.$$

On dit que X *possède une variation quadratique* sur $[0, T]$ s'il existe un processus croissant $([X]_t)_{t \in [0, T]}$ tel que, pour tout $t \in [0, T]$ et pour toute suite de partitions (Π_n) de $[0, t]$ avec $|\Pi_n| \rightarrow 0$, on ait

$$Q_t(X; \Pi_n) \longrightarrow [X]_t \quad \text{en probabilité (ou p.s., selon le niveau de résultat).}$$

Remarque 1.2. L'intuition : la variation quadratique mesure l'énergie des oscillations à petite échelle. Pour un chemin « lisse », les incréments sont de taille Δt , donc leurs carrés sont de taille $(\Delta t)^2$ et la somme s'évanouit. Pour un brownien, les incréments sont de taille $\sqrt{\Delta t}$, donc les carrés sont de taille Δt et la somme converge vers quelque chose de non nul.

1.4.2 Premier exemple : une fonction C^1 a une variation quadratique nulle

Proposition 1.1 (Cas déterministe C^1). *Si $f : [0, T] \rightarrow \mathbb{R}$ est de classe C^1 , alors*

$$[f]_T = 0.$$

Démonstration. Par le théorème des accroissements finis, pour chaque intervalle $[t_i, t_{i+1}]$ il existe $\xi_i \in (t_i, t_{i+1})$ tel que

$$\Delta_i f = f(t_{i+1}) - f(t_i) = f'(\xi_i)(t_{i+1} - t_i).$$

Donc

$$\sum_i (\Delta_i f)^2 = \sum_i (f'(\xi_i))^2 (t_{i+1} - t_i)^2 \leq \left(\sup_{u \in [0, T]} |f'(u)| \right)^2 \sum_i (t_{i+1} - t_i)^2.$$

Enfin,

$$\sum_i (t_{i+1} - t_i)^2 \leq |\Pi| \sum_i (t_{i+1} - t_i) = |\Pi| T \xrightarrow{|\Pi| \rightarrow 0} 0.$$

□

1.4.3 Processus de variation finie $\Rightarrow$ variation quadratique nulle

Définition 1.4 (Variation totale (sur $[0, T]$)). Pour une fonction $x : [0, T] \rightarrow \mathbb{R}$, on définit sa *variation totale* par

$$V_T(x) := \sup_{\Pi} \sum_{i=0}^{n-1} |\Delta_i x|.$$

Si $V_T(x) < \infty$, on dit que x est de *variation finie* sur $[0, T]$.

Proposition 1.2 (Variation finie $\Rightarrow$ variation quadratique nulle). *Si x est continue et de variation finie sur $[0, T]$, alors $[x]_T = 0$.*

Démonstration. Fixons une partition Π . Alors

$$\sum_i (\Delta_i x)^2 \leq \left(\max_i |\Delta_i x| \right) \sum_i |\Delta_i x|.$$

Si x est continue, $\max_i |\Delta_i x| \rightarrow 0$ quand $|\Pi| \rightarrow 0$. Si de plus x est de variation finie, alors $\sum_i |\Delta_i x| \leq V_T(x)$. D'où la convergence vers 0. □

Remarque 1.3. Cela explique pourquoi un terme en dt (qui est de variation finie) ne contribue pas au crochet : on a typiquement $[t]_T = 0$.

1.4.4 Le théorème fondamental : $[W]_t = t$ pour le brownien

Théorème 1.1 (Variation quadratique du brownien). *Soit $(W_t)_{t \geq 0}$ un mouvement brownien standard. Alors, pour tout $t \geq 0$,*

$$[W]_t = t \quad (\text{au moins en probabilité, et même p.s. pour des partitions adaptées}).$$

1.4.4.1 Preuve en probabilité (via un contrôle de variance)

Méthode. Le schéma est : (i) calculer $\mathbb{E}[S(\Pi)]$, (ii) contrôler $\text{Var}(S(\Pi))$ et montrer qu'elle tend vers 0, puis (iii) conclure par Chebyshev. On gagne ici parce que les incréments browniens sont *indépendants* et ont des moments explicites.

Fixons $t > 0$. Considérons une partition $\Pi = \{0 = t_0 < \dots < t_n = t\}$ et posons

$$S(\Pi) := \sum_{i=0}^{n-1} (\Delta_i W)^2.$$

Comme les incréments browniens sont indépendants et $\Delta_i W \sim \mathcal{N}(0, \Delta t_i)$ avec $\Delta t_i = t_{i+1} - t_i$, on a

$$\mathbb{E}[(\Delta_i W)^2] = \Delta t_i \quad \Rightarrow \quad \mathbb{E}[S(\Pi)] = \sum_i \Delta t_i = t.$$

De plus, si $Z \sim \mathcal{N}(0, \Delta t)$, alors $\mathbb{E}[Z^4] = 3(\Delta t)^2$ et donc

$$\text{Var}(Z^2) = \mathbb{E}[Z^4] - \mathbb{E}[Z^2]^2 = 3(\Delta t)^2 - (\Delta t)^2 = 2(\Delta t)^2.$$

Par indépendance,

$$\text{Var}(S(\Pi)) = \sum_i \text{Var}((\Delta_i W)^2) = 2 \sum_i (\Delta t_i)^2.$$

Or

$$\sum_i (\Delta t_i)^2 \leq |\Pi| \sum_i \Delta t_i = |\Pi| t \xrightarrow{|\Pi| \rightarrow 0} 0,$$

donc $\text{Var}(S(\Pi)) \rightarrow 0$. Par Chebyshev,

$$\mathbb{P}(|S(\Pi) - t| > \varepsilon) \leq \frac{\text{Var}(S(\Pi))}{\varepsilon^2} \xrightarrow{|\Pi| \rightarrow 0} 0,$$

ce qui donne $S(\Pi) \rightarrow t$ en probabilité lorsque $|\Pi| \rightarrow 0$.

1.4.4.2 Preuve presque sûre le long des partitions dyadiques (détaillée)

Fixons $t > 0$ et considérons la suite de partitions dyadiques de $[0, t]$:

$$\Pi_n = \left\{ \frac{kt}{2^n} : k = 0, \dots, 2^n \right\}, \quad S_n := S(\Pi_n) = \sum_{k=0}^{2^n-1} \left(W_{\frac{(k+1)t}{2^n}} - W_{\frac{kt}{2^n}} \right)^2.$$

On a toujours $\mathbb{E}[S_n] = t$. Le point clef est que, pour cette famille spécifique, la variance décroît assez vite pour que l'on puisse sommer les probabilités. En effet, chaque incrément est $\mathcal{N}(0, t/2^n)$, donc comme plus haut

$$\text{Var}\left((\Delta_k^n W)^2\right) = 2\left(\frac{t}{2^n}\right)^2, \quad \text{Var}(S_n) = \sum_{k=0}^{2^n-1} 2\left(\frac{t}{2^n}\right)^2 = \frac{2t^2}{2^n}.$$

Par Chebyshev, pour tout $\varepsilon > 0$:

$$\mathbb{P}(|S_n - t| > \varepsilon) \leq \frac{\text{Var}(S_n)}{\varepsilon^2} = \frac{2t^2}{\varepsilon^2 2^n}.$$

La série $\sum_{n \geq 1} \mathbb{P}(|S_n - t| > \varepsilon)$ converge, donc par Borel–Cantelli l'événement $\{|S_n - t| > \varepsilon\}$ ne se produit qu'un nombre fini de fois. Autrement dit,

$$S_n \longrightarrow t \quad \text{p.s.}$$

Pour obtenir la convergence sans fixer ε , on applique ce raisonnement à $\varepsilon_m = 1/m$ et on intersecte sur $m \in \mathbb{N}$ (argument dénombrabilité).

Remarque 1.4. Cette convergence presque sûre est *liée au choix* des partitions dyadiques (ou, plus généralement, à des suites de partitions déterministes et emboîtées). Pour des partitions arbitraires, la notion robuste utilisée en théorie est la convergence *en probabilité*.

1.4.5 Covariation (crochet croisé) et polarisation

Pour deux processus continus X et Y possédant des variations quadratiques, on définit leur *covariation* par

$$[X, Y]_t := \lim_{|\Pi| \rightarrow 0} \sum_i (\Delta_i X)(\Delta_i Y),$$

si la limite existe. Une identité utile est la polarisation :

$$[X, Y]_t = \frac{1}{4}([X + Y]_t - [X - Y]_t).$$

En particulier, $[X]_t = [X, X]_t$.

Justification (par polarisation au niveau des incréments). Sur chaque intervalle $[t_i, t_{i+1}]$, on a l'identité algébrique

$$(\Delta_i(X + Y))^2 - (\Delta_i(X - Y))^2 = 4(\Delta_i X)(\Delta_i Y).$$

En sommant sur i puis en passant à la limite le long d'une suite de partitions de maillage $\rightarrow 0$, on obtient la formule de polarisation annoncée. $\square$

Proposition 1.3 (Règles de base). *Lorsque les crochets existent, on a pour tout t :*

$$[X + Y]_t = [X]_t + [Y]_t + 2[X, Y]_t, \quad [aX]_t = a^2[X]_t, \quad [X, A]_t = 0 \text{ si } A \text{ est de variation finie.}$$

Démonstration. Les deux premières identités viennent des identités algébriques sur les incréments (puis passage à la limite). Pour la troisième : si A est de variation finie, alors $\sum (\Delta A)^2 \rightarrow 0$ (chapitre plus haut), et par Cauchy-Schwarz

$$\left| \sum_i (\Delta_i X)(\Delta_i A) \right| \leq \left(\sum_i (\Delta_i X)^2 \right)^{1/2} \left(\sum_i (\Delta_i A)^2 \right)^{1/2} \xrightarrow{|\Pi| \rightarrow 0} 0,$$

ce qui donne $[X, A]_t = 0$. $\square$

Exemple 1.1 (Brownien multidimensionnel). Si $W = (W^1, \dots, W^d)$ est un brownien d -dimensionnel à composantes indépendantes, alors

$$[W^i, W^j]_t = \delta_{ij} t.$$

Exemple 1.2 (Brownien corrélé (cas $d = 2$)). Soient W^1 et B deux browniens indépendants et $\rho \in [-1, 1]$. Définissons

$$W_t^2 := \rho W_t^1 + \sqrt{1 - \rho^2} B_t.$$

Alors W^2 est un brownien et, par bilinéarité du crochet,

$$[W^1, W^2]_t = \rho[W^1]_t + \sqrt{1 - \rho^2}[W^1, B]_t = \rho t.$$

Cette identité est la traduction mathématique de la corrélation instantanée en modélisation diffusive.

Exercice 1.1. Montrer que si $X_t = W_t + t$, alors $[X]_t = t$ et $[W, t]_t = 0$.

Correction détaillée. On écrit $X = W + A$ avec $A_t = t$ de variation finie, donc $[A]_t = 0$ et $[W, A]_t = 0$. Ainsi $[X]_t = [W]_t + [A]_t + 2[W, A]_t = t$. $\square$

1.4.6 Règles de calcul différentiel : d'où vient $(dW)^2 = dt$?

Le calcul stochastique se résume souvent à des règles formelles :

$$(dW_t)^2 = dt, \quad dt dW_t = 0, \quad (dt)^2 = 0.$$

On peut les lire comme une notation compacte des limites de variations quadratiques :

$$\sum_i (\Delta_i W)^2 \rightarrow t \quad \rightsquigarrow \quad (dW_t)^2 = dt,$$

et comme $t \mapsto t$ est de variation finie, son crochet est nul, d'où $dt dW_t = 0$.

1.4.7 Un critère de régularité : Hölder $> \frac{1}{2}$ implique crochet nul

La variation quadratique est liée à la rugosité des trajectoires.

Définition 1.5 (Hölder α). Une fonction $x : [0, T] \rightarrow \mathbb{R}$ est dite *Hölder* d'exposant $\alpha \in (0, 1]$ s'il existe une constante C telle que

$$|x_t - x_s| \leq C|t - s|^\alpha, \quad \forall s, t \in [0, T].$$

Proposition 1.4 (Seuil $\alpha > \frac{1}{2}$). Si x est Hölder d'exposant $\alpha > \frac{1}{2}$, alors $[x]_T = 0$.

Démonstration. Pour une partition Π , on a $|\Delta_i x| \leq C(\Delta t_i)^\alpha$, donc

$$\sum_i (\Delta_i x)^2 \leq C^2 \sum_i (\Delta t_i)^{2\alpha}.$$

Or $\sum_i (\Delta t_i)^{2\alpha} \leq |\Pi|^{2\alpha-1} \sum_i \Delta t_i = |\Pi|^{2\alpha-1} T$. Comme $2\alpha - 1 > 0$, on obtient la convergence vers 0 quand $|\Pi| \rightarrow 0$. $\square$

Remarque 1.5. Le brownien est Hölder α pour tout $\alpha < \frac{1}{2}$ (et pour aucun $\alpha \geq \frac{1}{2}$). Ce « presque $\frac{1}{2}$ » explique qu'il soit à la frontière : assez régulier pour être continu, mais assez irrégulier pour avoir une variation quadratique non nulle.

1.4.8 Attention : la variation quadratique n'existe pas toujours

Pour un processus continu arbitraire, la limite $\lim \sum (\Delta X)^2$ peut ne pas exister (ou dépendre du choix des partitions). Le cadre naturel où l'existence est garantie est celui des *semi-martingales* (qui inclut les diffusions usuelles en finance). Dans ces notes, on travaille essentiellement avec des processus d'Itô, pour lesquels le crochet existe et vaut $\int b^2$.

1.4.9 Interprétation financière : variance réalisée et volatilité intégrée

Supposons que le log-prix suive un processus d'Itô (nous le définirons bientôt) :

$$d(\log S_t) = \left(\mu_t - \frac{1}{2}\sigma_t^2\right)dt + \sigma_t dW_t.$$

Alors son crochet vaut

$$[\log S]_t = \int_0^t \sigma_s^2 ds.$$

Si l'on observe S à haute fréquence aux dates $0 = t_0 < \dots < t_n = t$, la *variance réalisée*

$$RV_t := \sum_{i=0}^{n-1} (\log S_{t_{i+1}} - \log S_{t_i})^2$$

converge (quand le maillage tend vers 0) vers $[\log S]_t$, c'est-à-dire la volatilité intégrée.

Interprétation marché. C'est l'objet statistique de base derrière *tous* les estimateurs de volatilité haute-fréquence : à frictions négligées, la somme des carrés de rendements log à haute fréquence estime l'intégrale de σ^2 . Dans un modèle diffusive, $[\log S]_t$ est « la variance cumulée » sur $[0, t]$.

Check dimensionnel. Si S est un prix (unité : euros), alors $\log S$ est sans dimension. Le crochet $[\log S]_t$ est donc une *variance* sans dimension (typiquement de l'ordre de $\sigma^2 t$). Pour $\sigma = 20\%$ et $t = 1$ an, on attend $[\log S]_1 \approx 0.04$.

Piège classique. En présence de sauts, la variance réalisée converge vers $[\log S]_t = \int_0^t \sigma_s^2 ds + \sum_{0 < s \leq t} (\Delta \log S_s)^2$: les sauts laissent une trace « en carré ». C'est une raison pour laquelle les modèles à sauts impactent fortement les produits sensibles à la variance (variance swaps, options OTM).

1.5 Mode microscope : pourquoi $[W]_t = t$?

1.5.1 Définition via partitions

Soit $\pi = \{0 = t_0 < t_1 < \dots < t_n = t\}$ une partition de $[0, t]$ et $|\pi| = \max_i(t_{i+1} - t_i)$ son pas. Pour un processus X , on considère la somme

$$Q_\pi(X) := \sum_{i=0}^{n-1} (X_{t_{i+1}} - X_{t_i})^2.$$

Si $Q_\pi(X) \rightarrow [X]_t$ quand $|\pi| \rightarrow 0$ (au sens voulu), on appelle $[X]_t$ la variation quadratique.

1.5.2 Calcul en L^2 pour le Brownien

Posons $X = W$ un Brownien standard. Par indépendance des incréments, on calcule

$$\mathbb{E}[Q_\pi(W)] = \sum_i \mathbb{E}[(\Delta W_i)^2] = \sum_i (t_{i+1} - t_i) = t.$$

Pour la variance, utiliser que pour une gaussienne centrée $Z \sim \mathcal{N}(0, \sigma^2)$, on a $\mathbb{E}[Z^4] = 3\sigma^4$ donc $\text{Var}(Z^2) = 2\sigma^4$. Comme les (ΔW_i) sont indépendants :

$$\text{Var}(Q_\pi(W)) = \sum_i \text{Var}((\Delta W_i)^2) = \sum_i 2(t_{i+1} - t_i)^2 \leq 2|\pi| \sum_i (t_{i+1} - t_i) = 2t|\pi|.$$

Ainsi, $\text{Var}(Q_\pi(W)) \rightarrow 0$ quand $|\pi| \rightarrow 0$, donc $Q_\pi(W) \rightarrow t$ dans L^2 , et en particulier en probabilité.

Lecture. Le terme $(\Delta W_i)^2$ est d'ordre Δt (pas $(\Delta t)^2$) : c'est la raison pour laquelle Itô a un terme $\frac{1}{2}f''dt$.

Sanity check. Échelle : $\Delta W \sim \sqrt{\Delta t}$ donc $(\Delta W)^2 \sim \Delta t$ et la somme des carrés s'additionne comme un temps.

Exemple jouet. Exemple jouet : en discret, si on simule $\Delta W_i \sim \mathcal{N}(0, \Delta t)$, alors $\sum_i (\Delta W_i)^2$ fluctue autour de t avec une dispersion d'ordre $\sqrt{|\pi|}$.

1.5.3 Variation finie $\Rightarrow$ variation quadratique nulle (heuristique)

Si A est de variation finie sur $[0, t]$, alors $\sum_i |\Delta A_i|$ est bornée. Or

$$\sum_i (\Delta A_i)^2 \leq \left(\max_i |\Delta A_i| \right) \sum_i |\Delta A_i|.$$

Quand $|\pi| \rightarrow 0$, $\max_i |\Delta A_i| \rightarrow 0$ (continuité / variation finie), donc $Q_\pi(A) \rightarrow 0$.

1.6 Pièges classiques / erreurs fréquentes

- Confondre variation totale et variation quadratique : ce sont deux objets différents (l'une diverge pour W , l'autre vaut t).
- Oublier l'échelle $\Delta W \sim \sqrt{\Delta t}$: c'est la source du terme d'ordre dt dans Itô.
- Utiliser des partitions trop grossières pour « estimer » $[W]_t$: forte variance.

1.7 Checklist — savoir refaire sans regarder

- Écrire la définition $Q_\pi(X)$ et expliquer la limite $|\pi| \rightarrow 0$.
- Démontrer $[W]_t = t$ en L^2 (calcul d'espérance/variance).

- Montrer qu'un processus de variation finie a une qv nulle.
- Manipuler les règles de calcul : $[aX] = a^2[X]$, $[X + Y] = [X] + [Y] + 2[X, Y]$.

Chapitre 2

Intégrale et lemme d'Itô (version canonique)

Idée centrale. Construire l'intégrale stochastique et la formule d'Itô : c'est le calcul différentiel du continu sous bruit brownien, indispensable pour SDE, pricing, greeks et schémas numériques.

Cadre mathématique.

- **Itô-intégrale.** Définie par complétion L^2 sur des processus simples, avec adaptation (pas d'anticipation).
- **Isométrie.** $\mathbb{E}[(\int_0^T H_t dW_t)^2] = \mathbb{E}[\int_0^T H_t^2 dt]$ (outil central).
- **Formule d'Itô.** Pour X_t diffusion : $df(t, X_t) = f_t dt + f_x dX_t + \frac{1}{2}f_{xx} d[X]_t$.

Intuition marché / interprétation. Intuition : le terme $\frac{1}{2}f_{xx}$ est une « correction de rugosité » (variation quadratique). En desk, il sépare un hedging cohérent d'une erreur de calcul.

Implémentation.

- Simulation : Euler-Maruyama, Milstein (si diffusion lisse); approximer $\int H dW$ par somme $\sum H_{t_i}(W_{t_{i+1}} - W_{t_i})$.
- Grecques : finite differences vs pathwise (sensibilités); attention au bruit numérique.

Tests / sanity checks.

- Isométrie : vérifier numériquement sur simulation (moyenne des carrés vs intégrale de H^2).
- Convergence : erreur de schéma $\rightarrow 0$ quand $\Delta t \downarrow$ (ordre attendu).
- Martingale : $\mathbb{E}[\int_0^t H dW] = 0$ (diagnostic de biais).

Pont vers pratique quant. Pont quant : dérivation de la PDE Black-Scholes, construction de schémas MC/PDE, calcul de greeks, et fondation des modèles plus riches (sauts, vol stoch, rough via Volterra).

2.1 Avant-propos : construire l'intégrale d'Itô et la formule d'Itô

Le chapitre précédent a introduit le crochet $[W]_t = t$: c'est la *raison* pour laquelle le calcul différentiel classique ne s'applique pas directement au brownien. Ici, on fait le pas suivant : on veut définir proprement l'objet

$$\int_0^t H_s dW_s$$

et en déduire une règle de chaîne valide pour $f(t, W_t)$ et plus généralement $f(t, X_t)$.

2.1.1 Pourquoi une *nouvelle* intégrale ?

En calcul déterministe, l'intégrale de Riemann-Stieltjes demande (au minimum) une certaine régularité de l'intégrateur. Le brownien étant trop « rugueux », l'approche *pathwise* n'est pas robuste. L'idée d'Itô consiste à (i) imposer l'adaptation (pas d'anticipation), et (ii) choisir une notion de convergence probabiliste naturelle

(souvent L^2), ce qui fait apparaître une identité-clé : l'isométrie d'Itô.

2.1.2 Objectifs pédagogiques (ce qu'on doit savoir refaire)

- Construire l'intégrale d'Itô à partir des processus simples et de la complétion L^2 .
- Démontrer l'isométrie, puis en déduire la propriété de martingale et le crochet de l'intégrale.
- Dériver la formule d'Itô par un schéma « partition + Taylor » en expliquant à quel endroit intervient $[W]_t = t$.
- Maîtriser les règles opérationnelles : produit, intégration par parties, version multidimensionnelle.

2.1.3 Pré-requis

- Chapitre chapitre 1 : variation quadratique et ordres de grandeur $\Delta W \sim \sqrt{\Delta t}$.
- Taylor à l'ordre 2 (en une et deux variables).
- Notion de filtration et adaptation (lecture « pas d'anticipation »).

2.1.4 Plan du chapitre (et fil rouge finance)

1. Intégrale d'Itô : définition, isométrie, extension, crochet.
2. Formule d'Itô : dérivation pas à pas et *table de multiplication* $(dW)^2 = dt$.
3. Applications finance : GBM, log-returns, lecture PDE / Feynman-Kac (préparation de Black-Scholes).

Intuition de marché. En finance, Itô est la convention naturelle : (i) elle respecte l'information (intégrande à gauche), (ii) les intégrales d'Itô sont des martingales, ce qui s'aligne exactement avec la logique « actif actualisé = martingale sous $\mathbb{Q}$ ».

2.2 Intégrale d'Itô : motivation et construction (niveau cours)

2.2.1 Pourquoi une *nouvelle* intégrale ?

Dans le calcul classique, on définit

$$\int_0^T H_t dX_t$$

comme limite de sommes de Riemann-Stieltjes le long de partitions. Pour que cette construction soit stable, une condition suffisante est que X soit de *variation finie*. Or, le mouvement brownien n'est pas de variation finie (il a même une variation totale infinie sur tout intervalle), ce qui rend l'intégrale pathwise très délicate.

L'idée d'Itô est de définir l'intégrale à partir de :

- l'adaptation (le futur ne doit pas intervenir) ;
- une notion de convergence probabiliste, typiquement en L^2 ;
- une identité clef de type « conservation d'énergie » : l'isométrie d'Itô.

2.2.2 Sommes discrètes et choix du point d'évaluation

Soit une partition $\Pi = \{0 = t_0 < \dots < t_n = T\}$. Pour un intégrand H , on peut former deux sommes :

$$I^{\text{gauche}}(\Pi) := \sum_{i=0}^{n-1} H_{t_i} (W_{t_{i+1}} - W_{t_i}), \quad I^{\text{milieu}}(\Pi) := \sum_{i=0}^{n-1} H_{(t_i+t_{i+1})/2} (W_{t_{i+1}} - W_{t_i}).$$

Le choix « à gauche » est compatible avec l'adaptation : H_{t_i} est connu à la date t_i , avant que l'incrément $W_{t_{i+1}} - W_{t_i}$ ne se réalise. C'est ce choix qui conduit à l'intégrale d'Itô. Le choix « au milieu » (ou symétrique)

conduit à l'intégrale de Stratonovich, utile dans certains modèles physiques, mais moins naturelle pour les arguments de martingale en finance.

2.2.3 Processus simples et définition de l'intégrale

Définition 2.1 (Processus simple (prédicible)). On appelle *processus simple* (sur $[0, T]$) un processus de la forme

$$H_t(\omega) = \sum_{i=0}^{n-1} H_i(\omega) \mathbf{1}_{(t_i, t_{i+1}]}(t),$$

où $0 = t_0 < \dots < t_n = T$ et où chaque H_i est $\mathcal{F}_{t_i}$ -mesurable (donc connu au temps t_i).

Définition 2.2 (Intégrale d'Itô pour un processus simple). Pour un processus simple H , on définit

$$\int_0^T H_t dW_t := \sum_{i=0}^{n-1} H_i (W_{t_{i+1}} - W_{t_i}).$$

Plus généralement, pour $t \leq T$:

$$\int_0^t H_s dW_s := \sum_{i=0}^{n-1} H_i (W_{t_{i+1} \wedge t} - W_{t_i \wedge t}).$$

2.2.3.1 Centrage et propriété de martingale (pourquoi le choix à gauche compte)

Proposition 2.1 (L'intégrale d'Itô est une martingale (cas simple)). Soit H un processus simple et posons

$$M_t := \int_0^t H_s dW_s.$$

Alors $(M_t)_{t \in [0, T]}$ est une martingale continue, et en particulier $\mathbb{E}[M_t] = 0$.

Démonstration. Fixons $0 \leq s < t \leq T$ et prenons une partition qui contient s et t (quitte à la raffiner). Par définition,

$$M_t - M_s = \sum_{k: t_k \in (s, t]} H_k (W_{t_{k+1}} - W_{t_k}).$$

Chaque H_k est $\mathcal{F}_{t_k}$ -mesurable, tandis que l'incrément $W_{t_{k+1}} - W_{t_k}$ est indépendant de $\mathcal{F}_{t_k}$ et centré. Par l'argument de tour d'espérance,

$$\mathbb{E}[H_k (W_{t_{k+1}} - W_{t_k}) \mid \mathcal{F}_{t_k}] = H_k \mathbb{E}[W_{t_{k+1}} - W_{t_k} \mid \mathcal{F}_{t_k}] = 0.$$

En prenant l'espérance conditionnelle par rapport à $\mathcal{F}_s$ et en itérant sur les pas après s , on obtient $\mathbb{E}[M_t - M_s \mid \mathcal{F}_s] = 0$, donc $\mathbb{E}[M_t \mid \mathcal{F}_s] = M_s$. $\square$

Interprétation marché. Sous une mesure risque-neutre $\mathbb{Q}$, l'argument « prix actualisé = martingale » se ramène souvent à montrer qu'un terme est une intégrale d'Itô : c'est exactement l'objet dont l'espérance conditionnelle est nulle.

Piège classique. Si l'on remplaçait H_{t_i} par $H_{(t_i + t_{i+1})/2}$ dans les sommes discrètes, on *casserait* l'adaptation : l'intégrand dépendrait (un peu) du futur. On obtient alors l'intégrale de Stratonovich, qui n'est en général pas une martingale.

2.2.4 Isométrie d'Itô : la propriété structurante

Théorème 2.1 (Isométrie d'Itô (cas simple)). Si H est un processus simple, alors

$$\mathbb{E}\left[\left(\int_0^T H_t dW_t\right)^2\right] = \mathbb{E}\left[\int_0^T H_t^2 dt\right].$$

Démonstration. En développant le carré,

$$\left(\sum_i H_i \Delta_i W \right)^2 = \sum_i H_i^2 (\Delta_i W)^2 + 2 \sum_{i < j} H_i H_j \Delta_i W \Delta_j W.$$

Pour les termes croisés : conditionnellement à $\mathcal{F}_{t_j}$, on a $\mathbb{E}[\Delta_j W \mid \mathcal{F}_{t_j}] = 0$ et $\Delta_j W$ est indépendant de $\mathcal{F}_{t_j}$, tandis que $H_i \Delta_i W$ est $\mathcal{F}_{t_j}$ -mesurable si $i < j$. Donc

$$\mathbb{E}[H_i H_j \Delta_i W \Delta_j W] = 0 \quad (i < j).$$

Pour les termes diagonaux, H_i est $\mathcal{F}_{t_i}$ -mesurable et indépendant de $\Delta_i W$ conditionnellement à $\mathcal{F}_{t_i}$, donc

$$\mathbb{E}[H_i^2 (\Delta_i W)^2] = \mathbb{E}[H_i^2 \mathbb{E}[(\Delta_i W)^2 \mid \mathcal{F}_{t_i}]] = \mathbb{E}[H_i^2] \Delta t_i.$$

En sommant, on obtient

$$\mathbb{E}\left[\left(\int_0^T H_t dW_t\right)^2\right] = \sum_i \mathbb{E}[H_i^2] \Delta t_i = \mathbb{E}\left[\int_0^T H_t^2 dt\right].$$

□

Remarque 2.1. Cette identité a deux conséquences majeures :

- L'intégrale d'Itô est naturellement une limite en L^2 (car le membre de droite contrôle la norme L^2).
- L'intégrale $\int_0^t H_s dW_s$ est une martingale de variance $\mathbb{E}[\int_0^t H_s^2 ds]$.

2.2.5 Extension à des intégrandes générales

Méthode. La construction « propre » consiste à définir d'abord l'intégrale sur les processus simples, puis à *compléter* par continuité dans la norme $L^2(\Omega \times [0, T])$. L'isométrie est exactement ce qui rend cette extension non ambiguë.

On considère l'espace (souvent noté $\mathcal{H}^2$) des processus prédictibles H tels que

$$\mathbb{E}\left[\int_0^T H_t^2 dt\right] < \infty.$$

Dérivation (pas à pas).

Étape 1: Approximation. On choisit une suite de processus simples $(H^{(n)})$ telle que $H^{(n)} \rightarrow H$ dans la norme

$$\|H\|_{L^2(\Omega \times [0, T])}^2 := \mathbb{E}\left[\int_0^T H_t^2 dt\right],$$

Étape 2: Cauchy via l'isométrie. Pour m, n ,

$$\mathbb{E}\left[\left(\int_0^T (H_t^{(n)} - H_t^{(m)}) dW_t\right)^2\right] = \mathbb{E}\left[\int_0^T (H_t^{(n)} - H_t^{(m)})^2 dt\right] \xrightarrow{n, m \rightarrow \infty} 0,$$

donc $(\int_0^T H^{(n)} dW)$ est Cauchy dans $L^2(\Omega)$ et converge.

Étape 3: Définition. On pose alors

$$\int_0^T H_t dW_t := L^2\text{-}\lim_{n \rightarrow \infty} \int_0^T H_t^{(n)} dW_t.$$

Étape 4: Indépendance de l'approximation. Si $(\tilde{H}^{(n)})$ est une autre suite simple convergeant vers H , on applique la même inégalité à $H^{(n)} - \tilde{H}^{(n)}$: la limite est la même.

On obtient ainsi une application linéaire continue $H \mapsto \int H dW$ de $\mathcal{H}^2$ vers $L^2(\Omega)$, qui vérifie encore l'isométrie.

2.2.6 Crochets des intégrales stochastiques

Si l'on pose

$$M_t := \int_0^t H_s dW_s,$$

alors M est une martingale continue et sa variation quadratique est

$$[M]_t = \int_0^t H_s^2 ds.$$

Plus généralement, si

$$N_t := \int_0^t G_s dW_s,$$

alors leur covariation vaut

$$[M, N]_t = \int_0^t H_s G_s ds.$$

Ces identités sont l'analogie (stochastique) de « $(dW)^2 = dt$ ».

Preuve (niveau cours). Idée / intuition. Pour H simple, M est par morceaux une combinaison linéaire d'incrément browniens. La variation quadratique doit donc être « la somme des H^2 fois la variation quadratique de W ».

Démonstration détaillée. Supposons d'abord H simple : $H = \sum_{k=0}^{n-1} H_k \mathbf{1}_{(t_k, t_{k+1}]}$. Prenons une partition dyadique Π_m qui raffine la partition $\{t_k\}$ (on peut toujours raffiner). Sur un intervalle où H est constant à la valeur H_k , on a $\Delta M = H_k \Delta W$, donc

$$\sum_{[u,v] \in \Pi_m} (\Delta M)^2 = \sum_{[u,v] \in \Pi_m} H_u^2 (\Delta W)^2.$$

Par le résultat de variation quadratique du brownien, sur un intervalle $[t_k, t_{k+1}]$:

$$\sum_{[u,v] \in \Pi_m \cap [t_k, t_{k+1}]} (\Delta W)^2 \longrightarrow t_{k+1} - t_k \quad (\text{p.s. le long des dyadiques}).$$

En multipliant par H_k^2 et en sommant sur k , on obtient

$$\sum_{[u,v] \in \Pi_m} (\Delta M)^2 \longrightarrow \sum_{k=0}^{n-1} H_k^2 (t_{k+1} - t_k) = \int_0^t H_s^2 ds,$$

ce qui donne $[M]_t = \int_0^t H_s^2 ds$ pour les intégrandes simples.

Pour H général dans $\mathcal{H}^2$, on approche H par $H^{(n)}$ simples dans $L^2(\Omega \times [0, T])$. Alors $M^{(n)} = \int H^{(n)} dW$ converge vers M dans $L^2(\Omega)$ (construction), et les crochets vérifient

$$[M^{(n)}]_t = \int_0^t (H_s^{(n)})^2 ds \longrightarrow \int_0^t H_s^2 ds$$

dans $L^1(\Omega)$ (par convergence L^2 et inégalité de Cauchy-Schwarz). On obtient bien la formule annoncée pour M . La formule de covariation $[M, N]_t = \int_0^t H_s G_s ds$ se déduit de la polarisation. $\square$

2.2.7 Cas déterministe : une variable gaussienne explicite

Si $h : [0, T] \rightarrow \mathbb{R}$ est déterministe et $h \in L^2(0, T)$, alors

$$I := \int_0^T h(t) dW_t$$

est une variable gaussienne centrée. De plus,

$$\text{Var}(I) = \mathbb{E}[I^2] = \int_0^T h(t)^2 dt$$

(isométrie).

Idée de preuve. On approxime h par des fonctions en escalier $h^{(n)}$. Alors

$$\int_0^T h^{(n)}(t) dW_t = \sum_i h_i^{(n)}(W_{t_{i+1}} - W_{t_i})$$

est une somme de gaussiennes indépendantes, donc gaussienne. L'isométrie donne la convergence en L^2 et donc en loi. $\square$

Remarque 2.2. Ce résultat est particulièrement utile en finance pour calculer des lois exactes (par exemple la loi du log-prix dans le GBM).

2.2.8 Processus d'Itô et notation différentielle

Définition 2.3 (Processus d'Itô (scalaire)). On appelle *processus d'Itô* tout processus de la forme

$$X_t = X_0 + \int_0^t a_s ds + \int_0^t b_s dW_s,$$

où a et b sont adaptés (et suffisamment intégrables pour que les intégrales aient un sens).

On écrit souvent, comme raccourci :

$$dX_t = a_t dt + b_t dW_t.$$

Le point essentiel est : **seul le terme en dW_t contribue au crochet**. En effet, le terme $\int a_s ds$ est de variation finie, donc n'a pas de variation quadratique, tandis que

$$\left[\int_0^t b_s dW_s \right]_t = \int_0^t b_s^2 ds.$$

Ainsi, pour un processus d'Itô :

$$[X]_t = \int_0^t b_s^2 ds, \quad d[X]_t = b_t^2 dt.$$

2.3 Du crochet au lemme d'Itô : dérivation pas à pas

2.3.1 Énoncé : la formule d'Itô (cas scalaire)

Théorème 2.2 (Lemme / formule d'Itô (processus d'Itô scalaire)). Soit X un processus d'Itô sur $[0, T]$:

$$dX_t = a_t dt + b_t dW_t,$$

et soit $f : [0, T] \times \mathbb{R} \rightarrow \mathbb{R}$ de classe $C^{1,2}$. Alors le processus $Y_t := f(t, X_t)$ est encore un processus d'Itô et l'on a

$$df(t, X_t) = \partial_t f(t, X_t) dt + \partial_x f(t, X_t) dX_t + \frac{1}{2} \partial_{xx} f(t, X_t) d[X]_t.$$

Comme $d[X]_t = b_t^2 dt$, cela donne la forme explicite

$$df(t, X_t) = \left(\partial_t f + a_t \partial_x f + \frac{1}{2} b_t^2 \partial_{xx} f \right)(t, X_t) dt + (b_t \partial_x f)(t, X_t) dW_t.$$

Remarque 2.3. Il est utile de retenir la lecture suivante :

- le terme en $\partial_t f$ est celui qu'on aurait déjà en calcul déterministe ;
- le terme en $\partial_x f dX$ est la « chaîne » classique ;

— le **terme nouveau** est $\frac{1}{2} \partial_{xx} f d[X]$, qui n'existe que parce que $[X]$ est non nul.

2.3.2 Pourquoi la dérivée seconde apparaît : le calcul à l'échelle Δt

Le point de départ est un Taylor à l'ordre 2. Pour fixer les idées, prenons d'abord $X_t = W_t$ et f indépendante du temps. On écrit

$$f(W_{t+h}) - f(W_t) = f'(W_t) \Delta W + \frac{1}{2} f''(W_t) (\Delta W)^2 + r_h, \quad \Delta W := W_{t+h} - W_t.$$

Or $\Delta W = \mathcal{O}(\sqrt{h})$, donc $(\Delta W)^2 = \mathcal{O}(h)$: le terme en f'' est **du même ordre** que dt et ne disparaît pas quand on raffine les partitions. L'objet qui capture l'accumulation des $(\Delta W)^2$ est $[W]_t = t$.

2.3.3 Dérivation pas à pas (cas général $f(t, X_t)$)

On dérive la formule en sommant une identité de Taylor le long d'une partition.

2.3.3.1 Étape 1 : poser une partition et sommer les incréments

Fixons $t \in [0, T]$ et une partition $\Pi = \{0 = t_0 < \dots < t_n = t\}$. En sommant les incréments, on a l'identité télescopique

$$f(t, X_t) - f(0, X_0) = \sum_{i=0}^{n-1} \left(f(t_{i+1}, X_{t_{i+1}}) - f(t_i, X_{t_i}) \right).$$

2.3.3.2 Étape 2 : Taylor à deux variables sur chaque pas

Sur l'intervalle $[t_i, t_{i+1}]$, notons

$$\Delta t_i := t_{i+1} - t_i, \quad \Delta X_i := X_{t_{i+1}} - X_{t_i}.$$

Comme $f \in C^{1,2}$, on peut écrire (formellement, et rigoureusement sous des hypothèses de bornes locales) :

$$\begin{aligned} f(t_{i+1}, X_{t_{i+1}}) &= f(t_i, X_{t_i}) + f_t(t_i, X_{t_i}) \Delta t_i + f_x(t_i, X_{t_i}) \Delta X_i \\ &\quad + \frac{1}{2} f_{xx}(t_i, X_{t_i}) (\Delta X_i)^2 + R_i, \end{aligned}$$

où le reste R_i est d'ordre plus élevé (en gros $\mathcal{O}(|\Delta t_i|^2 + |\Delta X_i|^3)$).

2.3.3.3 Étape 3 : sommer les termes et identifier les limites

En sommant, on obtient

$$\begin{aligned} f(t, X_t) - f(0, X_0) &= \sum_i f_t(t_i, X_{t_i}) \Delta t_i + \sum_i f_x(t_i, X_{t_i}) \Delta X_i \\ &\quad + \frac{1}{2} \sum_i f_{xx}(t_i, X_{t_i}) (\Delta X_i)^2 + \sum_i R_i. \end{aligned}$$

Quand $|\Pi| \rightarrow 0$, les quatre blocs ont des comportements différents.

(i) **Le terme en Δt .** Sous continuité et intégrabilité suffisantes, la somme de Riemann converge :

$$\sum_i f_t(t_i, X_{t_i}) \Delta t_i \longrightarrow \int_0^t f_t(s, X_s) ds.$$

(ii) **Le terme en ΔX .** On décompose ΔX_i à partir de $dX_s = a_s ds + b_s dW_s$:

$$\Delta X_i = \int_{t_i}^{t_{i+1}} a_s ds + \int_{t_i}^{t_{i+1}} b_s dW_s.$$

Alors

$$\sum_i f_x(t_i, X_{t_i}) \Delta X_i = \sum_i f_x(t_i, X_{t_i}) \int_{t_i}^{t_{i+1}} a_s ds + \sum_i f_x(t_i, X_{t_i}) \int_{t_i}^{t_{i+1}} b_s dW_s.$$

La première somme converge vers $\int_0^t f_x(s, X_s) a_s ds$ (somme de Riemann). La seconde converge, par définition de l'intégrale d'Itô (limite en L^2 de sommes à gauche), vers

$$\int_0^t f_x(s, X_s) b_s dW_s.$$

(iii) Le terme en $(\Delta X)^2$: le crochet apparaît. Ici se situe la différence avec le calcul déterministe. On utilise l'ordre de grandeur :

$$\Delta X_i = \underbrace{\int_{t_i}^{t_{i+1}} a_s ds}_{\mathcal{O}(\Delta t_i)} + \underbrace{\int_{t_i}^{t_{i+1}} b_s dW_s}_{\mathcal{O}(\sqrt{\Delta t_i})}.$$

Le terme stochastique domine dans le carré, de sorte que

$$(\Delta X_i)^2 \approx \left(\int_{t_i}^{t_{i+1}} b_s dW_s \right)^2.$$

Justification (un peu plus rigoureuse). Notons

$$A_i := \int_{t_i}^{t_{i+1}} a_s ds, \quad B_i := \int_{t_i}^{t_{i+1}} b_s dW_s, \quad \Delta X_i = A_i + B_i.$$

Alors

$$(\Delta X_i)^2 = A_i^2 + 2A_i B_i + B_i^2.$$

Sous une hypothèse de bornes (ou de localisation) sur a , on a $|A_i| \leq C\Delta t_i$, donc

$$\sum_i A_i^2 \leq C^2 \sum_i (\Delta t_i)^2 \leq C^2 |\Pi| t \xrightarrow{|\Pi| \rightarrow 0} 0.$$

Pour le terme croisé, l'inégalité de Cauchy-Schwarz donne

$$\left| \sum_i 2A_i B_i \right| \leq 2 \left(\sum_i A_i^2 \right)^{1/2} \left(\sum_i B_i^2 \right)^{1/2}.$$

Le premier facteur tend vers 0 comme ci-dessus. Le second facteur est typiquement d'ordre 1 car $\mathbb{E}[\sum_i B_i^2] = \mathbb{E}[\int_0^t b_s^2 ds]$ (isométrie par morceaux). On obtient donc $\sum_i A_i B_i \rightarrow 0$ en probabilité. Il reste le terme principal $\sum_i B_i^2$, qui converge vers $\int_0^t b_s^2 ds$: c'est la variation quadratique de l'intégrale stochastique $\int_0^\cdot b_s dW_s$.

En sommant sur i , c'est exactement ce qui définit la variation quadratique :

$$\sum_i (\Delta X_i)^2 \rightarrow [X]_t.$$

Dans le cas d'un processus d'Itô, on sait de plus que $[X]_t = \int_0^t b_s^2 ds$, donc le bloc (iii) converge vers

$$\frac{1}{2} \int_0^t f_{xx}(s, X_s) d[X]_s = \frac{1}{2} \int_0^t f_{xx}(s, X_s) b_s^2 ds.$$

(iv) Le reste R_i . Les restes proviennent d'ordres supérieurs (typiquement $|\Delta X|^3$). Comme $|\Delta X_i| = \mathcal{O}(\sqrt{\Delta t_i})$, on a $|\Delta X_i|^3 = \mathcal{O}((\Delta t_i)^{3/2})$, et la somme de ces termes tend vers 0 quand $|\Pi| \rightarrow 0$ (on peut le formaliser en probabilité).

2.3.3.4 Étape 4 : passer à la limite et réécrire en différentiel

En rassemblant les limites (i)–(iv), on obtient la forme intégrale

$$f(t, X_t) = f(0, X_0) + \int_0^t f_t(s, X_s) ds + \int_0^t f_x(s, X_s) dX_s + \frac{1}{2} \int_0^t f_{xx}(s, X_s) d[X]_s.$$

En utilisant $dX_s = a_s ds + b_s dW_s$ et $d[X]_s = b_s^2 ds$, on retrouve la forme différentielle de l'énoncé.

2.3.4 Règle du produit et intégration par parties

Prenons deux processus d'Itô continus X et Y . En appliquant Itô à la fonction $f(x, y) = xy$ (version à deux variables), on obtient la **règle du produit stochastique** :

$$d(X_t Y_t) = X_t dY_t + Y_t dX_t + d[X, Y]_t.$$

Dans le cas déterministe (variation finie), on a $d[X, Y] = 0$ et on retrouve la formule classique.

2.3.5 Version multidimensionnelle (énoncé)

Soit $X_t \in \mathbb{R}^d$ solution d'une SDE

$$dX_t = a_t dt + B_t dW_t,$$

où $W_t \in \mathbb{R}^m$ est un brownien m -dimensionnel et B_t une matrice $d \times m$. Si $f \in C^{1,2}([0, T] \times \mathbb{R}^d)$, alors

$$df(t, X_t) = \partial_t f dt + \nabla f(t, X_t)^\top dX_t + \frac{1}{2} \text{Tr}(B_t B_t^\top \nabla^2 f(t, X_t)) dt.$$

2.3.5.1 D'où vient le terme de trace ? (lecture via les covariations)

Idee / intuition. Dans le cas scalaire, on retient $df = f_t dt + f_x dX + \frac{1}{2} f_{xx} d[X]$. En dimension d , le terme de second ordre devient

$$\frac{1}{2} \sum_{i,j=1}^d \partial_{x_i x_j} f(t, X_t) d[X^i, X^j]_t.$$

Démonstration détaillée. Si $dX_t = a_t dt + B_t dW_t$ avec $W \in \mathbb{R}^m$, alors

$$dX_t^i = a_t^i dt + \sum_{k=1}^m B_{ik}(t) dW_t^k.$$

Par bilinéarité du crochet et le fait que $[W^k, W^\ell]_t = \delta_{k\ell} t$,

$$d[X^i, X^j]_t = \sum_{k=1}^m B_{ik}(t) B_{jk}(t) dt = (B_t B_t^\top)_{ij} dt.$$

Donc

$$\frac{1}{2} \sum_{i,j=1}^d \partial_{x_i x_j} f(t, X_t) d[X^i, X^j]_t = \frac{1}{2} \sum_{i,j=1}^d \partial_{x_i x_j} f(t, X_t) (B_t B_t^\top)_{ij} dt = \frac{1}{2} \text{Tr}(B_t B_t^\top \nabla^2 f(t, X_t)) dt.$$

Cette « forme trace » est juste une manière compacte d'écrire la contraction entre la matrice de covariation instantanée $B_t B_t^\top$ et la Hessienne.

2.3.6 Deux exemples classiques à connaître

Exemple 2.1 (Carré du brownien). Avec $f(x) = x^2$, $f'(x) = 2x$, $f''(x) = 2$, on obtient

$$d(W_t^2) = 2W_t dW_t + dt.$$

En prenant l'espérance : $\mathbb{E}[W_t^2] = t$.

Exemple 2.2 (Martingale exponentielle). Pour $\lambda \in \mathbb{R}$, posons $M_t := \exp(\lambda W_t - \frac{1}{2}\lambda^2 t)$. En appliquant Itô à $f(t, x) = \exp(\lambda x - \frac{1}{2}\lambda^2 t)$, on trouve

$$dM_t = \lambda M_t dW_t,$$

donc (M_t) est une martingale (en particulier $\mathbb{E}[M_t] = 1$).

2.3.7 Fiche méthode : les règles de calcul à connaître

Cadre. Si X est un processus d'Itô

$$dX_t = a_t dt + b_t dW_t,$$

alors :

— **Crochet.** $d[X]_t = b_t^2 dt$.

— **Changement de variable.** Pour $f \in C^2$,

$$df(X_t) = f'(X_t) dX_t + \frac{1}{2} f''(X_t) d[X]_t.$$

— **Produit.** Si Y est aussi d'Itô, alors

$$d(X_t Y_t) = X_t dY_t + Y_t dX_t + d[X, Y]_t, \quad d[X, Y]_t = b_t c_t dt$$

si $dY_t = \dots + c_t dW_t$.

— **Log.** Si $X_t > 0$,

$$d(\log X_t) = \frac{1}{X_t} dX_t - \frac{1}{2} \frac{1}{X_t^2} d[X]_t.$$

Remarque 2.4. La « table de multiplication » des différentiels est une mémo-technique : $(dW)^2 = dt$, $dt dW = 0$, $(dt)^2 = 0$. Elle se déduit (et se justifie) via les crochets.

2.4 Applications en finance quantitative

2.4.1 Mouvement brownien géométrique : solution explicite et log-returns

Le modèle de Black-Scholes commence par l'hypothèse que le prix suit une diffusion proportionnelle :

$$dS_t = \mu S_t dt + \sigma S_t dW_t, \quad S_0 > 0, \sigma > 0.$$

Pour résoudre cette EDS, on applique Itô à $f(x) = \log x$ (sur $\mathbb{R}_+^*$). On a $f'(x) = 1/x$ et $f''(x) = -1/x^2$. Comme

$$d[S]_t = (\sigma S_t)^2 dt = \sigma^2 S_t^2 dt,$$

Itô donne

$$d(\log S_t) = \frac{1}{S_t} dS_t + \frac{1}{2} \left(-\frac{1}{S_t^2} \right) d[S]_t = \left(\mu - \frac{1}{2}\sigma^2 \right) dt + \sigma dW_t.$$

En intégrant :

$$\log S_t = \log S_0 + \left(\mu - \frac{1}{2}\sigma^2 \right) t + \sigma W_t,$$

soit

$$S_t = S_0 \exp \left(\left(\mu - \frac{1}{2}\sigma^2 \right) t + \sigma W_t \right).$$

Remarque 2.5. Le terme $-\frac{1}{2}\sigma^2$ est **purement stochastique** : il vient de la variation quadratique via f'' et $d[S]$. Sans lui, la solution serait fautive.

2.4.2 Black–Scholes PDE : où intervient Itô ?

On suppose (pour simplifier) un taux sans risque constant r et un sous-jacent S suivant

$$dS_t = \mu S_t dt + \sigma S_t dW_t.$$

Soit $V(t, S)$ le prix d'un produit dérivé à la date t quand le sous-jacent vaut S . En posant $X_t = S_t$ et $f(t, x) = V(t, x)$, Itô donne

$$dV(t, S_t) = \left(\partial_t V + \mu S_t \partial_S V + \frac{1}{2} \sigma^2 S_t^2 \partial_{SS} V \right) dt + \sigma S_t \partial_S V dW_t.$$

Considérons un portefeuille auto-financé $\Pi_t := V(t, S_t) - \Delta_t S_t$. Alors

$$d\Pi_t = dV(t, S_t) - \Delta_t dS_t.$$

En choisissant $\Delta_t := \partial_S V(t, S_t)$, le terme en dW_t disparaît (couverture delta) et on obtient un portefeuille sans risque à l'instant t , donc

$$d\Pi_t = r \Pi_t dt.$$

En remplaçant $\Pi_t = V - \partial_S V S$ et en identifiant les termes en dt , on arrive à la PDE de Black–Scholes :

$$\partial_t V + \frac{1}{2} \sigma^2 S^2 \partial_{SS} V + r S \partial_S V - r V = 0.$$

Remarque 2.6. Le terme $\frac{1}{2} \sigma^2 S^2 \partial_{SS} V$ est exactement le terme d'Itô associé à la variation quadratique de S . Il mesure la sensibilité *convexe* (Gamma) du prix et est au coeur du hedging.

2.4.3 Feynman–Kac (preuve guidée) : Itô $\Rightarrow$ représentation en espérance

Une manière très utile (en pratique *et* en théorie) de relire Black–Scholes est : *la PDE est exactement la condition qui rend un certain processus actualisé martingale*. Cette idée, une fois généralisée, devient la formule de Feynman–Kac.

Étape 0 — construire la mesure risque-neutre dans Black–Scholes (cas constant). Sous $\mathbb{P}$, on part du modèle (simple) à coefficients constants

$$dS_t = \mu S_t dt + \sigma S_t dW_t, \quad \sigma > 0. \quad (2.1)$$

On fixe un taux sans risque constant r et on pose le *market price of risk*

$$\lambda := \frac{\mu - r}{\sigma}.$$

On définit alors le processus exponentiel

$$Z_t := \exp\left(-\lambda W_t - \frac{1}{2} \lambda^2 t\right), \quad t \in [0, T]. \quad (2.2)$$

(i) **Z est une martingale de moyenne 1.** Comme $W_t \sim \mathcal{N}(0, t)$, on a $\mathbb{E}[\exp(-\lambda W_t)] = \exp(\frac{1}{2} \lambda^2 t)$, donc $\mathbb{E}[Z_t] = 1$. De plus, pour $s \leq t$,

$$Z_t = Z_s \exp\left(-\lambda(W_t - W_s) - \frac{1}{2} \lambda^2 (t - s)\right),$$

et comme $W_t - W_s$ est indépendant de $\mathcal{F}_s$ et gaussien $\mathcal{N}(0, t - s)$, on obtient $\mathbb{E}[Z_t | \mathcal{F}_s] = Z_s$.

(ii) **Définition de $\mathbb{Q}$.** On définit une nouvelle probabilité $\mathbb{Q}$ sur $\mathcal{F}_T$ par

$$\frac{d\mathbb{Q}}{d\mathbb{P}} \Big|_{\mathcal{F}_T} = Z_T. \quad (2.3)$$

La martingalité de Z assure la cohérence temporelle : pour tout $t \leq T$, on a bien $\frac{d\mathbb{Q}}{d\mathbb{P}} \Big|_{\mathcal{F}_t} = Z_t$.

(iii) **Brownien sous $\mathbb{Q}$ (preuve directe à un pas).** Posons

$$W_t^{\mathbb{Q}} := W_t + \lambda t. \quad (2.4)$$

On montre que $(W_t^{\mathbb{Q}})$ est un brownien sous $\mathbb{Q}$. Fixons $0 \leq s < t \leq T$ et $u \in \mathbb{R}$. Par formule de Bayes (changement de mesure),

$$\mathbb{E}^{\mathbb{Q}}[e^{iu(W_t^{\mathbb{Q}} - W_s^{\mathbb{Q}})} \mid \mathcal{F}_s] = \frac{1}{Z_s} \mathbb{E}[Z_t e^{iu(W_t - W_s + \lambda(t-s))} \mid \mathcal{F}_s].$$

Or $Z_t = Z_s \exp(-\lambda(W_t - W_s) - \frac{1}{2}\lambda^2(t-s))$, donc

$$\begin{aligned} \mathbb{E}^{\mathbb{Q}}[e^{iu(W_t^{\mathbb{Q}} - W_s^{\mathbb{Q}})} \mid \mathcal{F}_s] &= e^{iu\lambda(t-s)} e^{-\frac{1}{2}\lambda^2(t-s)} \mathbb{E}\left[\exp((- \lambda + iu)(W_t - W_s))\right] \\ &= e^{iu\lambda(t-s)} e^{-\frac{1}{2}\lambda^2(t-s)} \exp\left(\frac{1}{2}(-\lambda + iu)^2(t-s)\right) \\ &= \exp\left(-\frac{1}{2}u^2(t-s)\right), \end{aligned}$$

car $W_t - W_s \sim \mathcal{N}(0, t-s)$ sous $\mathbb{P}$. Cette fonction caractéristique est celle d'une $\mathcal{N}(0, t-s)$ et ne dépend pas de $\mathcal{F}_s$: les accroissements de $W^{\mathbb{Q}}$ sont gaussiens centrés, de variance $t-s$, et indépendants du passé. Donc $W^{\mathbb{Q}}$ est un brownien.

(iv) **Dynamique sous $\mathbb{Q}$.** En écrivant $dW_t = dW_t^{\mathbb{Q}} - \lambda dt$ dans (2.1), on obtient

$$dS_t = rS_t dt + \sigma S_t dW_t^{\mathbb{Q}}, \quad (2.5)$$

c'est-à-dire exactement la dynamique risque-neutre attendue.

Étape 1 — PDE $\Rightarrow$ martingale actualisée. Soit un payoff européen $H = \Phi(S_T)$. Supposons qu'il existe une fonction $V \in C^{1,2}$ telle que

$$\partial_t V + \frac{1}{2}\sigma^2 S^2 \partial_{SS} V + rS \partial_S V - rV = 0, \quad V(T, S) = \Phi(S), \quad (2.6)$$

et que V (ainsi que $\partial_S V$) a une croissance au plus polynomiale en S . On considère, sous $\mathbb{Q}$, le processus actualisé

$$M_t := e^{-rt} V(t, S_t).$$

En appliquant Itô à $V(t, S_t)$ sous (2.5) puis la règle du produit à $e^{-rt} V$, on obtient

$$dM_t = e^{-rt} \left(\partial_t V + \frac{1}{2}\sigma^2 S_t^2 \partial_{SS} V + rS_t \partial_S V - rV \right)(t, S_t) dt + e^{-rt} \sigma S_t \partial_S V(t, S_t) dW_t^{\mathbb{Q}}.$$

Par (2.6), le drift est nul, donc

$$dM_t = e^{-rt} \sigma S_t \partial_S V(t, S_t) dW_t^{\mathbb{Q}}. \quad (2.7)$$

Le terme de droite est une intégrale stochastique. Sous nos hypothèses de croissance et parce que S_t est lognormal sous $\mathbb{Q}$ (donc a des moments de tout ordre), on a $\mathbb{E}^{\mathbb{Q}}[\int_0^T e^{-2rs} \sigma^2 S_s^2 (\partial_S V(s, S_s))^2 ds] < \infty$, donc l'intégrale est une vraie martingale (de carré intégrable) et (M_t) est une martingale.

Étape 2 — représentation en espérance. Comme M est une martingale,

$$M_t = \mathbb{E}^{\mathbb{Q}}[M_T \mid \mathcal{F}_t] \Rightarrow V(t, S_t) = \mathbb{E}^{\mathbb{Q}}[e^{-r(T-t)} \Phi(S_T) \mid \mathcal{F}_t].$$

Sanity check. Pour $\Phi(s) = s$ on obtient $V(t, S_t) = S_t$, cohérent avec le fait que le sous-jacent est précisément un actif tradable de prix S_t .

Remarque (réciproque à retenir). Si l'on définit $V(t, S_t)$ par l'espérance conditionnelle ci-dessus et qu'on suppose (a posteriori) que V est $C^{1,2}$, alors $M_t = e^{-rt} V(t, S_t)$ est une martingale, donc son terme de drift dans la décomposition d'Itô doit être nul : on retrouve la PDE (2.6).

2.4.4 Variance réalisée, variance swap et crochet du log-prix

Dans un modèle général où le log-prix suit

$$d(\log S_t) = \alpha_t dt + \sigma_t dW_t,$$

on a

$$[\log S]_T = \int_0^T \sigma_t^2 dt.$$

Dans la pratique, on observe S à des dates discrètes et on forme

$$RV_T = \sum_{i=0}^{n-1} (\log S_{t_{i+1}} - \log S_{t_i})^2.$$

Sous des hypothèses standards (pas de bruit de microstructure, maillage qui tend vers 0), RV_T approxime $[\log S]_T$: c'est la base de l'estimation non paramétrique de la volatilité intégrée et du pricing de produits sur variance (variance swaps, vol swaps).

2.4.5 Encadré (optionnel) : un lien « modèle-free » entre options et variance

Le crochet (donc la variation quadratique) apparaît aussi dans des résultats *sans modèle* : on peut relier la variance réalisée à des payoffs convexes (log, options OTM). Nous donnons ici une version guidée (niveau intuition mathématique) qui explique où intervient Itô.

2.4.5.1 1) Une identité de trajectoire via Itô

Supposons $S_t > 0$ continu et que $d(\log S_t) = \alpha_t dt + \sigma_t dW_t$. Alors $[\log S]_T = \int_0^T \sigma_t^2 dt$. Par Itô appliqué à $f(x) = \log x$, on a (en notant $X_t = S_t$) :

$$d(\log S_t) = \frac{1}{S_t} dS_t - \frac{1}{2} \frac{1}{S_t^2} d[S]_t.$$

En intégrant :

$$\log \frac{S_T}{S_0} = \int_0^T \frac{1}{S_t} dS_t - \frac{1}{2} \int_0^T \frac{1}{S_t^2} d[S]_t.$$

Mais, comme $d[S]_t = S_t^2 d[\log S]_t$ (puisque $dS_t = S_t d(\log S_t) + \dots$ et les crochets ne voient que la partie en dW), on a

$$\frac{1}{S_t^2} d[S]_t = d[\log S]_t.$$

Donc

$$[\log S]_T = 2 \int_0^T \frac{1}{S_t} dS_t - 2 \log \frac{S_T}{S_0}.$$

Message : la variance réalisée (limite de la somme des carrés des log-returns) est liée à une intégrale « en $1/S$ » et à un payoff $\log(S_T)$.

2.4.5.2 2) Pourquoi cela suggère une réplication par options

En valorisation risque-neutre, des intégrales du type $\int \frac{1}{S_t} dS_t$ peuvent être répliquées par des stratégies de trading dynamiques (deltas), tandis que des payoffs convexes comme $-\log(S_T)$ se réécrivent sous forme de représentations intégrales en options vanilles (via des identités de type Breeden–Litzenberger).

Le résultat final (dans un cadre idéalisé, sans sauts, et avec une grille dense) est que le prix d'un *variance swap* peut s'exprimer comme :

$$\mathbb{E}^{\mathbb{Q}}[[\log S]_T] \quad (\text{variance intégrée risque-neutre})$$

et que cette quantité est répliquable (statique) par un continuum d'options OTM (calls/puts) plus une position dynamique en sous-jacent.

Remarque 2.7. Cet encadré n'est pas nécessaire pour utiliser Itô au quotidien, mais il montre la portée de la variation quadratique en finance : un objet « de trajectoire » devient un objet « de marché » observable via les options.

2.4.6 Lecture « finance » du terme de correction : convexité $\times$ variance

La formule d'Itô peut être lue comme : quand on applique une fonction convexe à une variable aléatoire qui bouge à l'échelle $\sqrt{dt}$, le gain moyen comporte un terme de second ordre.

Pour simplifier, supposons $dX_t = b_t dW_t$ (pas de drift) et considérons $Y_t = f(X_t)$ avec $f'' \geq 0$. Alors

$$dY_t = f'(X_t)b_t dW_t + \frac{1}{2}f''(X_t)b_t^2 dt.$$

Le terme en dW_t est de moyenne nulle, mais le terme en dt est *positif* : il reflète une **dérive moyenne due à la convexité** (Jensen + bruit).

2.4.7 Un mot sur les sauts (hors programme, mais à connaître)

Si le sous-jacent présente des sauts, la variation quadratique contient en plus une somme des carrés des sauts :

$$[X]_t = [X]_t^c + \sum_{0 < s \leq t} (\Delta X_s)^2,$$

où $[X]^c$ est la partie continue. Il existe une version d'Itô avec sauts (formule d'Itô-Lévy) où apparaissent des termes supplémentaires. Dans beaucoup d'applications (options à court terme, events), cette extension est importante, mais nous restons ici dans le cadre continu.

2.5 Annexes techniques (preuves et compléments)

2.5.1 Convergences : en probabilité, en L^2 , presque sûre

On utilise plusieurs notions de convergence.

Définition 2.4 (Convergence en probabilité). Une suite X_n converge vers X *en probabilité* si, pour tout $\varepsilon > 0$,

$$\mathbb{P}(|X_n - X| > \varepsilon) \xrightarrow{n \rightarrow \infty} 0.$$

Définition 2.5 (Convergence dans L^2). On dit que $X_n \rightarrow X$ dans L^2 si $\mathbb{E}[(X_n - X)^2] \rightarrow 0$.

Remarque 2.8. La convergence L^2 implique la convergence en probabilité (par Chebyshev). La convergence presque sûre est plus forte, et l'on obtient souvent des résultats presque sûrs en appliquant Borel-Cantelli à une suite d'estimations de type Chebyshev.

2.5.2 Borel-Cantelli et quadratic variation dyadique (preuve p.s.)

On donne une preuve classique de $[W]_t = t$ *presque sûrement* le long des partitions dyadiques.

Fixons $t > 0$ et considérons $\Pi_n = \{k2^{-n}t : k = 0, \dots, 2^n\}$. Posons

$$S_n := \sum_{k=0}^{2^n-1} (W_{(k+1)2^{-n}t} - W_{k2^{-n}t})^2.$$

Comme précédemment,

$$\mathbb{E}[S_n] = t, \quad \text{Var}(S_n) = 2 \sum_{k=0}^{2^n-1} (2^{-n}t)^2 = 2 \cdot 2^n \cdot 2^{-2n}t^2 = \frac{2t^2}{2^n}.$$

Par Chebyshev,

$$\mathbb{P}(|S_n - t| > \varepsilon) \leq \frac{\text{Var}(S_n)}{\varepsilon^2} = \frac{2t^2}{2^n \varepsilon^2}.$$

La série $\sum_n \mathbb{P}(|S_n - t| > \varepsilon)$ converge, donc par Borel–Cantelli : pour tout $\varepsilon > 0$, l'événement $\{|S_n - t| > \varepsilon\}$ ne se produit qu'un nombre fini de fois. Autrement dit, $S_n \rightarrow t$ p.s.

2.5.3 Pourquoi le brownien n'est pas de variation finie : preuve

On veut montrer que, presque sûrement, la trajectoire $t \mapsto W_t(\omega)$ a une variation totale infinie sur tout intervalle $[0, T]$ avec $T > 0$. L'idée est : *une fonction continue de variation finie a une variation quadratique nulle*, alors que l'on vient d'établir $[W]_T = T$.

1) Outil : variation finie $\Rightarrow$ crochet nul (cas continu). Soit $x : [0, T] \rightarrow \mathbb{R}$ un chemin continu de variation totale finie. On note

$$\text{Var}(x; [0, T]) := \sup_{\Pi} \sum_i |x_{t_{i+1}} - x_{t_i}| < \infty,$$

où le sup porte sur toutes les partitions Π de $[0, T]$. Fixons une partition $\Pi = \{0 = t_0 < \dots < t_n = T\}$ et posons $\Delta_i x := x_{t_{i+1}} - x_{t_i}$. Alors

$$\sum_{i=0}^{n-1} (\Delta_i x)^2 \leq \left(\max_{0 \leq i \leq n-1} |\Delta_i x| \right) \sum_{i=0}^{n-1} |\Delta_i x| \leq \left(\max_i |\Delta_i x| \right) \text{Var}(x; [0, T]).$$

Si $|\Pi| \rightarrow 0$, la continuité de x implique $\max_i |\Delta_i x| \rightarrow 0$, donc

$$\sum_{i=0}^{n-1} (\Delta_i x)^2 \xrightarrow{|\Pi| \rightarrow 0} 0. \quad (2.8)$$

Autrement dit, tout candidat à « crochet » construit comme limite de sommes de carrés d'incrémentes est nul pour un chemin continu de variation finie.

2) Application au brownien. En particulier, si une trajectoire $W(\omega)$ était de variation finie, on aurait la limite (2.8) le long de toute suite de partitions de maille $\rightarrow 0$. Or on a montré juste au-dessus (via Borel–Cantelli sur les partitions dyadiques) que, pour tout $t > 0$,

$$\sum_{k=0}^{2^n-1} (W_{(k+1)2^{-n}t}(\omega) - W_{k2^{-n}t}(\omega))^2 \xrightarrow{n \rightarrow \infty} t \quad \text{p.s.}$$

C'est incompatible avec (2.8) dès que $t > 0$. Donc, presque sûrement, W n'est pas de variation finie sur $[0, t]$ (et donc sur aucun intervalle non trivial).

2.5.4 Stratonovich vs Itô (complément)

On définit parfois une intégrale *symétrique* en utilisant des points milieux dans les sommes discrètes. Elle conduit à la notation $\int H_t \circ dW_t$ (Stratonovich). Pour un intégrand de la forme $H_t = g(W_t)$ avec g suffisamment régulière, on a la formule de conversion

$$\int_0^t g(W_s) \circ dW_s = \int_0^t g(W_s) dW_s + \frac{1}{2} \int_0^t g'(W_s) ds.$$

On retrouve ici la même source : le $\frac{1}{2}$ vient de $(\Delta W)^2 \sim \Delta t$, donc du crochet $[W]_t = t$.

2.5.5 Petit glossaire

- **Crochet / variation quadratique** : $[X]_t = \lim \sum (\Delta X)^2$.
- **Covariation** : $[X, Y]_t = \lim \sum (\Delta X)(\Delta Y)$.
- **Processus d'Itô** : $X_t = X_0 + \int a dt + \int b dW$.

— **Formule d'Itô** : $df(t, X_t) = f_t dt + f_x dX_t + \frac{1}{2} f_{xx} d[X]_t$.

2.6 Mode microscope : construire Itô et dériver la formule

2.6.1 Intégrale d'Itô et isométrie

Processus simples. On commence par $H_t = \sum_{k=0}^{n-1} H_{t_k} \mathbf{1}_{(t_k, t_{k+1}]}(t)$ avec H_{t_k} $\mathcal{F}_{t_k}$ -mesurable. On définit

$$\int_0^T H_t dW_t := \sum_{k=0}^{n-1} H_{t_k} (W_{t_{k+1}} - W_{t_k}).$$

Isométrie (calcul clé). Par indépendance et centrage des incréments,

$$\mathbb{E} \left[\left(\int_0^T H_t dW_t \right)^2 \right] = \sum_k \mathbb{E} [H_{t_k}^2] (t_{k+1} - t_k) = \mathbb{E} \left[\int_0^T H_t^2 dt \right].$$

Cette identité (isométrie d'Itô) permet d'étendre l'intégrale à des intégrands plus généraux par complétion en L^2 .

Sanity check. Dimension : dW est d'ordre $\sqrt{dt}$, donc l'intégrale d'Itô est d'ordre $\sqrt{T}$; l'isométrie donne une variance proportionnelle à $\int H^2 dt$.

2.6.2 Formule d'Itô par partitions et Taylor

Cadre. Pour exposer l'idée, on prend d'abord $f \in C^2$ et $X_t = W_t$. Sur une partition π , Taylor à l'ordre 2 donne

$$f(W_{t_{i+1}}) - f(W_{t_i}) = f'(W_{t_i}) \Delta W_i + \frac{1}{2} f''(W_{t_i}) (\Delta W_i)^2 + R_i,$$

où R_i est un reste d'ordre $(\Delta W_i)^3$. En sommant et en passant à la limite :

- $\sum_i f'(W_{t_i}) \Delta W_i \rightarrow \int_0^t f'(W_s) dW_s$ (définition de l'intégrale) ;
- $\sum_i (\Delta W_i)^2 \rightarrow t$ (chapitre chapitre 1) donc $\sum_i \frac{1}{2} f''(W_{t_i}) (\Delta W_i)^2 \rightarrow \frac{1}{2} \int_0^t f''(W_s) ds$;
- le reste R_i est négligeable car $(\Delta W_i)^3$ est d'ordre $(\Delta t)^{3/2}$.

On obtient :

$$df(W_t) = f'(W_t) dW_t + \frac{1}{2} f''(W_t) dt.$$

Extension (Itô process). Si $dX_t = a_t dt + b_t dW_t$, alors

$$df(t, X_t) = \partial_t f dt + \partial_x f dX_t + \frac{1}{2} \partial_{xx} f b_t^2 dt = \left(\partial_t f + a_t \partial_x f + \frac{1}{2} b_t^2 \partial_{xx} f \right) dt + b_t \partial_x f dW_t.$$

2.6.3 Itô vs Stratonovich : conversion

La règle pratique est

$$\int_0^t H_s \circ dW_s = \int_0^t H_s dW_s + \frac{1}{2} [H, W]_t.$$

Si H est un Itô process $dH_t = \alpha_t dt + \beta_t dW_t$, alors $[H, W]_t = \int_0^t \beta_s ds$ et

$$\int_0^t H_s \circ dW_s = \int_0^t H_s dW_s + \frac{1}{2} \int_0^t \beta_s ds.$$

Intuition de marché. En finance, la convention Itô est standard car elle s'aligne sur la filtration (information) et sur les martingales sous $\mathbb{Q}$. Stratonovich apparaît plutôt en physique (bruit comme limite de signaux réguliers).

2.7 Pièges classiques / erreurs fréquentes

- Oublier le terme $\frac{1}{2}f''b^2dt$: c'est l'erreur « de chaîne classique ».
- Confondre Itô et Stratonovich : la conversion ajoute un drift.
- Traiter dW comme dt : dW est d'ordre $\sqrt{dt}$, mais $(dW)^2$ est d'ordre dt .

2.8 Checklist — savoir refaire sans regarder

- Définir l'intégrale d'Itô pour des processus simples et prouver l'isométrie.
- Démontrer la formule d'Itô par partitions (Taylor + $[W]_t = t$).
- Appliquer Itô à des fonctions usuelles : x^2 , $\ln x$, exponentielle.
- Convertir Stratonovich $\leftrightarrow$ Itô dans des cas simples.

Chapitre 3

Toolbox entretien : martingales, changements de mesure, identités

3.1 Idée centrale

En entretien, on attend que tu saches passer rapidement entre (i) SDE, (ii) martingales, (iii) mesures/numéraires, et que tu identifies les hypothèses (intégrabilité, localisation, régularité). Le contenu ci-dessous sert de *checklist* haute densité.

3.2 Identités à connaître (et à utiliser)

3.2.1 Itô isometry (1D)

Si H est adapté et $\mathbb{E} \int_0^T H_t^2 dt < \infty$, alors

$$\mathbb{E} \left[\left(\int_0^T H_t dW_t \right)^2 \right] = \mathbb{E} \int_0^T H_t^2 dt.$$

Usage. Contrôler la variance, prouver convergence L^2 .

3.2.2 BDG (borne du sup, « interview-level »)

Pour $p \geq 1$, il existe C_p tel que, pour toute martingale locale continue M ,

$$\mathbb{E} \left[\sup_{t \leq T} |M_t|^p \right] \leq C_p \mathbb{E} \left[[M]_T^{p/2} \right].$$

Usage. Contrôler un sup sur $[0, T]$ via la variation quadratique.

3.2.3 Covariation et intégration par parties

Pour semimartingales continues X, Y :

$$d(X_t Y_t) = X_t dY_t + Y_t dX_t + d[X, Y]_t.$$

En particulier, si $X = \int a dW$ et $Y = \int b dW$, alors $[X, Y]_t = \int_0^t a_s b_s ds$.

3.2.4 Exponential martingale (Doléans–Dade)

Pour θ adapté (Novikov),

$$\mathcal{E}\left(-\int_0^t \theta_s dW_s\right) = \exp\left(-\int_0^t \theta_s dW_s - \frac{1}{2} \int_0^t \theta_s^2 ds\right)$$

est une martingale strictement positive. **Usage.** Construire un changement de mesure (Girsanov).

3.2.5 Itô en dimension d (formule « à ressortir »)

Si $X_t \in \mathbb{R}^d$ suit $dX_t = b_t dt + \sigma_t dW_t$ avec W m -dimensionnel et $\Sigma_t = \sigma_t \sigma_t^\top$, alors pour $f \in C^{1,2}$,

$$df(t, X_t) = \partial_t f dt + \nabla f^\top dX_t + \frac{1}{2} \text{tr}(\Sigma_t \nabla^2 f) dt.$$

Usage. Passer du modèle au générateur (Feynman–Kac, PDE, moments).

3.2.6 Itô sur $\log S$ (GBM)

Si $S_t > 0$ et $dS_t/S_t = \mu_t dt + \sigma_t dW_t$, alors

$$d \log S_t = \left(\mu_t - \frac{1}{2} \sigma_t^2\right) dt + \sigma_t dW_t.$$

Usage. Dériver les densités lognormales, tester une simulation, à citer en pricing.

3.3 Girsanov (multi-dim, version « desk-ready »)

Si W est d -dimensionnel et $\theta_t \in \mathbb{R}^d$,

$$\frac{d\mathbb{Q}}{d\mathbb{P}} \Big|_{\mathcal{F}_T} = \exp\left(-\int_0^T \theta_t^\top dW_t - \frac{1}{2} \int_0^T \|\theta_t\|^2 dt\right), \quad W_t^\mathbb{Q} = W_t + \int_0^t \theta_s ds.$$

Alors $W^\mathbb{Q}$ est un Brownien sous $\mathbb{Q}$. **Message.** On *déplace* les drifts, pas les diffusions.

3.4 Changement de numéraire (résumé)

Pour un numéraire $N_t > 0$, on définit $\mathbb{Q}^N$ tel que V_t/N_t soit une martingale. Formule :

$$V_t = N_t \mathbb{E}^{\mathbb{Q}^N} \left[\frac{\Phi}{N_T} \mid \mathcal{F}_t \right].$$

Usage. Pricing de forwards, swaps, options sur taux ; simplifier les drifts.

3.5 Localisation : comment sauver une preuve

Si une condition d'intégrabilité globale est douteuse, on localise avec

$$\tau_n = \inf\{t : |X_t| \geq n\} \wedge T,$$

on prouve sur $[0, \tau_n]$, puis on fait $n \rightarrow \infty$. **Mot-clé.** *Local martingale* vs martingale (attention à l'uniforme intégrabilité).

3.6 Arrêts : optional sampling (ce qu’il faut dire proprement)

Si M est une vraie martingale uniforme intégrable et τ un temps d’arrêt borné, alors $\mathbb{E}[M_\tau] = \mathbb{E}[M_0]$. **Piège.** Pour une *local martingale*, l’égalité peut être fausse (ex : strict local martingales). En entretien : dire « sous condition d’UI / intégrabilité ».

3.7 Local time et Itô–Tanaka (utile sur digitals/barrières)

Pour une semimartingale continue X ,

$$|X_t| = |X_0| + \int_0^t \operatorname{sgn}(X_s) dX_s + L_t^0(X),$$

où $L_t^0(X)$ est le *local time* en 0. **Message.** Quand f n’est pas C^2 (kinks), Itô requiert un terme de local time.

3.8 Dambis–Dubins–Schwarz (time change : « trick »)

Si M est une martingale locale continue avec $[M]_t$ croissante, alors il existe un Brownien B tel que

$$M_t = B_{[M]_t}.$$

Usage. Ramener des propriétés à celles du Brownien via le temps aléatoire.

3.9 Sanity checks de calcul stochastique

- Dimensions : drift en 1/temps, diffusion en $1/\sqrt{\text{temps}}$.
- Dans Itô, le terme $\frac{1}{2}f_{xx}\sigma^2$ vient de $(dW)^2 = dt$.
- Si tu proposes un changement de mesure : vérifier Novikov/Kazamaki (au moins citer).
- Si tu annonces une martingale : contrôler l’intégrabilité, sinon dire « local martingale ».

3.10 Implémentation : deux checks rapides (simulation)

```
import numpy as np

def qv_brownian(T=1.0, n=10_000, m=1_000):
    dt = T / n
    dW = np.sqrt(dt) * np.random.randn(m, n)
    qv = np.sum(dW**2, axis=1)
    return qv.mean(), qv.std()

# expected: E[QV_T] ~ T, std ~ sqrt(2T^2/n)
```

3.11 Pièges classiques (interview)

- Confondre drift historique et drift sous $\mathbb{Q}$ (ou sous numéraire différent).
- Utiliser Itô sur une fonction non $C^{1,2}$ sans précaution (local time).
- Oublier la covariation dans l’intégration par parties.

Chapitre 4

Applications entretien : Girsanov, Feynman–Kac, simulation

4.1 Girsanov : passer du drift historique au drift risque-neutre

Idée centrale. Un changement de mesure *re-centre* un Brownien : on déplace le drift dans les SDE tout en conservant la même volatilité. En finance, c’est le mécanisme qui fait disparaître le drift historique μ au profit du drift de *carry* ($r - q$) sous la mesure de pricing $\mathbb{Q}$.

4.1.1 Cadre

Soit $(W_t)_{t \geq 0}$ un Brownien sous $\mathbb{P}$ et θ_t un processus adapté tel que la condition de Novikov soit satisfaite :

$$\mathbb{E}^{\mathbb{P}} \left[\exp \left(\frac{1}{2} \int_0^T \theta_s^2 ds \right) \right] < \infty.$$

On définit la densité de Radon–Nikodym sur $\mathcal{F}_T$:

$$\frac{d\mathbb{Q}}{d\mathbb{P}} \Big|_{\mathcal{F}_T} = \exp \left(- \int_0^T \theta_s dW_s - \frac{1}{2} \int_0^T \theta_s^2 ds \right).$$

Alors le processus

$$W_t^{\mathbb{Q}} := W_t + \int_0^t \theta_s ds$$

est un Brownien sous $\mathbb{Q}$.

4.1.2 Application canonique : GBM

Sous $\mathbb{P}$,

$$\frac{dS_t}{S_t} = \mu dt + \sigma dW_t.$$

Sous $\mathbb{Q}$ (numéraire cash $B_t = e^{rt}$, dividende continu q), on veut

$$\frac{dS_t}{S_t} = (r - q) dt + \sigma dW_t^{\mathbb{Q}}.$$

On choisit donc $\theta = \frac{\mu - (r - q)}{\sigma}$ (constant) : on obtient bien le drift $(r - q)$ sous $\mathbb{Q}$.

Sanity checks.

- **Martingale** : $S_t e^{-(r - q)t}$ doit être une $\mathbb{Q}$ -martingale.
- **Dimensions** : θ est sans dimension, μ, r, q sont en $1/\text{temps}$, σ est en $1/\sqrt{\text{temps}}$.

4.2 Feynman-Kac : PDE $\leftrightarrow$ espérance conditionnelle

Idée centrale. Une PDE de pricing est l'écriture analytique du fait que le prix actualisé est une martingale sous $\mathbb{Q}$.

4.2.1 Forme utile en entretien

Sous $\mathbb{Q}$, X_t suit $dX_t = b(t, X_t)dt + \sigma(t, X_t)dW_t$. Si V résout (régularité suffisante)

$$\partial_t V + \mathcal{L}V - rV = 0, \quad V(T, x) = \Phi(x),$$

où $\mathcal{L}$ est le générateur $\mathcal{L}V = bV_x + \frac{1}{2}\sigma^2 V_{xx}$ (ou matrice en dimension d), alors

$$V(t, X_t) = \mathbb{E}^{\mathbb{Q}} \left[e^{-r(T-t)} \Phi(X_T) \mid \mathcal{F}_t \right].$$

4.2.2 Pont direct via Itô

Poser $M_t = e^{-rt}V(t, X_t)$, appliquer Itô, utiliser la PDE pour annuler le drift $\Rightarrow M$ est martingale.

Piège classique. Payoff non lisse (digitals, barrières) : la PDE reste vraie au sens faible, mais une dérivation « à la main » peut nécessiter une régularisation (et parfois un *local time*).

4.3 Simulation : Euler, biais, diagnostics

Idée centrale. En entretien, on attend que tu saches distinguer *biais de discrétisation* (erreur de schéma) et *variance Monte Carlo*, et que tu proposes des checks simples.

4.3.1 Euler-Maruyama (1D)

$$X_{t+\Delta} = X_t + b(t, X_t)\Delta + \sigma(t, X_t)\sqrt{\Delta}Z, \quad Z \sim \mathcal{N}(0, 1).$$

Convergence : forte $O(\sqrt{\Delta})$ (typique), faible $O(\Delta)$ en diffusion régulière.

4.3.2 Exemple : GBM sous $\mathbb{Q}$

Pour $dS_t = (r - q)S_t dt + \sigma S_t dW_t$:

$$S_{t+\Delta} = S_t \exp \left((r - q - \frac{1}{2}\sigma^2)\Delta + \sigma\sqrt{\Delta}Z \right)$$

est **exact** (utile pour tester un code).

4.3.3 Checks concrets (à citer)

- **Martingale test** : $\mathbb{E}^{\mathbb{Q}}[S_T e^{-(r-q)T}] \approx S_0$.
- **Limites** : $\sigma \rightarrow 0$ (trajectoires quasi-déterministes), $T \rightarrow 0$ (payoff $\approx$ intrinsèque).
- **Régression** : prix MC d'un call vs formule fermée BS (erreur $\sim 1/\sqrt{N}$).
- **Stabilité** : underflow/overflow pour lognormal (travailler en log, normaliser).

4.4 Ce qu'on te demandera (format entretien)

- Expliquer *pourquoi* μ disparaît dans BS (réplication / numéraire / Girsanov).

- Donner un exemple où Itô *échoue* naïvement (fonction non $C^{1,2}$, local time).
- Discuter *erreur* : discrétisation vs variance, et comment diagnostiquer chacune.

Interview Pack — Partie IV (core)

Black–Scholes (pricing continu)

Table des matières

1	Black–Scholes : dérivation et formule (avec rappels Itô applicatifs)	1
1.1	Avant-propos : de Itô au pricing continu (Black–Scholes)	1
	Avant-propos : prérequis, notations, objectifs	2
1.2	Préliminaires de calcul stochastique	3
1.1	Espace probabilisé filtré : formaliser l’information	3
1.2	Mouvement brownien : la brique aléatoire de base	3
1.3	Intégrale d’Itô : intégrer contre le bruit	4
1.4	Martingales : le langage des prix (actualisés)	5
1.5	Processus d’Itô et EDS (équations différentielles stochastiques)	6
1.6	Lemme d’Itô : l’outil clé	6
1.7	Comment Itô conduit à la PDE de Black–Scholes	8
1.8	Le marché Black–Scholes : actifs et portefeuilles	9
1.9	Où intervient Itô ? Dynamique du prix d’une option	10
1.10	Dérivation pas à pas de la PDE de Black–Scholes	10
1.11	Réplication explicite et unicité du prix	11
1.12	Extension : dividendes continus et coût de portage	12
1.13	Mesure risque-neutre et Feynman–Kac : une autre lecture	13
1.14	Intermède discret : modèle binomial (1 pas) et probabilité risque-neutre	14
1.15	Fiche d’oral : expliquer la dérivation en 10 minutes	15
1.16	De la PDE à la formule de Black–Scholes	16
1.17	Solution explicite de S_t : Itô sur $\log S_t$	16
1.18	Calcul détaillé du prix d’une call européenne	16
1.19	Résoudre la PDE : réduction à l’équation de la chaleur	18
1.20	Mode microscope : PDE, formule fermée, greeks (pas à pas)	20
1.21	Pièges classiques / erreurs fréquentes	21
1.22	Checklist — savoir refaire sans regarder	21
2	Compléments Black–Scholes : greeks, limites, numérique et panorama	22
2.1	Avant-propos : au-delà de la formule (greeks, couverture, smile)	22
2.2	Greeks : relire la réplication	23
2.3	Couverture en pratique : discrétisation et PnL de couverture	25
2.4	Limites du modèle et motivation de la volatilité stochastique	26
2.5	Pourquoi ajouter une dynamique de volatilité ?	26
2.6	Modèle de Heston : dynamique sous $\mathbb{P}$ et sous $\mathbb{Q}$	26
2.7	Itô en dimension 2 : dériver la PDE de Heston	27
2.8	Pourquoi Heston reste calculable : structure affine et fonction caractéristique	28
2.9	Calibration : lecture qualitative des paramètres	28

2.10 Comparaison Black–Scholes / Heston (résumé)	28
2.11 Corrigé (éléments de solution)	29
2.12 Complétion du carré (rappel)	31
2.13 Table mnémotechnique d'Itô	32
2.14 Formule d'Itô et delta-hedging : obtenir la PDE	32
2.15 Résolution : formules fermées de Black–Scholes (call/put européens)	32
2.16 De la PDE à l'espérance : la formule de Feynman–Kac (preuve guidée)	33
2.17 Définitions et point de vue « optimal stopping »	34
2.18 Formulation PDE : problème à frontière libre	34
2.19 Méthodes numériques (à connaître et savoir justifier)	34
2.20 Panorama des options : vanilles, digitals, exotiques	34
2.21 Comment choisir une méthode de pricing ?	35
2.22 Arbres binomiaux / trinômiaux	35
2.23 PDE et différences finies	35
2.24 Monte Carlo : universel mais bruité	36
2.25 Fourier / FFT : rapide pour les vanilles	36
2.26 Pourquoi sortir de Black–Scholes ? (smile, skew, leverage)	37
2.27 Trois familles de modèles (vue d'ensemble)	37
2.28 Modèle de Heston : définition et interprétation	37
2.29 PDE de Heston et incomplétude : ce qui change par rapport à BS	38
2.30 Pricing des vanilles en Heston : l'idée « Fourier »	38
2.31 Simulation et pricing numérique en Heston (ce qu'il faut connaître)	39
Conclusion	40
2.32 Fiche mémo : payoffs et écritures risque-neutres	40
2.33 Fiche mémo : formules Black–Scholes	40
2.34 Fiche mémo : Greeks Black–Scholes (vanilles)	40
2.35 Glossaire rapide (produits et mots-clés)	41
2.36 Mode microscope : vol implicite, smile et méthodes	41
2.37 Pièges classiques / erreurs fréquentes	41
2.38 Checklist — savoir refaire sans regarder	41
3 Black–Scholes en pratique : smile, hedging discret, numérique (desk-ready)	43
3.1 Idée centrale	43
3.2 Cadre mathématique (propre et standard)	43
3.3 Intuition marché / interprétation	44
3.4 Implémentation (robuste)	44
3.5 Tests / sanity checks (3–6 concrets)	45
3.6 Pitfalls (erreurs qui coûtent cher)	45
3.7 Pont vers pratique quant	45

Chapitre 1

Black–Scholes : dérivation et formule (avec rappels Itô applicatifs)

Idée centrale. Black–Scholes est le premier modèle continu complet : (i) dynamique sous-jacente, (ii) réplication et auto-financement, (iii) PDE puis formule fermée, (iv) lecture risque-neutre (Feynman–Kac).

Cadre mathématique.

- **GBM sous $\mathbb{Q}$.** $dS_t = (r - q)S_t dt + \sigma S_t dW_t^{\mathbb{Q}}$.
- **PDE.** Pour $V(t, S) : V_t + \frac{1}{2}\sigma^2 S^2 V_{SS} + (r - q)SV_S - rV = 0$, terminal $V(T, S) = \Phi(S)$.
- **Formule.** $C_0 = S_0 e^{-qT} \Phi(d_1) - K e^{-rT} \Phi(d_2)$, $d_{1,2} = \frac{\ln(S_0/K) + (r - q \pm \frac{1}{2}\sigma^2)T}{\sigma\sqrt{T}}$.

Intuition marché / interprétation. Le modèle est faux mais sert de « langage » : on quote en vol implicite et on hedge en delta/gamma. Les écarts (smile) viennent de sauts, vol stoch, frictions, et hedging discret.

Implémentation.

- Implémenter prix + greeks analytiques ; inversion IV (Newton) ; comparer BS vs arbre/MC.
- Numérique : PDE/FD (stabilité), MC (variance reduction), et contrôle des erreurs de bump (greeks).

Tests / sanity checks.

- Limites : $T \downarrow 0$ (prix $\rightarrow$ intrinsic), $\sigma \downarrow 0$ (option $\rightarrow$ forward tronqué).
- Parité : vérifier $C - P = S_0 e^{-qT} - K e^{-rT}$.
- Monotonie : prix croissant en σ (vega ≥ 0), décroissant en K .

Pont vers pratique quant. Pont quant : construction de surfaces de vol implicite, risk (delta/gamma/-vega), calibration de modèles (Heston/jumps) à un langage commun, et bases des méthodes PDE/MC industrielles.

1.1 Avant-propos : de Itô au pricing continu (Black–Scholes)

On vient de construire le calcul stochastique : intégrale d'Itô, formule d'Itô, et lecture du crochet comme « terme d'ordre 2 ». Black–Scholes est la première application *complète* où tout s'enchaîne :

$$\text{dynamique de } S \Rightarrow \text{dynamique de } V(t, S_t) \text{ (Itô)} \Rightarrow \text{couverture} \Rightarrow \text{PDE} \Rightarrow \text{formule.}$$

1.1.1 Pourquoi ce chapitre est central

Deux messages structurants :

- La **PDE** n'est pas une formule magique : elle est la traduction « absence d'arbitrage + portefeuille auto-financé + élimination du risque ».
- La **mesure risque-neutre** n'est pas un axiome : elle est cohérente avec la réplication, et devient un

outil de calcul via Feynman–Kac.

Intuition de marché. Black–Scholes est une *boussole* : un prix de référence, une couverture delta, et surtout un langage (vol implicite). Même quand le modèle est faux, on parle « en Black–Scholes » pour comparer des options.

1.1.2 Objectifs pédagogiques (niveau granulaire)

- Écrire proprement un portefeuille (Δ_t, β_t) , comprendre la contrainte auto-financée, et détecter les pièges classiques (termes en $d\Delta$).
- Dériver la PDE BS pas à pas : construction du portefeuille, choix $\Delta = V_S$, argument « portefeuille sans risque $\Rightarrow$ taux r ».
- Passer de la PDE à la formule : (i) lecture risque-neutre/Feynman–Kac, (ii) réduction à l'équation de la chaleur.
- Ajouter des sanity checks (bornes, limites $\tau \rightarrow 0$, $\sigma \rightarrow 0$) et préparer les greeks (chapitre suivant).

1.1.3 Pré-requis

- Calcul stochastique : variation quadratique et formule d'Itô.
- Actualisation (numéraire $B_t = e^{rt}$) et, si besoin, dividende continu q .
- Un minimum d'aisance avec les dérivées partielles ($C^{1,2}$) et Taylor à l'ordre 2.

1.1.4 Plan du chapitre (ce qu'il faut savoir refaire)

1. Marché BS : actifs, portefeuilles, auto-financement.
2. Itô sur $V(t, S_t)$ et dérivation de la PDE par delta-hedging.
3. Pricing : mesure $\mathbb{Q}$, Feynman–Kac, loi lognormale et formule call/put.
4. Résolution PDE : changement de variables $\Rightarrow$ équation de la chaleur (lecture complémentaire).

Sanity check. Fil rouge à garder : le terme $\frac{1}{2}\sigma^2 S^2 V_{SS}$ vient *uniquement* du crochet $[S]$ (donc de Itô). Sans variation quadratique, pas de PDE BS.

Résumé

Ce cours a un objectif très précis : comprendre *comment* et *pourquoi* le lemme d'Itô intervient au cœur de la dérivation de la PDE de Black–Scholes, puis de la formule fermée du prix de l'option. Le fil conducteur est simple : (i) modéliser le sous-jacent par une EDS, (ii) appliquer Itô au prix de l'option $V(t, S_t)$ pour obtenir sa dynamique, (iii) construire un portefeuille auto-finançant qui élimine le risque instantané, (iv) imposer l'absence d'arbitrage pour obtenir la PDE, (v) relier la PDE à une espérance risque-neutre (Feynman–Kac) et calculer la formule.

Le niveau visé est M1 finance quantitative (maths post-prépa) : on explicite les notions probabilistes minimales (filtration, intégrale d'Itô, variation quadratique), sans chercher à être encyclopédique. Une dernière partie ouvre vers Heston (volatilité stochastique) : la formule d'Itô multi-dimensionnelle devient alors indispensable, et la question de l'incomplétude de marché apparaît naturellement.

Avant-propos : prérequis, notations, objectifs

Public. Étudiants de M1 en finance quantitative, à l'aise avec : calcul différentiel, intégration, probabilités de base (lois usuelles, espérance/variance), analyse réelle. On suppose connues les notions financières élémentaires : action, taux sans risque, option européenne, valeur temps, arbitrage.

Objectifs pédagogiques. À la fin, vous devez pouvoir :

- énoncer le lemme d'Itô (version 1D et 2D) et expliquer le rôle de la variation quadratique ;
- appliquer Itô à $V(t, S_t)$ et isoler précisément le terme aléatoire en dW_t ;
- construire un portefeuille auto-finançant et choisir Δ pour neutraliser le risque instantané ;
- dériver la PDE de Black–Scholes, comprendre d'où vient chaque terme, et expliquer pourquoi μ disparaît ;
- relier la PDE à une espérance sous $\mathbb{Q}$ et retrouver la formule de Black–Scholes ;
- comprendre ce qui change dans Heston (2 bruits, volatilité stochastique, PDE à deux variables, incomplétude).

Notations. On travaille sur un espace probabilisé filtré $(\Omega, \mathcal{F}, (\mathcal{F}_t)_{t \geq 0}, \mathbb{P})$. Un mouvement brownien (standard) est noté $(W_t)_{t \geq 0}$. Le taux sans risque est r (constant, pour simplifier) et le prix de l'action est $(S_t)_{t \geq 0}$. Les dérivées partielles de $V(t, S)$ sont notées V_t, V_S, V_{SS} . On note $\tau := T - t$ le temps restant jusqu'à l'échéance.

Idée centrale en une phrase. Itô transforme « une fonction d'un processus aléatoire » en « une EDS explicite » : on voit apparaître un terme en dW_t (le risque instantané). La réplication consiste à choisir un portefeuille pour faire disparaître ce terme.

1.2 Préliminaires de calcul stochastique

1.1 Espace probabilisé filtré : formaliser l'information

Définition 1.1 (Filtration). Une filtration $(\mathcal{F}_t)_{t \geq 0}$ est une famille croissante de sous- σ -algèbres de $\mathcal{F}$: $\mathcal{F}_s \subseteq \mathcal{F}_t$ si $s \leq t$. Intuitivement, $\mathcal{F}_t$ représente l'information disponible au temps t .

Définition 1.2 (Processus adapté). Un processus $(X_t)_{t \geq 0}$ est *adapté* à $(\mathcal{F}_t)$ si, pour tout t , la variable aléatoire X_t est $\mathcal{F}_t$ -mesurable. Autrement dit, X_t est « observable » à la date t .

Remarque 1.1. En finance continue, la filtration modélise *l'information de marché* : prix passés, news, etc. Les stratégies de trading admissibles doivent être adaptées (pas d'anticipation).

Pourquoi s'embêter ? Parce que l'intégrale stochastique $\int_0^t H_s dW_s$ n'a de sens (et de bonnes propriétés) que si l'intégrande (H_t) ne « voit pas le futur ». La filtration encode précisément ce « pas de délit d'initié ».

À retenir. Le triptyque *processus + filtration + adaptation* est la base pour définir proprement : (i) intégrale d'Itô, (ii) EDS, (iii) stratégies auto-finançantes.

1.2 Mouvement brownien : la brique aléatoire de base

Définition 1.3 (Mouvement brownien standard). Un processus $(W_t)_{t \geq 0}$ est un mouvement brownien standard si :

1. $W_0 = 0$ presque sûrement ;
2. $t \mapsto W_t$ est continu ;
3. les accroissements sont indépendants : pour $0 \leq s < t$, $W_t - W_s$ est indépendant de $\mathcal{F}_s$;
4. $W_t - W_s \sim \mathcal{N}(0, t - s)$ (gaussien centré de variance $t - s$).

Ordres de grandeur. Sur un pas de temps Δt , on a typiquement :

$$\Delta W \sim \mathcal{N}(0, \Delta t) \quad \Rightarrow \quad \Delta W = \mathcal{O}(\sqrt{\Delta t}).$$

Ce simple fait explique presque toute la différence entre calcul classique et calcul d'Itô.

1.2.1 Non-dérivabilité et variation quadratique

Le brownien est continu mais (presque sûrement) *nulle part dérivable*. La conséquence pratique est la suivante : si l'on tente un « Taylor classique » en temps, certains termes apparemment d'ordre $(\Delta t)^2$ ne sont plus négligeables, car ils contiennent $(\Delta W)^2$.

Définition 1.4 (Variation quadratique). Soit X un processus continu. Sa variation quadratique sur $[0, t]$ est la limite (si elle existe) des sommes

$$\sum_{k=0}^{n-1} (X_{t_{k+1}} - X_{t_k})^2$$

lorsque le pas de la partition $0 = t_0 < \dots < t_n = t$ tend vers 0. On la note $[X]_t$.

Proposition 1.1 (Variation quadratique du brownien). Pour un mouvement brownien (W_t) , on a

$$[W]_t = t.$$

On retient la règle mnémotechnique : $(dW_t)^2 = dt$.

Remarque 1.2. Les règles d'Itô (en dimension 1) se résument bien par :

$$(dt)^2 = 0, \quad dt dW_t = 0, \quad (dW_t)^2 = dt.$$

Ce n'est pas une égalité algébrique, mais un « calcul » cohérent avec la variation quadratique.

1.2.2 Exemple clé : $W_t^2 - t$ est une martingale

L'expression $W_t^2 - t$ apparaît souvent comme *prototype* de la correction d'Itô. L'idée est que W_t^2 croît, en moyenne, comme t . On le re-verra en dérivant le lemme d'Itô.

À retenir. La phrase « ΔW est d'ordre $\sqrt{\Delta t}$ » implique « $(\Delta W)^2$ est d'ordre Δt ». C'est *exactement* la source du terme $\frac{1}{2}b^2 f_{xx}$ dans Itô.

1.3 Intégrale d'Itô : intégrer contre le bruit

1.3.1 Motivation

On veut donner un sens à

$$\int_0^t H_s dW_s,$$

où (H_t) est un processus *adapté* (stratégie, sensibilité, etc). Dans Black-Scholes, H_s sera typiquement une quantité de stock détenue au temps s .

1.3.2 Définition (idée)

On commence par des processus en escalier :

$$H_s = \sum_{k=0}^{n-1} h_k \mathbf{1}_{(t_k, t_{k+1}]}(s), \quad h_k \text{ est } \mathcal{F}_{t_k}\text{-mesurable.}$$

Alors on pose

$$\int_0^t H_s dW_s := \sum_{k=0}^{n-1} h_k (W_{t_{k+1} \wedge t} - W_{t_k \wedge t}).$$

Puis on étend par densité à une classe large de processus (carré-intégrables).

1.3.3 Propriétés fondamentales

Proposition 1.2 (Isométrie d'Itô). *Si H est adapté et $\mathbb{E}\left[\int_0^t H_s^2 ds\right] < \infty$, alors*

$$\mathbb{E}\left[\left(\int_0^t H_s dW_s\right)^2\right] = \mathbb{E}\left[\int_0^t H_s^2 ds\right].$$

Proposition 1.3 (Martingale). *Sous des hypothèses usuelles d'intégrabilité, le processus*

$$M_t := \int_0^t H_s dW_s$$

est une martingale (en particulier, $\mathbb{E}[M_t] = 0$).

Intuition. Intégrer contre dW produit un terme « purement aléatoire » (martingale), tandis qu'intégrer contre dt produit un drift (tendance). Black–Scholes consiste précisément à *neutraliser* le terme martingale dans la dynamique d'un portefeuille.

1.4 Martingales : le langage des prix (actualisés)

1.4.1 Définition et intuition

Définition 1.5 (Martingale). Un processus adapté $(M_t)_{t \geq 0}$ est une *martingale* (sous $\mathbb{P}$) si, pour tout $s \leq t$:

- M_t est intégrable : $\mathbb{E}[|M_t|] < \infty$;
- $\mathbb{E}[M_t | \mathcal{F}_s] = M_s$.

Lecture. La condition $\mathbb{E}[M_t | \mathcal{F}_s] = M_s$ signifie : « pas de tendance prédictible » compte tenu de l'information disponible à s . Une martingale est un modèle mathématique de « jeu équitable ».

1.4.2 Exemples

- Le brownien (W_t) est une martingale.
- Les intégrales d'Itô $\int_0^t H_s dW_s$ sont des martingales (quand elles sont bien définies).
- Le processus $W_t^2 - t$ est une martingale (vu plus haut).

1.4.3 Pourquoi c'est central en finance ?

Dans un modèle sans arbitrage, on cherche une mesure $\mathbb{Q}$ telle que *les prix actualisés des actifs tradables* soient des martingales :

$$\frac{S_t}{B_t} \text{ martingale sous } \mathbb{Q}.$$

Alors (formellement) :

$$\frac{S_t}{B_t} = \mathbb{E}^{\mathbb{Q}}\left[\frac{S_T}{B_T} \mid \mathcal{F}_t\right].$$

Cette égalité est une version abstraite de « le prix aujourd'hui est l'espérance (risque-neutre) du payoff actualisé ». Le théorème de Feynman–Kac est un pont entre cette lecture probabiliste et la lecture PDE.

Message clé pour Black–Scholes. Le calcul d'Itô permet d'écrire la dynamique d'un portefeuille comme :

$$d(\text{portefeuille}) = (\text{drift}) dt + (\text{martingale}) dW.$$

La couverture cherche à éliminer le terme martingale. Une fois le portefeuille rendu sans risque, son drift est forcé à être r par absence d'arbitrage.

1.5 Processus d'Itô et EDS (équations différentielles stochastiques)

Définition 1.6 (Processus d'Itô). Un processus (X_t) est un processus d'Itô s'il s'écrit

$$X_t = X_0 + \int_0^t a(s, X_s) ds + \int_0^t b(s, X_s) dW_s.$$

On écrit formellement :

$$dX_t = a(t, X_t) dt + b(t, X_t) dW_t.$$

1.5.1 Exemple central : le mouvement brownien géométrique

Dans Black-Scholes, le sous-jacent est supposé suivre

$$dS_t = \mu S_t dt + \sigma S_t dW_t, \quad S_0 > 0, \quad (1.1)$$

avec $\mu \in \mathbb{R}$ et $\sigma > 0$ constants.

Pourquoi ce modèle ?

- S_t reste positif (en fait, lognormal) ;
- les rendements logarithmiques sont gaussiens ;
- l'échelle $\sigma\sqrt{t}$ correspond au comportement empirique (volatilité).

Ce n'est pas la réalité exacte, mais un « laboratoire » où l'on peut dériver un prix d'option *à la main*.

1.5.2 Solution explicite via Itô (avant-goût)

Posons $X_t := \log S_t$. Le calcul de $d(\log S_t)$ par Itô est un premier usage crucial du lemme. On verra plus loin qu'il mène à :

$$S_t = S_0 \exp\left(\left(\mu - \frac{1}{2}\sigma^2\right)t + \sigma W_t\right).$$

1.6 Lemme d'Itô : l'outil clé

1.6.1 Énoncé en dimension 1

Théorème 1.1 (Lemme d'Itô, version 1D). Soit (X_t) un processus d'Itô :

$$dX_t = a(t, X_t) dt + b(t, X_t) dW_t,$$

et soit $f \in C^{1,2}([0, T] \times \mathbb{R})$. Alors le processus $Y_t := f(t, X_t)$ vérifie

$$df(t, X_t) = \left(f_t + af_x + \frac{1}{2}b^2 f_{xx}\right)(t, X_t) dt + (bf_x)(t, X_t) dW_t. \quad (1.2)$$

Comment lire la formule. La dérivée totale classique serait « $df = f_t dt + f_x dX$ ». Itô ajoute un terme de correction :

$$\frac{1}{2}f_{xx} d[X]_t \quad \text{avec} \quad d[X]_t = b(t, X_t)^2 dt.$$

1.6.2 Heuristique (la règle $(dW)^2 = dt$)

Sur un petit pas Δt , l'incrément ΔX est dominé par $b \Delta W$ (ordre $\sqrt{\Delta t}$). Dans un Taylor :

$$\Delta f \approx f_t \Delta t + f_x \Delta X + \frac{1}{2}f_{xx}(\Delta X)^2.$$

Or $(\Delta X)^2 \approx b^2(\Delta W)^2$ et $(\Delta W)^2 \approx \Delta t$ (variation quadratique). Donc $(\Delta X)^2$ est d'ordre Δt et ne disparaît pas, d'où le $\frac{1}{2}b^2 f_{xx}$.

1.6.3 Preuve détaillée (niveau M1, hypothèses explicites)

On veut justifier l'égalité (1.2) à partir d'un Taylor sur des pas de temps fins. Pour rendre les bornes et les passages à la limite transparents, on commence par un cadre « borné » puis on explique l'extension au cas général.

Hypothèses (version simple). On suppose que a et b sont continues et bornées sur $[0, T] \times \mathbb{R}$. On suppose que $f \in C^{1,2}([0, T] \times \mathbb{R})$ et que f_t, f_x, f_{xx} sont bornées, avec f_{xx} Lipschitz en x sur tout compact (uniformément en t). Sous ces hypothèses, les incréments de X ont des moments contrôlés et le reste de Taylor est sommable.

1) Décomposition télescopique (identité exacte). Fixons $t \in [0, T]$ et une partition $0 = t_0 < t_1 < \dots < t_n = t$. On pose $\Delta t_i = t_{i+1} - t_i$ et $\Delta X_i = X_{t_{i+1}} - X_{t_i}$. Alors

$$f(t, X_t) - f(0, X_0) = \sum_{i=0}^{n-1} \left(f(t_{i+1}, X_{t_{i+1}}) - f(t_i, X_{t_i}) \right).$$

2) Taylor d'ordre 2 avec un reste contrôlé. On applique Taylor à la fonction $(\Delta t, \Delta x) \mapsto f(t_i + \Delta t, X_{t_i} + \Delta x)$ au point $(0, 0)$. Il existe un reste R_i tel que

$$f(t_{i+1}, X_{t_{i+1}}) - f(t_i, X_{t_i}) = f_t(t_i, X_{t_i}) \Delta t_i + f_x(t_i, X_{t_i}) \Delta X_i + \frac{1}{2} f_{xx}(t_i, X_{t_i}) (\Delta X_i)^2 + R_i, \quad (1.3)$$

et, pour une constante C indépendante de i ,

$$|R_i| \leq C \left((\Delta t_i)^2 + |\Delta t_i| |\Delta X_i| + |\Delta X_i|^3 \right). \quad (1.4)$$

3) Contrôle du reste : $\sum_i R_i \rightarrow 0$. Notons $|\Pi| = \max_i \Delta t_i$ le pas de la partition. Comme $\sum_i (\Delta t_i)^2 \leq |\Pi| \sum_i \Delta t_i = |\Pi| t$, le terme en $(\Delta t_i)^2$ disparaît.

Pour les termes impliquant ΔX_i , on utilise la décomposition d'Itô

$$\Delta X_i = \underbrace{\int_{t_i}^{t_{i+1}} a(s, X_s) ds}_{=: \Delta A_i} + \underbrace{\int_{t_i}^{t_{i+1}} b(s, X_s) dW_s}_{=: \Delta M_i}.$$

Sous bornes, $|\Delta A_i| \leq \|a\|_\infty \Delta t_i$. De plus, ΔM_i est une intégrale d'Itô, donc (isométrie d'Itô)

$$\mathbb{E}[(\Delta M_i)^2] = \mathbb{E} \left[\int_{t_i}^{t_{i+1}} b(s, X_s)^2 ds \right] \leq \|b\|_\infty^2 \Delta t_i,$$

et par inégalité de Cauchy-Schwarz, $\mathbb{E}[|\Delta M_i|] \leq \sqrt{\mathbb{E}[(\Delta M_i)^2]} \lesssim \sqrt{\Delta t_i}$. On en déduit $\mathbb{E}[|\Delta X_i|] \lesssim \sqrt{\Delta t_i}$. Ainsi

$$\sum_i \Delta t_i \mathbb{E}[|\Delta X_i|] \lesssim \sum_i (\Delta t_i)^{3/2} \leq \sqrt{|\Pi|} \sum_i \Delta t_i = \sqrt{|\Pi|} t \rightarrow 0.$$

De même, ΔM_i a des moments gaussiens conditionnels, donc $\mathbb{E}[|\Delta M_i|^3] \lesssim (\Delta t_i)^{3/2}$ et, avec $\Delta A_i = O(\Delta t_i)$, on obtient $\mathbb{E}[|\Delta X_i|^3] \lesssim (\Delta t_i)^{3/2}$, donc $\sum_i \mathbb{E}[|\Delta X_i|^3] \lesssim \sqrt{|\Pi|} t \rightarrow 0$. En combinant, (1.4) implique $\mathbb{E}[\sum_i |R_i|] \rightarrow 0$, donc $\sum_i R_i \rightarrow 0$ en probabilité.

4) Identification des trois termes principaux. On somme (1.3) et on fait tendre $|\Pi| \rightarrow 0$.

- $\sum_i f_t(t_i, X_{t_i}) \Delta t_i \rightarrow \int_0^t f_t(s, X_s) ds$ (sommes de Riemann).
- Pour $\sum_i f_x(t_i, X_{t_i}) \Delta X_i$, on écrit $\Delta X_i = \Delta A_i + \Delta M_i$:

$$\sum_i f_x(t_i, X_{t_i}) \Delta A_i \rightarrow \int_0^t f_x(s, X_s) a(s, X_s) ds,$$

et, par définition de l'intégrale d'Itô, les sommes $\sum_i f_x(t_i, X_{t_i}) \Delta M_i$ convergent en L^2 vers $\int_0^t f_x(s, X_s) b(s, X_s) dW_s$.

- Pour le terme quadratique, on développe $(\Delta X_i)^2 = (\Delta A_i)^2 + 2\Delta A_i \Delta M_i + (\Delta M_i)^2$. La somme des $(\Delta A_i)^2$ est en $O(\sum (\Delta t_i)^2)$ donc tend vers 0. La somme des termes croisés est en $O(\sum \Delta t_i^{3/2})$ donc tend aussi vers 0. Il reste donc $\sum_i f_{xx}(t_i, X_{t_i})(\Delta M_i)^2$. Or $M_t = \int_0^t b(s, X_s) dW_s$ est une martingale continue, et sa variation quadratique vaut $[M]_t = \int_0^t b(s, X_s)^2 ds$ (résultat standard). Par définition du crochet, $\sum_i (\Delta M_i)^2 \rightarrow [M]_t$ en probabilité, et comme f_{xx} est bornée on obtient

$$\frac{1}{2} \sum_i f_{xx}(t_i, X_{t_i})(\Delta X_i)^2 \rightarrow \frac{1}{2} \int_0^t f_{xx}(s, X_s) b(s, X_s)^2 ds.$$

En regroupant, on obtient la forme intégrale du lemme d'Itô, puis la forme différentielle (1.2).

Extension (cas général). Quand a, b, f ne sont pas bornés, on localise avec des temps d'arrêt τ_n qui bornent X et les coefficients sur $[0, t \wedge \tau_n]$, on applique la preuve ci-dessus à $t \wedge \tau_n$, puis on fait $n \rightarrow \infty$.

1.6.4 Exemples rapides

Exemple 1.1 (Retrouver $W_t^2 - t$). Prenez $X_t = W_t$ et $f(x) = x^2$. On a $f'(x) = 2x$, $f''(x) = 2$, et $dX_t = dW_t$. Itô donne :

$$d(W_t^2) = 2W_t dW_t + 1 \cdot dt \quad \Rightarrow \quad d(W_t^2 - t) = 2W_t dW_t.$$

Le membre de droite est une intégrale d'Itô, donc une martingale : $W_t^2 - t$ est une martingale.

Exemple 1.2 (Calcul de $d(\log S_t)$). Avec (1.1), posez $f(s) = \log s$. Comme $f'(s) = 1/s$ et $f''(s) = -1/s^2$, et que $d[S]_t = (\sigma S_t)^2 dt$, Itô donne :

$$d(\log S_t) = \left(\mu - \frac{1}{2}\sigma^2\right) dt + \sigma dW_t.$$

1.6.5 Énoncé en dimension 2 (ouverture vers Heston)

Théorème 1.2 (Formule d'Itô multi-dimensionnelle (2D)). Soient (X_t, Y_t) des processus d'Itô corrélés :

$$\begin{aligned} dX_t &= a_X dt + b_X dW_t^{(1)}, \\ dY_t &= a_Y dt + b_Y dW_t^{(2)}, \end{aligned} \quad d\langle W^{(1)}, W^{(2)} \rangle_t = \rho dt.$$

Pour $f \in C^{1,2,2}$, on a

$$df(t, X_t, Y_t) = f_t dt + f_x dX_t + f_y dY_t + \frac{1}{2} f_{xx} d[X]_t + \frac{1}{2} f_{yy} d[Y]_t + f_{xy} d[X, Y]_t. \quad (1.5)$$

Ici, $d[X]_t = b_X^2 dt$, $d[Y]_t = b_Y^2 dt$, et $d[X, Y]_t = b_X b_Y \rho dt$.

À retenir. La dimension 2 fait apparaître un terme *croisé* en f_{xy} , proportionnel à la corrélation. Dans Heston, c'est ce terme qui engendre le dérivé croisé V_{Sv} dans la PDE.

1.7 Comment Itô conduit à la PDE de Black–Scholes

On se place dans un modèle à diffusion continue pour S_t et on considère la valeur d'une option $V(t, S_t)$. L'idée est :

- appliquer Itô à $V(t, S_t)$ pour exprimer dV en fonction de dt et dW_t ;
- former un portefeuille auto-finançant (option + position en sous-jacent) dont le terme en dW_t est annulé ;
- imposer l'absence d'arbitrage : un portefeuille devenu sans risque doit croître au taux r ;
- identifier la condition équivalente sur V : c'est la PDE de Black–Scholes.

La suite du chapitre déroule cette dérivation et montre comment la PDE mène à une formule fermée pour les vanilles.

1.8 Le marché Black–Scholes : actifs et portefeuilles

1.8.1 Les deux actifs : banque et action

On modélise :

- un actif sans risque (compte bancaire) (B_t) :

$$dB_t = rB_t dt, \quad B_0 = 1 \quad \Rightarrow \quad B_t = e^{rt};$$

- un actif risqué (action) (S_t) :

$$dS_t = \mu S_t dt + \sigma S_t dW_t,$$

avec μ le rendement espéré (sous $\mathbb{P}$) et σ la volatilité (constante).

1.8.2 Portefeuille auto-finançant

Une stratégie est donnée par deux processus adaptés (Δ_t, β_t) :

- Δ_t : nombre d'actions détenues à t ;
- β_t : nombre d'unités du compte bancaire détenues à t .

La valeur du portefeuille est

$$\Pi_t = \Delta_t S_t + \beta_t B_t.$$

La stratégie est *auto-finançante* si les variations de richesse proviennent uniquement des gains sur actifs :

$$d\Pi_t = \Delta_t dS_t + \beta_t dB_t. \quad (1.6)$$

Idée / intuition. La formule (1.6) ne dit pas que $\Pi_t = \Delta_t S_t + \beta_t B_t$ est « différentiable » au sens classique : elle formalise une contrainte de *flux*. Quand on rééquilibre (on change Δ_t et β_t), on impose que ce rééquilibrage soit financé *uniquement* par des achats/ventes des deux actifs (pas d'apport externe de cash).

Dérivation (pas à pas).

Étape 1: Lecture discrète. Sur un pas $[t, t + \Delta t]$, on tient d'abord une position (Δ_t, β_t) , donc le gain (avant rééquilibrage) vaut environ

$$\Delta_t(S_{t+\Delta t} - S_t) + \beta_t(B_{t+\Delta t} - B_t).$$

Étape 2: Rééquilibrage. Si on décide ensuite de passer à $(\Delta_{t+\Delta t}, \beta_{t+\Delta t})$, l'achat d'actions supplémentaires est payé en vendant du compte bancaire (ou l'inverse). Il n'y a donc pas de flux exogène.

Étape 3: Limite continue. En faisant tendre $\Delta t \rightarrow 0$ (et en supposant une stratégie suffisamment régulière), cette contrainte se résume par (1.6).

Piège classique. À ne pas faire : écrire $d\Pi_t = d(\Delta_t S_t) + d(\beta_t B_t)$ puis oublier les termes en $d\Delta_t$. La bonne lecture est : on part de l'identité *comptable* $\Pi_t = \Delta_t S_t + \beta_t B_t$, et on impose ensuite la contrainte *financière* (1.6) pour exclure les apports/retraits de capital.

Remarque 1.3. La condition (1.6) exclut les injections/retraits exogènes de capital. C'est une hypothèse structurante en pricing par réplcation.

1.8.3 Absence d'arbitrage (niveau cours)

Intuitivement : *pas de stratégie auto-finançante qui garantit un gain sans risque, sans investissement initial*.
Au niveau opérationnel :

- si un portefeuille est sans risque, il doit rapporter r (sinon on crée un arbitrage en empruntant/-prêtant au taux r).

Cette idée suffit à dériver la PDE de Black–Scholes.

1.9 Où intervient Itô ? Dynamique du prix d'une option

Soit un produit dérivé européen de payoff $\Phi(S_T)$ à maturité T . On note $V(t, S)$ son prix au temps t lorsque le sous-jacent vaut S . Dans Black-Scholes, on suppose suffisamment de régularité : $V \in C^{1,2}$.

1.9.1 Application directe du lemme d'Itô

Considérons le processus $V(t, S_t)$. En appliquant le Théorème 1.1 avec $X_t = S_t$, on obtient :

$$dV(t, S_t) = V_t(t, S_t) dt + V_S(t, S_t) dS_t + \frac{1}{2} V_{SS}(t, S_t) d[S]_t. \quad (1.7)$$

Or

$$dS_t = \mu S_t dt + \sigma S_t dW_t, \quad d[S]_t = (\sigma S_t)^2 dt = \sigma^2 S_t^2 dt.$$

En substituant dans (1.7), on obtient la **décomposition drift + diffusion** :

$$dV(t, S_t) = \underbrace{\left(V_t + \mu S_t V_S + \frac{1}{2} \sigma^2 S_t^2 V_{SS} \right) dt}_{\text{drift (tendance)}} + \underbrace{(\sigma S_t V_S)}_{\text{risque instantané}} dW_t. \quad (1.8)$$

Point clé. Le terme en dW_t porte le risque instantané : c'est *exactement* ce que l'on va chercher à neutraliser par une stratégie de couverture (delta-hedging).

1.10 Dérivation pas à pas de la PDE de Black-Scholes

1.10.1 Étape 1 : construire un portefeuille « option - actions »

On considère le portefeuille

$$\Pi_t := V(t, S_t) - \Delta_t S_t, \quad (1.9)$$

où Δ_t sera choisi de manière optimale. L'intuition : on vend (ou achète) l'option et on compense une partie de son risque en prenant une position en actions.

1.10.2 Étape 2 : calculer $d\Pi_t$ avec Itô

En différenciant (1.9) :

$$d\Pi_t = dV(t, S_t) - \Delta_t dS_t.$$

En utilisant (1.8) et la dynamique de S_t :

$$\begin{aligned} d\Pi_t &= \left(V_t + \mu S_t V_S + \frac{1}{2} \sigma^2 S_t^2 V_{SS} \right) dt + \sigma S_t V_S dW_t \\ &\quad - \Delta_t (\mu S_t dt + \sigma S_t dW_t) \\ &= \left(V_t + \mu S_t V_S + \frac{1}{2} \sigma^2 S_t^2 V_{SS} - \mu S_t \Delta_t \right) dt + \sigma S_t (V_S - \Delta_t) dW_t. \end{aligned}$$

1.10.3 Étape 3 : choisir Δ_t pour éliminer le risque

On choisit

$$\Delta_t := V_S(t, S_t). \quad (1.10)$$

Check dimensionnel. La delta est une dérivée *par rapport à un prix* : elle est donc sans dimension (c'est un ratio « prix/prix »). En pratique, c'est une quantité d'actions.

Interprétation marché. La lecture praticien est : *on se met long/short Δ_t actions* pour neutraliser, à l'instant t , le risque « premier ordre » sur le sous-jacent. Dans la réalité, on rééquilibre à dates discrètes : le résidu de couverture est gouverné par la gamma et la variation quadratique (voir le chapitre sur les greeks).

Piège classique. La couverture par delta neutralise le terme en dW_t (diffusion). En présence de sauts, elle ne suffit pas à supprimer le risque instantané (les sauts ne sont pas « petits »), ce qui conduit à une PIDE et à de l'incomplétude.

Alors le coefficient de dW_t devient nul, et

$$d\Pi_t = (V_t + \frac{1}{2}\sigma^2 S_t^2 V_{SS}) dt. \quad (1.11)$$

Commentaires pédagogiques.

- La magie est dans Itô : sans Itô, on ne verrait pas le terme V_{SS} , donc on ne pourrait pas écrire (1.11).
- Le drift μ disparaît (il est entièrement couvert par le choix de Δ).
- La stratégie (1.10) s'appelle **delta-hedging** : elle neutralise le risque *au premier ordre* par rapport aux variations de S .

1.10.4 Étape 4 : imposer l'absence d'arbitrage

Le portefeuille (1.9) avec (1.10) est (localement) sans risque : sa dynamique (1.11) ne contient plus de dW_t . Dans un marché sans arbitrage, un portefeuille sans risque doit rapporter le taux sans risque r :

$$d\Pi_t = r\Pi_t dt. \quad (1.12)$$

Or $\Pi_t = V(t, S_t) - V_S(t, S_t)S_t$. En combinant (1.11) et (1.12) :

$$(V_t + \frac{1}{2}\sigma^2 S_t^2 V_{SS}) dt = r(V - S_t V_S) dt.$$

En simplifiant par dt et en réarrangeant :

$$V_t + \frac{1}{2}\sigma^2 S^2 V_{SS} + rSV_S - rV = 0, \quad (t, S) \in [0, T] \times (0, \infty). \quad (1.13)$$

1.10.5 Étape 5 : ajouter la condition terminale

Si l'option est européenne de payoff $\Phi(S_T)$, alors

$$V(T, S) = \Phi(S). \quad (1.14)$$

Pour une call de strike K : $\Phi(S) = (S - K)^+$.

Synthèse : la dérivation en 5 lignes.

1. Modèle : $dS_t = \mu S_t dt + \sigma S_t dW_t$.
2. Itô : $dV = (V_t + \mu S V_S + \frac{1}{2}\sigma^2 S^2 V_{SS})dt + \sigma S V_S dW$.
3. Portefeuille : $\Pi = V - \Delta S$.
4. Choix $\Delta = V_S$: $d\Pi = (V_t + \frac{1}{2}\sigma^2 S^2 V_{SS})dt$ (sans risque).
5. Pas d'arbitrage : $d\Pi = r\Pi dt \Rightarrow$ PDE (1.13).

1.11 Réplication explicite et unicité du prix

La PDE (1.13) n'est pas qu'une identité formelle : elle encode une stratégie de couverture *répliquative*. Dans Black-Scholes, sous les hypothèses idéales (trading continu, pas de coûts, σ constant), cette stratégie réplique exactement le payoff.

1.11.1 Construire la stratégie (Δ_t, β_t)

Supposons que V soit une solution régulière de (1.13)–(1.14). Définissons :

$$\Delta_t := V_S(t, S_t), \quad \beta_t := \frac{V(t, S_t) - \Delta_t S_t}{B_t}. \quad (1.15)$$

Alors la valeur du portefeuille vaut, par construction,

$$\Pi_t = \Delta_t S_t + \beta_t B_t = V(t, S_t).$$

1.11.2 Pourquoi la PDE garantit l'auto-financement

Si le portefeuille est auto-finançant, il doit satisfaire (1.6) :

$$d\Pi_t = \Delta_t dS_t + \beta_t dB_t.$$

Or, par Itô,

$$dV(t, S_t) = V_S dS_t + \left(V_t + \frac{1}{2}\sigma^2 S_t^2 V_{SS}\right) dt.$$

En utilisant la PDE (1.13) (et en remplaçant S_t par S pour lire l'identité), on obtient :

$$V_t + \frac{1}{2}\sigma^2 S^2 V_{SS} = r(V - SV_S) = r\beta B.$$

Donc

$$dV = \Delta dS + r\beta B dt = \Delta dS + \beta dB,$$

ce qui est exactement la condition d'auto-financement et la dynamique d'un portefeuille de trading. Ainsi, V est bien le coût de réplcation du payoff.

1.11.3 Unicité du prix (argument d'arbitrage)

Supposons qu'il existe deux prix V et $\tilde{V}$ satisfaisant (1.13)–(1.14). Alors $U := V - \tilde{V}$ satisfait la même PDE avec condition terminale nulle : $U(T, S) = 0$. La stratégie (1.15) appliquée à U réplique donc un payoff nul. Si $U(0, S_0) \neq 0$, on obtient un arbitrage (payer un coût initial non nul pour un payoff presque sûrement nul). Donc nécessairement $U(0, S_0) = 0$ et le prix est unique.

1.12 Extension : dividendes continus et coût de portage

Dans beaucoup de marchés (actions, indices), le sous-jacent verse des dividendes. Une modélisation standard consiste à supposer un *taux de dividende continu* $q \geq 0$ (dividend yield). Le point important est que, si vous détenez Δ_t actions, vous recevez un flux de trésorerie $\Delta_t q S_t dt$.

1.12.1 Modification de la condition d'auto-financement

Le gain total d'une position « long 1 action » n'est pas seulement dS_t mais

$$dG_t = dS_t + qS_t dt.$$

Un portefeuille auto-finançant vérifie alors :

$$d\Pi_t = \Delta_t dG_t + \beta_t dB_t = \Delta_t dS_t + \Delta_t q S_t dt + \beta_t r B_t dt.$$

Le reste de la dérivation est identique : on applique Itô à $V(t, S_t)$, on choisit $\Delta_t = V_S(t, S_t)$ pour annuler dW_t , puis on impose que le portefeuille sans risque croît à r .

1.12.2 PDE avec dividendes

On obtient la variante **avec dividendes** :

$$V_t + \frac{1}{2}\sigma^2 S^2 V_{SS} + (r - q)SV_S - rV = 0, \quad V(T, S) = \Phi(S). \quad (1.16)$$

1.12.3 Formule de Black-Scholes avec dividendes

Pour une call européenne, la formule devient :

$$C(t, S) = S e^{-q\tau} \Phi(d_1) - K e^{-r\tau} \Phi(d_2),$$

avec

$$d_1 = \frac{\log(S/K) + (r - q + \frac{1}{2}\sigma^2)\tau}{\sigma\sqrt{\tau}}, \quad d_2 = d_1 - \sigma\sqrt{\tau}.$$

Cette écriture met en évidence le rôle du forward $F(t, T) = S e^{(r-q)\tau}$.

1.13 Mesure risque-neutre et Feynman-Kac : une autre lecture

1.13.1 Actualisation et martingale

On introduit le numéraire $B_t = e^{rt}$. Sous une mesure risque-neutre $\mathbb{Q}$, les prix actualisés des actifs tradables sont des martingales. En particulier,

$$\frac{S_t}{B_t} = e^{-rt} S_t \quad \text{est une martingale sous } \mathbb{Q}.$$

Cela entraîne que, sous $\mathbb{Q}$, le drift de S est r :

$$dS_t = rS_t dt + \sigma S_t dW_t^{\mathbb{Q}}. \quad (1.17)$$

Remarque 1.4 (Girsanov (idée)). On peut (sous conditions) changer de mesure de probabilité pour « absorber » le drift excédentaire $\mu - r$ dans la définition du brownien. La formule de Girsanov donne un brownien sous $\mathbb{Q}$:

$$W_t^{\mathbb{Q}} = W_t + \frac{\mu - r}{\sigma} t.$$

1.13.2 Feynman-Kac (version pratique)

Considérons l'opérateur générateur associé à (1.17) :

$$\mathcal{L}f(S) := rSf'(S) + \frac{1}{2}\sigma^2 S^2 f''(S).$$

La PDE (1.13) s'écrit

$$V_t + \mathcal{L}V - rV = 0, \quad V(T, S) = \Phi(S).$$

Le théorème de Feynman-Kac (dans ce cadre) relie cette PDE à l'espérance :

$$V(t, S) = \mathbb{E}^{\mathbb{Q}} \left[e^{-r(T-t)} \Phi(S_T) \mid S_t = S \right]. \quad (1.18)$$

1.13.2.1 Preuve éclair de Feynman-Kac dans Black-Scholes (Itô + martingale)

Dérivation (pas à pas).

Étape 1: Sous $\mathbb{Q}$, on a $dS_t = rS_t dt + \sigma S_t dW_t^{\mathbb{Q}}$.

Étape 2: Soit $V \in C^{1,2}$ une solution de la PDE $V_t + \mathcal{L}V - rV = 0$ avec condition terminale $V(T, S) = \Phi(S)$.

Étape 3: Par Itô appliqué à $V(t, S_t)$ puis actualisation, on obtient

$$d(e^{-rt}V(t, S_t)) = e^{-rt}(V_t + \mathcal{L}V - rV)(t, S_t)dt + e^{-rt}\sigma S_t V_S(t, S_t) dW_t^{\mathbb{Q}}.$$

Étape 4: Le terme en dt est nul par la PDE : $e^{-rt}V(t, S_t)$ est donc une martingale sous $\mathbb{Q}$.

Étape 5: En prenant l'espérance conditionnelle entre t et T :

$$e^{-rt}V(t, S) = \mathbb{E}^{\mathbb{Q}}[e^{-rT}V(T, S_T) | S_t = S] = \mathbb{E}^{\mathbb{Q}}[e^{-rT}\Phi(S_T) | S_t = S],$$

ce qui donne (1.18).

Piège classique. Feynman–Kac « fonctionne » ici parce que S est Markov et que l'on est dans un cadre suffisamment régulier (solution $C^{1,2}$). Dans des modèles plus complexes (sauts, vol stochastique), la même logique reste vraie mais la PDE devient une PIDE ou une PDE en dimension supérieure, et les questions de régularité/conditions aux bords deviennent plus délicates.

Lien avec la dérivation par couverture. La réplication donne *la PDE* sans invoquer explicitement $\mathbb{Q}$. Feynman–Kac donne *la représentation* (1.18) et donc une méthode de calcul (par loi de S_T). Les deux points de vue sont cohérents et complémentaires.

1.14 Intermède discret : modèle binomial (1 pas) et probabilité risque-neutre

Avant de passer à la formule fermée, il est utile de voir la même logique de réplication dans un cadre discret très simple. Cet intermède explique *d'où vient* l'idée « prix = espérance actualisée sous une probabilité spéciale ».

1.14.1 Un pas de temps

On fixe un pas Δt . Au temps 0, l'action vaut S_0 . Au temps Δt , elle vaut :

$$S_{\Delta t} = \begin{cases} S_0 u & \text{avec scénario « up »,} \\ S_0 d & \text{avec scénario « down »,} \end{cases} \quad u > d > 0.$$

Le compte bancaire vaut $B_0 = 1$ et $B_{\Delta t} = 1 + r\Delta t$. On considère un payoff $V_{\Delta t} = \Phi(S_{\Delta t})$ avec valeurs (V_u, V_d) selon les deux scénarios.

1.14.2 Réplication

On cherche Δ et β tels que le portefeuille

$$\Pi_{\Delta t} = \Delta S_{\Delta t} + \beta B_{\Delta t}$$

réplique le payoff :

$$\Delta S_0 u + \beta(1 + r\Delta t) = V_u, \quad \Delta S_0 d + \beta(1 + r\Delta t) = V_d.$$

En soustrayant, on obtient

$$\Delta = \frac{V_u - V_d}{S_0(u - d)}.$$

Puis

$$\beta = \frac{1}{1 + r\Delta t} (V_d - \Delta S_0 d).$$

Le prix au temps 0 est alors le coût initial de réplication :

$$V_0 = \Pi_0 = \Delta S_0 + \beta.$$

1.14.3 Probabilité risque-neutre

Après quelques réarrangements, on peut écrire V_0 sous la forme :

$$V_0 = \frac{1}{1+r\Delta t} (qV_u + (1-q)V_d), \quad q := \frac{(1+r\Delta t) - d}{u - d}. \quad (1.19)$$

La quantité q joue le rôle d'une *probabilité risque-neutre*. La condition d'absence d'arbitrage est exactement :

$$d < 1 + r\Delta t < u \iff 0 < q < 1.$$

Lien avec Black–Scholes. Dans Black–Scholes, on retrouve la même structure : le prix est un coût de réplication, et peut aussi s'écrire comme une espérance actualisée sous une mesure $\mathbb{Q}$. La différence est qu'en temps continu, pour écrire la dynamique de $V(t, S_t)$ et construire la couverture instantanée, on a besoin du lemme d'Itô.

1.15 Fiche d'oral : expliquer la dérivation en 10 minutes

Cette section est une « trame » que vous pouvez réciter au tableau. L'idée est de savoir expliquer *où* Itô intervient et *pourquoi* la PDE apparaît.

1) Hypothèses et modèle. On suppose un marché frictionless, trading continu, taux sans risque constant r , volatilité constante σ , et une action suivant un brownien géométrique :

$$dS_t = \mu S_t dt + \sigma S_t dW_t.$$

On introduit le compte bancaire $B_t = e^{rt}$.

2) Prix de l'option comme fonction régulière. On note $V(t, S)$ le prix à t d'un payoff européen $\Phi(S_T)$. On suppose $V \in C^{1,2}$ (hypothèse de calcul).

3) Itô : dynamique de $V(t, S_t)$. On applique le lemme d'Itô :

$$dV = (V_t + \mu S V_S + \frac{1}{2} \sigma^2 S^2 V_{SS}) dt + \sigma S V_S dW.$$

Point clé : Itô fait apparaître le terme $\frac{1}{2} \sigma^2 S^2 V_{SS}$ via la variation quadratique.

4) Construire un portefeuille et choisir Δ . On considère $\Pi = V - \Delta S$. Alors

$$d\Pi = dV - \Delta dS = \left(V_t + \frac{1}{2} \sigma^2 S^2 V_{SS} - \mu S (\Delta - V_S) \right) dt + \sigma S (V_S - \Delta) dW.$$

On choisit $\Delta = V_S$ pour annuler le terme aléatoire en dW .

5) Absence d'arbitrage $\Rightarrow$ PDE. Avec $\Delta = V_S$, le portefeuille est sans risque, donc doit croître à r :

$$d\Pi = r\Pi dt = r(V - S V_S) dt.$$

En identifiant les coefficients de dt , on obtient la PDE BS :

$$V_t + \frac{1}{2} \sigma^2 S^2 V_{SS} + r S V_S - r V = 0, \quad V(T, S) = \Phi(S).$$

6) Solution : mesure risque-neutre et loi lognormale. Sous $\mathbb{Q}$, le drift devient r et

$$V(t, S) = \mathbb{E}^{\mathbb{Q}}[e^{-r\tau} \Phi(S_T) \mid S_t = S].$$

On calcule S_T par Itô appliqué à $\log S_t$: S_T est lognormal. Pour une call, l'intégrale donne la formule fermée avec d_1, d_2 .

7) Ouverture. En pratique, σ n'est pas constant (smile). Heston remplace σ par $\sqrt{v_t}$ et impose une dynamique à v_t : Itô 2D produit alors une PDE en (S, v) avec un terme croisé.

1.16 De la PDE à la formule de Black-Scholes

Deux voies sont classiquement utilisées pour passer de la PDE de Black-Scholes à une formule exploitable :

- une voie **probabiliste** : interprétation risque-neutre (Feynman-Kac) + loi lognormale de S_T ;
- une voie **analytique** : réduction de la PDE à l'équation de la chaleur via un changement de variables.

Les deux racontent la même histoire : la PDE encode l'absence d'arbitrage, et sa solution se lit comme une espérance actualisée sous $\mathbb{Q}$.

1.17 Solution explicite de S_t : Itô sur $\log S_t$

On reprend l'exemple 1.2 de manière systématique. Sous $\mathbb{Q}$, la dynamique est (1.17). Posons $X_t := \log S_t$. Itô donne :

$$dX_t = \left(r - \frac{1}{2}\sigma^2\right) dt + \sigma dW_t^{\mathbb{Q}}.$$

En intégrant de t à T :

$$X_T - X_t = \left(r - \frac{1}{2}\sigma^2\right) (T - t) + \sigma (W_T^{\mathbb{Q}} - W_t^{\mathbb{Q}}).$$

Comme $W_T^{\mathbb{Q}} - W_t^{\mathbb{Q}} \sim \mathcal{N}(0, T - t)$, on obtient :

$$S_T = S_t \exp\left(\left(r - \frac{1}{2}\sigma^2\right) \tau + \sigma \sqrt{\tau} Z\right), \quad Z \sim \mathcal{N}(0, 1). \quad (1.20)$$

Autrement dit, S_T est **lognormal** conditionnellement à S_t .

Conséquence. La formule de pricing (1.18) devient un calcul explicite d'espérance sur une lognormale.

1.18 Calcul détaillé du prix d'une call européenne

On fixe un strike $K > 0$ et on considère le payoff $\Phi(S_T) = (S_T - K)^+$. On note $C(t, S)$ le prix de la call. Par (1.18) :

$$C(t, S) = e^{-r\tau} \mathbb{E}^{\mathbb{Q}}[(S_T - K)^+ \mid S_t = S].$$

1.18.1 Étape 1 : écrire le payoff avec un indicateur

On utilise

$$(S_T - K)^+ = (S_T - K) \mathbf{1}_{\{S_T > K\}}.$$

Donc

$$C(t, S) = e^{-r\tau} \left(\mathbb{E}^{\mathbb{Q}}[S_T \mathbf{1}_{\{S_T > K\}}] - K \mathbb{Q}(S_T > K) \right). \quad (1.21)$$

On va calculer séparément ces deux termes.

1.18.2 Étape 2 : normaliser avec $\log S_T$

Posons $X_T := \log S_T$ et $k := \log K$. Avec (1.20), conditionnellement à $S_t = S$:

$$X_T \sim \mathcal{N}\left(m, \sigma^2 \tau\right), \quad m := \log S + \left(r - \frac{1}{2}\sigma^2\right) \tau.$$

L'événement $\{S_T > K\}$ équivaut à $\{X_T > k\}$.

1.18.3 Étape 3 : calculer $\mathbb{Q}(S_T > K)$

On écrit

$$\mathbb{Q}(S_T > K) = \mathbb{Q}(X_T > k).$$

En posant

$$d_2 := \frac{\log(S/K) + (r - \frac{1}{2}\sigma^2)\tau}{\sigma\sqrt{\tau}},$$

on obtient

$$\mathbb{Q}(S_T > K) = \Phi(d_2), \quad (1.22)$$

où Φ est la CDF de la normale standard.

1.18.4 Étape 4 : calculer $\mathbb{E}^\mathbb{Q}[S_T \mathbf{1}_{\{S_T > K\}}]$

Comme $S_T = e^{X_T}$,

$$\mathbb{E}^\mathbb{Q}[S_T \mathbf{1}_{\{S_T > K\}}] = \mathbb{E}^\mathbb{Q}[e^{X_T} \mathbf{1}_{\{X_T > k\}}].$$

Ce calcul est un « moment tronqué » de la normale. On peut le dériver en quelques lignes.

Comme $X_T \sim \mathcal{N}(m, \sigma^2\tau)$, on peut écrire $X_T = m + \sigma\sqrt{\tau}Z$ avec $Z \sim \mathcal{N}(0, 1)$. Posons

$$a := \frac{k - m}{\sigma\sqrt{\tau}}.$$

Alors

$$\begin{aligned} \mathbb{E}^\mathbb{Q}[e^{X_T} \mathbf{1}_{\{X_T > k\}}] &= e^m \mathbb{E}[\exp(\sigma\sqrt{\tau}Z) \mathbf{1}_{\{Z > a\}}] \\ &= e^m \int_a^\infty \exp(\sigma\sqrt{\tau}z) \varphi(z) dz. \end{aligned}$$

On complète le carré dans l'exposant :

$$\exp(\sigma\sqrt{\tau}z) \varphi(z) = \frac{1}{\sqrt{2\pi}} \exp\left(\sigma\sqrt{\tau}z - \frac{z^2}{2}\right) = \exp\left(\frac{1}{2}\sigma^2\tau\right) \varphi(z - \sigma\sqrt{\tau}).$$

Donc

$$\begin{aligned} \int_a^\infty \exp(\sigma\sqrt{\tau}z) \varphi(z) dz &= \exp\left(\frac{1}{2}\sigma^2\tau\right) \int_a^\infty \varphi(z - \sigma\sqrt{\tau}) dz \\ &= \exp\left(\frac{1}{2}\sigma^2\tau\right) \int_{a - \sigma\sqrt{\tau}}^\infty \varphi(u) du \\ &= \exp\left(\frac{1}{2}\sigma^2\tau\right) \Phi(\sigma\sqrt{\tau} - a). \end{aligned}$$

Or $\sigma\sqrt{\tau} - a = \frac{m - k + \sigma^2\tau}{\sigma\sqrt{\tau}} = d_1$. Ainsi, le résultat (souvent cité comme « standard ») est :

$$\mathbb{E}[e^X \mathbf{1}_{\{X > k\}}] = e^{m + \frac{1}{2}\sigma^2\tau} \Phi(d_1),$$

où

$$d_1 := \frac{\log(S/K) + (r + \frac{1}{2}\sigma^2)\tau}{\sigma\sqrt{\tau}} = d_2 + \sigma\sqrt{\tau}.$$

Comme $e^{m + \frac{1}{2}\sigma^2\tau} = S e^{r\tau}$, on obtient :

$$\mathbb{E}^\mathbb{Q}[S_T \mathbf{1}_{\{S_T > K\}}] = S e^{r\tau} \Phi(d_1). \quad (1.23)$$

1.18.5 Étape 5 : assembler

En injectant (1.22) et (1.23) dans (1.21) :

$$C(t, S) = e^{-r\tau} (S e^{r\tau} \Phi(d_1) - K \Phi(d_2)) = S \Phi(d_1) - K e^{-r\tau} \Phi(d_2).$$

Théorème 1.3 (Formule de Black-Scholes (call)). *Sous les hypothèses du modèle Black-Scholes, le prix d'une call européenne est :*

$$C(t, S) = S \Phi(d_1) - K e^{-r\tau} \Phi(d_2), \quad (1.24)$$

avec

$$d_1 = \frac{\log(S/K) + (r + \frac{1}{2}\sigma^2)\tau}{\sigma\sqrt{\tau}}, \quad d_2 = d_1 - \sigma\sqrt{\tau}.$$

Sanity check.

- **Bornes.** On doit avoir $0 \leq C(t, S) \leq S$ et $C(t, S) \geq (S - K e^{-r\tau})^+$ (borne d'arbitrage par parité et domination).
- **Court terme.** Quand $\tau \downarrow 0$, le prix doit tendre vers le payoff $(S - K)^+$: c'est bien le cas, car d_1, d_2 deviennent très grands (en valeur absolue) et les CDF « saturant » vers 0 ou 1 selon $S \leq K$.
- **Volatilité nulle.** Quand $\sigma \downarrow 0$, S_T devient (presque) déterministe sous $\mathbb{Q}$ et C tend vers $(S - K e^{-r\tau})^+$: on retrouve le pricing d'un payoff sur un forward sans incertitude.

Remarque 1.5 (Interprétation de d_1 et d_2). La formule (1.24) peut se lire comme

$$C(t, S) = S \Phi(d_1) - K e^{-r\tau} \Phi(d_2).$$

Sous la mesure risque-neutre $\mathbb{Q}$, $\Phi(d_2)$ est exactement une probabilité d'être dans la monnaie :

$$\Phi(d_2) = \mathbb{Q}(S_T > K \mid S_t = S).$$

Le terme $\Phi(d_1)$ est une probabilité analogue sous une mesure « pondérée par l'action » (numéraire S) : si l'on définit $\mathbb{Q}^S$ par

$$\frac{d\mathbb{Q}^S}{d\mathbb{Q}} := \frac{S_T}{S_t e^{r\tau}},$$

alors $\Phi(d_1) = \mathbb{Q}^S(S_T > K \mid S_t = S)$. Cette lecture explique pourquoi deux CDF normales apparaissent naturellement.

1.18.6 Put, parité call-put

Pour une put européenne, la formule est :

$$P(t, S) = K e^{-r\tau} \Phi(-d_2) - S \Phi(-d_1). \quad (1.25)$$

La parité call-put s'écrit :

$$C(t, S) - P(t, S) = S - K e^{-r\tau}.$$

1.19 Résoudre la PDE : réduction à l'équation de la chaleur

La section précédente a utilisé la représentation risque-neutre (1.18) et la loi lognormale (1.20). Il est aussi instructif de *résoudre directement* la PDE (1.13). Cela clarifie le rôle des changements de variables et montre le lien entre Black-Scholes et l'équation de la chaleur.

1.19.1 Étape 0 : réécrire la PDE en temps restant

On pose $\tau := T - t$. Comme $V_t = -V_\tau$, la PDE (1.13) devient :

$$V_\tau = \frac{1}{2}\sigma^2 S^2 V_{SS} + r S V_S - r V, \quad V(0, S) = \Phi(S). \quad (1.26)$$

1.19.2 Étape 1 : enlever le terme $-rV$ par actualisation

On introduit une fonction adimensionnée u via

$$V(t, S) = K e^{-r\tau} u(\tau, x), \quad x := \log(S/K). \quad (1.27)$$

(Cette transformation combine : (i) actualisation, (ii) normalisation par le strike, (iii) passage en log-prix.)

Calculons les dérivées :

$$V_\tau = K e^{-r\tau} (u_\tau - ru), \quad V_S = K e^{-r\tau} \frac{u_x}{S}, \quad V_{SS} = K e^{-r\tau} \frac{u_{xx} - u_x}{S^2}.$$

En substituant dans (1.26) et en simplifiant par $Ke^{-r\tau}$, on obtient :

$$u_\tau = \frac{1}{2}\sigma^2 u_{xx} + \left(r - \frac{1}{2}\sigma^2\right) u_x. \quad (1.28)$$

On a donc une équation de *convection-diffusion* : diffusion (terme u_{xx}) + drift (terme u_x).

1.19.3 Étape 2 : supprimer la convection par un changement de repère

Notons $c := r - \frac{1}{2}\sigma^2$. On définit une nouvelle variable spatiale

$$y := x + c\tau$$

et une fonction w par $w(\tau, y) := u(\tau, x)$ (avec $y = x + c\tau$). Alors, par dérivation en chaîne,

$$u_x = w_y, \quad u_{xx} = w_{yy}, \quad u_\tau = w_\tau + cw_y.$$

En injectant dans (1.28), les termes en cw_y s'annulent et il reste :

$$w_\tau = \frac{1}{2}\sigma^2 w_{yy}. \quad (1.29)$$

C'est l'équation de la chaleur (en 1D), avec coefficient de diffusion σ .

1.19.4 Étape 3 : condition initiale et solution par convolution

À $\tau = 0$ (donc $t = T$), on a $V(0, S) = \Phi(S)$. Pour une call, $\Phi(S) = (S - K)^+$. Avec $S = Ke^x$, on obtient

$$u(0, x) = \frac{\Phi(Ke^x)}{K} = (e^x - 1)^+.$$

Comme $y = x$ lorsque $\tau = 0$, la condition initiale de w est :

$$w(0, y) = u(0, y) = (e^y - 1)^+.$$

La solution de (1.29) s'écrit comme une convolution gaussienne :

$$w(\tau, y) = \mathbb{E}[w(0, y + \sigma\sqrt{\tau}Z)], \quad Z \sim \mathcal{N}(0, 1). \quad (1.30)$$

En revenant à u puis V , on retrouve une représentation en espérance qui est (au fond) une version de Feynman–Kac.

1.19.5 Étape 4 : retrouver d_1, d_2

En combinant (1.27) et (1.30), on obtient (pour une call) :

$$V(t, S) = K e^{-r\tau} \mathbb{E}\left[\left(\exp(x + c\tau + \sigma\sqrt{\tau}Z) - 1\right)^+\right].$$

En substituant $x = \log(S/K)$ et $c = r - \frac{1}{2}\sigma^2$, on reconnaît la même structure que (1.20). Le calcul explicite de cette espérance mène exactement aux d_1, d_2 et à la formule (1.24).

1.20 Mode microscope : PDE, formule fermée, greeks (pas à pas)

1.20.1 Hypothèses explicites du modèle

- Sous-jacent S_t continu, sans sauts, dynamique de type GBM : $dS_t = \mu S_t dt + \sigma S_t dW_t$ sous $\mathbb{P}$.
- Marché frictionless : pas de coûts de transaction, possibilité de shorter et d'emprunter/prêter au taux r .
- Dividende continu q (optionnel) : une position longue en S reçoit $qS_t dt$.
- Volatilité constante σ et taux constants (hypothèses simplificatrices, discutées ensuite via le smile).

1.20.2 Dérivation de la PDE par réplication

Soit $V(t, S)$ le prix de l'option à l'instant t quand $S_t = S$. Par Itô, en utilisant $dS_t = (r - q)S_t dt + \sigma S_t dW_t$ sous $\mathbb{Q}$:

$$dV = \partial_t V dt + \partial_S V dS + \frac{1}{2} \partial_{SS} V \sigma^2 S^2 dt.$$

Considérons le portefeuille auto-financé

$$\Pi_t = V(t, S_t) - \Delta_t S_t.$$

La variation de gain du portefeuille est

$$d\Pi = dV - \Delta dS - q\Delta S dt,$$

car une position *courte* $-\Delta S$ implique de payer le dividende $q\Delta S dt$. Choisissons $\Delta = \partial_S V$: le terme en dS (donc en dW) s'annule et

$$d\Pi = \left(\partial_t V + \frac{1}{2} \sigma^2 S^2 \partial_{SS} V - qS \partial_S V \right) dt.$$

Comme Π est sans risque, il doit croître au taux r :

$$d\Pi = r\Pi dt = r(V - S\partial_S V) dt.$$

En identifiant les drifts, on obtient la PDE de Black-Scholes :

$$\partial_t V + \frac{1}{2} \sigma^2 S^2 \partial_{SS} V + (r - q)S \partial_S V - rV = 0, \quad V(T, S) = \Phi(S). \quad (1.31)$$

Interprétation.

- Le terme $\frac{1}{2} \sigma^2 S^2 \partial_{SS} V$ vient de la variation quadratique (terme d'ordre dt).
- $(r - q)S \partial_S V$ est le drift risque-neutre du sous-jacent (carry).
- $-rV$ est l'actualisation (valeur temps de l'argent).

Sanity check. Dimensions : $\partial_t V$ est en « prix / temps » ; chaque terme de (1.31) est en « prix / temps ».

1.20.3 Formule fermée du call européen

Sous $\mathbb{Q}$, $\ln S_T$ est normal :

$$\ln S_T \sim \mathcal{N}\left(\ln S_0 + (r - q - \frac{1}{2}\sigma^2)T, \sigma^2 T\right).$$

Pour un call $\Phi(S_T) = (S_T - K)^+$, le prix est

$$C_0 = S_0 e^{-qT} N(d_1) - K e^{-rT} N(d_2), \quad d_1 = \frac{\ln(S_0/K) + (r - q + \frac{1}{2}\sigma^2)T}{\sigma\sqrt{T}}, \quad d_2 = d_1 - \sigma\sqrt{T}. \quad (1.32)$$

Le put s'obtient via la parité call-put (arbitrage statique).

Exemple jouet. Exemple jouet : $S_0 = 100$, $K = 100$, $r = 2\%$, $q = 0$, $\sigma = 20\%$, $T = 1$. Alors $d_1 = 0.2$, $d_2 = 0$, $N(d_1) \approx 0.5793$, $N(d_2) = 0.5$, donc $C_0 \approx 8.92$.

1.20.4 Greeks : lecture de couverture

Pour le call (1.32) :

$$\Delta = \partial_{S_0} C_0 = e^{-qT} N(d_1), \quad \Gamma = \partial_{S_0 S_0} C_0 = e^{-qT} \frac{\varphi(d_1)}{S_0 \sigma \sqrt{T}}, \quad \text{Vega} = \partial_{\sigma} C_0 = S_0 e^{-qT} \varphi(d_1) \sqrt{T},$$

où φ est la densité $\mathcal{N}(0, 1)$.

Intuition de marché. Une position longue option est *gamma positive* : elle gagne quand le marché bouge, mais elle coûte du theta. La couverture delta vise à neutraliser les petits mouvements de S , pas le risque de volatilité.

1.21 Pièges classiques / erreurs fréquentes

- Oublier le dividende q dans la PDE / la formule (carry).
- Confondre μ (drift historique) et $r - q$ (drift risque-neutre).
- Croire que la couverture delta *élimine* tout risque : elle neutralise seulement le risque instantané en S , pas le risque de volatilité / sauts.
- Perdre les termes d'ordre dt en appliquant la chaîne classique au lieu d'Itô.

1.22 Checklist — savoir refaire sans regarder

- Dériver la PDE BS en partant de dS et d'Itô sur $V(t, S_t)$.
- Passer PDE $\leftrightarrow$ espérance sous $\mathbb{Q}$.
- Retrouver la formule du call/put et calculer un exemple numérique jouet.
- Dériver proprement $\Delta, \Gamma, \text{Vega}$ et expliquer leur lecture de couverture.

Chapitre 2

Compléments Black–Scholes : greeks, limites, numérique et panorama

Idée centrale. Passer de « formule » à « production » : greeks, P&L de hedging discret, volatilité implicite (smile/skew) et panorama des méthodes numériques (arbres, PDE, MC) quand BS casse.

Cadre mathématique.

- **Greeks.** $\Delta = \partial_S V$, $\Gamma = \partial_{SS} V$, Vega $\partial_\sigma V$, Theta $\partial_t V$; unités et interprétation.
- **Hedging discret.** Erreur gouvernée par Γ et la variation quadratique ; realised vol vs implied vol.
- **Smile.** Surface IV = reparamétrisation des prix ; contraintes d’absence d’arbitrage (monotonie/convexité en strike).

Intuition marché / interprétation. En desk, on gère des sensibilités, pas des prix : le hedging est imparfait (discret, coûts) et la surface IV encode les déviations (queues, leverage, vol-of-vol).

Implémentation.

- Implémenter greeks (analytique + bump) ; contrôler stabilité au bump.
- Construire un solveur d’IV robuste (Newton + garde-fous), puis des interpolations arbitrage-aware.

Tests / sanity checks.

- Bump test : greeks stables quand ε varie (sinon bruit numérique).
- P&L : delta-hedge sur trajectoires simulées ; vérifier dépendance à la realised vol et au pas de rebalancement.
- Arbitrage statique : tests monotonie/convexité sur chaque maturité.

Pont vers pratique quant. Pont quant : construction/cleaning de surfaces IV, choix de modèle (sauts, Heston, local/rough vol), et sélection de méthode numérique (PDE/MC/FFT) avec contrôles d’erreur et coûts de calcul.

2.1 Avant-propos : au-delà de la formule (greeks, couverture, smile)

Le chapitre précédent a donné deux objets :

- une **formule fermée** (call/put) dans un modèle idéalisé ;
- une **stratégie de couverture** (delta) qui réplique exactement le payoff *dans ce modèle*.

Dans la pratique, on ne vit pas dans Black–Scholes : σ n’est pas constante, la couverture est discrète, il y a des frictions, et les distributions ont des queues plus lourdes. Ce chapitre sert à faire le pont entre le « modèle » et la « salle de marché ».

2.1.1 Objectifs pédagogiques

- Relier les greeks à la réplication : pourquoi Δ annule le risque diffusif, pourquoi Γ gouverne l'erreur de couverture.
- Comprendre le PnL de delta-hedging : couverture discrète, volatilité réalisée vs volatilité de pricing.
- Introduire la volatilité implicite et le smile/skew comme *diagnostic* de modèle : BS devient un « langage ».
- Motiver les extensions : sauts (chapitre suivant) et volatilité stochastique (Heston).

2.1.2 Pré-requis

- Chapitre chapitre 1 : formule BS, définition de d_1, d_2 , et lecture sous $\mathbb{Q}$.
- Dérivées : savoir différencier $C(S, \sigma, t)$ et interpréter les unités.

2.1.3 Plan (et transition vers les modèles « industrie »)

1. Greeks : dérivations et interprétations.
2. Couverture : pourquoi l'erreur est gouvernée par la variation quadratique.
3. Smile : observation de marché $\Rightarrow$ motivation des sauts et de la vol stochastique.

Intuition de marché. En desk options, on quote en *vol implicite* (pas en prix). Les greeks et la couverture se pilotent au quotidien, tandis que le smile dit « quel modèle on doit ajouter » : queues/sauts, skew (levier), ou vol-of-vol.

2.2 Greeks : relire la réplication

Les *Greeks* sont des dérivées de V et mesurent la sensibilité du prix. Ils expliquent concrètement les choix faits dans la couverture :

- **Delta** : $\Delta = V_S$ (c'est *exactement* la quantité d'action utilisée pour annuler le terme en dW) ;
- **Gamma** : $\Gamma = V_{SS}$ (apparaît dans le drift de $d\Pi$ via Itô) ;
- **Vega** : $\nu = \partial_\sigma V$ (sensibilité à σ , qui n'est pas directement tradable dans BS) ;
- **Theta** : $\Theta = V_t$ (érosion temporelle) ;
- **Rho** : $\rho_r = \partial_r V$.

Formules (call). On note $\varphi(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}$ la densité normale standard. Alors pour une call BS :

$$\Delta = \Phi(d_1), \quad \Gamma = \frac{\varphi(d_1)}{S\sigma\sqrt{\tau}}, \quad \nu = S\sqrt{\tau} \varphi(d_1).$$

(Les expressions de Θ et ∂_r se déduisent par dérivation, et sont classiques.)

2.2.1 Dérivations détaillées (call) : pourquoi ces formules sont « propres »

Notation. On note $\tau := T - t$ et

$$d_1 = \frac{\log(S/K) + (r + \frac{1}{2}\sigma^2)\tau}{\sigma\sqrt{\tau}}, \quad d_2 = d_1 - \sigma\sqrt{\tau}.$$

On rappelle aussi que $\Phi' = \varphi$.

2.2.1.1 Identité-clé : $S \varphi(d_1) = K e^{-r\tau} \varphi(d_2)$

Cette identité est le petit « truc » derrière la simplicité de la delta et de la vega. Elle se vérifie par un calcul direct :

$$\frac{S \varphi(d_1)}{K e^{-r\tau} \varphi(d_2)} = \exp\left(\log(S/K) + r\tau - \frac{1}{2}(d_1^2 - d_2^2)\right).$$

Or $d_1 = d_2 + \sigma\sqrt{\tau}$, donc $d_1^2 - d_2^2 = 2d_2\sigma\sqrt{\tau} + \sigma^2\tau$ et

$$\frac{1}{2}(d_1^2 - d_2^2) = d_2\sigma\sqrt{\tau} + \frac{1}{2}\sigma^2\tau = \log(S/K) + (r - \frac{1}{2}\sigma^2)\tau + \frac{1}{2}\sigma^2\tau = \log(S/K) + r\tau.$$

Le rapport vaut donc $\exp(0) = 1$.

2.2.1.2 Delta : $\Delta = \partial_S C = \Phi(d_1)$

Partons de $C(S) = S\Phi(d_1) - K e^{-r\tau} \Phi(d_2)$ et différencions :

$$\partial_S C = \Phi(d_1) + S\varphi(d_1) \partial_S d_1 - K e^{-r\tau} \varphi(d_2) \partial_S d_2.$$

Comme $\partial_S d_1 = \partial_S d_2 = \frac{1}{S\sigma\sqrt{\tau}}$, on obtient

$$\partial_S C = \Phi(d_1) + \frac{1}{S\sigma\sqrt{\tau}} (S\varphi(d_1) - K e^{-r\tau} \varphi(d_2)) = \Phi(d_1),$$

grâce à l'identité précédente.

2.2.1.3 Gamma : $\Gamma = \partial_{SS} C = \frac{\varphi(d_1)}{S\sigma\sqrt{\tau}}$

On part de $\Delta = \Phi(d_1)$ et on re-différencie :

$$\Gamma = \partial_S \Delta = \varphi(d_1) \partial_S d_1 = \frac{\varphi(d_1)}{S\sigma\sqrt{\tau}}.$$

2.2.1.4 Vega : $\nu = \partial_\sigma C = S\sqrt{\tau} \varphi(d_1)$

On a (seuls d_1, d_2 dépendent de σ) :

$$\partial_\sigma C = S\varphi(d_1) \partial_\sigma d_1 - K e^{-r\tau} \varphi(d_2) \partial_\sigma d_2.$$

En écrivant $d_1 = \frac{\log(S/K) + r\tau}{\sigma\sqrt{\tau}} + \frac{1}{2}\sigma\sqrt{\tau}$, on obtient

$$\partial_\sigma d_1 = -\frac{d_2}{\sigma}, \quad \partial_\sigma d_2 = \partial_\sigma (d_1 - \sigma\sqrt{\tau}) = -\frac{d_1}{\sigma}.$$

Donc

$$\partial_\sigma C = \frac{1}{\sigma} \left(-S d_2 \varphi(d_1) + K e^{-r\tau} d_1 \varphi(d_2) \right) = \frac{S \varphi(d_1)}{\sigma} (d_1 - d_2) = S\sqrt{\tau} \varphi(d_1),$$

en utilisant encore $S\varphi(d_1) = K e^{-r\tau} \varphi(d_2)$ et $d_1 - d_2 = \sigma\sqrt{\tau}$.

2.2.1.5 Theta et rho : comment les obtenir sans se noyer

Méthode. On peut (i) dériver directement la formule fermée, ou (ii) utiliser la PDE de Black-Scholes pour simplifier les expressions et éviter des annulations numériques. En pratique, on retient surtout le *signe* et les ordres de grandeur (par ex. la theta est typiquement négative pour une call vanille, hors dividendes).

Check dimensionnel. Δ est sans dimension ; Γ a la dimension de $1/S$; la vega a la dimension d'un prix (variation de C pour une variation « absolue » de σ). Cela aide à détecter des erreurs de facteur $\sqrt{\tau}$ ou S .

2.3 Couverture en pratique : discrétisation et PnL de couverture

La théorie Black–Scholes suppose une couverture continue, sans coûts, et un modèle (volatilité) correct. Dans la réalité, la couverture est discrète et le modèle est approximatif. Cette section explique *où* l'erreur apparaît et *pourquoi* la gamma est la quantité clé.

2.3.1 Couverture continue dans le modèle : réplication exacte

Dans le modèle BS, si l'on ré-équilibre en continu avec $\Delta_t = V_S(t, S_t)$, la diffusion en dW_t s'annule exactement dans $d\Pi_t = dV - \Delta dS$. Le portefeuille devient sans risque et son rendement est forcé à être r : c'est la réplication.

2.3.2 Erreur de modèle : volatilité réalisée différente de la volatilité de pricing

Supposons maintenant que l'on price avec une volatilité σ_{mod} , mais que le sous-jacent réalise une volatilité instantanée $\sigma_{\text{réel}}$ (en gardant r constant pour simplifier). On considère le prix *modèle* $V(t, S; \sigma_{\text{mod}})$, mais on applique Itô en utilisant la dynamique *réelle* :

$$dS_t = rS_t dt + \sigma_{\text{réel}} S_t dW_t.$$

Alors

$$dV = (V_t + rSV_S + \frac{1}{2}\sigma_{\text{réel}}^2 S^2 V_{SS}) dt + \sigma_{\text{réel}} SV_S dW_t.$$

En delta-hedgeant avec $\Delta = V_S$, le terme en dW_t s'annule encore, mais le drift du portefeuille devient :

$$d\Pi_t = (V_t + \frac{1}{2}\sigma_{\text{réel}}^2 S^2 V_{SS}) dt - r(V - SV_S)dt.$$

Or la PDE du *modèle* impose :

$$V_t + \frac{1}{2}\sigma_{\text{mod}}^2 S^2 V_{SS} = r(V - SV_S).$$

En soustrayant, on obtient une approximation classique du PnL de couverture (au premier ordre) :

$$d\Pi_t \approx \frac{1}{2} (\sigma_{\text{réel}}^2 - \sigma_{\text{mod}}^2) S_t^2 \Gamma_t dt. \quad (2.1)$$

Cette formule explique l'intuition suivante :

être long gamma, c'est gagner quand la variance réalisée dépasse la variance « pricée » ; être short gamma, c'est perdre.

2.3.3 Couverture discrète : l'erreur vient du terme quadratique

Si l'on ne ré-équilibre pas en continu, la quantité Δ_t est maintenue constante sur des intervalles $[t_i, t_{i+1}]$. Sur un petit pas, un développement de Taylor/Itô suggère que l'erreur de réplication contient un terme d'ordre

$$\frac{1}{2}\Gamma S^2 ((\Delta W)^2 - \Delta t),$$

qui a espérance nulle mais variance non nulle. Ainsi, même dans le « bon » modèle, une couverture discrète produit un PnL aléatoire, d'autant plus important que la gamma est grande (options proches du strike et proches de l'échéance).

Message à emporter. Itô ne sert pas seulement à dériver une PDE : il explique aussi pourquoi la convexité (Γ) gouverne l'erreur de couverture via la variation quadratique.

2.4 Limites du modèle et motivation de la volatilité stochastique

2.4.1 Volatilité implicite et smile

Dans Black-Scholes, σ est constant. Dans la pratique, on observe une surface de volatilité implicite $\sigma_{\text{impl}}(K, T)$, qui varie avec le strike et la maturité. Ce fait (le *smile* ou *skew*) indique que le modèle BS est trop simple pour décrire les prix de marché.

2.4.2 D'où peut venir l'écart ?

- Volatilité non constante (stochastique ou locale) ;
- queues plus épaisses que gaussiennes, sauts ;
- taux et dividendes non constants ;
- frictions : coûts de transaction, couverture discrète ;
- risques non couverts (modèle incomplet).

Transition naturelle vers Heston. Si l'on conserve l'idée « pas d'arbitrage + dynamique continue », mais qu'on laisse la variance évoluer aléatoirement, on obtient une classe de modèles de volatilité stochastique. Heston est le plus célèbre car il reste (relativement) tractable.

2.5 Pourquoi ajouter une dynamique de volatilité ?

Le smile/skew s'explique qualitativement par :

- des distributions de rendements asymétriques et leptokurtiques ;
- un *effet de levier* : baisse du stock $\Rightarrow$ hausse de la volatilité (corrélation négative) ;
- une volatilité qui « mean-revert » plutôt que d'être constante.

Un modèle de volatilité stochastique encode ces phénomènes avec une variable d'état supplémentaire (la variance).

2.6 Modèle de Heston : dynamique sous $\mathbb{P}$ et sous $\mathbb{Q}$

2.6.1 Définition (forme standard)

Le modèle de Heston (1993) introduit une variance instantanée (v_t) :

$$\begin{aligned} dS_t &= \mu S_t dt + \sqrt{v_t} S_t dW_t^{(1)}, \\ dv_t &= \kappa(\theta - v_t) dt + \xi \sqrt{v_t} dW_t^{(2)}, \\ d\langle W^{(1)}, W^{(2)} \rangle_t &= \rho dt, \end{aligned} \tag{2.2}$$

où :

- $\kappa > 0$ est la vitesse de retour à la moyenne ;
- $\theta > 0$ est le niveau de variance de long terme ;
- $\xi > 0$ (souvent noté σ_v) est la volatilité de la variance ;
- $\rho \in [-1, 1]$ est la corrélation (souvent négative pour reproduire le skew).

2.6.2 Positivité et condition de Feller

Le processus v_t est de type CIR. Sous la condition de Feller

$$2\kappa\theta \geq \xi^2,$$

on a (intuitivement) une forte poussée vers le haut près de 0, ce qui aide à maintenir $v_t > 0$. En pratique, même si la condition n'est pas strictement satisfaite, on utilise souvent des schémas numériques qui préservent la positivité.

2.6.3 Mesure risque-neutre et prime de risque de volatilité

Contrairement à Black–Scholes, il y a *deux* sources de risque $(W^{(1)}, W^{(2)})$. Si seuls S et B sont tradables, on ne peut pas couvrir parfaitement les deux. Le marché est typiquement **incomplet** : la mesure risque-neutre n'est plus unique.

Une manière courante de paramétrer la mesure de pricing $\mathbb{Q}$ est :

$$\begin{aligned} dS_t &= rS_t dt + \sqrt{v_t} S_t dW_t^{(1),\mathbb{Q}}, \\ dv_t &= \kappa^{\mathbb{Q}}(\theta^{\mathbb{Q}} - v_t) dt + \xi \sqrt{v_t} dW_t^{(2),\mathbb{Q}}, \\ d\langle W^{(1),\mathbb{Q}}, W^{(2),\mathbb{Q}} \rangle_t &= \rho dt. \end{aligned} \tag{2.3}$$

Les paramètres $(\kappa^{\mathbb{Q}}, \theta^{\mathbb{Q}})$ peuvent différer de ceux sous $\mathbb{P}$: la différence encode une *prime de risque de volatilité*.

2.7 Itô en dimension 2 : dériver la PDE de Heston

Soit $V(t, S, v)$ le prix d'un payoff $\Phi(S_T)$ dans Heston. On suppose V suffisamment régulière. On applique le Théorème 1.2 avec $(X, Y) = (S, v)$ et la dynamique (2.3).

2.7.1 Calcul des variations quadratiques

Sous (2.3) :

$$d[S]_t = v_t S_t^2 dt, \quad d[v]_t = \xi^2 v_t dt, \quad d[S, v]_t = \rho \xi v_t S_t dt.$$

2.7.2 Formule d'Itô et identification de la PDE

En appliquant (1.5) à $V(t, S_t, v_t)$ et en regroupant les termes en dt :

$$\begin{aligned} dV &= \left(V_t + rSV_S + \kappa^{\mathbb{Q}}(\theta^{\mathbb{Q}} - v)V_v + \frac{1}{2}vS^2V_{SS} + \frac{1}{2}\xi^2vV_{vv} + \rho\xi vSV_{Sv} \right) dt \\ &\quad + \left(\sqrt{v}SV_S \right) dW^{(1),\mathbb{Q}} + \left(\xi\sqrt{v}V_v \right) dW^{(2),\mathbb{Q}}. \end{aligned} \tag{2.4}$$

Dans un marché complet, on construirait une stratégie pour annuler les deux termes en dW (il faut alors deux actifs risqués). Dans Heston, le marché étant incomplet (en général), on choisit une mesure $\mathbb{Q}$ et on impose que le prix actualisé soit une martingale : on obtient la PDE de pricing suivante :

$$V_t + rSV_S + \kappa^{\mathbb{Q}}(\theta^{\mathbb{Q}} - v)V_v + \frac{1}{2}vS^2V_{SS} + \frac{1}{2}\xi^2vV_{vv} + \rho\xi vSV_{Sv} - rV = 0, \tag{2.5}$$

avec condition terminale $V(T, S, v) = \Phi(S)$.

Point clé. Le terme croisé V_{Sv} provient directement de la covariation $d[S, v]_t$ et donc de la corrélation ρ : c'est un pur effet *Itô multi-dimensionnel*.

2.8 Pourquoi Heston reste calculable : structure affine et fonction caractéristique

2.8.1 La bonne variable : $\log S_t$

Comme dans Black-Scholes, on travaille souvent avec $X_t = \log S_t$. Mais ici, l'EDS de X_t contient v_t :

$$dX_t = \left(r - \frac{1}{2}v_t\right) dt + \sqrt{v_t} dW_t^{(1),\mathbb{Q}}.$$

La loi marginale de X_T n'est plus normale.

2.8.2 Idée Heston : fonction caractéristique

Heston a montré que l'on peut calculer explicitement la fonction caractéristique de X_T conditionnellement à (X_t, v_t) :

$$\phi(u) := \mathbb{E}^{\mathbb{Q}}[\exp(iuX_T) \mid X_t = x, v_t = v],$$

et que $\phi(u)$ a une forme fermée (solution d'un système de Riccati). Ensuite, on obtient le prix des options par inversion de Fourier.

Conséquence pratique. On peut calibrer Heston à une surface de volatilité implicite en évaluant rapidement le prix de nombreuses options via FFT/quadrature.

2.9 Calibration : lecture qualitative des paramètres

Sans entrer dans tous les détails numériques, on peut retenir :

- $\theta^{\mathbb{Q}}$ contrôle le niveau moyen de variance à long terme (donc le niveau de vol) ;
- $\kappa^{\mathbb{Q}}$ contrôle la vitesse de retour et l'importance des effets court terme ;
- ξ contrôle la « vol-of-vol » (courbure et épaisseur des smiles) ;
- ρ contrôle le skew (asymétrie) ;
- v_0 fixe la volatilité instantanée au temps $t = 0$.

2.10 Comparaison Black-Scholes / Heston (résumé)

Aspect	Black-Scholes	Heston
Volatilité	σ constante	v_t stochastique (CIR), « vol-of-vol » ξ
Facteurs	1 facteur (S_t)	2 facteurs (S_t, v_t)
Bruits	1 brownien	2 browniens corrélés (ρ)
PDE	1D, sans terme croisé	2D, terme croisé V_{Sv}
Marché	complet (dans le modèle)	typiquement incomplet (prime de risque de vol)
Smile/skew	non (surface plate)	oui (skew via ρ , courbure via ξ)
Formule	fermée via Φ	semi-fermée via Fourier (fonction caractéristique)

Conclusion. Heston est une extension naturelle de Black-Scholes : on conserve le cadre continu et Itô, mais on enrichit le modèle pour reproduire les smiles. Le prix à payer est une complexité mathématique et numérique plus élevée, et la perte de complétude (d'où l'apparition d'une prime de risque de volatilité).

2.11 Corrigé (éléments de solution)

Les solutions ci-dessous sont volontairement « semi-rédigées » : l'objectif est de vous donner une structure que vous pourrez réexpliquer.

2.11.1 Itô sur un polynôme

1) **Calcul de $d(W_t^3)$.** On prend $f(x) = x^3$, donc $f'(x) = 3x^2$ et $f''(x) = 6x$. Comme dW_t est un processus d'Itô avec $a = 0$, $b = 1$, la formule (1.2) donne :

$$d(W_t^3) = 3W_t^2 dW_t + \frac{1}{2} \cdot 6W_t dt = 3W_t^2 dW_t + 3W_t dt.$$

2) **Construire une martingale.** Le terme de drift est $3W_t dt$. Une manière simple de le supprimer consiste à considérer $M_t := W_t^3 - 3tW_t$. En effet, par règle de produit,

$$d(tW_t) = W_t dt + t dW_t,$$

donc

$$dM_t = d(W_t^3) - 3d(tW_t) = (3W_t^2 dW_t + 3W_t dt) - 3(W_t dt + t dW_t) = 3(W_t^2 - t) dW_t.$$

Le membre de droite est une intégrale d'Itô : M_t est donc une martingale.

2.11.2 Produit et covariation

On applique Itô 2D à $f(x, y) = xy$. On a $f_x = y$, $f_y = x$, $f_{xy} = 1$, $f_{xx} = f_{yy} = 0$. La formule (1.5) donne alors :

$$d(X_t Y_t) = Y_t dX_t + X_t dY_t + d[X, Y]_t,$$

et $d[X, Y]_t = b_X b_Y \rho dt$.

2.11.3 Log et exponentielle

1) $d(\log S_t)$. C'est l'exemple 1.2 :

$$d(\log S_t) = \left(\mu - \frac{1}{2}\sigma^2\right) dt + \sigma dW_t.$$

2) $d(S_t^\alpha)$. Avec $f(s) = s^\alpha$, $f'(s) = \alpha s^{\alpha-1}$, $f''(s) = \alpha(\alpha-1)s^{\alpha-2}$. Comme $d[S]_t = \sigma^2 S_t^2 dt$, Itô donne :

$$d(S_t^\alpha) = \alpha S_t^{\alpha-1} dS_t + \frac{1}{2} \alpha(\alpha-1) S_t^{\alpha-2} d[S]_t = S_t^\alpha \left(\alpha\mu + \frac{1}{2} \alpha(\alpha-1) \sigma^2 \right) dt + \alpha \sigma S_t^\alpha dW_t.$$

3) **Martingale de type exponentielle.** Si l'on pose $M_t := S_t^\alpha e^{-ct}$, alors

$$dM_t = e^{-ct} d(S_t^\alpha) - c e^{-ct} S_t^\alpha dt.$$

Le drift s'annule si

$$c = \alpha\mu + \frac{1}{2} \alpha(\alpha-1) \sigma^2.$$

Dans ce cas, $dM_t = \alpha \sigma M_t dW_t$ et M est une martingale (sous hypothèses d'intégrabilité usuelles).

2.11.4 Re-dériver la PDE sans passer sous $\mathbb{Q}$

Le point crucial est que, dans $d\Pi_t = dV - \Delta dS$, le choix $\Delta = V_S$ annule le terme en dW et *annule aussi* le terme en μ . On obtient $d\Pi_t = (V_t + \frac{1}{2} \sigma^2 S_t^2 V_{SS}) dt$, puis $d\Pi_t = r\Pi_t dt$, d'où (1.13).

2.11.5 PDE et condition terminale

Put européenne. La PDE est toujours (1.13), mais la condition terminale est $V(T, S) = (K - S)^+$.

Digital call. La PDE est encore (1.13) avec condition terminale $V(T, S) = \mathbf{1}_{\{S > K\}}$. La fonction terminale est discontinue en $S = K$: on ne peut pas attendre une solution $C^{1,2}$ « classique » partout. En pratique, on travaille avec des solutions au sens faible (ou on lisse le payoff).

2.11.6 Dividendes continus

Si l'action verse un taux de dividende continu q , le gain d'une action détenue sur $[t, t + dt]$ devient $dS_t + qS_t dt$. La condition d'auto-financement s'écrit donc :

$$d\Pi_t = \Delta_t(dS_t + qS_t dt) + \beta_t dB_t.$$

En reprenant la construction $\Pi = V - \Delta S$ et en choisissant $\Delta = V_S$ pour annuler le terme en dW_t , on obtient le portefeuille sans risque :

$$d\Pi_t = (V_t + \frac{1}{2}\sigma^2 S^2 V_{SS} - qSV_S) dt.$$

L'absence d'arbitrage impose encore $d\Pi_t = r\Pi_t dt$, ce qui donne (1.16) :

$$V_t + \frac{1}{2}\sigma^2 S^2 V_{SS} + (r - q)SV_S - rV = 0.$$

Pour une call, la formule devient $C = Se^{-q\tau}\Phi(d_1) - Ke^{-r\tau}\Phi(d_2)$.

2.11.7 De la PDE à Feynman-Kac (martingale actualisée)

Sous $\mathbb{Q}$, $dS_t = rS_t dt + \sigma S_t dW_t^{\mathbb{Q}}$. Appliquez Itô à $e^{-rt}V(t, S_t)$:

$$d(e^{-rt}V) = e^{-rt}(dV - rV dt).$$

Or, sous $\mathbb{Q}$,

$$dV = (V_t + rSV_S + \frac{1}{2}\sigma^2 S^2 V_{SS}) dt + \sigma SV_S dW_t^{\mathbb{Q}}.$$

La PDE (1.13) implique que le coefficient de dt est nul dans $d(e^{-rt}V)$, donc

$$d(e^{-rt}V) = e^{-rt}\sigma SV_S dW_t^{\mathbb{Q}},$$

qui est une intégrale d'Itô : le processus est une martingale, ce qui redonne la représentation (1.18).

2.11.8 Calcul intégral de la call

Écrivez $S_T = S \exp((r - \frac{1}{2}\sigma^2)\tau + \sigma\sqrt{\tau}Z)$ avec $Z \sim \mathcal{N}(0, 1)$. Puis

$$C = e^{-r\tau}\mathbb{E}[(S_T - K)^+] = e^{-r\tau}\mathbb{E}[(S_T - K)\mathbf{1}_{\{S_T > K\}}].$$

On calcule $\mathbb{Q}(S_T > K) = \Phi(d_2)$ et $\mathbb{E}[S_T \mathbf{1}_{\{S_T > K\}}] = Se^{r\tau}\Phi(d_1)$ (voir le calcul détaillé dans le cours), d'où $C = S\Phi(d_1) - Ke^{-r\tau}\Phi(d_2)$.

2.11.9 Digital call en Black-Scholes

Par définition,

$$D(t, S) = \mathbb{E}^{\mathbb{Q}}[e^{-r\tau}\mathbf{1}_{\{S_T > K\}} \mid S_t = S] = e^{-r\tau}\mathbb{Q}(S_T > K \mid S_t = S).$$

Or $\mathbb{Q}(S_T > K) = \Phi(d_2)$ par (1.22). Donc $D(t, S) = e^{-r\tau}\Phi(d_2)$. L'interprétation est immédiate : le digital est le « pari » sur l'événement « être ITM », actualisé.

2.11.10 Put-call parity

L'identité sur les payoffs donne

$$C - P = e^{-r\tau}\mathbb{E}^{\mathbb{Q}}[S_T - K] = e^{-r\tau}(Se^{r\tau} - K) = S - Ke^{-r\tau}.$$

2.11.11 Greeks et interprétation

Delta. On dérive (1.24) par rapport à S et on obtient $\Delta = \Phi(d_1)$. Comme $\Phi \in (0, 1)$, la delta d'une call est entre 0 et 1.

Gamma. La gamma vaut $\Gamma = \varphi(d_1)/(S\sigma\sqrt{\tau}) > 0$: une call est « convexe » en S .

Vega. La vega vaut $\nu = S\sqrt{\tau}\varphi(d_1) > 0$: une hausse de σ augmente le prix d'une option vanille (plus d'incertitude).

2.11.12 PnL de delta-hedging et mismatch de volatilité

On suppose que $V(t, S)$ est le prix modèle (volatilité σ_{mod}) mais que S réalise $\sigma_{\text{réel}}$. Le calcul est celui de la section sur la couverture en pratique :

- le terme en dW s'annule encore avec $\Delta = V_S$;
- le drift restant est la différence entre la PDE « réelle » (avec $\sigma_{\text{réel}}$) et la PDE modèle (avec σ_{mod}).

On obtient :

$$d\Pi_t \approx \frac{1}{2}(\sigma_{\text{réel}}^2 - \sigma_{\text{mod}}^2)S_t^2\Gamma_t dt.$$

Si vous êtes long gamma ($\Gamma > 0$), vous gagnez lorsque la variance réalisée dépasse la variance implicite du modèle, et inversement.

2.11.13 Itô 2D et terme croisé (Heston)

Dans (2.3), les diffusions sont $b_S = \sqrt{v}S$ et $b_v = \xi\sqrt{v}$, avec corrélation ρ . Donc

$$d[S, v]_t = b_S b_v \rho dt = \rho \xi v_t S_t dt,$$

ce qui engendre le terme $V_{Sv} d[S, v]_t$ et donc le coefficient $\rho \xi v S$ devant V_{Sv} dans (2.5).

2.11.14 Réduction à Black–Scholes

Si $v_t \equiv \bar{v}$, alors (2.3) devient

$$dS_t = rS_t dt + \sqrt{\bar{v}}S_t dW_t^{(1), \mathbb{Q}},$$

soit un brownien géométrique de volatilité $\sigma = \sqrt{\bar{v}}$. Dans la PDE de Heston (2.5), les termes en V_v , V_{vv} et V_{Sv} disparaissent (puisque V ne dépend plus de v) et il reste exactement la PDE de Black–Scholes (1.13) avec $\sigma^2 = \bar{v}$.

2.11.15 Incomplétude

Il y a deux bruits ($W^{(1)}, W^{(2)}$), donc deux risques instantanés indépendants à couvrir. Si l'on ne peut trader que S (et B), on ne dispose que d'une source de couverture risquée : on ne peut annuler simultanément les deux termes en dW dans (2.4). Pour compléter le marché, il faut typiquement ajouter un second actif risqué sensible à v (par exemple une option liquide, ou un produit variance/volatilité).

2.12 Complétion du carré (rappel)

Un calcul très fréquent est :

$$\int_a^\infty \exp\left(-\frac{(x-m)^2}{2s^2} + x\right) dx.$$

On écrit

$$-\frac{(x-m)^2}{2s^2} + x = -\frac{1}{2s^2} (x - (m + s^2))^2 + m + \frac{1}{2}s^2.$$

Cette identité explique le passage de d_2 à d_1 dans le calcul de (1.23).

2.13 Table mnémotechnique d'Itô

Produit	Valeur (Itô)	Commentaire
$(dt)^2$	0	ordre dt^2
$dt dW_t$	0	ordre $dt^{3/2}$
$(dW_t)^2$	dt	variation quadratique

2.14 Formule d'Itô et delta-hedging : obtenir la PDE

2.14.1 Itô (ce qu'on utilise)

Si S_t suit

$$dS_t = a(t, S_t) dt + b(t, S_t) dW_t,$$

et si $V(t, S)$ est $C^{1,2}$, alors

$$dV(t, S_t) = \left(V_t + aV_S + \frac{1}{2}b^2V_{SS} \right) dt + bV_S dW_t.$$

2.14.2 Application à Black–Scholes

Sous Black–Scholes (mesure $\mathbb{Q}$), on a

$$dS_t = (r - q)S_t dt + \sigma S_t dW_t,$$

donc $a(t, S) = (r - q)S$ et $b(t, S) = \sigma S$. Donc :

$$dV_t = \left(V_t + (r - q)S_t V_S + \frac{1}{2}\sigma^2 S_t^2 V_{SS} \right) dt + \sigma S_t V_S dW_t.$$

Considérons le portefeuille auto-finançant $\Pi_t = V_t - \Delta_t S_t$. Alors

$$d\Pi_t = dV_t - \Delta_t dS_t.$$

En choisissant $\Delta_t := V_S(t, S_t)$, on élimine le terme en dW_t . Le portefeuille est localement sans risque ; par absence d'arbitrage :

$$d\Pi_t = r\Pi_t dt = r(V_t - S_t V_S)dt.$$

On obtient la **PDE de Black–Scholes** :

$$V_t + \frac{1}{2}\sigma^2 S^2 V_{SS} + (r - q)SV_S - rV = 0. \quad (2.6)$$

Remarque 2.1 (Point pédagogique clé). Le drift historique μ disparaît car l'option est **répliquée** par l'action et le cash. Une fois le risque éliminé, le rendement doit être r : le prix est gouverné par l'arbitrage, pas par les anticipations.

2.15 Résolution : formules fermées de Black–Scholes (call/put européens)

2.15.1 Distribution du sous-jacent sous $\mathbb{Q}$

La solution de l'SDE Black–Scholes ci-dessus est

$$S_T = S_0 \exp\left((r - q - \frac{1}{2}\sigma^2)T + \sigma\sqrt{T}Z\right), \quad Z \sim \mathcal{N}(0, 1).$$

2.15.2 Calcul pas à pas du call

On écrit

$$(S_T - K)^+ = S_T \mathbf{1}_{\{S_T > K\}} - K \mathbf{1}_{\{S_T > K\}}.$$

Donc

$$C_0 = e^{-rT} \mathbb{E}_{\mathbb{Q}}[S_T \mathbf{1}_{\{S_T > K\}}] - e^{-rT} K \mathbb{Q}(S_T > K).$$

On obtient (calcul lognormal standard) :

$$\mathbb{Q}(S_T > K) = \Phi(d_2), \quad e^{-rT} \mathbb{E}_{\mathbb{Q}}[S_T \mathbf{1}_{\{S_T > K\}}] = S_0 e^{-qT} \Phi(d_1),$$

où

$$d_1 = \frac{\ln(S_0/K) + (r - q + \frac{1}{2}\sigma^2)T}{\sigma\sqrt{T}}, \quad d_2 = d_1 - \sigma\sqrt{T}.$$

Finalement :

$$C_0 = S_0 e^{-qT} \Phi(d_1) - K e^{-rT} \Phi(d_2). \quad (2.7)$$

2.15.3 Put : soit par calcul direct, soit par parité

La formule du put est :

$$P_0 = K e^{-rT} \Phi(-d_2) - S_0 e^{-qT} \Phi(-d_1). \quad (2.8)$$

2.15.4 Greeks (formules utiles et interprétation)

Pour un call BS :

$$\Delta_{\text{call}} = e^{-qT} \Phi(d_1), \quad \Gamma_{\text{call}} = \frac{e^{-qT} \varphi(d_1)}{S_0 \sigma \sqrt{T}}, \quad \nu_{\text{call}} = S_0 e^{-qT} \varphi(d_1) \sqrt{T}.$$

2.16 De la PDE à l'espérance : la formule de Feynman–Kac (preuve guidée)

La PDE (2.6) est un objet d'analyse ; la formule d'espérance $e^{-rT} \mathbb{E}_{\mathbb{Q}}[\Phi(S_T)]$ est un objet probabiliste. Il faut savoir expliquer le pont entre les deux.

Théorème 2.1 (Feynman–Kac dans Black–Scholes (version utile ici)). *Soit $V(t, S)$ une solution suffisamment régulière de la PDE de Black–Scholes (2.6) avec condition terminale $V(T, S) = \Phi(S)$. Alors, pour tout $t \in [0, T]$,*

$$V(t, S_t) = \mathbb{E}_{\mathbb{Q}} \left[e^{-r(T-t)} \Phi(S_T) \mid \mathcal{F}_t \right].$$

En particulier, $V(0, S_0) = e^{-rT} \mathbb{E}_{\mathbb{Q}}[\Phi(S_T)]$.

Preuve guidée (à connaître). Sous $\mathbb{Q}$, S_t suit l'SDE Black–Scholes. On considère le processus actualisé :

$$M_t := e^{-rt} V(t, S_t).$$

On applique Itô à $V(t, S_t)$, puis la règle du produit à $e^{-rt} V(t, S_t)$. En utilisant que V satisfait la PDE (2.6), tous les termes de drift se simplifient et il reste

$$dM_t = e^{-rt} \sigma S_t V_S(t, S_t) dW_t,$$

donc M_t est une martingale (intégrabilité supposée). Ainsi,

$$M_t = \mathbb{E}_{\mathbb{Q}}[M_T \mid \mathcal{F}_t] = \mathbb{E}_{\mathbb{Q}}[e^{-rT} \Phi(S_T) \mid \mathcal{F}_t].$$

En multipliant par e^{rt} , on obtient l'égalité annoncée. □

Remarque 2.2 (Ce qu'il faut retenir). La PDE de Black-Scholes n'est pas « un choix » : elle est imposée par l'absence d'arbitrage. La formule d'espérance n'est pas « un postulat » : elle découle du fait que le prix actualisé est une martingale sous $\mathbb{Q}$.

2.17 Définitions et point de vue « optimal stopping »

Définition 2.1 (Option américaine). Une option américaine peut être exercée à tout instant $\tau \in [0, T]$. Sa valeur au temps t est

$$V_t = \sup_{\tau \in \mathcal{T}_{t,T}} \mathbb{E}_{\mathbb{Q}} \left[e^{-r(\tau-t)} \Phi(S_{\tau}) \mid \mathcal{F}_t \right],$$

où $\mathcal{T}_{t,T}$ est l'ensemble des temps d'arrêt à valeurs dans $[t, T]$.

Définition 2.2 (Option bermudane). Une option bermudane ne peut être exercée que sur un ensemble discret de dates $0 < t_1 < \dots < t_m \leq T$. Elle est un compromis pratique entre européenne (une seule date) et américaine (continu).

2.17.1 Principe de programmation dynamique

En discret (arbre binomial ou dates bermudanes), la valeur vérifie une relation simple :

$$V_{t_k} = \max \left(\Phi(S_{t_k}), e^{-r\Delta t} \mathbb{E}_{\mathbb{Q}}[V_{t_{k+1}} \mid \mathcal{F}_{t_k}] \right).$$

Deux régions apparaissent :

- **exercice region** : on exerce car la valeur intrinsèque domine ;
- **continuation region** : on conserve l'option.

2.18 Formulation PDE : problème à frontière libre

Dans la région de continuation, V satisfait la PDE de Black-Scholes. Dans la région d'exercice, $V = \Phi$. On peut résumer le tout via des conditions de complémentarité :

$$\max (\mathcal{L}V - rV, \Phi - V) = 0,$$

où $\mathcal{L}$ est le générateur de S_t sous $\mathbb{Q}$:

$$\mathcal{L}V = V_t + (r - q)SV_S + \frac{1}{2}\sigma^2 S^2 V_{SS}.$$

2.19 Méthodes numériques (à connaître et savoir justifier)

- **Arbres binomiaux/trinômiaux** : robustes, rapides, pédagogiques ; très utilisés pour américaines.
- **Différences finies (PDE)** : efficaces en faible dimension ; permettent d'obtenir la frontière.
- **Monte Carlo + régression (Longstaff-Schwartz)** : standard pour Bermudans multi-actifs.

2.20 Panorama des options : vanilles, digitals, exotiques

Ce panorama sert de *pont* entre les payoffs (arbitrage statique) et les choix de méthodes de pricing. Avant de sortir une technique (formule fermée, arbre, PDE, Monte Carlo, Fourier), on commence par classer le produit :

- **dépendance au chemin** (Asian, barrière, lookback) vs payoff terminal ;
- **dimension** (mono-actif vs multi-actifs) ;
- **exercice** (européen vs américain/bermudan) ;

- **régularité** (payoff lisse vs discontinuités de type digital).

L'objectif est de savoir justifier, pour chaque famille, la méthode « naturelle » et ses limites.

2.21 Comment choisir une méthode de pricing ?

Le choix de la méthode dépend essentiellement de :

- la dimension (un actif vs multi-actifs) ;
- la dépendance au chemin (barrières, Asians, lookbacks, cliquets) ;
- l'exercice anticipé (américaines/bermudanes) ;
- le modèle (diffusion simple vs vol stochastique vs sauts).

Produit	Dimension	Exercice	Méthodes typiques
Vanille (BS)	1	Européen	Formule fermée, PDE
Américaine (1D)	1	Continu	Arbre, PDE (frontière libre)
Asian	1 (+moyenne)	Européen	Monte Carlo, PDE 2D
Barrière	1	Européen	Formule (BS), PDE, MC+bridge
Basket/spread	$d \geq 2$	Souvent eur.	Monte Carlo, approximations
Heston vanilles	2 (spot,var)	Européen	Fourier/FFT, PDE 2D

2.22 Arbres binomiaux / trinômiaux

2.22.1 Ce qu'ils font bien

- ils sont **très pédagogiques** (réplication explicite) ;
- ils gèrent naturellement l'**exercice anticipé** (max à chaque nœud) ;
- ils sont robustes pour beaucoup de produits « 1D ».

2.22.2 Points d'attention

- convergence parfois lente pour greeks (sauts de discrétisation) ;
- extension multi-actifs coûteuse (explosion combinatoire) ;
- choix de u, d et calibration de σ importants.

2.23 PDE et différences finies

2.23.1 Le cadre

En BS, une option européenne vérifie la PDE (2.6) avec condition terminale $V(T, S) = \Phi(S)$. Les différences finies consistent à discrétiser :

- le temps t (ou le temps restant $\tau = T - t$),
- l'espace S (ou $\ln S$).

2.23.2 Schémas classiques

- **Explicite** : simple mais condition de stabilité (CFL).
- **Implicite** : stable, mais nécessite la résolution d'un système linéaire.
- **Crank–Nicolson** : ordre 2 en temps (souvent bon compromis), attention aux oscillations si payoff non lisse (Rannacher).

2.23.3 Américaines : frontière libre en pratique

En différences finies, on impose la contrainte $V \geq \Phi$. Méthodes : **PSOR** (Projected SOR), **penalty method**, ou formulation complémentarité.

2.24 Monte Carlo : universel mais bruité

2.24.1 Principe

On simule N trajectoires sous $\mathbb{Q}$ et on estime

$$V_0 \approx e^{-rT} \frac{1}{N} \sum_{j=1}^N \Phi^{(j)}.$$

L'erreur statistique décroît comme $1/\sqrt{N}$ (dimension-indépendant).

2.24.2 Réduction de variance (essentiels)

- **Antithétiques** : simuler Z et $-Z$.
- **Control variates** : utiliser un produit proche à prix connu (ex. Asian arithmétique avec control géométrique).
- **Stratification / quasi-Monte Carlo** : améliorer la convergence en dimension modérée.

2.24.3 Barrières : franchissement entre deux dates

Sans correction, un MC discret sous-estime le nombre de hits. On utilise un **Brownian bridge** pour approximer la probabilité de franchissement conditionnelle entre t et $t+h$ (voir section barrières).

2.24.4 Greeks en Monte Carlo

- **Bump & revalue** : simple, mais bruité et coûteux.
- **Pathwise derivative** : efficace si payoff lisse.
- **Likelihood ratio** : utile pour digitals/discontinuités.

2.24.5 Exercice anticipé : Longstaff-Schwartz (LSM)

Pour une Bermudan, on approxime la valeur de continuation par régression sur des fonctions de base (polynômes, splines) :

$$\hat{C}(S_{t_k}) \approx \sum_{\ell} a_{\ell} \psi_{\ell}(S_{t_k}),$$

et on décide exercice vs continuation sur chaque trajectoire.

2.25 Fourier / FFT : rapide pour les vanilles

2.25.1 Quand c'est pertinent

Si le modèle fournit une fonction caractéristique $\phi(u) = \mathbb{E}[e^{iuX_T}]$ explicite (Heston, Bates), on peut pricer les vanilles par inversion de Fourier.

2.25.2 Carr–Madan (idée)

On applique un « damping » au payoff pour assurer l'intégrabilité, puis on calcule une transformée de Fourier du prix en fonction du log-strike, et on utilise une FFT pour obtenir une grille de strikes rapidement.

2.26 Pourquoi sortir de Black–Scholes ? (smile, skew, leverage)

2.26.1 Le constat empirique

Dans Black–Scholes, la volatilité σ est constante. Sur les marchés, la volatilité implicite dépend :

- du strike (smile / skew) ;
- de la maturité (structure par terme) ;
- du sous-jacent (équity vs FX vs taux).

2.26.2 Lecture en termes de distribution

Grâce à Breeden–Litzenberger, une dépendance en strike signifie que la loi de S_T sous $\mathbb{Q}$ n'est pas lognormale. Le skew equity (vol plus élevée pour strikes bas) est cohérent avec :

- des queues de distribution plus épaisses ;
- un effet de levier : quand S baisse, la volatilité augmente.

2.27 Trois familles de modèles (vue d'ensemble)

- **Volatilité locale** : $\sigma = \sigma(t, S)$ calibrée pour reproduire exactement les vanilles (Dupire). Très bon fit statique, mais dynamique parfois peu réaliste.
- **Volatilité stochastique** : la variance suit un processus aléatoire (Heston, SABR, etc.). Bon compromis entre réalisme et tractabilité.
- **Sauts** : on ajoute des jumps au log-prix (Merton, Bates). Utile pour capturer des queues et des smiles courts termes.

2.28 Modèle de Heston : définition et interprétation

2.28.1 Dynamique sous la mesure risque-neutre

Définition 2.3 (Heston sous $\mathbb{Q}$). Le modèle de Heston s'écrit (avec dividendes q) :

$$\begin{aligned} dS_t &= (r - q)S_t dt + \sqrt{v_t} S_t dW_t^{(1)}, \\ dv_t &= \kappa(\theta - v_t) dt + \xi \sqrt{v_t} dW_t^{(2)}, \quad d\langle W^{(1)}, W^{(2)} \rangle_t = \rho dt. \end{aligned}$$

2.28.2 Lecture économique des paramètres

- θ : variance long-terme (« niveau » moyen) ;
- κ : vitesse de retour vers θ (mean reversion) ;
- ξ : « vol of vol » (amplitude des fluctuations de volatilité) ;
- ρ : corrélation spot/variance (contrôle le skew, effet de levier quand $\rho < 0$).

2.28.3 Positivité de la variance et condition de Feller

Une condition suffisante (classique) pour éviter que v_t touche zéro est :

$$2\kappa\theta \geq \xi^2.$$

En calibration, cette condition peut être violée : il faut alors choisir des schémas numériques robustes.

2.29 PDE de Heston et incomplétude : ce qui change par rapport à BS

2.29.1 Itô 2D et générateur

Le prix d'une option européenne est une fonction $V(t, S, v)$. En appliquant Itô à deux dimensions, on obtient une dynamique avec deux bruits $dW^{(1)}, dW^{(2)}$. Le générateur (sous $\mathbb{Q}$) est :

$$\mathcal{L}V = V_t + (r - q)SV_S + \kappa(\theta - v)V_v + \frac{1}{2}vS^2V_{SS} + \rho\xi vSV_{Sv} + \frac{1}{2}\xi^2vV_{vv}.$$

La PDE est alors :

$$\mathcal{L}V - rV = 0, \quad V(T, S, v) = \Phi(S).$$

2.29.2 Incomplétude (idée simple)

Dans Black-Scholes, une seule source de risque dW : l'action et le cash suffisent à répliquer. Dans Heston, deux sources de risque : en général, une seule action ne permet pas de couvrir le risque de variance. Le marché devient **incomplet** : plusieurs mesures martingales équivalentes peuvent exister, et il faut choisir une spécification de la prime de risque de volatilité pour passer de $\mathbb{P}$ à $\mathbb{Q}$.

2.30 Pricing des vanilles en Heston : l'idée « Fourier »

2.30.1 Pourquoi Fourier ?

On veut pricer

$$C_0(K, T) = e^{-rT} \mathbb{E}_{\mathbb{Q}}[(S_T - K)^+].$$

Le payoff $(\cdot - K)^+$ n'est pas lisse mais il a une transformée de Fourier (au sens distributionnel). Heston est **affine** : la fonction caractéristique de $X_T = \ln S_T$ est explicite, ce qui rend Fourier naturel.

2.30.2 Forme affine de la fonction caractéristique : système de Riccati

On veut calculer la fonction caractéristique du log-prix $X_T = \ln S_T$ sous Heston :

$$\phi_T(u) = \mathbb{E}_{\mathbb{Q}}[e^{iuX_T}].$$

Le point clef est que (X_t, v_t) est markovien et que, pour un payoff exponentiel, l'ansatz exponentiel-affine *se ferme*.

1) Passer en conditionnel. On pose la transformée conditionnelle

$$p(t, x, v; u) := \mathbb{E}_{\mathbb{Q}}[e^{iuX_T} \mid X_t = x, v_t = v].$$

Alors $\phi_T(u) = p(0, \ln S_0, v_0; u)$.

2) PDE de Feynman-Kac. Sous Heston (et en notant $\text{Corr}(dW^{(1)}, dW^{(2)}) = \rho$), on a

$$dX_t = \left(r - \frac{1}{2}v_t\right)dt + \sqrt{v_t} dW_t^{(1)}, \quad dv_t = \kappa(\theta - v_t)dt + \xi\sqrt{v_t} dW_t^{(2)}.$$

Le générateur $\mathcal{L}$ du couple (X, v) agit sur p par

$$(\mathcal{L}p)(t, x, v) = \left(r - \frac{1}{2}v\right) \partial_x p + \kappa(\theta - v) \partial_v p + \frac{1}{2}v \partial_{xx} p + \rho \xi v \partial_{xv} p + \frac{1}{2}\xi^2 v \partial_{vv} p.$$

La fonction p satisfait la PDE rétrograde

$$\partial_t p + \mathcal{L}p = 0, \quad p(T, x, v; u) = e^{iux}.$$

3) Ansatz exponentiel-affine. On pose $\tau := T - t$ et on cherche une solution de la forme

$$p(t, x, v; u) = \exp(A(\tau; u) + B(\tau; u)v + iux), \quad A(0; u) = 0, \quad B(0; u) = 0.$$

On calcule (en factorisant p) :

$$\partial_x p = iu p, \quad \partial_{xx} p = -(u^2) p, \quad \partial_v p = B p, \quad \partial_{vv} p = B^2 p, \quad \partial_{xv} p = iu B p,$$

et, comme $\partial_t = -\partial_\tau$,

$$\partial_t p = -(A'(\tau; u) + B'(\tau; u)v) p.$$

En injectant dans la PDE et en divisant par p , on obtient une identité de la forme

$$0 = (\text{termes constants en } v) + v \cdot (\text{termes linéaires en } v).$$

L'identification des coefficients en 1 et en v donne le système :

$$A'(\tau; u) = iur + \kappa\theta B(\tau; u), \tag{2.9}$$

$$B'(\tau; u) = -\frac{1}{2}(u^2 + iu) + (\rho\xi iu - \kappa) B(\tau; u) + \frac{1}{2}\xi^2 B(\tau; u)^2. \tag{2.10}$$

La seconde équation est une Riccati ; sa résolution explicite (et les précautions de branche/log) sont détaillées plus loin. Une fois A et B connues, on a

$$\phi_T(u) = \exp(A(T; u) + B(T; u)v_0 + iu \ln S_0).$$

Remarque 2.3 (Où trouver la suite). La chaîne « PDE $\rightarrow$ Riccati $\rightarrow$ inversion Fourier/FFT » est développée en détail dans la partie sur Heston et Carr–Madan, avec une résolution complète de la Riccati (2.10).

2.31 Simulation et pricing numérique en Heston (ce qu'il faut connaître)

2.31.1 Simulation de (S_t, v_t)

La discrétisation naïve d'Euler peut donner des variances négatives. Schémas utilisés :

- **full truncation Euler** (simple, robuste) ;
- **QE scheme** (Andersen) : souvent très bon pour CIR ;
- schémas implicites/alphas pour stabiliser la variance.

2.31.2 Pricing

Pour les vanilles : Fourier (Heston/Carr–Madan) est rapide et précis. Pour les exotiques : Monte Carlo sous Heston est standard (avec attention aux barrières : Brownian bridge).

2.31.3 Hedging (intuition)

Sous Heston, une couverture purement delta n'élimine pas le risque de variance. On introduit souvent une couverture **vega** (par une autre option) ou on accepte un risque résiduel (market incompleteness).

Conclusion

Ce cours a construit une vue **structurée** des options :

- la typologie des produits se lit d’abord via les **payoffs** (et leurs graphes) ;
- le pricing repose sur **absence d’arbitrage**, **réplication** et **mesure risque-neutre** ;
- Black–Scholes fournit un cadre analytique de base, mais le smile mène naturellement à des modèles plus riches ;
- Heston illustre une voie tractable vers la volatilité stochastique (et introduit l’incomplétude).

2.32 Fiche mémo : payoffs et écritures risque-neutres

Produit	Payoff (à T)
Forward	$S_T - K$
Call européen	$(S_T - K)^+$
Put européen	$(K - S_T)^+$
Digital cash call	$\mathbf{1}_{\{S_T > K\}}$
Gap call	$(S_T - K_1)\mathbf{1}_{\{S_T > K_2\}}$
Barrier KO (ex.)	$(S_T - K)^+ \mathbf{1}_{\{\tau_B > T\}}$
Asian avg price	$(A_T - K)^+$, $A_T = \frac{1}{n} \sum S_{t_i}$
Lookback fixed strike	$(M_T - K)^+$, $M_T = \max_{t \leq T} S_t$

2.33 Fiche mémo : formules Black–Scholes

$$C_0 = S_0 e^{-qT} \Phi(d_1) - K e^{-rT} \Phi(d_2), \quad P_0 = K e^{-rT} \Phi(-d_2) - S_0 e^{-qT} \Phi(-d_1),$$

$$d_1 = \frac{\ln(S_0/K) + (r - q + \frac{1}{2}\sigma^2)T}{\sigma\sqrt{T}}, \quad d_2 = d_1 - \sigma\sqrt{T}.$$

Digitale cash (call) : $D_0^{\text{cash}} = e^{-rT} \Phi(d_2)$.

2.34 Fiche mémo : Greeks Black–Scholes (vanilles)

On note toujours d_1, d_2 comme dans (2.7), et φ la densité normale standard.

Delta/Gamma.

$$\Delta_{\text{call}} = e^{-qT} \Phi(d_1), \quad \Delta_{\text{put}} = e^{-qT} (\Phi(d_1) - 1),$$

$$\Gamma_{\text{call}} = \Gamma_{\text{put}} = \frac{e^{-qT} \varphi(d_1)}{S_0 \sigma \sqrt{T}}.$$

Vega.

$$\nu_{\text{call}} = \nu_{\text{put}} = S_0 e^{-qT} \varphi(d_1) \sqrt{T}.$$

Rho (taux) et sens des signes. Pour r (taux sans risque), on retient :

$$\rho_{\text{call}} > 0, \quad \rho_{\text{put}} < 0,$$

et on peut dériver les expressions exactes à partir de (2.7)–(2.8).

2.35 Glossaire rapide (produits et mots-clés)

Terme	Idée / remarque
Vanille	Dépend uniquement de S_T ; formules fermées en BS.
Américaine	Exercice continu ; problème d'arrêt optimal ; arbre/PDE.
Bermudane	Exercice sur dates discrètes ; LSM très utilisé.
Digitale	Payoff indicateur ; liée à $\partial_K C$.
Barrière	Dépend du franchissement ; attention au monitoring discret (bridge).
Asian	Dépend d'une moyenne ; MC + control variate (géométrie).
Lookback	Dépend d'un extrême ; valeur temps élevée.
Spread/Basket	Multi-actifs ; corrélation cruciale ; MC/approximations.
Quanto	Changement de numéraire ; drift adjustment via corrélations.

2.36 Mode microscope : vol implicite, smile et méthodes

2.36.1 Volatilité implicite et méthode de Newton

On définit la volatilité implicite σ_{imp} comme la solution de

$$BS(\sigma_{\text{imp}}) = C^{\text{mkt}},$$

où $BS(\sigma)$ est le prix Black–Scholes (1.32) vu comme fonction de σ . Comme BS est croissante en σ (vega positive), on peut résoudre par Newton :

$$\sigma^{(n+1)} = \sigma^{(n)} - \frac{BS(\sigma^{(n)}) - C^{\text{mkt}}}{\text{Vega}(\sigma^{(n)})}.$$

Sanity check. Newton diverge si la vega est trop faible (options très ITM/OTM, maturité très courte). Dans ce cas, il faut borner / bisection.

2.36.2 Smile et densité implicite

Un smile (structure de $\sigma_{\text{imp}}(K)$) signifie que la loi risque-neutre n'est pas lognormale. Le lien avec la densité est donné par Breeden–Litzenberger (arbitrage statique) :

$$\partial_{KK} C_0(K, T) = e^{-rT} f_{S_T}^{\mathbb{Q}}(K).$$

Ainsi, la convexité en strike encode une densité ; le smile est une façon de reparamétriser cette information.

Intuition de marché. En desk, on cote souvent en vol implicite plutôt qu'en prix : c'est plus stable transversalement (maturités/strikes), et cela sépare « carry » (courbe) et « vol ».

2.37 Pièges classiques / erreurs fréquentes

- Confondre smile (fonction de K) et term-structure (fonction de T) : ce sont deux dimensions différentes.
- Utiliser Newton sans bornes : risque d'oscillation/divergence quand la vega est faible.
- Oublier les contraintes d'arbitrage statique : une surface « lisse » peut être arbitrable.

2.38 Checklist — savoir refaire sans regarder

- Définir σ_{imp} et écrire Newton avec vega.
- Relier smile $\leftrightarrow$ densité via Breeden–Litzenberger.

- Donner des sanity-checks d'arbitrage statique sur $K \mapsto C(K, T)$.
- Choisir une méthode numérique adaptée au produit (dimension, path-dependence, régularité).

Chapitre 3

Black–Scholes en pratique : smile, hedging discret, numérique (desk-ready)

3.1 Idée centrale

Black–Scholes est le **benchmark arbitrage-free** pour les options vanilles : (i) réplication $\Leftrightarrow$ martingale sous $\mathbb{Q}$, (ii) formule fermée $\Rightarrow$ greeks analytiques, (iii) **vol implicite** comme paramétrisation de marché. En production, la difficulté n'est pas le pricing BS, mais la **surface** (no-arb), l'**erreur de hedge** (discret/vol stoch/jumps) et la **stabilité numérique**.

3.2 Cadre mathématique (propre et standard)

3.2.1 Dynamiques sous mesure risque-neutre

Sous numéraire cash $B_t = e^{rt}$ (dividende continu q), le sous-jacent suit

$$\frac{dS_t}{S_t} = (r - q) dt + \sigma dW_t^{\mathbb{Q}}, \quad F_0(T) = S_0 e^{(r-q)T}.$$

Formule call (avec discounting) :

$$C_{BS} = S_0 e^{-qT} \Phi(d_1) - K e^{-rT} \Phi(d_2), \quad d_{1,2} = \frac{\ln(F_0/K) \pm \frac{1}{2}\sigma^2 T}{\sigma\sqrt{T}}.$$

3.2.2 PDE (lecture risk & numérique)

Pour $V(t, S)$, la PDE BS est

$$\partial_t V + (r - q)S \partial_S V + \frac{1}{2}\sigma^2 S^2 \partial_{SS} V - rV = 0, \quad V(T, S) = \Phi(S).$$

Greeks utiles (call) :

$$\Delta = e^{-qT} \Phi(d_1), \quad \Gamma = \frac{e^{-qT} \varphi(d_1)}{S_0 \sigma \sqrt{T}}, \quad \text{Vega} = S_0 e^{-qT} \sqrt{T} \varphi(d_1).$$

3.2.3 Vol implicite

La vol implicite $\sigma_{\text{imp}}(K, T)$ est définie par l'inversion $C^{\text{mkt}}(K, T) = C_{BS}(S_0, K, T, r, q, \sigma_{\text{imp}})$. **Point clé.** La surface implicite est *une représentation*, pas un modèle : elle doit être **sans arbitrage statique** (convexité en K , monotone en T).

3.3 Intuition marché / interprétation

- Le smile/skew résulte de (i) **vol stochastique** et leverage effect (corrélation prix/vol), (ii) **sauts** (queues), (iii) offre/demande (flow) + contraintes de hedge.
- La prime de risque de vol fait que la dynamique sous $\mathbb{P}$ (historique) diffère de celle sous $\mathbb{Q}$: calibrer à l'implicite *n'identifie pas* un drift historique.
- BS « casse » typiquement sur : maturités très courtes, barrières/digitals (sensibles à la dynamique fine), régimes de stress (corrélations et sauts).

3.4 Implémentation (robuste)

3.4.1 Pricing BS (attention au forward)

```
from math import log, sqrt, exp, erf, pi

def phi(x): # N(0,1) pdf
    return exp(-0.5*x*x)/sqrt(2*pi)

def Phi(x): # N(0,1) cdf
    return 0.5*(1.0 + erf(x/sqrt(2.0)))

def bs_call(S0, K, T, r, q, sigma):
    if T <= 0.0:
        return max(S0 - K, 0.0)
    F = S0*exp((r-q)*T)
    vol = max(1e-12, sigma*sqrt(T))
    d1 = (log(F/K) + 0.5*vol*vol)/vol
    d2 = d1 - vol
    return exp(-r*T) * (F*Phi(d1) - K*Phi(d2))
```

3.4.2 Vol implicite (Newton + garde-fous)

```
def implied_vol_call(C_mkt, S0, K, T, r, q, sigma0=0.2, it=30):
    sigma = max(1e-6, sigma0)
    for _ in range(it):
        price = bs_call(S0, K, T, r, q, sigma)
        F = S0*exp((r-q)*T)
        vol = max(1e-12, sigma*sqrt(T))
        d1 = (log(F/K) + 0.5*vol*vol)/vol
        vega = S0*exp(-q*T)*sqrt(T)*phi(d1)
        sigma = max(1e-8, sigma - (price - C_mkt)/max(vega, 1e-12))
    return sigma
```

En pratique. Bracketing (bissection) est plus robuste que Newton pour strikes extrêmes ; Newton est rapide si bien initialisé.

3.4.3 PDE (grille) : schémas stables

- **Crank-Nicolson** (ordre 2) est standard, mais un payoff non lisse (call) crée des oscillations : **Rannacher** (quelques pas implicites) stabilise.
- Stabilisé : travailler en $x = \ln S$ (coefficients plus doux), poser des **conditions aux bords** cohérentes (asymptotiques).
- Contrôle : positivity du prix, monotonicité vs K et S_0 , repricing des vanilles.

3.4.4 Hedging discret : ordre de grandeur de l'erreur

Sous BS, le hedge continu réplique. En discret (à pas Δ), le P&L de hedge est dominé par le terme gamma :

$$\Delta\Pi \approx \frac{1}{2} \Gamma_t S_t^2 \sigma^2 \left((\Delta W)^2 - \Delta \right),$$

donc $\text{Var}(\Delta\Pi)$ est d'ordre $\Gamma^2 S^4 \sigma^4 \Delta^2$ par pas et **l'erreur totale** est d'ordre $O(\Delta)$: *plus gamma est grand (ATM/short-dated), plus le hedge discret est risqué.*

3.5 Tests / sanity checks (3–6 concrets)

- **Put–call parity** : $C - P = S_0 e^{-qT} - K e^{-rT}$.
- **Monotonie/convexité** : C croît en S_0 , décroît en K , est convexe en K ; Vega > 0 .
- **Limites** : $T \rightarrow 0$ (intrinsèque), $\sigma \rightarrow 0$ (valeur $\approx e^{-rT} (F_0 - K)^+$).
- **Inversion** : σ_{imp} stable vs initialisation ; pas de sigma négatif, pas d'explosion en deep OTM.
- **Cross-check** : PDE/MC vs formule BS sur un grid (erreurs $\ll$ tick size).

3.6 Pitfalls (erreurs qui coûtent cher)

- Utiliser S_0 au lieu du **forward** (carry $r - q$) : erreur systématique sur d1/d2 et les greeks.
- Confondre unités : r en % annuel vs T en jours, σ en % vs décimal.
- Interpoler la vol implicite sans contrainte $\Rightarrow$ **butterfly/calendar arbitrage**.
- Newton sans garde-fous (deep ITM/OTM) $\Rightarrow$ divergence ; préférer bracketing.
- Oublier que le hedge réel subit **coûts + sauts + vol stoch** : « delta-hedge parfait » est un mythe de modèle.

3.7 Pont vers pratique quant

- **Risk** : greeks (delta/gamma/vega) + stress smile ; exposition au skew.
- **Surface** : construire une surface no-arb (SVI/SABR/local vol) avec contrôles (convexité/monotonie) et repricing.
- **Exotiques** : BS sert de base (numérique PDE/MC) ; le choix du modèle smile (local vs stoch vol) pilote le hedging et le model risk.

Interview Pack — Partie V (core)

Extensions « industrie » (sauts, vol stoch, Fourier/FFT)

Table des matières

1	Jump diffusion	1
1.1	Avant-propos : pourquoi ajouter des sauts ? (jump-diffusion)	1
1.2	Introduction : pourquoi ajouter des sauts ?	2
1.3	Rappels minimaux : diffusion, log-prix, absence d'arbitrage	3
1.4	Plan du cours (feuille de route)	3
1.5	Processus de Poisson : le chronomètre des sauts	3
1.6	Poisson marqué et Poisson composé : la taille des sauts	4
1.7	Le modèle de Merton : diffusion + sauts multiplicatifs	5
1.8	Résolution explicite et distribution de S_T	6
1.9	Calcul stochastique avec sauts : formule d'Itô (finie activité)	6
1.10	Mesure risque-neutre : ajustement de dérive et incomplétude	7
1.11	Générateur et PIDE de pricing	8
1.12	Formule semi-fermée de Merton (call européen) : dérivation pas à pas	9
1.13	Fonction caractéristique et pricing par Fourier (complément)	10
1.14	Simulation Monte Carlo (Merton)	11
1.15	Calibrage et interprétation des paramètres	12
1.16	Hedging et incomplétude	12
1.17	Ouverture : volatilité stochastique et modèle de Heston	12
1.18	Annexe A : résumé des formules essentielles (Merton)	15
1.19	Annexe B : preuve de la formule	15
1.20	Annexe C : notation « mesure de sauts » (optionnel)	16
1.21	Mode microscope : Itô avec sauts, PIDE et formule de Merton	16
1.22	Pièges classiques / erreurs fréquentes	17
1.23	Checklist — savoir refaire sans regarder	17
2	Heston : volatilité stochastique	18
2.1	Avant-propos : volatilité stochastique et modèle de Heston	18
2.2	Objectifs, prérequis, conventions	19
2.3	Rappels de finance mathématique : numéraire et changement de mesure	20
2.4	Cadre de pricing et rôle des fonctions caractéristiques	21
2.5	Boîte à outils Fourier : fonctions caractéristiques et prolongement complexe	21
2.6	Outil clé : inversion de Fourier pour une probabilité de queue	22
2.7	Le modèle de Heston : volatilité stochastique (CIR)	25
2.8	La PDE de Heston pour le pricing (contexte)	26
2.9	Étape 1 : fonction caractéristique de X_T sous Heston	27
2.10	Étape 2 : formule de Heston pour un call européen	29
2.11	Compléments : digitals, puts, greeks, et lecture économique de P_1, P_2	30
2.12	Mode microscope : affinité, Riccati et lecture des paramètres	31
2.13	Pièges classiques / erreurs fréquentes	31
2.14	Checklist — savoir refaire sans regarder	31
3	Fourier/fft - Carr–Madan	32
3.1	Avant-propos : Fourier/FFT (Carr–Madan)	32
3.2	Étape 3 : Carr–Madan (transformée de Fourier du prix en log-strike)	33

3.3	Mise en pratique : discrétisation et FFT (Carr–Madan)	35
3.4	Exemple numérique guidé (sans code) : pricer un call européen	35
3.5	Implémentation : stabilité numérique et tests de cohérence	37
3.6	Ouvertures : calibration, sourire de volatilité, extensions	38
3.7	Conclusion : la chaîne complète (à savoir refaire)	39
3.8	Corrigés détaillés (incontournables)	39
3.9	Annexe A : preuve de la formule de queue (variante)	40
3.10	Annexe B : note sur les conventions de signe	41
3.11	Annexe C : résolution détaillée de la Riccati de Heston	41
3.12	Annexe D : de l’inversion de Carr–Madan à la FFT (dérivation)	42
3.13	Annexe E : moments sous Heston et choix du paramètre α	43
3.14	Annexe F : Feynman–Kac (preuve complète, version utile)	44
3.15	Annexe G : changement de numéraire (preuve complète)	45
3.16	Annexe H : modèles affines — le « gabarit » derrière Heston	46
3.17	Annexe I : deux autres points de vue (sans détails techniques)	46
3.18	Annexe J : erreurs numériques (Carr–Madan / FFT)	47
3.19	Mode microscope : inversion Fourier et FFT	47
3.20	Pièges classiques / erreurs fréquentes	48
3.21	Checklist — savoir refaire sans regarder	48
4	CF/FFT en production : calibration, intégration, simulation (notes quant)	49
4.1	Idée centrale	49
4.2	Cadre mathématique (rappel minimal utile)	49
4.3	Implémentation FFT (ce qui compte vraiment)	49
4.4	Calibration (Heston/jumps) : réflexes buy-side/sell-side	50
4.5	Simulation (exotiques) : schémas qui tiennent	50
4.6	Tests / sanity checks (indispensables)	50
4.7	Pont vers pratique quant	50

Chapitre 1

Jump diffusion

Idée centrale. Ajouter des sauts pour capturer queues lourdes et mouvements brusques : jump-diffusion à la Merton, PIDE de pricing, et incomplétude (le saut n'est pas couvert par action+cash).

Cadre mathématique.

- **Modèle.** $dS_t/S_{t-} = (r - q - \lambda\kappa)dt + \sigma dW_t^{\mathbb{Q}} + (J - 1)dN_t$ avec N Poisson d'intensité λ , $\kappa = \mathbb{E}[J - 1]$.
- **Loi.** S_T est un mélange (conditionnellement à N_T) de lognormales (Merton).
- **Pricing.** PDE $\rightarrow$ PIDE (terme intégral sur les tailles de saut) ; mesure RN non unique en général.

Intuition marché / interprétation. Intuition desk : les sauts expliquent le smile court terme (skew/crash risk) et créent du risque de hedging « gap » (barrières, stops). La calibration remplace la réplication parfaite.

Implémentation.

- Simulation : tirer N_T , puis les tailles de saut et la diffusion ; MC avec contrôle de variance.
- Pricing : série de Merton, ou Fourier (fonction caractéristique) quand disponible.

Tests / sanity checks.

- Limite $\lambda \rightarrow 0$: retour Black-Scholes.
- Martingale : vérifier drift RN $r - q$ après compensation $(-\lambda\kappa)$.
- Smile : sensibilité des prix aux paramètres $(\lambda, \mu_J, \sigma_J)$ cohérente (skew/queues).

Pont vers pratique quant. Pont quant : modélisation du crash risk, pricing de barrières/exotiques sensibles aux gaps, calibration via options liquides, et transition naturelle vers les méthodes Fourier/FFT.

1.1 Avant-propos : pourquoi ajouter des sauts ? (jump-diffusion)

Black-Scholes est un modèle *diffusif* : les trajectoires sont continues, et l'incertitude s'accumule via une variation quadratique. Or, empiriquement, les rendements présentent des queues lourdes et des mouvements brusques (annonces macro, earnings, stress de liquidité). L'idée d'une jump-diffusion est donc : garder la diffusion (pour le bruit « normal ») et ajouter un mécanisme rare mais potentiellement violent.

1.1.1 Pourquoi c'est un chapitre « industrie »

Les sauts changent trois choses majeures :

- le pricing devient une **PIDE** (PDE + terme intégral), et non plus une PDE pure ;
- le marché devient typiquement **incomplet** (un saut ne se couvre pas avec uniquement action+banque) ;
- la mesure risque-neutre n'est plus unique : il faut un *choix* (principe) ou une calibration aux options.

1.1.2 Objectifs pédagogiques

- Comprendre le processus de Poisson (intensité, compensateur) et le Poisson marqué (taille des sauts).
- Écrire le modèle de Merton (diffusion + sauts multiplicatifs) et calculer explicitement la loi de S_T (mélange de lognormales).
- Dériver la condition de martingale sous $\mathbb{Q}$ et interpréter le terme $\lambda\kappa$ comme « drift moyen des sauts ».
- Dériver le générateur et la PIDE de pricing, puis la formule semi-fermée de Merton.

- Faire des sanity checks : cas $\lambda \rightarrow 0$ (retour BS), impact des paramètres sur le smile, et lien avec Fourier.

1.1.3 Pré-requis

- Black–Scholes : réplication, mesure $\mathbb{Q}$, lecture Feynman–Kac.
- Un minimum de calcul stochastique (Itô) et l'idée d'intégrale compensée.

1.1.4 Plan du chapitre

1. Poisson, Poisson marqué, et modèle de Merton.
2. Itô avec sauts (finie activité) et dynamique du log-prix.
3. Mesure risque-neutre : condition de martingale, incomplétude.
4. Générateur, PIDE, et pricing (Merton en série).
5. Ouverture : fonction caractéristique et lien naturel avec Fourier/FFT.

Sanity check. Retenir l'intuition : sous $\mathbb{Q}$, la dérive s'ajuste pour que le prix actualisé soit une martingale ; avec des sauts, cet ajustement inclut un terme « intensité $\times$ taille moyenne » : $\lambda\kappa$.

Résumé

Ces notes construisent pas à pas le modèle de *jump-diffusion* de Merton : pourquoi on ajoute des sauts, comment les modéliser via un processus de Poisson marqué, comment résoudre la dynamique, comment passer à la mesure risque-neutre, puis comment obtenir (i) la PIDE de pricing et (ii) la formule semi-fermée de Merton pour un call européen. Le document se termine par une ouverture vers la volatilité stochastique et le modèle de Heston (et annonce Bates : Heston + sauts).

1.2 Introduction : pourquoi ajouter des sauts ?

1.2.1 Le point de départ : Black–Scholes est un modèle diffusif

Dans Black–Scholes, le prix S_t suit un mouvement brownien géométrique :

$$\frac{dS_t}{S_t} = \mu dt + \sigma dW_t,$$

où W est un mouvement brownien standard et σ une constante. Les trajectoires sont continues : sur un intervalle court Δt , l'incrément relatif est de taille typique $\sigma\sqrt{\Delta t}$.

1.2.2 Faits stylisés (version quantitative)

Les rendements observés en pratique présentent souvent :

- **queues plus lourdes** que la normale (kurtosis) ;
- **asymétrie** (skewness), notamment sur equity ;
- **mouvements rares et violents** liés à l'information (earnings, annonces macro, crises) ;
- **smile/skew de volatilité implicite** (surface de vol non plate).

Un modèle à vol constante ne produit pas de smile : il force, à maturité fixée, une distribution lognormale simple pour S_T .

1.2.3 Principe de la jump-diffusion

L'idée est de conserver une composante diffusive (pour le bruit « normal » de marché) et d'y ajouter une composante de sauts (pour les chocs). On obtient des trajectoires **càdlàg** : continues à droite, avec des sauts ponctuels.

1.2.4 Objectifs pédagogiques

1. Construire un modèle de sauts à partir d'un processus de Poisson marqué.
2. Écrire et résoudre une SDE à sauts (forme explicite de S_t et de $\ln S_t$).

3. Comprendre la mesure risque-neutre et l'ajustement de dérive en présence de sauts.
4. Dériver la PIDE de pricing et la formule de Merton pour un call européen.
5. Situer jump-diffusion face à la volatilité stochastique (Heston) et comprendre le lien (Bates).

1.3 Rappels minimaux : diffusion, log-prix, absence d'arbitrage

1.3.1 Cadre probabiliste et numéraire

On travaille sur $(\Omega, \mathcal{F}, (\mathcal{F}_t)_{t \geq 0}, \mathbb{P})$. Le numéraire sans risque est

$$B_t = e^{rt},$$

avec r constant (hypothèse de cours).

1.3.2 Rappel : log d'un GBM

Sous une mesure quelconque (historique ou risque-neutre), si

$$\frac{dS_t}{S_t} = a dt + \sigma dW_t,$$

alors par Itô continu,

$$d(\ln S_t) = (a - \frac{1}{2}\sigma^2) dt + \sigma dW_t.$$

La variance du log à horizon T est $\sigma^2 T$: dans Black-Scholes, elle est à la fois **linéaire en T** et **déterministe**.

1.3.3 Principe de pricing risque-neutre

Sous l'absence d'arbitrage, il existe (sous des hypothèses standard) une mesure $\mathbb{Q}$ équivalente à $\mathbb{P}$ telle que le prix actualisé $\hat{S}_t = S_t/B_t$ soit une $\mathbb{Q}$ -martingale. Alors, pour un payoff européen $g(S_T)$,

$$V(t, S_t) = \mathbb{E}^{\mathbb{Q}} \left[e^{-r(T-t)} g(S_T) \mid \mathcal{F}_t \right].$$

1.3.4 Limite conceptuelle : un marché complet devient incomplet

Dès qu'on ajoute des sauts, le risque de saut n'est généralement pas répliquable avec S et B seuls : le marché devient **incomplet**. Conséquence centrale : la mesure risque-neutre n'est plus unique (on y revient plus loin).

1.4 Plan du cours (feuille de route)

1. Processus de Poisson : modéliser *l'arrivée* des sauts.
2. Poisson composé / Poisson marqué : modéliser *la taille* des sauts.
3. Modèle de Merton : une diffusion + un Poisson marqué multiplicatif.
4. Itô avec sauts : la bonne formule de calcul différentiel.
5. Mesure risque-neutre : dérive ajustée pour compenser les sauts.
6. Pricing : PIDE et formule semi-fermée de Merton.
7. Ouverture : Heston (volatilité stochastique) et Bates (Heston + sauts).

1.5 Processus de Poisson : le chronomètre des sauts

1.5.1 Définition

Définition 1.1 (Processus de Poisson). Un processus $(N_t)_{t \geq 0}$ est un *processus de Poisson* d'intensité $\lambda > 0$ si :

1. $N_0 = 0$;
2. (N_t) a des incréments indépendants et stationnaires;
3. pour tout $t \geq 0$, $N_t \sim \text{Poisson}(\lambda t)$.

On interprète N_t comme le nombre d'événements (sauts) sur l'intervalle $[0, t]$.

1.5.2 Propriétés essentielles (pour la finance)

Proposition 1.1 (Moments). *Pour tout $t \geq 0$:*

$$\mathbb{E}[N_t] = \lambda t, \quad \text{Var}(N_t) = \lambda t.$$

Proposition 1.2 (Approximation à court terme). *Quand $\Delta t \rightarrow 0$:*

$$\mathbb{P}(N_{t+\Delta t} - N_t = 1) = \lambda \Delta t + o(\Delta t), \quad \mathbb{P}(N_{t+\Delta t} - N_t \geq 2) = o(\Delta t).$$

Remarque 1.1 (Lecture « probabiliste »). Sur un horizon très court, on observe (presque) jamais deux sauts : le modèle est cohérent avec des « chocs ponctuels ».

1.5.3 Temps inter-arrivée : exponentielle

On note T_1 le temps du premier saut :

$$T_1 := \inf\{t \geq 0 : N_t = 1\}.$$

Proposition 1.3. *On a $T_1 \sim \text{Exp}(\lambda)$ et, plus généralement, les temps inter-arrivée $(T_k - T_{k-1})$ sont i.i.d. exponentiels de paramètre λ .*

Remarque 1.2 (Mémoire nulle). La loi exponentielle est sans mémoire : c'est un modèle minimaliste (et souvent pertinent) pour des « arrivées » d'événements.

1.5.4 Processus compensé : martingale

On définit

$$M_t := N_t - \lambda t.$$

Proposition 1.4. *(M_t) est une martingale (adaptée à $(\mathcal{F}_t)$ si N l'est).*

Remarque 1.3 (Pourquoi c'est important ?). Les martingales sont les objets naturels de l'absence d'arbitrage. Dans les modèles à sauts, on passe très souvent de N_t à sa version compensée $N_t - \lambda t$ pour isoler un terme de drift.

1.6 Poisson marqué et Poisson composé : la taille des sauts

1.6.1 Marks : définir la taille du k -ième saut

Le processus de Poisson décrit *quand* un saut arrive. On ajoute une suite i.i.d. $(Y_k)_{k \geq 1}$, indépendante de N , où Y_k est la **taille** du k -ième saut.

Définition 1.2 (Poisson composé). On définit le processus de sauts cumulés

$$J_t := \sum_{k=1}^{N_t} Y_k,$$

avec la convention $\sum_{k=1}^0 (\cdot) = 0$. On dit que (J_t) est un *processus de Poisson composé*.

1.6.2 Transformée exponentielle (outil de base)

Proposition 1.5 (MGF/CF d'un Poisson composé). *Si $\mathbb{E}[e^{uY_1}] < \infty$, alors*

$$\mathbb{E}[e^{uJ_t}] = \exp\left(\lambda t (\mathbb{E}[e^{uY_1}] - 1)\right).$$

En prenant $u = iv$, on obtient la fonction caractéristique.

Preuve (très instructive). Conditionnons par $N_t = n$:

$$\mathbb{E}[e^{uJ_t} \mid N_t = n] = \mathbb{E}\left[e^{u \sum_{k=1}^n Y_k}\right] = \left(\mathbb{E}[e^{uY_1}]\right)^n$$

par indépendance. Puis

$$\mathbb{E}[e^{uJ_t}] = \sum_{n=0}^{\infty} \mathbb{P}(N_t = n) \left(\mathbb{E}[e^{uY_1}]\right)^n = \sum_{n=0}^{\infty} e^{-\lambda t} \frac{(\lambda t)^n}{n!} \left(\mathbb{E}[e^{uY_1}]\right)^n.$$

Reconnaître la série de l'exponentielle donne le résultat. $\square$

1.6.3 Choix standard : sauts lognormaux (Merton)

Pour maintenir $S_t > 0$, un choix naturel est de modéliser des sauts **multiplicatifs** :

$$S_t = S_{t-} e^{Y_k} \quad \text{au temps du } k\text{-ième saut.}$$

Dans Merton (1976), on prend

$$Y_k \sim \mathcal{N}(\mu_J, \delta^2).$$

On introduit aussi la moyenne relative du saut :

$$\kappa := \mathbb{E}[e^{Y_1} - 1] = e^{\mu_J + \frac{1}{2}\delta^2} - 1.$$

Remarque 1.4 (Interprétation). Si $\mu_J < 0$ et δ modéré, on modélise des sauts en moyenne négatifs (crash risk), ce qui a un impact fort sur les prix des puts OTM.

1.7 Le modèle de Merton : diffusion + sauts multiplicatifs

1.7.1 Heuristique à partir d'un pas de temps Δt

Sur un intervalle court Δt :

- Avec probabilité $1 - \lambda\Delta t$, pas de saut : $\Delta S/S$ est de taille $\sigma\sqrt{\Delta t}$.
- Avec probabilité $\lambda\Delta t$, un saut : S est multiplié par e^Y .

Quand $\Delta t \rightarrow 0$, ces « sauts rares » convergent vers un processus de Poisson.

1.7.2 Dynamique sous la mesure historique $\mathbb{P}$

On introduit :

- un brownien $(W_t)_{t \geq 0}$;
- un Poisson $(N_t)_{t \geq 0}$ d'intensité λ ;
- des marks $(Y_k)_{k \geq 1}$ i.i.d. (indépendants de W et N).

Le modèle (multiplicatif) s'écrit :

$$\boxed{\frac{dS_t}{S_{t-}} = \mu dt + \sigma dW_t + (e^Y - 1) dN_t.} \quad (1.1)$$

Ici, quand $dN_t = 1$ (un saut), on a $S_t = S_{t-} e^Y$.

Remarque 1.5 (Notation S_{t-}). En présence de sauts, S_t est càdlàg : la valeur juste avant le saut est S_{t-} , et la valeur juste après est S_t .

1.7.3 Log-prix : forme additive

Posons $X_t := \ln S_t$. On montrera plus loin (Itô avec sauts) que :

$$\boxed{dX_t = \left(\mu - \frac{1}{2}\sigma^2\right) dt + \sigma dW_t + Y dN_t.} \quad (1.2)$$

Cette forme est très utile : le log-prix est la somme d'une diffusion (gaussienne) et d'un Poisson composé.

1.8 Résolution explicite et distribution de S_T

1.8.1 Solution explicite (forme produit)

Entre deux sauts, (1.1) est un GBM. Au temps de saut, S est multiplié par e^Y . On obtient :

$$S_t = S_0 \exp\left(\left(\mu - \frac{1}{2}\sigma^2\right)t + \sigma W_t\right) \prod_{k=1}^{N_t} e^{Y_k}. \quad (1.3)$$

Comme $\prod_{k=1}^{N_t} e^{Y_k} = \exp(\sum_{k=1}^{N_t} Y_k)$, on a :

$$X_t := \ln S_t = \ln S_0 + \left(\mu - \frac{1}{2}\sigma^2\right)t + \sigma W_t + \sum_{k=1}^{N_t} Y_k. \quad (1.4)$$

1.8.2 Distribution conditionnelle (mélange de normales)

Conditionnellement à $N_t = n$, on a :

$$\sum_{k=1}^{N_t} Y_k = \sum_{k=1}^n Y_k.$$

Si $Y_k \sim \mathcal{N}(\mu_J, \delta^2)$, alors $\sum_{k=1}^n Y_k \sim \mathcal{N}(n\mu_J, n\delta^2)$. Comme $\sigma W_t \sim \mathcal{N}(0, \sigma^2 t)$, on obtient :

$$X_t \mid (N_t = n) \sim \mathcal{N}\left(\ln S_0 + \left(\mu - \frac{1}{2}\sigma^2\right)t + n\mu_J, \sigma^2 t + n\delta^2\right).$$

Remarque 1.6 (Queues lourdes : intuition). Inconditionnellement, X_t est un **mélange** gaussien (mélange Poisson sur n). Les mélanges gaussiens ont typiquement des queues plus épaisses qu'une gaussienne unique : c'est un mécanisme simple de « fat tails ».

1.8.3 Un calcul utile : espérance de S_t sous $\mathbb{P}$

En utilisant (1.3) et l'indépendance :

$$\mathbb{E}[S_t] = S_0 \mathbb{E}\left[\exp\left(\left(\mu - \frac{1}{2}\sigma^2\right)t + \sigma W_t\right)\right] \mathbb{E}\left[\prod_{k=1}^{N_t} e^{Y_k}\right].$$

Le premier terme vaut $S_0 e^{\mu t}$ (car $\mathbb{E}[e^{\sigma W_t - \frac{1}{2}\sigma^2 t}] = 1$). Pour le second, conditionner par N_t donne :

$$\mathbb{E}\left[\prod_{k=1}^{N_t} e^{Y_k}\right] = \mathbb{E}\left[e^{\sum_{k=1}^{N_t} Y_k}\right] = \exp(\lambda t (\mathbb{E}[e^{Y_1}] - 1)) = e^{\lambda t \kappa}.$$

Donc

$$\mathbb{E}[S_t] = S_0 e^{(\mu + \lambda \kappa)t}.$$

Ce calcul anticipe l'ajustement de dérive sous $\mathbb{Q}$: sous la mesure risque-neutre, on veut $\mathbb{E}^{\mathbb{Q}}[S_t] = S_0 e^{rt}$.

1.9 Calcul stochastique avec sauts : formule d'Itô (finie activité)

1.9.1 Deux règles à ne pas confondre

Pour un brownien, le calcul d'Itô dit « $(dW_t)^2 = dt$ ». Avec des sauts, une trajectoire peut bouger *d'un coup* : la bonne règle est de traiter les sauts **exactement**, pas via un développement limité.

1.9.2 Itô avec sauts (forme utile pour Merton)

On considère

$$dS_t = \mu S_{t-} dt + \sigma S_{t-} dW_t + S_{t-}(e^Y - 1) dN_t.$$

Théorème 1.1 (Itô avec sauts (cas Poisson, marks i.i.d.)). Soit $f = f(t, s)$ de classe $C^{1,2}$. Alors

$$\begin{aligned} df(t, S_t) = & \partial_t f(t, S_{t-}) dt + \partial_s f(t, S_{t-}) dS_t + \frac{1}{2} \partial_{ss} f(t, S_{t-}) \sigma^2 S_{t-}^2 dt \\ & + \left(f(t, S_{t-} e^Y) - f(t, S_{t-}) - \partial_s f(t, S_{t-}) S_{t-} (e^Y - 1) \right) dN_t. \end{aligned} \quad (1.5)$$

Remarque 1.7 (Lecture). Le terme entre parenthèses est le *reste* qui transforme l'approximation linéaire $f_s \Delta S$ en *variation exacte* $f(S_t) - f(S_{t-})$ lors d'un saut.

1.9.3 Application : dynamique du log-prix

Prenons $f(s) = \ln s$. On a $f_s = 1/s$ et $f_{ss} = -1/s^2$. La formule (1.5) donne :

$$d(\ln S_t) = \frac{1}{S_{t-}} dS_t - \frac{1}{2} \sigma^2 dt + \left(\ln(S_{t-} e^Y) - \ln(S_{t-}) - \frac{1}{S_{t-}} S_{t-} (e^Y - 1) \right) dN_t.$$

Or $\ln(S_{t-} e^Y) - \ln(S_{t-}) = Y$, donc le terme de saut vaut $(Y - (e^Y - 1)) dN_t$. Comme $\frac{1}{S_{t-}} dS_t$ contient $+(e^Y - 1) dN_t$, les deux s'annulent et on obtient :

$$d(\ln S_t) = \left(\mu - \frac{1}{2} \sigma^2 \right) dt + \sigma dW_t + Y dN_t,$$

c'est-à-dire (1.2).

1.10 Mesure risque-neutre : ajustement de dérive et incomplétude

1.10.1 Condition de martingale du prix actualisé

Sous une mesure risque-neutre $\mathbb{Q}$, l'absence d'arbitrage impose (au minimum) :

$$\tilde{S}_t := e^{-rt} S_t \quad \text{est une martingale sous } \mathbb{Q}.$$

En particulier,

$$\mathbb{E}^{\mathbb{Q}}[S_T | \mathcal{F}_t] = S_t e^{r(T-t)}.$$

1.10.2 Dérive et sauts : condition à l'ordre dt

Sous une mesure $\mathbb{Q}$, on écrit généralement :

$$\frac{dS_t}{S_{t-}} = \mu^{\mathbb{Q}} dt + \sigma dW_t^{\mathbb{Q}} + (e^Y - 1) dN_t^{\mathbb{Q}},$$

où l'intensité et la loi de Y peuvent changer sous $\mathbb{Q}$.

Méthode. On veut que $\tilde{S}_t = e^{-rt} S_t$ soit une martingale. Pour cela, le terme de *tendance moyenne* (ordre dt) de $\tilde{S}$ doit être nul. Avec des sauts, la tendance moyenne vient à la fois de la dérive $\mu^{\mathbb{Q}}$ et de l'espérance des sauts (fréquence $\times$ taille moyenne).

Dérivation (pas à pas).

Étape 1: Actualiser. Comme e^{-rt} est continu, il n'y a pas de saut sur le facteur d'actualisation, et

$$d(e^{-rt} S_t) = e^{-rt} dS_t - r e^{-rt} S_{t-} dt.$$

Étape 2: Regrouper les termes d'ordre dt . En divisant par $e^{-rt} S_{t-}$:

$$\frac{d(e^{-rt} S_t)}{e^{-rt} S_{t-}} = (\mu^{\mathbb{Q}} - r) dt + \sigma dW_t^{\mathbb{Q}} + (e^Y - 1) dN_t^{\mathbb{Q}}.$$

Étape 3: Prendre l'espérance à l'ordre dt . Sur un petit pas, $\Delta W = \mathcal{O}(\sqrt{\Delta t})$ et $\mathbb{E}[\Delta W] = 0$. De plus, $\mathbb{P}(\Delta N = 1) \approx \lambda^{\mathbb{Q}} \Delta t$ et, conditionnellement à un saut, le retour relatif est $e^Y - 1$.

Étape 4: Conclusion. Le drift moyen du terme de saut est donc $\lambda^{\mathbb{Q}} \mathbb{E}^{\mathbb{Q}}[e^Y - 1] dt = \lambda^{\mathbb{Q}} \kappa^{\mathbb{Q}} dt$, et la condition « drift nul du prix actualisé » impose $\mu^{\mathbb{Q}} + \lambda^{\mathbb{Q}} \kappa^{\mathbb{Q}} = r$.

Piège classique. Le terme $\kappa^{\mathbb{Q}} = \mathbb{E}^{\mathbb{Q}}[e^Y - 1]$ est une espérance en *espace prix* (sauts multiplicatifs). Si l'on paramètre plutôt des sauts additifs sur le log ($\Delta \log S = Y$), il faut se souvenir que le saut sur S vaut $e^Y - 1$: oublier l'exponentielle est une erreur fréquente.

Sur une fenêtre Δt ,

$$\mathbb{E}^{\mathbb{Q}} \left[\frac{\Delta S_t}{S_{t-}} \mid \mathcal{F}_{t-} \right] \approx \mu^{\mathbb{Q}} \Delta t + \lambda^{\mathbb{Q}} \kappa^{\mathbb{Q}} \Delta t, \quad \kappa^{\mathbb{Q}} := \mathbb{E}^{\mathbb{Q}}[e^Y - 1].$$

Pour que le taux de croissance moyen soit r , il faut donc

$$\mu^{\mathbb{Q}} + \lambda^{\mathbb{Q}} \kappa^{\mathbb{Q}} = r.$$

Sanity check.

- Si $\lambda^{\mathbb{Q}} = 0$ (pas de sauts), on retrouve $\mu^{\mathbb{Q}} = r$: c'est exactement Black–Scholes.
- Si les sauts sont « en moyenne nuls » en espace prix ($\kappa^{\mathbb{Q}} = 0$), alors la dérive risque-neutre est encore $\mu^{\mathbb{Q}} = r$: les sauts ajoutent du risque, mais pas de tendance moyenne.

1.10.3 Choix « Merton » (simple)

Un choix fréquent pour démarrer (et obtenir des formules fermées) est :

$$\lambda^{\mathbb{Q}} = \lambda, \quad Y^{\mathbb{Q}} \stackrel{d}{=} Y.$$

Alors $\kappa^{\mathbb{Q}} = \kappa$ et

$$\frac{dS_t}{S_{t-}} = (r - \lambda \kappa) dt + \sigma dW_t^{\mathbb{Q}} + (e^Y - 1) dN_t. \quad (1.6)$$

Remarque 1.8 (Incomplétude = plusieurs mesures $\mathbb{Q}$). Avec des sauts, le marché est (généralement) incomplet : l'absence d'arbitrage seule ne fixe pas la mesure $\mathbb{Q}$. Deux approches courantes :

- **Choisir** une mesure $\mathbb{Q}$ par un principe (Esscher transform, minimal martingale measure, etc.).
- **Impliciter** la mesure via calibration aux options : « la $\mathbb{Q}$ est dans les prix ».

1.11 Générateur et PIDE de pricing

1.11.1 Principe : Feynman–Kac pour processus à sauts

Sous (1.6), le prix d'un payoff européen $g(S_T)$ vaut

$$V(t, s) = \mathbb{E}^{\mathbb{Q}} \left[e^{-r(T-t)} g(S_T) \mid S_t = s \right].$$

Lorsque S est Markov, V résout une équation aux dérivées partielles *avec un terme intégral* (PIDE).

1.11.2 Générateur infinitésimal

Pour une fonction test $\varphi \in C^2$, le générateur $\mathcal{L}$ associé à (1.6) est :

$$(\mathcal{L}\varphi)(s) = (r - \lambda \kappa) s \varphi'(s) + \frac{1}{2} \sigma^2 s^2 \varphi''(s) + \lambda \mathbb{E}[\varphi(se^Y) - \varphi(s)]. \quad (1.7)$$

Remarque 1.9 (Pourquoi ce terme?). Le terme $\lambda \mathbb{E}[\varphi(se^Y) - \varphi(s)]$ dit : à taux λ , on saute de s à se^Y , donc l'espérance de la variation instantanée de φ est celle-ci.

1.11.3 La PIDE

La forme standard est

$$\partial_t V(t, s) + (\mathcal{L}V)(t, s) - rV(t, s) = 0, \quad V(T, s) = g(s),$$

soit explicitement :

$$\partial_t V + (r - \lambda \kappa) s \partial_s V + \frac{1}{2} \sigma^2 s^2 \partial_{ss} V - rV + \lambda \mathbb{E}[V(t, se^Y) - V(t, s)] = 0. \quad (1.8)$$

1.11.4 Forme intégrale (densité du mark)

Si Y a une densité f_Y , alors

$$\mathbb{E}[V(t, se^Y) - V(t, s)] = \int_{\mathbb{R}} (V(t, se^y) - V(t, s)) f_Y(y) dy.$$

Remarque 1.10 (Retour à Black–Scholes). Si $\lambda = 0$ (pas de saut), (1.8) devient l'équation de Black–Scholes.

1.11.5 Conditions aux bords (vanilles)

Pour un call européen $g(s) = (s - K)^+$:

- à l'échéance : $V(T, s) = (s - K)^+$;
- pour $s \rightarrow 0$: $V(t, s) \rightarrow 0$ (call vaut presque 0) ;
- pour $s \rightarrow +\infty$: $V(t, s) \sim s - Ke^{-r(T-t)}$.

Ces conditions guident les schémas numériques (différences finies + quadrature).

1.12 Formule semi-fermée de Merton (call européen) : dérivation pas à pas

1.12.1 Setup

Soit un call européen de strike $K > 0$, maturité T , payoff $(S_T - K)^+$. On note $\tau := T - t$ et $S_t = s$. Sous (1.6),

$$\ln S_T = \ln s + \left(r - \lambda\kappa - \frac{1}{2}\sigma^2\right)\tau + \sigma\sqrt{\tau}Z + \sum_{k=1}^{N_\tau} Y_k,$$

avec $Z \sim \mathcal{N}(0, 1)$ et $N_\tau \sim \text{Poisson}(\lambda\tau)$.

1.12.2 Étape 1 : loi totale de l'espérance

Le prix est

$$C(t, s) = \mathbb{E}^{\mathbb{Q}}[e^{-r\tau}(S_T - K)^+ \mid S_t = s].$$

Conditionnons par N_τ :

$$C(t, s) = \sum_{n=0}^{\infty} \mathbb{P}(N_\tau = n) \mathbb{E}^{\mathbb{Q}}[e^{-r\tau}(S_T - K)^+ \mid S_t = s, N_\tau = n].$$

Or

$$\mathbb{P}(N_\tau = n) = e^{-\lambda\tau} \frac{(\lambda\tau)^n}{n!}.$$

1.12.3 Étape 2 : loi de $\ln S_T$ conditionnellement à $N_\tau = n$

Supposons $Y_k \sim \mathcal{N}(\mu_J, \delta^2)$. Alors, conditionnellement à $N_\tau = n$:

$$\sum_{k=1}^{N_\tau} Y_k \sim \mathcal{N}(n\mu_J, n\delta^2),$$

et comme Z est indépendant :

$$\ln S_T \mid (S_t = s, N_\tau = n) \sim \mathcal{N}(m_n, v_n),$$

avec

$$m_n := \ln s + \left(r - \lambda\kappa - \frac{1}{2}\sigma^2\right)\tau + n\mu_J, \quad v_n := \sigma^2\tau + n\delta^2.$$

1.12.4 Étape 3 : calcul du call quand $\ln S_T$ est normal

Soit $X \sim \mathcal{N}(m, v)$ et $S = e^X$. On calcule

$$\mathbb{E}[(S - K)^+] = \mathbb{E}[e^X \mathbf{1}_{X > \ln K}] - K \mathbb{P}(X > \ln K).$$

On standardise $X = m + \sqrt{v} Z$ avec $Z \sim \mathcal{N}(0, 1)$. On obtient le résultat classique :

$$\mathbb{E}[(e^X - K)^+] = e^{m + \frac{1}{2}v} \Phi(d_1) - K \Phi(d_2), \quad (1.9)$$

où

$$d_1 = \frac{m - \ln K + v}{\sqrt{v}}, \quad d_2 = d_1 - \sqrt{v} = \frac{m - \ln K}{\sqrt{v}}.$$

Remarque 1.11 (Interprétation). La quantité $e^{m + \frac{1}{2}v} = \mathbb{E}[e^X] = \mathbb{E}[S]$ joue le rôle d'un « forward » lognormal : (1.9) est une forme de formule de Black sur un sous-jacent lognormal.

1.12.5 Étape 4 : assembler les morceaux

On en déduit, pour chaque n :

$$C_n(t, s) := \mathbb{E}^\mathbb{Q}[e^{-r\tau} (S_T - K)^+ \mid S_t = s, N_\tau = n] = e^{-r\tau} \left(e^{m_n + \frac{1}{2}v_n} \Phi(d_{1,n}) - K \Phi(d_{2,n}) \right),$$

avec

$$d_{1,n} = \frac{m_n - \ln K + v_n}{\sqrt{v_n}}, \quad d_{2,n} = \frac{m_n - \ln K}{\sqrt{v_n}}.$$

Finalement, la formule de Merton est :

$$C(t, s) = \sum_{n=0}^{\infty} e^{-\lambda\tau} \frac{(\lambda\tau)^n}{n!} e^{-r\tau} \left(e^{m_n + \frac{1}{2}v_n} \Phi(d_{1,n}) - K \Phi(d_{2,n}) \right). \quad (1.10)$$

1.12.6 Troncature de la série

En pratique, on tronque à $n_{\max}$:

$$C(t, s) \approx \sum_{n=0}^{n_{\max}} e^{-\lambda\tau} \frac{(\lambda\tau)^n}{n!} C_n(t, s).$$

Une règle simple est de prendre $n_{\max}$ tel que la masse de Poisson au-delà soit négligeable, par exemple $n_{\max} \approx \lambda\tau + 10\sqrt{\lambda\tau}$.

1.12.7 Put et parité

La parité call-put reste vraie :

$$C(t, s) - P(t, s) = s - K e^{-r\tau},$$

car elle découle d'un argument d'arbitrage statique et ne dépend pas du modèle de dynamique.

1.13 Fonction caractéristique et pricing par Fourier (complément)

1.13.1 Pourquoi la fonction caractéristique est utile

La formule de Merton (1.10) est spécifique au cas lognormal pour les sauts. Dès qu'on change la loi de Y (double-exponentielle, etc.), la série fermée peut disparaître, mais la fonction caractéristique de $X_T = \ln S_T$ reste souvent simple. On peut alors pricer des options par transformée de Fourier.

1.13.2 Calcul pas à pas de la fonction caractéristique de X_T

Sous (1.6),

$$X_T = \ln s + \left(r - \lambda\kappa - \frac{1}{2}\sigma^2\right)\tau + \sigma\sqrt{\tau}Z + \sum_{k=1}^{N_\tau} Y_k.$$

Soit $u \in \mathbb{R}$. Par indépendance :

$$\begin{aligned}\varphi_{X_T}(u) &:= \mathbb{E}^{\mathbb{Q}}[e^{iuX_T} \mid S_t = s] \\ &= e^{iu \ln s} e^{iu(r - \lambda\kappa - \frac{1}{2}\sigma^2)\tau} \mathbb{E}[e^{iu\sigma\sqrt{\tau}Z}] \mathbb{E}\left[e^{iu \sum_{k=1}^{N_\tau} Y_k}\right].\end{aligned}$$

Or

$$\mathbb{E}[e^{iu\sigma\sqrt{\tau}Z}] = \exp\left(-\frac{1}{2}u^2\sigma^2\tau\right),$$

et, par la formule du Poisson composé :

$$\mathbb{E}\left[e^{iu \sum_{k=1}^{N_\tau} Y_k}\right] = \exp(\lambda\tau(\varphi_Y(u) - 1)), \quad \varphi_Y(u) := \mathbb{E}[e^{iuY_1}].$$

Donc

$$\boxed{\varphi_{X_T}(u) = \exp\left(iu \ln s + iu(r - \lambda\kappa - \frac{1}{2}\sigma^2)\tau - \frac{1}{2}u^2\sigma^2\tau + \lambda\tau(\varphi_Y(u) - 1)\right).} \quad (1.11)$$

1.13.3 Cas gaussien (Merton) : expression fermée

Si $Y \sim \mathcal{N}(\mu_J, \delta^2)$, alors

$$\varphi_Y(u) = \exp\left(iu\mu_J - \frac{1}{2}u^2\delta^2\right).$$

En injectant dans (1.11) on obtient une expression explicite (très pratique en FFT).

1.13.4 Idée de Carr–Madan (sans détails techniques)

La transformée de Fourier d'un call amorti $e^{\alpha k}C(k)$ (avec $k = \ln K$) s'exprime en fonction de φ_{X_T} . En pratique :

- on choisit un *damping* $\alpha > 0$;
- on calcule une intégrale numérique sur $v \in [0, \infty)$;
- on récupère $C(K)$ par inversion.

Le même schéma sera central dans Heston.

1.14 Simulation Monte Carlo (Merton)

1.14.1 Cas européen : simulation directe de S_T (exacte)

Pour pricer un payoff qui dépend uniquement de S_T , on peut simuler directement S_T sans discrétiser le temps. Sous (1.6) :

$$X_T = \ln S_T = \ln s + \left(r - \lambda\kappa - \frac{1}{2}\sigma^2\right)\tau + \sigma\sqrt{\tau}Z + \sum_{k=1}^{N_\tau} Y_k.$$

Algorithme (une trajectoire) :

1. Simuler $N \sim \text{Poisson}(\lambda\tau)$.
2. Simuler $Z \sim \mathcal{N}(0, 1)$.
3. Simuler $Y_1, \dots, Y_N$ i.i.d. (ex. gaussien) et poser $Y_\Sigma = \sum_{k=1}^N Y_k$ (si $N = 0$, $Y_\Sigma = 0$).
4. Poser $\ln S_T = \ln s + (r - \lambda\kappa - \frac{1}{2}\sigma^2)\tau + \sigma\sqrt{\tau}Z + Y_\Sigma$.

Puis

$$C(t, s) \approx \frac{1}{M} \sum_{m=1}^M e^{-r\tau} (S_T^{(m)} - K)^+.$$

1.14.2 Produits à dépendance de chemin

Pour un produit path-dependent (barrière, lookback, asiatique), il faut simuler une trajectoire. Une approche exacte consiste à :

- simuler les temps de saut sur $[t, T]$ via des exponentielles ;
- entre deux sauts, simuler un GBM (donc exact) ;
- au temps du saut, multiplier S par e^Y .

Remarque 1.12 (Attention : barrières et sauts). Avec des sauts, une barrière peut être franchie instantanément (sans « toucher »). Les corrections de type Brownian bridge ne suffisent pas : il faut traiter explicitement les sauts.

1.15 Calibrage et interprétation des paramètres

1.15.1 Paramètres du modèle de Merton

Dans la version simple (1.6), les paramètres principaux sont :

$$(\sigma, \lambda, \mu_J, \delta, r).$$

En pratique, r est issu de la courbe de taux (ou supposé constant sur une courte maturité), et l'on calibre $(\sigma, \lambda, \mu_J, \delta)$ sur une surface de volatilité implicite.

1.15.2 Effets qualitatifs

- σ : dispersion « diffusive » (largeur de la partie centrale).
- λ : fréquence des chocs ; augmente la probabilité de rendements extrêmes.
- μ_J : asymétrie (sauts moyens négatifs $\Rightarrow$ skew).
- δ : étalement des tailles de saut (convexité du smile).

1.15.3 Observation empirique importante

Les sauts ont un impact particulièrement fort sur les smiles à courte maturité : sur un horizon τ petit, la diffusion est d'ordre $\sqrt{\tau}$, tandis qu'un saut (s'il arrive) est d'ordre 1. Même si la probabilité de saut est $\approx \lambda\tau$, son effet sur les queues peut dominer.

1.16 Hedging et incomplétude

1.16.1 Pourquoi la couverture parfaite disparaît

Dans Black-Scholes, une option européenne est répliquable par un portefeuille dynamique (delta hedging) car les variations sont continues. Avec des sauts, une variation discontinue de S génère une variation du payoff qui ne peut pas être compensée instantanément par un ajustement de delta : il reste un **risque résiduel de saut**.

1.16.2 Conséquences pratiques

- Couvertures **approx.** : minimisation de variance, couverture delta+vega avec options additionnelles, etc.
- Non-unicité de $\mathbb{Q}$: les prix d'options dépendent de la prime de risque de saut (choix de $\lambda^{\mathbb{Q}}$ et de la loi sous $\mathbb{Q}$).

1.17 Ouverture : volatilité stochastique et modèle de Heston

1.17.1 Pourquoi la volatilité stochastique ?

Les sauts capturent très bien :

- des rendements extrêmes ;
- un smile court terme marqué ;
- une asymétrie via $\mu_J < 0$.

Mais ils n'expliquent pas toujours (ou pas seuls) :

- le **clustering** de volatilité (phases longues de vol haute) ;
- la **dynamique temporelle** de la surface de vol (term structure) ;
- l'**effet de levier** (corrélation négative rendement/variation de vol).

L'idée : rendre la variance instantanée elle-même aléatoire.

1.17.2 Le modèle de Heston (sous $\mathbb{Q}$)

Sous la mesure risque-neutre :

$$\begin{cases} dS_t = rS_t dt + \sqrt{v_t} S_t dW_t^{(1)}, \\ dv_t = \kappa(\theta - v_t) dt + \xi \sqrt{v_t} dW_t^{(2)}, \\ dW_t^{(1)} dW_t^{(2)} = \rho dt, \end{cases} \quad (1.12)$$

avec $v_0 > 0$, $\kappa > 0$, $\theta > 0$, $\xi > 0$, $|\rho| \leq 1$.

1.17.3 Lecture des paramètres

- θ : niveau de long terme (moyenne) de la variance.
- κ : vitesse de retour à la moyenne.
- ξ : *vol de vol* (amplitude des fluctuations de v_t).
- ρ : corrélation entre choc de prix et choc de variance (souvent $\rho < 0$ sur equity).

1.17.4 Le processus de variance : un CIR (positivité)

La dynamique

$$dv_t = \kappa(\theta - v_t)dt + \xi \sqrt{v_t} dW_t^{(2)}$$

est un processus de Cox–Ingersoll–Ross. Il est choisi car :

- v_t reste en général non négatif (variance!) ;
- il est mean-reverting : v_t est attiré vers θ à vitesse κ .

Une condition classique (Feller) garantissant que v_t ne touche pas 0 est

$$2\kappa\theta \geq \xi^2.$$

1.17.5 Calcul simple : moyenne de la variance

En prenant l'espérance dans l'équation de v_t :

$$\frac{d}{dt} \mathbb{E}[v_t] = \kappa(\theta - \mathbb{E}[v_t]),$$

donc

$$\mathbb{E}[v_t] = \theta + (v_0 - \theta)e^{-\kappa t}.$$

Ce résultat explique la **term structure** naturelle dans Heston : à court terme, v_t est proche de v_0 ; à long terme, il converge vers θ .

1.17.6 Pourquoi Heston génère un smile ?

Posons $X_t = \ln S_t$. Par Itô continu appliqué à (1.12) :

$$dX_t = \left(r - \frac{1}{2}v_t\right) dt + \sqrt{v_t} dW_t^{(1)}.$$

Donc, conditionnellement à la trajectoire de v , X_T est gaussien avec variance $\int_t^T v_s ds$. Mais **inconditionnellement**, $\int_t^T v_s ds$ est aléatoire : on obtient un mélange de gaussiennes, ce qui produit un smile. La corrélation ρ crée une asymétrie (skew) : si un choc négatif sur S est corrélé à une hausse de v , les puts deviennent plus chers.

1.17.7 Pricing : même philosophie que Merton (fonction caractéristique)

Comme pour Merton, une voie efficace est la Fourier-pricing. Le couple (X_t, v_t) est un processus **affine** : on peut calculer

$$\varphi_T(u) := \mathbb{E}^{\mathbb{Q}}[e^{iuX_T} \mid X_t = x, v_t = v]$$

sous la forme

$$\varphi_T(u) = \exp(C(\tau; u) + D(\tau; u)v + iux), \quad \tau := T - t,$$

où C et D satisfont des EDO (de type Riccati).

1.17.8 Dérivation détaillée : ansatz affine et Riccati

On explicite proprement la chaîne « Markov $\rightarrow$ PDE $\rightarrow$ ansatz $\rightarrow$ Riccati ». L'objectif est de voir à quel endroit apparaît la structure *affine*.

1) Transformer en un problème conditionnel. On travaille avec $X_t = \ln S_t$ et on définit, pour $u \in \mathbb{R}$,

$$p(t, x, v; u) := \mathbb{E}^{\mathbb{Q}}[e^{iuX_T} \mid X_t = x, v_t = v].$$

On a alors $\varphi_T(u) = p(0, \ln S_0, v_0; u)$.

2) Écrire le générateur. Sous $\mathbb{Q}$, le couple (X_t, v_t) suit

$$dX_t = \left(r - \frac{1}{2}v_t\right)dt + \sqrt{v_t}dW_t^{(1)}, \quad dv_t = \kappa(\theta - v_t)dt + \xi\sqrt{v_t}dW_t^{(2)}, \quad \text{Corr}(dW^{(1)}, dW^{(2)}) = \rho.$$

Le générateur $\mathcal{L}^{\text{Heston}}$ agit sur une fonction lisse $f(t, x, v)$ par

$$(\mathcal{L}^{\text{Heston}}f)(t, x, v) = \left(r - \frac{1}{2}v\right)\partial_x f + \kappa(\theta - v)\partial_v f + \frac{1}{2}v\partial_{xx}f + \rho\xi v\partial_{xv}f + \frac{1}{2}\xi^2 v\partial_{vv}f.$$

3) PDE de Feynman–Kac. Comme (X, v) est markovien, p satisfait la PDE rétrograde

$$\partial_t p + \mathcal{L}^{\text{Heston}}p = 0, \quad p(T, x, v; u) = e^{iux}.$$

4) Ansatz exponentiel-affine. On pose $\tau := T - t$ et on cherche une solution de la forme

$$p(t, x, v; u) = \exp(C(\tau; u) + D(\tau; u)v + iux), \quad C(0; u) = 0, \quad D(0; u) = 0.$$

On calcule :

$$\partial_x p = iu p, \quad \partial_{xx} p = -(u^2)p, \quad \partial_v p = Dp, \quad \partial_{vv} p = D^2 p, \quad \partial_{xv} p = iu Dp,$$

et $\partial_t p = -(C'(\tau; u) + D'(\tau; u)v)p$. En injectant dans la PDE et en divisant par p , on obtient une identité affine en v . L'annulation séparée des termes constants et des termes en v donne :

$$C'(\tau; u) = iur + \kappa\theta D(\tau; u), \tag{1.13}$$

$$D'(\tau; u) = -\frac{1}{2}(u^2 + iu) + (\rho\xi iu - \kappa)D(\tau; u) + \frac{1}{2}\xi^2 D(\tau; u)^2. \tag{1.14}$$

La seconde est une équation de Riccati ; la première s'intègre ensuite par quadrature. Une fois C et D connus, on a la formule fermée

$$\varphi_T(u) = \exp(C(T; u) + D(T; u)v_0 + iu \ln S_0),$$

puis le prix des vanilles par inversion de Fourier (Carr–Madan, Lewis, etc.).

1.17.9 Lien naturel : Bates = Heston + sauts

Un modèle très utilisé pour mieux coller à la fois :

- aux smiles **très courts** (sauts) ;
- à la **dynamique** de surface (variance stochastique) ;

est le modèle de Bates : on prend Heston pour v_t et on ajoute des sauts multiplicatifs à la Merton sur S_t . Techniquement, on conserve une fonction caractéristique explicite : celle de Heston est multipliée par le facteur exponentiel du Poisson composé (comme (1.11)).

1.18 Annexe A : résumé des formules essentielles (Merton)

Dynamique (sous $\mathbb{P}$)

$$\frac{dS_t}{S_{t-}} = \mu dt + \sigma dW_t + (e^Y - 1) dN_t, \quad Y \sim \mathcal{N}(\mu_J, \delta^2), \quad N_t \sim \text{Poisson}(\lambda t).$$

$$d(\ln S_t) = \left(\mu - \frac{1}{2}\sigma^2\right) dt + \sigma dW_t + Y dN_t.$$

Ajustement risque-neutre (choix Merton)

$$\mu^{\mathbb{Q}} = r - \lambda\kappa, \quad \kappa = \mathbb{E}[e^Y - 1] = e^{\mu_J + \frac{1}{2}\delta^2} - 1.$$

$$\frac{dS_t}{S_{t-}} = (r - \lambda\kappa) dt + \sigma dW_t^{\mathbb{Q}} + (e^Y - 1) dN_t.$$

Générateur et PIDE

$$(\mathcal{L}\varphi)(s) = (r - \lambda\kappa)s\varphi'(s) + \frac{1}{2}\sigma^2 s^2 \varphi''(s) + \lambda \mathbb{E}[\varphi(se^Y) - \varphi(s)].$$

$$\partial_t V + \mathcal{L}V - rV = 0, \quad V(T, s) = g(s).$$

Call européen (série de Merton)

Avec $\tau = T - t$:

$$C(t, s) = \sum_{n=0}^{\infty} e^{-\lambda\tau} \frac{(\lambda\tau)^n}{n!} e^{-r\tau} \left(e^{m_n + \frac{1}{2}v_n} \Phi(d_{1,n}) - K \Phi(d_{2,n}) \right),$$

où

$$m_n = \ln s + \left(r - \lambda\kappa - \frac{1}{2}\sigma^2\right)\tau + n\mu_J, \quad v_n = \sigma^2\tau + n\delta^2,$$

$$d_{1,n} = \frac{m_n - \ln K + v_n}{\sqrt{v_n}}, \quad d_{2,n} = \frac{m_n - \ln K}{\sqrt{v_n}}.$$

Fonction caractéristique de $X_T = \ln S_T$

$$\varphi_{X_T}(u) = \exp\left(iu \ln s + iu(r - \lambda\kappa - \frac{1}{2}\sigma^2)\tau - \frac{1}{2}u^2\sigma^2\tau + \lambda\tau(\varphi_Y(u) - 1)\right), \quad \varphi_Y(u) = \mathbb{E}[e^{iuY}].$$

1.19 Annexe B : preuve de la formule

On prouve ici la formule (1.9).

Soit $X \sim \mathcal{N}(m, v)$ et $S = e^X$. Posons $k = \ln K$. On part de

$$\mathbb{E}[(S - K)^+] = \mathbb{E}[e^X \mathbf{1}_{X > k}] - K \mathbb{P}(X > k).$$

Écrivons $X = m + \sqrt{v} Z$ avec $Z \sim \mathcal{N}(0, 1)$.

Deuxième terme

$$\mathbb{P}(X > k) = \mathbb{P}\left(Z > \frac{k - m}{\sqrt{v}}\right) = \Phi\left(\frac{m - k}{\sqrt{v}}\right).$$

On reconnaît $d_2 = (m - k)/\sqrt{v}$.

Premier terme

On calcule

$$\mathbb{E}[e^X \mathbf{1}_{X > k}] = e^m \mathbb{E}\left[e^{\sqrt{v}Z} \mathbf{1}_{Z > \frac{k-m}{\sqrt{v}}}\right].$$

On utilise la densité $\phi(z) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2}$:

$$\mathbb{E}[e^{\sqrt{v}Z} \mathbf{1}_{Z>a}] = \int_a^\infty e^{\sqrt{v}z} \phi(z) dz = \int_a^\infty \frac{1}{\sqrt{2\pi}} \exp\left(\sqrt{v}z - \frac{z^2}{2}\right) dz.$$

On complète le carré :

$$\sqrt{v}z - \frac{z^2}{2} = -\frac{1}{2}(z^2 - 2\sqrt{v}z) = -\frac{1}{2}(z - \sqrt{v})^2 + \frac{1}{2}v.$$

Donc

$$\mathbb{E}[e^{\sqrt{v}Z} \mathbf{1}_{Z>a}] = e^{v/2} \int_a^\infty \frac{1}{\sqrt{2\pi}} e^{-(z-\sqrt{v})^2/2} dz = e^{v/2} \Phi(\sqrt{v} - a).$$

En prenant $a = (k - m)/\sqrt{v}$, on obtient

$$\sqrt{v} - a = \frac{m - k + v}{\sqrt{v}} = d_1.$$

Donc

$$\mathbb{E}[e^X \mathbf{1}_{X>k}] = e^{m+v/2} \Phi(d_1).$$

Conclusion

$$\mathbb{E}[(e^X - K)^+] = e^{m+v/2} \Phi(d_1) - K \Phi(d_2).$$

1.20 Annexe C : notation « mesure de sauts » (optionnel)

Pour rendre la notation pleinement rigoureuse, on peut représenter les sauts via une mesure aléatoire de Poisson $\mu(dt, dy)$, telle que

$$\int_0^t \int_{\mathbb{R}} g(y) \mu(ds, dy) = \sum_{k=1}^{N_t} g(Y_k).$$

Son compensateur est $\nu(dt, dy) = \lambda f_Y(y) dy dt$ (si Y a une densité f_Y). On définit la mesure compensée $\tilde{\mu} = \mu - \nu$. Dans cette notation, le terme de saut du modèle est

$$\int_{\mathbb{R}} (e^y - 1) \mu(dt, dy) = \int_{\mathbb{R}} (e^y - 1) \tilde{\mu}(dt, dy) + \lambda \kappa dt,$$

ce qui rend transparent l'apparition de $\kappa = \mathbb{E}[e^Y - 1]$ dans la dérive risque-neutre.

1.21 Mode microscope : Itô avec sauts, PIDE et formule de Merton

1.21.1 Modèle de Merton (écriture claire)

On écrit (sous $\mathbb{Q}$) un modèle multiplicatif :

$$\frac{dS_t}{S_{t-}} = (r - q - \lambda \kappa) dt + \sigma dW_t + (J - 1) dN_t,$$

où N_t est un Poisson d'intensité λ , J est le facteur multiplicatif de jump (i.i.d.), et

$$\kappa = \mathbb{E}[J - 1]$$

assure que le drift est bien ajusté (martingale actualisée).

Interprétation. Le terme $-\lambda \kappa$ retire l'espérance de gain due aux jumps, afin que l'espérance sous $\mathbb{Q}$ reste compatible avec $r - q$.

Sanity check. Si $\lambda = 0$ (pas de sauts), on retrouve le GBM et Black-Scholes.

1.21.2 Conditionnement sur le nombre de sauts : mélange lognormal

Supposons $J = e^Y$ avec $Y \sim \mathcal{N}(\mu_J, \sigma_J^2)$. Conditionnellement à $N_T = n$, on a

$$\ln S_T = \ln S_0 + (r - q - \lambda\kappa - \tfrac{1}{2}\sigma^2)T + \sigma W_T + \sum_{i=1}^n Y_i,$$

donc

$$\ln S_T \mid (N_T = n) \sim \mathcal{N}(m_n, v_n), \quad m_n = \ln S_0 + (r - q - \lambda\kappa - \tfrac{1}{2}\sigma^2)T + n\mu_J, \quad v_n = \sigma^2 T + n\sigma_J^2.$$

Comme $N_T \sim \text{Pois}(\lambda T)$, on obtient un mélange :

$$\mathbb{Q}(N_T = n) = p_n := e^{-\lambda T} \frac{(\lambda T)^n}{n!}.$$

Le prix d'un call $C_0 = e^{-rT} \mathbb{E}^\mathbb{Q}[(S_T - K)^+]$ s'écrit alors

$$C_0 = \sum_{n=0}^{\infty} p_n C^{(n)}, \quad C^{(n)} = e^{-rT} \left(e^{m_n + v_n/2} N(d_1^{(n)}) - K N(d_2^{(n)}) \right), \quad (1.15)$$

avec

$$d_1^{(n)} = \frac{m_n - \ln K + v_n}{\sqrt{v_n}}, \quad d_2^{(n)} = d_1^{(n)} - \sqrt{v_n}.$$

Exemple jouet. Exemple jouet : si σ_J est grand, même un petit λ augmente fortement le prix des options OTM (queues plus épaisses).

1.21.3 PIDE de pricing (forme type)

Pour $V(t, S)$ (option européenne), l'équation de pricing prend la forme

$$\partial_t V + (r - q - \lambda\kappa) S \partial_S V + \tfrac{1}{2} \sigma^2 S^2 \partial_{SS} V - rV + \lambda \mathbb{E}[V(t, SJ) - V(t, S)] = 0, \quad V(T, S) = \Phi(S).$$

Le dernier terme est *l'apport des sauts* : une espérance d'un décalage multiplicatif $S \mapsto SJ$.

Intuition de marché. Avec sauts, le marché est incomplet : une seule action ne suffit pas à couvrir un risque de jump. Le prix dépend donc d'hypothèses de mesure (choix de $\mathbb{Q}$) et/ou d'inputs de marché (smile).

1.22 Pièges classiques / erreurs fréquentes

- Oublier le drift compensé $-\lambda\kappa$: on casse la martingale actualisée.
- Confondre distribution conditionnelle (lognormale) et mélange (non lognormal).
- Traiter un modèle à sauts comme complet : la couverture delta ne suffit pas.

1.23 Checklist — savoir refaire sans regarder

- Écrire le modèle de Merton et expliquer le rôle de λ, κ .
- Conditionner sur N_T et obtenir un mélange de lois normales pour $\ln S_T$.
- Écrire la PIDE de pricing et interpréter le terme intégral.
- Proposer une troncature et des sanity-checks numériques.

Chapitre 2

Heston : volatilité stochastique

Idee centrale. Heston est le standard de volatilité stochastique : variance mean-reverting + corrélation (leverage) $\rho \Rightarrow$ smile/skew, avec pricing efficace via fonction caractéristique (affine).

Cadre mathématique.

- **SDE sous $\mathbb{Q}$.** $dS_t/S_t = (r-q)dt + \sqrt{v_t}dW_t^{(1)}$, $dv_t = \kappa(\theta - v_t)dt + \xi\sqrt{v_t}dW_t^{(2)}$, $\text{corr}(dW^{(1)}, dW^{(2)}) = \rho$.
- **Positivité.** Condition de Feller (suffisante) : $2\kappa\theta \geq \xi^2$.
- **Pricing.** Fonction caractéristique exponentielle-affine $\Rightarrow$ inversion de Fourier / Carr–Madan.

Intuition marché / interprétation. Le skew (souvent $\rho < 0$ en equity) reflète l’asymétrie « baisse $\Rightarrow$ vol monte ». La calibration est un compromis : smile court terme, stabilité numérique (branches/log complexe), et robustesse out-of-sample.

Implémentation.

- Implémenter pricing via CF + intégration (quadrature) ou FFT ; calibrer sur surface IV (pondérations, régularisation).
- Simulation : schémas préservant $v_t \geq 0$ (QE, full truncation) ; attention au biais de discrétisation.

Tests / sanity checks.

- Limites : $\xi \rightarrow 0$ ou $v_t \equiv \theta \Rightarrow$ Black–Scholes (check).
- CF : $\varphi(0) = 1$ et stabilité vs choix de branche (diagnostic).
- Positivité : vérifier numériquement $v_t \geq 0$ en simulation (sinon schéma).

Pont vers pratique quant. Pont quant : calibration de smiles equity/FX, pricing rapide de vanilles (CF/FFT), greeks sous smile, et brique pour modèles plus riches (jumps+SV, rough).

2.1 Avant-propos : volatilité stochastique et modèle de Heston

Le smile/skew observé en marché suggère que la volatilité n’est pas constante. Une façon naturelle de l’enrichir est de rendre la variance *aléatoire* et mean-reverting. Le modèle de Heston est le standard : il est suffisamment riche pour générer un skew, et suffisamment structuré pour rester calculable (fonction caractéristique exponentielle-affine).

2.1.1 Objectifs pédagogiques

- Écrire clairement le modèle sous $\mathbb{Q}$ et interpréter les paramètres $(\kappa, \theta, \sigma, \rho, v_0)$.
- Comprendre pourquoi l’Itô en dimension 2 conduit à une PDE en (S, v) (avec terme croisé via ρ).
- Dériver la fonction caractéristique : ansatz affine $\Rightarrow$ EDO de Riccati $\Rightarrow$ formules fermées $(C(\tau; u), D(\tau; u))$.
- Passer de la fonction caractéristique au prix : inversion de Fourier (formules P_1/P_2), et préparer Carr–Madan/FFT.
- Ajouter des sanity checks (limite Black–Scholes, $\varphi(0) = 1$, choix de branche/log complexe).

2.1.2 Pré-requis

- Black–Scholes et Itô multidimensionnel.
- Outils Fourier de base : fonction caractéristique, inversion.

- Un minimum d'algèbre linéaire (pour lire les covariations et le terme croisé).

2.1.3 Plan (et transition vers le calcul Fourier)

1. Rappels : numéraire, mesure $\mathbb{Q}$, et pourquoi les fonctions caractéristiques sont utiles.
2. Modèle de Heston : dynamique et interprétations.
3. Fonction caractéristique : ansatz affine et Riccati (détails).
4. Pricing : inversion 1D (P_1, P_2) et points numériques.

Intuition de marché. Heston est un modèle « langage » : même si l'on ne croit pas au processus exact, ses paramètres ont une lecture économique (niveau de variance, vitesse de rappel, vol-of-vol, levier). En calibration, on le juge autant sur le smile que sur la stabilité numérique (log complexe).

Résumé

Ces notes construisent, pas à pas, le **pricing d'une option européenne** dans le **modèle de volatilité stochastique de Heston**, et montrent comment la **méthode de Carr–Madan** (transformée de Fourier + FFT) permet de transformer la connaissance d'une **fonction caractéristique** en une formule de prix (et en un algorithme rapide sur une grille de strikes).

L'objectif est pédagogique : chaque étape est motivée, les hypothèses sont explicites, et les manipulations (PDE de Feynman–Kac, ansatz affine, équation de Riccati, inversion de Fourier, « damping ») sont détaillées de façon à pouvoir être **ré-expliquées à l'oral**.

2.2 Objectifs, prérequis, conventions

2.2.1 Ce que l'on veut obtenir

On cherche une **formule (semi-)analytique** pour le prix au temps 0 d'une option call européenne :

$$C_0(K, T) = e^{-rT} \mathbb{E}_{\mathbb{Q}}[(S_T - K)^+],$$

dans un modèle où la volatilité instantanée est **stochastique** (modèle de Heston).

Deux routes complémentaires seront développées :

- **Formule de Heston** : une représentation en intégrales (1 dimension) faisant intervenir la fonction caractéristique du log-prix.
- **Carr–Madan** : une représentation de type transformée de Fourier du prix en fonction du log-strike, qui mène naturellement à un schéma FFT.

2.2.2 Niveau requis (rappels rapides)

On suppose connus :

- calcul d'Itô, SDEs usuelles, corrélation brownienne ;
- absence d'arbitrage, mesure risque-neutre, numéraire (au moins au niveau « cours ») ;
- transformée de Fourier et fonctions caractéristiques.

Les points utilisés seront rappelés au fil de l'eau.

2.2.3 Conventions

- Horizon : $t \in [0, T]$.
- Taux sans risque constant $r \in \mathbb{R}$ et **pas de dividendes** dans la dérivation principale. (Une remarque indique la modification en présence d'un taux de dividende continu q .)
- Variables de log : $X_t := \ln S_t$ et log-strike $k := \ln K$.
- La fonction caractéristique de X_T est

$$\varphi_T(u) := \mathbb{E}_{\mathbb{Q}}[e^{iuX_T}], \quad u \in \mathbb{C}.$$

2.3 Rappels de finance mathématique : numéraire et changement de mesure

2.3.1 Le cadre minimal

On travaille sur un espace probabilisé filtré $(\Omega, \mathcal{F}, (\mathcal{F}_t)_{t \in [0, T]}, \mathbb{P})$ satisfaisant les conditions usuelles. On considère :

- un compte monétaire $B_t = e^{rt}$ (taux sans risque constant r) ;
- un actif risqué S_t (ici, une action ou un indice).

Remarque 2.1 (Pourquoi parler de numéraire ?). Le choix du numéraire fixe « l'unité de compte ». C'est lui qui dicte la mesure sous laquelle les prix actualisés sont des martingales. Dans ce cours, on utilisera surtout deux numéraires :

- B (compte monétaire) $\Rightarrow$ mesure risque-neutre $\mathbb{Q}$;
- S (action) $\Rightarrow$ mesure action $\mathbb{Q}^S$.

2.3.2 Portefeuilles auto-finançants et absence d'arbitrage (idée)

Un portefeuille composé de Δ_t actions et β_t unités du compte monétaire a pour valeur

$$V_t = \Delta_t S_t + \beta_t B_t.$$

Il est **auto-finçant** si ses variations proviennent uniquement des variations des sous-jacents (pas d'injection/retrait de cash).

Le théorème fondamental de l'absence d'arbitrage (dans sa version diffusion) dit, schématiquement :

Pas d'arbitrage $\iff$ existence d'une mesure $\mathbb{Q}$ équivalente à $\mathbb{P}$ telle que les prix actualisés (par B) soient des martingales.

Dans ce cours, on se place directement sous $\mathbb{Q}$.

2.3.3 Théorème du numéraire (version praticien)

Théorème 2.1 (Changement de numéraire (énoncé utilisable)). Soit $N_t > 0$ un numéraire (processus strictement positif). Il existe une mesure $\mathbb{Q}^N$ telle que, pour tout actif A_t , le ratio A_t/N_t soit une $\mathbb{Q}^N$ -martingale (sous des hypothèses techniques standard). En particulier, le prix au temps 0 d'une payoff H_T s'écrit

$$V_0 = N_0 \mathbb{E}_{\mathbb{Q}^N} \left[\frac{H_T}{N_T} \right].$$

Remarque 2.2. Pour $N = B$, on retrouve le pricing risque-neutre $V_0 = e^{-rT} \mathbb{E}_{\mathbb{Q}}[H_T]$. Pour $N = S$, on obtient une formule où l'espérance porte sur $\mathbb{Q}^S$: c'est exactement l'astuce derrière la décomposition $C = S_0 P_1 - K e^{-rT} P_2$.

2.3.4 Girsanov (intuition) et paramètres sous $\mathbb{Q}$

Sous la mesure historique $\mathbb{P}$, la drift d'un actif contient une prime de risque. Le théorème de Girsanov décrit comment un changement de mesure transforme les drifts :

- les **diffusions** (coefficients devant les dW) restent inchangées ;
- les **drifts** changent en fonction de la densité de Radon–Nikodym (la « prime de risque »).

Exemple 2.1 (Rappel Black–Scholes). Sous $\mathbb{P}$, $dS_t = \mu S_t dt + \sigma S_t dW_t^{\mathbb{P}}$. Sous $\mathbb{Q}$, $dS_t = r S_t dt + \sigma S_t dW_t^{\mathbb{Q}}$. On a remplacé μ par r .

Remarque 2.3 (Prime de risque de volatilité). Dans Heston, la dynamique de v_t peut aussi changer entre $\mathbb{P}$ et $\mathbb{Q}$ (prime de risque de variance/volatilité). Cela se traduit typiquement par un paramètre de rappel κ et/ou une moyenne long-terme θ « risque-neutres », notés parfois κ^*, θ^* . Pour alléger les notations, on suppose que (2.10) est déjà donnée sous $\mathbb{Q}$.

2.4 Cadre de pricing et rôle des fonctions caractéristiques

2.4.1 Pricing risque-neutre (rappel)

Définition 2.1 (Mesure risque-neutre). On dit que $\mathbb{Q}$ est une mesure risque-neutre (pour un actif S et un compte monétaire $B_t = e^{rt}$) si le **prix actualisé** $\tilde{S}_t := e^{-rt} S_t$ est une $\mathbb{Q}$ -martingale (sous des hypothèses techniques usuelles).

Dans ce cadre, pour une payoff européenne $H(S_T)$ intégrable :

$$V_0 = e^{-rT} \mathbb{E}_{\mathbb{Q}}[H(S_T)].$$

2.4.2 Pourquoi les fonctions caractéristiques apparaissent

L'objet central du pricing européen est la loi de S_T (ou de $X_T = \ln S_T$). Deux idées structurent tout le cours :

1. La payoff d'un call s'écrit naturellement en fonction de X_T via $(e^{X_T} - K)^+$.
2. Si l'on sait calculer $\varphi_T(u) = \mathbb{E}[e^{iuX_T}]$, alors (via **inversion de Fourier**) on peut reconstituer des probabilités, des densités, et donc des prix.

2.4.3 Décomposition « Heston » : $C = S_0 P_1 - K e^{-rT} P_2$

Écrivons le call sous la forme

$$(S_T - K)^+ = S_T \mathbf{1}_{\{S_T > K\}} - K \mathbf{1}_{\{S_T > K\}} = e^{X_T} \mathbf{1}_{\{X_T > k\}} - e^k \mathbf{1}_{\{X_T > k\}}.$$

On obtient

$$C_0(K, T) = e^{-rT} \mathbb{E}_{\mathbb{Q}}[e^{X_T} \mathbf{1}_{\{X_T > k\}}] - K e^{-rT} \mathbb{Q}(X_T > k). \quad (2.1)$$

Le second terme est déjà une **probabilité de queue** :

$$P_2 := \mathbb{Q}(X_T > k).$$

Le premier terme devient lui aussi une probabilité si l'on change de numéraire.

Définition 2.2 (Mesure action (« share measure »)). On définit la mesure $\mathbb{Q}^S$ associée au numéraire S_t par

$$\frac{d\mathbb{Q}^S}{d\mathbb{Q}} \Big|_{\mathcal{F}_T} := \frac{e^{-rT} S_T}{S_0} = \frac{e^{-rT} e^{X_T}}{S_0}.$$

Alors pour toute variable Y intégrable,

$$\mathbb{E}_{\mathbb{Q}}[e^{-rT} S_T Y] = S_0 \mathbb{E}_{\mathbb{Q}^S}[Y].$$

Avec $Y = \mathbf{1}_{\{X_T > k\}}$, la première espérance dans (2.1) vaut $S_0 \mathbb{Q}^S(X_T > k)$. En posant

$$P_1 := \mathbb{Q}^S(X_T > k),$$

on obtient la forme canonique

$$\boxed{C_0(K, T) = S_0 P_1 - K e^{-rT} P_2.} \quad (2.2)$$

Le problème est donc ramené à calculer deux probabilités de queue P_1 et P_2 .

2.5 Boîte à outils Fourier : fonctions caractéristiques et prolongement complexe

2.5.1 Transformée de Fourier : conventions

Pour une fonction $f : \mathbb{R} \rightarrow \mathbb{C}$ intégrable, on définit sa transformée de Fourier (convention « $+iux$ ») :

$$\hat{f}(u) := \int_{-\infty}^{+\infty} e^{iux} f(x) dx.$$

Sous des hypothèses standard (par exemple f intégrable et suffisamment régulière), l'inversion donne

$$f(x) = \frac{1}{2\pi} \int_{-\infty}^{+\infty} e^{-iux} \widehat{f}(u) du.$$

2.5.2 Fonction caractéristique et densité

Définition 2.3 (Fonction caractéristique). Pour une v.a. réelle X , on définit

$$\varphi_X(u) := \mathbb{E}[e^{iuX}], \quad u \in \mathbb{R}.$$

Remarque 2.4. Pour $u \in \mathbb{R}$, la fonction caractéristique existe *toujours* car $|e^{iuX}| = 1$. Les difficultés apparaissent seulement lorsque l'on veut évaluer φ en un **argument complexe** (ce que feront Heston via $u - i$, et Carr–Madan via $v - i(\alpha + 1)$).

Si X possède une densité f_X , alors φ_X est la transformée de Fourier de f_X :

$$\varphi_X(u) = \int_{\mathbb{R}} e^{iux} f_X(x) dx.$$

En particulier (hypothèses d'inversion), on peut reconstruire f_X à partir de φ_X .

2.5.3 Arguments complexes : lien avec la fonction génératrice des moments

Pour $z \in \mathbb{C}$, on peut considérer

$$M_X(z) := \mathbb{E}[e^{zX}]$$

lorsqu'elle existe (c'est la **fonction génératrice des moments**, ou mgf). On a alors la relation fondamentale

$$M_X(z) = \varphi_X(-iz), \quad \varphi_X(u) = M_X(iu),$$

tant que les quantités sont bien définies.

Remarque 2.5 (Ce que cela implique pour Heston/Carr–Madan). Dans la formule de Heston, apparaissent $\varphi_T(-i) = \mathbb{E}[e^{X_T}] = \mathbb{E}[S_T]$ et $\varphi_T(u - i) = \mathbb{E}[e^{(1+iu)X_T}]$: il faut donc l'existence d'un moment d'ordre 1 (ce qui est vrai sous une mesure risque-neutre bien posée) et, plus généralement, d'un petit voisinage analytique. Dans Carr–Madan, on évalue $\varphi_T(v - i(\alpha + 1)) = \mathbb{E}[e^{(\alpha+1+iv)X_T}]$: il faut donc $\mathbb{E}[S_T^{\alpha+1}] < \infty$.

2.5.4 Exemple : cas gaussien

Si $X \sim \mathcal{N}(m, s^2)$, alors

$$\varphi_X(u) = \exp\left(ium - \frac{1}{2}u^2s^2\right).$$

Le prolongement analytique en $u \in \mathbb{C}$ est immédiat car l'exponentielle est une fonction entière. C'est une manière simple de se rappeler que l'on peut (dans certains modèles) « plugger » des arguments complexes sans difficulté, à condition de contrôler l'intégrabilité.

2.5.5 Prix, probabilités, densités : trois objets reliés

Pour des payoffs vanilles, plusieurs identités relient prix, probabilités et densités. En particulier, pour un call européen et sous des hypothèses de régularité (Breedon–Litzenberger) :

$$\frac{\partial C_0(K, T)}{\partial K} = -e^{-rT} \mathbb{Q}(S_T > K), \quad \frac{\partial^2 C_0(K, T)}{\partial K^2} = e^{-rT} f_{S_T}(K).$$

Ces relations donnent un sens financier aux quantités de type $P_2 = \mathbb{Q}(S_T > K)$: ce sont des **digitals** (dérivées du prix par rapport au strike).

2.6 Outil clé : inversion de Fourier pour une probabilité de queue

Cette section donne une formule exploitable numériquement pour $\mathbb{Q}(X_T > k)$ à partir de φ_T .

2.6.1 Un fait d'analyse (version utile)

Lemme 2.1 (Représentation de l'indicatrice). *Pour tout $y \in \mathbb{R}$,*

$$\mathbf{1}_{\{y>0\}} = \frac{1}{2} + \frac{1}{\pi} \int_0^{+\infty} \frac{\sin(uy)}{u} du,$$

au sens des intégrales impropres.

Preuve détaillée. On démontre d'abord l'identité de Dirichlet

$$\int_0^{+\infty} \frac{\sin(uy)}{u} du = \frac{\pi}{2} \operatorname{sgn}(y), \quad y \neq 0, \quad (2.3)$$

au sens des intégrales impropres (limite en $R \rightarrow \infty$ de $\int_0^R$). On en déduit ensuite l'écriture de l'indicatrice.

1) Convergence de l'intégrale impropre. Fixons $y \neq 0$ et posons

$$I_R(y) := \int_0^R \frac{\sin(uy)}{u} du.$$

La fonction $g(u) = 1/u$ est décroissante et tend vers 0. Une primitive de $u \mapsto \sin(uy)$ est $F(u) = \int_0^u \sin(vy) dv = \frac{1 - \cos(uy)}{y}$, donc $\sup_{u \geq 0} |F(u)| \leq \frac{2}{|y|}$. Le test de Dirichlet donne alors que $(I_R(y))_{R \geq 0}$ converge quand $R \rightarrow \infty$. On peut aussi retenir le contrôle quantitatif (utile pour la suite) : pour tout $R > 0$,

$$\left| \int_R^{+\infty} \frac{\sin(uy)}{u} du \right| \leq \frac{2}{|y|} \cdot \frac{1}{R}. \quad (2.4)$$

2) Calcul de la valeur via un amortissement exponentiel. Pour $\varepsilon > 0$, considérons l'intégrale (absolument convergente)

$$I_\varepsilon(y) := \int_0^{+\infty} e^{-\varepsilon u} \frac{\sin(uy)}{u} du.$$

On veut la calculer explicitement, puis faire $\varepsilon \downarrow 0$. On peut dériver sous le signe intégral : en effet, pour tout $\varepsilon > 0$, la fonction $u \mapsto e^{-\varepsilon u} \cos(uy)$ est intégrable sur $[0, +\infty)$, donc (par convergence dominée) :

$$I'_\varepsilon(y) = \int_0^{+\infty} e^{-\varepsilon u} \cos(uy) du.$$

Or cette intégrale est un calcul standard (transformée de Laplace) :

$$\int_0^{+\infty} e^{-\varepsilon u} \cos(uy) du = \operatorname{Re} \int_0^{+\infty} e^{-(\varepsilon - iy)u} du = \operatorname{Re} \left(\frac{1}{\varepsilon - iy} \right) = \frac{\varepsilon}{\varepsilon^2 + y^2}.$$

Ainsi $I'_\varepsilon(y) = \frac{\varepsilon}{\varepsilon^2 + y^2}$, et en intégrant de 0 à y (avec $I_\varepsilon(0) = 0$ car $\sin(0) = 0$) :

$$I_\varepsilon(y) = \int_0^y \frac{\varepsilon}{\varepsilon^2 + z^2} dz = \arctan\left(\frac{y}{\varepsilon}\right).$$

En particulier, pour $y > 0$, $I_\varepsilon(y) \rightarrow \frac{\pi}{2}$ quand $\varepsilon \downarrow 0$, et pour $y < 0$, $I_\varepsilon(y) = -I_\varepsilon(-y) \rightarrow -\frac{\pi}{2}$. On a donc

$$\lim_{\varepsilon \downarrow 0} I_\varepsilon(y) = \frac{\pi}{2} \operatorname{sgn}(y), \quad y \neq 0. \quad (2.5)$$

3) Justifier que l'amortissement ne change pas la limite. Il reste à relier $I_\varepsilon(y)$ et l'intégrale impropre $I(y) := \lim_{R \rightarrow \infty} I_R(y)$. Fixons $R > 0$. Sur $[0, R]$, on a $\left| e^{-\varepsilon u} \frac{\sin(uy)}{u} \right| \leq \frac{1}{u}$ et $\frac{1}{u}$ est intégrable sur $[0, R]$, donc, par convergence dominée,

$$\lim_{\varepsilon \downarrow 0} \int_0^R e^{-\varepsilon u} \frac{\sin(uy)}{u} du = \int_0^R \frac{\sin(uy)}{u} du. \quad (2.6)$$

Pour la queue, on utilise (2.4) et le fait que $0 < e^{-\varepsilon u} \leq 1$: pour tout $\varepsilon \geq 0$,

$$\left| \int_R^{+\infty} e^{-\varepsilon u} \frac{\sin(uy)}{u} du \right| \leq \frac{2}{|y|} \cdot \frac{1}{R}.$$

En combinant (2.6) avec ce contrôle uniforme en ε , on peut faire $\varepsilon \downarrow 0$ puis $R \rightarrow \infty$ et conclure que

$$\lim_{\varepsilon \downarrow 0} I_\varepsilon(y) = \lim_{R \rightarrow \infty} I_R(y) = \int_0^{+\infty} \frac{\sin(uy)}{u} du.$$

Avec (2.5), on obtient bien (2.3).

4) Fin de la preuve de l'identité de l'indicatrice. Pour $y \neq 0$, en utilisant (2.3),

$$\frac{1}{2} + \frac{1}{\pi} \int_0^{+\infty} \frac{\sin(uy)}{u} du = \frac{1}{2} + \frac{1}{2} \operatorname{sgn}(y) = \begin{cases} 1, & y > 0, \\ 0, & y < 0. \end{cases}$$

C'est exactement $\mathbf{1}_{\{y>0\}}$ pour $y \neq 0$. Au point $y = 0$, l'intégrale vaut 0 (car l'intégrand est nul), et le membre de droite vaut $1/2$: ce décalage est normal, car la fonction $y \mapsto \mathbf{1}_{\{y>0\}}$ a une discontinuité en 0. Dans les applications (probabilités de queue), cet unique point n'a pas d'importance dès qu'on a une densité ou, plus généralement, dès que $\mathbb{Q}(X = k) = 0$. $\square$

Remarque 2.6. Cette identité est un avatar de l'inversion de Fourier de la fonction « marche » (Heaviside). Elle est à connaître : elle permet de transformer une **probabilité** en une **intégrale d'une fonction caractéristique**.

2.6.2 Conséquence pour une probabilité de queue

Soit X une v.a. réelle telle que sa fonction caractéristique $\varphi_X(u) = \mathbb{E}[e^{iuX}]$ existe. Alors

$$\mathbb{Q}(X > k) = \mathbb{E}[\mathbf{1}_{\{X-k>0\}}] = \frac{1}{2} + \frac{1}{\pi} \int_0^{+\infty} \mathbb{E}\left[\frac{\sin(u(X-k))}{u}\right] du.$$

En utilisant $\sin(z) = \operatorname{Im}(e^{iz})$ et en échangeant $\mathbb{E}$ et $\int$ (hypothèses d'intégrabilité), on obtient

$$\boxed{\mathbb{Q}(X > k) = \frac{1}{2} + \frac{1}{\pi} \int_0^{+\infty} \operatorname{Re}\left(\frac{e^{-iuk} \varphi_X(u)}{iu}\right) du.} \quad (2.7)$$

Remarque 2.7 (Forme « réelle » sans i). On peut réécrire l'intégrande sans division par i :

$$\operatorname{Re}\left(\frac{e^{-iuk} \varphi_X(u)}{iu}\right) = \frac{1}{u} \operatorname{Im}(e^{-iuk} \varphi_X(u)).$$

Cela rappelle que l'on intègre essentiellement une combinaison de sinus/cosinus, et aide parfois à déboguer une implémentation.

Remarque 2.8. La formule (2.7) est l'un des deux « cœurs » de la formule de Heston : elle convertit une probabilité de queue en intégrale sur la fonction caractéristique.

2.6.3 Application à P_2 et P_1

Dans notre cas, $X = X_T = \ln S_T$ sous $\mathbb{Q}$:

$$\boxed{P_2 = \mathbb{Q}(X_T > k) = \frac{1}{2} + \frac{1}{\pi} \int_0^{+\infty} \operatorname{Re}\left(\frac{e^{-iuk} \varphi_T(u)}{iu}\right) du.} \quad (2.8)$$

Pour $P_1 = \mathbb{Q}^S(X_T > k)$, on applique la même formule sous $\mathbb{Q}^S$, donc il faut la fonction caractéristique de X_T sous $\mathbb{Q}^S$.

Proposition 2.1 (Décalage complexe sous la mesure action). *Supposons $\mathbb{E}_{\mathbb{Q}}[e^{X_T}] < \infty$. Alors*

$$\varphi_T^S(u) := \mathbb{E}_{\mathbb{Q}^S}[e^{iuX_T}] = \frac{\varphi_T(u - i)}{\varphi_T(-i)}.$$

Démonstration. Par définition de $\mathbb{Q}^S$,

$$\varphi_T^S(u) = \mathbb{E}_{\mathbb{Q}} \left[e^{iuX_T} \frac{d\mathbb{Q}^S}{d\mathbb{Q}} \right] = \mathbb{E}_{\mathbb{Q}} \left[e^{iuX_T} \frac{e^{-rT} e^{X_T}}{S_0} \right] = \frac{e^{-rT}}{S_0} \mathbb{E}_{\mathbb{Q}} [e^{(1+iu)X_T}].$$

Or $e^{(1+iu)X_T} = e^{i(u-i)X_T}$, donc $\mathbb{E}_{\mathbb{Q}}[e^{(1+iu)X_T}] = \varphi_T(u - i)$. Enfin, $\varphi_T(-i) = \mathbb{E}_{\mathbb{Q}}[e^{X_T}] = \mathbb{E}_{\mathbb{Q}}[S_T] = S_0 e^{rT}$ (sans dividendes), donc $e^{-rT}/S_0 = 1/\varphi_T(-i)$. $\square$

Ainsi

$$P_1 = \frac{1}{2} + \frac{1}{\pi} \int_0^{+\infty} \operatorname{Re} \left(\frac{e^{-iuk} \varphi_T(u - i)}{iu \varphi_T(-i)} \right) du. \quad (2.9)$$

Remarque 2.9 (Présence d'un dividende continu). Si S verse un dividende continu q , alors $B_t = e^{rt}$ reste le compte monétaire mais la drift risque-neutre devient $(r - q)$. On a alors $\mathbb{E}_{\mathbb{Q}}[S_T] = S_0 e^{(r-q)T}$, et la normalisation dans (2.1) devient $\varphi_T(-i) = S_0 e^{(r-q)T}$.

2.7 Le modèle de Heston : volatilité stochastique (CIR)

2.7.1 La dynamique sous $\mathbb{Q}$

Le modèle de Heston postule que la variance instantanée v_t suit un processus de type **Cox–Ingersoll–Ross** (CIR), et que S_t est entraîné par $\sqrt{v_t}$:

$$\begin{cases} dS_t = rS_t dt + \sqrt{v_t} S_t dW_t^{(1)}, \\ dv_t = \kappa(\theta - v_t) dt + \sigma \sqrt{v_t} dW_t^{(2)}, \\ dW_t^{(1)} dW_t^{(2)} = \rho dt, \end{cases} \quad S_0 > 0, v_0 > 0, \quad (2.10)$$

avec paramètres $\kappa, \theta, \sigma > 0$ et $\rho \in [-1, 1]$.

2.7.2 Interprétation des paramètres (intuition finance)

- θ : **niveau long terme** de la variance.
- κ : **vitesse de rappel** vers θ .
- σ : **vol de vol** (amplitude des fluctuations de v_t).
- ρ : corrélation entre choc prix et choc variance ; typiquement $\rho < 0$ sur actions (effet de levier), ce qui génère un **skew** de volatilité implicite.
- v_0 : variance initiale (liée au niveau du smile à très courte maturité).

2.7.3 Pourquoi un modèle de volatilité stochastique ?

Le modèle de Black–Scholes suppose une volatilité constante : cela implique une distribution log-normale de S_T et donc une volatilité implicite **plate** en fonction du strike. Empiriquement, on observe au contraire :

- un **smile** ou **skew** (volatilité implicite dépendant de K) ;
- une dynamique de surface de volatilité (la vol implicite bouge au cours du temps, et pas seulement via S_t) ;
- une asymétrie (queues plus lourdes à la baisse sur actions).

L'intuition est qu'une volatilité aléatoire et corrélée aux retours est un mécanisme minimal pour capturer ces effets, tout en restant relativement tractable.

2.7.4 Propriétés du processus CIR (moyenne, stationnarité, loi marginale)

Le processus de variance

$$dv_t = \kappa(\theta - v_t)dt + \sigma \sqrt{v_t} dW_t^{(2)}$$

est un CIR. Quelques faits utiles :

— **Rappel vers la moyenne** :

$$\mathbb{E}_{\mathbb{Q}}[v_t] = \theta + (v_0 - \theta)e^{-\kappa t}.$$

— **Variance intégrée (au sens espérance)** :

$$\mathbb{E}_{\mathbb{Q}} \left[\int_0^T v_t dt \right] = \theta T + (v_0 - \theta) \frac{1 - e^{-\kappa T}}{\kappa}.$$

— **Stationnarité** : quand $t \rightarrow \infty$, la loi de v_t converge (sous conditions) vers une loi Gamma de moyenne θ .

— **Loi marginale explicite** : v_t suit une loi χ^2 non centrale (utile pour des schémas de simulation exacts).

Remarque 2.10 (Volatilité instantanée vs variance). Dans la pratique, on appelle souvent « volatilité » $\sqrt{v_t}$. Le choix de modéliser v_t (plutôt que $\sqrt{v_t}$) est motivé par (i) la positivité, (ii) l’affinité, (iii) des propriétés de moments plus simples.

2.7.5 Positivité de v_t et condition de Feller

Le processus CIR est non négatif. Une condition classique garantissant que v_t ne touche pas 0 est la **condition de Feller** :

$$2\kappa\theta \geq \sigma^2.$$

Remarque 2.11. Même si la condition de Feller n’est pas satisfaite, on a encore $v_t \geq 0$ (au sens fort) mais la frontière 0 peut devenir atteignable. Numériquement, cela peut influencer sur certains schémas de simulation, pas sur l’existence de la fonction caractéristique.

2.7.6 Passage au log-prix

Posons $X_t = \ln S_t$. Par Itô appliqué à $\ln(\cdot)$:

$$dX_t = \left(r - \frac{1}{2}v_t \right) dt + \sqrt{v_t} dW_t^{(1)}. \quad (2.11)$$

Le couple (X_t, v_t) est un **processus affine** : c’est cette structure qui rend $\varphi_T(u)$ calculable explicitement.

2.8 La PDE de Heston pour le pricing (contexte)

Avant de calculer φ_T , il est utile de voir le « problème PDE » auquel Heston répond.

2.8.1 Le prix comme fonction $(t, S, v) \mapsto V(t, S, v)$

Pour une payoff européenne $H(S_T)$, on définit pour $t \leq T$:

$$V(t, S, v) := e^{-r(T-t)} \mathbb{E}_{\mathbb{Q}}[H(S_T) \mid S_t = S, v_t = v].$$

Le triplet (t, S_t, v_t) est Markovien ; ainsi, $V(t, S_t, v_t)$ est bien un processus adapté, et l’on peut appliquer Feynman–Kac.

2.8.2 Générateur en variables (S, v)

Le générateur du couple (S_t, v_t) (sous (2.10)) est

$$\mathcal{A}f = rS \partial_S f + \kappa(\theta - v) \partial_v f + \frac{1}{2}vS^2 \partial_{SS} f + \rho\sigma vS \partial_{Sv} f + \frac{1}{2}\sigma^2 v \partial_{vv} f,$$

où $f = f(S, v)$.

2.8.3 PDE de Heston

La fonction V résout la PDE (rétrograde) :

$$\partial_t V + \mathcal{A}V - rV = 0, \quad V(T, S, v) = H(S). \quad (2.12)$$

Pour un call, $H(S) = (S - K)^+$.

Remarque 2.12 (Pourquoi n'obtient-on pas une formule simple en résolvant (2.12) ?). La PDE (2.12) est **bidimensionnelle** (variables S et v) et contient un terme croisé ∂_{Sv} dû à la corrélation ρ . On peut la résoudre numériquement (différences finies, éléments finis), mais obtenir une formule fermée en général est difficile. L'approche « Heston » contourne ce problème en :

- calculant d'abord une transformée (la fonction caractéristique) où l'exponentielle transforme la PDE en **EDO** ;
- puis en revenant au prix via une inversion de Fourier.

2.8.4 Pourquoi passer au log et aux transformées

Le passage au log-prix $X = \ln S$ linéarise les termes en S dans le générateur et rend naturelle l'étude d'objets de type $\mathbb{E}[e^{iuX_T}]$. Cette observation est au cœur des méthodes Fourier (Heston, Lewis, Carr–Madan) : les exponentielles diagonalisent les opérateurs différentiels.

2.9 Étape 1 : fonction caractéristique de X_T sous Heston

2.9.1 Stratégie

On veut $\varphi_T(u) = \mathbb{E}_{\mathbb{Q}}[e^{iuX_T}]$. Plutôt que de chercher directement la loi de X_T , on calcule la **transformée** :

$$p(t, x, v; u) := \mathbb{E}_{\mathbb{Q}}[e^{iuX_T} \mid X_t = x, v_t = v].$$

Alors $\varphi_T(u) = p(0, \ln S_0, v_0; u)$.

2.9.2 Générateur et PDE de Feynman–Kac

Le générateur infinitésimal du couple (X_t, v_t) (dédit de (2.10)–(2.11)) est, pour une fonction régulière f ,

$$\mathcal{L}f = \left(r - \frac{v}{2}\right) \partial_x f + \kappa(\theta - v) \partial_v f + \frac{1}{2}v \partial_{xx} f + \rho\sigma v \partial_{xv} f + \frac{1}{2}\sigma^2 v \partial_{vv} f. \quad (2.13)$$

Par Feynman–Kac, p satisfait la PDE rétrograde :

$$\partial_t p + \mathcal{L}p = 0, \quad p(T, x, v; u) = e^{iux}. \quad (2.14)$$

2.9.3 Ansatz affine

On exploite l'affinité en proposant une solution exponentielle-affine en v :

$$p(t, x, v; u) = \exp\left(C(\tau; u) + D(\tau; u)v + iux\right), \quad \tau := T - t, \quad (2.15)$$

avec conditions $C(0; u) = 0$ et $D(0; u) = 0$ pour respecter $p(T, x, v; u) = e^{iux}$.

2.9.4 Pourquoi un ansatz exponentiel-affine ? (intuition « affine »)

L'idée est la suivante :

- Le générateur $\mathcal{L}$ de (2.13) dépend de v de façon **affine** (linéaire en v) : les termes de diffusion sont proportionnels à v et la drift de v contient $-\kappa v$.
- Si l'on teste une fonction de la forme $\exp(A + Bv + iux)$, alors ses dérivées $\partial_x, \partial_v, \partial_{xx}, \partial_{xv}, \partial_{vv}$ redonnent la même exponentielle multipliée par un polynôme (au plus) **quadratique en B** et **affine en v** .
- La PDE doit être vraie pour *tout* $v \geq 0$: on obtient donc une égalité « polynôme en v » = 0, ce qui force séparément le terme constant et le coefficient de v à s'annuler.

C'est exactement le mécanisme général des **modèles affines** : le log de la transformée (ici $\ln p$) est affine en l'état.

2.9.5 Calcul des dérivées

À partir de (2.15) :

$$\begin{aligned}\partial_t p &= -(C' + D'v)p, & \partial_x p &= iup, & \partial_{xx} p &= -u^2 p, \\ \partial_v p &= Dp, & \partial_{vv} p &= D^2 p, & \partial_{xv} p &= iuDp,\end{aligned}$$

où les dérivées C', D' sont par rapport à τ .

2.9.6 Identification : un système d'EDO (dont une Riccati)

On injecte dans (2.14), on divise par $p \neq 0$ et on identifie les termes constants et ceux en v . On obtient :

$$C'(\tau; u) = iur + \kappa\theta D(\tau; u), \quad C(0; u) = 0, \quad (2.16)$$

$$D'(\tau; u) = \frac{1}{2}\sigma^2 D(\tau; u)^2 + (\rho\sigma iu - \kappa)D(\tau; u) - \frac{1}{2}(u^2 + iu), \quad D(0; u) = 0. \quad (2.17)$$

L'équation (2.17) est une **équation de Riccati**. Toute la « magie » de Heston est que cette Riccati se résout explicitement.

2.9.7 Lecture de l'EDO : d'où viennent les termes ?

Il est utile de savoir « lire » (2.17) :

- le terme $-\frac{1}{2}(u^2 + iu)$ vient des dérivées en x : la diffusion $\frac{1}{2}v\partial_{xx}$ fournit $-\frac{1}{2}vu^2$, et la drift $-\frac{1}{2}v$ dans (2.11) fournit $-\frac{1}{2}v(iu)$;
- le terme $(\rho\sigma iu - \kappa)D$ vient du couplage entre x et v (corrélation ρ) et du rappel $-\kappa v$;
- le terme $\frac{1}{2}\sigma^2 D^2$ provient de la diffusion de v_t via $\frac{1}{2}\sigma^2 v\partial_{vv}$.

Retenir cette décomposition aide à re-dériver la formule sans la « réciter ».

2.9.8 Résolution de la Riccati : formules fermées

On pose (notations standard)

$$b(u) := \kappa - \rho\sigma iu, \quad d(u) := \sqrt{b(u)^2 + \sigma^2(u^2 + iu)}, \quad \operatorname{Re}(d(u)) > 0,$$

et

$$g(u) := \frac{b(u) - d(u)}{b(u) + d(u)}.$$

Proposition 2.2 (Solution explicite). *La solution de (2.16)–(2.17) est donnée par*

$$D(\tau; u) = \frac{b(u) - d(u)}{\sigma^2} \frac{1 - e^{-d(u)\tau}}{1 - g(u)e^{-d(u)\tau}}, \quad (2.18)$$

$$C(\tau; u) = iur\tau + \frac{\kappa\theta}{\sigma^2} \left[(b(u) - d(u))\tau - 2 \ln \left(\frac{1 - g(u)e^{-d(u)\tau}}{1 - g(u)} \right) \right]. \quad (2.19)$$

Remarque 2.13 (Choix de la branche de la racine et stabilité numérique). La racine carrée complexe $d(u)$ impose un choix de branche. Le choix usuel est celui satisfaisant $\operatorname{Re}(d(u)) > 0$. En implémentation, certains jeux de paramètres peuvent entraîner des discontinuités dans le logarithme complexe. Une recette classique (souvent appelée « Little Heston Trap ») consiste à réécrire les expressions en termes de $1/g(u)$ pour stabiliser le terme logarithmique. Ces détails ne changent pas la dérivation, mais comptent en pratique.

Piège classique. Le problème n'est pas mathématique mais *numérique* : la fonction $\log(\cdot)$ complexe est multivaluée. Si l'argument traverse une coupure de branche lorsque u varie sur la grille d'intégration, la partie réelle de $C(\tau; u)$ peut sauter, ce qui détruit l'intégration (oscillations, prix négatifs, etc.).

Méthode. Recette simple et robuste : (i) imposer $\operatorname{Re}(d(u)) > 0$, (ii) calculer le terme logarithmique dans C sous une forme stable, par exemple

$$\log\left(\frac{1 - ge^{-d\tau}}{1 - g}\right) = \log\left(\frac{g^{-1} - e^{-d\tau}}{g^{-1} - 1}\right),$$

et (iii) vérifier systématiquement les sanity checks $\varphi_T(0) = 1$ et la continuité de $u \mapsto \varphi_T(u)$ sur la grille.

2.9.9 Fonction caractéristique finale

On déduit immédiatement :

$$\varphi_T(u) = \exp\left(C(T; u) + D(T; u) v_0 + iu \ln S_0\right). \quad (2.20)$$

Sanity check.

- **Normalisation.** En posant $u = 0$, on doit obtenir $\varphi_T(0) = \mathbb{E}[e^0] = 1$.
- **Module.** Pour $u \in \mathbb{R}$, $|\varphi_T(u)| \leq 1$ (propriété générale des fonctions caractéristiques) : si votre code donne des valeurs avec un module qui explose, il y a un problème de branche/log.
- **Moment à $u = -i$.** Si l'on évalue (quand c'est numériquement stable) $\varphi_T(-i) = \mathbb{E}[e^{X_T}] = \mathbb{E}[S_T]$, on doit retrouver $S_0 e^{rT}$ sous $\mathbb{Q}$ (condition de martingale du sous-jacent).

Exemple 2.2 (Vérification : limite Black–Scholes). Si $\sigma = 0$ (pas de vol de vol) et $v_t \equiv v_0$ constant, alors X_T est gaussien et on retombe sur Black–Scholes avec volatilité $\sqrt{v_0}$. La formule (2.20) se réduit alors à la fonction caractéristique d'une normale de moyenne $\ln S_0 + (r - \frac{1}{2}v_0)T$ et variance $v_0 T$.

2.10 Étape 2 : formule de Heston pour un call européen

On combine :

- la décomposition (2.2) ;
- les formules de probabilité (2.9)–(2.8) ;
- la fonction caractéristique (2.20).

2.10.1 Formule finale (version « P_1, P_2 »)

En notant $k = \ln K$, on obtient

$$C_0(K, T) = S_0 P_1 - K e^{-rT} P_2, \quad (2.21)$$

où

$$P_2 = \frac{1}{2} + \frac{1}{\pi} \int_0^{+\infty} \operatorname{Re}\left(\frac{e^{-iuk} \varphi_T(u)}{iu}\right) du, \quad (2.22)$$

$$P_1 = \frac{1}{2} + \frac{1}{\pi} \int_0^{+\infty} \operatorname{Re}\left(\frac{e^{-iuk} \varphi_T(u - i)}{iu \varphi_T(-i)}\right) du. \quad (2.23)$$

2.10.2 Interprétation : deux probabilités sous deux mesures

- $P_2 = \mathbb{Q}(S_T > K)$: probabilité (risque-neutre) d'exercice.
- $P_1 = \mathbb{Q}^S(S_T > K)$: probabilité d'exercice sous la mesure action (numéraire S).

Cette séparation est très utile conceptuellement : le call est la différence entre une « position action » pondérée par P_1 et une « obligation » pondérée par P_2 .

2.10.3 Recette de calcul (quadrature 1D)

Méthode 2.1 (Pricing d'un call par Heston (quadrature)). 1. Fixer S_0, K, T, r et les paramètres $(\kappa, \theta, \sigma, \rho, v_0)$.
 2. Pour une grille u_j sur $[0, U_{\max}]$, calculer $\varphi_T(u_j)$ et $\varphi_T(u_j - i)$ via (2.20).
 3. Approcher les intégrales (2.22)–(2.23) par une quadrature (trapèzes/Simpson).
 4. Combiner dans (2.21).

Remarque 2.14 (Pourquoi « semi-analytique » ?). Tout est explicite sauf l'intégration numérique (1 dimension). C'est ce qu'on appelle classiquement une formule « semi-fermée ».

2.11 Compléments : digitals, puts, greeks, et lecture économique de P_1, P_2

2.11.1 Digitals et interprétation de P_2

Considérons le **digital cash-or-nothing** qui paye 1 si $S_T > K$:

$$H^{\text{dig}} = \mathbf{1}_{\{S_T > K\}}.$$

Son prix est $e^{-rT} \mathbb{Q}(S_T > K) = e^{-rT} P_2$. Ainsi, P_2 est littéralement une **probabilité risque-neutre d'exercice**.

Remarque 2.15 (Lien avec la dérivée en strike). Sous des hypothèses régulières, on peut aussi écrire

$$\frac{\partial C_0(K, T)}{\partial K} = -e^{-rT} \mathbb{Q}(S_T > K) = -e^{-rT} P_2.$$

Cette relation est très utile pour vérifier numériquement un code : la dérivée du call en K doit être négative et comprise entre $-e^{-rT}$ et 0.

2.11.2 Prix du put

On a deux manières de pricing :

— **Put-call parity** (sans dividendes) :

$$P_0(K, T) = C_0(K, T) - S_0 + K e^{-rT}.$$

— **Décomposition symétrique** :

$$(K - S_T)^+ = K \mathbf{1}_{\{S_T < K\}} - S_T \mathbf{1}_{\{S_T < K\}},$$

d'où, avec les mêmes mesures $\mathbb{Q}$ et $\mathbb{Q}^S$,

$$P_0(K, T) = K e^{-rT} (1 - P_2) - S_0 (1 - P_1).$$

Cette seconde écriture donne une interprétation parallèle à celle du call.

2.11.3 Greeks : pourquoi P_1 ressemble à une delta

En Black-Scholes, la delta du call vaut $N(d_1)$, et $N(d_1)$ correspond précisément au « P_1 » de la décomposition. Sous Heston, un fait similaire subsiste : P_1 est intimement lié à la sensibilité du prix à S_0 .

Idée : la solution de (2.10) s'écrit

$$S_T = S_0 \exp \left(\int_0^T \left(r - \frac{1}{2} v_t \right) dt + \int_0^T \sqrt{v_t} dW_t^{(1)} \right),$$

donc S_T est **linéaire en** S_0 . En dérivant sous le signe espérance (hypothèses techniques) :

$$\frac{\partial}{\partial S_0} C_0(K, T) = \mathbb{E}_{\mathbb{Q}}[e^{-rT} \partial_{S_0}(S_T - K)^+] = \mathbb{E}_{\mathbb{Q}}[e^{-rT} \frac{S_T}{S_0} \mathbf{1}_{\{S_T > K\}}] = \mathbb{E}_{\mathbb{Q}^S}[\mathbf{1}_{\{S_T > K\}}] = P_1.$$

On peut donc retenir l'interprétation mnémotechnique :

$$\Delta_{\text{call}} \approx P_1, \quad \Delta_{\text{put}} \approx P_1 - 1,$$

exactement comme dans Black-Scholes.

2.11.4 Heston vs Carr–Madan : deux inversions de Fourier

Il est instructif de comparer les deux inversions :

- Dans Heston (version P_1, P_2), on reconstruit une **probabilité de queue** via (2.7).
- Dans Carr–Madan, on reconstruit directement le **prix** (fonction de k) via (3.3).

Dans les deux cas, la difficulté mathématique est la même : contrôler l'intégrabilité et manipuler des intégrales oscillantes de la forme $\int e^{-iuk} \times (\dots) du$.

2.12 Mode microscope : affinité, Riccati et lecture des paramètres

2.12.1 Dynamique sous $\mathbb{Q}$ (rappel)

On considère

$$\frac{dS_t}{S_t} = (r - q) dt + \sqrt{v_t} dW_t^S, \quad dv_t = \kappa(\theta - v_t) dt + \xi \sqrt{v_t} dW_t^v, \quad dW_t^S dW_t^v = \rho dt.$$

Lecture paramètres.

- θ : niveau moyen de variance ; κ : vitesse de rappel (mean reversion).
- ξ : « vol de vol » (amplitude des fluctuations de v_t).
- ρ : corrélation prix/vol ; $\rho < 0$ génère un skew (effet leverage).

2.12.2 Pourquoi une forme affine ?

L'objet clé pour le pricing Fourier est la fonction caractéristique de $\ln S_T$:

$$\phi(u) := \mathbb{E}^{\mathbb{Q}}[e^{iu \ln S_T} \mid S_0, v_0].$$

Pour Heston, ϕ est de forme affine :

$$\phi(u) = \exp \left(C(T, u) + D(T, u)v_0 + iu \ln S_0 \right),$$

où C et D satisfont des équations de type Riccati (issues d'une PDE / Feynman–Kac).

Idée de dérivation. On considère $f(t, x, v) = \mathbb{E}^{\mathbb{Q}}[\exp(iuX_T) \mid X_t = x, v_t = v]$ avec $X_t = \ln S_t$. Alors f satisfait une PDE linéaire $\partial_t f + \mathcal{L}f = 0$ avec condition terminale $f(T, x, v) = e^{iux}$. On propose l'ansatz $f = \exp(C + Dv + iux)$ et on identifie les coefficients en v pour obtenir une Riccati pour D .

Sanity check. Si $\xi = 0$ et $v_t \equiv v_0$ constant, Heston se réduit à Black–Scholes avec $\sigma = \sqrt{v_0}$.

Intuition de marché. Heston est un *compromis industriel* : assez riche pour produire skew/smile et assez structuré pour pricer vite (Fourier).

2.13 Pièges classiques / erreurs fréquentes

- Oublier que la mesure risque-neutre peut changer le drift de v_t (prime de risque de volatilité) selon le cadre.
- Perdre la corrélation ρ dans les calculs : c'est le moteur du skew.
- Instabilités numériques quand v_t touche 0 (schémas de simulation).

2.14 Checklist — savoir refaire sans regarder

- Écrire la dynamique Heston et interpréter $\kappa, \theta, \xi, \rho$.
- Expliquer l'ansatz affine et pourquoi il mène à une Riccati.
- Relier qualitativement ρ au skew et ξ à la convexité de smile.
- Faire des sanity-checks de paramètres et de limites (réduction à BS).

Chapitre 3

Fourier/fft - Carr–Madan

Idée centrale. Carr–Madan exploite une fonction caractéristique fermée pour pricer des options via transformée de Fourier, puis FFT sur une grille de strikes. Objectif : vitesse et calibration scalable.

Cadre mathématique.

- **Brique.** Fonction caractéristique $\varphi_T(u) = \mathbb{E}^{\mathbb{Q}}[e^{iu \log S_T}]$ (modèle affiné, Heston, sauts).
- **Damping.** Introduire $\alpha > 0$ pour rendre l'intégrale convergente et stabiliser l'inversion.
- **FFT.** Discrétiser sur une grille (pas η , taille N) : attention aliasing, troncature, interpolation en K .

Intuition marché / interprétation. En production, la calibration exige des milliers de pricings ; la FFT donne un « bulk pricer ». Les erreurs viennent de paramètres numériques (grille, damping) plus que du modèle.

Implémentation.

- Implémenter la recette : choisir (α, N, η) , calculer l'intégrande, appliquer FFT, interpoler.
- Contrôler via pricer 1D (quadrature) sur quelques strikes et imposer no-arbitrage en strike.

Tests / sanity checks.

- Comparaison : FFT vs quadrature sur un sous-ensemble de strikes (écart toléré).
- Stabilité : sensibilité faible à (α, N, η) dans une zone de paramètres (sinon artefacts).
- No-arbitrage : monotonie/convexité en strike sur la grille.

Pont vers pratique quant. Pont quant : calibration rapide de modèles à CF (Heston/jumps), construction de surfaces (bulk pricing), et routines de validation numérique (aliasing/troncature/branches).

3.1 Avant-propos : Fourier/fft (Carr–Madan)

Dans Heston (et plus généralement dans les modèles affines), on sait calculer une **fonction caractéristique** fermée. L'idée de Carr–Madan est d'exploiter cette brique pour obtenir un pricer efficace sur une *grille* de strikes :

$$\varphi_T(u) \quad \Rightarrow \quad \text{intégrale de Fourier} \quad \Rightarrow \quad \text{FFT}.$$

3.1.1 Pourquoi cette méthode est si utilisée

- **Vitesse.** On calcule $C(K)$ pour beaucoup de strikes en une passe.
- **Modularité.** Toute la dépendance au modèle est dans φ_T .
- **Calibration.** Quand on doit pricer des centaines de vanilles à chaque itération, la FFT devient un avantage compétitif.

3.1.2 Objectifs pédagogiques

- Comprendre le problème d'intégrabilité et le rôle du *damping* α .
- Dériver la transformée de Carr–Madan à partir de la densité (Fubini + fonction caractéristique complexe).
- Passer de l'inversion à la FFT : choix des grilles (v, k) , discretisation, aliasing.
- Identifier les pièges numériques (log complexe, choix de α , troncature) et proposer des sanity checks.

3.1.3 Pré-requis

- Heston (chapitre 2) : fonction caractéristique et conventions.
- Fourier : inversion, partie réelle, intégrales oscillantes.
- Notions numériques : quadrature, discrétisation, conditionnement.

3.1.4 Plan du chapitre

1. Formule de Carr–Madan : dérivation et conditions de moments.
2. Discrétisation et FFT : recette standard et choix de paramètres.
3. Stabilité numérique : log complexe, tests rapides, sanity checks.

Sanity check. La FFT ne remplace pas les checks d'arbitrage : on compare toujours à des pricers 1D (quadrature P_1/P_2) et on vérifie monotonie/convexité en strike sur quelques points.

3.2 Étape 3 : Carr–Madan (transformée de Fourier du prix en log-strike)

La méthode de Carr–Madan (1999) part non pas d'une probabilité de queue, mais de la fonction $k \mapsto C(k)$ elle-même (prix en fonction du log-strike), et construit une transformée de Fourier exploitable par FFT.

3.2.1 Le problème d'intégrabilité et l'idée du « damping »

La transformée de Fourier classique de $C(k)$ n'est pas forcément intégrable car $C(k)$ décroît lentement quand $k \rightarrow -\infty$ (strike très faible : le call devient proche de S_0). Carr–Madan propose d'étudier une version **amortie** :

$$c_\alpha(k) := e^{\alpha k} C(k),$$

où $\alpha > 0$ est choisi pour rendre c_α intégrable.

Remarque 3.1 (Condition de moment). Pour que la méthode soit valide, il faut (au moins) que $\mathbb{E}_{\mathbb{Q}}[e^{(\alpha+1)X_T}] < \infty$, c'est-à-dire l'existence d'un moment d'ordre $\alpha + 1$ de S_T . Sous Heston, les moments existent sur un intervalle (p_-, p_+) mais peuvent « exploser » au-delà (phénomène de « moment explosion »). En pratique, on choisit α « modéré » et on vérifie la stabilité numérique.

Piège classique. Deux échecs classiques en implémentation Carr–Madan : (i) choisir α trop petit, et l'intégrande ne décroît pas assez (intégrale instable) ; (ii) choisir α trop grand, et on sort du domaine de moments (moment explosion) : l'intégrale devient *mathématiquement* illégitime, ou numériquement explosive.

Méthode. Choix pratique de α : démarrer avec une valeur standard (souvent $\alpha \in [1, 2]$ pour des calls), vérifier la décroissance de $v \mapsto \operatorname{Re}(e^{-ivk} \psi_T(v))$, puis ajuster. En calibration, on garde le même α sur toute la grille de strikes pour éviter des artefacts.

Sanity check.

- À paramètres fixés, le prix Carr–Madan doit coïncider (à tolérance numérique près) avec une quadrature P_1/P_2 sur quelques strikes tests.
- Le prix doit respecter les bornes d'arbitrage : $0 \leq C \leq S_0$ et $C \geq (S_0 - Ke^{-rT})^+$.

3.2.2 Prix du call comme intégrale contre la densité de X_T

Écrivons le prix en fonction de $k = \ln K$. Si f_{X_T} est la densité de X_T sous $\mathbb{Q}$:

$$C(k) = e^{-rT} \int_k^{+\infty} (e^x - e^k) f_{X_T}(x) dx. \quad (3.1)$$

3.2.3 Transformée de Fourier de c_α

On définit, pour $v \in \mathbb{R}$,

$$\psi_T(v) := \int_{-\infty}^{+\infty} e^{ivk} c_\alpha(k) dk = \int_{-\infty}^{+\infty} e^{(\alpha+iv)k} C(k) dk.$$

Proposition 3.1 (Formule de Carr–Madan). *Supposons que les échanges d'intégrales soient justifiés et que $\mathbb{E}_\mathbb{Q}[e^{(\alpha+1)X_T}] < \infty$. Alors*

$$\boxed{\psi_T(v) = e^{-rT} \frac{\varphi_T(v - i(\alpha + 1))}{(\alpha + iv)(\alpha + 1 + iv)}}. \quad (3.2)$$

Idee de preuve (étape par étape). On part de (3.1) :

$$\psi_T(v) = \int_{\mathbb{R}} e^{(\alpha+iv)k} \left(e^{-rT} \int_k^{+\infty} (e^x - e^k) f_{X_T}(x) dx \right) dk.$$

On échange les intégrales (Fubini), ce qui revient à intégrer sur le domaine $\{(k, x) : k \leq x\}$:

$$\psi_T(v) = e^{-rT} \int_{\mathbb{R}} \left(\int_{-\infty}^x e^{(\alpha+iv)k} (e^x - e^k) dk \right) f_{X_T}(x) dx.$$

On calcule l'intégrale interne :

$$\int_{-\infty}^x e^{(\alpha+iv)k} e^x dk = \frac{e^{(\alpha+1+iv)x}}{\alpha + iv}, \quad \int_{-\infty}^x e^{(\alpha+iv)k} e^k dk = \frac{e^{(\alpha+1+iv)x}}{\alpha + 1 + iv},$$

et donc

$$\int_{-\infty}^x e^{(\alpha+iv)k} (e^x - e^k) dk = \frac{e^{(\alpha+1+iv)x}}{(\alpha + iv)(\alpha + 1 + iv)}.$$

Ainsi

$$\psi_T(v) = e^{-rT} \frac{1}{(\alpha + iv)(\alpha + 1 + iv)} \int_{\mathbb{R}} e^{(\alpha+1+iv)x} f_{X_T}(x) dx.$$

Le dernier terme est $\mathbb{E}[e^{(\alpha+1+iv)X_T}]$, qui vaut $\varphi_T(v - i(\alpha + 1))$ par prolongement complexe de la fonction caractéristique. $\square$

3.2.4 Inversion : retour au prix $C(k)$

Comme c_α est intégrable, on a la formule d'inversion de Fourier :

$$c_\alpha(k) = \frac{1}{2\pi} \int_{-\infty}^{+\infty} e^{-ivk} \psi_T(v) dv.$$

Et donc

$$\boxed{C(k) = \frac{e^{-\alpha k}}{2\pi} \int_{-\infty}^{+\infty} e^{-ivk} \psi_T(v) dv}. \quad (3.3)$$

En utilisant la réalité du prix, on peut écrire une intégrale sur $[0, +\infty)$:

$$\boxed{C(k) = \frac{e^{-\alpha k}}{\pi} \int_0^{+\infty} \operatorname{Re} \left(e^{-ivk} \psi_T(v) \right) dv}. \quad (3.4)$$

3.2.5 Carr–Madan + Heston : formule finale directement exploitable

Sous Heston, on injecte (2.20) dans (3.2) :

$$\psi_T(v) = e^{-rT} \frac{\exp \left(C(T; u) + D(T; u) v_0 + iu \ln S_0 \right)}{(\alpha + iv)(\alpha + 1 + iv)}, \quad u := v - i(\alpha + 1).$$

Puis on intègre (3.4) pour obtenir $C(k)$.

Remarque 3.2 (Comparaison Heston vs Carr–Madan). Les deux méthodes reposent sur la même brique : la fonction caractéristique φ_T .

- La formule « P_1, P_2 » (Heston) donne une intégrale par strike.
- Carr–Madan prépare le terrain pour calculer **une grille** de strikes en une seule passe via FFT.

3.3 Mise en pratique : discrétisation et fft (Carr–Madan)

3.3.1 Principe général

La FFT calcule efficacement une famille de sommes du type

$$\sum_{j=0}^{N-1} e^{-i2\pi jm/N} a_j,$$

qui ressemble à une quadrature d'inversion de Fourier sur une grille régulière. Carr–Madan choisit donc :

- une grille régulière en fréquences $v_j = j\eta$;
- une grille régulière en log-strikes $k_m = -b + m\lambda$;
- des pas reliés par $\lambda = \frac{2\pi}{N\eta}$.

3.3.2 Une recette standard

Fixons un entier N (souvent puissance de 2), un pas $\eta > 0$ et un damping $\alpha > 0$. On pose

$$v_j = j\eta, \quad j = 0, \dots, N-1, \quad \lambda = \frac{2\pi}{N\eta}, \quad k_m = -b + m\lambda, \quad m = 0, \dots, N-1,$$

où b règle l'intervalle de strikes couverts.

Méthode 3.1 (FFT Carr–Madan (schéma de base)). 1. Pour chaque v_j , calculer $\psi_T(v_j)$ via (3.2) (donc évaluer φ_T au point complexe $u = v_j - i(\alpha + 1)$).

2. Appliquer une quadrature (trapèzes/Simpson) en incorporant les poids dans a_j :

$$a_j := e^{iv_j b} \psi_T(v_j) w_j \eta,$$

où w_j sont les poids de quadrature.

3. Calculer la FFT des a_j pour obtenir approximativement les $c_\alpha(k_m)$.
4. En déduire $C(k_m) = e^{-\alpha k_m} c_\alpha(k_m)$.

3.3.3 Points numériques importants

- **Troncature** : l'intégrale en v est tronquée à $[0, (N-1)\eta]$. On augmente N et/ou η pour réduire l'erreur de troncature.
- **Aliasing** : la discrétisation impose une périodisation implicite en k . Le choix de b et des pas est crucial.
- **Choix de α** : trop petit $\Rightarrow$ intégrale mal amortie ; trop grand $\Rightarrow$ amplification d'erreurs numériques et possible violation de la condition de moment.
- **Branch cut** : attention au logarithme complexe dans $C(T; u)$.
- **Contrôles** : put–call parity, monotonie en K , convexité en K (absence d'arbitrage statique) sont des sanity checks utiles.

3.4 Exemple numérique guidé (sans code) : pricer un call européen

Cette section propose une lecture « pas à pas » d'un pricing Heston, sans entrer dans les détails d'implémentation. L'idée est d'avoir un scénario que l'on peut expliquer au tableau.

3.4.1 Données

On fixe par exemple :

Paramètre	Valeur (exemple)
S_0	100
K	100 (ATM)
T	1 an
r	2%
v_0	0.04 (soit 20% de vol instantanée)
κ	2
θ	0.04
σ	0.5
ρ	-0.7

On note $k = \ln K$ et $x_0 = \ln S_0$.

3.4.2 Étape A : construire la fonction caractéristique

Pour chaque argument complexe u dont on aura besoin (selon la méthode), on calcule :

1. $b(u) = \kappa - \rho\sigma iu$;
2. $d(u) = \sqrt{b(u)^2 + \sigma^2(u^2 + iu)}$ avec $\text{Re}(d) > 0$;
3. $g(u) = \frac{b(u)-d(u)}{b(u)+d(u)}$;
4. $D(T; u)$ via (2.18) ;
5. $C(T; u)$ via (2.19) ;
6. $\varphi_T(u) = \exp(C(T; u) + D(T; u)v_0 + iux_0)$.

Sanity checks : $\varphi_T(0) = 1$ et $\varphi_T(-i) = S_0 e^{rT}$.

3.4.3 Étape B1 : pricer par la formule de Heston (P_1, P_2)

On calcule

$$P_2 = \frac{1}{2} + \frac{1}{\pi} \int_0^{+\infty} \text{Re} \left(\frac{e^{-iuk} \varphi_T(u)}{iu} \right) du, \quad P_1 = \frac{1}{2} + \frac{1}{\pi} \int_0^{+\infty} \text{Re} \left(\frac{e^{-iuk} \varphi_T(u-i)}{iu \varphi_T(-i)} \right) du.$$

Puis

$$C_0 = S_0 P_1 - K e^{-rT} P_2.$$

Lecture pédagogique.

- P_2 est une probabilité d'exercice *sous* $\mathbb{Q}$.
- P_1 est une probabilité d'exercice *sous* $\mathbb{Q}^S$ (numéraire action), donc naturellement liée à la delta.
- Les deux intégrales viennent d'une « même » formule d'inversion de Fourier appliquée à deux mesures.

3.4.4 Étape B2 : pricer par Carr–Madan (et préparer une grille)

On choisit un damping $\alpha > 0$ (par exemple $\alpha = 1.5$), puis on calcule, pour $v \geq 0$:

$$\psi_T(v) = e^{-rT} \frac{\varphi_T(v - i(\alpha + 1))}{(\alpha + iv)(\alpha + 1 + iv)}.$$

Enfin

$$C(k) = \frac{e^{-\alpha k}}{\pi} \int_0^{+\infty} \text{Re}(e^{-ivk} \psi_T(v)) dv.$$

Lecture pédagogique.

- On « amortit » le call (multiplication par $e^{\alpha k}$) pour rendre sa transformée intégrable.
- On récupère une formule en termes de φ_T évaluée en un point complexe $v - i(\alpha + 1)$.
- Sur une grille régulière $v_j = j\eta$, l'inversion devient une FFT qui donne $C(k_m)$ pour beaucoup de strikes.

3.4.5 Comparaison rapide des deux approches

- **Une option / un strike** : la formule P_1, P_2 est souvent la plus simple.

- **Beaucoup de strikes (surface)** : Carr–Madan+FFT devient très avantageux.
- **Dans les deux cas** : le coût principal est l'évaluation de φ_T (donc de C et D) sur une grille d'arguments complexes.

3.5 Implémentation : stabilité numérique et tests de cohérence

Cette section n'ajoute pas de nouveaux résultats théoriques ; elle rassemble les points qui, en pratique, font la différence entre « une formule correcte sur le papier » et « un code robuste ».

3.5.1 Tests rapides sur la fonction caractéristique

Avant même de pricer, on peut tester φ_T :

- **Normalisation** : $\varphi_T(0) = \mathbb{E}[e^0] = 1$.
- **Premier moment** (sans dividendes) : $\varphi_T(-i) = \mathbb{E}[e^{X_T}] = \mathbb{E}[S_T] = S_0 e^{rT}$.
- **Symétrie** : pour $u \in \mathbb{R}$, $\varphi_T(-u) = \varphi_T(u)$.
- **Borne** : pour $u \in \mathbb{R}$, $|\varphi_T(u)| \leq 1$ (propriété générale des fonctions caractéristiques).

Ces identités attrapent rapidement des erreurs de signe, de branche, ou de drift.

3.5.2 Piège classique : logarithme complexe dans $C(T; u)$

La formule de $C(T; u)$ contient un $\ln\left(\frac{1-qe^{-dT}}{1-g}\right)$. Or, en complexe, $\ln$ dépend d'une branche ; si l'argument traverse une coupure, on peut voir apparaître des sauts de $2\pi i$, ce qui ruine l'intégrale.

Symptôme : le prix oscille fortement ou devient négatif pour certains strikes.

Remède : stabiliser la formule (par exemple via le « Little Heston Trap ») :

- utiliser une forme algébriquement équivalente mais numériquement plus stable ;
- imposer $\text{Re}(d) > 0$ systématiquement ;
- contrôler la continuité de la phase du logarithme (ou utiliser des bibliothèques gérant le « branch tracking »).

3.5.3 Quadrature (Heston P_1, P_2) : gestion de $u \approx 0$

Les intégrales (2.22)–(2.23) contiennent un facteur $1/(iu)$. Le terme est intégrable (la singularité est « apparente »), mais en discret cela peut être source d'instabilité. Deux techniques pratiques :

- commencer la grille à un $u_{\min} > 0$ petit plutôt qu'à 0 ;
- remplacer l'intégrande près de 0 par son **développement limité** (en utilisant $\varphi_T(0) = 1$ et $\varphi'_T(0) = i\mathbb{E}[X_T]$).

3.5.4 Choix des paramètres fft : lecture pratique

On choisit (N, η, b, α) en fonction de l'objectif :

- **Largeur en strikes** : b et λ fixent l'intervalle de k couverts, donc de $K = e^k$.
- **Résolution en strikes** : $\lambda = \frac{2\pi}{N\eta}$.
- **Troncature en fréquence** : $v_{\max} \approx (N-1)\eta$.
- **Stabilité de l'intégrande** : α amortit la partie « non intégrable » du call quand $k \rightarrow -\infty$.

En pratique, on procède par itérations : on fixe un intervalle de strikes cible, puis on ajuste N et η pour stabiliser les prix.

3.5.5 Dividendes, forwards, et variable de log pertinente

Quand un dividende continu q est présent, il est souvent plus stable de travailler avec le **forward** $F_0 = S_0 e^{(r-q)T}$ et avec la variable $\ln(S_T/F_0)$. Le modèle et les formules se réécrivent alors en remplaçant r par $(r-q)$ dans le drift du log-prix, ce qui évite des erreurs de convention.

3.6 Ouvertures : calibration, sourire de volatilité, extensions

3.6.1 Pourquoi Heston génère un smile/skew

Dans Black-Scholes, σ est constante, donc l'implicite est plate. Sous Heston :

- le caractère aléatoire de v_t génère un **smile** (convexité de la distribution de X_T) ;
- une corrélation $\rho < 0$ génère un **skew** (asymétrie) : les baisses de S s'accompagnent de hausses de variance, ce qui renchérit les puts OTM.

3.6.2 Calibration (vue d'ensemble)

Calibrer Heston consiste à choisir $(\kappa, \theta, \sigma, \rho, v_0)$ pour minimiser l'écart entre prix (ou volatilités implicites) modèle et marché sur un ensemble (K, T) . Points clés :

- contraintes naturelles : $\kappa, \theta, \sigma > 0$, $\rho \in [-1, 1]$, $v_0 \geq 0$;
- non-convexité : plusieurs minima locaux ;
- « sloppiness » : certaines directions paramétriques sont peu identifiables sans données riches ;
- stabilité : régularisation et bornes sont souvent indispensables.

3.6.3 Simulation du modèle : pourquoi c'est délicat

Même si l'on dispose d'une formule semi-fermée, la simulation de Heston reste centrale (Monte Carlo pour exotiques, PnL, XVA, stress tests). Le point délicat est la simulation de v_t :

- un schéma d'Euler naïf peut produire des valeurs négatives de v ;
- la racine $\sqrt{v_t}$ impose une gestion robuste du voisinage de 0 ;
- la corrélation ρ entre les browniens doit être respectée.

Schémas usuels (vue d'ensemble).

- **Euler tronqué** (« full truncation ») : remplacer $\sqrt{v}$ par $\sqrt{v^+}$ et v par v^+ dans le drift, ce qui limite les explosions numériques.
- **Quadratic-Exponential (QE)** (Andersen) : approximation dédiée qui respecte mieux la loi conditionnelle de v et améliore la précision pour des pas de temps réalistes.
- **Simulation exacte de v** : la loi de $v_{t+\Delta}$ conditionnellement à v_t est χ^2 non centrale, donc simulable exactement ; cela supprime l'erreur de discrétisation sur v .
- **Simulation exacte (Broadie-Kaya)** : méthode exacte (mais coûteuse) basée sur la loi de l'intégrale $\int v dt$ conditionnellement aux extrémités.

Remarque 3.3 (Lien avec le procédé de volatilité stochastique). La diffusion CIR a une interprétation « processus de variance instantanée » mean-reverting et positive. C'est précisément ce **procédé de volatilité** qui rend Heston plus réaliste que Black-Scholes et, simultanément, plus difficile à simuler qu'une volatilité constante.

3.6.4 Application rapide : variance swap (ordre 1)

Le taux de variance swap (au sens de l'espérance) dépend de $\mathbb{E}[\int_0^T v_t dt]$, qui est explicite sous CIR :

$$\frac{1}{T} \mathbb{E} \left[\int_0^T v_t dt \right] = \theta + (v_0 - \theta) \frac{1 - e^{-\kappa T}}{\kappa T}.$$

Cela illustre un point important : même quand la loi complète de $\int v dt$ est compliquée, certaines quantités agrégées sont simples.

3.6.5 Extensions populaires

- **Bates** : Heston + sauts (Merton) pour mieux capter le smile court terme.
- **Paramètres dépendant du temps** (piecewise constant) : améliore la calibration multi-maturités.
- **Multi-facteurs** : plusieurs variances pour mieux ajuster la forme de surface.

- **Rough volatility** (rBergomi, rough Heston) : pour capturer l'empilement des smiles à court terme et la « rugosité » empirique de la vol.

3.6.6 Lecture qualitative : quel paramètre « fait » quoi ?

Une bonne calibration n'est pas qu'un problème d'optimisation : c'est aussi un problème d'interprétation. Une règle mnémotechnique utile :

- v_0 : **niveau** du smile aux maturités très courtes (vol instantanée initiale) ;
- θ : **niveau long terme** de la variance (queue de la term structure) ;
- κ : **vitesse** d'oubli de v_0 (comment on passe du court terme au long terme) ;
- σ : **courbure** / **kurtosis** (épaisseur des queues) ;
- ρ : **skew** (asymétrie à gauche/droite), via l'effet de levier.

Cette lecture aide à choisir de bonnes initialisations et à diagnostiquer des calibrations « bizarres ».

3.6.7 Limites et risques de modèle

Heston est un excellent compromis entre réalisme et tractabilité, mais il a des limites :

- **Smile court terme** : sans sauts et avec des paramètres constants, il peut sous-ajuster les très courtes maturités (queues trop « douces »).
- **Paramètres constants** : la surface de volatilité réelle est souvent trop riche pour être capturée par 5 paramètres fixes.
- **Risque de calibration** : instabilité, multi-minima, dépendance au choix de la métrique (prix vs vol implicite).
- **Risque de dynamique** : une calibration statique (à $t = 0$) ne garantit pas une bonne dynamique de surface dans le temps.

En pratique, on complète souvent Heston par des extensions (Bates, paramètres piecewise constant, ou modèles rough).

3.7 Conclusion : la chaîne complète (à savoir refaire)

3.7.1 La chaîne « PDE $\rightarrow$ Riccati $\rightarrow$ Fourier »

Le cours repose sur une séquence logique qu'il faut savoir dérouler :

1. **Poser le modèle sous $\mathbb{Q}$** : SDEs pour (S_t, v_t) , puis pour $X_t = \ln S_t$.
2. **Écrire la transformée conditionnelle** $p(t, x, v; u) = \mathbb{E}[e^{iuX_T} \mid X_t = x, v_t = v]$.
3. **Feynman–Kac** : p satisfait une PDE rétrograde $\partial_t p + \mathcal{L}p = 0$.
4. **Ansatz affine** : $p = \exp(C(\tau; u) + D(\tau; u)v + iux)$.
5. **Identification** : une Riccati pour D et une EDO linéaire pour C .
6. **Fonction caractéristique** : $\varphi_T(u) = \exp(C(T; u) + D(T; u)v_0 + iu \ln S_0)$.
7. **Inversion** :
 - soit via P_1, P_2 (probabilités de queue) ;
 - soit via Carr–Madan (transformée du prix en k), puis FFT.

3.7.2 Formules « à avoir sous la main »

- Heston (call) : $C = S_0 P_1 - K e^{-rT} P_2$ avec P_1, P_2 donnés par (2.23)–(2.22).
- Carr–Madan : $\psi_T(v) = e^{-rT} \frac{\varphi_T(v - i(\alpha+1))}{(\alpha+iv)(\alpha+1+iv)}$ puis inversion (3.4).
- Critères de cohérence : $\varphi_T(0) = 1$, $\varphi_T(-i) = S_0 e^{rT}$, put–call parity.

3.8 Corrigés détaillés (incontournables)

Exercice : Itô sur $X_t = \ln S_t$ sous Heston. On part de la dynamique (sous $\mathbb{Q}$) :

$$dS_t = rS_t dt + \sqrt{v_t} S_t dW_t^{(1)}.$$

On pose $X_t = \ln S_t$ et on applique Itô à la fonction $f(s) = \ln s$. On a $f'(s) = 1/s$ et $f''(s) = -1/s^2$. La formule d'Itô donne

$$dX_t = f'(S_t)dS_t + \frac{1}{2}f''(S_t)d[S]_t = \frac{1}{S_t}dS_t - \frac{1}{2S_t^2}d[S]_t.$$

Or, comme dS_t a un terme brownien $\sqrt{v_t}S_t dW_t^{(1)}$, on a

$$d[S]_t = (\sqrt{v_t}S_t)^2 dt = v_t S_t^2 dt.$$

Donc

$$dX_t = \frac{1}{S_t} \left(rS_t dt + \sqrt{v_t}S_t dW_t^{(1)} \right) - \frac{1}{2S_t^2} (v_t S_t^2 dt) = \left(r - \frac{1}{2}v_t \right) dt + \sqrt{v_t} dW_t^{(1)}.$$

Sanity check. Si $v_t \equiv \sigma^2$ est constante, on retrouve le cas Black-Scholes : $dX_t = (r - \frac{1}{2}\sigma^2)dt + \sigma dW_t$.

Exercice : décomposition $C_0 = S_0 P_1 - K e^{-rT} P_2$. On part du payoff du call :

$$(S_T - K)^+ = S_T \mathbf{1}_{\{S_T > K\}} - K \mathbf{1}_{\{S_T > K\}}.$$

En actualisant et en prenant l'espérance sous $\mathbb{Q}$:

$$\begin{aligned} C_0 &= \mathbb{E}_{\mathbb{Q}}[e^{-rT}(S_T - K)^+] \\ &= \mathbb{E}_{\mathbb{Q}}[e^{-rT} S_T \mathbf{1}_{\{S_T > K\}}] - K e^{-rT} \mathbb{Q}(S_T > K). \end{aligned}$$

On pose $P_2 := \mathbb{Q}(S_T > K)$, ce qui donne immédiatement le second terme $-K e^{-rT} P_2$.

Pour le premier terme, on utilise le changement de numéraire vers la mesure action (Annexe G). On définit $\mathbb{Q}^S$ par $\frac{d\mathbb{Q}^S}{d\mathbb{Q}} \Big|_{\mathcal{F}_T} = \frac{e^{-rT} S_T}{S_0}$. Alors, pour toute variable Y intégrable,

$$\mathbb{E}_{\mathbb{Q}}[e^{-rT} S_T Y] = S_0 \mathbb{E}_{\mathbb{Q}^S}[Y].$$

En prenant $Y = \mathbf{1}_{\{S_T > K\}}$, on obtient

$$\mathbb{E}_{\mathbb{Q}}[e^{-rT} S_T \mathbf{1}_{\{S_T > K\}}] = S_0 \mathbb{Q}^S(S_T > K).$$

On pose donc $P_1 := \mathbb{Q}^S(S_T > K)$, et on conclut :

$$C_0 = S_0 P_1 - K e^{-rT} P_2.$$

Sanity check. Si $K \downarrow 0$, alors $P_1 = P_2 = 1$ et $C_0 \rightarrow S_0$, cohérent avec $(S_T - 0)^+ = S_T$.

Exercice : pourquoi le choix des grilles donne une fft. Dans Carr-Madan, on calcule numériquement une inversion de Fourier en variable v puis on veut obtenir une grille de prix en *log-strike* $k = \ln K$. On discrétise $v_j = j\eta$ (pas η) et $k_m = -b + m\lambda$ (pas λ). Dans l'inversion apparaît le facteur oscillant e^{-ivk} , donc ici

$$e^{-iv_j k_m} = e^{-i(j\eta)(-b+m\lambda)} = e^{ij\eta b} e^{-ij\eta m\lambda}.$$

Si l'on choisit

$$\lambda = \frac{2\pi}{N\eta},$$

alors $j\eta m\lambda = 2\pi jm/N$ et

$$e^{-ij\eta m\lambda} = e^{-2\pi i jm/N},$$

qui est exactement le noyau de la transformée de Fourier discrète (DFT). Autrement dit, à facteur multiplicatif $e^{ij\eta b}$ près, la somme sur j est une FFT.

3.9 Annexe A : preuve de la formule de queue (variante)

On peut aussi obtenir (2.7) en partant de l'inversion de Fourier de la fonction de répartition $F(k) = \mathbb{Q}(X \leq k)$:

$$F(k) = \frac{1}{2} - \frac{1}{\pi} \int_0^{+\infty} \operatorname{Re} \left(\frac{e^{-iuk} \varphi_X(u)}{iu} \right) du,$$

puis $1 - F(k) = \mathbb{Q}(X > k)$.

3.10 Annexe B : note sur les conventions de signe

Dans la littérature, on trouve des conventions où la fonction caractéristique est définie comme $\mathbb{E}[e^{-iuX}]$ au lieu de $\mathbb{E}[e^{iuX}]$. Cela change certains signes dans les formules intermédiaires (notamment dans l'EDO de Riccati), mais pas la structure : une fois la convention fixée, la chaîne « PDE $\rightarrow$ Riccati $\rightarrow \varphi \rightarrow$ inversion » est identique.

3.11 Annexe C : résolution détaillée de la Riccati de Heston

Cette annexe montre comment obtenir les expressions fermées de $D(\tau; u)$ et $C(\tau; u)$ à partir des EDO (2.16)–(2.17).

3.11.1 Mise sous forme standard

On réécrit (2.17) sous la forme

$$D'(\tau) = a D(\tau)^2 + b D(\tau) + c, \quad D(0) = 0, \quad (3.5)$$

où (pour un u fixé) les coefficients sont constants en τ :

$$a = \frac{\sigma^2}{2}, \quad b = \rho\sigma iu - \kappa, \quad c = -\frac{1}{2}(u^2 + iu).$$

3.11.2 Truc classique : Riccati $\rightarrow$ équation linéaire d'ordre 2

On utilise la substitution

$$D(\tau) = -\frac{1}{a} \frac{y'(\tau)}{y(\tau)},$$

où $y(\tau) \neq 0$. En dérivant :

$$D'(\tau) = -\frac{1}{a} \left(\frac{y''}{y} - \left(\frac{y'}{y} \right)^2 \right).$$

En injectant dans (3.5), on obtient après simplification (les termes $(y'/y)^2$ se compensent) :

$$y''(\tau) - b y'(\tau) - a c y(\tau) = 0.$$

On a donc une équation différentielle linéaire à coefficients constants.

3.11.3 Résolution de l'équation linéaire

On cherche une solution $y(\tau) = e^{\lambda\tau}$. On obtient l'équation caractéristique

$$\lambda^2 - b\lambda - ac = 0,$$

donc

$$\lambda_{\pm} = \frac{b \pm d}{2}, \quad d := \sqrt{b^2 + 4ac}.$$

Ici,

$$b^2 + 4ac = (\rho\sigma iu - \kappa)^2 + \sigma^2(u^2 + iu),$$

ce qui motive la définition (équivalente) utilisée dans le corps du texte :

$$d(u) = \sqrt{(\kappa - \rho\sigma iu)^2 + \sigma^2(u^2 + iu)}.$$

On choisit la branche telle que $\text{Re}(d) > 0$.

La solution générale est alors

$$y(\tau) = A e^{\lambda_+ \tau} + B e^{\lambda_- \tau}.$$

On en déduit

$$\frac{y'(\tau)}{y(\tau)} = \frac{\lambda_+ A e^{\lambda_+ \tau} + \lambda_- B e^{\lambda_- \tau}}{A e^{\lambda_+ \tau} + B e^{\lambda_- \tau}}.$$

Comme $D = -\frac{1}{a} \frac{y'}{y}$, il reste à choisir le ratio B/A pour satisfaire $D(0) = 0$.

3.11.4 Condition initiale $D(0) = 0$ et apparition de g

À $\tau = 0$:

$$D(0) = -\frac{1}{a} \frac{\lambda_+ A + \lambda_- B}{A + B}.$$

Imposer $D(0) = 0$ équivaut à $\lambda_+ A + \lambda_- B = 0$, donc

$$\frac{B}{A} = -\frac{\lambda_+}{\lambda_-} = -\frac{b+d}{b-d}.$$

En posant

$$g := \frac{b-d}{b+d},$$

on vérifie que $B/A = -1/g$. En réinjectant et en simplifiant (en factorisant par $e^{\lambda_- \tau}$), on obtient après calcul :

$$D(\tau) = \frac{b-d}{\sigma^2} \frac{1 - e^{-d\tau}}{1 - g e^{-d\tau}},$$

ce qui est la forme annoncée dans (2.18) (avec les notations du texte $b(u) = \kappa - \rho \sigma i u$).

3.11.5 Intégration de $C'(\tau) = iur + \kappa \theta D(\tau)$

Une fois D connue,

$$C(\tau) = iur \tau + \kappa \theta \int_0^\tau D(s) ds.$$

En insérant l'expression fermée de D et en remarquant que

$$\int_0^\tau \frac{1 - e^{-ds}}{1 - g e^{-ds}} ds = \frac{1}{d} \left(\tau - \frac{2}{d} \ln \left(\frac{1 - g e^{-d\tau}}{1 - g} \right) \right) \quad (\text{à constantes près}),$$

on retrouve la formule logarithmique (2.19).

Message à retenir : une fois la Riccati résolue, C est une primitive explicite de D .

3.12 Annexe D : de l'inversion de Carr–Madan à la fft (dérivation)

On détaille ici comment l'intégrale d'inversion devient une somme de type DFT (discrete Fourier transform).

3.12.1 Point de départ

On part de (3.4) :

$$C(k) = \frac{e^{-\alpha k}}{\pi} \int_0^{+\infty} \operatorname{Re} \left(e^{-ivk} \psi_T(v) \right) dv.$$

On tronque l'intégrale à $[0, v_{\max}]$ et on discrétise avec un pas $\eta > 0$:

$$v_j = j\eta, \quad j = 0, \dots, N-1, \quad v_{\max} \approx (N-1)\eta.$$

Une quadrature de type trapèzes donne

$$C(k) \approx \frac{e^{-\alpha k}}{\pi} \operatorname{Re} \left(\sum_{j=0}^{N-1} e^{-iv_j k} \psi_T(v_j) w_j \eta \right), \quad (3.6)$$

où $w_0 = \frac{1}{2}$, $w_{N-1} = \frac{1}{2}$, et $w_j = 1$ sinon.

3.12.2 Choix d'une grille en k compatible fft

Pour obtenir les prix sur une grille de log-strikes k_m , on choisit

$$k_m = -b + m\lambda, \quad m = 0, \dots, N-1,$$

avec un pas λ lié à η par

$$\lambda = \frac{2\pi}{N\eta}.$$

Alors

$$e^{-iv_j k_m} = e^{-i(j\eta)(-b+m\lambda)} = e^{iv_j b} e^{-ij\eta m\lambda} = e^{iv_j b} e^{-i2\pi jm/N}.$$

C'est exactement le noyau de la DFT.

3.12.3 Vecteur à transformer

En posant

$$a_j := e^{iv_j b} \psi_T(v_j) w_j \eta,$$

la somme dans (3.6) devient

$$\sum_{j=0}^{N-1} a_j e^{-i2\pi jm/N},$$

qui est (à convention de signe près) une FFT. On obtient donc efficacement les $c_\alpha(k_m)$ puis

$$C(k_m) = e^{-\alpha k_m} c_\alpha(k_m).$$

3.12.4 Remarque : poids de Simpson

Pour améliorer la précision, on peut utiliser la règle de Simpson (nécessite N impair ou un traitement adapté). Une version pratique (souvent utilisée dans les implémentations) consiste à remplacer w_j par

$$w_j^{\text{Simp}} = \frac{1}{3} \times \begin{cases} 1, & j = 0, \\ 4, & j \text{ impair}, \\ 2, & j \text{ pair}, 0 < j < N-1, \\ 1, & j = N-1, \end{cases}$$

et à multiplier par η . Le principe FFT reste identique : seuls les poids changent.

3.13 Annexe E : moments sous Heston et choix du paramètre α

3.13.1 Moments et arguments complexes

Pour $p \in \mathbb{R}$, le moment $\mathbb{E}_{\mathbb{Q}}[S_T^p]$ s'écrit

$$\mathbb{E}_{\mathbb{Q}}[S_T^p] = \mathbb{E}_{\mathbb{Q}}[e^{pX_T}] = \varphi_T(-ip),$$

si la quantité est finie. Sous Heston, la formule (2.20) fournit donc (formellement)

$$\mathbb{E}_{\mathbb{Q}}[S_T^p] = \exp\left(C(T; -ip) + D(T; -ip) v_0 + p \ln S_0\right),$$

tant que C et D sont bien définies (et que l'on a choisi une branche cohérente).

3.13.2 Pourquoi cela compte pour Carr–Madan

Carr–Madan requiert

$$\mathbb{E}_{\mathbb{Q}}[e^{(\alpha+1)X_T}] < \infty \iff \mathbb{E}_{\mathbb{Q}}[S_T^{\alpha+1}] < \infty.$$

Autrement dit, il faut que le moment d'ordre $\alpha+1$ existe. Sous Heston, il existe des horizons et des paramètres pour lesquels certains moments explosent (moment explosion). Le phénomène se lit dans la Riccati : à mesure que p augmente, le dénominateur $1 - g(u)e^{-d(u)T}$ peut s'annuler pour $u = -ip$, ce qui rend $D(T; -ip)$ infini.

3.13.3 Choix pratique de α

En pratique :

- on choisit souvent $\alpha \in [1, 2]$ pour des calls (valeurs classiques : 1, 1.25, 1.5) ;
- on vérifie numériquement que $\varphi_T(v - i(\alpha + 1))$ est stable sur la grille v_j ;
- si l'intégrande oscille fortement (ou si la surface présente de fortes queues), on ajuste (α, N, η, b) conjointement.

Remarque 3.4 (Puts et signe de α). Pour des puts, une approche consiste à utiliser put-call parity une fois les calls calculés. Il existe aussi des variantes Carr-Madan dédiées aux puts (damping négatif), mais elles demandent les moments à gauche et un contrôle analogue.

3.14 Annexe F : Feynman-Kac (preuve complète, version utile)

On utilise Feynman-Kac à deux endroits : (i) pour relier une PDE de pricing à une espérance risque-neutre, (ii) pour transformer une PDE en EDO (via un ansatz affine) lorsqu'on calcule une fonction caractéristique. Le point clef est toujours le même : *la PDE est exactement la condition pour qu'un processus actualisé soit une martingale*.

3.14.1 Cadre (diffusion markovienne)

Soit $(Z_t)_{t \in [0, T]}$ une diffusion (sous une mesure donnée, notée ici $\mathbb{Q}$) de dimension d , solution de

$$dZ_t = b(t, Z_t) dt + \sigma(t, Z_t) dW_t,$$

où W est un brownien d -dimensionnel. On note $\mathcal{L}$ le générateur agissant sur les fonctions $u \in C^{1,2}$ par

$$(\mathcal{L}u)(t, z) = \sum_{i=1}^d b_i(t, z) \partial_{z_i} u(t, z) + \frac{1}{2} \sum_{i,j=1}^d (a_{ij}(t, z)) \partial_{z_i z_j} u(t, z), \quad a(t, z) := \sigma(t, z) \sigma(t, z)^\top.$$

On fixe une fonction terminale $\Phi : \mathbb{R}^d \rightarrow \mathbb{R}$ et un taux d'actualisation constant $c \in \mathbb{R}$.

3.14.2 Énoncé (une direction)

Théorème 3.1 (Feynman-Kac, direction « PDE $\Rightarrow$ espérance »). Soit $u \in C^{1,2}([0, T] \times \mathbb{R}^d)$ telle que :

1. $u(T, z) = \Phi(z)$ pour tout z ;
2. u satisfait la PDE rétrograde

$$\partial_t u + \mathcal{L}u - cu = 0; \tag{3.7}$$

3. le processus $(e^{-cs} u(s, Z_s))_{s \in [0, T]}$ est de carré intégrable (par exemple : u et ∇u ont une croissance au plus polynomiale et Z possède les moments correspondants).

Alors, pour tout $t \in [0, T]$,

$$u(t, Z_t) = \mathbb{E}^{\mathbb{Q}}[e^{-c(T-t)} \Phi(Z_T) \mid \mathcal{F}_t]. \tag{3.8}$$

En particulier, par propriété de Markov, $u(t, z) = \mathbb{E}^{\mathbb{Q}}[e^{-c(T-t)} \Phi(Z_T) \mid Z_t = z]$.

Démonstration. Fixons $t \in [0, T]$ et définissons, pour $s \in [t, T]$,

$$M_s := e^{-c(s-t)} u(s, Z_s).$$

1) Itô + produit. On applique Itô à $u(s, Z_s)$:

$$du(s, Z_s) = (\partial_s u + \mathcal{L}u)(s, Z_s) ds + \nabla u(s, Z_s)^\top \sigma(s, Z_s) dW_s.$$

Puis la règle du produit à $e^{-c(s-t)} u(s, Z_s)$:

$$\begin{aligned} dM_s &= d(e^{-c(s-t)} u(s, Z_s)) + e^{-c(s-t)} du(s, Z_s) \\ &= -c e^{-c(s-t)} u(s, Z_s) ds + e^{-c(s-t)} (\partial_s u + \mathcal{L}u)(s, Z_s) ds + e^{-c(s-t)} \nabla u(s, Z_s)^\top \sigma(s, Z_s) dW_s \\ &= e^{-c(s-t)} (\partial_s u + \mathcal{L}u - cu)(s, Z_s) ds + e^{-c(s-t)} \nabla u(s, Z_s)^\top \sigma(s, Z_s) dW_s. \end{aligned}$$

2) La PDE annule le drift. Par (3.7), le terme en ds est nul, donc

$$dM_s = e^{-c(s-t)} \nabla u(s, Z_s)^\top \sigma(s, Z_s) dW_s.$$

3) Le terme stochastique est une vraie martingale. Sous l'hypothèse (3), l'intégrale stochastique est de carré intégrable, donc une martingale. Ainsi $(M_s)_{s \in [t, T]}$ est une martingale.

4) Conclure par espérance conditionnelle. On a alors $M_t = \mathbb{E}^\mathbb{Q}[M_T \mid \mathcal{F}_t]$. Or $M_t = u(t, Z_t)$ et $M_T = e^{-c(T-t)} u(T, Z_T) = e^{-c(T-t)} \Phi(Z_T)$. Donc $u(t, Z_t) = \mathbb{E}^\mathbb{Q}[e^{-c(T-t)} \Phi(Z_T) \mid \mathcal{F}_t]$, ce qui est (3.8). $\square$

3.14.3 Réciproque (ce qu'il faut retenir)

Si l'on définit $u(t, Z_t)$ par le membre de droite de (3.8) et que l'on sait (par ailleurs) que u est $C^{1,2}$, alors $M_s = e^{-c(s-t)} u(s, Z_s)$ est une martingale; en appliquant Itô à M et en identifiant le terme de variation finie, on retrouve la PDE (3.7).

3.15 Annexe G : changement de numéraire (preuve complète)

On détaille l'outil utilisé dans la décomposition du call $C_0 = S_0 P_1 - K e^{-rT} P_2$: le passage à la *mesure action* $\mathbb{Q}^S$.

3.15.1 Principe général

On note $B_t = e^{rt}$ le numéraire numéraire « cash » (compte bancaire) et on se place sous une mesure martingale $\mathbb{Q}$ associée à B : pour tout actif tradable A , le prix actualisé A_t/B_t est une martingale $\mathbb{Q}$.

Soit $N_t > 0$ un autre numéraire tradable (strictement positif). Comme N_t/B_t est une martingale $\mathbb{Q}$, le processus

$$\Lambda_t := \frac{N_t/B_t}{N_0/B_0} = \frac{B_0^{-1} N_t}{B_t^{-1} N_0} \quad (3.9)$$

est une martingale positive de moyenne 1. On définit alors une nouvelle mesure $\mathbb{Q}^N$ par

$$\frac{d\mathbb{Q}^N}{d\mathbb{Q}} \Big|_{\mathcal{F}_t} = \Lambda_t \quad (\text{en particulier } \frac{d\mathbb{Q}^N}{d\mathbb{Q}} \Big|_{\mathcal{F}_T} = \Lambda_T). \quad (3.10)$$

3.15.2 Résultat : les prix en unités de N sont des martingales sous $\mathbb{Q}^N$

Proposition 3.2 (Changement de numéraire). *Soit A un actif tradable. Sous $\mathbb{Q}^N$, le processus A_t/N_t est une martingale, i.e.*

$$\frac{A_t}{N_t} = \mathbb{E}_{\mathbb{Q}^N} \left[\frac{A_T}{N_T} \mid \mathcal{F}_t \right]. \quad (3.11)$$

Démonstration. On utilise la formule de Bayes associée à (3.10) : pour toute variable intégrable X ,

$$\mathbb{E}_{\mathbb{Q}^N}[X \mid \mathcal{F}_t] = \frac{1}{\Lambda_t} \mathbb{E}_{\mathbb{Q}}[\Lambda_T X \mid \mathcal{F}_t].$$

On applique ceci à $X = A_T/N_T$. Avec (3.9),

$$\Lambda_T \frac{A_T}{N_T} = \frac{N_T/B_T}{N_0/B_0} \cdot \frac{A_T}{N_T} = \frac{1}{N_0/B_0} \cdot \frac{A_T}{B_T}.$$

Comme A_t/B_t est une martingale sous $\mathbb{Q}$,

$$\mathbb{E}_{\mathbb{Q}} \left[\frac{A_T}{B_T} \mid \mathcal{F}_t \right] = \frac{A_t}{B_t}.$$

Donc

$$\mathbb{E}_{\mathbb{Q}}[\Lambda_T A_T/N_T \mid \mathcal{F}_t] = \frac{1}{N_0/B_0} \cdot \frac{A_t}{B_t}.$$

En divisant par $\Lambda_t = (N_t/B_t)/(N_0/B_0)$, on obtient

$$\mathbb{E}_{\mathbb{Q}^N}[A_T/N_T \mid \mathcal{F}_t] = \frac{A_t/B_t}{N_t/B_t} = \frac{A_t}{N_t},$$

ce qui est (3.11). □

3.15.3 Cas $N = S$: la mesure action $\mathbb{Q}^S$

En prenant $N_t = S_t$, (3.10) donne

$$\left. \frac{d\mathbb{Q}^S}{d\mathbb{Q}} \right|_{\mathcal{F}_T} = \frac{S_T/B_T}{S_0/B_0} = \frac{e^{-rT} S_T}{S_0}. \quad (3.12)$$

Alors, pour toute variable Y intégrable,

$$\mathbb{E}_{\mathbb{Q}}[e^{-rT} S_T Y] = S_0 \mathbb{E}_{\mathbb{Q}} \left[\left. \frac{d\mathbb{Q}^S}{d\mathbb{Q}} \right|_{\mathcal{F}_T} Y \right] = S_0 \mathbb{E}_{\mathbb{Q}^S}[Y].$$

C'est exactement l'identité utilisée dans la décomposition du call, en prenant $Y = \mathbf{1}_{\{S_T > K\}}$.

3.16 Annexe H : modèles affines — le « gabarit » derrière Heston

Cette annexe explique pourquoi les calculs « fonctionnent » si bien dans Heston : il appartient à la classe des **modèles affines**.

3.16.1 Définition (idée)

Un processus Markovien $Y_t \in \mathbb{R}^d$ est dit **affine** si, pour tout vecteur u dans un domaine admissible, la transformée exponentielle a la forme

$$\mathbb{E}[e^{u^\top Y_T} \mid Y_t = y] = \exp(A(T-t; u) + B(T-t; u)^\top y),$$

où A est scalaire et B est vectorielle.

Remarque 3.5. On reconnaît immédiatement la structure de (2.15) : ici $Y = (X, v)$, et u joue le rôle de $(iu, 0)$ (avec un terme terminal $e^{iu x}$).

3.16.2 Pourquoi une Riccati apparaît toujours

Quand le générateur $\mathcal{L}$ du processus a des coefficients affines en y , l'application de $\mathcal{L}$ à une fonction $\exp(A + B^\top y)$ produit à nouveau cette exponentielle, multipliée par un polynôme (au plus quadratique) en B et affine en y . Imposer que la PDE soit vraie pour tout y force l'annulation séparée des coefficients : on obtient un système d'EDO pour A et B . Dans les diffusions affines, ces EDO sont typiquement des **Riccati**.

3.16.3 Lecture « ingénierie quant » : ce qu'il faut retenir

Si vous savez :

- écrire le générateur ;
- poser un ansatz exponentiel-affine ;
- identifier le système Riccati ;
- faire une inversion de Fourier,

alors vous savez répliquer la démarche sur de nombreux modèles : Vasicek/CIR (taux), Heston/Bates (volatilité), certains modèles multi-facteurs, etc.

3.17 Annexe I : deux autres points de vue (sans détails techniques)

3.17.1 Lewis (contour) : même idée, autre packaging

La représentation de Lewis pour le call consiste à :

- écrire le prix comme une intégrale de Fourier dans le plan complexe ;
- choisir un « contour » (un décalage imaginaire) qui assure la convergence ;
- exprimer l'intégrande en termes de la même fonction caractéristique φ_T .

Conceptuellement, c'est très proche de Carr–Madan : on amortit/décale pour obtenir une intégrale convergente et numériquement stable.

3.17.2 PDE numérique : quand on sort du semi-analytique

Si l'on remplace la payoff européenne par une barrière, une asiatique, ou si l'on ajoute des features (taux stochastiques, dividendes discrets), la formule semi-fermée peut disparaître. On revient alors à des méthodes numériques : PDE, arbres, Monte Carlo (souvent couplés à des méthodes de variance reduction).

3.18 Annexe J : erreurs numériques (Carr–Madan / fft)

Cette annexe résume les principales sources d'erreur quand on implémente Carr–Madan avec FFT.

3.18.1 Erreur de troncature en fréquence

On remplace $\int_0^{+\infty}$ par $\int_0^{v_{\max}}$:

$$\int_0^{+\infty} \text{Re}(\cdots) dv \approx \int_0^{v_{\max}} \text{Re}(\cdots) dv.$$

L'erreur dépend de la décroissance de l'intégrande. Le damping α est précisément choisi pour accélérer cette décroissance. En pratique, on augmente $v_{\max}$ jusqu'à stabilisation des prix sur la zone de strikes d'intérêt.

3.18.2 Erreur de discrétisation (pas η)

Même avec $v_{\max}$ fixé, on remplace l'intégrale par une somme. Un pas η trop grand introduit :

- une mauvaise résolution des oscillations e^{-ivk} (surtout pour de grands $|k|$) ;
- une quadrature peu précise.

La règle de Simpson améliore souvent la précision à coût comparable, au prix d'une gestion attentive des poids.

3.18.3 Aliasing (périodisation en k)

La FFT implique une périodisation : la fonction reconstruite en k est, implicitement, périodique sur une fenêtre de taille $N\lambda$. Si la fenêtre ne couvre pas correctement la zone où $C(k)$ est « significatif », les queues se replient (« wrap-around ») et polluent les strikes utiles.

Heuristique : choisir b et $N\lambda$ de sorte que la fenêtre en k soit largement plus grande que l'intervalle de strikes visé.

3.18.4 Trade-off typique

Les paramètres (N, η, α, b) sont liés :

$$\lambda = \frac{2\pi}{N\eta}.$$

Augmenter N améliore à la fois la résolution et $v_{\max}$ (si η est fixé), mais augmente le coût. Augmenter η augmente $v_{\max}$ mais dégrade la résolution en k . Il faut donc ajuster conjointement (souvent en partant d'un intervalle de strikes cible).

3.19 Mode microscope : inversion Fourier et FFT

3.19.1 Idée générale

On suppose connue la fonction caractéristique $\phi(u) = \mathbb{E}^{\mathbb{Q}}[e^{iu \ln S_T}]$. L'objectif est d'obtenir $C(K)$ pour beaucoup de strikes K .

3.19.2 Amortissement (damping) et transformée

On travaille en log-strike $k = \ln K$ et on amortit le call :

$$\tilde{C}(k) := e^{\alpha k} C(e^k),$$

avec $\alpha > 0$ choisi pour assurer l'intégrabilité. Carr-Madan montre alors que la transformée de Fourier de $\tilde{C}$ s'exprime en fonction de ϕ (via une fonction ψ explicite). Le prix se récupère par inversion :

$$C(e^k) = e^{-\alpha k} \frac{1}{\pi} \int_0^\infty \Re(e^{-iuk} \psi(u)) du.$$

Sanity check. Le choix de α est un compromis : trop petit $\Rightarrow$ intégrale divergent/bruitée ; trop grand $\Rightarrow$ amplification des erreurs numériques.

3.19.3 FFT : relation de grille

On approxime l'intégrale par une somme discrète sur une grille $u_j = j\Delta u$, $j = 0, \dots, N-1$. La FFT fournit simultanément $C(K_m)$ sur une grille de $k_m = k_0 + m\Delta k$ si

$$\Delta u \Delta k = \frac{2\pi}{N}.$$

On obtient ainsi un vecteur de prix en $O(N \log N)$.

Intuition de marché. Le gain industriel est majeur : on calibre une surface en pricer très vite une grille de strikes. Les pièges sont *numériques* (aliasing, pas, intégrabilité), pas conceptuels.

3.20 Pièges classiques / erreurs fréquentes

- Choisir α sans tester la stabilité (prix négatifs/oscillations).
- Pas trop gros : intégrale sous-échantillonnée $\Rightarrow$ bruit.
- Ne pas vérifier la convexité en K : signal d'erreur numérique ou d'arbitrage introduit.

3.21 Checklist — savoir refaire sans regarder

- Expliquer l'amortissement et écrire la formule d'inversion de principe.
- Relier la grille Fourier et la grille en log-strike.
- Lister les sources d'erreur (troncature, discretisation, aliasing) et les sanity-checks.
- Vérifier la cohérence sur BS et la convexité des prix en strike.

Chapitre 4

CF/FFT en production : calibration, intégration, simulation (notes quant)

4.1 Idée centrale

Les modèles « industrie » (sauts, vol stoch) sont pilotés par (i) une **fonction caractéristique** pour pricer vite les vanilles (calibration), et (ii) des schémas de **simulation** pour les exotiques. Les points qui dégradent un desk sont presque toujours numériques : **aliasing/FFT**, **branch cuts** complexes, et **contraintes** (positivité, stabilité) pendant la calibration.

4.2 Cadre mathématique (rappel minimal utile)

4.2.1 Fonction caractéristique

Pour $X_T = \ln S_T$, on note $\varphi_T(u) = \mathbb{E}^{\mathbb{Q}}[e^{iuX_T}]$. Le pricing Fourier repose sur une inversion (avec damping) ; Carr–Madan introduit un paramètre $\alpha > 0$ pour rendre l'intégrale intégrable.

4.2.2 Jump-diffusion (Merton) : drift sous $\mathbb{Q}$

Modèle type :

$$\frac{dS_t}{S_{t-}} = (r - q - \lambda\kappa)dt + \sigma dW_t + (e^Y - 1)dN_t, \quad \kappa = \mathbb{E}[e^Y - 1],$$

avec N Poisson (intensité λ), Y taille de saut. **Message.** Le terme $-\lambda\kappa$ est indispensable pour la martingale (discounted).

4.3 Implémentation FFT (ce qui compte vraiment)

4.3.1 Grille et aliasing

- Choisir $N = 2^m$, pas en fréquence η ; $u_j = j\eta$.
- Le pas en log-strike vaut $\Delta k = \frac{2\pi}{N\eta}$, et la fenêtre couvre $\approx N\Delta k$.
- Aliasing = fenêtre trop petite ou η mal choisi : prix oscillants / non convexes $\Rightarrow$ augmenter N ou ajuster η .

4.3.2 Pondération (Simpson) et stabilité

```
import numpy as np

def simpson_weights(N):
    w = np.ones(N)
    w[1:-1:2] = 4.0
    w[2:-2:2] = 2.0
    return w / 3.0
```

En production. Toujours logger : (i) convexité en K , (ii) monotonie, (iii) prix négatifs à clipper (symptôme de grille).

4.4 Calibration (Heston/jumps) : réflexes buy-side/sell-side

4.4.1 Objectif

Minimiser une erreur sur **vols implicites** (plutôt que prix) avec poids de liquidité :

$$\min_{\theta} \sum_i w_i (\sigma_{imp}^{model}(K_i, T_i; \theta) - \sigma_{imp}^{mkt}(K_i, T_i))^2.$$

Pourquoi vols ? Échelles comparables sur strikes/maturités et diagnostic direct du smile.

4.4.2 Contraintes et régularisation

- Bornes : $\kappa, \theta, v_0, \sigma_v > 0$, $\rho \in (-1, 1)$; (optionnel) Feller $2\kappa\theta \geq \sigma_v^2$.
- Multi-start + pénalisation douce (ex : ρ proche de -1) pour éviter les minima locaux absurdes.
- **Regulariser** dans T : pénaliser des variations trop rapides de paramètres par maturité (sinon overfit).

4.4.3 Complex log / « Heston trap »

La formule CF implique des logarithmes complexes : une mauvaise branche $\log(\cdot)$ crée des discontinuités $\Rightarrow$ prix instables. En entretien : citer qu'on utilise une implémentation **stable** (ex : « Little Heston Trap ») et qu'on teste la continuité en u .

4.5 Simulation (exotiques) : schémas qui tiennent

- **Heston** : Euler naïf peut rendre $v_t < 0$. Schémas standards : full truncation, QE (Andersen), ou exact (Broadie–Kaya, plus cher).
- **Jumps** : simuler $N_T \sim \text{Poisson}(\lambda T)$ puis sommer les tailles de saut ; travailler en log pour stabilité.
- **Variance reduction** : antithetic + control variate (prix BS) accélère fortement la calibration MC.

4.6 Tests / sanity checks (indispensables)

- $\varphi_T(0) = 1$; moments : $\varphi'_T(0)$ cohérent avec $\mathbb{E}[X_T]$ si disponible.
- Limites : $\lambda \rightarrow 0$ (retour diffusion), $\sigma_v \rightarrow 0$ (Heston $\rightarrow$ BS à vol quasi-constante).
- Prix vanilles : non négatif, décroissant et convexe en K , monotone en T .
- FFT : absence d'oscillations (repricing smooth) ; variation des prix stable en changeant (N, η) .

4.7 Pont vers pratique quant

- Calibration intraday : pré-calculs (grilles, discounts), cache des $\varphi(u)$, parallélisation.
- Risk : greeks par différences finies (complex-step) ou adjoint ; stress sur paramètres et smile.
- Model risk : valider sur exotiques simples (barrières) et sur différentes périodes (régimes).

Interview Pack — Partie VI (core)

Estimation (Kalman)

Table des matières

1	Kalman - théorie (espace-état, filtrage)	1
1.1	Avant-propos : filtrer un état latent (Kalman)	1
1.2	Pourquoi les filtres de Kalman en finance ?	2
1.3	Pré-requis : gaussiennes, conditionnement, projection L^2	3
1.4	Modèle espace d'états linéaire-gaussien	5
1.5	Filtrage bayésien : la récursion générale	6
1.6	Dérivation du filtre de Kalman (pas à pas)	6
1.7	Interprétations et dérivations alternatives (pour mieux expliquer)	8
1.8	Propriétés importantes à connaître	10
1.9	Mode microscope : conditionnement gaussien et dérivation du filtre	11
1.10	Pièges classiques / erreurs fréquentes	12
1.11	Checklist — savoir refaire sans regarder	12
2	Kalman - pratiques, vraisemblance, lissage et cas finance	13
2.1	Avant-propos : du filtre à la vraisemblance et au lissage (RTS)	13
2.2	Vraisemblance (via innovations) et estimation des paramètres	14
2.3	Lissage : estimer avec toute la série (RTS)	15
2.4	Exemples en finance quantitative (mise en modèle)	16
2.5	Extension : filtre de Kalman–Bucy (temps continu, optionnel)	17
2.6	Ouverture : volatilité stochastique et modèle de Heston	18
2.7	Synthèse : ce qu'un élève doit savoir refaire et expliquer	19
2.8	Identités matricielles utiles (annexe technique)	20
2.9	Preuve complète du conditionnement gaussien (annexe)	21
2.10	Mode microscope : vraisemblance, diagnostics et lissage	22
2.11	Pièges classiques / erreurs fréquentes	22
2.12	Checklist — savoir refaire sans regarder	22
3	Kalman en production : MLE/EM, robustesse, numérique	23
3.1	Idée centrale	23
3.2	Cadre mathématique (state-space)	23
3.3	Vraisemblance via innovations (clé en calibration)	23
3.4	Estimation des paramètres : MLE vs EM	23
3.5	Numérique : éviter la divergence	24
3.6	Robustesse marché (ce qui casse les hypothèses)	24
3.7	Implémentation (pseudo-code)	24
3.8	Tests / diagnostics (3–6 à connaître)	24
3.9	Pont vers pratique quant	24

4	Non-linéaire / non-gaussien : EKF, UKF, particules (interview-level)	25
4.1	Idée centrale	25
4.2	Modèles non linéaires	25
4.3	EKF (Extended Kalman Filter)	25
4.4	UKF (Unscented Kalman Filter)	25
4.5	Particle filter (SIR)	26
4.6	Quand l'utiliser en finance ?	26
4.7	Sanity checks	26
5	Kalman continu (Kalman-Bucy) : lien avec SDE et discrétisation	27
5.1	Idée centrale	27
5.2	Modèle linéaire en temps continu	27
5.3	Kalman-Bucy (forme compacte)	27
5.4	Discrétisation correcte : $F(\Delta t)$ et $Q(\Delta t)$	27
5.5	Applications finance (exemples typiques)	28
5.6	Sanity checks	28
6	Régimes & robustesse : switching Kalman, Student-t, missing data	29
6.1	Idée centrale	29
6.2	Switching state-space (HMM + Kalman)	29
6.3	Bruit robuste : Student- t (outliers)	29
6.4	Missing data / observations irrégulières	30
6.5	Identifiabilité (piège classique)	30
6.6	Implémentation : update de poids en log (stabilité)	30
6.7	Tests / diagnostics (3-6)	30
6.8	Pont vers pratique quant	30
7	Lissage (RTS), prédiction, EM : ce qu'on attend en entretien quant	31
7.1	Idée centrale	31
7.2	Cadre : RTS smoother (discret, linéaire gaussien)	31
7.3	Prédiction (forecast) : distribution	31
7.4	EM (Shumway-Stoffer) : updates fermés (cas simple)	31
7.5	Numérique : points durs	32
7.6	Tests / sanity checks	32
7.7	Pont vers pratique quant	32
8	State-space templates finance : levels, trends, OU, courbe (ultra-pratique)	33
8.1	Idée centrale	33
8.2	Template 1 : local level (random walk + noise)	33
8.3	Template 2 : local linear trend (niveau + pente)	33
8.4	Template 3 : OU discretisé proprement (mean-reversion)	33
8.5	Template 4 : courbe des taux (facteurs + observation yields)	33
8.6	Implémentation : 1D local level (numpy minimal)	34
8.7	Tests / sanity checks	34
8.8	Pont vers pratique quant	34

Chapitre 1

Kalman - théorie (espace-état, filtrage)

Idée centrale. Le filtre de Kalman est la solution fermée du problème « estimer un état latent en temps réel » en modèle linéaire-gaussien : récursions sur moyenne/covariance, gain optimal au sens L^2 .

Cadre mathématique.

- **État-espace.** $x_{t+1} = Ax_t + w_t$, $y_t = Cx_t + v_t$, avec $w_t \sim \mathcal{N}(0, Q)$, $v_t \sim \mathcal{N}(0, R)$.
- **Récursions.** Prédiction $(m_{t|t-1}, P_{t|t-1})$ puis update $(m_{t|t}, P_{t|t})$ via gain K_t .
- **Gain.** $K_t = P_{t|t-1}C^\top(CP_{t|t-1}C^\top + R)^{-1}$: coefficient de régression / projection L^2 .

Intuition marché / interprétation. Kalman sépare signal et bruit de manière quantitative et fournit une incertitude (covariance). Les échecs viennent de non-stationnarité, outliers, mauvaise spécification (Q/R), et dépendances non gaussiennes.

Implémentation.

- Implémenter en forme « Joseph » / Cholesky pour préserver PSD ; gérer données manquantes.
- Monitorer innovations : base des diagnostics et de la vraisemblance (chapitre pratique).

Tests / sanity checks.

- PSD : $P_{t|t} \succeq 0$ (eigenvalues ≥ 0) ; sinon instabilité numérique.
- Innovations : moyenne ≈ 0 , autocorr faible, variance compatible (whiteness).
- Dimensions : checks systématiques (compatibilité A, C, Q, R).

Pont vers pratique quant. Pont quant : estimation de facteurs (courbe, trend, beta), filtrage micro-structure, calibration via likelihood (innovations), et outils de production « online » (state estimation + uncertainty).

1.1 Avant-propos : filtrer un état latent (Kalman)

Après les chapitres de modélisation (pricing), on change de point de vue : en pratique, beaucoup de variables utiles sont **latentes** (volatilité instantanée, facteurs de courbe, bêta, tendance) et on n'observe que des proxies bruités. Le filtre de Kalman est le cadre canonique pour estimer un état latent en temps réel lorsque tout est linéaire-gaussien.

1.1.1 Objectifs pédagogiques

- Poser proprement le modèle espace d'états linéaire-gaussien (dynamique + observation).
- Dédire le filtre à partir du **conditionnement gaussien** : mise à jour des moyennes et covariances.
- Comprendre le gain de Kalman comme un coefficient de régression / projection L^2 .
- Lire l'équation de Riccati comme une récursion de covariance, et faire des checks de dimensions.

1.1.2 Pré-requis

- Algèbre linéaire : produits, transposée, matrices symétriques $\succeq 0$, inversion par blocs.
- Lois gaussiennes : moyenne/covariance et intuition du conditionnement (la preuve est donnée dans le chapitre).

1.1.3 Plan du chapitre

1. Pré-requis gaussien : conditionnement, projection, régression linéaire.
2. Modèle espace d'états et récursion bayésienne.
3. Filtre de Kalman : prédiction puis mise à jour (gain).
4. Propriétés : innovations, Riccati, formes numériquement stables.

Intuition de marché. Kalman est une brique « de production » : il tourne en ligne, fournit un estimateur et une incertitude (covariance), et permet de calculer une vraisemblance via les innovations (chapitre suivant), donc de calibrer des modèles état-espace par maximum de vraisemblance.

Résumé

Le filtre de Kalman est l'outil standard pour estimer, en temps réel, un état *latent* (non observé) d'un système à partir d'observations bruitées, lorsque la dynamique est **linéaire** et les bruits **gaussiens**. Ces notes construisent le filtre *from ground up* : rappels de gaussiennes multivariées et de projection L^2 , modèle espace d'états, puis dérivation complète des étapes *prediction* et *mise à jour* (gain de Kalman, innovations, équations de Riccati). On termine par les briques de pratique (vraisemblance, estimation de paramètres, lissage) et une ouverture vers la **volatilité stochastique** : comment poser le modèle de **Heston** en filtrage, pourquoi le filtre de Kalman n'est plus exact, et quelles approximations (EKF/UKF, filtres particuliers) sont utilisées en finance quantitative.

1.2 Pourquoi les filtres de Kalman en finance ?

1.2.1 Le motif : état latent, bruit de mesure, décisions en temps réel

En finance quantitative, on observe des séries temporelles : prix, rendements, taux, spreads, volatilités implicites, données de carnet d'ordres, etc. Pourtant, les quantités qui nous intéressent vraiment sont souvent **latentes** :

- une tendance (*trend*) ou un niveau fondamental,
- des facteurs de courbe de taux (niveau, pente, courbure),
- une **variance instantanée** (volatilité stochastique),
- des paramètres qui changent dans le temps (bêta de portefeuille, alpha),
- un signal contaminé par du bruit de microstructure.

Le filtrage répond à la question :

« Que puis-je estimer à la date t , à partir des observations jusqu'à t ? »

Le filtre de Kalman est la réponse *exacte* quand tout est linéaire et gaussien, et une base conceptuelle quand ce n'est plus le cas.

1.2.2 Filtrage, prédiction, lissage : trois problèmes à distinguer

On rencontre trois tâches proches mais différentes :

- **Filtrage** : estimer x_t sachant $y_{1:t}$ (inference *en ligne*),

- **Prédiction** : estimer x_{t+1} sachant $y_{1:t}$ (forecast),
- **Lissage** : estimer x_t sachant $y_{1:T}$ (inference *hors ligne*).

En trading, on filtre. En calibration/diagnostic, on lisse.

1.2.3 Pourquoi ça marche si bien : fermeture dans les gaussiennes

Le filtre de Kalman s'applique au modèle **espace d'états** :

- une **dynamique** pour l'état latent x_t ,
- une **équation d'observation** qui relie x_t à y_t .

Si ces deux relations sont linéaires et les bruits gaussiens, alors toutes les lois conditionnelles $p(x_t | y_{1:t})$ sont gaussiennes : on peut donc résumer l'information par **moyenne** et **covariance**.

Idée à retenir. Le filtre de Kalman = **Bayes séquentiel** + **conditionnement gaussien**. Les matrices ne sont que la traduction des « règles de conditionnement ».

1.3 Pré-requis : gaussiennes, conditionnement, projection L^2

1.3.1 Notations (moyennes et covariances)

On utilise :

- $x \in \mathbb{R}^n$ (état) et $y \in \mathbb{R}^m$ (observation),
- $\mu_x = \mathbb{E}[x]$ et $\Sigma_{xx} = \text{Cov}(x) = \mathbb{E}[(x - \mu_x)(x - \mu_x)^\top]$,
- $\Sigma_{xy} = \text{Cov}(x, y) = \mathbb{E}[(x - \mu_x)(y - \mu_y)^\top]$.

Rappel : Σ_{xx} est symétrique, positive semi-définie.

1.3.2 Gaussienne multivariée

Définition 1.1 (Gaussienne multivariée). Un vecteur aléatoire $z \in \mathbb{R}^d$ est *gaussien* si toute combinaison linéaire $a^\top z$ est gaussienne en dimension 1. On note $z \sim \mathcal{N}(\mu, \Sigma)$.

Remarque 1.1. Deux propriétés structurelles :

- (stabilité affine) si $z \sim \mathcal{N}(\mu, \Sigma)$ alors $Az + b$ est gaussien,
- une loi gaussienne est entièrement déterminée par (μ, Σ) .

1.3.3 Formule de conditionnement gaussien (le coeur du filtre)

Le filtre de Kalman se déduit d'une formule unique.

Théorème 1.1 (Conditionnement d'une gaussienne : formule bloc). *Soit*

$$\begin{pmatrix} x \\ y \end{pmatrix} \sim \mathcal{N}\left(\begin{pmatrix} \mu_x \\ \mu_y \end{pmatrix}, \begin{pmatrix} \Sigma_{xx} & \Sigma_{xy} \\ \Sigma_{yx} & \Sigma_{yy} \end{pmatrix}\right),$$

avec Σ_{yy} inversible. Alors :

$$x | y \sim \mathcal{N}(\mu_{x|y}, \Sigma_{x|y}),$$

où

$$\mu_{x|y} = \mu_x + \Sigma_{xy}\Sigma_{yy}^{-1}(y - \mu_y), \quad (1.1)$$

$$\Sigma_{x|y} = \Sigma_{xx} - \Sigma_{xy}\Sigma_{yy}^{-1}\Sigma_{yx}. \quad (1.2)$$

Remarque 1.2. La matrice $\Sigma_{xy}\Sigma_{yy}^{-1}$ est un **coefficient de régression** : elle dit comment corriger μ_x quand y prend une valeur inattendue.

1.3.3.1 Preuve complète (régression + indépendance gaussienne)

Idée / intuition. L'astuce est d'écrire x comme « partie expliquée par y » + « résidu ». Dans le monde gaussien, un résidu non corrélé à y est automatiquement indépendant de y : on obtient alors la loi conditionnelle en une ligne.

Lemme 1.1 (Gaussien : non-corrélé $\Rightarrow$ indépendant). *Si (u, v) est un vecteur gaussien (conjointement) et si $\text{Cov}(u, v) = 0$, alors u et v sont indépendants.*

Démonstration. Comme (u, v) est gaussien, toute combinaison linéaire $a^\top u + b^\top v$ est gaussienne. L'hypothèse $\text{Cov}(u, v) = 0$ implique que la matrice de covariance de (u, v) est *bloc diagonale*. Une gaussienne de covariance bloc diagonale a une densité qui se factorise en produit des densités marginales, d'où l'indépendance. $\square$

Démonstration détaillée. On part de l'écriture du théorème 1.1. On commence par se ramener au cas centré.

Étape 1: Recentrage. Posons $x' := x - \mu_x$ et $y' := y - \mu_y$. Alors (x', y') est gaussien centré avec la même covariance par blocs $(\Sigma_{xx}, \Sigma_{xy}, \Sigma_{yy})$. On se ramène donc au cas $\mu_x = \mu_y = 0$; une fois ce cas traité, on réajoute les moyennes à la fin.

Étape 2: Meilleur prédicteur linéaire. Posons

$$G := \Sigma_{xy} \Sigma_{yy}^{-1} \quad (\Sigma_{yy} \text{ inversible}).$$

On définit le résidu (erreur de prédiction)

$$\varepsilon := x - Gy.$$

Étape 3: Le résidu est décorrélié de y . En utilisant la linéarité de la covariance,

$$\text{Cov}(\varepsilon, y) = \text{Cov}(x - Gy, y) = \Sigma_{xy} - G\Sigma_{yy} = \Sigma_{xy} - \Sigma_{xy} \Sigma_{yy}^{-1} \Sigma_{yy} = 0.$$

Étape 4: Donc ε est indépendant de y . Comme (x, y) est gaussien, tout couple linéairement transformé l'est aussi ; en particulier (ε, y) est conjointement gaussien. Par le lemme 1.1, ε et y sont indépendants.

Étape 5: Identifier la loi conditionnelle. Comme $x = Gy + \varepsilon$ et que ε est indépendant de y , conditionner par y revient à figer Gy et laisser ε inchangé :

$$x \mid y = Gy + \varepsilon, \quad \text{avec } \varepsilon \sim \mathcal{N}(0, \text{Cov}(\varepsilon)) \text{ et } \varepsilon \perp y.$$

Ainsi $x \mid y$ est gaussien de moyenne Gy et de covariance $\text{Cov}(\varepsilon)$.

Étape 6: Calculer la covariance conditionnelle. On a

$$\text{Cov}(\varepsilon) = \text{Cov}(x - Gy) = \Sigma_{xx} - G\Sigma_{yx} - \Sigma_{xy}G^\top + G\Sigma_{yy}G^\top.$$

En remplaçant $G = \Sigma_{xy} \Sigma_{yy}^{-1}$ et en simplifiant, les termes se réduisent en

$$\text{Cov}(\varepsilon) = \Sigma_{xx} - \Sigma_{xy} \Sigma_{yy}^{-1} \Sigma_{yx},$$

qui est exactement (1.2).

Étape 7: Remettre les moyennes. En revenant à $x' = x - \mu_x$, $y' = y - \mu_y$, on obtient

$$\mathbb{E}[x \mid y] = \mu_x + G(y - \mu_y),$$

soit (1.1).

Piège classique. En numérique, on ne calcule jamais Σ_{yy}^{-1} à la main : on résout des systèmes linéaires (Cholesky) et on surveille le conditionnement de Σ_{yy} . Les instabilités viennent souvent de l'inversion explicite, pas des formules.

1.3.4 Projection L^2 : « meilleur estimateur »

En filtrage, le critère canonique est l'erreur quadratique moyenne :

$$\hat{x} = \operatorname{argmin}_{g(Y)} \mathbb{E}[\|x - g(Y)\|^2].$$

Théorème 1.2 (Conditionnelle comme projection). *Soient x de carré intégrable et $\mathcal{G}$ une tribu (information). Alors*

$$\mathbb{E}[x \mid \mathcal{G}]$$

est l'unique (p.s.) minimiseur de $\mathbb{E}[\|x - Z\|^2]$ parmi les Z $\mathcal{G}$ -mesurables.

Remarque 1.3. Interprétation : $\mathbb{E}[x \mid \mathcal{G}]$ est la **projection orthogonale** de x sur l'espace des variables $\mathcal{G}$ -mesurables (dans L^2).

1.3.5 Régression linéaire : le meilleur estimateur linéaire

On peut aussi chercher le meilleur estimateur **affine** de x en fonction de y :

$$\hat{x} = a + Gy.$$

En minimisant $\mathbb{E}[\|x - (a + Gy)\|^2]$, on obtient :

$$G^* = \Sigma_{xy} \Sigma_{yy}^{-1}, \quad a^* = \mu_x - G^* \mu_y.$$

Si (x, y) est conjointement gaussien, le meilleur estimateur (au sens MSE) est automatiquement affine : cela redonne (1.1).

Deux portes vers Kalman.

- **Bayes** : on propage et on conditionne des gaussiennes.
- **Moindres carrés** : on calcule un meilleur prédicteur linéaire.

Les deux dérivations mènent aux mêmes formules ; il faut connaître les deux.

1.4 Modèle espace d'états linéaire-gaussien

1.4.1 Le modèle (forme générale)

On travaille en temps discret $t = 0, 1, 2, \dots$

Définition 1.2 (Modèle linéaire-gaussien). On dit que (x_t, y_t) suit un modèle espace d'états linéaire-gaussien si :

$$x_t = A_t x_{t-1} + b_t + w_t, \tag{1.3}$$

$$y_t = H_t x_t + c_t + v_t, \tag{1.4}$$

où $x_t \in \mathbb{R}^n$ est l'état latent, $y_t \in \mathbb{R}^m$ l'observation, et :

- $w_t \sim \mathcal{N}(0, Q_t)$ (bruit de processus),
- $v_t \sim \mathcal{N}(0, R_t)$ (bruit d'observation),
- (w_t) et (v_t) sont indépendants dans le temps et indépendants l'un de l'autre,
- $x_0 \sim \mathcal{N}(m_0, P_0)$.

Remarque 1.4. On peut ajouter une entrée u_{t-1} : $x_t = A_t x_{t-1} + B_t u_{t-1} + w_t$. On la laisse de côté pour alléger, mais les formules se modifient immédiatement.

1.4.2 Information disponible et notations

On note $y_{1:t} = (y_1, \dots, y_t)$ et $\mathcal{Y}_t = \sigma(y_{1:t})$. On veut calculer :

$$m_{t|t} := \mathbb{E}[x_t | \mathcal{Y}_t], \quad P_{t|t} := \text{Cov}(x_t | \mathcal{Y}_t).$$

Et aussi les quantités de prédiction :

$$m_{t|t-1} := \mathbb{E}[x_t | \mathcal{Y}_{t-1}], \quad P_{t|t-1} := \text{Cov}(x_t | \mathcal{Y}_{t-1}).$$

1.5 Filtrage bayésien : la récursion générale

1.5.1 Deux étapes : prediction puis mise à jour

Sans hypothèses particulières, le filtrage est une application directe de Bayes et de la propriété de Markov de l'état.

(i) **Prediction.** On passe de la loi filtrée à $t-1$ à la loi *a priori* à t :

$$p(x_t | \mathcal{Y}_{t-1}) = \int p(x_t | x_{t-1}) p(x_{t-1} | \mathcal{Y}_{t-1}) dx_{t-1}.$$

(ii) **Mise à jour (assimilation de y_t).** On incorpore l'observation via Bayes :

$$p(x_t | \mathcal{Y}_t) \propto p(y_t | x_t) p(x_t | \mathcal{Y}_{t-1}).$$

Remarque 1.5. Dans le cas général (non linéaire/non gaussien), ces distributions n'ont pas de forme fermée : la dimension augmente, les intégrales deviennent inaccessibles, et l'on doit approcher (EKF/UKF, particules, etc.).

1.5.2 Ce qui se ferme dans le cas linéaire-gaussien

Dans le modèle (1.3)–(1.4), on a :

$$p(x_0) = \mathcal{N}(m_0, P_0), \quad p(x_t | x_{t-1}) = \mathcal{N}(A_t x_{t-1} + b_t, Q_t), \quad p(y_t | x_t) = \mathcal{N}(H_t x_t + c_t, R_t).$$

Par stabilité des gaussiennes :

- l'étape **prediction** transforme une gaussienne en gaussienne (transformation affine + bruit gaussien),
- l'étape **mise à jour** conditionne une gaussienne conjointe (théorème 1.1).

Ainsi, on ne propage que (m, P) .

1.6 Dérivation du filtre de Kalman (pas à pas)

1.6.1 Hypothèse d'induction à la date $t-1$

On suppose acquis :

$$x_{t-1} | \mathcal{Y}_{t-1} \sim \mathcal{N}(m_{t-1|t-1}, P_{t-1|t-1}).$$

Objectif : calculer successivement $x_t | \mathcal{Y}_{t-1}$ puis $x_t | \mathcal{Y}_t$.

1.6.2 Étape 1 : prediction (propagation de la dynamique)

Partant de (1.3),

$$x_t = A_t x_{t-1} + b_t + w_t, \quad w_t \sim \mathcal{N}(0, Q_t).$$

Proposition 1.1 (Formules de prediction). *Sous (1.3), on a :*

$$m_{t|t-1} = A_t m_{t-1|t-1} + b_t, \quad (1.5)$$

$$P_{t|t-1} = A_t P_{t-1|t-1} A_t^\top + Q_t. \quad (1.6)$$

Démonstration. On prend l'espérance conditionnelle sachant $\mathcal{Y}_{t-1}$:

$$\mathbb{E}[x_t | \mathcal{Y}_{t-1}] = A_t \mathbb{E}[x_{t-1} | \mathcal{Y}_{t-1}] + b_t + \mathbb{E}[w_t] = A_t m_{t-1|t-1} + b_t,$$

car w_t est centré et indépendant du passé. Pour la covariance, écrire

$$x_t - m_{t|t-1} = A_t(x_{t-1} - m_{t-1|t-1}) + w_t,$$

puis utiliser $\text{Cov}(Au + w) = A \text{Cov}(u) A^\top + \text{Cov}(w)$, et l'annulation du terme croisé (indépendance). $\square$

Lecture financière. Q_t contrôle à quelle vitesse l'état est autorisé à *bouger* (incertitude de modèle). Plus Q_t est grand, plus la prédiction devient incertaine, et plus le filtre sera réactif à l'observation.

1.6.3 Étape 2 : mise à jour (assimiler l'observation y_t)

On observe y_t via (1.4) :

$$y_t = H_t x_t + c_t + v_t, \quad v_t \sim \mathcal{N}(0, R_t).$$

On veut la loi de x_t sachant $\mathcal{Y}_t = \sigma(y_{1:t})$.

1.6.3.1 2.1. Observation prédite et innovation

On définit l'observation prédite :

$$\hat{y}_{t|t-1} := \mathbb{E}[y_t | \mathcal{Y}_{t-1}] = H_t m_{t|t-1} + c_t. \quad (1.7)$$

et l'**innovation** (ou résidu) :

$$\tilde{y}_t := y_t - \hat{y}_{t|t-1}. \quad (1.8)$$

Intuition : $\tilde{y}_t$ mesure la partie de y_t **non expliquée** par la prédiction.

1.6.3.2 2.2. Variance de l'innovation

En utilisant $y_t - \hat{y}_{t|t-1} = H_t(x_t - m_{t|t-1}) + v_t$, on obtient

$$S_t := \text{Cov}(\tilde{y}_t | \mathcal{Y}_{t-1}) = H_t P_{t|t-1} H_t^\top + R_t. \quad (1.9)$$

La matrice S_t est parfois appelée *innovation covariance*.

1.6.3.3 2.3. Covariance croisée état–innovation

Toujours conditionnellement à $\mathcal{Y}_{t-1}$:

$$\text{Cov}(x_t, \tilde{y}_t | \mathcal{Y}_{t-1}) = P_{t|t-1} H_t^\top. \quad (1.10)$$

1.6.3.4 2.4. Conditionnement gaussien $\Rightarrow$ gain de Kalman

Le vecteur

$$\begin{pmatrix} x_t \\ y_t \end{pmatrix} \Big| \mathcal{Y}_{t-1}$$

est gaussien (affinité + bruit). On applique donc le théorème 1.1 avec

$$\Sigma_{xx} = P_{t|t-1}, \quad \Sigma_{yy} = S_t, \quad \Sigma_{xy} = P_{t|t-1} H_t^\top.$$

Théorème 1.3 (Mise à jour de Kalman). *Supposons S_t inversible. Le gain de Kalman est*

$$K_t := P_{t|t-1} H_t^\top S_t^{-1}. \quad (1.11)$$

Alors la loi filtrée est

$$x_t | \mathcal{Y}_t \sim \mathcal{N}(m_{t|t}, P_{t|t}),$$

avec

$$m_{t|t} = m_{t|t-1} + K_t (y_t - \hat{y}_{t|t-1}) = m_{t|t-1} + K_t \tilde{y}_t, \quad (1.12)$$

$$P_{t|t} = P_{t|t-1} - K_t S_t K_t^\top. \quad (1.13)$$

Remarque 1.6 (Forme de Joseph). On écrit souvent $P_{t|t} = (\text{Id} - K_t H_t) P_{t|t-1}$, mais cette formule peut accumuler des erreurs numériques (perte de symétrie/positivité). La forme de Joseph

$$P_{t|t} = (\text{Id} - K_t H_t) P_{t|t-1} (\text{Id} - K_t H_t)^\top + K_t R_t K_t^\top \quad (1.14)$$

est préférable en pratique.

Lecture financière. Le gain K_t arbitre entre « confiance dans le modèle » ($P_{t|t-1}$ petit) et « confiance dans l'observation » (R_t petit). C'est l'analogie multivarié d'une moyenne pondérée.

Algorithme (filtre de Kalman).

1. **Initialisation** : $m_{0|0} = m_0$, $P_{0|0} = P_0$.
2. Pour $t = 1, 2, \dots$:
 - (a) **Prediction** : (1.5)–(1.6).
 - (b) **Innovation** : $\tilde{y}_t = y_t - (H_t m_{t|t-1} + c_t)$, $S_t = H_t P_{t|t-1} H_t^\top + R_t$.
 - (c) **Gain** : $K_t = P_{t|t-1} H_t^\top S_t^{-1}$.
 - (d) **Update** : $m_{t|t} = m_{t|t-1} + K_t \tilde{y}_t$ et $P_{t|t}$ via (1.13) (ou (1.14)).

1.7 Interprétations et dérivations alternatives (pour mieux expliquer)

1.7.1 Mise à jour comme meilleur estimateur linéaire (moindres carrés)

Une manière très pédagogique d'expliquer le filtre est de dire :

« On part de la meilleure prédiction $m_{t|t-1}$, puis on la corrige en fonction du résidu $\tilde{y}_t$; on choisit la correction pour minimiser l'erreur quadratique. »

On cherche donc un estimateur de la forme

$$\hat{x}_t = m_{t|t-1} + G_t \tilde{y}_t,$$

et on veut minimiser l'erreur conditionnelle

$$G_t^* = \operatorname{argmin}_{G_t} \mathbb{E}[\|x_t - \hat{x}_t\|^2 | \mathcal{Y}_{t-1}].$$

Proposition 1.2 (Le minimiseur est le gain de Kalman). *Le minimiseur est $G_t^* = K_t$ donné par (1.11).*

Preuve détaillée. On travaille conditionnellement à $\mathcal{Y}_{t-1}$, c'est-à-dire en considérant que toute quantité $\mathcal{Y}_{t-1}$ -mesurable est « figée ».

1) Écrire l'erreur en fonction de G_t . Par définition, l'erreur de prédiction est $e_t := x_t - m_{t|t-1}$. Le modèle d'observation (1.2) donne $y_t - (H_t m_{t|t-1} + c_t) = H_t x_t + c_t + v_t - (H_t m_{t|t-1} + c_t) = H_t e_t + v_t$, donc

$$\tilde{y}_t = H_t e_t + v_t. \quad (1.15)$$

L'estimateur candidat est $\hat{x}_t = m_{t|t-1} + G_t \tilde{y}_t$, donc l'erreur d'estimation vaut

$$x_t - \hat{x}_t = e_t - G_t \tilde{y}_t = (\text{Id} - G_t H_t) e_t - G_t v_t, \quad (1.16)$$

en utilisant (1.15).

2) Reformuler le critère : minimiser une quantité quadratique. On veut minimiser

$$J(G_t) := \mathbb{E}[\|x_t - \hat{x}_t\|^2 \mid \mathcal{Y}_{t-1}] = \mathbb{E}[\|e_t - G_t \tilde{y}_t\|^2 \mid \mathcal{Y}_{t-1}].$$

Le critère J est un polynôme quadratique en les coefficients de G_t (parce que l'erreur (1.16) est affine en G_t). En particulier, si $R_t \succ 0$ alors J est strictement convexe et le minimiseur est unique.

3) Principe d'orthogonalité (outil). Dans un espace de Hilbert (ici L^2 conditionnellement à $\mathcal{Y}_{t-1}$), le meilleur estimateur linéaire est caractérisé par l'orthogonalité du résidu : au minimum, l'erreur $e_t - G_t \tilde{y}_t$ doit être orthogonale à tout vecteur de la forme $A \tilde{y}_t$. En particulier, on impose la condition nécessaire (et en fait suffisante ici)

$$\mathbb{E}[(e_t - G_t \tilde{y}_t) \tilde{y}_t^\top \mid \mathcal{Y}_{t-1}] = 0. \quad (1.17)$$

4) Résoudre (1.17). En développant,

$$\mathbb{E}[e_t \tilde{y}_t^\top \mid \mathcal{Y}_{t-1}] - G_t \mathbb{E}[\tilde{y}_t \tilde{y}_t^\top \mid \mathcal{Y}_{t-1}] = 0,$$

donc, si la matrice d'innovation $S_t := \mathbb{E}[\tilde{y}_t \tilde{y}_t^\top \mid \mathcal{Y}_{t-1}]$ est inversible,

$$G_t = \mathbb{E}[e_t \tilde{y}_t^\top \mid \mathcal{Y}_{t-1}] S_t^{-1}. \quad (1.18)$$

Or, avec (1.15),

$$\mathbb{E}[\tilde{y}_t \tilde{y}_t^\top \mid \mathcal{Y}_{t-1}] = \mathbb{E}[(H_t e_t + v_t)(H_t e_t + v_t)^\top \mid \mathcal{Y}_{t-1}].$$

En développant le produit,

$$\mathbb{E}[\tilde{y}_t \tilde{y}_t^\top \mid \mathcal{Y}_{t-1}] = H_t \mathbb{E}[e_t e_t^\top \mid \mathcal{Y}_{t-1}] H_t^\top + H_t \mathbb{E}[e_t v_t^\top \mid \mathcal{Y}_{t-1}] + \mathbb{E}[v_t e_t^\top \mid \mathcal{Y}_{t-1}] H_t^\top + \mathbb{E}[v_t v_t^\top \mid \mathcal{Y}_{t-1}].$$

Sous les hypothèses du modèle (bruits indépendants, v_t indépendant de $\mathcal{Y}_{t-1}$ et de e_t conditionnellement à $\mathcal{Y}_{t-1}$), les termes croisés s'annulent : $\mathbb{E}[e_t v_t^\top \mid \mathcal{Y}_{t-1}] = 0$ et $\mathbb{E}[v_t e_t^\top \mid \mathcal{Y}_{t-1}] = 0$. De plus, $\mathbb{E}[e_t e_t^\top \mid \mathcal{Y}_{t-1}] = P_{t|t-1}$ et $\mathbb{E}[v_t v_t^\top \mid \mathcal{Y}_{t-1}] = R_t$. On obtient bien

$$S_t = H_t P_{t|t-1} H_t^\top + R_t, \quad (1.19)$$

qui est définie positive dès que $R_t \succ 0$ (donc inversible).

Il reste à calculer $\mathbb{E}[e_t \tilde{y}_t^\top \mid \mathcal{Y}_{t-1}]$:

$$\mathbb{E}[e_t \tilde{y}_t^\top \mid \mathcal{Y}_{t-1}] = \mathbb{E}[e_t (H_t e_t + v_t)^\top \mid \mathcal{Y}_{t-1}] = \mathbb{E}[e_t e_t^\top \mid \mathcal{Y}_{t-1}] H_t^\top + \mathbb{E}[e_t v_t^\top \mid \mathcal{Y}_{t-1}].$$

Le second terme est nul par indépendance, donc

$$\mathbb{E}[e_t \tilde{y}_t^\top \mid \mathcal{Y}_{t-1}] = P_{t|t-1} H_t^\top,$$

ce qui est exactement la covariance croisée état-innovation annoncée en (1.10). En injectant (1.19) et (1.10) dans (1.18), on obtient

$$G_t = P_{t|t-1} H_t^\top (H_t P_{t|t-1} H_t^\top + R_t)^{-1},$$

qui est exactement le gain de Kalman (1.11). $\square$

1.7.2 Vue MAP : posterior gaussien = minimisation quadratique

Dans le modèle statique à une date ($x \sim \mathcal{N}(m, P)$, $y = Hx + v$, $v \sim \mathcal{N}(0, R)$), le posterior vérifie

$$p(x | y) \propto \exp\left(-\frac{1}{2}(\|x - m\|_{P^{-1}}^2 + \|y - Hx\|_{R^{-1}}^2)\right), \quad \|u\|_M^2 := u^\top M u.$$

Ainsi la moyenne a posteriori (qui coïncide avec le MAP en gaussien) minimise un compromis :

- rester proche du prior (terme $\|x - m\|_{P^{-1}}^2$),
- expliquer l'observation (terme $\|y - Hx\|_{R^{-1}}^2$).

Cette lecture est très utile pour expliquer Kalman à un public « optimisation ».

1.7.3 Cas scalaire : une moyenne pondérée explicite

Supposons $n = m = 1$, $H_t = 1$ et $c_t = 0$. Alors

$$K_t = \frac{P_{t|t-1}}{P_{t|t-1} + R_t} \in (0, 1), \quad m_{t|t} = (1 - K_t)m_{t|t-1} + K_t y_t.$$

On peut littéralement dire : « on fait la moyenne entre prédiction et observation, avec un poids qui dépend des incertitudes ».

1.8 Propriétés importantes à connaître

1.8.1 Innovations : gaussiennes, centrées, (souvent) blanches

Sous le modèle (1.2), l'innovation $\tilde{y}_t$ vérifie :

$$\tilde{y}_t | \mathcal{Y}_{t-1} \sim \mathcal{N}(0, S_t), \quad S_t = H_t P_{t|t-1} H_t^\top + R_t.$$

Cette propriété est la base de la vraisemblance par innovations (section 2.2).

Remarque 1.7 (Pourquoi parle-t-on de « blanc » ?). Dans un modèle linéaire-gaussien bien spécifié, la suite des innovations est non corrélée (et donc indépendante car gaussienne). Cela signifie que *tout* ce que y_t apporte de nouveau par rapport au passé est capturé par $\tilde{y}_t$.

1.8.2 Équation de Riccati : dynamique de la covariance

La covariance suit une récurrence non linéaire (Riccati). On peut la voir ainsi :

- $P_{t|t-1} = A_t P_{t-1|t-1} A_t^\top + Q_t$ (« incertitude après propagation »),
- $P_{t|t} = P_{t|t-1} - K_t S_t K_t^\top$ (« réduction par l'observation »).

Le terme $K_t S_t K_t^\top$ est positif semi-défini : l'observation ne peut qu'**réduire** l'incertitude (au sens Loewner), si le modèle est cohérent.

1.8.3 Régime stationnaire : gain constant et Riccati algébrique

Si le système est **temps-invariant** ($A_t = A$, $H_t = H$, $Q_t = Q$, $R_t = R$), on observe souvent une convergence :

$$P_{t|t-1} \rightarrow P_\infty, \quad K_t \rightarrow K_\infty,$$

où P_∞ résout une **équation de Riccati algébrique**. Ce régime stationnaire est très utile en pratique (filtre « à gain constant »).

Remarque 1.8 (Conditions (culture générale)). La convergence n'est pas automatique ; elle dépend de propriétés d'observabilité/déteçtabilité et de stabilisabilité. Au niveau M1, on retient l'intuition suivante : « si le système est raisonnablement observable et stable, le gain se stabilise ».

1.8.4 Forme informationnelle (precision) et identité de Woodbury

On peut mettre à jour la **precision** $J_{t|t} := P_{t|t}^{-1}$ plutôt que $P_{t|t}$. En un pas (modèle statique), on a :

$$P_{t|t}^{-1} = P_{t|t-1}^{-1} + H_t^\top R_t^{-1} H_t, \quad P_{t|t}^{-1} m_{t|t} = P_{t|t-1}^{-1} m_{t|t-1} + H_t^\top R_t^{-1} (y_t - c_t).$$

Ces formules sont équivalentes à (1.12)–(1.13) via l'identité de Woodbury. Elles sont utiles quand P est grande mais creuse, ou quand on veut exploiter des solveurs linéaires.

1.8.5 Données manquantes et observations partielles

Un avantage pratique du filtre de Kalman : il gère naturellement :

- des observations manquantes (on saute la mise à jour à la date concernée),
- des sous-vecteurs observés (on adapte H_t , R_t à la dimension observée).

On obtient un filtrage robuste sans bricolage : la probabilité conditionnelle donne la bonne règle.

1.8.6 Complexité et numérique : ce qu'on surveille

Dans un filtre direct, l'opération coûteuse est l'inversion de $S_t \in \mathbb{R}^{m \times m}$.

- Si m est petit : inversion directe (ou factorisation de Cholesky) suffit.
- Si m est grand : formes informationnelles, solveurs, ou réduction de dimension.
- Stabilité : préférer (1.14) et des factorisations symétriques.

1.9 Mode microscope : conditionnement gaussien et dérivation du filtre

1.9.1 Conditionnement gaussien (complétion du carré)

Soit le vecteur joint (x, y) gaussien :

$$\begin{pmatrix} x \\ y \end{pmatrix} \sim \mathcal{N}\left(\begin{pmatrix} m_x \\ m_y \end{pmatrix}, \begin{pmatrix} \Sigma_{xx} & \Sigma_{xy} \\ \Sigma_{yx} & \Sigma_{yy} \end{pmatrix}\right).$$

Alors la loi conditionnelle $x \mid y$ est gaussienne avec

$$\mathbb{E}[x \mid y] = m_x + \Sigma_{xy} \Sigma_{yy}^{-1} (y - m_y), \quad \text{Cov}(x \mid y) = \Sigma_{xx} - \Sigma_{xy} \Sigma_{yy}^{-1} \Sigma_{yx}. \quad (1.20)$$

Une preuve standard consiste à écrire la densité jointe, regrouper les termes en x et compléter le carré.

Sanity check. La covariance conditionnelle est Σ_{xx} moins un terme PSD : l'information y réduit l'incertitude (ou la laisse inchangée).

1.9.2 Dérivation du filtre (linéaire-gaussien)

Modèle espace-état discret (notation classique) :

$$x_t = A x_{t-1} + w_t, \quad w_t \sim \mathcal{N}(0, Q), \quad y_t = H x_t + v_t, \quad v_t \sim \mathcal{N}(0, R),$$

avec indépendances usuelles.

Prédiction. Si $x_{t-1} \mid y_{1:t-1} \sim \mathcal{N}(m_{t-1}, P_{t-1})$, alors

$$m_{t|t-1} = A m_{t-1}, \quad P_{t|t-1} = A P_{t-1} A^\top + Q.$$

Mise à jour. On considère le joint (x_t, y_t) conditionnellement à $y_{1:t-1}$:

$$\begin{pmatrix} x_t \\ y_t \end{pmatrix} \Big| y_{1:t-1} \sim \mathcal{N} \left(\begin{pmatrix} m_{t|t-1} \\ H m_{t|t-1} \end{pmatrix}, \begin{pmatrix} P_{t|t-1} & P_{t|t-1} H^\top \\ H P_{t|t-1} & H P_{t|t-1} H^\top + R \end{pmatrix} \right).$$

En appliquant (1.20) :

$$\begin{aligned} S_t &:= H P_{t|t-1} H^\top + R, & K_t &:= P_{t|t-1} H^\top S_t^{-1}, \\ m_t &= m_{t|t-1} + K_t (y_t - H m_{t|t-1}), & P_t &= P_{t|t-1} - K_t S_t K_t^\top. \end{aligned}$$

Intuition de marché. Le gain K_t arbitre entre *modèle* (prédiction) et *donnée* (observation) : si R est grand (bruit d'observation), on fait confiance au modèle ; si Q est grand (modèle incertain), on suit davantage la donnée.

1.10 Pièges classiques / erreurs fréquentes

- Inverser S_t de façon instable : préférer une factorisation (Cholesky) si possible.
- Perdre la symétrie/PSD de P_t en numérique : symétriser, utiliser la forme Joseph.
- Confondre bruits Q (dynamique) et R (observation) : effets opposés sur K_t .

1.11 Checklist — savoir refaire sans regarder

- Écrire le modèle espace-état et les hypothèses gaussiennes.
- Démontrer le conditionnement gaussien et en déduire K_t .
- Écrire les étapes prédiction/mise à jour (moyenne et covariance) avec dimensions.
- Donner l'intuition du gain de Kalman et du rôle de Q, R .

Chapitre 2

Kalman - pratiques, vraisemblance, lissage et cas finance

Idée centrale. Passer du filtre (online) à la production : log-vraisemblance via innovations, lissage RTS (offline), et estimation/calibration des paramètres (Q,R, etc.) avec stabilité numérique.

Cadre mathématique.

- **Innovations.** $e_t = y_t - C m_{t|t-1}$, $S_t = C P_{t|t-1} C^\top + R$; base de la log-likelihood.
- **Log-vraisemblance.** Somme de termes $\log \det S_t + \text{Mahalanobis } e_t^\top S_t^{-1} e_t$.
- **Lissage.** RTS : utiliser $p(x_t | y_{1:T})$ avec un passage backward (gain de lissage).

Intuition marché / interprétation. En finance, on veut souvent une estimation « ex post » (lissage) et des paramètres calibrés (trend, facteurs de courbe). Les pièges sont l'instabilité numérique, les outliers, et la non-stationnarité (Q/R variables).

Implémentation.

- Implémenter avec Cholesky (pas d'inversion explicite), symétriser les covariances, gérer missing data/outliers.
- Estimation : EM (si utilisé) ou optimisation de likelihood ; régulariser pour éviter sur-ajustement.

Tests / sanity checks.

- Innovations $\approx$ blanches (ACF faible) ; résidus normalisés $\approx \mathcal{N}(0, 1)$ en linéaire-gaussien.
- Likelihood : sensibilité aux paramètres stable ; pas de « pics » instables (diagnostic de mauvais scaling).
- PSD : covariances restent $\succeq 0$; sinon bug numérique.

Pont vers pratique quant. Pont quant : estimation de tendance/beta dynamique, calibration de modèles état-espace (taux, vol), diagnostics de qualité de signal, et intégration en pipeline (online + offline).

2.1 Avant-propos : du filtre à la vraisemblance et au lissage (RTS)

Le filtre de Kalman donne $p(x_t | y_{1:t})$: une estimation *en ligne* (temps réel). Dans beaucoup d'applications finance, on veut aussi :

- calibrer des paramètres par maximum de vraisemblance ;
- reconstruire un état *a posteriori* avec toutes les données (lissage).

Ce chapitre est le pont « théorie $\rightarrow$ pratique ».

2.1.1 Objectifs pédagogiques

- Calculer la log-vraisemblance à partir des innovations (un passage du filtre).

- Comprendre le lisseur RTS : passage arrière, gain de lissage, intuition.
- Discuter les points de robustesse numérique (Cholesky, stabilité des covariances, initialisation).
- Voir des mises en modèle finance : tendance, bêta dynamique, facteurs de courbe.

2.1.2 Pré-requis

- Chapitre chapitre 1 : filtre de Kalman et conditionnement gaussien.
- Notions numériques : résolution de systèmes linéaires, déterminant via Cholesky.

2.1.3 Plan du chapitre

1. Vraisemblance : innovations, log-déterminants, Mahalanobis.
2. Lissage : RTS (moyennes/covariances) et intuition.
3. Exemples finance et ouvertures (non-linéaire/non-gaussien).

Sanity check. Une covariance doit rester symétrique et $\succeq 0$. En implémentation, on symétrise (à tolérance) et on évite les inversions explicites : Cholesky si possible.

2.2 Vraisemblance (via innovations) et estimation des paramètres

2.2.1 Vraisemblance conditionnelle à une date

Conditionnellement à $\mathcal{Y}_{t-1}$, on a

$$y_t \mid \mathcal{Y}_{t-1} \sim \mathcal{N}(\hat{y}_{t|t-1}, S_t),$$

où $\hat{y}_{t|t-1} = H_t m_{t|t-1} + c_t$ et S_t est donné par (1.9). Donc

$$p(y_t \mid y_{1:t-1}) = \frac{1}{(2\pi)^{m/2} \det(S_t)^{1/2}} \exp\left(-\frac{1}{2} \tilde{y}_t^\top S_t^{-1} \tilde{y}_t\right).$$

Idée / intuition. La quantité $\tilde{y}_t := y_t - \hat{y}_{t|t-1}$ est l'**innovation** : l'erreur de prédiction de l'observation à un pas. Le filtre de Kalman fournit exactement sa loi conditionnelle, donc on obtient une vraisemblance *sans* intégrer sur les états latents.

Interprétation marché. En économétrie/finance empirique, c'est ce qui rend ces modèles attractifs : on peut faire du maximum de vraisemblance sur des centaines de milliers d'observations à coût linéaire, parce qu'on ne manipule que des innovations gaussiennes et leurs covariances.

Méthode. Calcul stable en pratique : on factorise S_t par Cholesky $S_t = LL^\top$. Alors

$$\log \det(S_t) = 2 \sum_i \log L_{ii}, \quad \tilde{y}_t^\top S_t^{-1} \tilde{y}_t = \|L^{-1} \tilde{y}_t\|^2.$$

On évite ainsi de former S_t^{-1} explicitement.

2.2.2 Log-vraisemblance totale

En chaînant :

$$\ell(\theta) = \log p(y_{1:T}; \theta) = \sum_{t=1}^T \log p(y_t \mid y_{1:t-1}; \theta), \quad (2.1)$$

ce qui donne la forme explicite :

$$\ell(\theta) = -\frac{1}{2} \sum_{t=1}^T \left(m \log(2\pi) + \log \det(S_t) + \tilde{y}_t^\top S_t^{-1} \tilde{y}_t \right). \quad (2.2)$$

Remarque 2.1. Point-clé : on calcule $\ell(\theta)$ en **un passage** du filtre. C'est l'un des grands intérêts des modèles espace d'états en économétrie : estimation par ML à coût linéaire en T .

2.2.3 EM (aperçu) : quand ML direct est délicat

Si l'optimisation directe de (2.2) est instable, on peut utiliser **EM** :

- E-step : calculer des espérances conditionnelles sur les x_t données $y_{1:T}$ (via lissage),
- M-step : mettre à jour A, Q, H, R par des formules fermées (type moindres carrés/covariances).

EM est très standard pour les modèles linéaires-gaussiens.

2.3 Lissage : estimer avec toute la série (RTS)

2.3.1 Filtrage vs lissage

Le filtrage donne $p(x_t | y_{1:t})$. Le lissage cherche

$$p(x_t | y_{1:T}) \quad (T \geq t),$$

donc il utilise aussi des observations *futures* par rapport à t .

2.3.2 Le lisseur RTS : formules

On suppose que l'on a stocké, pour $t = 0, \dots, T$:

$$m_{t|t}, P_{t|t}, \quad m_{t+1|t}, P_{t+1|t}.$$

Le lisseur s'obtient par un **passage arrière** $t = T - 1, \dots, 0$.

Théorème 2.1 (Rauch–Tung–Striebel (RTS)). *Posons le gain de lissage*

$$J_t := P_{t|t} A_{t+1}^\top P_{t+1|t}^{-1}. \quad (2.3)$$

En prenant $m_{T|T}, P_{T|T}$ comme conditions terminales, on définit pour $t = T - 1, \dots, 0$:

$$m_{t|T} = m_{t|t} + J_t (m_{t+1|T} - m_{t+1|t}), \quad (2.4)$$

$$P_{t|T} = P_{t|t} + J_t (P_{t+1|T} - P_{t+1|t}) J_t^\top. \quad (2.5)$$

2.3.2.1 Dérivation (idée) : pourquoi ces formules sont naturelles

Idée / intuition. Le lissage combine deux sources d'information sur x_t : (i) l'information *passée* $y_{1:t}$ (donnée par le filtre), et (ii) l'information *future* $y_{t+1:T}$, qui arrive via x_{t+1} (la dynamique couple x_t et x_{t+1}).

Dérivation (pas à pas).

Étape 1: Le filtre donne $p(x_t | y_{1:t}) = \mathcal{N}(m_{t|t}, P_{t|t})$ et la prédiction $p(x_{t+1} | y_{1:t}) = \mathcal{N}(m_{t+1|t}, P_{t+1|t})$.

Étape 2: Le lisseur cherche $p(x_t | y_{1:T})$. Une identité utile est :

$$p(x_t | y_{1:T}) \propto p(x_t | y_{1:t}) \int \frac{p(x_{t+1} | x_t) p(x_{t+1} | y_{1:T})}{p(x_{t+1} | y_{1:t})} dx_{t+1},$$

qui formalise l'idée « x_{t+1} transmet l'information future vers t ».

Étape 3: Dans le cas linéaire-gaussien, tous ces termes sont gaussiens : l'intégrale se calcule par conditionnement gaussien, et on obtient une correction affine de $m_{t+1|t}$ vers $m_{t+1|T}$.

Étape 4: Le gain $J_t = P_{t|t} A_{t+1}^\top P_{t+1|t}^{-1}$ est exactement le coefficient de régression (au sens du théorème 1.1) de x_t sur la prédiction $x_{t+1|t}$.

Piège classique. Comme pour le filtre, on évite de former $P_{t+1|t}^{-1}$: on résout des systèmes (Cholesky/LDL) et on surveille la symétrie/positivité numérique de $P_{t|T}$.

Remarque 2.2 (Interprétation). Si, a posteriori, on découvre que x_{t+1} est différent de ce que prédisait $m_{t+1|t}$, on corrige x_t dans le sens qui rend la dynamique plus cohérente. Le gain J_t est l'analogue « backward » du gain de Kalman.

2.3.3 Pour EM : covariance croisée lissée

Pour certaines mises à jour de paramètres, EM requiert aussi

$$P_{t,t-1|T} := \text{Cov}(x_t, x_{t-1} \mid y_{1:T}).$$

Il existe une formule récursive (qu'on trouve dans les références) permettant de calculer $P_{t,t-1|T}$ pendant le passage arrière, à coût linéaire en T .

2.4 Exemples en finance quantitative (mise en modèle)

2.4.1 Exemple 1 : « local level » (tendance + bruit)

On veut débruiter un prix observé y_t pour reconstruire un niveau latent x_t :

$$\begin{aligned} x_t &= x_{t-1} + w_t, & w_t &\sim \mathcal{N}(0, q), \\ y_t &= x_t + v_t, & v_t &\sim \mathcal{N}(0, r). \end{aligned}$$

Ici $A = 1$, $H = 1$, $Q = q$, $R = r$.

- Si $q \ll r$, la tendance est supposée **lisse** (peu de variations) et le filtre **lisse fortement** les données.
- Si $q \gg r$, le niveau latent est supposé **très variable** et le filtre suit davantage l'observation.

Ce modèle est un point de départ pour comprendre la différence entre « signal » et « bruit de mesure ».

2.4.2 Exemple 2 : slope/intercept latents (tendance + vitesse)

On peut enrichir le local level en introduisant une **pente** (vitesse) latente b_t :

$$\begin{pmatrix} x_t \\ b_t \end{pmatrix} = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} x_{t-1} \\ b_{t-1} \end{pmatrix} + \begin{pmatrix} w_t^{(x)} \\ w_t^{(b)} \end{pmatrix}, \quad y_t = (1 \quad 0) \begin{pmatrix} x_t \\ b_t \end{pmatrix} + v_t.$$

On obtient un filtre qui estime simultanément niveau et vitesse, utile pour modéliser des tendances plus « inertielles ».

2.4.3 Exemple 3 : bêta dynamique (CAPM time-varying)

On observe un rendement d'actif $r_{i,t}$ et le rendement de marché $r_{m,t}$:

$$r_{i,t} = \beta_t r_{m,t} + \varepsilon_t, \quad \varepsilon_t \sim \mathcal{N}(0, \sigma_\varepsilon^2).$$

On modélise la lente variation de β_t :

$$\beta_t = \beta_{t-1} + \eta_t, \quad \eta_t \sim \mathcal{N}(0, \sigma_\eta^2).$$

On identifie alors :

$$x_t = \beta_t, \quad y_t = r_{i,t}, \quad H_t = r_{m,t}, \quad Q = \sigma_\eta^2, \quad R = \sigma_\varepsilon^2.$$

Le gain de Kalman varie dans le temps car H_t varie : si $|r_{m,t}|$ est faible, l'observation renseigne peu sur β_t .

2.4.4 Exemple 4 : paire cointégrée (hedge ratio variable)

Dans une paire (assets 1 et 2) on cherche un ratio de couverture β_t tel que

$$\log S_t^{(1)} \approx \alpha_t + \beta_t \log S_t^{(2)}.$$

On peut poser un état $x_t = (\alpha_t, \beta_t)^\top$ suivant un random walk, et une observation

$$y_t = \log S_t^{(1)}, \quad H_t = \begin{pmatrix} 1 & \log S_t^{(2)} \end{pmatrix}.$$

Le filtre fournit un estimateur en ligne d'un **hedge ratio dynamique**, souvent utilisé en pairs trading.

2.4.5 Exemple 5 : facteurs de courbe de taux (affine gaussien)

Dans les modèles de taux gaussiens multi-facteurs, les rendements (yields) observés $y_t(\tau)$ à différentes maturités τ s'écrivent souvent (exactement ou approximativement) comme :

$$y_t = Hx_t + d + v_t, \quad x_t = Ax_{t-1} + b + w_t,$$

où x_t sont des facteurs latents.

- Le filtre estime x_t (extraction de facteurs).
- La vraisemblance (2.2) sert à calibrer les paramètres de dynamique.

Ce point est central en économétrie des taux (*Gaussian affine term structure models*).

2.4.6 Comment choisir Q et R ? (lecture pratique)

Dans beaucoup d'applications, Q et R sont des hyperparamètres : ils codent un compromis de lissage.

- R est lié à la qualité de la mesure (microstructure noise, bid-ask bounce, erreurs de cotation).
- Q est lié à la « flexibilité » du signal latent (régime changeant, drift variable, etc.).

On peut les estimer par maximum de vraisemblance, ou les fixer par considérations de marché (fréquence, horizon, qualité des données).

2.5 Extension : filtre de Kalman–Bucy (temps continu, optionnel)

2.5.1 Pourquoi en parler ?

Beaucoup de modèles financiers sont posés en temps continu (SDE). Il existe un analogue du filtre de Kalman pour des systèmes linéaires-gaussiens en temps continu : le **filtre de Kalman–Bucy**. Il joue un rôle conceptuel proche de celui de Kalman en discret, et sert de passerelle vers des filtrages pour volatilité stochastique.

2.5.2 Système linéaire gaussien en temps continu

On écrit un système (formellement) :

$$dx_t = F_t x_t dt + f_t dt + G_t dW_t, \tag{2.6}$$

$$dy_t = H_t x_t dt + h_t dt + dV_t, \tag{2.7}$$

où W est un brownien (bruit de processus) et V un brownien (bruit d'observation), indépendants, avec

$$dV_t \sim \mathcal{N}(0, R_t dt).$$

Intuition : on observe un **flux** d'information à la vitesse dt .

2.5.3 Forme des équations de filtrage

Le filtre de Kalman–Bucy met à jour la moyenne filtrée $m_t = \mathbb{E}[x_t | \mathcal{Y}_t]$ et la covariance $P_t = \text{Cov}(x_t | \mathcal{Y}_t)$ via :

$$dm_t = F_t m_t dt + f_t dt + K_t(dy_t - (H_t m_t + h_t)dt), \quad (2.8)$$

$$\dot{P}_t = F_t P_t + P_t F_t^\top + G_t G_t^\top - K_t R_t K_t^\top, \quad (2.9)$$

avec un gain

$$K_t = P_t H_t^\top R_t^{-1}.$$

On reconnaît la structure discret : « drift + gain $\times$ innovation ».

Remarque 2.3. Ces formules demandent un cadre technique (filtrations, martingales). Pour un cours M1, l’objectif n’est pas la preuve, mais la **structure** : la mise à jour en ligne est encore une correction proportionnelle à une innovation.

2.6 Ouverture : volatilité stochastique et modèle de Heston

2.6.1 Pourquoi la volatilité stochastique casse le cadre gaussien

Avec Black–Scholes, la volatilité est constante : le bruit sur les rendements a variance proportionnelle au temps. Dans les données, la volatilité varie, ce qui suggère d’introduire une variance v_t latente. Mais dès que la volatilité dépend de l’état (via $\sqrt{v_t}$), on sort du cas « linéaire + bruit additif gaussien ».

2.6.2 Heston : dynamique du prix et de la variance

Sous la mesure risque-neutre Q , le modèle de Heston est :

$$\begin{cases} dS_t = rS_t dt + \sqrt{v_t} S_t dW_t^{(1)}, \\ dv_t = \kappa(\theta - v_t) dt + \xi \sqrt{v_t} dW_t^{(2)}, \\ dW_t^{(1)} dW_t^{(2)} = \rho dt. \end{cases} \quad (2.10)$$

La variance suit un **CIR** : elle est tirée vers θ à vitesse κ et subit une vol-of-vol ξ .

2.6.3 Quelques propriétés du CIR (culture quantitative)

Le processus CIR est positif (avec une condition de Feller) et non gaussien.

- Positivité : si $2\kappa\theta \geq \xi^2$, alors $v_t > 0$ p.s. (condition de Feller, suffisante).
- Stationnarité : en régime stationnaire, v_t a une loi Gamma (intuition : variance qui fluctue autour d’un niveau).

Ces propriétés expliquent à la fois l’intérêt (volatilité réaliste) et la difficulté (non-gaussien).

2.6.4 Mettre Heston en espace d’états : choix de l’état et des observations

Pour filtrer, on doit choisir :

- état x_t : souvent v_t seul, ou (X_t, v_t) avec $X_t = \log S_t$,
- observations y_t : rendements, variance réalisée, prix d’options / vol implicites.

2.6.5 Observations par rendements : conditionnellement gaussien, mais hétéroscédastique

On pose $X_t = \log S_t$. Par Itô :

$$dX_t = \left(r - \frac{v_t}{2}\right) dt + \sqrt{v_t} dW_t^{(1)}.$$

Sur un pas Δ , une approximation (Euler) donne :

$$\Delta X_t \approx \left(r - \frac{v_t}{2}\right) \Delta + \sqrt{v_t \Delta} \varepsilon_t, \quad \varepsilon_t \sim \mathcal{N}(0, 1). \quad (2.11)$$

On lit (2.11) comme :

- conditionnellement à v_t , ΔX_t est gaussien,
- mais la variance d'observation vaut $v_t \Delta$ et dépend de l'état : ce n'est pas un bruit additif à variance constante.

Donc un filtre de Kalman *exact* ne s'applique pas.

2.6.6 Observations par options : non linéaire

Si l'on observe un vecteur de prix d'options $C_t^{\text{mkt}}(K, T)$, une modélisation typique est :

$$y_t = h(S_t, v_t; \theta) + \eta_t,$$

où h est un pricer Heston (ou une volatilité implicite issue du pricer), et η_t modélise l'erreur de marché. Ici, h est fortement non linéaire : l'update n'est pas gaussien.

2.6.7 Quelles approximations à partir de Kalman ?

(1) **EKF : linéariser.** On écrit un modèle discret non linéaire :

$$x_t = f(x_{t-1}) + w_t, \quad y_t = h(x_t) + v_t,$$

et on linéarise f et h autour de l'estimation courante (Jacobiennes). On applique ensuite des formules à la Kalman avec matrices « locales ».

(2) **UKF : points sigma.** On représente une gaussienne par des points sigma, que l'on propage par f et h ; on reconstruit ensuite une moyenne/covariance. Utile quand les dérivées sont compliquées (e.g. pricer d'options).

(3) **Filtres particuliers.** On approxime directement $p(v_t | y_{1:t})$ par un nuage de particules. Cela gère la non-gaussienneté (asymétrie, contraintes) mais coûte plus cher.

Message à savoir dire. Heston $\Rightarrow$ **variance latente** + **non-linéarité/non-gaussien** $\Rightarrow$ Kalman exact impossible, mais Kalman reste la **brique de base** pour comprendre et construire des filtres approchés (EKF/UKF) ou des schémas plus généraux (particules).

2.7 Synthèse : ce qu'un élève doit savoir refaire et expliquer

Checklist (niveau M1).

- Poser clairement un modèle espace d'états : dynamique x_t et observation y_t .
- Dériver la **prediction** (1.5)–(1.6).
- Dériver la **mise à jour** : innovation (1.8), covariance (1.9), gain (1.11), update (1.12)–(1.13).
- Expliquer l'intuition de K_t (confiance modèle vs observation).
- Construire la log-vraisemblance via innovations (2.2).
- Distinguer filtrage / prédiction / lissage (RTS).
- Dire pourquoi Heston sort du cadre et citer EKF/UKF/particules comme extensions naturelles.

2.8 Identités matricielles utiles (annexe technique)

2.8.1 Complément de Schur

Considérons une matrice bloc

$$M = \begin{pmatrix} A & B \\ C & D \end{pmatrix},$$

où A est inversible. Le **complément de Schur** de A dans M est

$$S := D - CA^{-1}B.$$

Il apparaît naturellement dans :

- l'inversion bloc,
- les conditionnements gaussiens (covariance conditionnelle),
- les tests de définitude positive.

2.8.2 Inversion d'une matrice 2×2 par blocs

Si A et S sont inversibles, alors :

$$M^{-1} = \begin{pmatrix} A^{-1} + A^{-1}BS^{-1}CA^{-1} & -A^{-1}BS^{-1} \\ -S^{-1}CA^{-1} & S^{-1} \end{pmatrix}.$$

Il existe une formule symétrique si D est inversible (en inversant avec le complément de Schur de D).

2.8.3 Identité de Woodbury (matrix inversion lemma)

Pour des matrices de dimensions compatibles, avec A et C inversibles :

$$(A + UCV)^{-1} = A^{-1} - A^{-1}U(C^{-1} + VA^{-1}U)^{-1}VA^{-1}. \quad (2.12)$$

Dans Kalman, on l'applique typiquement avec $A = P^{-1}$, $U = H^T$, $C = R^{-1}$, $V = H$.

2.8.4 Déterminant lemma (utile pour la vraisemblance)

Sous les mêmes hypothèses :

$$\det(A + UCV) = \det(C^{-1} + VA^{-1}U) \det(C) \det(A).$$

Cela permet parfois de calculer $\log \det(S_t)$ de manière plus stable.

2.8.5 Application à la covariance a posteriori

En utilisant (2.12), on obtient l'identité :

$$(P^{-1} + H^T R^{-1} H)^{-1} = P - PH^T (HPH^T + R)^{-1} HP,$$

qui est exactement la mise à jour de covariance (1.13). C'est une manière *très* utile d'expliquer pourquoi la forme informationnelle est équivalente au filtre classique.

2.9 Preuve complète du conditionnement gaussien (annexe)

2.9.1 Objectif

On veut justifier rigoureusement (dans un cadre densitaire) :

$$x \mid y \sim \mathcal{N}(\mu_x + \Sigma_{xy}\Sigma_{yy}^{-1}(y - \mu_y), \Sigma_{xx} - \Sigma_{xy}\Sigma_{yy}^{-1}\Sigma_{yx}).$$

2.9.2 Réduction au cas centré

On se ramène au cas $\mu_x = \mu_y = 0$ en appliquant la translation :

$$\tilde{x} := x - \mu_x, \quad \tilde{y} := y - \mu_y.$$

Le conditionnement de (x, y) est le même que celui de $(\tilde{x}, \tilde{y})$, puis on retranslate.

2.9.3 Écriture via la matrice de précision

Soit $z = (x, y)^\top$ et $\Sigma = \text{Cov}(z)$. On note $\Lambda = \Sigma^{-1}$ la matrice de précision et on la découpe en blocs :

$$\Lambda = \begin{pmatrix} \Lambda_{xx} & \Lambda_{xy} \\ \Lambda_{yx} & \Lambda_{yy} \end{pmatrix}.$$

La densité jointe est

$$p(x, y) \propto \exp\left(-\frac{1}{2} z^\top \Lambda z\right) = \exp\left(-\frac{1}{2} (x^\top \Lambda_{xx} x + 2x^\top \Lambda_{xy} y + y^\top \Lambda_{yy} y)\right).$$

Conditionnellement à y , le terme $y^\top \Lambda_{yy} y$ est constant, donc

$$p(x \mid y) \propto \exp\left(-\frac{1}{2} (x^\top \Lambda_{xx} x + 2x^\top \Lambda_{xy} y)\right).$$

2.9.4 Complétion du carré

On complète le carré :

$$x^\top \Lambda_{xx} x + 2x^\top \Lambda_{xy} y = (x + \Lambda_{xx}^{-1} \Lambda_{xy} y)^\top \Lambda_{xx} (x + \Lambda_{xx}^{-1} \Lambda_{xy} y) - y^\top \Lambda_{yx} \Lambda_{xx}^{-1} \Lambda_{xy} y.$$

Donc $p(x \mid y)$ est une gaussienne de covariance Λ_{xx}^{-1} et de moyenne

$$\mu_{x|y} = -\Lambda_{xx}^{-1} \Lambda_{xy} y.$$

2.9.5 Relier cette expression aux blocs de covariance

Il reste à montrer :

$$-\Lambda_{xx}^{-1} \Lambda_{xy} = \Sigma_{xy} \Sigma_{yy}^{-1}, \quad \Lambda_{xx}^{-1} = \Sigma_{xx} - \Sigma_{xy} \Sigma_{yy}^{-1} \Sigma_{yx}.$$

Ces identités se prouvent en utilisant l'inversion bloc (annexe précédente) sur Σ et en identifiant les blocs de $\Lambda = \Sigma^{-1}$. Le résultat $\Sigma_{xx} - \Sigma_{xy} \Sigma_{yy}^{-1} \Sigma_{yx}$ est exactement un complément de Schur.

Lectures recommandées

- S. J. Durbin, S. J. Koopman, *Time Series Analysis by State Space Methods*.
- A. C. Harvey, *Forecasting, Structural Time Series Models and the Kalman Filter*.
- D. Simon, *Optimal State Estimation*.
- S. M. Kay, *Fundamentals of Statistical Signal Processing* (projection/régression).
- S. L. Heston, *A Closed-Form Solution for Options with Stochastic Volatility*, 1993.

2.10 Mode microscope : vraisemblance, diagnostics et lissage

2.10.1 Log-vraisemblance via innovations

L'innovation est

$$\varepsilon_t := y_t - Hm_{t|t-1}, \quad S_t := HP_{t|t-1}H^\top + R.$$

Sous l'hypothèse linéaire-gaussienne, $\varepsilon_t \sim \mathcal{N}(0, S_t)$ conditionnellement au passé, donc la log-vraisemblance (à constante près) s'écrit :

$$\log L = -\frac{1}{2} \sum_{t=1}^T \left(\log \det S_t + \varepsilon_t^\top S_t^{-1} \varepsilon_t \right). \quad (2.13)$$

Cela permet de calibrer des paramètres (dans A, Q, H, R) par maximisation.

2.10.2 Lissage RTS (idée)

Le filtre donne $m_t = x_{t|t}$ et $P_t = P_{t|t}$. Le lisseur RTS calcule $x_{t|T}$ en remontant :

$$J_t = P_t A^\top P_{t+1|t}^{-1}, \quad m_{t|T} = m_t + J_t(m_{t+1|T} - m_{t+1|t}),$$

avec une formule analogue pour $P_{t|T}$.

Intuition de marché. Filtrer = estimation en temps réel ; lisser = *reconstruire* la trajectoire en utilisant toutes les observations. En finance, le lissage sert à estimer des états latents (volatilité, facteurs) a posteriori.

2.11 Pièges classiques / erreurs fréquentes

- Mauvaise initialisation : transitoires longs, biais au début de l'échantillon.
- Perte de PSD : P devient numériquement non-PSD (instabilités) si on ne stabilise pas.
- Sur-calibrage : optimiser trop de paramètres de Q, R sans identifiabilité.

2.12 Checklist — savoir refaire sans regarder

- Calculer innovations ε_t , covariance S_t , et la log-vraisemblance.
- Mettre en place une initialisation raisonnable et des diagnostics.
- Expliquer/écrire la récursion RTS (gain J_t).
- Décrire une calibration par maximum de vraisemblance basée sur les innovations.

Chapitre 3

Kalman en production : MLE/EM, robustesse, numérique

3.1 Idée centrale

Le filtre de Kalman est un algorithme *optimal* (MMSE) pour les modèles linéaires Gaussiens. En recherche quant, sa valeur est double : (i) **extraire un état latent** (facteurs, trend, volatilité, microstructure), (ii) **estimer** des paramètres par vraisemblance (innovations) avec diagnostics de cohérence.

3.2 Cadre mathématique (state-space)

Modèle discret (temps possiblement irrégulier) :

$$\begin{aligned}x_{t+1} &= F_t x_t + u_t + \eta_t, & \eta_t &\sim \mathcal{N}(0, Q_t), \\ y_t &= H_t x_t + d_t + \epsilon_t, & \epsilon_t &\sim \mathcal{N}(0, R_t),\end{aligned}$$

avec indépendance conditionnelle et $x_0 \sim \mathcal{N}(m_0, P_0)$.

Notations (filtre). m_t^-, P_t^- : prédiction ; m_t, P_t : filtré ; innovation $\nu_t = y_t - H_t m_t^- - d_t$; covariance innovation $S_t = H_t P_t^- H_t^\top + R_t$.

3.3 Vraisemblance via innovations (clé en calibration)

Sous hypothèses Gaussiennes, la log-vraisemblance s'écrit :

$$\log p(y_{0:T}) = -\frac{1}{2} \sum_{t=0}^T \left(\log |S_t| + \nu_t^\top S_t^{-1} \nu_t \right) + \text{cste}.$$

Intuition. Si le modèle est correct, les innovations ν_t sont (i) centrées, (ii) non corrélées, (iii) de covariance S_t .

3.4 Estimation des paramètres : MLE vs EM

3.4.1 MLE direct

Optimiser la log-vraisemblance ci-dessus en paramètres θ (dans F, Q, H, R) via gradient (auto-diff) ou dérivées analytiques. **Point d'attention** : imposer $Q, R \succeq 0$ (paramétrisation Cholesky, logs sur variances).

3.4.2 EM (structurellement robuste)

E-step. Utiliser un lisseur RTS pour obtenir $\mathbb{E}[x_t | y_{0:T}]$, $\mathbb{E}[x_t x_t^\top | y_{0:T}]$, $\mathbb{E}[x_{t+1} x_t^\top | y_{0:T}]$.

M-step. Mettre à jour les paramètres en fermant les équations (cas simple où F, H sont constants) :

$$Q = \frac{1}{T} \sum_{t=0}^{T-1} \mathbb{E}[(x_{t+1} - Fx_t - u)(x_{t+1} - Fx_t - u)^\top | y],$$

et de même pour R à partir des résidus d'observation. **Trade-off.** EM est stable mais peut converger lentement ; MLE direct est rapide mais plus fragile.

3.5 Numérique : éviter la divergence

- **Joseph form** : $P_t = (I - KH)P_t^-(I - KH)^\top + KRK^\top$ (préserve PSD).
- **Square-root Kalman** : propager Cholesky de P (stabilité + conditionnement).
- **Regularisation** : $Q \leftarrow Q + \varepsilon I$ si quasi-singulier ; bornes sur variances.
- **Stiffness** : en pas de temps irréguliers, construire $F(\Delta t)$ via exponentielle de matrice (modèle continu linéaire).

3.6 Robustesse marché (ce qui casse les hypothèses)

- **Outliers / sauts** : innovations non gaussiennes $\Rightarrow$ filtrage robuste (Huber), Student- t (scale-mixture), ou filtre particulaire.
- **Non-stationnarité** : paramètres θ varient par régime $\Rightarrow$ forgetting factor, filtre adaptatif, switching Kalman (HMM).
- **Modèle mal spécifié** : innovations autocorrélées $\Rightarrow$ manque d'état (ajouter un facteur) ou mauvaise structure de R .

3.7 Implémentation (pseudo-code)

1. Prédire : $m_t^- = F_{t-1}m_{t-1} + u_{t-1}$, $P_t^- = F_{t-1}P_{t-1}F_{t-1}^\top + Q_{t-1}$.
2. Innover : $\nu_t = y_t - H_t m_t^- - d_t$, $S_t = H_t P_t^- H_t^\top + R_t$.
3. Gain : $K_t = P_t^- H_t^\top S_t^{-1}$ (résoudre via Cholesky de S_t).
4. Mettre à jour : $m_t = m_t^- + K_t \nu_t$, P_t via Joseph/square-root.

3.8 Tests / diagnostics (3–6 à connaître)

- **Whiteness** : autocorrélation des innovations ν_t (Ljung–Box).
- **NIS** : $\nu_t^\top S_t^{-1} \nu_t$ doit suivre χ^2 (dimension obs).
- **NEES** (si vérité simulée) : $(x_t - m_t)^\top P_t^{-1} (x_t - m_t)$.
- **Sensitivity** : stabilité des paramètres vs fenêtre, sampling, régimes.

3.9 Pont vers pratique quant

- **Term structure** : facteurs latents (niveau/pente/courbure), observation = yields ; estimation + nowcast.
- **Pairs / stat arb** : spread latent + microstructure noise, estimation du mean-reversion.
- **Volatility** : modèle local (log-vol) linéarisé ; Kalman étendu/unscented si non linéaire.

Chapitre 4

Non-linéaire / non-gaussien : EKF, UKF, particules (interview-level)

4.1 Idée centrale

Le filtre de Kalman est exact pour *linéaire + Gaussien*. Dès qu'on sort de ce cadre (microstructure, vol latent, contraintes), on doit choisir : (i) linéariser (EKF), (ii) propager des points sigma (UKF), (iii) échantillonner (particle filter). Le choix est un compromis **biais / variance / coût**.

4.2 Modèles non linéaires

$$x_{t+1} = f(x_t) + \eta_t, \quad y_t = h(x_t) + \epsilon_t,$$

avec $\eta_t \sim \mathcal{N}(0, Q)$, $\epsilon_t \sim \mathcal{N}(0, R)$ (souvent).

4.3 EKF (Extended Kalman Filter)

4.3.1 Principe

Linéariser f, h autour de l'estimateur courant :

$$F_t = \nabla f(m_t), \quad H_t = \nabla h(m_t),$$

puis appliquer les formules Kalman avec F_t, H_t . **Piège**. Linéarisation mauvaise $\Rightarrow$ divergence ; très sensible aux régimes.

4.4 UKF (Unscented Kalman Filter)

4.4.1 Principe

Construire des *sigma points* qui matchent moyenne/covariance, propager via f, h , puis reconstruire moyenne/covariance. Souvent plus stable que EKF sans calcul de Jacobiennes. **Coût**. $O(n^3)$ par pas (Cholesky) + propagation de $2n + 1$ points.

4.5 Particle filter (SIR)

4.5.1 Principe

Approximations par particules $\{x_t^{(i)}, w_t^{(i)}\}$:

1. Propager $x_{t+1}^{(i)} \sim p(\cdot | x_t^{(i)})$.
2. Repondérer $w_{t+1}^{(i)} \propto w_t^{(i)} p(y_{t+1} | x_{t+1}^{(i)})$.
3. Resampler si ESS faible.

Atout. Gère non-Gaussien, multimodal, contraintes. **Faiblesse.** Dégénérescence (variance), coût.

4.6 Quand l'utiliser en finance ?

- **Vol latent** : modèles SV non linéaires, observations non gaussiennes (returns).
- **Microstructure** : prix observés = prix latent + bruit (stale/outliers).
- **Regimes** : switching models (HMM + Kalman) pour changements de régime.

4.7 Sanity checks

- Innovations (ou résidus) : centrés, non corrélés.
- Sensibilité : robustesse à l'initialisation, au choix de Q, R .
- Diagnostics PF : ESS, dégénérescence, collapse des poids.

Chapitre 5

Kalman continu (Kalman–Bucy) : lien avec SDE et discrétisation

5.1 Idée centrale

Beaucoup de modèles financiers sont *naturellement* en temps continu (OU, facteurs taux). En production, on observe à des timestamps irréguliers Δt : il faut savoir (i) passer du continu au discret proprement, (ii) expliquer la Riccati et la stabilité.

5.2 Modèle linéaire en temps continu

$$dx_t = Ax_t dt + a dt + G dW_t, \quad dy_t = Hx_t dt + h dt + D dV_t,$$

avec W, V browniens indépendants. On observe typiquement y à des dates discrètes (ou en flux).

5.3 Kalman–Bucy (forme compacte)

Le filtre continu s'écrit :

$$dm_t = (Am_t + a) dt + K_t(dy_t - (Hm_t + h) dt), \quad K_t = P_t H^\top (DD^\top)^{-1},$$

et la covariance suit une Riccati différentielle :

$$\dot{P}_t = AP_t + P_t A^\top + GG^\top - P_t H^\top (DD^\top)^{-1} H P_t.$$

Lecture. Terme $GG^\top$ injecte du bruit (process noise), le terme $-PH^\top R^{-1}HP$ réduit l'incertitude via l'information observation.

5.4 Discrétisation correcte : $F(\Delta t)$ et $Q(\Delta t)$

Si x suit $dx = Ax dt + G dW$, alors

$$F(\Delta t) = \exp(A\Delta t), \quad Q(\Delta t) = \int_0^{\Delta t} \exp(A\tau) GG^\top \exp(A^\top \tau) d\tau.$$

Implémentation. Calculer $Q(\Delta t)$ via la méthode de Van Loan (exponentielle de bloc) ou résolution de Lyapunov.

5.5 Applications finance (exemples typiques)

- **OU latent** (mean-reversion) : x suit OU, y est prix/spread bruité.
- **Taux** : facteurs (niveau/pente/courbure) en continu, observation = yields.
- **Microstructure** : prix latent continu + bruit d'observation.

5.6 Sanity checks

- $P_t \succeq 0$ toujours ; si non, problème numérique.
- Limite $\Delta t \rightarrow 0$: cohérence discret/continu.
- Régime stationnaire : P converge vers solution de Riccati algébrique (si stable).

Chapitre 6

Régimes & robustesse : switching Kalman, Student- t , missing data

6.1 Idée centrale

Les séries financières violent systématiquement « linéaire + gaussien + stationnaire » : changements de régime, queues lourdes, outliers, observations manquantes/irrégulières. Un quant researcher doit savoir **déformer Kalman** pour rester stable : (i) mélanges de régimes (HMM/IMM), (ii) bruit robuste (Student- t /Huber), (iii) update partiel (missing data).

6.2 Switching state-space (HMM + Kalman)

6.2.1 Modèle

Régime latent $z_t \in \{1, \dots, K\}$ Markovien avec matrice de transition $\Pi = (\pi_{ij})$. Conditionnellement à z_t :

$$x_{t+1} = F^{(z_t)}x_t + u^{(z_t)} + \eta_t, \quad \eta_t \sim \mathcal{N}(0, Q^{(z_t)}), \quad y_t = H^{(z_t)}x_t + d^{(z_t)} + \epsilon_t, \quad \epsilon_t \sim \mathcal{N}(0, R^{(z_t)}).$$

Interprétation. Chaque régime correspond à une dynamique (volatilité, mean-reversion, microstructure) différente.

6.2.2 Inference (idée IMM, « desk-ready »)

On maintient K filtres de Kalman et des poids $\gamma_t^{(k)} = \mathbb{P}(z_t = k \mid y_{0:t})$. Un pas typique :

1. **Mixing** : prédire les poids $\tilde{\gamma}_t^{(k)} = \sum_j \gamma_{t-1}^{(j)} \pi_{jk}$ et mélanger les conditions initiales.
2. **Kalman** : exécuter un update KF par régime k et calculer la vraisemblance $\ell_t^{(k)} = p(y_t \mid y_{0:t-1}, z_t = k)$ via innovation.
3. **Reweight** : $\gamma_t^{(k)} \propto \tilde{\gamma}_t^{(k)} \ell_t^{(k)}$ (normaliser).
4. (Optionnel) **Moment matching** : compresser le mélange en une gaussienne (IMM) pour rester $O(K)$.

Coût. $O(K^2)$ si mixing complet, sinon approximations (IMM) pour rester temps-réel.

6.3 Bruit robuste : Student- t (outliers)

6.3.1 Scale-mixture (trick classique)

Un bruit t_ν s'écrit comme un mélange d'observations gaussiennes à variance aléatoire :

$$\epsilon_t \mid \lambda_t \sim \mathcal{N}(0, R/\lambda_t), \quad \lambda_t \sim \text{Gamma}\left(\frac{\nu}{2}, \frac{\nu}{2}\right).$$

Conditionnellement à λ_t , on fait un update Kalman standard avec R/λ_t . **Lecture.** Un résidu grand $\Rightarrow \lambda_t$ petit $\Rightarrow$ variance effective grande $\Rightarrow$ l'observation est *down-weighted*.

6.3.2 Huberisation (version rapide)

En pratique : saturer l'innovation via un poids $w_t = \min(1, c/\|\nu_t\|)$ et remplacer R par R/w_t (approx robuste).

6.4 Missing data / observations irrégulières

- Si une composante de y_t est manquante, on supprime la ligne correspondante de H_t et le bloc correspondant de R_t (update partiel).
- Si les timestamps sont irréguliers : utiliser $F(\Delta t) = \exp(A\Delta t)$ et $Q(\Delta t)$ (cf. Kalman continu) pour éviter le biais.
- **Sanity.** Ne jamais « imputer » avec de l'information future (leakage).

6.5 Identifiabilité (piège classique)

- Q vs R : beaucoup de combinaisons produisent des innovations similaires (trade-off process vs observation noise).
- **Normaliser** l'état (échelle) ou fixer certaines variances est souvent nécessaire.
- En switching : sans régularisation, permutation des régimes (label switching) et sur-ajustement.

6.6 Implémentation : update de poids en log (stabilité)

```
import numpy as np

def logsumexp(a):
    m = np.max(a)
    return m + np.log(np.sum(np.exp(a - m)))

def normalize_log_weights(logw):
    z = logsumexp(logw)
    return np.exp(logw - z)
```

6.7 Tests / diagnostics (3–6)

- $\sum_k \gamma_t^{(k)} = 1$; pas de collapse numérique (tout à 0).
- Innovations *par régime* : centrées, faible autocorrélation (sinon modèle incomplet).
- Log-vraisemblance : pas de sauts aberrants d'un pas à l'autre (problème de branche/log).
- En robuste : vérifier que les outliers sont bien down-weighted (poids λ_t).
- Backtest : régimes stables hors échantillon (sinon sur-ajustement).

6.8 Pont vers pratique quant

- **Taux** : régimes de vol (crise vs calme), observation yields + spreads.
- **Microstructure** : prix latent + outliers + quotes manquantes.
- **Alpha** : détection de trend/mean-reversion avec régimes, robustes aux sauts.

Chapitre 7

Lissage (RTS), prédiction, EM : ce qu'on attend en entretien quant

7.1 Idée centrale

Le filtre fournit $p(x_t | y_{0:t})$ (online). En recherche/production, on veut souvent (i) **lisser** ($p(x_t | y_{0:T})$) pour extraire des états propres, (ii) **prédire** (y_{t+h}) avec intervalles, (iii) **estimer** des paramètres par EM/MLE via la forme innovations. Ce sont des compétences « desk-ready ».

7.2 Cadre : RTS smoother (discret, linéaire gaussien)

On note m_t, P_t (filtrés) et m_{t+1}^-, P_{t+1}^- (prédits) avec transition F_t . Le gain du lisseur :

$$G_t = P_t F_t^\top (P_{t+1}^-)^{-1}.$$

Récursions (backward $t = T - 1, \dots, 0$) :

$$m_t^s = m_t + G_t(m_{t+1}^s - m_{t+1}^-), \quad P_t^s = P_t + G_t(P_{t+1}^s - P_{t+1}^-)G_t^\top.$$

Usage. Extraire un trend/level latent sans retard (le filtre a du lag), estimer des facteurs (taux, vol) proprement.

7.3 Prédiction (forecast) : distribution

Si $y_t = H_t x_t + d_t + \epsilon_t$, alors

$$y_{t+1} | y_{0:t} \sim \mathcal{N}(H_{t+1} m_{t+1}^- + d_{t+1}, H_{t+1} P_{t+1}^- H_{t+1}^\top + R_{t+1}).$$

Message. Le forecast vient gratuitement du pas de prédiction ; on obtient aussi un intervalle.

7.4 EM (Shumway–Stoffer) : updates fermés (cas simple)

7.4.1 Modèle

Supposer $x_{t+1} = F x_t + \eta_t$ et $y_t = H x_t + \epsilon_t$ avec $\eta \sim \mathcal{N}(0, Q)$, $\epsilon \sim \mathcal{N}(0, R)$ constants. E-step : calculer via RTS

$$\hat{x}_t = \mathbb{E}[x_t | y], \quad \hat{P}_t = \mathbb{E}[x_t x_t^\top | y], \quad \hat{P}_{t,t-1} = \mathbb{E}[x_t x_{t-1}^\top | y].$$

7.4.2 M-step (formes clés)

$$F \leftarrow \left(\sum_{t=1}^T \hat{P}_{t,t-1} \right) \left(\sum_{t=0}^{T-1} \hat{P}_t \right)^{-1}, \quad Q \leftarrow \frac{1}{T} \sum_{t=0}^{T-1} \mathbb{E}[(x_{t+1} - Fx_t)(x_{t+1} - Fx_t)^\top \mid y].$$

Et pour l'observation :

$$H \leftarrow \left(\sum_{t=0}^T y_t \hat{x}_t^\top \right) \left(\sum_{t=0}^T \hat{P}_t \right)^{-1}, \quad R \leftarrow \frac{1}{T+1} \sum_{t=0}^T \mathbb{E}[(y_t - Hx_t)(y_t - Hx_t)^\top \mid y].$$

Interprétation. EM alterne « reconstruire les états » et « régresser » les matrices sur ces états.

7.5 Numérique : points durs

- Ne jamais inverser explicitement : résoudre via Cholesky (comme pour $S_t^{-1}\nu_t$).
- Garantir $Q, R \succeq 0$: paramétriser Cholesky, ajouter ridge si nécessaire.
- Identifiabilité : $\text{scale}(x)$ et H se compensent ; fixer une normalisation si besoin.

7.6 Tests / sanity checks

- RTS : $P_t^s \preceq P_t$ (le lissage réduit l'incertitude).
- Forecast : erreurs normalisées $\nu_t^\top S_t^{-1} \nu_t$ proches d'une χ^2 (diagnostic).
- EM : log-vraisemblance non décroissante à chaque itération (sinon bug/instabilité).
- Stationnarité : sur fenêtres différentes, F, Q ne doivent pas varier de manière absurde (sinon régimes).

7.7 Pont vers pratique quant

- **Taux** : modèles affine (filtres sur yields) ; extraction de facteurs + nowcast.
- **Trend** : local level/trend + lissage RTS (moins de lag) ; contrôle par innovations.
- **Calibration** : EM pour initialiser un MLE plus fin (ou auto-diff) ; warm-start par fenêtres.

Chapitre 8

State-space templates finance : levels, trends, OU, courbe (ultra-pratique)

8.1 Idée centrale

La plupart des cas « finance » se ramènent à quelques gabarits (templates) espace-état. Les connaître permet (i) d'écrire un modèle en 5 minutes en entretien, (ii) d'initialiser proprement Q/R , (iii) d'avoir des diagnostics immédiats (innovations, lag, smoothing).

8.2 Template 1 : local level (random walk + noise)

$$x_{t+1} = x_t + \eta_t, \quad \eta_t \sim \mathcal{N}(0, q), \quad y_t = x_t + \epsilon_t, \quad \epsilon_t \sim \mathcal{N}(0, r).$$

Lecture. q/r règle le lissage : petit $q \Rightarrow$ état très lisse (fort lag), grand $q \Rightarrow$ suit le bruit. **Usage.** Nowcast d'un prix latent, microstructure (efficient price + noise), smoothing de spread.

8.3 Template 2 : local linear trend (niveau + pente)

État $x_t = (\ell_t, b_t)$:

$$\begin{pmatrix} \ell_{t+1} \\ b_{t+1} \end{pmatrix} = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} \ell_t \\ b_t \end{pmatrix} + \eta_t, \quad y_t = \ell_t + \epsilon_t.$$

Usage. Extraction de trend (moins de lag avec lissage RTS), détection de changements de pente.

8.4 Template 3 : OU discretisé proprement (mean-reversion)

SDE : $dx_t = \kappa(\theta - x_t)dt + \sigma dW_t$. Sur pas Δ :

$$x_{t+\Delta} = \theta + e^{-\kappa\Delta}(x_t - \theta) + \eta, \quad \eta \sim \mathcal{N}\left(0, \frac{\sigma^2}{2\kappa}(1 - e^{-2\kappa\Delta})\right).$$

Message. Citer cette forme à la place d'un Euler (moins biaisée, stable en Δ irrégulier).

8.5 Template 4 : courbe des taux (facteurs + observation yields)

État latent x_t (niveau/pente/courbure) ; observation $y_t(\tau) = \text{yield à maturité } \tau$:

$$y_t(\tau) = H(\tau) x_t + \epsilon_t(\tau),$$

où $H(\tau)$ peut être pris comme chargements Nelson–Siegel (« loadings » en τ). **Usage.** Estimer des facteurs de courbe + incertitude ; filtrer des quotes bruitées/illiquides.

8.6 Implémentation : 1D local level (numpy minimal)

```
import numpy as np

def local_level_kf(y, q, r, m0=0.0, P0=1.0):
    m, P = m0, P0
    out = []
    for yt in y:
        # predict
        m_pred, P_pred = m, P + q
        # update
        nu = yt - m_pred
        S = P_pred + r
        K = P_pred / S
        m = m_pred + K * nu
        P = (1 - K) * P_pred
        out.append((m, P, nu, S))
    return out
```

8.7 Tests / sanity checks

- $q \downarrow 0$: l'état devient quasi constant (fort smoothing) ; $r \downarrow 0$: l'état colle aux observations.
- NIS : ν_t^2/S_t suit approximativement $\chi^2(1)$ si le modèle est correct.
- Résidus : autocorrélation ≈ 0 ; sinon il manque un état (pente, saisonnalité, microstructure).

8.8 Pont vers pratique quant

- **Recherche** : prototyper un signal de trend/mean-reversion avec estimation d'incertitude.
- **Production** : handling des missing data (quotes), timestamps irréguliers, robustesse aux outliers.
- **Risk** : fournir des intervalles (uncertainty-aware) plutôt qu'un point estimate.

Interview Pack — Partie VII (core)

Allocation & rebalancement

Table des matières

1	Allocation & rebalancement	1
1.1	Avant-propos : Allocation & rebalancement (pont entre estimation et décision)	1
1.2	Setup commun : univers, notations, estimation	2
1.3	Markowitz — Minimum Variance (GMV)	4
1.4	Markowitz — Maximum Sharpe (portefeuille de tangence)	6
1.5	Rebalancement : pourquoi les poids dérivent, comment ajouter les coûts	7
1.6	Risk Parity (ERC) : contributions au risque et algorithmes	8
1.7	Eigenportfolios (PCA) : diagonaliser la covariance pour comprendre et stabiliser	10
1.8	Synthèse comparative et pont vers RL	11
1.9	Mode microscope : dérivations complètes et checks	12
1.10	Pièges classiques / erreurs fréquentes	14
1.11	Checklist - savoir refaire sans regarder	14
2	Toolbox interview : optimisation de portefeuille en production	15
2.1	Idée centrale	15
2.2	Cadre mathématique : problèmes types	15
2.3	Estimation : Σ domine tout	16
2.4	Contraintes, coûts, turnover	16
2.5	Robust optimisation (interview-level)	16
2.6	Sanity checks (à annoncer spontanément)	16
2.7	Pitfalls de backtest (quant researcher)	17
2.8	Ce qu'on te demandera (format entretien)	17
3	Covariance en pratique : shrinkage, facteurs, nettoyage	18
3.1	Idée centrale	18
3.2	Échantillonnage : pourquoi l'empirique casse	18
3.3	Shrinkage (réflexe standard)	18
3.4	Factor models : structure $\Sigma = B\Sigma_f B^\top + D$	18
3.5	EWMA / covariance conditionnelle	19
3.6	Nettoyage / PSD / inversion stable	19
3.7	Sanity checks (pratique)	19
4	Friction, turnover, exécution : optimiser sous coûts	20
4.1	Idée centrale	20
4.2	Modèles de coûts	20
4.3	Problème type (convexe)	20
4.4	No-trade region : exemple 1D	20

4.5	Lien exécution : Almgren–Chriss (interview-level)	21
4.6	Diagnostics en backtest	21
5	Optimisation en production : KKT, dualité, proximal/ADMM (dense)	22
5.1	Idée centrale	22
5.2	KKT (lecture structurante)	22
5.3	Turnover L^1 : proximal (intuition) et ADMM (pratique)	22
5.4	Conditionnement et stabilité	23
5.5	Tests / sanity checks (solver-level)	23
5.6	Pont vers pratique quant	23
6	Alternatives à Markowitz : risk parity, Black–Litterman, heuristiques	24
6.1	Idée centrale	24
6.2	Risk parity / ERC (Equal Risk Contribution)	24
6.3	Maximum diversification	24
6.4	Black–Litterman (BL) : prior + vues	25
6.5	Heuristiques robustes (quand le pipeline est fragile)	25
6.6	Ce qu'on te demandera (format entretien)	25
7	Pipeline complet : données → risk model → optim → monitoring	26
7.1	Idée centrale	26
7.2	Données (avant l'optimisation)	26
7.3	Risk model (ce que tu livres vraiment)	26
7.4	Optimisation (décisions)	26
7.5	Exécution (traduire en trades)	26
7.6	Monitoring (post-trade)	27
7.7	Sanity checks (liste courte)	27
8	Notes quant researcher : estimer μ, valider, éviter les mirages	28
8.1	Idée centrale	28
8.2	Cadre mathématique : du signal à $\hat{\mu}$	28
8.3	Intuition marché : pourquoi $\hat{\mu}$ casse	28
8.4	Validation (ce qu'un interview top-tier teste)	28
8.5	Implémentation : split purgé (pseudo-code)	29
8.6	Tests / sanity checks (3–6)	29
8.7	Pitfalls (quant researcher)	29
8.8	Pont vers pratique quant	29
9	Backtest stats : significativité, dépendance, overfitting (interview-level)	30
9.1	Idée centrale	30
9.2	Cadre : Sharpe, t-stat, dépendance	30
9.3	Queues, drawdowns, risque de modèle	30
9.4	Multiple testing : le vrai ennemi	30
9.5	Implémentation : effective sample size (diagnostic rapide)	31
9.6	Tests / sanity checks (3–6)	31
9.7	Pont vers pratique quant	31

Chapitre 1

Allocation & rebalancement

Idée centrale. Allocation = optimisation sous incertitude d'estimation : transformer des données en poids w sous contraintes (budget, long-only, turnover) en contrôlant le risque (covariance) et les coûts.

Cadre mathématique.

- **Markowitz.** Prototypes : GMV et tangency ; avec contraintes $\Rightarrow$ QP (long-only, bornes, sector caps).
- **Risque.** $\sigma_p^2 = w^\top \Sigma w$; contributions au risque (ERC) via $RC_i = w_i(\Sigma w)_i / \sigma_p$.
- **Estimation.** $\hat{\Sigma}$ instable $\Rightarrow$ shrinkage (Ledoit–Wolf), factor models/PKA, régularisation.
- **Frictions.** Turnover, coûts de transaction, impact $\Rightarrow$ pénalisation et contraintes.

Intuition marché / interprétation. Le piège pratique est l'optimiseur : sans régularisation, il amplifie le bruit d'estimation et produit des poids extrêmes. La performance out-of-sample est dominée par les erreurs sur Σ et par les coûts.

Implémentation.

- Estimer $\hat{\Sigma}$ (shrinkage) + $\hat{\mu}$ (robuste) ; résoudre QP ; intégrer coûts via pénalité $\lambda \|w - w_{prev}\|_1$ ou contrainte de turnover.
- Backtest walk-forward avec ré-estimation et coûts ; comparer à baselines (EW, vol targeting).

Tests / sanity checks.

- Contraintes : $\mathbf{1}^\top w = 1$ (budget), bornes respectées ; $\hat{\Sigma} \succeq 0$.
- Stabilité : poids/RC peu sensibles à de petites perturbations (sinon sur-ajustement).
- Coûts : turnover et P&L net cohérents ; diagnostics de concentration (HHI).

Pont vers pratique quant. Pont quant : construction de portefeuilles multi-actifs (risk budgeting), nettoyage de covariance (PCA), optimisation robuste (constraints + régularisation), et lien vers contrôle séquentiel (rebalancement/RL).

1.1 Avant-propos : Allocation & rebalancement (pont entre estimation et décision)

Jusqu'ici, on a vu deux familles de problèmes : (i) **pricer** des payoffs à partir d'une dynamique (pricing), et (ii) **estimer** des états/paramètres à partir de données (Kalman). Ici, on fait le pas naturel suivant : **décider** d'une allocation de portefeuille à partir d'entrées estimées. L'idée est volontairement « très praticien » :

$$\text{données} \Rightarrow (\hat{\mu}, \hat{\Sigma}) \Rightarrow w^* \Rightarrow \text{rebalancement} \Rightarrow PnL + \text{risques} + \text{coûts}.$$

1.1.1 Objectifs pédagogiques (niveau ultra-granulaire)

- Poser un **setup commun** (poids, contraintes, rendements, covariance) et savoir faire les checks de base (dimensions, convexité, cohérence d'annualisation).

- Dériver **pas à pas** les deux problèmes Markowitz incontournables :
 - minimum variance (GMV) : solution fermée et lecture géométrique ;
 - maximum Sharpe (tangency) : lien avec $\Sigma^{-1}(\mu - r_f \mathbf{1})$ et normalisation.
- Comprendre le **rebalancement** : pourquoi les poids dérivent, comment choisir une règle (time-based vs threshold-based) et comment intégrer les coûts (turnover).
- Construire un **risk parity** (ERC) : contributions au risque, formulation d'optimisation, algorithme (pseudo-code) et exemple numérique.
- Construire des **eigenportfolios** (PCA) : diagonalisation de Σ , interprétation, usage en réduction de dimension / nettoyage de covariance.
- Faire le lien **Kalman** $\rightarrow$ **allocation** $\rightarrow$ **RL** : Kalman fournit des entrées (état latent, volatilité) et RL généralise le rebalancement comme un contrôle séquentiel.

1.1.2 Pré-requis

- Algèbre linéaire : vecteurs/matrices, produit scalaire, matrices symétriques définies positives, valeurs propres.
- Probabilités/statistiques de base : moyenne, covariance, annualisation.
- Optimisation convexe niveau M1/M2 : Lagrangien, conditions du premier ordre (FOC), intuition des contraintes (KKT en toile de fond).

1.1.3 Plan du chapitre

1. Setup commun : notations, risque (variance), estimation de (μ, Σ) et checks.
2. Markowitz minimum variance : dérivation complète, interprétations, variante long-only (QP).
3. Markowitz maximum Sharpe : tangency portfolio, normalisation, exemple GMV vs tangency.
4. Rebalancement : dérive des poids, règles, coûts, pénalisation de turnover.
5. Risk parity (ERC) : contributions au risque, optimisation, algorithmes, exemple itératif.
6. Eigenportfolios (PCA) : décomposition spectrale, portefeuilles facteurs, covariance cleaning.
7. Mode microscope + exercices + pièges + checklist (savoir refaire sans regarder).

Interprétation marché. Dans la pratique de marché, l'erreur dominante vient rarement de Σ *en elle-même* (qu'on peut shrinker) : elle vient surtout (i) de l'instabilité de μ , (ii) du turnover et des coûts, (iii) des contraintes (long-only, leverage, limites). Ce chapitre est construit pour rendre ces points visibles, pas pour les cacher sous une formule.

Sanity check. On retiendra un fil rouge : *l'allocation est une optimisation d'entrées estimées*.
Donc on doit toujours demander : « quelle est la sensibilité de w^* à $\hat{\mu}$ et $\hat{\Sigma}$? »

1.2 Setup commun : univers, notations, estimation

On veut construire un portefeuille *explicable* et *pilotable* : un vecteur de poids w qui transforme des hypothèses statistiques (μ, Σ) en une décision d'investissement, puis en une trajectoire de PnL une fois qu'on ajoute le rebalancement et les coûts. Le but de ce chapitre est de rendre visibles les **chaînes** :

$$(\hat{\mu}, \hat{\Sigma}) \implies w^* \implies \text{rebalancement} \implies \text{PnL} \implies \text{risques} + \text{coûts}.$$

1.2.1 Univers, poids, contrainte de budget

On considère N actifs risqués, avec rendements (sur un horizon donné) regroupés dans un vecteur aléatoire

$$R = (R^1, \dots, R^N)^\top \in \mathbb{R}^N.$$

Une allocation est un vecteur de poids $w = (w_1, \dots, w_N)^\top$.

- **Contrainte de budget.** On impose en général $\mathbf{1}^\top w = 1$ (portefeuille « pleinement investi »).
- **Long-only vs short.** Long-only : $w_i \geq 0$ pour tout i . Sinon, on autorise $w_i < 0$ (vente à découvert) et/ou du leverage (somme des valeurs absolues > 1).

Notation. Convention de base. On travaille à poids constants sur un pas de temps : on choisit w_t à la date t , on tient le portefeuille sur $(t, t+1]$, puis on peut rebalancer à $t+1$. Le rendement du portefeuille sur le pas est alors (approximation standard en rendements simples) :

$$R_{p,t+1} = w_t^\top R_{t+1}.$$

1.2.2 Moments : moyenne et covariance

On note

$$\mu := \mathbb{E}[R] \in \mathbb{R}^N, \quad \Sigma := \text{Cov}(R) \in \mathbb{R}^{N \times N}.$$

Par définition,

$$\Sigma = \mathbb{E}[(R - \mu)(R - \mu)^\top],$$

donc Σ est symétrique et positive semi-définie.

Proposition 1.1 (Risque (variance) d'un portefeuille). *Sous les notations ci-dessus, le portefeuille $R_p = w^\top R$ a :*

$$\mathbb{E}[R_p] = w^\top \mu, \quad \text{Var}(R_p) = w^\top \Sigma w, \quad \sigma_p = \sqrt{w^\top \Sigma w}.$$

Démonstration. On utilise la linéarité de l'espérance : $\mathbb{E}[w^\top R] = w^\top \mathbb{E}[R] = w^\top \mu$. Ensuite,

$$\text{Var}(w^\top R) = \mathbb{E}[(w^\top (R - \mu))^2] = \mathbb{E}[w^\top (R - \mu)(R - \mu)^\top w] = w^\top \mathbb{E}[(R - \mu)(R - \mu)^\top] w = w^\top \Sigma w.$$

□

Check dimensionnel. Les poids w sont *sans unité*. La covariance Σ a l'unité « (rendement)² ». Donc $w^\top \Sigma w$ est bien un *rendement*² et σ_p un *rendement*.

1.2.3 Estimation, annualisation, stabilité (le point qui casse tout)

En pratique, (μ, Σ) ne sont pas connus : on travaille avec des estimateurs $(\hat{\mu}, \hat{\Sigma})$ calculés sur une fenêtre de données. Pour des rendements (simples ou log) observés $r_1, \dots, r_T \in \mathbb{R}^N$:

$$\hat{\mu} = \frac{1}{T} \sum_{t=1}^T r_t, \quad \hat{\Sigma} = \frac{1}{T-1} \sum_{t=1}^T (r_t - \hat{\mu})(r_t - \hat{\mu})^\top.$$

Annualisation (règle de pouce). Si les rendements sont *i.i.d.* à pas Δ (jour, semaine) :

$$\mu_{\text{ann}} \approx A \mu_\Delta, \quad \Sigma_{\text{ann}} \approx A \Sigma_\Delta, \quad \sigma_{\text{ann}} \approx \sqrt{A} \sigma_\Delta,$$

où A est le nombre de pas par an (252 jours ouvrés, 52 semaines, 12 mois).

Piège classique. Mélanger des horizons : utiliser $\hat{\mu}$ annualisé mais $\hat{\Sigma}$ à l'horizon mensuel (ou inversement) donne des poids incohérents. Un check simple : si vous changez l'unité de temps, les *poids* doivent rester identiques dans un problème sans friction et homogène (GMV, direction de tangence), car seule l'échelle du risque change.

Interprétation marché. Dans la pratique de marché, $\hat{\mu}$ est **beaucoup plus instable** que $\hat{\Sigma}$. Intuition : l'erreur sur une moyenne décroît comme $1/\sqrt{T}$ mais la moyenne elle-même est petite (quelques % par an), donc le signal/bruit est mauvais. À l'inverse, la structure de corrélation/volatilité est plus stable et se « shrinke » (Ledoit–Wolf, facteurs, cleaning). Conclusion : les portefeuilles « max Sharpe » sont très sensibles à $\hat{\mu}$, alors que GMV et ERC dépendent surtout de $\hat{\Sigma}$.

Sanity check. Si on multiplie Σ par une constante positive (changement d'horizon, unité), le GMV et la direction $\Sigma^{-1}(\mu - r_f \mathbf{1})$ ne changent pas : seule la *valeur* de la variance change.

1.3 Markowitz — Minimum Variance (GMV)

Le premier problème « industriel » est : **minimiser le risque** sans discuter le niveau de rendement attendu. C'est l'allocation la plus « robuste » quand μ est trop bruité.

1.3.1 Problème, convexité, existence

Le problème GMV (Global Minimum Variance) s'écrit :

$$\min_{w \in \mathbb{R}^N} w^\top \Sigma w \quad \text{s.c.} \quad \mathbf{1}^\top w = 1. \quad (1.1)$$

- Si $\Sigma \succeq 0$, l'objectif est convexe (quadratique).
- Si $\Sigma \succ 0$ (définie positive), l'objectif est *strictement* convexe : la solution est unique.

1.3.2 Solution fermée via Lagrangien (pas à pas)

Proposition 1.2 (Formule GMV). *Si $\Sigma \succ 0$, le problème (1.1) admet une unique solution :*

$$w^{\text{GMV}} = \frac{\Sigma^{-1} \mathbf{1}}{\mathbf{1}^\top \Sigma^{-1} \mathbf{1}}. \quad (1.2)$$

Démonstration. Dérivation (pas à pas). On pose le Lagrangien (une contrainte égalité) :

$$\mathcal{L}(w, \lambda) = w^\top \Sigma w - \lambda(\mathbf{1}^\top w - 1).$$

On dérive par rapport à w (règle : $\nabla_w(w^\top \Sigma w) = 2\Sigma w$ quand Σ est symétrique) :

$$\nabla_w \mathcal{L}(w, \lambda) = 2\Sigma w - \lambda \mathbf{1}.$$

Condition du premier ordre :

$$2\Sigma w - \lambda \mathbf{1} = 0 \quad \implies \quad w = \frac{\lambda}{2} \Sigma^{-1} \mathbf{1}.$$

On impose la contrainte $\mathbf{1}^\top w = 1$:

$$1 = \mathbf{1}^\top w = \frac{\lambda}{2} \mathbf{1}^\top \Sigma^{-1} \mathbf{1} \quad \implies \quad \frac{\lambda}{2} = \frac{1}{\mathbf{1}^\top \Sigma^{-1} \mathbf{1}}.$$

En remplaçant, on obtient (1.2). L'unicité vient de la stricte convexité quand $\Sigma \succ 0$. □

Sanity checks.

- **Contrainte.** $\mathbf{1}^\top w^{\text{GMV}} = 1$ par construction.
- **Dimensions.** Σ^{-1} a l'unité « $1/(\text{rendement})^2$ » ; multiplié par $\mathbf{1}$ (sans unité) puis normalisé, w est sans unité.
- **Diversification.** Si les actifs ne sont pas parfaitement corrélés, on peut obtenir σ_p inférieure à la plus petite vol individuelle.

1.3.3 Lecture géométrique (pour ne pas apprendre une formule par coeur)

On peut lire (1.1) comme une projection. Définissons un produit scalaire (dépendant de Σ) :

$$\langle x, y \rangle_\Sigma := x^\top \Sigma y, \quad \|x\|_\Sigma^2 := x^\top \Sigma x.$$

Alors l'objectif est $\|w\|_{\Sigma}^2$. Le GMV est donc le point de l'hyperplan affine $\{\mathbf{1}^{\top}w = 1\}$ le plus proche de 0 pour la norme $\|\cdot\|_{\Sigma}$. Cette lecture est utile pour comprendre :

- pourquoi la solution change peu si on modifie faiblement Σ (tant que la géométrie bouge peu) ;
- pourquoi ajouter des contraintes (long-only, bornes) revient à changer l'ensemble admissible : on projette sur un polytope au lieu d'un hyperplan.

1.3.4 Variante long-only : formulation QP (pas de solution fermée)

Si l'on impose $w_i \geq 0$, le problème devient :

$$\min_w w^{\top} \Sigma w \quad \text{s.c.} \quad \mathbf{1}^{\top} w = 1, \quad w \geq 0.$$

C'est un programme quadratique convexe (QP) quand $\Sigma \succeq 0$. **Mais** il n'y a en général pas de formule fermée : la solution dépend du *pattern d'actifs actifs/inactifs* (KKT). Dans la pratique, on résout numériquement (QP solver) et on contrôle :

- stabilité des poids (sensibilité à $\hat{\Sigma}$),
- concentration (poids max) et expositions (secteurs, devises),
- turnover induit par la re-optimisation.

1.3.5 Exemple numérique complet (3 actifs)

On se donne des volatilités annuelles $\sigma = (20\%, 10\%, 15\%)$ et une corrélation :

$$\text{Corr} = \begin{pmatrix} 1 & 0.2 & 0.1 \\ 0.2 & 1 & 0.3 \\ 0.1 & 0.3 & 1 \end{pmatrix}.$$

La covariance est $\Sigma_{ij} = \sigma_i \sigma_j \text{Corr}_{ij}$, donc

$$\Sigma = \begin{pmatrix} 0.04 & 0.004 & 0.003 \\ 0.004 & 0.01 & 0.0045 \\ 0.003 & 0.0045 & 0.0225 \end{pmatrix}.$$

Une inversion (ici numérique) donne :

$$\Sigma^{-1} \approx \begin{pmatrix} 26.089 & -9.748 & -1.529 \\ -9.748 & 113.532 & -21.407 \\ -1.529 & -21.407 & 48.930 \end{pmatrix}.$$

On calcule ensuite

$$v := \Sigma^{-1} \mathbf{1} \approx (14.813, 82.378, 25.994)^{\top}, \quad \mathbf{1}^{\top} v \approx 123.184,$$

et donc

$$w^{\text{GMV}} = \frac{v}{\mathbf{1}^{\top} v} \approx (0.120, 0.669, 0.211)^{\top}.$$

La variance et la vol du portefeuille valent :

$$\text{Var}(R_p) = w^{\top} \Sigma w \approx 0.00812, \quad \sigma_p \approx 9.01\%.$$

Sanity check. Ici, l'actif 2 a une vol individuelle de 10%. Le portefeuille GMV a une vol $\approx 9\%$: la diversification (corrélations < 1) permet de « passer sous » la meilleure vol individuelle.

Exercice 1.1. Vérifier (i) que $\mathbf{1}^{\top} w^{\text{GMV}} = 1$, (ii) que w^{GMV} minimise bien la variance parmi les portefeuilles pleinement investis (argument de convexité).

Correction détaillée. (i) La normalisation $w = v/(\mathbf{1}^{\top} v)$ force $\mathbf{1}^{\top} w = 1$. (ii) Quand $\Sigma \succ 0$, l'objectif $w \mapsto w^{\top} \Sigma w$ est strictement convexe, donc tout point stationnaire sous contrainte est l'unique minimiseur global. $\square$

1.4 Markowitz — Maximum Sharpe (portefeuille de tangence)

Le deuxième problème canonique est : **maximiser le Sharpe** à partir d'un taux sans risque r_f . Il faut ici être très clair sur les hypothèses : ce problème est *hyper sensible* à $\hat{\mu}$ et produit souvent des positions extrêmes si on n'impose pas de contraintes.

1.4.1 Définition du Sharpe

On pose le vecteur d'excès de rendement :

$$\tilde{\mu} := \mu - r_f \mathbf{1}.$$

Pour un portefeuille de poids w , le Sharpe (statique, sur l'horizon de modélisation) est :

$$\text{SR}(w) = \frac{w^\top \tilde{\mu}}{\sqrt{w^\top \Sigma w}}. \quad (1.3)$$

1.4.2 Dérivation : direction de tangence $\Sigma^{-1} \tilde{\mu}$

Proposition 1.3 (Portefeuille de tangence (direction max Sharpe)). *Supposons $\Sigma \succ 0$ et $\tilde{\mu} \neq 0$. Le problème de maximisation de (1.3) sur $w \neq 0$ a pour solution (au sens direction) :*

$$w \propto \Sigma^{-1} \tilde{\mu}. \quad (1.4)$$

Si l'on souhaite une normalisation à budget $\mathbf{1}^\top w = 1$ (portefeuille risqué pleinement investi), on prend :

$$w^{\text{tan}} = \frac{\Sigma^{-1} \tilde{\mu}}{\mathbf{1}^\top \Sigma^{-1} \tilde{\mu}}. \quad (1.5)$$

Démonstration. Dérivation (pas à pas). Le Sharpe est homogène de degré 0 : $\text{SR}(cw) = \text{SR}(w)$ pour tout $c > 0$. On peut donc imposer une contrainte d'échelle, par exemple $w^\top \Sigma w = 1$. Le problème devient :

$$\max_w w^\top \tilde{\mu} \quad \text{s.c.} \quad w^\top \Sigma w = 1.$$

Lagrangien :

$$\mathcal{L}(w, \lambda) = w^\top \tilde{\mu} - \lambda(w^\top \Sigma w - 1).$$

FOC : $\tilde{\mu} - 2\lambda \Sigma w = 0$, donc $w \propto \Sigma^{-1} \tilde{\mu}$. La normalisation à budget donne (1.5). $\square$

Piège classique. Sans contraintes (long-only, bornes, leverage, turnover), (1.5) peut produire des poids négatifs ou gigantesques. Ce n'est pas un bug : c'est la conséquence d'un estimateur $\hat{\mu}$ bruité et d'une optimisation qui « amplifie » le bruit.

1.4.3 Lien avec l'optimisation moyenne-variance

Une manière robuste de définir une famille de portefeuilles est l'objectif :

$$\max_{w \in \mathcal{C}} \left(w^\top \tilde{\mu} - \frac{\gamma}{2} w^\top \Sigma w \right), \quad (1.6)$$

où $\gamma > 0$ est un paramètre d'aversion au risque et $\mathcal{C}$ encode les contraintes (budget, long-only, bornes, etc.). Sans contraintes (et sans budget), le FOC donne $w(\gamma) = \frac{1}{\gamma} \Sigma^{-1} \tilde{\mu}$: *même direction* que la tangence, échelle contrôlée par γ .

Interprétation marché. En pratique, (1.6) est souvent plus stable que « max Sharpe pur ». On peut (i) régulariser Σ (shrinkage, facteurs), (ii) pénaliser la concentration (ℓ_2), (iii) pénaliser le turnover, (iv) imposer long-only/ bornes.

1.4.4 Exemple numérique : GMV vs tangence

On garde la même covariance Σ que dans §1.3.5. On suppose des rendements espérés (annualisés) et un taux sans risque :

$$\mu = (7\%, 4\%, 6\%)^\top, \quad r_f = 2\%.$$

On calcule $\tilde{\mu} = \mu - r_f \mathbf{1} = (5\%, 2\%, 4\%)^\top$ puis

$$w^{\text{tan}} = \frac{\Sigma^{-1} \tilde{\mu}}{\mathbf{1}^\top \Sigma^{-1} \tilde{\mu}} \approx (0.306, 0.270, 0.424)^\top.$$

Comparaison (ordre de grandeur) :

- GMV : $\mathbb{E}[R_p] \approx 4.78\%$, $\sigma_p \approx 9.01\%$, Sharpe ≈ 0.309 ;
- Tangence : $\mathbb{E}[R_p] \approx 5.76\%$, $\sigma_p \approx 10.48\%$, Sharpe ≈ 0.359 .

Sanity check. Dans cet exemple, la tangence augmente à la fois le rendement et le risque, mais améliore le ratio. Ce n'est pas garanti sous contraintes long-only : on peut être forcé de rester proche du GMV.

1.5 Rebalancement : pourquoi les poids dérivent, comment ajouter les coûts

Les allocations ci-dessus sont *statique* : elles donnent un w^* à partir de (μ, Σ) . En gestion réelle, on a un portefeuille dynamique : les poids **dérivent** avec les performances relatives, puis on **rebalancer** en payant des coûts.

1.5.1 Dérive des poids sans trading

Soit V_t la valeur du portefeuille juste après rebalancement à t avec poids w_t . Sur $(t, t+1]$, les actifs réalisent des rendements R_{t+1} . La valeur de la position i devient $w_{t,i} V_t (1 + R_{t+1}^i)$, et la valeur totale devient :

$$V_{t+1}^- = V_t (1 + w_t^\top R_{t+1}).$$

Donc, *avant* rebalancement à $t+1$, les poids « naturels » sont :

$$\tilde{w}_{t+1,i} = \frac{w_{t,i} (1 + R_{t+1}^i)}{1 + w_t^\top R_{t+1}}. \quad (1.7)$$

Sanity check. Si tous les actifs ont le même rendement $R_{t+1}^i = R$ alors $\tilde{w}_{t+1,i} = w_{t,i}$: les poids ne bougent pas quand il n'y a pas de performance relative.

1.5.2 Deux grandes familles de règles de rebalancement

- **Time-based.** On rebalancer à dates fixes (quotidien, hebdo, mensuel). Simple à backtester, facile à opérer.
- **Threshold-based.** On rebalancer quand un indicateur dépasse un seuil : dérive des poids ($\|\tilde{w}_{t+1} - w^*\|$), dérive de risque (vol cible), tracking error, etc.

Le point clé : **rebalancer trop souvent** augmente le turnover (coûts), **rebalancer trop rarement** laisse le risque et les expositions dériver.

1.5.3 Mesurer le turnover et modéliser les coûts

Une mesure standard de turnover (sur poids) est :

$$\text{TO}_{t+1} := \sum_{i=1}^N |w_{t+1,i} - \tilde{w}_{t+1,i}|,$$

où w_{t+1} sont les poids *après* rebalancement. Un modèle de coût linéaire très simple est :

$$\text{coût} \approx c \cdot \text{TO}_{t+1} \cdot V_{t+1}^-,$$

où c est un *coût en bps* (spread + fees + slippage moyen).

Interprétation marché. Les coûts réels dépendent du volume, de la liquidité, et de l'impact de marché : ils sont souvent *convexes* en taille (coût quadratique). Dans un premier modèle, une pénalité ℓ_1 (coûts linéaires) ou ℓ_2 (coûts quadratiques) capture déjà le fait que le turnover est le vrai ennemi de l'optimisation statique.

1.5.4 Optimisation avec pénalité de turnover : forme générique

Une façon simple d'intégrer les coûts est d'ajouter une pénalité à la distance à l'allocation courante. Par exemple, une version *mean-variance* avec turnover quadratique :

$$\max_{w \in \mathcal{C}} \left(w^\top \hat{\mu} - \frac{\gamma}{2} w^\top \hat{\Sigma} w - \frac{\lambda}{2} \|w - \tilde{w}_{t+1}\|^2 \right), \quad (1.8)$$

où $\tilde{w}_{t+1}$ est donné par (1.7), γ pilote le risque, et λ pilote « l'inertie » (donc le turnover).

Recette. Procédure rebalancement (baseline).

Étape 1: Estimer $(\hat{\mu}, \hat{\Sigma})$ sur une fenêtre roulante.

Étape 2: Calculer la cible statique w^* (GMV, tangence, ERC, etc.).

Étape 3: Mesurer les poids naturels $\tilde{w}_{t+1}$ via (1.7).

Étape 4: Résoudre une optimisation avec coûts, par ex. (1.8), pour obtenir w_{t+1} .

Étape 5: Appliquer un garde-fou : bornes de poids, contrôle de risque (vol cible), contrôle de concentration.

1.6 Risk Parity (ERC) : contributions au risque et algorithmes

L'idée du risk parity est de construire une allocation qui **ne dépend pas de μ** et qui équilibre le risque entre actifs (ou groupes d'actifs). On travaille donc surtout à partir de Σ .

1.6.1 Contributions au risque : définitions qui se checkent

On note $\sigma(w) = \sqrt{w^\top \Sigma w}$ la vol du portefeuille. Le *marginal risk contribution* (MRC) est la dérivée :

$$\frac{\partial \sigma(w)}{\partial w_i} = \frac{(\Sigma w)_i}{\sigma(w)}. \quad (1.9)$$

La *risk contribution* (RC) de l'actif i est :

$$\text{RC}_i(w) := w_i \frac{\partial \sigma(w)}{\partial w_i} = \frac{w_i (\Sigma w)_i}{\sigma(w)}. \quad (1.10)$$

Proposition 1.4 (Décomposition de la vol en contributions). *On a $\sum_{i=1}^N \text{RC}_i(w) = \sigma(w)$.*

Démonstration. En sommant (1.10) :

$$\sum_i \text{RC}_i(w) = \frac{1}{\sigma(w)} \sum_i w_i (\Sigma w)_i = \frac{w^\top \Sigma w}{\sigma(w)} = \sigma(w).$$

□

Sanity check. Les RC_i sont des « points de vol » : leur somme redonne la vol totale. On peut donc viser des parts de vol b_i et vérifier numériquement que $\text{RC}_i/\sigma \approx b_i$.

1.6.2 ERC : égaliser les contributions (ou cibler des budgets b_i)

Fixons des budgets $b_i \geq 0$ tels que $\sum_i b_i = 1$. Le problème « ERC » (Equal Risk Contribution) vise :

$$\frac{\text{RC}_i(w)}{\sigma(w)} = b_i \quad \text{pour tout } i, \quad \text{c.-à-d.} \quad w_i (\Sigma w)_i = b_i w^\top \Sigma w.$$

Typiquement, **ERC** correspond à $b_i = 1/N$.

1.6.3 Formulation optimisation (qui donne un algorithme)

Sous contrainte $w_i > 0$ (long-only strict), une formulation standard est :

$$\min_{w_i > 0} f(w) := \frac{1}{2} w^\top \Sigma w - \sum_{i=1}^N b_i \log w_i. \quad (1.11)$$

On montre en mode microscope que les FOC donnent :

$$(\Sigma w)_i - \frac{b_i}{w_i} = 0 \quad \Longleftrightarrow \quad w_i (\Sigma w)_i = b_i,$$

ce qui implique $w^\top \Sigma w = \sum_i b_i = 1$ (donc le minimiseur a *vol unité*). Ensuite, on renormalise souvent les poids pour imposer $\mathbf{1}^\top w = 1$: les *parts* de risque restent identiques.

1.6.4 Pseudo-code : itération multiplicative (simple et explicable)

Recette. ERC par mise à jour multiplicative (baseline). On veut $\text{RC}_i(w)/\sigma(w) = b_i$.

Étape 1: Initialiser $w^{(0)}$ (par ex. $w_i^{(0)} = 1/N$), avec $w_i^{(0)} > 0$.

Étape 2: Pour $k = 0, 1, 2, \dots$:

- calculer $\sigma^{(k)} = \sqrt{(w^{(k)})^\top \Sigma w^{(k)}}$;
- calculer les contributions $\text{RC}_i^{(k)} = \frac{w_i^{(k)} (\Sigma w^{(k)})_i}{\sigma^{(k)}}$;
- mise à jour multiplicative : $w_i^{(k+1)} \leftarrow w_i^{(k)} \cdot \frac{b_i \sigma^{(k)}}{\text{RC}_i^{(k)}}$;
- renormaliser $w^{(k+1)} \leftarrow w^{(k+1)} / (\mathbf{1}^\top w^{(k+1)})$.

Étape 3: Arrêter quand les parts RC_i/σ sont proches de b_i (tolérance).

1.6.5 Exemple numérique : ERC à 3 actifs (quelques itérations)

On reprend la covariance Σ de §1.3.5 et on vise $b_i = 1/3$. En partant de $w^{(0)} = (1/3, 1/3, 1/3)$, on obtient par exemple :

Itération	w_1	w_2	w_3
$k = 0$	0.333	0.333	0.333
$k = 1$	0.196	0.497	0.307
$k = 2$	0.277	0.417	0.306
$k = 3$	0.223	0.459	0.318

Après quelques itérations, on converge vers :

$$w^{\text{ERC}} \approx (0.258, 0.437, 0.305)^\top,$$

avec des parts de risque proches de $(1/3, 1/3, 1/3)$.

Piège classique. ERC n'est *pas* « diversification des poids » : c'est une diversification des *contributions au risque*. Si un actif est très volatil ou très corrélé aux autres, il peut recevoir un petit poids mais contribuer autant au risque.

1.7 Eigenportfolios (PCA) : diagonaliser la covariance pour comprendre et stabiliser

La PCA (analyse en composantes principales) n'est pas une allocation à elle seule : c'est une **brique de modélisation** de Σ . On l'utilise pour (i) comprendre les sources de risque, (ii) réduire la dimension, (iii) nettoyer/shrinker une covariance.

1.7.1 Rappel : décomposition spectrale de Σ

Comme Σ est symétrique PSD, il existe une base orthonormée de vecteurs propres :

$$\Sigma = Q\Lambda Q^\top, \quad (1.12)$$

où $Q = [q_1 | \dots | q_N]$ est orthogonale ($Q^\top Q = I$) et $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_N)$ avec $\lambda_1 \geq \dots \geq \lambda_N \geq 0$.

1.7.2 Facteurs PCA et « eigenportfolios »

Posons les facteurs

$$f := Q^\top R.$$

Alors $\text{Cov}(f) = Q^\top \Sigma Q = \Lambda$: les composantes f_k sont décorrélées et $\text{Var}(f_k) = \lambda_k$. On peut lire q_k comme un portefeuille (pas forcément investissable sous contrainte $\mathbf{1}^\top w = 1$) dont le rendement est $q_k^\top R$.

Interprétation marché. Interprétation : souvent, q_1 ressemble à un facteur « marché » (toutes composantes même signe) si l'univers est homogène. Mais ce n'est pas automatique : sur des actifs hétérogènes (taux, FX, commodities), la PCA mélange des échelles. Dans la pratique, on fait souvent la PCA sur la **corrélacion** (actifs standardisés) plutôt que sur la covariance.

1.7.3 Nettoyage de covariance : tronquer et shrinker le spectre

Une technique simple de « cleaning » est :

- garder les k plus grandes valeurs propres (signal),
- remplacer les autres (bruit) par une valeur moyenne (shrinkage),
- reconstruire $\tilde{\Sigma} = Q\tilde{\Lambda}Q^\top$ (reste PSD).

Cela stabilise Σ^{-1} et donc les portefeuilles GMV/tangence.

Recette. PCA/covariance cleaning (procédure).

Étape 1: Estimer une covariance $\hat{\Sigma}$ (sur rendements ou corrélations).

Étape 2: Diagonaliser : $\hat{\Sigma} = Q\Lambda Q^\top$.

Étape 3: Choisir k (variance expliquée, scree plot, critère simple).

Étape 4: Construire $\tilde{\Lambda}$:

$$— \tilde{\lambda}_1, \dots, \tilde{\lambda}_k = \lambda_1, \dots, \lambda_k ;$$

$$— \tilde{\lambda}_{k+1} = \dots = \tilde{\lambda}_N = \bar{\lambda} \text{ (moyenne des « petites » valeurs propres).}$$

Étape 5: Recomposer : $\tilde{\Sigma} = Q\tilde{\Lambda}Q^\top$ et utiliser $\tilde{\Sigma}$ dans GMV/tangence/ERC.

1.7.4 Exemple numérique : eigenvalues et variance expliquée

Avec la covariance à 3 actifs de §1.3.5, on obtient :

$$(\lambda_1, \lambda_2, \lambda_3) \approx (0.0412, 0.0230, 0.00828), \quad \frac{\lambda}{\text{tr}(\Sigma)} \approx (56.9\%, 31.7\%, 11.4\%).$$

Le premier vecteur propre vaut (au signe près) :

$$q_1 \approx (0.970, 0.152, 0.192)^\top.$$

Piège classique. Le signe des vecteurs propres est arbitraire : q et $-q$ définissent le même sous-espace. Ne pas sur-interpréter un changement de signe d'une fenêtre à l'autre : c'est un artefact numérique.

1.8 Synthèse comparative et pont vers RL

Méthode	Objectif	Entrées	Points d'attention (pratique)
GMV	Minimiser $w^\top \Sigma w$ sous budget	Σ	Stable si Σ shrinkée ; concentration possible ; contraintes long-only
Max Sharpe (tangence)	Maximiser $\frac{w^\top (\mu - r_f \mathbf{1})}{\sqrt{w^\top \Sigma w}}$	μ, Σ, r_f	Très sensible à μ ; risque de poids extrêmes ; régularisation/contraintes essentielles
ERC (risk parity)	Égaliser RC_i (ou cibler b_i)	Σ	Nécessite $w_i > 0$; algorithmes itératifs ; groupes/budgets utiles
PCA/eigenportfolios	Comprendre/cleaner Σ (facteurs)	Σ (spectre)	Choix de k ; PCA sur corrélation ; stabilité ; signe des vecteurs propres

TABLE 1.1 – Comparaison : ce que chaque méthode optimise et ce qui casse en pratique.

Interprétation marché. Le fil conducteur pour la suite (RL) est :

- une allocation statique donne une « cible » w^* à partir d'un *état estimé* (ex : via Kalman) ;
- le rebalancement, avec coûts, est déjà un **contrôle séquentiel** : on choisit w_t en fonction de l'historique et d'une fonction de coût ;
- RL généralise ce point : l'allocation devient une *politique* $\pi(s_t)$, et les contraintes/coûts/risques sont dans la reward.

1.9 Mode microscope : dérivations complètes et checks

1.9.1 Règles de calcul : dérivée d'une forme quadratique

On utilise plusieurs fois le fait que, pour Σ symétrique,

$$g(w) = w^\top \Sigma w \implies \nabla g(w) = 2\Sigma w.$$

Démonstration détaillée. On écrit $g(w) = \sum_{i,j} w_i \Sigma_{ij} w_j$. Alors

$$\frac{\partial g}{\partial w_k} = \sum_j \Sigma_{kj} w_j + \sum_i w_i \Sigma_{ik} = (\Sigma w)_k + (\Sigma^\top w)_k = 2(\Sigma w)_k,$$

car $\Sigma^\top = \Sigma$.

1.9.2 GMV : FOC, unicité, interprétation

On reprend (1.1).

- **Existence.** L'ensemble $\{w : \mathbf{1}^\top w = 1\}$ est non vide et fermé. L'objectif est continu et coercif sur cet hyperplan si $\Sigma \succ 0$ (il croît comme une norme). Donc un minimiseur existe.
- **Unicité.** Si $\Sigma \succ 0$, $w \mapsto w^\top \Sigma w$ est strictement convexe, donc le minimiseur est unique.

1.9.2.1 Check « invariance d'horizon »

Si on annualise : $\Sigma_{\text{ann}} = A\Sigma_\Delta$. Alors

$$w^{\text{GMV}}(\Sigma_{\text{ann}}) = \frac{(A\Sigma_\Delta)^{-1}\mathbf{1}}{\mathbf{1}^\top (A\Sigma_\Delta)^{-1}\mathbf{1}} = \frac{\Sigma_\Delta^{-1}\mathbf{1}}{\mathbf{1}^\top \Sigma_\Delta^{-1}\mathbf{1}} = w^{\text{GMV}}(\Sigma_\Delta).$$

Donc les poids ne dépendent pas de l'échelle de temps (dans le modèle frictionless).

1.9.3 Max Sharpe : preuve alternative (Cauchy–Schwarz)

On veut maximiser

$$\text{SR}(w) = \frac{w^\top \tilde{\mu}}{\sqrt{w^\top \Sigma w}}, \quad \tilde{\mu} = \mu - r_f \mathbf{1}.$$

Supposons $\Sigma \succ 0$ et notons $\Sigma^{1/2}$ sa racine symétrique. Posons

$$a := \Sigma^{1/2} w, \quad b := \Sigma^{-1/2} \tilde{\mu}.$$

Alors $w^\top \tilde{\mu} = a^\top b$ et $w^\top \Sigma w = \|a\|^2$. Par Cauchy–Schwarz :

$$w^\top \tilde{\mu} = a^\top b \leq \|a\| \|b\| = \sqrt{w^\top \Sigma w} \sqrt{\tilde{\mu}^\top \Sigma^{-1} \tilde{\mu}}.$$

Donc

$$\text{SR}(w) \leq \sqrt{\tilde{\mu}^\top \Sigma^{-1} \tilde{\mu}},$$

avec égalité si et seulement si a est colinéaire à b , i.e. $\Sigma^{1/2} w \propto \Sigma^{-1/2} \tilde{\mu}$, donc $w \propto \Sigma^{-1} \tilde{\mu}$.

Sanity check. Cette preuve met en évidence le « meilleur Sharpe atteignable » : $\sqrt{\tilde{\mu}^\top \Sigma^{-1} \tilde{\mu}}$. En pratique, quand $\hat{\Sigma}$ est mal conditionnée, ce nombre explose et signale une instabilité.

1.9.4 Rebalancement : dériver la formule de dérive des poids

On dérive (1.7) proprement. Soit V_t la valeur totale à t , et $V_{t,i} = w_{t,i}V_t$ la valeur investie dans l'actif i juste après rebalancement. Sans trading sur $(t, t+1]$:

$$V_{t+1,i}^- = V_{t,i}(1 + R_{t+1}^i) = w_{t,i}V_t(1 + R_{t+1}^i).$$

En sommant :

$$V_{t+1}^- = \sum_i V_{t+1,i}^- = V_t \sum_i w_{t,i}(1 + R_{t+1}^i) = V_t(1 + w_t^\top R_{t+1}).$$

Le poids naturel est le ratio :

$$\tilde{w}_{t+1,i} = \frac{V_{t+1,i}^-}{V_{t+1}^-} = \frac{w_{t,i}(1 + R_{t+1}^i)}{1 + w_t^\top R_{t+1}}.$$

1.9.5 ERC : gradient et conditions du premier ordre

On considère l'objectif (1.11) :

$$f(w) = \frac{1}{2}w^\top \Sigma w - \sum_{i=1}^N b_i \log w_i, \quad w_i > 0.$$

Gradient (composante par composante) :

$$\nabla f(w) = \Sigma w - (b_1/w_1, \dots, b_N/w_N)^\top.$$

Hessien :

$$\nabla^2 f(w) = \Sigma + \text{diag}\left(\frac{b_1}{w_1^2}, \dots, \frac{b_N}{w_N^2}\right),$$

donc si $\Sigma \succeq 0$, alors $\nabla^2 f(w) \succ 0$: le problème est strictement convexe sur $w_i > 0$ et le minimiseur est unique.

1.9.5.1 FOC et lien avec les budgets

FOC : $\nabla f(w) = 0$, donc

$$(\Sigma w)_i - \frac{b_i}{w_i} = 0 \quad \Longleftrightarrow \quad w_i(\Sigma w)_i = b_i.$$

En sommant,

$$w^\top \Sigma w = \sum_i b_i = 1,$$

et donc $\sigma(w) = 1$: le minimiseur a vol unité. Si on renormalise $\bar{w} = w/(\mathbf{1}^\top w)$ pour imposer $\mathbf{1}^\top \bar{w} = 1$, alors

$$\frac{\text{RC}_i(\bar{w})}{\sigma(\bar{w})} = \frac{\text{RC}_i(w)}{\sigma(w)} = b_i,$$

car les *parts* de contributions sont invariantes par mise à l'échelle de w .

1.9.6 PCA : checks structurels

Si $\Sigma = Q\Lambda Q^\top$:

- $\text{tr}(\Sigma) = \sum_i \lambda_i$ (variance totale = somme des valeurs propres).
- $\Sigma \succeq 0 \Longleftrightarrow \lambda_i \geq 0$ pour tout i .
- La troncature $\Lambda_k = \text{diag}(\lambda_1, \dots, \lambda_k, 0, \dots, 0)$ donne une matrice PSD de rang k : $Q\Lambda_k Q^\top \succeq 0$.

1.10 Pièges classiques / erreurs fréquentes

- **Instabilité de $\hat{\mu}$.** Max Sharpe sans régularisation produit des poids extrêmes et une performance hors échantillon dégradée.
- **Covariance mal conditionnée.** Inverser $\hat{\Sigma}$ sans shrinkage (ou avec T proche de N) amplifie le bruit.
- **Annualisation incohérente.** Mélanger des horizons (jour vs mois) sans ajuster μ et Σ .
- **Contraintes oubliées.** Budget, long-only, bornes, leverage, expositions : l'optimum théorique peut être non investissable.
- **Turnover ignoré.** Une stratégie peut être « gagnante » sans coûts et perdante dès qu'on ajoute 5–10 bps.
- **Biais de backtest.** Look-ahead, survivorship, biais de sélection, données révisées.
- **PCA mal interprétée.** Signe arbitraire, choix de k ad hoc, PCA covariance au lieu de corrélation sur des actifs d'échelles différentes.

1.11 Checklist - savoir refaire sans regarder

- **Setup.** Écrire w , $\mathbf{1}^\top w = 1$, μ , Σ , et $\text{Var}(R_p) = w^\top \Sigma w$ (check dimensions, annualisation).
- **GMV.** Écrire le problème, le Lagrangien, les FOC, obtenir $w^{\text{GMV}} = \Sigma^{-1} \mathbf{1} / (\mathbf{1}^\top \Sigma^{-1} \mathbf{1})$, faire les sanity checks.
- **Max Sharpe.** Définir $\tilde{\mu} = \mu - r_f \mathbf{1}$, montrer $w \propto \Sigma^{-1} \tilde{\mu}$, normaliser (budget) et discuter l'effet des contraintes.
- **Rebalancement.** Dériver la dérive des poids $\tilde{w}_{t+1}$ et savoir ajouter une pénalité de turnover.
- **ERC.** Définir MRC/RC, montrer $\sum_i \text{RC}_i = \sigma$, écrire l'objectif (1.11), calculer le gradient et itérer.
- **PCA.** Écrire $\Sigma = Q \Lambda Q^\top$, lire variance expliquée, construire un cleaning PSD, et savoir quoi checker (trace, signes, stabilité).

Chapitre 2

Toolbox interview : optimisation de portefeuille en production

2.1 Idée centrale

En entretien buy-side/sell-side, on ne teste pas seulement Markowitz : on teste ta capacité à relier **optimisation** $\leftrightarrow$ **estimation** $\leftrightarrow$ **frictions** $\leftrightarrow$ **robustesse**. Le portefeuille « optimal » est souvent dominé par l'erreur de covariance, les contraintes et les coûts.

2.2 Cadre mathématique : problèmes types

2.2.1 Mean–variance (forme « utility »)

$$\max_{w \in \mathbb{R}^n} \mu^\top w - \frac{\lambda}{2} w^\top \Sigma w \quad \text{s.c.} \quad \mathbf{1}^\top w = 1, \quad w \in \mathcal{C}.$$

Sans contraintes ($\mathcal{C} = \mathbb{R}^n$), $w^* = \frac{1}{\lambda} \Sigma^{-1} \mu$. Avec $\mathbf{1}^\top w = 1$:

$$w^* = a \Sigma^{-1} \mathbf{1} + b \Sigma^{-1} \mu, \quad \begin{pmatrix} \mathbf{1}^\top \Sigma^{-1} \mathbf{1} & \mathbf{1}^\top \Sigma^{-1} \mu \\ \mu^\top \Sigma^{-1} \mathbf{1} & \mu^\top \Sigma^{-1} \mu \end{pmatrix} \begin{pmatrix} a \\ b \end{pmatrix} = \begin{pmatrix} 1 \\ \kappa \end{pmatrix},$$

où κ fixe le niveau de rendement/aversion.

2.2.2 Min-variance / tracking error

Min-variance : $\min_w w^\top \Sigma w$ s.c. $\mathbf{1}^\top w = 1$. Tracking error vs benchmark w^{bmk} : $\min_w (w - w^{bmk})^\top \Sigma (w - w^{bmk})$ + contraintes.

2.2.3 CVaR (Expected Shortfall) : formulation LP

Pour pertes scénarisées $\ell_i(w)$ et niveau α ,

$$\min_{w, \eta, u} \eta + \frac{1}{(1 - \alpha)N} \sum_{i=1}^N u_i \quad \text{s.c.} \quad u_i \geq \ell_i(w) - \eta, \quad u_i \geq 0.$$

Atout : robuste aux queues, intégrable avec contraintes linéaires.

2.3 Estimation : Σ domine tout

2.3.1 Régime haute dimension

Si n est comparable à T (fenêtre), la covariance empirique est instable : eigenvalues bruitées $\Rightarrow$ allocations extrêmes.

2.3.2 Shrinkage (Ledoit–Wolf : idée)

$$\widehat{\Sigma} = \delta F + (1 - \delta)S, \quad \delta \in [0, 1],$$

où S est la covariance empirique, F une cible structurée (diagonale, single-factor, constant-correlation).

2.3.3 Factor models (pratique)

Modèle $r = Bf + \epsilon : \Sigma \approx B\Sigma_f B^\top + D$ (réduit variance d'estimation, contrôle des expositions).

2.4 Contraintes, coûts, turnover

2.4.1 Contraintes usuelles

- long-only : $w_i \geq 0$
- bornes : $w_i \in [w_i^{min}, w_i^{max}]$
- expositions : $Aw \leq b$ (secteur, pays, duration, beta)
- leverage : $\|w\|_1 \leq L$

2.4.2 Coûts de transaction (modèle simple)

Si w^{old} est l'allocation précédente, $\Delta w = w - w^{old}$. Coût linéaire $\propto \|\Delta w\|_1$ (bid-ask), coût quadratique $\propto \Delta w^\top \Gamma \Delta w$ (impact). Objectif typique :

$$\max_w \mu^\top w - \frac{\lambda}{2} w^\top \Sigma w - c_1 \|\Delta w\|_1 - \frac{c_2}{2} \Delta w^\top \Gamma \Delta w.$$

Lecture. Le terme L^1 induit sparsité et *no-trade region* (proximale).

2.5 Robust optimisation (interview-level)

2.5.1 Incertitude sur μ

Si μ est très bruité, beaucoup de desks fixent $\mu = 0$ et font min-var / risk parity ; ou utilisent μ shrinké (Bayes, Black–Litterman).

2.5.2 Incertitude sur Σ

Robustifier via ensembles ellipsoïdaux autour de $\widehat{\Sigma}$ conduit à des programmes convexes (SOCP) et limite les allocations extrêmes.

2.6 Sanity checks (à annoncer spontanément)

- $\mathbf{1}^\top w = 1$ (ou cash explicite), respect leverage/bornes.
- Décomposition du risque : contributions marginales $w_i(\Sigma w)_i$.

- Turnover $\|\Delta w\|_1$ vs budget coûts ; sensibilité au rebalancing.
- Stabilité : perturber μ, Σ (bootstrap) et mesurer dispersion des poids.

2.7 Pitfalls de backtest (quant researcher)

- **Look-ahead / leakage** (indices, corp actions, survivorship).
- **Non-stationnarité** : paramètres de risque varient par régime $\Rightarrow$ fenêtres adaptatives / shrinkage plus fort.
- **Friction mismatch** : coûts sous-estimés $\Rightarrow$ alpha fantôme (turnover).
- **Multiple testing** : choisir λ , fenêtre, univers sur la perf $\Rightarrow$ biais (corriger, nested CV).

2.8 Ce qu'on te demandera (format entretien)

- Pourquoi Markowitz produit des poids extrêmes et comment le corriger (shrinkage, contraintes, factor model).
- Comment intégrer les coûts et expliquer la *no-trade region*.
- Comment diagnostiquer une covariance « mauvaise » (eigenvalues, instabilité, N eff.).

Chapitre 3

Covariance en pratique : shrinkage, facteurs, nettoyage

3.1 Idée centrale

La matrice de covariance est l'objet *le plus fragile* du pipeline : elle est bruitée, non stationnaire, et sa pseudo-inversion amplifie le bruit. La plupart des « améliorations » de Markowitz sont en réalité des stratégies de **stabilisation de $\hat{\Sigma}^{-1}$** .

3.2 Échantillonnage : pourquoi l'empirique casse

Covariance empirique sur fenêtre T :

$$S = \frac{1}{T-1} \sum_{t=1}^T (r_t - \bar{r})(r_t - \bar{r})^\top.$$

En haute dimension (n/T non négligeable), les eigenvalues sont fortement biaisées (Marchenko–Pastur) $\Rightarrow$ allocations extrêmes.

3.3 Shrinkage (réflexe standard)

3.3.1 Principe

$$\hat{\Sigma} = (1 - \delta)S + \delta F, \quad \delta \in [0, 1],$$

où F est une cible structurée. **Rôle.** Réduire la variance d'estimation au prix d'un biais contrôlé.

3.3.2 Cibles usuelles

- **Diagonal** : $F = \text{diag}(S)$ (suppose corrélation nulle).
- **Constant-correlation** : toutes corrélations égales (Ledoit–Wolf CC).
- **Single-factor** : $F = \beta\beta^\top \sigma_f^2 + D$ (type CAPM).

3.4 Factor models : structure $\Sigma = B\Sigma_f B^\top + D$

Modèle rendements $r = Bf + \epsilon$.

- Réduction de dimension : estimer Σ_f (petite) est stable.

- Contrôle des expositions : contraintes directement sur $B^\top w$.
- **Diagnostic** : si le portefeuille est très chargé sur un eigenvector « bruit », c'est un red flag.

3.5 EWMA / covariance conditionnelle

$$\hat{\Sigma}_t = \lambda \hat{\Sigma}_{t-1} + (1 - \lambda) r_t r_t^\top, \quad \lambda \in (0, 1).$$

Trade-off. λ petit suit les régimes mais augmente le bruit ; λ grand est stable mais lent.

3.6 Nettoyage / PSD / inversion stable

- **PSD** : symétriser $(\Sigma + \Sigma^\top)/2$, clipper eigenvalues négatives.
- **Ridge** : $\Sigma_\varepsilon = \Sigma + \varepsilon I$ (stabilise Cholesky).
- **Condition number** : surveiller $\kappa(\Sigma)$; si énorme, Σ^{-1} est numériquement instable.

3.7 Sanity checks (pratique)

- Variances positives ; corrélations dans $[-1, 1]$.
- Stabilité hors échantillon : covariance sur sous-fenêtres.
- Contributions au risque cohérentes : $RC_i = w_i(\Sigma w)_i$.
- $\hat{\Sigma}$ prédit la volatilité réalisée (calibration de λ EWMA).

Chapitre 4

Friction, turnover, exécution : optimiser sous coûts

4.1 Idée centrale

En production, l'optimisation n'est pas statique : à chaque rebalance, tu arbitres **risque vs coût**. L'optimum présente typiquement une *no-trade region* : ne pas trader est optimal tant que le gain marginal est inférieur au coût marginal.

4.2 Modèles de coûts

4.2.1 Coût linéaire (spread, fees)

Pour $\Delta w = w - w^{old}$:

$$TC_{lin}(\Delta w) = c^\top |\Delta w|.$$

Convexe mais non différentiable (proximale / QP avec variables auxiliaires).

4.2.2 Impact quadratique (approximation)

$$TC_{quad}(\Delta w) = \frac{1}{2} \Delta w^\top \Gamma \Delta w, \quad \Gamma \succeq 0.$$

Interprétation : plus tu trades, plus tu paies (impact croissant).

4.3 Problème type (convexe)

$$\min_w \frac{\lambda}{2} w^\top \Sigma w - \mu^\top w + c_1 \|\Delta w\|_1 + \frac{c_2}{2} \Delta w^\top \Gamma \Delta w \quad \text{s.c.} \quad \mathbf{1}^\top w = 1, \quad w \in \mathcal{C}.$$

4.4 No-trade region : exemple 1D

Si on ignore Σ et qu'on maximise un gain linéaire αw avec coût $c|w - w^{old}|$, l'optimum est :

- $\alpha > c$: trader dans le sens du signal ;
- $|\alpha| \leq c$: **ne pas trader**.

Message. En multi-dimensions, c'est pareil mais dans une géométrie induite par Σ, Γ .

4.5 Lien exécution : Almgren–Chriss (interview-level)

Sur une fenêtre $[0, T]$, exécuter une quantité X avec coût d'impact + risque de prix conduit à un compromis coût moyen + $\eta \cdot$ variance. **Sortie attendue.** Profil d'exécution plus agressif si l'aversion au risque est élevée, plus lisse si l'impact est élevé.

4.6 Diagnostics en backtest

- Sensibilité aux coûts : multiplier c par 2/5/10 et voir si l'alpha survit.
- Turnover : distribution $\|\Delta w\|_1$, concentration sur quelques assets.
- Slippage : vérifier que la perf est *monotone* en fonction des frictions (sinon bug/leakage).

Chapitre 5

Optimisation en production : KKT, dualité, proximal/ADMM (dense)

5.1 Idée centrale

Sur desk, l'optimisation est (i) **convexe** (QP/SOCP/LP) mais (ii) **mal conditionnée** (covariance, contraintes, coûts) et (iii) résolue à haute fréquence (warm-start, robustesse). En entretien, on attend que tu saches **lire** un optimum via KKT/dual et proposer une méthode numérique stable.

5.2 KKT (lecture structurante)

Pour un QP convexe

$$\min_w \frac{1}{2} w^\top \Sigma w - \mu^\top w \quad \text{s.c.} \quad Aw \leq b, \quad \mathbf{1}^\top w = 1,$$

les conditions KKT (avec multiplicateurs $\lambda \geq 0$ et ν) :

$$\Sigma w - \mu + A^\top \lambda + \nu \mathbf{1} = 0, \quad Aw \leq b, \quad \lambda \geq 0, \quad \lambda_i (Aw - b)_i = 0.$$

Lecture desk. Les λ_i sont des *shadow prices* : contrainte active $\Rightarrow$ elle « coûte » en objectif.

5.3 Turnover L^1 : proximal (intuition) et ADMM (pratique)

Problème typique avec coût linéaire $c \|\Delta w\|_1$ ($\Delta w = w - w^{old}$) :

$$\min_w f(w) + c \|\Delta w\|_1, \quad f(w) = \frac{1}{2} w^\top \Sigma w - \mu^\top w \quad (+\text{contraintes}).$$

5.3.1 Prox (cas simple)

Si f est proche d'un terme quadratique isotrope, la mise à jour « prox » ressemble à un **soft-thresholding** sur Δw :

$$\text{soft}(x, \kappa) = \text{sgn}(x) \max(|x| - \kappa, 0).$$

```
import numpy as np
def soft(x, kappa):
    return np.sign(x)*np.maximum(np.abs(x)-kappa, 0.0)
```

5.3.2 ADMM (pattern standard)

Poser $z = \Delta w$ et imposer $z = w - w^{old}$:

$$\min_{w,z} f(w) + c\|z\|_1 \quad \text{s.c. } z = w - w^{old}.$$

ADMM alterne :

- w -update : QP (souvent résolu via Cholesky, warm-start) ;
- z -update : $z \leftarrow \text{soft}(w - w^{old} + u, c/\rho)$;
- dual : $u \leftarrow u + (w - w^{old} - z)$.

Message. La non-différentiabilité L^1 est gérée par le proximal (soft).

5.4 Conditionnement et stabilité

- Si Σ est mal conditionnée : ridge $\Sigma \leftarrow \Sigma + \varepsilon I$ (stabilise Cholesky).
- Rebalancing répété : warm-start + tolérances adaptatives $\Rightarrow$ gros gain de temps.
- Long-only : solution souvent sur une face du simplexe $\Rightarrow$ actif-set, coordinate descent (rapide).

5.5 Tests / sanity checks (solver-level)

- Primal feasibility : contraintes respectées (budget, bornes, expositions).
- Dual gap / KKT residual : stationnarité $\|\Sigma w - \mu + A^\top \lambda + \nu \mathbf{1}\|$ petite.
- Monotonie vs coûts : augmenter c doit réduire $\|\Delta w\|_1$.
- Sensibilité : petites perturbations de μ, Σ ne doivent pas changer w de manière catastrophique (sinon manque de régularisation).

5.6 Pont vers pratique quant

- **Portfolio construction** : QP/SOCP avec contraintes factorielles, risk budgets, turnover.
- **Execution-aware** : intégrer impact (quadratique) à l'optim (stabilise le trading).
- **Research** : comparer des formulations (mean-var vs CVaR vs TE) et mesurer la stabilité hors échantillon.

Chapitre 6

Alternatives à Markowitz : risk parity, Black–Litterman, heuristiques

6.1 Idée centrale

Quand μ est trop bruité, on bascule souvent vers des objectifs *risk-based* (min-var, risk parity) ou vers une *prior* structurée sur μ (Black–Litterman). En entretien, on veut que tu saches **quand** et **pourquoi** ces approches dominent Markowitz.

6.2 Risk parity / ERC (Equal Risk Contribution)

6.2.1 Définitions

Pour un portefeuille w , la volatilité est $\sigma_p = \sqrt{w^\top \Sigma w}$. La contribution marginale au risque est $\partial_{w_i} \sigma_p = (\Sigma w)_i / \sigma_p$. La contribution au risque (vol) :

$$RC_i = w_i \frac{(\Sigma w)_i}{\sigma_p}.$$

ERC impose $RC_i = \sigma_p / n$ (ou proportionnelles à des budgets b_i).

6.2.2 Solve (pratique)

Problème non linéaire convexe sous conditions (long-only, $\Sigma \succ 0$). Méthodes : Newton sur log-weights, coordinate descent, ADMM. **Sanity** : si les corrélations augmentent, risk parity se concentre sur les actifs low-vol / low-corr.

6.3 Maximum diversification

Maximiser le ratio :

$$DR(w) = \frac{w^\top \sigma}{\sqrt{w^\top \Sigma w}},$$

où σ est le vecteur de volatilités individuelles. Intuition : charger des actifs faiblement corrélés pour maximiser *diversification effective*.

6.4 Black–Litterman (BL) : prior + vues

6.4.1 Idée

On part d'une *prior* sur les rendements attendus (souvent d'équilibre CAPM) :

$$\mu_0 = \delta \Sigma w^{mkt},$$

puis on ajoute des vues linéaires $P\mu = q$ avec incertitude Ω .

6.4.2 Posterior (forme standard)

$$\mu_{BL} = \mu_0 + \Sigma P^\top (P \Sigma P^\top + \Omega)^{-1} (q - P \mu_0),$$

avec un paramètre τ souvent introduit ($\tau \Sigma$) pour refléter l'incertitude sur la prior. **Lecture.** Si Ω est grande (vues incertaines), $\mu_{BL} \approx \mu_0$; si petite, on colle aux vues.

6.5 Heuristiques robustes (quand le pipeline est fragile)

- **Equal-weight** (EW) : baseline incroyablement difficile à battre net de coûts.
- **Vol targeting** : fixer σ_p via scaling, gérer la marge/leverage.
- **Risk control** : caps par secteur, beta, duration, exposure factor.

6.6 Ce qu'on te demandera (format entretien)

- Définir et calculer RC_i ; expliquer pourquoi ERC est plus stable que Markowitz.
- Donner la formule BL et l'interprétation de Ω , τ , δ .
- Comparer EW vs min-var vs risk parity quand les corrélations montent.

Chapitre 7

Pipeline complet : données $\rightarrow$ risk model $\rightarrow$ optim $\rightarrow$ monitoring

7.1 Idée centrale

Le *portfolio optimizer* n'est qu'un module. En entretien, on attend une vision système : où sont les sources d'erreurs (données, estimation, exécution) et comment les contrôler par des diagnostics.

7.2 Données (avant l'optimisation)

- **Alignement temporel** : close-to-close vs open-to-close, fuseaux, holidays.
- **Corporate actions** : splits/dividendes $\Rightarrow$ returns cohérents.
- **Survivorship** : univers $\Rightarrow$ inclure delisted pour backtests.
- **Nettoyage** : outliers (winsorize), stale prices (liquidité), missing data.

7.3 Risk model (ce que tu livres vraiment)

- **Covariance** : shrinkage/factor/EWMA ; PSD ; condition number.
- **Expositions** : secteurs, styles (value, momentum), beta, duration, FX.
- **Scénarios** : stress macro (rates up/down), corrélations $\uparrow$, vol spikes.

7.4 Optimisation (décisions)

- **Objectif** : min-var / tracking error / mean-variance / CVaR.
- **Contraintes** : budgets risque, caps, leverage, concentration, turnover.
- **Frictions** : coûts (spread/impact), lots, borrow (short), restrictions.

7.5 Exécution (traduire en trades)

- **Trade list** : Δw en quantités, prise en compte du cash et des arrondis.
- **Scheduling** : TWAP/VWAP/Almgren-Chriss selon urgence et impact.
- **Pre-trade risk** : vérifier expositions et contraintes *avant* envoi.

7.6 Monitoring (post-trade)

- **Attribution** : performance par facteurs/secteurs, PnL expliquée vs inexpliquée.
- **Risque** : contributions au risque, drawdown, tail events.
- **Drift** : changement de régime $\Rightarrow$ recalibrer λ EWMA, shrinkage, contraintes.

7.7 Sanity checks (liste courte)

- Les résultats sont monotones : plus de coûts $\Rightarrow$ moins de perf.
- Les contraintes sont respectées *après* exécution (slippage, partial fills).
- Le pipeline est reproductible : mêmes inputs $\Rightarrow$ mêmes weights.

Chapitre 8

Notes quant researcher : estimer μ , valider, éviter les mirages

8.1 Idée centrale

En pratique, $\hat{\Sigma}$ est déjà difficile, mais $\hat{\mu}$ est **bien pire** : bruit extrême, instabilité par régime, sur-ajustement. Un process « Wall Street level » est un pipeline : **signal** $\rightarrow$ **prévision** (shrinkage) $\rightarrow$ **optim sous frictions** $\rightarrow$ **validation** (purge/leakage/multiple testing) $\rightarrow$ **monitoring**.

8.2 Cadre mathématique : du signal à $\hat{\mu}$

8.2.1 Régression (cross-sectional ou time-series)

Modèle simple :

$$r_{t+1} = \alpha + \beta s_t + \varepsilon_{t+1}, \quad \hat{\mu}_{t+1} = \hat{\alpha} + \hat{\beta} s_t.$$

Point clé. β est régime-dépendant (vol, corrélations) $\Rightarrow$ estimation adaptative (fenêtre/glissante) + shrinkage.

8.2.2 Shrinkage / Bayes (réflexe)

Prior $\mu \sim \mathcal{N}(0, \tau^2 I)$ et estimateur bruité $\hat{\mu} \mid \mu \sim \mathcal{N}(\mu, \Sigma_\mu)$ donnent un posterior

$$\mu^{post} = (\Sigma_\mu^{-1} + \tau^{-2} I)^{-1} \Sigma_\mu^{-1} \hat{\mu},$$

donc μ^{post} est un **shrinkage vers 0**. **Lecture.** Plus Σ_μ est grande (signal faible), plus on shrink.

8.3 Intuition marché : pourquoi $\hat{\mu}$ casse

- Horizon court : microstructure + coûts dominant.
- Horizon long : non-stationnarité (régimes) + contraintes/capacity dominant.
- Beaucoup d'alpha « backtest » est une erreur de données (leakage) ou un multiple testing non contrôlé.

8.4 Validation (ce qu'un interview top-tier teste)

8.4.1 Time-series CV : purge + embargo

Si les labels utilisent des fenêtres qui se chevauchent (ex : returns sur $[t, t+h]$), une split naïve fuit. Il faut **purger** les observations qui chevauchent le test set, et imposer un **embargo** (buffer) autour.

8.4.2 Multiple testing

Si tu tentes M variantes et tu reportes la meilleure, ton Sharpe est optimiste. Outils : hold-out strict, nested CV, corrections type FDR (Benjamini–Hochberg), et diagnostics de *stability* (même signal $\Rightarrow$ mêmes expositions).

8.5 Implémentation : split purgé (pseudo-code)

```
def purged_split(indices, test_start, test_end, horizon, embargo):
    test = [i for i in indices if test_start <= i <= test_end]
    # purge: drop points whose label window overlaps test window
    train = [i for i in indices if i < test_start - horizon or i > test_end +
             horizon]
    # embargo: drop points close to test window to avoid leakage via features
    train = [i for i in train if i < test_start - embargo or i > test_end + embargo
             ]
    return train, test
```

8.6 Tests / sanity checks (3–6)

- Baselines **difficiles à battre** : equal-weight, min-var, risk parity, no-trade (net de coûts).
- Sensibilité : faire varier fenêtre, universe, coûts ; la perf doit décroître quand les frictions montent.
- Stabilité : corrélation des poids et des expositions d’une période à l’autre (sinon sur-ajustement).
- Attribution : PnL expliquée par facteurs vs idiosyncratique ; si tout vient d’un facteur non voulu, c’est un red flag.
- Capacity : perf vs volume/ADV ; slippage réaliste.

8.7 Pitfalls (quant researcher)

- Utiliser des features non disponibles (survivorship, revisions, look-ahead).
- Optimiser les hyperparamètres sur le test set (data snooping).
- Sous-estimer l’impact : alpha « fantôme » à turnover élevé.
- Confondre $\hat{\mu}$ prédictif et exposition à un facteur de risque (beta) : l’un n’est pas l’autre.

8.8 Pont vers pratique quant

- **Alpha combiner** : shrinkage + neutralisation factorielle + contraintes d’exposition + coûts.
- **Robust optimisation** : pénalisation L^2 sur w (ridge), incertitude sur μ (sets), ou objectifs risk-based.
- **Monitoring** : drift de régime (IC, turnover, impact), re-calibrage et kill-switch.

Chapitre 9

Backtest stats : significativité, dépendance, overfitting (interview-level)

9.1 Idée centrale

Un bon quant researcher ne vend pas un Sharpe « brut » : il sait (i) corriger l'**autocorrélation** et les retours non-Gaussiens, (ii) gérer **overfitting** et multiple testing, (iii) relier statistique $\leftrightarrow$ capacity/coûts. La statistique doit soutenir la décision de déploiement.

9.2 Cadre : Sharpe, t-stat, dépendance

9.2.1 Naïf (i.i.d.)

Si les returns r_t sont i.i.d. (approx), $\hat{\mu} = \frac{1}{T} \sum r_t$, $\hat{\sigma}$, et Sharpe annualisé $\widehat{SR} = \frac{\hat{\mu}}{\hat{\sigma}} \sqrt{A}$. Heuristique entretien : t-stat de la moyenne $\approx \widehat{SR} \sqrt{T/A}$.

9.2.2 Avec autocorrélation (HAC/Newey–West)

La variance de la moyenne est

$$\text{Var}(\hat{\mu}) \approx \frac{1}{T} \left(\gamma_0 + 2 \sum_{k=1}^L \omega_k \gamma_k \right),$$

avec $\gamma_k = \text{Cov}(r_t, r_{t-k})$ et poids ω_k (Newey–West). **Message.** Un Sharpe « joli » peut n'être qu'une autocorrélation/microstructure.

9.3 Queues, drawdowns, risque de modèle

- Returns non symétriques $\Rightarrow$ regarder skew/kurtosis, ES/CVaR, et pas seulement σ .
- Drawdown : la distribution du MDD dépend fortement de la dépendance et du regime ; un « petit » MDD en backtest est suspect si trop court.
- Stresser corrélations/vols : en crise, tout converge (corr $\uparrow$), les coûts montent.

9.4 Multiple testing : le vrai ennemi

- Si tu testes M stratégies et tu gardes la meilleure, tu optimises sur le bruit.

- Réflexes : hold-out strict, nested CV, et **stability** (mêmes expositions/IC dans le temps).
- Mesures usuelles (interview-level) : Probabilistic Sharpe Ratio (PSR) / Deflated Sharpe Ratio (DSR) pour tenir compte de non-normalité et data-snooping.

9.5 Implémentation : effective sample size (diagnostic rapide)

```
import numpy as np

def eff_n_from_acf(r, L=20):
    r = np.asarray(r) - np.mean(r)
    T = len(r)
    acf = []
    v = np.dot(r, r) / T
    for k in range(1, min(L, T-1)+1):
        acf_k = np.dot(r[k:], r[:-k]) / (T-k) / v
        acf.append(acf_k)
    # Bartlett approximation
    n_eff = T / (1 + 2*sum((1 - (k+1)/(L+1))*acf[k] for k in range(len(acf))))
    return max(1.0, n_eff)
```

Lecture. Si $n_{\text{eff}} \ll T$, les p-values naïves sont trompeuses.

9.6 Tests / sanity checks (3–6)

- Walk-forward : perf stable sur sous-périodes (pas de « one lucky regime »).
- Sensibilité aux coûts : multiplier les frictions (x2, x5) ; la perf doit décroître graduellement.
- Baselines : EW/min-var/risk parity/no-trade à battre *net*.
- Stability : IC, turnover, expositions factoriels stables ; sinon overfit.
- Capacity : perf vs ADV/impact ; si la strat ne scale pas, elle ne déploie pas.

9.7 Pont vers pratique quant

- Comité de validation : fournir stats ajustées (HAC), stress tests, et analyse de failure modes.
- Monitoring live : détecter drift (IC, slippage, fill rates), kill-switch et re-calibrage.

Interview Pack — Partie VIII (core)

Décision / ML (DQN, applications finance)

Table des matières

1	RL & Q-learning	1
1.1	Avant-propos : décision séquentielle (RL, Bellman, Q-learning)	1
	Avant-propos : prérequis, notations, objectifs	2
1.2	Introduction : contexte du RL (et perspective finance)	3
1.3	MDP et équations de Bellman : la base mathématique	4
1.4	De la programmation dynamique à l'échantillonnage : MC, TD, GPI	6
1.5	Contrôle tabulaire : SARSA, Expected SARSA, Q-learning	8
1.6	Mode microscope : Bellman, contraction et convergence (tabulaire)	10
1.7	Pièges classiques / erreurs fréquentes	10
1.8	Checklist — savoir refaire sans regarder	10
2	DQN - architecture, stabilisation, diagnostics	11
2.1	Avant-propos : DQN (approximer Q^* avec un réseau)	11
2.2	Approximation de fonction : pourquoi et comment (avant le DQN)	12
2.3	Deep Q-Network (DQN) : de Q-learning à l'approximation profonde	13
2.4	Au-delà de DQN : biais de surestimation et améliorations	16
2.5	Mode microscope : perte DQN et stabilisation	17
2.6	Pièges classiques / erreurs fréquentes	17
2.7	Checklist — savoir refaire sans regarder	17
3	Application finance (hedging/trading) : MDP, reward, limites	18
3.1	Avant-propos : appliquer le RL à la finance (MDP, reward, limites)	18
3.2	Finance quantitative : formuler un problème (hedging/trading) en MDP	19
3.3	Ouverture : modèle de Heston et volatilité stochastique	20
3.4	Exploration, exploitation et politiques stochastiques	21
3.5	Off-policy, données historiques et « distribution shift »	22
3.6	Synthèse : ce qu'il faut savoir ré-expliquer	23
3.7	Preuve détaillée : contraction de l'opérateur de Bellman	24
3.8	Stochastic approximation et conditions de convergence (tabulaire)	24
3.9	DQN en pratique : checklist d'implémentation et diagnostics	26
3.10	Risque, utilité et design de récompense en finance	27
3.11	Complément : Heston (mesure, moments, simulation)	28
3.12	Mode microscope : formuler un problème finance en MDP	28
3.13	Pièges classiques / erreurs fréquentes	29
3.14	Checklist — savoir refaire sans regarder	29
4	RL en production : offline RL, OPE, contraintes de risque	30

4.1	Idée centrale	30
4.2	Offline RL : pourquoi c'est dur	30
4.3	OPE (Off-Policy Evaluation) : outils interview-level	30
4.4	Conservatism (éviter l'extrapolation)	30
4.5	Contraintes de risque (indispensable)	31
4.6	Tests / sanity checks	31
5	RL finance avancé : risque, contraintes, évaluation (interview-level)	32
5.1	Idée centrale	32
5.2	Cadre mathématique : risque et contraintes	32
5.3	Implémentation : Lagrangian DQN (sketch)	33
5.4	Évaluation (OPE) : réflexes	33
5.5	Tests / sanity checks (3–6)	33
5.6	Pont vers pratique quant	33

Chapitre 1

RL & Q-learning

Idee centrale. Formuler la décision séquentielle comme un MDP : Bellman, valeurs V/Q , et apprentissage par itération stochastique (Q-learning). La clé est la rigueur sur « état = information disponible ».

Cadre mathématique.

- **MDP.** $(\mathcal{S}, \mathcal{A}, P, r, \gamma)$; politique $\pi(a | s)$; retour $G_t = \sum_{k \geq 0} \gamma^k r_{t+k}$.
- **Bellman.** $V^\pi = T^\pi V^\pi$; optimalité $V^* = TV^*$ (contraction si $\gamma < 1$).
- **Q-learning.** $Q \leftarrow Q + \alpha (r + \gamma \max_{a'} Q(s', a') - Q(s, a))$ (off-policy).

Intuition marché / interprétation. En finance, le danger est moins l'algorithme que la modélisation : non-stationnarité, POMDP (état incomplet), coûts de transaction/impact, et validation out-of-sample (leakage).

Implémentation.

- Implémenter tabulaire sur un MDP jouet (contrôle) puis introduire coûts/contraintes progressivement.
- Design reward : P&L net de coûts + pénalités de risque (variance, CVaR, drawdown); normalisation des échelles.

Tests / sanity checks.

- MDP jouet : convergence des valeurs vers solution DP connue (sanity).
- Sensibilité : performance stable vs seed et découpage temporel (walk-forward).
- Baselines : no-trade, delta-hedge simple, policy heuristique (doivent être battues de façon robuste).

Pont vers pratique quant. Pont quant : exécution (inventaire/impact), hedging discret (coûts), allocation dynamique, et contrôle stochastique (DP) avec contraintes opérationnelles.

1.1 Avant-propos : décision séquentielle (RL, Bellman, Q-learning)

On sort maintenant du « pricing » et de l'« estimation » pour entrer dans la **décision** : on choisit des actions au fil du temps (trader, hedger, exécuter) en observant un état et en subissant un bruit. Le formalisme unificateur est celui des *processus de décision markoviens* (MDP).

1.1.1 Objectifs pédagogiques

- Définir proprement un MDP : états, actions, transitions, récompenses, et horizon.
- Construire les fonctions de valeur V^π et Q^π et dériver les équations de Bellman.
- Comprendre les opérateurs de Bellman comme des **contractions** (preuve) et lire la programmation dynamique comme un point fixe.
- Dériver Q-learning tabulaire comme une itération stochastique vers le point fixe optimal.

1.1.2 Pré-requis

- Probabilités élémentaires et chaînes de Markov (au niveau définitions).
- Notion d'optimisation / descente de gradient (utile pour DQN au chapitre suivant).

1.1.3 Plan du chapitre

1. MDP et valeurs : V^π , Q^π , retour, facteur d'actualisation γ .
2. Bellman : dérivations et contraction (preuve détaillée).
3. Control tabulaire : SARSA, Q-learning, exploration/exploitation.
4. Conditions de convergence (intuition) et limites hors tabulaire.

Intuition de marché. En finance, le RL apparaît dès qu'on doit décider séquentiellement sous contraintes et frictions : hedging discret avec coûts, exécution (market impact), allocation dynamique. Le plus dur n'est pas l'algorithme mais le *design* : état, reward, contraintes, et validation hors échantillon.

Résumé

Ces notes introduisent l'apprentissage par renforcement (*Reinforcement Learning*, RL) puis construisent, à partir de la base, les algorithmes de contrôle **tabulaires** (Q-learning, SARSA, Expected SARSA) et leur extension **profonde** : le **Deep Q-Network** (DQN).

L'objectif est pédagogique : comprendre *d'où vient* chaque équation (Bellman, erreur TD, mise à jour stochastique), puis expliquer *pourquoi* la version réseau de neurones est instable sans deux idées clés : **rejeu d'expérience** (*experience replay*) et **réseau cible** (*target network*). On dérive pas à pas la fonction de perte du DQN, sa descente de gradient (semi-gradient) et on discute les pièges (biais de surestimation, non-stationnarité, validation).

La dernière partie ouvre vers la finance quantitative : comment formuler un problème de décision séquentielle (hedging/trading) comme un MDP, puis comment utiliser un modèle de dynamique (notamment **Heston** et sa volatilité stochastique) pour simuler un environnement d'entraînement et comprendre les enjeux d'observabilité (variance latente) et de robustesse.

Avant-propos : prérequis, notations, objectifs

Prérequis. Ces notes visent des étudiants de M1 en finance quantitative (maths post-prépa). On suppose acquis :

- calcul différentiel, algèbre linéaire (produits scalaires, projections) ;
- probabilités de base (lois usuelles, espérance, variance, conditionnement) ;
- optimisation (descente de gradient, convexité de base) ;
- intuition financière sur le PnL, les coûts de transaction et les arbitrages.

Philosophie du cours. On construit les équations *from the ground up* : on part du modèle (MDP), on écrit les relations exactes (Bellman), puis on montre comment des algorithmes pratiques apparaissent en remplaçant les espérances par des échantillons (mises à jour TD). L'objectif n'est pas d'être exhaustif mais d'être **ré-explicable à l'oral**.

Objectifs. À la fin, vous devez pouvoir :

1. définir un MDP $(\mathcal{S}, \mathcal{A}, \mathcal{P}, \mathbf{r}, \gamma)$ et expliquer la propriété de Markov ;
2. définir V^π et Q^π , et interpréter $Q^\pi(s, a)$ comme « la valeur de faire a puis suivre π » ;
3. dériver les mises à jour de SARSA, Expected SARSA, Q-learning et expliquer *on-policy* vs *off-policy* ;
4. dériver la perte DQN et sa descente de gradient (semi-gradient) ;

5. expliquer le rôle du replay buffer et du target network ;
6. faire le lien avec un problème de hedging simulé sous Heston (volatilité stochastique).

Notations. On travaille en temps discret $t = 0, 1, 2, \dots$. On note :

$$S_t \in \mathcal{S}, \quad A_t \in \mathcal{A}, \quad R_{t+1} \in \mathbb{R}, \quad \gamma \in [0, 1).$$

La politique est $\pi(a \mid s)$. Le retour est

$$G_t := \sum_{k=0}^{\infty} \gamma^k R_{t+1+k}.$$

Attention au symbole γ en finance. Dans ces notes, γ est le *discount factor* du RL. Ne pas confondre avec le Gamma d'une option.

1.2 Introduction : contexte du RL (et perspective finance)

1.2.1 Une optimisation à boucle fermée

Le RL formalise une situation où :

1. un **agent** observe un état S_t ;
2. choisit une action A_t ;
3. reçoit une récompense R_{t+1} et observe un nouvel état S_{t+1} ;
4. répète.

L'objectif est de maximiser un gain cumulé (le retour) en prenant en compte les conséquences futures.

1.2.2 Pourquoi ce cadre est naturel en finance ?

Plusieurs problèmes quantitatifs sont intrinsèquement séquentiels :

- **hedging discret** avec coûts de transaction ;
- **exécution optimale** (impact, contrainte de temps) ;
- **market making** (inventaire, risque, spread) ;
- **allocation dynamique** (contraintes, aversion au risque).

Le point commun : la décision modifie l'exposition au risque et donc la distribution future du PnL.

1.2.3 Fil conducteur : hedging discret comme MDP

Pour fixer les idées, pensons à une option européenne de maturité T . On ajuste une position h_t en sous-jacent à des dates discrètes. Une récompense naturelle est un PnL incrémental pénalisé par les coûts :

$$R_{t \rightarrow t+\Delta} = \Delta \Pi_{t \rightarrow t+\Delta} - \lambda \text{TC}_{t \rightarrow t+\Delta}.$$

Le RL fournit alors une boîte à outils pour approximer une politique « bonne » sans résoudre analytiquement un contrôle stochastique.

Remarque 1.1 (RL vs contrôle stochastique (HJB)). En contrôle stochastique, on postule une dynamique continue et on dérive une équation HJB (ou une PDE). En RL, on peut :

- partir d'un simulateur (modèle ou données) ;
- approximer la valeur/politique par une fonction paramétrique ;
- optimiser numériquement.

En finance, les deux perspectives sont complémentaires : la première donne une structure/théorie ; la seconde donne des approximations quand l'analytique est impossible.

1.3 MDP et équations de Bellman : la base mathématique

1.3.1 Définition formelle d'un MDP

Définition 1.1 (MDP). Un *Markov Decision Process* (MDP) est un quintuplet $(\mathcal{S}, \mathcal{A}, \mathcal{P}, \mathfrak{r}, \gamma)$ où :

- $\mathcal{S}$ est l'ensemble des états ;
- $\mathcal{A}$ est l'ensemble des actions ;
- $\mathcal{P}(s', r \mid s, a)$ est la loi de (S_{t+1}, R_{t+1}) conditionnellement à $(S_t = s, A_t = a)$;
- $\mathfrak{r}(s, a) := \mathbb{E}[R_{t+1} \mid S_t = s, A_t = a]$ est la récompense moyenne ;
- $\gamma \in [0, 1)$ est le facteur d'actualisation.

Propriété de Markov. Le futur dépend du passé uniquement via l'état courant :

$$\mathbb{P}(S_{t+1} \in B, R_{t+1} \in C \mid S_0, A_0, \dots, S_t, A_t) = \mathbb{P}(S_{t+1} \in B, R_{t+1} \in C \mid S_t, A_t).$$

Remarque 1.2 (Choisir un état « Markovien »). En pratique, définir un MDP commence par **choisir l'état**. Si l'état ne contient pas assez d'information, la propriété de Markov est fautive et le RL devient plus difficile (POMDP). En finance, c'est typique : on n'observe pas directement la volatilité instantanée ni les flux d'ordres « complets ».

1.3.2 Retour, politique, valeurs

Retour (rappel). Le retour cumulé est

$$G_t := \sum_{k=0}^{\infty} \gamma^k R_{t+1+k}.$$

Intuition : γ pondère le futur ; mathématiquement, $\gamma < 1$ assure la finitude des séries dans de nombreux cas.

Politique. Une politique π associe à chaque état une distribution sur les actions : $\pi(\cdot \mid s)$. Une politique est dite *stationnaire* si elle ne dépend pas explicitement de t .

Valeur d'état et valeur d'action. On définit :

$$V^\pi(s) := \mathbb{E}_\pi[G_t \mid S_t = s], \quad Q^\pi(s, a) := \mathbb{E}_\pi[G_t \mid S_t = s, A_t = a].$$

Ces quantités sont des espérances conditionnelles : elles capturent un « gain futur moyen » sous π .

1.3.3 Dérivation pas à pas : Bellman (espérance)

Méthode 1.1 (Bellman découle de $G_t = R_{t+1} + \gamma G_{t+1}$). On part de l'identité exacte :

$$G_t = R_{t+1} + \gamma G_{t+1}.$$

(1) **Conditionner.** Conditionnons par $S_t = s$:

$$\mathbb{E}_\pi[G_t \mid S_t = s] = \mathbb{E}_\pi[R_{t+1} + \gamma G_{t+1} \mid S_t = s].$$

(2) **Reconnaître V^π .** Le membre de gauche est $V^\pi(s)$.

(3) **Tour de passe-passe (Markov).** Si l'on suit π à partir de $t+1$, alors $\mathbb{E}_\pi[G_{t+1} \mid S_{t+1}] = V^\pi(S_{t+1})$.

(4) **Conclusion.** On obtient :

$$V^\pi(s) = \mathbb{E}_\pi[R_{t+1} + \gamma V^\pi(S_{t+1}) \mid S_t = s].$$

Proposition 1.1 (Bellman (espérance)). *Pour toute politique π :*

$$V^\pi(s) = \mathbb{E}_\pi[R_{t+1} + \gamma V^\pi(S_{t+1}) \mid S_t = s], \quad (1.1)$$

$$Q^\pi(s, a) = \mathbb{E}[R_{t+1} + \gamma \mathbb{E}_{A' \sim \pi(\cdot \mid S_{t+1})}[Q^\pi(S_{t+1}, A')] \mid S_t = s, A_t = a]. \quad (1.2)$$

1.3.4 Optimalité : Bellman (optimalité)

Définition 1.2 (Valeurs optimales). On définit :

$$V^*(s) := \sup_{\pi} V^\pi(s), \quad Q^*(s, a) := \sup_{\pi} Q^\pi(s, a).$$

Proposition 1.2 (Bellman (optimalité)). *Les valeurs optimales satisfont :*

$$V^*(s) = \max_{a \in \mathcal{A}} Q^*(s, a), \quad (1.3)$$

$$Q^*(s, a) = \mathbb{E}[R_{t+1} + \gamma \max_{a' \in \mathcal{A}} Q^*(S_{t+1}, a') \mid S_t = s, A_t = a]. \quad (1.4)$$

Remarque 1.3 (Lecture « greedy » de Q^*). Si l'on connaît Q^* , une politique optimale est :

$$\pi^*(s) \in \operatorname{argmax}_{a \in \mathcal{A}} Q^*(s, a).$$

Le grand enjeu du RL est donc souvent : **approximer Q^*** .

1.3.5 Opérateurs de Bellman et contraction (preuve détaillée)

Définition 1.3 (Opérateur T^π). Pour une politique π , on définit l'opérateur T^π agissant sur une fonction Q par :

$$(T^\pi Q)(s, a) := \mathbb{E}[R_{t+1} + \gamma \mathbb{E}_{A' \sim \pi(\cdot \mid S_{t+1})}[Q(S_{t+1}, A')] \mid S_t = s, A_t = a].$$

Définition 1.4 (Opérateur optimal T). On définit :

$$(TQ)(s, a) := \mathbb{E}[R_{t+1} + \gamma \max_{a' \in \mathcal{A}} Q(S_{t+1}, a') \mid S_t = s, A_t = a].$$

Théorème 1.1 (Contraction (cas fini)). *Sous la norme $\sup \|\cdot\|_\infty$, les opérateurs T^π et T sont des γ -contractions. Ils possèdent donc des points fixes uniques : $Q^\pi = T^\pi Q^\pi$ et $Q^* = TQ^*$.*

Démonstration. On se place sur l'espace des fonctions bornées $Q : \mathcal{S} \times \mathcal{A} \rightarrow \mathbb{R}$ muni de la norme $\sup \|Q\|_\infty := \sup_{(s,a)} |Q(s, a)|$.

1) Contraction de T^π . Soient Q_1, Q_2 . Pour tout (s, a) ,

$$\begin{aligned} |(T^\pi Q_1)(s, a) - (T^\pi Q_2)(s, a)| &= \gamma \left| \mathbb{E}_{A' \sim \pi(\cdot \mid S_{t+1})}[Q_1(S_{t+1}, A') - Q_2(S_{t+1}, A')] \right| \\ &\leq \gamma \mathbb{E}_{A' \sim \pi(\cdot \mid S_{t+1})}[|Q_1(S_{t+1}, A') - Q_2(S_{t+1}, A')|] \\ &\leq \gamma \|Q_1 - Q_2\|_\infty. \end{aligned}$$

En prenant le sup sur (s, a) , on obtient $\|T^\pi Q_1 - T^\pi Q_2\|_\infty \leq \gamma \|Q_1 - Q_2\|_\infty$.

2) Contraction de T . Soient Q_1, Q_2 . Pour tout (s, a) ,

$$\begin{aligned} |(TQ_1)(s, a) - (TQ_2)(s, a)| &= \gamma \left| \mathbb{E} \left[\max_{a'} Q_1(S_{t+1}, a') - \max_{a'} Q_2(S_{t+1}, a') \right] \right| \\ &\leq \gamma \mathbb{E} \left[\left| \max_{a'} Q_1(S_{t+1}, a') - \max_{a'} Q_2(S_{t+1}, a') \right| \right]. \end{aligned}$$

Or, pour tous réels $(u_{a'})$ et $(v_{a'})$,

$$\left| \max_{a'} u_{a'} - \max_{a'} v_{a'} \right| \leq \max_{a'} |u_{a'} - v_{a'}|.$$

En appliquant cette inégalité avec $u_{a'} = Q_1(S_{t+1}, a')$ et $v_{a'} = Q_2(S_{t+1}, a')$, on obtient

$$|(TQ_1)(s, a) - (TQ_2)(s, a)| \leq \gamma \mathbb{E} \left[\max_{a'} |Q_1(S_{t+1}, a') - Q_2(S_{t+1}, a')| \right] \leq \gamma \|Q_1 - Q_2\|_{\infty}.$$

Donc $\|TQ_1 - TQ_2\|_{\infty} \leq \gamma \|Q_1 - Q_2\|_{\infty}$.

3) Unicité du point fixe. Une γ -contraction sur un espace complet possède un point fixe unique (théorème du point fixe de Banach), et l'itération $Q_{k+1} = TQ_k$ converge vers ce point fixe. Dans le cas π fixée, ce point fixe est Q^{π} ; dans le cas optimal, c'est Q^* . $\square$

Remarque 1.4 (Conséquence pour les algorithmes). Si l'on pouvait appliquer T exactement (espérance connue), l'itération $Q_{k+1} = TQ_k$ convergerait vers Q^* . Les algorithmes à la Q-learning sont une version *stochastique* de cette idée.

1.4 De la programmation dynamique à l'échantillonnage : MC, TD, GPI

1.4.1 Pourquoi ne pas résoudre Bellman exactement ?

Dans un monde idéal, si l'on connaît le modèle $\mathcal{P}$ et la récompense moyenne $\mathbf{r}$, on peut :

- écrire l'équation de Bellman sous forme linéaire (pour une politique fixée) ;
- résoudre un système (ou itérer) pour obtenir V^{π} ou Q^{π} ;
- appliquer une étape d'amélioration (politique greedy) et recommencer.

En RL, le point de départ est généralement : **on n'a pas $\mathcal{P}$** , seulement des transitions observées.

Remarque 1.5 (Model-based vs model-free). **Model-based** : on apprend/estime $\mathcal{P}$ puis on planifie.

Model-free : on apprend directement V , Q ou π .

DQN est un algorithme *model-free*.

1.4.2 Policy evaluation : trois approches

Pour une politique π fixée, on veut estimer V^{π} ou Q^{π} . Trois familles :

- **DP (modèle connu)** : appliquer T^{π} exactement ;
- **Monte Carlo (MC)** : utiliser des retours complets G_t ;
- **Temporal Difference (TD)** : bootstrapper via $V(S_{t+1})$.

1.4.3 Monte Carlo : non-biaisé mais variance

Idée : si l'on observe un épisode et le retour G_t , alors

$$V^{\pi}(S_t) \approx G_t.$$

En tabulaire, on fait une moyenne empirique :

$$V(s) \leftarrow V(s) + \alpha (G_t - V(s)) \quad \text{lorsque } S_t = s.$$

Avantage : la cible G_t est non-biaisée.

Inconvénient : variance forte, besoin d'épisodes (ou de découpes).

1.4.4 TD(0) : biais mais propagation rapide

TD(« 0 ») remplace le retour complet par un bootstrap à un pas :

$$G_t \approx R_{t+1} + \gamma V(S_{t+1}).$$

On définit l'erreur TD :

$$\delta_t := R_{t+1} + \gamma V(S_{t+1}) - V(S_t),$$

et la mise à jour tabulaire :

$$V(S_t) \leftarrow V(S_t) + \alpha \delta_t.$$

TD introduit un biais (car V est estimé), mais réduit la variance et propage l'information plus vite qu'une méthode MC.

1.4.5 n -step et TD(λ) : compromis biais/variance

On peut construire un retour à n pas :

$$G_t^{(n)} := \sum_{k=0}^{n-1} \gamma^k R_{t+1+k} + \gamma^n V(S_{t+n}).$$

Puis TD(λ) combine tous les n -step via des poids décroissants :

$$G_t^{(\lambda)} := (1 - \lambda) \sum_{n \geq 1} \lambda^{n-1} G_t^{(n)}, \quad \lambda \in [0, 1].$$

Intuition :

- $\lambda \approx 0$: proche de TD(0) (bootstrap fort) ;
- $\lambda \approx 1$: proche de MC (peu de bootstrap).

1.4.6 Control : Generalized Policy Iteration (GPI)

Le contrôle vise à trouver une politique optimale. Le schéma conceptuel est :

1. **évaluation** : approximer Q^π ;
2. **amélioration** : rendre la politique plus greedy : $\pi_{\text{new}}(\cdot \mid s)$ concentrée sur $\operatorname{argmax}_a Q^\pi(s, a)$.

En pratique, on ne sépare pas strictement ces deux étapes : les algorithmes TD control (SARSA, Q-learning) font les deux en continu.

1.4.7 Exploration : ε -greedy et GLIE

Une politique ε -greedy par rapport à Q est :

$$\pi_\varepsilon(a \mid s) = \begin{cases} 1 - \varepsilon + \varepsilon/|\mathcal{A}|, & a \in \operatorname{argmax}_{a'} Q(s, a'), \\ \varepsilon/|\mathcal{A}|, & \text{sinon.} \end{cases}$$

Une condition classique pour converger (tabulaire) est *GLIE* :

- exploration infinie (chaque (s, a) visité infiniment souvent) ;

— politique qui devient greedy à la limite ($\varepsilon_t \rightarrow 0$).

1.5 Contrôle tabulaire : SARSA, Expected SARSA, Q-learning

1.5.1 Point de départ : apprendre Q plutôt que V

En contrôle, l'objet central est souvent $Q(s, a)$: connaître la valeur des actions permet de construire une politique greedy. On va donc chercher à approximer Q^* (ou Q^π) via des mises à jour TD.

1.5.2 Une structure commune : erreur TD sur Q

Dans les trois algorithmes, on observe une transition $(S_t, A_t, R_{t+1}, S_{t+1})$ et on définit :

$$\delta_t := \underbrace{R_{t+1} + \gamma \text{cible}(S_{t+1})}_{\text{approximation de } G_t} - Q(S_t, A_t).$$

Puis on met à jour :

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha \delta_t.$$

La différence est le choix de la *cible* au pas suivant.

1.5.3 SARSA : on-policy

Définition 1.5 (SARSA). SARSA (State-Action-Reward-State-Action) utilise l'action effectivement jouée A_{t+1} :

$$\delta_t^{\text{SARSA}} = R_{t+1} + \gamma Q(S_{t+1}, A_{t+1}) - Q(S_t, A_t), \quad A_{t+1} \sim \pi(\cdot | S_{t+1}).$$

Interprétation. SARSA apprend Q^π pour la politique π réellement suivie (incluant l'exploration). Conséquence importante : si π est ε -greedy avec $\varepsilon > 0$ constant, la politique apprise intègre le fait qu'on explorera encore dans le futur.

1.5.4 Q-learning : off-policy

Définition 1.6 (Q-learning). Q-learning utilise une cible greedy, indépendante de l'action jouée :

$$\delta_t^{\text{QL}} = R_{t+1} + \gamma \max_{a' \in \mathcal{A}} Q(S_{t+1}, a') - Q(S_t, A_t).$$

Interprétation. La politique *cible* est greedy (celle associée au max), mais la politique *de comportement* peut explorer (par exemple ε -greedy). On dit que Q-learning est **off-policy**.

1.5.5 Expected SARSA : on-policy à variance réduite

Définition 1.7 (Expected SARSA). Expected SARSA remplace l'action aléatoire A_{t+1} par son espérance sous π :

$$\delta_t^{\text{Exp}} = R_{t+1} + \gamma \sum_{a' \in \mathcal{A}} \pi(a' | S_{t+1}) Q(S_{t+1}, a') - Q(S_t, A_t).$$

Interprétation. On garde le caractère on-policy, mais la cible a une variance plus faible que SARSA (pas de sampling de A_{t+1}).

1.5.6 Table récap et lecture « on-policy/off-policy »

Algo	Cible TD au pas suivant
SARSA	$Q(S_{t+1}, A_{t+1})$ avec $A_{t+1} \sim \pi(\cdot S_{t+1})$
Expected SARSA	$\sum_{a'} \pi(a' S_{t+1}) Q(S_{t+1}, a')$
Q-learning	$\max_{a'} Q(S_{t+1}, a')$

Remarque 1.6 (Une phrase à savoir). SARSA/Expected SARSA apprennent *la valeur de la politique suivie* ; Q-learning apprend *la valeur de la politique greedy* tout en explorant différemment.

1.5.7 Dérivation pas à pas : du point fixe à Q-learning

Méthode 1.2 (Q-learning comme approximation stochastique de $Q = TQ$). On part du point fixe $Q^* = TQ^*$ avec

$$(TQ)(s, a) = \mathbb{E} \left[R_{t+1} + \gamma \max_{a'} Q(S_{t+1}, a') \mid S_t = s, A_t = a \right].$$

(1) **Cible idéale.** Si l'on connaissait l'espérance, on mettrait $Q(s, a) \leftarrow (TQ)(s, a)$.

(2) **Échantillon.** Sur une transition observée (s, a, r, s') , on utilise l'estimateur :

$$(\widehat{TQ})(s, a) = r + \gamma \max_{a'} Q(s', a').$$

(3) **Pas de Robbins–Monro.** On fait une mise à jour à pas α :

$$Q(s, a) \leftarrow (1 - \alpha)Q(s, a) + \alpha (\widehat{TQ})(s, a).$$

(4) **Erreur TD.** On obtient $Q \leftarrow Q + \alpha \delta$ avec $\delta = r + \gamma \max_{a'} Q(s', a') - Q(s, a)$.

1.5.8 Exemple qualitatif : « cliff walking »

Dans le problème classique « cliff walking », un agent doit aller du point A au point B sur une grille, avec une falaise qui donne une grosse récompense négative si on tombe.

- Q-learning apprend souvent le chemin « au bord » (optimal si on est toujours greedy),
- SARSA apprend un chemin plus sécurisé, car il « anticipe » qu'il continuera à explorer avec probabilité ε .

Ce phénomène est une bonne intuition pour la différence on-policy/off-policy en présence d'exploration.

1.5.9 Convergence (tabulaire) : conditions à connaître

Sans entrer dans toutes les démonstrations, retenir :

- avec exploration suffisante et pas décroissants, Q-learning converge vers Q^* (cas fini) ;
- SARSA converge vers Q^π pour la politique suivie ; si la politique est GLIE, alors convergence vers l'optimal ;
- Expected SARSA a des propriétés similaires à SARSA avec une variance plus faible.

Remarque 1.7 (Importance sampling). En off-policy (données collectées sous une politique μ mais objectif sous une politique π), une correction classique est l'*importance sampling* : pondérer par $\pi(A_t | S_t) / \mu(A_t | S_t)$. En pratique, cela peut exploser en variance si les rapports sont grands : encore un point où la théorie rencontre la difficulté numérique.

1.6 Mode microscope : Bellman, contraction et convergence (tabulaire)

1.6.1 Opérateur de Bellman (preuve de contraction)

Soit un MDP avec facteur d'actualisation $\gamma \in (0, 1)$. L'opérateur de Bellman optimal T agit sur une fonction de valeur V par

$$(TV)(s) = \max_a \left(r(s, a) + \gamma \mathbb{E}[V(s') \mid s, a] \right).$$

Alors, pour la norme $\|\cdot\|_\infty$,

$$\|TV - TW\|_\infty \leq \gamma \|V - W\|_\infty.$$

Preuve (guidée). Pour tout s ,

$$(TV)(s) - (TW)(s) \leq \max_a \gamma \mathbb{E}[V(s') - W(s') \mid s, a] \leq \gamma \|V - W\|_\infty,$$

et symétriquement en échangeant V, W . On conclut. Donc T est une contraction : il a un unique point fixe V^* et la valeur iteration converge.

Sanity check. Si $\gamma \rightarrow 1$, la contraction devient faible : convergence plus lente et variance plus élevée en apprentissage.

1.6.2 Q-learning tabulaire : lecture

Mise à jour :

$$Q_{t+1}(s_t, a_t) = Q_t(s_t, a_t) + \alpha_t \left(r_t + \gamma \max_a Q_t(s_{t+1}, a) - Q_t(s_t, a_t) \right).$$

Le terme entre parenthèses est l'erreur TD (temporal difference).

Intuition de marché. En finance, l'exploration est coûteuse (risque réel) : on simule, on contraint, ou on utilise des politiques sûres. Le RL « pur » en live est rare sans garde-fous.

1.7 Pièges classiques / erreurs fréquentes

- Prendre γ trop proche de 1 sans régularisation : variance élevée, instabilités.
- Confondre performance in-sample (sur données vues) et robustesse out-of-sample.
- Mauvaise exploration : on n'observe pas certaines transitions, donc on apprend une valeur biaisée.

1.8 Checklist — savoir refaire sans regarder

- Définir MDP, V^π , Q^π et écrire Bellman.
- Prouver la contraction de l'opérateur de Bellman et expliquer la convergence.
- Écrire la mise à jour Q-learning et interpréter l'erreur TD.
- Décrire exploration/exploitation et les diagnostics de stabilité.

Chapitre 2

DQN - architecture, stabilisation, diagnostics

Idée centrale. DQN approxime $Q^*(s, a)$ avec un réseau, mais doit stabiliser la « deadly triad » (off-policy + bootstrap + approximation). Le chapitre est un guide de stabilisation + diagnostics.

Cadre mathématique.

- **Perte.** Régression vers cible de Bellman : $(r + \gamma \max_{a'} Q_{\theta'}(s', a') - Q_{\theta}(s, a))^2$ (semi-gradient).
- **Stabilisation.** Target network, replay buffer, clipping/normalisation ; variantes Double DQN, dueling, prioritized replay.
- **Diagnostics.** TD-error, amplitude des Q-values, overestimation, distribution shift.

Intuition marché / interprétation. En finance, l'instabilité est aggravée par non-stationnarité et data scarcity : un DQN peut « sur-apprendre » un régime et casser en live. La robustesse (walk-forward, baselines, stress) est non négociable.

Implémentation.

- Implémenter la boucle d'entraînement (buffer, target updates, gradient clipping) et logger systématiquement (Q histograms, TD-error, action entropy).
- Mettre des garde-fous : reward scaling, action constraints, pénalités de risque, early stopping.

Tests / sanity checks.

- Sanity MDP : sur un environnement simple, reproduire la performance tabulaire (ou proche).
- Q-values : ordre de grandeur cohérent avec la somme actualisée des rewards ; pas d'explosion.
- Robustesse : performance stable vs seeds et périodes (walk-forward), pas seulement in-sample.

Pont vers pratique quant. Pont quant : trading/exécution/hedging sous frictions, mais avec exigences de production (monitoring, risk constraints, tests de dérive de distribution) et comparaison systématique à des politiques baselines.

2.1 Avant-propos : DQN (approximer Q^* avec un réseau)

Le chapitre précédent a donné Q-learning dans le monde tabulaire (états/actions finis). Quand l'état est continu ou très grand (marchés, portefeuilles, features), on ne peut plus stocker une table. DQN (Deep Q-Network) remplace la table par un réseau $Q(s, a; \theta)$, mais cela introduit des instabilités : off-policy + bootstrap + approximation.

2.1.1 Objectifs pédagogiques

- Comprendre la perte DQN comme une régression sur une cible de Bellman (semi-gradient).
- Voir pourquoi l'apprentissage est instable sans astuces (deadly triad) et comment DQN répond :
 - réseau cible (target network) pour stabiliser la cible ;

- replay buffer pour décorrélérer les données ;
- tricks usuels (clipping, Double DQN, dueling, prioritized replay).
- Savoir diagnostiquer un entraînement (TD error, Q-values, overestimation, distribution shift).

2.1.2 Pré-requis

- Chapitre chapitre 1 : Bellman, Q-learning, off-policy/on-policy.
- Descente de gradient : notion de loss, mini-batch, overfitting.

2.1.3 Plan du chapitre

1. Pourquoi Q-learning + réseau diverge : structure du problème.
2. Les briques de stabilisation (target, replay) et leur rôle.
3. Dérivation du semi-gradient DQN et pseudo-code.
4. Améliorations (Double, dueling, prioritized, multi-step) et pièges.

Sanity check. Un DQN qui « marche » produit des politiques raisonnables, mais aussi des diagnostics cohérents : perte qui décroît, Q-values de bon ordre de grandeur, et performance stable hors buffer. Si les Q-values explosent, suspecter la cible et/ou la distribution de données.

2.2 Approximation de fonction : pourquoi et comment (avant le DQN)

2.2.1 Limitation du tabulaire : explosion combinatoire

Une table $Q(s, a)$ suppose de pouvoir *indexer* tous les états. Dès que :

- l'état est continu (prix, volatilité, taux),
- ou de grande dimension (multi-actifs, indicateurs, historiques),

la table devient impossible. On introduit alors une famille paramétrique $Q(\cdot, \cdot; \theta)$.

2.2.2 Approximation linéaire : un bon intermédiaire

Avec des features $\phi(s, a) \in \mathbb{R}^p$, on pose :

$$Q(s, a; \theta) = \langle \theta, \phi(s, a) \rangle.$$

Avantages :

- interprétabilité (choix de features),
- calculs analytiques du gradient,
- bonne passerelle conceptuelle vers les réseaux (où Q est différentiable en θ).

2.2.3 Quelle fonction de perte ?

On observe une transition (s, a, r, s') . Une cible de type Q-learning est :

$$y := r + \gamma \max_{a'} Q(s', a'; \theta).$$

Une idée naturelle est de minimiser le carré de l'erreur :

$$\ell(\theta) := \frac{1}{2} (y - Q(s, a; \theta))^2.$$

Mais attention : ici y dépend aussi de θ (bootstrap). Deux choix conceptuels apparaissent :

- **Bellman residual** (plein gradient) : minimiser $\frac{1}{2} |(TQ_\theta)(s, a) - Q_\theta(s, a)|^2$;
- **TD error** (semi-gradient) : traiter y comme constant pendant une mise à jour.

En pratique, les algorithmes de la famille DQN utilisent le **semi-gradient** avec une cible rendue « quasi fixe » via un réseau cible.

2.2.4 Semi-gradient : dérivation à retenir

Si l'on traite y comme constant, alors :

$$\nabla_\theta \ell(\theta) = (Q(s, a; \theta) - y) \nabla_\theta Q(s, a; \theta).$$

Et la descente de gradient stochastique donne :

$$\theta \leftarrow \theta - \alpha \nabla_\theta \ell(\theta) = \theta + \alpha (y - Q(s, a; \theta)) \nabla_\theta Q(s, a; \theta).$$

2.2.5 La « deadly triad »

Deadly triad : (i) approximation de fonction, (ii) bootstrap (TD), (iii) off-policy.
La combinaison des trois peut mener à une divergence (valeurs qui explosent), même dans des MDP simples.

Q-learning est off-policy et bootstrappe ; donc, dès qu'on quitte le tabulaire, la stabilité n'est plus automatique. DQN est une réponse empirique : décorréliser les données (replay) et stabiliser la cible (target network).

2.2.6 Fitted Q-Iteration (FQI) : vue « batch »

Une autre lecture utile (surtout en finance, données historiques) est le **Fitted Q-Iteration** :

1. on fixe une cible $y_i = r_i + \gamma \max_{a'} Q_k(s'_i, a')$ sur un dataset ;
2. on **régresse** un nouveau modèle Q_{k+1} sur $(s_i, a_i) \mapsto y_i$.

DQN peut être vu comme une version en-ligne de FQI, avec régression par mini-batches et stabilisation par réseau cible.

2.3 Deep Q-Network (DQN) : de Q-learning à l'approximation profonde

2.3.1 Cadre : actions discrètes, état potentiellement riche

Le DQN a été popularisé pour des problèmes où :

- l'espace d'actions est **discret** (taille $|\mathcal{A}|$ modérée),
- l'état est **riche** (grande dimension) : images, signaux, features.

Le réseau prend un état s en entrée et produit un vecteur :

$$Q(s, \cdot; \theta) \in \mathbb{R}^{|\mathcal{A}|}.$$

On lit la composante $Q(s, a; \theta)$ comme la valeur estimée de l'action a en s .

Remarque 2.1 (Pourquoi DQN n'est pas « naturel » pour des actions continues). Si l'action est continue (par exemple un hedge ratio $h_t \in \mathbb{R}$), le $\max_a Q(s, a)$ devient un problème d'optimisation continue à chaque pas. On peut discretiser l'action (au prix d'une approximation) ou utiliser des algorithmes spécifiques aux actions continues (DDPG, SAC, PPO).

2.3.2 De Q-learning à une régression : construire une perte

En tabulaire, Q-learning met à jour directement la valeur d'une case (s, a) . Avec un modèle paramétrique $Q(\cdot; \theta)$, on remplace « mettre à jour une case » par « ajuster des poids » via une perte.

On prend une transition (s, a, r, s') et on définit une cible (façon Q-learning) :

$$y(\theta) := r + \gamma \max_{a'} Q(s', a'; \theta).$$

La perte la plus simple est une MSE :

$$L(\theta) := \mathbb{E} \left[\left(y(\theta) - Q(s, a; \theta) \right)^2 \right].$$

Problème : $y(\theta)$ dépend de θ (cible mouvante).

2.3.3 Pourquoi c'est instable sans astuces ?

Trois sources majeures d'instabilité :

1. **Corrélations temporelles** : les transitions consécutives sont proches et donc non-i.i.d.
2. **Cible non stationnaire** : en modifiant θ , on modifie aussi la cible $y(\theta)$.
3. **Deadly triad** : off-policy + bootstrap + approximation.

La stabilisation du DQN est une réponse directe aux points (1) et (2), et une atténuation empirique du (3).

2.3.4 Brique 1 : réseau cible (*target network*)

On introduit un second jeu de paramètres θ^- (gelés pendant un moment) pour calculer la cible :

$$y := r + \gamma \max_{a'} Q(s', a'; \theta^-).$$

La perte DQN devient :

$$L(\theta) := \mathbb{E} \left[\left(y - Q(s, a; \theta) \right)^2 \right], \quad y = r + \gamma \max_{a'} Q(s', a'; \theta^-). \quad (2.1)$$

On met à jour θ souvent, et θ^- rarement (mise à jour « hard ») :

$$\theta^- \leftarrow \theta \quad \text{toutes les } C \text{ itérations.}$$

Remarque 2.2 (Soft update (Polyak)). Une variante est la mise à jour douce :

$$\theta^- \leftarrow \tau \theta + (1 - \tau) \theta^-, \quad \tau \ll 1.$$

2.3.5 Brique 2 : replay d'expérience (*experience replay*)

On maintient un buffer $\mathcal{D}$ de transitions $(s, a, r, s', \text{done})$. On entraîne en tirant des mini-batches au hasard :

$$(s, a, r, s') \sim \text{Uniform}(\mathcal{D}).$$

Effets :

- décorréler les données (meilleur pour SGD) ;
- réutiliser les transitions (meilleure efficacité échantillon) ;
- mélanger des régimes d'états (moins d'oubli).

2.3.6 Dérivation pas à pas : gradient DQN (semi-gradient)

Sur un échantillon (s, a, r, s') , on calcule :

$$y := r + \gamma(1 - \text{done}) \max_{a'} Q(s', a'; \theta^-).$$

La perte échantillon est

$$\ell(\theta) := \frac{1}{2} (y - Q(s, a; \theta))^2.$$

Comme y ne dépend pas de θ (car θ^- figé), on a :

$$\nabla_{\theta} \ell(\theta) = (Q(s, a; \theta) - y) \nabla_{\theta} Q(s, a; \theta).$$

Et la mise à jour SGD est :

$$\theta \leftarrow \theta - \alpha (Q(s, a; \theta) - y) \nabla_{\theta} Q(s, a; \theta). \quad (2.2)$$

Phrase à savoir expliquer.

Le DQN est une régression : on force $Q(s, a; \theta)$ à coller à une cible de Bellman calculée avec un réseau cible, et on stabilise l'entraînement en apprenant sur des mini-batches tirés d'un buffer de transitions.

2.3.7 Pseudo-code DQN

```
Initialiser Q-reseau (poids theta)
Initialiser reseau cible (poids theta_target <- theta)
Initialiser buffer de replay D

pour episode = 1..M:
  s <- reset()
  pour t = 1..T:
    # epsilon-greedy
    avec proba epsilon: a <- action aleatoire
    sinon: a <- argmax_a Q(s,a; theta)

    executer a, observer r, s', done
    stocker (s,a,r,s',done) dans D
    s <- s'

    echantillonner un minibatch B depuis D
    pour chaque transition (sj,aj,rj,sj',donej) dans B:
      yj <- rj + gamma*(1-donej) * max_a' Q(sj',a'; theta_target)
      mettre a jour theta par SGD sur moyenne_j (yj - Q(sj,aj; theta))^2

  toutes les C iterations:
    theta_target <- theta
```

2.3.8 Détails pratiques (souvent déterminants)

Perte de Huber. Souvent préférée à la MSE (robuste aux grands $|\delta|$) :

$$\mathcal{L}_{\kappa}(\delta) = \begin{cases} \frac{1}{2} \delta^2, & |\delta| \leq \kappa, \\ \kappa(|\delta| - \frac{1}{2} \kappa), & |\delta| > \kappa. \end{cases}$$

Clipping/normalisation des récompenses. Dans certains domaines (ex. Atari), on clippe $r \in [-1, 1]$. En finance, c'est plus délicat : clipper le PnL peut changer l'objectif. En revanche, **normaliser les features** et contrôler les échelles est souvent indispensable.

Gradient clipping. Limiter $\|\nabla_{\theta} L\|$ pour éviter des mises à jour instables.

Fréquence d'update et taille du buffer. Le buffer doit être assez grand pour mélanger les transitions, mais pas trop pour éviter un « dataset » trop hétérogène en environnement non stationnaire.

2.4 Au-delà de DQN : biais de surestimation et améliorations

2.4.1 Le biais de surestimation (overestimation bias)

La cible Q-learning contient un maximum :

$$\max_{a'} Q(s', a').$$

Si les valeurs estimées sont bruitées, le max tend à être **biaisé vers le haut** (on maximise le bruit). En deep RL, ce biais est souvent visible : Q explose et l'agent devient instable.

2.4.2 Double DQN : découpler sélection et évaluation

L'idée est de séparer :

- **sélection** de l'action : argmax ,
- **évaluation** de la valeur.

En Double DQN :

$$y := r + \gamma(1 - \text{done}) Q(s', \operatorname{argmax}_{a'} Q(s', a'; \theta); \theta^-).$$

Le réseau online choisit l'action ; le réseau cible l'évalue.

2.4.3 Dueling DQN : mieux factoriser l'information

Dans certains problèmes, la « valeur de l'état » est importante même si l'action change peu. Dueling DQN paramétrise :

$$Q(s, a) = V(s) + A(s, a) - \frac{1}{|\mathcal{A}|} \sum_{a'} A(s, a').$$

Intuition : séparer « bon état » et « bonne action ».

2.4.4 Prioritized replay : réviser les transitions « informative »

Au lieu d'échantillonner uniformément dans $\mathcal{D}$, on sur-échantillonne les transitions à grande erreur TD $|\delta|$. Avantage : apprentissage plus rapide. Risque : introduire du biais (corrigé par des poids d'importance sampling).

2.4.5 n -step returns : propager plus vite

On remplace la cible à 1 pas par une cible à n pas :

$$y^{(n)} := \sum_{k=0}^{n-1} \gamma^k r_{t+1+k} + \gamma^n \max_{a'} Q(s_{t+n}, a'; \theta^-).$$

Cela réduit le biais de bootstrap à court terme et accélère la propagation des récompenses, mais augmente potentiellement la variance.

2.4.6 Un mot sur Rainbow

Rainbow combine plusieurs améliorations (Double DQN, dueling, prioritized replay, multi-step, distributional RL, noisy nets). Message pédagogique : **la performance vient souvent d'un ensemble d'astuces**, mais chaque brique complique l'analyse et la validation.

2.5 Mode microscope : perte DQN et stabilisation

2.5.1 Perte DQN (semi-gradient)

On approxime Q^* par un réseau $Q_\theta(s, a)$. La cible TD (avec target network θ^-) est

$$y = r + \gamma \max_{a'} Q_{\theta^-}(s', a').$$

On minimise

$$L(\theta) = \mathbb{E}[(y - Q_\theta(s, a))^2].$$

Le gradient (semi-gradient) est

$$\nabla_\theta L(\theta) = \mathbb{E}[-2(y - Q_\theta(s, a)) \nabla_\theta Q_\theta(s, a)],$$

en traitant y comme constant (on ne rétro-propage pas à travers la cible).

2.5.2 Pourquoi c'est instable ?

- **Bootstrapping** : la cible dépend de Q lui-même.
- **Corrélations** : transitions consécutives très corrélées $\Rightarrow$ gradients biaisés.
- **Non-stationnarité** : la politique change pendant l'apprentissage.

Replay buffer $\Rightarrow$ décorrèle ; target network $\Rightarrow$ fige la cible temporairement.

Sanity check. Si les Q-values explosent (très grandes en valeur absolue), c'est souvent le signe d'une instabilité : learning rate trop grand, target update trop fréquent, récompenses mal normalisées.

2.6 Pièges classiques / erreurs fréquentes

- Apprendre avec des rewards non bornés / non normalisés : explosions numériques.
- Évaluer sur le même environnement/données que l'entraînement : faux sentiment de performance.
- Ignorer la non-stationnarité des marchés : un policy peut « marcher » puis casser.

2.7 Checklist — savoir refaire sans regarder

- Écrire la cible TD et la perte DQN.
- Dériver le semi-gradient et expliquer pourquoi on gèle la cible.
- Expliquer replay buffer et target network (problèmes qu'ils corrigent).
- Lister les diagnostics et garde-fous (clipping, normalisation, validation).

Chapitre 3

Application finance (hedging/trading) : MDP, reward, limites

Idée centrale. Appliquer le RL en finance = formuler un MDP réaliste (état, actions, coûts) et valider comme un quant : leakage-free, walk-forward, stress, et risk limits. L'algorithme est secondaire face au design.

Cadre mathématique.

- **État.** Résumé de l'information disponible ($\mathcal{F}_t$) : prix, features, positions, risques ; attention POMDP.
- **Actions.** Trades/hedges/exécution sous contraintes (bornes, lot size, inventory).
- **Reward.** P&L net de coûts + pénalités de risque (variance, CVaR, drawdown) ; choix d'horizon γ .

Intuition marché / interprétation. Le marché n'est pas stationnaire et l'exploration est coûteuse : l'offline RL est sujet au distribution shift et au reward hacking. La discipline « buy-side » est dans la validation et la gestion du risque.

Implémentation.

- Simulateur : slippage, coûts, impact, latence ; baselines fortes (no-trade, stratégies simples).
- Validation : découpage temporel strict, stress tests, et contrôle des invariances (scaling, time-of-day).

Tests / sanity checks.

- Leakage : tout feature doit être construite sans info future (tests d'horodatage).
- Walk-forward : performance stable sur fenêtres glissantes ; drawdowns contrôlés.
- Sensibilité : robustesse aux seeds, aux coûts, et aux shifts de volatilité (stress).

Pont vers pratique quant. Pont quant : exécution (impact/inventaire), hedging discret sous coûts, trading sous contraintes de risque, et évaluation « research-grade » (baselines, ablations, diagnostics).

3.1 Avant-propos : appliquer le RL à la finance (MDP, reward, limites)

Le RL devient intéressant en finance quand on peut formuler un problème comme :

observer un état $\Rightarrow$ décider une action $\Rightarrow$ subir une transition et un PnL.

Mais la difficulté n'est pas seulement algorithmique : la finance viole souvent les hypothèses confortables (stationnarité, données i.i.d., exploration libre).

3.1.1 Objectifs pédagogiques

- Construire un MDP « propre » pour un cas finance (hedging discret, trading, exécution) : état, action, reward, contraintes.

- Relier reward et objectif : PnL, variance, coûts de transaction, risk constraints (CVaR, drawdown).
- Comprendre les pièges spécifiques : non-stationnarité, distribution shift, leakage, sur-optimisation.
- Proposer des sanity checks : backtest walk-forward, stress tests, invariances, bornes.

3.1.2 Pré-requis

- Chapitres 1 and 2 : Bellman/Q-learning et stabilisation DQN.
- Culture finance : PnL, coûts, notion de hedging/trading.

3.1.3 Plan du chapitre

1. Formulation MDP : exemples et design du reward.
2. Données historiques : off-policy, distribution shift, validation.
3. Cas hedging/trading : contraintes, frictions, et limites de généralisation.

Intuition de marché. Le danger en finance est le « reward hacking » : un agent peut exploiter des artefacts du backtest. La rigueur est dans les checks (walk-forward, out-of-sample, stress) et dans la formulation des contraintes (risk limits, coûts).

3.2 Finance quantitative : formuler un problème (hedging/trading) en MDP

3.2.1 De la performance à la récompense : un choix de modélisation

En finance, **la récompense n'est pas donnée** : elle encode une préférence. Quelques objectifs possibles :

- maximiser $\mathbb{E}[\text{PnL}]$ (risque ignoré) ;
- maximiser $\mathbb{E}[U(\text{PnL})]$ pour une utilité concave (aversion au risque) ;
- maximiser $\mathbb{E}[\text{PnL}] - \eta \text{Var}(\text{PnL})$ (mean-variance) ;
- contrôler des risques (VaR/ES, drawdown) via pénalisations.

Le message pédagogique : **changer la récompense change le problème.**

3.2.2 Exemple fil rouge : hedging discret avec coûts

On se place à des dates $t_0 < t_1 < \dots < t_T$. On note h_t la position en sous-jacent. Un portefeuille de hedging a une valeur Π_t (option + cash + hedge).

État. Un état plausible :

$$s_t = (t, S_t, \text{features}, h_t, \text{cash}_t).$$

Les « features » peuvent inclure moneyness, volatilité implicite, Greeks, rendements passés, etc.

Action. Pour utiliser DQN, on discrétise une action de type « ajuster le hedge » :

$$a_t \in \{h^{(1)}, \dots, h^{(K)}\}.$$

Récompense. Une récompense incrémentale typique :

$$R_{t \rightarrow t+\Delta} = \Delta \Pi_{t \rightarrow t+\Delta} - \lambda \text{TC}_{t \rightarrow t+\Delta} - \eta \text{RiskPenalty}_{t \rightarrow t+\Delta}.$$

Les coûts de transaction TC peuvent modéliser bid-ask, slippage, impact. La pénalisation de risque peut viser une variance locale, une contrainte d'inventaire, etc.

3.2.3 Design de l'état : Markov, ou POMDP ?

La propriété de Markov repose sur l'état choisi. Si l'état observé ne contient pas une information clé (ex. volatilité instantanée), alors le processus n'est plus Markovien. Dans ce cas, le problème est un **POMDP**.

Trois remèdes pratiques.

- **Augmenter l'état** par un historique (fenêtre de rendements) ;
- **Filtrer** une variable latente (Kalman/particules) ;
- **Réseaux récurrents** (RNN/LSTM) pour « mémoriser ».

3.2.4 Validation : l'enjeu principal en finance

En finance, la difficulté n'est pas seulement d'entraîner un agent, mais de **valider** qu'il généralise :

- **walk-forward** (découpage temporel, out-of-sample) ;
- **stress tests** (chocs de volatilité, changement de régime) ;
- **sensibilité aux coûts** (bid-ask plus large, impact accru) ;
- **ablation** (retirer des features, changer la récompense) pour comprendre les dépendances.

Un bon indicateur de performance n'est pas seulement la moyenne du PnL : on veut des distributions, des drawdowns, et une robustesse aux changements de conditions.

3.3 Ouverture : modèle de Heston et volatilité stochastique

3.3.1 Motivation : sourire de volatilité et volatilité stochastique

Black-Scholes suppose une volatilité constante : cela contredit les smiles observés. Les modèles à volatilité stochastique introduisent une dynamique propre à la variance instantanée, ce qui génère naturellement un smile. Heston est l'exemple canonique : il est suffisamment riche et partiellement analytique.

3.3.2 Dynamique de Heston (sous $\mathbb{Q}$)

Dans une version simple (taux r constant, pas de dividendes), sous mesure risque-neutre $\mathbb{Q}$:

$$dS_t = rS_t dt + \sqrt{v_t} S_t dW_t^{(1)}, \quad (3.1)$$

$$dv_t = \kappa(\theta - v_t) dt + \xi \sqrt{v_t} dW_t^{(2)}, \quad (3.2)$$

$$d\langle W^{(1)}, W^{(2)} \rangle_t = \rho dt. \quad (3.3)$$

Les paramètres :

- κ : vitesse de retour à la moyenne,
- θ : niveau de variance de long terme,
- ξ : « vol-of-vol »,
- ρ : corrélation spot/variance (souvent négative).

3.3.3 Processus CIR : positivité et condition de Feller

La variance v_t suit un processus de type CIR. Une condition suffisante de positivité stricte est la condition de Feller :

$$2\kappa\theta \geq \xi^2.$$

Si elle est violée, le processus reste non-négatif mais peut toucher 0. Numériquement, une discrétisation Euler naïve peut produire des valeurs négatives, ce qui impose une attention particulière.

3.3.4 Simulation : corrélér les bruits et gérer $v_t \geq 0$

Corrélation. Pour simuler $(W^{(1)}, W^{(2)})$ avec corrélation ρ , on peut prendre deux gaussiennes $Z_1, Z_2 \sim \mathcal{N}(0, 1)$ indépendantes et poser :

$$\Delta W^{(1)} = \sqrt{\Delta t} Z_1, \quad \Delta W^{(2)} = \sqrt{\Delta t} (\rho Z_1 + \sqrt{1 - \rho^2} Z_2).$$

Schéma Euler avec troncature (idée simple). Un schéma robuste minimal est la *full truncation* :

$$v_{t+\Delta} = v_t + \kappa(\theta - v_t)\Delta + \xi \sqrt{\max(v_t, 0)} \Delta W^{(2)},$$

puis on remplace $\sqrt{v_{t+\Delta}}$ par $\sqrt{\max(v_{t+\Delta}, 0)}$ dans l'équation de S . Pour de la production, on préfère des schémas plus fins (QE, exact-CIR), mais l'idée pédagogique est : **garantir** $v \geq 0$.

3.3.5 Lien direct avec RL : environnement de simulation pour le hedging

Heston fournit un générateur de trajectoires. On peut donc construire un environnement RL :

- **état** : $(t, S_t, \hat{v}_t, h_t, \text{cash}_t, \dots)$;
- **action** : ajuster le hedge (discret si DQN) ;
- **récompense** : PnL incrémental - coûts - pénalisation de risque ;
- **transition** : simulation de $(S_{t+\Delta}, v_{t+\Delta})$ et mise à jour du portefeuille.

3.3.6 Point pédagogique : variance latente et POMDP

En marché, v_t n'est pas observable directement. Si l'agent n'observe que S_t , le processus est en général non Markovien. C'est un cas typique où :

- l'état doit inclure un historique (retours passés, volatilité réalisée) ;
- ou une estimation $\hat{v}_t$ (par filtrage / IV).

Cette discussion relie naturellement RL et estimation d'état latent (filtrage) en finance.

3.4 Exploration, exploitation et politiques stochastiques

3.4.1 Pourquoi l'exploration est centrale

En supervisé, la distribution des données est « donnée ». En RL, elle dépend de la politique : si l'on n'explore pas, on ne collecte jamais l'information sur les actions alternatives. Mais explorer est coûteux : cela dégrade la performance à court terme. La tension exploration/exploitation est donc structurelle.

3.4.2 ε -greedy : simple, mais brut

La politique ε -greedy est le standard pour DQN :

- avec probabilité ε , on choisit une action aléatoire ;
- sinon, on choisit l'action greedy $\arg\max_a Q(s, a)$.

En pratique, on fait décroître ε :

$$\varepsilon_t : 1 \rightarrow \varepsilon_{\min}.$$

Remarque 3.1 (Exploration et coûts de transaction). En finance, « explorer » signifie souvent « prendre des trades ». Dès qu'il y a des coûts, l'exploration a un coût réel. Cela renforce l'intérêt de simulateurs (explorer dans le modèle), mais rappelle aussi que la qualité de la simulation est critique.

3.4.3 Boltzmann/softmax : exploration guidée par les valeurs

Une alternative est une politique softmax :

$$\pi(a \mid s) = \frac{\exp(Q(s, a)/\tau)}{\sum_{b \in \mathcal{A}} \exp(Q(s, b)/\tau)},$$

où $\tau > 0$ est une température.

- τ grand : exploration quasi-uniforme ;
- τ petit : politique quasi-greedy.

Cette approche est plus « douce » que ε -greedy, mais peut être sensible aux échelles de Q .

3.4.4 Exploration à bruit paramétrique (Noisy Nets)

Une idée moderne : injecter du bruit dans les poids du réseau, de sorte que la politique explore en modifiant directement $Q(s, a; \theta)$. Cela peut être plus « cohérent » temporellement qu'une action aléatoire indépendante à chaque pas.

3.4.5 Exploration et stationnarité (finance)

En finance, la stationnarité est rarement vraie. Deux conséquences :

- **rejeu d'expérience** : un buffer trop long mélange des régimes incompatibles ;
- **evaluation** : une politique peut surperformer in-sample et s'effondrer out-of-sample.

Il est donc utile de penser à l'exploration comme « apprentissage robuste » plutôt que « chercher l'optimum stationnaire ».

3.5 Off-policy, données historiques et « distribution shift »

3.5.1 On-policy vs off-policy (rappel)

- **On-policy** : on apprend la valeur de la politique suivie.
- **Off-policy** : on apprend une politique cible différente de la politique de collecte.

Q-learning/DQN sont off-policy.

3.5.2 Pourquoi l'off-policy est tentant en finance

En finance, on dispose souvent de données historiques :

- soit des prix (et on simule des exécutions),
- soit des logs de stratégies (actions prises, PnL, exécutions).

L'idée naturelle est d'apprendre *sans interagir* : c'est l'**offline RL**.

3.5.3 Le problème : distribution shift

En RL, la politique modifie les états visités. En offline RL, on ne peut pas « aller » dans des états non couverts par les données. Si un algorithme extrapole mal Q sur des actions peu vues, il peut produire une politique « fantaisiste » qui semble bonne selon Q mais n'est jamais validée par les données. Ce phénomène est un **distribution shift** entre :

- distribution des données (buffer historique),
- distribution induite par la politique apprise.

3.5.4 Importance sampling : correction, mais variance

Dans un cadre où l'on observe des transitions sous μ mais on veut évaluer π , une correction est :

$$w_t = \frac{\pi(A_t | S_t)}{\mu(A_t | S_t)}.$$

Problème : si w_t est grand ou très variable, l'estimation devient inutilisable (variance).

3.5.5 Message pratique (M1) : prudence et validation

Sans rentrer dans la littérature offline RL moderne, retenir :

- l'off-policy sur données historiques est **dangereux** sans régularisation/conservatisme,
- une validation sérieuse doit inclure des tests de robustesse et, si possible, des environnements de simulation variés.

Dans un mémoire ou un projet, il est souvent raisonnable de :

- travailler d'abord en environnement simulé,
- puis comparer à des stratégies de base (baselines) et des stress tests.

3.6 Synthèse : ce qu'il faut savoir ré-expliquer

3.6.1 Les 12 phrases à maîtriser

1. Un MDP formalise une décision séquentielle via $(S_t, A_t, R_{t+1}, S_{t+1})$.
2. Une politique $\pi(a | s)$ décrit comment on agit à partir des états.
3. Le retour est $G_t = \sum_{k \geq 0} \gamma^k R_{t+1+k}$.
4. V^π et Q^π sont des espérances conditionnelles de G_t .
5. Bellman vient de $G_t = R_{t+1} + \gamma G_{t+1}$ et transforme un problème global en relation à un pas.
6. Q-learning approxime le point fixe $Q^* = TQ^*$ par des mises à jour stochastiques.
7. SARSA est on-policy : la cible utilise l'action effectivement jouée au pas suivant.
8. Expected SARSA remplace cette action par une espérance, réduisant la variance.
9. DQN remplace la table Q par un réseau $Q(\cdot; \theta)$.
10. La perte DQN est une régression sur une cible de Bellman calculée avec un réseau cible.
11. Le replay buffer décorrèle les données et réutilise l'expérience ; le target network stabilise la cible.
12. En finance, la difficulté majeure est le design/validation : récompense, coûts, non-stationnarité, distribution shift.

3.6.2 Mini-projet (idée de TP)

Mini-projet : du tabulaire au DQN, puis Heston.

- 1) Construire un MDP jouet (petit) et implémenter SARSA et Q-learning.
- 2) Observer la différence on-/off-policy avec une exploration ε .
- 3) Passer à un état continu (features) et implémenter un DQN.
- 4) Ajouter (i) replay, (ii) target network, puis (iii) Double DQN.
- 5) Formuler un MDP de hedging discret et simuler d'abord Black-Scholes, puis Heston.
- 6) Évaluer : out-of-sample, stress, sensibilité aux coûts.

3.7 Preuve détaillée : contraction de l'opérateur de Bellman

Cadre. On fixe un facteur d'actualisation $\gamma \in (0, 1)$. On note $\mathcal{B}$ l'espace des fonctions bornées $Q : S \times A \rightarrow \mathbb{R}$, muni de la norme sup

$$\|Q\|_\infty := \sup_{(s,a) \in S \times A} |Q(s,a)|.$$

On rappelle que $(\mathcal{B}, \|\cdot\|_\infty)$ est un espace de Banach (complet) : toute suite de Cauchy pour $\|\cdot\|_\infty$ converge uniformément vers une limite bornée.

Objectif. Montrer que, sous la norme sup, l'opérateur optimal T est une γ -contraction :

$$\|TQ_1 - TQ_2\|_\infty \leq \gamma \|Q_1 - Q_2\|_\infty.$$

Outil (inégalité « max »). Pour toute famille réelle $(x_i)_{i \in I}$ et $(y_i)_{i \in I}$ (avec I quelconque), on a

$$\left| \sup_{i \in I} x_i - \sup_{i \in I} y_i \right| \leq \sup_{i \in I} |x_i - y_i|. \quad (3.4)$$

Preuve. Pour tout i , on a $x_i \leq y_i + \sup_j |x_j - y_j|$, donc $\sup_i x_i \leq \sup_i y_i + \sup_j |x_j - y_j|$. En échangeant le rôle de x et y , on obtient aussi $\sup_i y_i \leq \sup_i x_i + \sup_j |x_j - y_j|$. En combinant, on obtient (3.4). $\square$

Preuve (détaillée). Fixons (s, a) . Par définition,

$$(TQ)(s, a) = \mathbb{E} \left[R_{t+1} + \gamma \max_{a'} Q(S_{t+1}, a') \mid S_t = s, A_t = a \right].$$

Donc, en soustrayant :

$$(TQ_1)(s, a) - (TQ_2)(s, a) = \gamma \mathbb{E} \left[\max_{a'} Q_1(S_{t+1}, a') - \max_{a'} Q_2(S_{t+1}, a') \mid s, a \right].$$

En prenant la valeur absolue et en utilisant $|\mathbb{E}[Z]| \leq \mathbb{E}[|Z|]$,

$$|(TQ_1)(s, a) - (TQ_2)(s, a)| \leq \gamma \mathbb{E} \left[\left| \max_{a'} Q_1(S_{t+1}, a') - \max_{a'} Q_2(S_{t+1}, a') \right| \mid s, a \right].$$

Puis on applique (3.4) (avec $I = A$) à l'intérieur de l'espérance :

$$\left| \max_{a'} Q_1(S_{t+1}, a') - \max_{a'} Q_2(S_{t+1}, a') \right| \leq \max_{a'} |Q_1(S_{t+1}, a') - Q_2(S_{t+1}, a')|.$$

Or, pour tout s' , $\max_{a'} |Q_1(s', a') - Q_2(s', a')| \leq \|Q_1 - Q_2\|_\infty$. Donc,

$$|(TQ_1)(s, a) - (TQ_2)(s, a)| \leq \gamma \|Q_1 - Q_2\|_\infty.$$

En prenant le sup sur (s, a) , on obtient la contraction.

Corollaire 3.1 (Point fixe unique). *Comme T est une contraction (et l'espace est complet), T a un unique point fixe Q^* .*

3.8 Stochastic approximation et conditions de convergence (tabulaire)

3.8.1 Robbins–Monro : deux conditions à connaître

Beaucoup de mises à jour RL tabulaires ont la forme :

$$x_{t+1} = x_t + \alpha_t (h(x_t) + \text{bruit}_t),$$

où $h(x^*) = 0$ est l'objectif (point fixe). Les conditions classiques sur le pas α_t sont :

$$\sum_{t \geq 0} \alpha_t = \infty, \quad \sum_{t \geq 0} \alpha_t^2 < \infty.$$

Intuition :

- $\sum \alpha_t = \infty$: on peut encore bouger à long terme (pas trop petits) ;
- $\sum \alpha_t^2 < \infty$: le bruit cumulé reste contrôlé.

Un choix typique est $\alpha_t = 1/t$ (ou $1/\sqrt{t}$ selon les cadres), mais en pratique on utilise souvent un petit pas constant (au prix de l'absence de convergence stricte).

3.8.2 Exploration : *sufficient exploration* et GLIE

Deux exigences reviennent dans les preuves tabulaires :

- **visiter tous les couples** (s, a) (sinon on n'apprend jamais certaines actions) ;
- **devenir greedy** à la limite si l'on vise l'optimal.

Définition 3.1 (GLIE). Une suite de politiques est *GLIE* si :

1. chaque (s, a) est visité infiniment souvent ;
2. la politique devient greedy à la limite.

3.8.3 Convergence (énoncés qualitatifs)

Q-learning (tabulaire). Dans un MDP fini, sous exploration suffisante et pas décroissants, Q-learning converge vers Q^* .

SARSA (tabulaire). SARSA converge vers Q^π pour la politique suivie. Si la politique est GLIE, convergence vers l'optimal.

Expected SARSA. Propriétés proches de SARSA, souvent avec variance réduite.

3.8.4 Pourquoi ces résultats ne se transfèrent pas à DQN

Les preuves tabulaires s'appuient sur :

- une représentation exacte (une case par (s, a)),
- une structure de contraction bien contrôlée,
- des hypothèses d'exploration et de pas.

En deep RL :

- l'approximation de fonction introduit un couplage entre états (généralisation),
- l'off-policy + bootstrap + approximation (deadly triad) peut diverger,
- les pas sont souvent constants (optimisation), et l'environnement peut être non stationnaire.

Conclusion : DQN est principalement justifié par l'empirie et l'ingénierie (replay + target + tricks), pas par une convergence générale.

3.9 DQN en pratique : checklist d'implémentation et diagnostics

3.9.1 Architecture : sortie à $|\mathcal{A}|$ composantes

En DQN, on prend l'état s en entrée et on produit un vecteur de taille $|\mathcal{A}|$:

$$Q(s, \cdot; \theta) = (Q(s, a^{(1)}; \theta), \dots, Q(s, a^{(|\mathcal{A}|)}; \theta)).$$

Cela permet de calculer $\operatorname{argmax}_a Q(s, a; \theta)$ en une passe avant.

3.9.2 Pseudo-code (version « ingénierie »)

Check minimal DQN.

- 1) Remplir le replay buffer avec un peu d'exploration avant d'apprendre (« warm-up »).
- 2) Apprendre sur mini-batches uniformes.
- 3) Cible calculée avec un réseau cible (détaché des gradients).
- 4) Masque terminal : pas de bootstrap si **done**.
- 5) Mise à jour périodique de θ^- .

3.9.3 Hyperparamètres : valeurs typiques (ordre de grandeur)

- γ : proche de 1 (ex. 0.99) si l'horizon effectif est long, plus petit si l'on veut myopie.
- Taille du buffer $|\mathcal{D}|$: 10^4 à 10^6 selon le problème.
- Batch size : 32 à 256.
- Learning rate : 10^{-4} à 10^{-3} (dépend du réseau et des échelles).
- Fréquence de mise à jour du target : toutes les 10^2 à 10^4 itérations (ou soft update).
- Planning de ε : décroissance linéaire/exponentielle vers $\varepsilon_{\min}$.

En finance, les échelles de récompenses et de features changent la donne : il faut calibrer ces valeurs sur votre environnement.

3.9.4 Diagnostics : quoi regarder pendant l'entraînement ?

- **Reward par épisode** : moyenne, quantiles, drawdowns.
- **Loss** : tendance globale, instabilités, explosions.
- **Amplitude des Q** : surestimation (valeurs qui explosent) ou collapse (valeurs plates).
- **TD error** : distribution de δ (outliers, asymétries).
- **Politique effective** : taux d'actions, inventaire moyen, turnover (finance).

3.9.5 Bugs fréquents (et symptômes)

- Oublier le masque terminal : le Q sur-boostre et dérive.
- Laisser les gradients passer dans la cible : objectif instable (moving target).
- Buffer trop petit ou pas de warm-up : sur-apprentissage immédiat sur données corrélées.
- Features non normalisées : gradients instables, apprentissage très lent.
- Action space mal définie : discrétisation trop grossière (politique limitée) ou trop fine (apprentissage difficile).

3.10 Risque, utilité et design de récompense en finance

3.10.1 PnL, coûts, et objectif : trois couches à distinguer

Dans un environnement de trading/hedging, il faut distinguer :

- **PnL brut** : variation de valeur du portefeuille,
- **coûts** : bid-ask, slippage, impact,
- **objectif** : critère de performance (moyenne/risque).

La récompense RL est le « signal » utilisé pour apprendre : elle doit refléter l'objectif final.

3.10.2 Mean-variance : simple mais limité

Un objectif courant est

$$\max_{\pi} \mathbb{E}[\text{PnL}] - \eta \text{Var}(\text{PnL}).$$

Avantages : simple, différentiable, interprétable.

Limites : la variance pénalise autant les gains que les pertes ; et l'objectif peut être difficile à décomposer en récompenses locales.

3.10.3 Utilité exponentielle : aversion au risque (CARA)

Avec une utilité exponentielle :

$$U(x) = -\exp(-\lambda x),$$

on cherche à maximiser $\mathbb{E}[U(\text{PnL})]$. Intuition : les pertes sont pénalisées fortement (aversion au risque). Dans un cadre gaussien, cela se relie à un compromis moyenne/variance, mais en général ce n'est pas équivalent.

3.10.4 VaR et ES : risque de queue

Pour une perte L (donc $L = -\text{PnL}$), la Value-at-Risk au niveau α est :

$$\text{VaR}_{\alpha}(L) := \inf\{l : \mathbb{P}(L \leq l) \geq \alpha\}.$$

L'Expected Shortfall (aussi appelé CVaR) est :

$$\text{ES}_{\alpha}(L) := \mathbb{E}[L \mid L \geq \text{VaR}_{\alpha}(L)].$$

Ces mesures ciblent les pertes extrêmes. En RL, les intégrer directement dans une récompense à chaque pas est subtil (risque de non additivité temporelle).

3.10.5 Drawdown : risque de trajectoire

Le maximum drawdown d'une trajectoire de PnL cumulé X_t est

$$\max_t \left(\max_{u \leq t} X_u - X_t \right).$$

C'est un risque **path-dependent**. Pour le RL, cela signifie : la récompense dépend de l'historique, donc l'état doit inclure des variables résumant le passé (ex. maximum passé).

3.10.6 Message pratique

Deux lignes directrices utiles :

- **aligner** la récompense sur l'objectif final (sinon on optimise le mauvais problème) ;
- **tester** la robustesse au choix de récompense (ablation) : un agent très sensible est un signal d'alerte.

3.11 Complément : Heston (mesure, moments, simulation)

3.11.1 Sous $\mathbb{P}$ vs sous $\mathbb{Q}$: où sont les primes de risque ?

Dans les modèles de marché, la dynamique sous la mesure historique $\mathbb{P}$ diffère de la dynamique sous la mesure risque-neutre $\mathbb{Q}$. Sous $\mathbb{P}$, on peut écrire :

$$\begin{aligned} dS_t &= \mu S_t dt + \sqrt{v_t} S_t dW_t^{(1),\mathbb{P}}, \\ dv_t &= \kappa_{\mathbb{P}}(\theta_{\mathbb{P}} - v_t) dt + \xi \sqrt{v_t} dW_t^{(2),\mathbb{P}}, \end{aligned}$$

alors que sous $\mathbb{Q}$ le drift de S devient rS_t . La dynamique de v_t sous $\mathbb{Q}$ dépend d'une « prime de risque de volatilité » : les paramètres (κ, θ) peuvent changer. Message : **calibrer sous $\mathbb{Q}$ (options) et entraîner sous $\mathbb{P}$ (historique) ne sont pas la même chose.**

3.11.2 Moment de v_t : moyenne conditionnelle

Pour un processus CIR, on obtient explicitement :

$$\mathbb{E}[v_t \mid v_0] = \theta + (v_0 - \theta)e^{-\kappa t}$$

(sous les paramètres correspondants à la mesure considérée). Intuition : retour exponentiel vers θ à vitesse κ .

3.11.3 Stationnarité

Quand $t \rightarrow \infty$, v_t converge en distribution vers une loi Gamma (sous conditions). La moyenne stationnaire est θ . Cela explique l'interprétation de θ comme variance de long terme.

3.11.4 Simulation : au-delà d'Euler

Exact-CIR (idée). Le processus CIR possède une transition exacte (liée à une loi χ^2 non centrale). Cela permet une simulation de $v_{t+\Delta}$ sans valeurs négatives.

QE (Quadratic-Exponential). Le schéma QE d'Andersen est très utilisé en pratique car il est stable et rapide. Il approxime la loi conditionnelle de $v_{t+\Delta}$ en fonction du rapport variance/moyenne.

Pourquoi c'est important pour RL. Si votre simulateur génère des $v_t < 0$ ou des trajectoires numériques instables, l'agent apprendra sur un monde artificiel. En finance, l'environnement (simulateur) est une partie du modèle : il doit être validé.

3.12 Mode microscope : formuler un problème finance en MDP

3.12.1 Exemple fil rouge (jouet) : hedging discret

On considère une option européenne à maturité T et une couverture discrète aux dates $t_0 < \dots < t_N = T$.

- **État** : $s_t = (t, S_t, \Delta_t)$ (temps, spot, position courante).
- **Action** : choisir la nouvelle couverture Δ_{t+} (ou l'incrément de position).
- **Transition** : $S_{t_{k+1}}$ via un modèle simulé (BS, Heston, etc.) + mise à jour de l'inventaire.
- **Reward** : P&L incrémental moins coût de transaction (ex : $-c|\Delta_{t+} - \Delta_t|S_t$) et éventuellement pénalisation de risque.

Le point subtil est le choix du reward : maximiser l'espérance du P&L n'est pas suffisant si l'on veut contrôler la variance / le risque extrême.

Intuition de marché. Le RL est surtout utile quand la stratégie est *non linéaire* (contraintes, coûts, limites de position) : autrement, les solutions analytiques (delta hedging) dominent.

3.13 Pièges classiques / erreurs fréquentes

- Choisir un reward trop proche du P&L brut sans contrôle du risque : politiques instables.
- Overfitting : optimiser sur un historique particulier sans robustesse.
- Oublier les coûts et contraintes réelles (slippage, latence, limites) : politique irréalisable.

3.14 Checklist — savoir refaire sans regarder

- Formuler un problème finance en MDP (état/action/reward) et justifier le design.
- Intégrer coûts/contraintes et discuter l'impact sur la stratégie optimale.
- Expliquer POMDP et proposer une solution pratique (features, filtrage, mémoire).
- Définir un protocole de validation robuste (out-of-sample, stress tests).

Chapitre 4

RL en production : offline RL, OPE, contraintes de risque

4.1 Idée centrale

En finance, l'obstacle n'est pas *d'entraîner* un agent, mais de *valider* qu'il ne sur-apprend pas un artefact de backtest. Le couple clé est : (i) **distribution shift** (offline), (ii) **non-stationnarité** (régimes).

4.2 Offline RL : pourquoi c'est dur

- Les données proviennent d'une politique π_b inconnue (behavior) ; la politique cible π modifie la distribution des états.
- Le *support mismatch* (actions jamais vues) rend Q extrapolatif $\Rightarrow$ valeurs arbitraires.
- Les séries financières violent i.i.d. : corrélations, changements de régime, microstructure.

4.3 OPE (Off-Policy Evaluation) : outils interview-level

4.3.1 Importance sampling (IS)

$$\hat{V}^{IS} = \frac{1}{N} \sum_{i=1}^N \left(\prod_t \frac{\pi(a_t^i | s_t^i)}{\pi_b(a_t^i | s_t^i)} \right) G^i.$$

Avantage : non biaisé (idéal). Problème : variance explosive en horizon long.

4.3.2 Doubly robust (DR)

Combine une estimation de Q et un correctif IS : réduit variance si le modèle est correct (sinon biais). **Message.** En trading, OPE reste fragile $\Rightarrow$ il faut des stress tests et du walk-forward.

4.4 Conservatism (éviter l'extrapolation)

Idée des méthodes type CQL/BCQ : pénaliser Q sur des actions hors-support, ou contraindre la politique à rester proche des actions observées. **Trade-off.** Plus conservateur $\Rightarrow$ moins d'alpha mais risque réduit de « hallucination ».

4.5 Contraintes de risque (indispensable)

- **Objective risk-sensitive** : utilité exponentielle, pénalité drawdown, CVaR.
- **Constraint** : limiter variance, tail loss, inventory, ou impact $\Rightarrow$ RL constraint (Lagrangien).
- **Reward** : toujours net de coûts (fees, spread, impact) et avec latence réaliste.

4.6 Tests / sanity checks

- Baselines : no-trade, random, simple heuristic (momentum/mean-reversion).
- Ablations : supprimer un feature pour détecter leakage ; tester sur périodes *out-of-regime*.
- Diagnostics : distribution des actions, exposition, turnover, slippage effectif.

Chapitre 5

RL finance avancé : risque, contraintes, évaluation (interview-level)

5.1 Idée centrale

En finance, « maximiser l'espérance » est rarement le bon objectif : on veut un compromis **rendement/-risque/coûts** sous contraintes (inventory, drawdown, VaR/ES, limites réglementaires). Le vrai enjeu est l'**évaluation** (offline) sous non-stationnarité : un agent qui « gagne » en backtest peut être un artefact de reward/leakage.

5.2 Cadre mathématique : risque et contraintes

5.2.1 Risk-sensitive objective

Au lieu de $J(\pi) = \mathbb{E}^\pi[\sum_{t \geq 0} \gamma^t r_t]$, on peut optimiser une utilité concave U :

$$J_U(\pi) = \mathbb{E}^\pi \left[U \left(\sum_{t \geq 0} \gamma^t r_t \right) \right],$$

ou une mesure de risque sur la perte $L = -G$. **Exemple (entropic)**. $\rho_\eta(L) = \frac{1}{\eta} \log \mathbb{E}[e^{\eta L}]$ (averse au risque si $\eta > 0$).

5.2.2 CVaR/ES (forme optimisation)

Pour une perte aléatoire L et niveau α ,

$$\text{CVaR}_\alpha(L) = \min_{\eta \in \mathbb{R}} \eta + \frac{1}{1 - \alpha} \mathbb{E}[(L - \eta)_+].$$

Usage. Intégrer des contraintes de queue (tail risk) dans la décision.

5.2.3 CMDP (Constrained MDP)

On maximise $J(\pi)$ sous contraintes de coûts $C_i(\pi) \leq d_i$ (ex : turnover, inventory, drawdown proxy). Lagrangien :

$$\max_{\pi} \min_{\lambda \geq 0} J(\pi) - \sum_i \lambda_i (C_i(\pi) - d_i).$$

Message. En pratique, on fait du primal-dual (mettre à jour π et λ).

5.3 Implémentation : Lagrangian DQN (sketch)

- Définir un reward net de coûts et un (ou plusieurs) coûts c_t (ex : impact, inventory).
- Entraîner un Q sur le signal composite $\tilde{r}_t = r_t - \lambda c_t$.
- Mettre à jour $\lambda \leftarrow [\lambda + \eta_\lambda(\hat{C} - d)]_+$ en ligne (contrainte violée $\Rightarrow$ pénalisation augmente).

Point d'attention. Les estimateurs $\hat{C}$ sont bruités hors échantillon : à traiter comme du risk (stress, marges).

5.4 Évaluation (OPE) : réflexes

- IS (importance sampling) : non biaisé mais variance explosive (horizon long).
- WIS / per-decision IS : plus stable mais biais introduit.
- Doubly robust : combine modèle de Q et IS ; utile si l'un des deux est raisonnable.
- **Finance-specific** : faire du walk-forward, tester *out-of-regime* (stress), et comparer à des heuristiques simples.

5.5 Tests / sanity checks (3–6)

- Baselines : no-trade, buy-and-hold, simple momentum/mean-reversion (même contraintes, mêmes coûts).
- Monotonie : augmenter les coûts/latence doit **dégrader** la perf (sinon bug/leakage).
- Distribution des actions : pas d'actions hors-support (offline), turnover/inventory sous contrôle.
- Robustesse : perf stable en changeant la période, l'univers, et les paramètres de reward (pas de sur-ajustement).
- Tail : stress tests (gaps, vol spikes) + contrôles ES/CVaR.

5.6 Pont vers pratique quant

- **Execution** : CMDP naturel (impact, risk, inventory) ; l'agent doit respecter des contraintes strictes.
- **Hedging** : reward = P&L hedgé - coûts, contrainte sur gamma/vega ; attention aux smile dynamics.
- **Model risk** : RL est une couche de décision, mais le risk model (covariance, impact) reste le socle.

Interview Pack — Partie IX (core)

Mémoire & rough (Volterra, fBm, rough Heston, rBergomi)

Table des matières

1	Volterra SDE	1
1.1	Avant-propos : mémoire et noyaux (Volterra SDE)	1
1.2	Pourquoi des Volterra SDE en finance quantitative ?	2
1.3	De la volatilité discrète à la mémoire continue : EWMA, GARCH et noyaux	3
1.4	Préliminaires : cadre probabiliste et intégrales d'Itô	4
1.5	Rappel : SDE d'Itô et forme intégrale	5
1.6	Équations de Volterra déterministes : le prototype avec mémoire	5
1.7	Volterra SDE : dérivation pas à pas depuis une dynamique discrète	7
1.8	Définitions générales : SVIE et forme convolution	8
1.9	Convolution stochastique : calculs de base et intuition	9
1.10	Exemples guidés : comprendre la mémoire par des cas concrets	10
1.11	Simulation numérique des Volterra SDE : schémas et complexité	11
1.12	Existence et unicité : version cours (cas régulier)	12
1.13	Kernels importants et markovianisation	12
1.14	Noyaux fractionnaires et rough volatility	13
1.15	Volterra SDE et volatilité stochastique : ouverture vers Heston	14
1.16	Zoom sur Heston : propriétés du processus CIR et éléments de pricing	15
1.17	Rough Heston : Riccati–Volterra, affinité et approximation multi-facteurs	17
1.18	Fiche de synthèse : définitions, cas particuliers, messages clés	18
1.19	Corrigés rapides (sélection)	18
1.20	Complément A : convolution, transformées de Laplace (utile pour les noyaux)	19
1.21	Complément B : Fubini stochastique et dérivations utiles	19
1.22	Mode microscope : noyau de convolution, covariance et discrétisation	20
1.23	Pièges classiques / erreurs fréquentes	20
1.24	Checklist — savoir refaire sans regarder	21
2	Fractional Brownian Motion	22
2.1	Avant-propos : mouvement brownien fractionnaire (fBm) et rugosité	22
2.2	Objectifs, prerequis, et fil conducteur	23
2.3	Rappel : pourquoi Ito marche pour le brownien (et ce que l'on perd ensuite)	23
2.4	Mouvement brownien fractionnaire : définition et propriétés fondamentales	24
2.5	Regularité, variation quadratique, et non-semimartingale	26
2.6	Représentations du fBm : ramener le rough à un brownien	28
2.7	Intégrer par rapport au fBm : panorama et choix de modélisation	30
2.8	Calcul fractionnaire minimal : intégrales de convolution	31
2.9	Mode microscope : définition, covariance, scaling	31
2.10	Pièges classiques / erreurs fréquentes	31
2.11	Checklist — savoir refaire sans regarder	32
3	Rough Heston	33
3.1	Avant-propos : rough Heston (mémoire + affinité)	33
3.2	Equations stochastiques de Volterra (SVIE) : le langage naturel de rHeston	34
3.3	Rough volatility : motivation et premier modèle rough	36
3.4	Ouverture structurante : Heston classique comme modèle affine	37
3.5	Dérivation pas à pas de rHeston à partir du fBm (cœur du cours)	37
3.6	Conséquences : mémoire, non-Markov, et skew court terme	39
3.7	Riccati fractionnaire : comment rHeston reste prenable pour le pricing	40
3.8	Simulation et calibration de rHeston (vue pratique)	41
3.9	Synthèse : Heston vs rHeston (quoi retenir ?)	43
3.10	Conclusion et pistes	43

3.11	Annexe A : integration fractionnaire et identite Beta/Gamma	43
3.12	Annexe B : comment expliquer rHeston en 5 minutes (script d'oral)	43
3.13	Annexe C : (ouverture) microstructure, Hawkes, et emergence du rough	44
3.14	Annexe D : forward variance, etat fonctionnel, et intuition de « markovianite infinie-dimensionnelle »	44
3.15	Mode microscope : SVIE, Riccati–Volterra et approximations	45
3.16	Pièges classiques / erreurs fréquentes	45
3.17	Checklist — savoir refaire sans regarder	45
4	Rough Bergomi (rBergomi)	46
4.1	Avant-propos : rBergomi (rough Bergomi)	46
	Avant-propos : prérequis, notations, objectif	47
4.2	Motivation : pourquoi la volatilité est « rough » ?	47
4.3	Cadre général : volatilité stochastique et variance forward	48
4.4	Point de départ : Heston et rough Heston (rappel de structure)	49
4.5	Le « truc » Bergomi : modéliser directement $\xi_t(T)$	50
4.6	Interlude : exponentielles stochastiques et loi de $\xi_t(T)$	51
4.7	Dérivation pas à pas du modèle rBergomi	51
4.8	Le facteur rough en détail : processus de Volterra et lien fBm	53
4.9	Vérifications rapides : positivité, $\mathbb{E}[V_t]$, cas limite	54
4.10	Interprétation des paramètres et impact sur le smile	54
4.11	Smile, skew et asymptotiques court terme : une lecture à savoir expliquer	55
4.12	Lien conceptuel avec rHeston : que gagne-t-on, que perd-t-on ?	55
4.13	Simulation Monte Carlo de rBergomi (pratique)	56
4.14	Accélération et extensions : approximations markoviennes (multi-facteurs)	57
4.15	Calibration : que calibre-t-on dans rBergomi ?	58
4.16	Mode microscope : construction et checks	59
4.17	Pièges classiques / erreurs fréquentes	60
4.18	Checklist — savoir refaire sans regarder	60
5	Rough cheat sheet : noyaux, approx Markovienne, calibration (ultra-dense)	61
5.1	Idée centrale	61
5.2	Cadre mathématique (Volterra / rough)	61
5.3	Rough Heston : ce qu'il faut savoir citer	61
5.4	Approximation Markovienne (somme d'exponentielles)	62
5.5	Calibration : réflexes et diagnostics	62
5.6	Tests / sanity checks (courts, mais indispensables)	62
5.7	Pitfalls (ce qui fait planter une implémentation)	62

Chapitre 1

Volterra SDE

Idée centrale. Les SVIE (Volterra SDE) modélisent de la mémoire via un noyau de convolution : le présent dépend de tout l'historique pondéré par K . C'est la brique technique derrière rough volatility (rHeston/rBergomi).

Cadre mathématique.

- **Forme.** $X_t = X_0 + \int_0^t K(t-s)b(X_s)ds + \int_0^t K(t-s)\sigma(X_s)dW_s$.
- **Noyaux.** Exponentiel $\Rightarrow$ mémoire courte (approx. Markov multi-facteurs) ; puissance $K(t) \sim t^{H-1/2} \Rightarrow$ rugosité.
- **Non-Markov.** Pas de réduction à un état fini sans approximation (coût mémoire).

Intuition marché / interprétation. Les noyaux capturent des régularités empiriques à court terme (signature rough). Le coût pratique est numérique : convolution, complexité, et calibration.

Implémentation.

- Discrétiser la convolution : coût naïf $O(N^2)$; accélérations via approximation multi-exponentielle / FFT selon structure.
- Simuler via schémas « hybrid » et contrôler erreur de pas (stabilité).

Tests / sanity checks.

- Cas limite $K \equiv 1$: retour à une EDS markovienne (check).
- Stabilité : résultats peu sensibles au pas dans une zone (sinon schéma trop grossier).
- Complexité : monitorer coût et mémoire vs N (diagnostic d'implémentation).

Pont vers pratique quant. Pont quant : implémentation rough en production (approx. multi-facteurs), pricing/MC sous mémoire, et calibration à court terme (smile, forward variance).

1.1 Avant-propos : mémoire et noyaux (Volterra SDE)

Jusqu'ici, la plupart des modèles étaient **markoviens** : l'avenir ne dépend du passé que via l'état courant. Les modèles « rough » et, plus largement, les modèles à mémoire, reposent sur une autre idée : le présent agrège tout l'historique via une **convolution** par un noyau K . Les équations stochastiques de Volterra (SVIE) sont le langage naturel de cette approche.

1.1.1 Objectifs pédagogiques

- Comprendre la forme générale d'une SVIE et le rôle du noyau $K(t-s)$.
- Relier noyau et mémoire : exponentiel $\Rightarrow$ mémoire courte, puissance $\Rightarrow$ mémoire singulière/rough.
- Voir pourquoi ces modèles sont non markoviens, et comment on les approxime numériquement (multi-facteurs).
- Préparer les chapitres fBm / rough Heston / rBergomi : mêmes noyaux, mais usages différents.

1.1.2 Pré-requis

- Itô et intégrales de convolution (au niveau « savoir lire »).
- Notion d'EDS classique (cas $K \equiv 1$) comme point de comparaison.

1.1.3 Plan du chapitre

1. SVIE : définition, exemples de noyaux, intuition.
2. Existence/unicité (niveau cours) et ordre de complexité.

3. Approximation multi-facteurs : pourquoi c'est la brique numérique derrière le rough.

Intuition de marché. Le « rough » n'est pas un gadget : il capture une régularité observée à très court terme. Les noyaux de Volterra sont la manière la plus économique de modéliser une mémoire qui n'est ni infinie, ni résumable par un seul facteur markovien.

Résumé

Ces notes introduisent, *from ground up*, les *équations stochastiques de Volterra* (souvent appelées *stochastic Volterra integral equations*, SVIE), c'est-à-dire des dynamiques en temps continu où l'évolution dépend du passé via un *noyau* (kernel) de mémoire. L'objectif est d'être capable (i) de **définir** rigoureusement une Volterra SDE, (ii) d'en **expliquer la dérivation pas à pas** à partir d'une dynamique discrète pondérée, (iii) de comprendre les **conséquences** (non-markovianité, régularité, simulation), et (iv) de faire une **ouverture** vers le modèle de Heston (volatilité stochastique) et sa version *Volterra/rough*.

1.2 Pourquoi des Volterra SDE en finance quantitative ?

1.2.1 Le point de départ : les diffusions markoviennes

En modélisation des marchés, un choix standard consiste à représenter le prix (ou le log-prix) par une diffusion d'Itô

$$dS_t = \mu(t, S_t) dt + \sigma(t, S_t) dW_t,$$

où W est un mouvement brownien. Dans ce cadre, tout est *local* : l'évolution future ne dépend que de l'état présent (propriété de Markov) si les coefficients ne dépendent que de (t, S_t) .

1.2.2 Pourquoi ce n'est pas toujours satisfaisant : mémoire et rugosité

En pratique, la volatilité observée (ou estimée) présente des caractéristiques qui motivent l'introduction de *mémoire* :

- **Persistence / long memory** : les chocs de volatilité se dissipent lentement.
- **Multiscale** : on observe des horizons multiples (intra-day, daily, weekly, etc.).
- **Rough volatility** : empiriquement, la volatilité est souvent plus « irrégulière » qu'une diffusion classique (paramètre de Hurst $H < 1/2$ dans les modèles rough).

Une manière naturelle d'encoder « l'influence du passé » est d'introduire un noyau K qui pondère les contributions passées.

1.2.3 Idée centrale : remplacer le « local » par une convolution

Au lieu d'écrire une SDE locale en dt et dW_t , on décrit le processus X par une équation intégrale où drift et diffusion apparaissent via un noyau :

$$X_t = X_0 + \int_0^t K(t-s) b(X_s) ds + \int_0^t K(t-s) \sigma(X_s) dW_s.$$

Le terme $K(t-s)$ dit : *ce qui s'est passé à la date s continue d'influencer t avec un poids qui dépend du délai $t-s$.*

1.2.4 Objectifs pédagogiques (ce que l'étudiant doit savoir refaire)

- Expliquer la différence entre **SDE d'Itô** et **Volterra SDE** (SVIE).
- Dériver pas à pas une Volterra SDE comme limite continue d'une dynamique discrète avec **poids de mémoire**.
- Reconnaître les noyaux importants (constant, exponentiel, somme d'exponentielles, noyau fractionnaire).
- Comprendre le lien avec la **volatilité stochastique** et l'ouverture vers **Heston** (et rough Heston).

1.2.5 Mini-résumé oral (2 minutes)

Une Volterra SDE est une équation d'évolution *non locale* : au lieu que dX_t dépende seulement de X_t , on écrit X_t comme une somme de contributions passées pondérées par un noyau $K(t-s)$. On l'obtient naturellement en partant d'un schéma discret où chaque choc (drift et bruit) persiste dans le temps avec un poids K , puis en passant à la limite $\Delta t \rightarrow 0$: les sommes pondérées deviennent des intégrales (Riemann et Itô). Si $K \equiv 1$, on retrouve l'SDE classique ; si K est exponentiel, on peut « markovianiser » en ajoutant des variables d'état ; si K est de type puissance, on obtient des dynamiques *rough* utilisées pour modéliser la volatilité.

1.3 De la volatilité discrète à la mémoire continue : EWMA, GARCH et noyaux

1.3.1 Pourquoi partir du discret ?

En pratique, beaucoup d'intuitions de modélisation viennent d'abord du discret :

- les données de marché sont observées sur une grille (ticks, minutes, jours) ;
- les estimateurs de volatilité (réalisée, EWMA, GARCH) sont formulés en sommes ;
- on comprend mieux la « mémoire » en regardant des pondérations explicites sur le passé.

L'idée des Volterra SDE est précisément de donner un analogue en temps continu de ces sommes pondérées.

1.3.2 EWMA : pondération exponentielle et mémoire courte

Un estimateur type EWMA (Exponentially Weighted Moving Average) s'écrit (discrètement)

$$v_{n+1} = (1 - \alpha) v_n + \alpha r_n^2, \quad \alpha \in (0, 1),$$

où r_n est un rendement sur l'intervalle $[t_n, t_{n+1}]$. En déroulant la récurrence,

$$v_{n+1} = (1 - \alpha)^{n+1} v_0 + \alpha \sum_{k=0}^n (1 - \alpha)^{n-k} r_k^2.$$

On voit apparaître une **convolution discrète** : les contributions passées r_k^2 sont pondérées par une décroissance exponentielle. C'est l'analogue discret d'un noyau

$$K(t) = e^{-\lambda t}, \quad \lambda > 0,$$

qui correspond à une mémoire courte (le poids chute vite quand t grandit).

1.3.3 GARCH : persistance et retour à la moyenne

Un GARCH(1, 1) s'écrit typiquement

$$v_{n+1} = \omega + \beta v_n + \alpha r_n^2, \quad \omega > 0, \alpha, \beta \geq 0, \alpha + \beta < 1.$$

Là encore, v_{n+1} est une somme de contributions passées (avec poids géométriques) plus un terme constant, ce qui encode :

- un **retour à la moyenne** (via ω et β) ;
- une **réaction aux chocs** (via r_n^2) ;
- une **persistance** (si $\alpha + \beta$ proche de 1).

En temps continu, le modèle de Heston (variance CIR) est souvent vu comme une version diffusion de cette intuition : variance mean-reverting, bruit de variance, corrélation avec le prix.

1.3.4 Poids en loi de puissance : mémoire longue et roughness

La mémoire empirique de la volatilité (et certaines statistiques de haute fréquence) suggère parfois des pondérations qui décroissent plus lentement qu'une exponentielle. Un prototype est un poids en loi de puissance :

$$K(t) \propto t^{H-\frac{1}{2}}, \quad H \in (0, 1/2).$$

Deux conséquences clés :

- la singularité en 0 renforce la contribution des *toutes petites échelles* (ce qui rend le processus plus « rough ») ;
- la décroissance lente du noyau fait persister l'impact d'un choc plus longtemps (mémoire longue).

Dans les modèles rough, on choisit précisément de tels noyaux pour reproduire simultanément ces deux phénomènes.

1.3.5 De la somme à l'intégrale : le message

Sur une grille, une dynamique à mémoire ressemble à

$$X_{n+1} \approx X_0 + \sum_{k \leq n} K(t_{n+1} - t_{k+1}) (\text{drift}) \Delta + \sum_{k \leq n} K(t_{n+1} - t_{k+1}) (\text{diffusion}) \Delta W_k.$$

En temps continu, cette somme devient une équation intégrale (Volterra SDE). C'est exactement la dérivation que l'on formalise dans la Section 1.7.

1.4 Préliminaires : cadre probabiliste et intégrales d'Itô

1.4.1 Espace probabilisé et filtration

On travaille sur un espace probabilisé $(\Omega, \mathcal{F}, \mathbb{P})$ muni d'une filtration $(\mathcal{F}_t)_{t \geq 0}$ (information disponible à la date t). Un processus (X_t) est *adapté* si X_t est $\mathcal{F}_t$ -mesurable pour tout t .

1.4.2 Mouvement brownien et brownien bidimensionnel

Définition 1.1 (Mouvement brownien standard). Un processus $(W_t)_{t \geq 0}$ est un mouvement brownien standard (relatif à $(\mathcal{F}_t)$) si :

1. $W_0 = 0$ p.s. ;
2. W a des trajectoires continues ;
3. $W_t - W_s \sim \mathcal{N}(0, t - s)$ pour $0 \leq s < t$;
4. les incréments sur des intervalles disjoints sont indépendants ;
5. W_t est $\mathcal{F}_t$ -mesurable.

En volatilité stochastique, on utilise souvent deux browniens corrélés (W, B) tels que

$$\langle W, B \rangle_t = \rho t, \quad \rho \in [-1, 1].$$

Une réalisation pratique consiste à écrire $B = \rho W + \sqrt{1 - \rho^2} W^\perp$ où $W^\perp$ est un brownien indépendant de W .

1.4.3 Intégrale d'Itô (rappel minimal)

Pour un processus adapté (H_t) satisfaisant $\mathbb{E}[\int_0^T H_t^2 dt] < \infty$, l'intégrale d'Itô $\int_0^T H_t dW_t$ est définie comme limite en L^2 d'intégrales de processus en escalier. Propriété clé :

Proposition 1.1 (Isométrie d'Itô). Si H est adapté et carré-intégrable,

$$\mathbb{E}\left[\left(\int_0^T H_t dW_t\right)^2\right] = \mathbb{E}\left[\int_0^T H_t^2 dt\right].$$

Remarque 1.1. L'isométrie est la base de presque tous les calculs de moments dans ce cours : elle permet de ramener une question « stochastique » à une intégrale déterministe.

1.4.4 Heuristique d'échelle : $dW_t \sim \sqrt{dt}$

Même si la notation dW_t n'a pas le statut d'une différentielle classique, elle encode correctement les ordres de grandeur :

$$W_{t+\Delta t} - W_t = \mathcal{O}(\sqrt{\Delta t}), \quad (\Delta W)^2 = \mathcal{O}(\Delta t).$$

En finance, cette heuristique explique pourquoi les modèles continus reproduisent naturellement des effets d'ordre **linéaire en temps** sur les variances et covariances (par exemple $\text{Var}(W_t) = t$).

1.4.5 Formule d'Itô (rappel) et message pour Volterra

Soit un processus d'Itô $X_t = X_0 + \int_0^t a_s ds + \int_0^t b_s dW_s$ et une fonction $f \in \mathcal{C}^{1,2}$. La formule d'Itô affirme :

$$df(t, X_t) = \partial_t f(t, X_t) dt + \partial_x f(t, X_t) dX_t + \frac{1}{2} \partial_{xx} f(t, X_t) b_t^2 dt.$$

Le terme $\frac{1}{2} b_t^2 dt$ est l'empreinte de la variation quadratique du brownien (heuristiquement $(dW_t)^2 = dt$).

Remarque 1.2. Point important pour la suite : si X est un *processus de Volterra* rough (souvent non semi-martingale), la formule d'Itô *ne s'applique pas directement* à $f(X_t)$. En revanche, dans les modèles de volatilité stochastique rough, le *prix* S reste une SDE d'Itô (donc Itô s'applique à $f(S_t)$), tandis que la variance V est un processus de Volterra.

1.5 Rappel : SDE d'Itô et forme intégrale

1.5.1 Définition et écriture intégrale

Définition 1.2 (SDE d'Itô (forme intégrale)). On dit que X vérifie la SDE

$$dX_t = b(t, X_t) dt + \sigma(t, X_t) dW_t, \quad X_0 = x_0,$$

si, pour tout $t \in [0, T]$,

$$X_t = x_0 + \int_0^t b(s, X_s) ds + \int_0^t \sigma(s, X_s) dW_s.$$

Cette écriture *intégrale* est la définition rigoureuse ; la notation différentielle $dX_t = \dots$ est un raccourci.

1.5.2 Existence et unicité (énoncé standard)

Théorème 1.1 (Existence et unicité forte : cas lipschitzien). *On suppose que b et σ sont lipschitziens en x (uniformément en t) et à croissance linéaire. Alors il existe un unique processus adapté à trajectoires continues solution de l'SDE.*

Remarque 1.3. La preuve passe par une itération de Picard (méthode du point fixe) dans un espace de processus, en utilisant des inégalités de type Grönwall et l'isométrie d'Itô. On fera un raisonnement analogue pour les équations de Volterra.

1.5.3 Pourquoi l'SDE classique est markovienne

Si $b(t, x)$ et $\sigma(t, x)$ dépendent seulement de l'état courant (t, X_t) , le futur *conditionnellement au présent* ne dépend pas de tout le passé : c'est la structure markovienne. Cette propriété est cruciale pour obtenir des PDE de pricing, des formules de transformée de Fourier, etc.

1.5.4 Mesure risque-neutre (rappel) : pourquoi introduire $\mathbb{Q}$?

En arbitrage-free pricing, on cherche une mesure $\mathbb{Q}$ sous laquelle les prix actualisés sont des martingales. Dans le cas le plus simple (Black–Scholes), sous la mesure historique $\mathbb{P}$ on a

$$dS_t = \mu S_t dt + \sigma S_t dW_t^{\mathbb{P}}.$$

Sous des hypothèses standard (absence d'arbitrage et complétude), on construit une mesure équivalente $\mathbb{Q}$ (Girsanov) telle que

$$dS_t = r S_t dt + \sigma S_t dW_t^{\mathbb{Q}}, \quad W_t^{\mathbb{Q}} := W_t^{\mathbb{P}} + \int_0^t \frac{\mu - r}{\sigma} ds.$$

On retrouve ainsi l'idée : **le drift change avec la mesure**, mais le bruit brownien reste le moteur de l'incertitude.

Remarque 1.4. Dans les modèles à volatilité stochastique (Heston, rough Heston), on travaille presque toujours sous $\mathbb{Q}$: la dynamique de S est écrite avec le taux sans risque r , tandis que la dynamique de V peut inclure des primes de risque (absorbées dans les paramètres sous $\mathbb{Q}$).

1.6 Équations de Volterra déterministes : le prototype avec mémoire

1.6.1 Volterra intégrale : définition

Définition 1.3 (Équation de Volterra (déterministe)). Soit $K : [0, T] \rightarrow \mathbb{R}$ un noyau (kernel) et $f : \mathbb{R} \rightarrow \mathbb{R}$. Une équation de Volterra est une équation intégrale du type

$$x(t) = x_0 + \int_0^t K(t-s) f(x(s)) ds, \quad t \in [0, T].$$

Le noyau K joue le rôle d'une *mémoire* : au temps t , la contribution de $x(s)$ est pondérée par $K(t-s)$.

1.6.2 Trois noyaux à connaître

1. **Noyau constant** $K \equiv 1$. On retrouve l'ODE classique :

$$x(t) = x_0 + \int_0^t f(x(s)) ds \iff x'(t) = f(x(t)) \text{ (si } x \text{ dérivable).}$$

2. **Noyau exponentiel** $K(t) = e^{-\lambda t}$. C'est le noyau d'une mémoire « à décroissance exponentielle ».
3. **Noyau puissance** $K(t) = t^{\alpha-1}$, $\alpha \in (0, 1)$. Il encode une mémoire « lourde » (singularité à 0 et décroissance lente).

1.6.3 Markovianisation dans le cas exponentiel

Le noyau exponentiel permet de transformer l'équation intégrale en système d'ODE (augmentation d'état). Posons

$$y(t) := \int_0^t e^{-\lambda(t-s)} f(x(s)) \, ds.$$

Alors $x(t) = x_0 + y(t)$ et (en dérivant formellement)

$$y'(t) = -\lambda y(t) + f(x(t)).$$

On obtient un système markovien (x, y) . Cette idée sera réutilisée en version stochastique.

1.6.4 Équation linéaire et noyau résolvant (résolvante)

Considérons l'équation linéaire (déterministe)

$$x(t) = x_0 + \int_0^t K(t-s) (a x(s) + c) \, ds, \quad (1.1)$$

où $a, c \in \mathbb{R}$. Le cas $c = 0$ est central : il décrit un feedback linéaire avec mémoire. On peut résoudre (1.1) via un *noyau résolvant* R (ou *résolvante*), défini comme la solution de

$$R(t) = K(t) + a \int_0^t K(t-s) R(s) \, ds \quad (t \in [0, T]). \quad (1.2)$$

Intuition : R joue le rôle de « réponse impulsionnelle » du système. On peut alors montrer (au moins formellement, et rigoureusement sous hypothèses d'intégrabilité) que la solution s'écrit

$$x(t) = x_0 + \int_0^t R(t-s) c \, ds + \int_0^t R(t-s) a x_0 \, ds.$$

Dans le cas $K \equiv 1$, on a $R(t) = e^{at}$ et on retrouve la solution de l'ODE $x'(t) = ax(t) + c$.

Remarque 1.5. La relation (1.2) est l'analogue de la formule $(I - aA)^{-1} = I + aA + a^2 A^2 + \dots$: on somme toutes les itérations de mémoire. En pratique, dès qu'on sait approximer K par une somme d'exponentielles, on sait aussi approcher R par une somme d'exponentielles.

1.6.5 Inégalité de Grönwall–Volterra (outil d'estimation)

Les équations de Volterra remplacent souvent l'inégalité de Grönwall standard par une version à *convolution*. Un énoncé typique est :

Lemme 1.1 (Grönwall–Volterra (forme simple)). *Soit $u : [0, T] \rightarrow \mathbb{R}_+$ telle que, pour tout t ,*

$$u(t) \leq A + \int_0^t K(t-s) u(s) \, ds,$$

où $A \geq 0$ et $K \geq 0$ est dans $L^1([0, T])$. Alors $u(t) \leq A g(t)$, où g est la solution de l'équation de Volterra

$$g(t) = 1 + \int_0^t K(t-s) g(s) \, ds.$$

Cette inégalité est un ingrédient standard pour la stabilité et l'unicité (en déterministe comme en stochastique).

1.6.6 Lien avec les intégrales fractionnaires

Pour $\alpha \in (0, 1)$, l'intégrale fractionnaire de Riemann–Liouville est

$$(I^\alpha f)(t) = \frac{1}{\Gamma(\alpha)} \int_0^t (t-s)^{\alpha-1} f(s) \, ds.$$

On reconnaît une équation de Volterra avec noyau $K(t) = t^{\alpha-1}/\Gamma(\alpha)$. Le noyau rough (1.9) correspond précisément à $\alpha = H + \frac{1}{2}$. Ainsi, une grande partie de la théorie rough peut se comprendre comme du **calcul fractionnaire** appliqué à des intégrales stochastiques.

1.7 Volterra SDE : dérivation pas à pas depuis une dynamique discrète

Cette section est le **cœur pédagogique** : on construit la Volterra SDE comme limite d'un modèle discret. L'objectif est de pouvoir raconter cette dérivation de manière claire et reproductible.

1.7.1 Étape 0 : point de départ discret (schéma Euler d'une SDE)

Soit une grille $t_n = n\Delta$ et des incréments browniens

$$\Delta W_n := W_{t_{n+1}} - W_{t_n} \sim \mathcal{N}(0, \Delta).$$

Un schéma d'Euler pour l'SDE classique $dX_t = b(X_t)dt + \sigma(X_t)dW_t$ est

$$X_{n+1} = X_n + b(X_n)\Delta + \sigma(X_n)\Delta W_n.$$

Ce schéma est *local* : l'update dépend seulement de X_n et du choc courant ΔW_n .

1.7.2 Étape 1 : introduire une mémoire explicite (poids sur le passé)

Pour modéliser une influence persistante des chocs, on suppose que les contributions passées restent actives avec un poids. On fixe une suite de poids $(K_m)_{m \geq 0}$, et on définit une dynamique à mémoire :

$$X_{n+1} = X_0 + \sum_{k=0}^n K_{n-k} b(X_k) \Delta + \sum_{k=0}^n K_{n-k} \sigma(X_k) \Delta W_k. \quad (1.3)$$

Lecture : le choc (drift ou bruit) produit à la date t_k influence encore t_{n+1} via le poids K_{n-k} .

Remarque 1.6. La dynamique (1.3) n'est **pas markovienne** en général : pour prédire X_{n+1} , connaître X_n ne suffit pas, car l'update contient des termes dépendant de tous les X_k passés.

1.7.3 Étape 2 : passer de (K_m) à un noyau continu $K(t)$

On veut maintenant une limite continue quand $\Delta \rightarrow 0$. On suppose que les poids viennent d'un noyau continu $K : [0, T] \rightarrow \mathbb{R}$ via

$$K_{n-k} \approx K(t_{n+1} - t_{k+1}) = K((n-k)\Delta).$$

Ainsi, plus t_k est loin dans le passé, plus son influence est modulée par K .

1.7.4 Étape 3 : somme déterministe $\rightarrow$ intégrale (Riemann)

Regardons la partie drift de (1.3) :

$$\sum_{k=0}^n K(t_{n+1} - t_{k+1}) b(X_k) \Delta.$$

Quand $\Delta \rightarrow 0$, cette somme est une somme de Riemann qui converge (heuristiquement) vers

$$\int_0^t K(t-s) b(X_s) ds, \quad \text{où } t = t_{n+1}.$$

Ce passage à la limite est le même que pour les équations de Volterra déterministes.

1.7.5 Étape 4 : somme stochastique $\rightarrow$ intégrale d'Itô

Regardons la partie bruit :

$$\sum_{k=0}^n K(t - t_{k+1}) \sigma(X_k) \Delta W_k.$$

Quand $\Delta \rightarrow 0$, c'est exactement la forme d'une *somme d'Itô* : un intégrand adapté ($\sigma(X_k)$) multiplié par un incrément brownien. Sous des conditions d'intégrabilité, ces sommes convergent vers l'intégrale stochastique

$$\int_0^t K(t-s) \sigma(X_s) dW_s.$$

Remarque 1.7. Intuition : la définition de $\int H_s dW_s$ est précisément la limite de sommes $\sum H_{t_k}(W_{t_{k+1}} - W_{t_k})$. Ici on a simplement un intégrand *modifié* par $K(t-s)$.

1.7.6 Étape 5 : équation limite (Volterra SDE)

En rassemblant les deux limites, on obtient l'équation continue suivante :

$$X_t = X_0 + \int_0^t K(t-s) b(X_s) ds + \int_0^t K(t-s) \sigma(X_s) dW_s. \quad (1.4)$$

On appelle (1.4) une **équation stochastique de Volterra** (ou Volterra SDE).

1.7.7 Étape 6 : vérifier les cas-limites (sanity check)

— Si $K \equiv 1$, alors (1.4) devient

$$X_t = X_0 + \int_0^t b(X_s) ds + \int_0^t \sigma(X_s) dW_s,$$

c'est-à-dire l'SDE d'Itô classique.

— Si $K(t) = e^{-\lambda t}$, on s'attend à pouvoir introduire une variable d'état supplémentaire et retrouver une dynamique markovienne (voir Section 1.13).

— Si $K(t) = t^{H-\frac{1}{2}}/\Gamma(H + \frac{1}{2})$ avec $H \in (0, 1/2)$, le noyau est singulier en 0 : on obtient des trajectoires *rough* (Section 1.14).

1.7.8 Comment l'expliquer à un autre étudiant (script)

1. Partir d'un schéma Euler (sans mémoire).
2. Dire : « chaque choc passé laisse une trace, pondérée par K ».
3. Écrire la somme pondérée sur le passé.
4. Passer à la limite : somme de Riemann $\rightarrow$ intégrale en ds ; somme d'Itô $\rightarrow$ intégrale en dW_s .
5. Conclure : l'équation limite est intégrale et non locale ; elle généralise l'SDE.

1.8 Définitions générales : SVIE et forme convolution

1.8.1 Forme générale (coefficients dépendant de (t, s))

Définition 1.4 (SVIE : stochastic Volterra integral equation). Une *équation stochastique de Volterra* est une équation intégrale du type

$$X_t = X_0 + \int_0^t b(t, s, X_s) ds + \int_0^t \sigma(t, s, X_s) dW_s, \quad t \in [0, T], \quad (1.5)$$

où b et σ peuvent dépendre de t et de s .

Remarque 1.8. La dépendance en (t, s) est naturelle : le poids accordé à l'information passée à la date s peut dépendre de la date d'évaluation t . Dans beaucoup d'applications en finance, on utilise une structure *stationnaire* via $K(t-s)$.

1.8.2 Forme convolution (kernel de mémoire)

Définition 1.5 (Volterra SDE de type convolution). On dit que X vérifie une Volterra SDE de type convolution si

$$X_t = X_0 + \int_0^t K(t-s) b(X_s) ds + \int_0^t K(t-s) \sigma(X_s) dW_s,$$

où $K : [0, T] \rightarrow \mathbb{R}$ est un noyau mesurable.

1.8.3 Conséquences immédiates : non-markovianité et non-localité

Dans une SDE classique, l'évolution est gouvernée par $b(X_t)$ et $\sigma(X_t)$ au temps t . Dans une Volterra SDE, l'état X_t dépend de toute la trajectoire $\{X_s : 0 \leq s \leq t\}$ à travers des intégrales. Cela entraîne typiquement :

- **Non-Markov** : X n'est pas markovien sauf cas particuliers (noyau exponentiel / somme d'exponentielles).
- **Non-semimartingale (souvent)** : certains noyaux singuliers produisent des processus qui ne sont pas des semimartingales (important pour le calcul stochastique sur X lui-même).
- **Mémoire** : les chocs ont une persistance structurée par K .

1.9 Convolution stochastique : calculs de base et intuition

1.9.1 Notations de convolution

Pour une fonction f (ou processus) on note

$$(K * f)(t) := \int_0^t K(t-s) f(s) ds.$$

Pour un processus H adapté carré-intégrable, on définit la convolution stochastique

$$(K * (H \cdot dW))(t) := \int_0^t K(t-s) H_s dW_s.$$

Avec ces notations, la Volterra SDE (1.4) s'écrit compactement :

$$X = X_0 + (K * b(X)) + (K * (\sigma(X) \cdot dW)).$$

1.9.2 Moment d'ordre 2 : version « Itô isometry »

Si $Z_t = \int_0^t K(t-s) H_s dW_s$, alors par isométrie d'Itô :

$$\mathbb{E}[Z_t^2] = \mathbb{E}\left[\int_0^t K(t-s)^2 H_s^2 ds\right]. \quad (1.6)$$

En particulier, si $H_s \equiv 1$, on obtient

$$\mathbb{E}[Z_t^2] = \int_0^t K(t-s)^2 ds = \int_0^t K(u)^2 du.$$

1.9.3 Exemple : processus de Volterra gaussien

Définition 1.6 (Processus gaussien de Volterra). On appelle *processus (gaussien) de Volterra* un processus

$$X_t = \int_0^t K(t-s) dW_s,$$

où K est déterministe et carré-intégrable sur $[0, T]$.

Il est centré gaussien, et sa covariance se calcule explicitement :

Proposition 1.2 (Covariance). Pour $t, u \in [0, T]$,

$$\text{Cov}(X_t, X_u) = \int_0^{t \wedge u} K(t-s) K(u-s) ds.$$

Démonstration. On écrit $X_t = \int_0^{t \wedge u} K(t-s) dW_s + \int_{t \wedge u}^t K(t-s) dW_s$. Le second terme est orthogonal à X_u (indépendance des incréments). On conclut par isométrie d'Itô. $\square$

1.9.4 Régularité : comment le noyau impose la « rugosité »

La régularité de $X_t = \int_0^t K(t-s) dW_s$ dépend du comportement de K près de 0. Heuristique utile :

- si K est **borné**, X ressemble localement à un brownien (régularité $\approx 1/2$ -Hölder) ;
- si $K(u) \sim u^{H-\frac{1}{2}}$ avec $H < 1/2$, alors X est **plus rugueux** (Hölder $\approx H$).

Cette observation explique pourquoi les noyaux de type puissance sont centraux en *rough volatility*.

1.10 Exemples guidés : comprendre la mémoire par des cas concrets

Cette section donne des exemples que l'on peut **recalculer à la main** : le but est de rendre tangible l'effet du noyau.

1.10.1 Exemple 1 : $K \equiv 1$ (Itô classique, semimartingale)

Si $K \equiv 1$, l'équation

$$X_t = X_0 + \int_0^t b(X_s) ds + \int_0^t \sigma(X_s) dW_s$$

définit un *processus d'Itô*. On dispose alors de tout l'arsenal standard :

- propriété de Markov (si b, σ ne dépendent que de X_t) ;
- formule d'Itô pour $f(X_t)$;
- crochet $[X]_t = \int_0^t \sigma(X_s)^2 ds$.

Ce cas sert de repère : les Volterra SDE généralisent ce cadre.

1.10.2 Exemple 2 : Volterra gaussien exponentiel = OU

On prend

$$Y_t = \int_0^t e^{-\lambda(t-s)} dW_s, \quad \lambda > 0.$$

On a vu que Y vérifie l'SDE d'Ornstein–Uhlenbeck :

$$dY_t = -\lambda Y_t dt + dW_t.$$

On peut alors calculer explicitement sa variance :

$$\text{Var}(Y_t) = \frac{1 - e^{-2\lambda t}}{2\lambda}, \quad \text{Var}(Y_\infty) = \lim_{t \rightarrow \infty} \text{Var}(Y_t) = \frac{1}{2\lambda}.$$

Ce calcul illustre un point clé : **un noyau exponentiel produit une mémoire courte et un modèle markovien en dimension augmentée**.

1.10.3 Exemple 3 : équation linéaire avec noyau exponentiel (réduction à une SDE)

Considérons la Volterra SDE linéaire

$$X_t = X_0 + \int_0^t e^{-\lambda(t-s)} (aX_s + c) ds + \int_0^t e^{-\lambda(t-s)} \sigma dW_s. \quad (1.7)$$

Posons

$$U_t := \int_0^t e^{-\lambda(t-s)} (aX_s + c) ds \quad \text{et} \quad V_t := \int_0^t e^{-\lambda(t-s)} \sigma dW_s.$$

Alors $X_t = X_0 + U_t + V_t$ et, en dérivant formellement les convolutions exponentielles,

$$dU_t = -\lambda U_t dt + (aX_t + c) dt, \quad dV_t = -\lambda V_t dt + \sigma dW_t.$$

En sommant : $dX_t = dU_t + dV_t$, donc

$$dX_t = -\lambda(X_t - X_0) dt + (aX_t + c) dt + \sigma dW_t = ((a - \lambda)X_t + \lambda X_0 + c) dt + \sigma dW_t.$$

Conclusion : (1.7) est équivalente à une SDE d'Itô classique. La mémoire exponentielle est *compatible* avec un état markovien fini.

1.10.4 Exemple 4 : noyau somme d'exponentielles = modèle multi-facteurs

Si $K(t) = \sum_{i=1}^m w_i e^{-\lambda_i t}$, alors toute convolution $t \mapsto \int_0^t K(t-s) \cdot d(\cdot)$ se décompose en somme de m convolutions exponentielles, chacune markovianisable. Le modèle obtenu est alors un **modèle multi-facteurs** (dimension m en plus), souvent utilisé pour approcher des noyaux rough en pratique.

1.10.5 Exemple 5 : noyau rough = non-semimartingale (intuition)

Pour $K_H(t) \propto t^{H-\frac{1}{2}}$ avec $H < 1/2$, le processus $X_t = \int_0^t K_H(t-s) dW_s$ est typiquement trop irrégulier pour être une semimartingale. Conséquence : on ne peut pas appliquer directement la formule d'Itô à $f(X_t)$. C'est une raison pour laquelle les modèles rough en finance sont construits de sorte que *le prix* reste une diffusion d'Itô, tandis que la *volatilité* est rough.

1.11 Simulation numérique des Volterra SDE : schémas et complexité

1.11.1 Schéma Euler–Volterra (discrétisation directe)

Sur une grille $t_n = n\Delta$ et avec $\Delta W_n = W_{t_{n+1}} - W_{t_n}$, un schéma naturel pour

$$X_t = X_0 + \int_0^t K(t-s)b(X_s)ds + \int_0^t K(t-s)\sigma(X_s)dW_s$$

est :

$$X_{n+1} = X_0 + \sum_{k=0}^n K(t_{n+1} - t_{k+1}) b(X_k) \Delta + \sum_{k=0}^n K(t_{n+1} - t_{k+1}) \sigma(X_k) \Delta W_k. \quad (1.8)$$

C'est exactement la dynamique discrète motivante de la Section 1.7.

1.11.2 Coût naïf : $\mathcal{O}(N^2)$

La formule (1.8) demande, pour chaque n , une somme sur $k \leq n$. Le coût total sur N pas de temps est donc en général $\mathcal{O}(N^2)$. Ce coût devient vite prohibitif en calibration ou pricing Monte Carlo.

1.11.3 Accélération 1 : markovianisation (mélange d'exponentielles)

Si on approxime K par $K_m(t) = \sum_{i=1}^m w_i e^{-\lambda_i t}$, alors on introduit m facteurs Y^i de type OU :

$$dY_t^i = -\lambda_i Y_t^i dt + \sigma(X_t) dW_t, \quad i = 1, \dots, m,$$

et on reconstruit la convolution comme combinaison linéaire de ces facteurs. Le coût devient $\mathcal{O}(mN)$, ce qui est souvent exploitable si m est modéré (typiquement 5–50 selon la précision).

1.11.4 Accélération 2 : convolution rapide (cas linéaires)

Dans des cas linéaires (où $b(X_s)$ ou $\sigma(X_s)$ ne dépendent pas de s de façon compliquée), on peut utiliser des méthodes de convolution rapides (FFT) sur grille régulière. Cela permet d'évaluer des sommes de type $\sum_{k \leq n} K_{n-k} u_k$ plus vite que $\mathcal{O}(N^2)$. En présence de non-linéarités, l'intérêt dépend de la manière dont on itère (mise à jour incrémentale, stockage, etc.).

1.11.5 Simulation rough : remarques pratiques

Pour K fractionnaire, la simulation directe est difficile (singularité et mémoire longue). En pratique, deux grandes idées coexistent :

- **Schémas hybrides** (pour les processus gaussiens de Volterra) : séparation entre la singularité locale et une partie plus régulière ;
- **Approximations multi-facteurs** : remplacement du noyau rough par une somme d'exponentielles (markovianisation).

Dans des modèles comme rough Heston, un point d'attention supplémentaire est la **positivité** de V ; on utilise souvent des variantes de schéma (troncature, schéma implicite, etc.) pour éviter des valeurs négatives dues à l'approximation numérique.

1.11.6 Pseudocode (schéma Euler–Volterra naïf)

```
Input: grid t0,...,tN, kernel K, fonctions b,sigma
X[0] = X0
for n = 0,...,N-1:
    drift = sum_{k=0}^{n} K(t_{n+1}-t_{k+1}) * b(X[k]) * dt
    diff  = sum_{k=0}^{n} K(t_{n+1}-t_{k+1}) * sigma(X[k]) * dW[k]
    X[n+1] = X0 + drift + diff
```

1.12 Existence et unicité : version cours (cas régulier)

On donne ici un cadre suffisant pour garantir l'existence et l'unicité d'une solution à la Volterra SDE. Le cas *singulier* (noyaux rough) demande des outils plus avancés ; on donnera l'intuition et les références.

1.12.1 Hypothèses simples

Hypothèse 1.1 (Kernel). Le noyau K est dans $L^2([0, T])$ et dans $L^1([0, T])$.

Hypothèse 1.2 (Coefficients). Les fonctions b et σ sont lipschitziennes et à croissance linéaire : il existe $L > 0$ tel que, pour tout $x, y \in \mathbb{R}$,

$$|b(x) - b(y)| + |\sigma(x) - \sigma(y)| \leq L|x - y|, \quad |b(x)| + |\sigma(x)| \leq L(1 + |x|).$$

1.12.2 Énoncé (idée : point fixe)

Théorème 1.2 (Existence et unicité (cas convolution régulier)). *Sous les hypothèses ci-dessus, l'équation*

$$X_t = X_0 + \int_0^t K(t-s)b(X_s)ds + \int_0^t K(t-s)\sigma(X_s)dW_s$$

possède une unique solution adaptée à trajectoires continues sur $[0, T]$.

Remarque 1.9. L'idée est de définir un opérateur Φ sur un espace de processus :

$$(\Phi(X))_t := X_0 + \int_0^t K(t-s)b(X_s)ds + \int_0^t K(t-s)\sigma(X_s)dW_s,$$

puis de montrer que Φ est contractant sur un horizon court (ou sous une norme pondérée), et d'itérer. Les estimations reposent sur Cauchy-Schwarz, Burkholder-Davis-Gundy, et sur $K \in L^1 \cap L^2$.

1.12.3 Cas singulier (rough) : ce qui change

Si $K(u) \sim u^{H-\frac{1}{2}}$ avec $H \in (0, 1/2)$, alors $K \notin L^2$ près de 0 quand $H \leq 0$ mais pour $H > 0$ on a $K \in L^2_{\text{loc}}$ tout en étant singulier. Les preuves demandent des arguments de régularité fractionnaire (intégrales fractionnaires) et des estimations adaptées. En finance, ces noyaux sont utilisés précisément parce qu'ils produisent une volatilité *rough*.

1.13 Kernels importants et markovianisation

1.13.1 Le cas $K \equiv 1$: retour à l'SDE

C'est le cas sanity check : une Volterra SDE avec noyau constant est exactement une SDE d'Itô. Moral : les Volterra SDE généralisent les SDE.

1.13.2 Le cas exponentiel : une variable d'état suffit

Considérons le processus gaussien de Volterra

$$Y_t := \int_0^t e^{-\lambda(t-s)} dW_s.$$

Proposition 1.3 (Convolution exponentielle = OU). *Le processus (Y_t) vérifie l'équation différentielle stochastique*

$$dY_t = -\lambda Y_t dt + dW_t, \quad Y_0 = 0,$$

et c'est donc un processus d'Ornstein-Uhlenbeck.

Démonstration. On veut obtenir une dynamique markovienne en dérivant explicitement Y . Posons

$$Z_t := \int_0^t e^{\lambda s} dW_s.$$

Alors, pour tout t ,

$$Y_t = \int_0^t e^{-\lambda(t-s)} dW_s = e^{-\lambda t} \int_0^t e^{\lambda s} dW_s = e^{-\lambda t} Z_t.$$

Comme $dZ_t = e^{\lambda t} dW_t$ et $d(e^{-\lambda t}) = -\lambda e^{-\lambda t} dt$, la règle du produit (avec $[e^{-\lambda \cdot}, Z] = 0$ car $e^{-\lambda t}$ est de variation finie) donne

$$dY_t = d(e^{-\lambda t} Z_t) = e^{-\lambda t} dZ_t + Z_t d(e^{-\lambda t}) = dW_t - \lambda e^{-\lambda t} Z_t dt = dW_t - \lambda Y_t dt.$$

Enfin $Y_0 = 0$ par définition. $\square$

Conclusion : une convolution exponentielle peut être représentée comme une dynamique markovienne en dimension augmentée.

1.13.3 Somme d'exponentielles : multi-facteurs (approximation de noyaux rough)

Si

$$K(t) = \sum_{i=1}^m w_i e^{-\lambda_i t}, \quad w_i > 0, \lambda_i > 0,$$

alors

$$\int_0^t K(t-s) H_s dW_s = \sum_{i=1}^m w_i \int_0^t e^{-\lambda_i(t-s)} H_s dW_s,$$

et chaque terme peut être « markovianisé » avec une variable d'état de type OU. Cette technique est au coeur des approximations rapides des modèles rough : on approxime un noyau puissance par un mélange d'exponentielles (via une discrétisation de transformées de Laplace).

1.14 Noyaux fractionnaires et rough volatility

1.14.1 Le noyau fractionnaire (Riemann–Liouville)

Un noyau canonique en rough volatility est

$$K_H(t) := \frac{t^{H-\frac{1}{2}}}{\Gamma(H+\frac{1}{2})}, \quad H \in (0, 1/2). \quad (1.9)$$

Il est **singulier en 0** (car $H - \frac{1}{2} < 0$), ce qui rend la dynamique plus « rugueuse ».

1.14.2 Processus de Volterra rough : régularité

Considérons

$$X_t = \int_0^t K_H(t-s) dW_s.$$

Proposition 1.4 (Régularité Hölder). *Pour tout $\gamma \in (0, H)$, il existe une version de X dont les trajectoires sont p.s. γ -Hölder sur tout compact de $[0, T]$. De plus, pour tout $\gamma > H$, les trajectoires ne sont pas γ -Hölder en 0.*

Démonstration. **1) Incréments et isométrie d'Itô.** Soient $0 \leq s < t \leq T$ et $\Delta := t - s$. On écrit

$$X_t - X_s = \int_0^s (K_H(t-u) - K_H(s-u)) dW_u + \int_s^t K_H(t-u) dW_u.$$

Par isométrie d'Itô,

$$\mathbb{E}[(X_t - X_s)^2] = \int_0^s (K_H(\Delta + v) - K_H(v))^2 dv + \int_0^\Delta K_H(v)^2 dv,$$

où l'on a posé $v := s - u$ dans le premier terme et $v := t - u$ dans le second.

2) Majorant en Δ^{2H} . On utilise $K_H(v) = \frac{v^{H-\frac{1}{2}}}{\Gamma(H+\frac{1}{2})}$. Pour le second terme,

$$\int_0^\Delta K_H(v)^2 dv = \frac{1}{\Gamma(H+\frac{1}{2})^2} \int_0^\Delta v^{2H-1} dv = \frac{\Delta^{2H}}{2H \Gamma(H+\frac{1}{2})^2}.$$

Pour le premier terme, avec $\alpha := H - \frac{1}{2} \in (-\frac{1}{2}, 0)$ et le changement d'échelle $v = \Delta x$,

$$\int_0^s ((\Delta + v)^\alpha - v^\alpha)^2 dv = \Delta^{2\alpha+1} \int_0^{s/\Delta} ((1+x)^\alpha - x^\alpha)^2 dx$$

$$\leq \Delta^{2H} \int_0^{+\infty} ((1+x)^\alpha - x^\alpha)^2 dx.$$

L'intégrale sur $[0, +\infty)$ est finie : près de 0, le terme dominant est $x^{2\alpha}$ (intégrable car $2\alpha > -1$), et à l'infini on a $(1+x)^\alpha - x^\alpha = \alpha x^{\alpha-1} + O(x^{\alpha-2})$, donc le carré est en $O(x^{2\alpha-2})$ (intégrable car $2\alpha - 2 < -1$). On obtient donc une constante $C_H < \infty$ telle que

$$\mathbb{E}[(X_t - X_s)^2] \leq C_H |t - s|^{2H}.$$

3) Moments d'ordre p et critère de Kolmogorov. Les incréments sont gaussiens centrés, donc pour tout $p \geq 2$,

$$\mathbb{E}[|X_t - X_s|^p] = c_p \mathbb{E}[(X_t - X_s)^2]^{p/2} \leq c_p C_H^{p/2} |t - s|^{pH}.$$

Choisissons p tel que $pH > 1$. Alors $\mathbb{E}[|X_t - X_s|^p] \leq C|t - s|^{1+(pH-1)}$ et le critère de Kolmogorov donne une version dont les trajectoires sont Hölder d'ordre strictement inférieur à $H - \frac{1}{p}$. Comme p peut être pris arbitrairement grand, cela donne toutes les régularités $\gamma < H$.

4) Pas Hölder pour un exposant $\gamma > H$ (au point 0). Fixons $\gamma > H$. Pour $n \geq 1$, posons $t_n := 2^{-n}$. Comme $X_0 = 0$, on a $X_{t_n} \sim \mathcal{N}(0, \sigma_H^2 t_n^{2H})$ avec $\sigma_H^2 = \frac{1}{2H \Gamma(H + \frac{1}{2})^2}$. Pour tout $m \in \mathbb{N}^*$,

$$\mathbb{P}(|X_{t_n}| \leq m t_n^\gamma) = \mathbb{P}\left(|Z| \leq \frac{m}{\sigma_H} t_n^{\gamma-H}\right) \leq \sqrt{\frac{2}{\pi}} \frac{m}{\sigma_H} t_n^{\gamma-H},$$

où $Z \sim \mathcal{N}(0, 1)$ et on a utilisé $\mathbb{P}(|Z| \leq x) \leq \sqrt{\frac{2}{\pi}} x$ pour $x \geq 0$. La série $\sum_n t_n^{\gamma-H} = \sum_n 2^{-n(\gamma-H)}$ converge, donc par Borel–Cantelli, pour tout m , l'événement $\{|X_{t_n}| \leq m t_n^\gamma\}$ ne se produit qu'un nombre fini de fois. En intersectant sur $m \in \mathbb{N}^*$, on obtient p.s. $\limsup_{n \rightarrow \infty} \frac{|X_{t_n}|}{t_n^\gamma} = +\infty$. Donc X n'est pas γ -Hölder en 0. $\square$

Cela capture l'observation empirique : la volatilité réalisée semble avoir $H \approx 0.1$.

1.14.3 Lien avec le brownien fractionnaire (intuition)

Le brownien fractionnaire B^H n'est pas une semimartingale quand $H \neq 1/2$, et ses incréments sont corrélés. Il possède néanmoins des représentations de type Volterra :

$$B_t^H = \int_0^t \tilde{K}_H(t-s) dW_s,$$

pour un noyau $\tilde{K}_H$ approprié. Dans les modèles rough en finance, on utilise des processus de Volterra construits sur un brownien standard : on reste dans le cadre (adapté) du calcul d'Itô pour le *prix*, tout en produisant une volatilité plus irrégulière.

Remarque 1.10. Point conceptuel : dans un modèle rough, le *prix* reste souvent une diffusion d'Itô conditionnellement à la variance, mais la *variance* elle-même n'est plus une diffusion markovienne.

1.15 Volterra SDE et volatilité stochastique : ouverture vers Heston

1.15.1 Cadre générique : prix avec variance stochastique

Un schéma standard (sous une mesure risque-neutre $\mathbb{Q}$) est

$$dS_t = rS_t dt + \sqrt{V_t} S_t dW_t, \tag{1.10}$$

où V_t est un processus de variance (positif) et W un brownien sous $\mathbb{Q}$. La question centrale est : *comment modéliser V ?*

1.15.2 Le modèle de Heston : volatilité de type CIR

Le modèle de Heston (1993) postule

$$dS_t = rS_t dt + \sqrt{V_t} S_t dW_t, \tag{1.11}$$

$$dV_t = \kappa(\theta - V_t) dt + \xi \sqrt{V_t} dB_t, \tag{1.12}$$

$$\langle W, B \rangle_t = \rho t, \tag{1.13}$$

avec paramètres $\kappa, \theta, \xi > 0$ et corrélation $\rho \in [-1, 1]$.

Remarque 1.11. Le processus (1.12) est une diffusion de type **CIR** (Cox–Ingersoll–Ross). Il est markovien, et (sous des conditions) reste positif. La corrélation ρ produit un effet de *leverage* (corrélation prix/vol) et explique l’asymétrie du smile.

1.15.3 Écriture intégrale de Heston (pour préparer la version Volterra)

L’équation (1.12) équivaut à

$$V_t = V_0 + \int_0^t \kappa(\theta - V_s) ds + \int_0^t \xi \sqrt{V_s} dB_s. \quad (1.14)$$

Comparer (1.14) avec (1.4) : c’est *exactement* une Volterra SDE avec noyau constant $K \equiv 1$.

1.15.4 Rough/Volterra Heston : remplacer $K \equiv 1$ par un noyau à mémoire

Une extension naturelle consiste à remplacer (1.14) par une équation à mémoire :

$$V_t = V_0 + \int_0^t K(t-s) \kappa(\theta - V_s) ds + \int_0^t K(t-s) \xi \sqrt{V_s} dB_s, \quad (1.15)$$

avec K typiquement fractionnaire (1.9). On parle alors de **(rough) Volterra Heston**.

- Si $K \equiv 1$, on retrouve Heston classique.
- Si K est singulier (fractionnaire), V devient **non-markovien** et **rough**.

1.15.5 Que garde-t-on de Heston ? que perd-on ?

- On garde : un prix d’Itô conditionnellement à V (l’équation (1.10) reste une SDE classique), une interprétation financière claire (variance aléatoire, corrélée au prix).
- On perd : la markovianité de (S, V) , donc les PDE simples ; on remplace souvent par des équations intégrales (par ex. équations de Riccati fractionnaires pour les fonctions caractéristiques).
- On gagne : une capacité à reproduire la **rugosité** empirique et des smiles/termes plus réalistes sur de courtes maturités.

1.15.6 Procédé de volatilité stochastique : intuition financière

Dans Heston, la variance est mean-reverting : elle revient vers θ à vitesse κ , avec une volatilité de variance $\xi\sqrt{V_t}$. Dans la version Volterra (1.15), la mean-reversion et les chocs ne s’appliquent pas instantanément : ils sont *étalés* dans le temps via K . Le noyau code donc un mécanisme de **rémanence** : les chocs passés continuent d’affecter la variance future.

1.16 Zoom sur Heston : propriétés du processus CIR et éléments de pricing

1.16.1 Interprétation des paramètres

Dans (1.12), chaque paramètre a une lecture quantitative :

- κ : vitesse de retour à la moyenne ; plus κ est grand, plus V_t revient vite vers θ .
- θ : niveau de variance de long terme (moyenne stationnaire lorsque le régime stationnaire existe).
- ξ : *vol-of-vol* ; il contrôle la variabilité de V et donc l’intensité des smiles.
- ρ : corrélation prix/variance ; typiquement négative en actions (effet de leverage), elle crée une asymétrie du smile.

1.16.2 Positivité et condition de Feller (CIR)

Le processus CIR (1.12) reste positif (au sens $V_t \geq 0$ p.s.). Une condition classique (suffisante) pour que la frontière 0 soit inatteignable est la condition de Feller :

$$2\kappa\theta \geq \xi^2.$$

Si la condition échoue, V peut toucher 0 mais reste *non négatif*.

Remarque 1.12. En pratique de calibration, la condition de Feller n’est pas toujours imposée : on peut calibrer des paramètres qui la violent tout en gardant un modèle utilisable (mais certaines quantités peuvent devenir plus délicates, notamment pour des schémas de simulation).

1.16.3 Moments simples et interprétation de la mean-reversion

On a déjà vu que $\mathbb{E}[V_t] = \theta + (V_0 - \theta)e^{-\kappa t}$. Ce résultat se lit comme suit :

- θ est le niveau vers lequel la variance est tirée ;
- l'écart $V_t - \theta$ décroît en moyenne à vitesse κ .

On peut également obtenir une expression fermée de $\mathbb{E}[\int_0^T V_s ds]$:

$$\mathbb{E}\left[\int_0^T V_s ds\right] = \int_0^T \mathbb{E}[V_s] ds = \theta T + (V_0 - \theta) \frac{1 - e^{-\kappa T}}{\kappa}.$$

Cette quantité est cruciale car elle gouverne la variance du log-prix via

$$\log \frac{S_T}{S_0} = \int_0^T \left(r - \frac{1}{2} V_s\right) ds + \int_0^T \sqrt{V_s} dW_s.$$

1.16.4 Distribution de V_t (information utile)

La transition du processus CIR est explicite : conditionnellement à $V_t = v$, la loi de V_T est une *chi-deux non centrée* (après renormalisation). Sans entrer dans les détails, cela signifie que :

- on peut simuler V_T exactement (méthodes exactes) ;
- certains calculs de pricing peuvent exploiter cette structure.

1.16.5 Pourquoi Heston est *affine*

Le couple $(\log S_t, V_t)$ est un processus *affine* : l'exponentielle de formes linéaires en $(\log S, V)$ a une espérance qui reste de forme exponentielle-affine. Concrètement, pour $u \in \mathbb{R}$,

$$\phi(u; t, T) := \mathbb{E}^{\mathbb{Q}}[\exp(iu \log S_T) \mid \mathcal{F}_t]$$

peut s'écrire sous la forme

$$\phi(u; t, T) = \exp(A(\tau; u) + B(\tau; u) V_t + iu \log S_t), \quad \tau := T - t,$$

où (A, B) résout un système de type **Riccati**.

1.16.6 Calcul Riccati (fonction caractéristique) : dérivation détaillée

On dérive explicitement l'équation de Riccati associée à Heston à partir de la PDE de Feynman–Kac. L'intérêt est double : (i) comprendre *pourquoi* une Riccati apparaît, (ii) voir exactement où se cache l'affinité.

1) Objet à calculer. On travaille avec $X_t = \ln S_t$ et on considère la transformée conditionnelle

$$p(t, x, v; u) := \mathbb{E}^{\mathbb{Q}}[e^{iu X_T} \mid X_t = x, V_t = v],$$

de sorte que $\phi(u; t, T) = p(t, \ln S_t, V_t; u)$. La condition terminale est $p(T, x, v; u) = e^{iux}$.

2) Générateur sous Heston. Sous $\mathbb{Q}$,

$$dX_t = \left(r - \frac{1}{2} V_t\right) dt + \sqrt{V_t} dW_t^{(1)}, \quad dV_t = \kappa(\theta - V_t) dt + \xi \sqrt{V_t} dW_t^{(2)}, \quad \text{Corr}(dW^{(1)}, dW^{(2)}) = \rho.$$

Le générateur $\mathcal{L}$ du couple (X, V) agit sur une fonction lisse $f(t, x, v)$ par

$$(\mathcal{L}f)(t, x, v) = \left(r - \frac{1}{2} v\right) \partial_x f + \kappa(\theta - v) \partial_v f + \frac{1}{2} v \partial_{xx} f + \rho \xi v \partial_{xv} f + \frac{1}{2} \xi^2 v \partial_{vv} f.$$

3) PDE de Feynman–Kac. La fonction p satisfait la PDE rétrograde

$$\partial_t p + \mathcal{L}p = 0, \quad p(T, x, v; u) = e^{iux}.$$

4) Ansatz exponentiel-affine. On pose $\tau := T - t$ et on cherche une solution de la forme

$$p(t, x, v; u) = \exp(A(\tau; u) + B(\tau; u) v + iux), \quad A(0; u) = 0, \quad B(0; u) = 0.$$

On calcule les dérivées (en factorisant p) :

$$\partial_x p = iu p, \quad \partial_{xx} p = -(u^2)p, \quad \partial_v p = Bp, \quad \partial_{vv} p = B^2 p, \quad \partial_{xv} p = iu Bp,$$

et $\partial_t p = -(A' + B'v)p$. En injectant dans la PDE et en divisant par p , on obtient une identité affine en v . L'annulation séparée des termes constants et des termes en v donne :

$$B'(\tau; u) = -\frac{1}{2}(u^2 + iu) + (\rho\xi iu - \kappa) B(\tau; u) + \frac{1}{2}\xi^2 B(\tau; u)^2, \quad B(0; u) = 0, \quad (1.16)$$

$$A'(\tau; u) = iur + \kappa\theta B(\tau; u), \quad A(0; u) = 0. \quad (1.17)$$

La première équation est une Riccati (quadratique en B) ; la seconde s'obtient ensuite par quadrature. Une fois A et B connus, on a la forme exponentielle-affine $\phi(u; t, T) = \exp(A(\tau; u) + B(\tau; u)V_t + iuX_t)$.

Remarque 1.13. Message pour la suite : dans rough Heston, l'ODE Riccati (1.16) est remplacée par une **Riccati-Volterra** (ou Riccati fractionnaire). On perd la Markovianité, mais on conserve une structure affine au sens Volterra.

1.17 Rough Heston : Riccati–Volterra, affinité et approximation multi-facteurs

1.17.1 Le noyau rough et le paramètre α

On rappelle que pour $H \in (0, 1/2)$ on pose

$$\alpha := H + \frac{1}{2} \in (1/2, 1), \quad K(t) = \frac{t^{\alpha-1}}{\Gamma(\alpha)}.$$

La convolution par K est alors l'intégrale fractionnaire I^α . Le cas Heston classique correspond à $\alpha = 1$ (donc $K \equiv 1$), c'est-à-dire $H = 1/2$.

1.17.2 Affines Volterra : idée qualitative

Dans rough Heston, le couple $(\log S_t, V_t)$ n'est plus markovien, mais il reste *affine* au sens Volterra : les transformées de Laplace/Fourier conditionnelles gardent une forme exponentielle-affine, où le coefficient devant V_t est solution d'une équation intégrale (au lieu d'une ODE).

1.17.3 Riccati–Volterra (forme intégrale)

Sans détailler toutes les étapes (voir El Euch–Rosenbaum), on obtient une équation du type :

$$\psi(t) = \int_0^t K(t-s) F(u, \psi(s)) ds, \quad (1.18)$$

où $F(u, \cdot)$ est une fonction quadratique (analogue au membre de droite de (1.16)) :

$$F(u, z) = \frac{1}{2}(iu + u^2) + (\rho\xi iu - \kappa)z + \frac{1}{2}\xi^2 z^2.$$

La fonction caractéristique du log-prix s'exprime ensuite à partir de ψ via des intégrales (structure affine).

1.17.4 Lecture : remplacement de la dérivée par une intégrale fractionnaire

Si $K(t) = t^{\alpha-1}/\Gamma(\alpha)$, alors (1.18) s'écrit

$$\psi = I^\alpha (F(u, \psi)),$$

et donc, formellement, $D^\alpha \psi = F(u, \psi)$ où D^α est une dérivée fractionnaire. Quand $\alpha = 1$, on récupère $D^1 \psi = \psi' = F(u, \psi)$: c'est exactement le Riccati d'Heston. Cela clarifie le slogan : **rough Heston = Heston avec une dérivée fractionnaire**.

1.17.5 Approximation multi-facteurs (pont vers la pratique)

Pour calculer/pricer rapidement, on approxime souvent le noyau rough par une somme d'exponentielles :

$$K(t) \approx \sum_{i=1}^m w_i e^{-\lambda_i t}.$$

Alors (1.15) devient approximativement un modèle multi-facteurs markovien (dimension m), proche d'un « Heston enrichi ». En pratique :

- plus m est grand, plus l'approximation de la mémoire est fidèle ;
- le coût de pricing/simulation devient contrôlable en $\mathcal{O}(mN)$.

1.17.6 Calibration : rôle de H (intuition)

Le paramètre H contrôle la rugosité à très court terme. Heuristique : plus H est petit, plus la variance est irrégulière à petite échelle, ce qui a tendance à renforcer certains effets de smile à courte maturité. Cela explique pourquoi rough Heston est particulièrement pertinent pour reproduire des smiles courts (options proches de l'échéance) là où Heston classique peut être trop rigide.

1.18 Fiche de synthèse : définitions, cas particuliers, messages clés

1.18.1 Définitions à savoir énoncer proprement

- **SVIE (général)**. $X_t = X_0 + \int_0^t b(t, s, X_s)ds + \int_0^t \sigma(t, s, X_s)dW_s$.
- **Volterra SDE (convolution)**.

$$X_t = X_0 + \int_0^t K(t-s)b(X_s)ds + \int_0^t K(t-s)\sigma(X_s)dW_s.$$

- **Processus de Volterra gaussien**. $X_t = \int_0^t K(t-s)dW_s$ (centré gaussien, covariance explicite).
- **Volterra Heston (variance)**. Equation (1.15), avec prix donné par (1.10).

1.18.2 Cas particuliers importants (à reconnaître)

Noyau K	Effet	Commentaire
$K(t) \equiv 1$	Pas de mémoire	SDE d'Itô classique (Markov)
$K(t) = e^{-\lambda t}$	Mémoire courte	Markovianisable (OU)
$K(t) = \sum_i w_i e^{-\lambda_i t}$	Multi-échelles	Markovianisable (multi-facteurs)
$K(t) = t^{H-\frac{1}{2}}/\Gamma(H + \frac{1}{2})$	Roughness	Non-Markov, souvent non semimartingale

1.18.3 Dérivation pas à pas (script minimal)

1. Écrire une dynamique discrète à mémoire : somme pondérée des contributions passées.
2. Identifier $K(t_n - t_k)$ comme poids de mémoire.
3. Passer à la limite : sommes de Riemann $\rightarrow \int K(t-s) \cdot ds$; sommes d'Itô $\rightarrow \int K(t-s) \cdot dW_s$.
4. Vérifier les sanity checks : $K \equiv 1$ redonne l'SDE ; K exponentiel se markovianise ; K puissance rend rough.

1.18.4 Pont Heston $\leftrightarrow$ rough Heston

- Heston classique : noyau $K \equiv 1$ et Riccati ODE.
- Rough Heston : noyau fractionnaire $K(t) = t^{\alpha-1}/\Gamma(\alpha)$ et Riccati-Volterra (fractionnaire).
- Cas-limite : $\alpha = 1 \Leftrightarrow H = 1/2$ redonne Heston.

1.18.5 Pièges classiques

- Écrire $dX_t = \dots$ comme si X était toujours une semimartingale : faux en général pour les noyaux rough.
- Oublier que le modèle peut être non-Markov : pas de PDE simple, on travaille souvent via transformées/équations intégrales.
- Simulation naïve : coût $\mathcal{O}(N^2)$; penser multi-facteurs si besoin.

1.19 Corrigés rapides (sélection)

Les corrigés ci-dessous sont volontairement courts : l'objectif est de donner la *structure* du raisonnement.

Exercice : covariance d'un processus de Volterra

On utilise la proposition de covariance :

$$\text{Cov}(X_t, X_u) = \int_0^{t \wedge u} K(t-s)K(u-s)ds.$$

En particulier $\text{Var}(X_t) = \int_0^t K(t-s)^2 ds = \int_0^t K(s)^2 ds$.

Exercice : covariance d'un OU

On peut écrire $Y_t = e^{-\lambda t} Y_0 + \int_0^t e^{-\lambda(t-s)} dW_s$. Pour $h \geq 0$,

$$\text{Cov}(Y_t, Y_{t+h}) = \mathbb{E}[Y_t Y_{t+h}] = e^{-\lambda h} \mathbb{E}[Y_t^2] = e^{-\lambda h} \text{Var}(Y_t),$$

car l'incrément de bruit sur $(t, t+h]$ est orthogonal à Y_t . Donc la corrélation décroît comme $e^{-\lambda h}$.

Exercice : martingale actualisée

On pose $\tilde{S}_t = e^{-rt} S_t$. Par Itô,

$$d\tilde{S}_t = e^{-rt} dS_t - r e^{-rt} S_t dt = e^{-rt} S_t \sqrt{V_t} dW_t,$$

qui est une intégrale d'Itô, donc une martingale (sous les hypothèses d'intégrabilité).

Exercice : complexité numérique

À chaque pas n , on somme sur $k = 0, \dots, n$, ce qui coûte $\mathcal{O}(n)$. La somme des coûts est $\sum_{n=1}^N \mathcal{O}(n) = \mathcal{O}(N^2)$. Si $K(t) = \sum_{i=1}^m w_i e^{-\lambda_i t}$, on introduit m facteurs de type OU (markovianisation) et on passe à $\mathcal{O}(mN)$.

1.20 Complément A : convolution, transformées de Laplace (utile pour les noyaux)

1.20.1 Convolution sur $[0, T]$

Pour deux fonctions f, g définies sur $[0, T]$, la convolution causale est

$$(f * g)(t) = \int_0^t f(t-s)g(s) ds.$$

Elle est associative et commutative (dans les cadres où les intégrales existent).

1.20.2 Transformée de Laplace et mélange d'exponentielles

Sur $[0, \infty)$, la transformée de Laplace de K est

$$\hat{K}(p) = \int_0^\infty e^{-pt} K(t) dt.$$

Beaucoup de noyaux (notamment les noyaux puissance) peuvent être représentés comme des mélanges continus d'exponentielles, ce qui motive les approximations par *somme d'exponentielles* et donc les modèles multi-facteurs markoviens.

1.21 Complément B : Fubini stochastique et dérivations utiles

1.21.1 Stochastic Fubini (idée)

Dans les calculs avec mémoire, on rencontre souvent des intégrales imbriquées du type

$$\int_0^t \left(\int_0^s K(s-u) H_u dW_u \right) ds.$$

Sous des conditions d'intégrabilité (typiquement $K \in L^2$ et H carré-intégrable), on peut permuter les intégrales (théorème de Fubini stochastique) et obtenir

$$\int_0^t \left(\int_0^s K(s-u) H_u dW_u \right) ds = \int_0^t \left(\int_u^t K(s-u) ds \right) H_u dW_u.$$

Cette formule est très utile pour :

- prouver la continuité de certaines convolutions stochastiques ;
- dériver des équations intégrales pour des moments ;
- simplifier des expressions de type « convolution de convolution ».

1.21.2 Dérivation de la convolution exponentielle (détail)

On justifie ici la formule

$$\frac{d}{dt} \int_0^t e^{-\lambda(t-s)} f(s) ds = -\lambda \int_0^t e^{-\lambda(t-s)} f(s) ds + f(t).$$

On écrit, pour $h > 0$,

$$\int_0^{t+h} e^{-\lambda(t+h-s)} f(s) ds = e^{-\lambda h} \int_0^t e^{-\lambda(t-s)} f(s) ds + \int_t^{t+h} e^{-\lambda(t+h-s)} f(s) ds,$$

on soustrait le terme à t , puis on divise par h et on laisse $h \rightarrow 0$ (en supposant f assez régulier). Cette manipulation est au coeur des **markovianisations**.

1.22 Mode microscope : noyau de convolution, covariance et discrétisation

1.22.1 Processus de Volterra gaussien : forme intégrale

Un prototype est

$$X_t = \int_0^t K(t-s) dW_s,$$

où K est un noyau (souvent singulier près de 0 dans les modèles rough).

1.22.2 Covariance (calcul pas à pas)

Pour $s \leq t$, par isométrie d'Itô,

$$\mathbb{E}[X_t X_s] = \mathbb{E} \left[\int_0^t K(t-u) dW_u \int_0^s K(s-v) dW_v \right] = \int_0^s K(t-u) K(s-u) du.$$

Ainsi, X est gaussien centré avec covariance explicite en termes de K .

Sanity check. Si $K \equiv 1$, alors $X_t = W_t$ et on retrouve $\mathbb{E}[W_t W_s] = s$ (pour $s \leq t$).

1.22.3 Discrétisation (convolution explicite)

Sur une grille $t_k = k\Delta t$, une approximation naturelle est

$$X_{t_k} \approx \sum_{j=0}^{k-1} K(t_k - t_j) \Delta W_j, \quad \Delta W_j := W_{t_{j+1}} - W_{t_j}.$$

Le coût naïf est $O(N^2)$ (convolution), ce qui motive des accélérations (multi-facteurs, FFT de convolution) quand N est grand.

Intuition de marché. La mémoire est le « prix » de la rugosité : pour reproduire le smile court terme, on accepte des schémas plus lourds. Les accélérations (Markovian lift) sont alors cruciales.

1.23 Pièges classiques / erreurs fréquentes

- Oublier la singularité potentielle de K près de 0 : pas de temps trop gros $\Rightarrow$ erreur.

- Coût $O(N^2)$: explosif si on simule long/court terme avec N grand sans accélération.
- Confondre « noyau » (mémoire) et « bruit » : ils interagissent via l'intégrale stochastique.

1.24 Checklist — savoir refaire sans regarder

- Calculer covariance par isométrie d'Itô.
- Écrire une discrétisation convolution et estimer son coût.
- Expliquer pourquoi le processus est non-Markov.
- Donner des sanity-checks sur K (intégrabilité, singularité) et sur la simulation.

Chapitre 2

Fractional Brownian Motion

Idée centrale. Le fBm généralise le Brownien via le Hurst $H \in (0, 1)$: autosimilarité, accroissements stationnaires, et rugosité contrôlée. Pour $H \neq \frac{1}{2}$, ce n'est pas une semi-martingale : l'Itô classique casse.

Cadre mathématique.

- **Covariance.** $\mathbb{E}[B_t^H B_s^H] = \frac{1}{2}(t^{2H} + s^{2H} - |t - s|^{2H})$.
- **Scaling.** $B_{ct}^H \stackrel{d}{=} c^H B_t^H$; régularité Hölder $\approx H$.
- **Cas $H = \frac{1}{2}$.** Retour Brownien ; sinon, besoin d'intégrales adaptées (Young/rough).
- **Volterra.** Représentations $B_t^H = \int_0^t K_H(t-s) dW_s$ (pont vers rough).

Intuition marché / interprétation. En finance, l'intérêt est surtout $H < \frac{1}{2}$ (trajectoires « plus rugueuses » que Brownien) : cela améliore la reproduction du smile court terme, mais complique le calcul stochastique et la calibration.

Implémentation.

- Simulation : Davies–Harte / Cholesky (covariance) ou représentation Volterra (convolution) ; attention coût $O(N^2)$ vs approximations.
- Estimation : diagnostics sur scaling (log-variogram) et biais (microstructure, non-stationnarité).

Tests / sanity checks.

- Scaling : $\text{Var}(B_t^H) \propto t^{2H}$ (check sur simulation).
- Covariance des incréments : structure cohérente (anti-persistence si $H < 1/2$).
- Cas limite : $H \rightarrow 1/2$ doit rapprocher le Brownien (prices/simulations).

Pont vers pratique quant. Pont quant : driver rough (rBergomi/rHeston), génération de trajectoires pour MC, et compréhension des contraintes d'intégration (Itô vs rough paths) en modèles de volatilité.

2.1 Avant-propos : mouvement brownien fractionnaire (fBm) et rugosité

Le mouvement brownien standard ($H = \frac{1}{2}$) est le bruit compatible avec le calcul d'Itô (semi-martingale). Le brownien fractionnaire (fBm) généralise le brownien en introduisant un paramètre de Hurst $H \in (0, 1)$, qui contrôle la régularité et la dépendance des accroissements. En finance, on s'y intéresse surtout pour sa **rugosité** quand $H < \frac{1}{2}$, et pour son lien naturel avec les représentations de Volterra.

2.1.1 Objectifs pédagogiques

- Définir le fBm par sa covariance, et déduire autosimilarité et accroissements stationnaires.
- Interpréter H : roughness ($H < \frac{1}{2}$) vs persistance ($H > \frac{1}{2}$) et ne pas confondre « long memory » et « rugosité ».
- Comprendre pourquoi le fBm n'est pas une semi-martingale pour $H \neq \frac{1}{2}$: pas d'Itô classique.
- Introduire les représentations Volterra (Mandelbrot–Van Ness, Riemann–Liouville) qui ramènent le rough à un brownien.

2.1.2 Pré-requis

- Brownien standard, covariance, et idée de variation quadratique.
- Convolutions et noyaux (chapitre chapitre 1).

2.1.3 Plan du chapitre

1. Définition et propriétés fondamentales (covariance, autosimilarité).
2. Régularité et variation quadratique : ce qui casse l'Itô classique.
3. Représentations : fBm comme intégrale Volterra d'un brownien.
4. Panorama des intégrales (Young/rough paths) et choix finance.

Sanity check. Deux repères : (i) $H = \frac{1}{2}$ redonne le brownien et l'Itô classique ; (ii) quand $H < \frac{1}{2}$, les trajectoires sont plus rugueuses que browniennes, ce qui motive les modèles rough volatility.

Résumé

Ces notes développent, *from ground up*, le mouvement brownien fractionnaire (fBm) et montrent comment il conduit naturellement à une dynamique de volatilité *rugueuse* (rough volatility). L'objectif principal est pédagogique : être capable d'expliquer et de re-deriver, pas à pas, la construction du modèle *rough Heston* (rHeston) à partir de la représentation Volterra du fBm, puis d'une généralisation "fractionnaire" de la variance de type CIR.

2.2 Objectifs, prerequis, et fil conducteur

2.2.1 Objectifs pédagogiques

À la fin de ce cours, vous devez pouvoir :

1. définir proprement le mouvement brownien fractionnaire (fBm) et interpréter le paramètre de Hurst H ;
2. expliquer pourquoi le fBm n'est pas un mouvement brownien (ni une semimartingale) lorsque $H \neq \frac{1}{2}$;
3. comprendre la représentation *Volterra* du fBm et le rôle d'un noyau singulier de type $(t-s)^{H-\frac{1}{2}}$;
4. dériver, pas à pas, l'équation de variance du modèle *rough Heston* (rHeston) comme une généralisation fractionnaire de la variance CIR du modèle de Heston ;
5. faire le lien entre rHeston et Heston classique (cas limite $H \uparrow \frac{1}{2}$) et commenter l'intérêt financier (skew court terme, calibration).

2.2.2 Prerequis minimaux

On suppose connus (ou acceptes comme « boîte noire ») :

- l'espace probabilisé filtré, les martingales de base ;
- le mouvement brownien standard, l'intégrale d'Itô, la formule d'Itô ;
- les EDS markoviennes simples (diffusions) et l'idée d'une mesure neutre au risque.

On utilisera quelques outils d'analyse (développements limites, intégrales de convolution) et un peu de théorie des processus gaussiens (covariance).

2.2.3 Plan de construction (le « from ground up »)

Le cours suit un chemin volontairement linéaire :

1. on rappelle ce qui rend le calcul d'Itô possible pour le brownien ;
2. on définit le fBm, on étudie ses propriétés de base et on identifie ce qui « casse » Itô ;
3. on introduit une représentation du fBm à partir d'un brownien (Volterra) ;
4. on injecte cette structure Volterra dans une dynamique de variance de type Heston pour obtenir rHeston.

2.2.4 Notation

On travaille sur $(\Omega, \mathcal{F}, (\mathcal{F}_t)_{t \geq 0}, \mathbb{P})$. En finance, on se placera sous une mesure neutre au risque $\mathbb{Q}$ et un taux court constant r . On note $\langle M, N \rangle$ le crochet quadratique (covariation) de deux martingales continues.

2.3 Rappel : pourquoi Ito marche pour le brownien (et ce que l'on perd ensuite)

2.3.1 Variation quadratique : le cœur du calcul stochastique

Une des façons les plus pédagogiques de comprendre Itô est de repartir de l'analogie avec Taylor. Pour une fonction $f \in C^2$ et un processus X , on écrit heuristiquement :

$$f(X_{t+\Delta t}) - f(X_t) \approx f'(X_t)\Delta X + \frac{1}{2}f''(X_t)(\Delta X)^2.$$

Pour une diffusion brownienne, ΔX est typiquement de taille $\sqrt{\Delta t}$, donc $(\Delta X)^2$ est de taille Δt et ne disparaît pas à la limite : c'est le terme de variation quadratique.

Remarque 2.1 (Message cle). Le calcul d'Ito est rendu nécessaire par le fait que le brownien a une variation quadratique non nulle. Changer la régularité du bruit (et donc la variation quadratique) change complètement le calcul.

2.3.2 Rappel express : Heston comme diffusion markovienne

Sous $\mathbb{Q}$, le modèle de Heston classique est :

$$dS_t = rS_t dt + S_t \sqrt{V_t} dW_t^S, \quad (2.1)$$

$$dV_t = \kappa(\theta - V_t) dt + \xi \sqrt{V_t} dW_t^V, \quad (2.2)$$

$$d\langle W^S, W^V \rangle_t = \rho dt,$$

avec $\kappa, \theta, \xi > 0$ et $\rho \in [-1, 1]$. La variance V est markovienne, de régularité « brownienne » (en gros $< 1/2$ -Holder). Rough Heston consistera à rendre V plus irrégulier (régularité $H < 1/2$), tout en gardant S comme diffusion.

2.4 Mouvement brownien fractionnaire : définition et propriétés fondamentales

2.4.1 Définition par la covariance

Définition 2.1 (Mouvement brownien fractionnaire). Soit $H \in (0, 1)$. Un processus $(B_t^H)_{t \geq 0}$ est un *mouvement brownien fractionnaire* de paramètre de Hurst H si :

- B^H est un processus gaussien centre, à trajectoires continues ;
- pour tous $s, t \geq 0$,

$$\text{Cov}(B_t^H, B_s^H) = \frac{1}{2} (t^{2H} + s^{2H} - |t - s|^{2H}). \quad (2.3)$$

Remarque 2.2 (Cas $H = \frac{1}{2}$). Lorsque $H = \frac{1}{2}$, (2.3) devient $\text{Cov}(B_t^H, B_s^H) = \min(t, s)$, soit la covariance du mouvement brownien standard. Ainsi, le brownien est le cas particulier $H = 1/2$.

2.4.2 Autosimilarité et accroissements stationnaires

Proposition 2.1 (Propriétés structurantes). *Le fBm vérifie :*

1. **Accroissements stationnaires** : la loi de $B_{t+h}^H - B_t^H$ ne dépend que de h .
2. **Autosimilarité** : pour $c > 0$,

$$(B_{ct}^H)_{t \geq 0} \stackrel{d}{=} (c^H B_t^H)_{t \geq 0}.$$

Idee. Comme B^H est gaussien centre, sa loi est déterminée par sa covariance. La covariance de $B_{t+h}^H - B_t^H$ se lit sur (2.3) et ne dépend que de h . De même, remplacer (t, s) par (ct, cs) multiplie la covariance par c^{2H} , d'où l'autosimilarité. $\square$

Théorème 2.1 (Caractérisation (gaussien + increments stationnaires + autosimilarité)). *Soit $(X_t)_{t \geq 0}$ un processus gaussien centre tel que $X_0 = 0$ p.s. On suppose :*

- X a des increments stationnaires ;
- X est autosimilaire d'ordre H : $(X_{ct}) \stackrel{d}{=} (c^H X_t)$.

Alors il existe une constante $\sigma > 0$ telle que, pour tous $s, t \geq 0$,

$$\text{Cov}(X_t, X_s) = \frac{\sigma^2}{2} (t^{2H} + s^{2H} - |t - s|^{2H}).$$

En particulier, $\sigma^{-1}X$ est un fBm de paramètre H .

Démonstration. Par autosimilarité, $\text{Var}(X_t) = \text{Var}(X_1)t^{2H} =: \sigma^2 t^{2H}$. Par increments stationnaires, $\text{Var}(X_t - X_s) = \text{Var}(X_{t-s}) = \sigma^2 |t - s|^{2H}$. Or, pour tout processus centre,

$$\text{Var}(X_t - X_s) = \text{Var}(X_t) + \text{Var}(X_s) - 2 \text{Cov}(X_t, X_s).$$

On injecte les expressions des variances et on isole $\text{Cov}(X_t, X_s)$. $\square$

2.4.3 Interpretation du parametre de Hurst H

Trois lectures complementaires de H :

1. **Echelle des increments.** Par stationnarite des increments,

$$\text{Var}(B_{t+h}^H - B_t^H) = h^{2H} \Rightarrow |B_{t+h}^H - B_t^H| \text{ est typiquement de l'ordre de } h^H.$$

2. **Rugosite.** Plus H est petit, plus les trajectoires sont rugueuses (regularite Holder proche de H).
3. **Memoire.** Pour $H \neq 1/2$, les increments sont correles (donc non independants) : la memoire est « longue » si $H > 1/2$ et « anti-persistante » si $H < 1/2$.

2.4.4 Memoire des increments : calcul explicite

On etudie la covariance du *fractional Gaussian noise* (fGn) $X_k := B_{k+1}^H - B_k^H$. Pour $k \geq 1$, par developpement :

$$\begin{aligned} \gamma_H(k) &:= \text{Cov}(X_k, X_0) \\ &= \mathbb{E}[(B_{k+1}^H - B_k^H)(B_1^H - B_0^H)] \\ &= \frac{1}{2} \left((k+1)^{2H} - 2k^{2H} + (k-1)^{2H} \right). \end{aligned} \quad (2.4)$$

En developpant $(k \pm 1)^{2H}$ a l'ordre 2 quand $k \rightarrow \infty$, on obtient :

$$\gamma_H(k) \sim H(2H-1) k^{2H-2}. \quad (2.5)$$

Donc :

- si $H > 1/2$, alors $\gamma_H(k) > 0$ pour k grand (persistence) ;
- si $H < 1/2$, alors $\gamma_H(k) < 0$ pour k grand (anti-persistence).

Remarque 2.3 (Lien rough volatility). Dans la litterature rough, l'estimation empirique de H se situe souvent autour de 0.05–0.2. Le regime $H < 1/2$ correspond a une volatilité (ou variance) tres irreguliere a tres courte echelle.

2.4.5 Long memory vs « roughness » : ne pas confondre

Le terme « fractionnaire » peut evoker « memoire longue », mais en rough volatility l'accent porte surtout sur la **regularite** (rugosite), pas necessairement sur une memoire longue au sens statistique. Une facon classique de definir la memoire longue pour une suite stationnaire (X_k) est de regarder la sommabilite de sa fonction d'autocovariance :

$$\sum_{k=1}^{\infty} |\text{Cov}(X_k, X_0)|.$$

Pour le fGn $(X_k = B_{k+1}^H - B_k^H)$, l'asymptotique (2.5) donne :

$$|\gamma_H(k)| \approx C k^{2H-2}.$$

Donc :

- si $H > 1/2$, alors $2H-2 \in (-1, 0)$ et la serie diverge : *long memory* ;
- si $H < 1/2$, alors $2H-2 < -1$ et la serie converge : *short memory* (mais trajectoires rough).

Moralite : en rough volatility, on peut avoir une memoire courte (au sens de sommabilite) tout en ayant une trajectoire tres irreguliere.

2.4.6 Ouverture : representation harmonisable (vue spectrale)

Une autre facon de représenter le fBm (plus « frequentielle ») est via une integrale sur les frequences :

$$B_t^H = \int_{\mathbb{R}} \frac{e^{it\xi} - 1}{|\xi|^{H+\frac{1}{2}}} \widetilde{W}(d\xi),$$

ou $\widetilde{W}$ est une mesure gaussienne complexe (construite pour que B_t^H soit reel). Cette representation met en evidence un spectre en loi de puissance. Elle est utile pour comprendre qualitativement la difference entre $H < 1/2$ et $H > 1/2$: le fGn a une densite spectrale (heuristique) de type $|\xi|^{1-2H}$, donc les hautes frequences sont plus presentes quand H est petit, ce qui correspond a une trajectoire plus « rugueuse ».

2.5 Regularite, variation quadratique, et non-semimartingale

2.5.1 Regularite Holder (resultat niveau cours)

Proposition 2.2 (Regularite de trajectoires). *Soit B^H un fBm de parametre $H \in (0, 1)$. Alors, pour tout $\alpha \in (0, H)$, il existe une version de B^H dont les trajectoires sont p.s. α -Holder sur tout compact. Inversement, pour tout $\alpha \geq H$, les trajectoires ne sont pas α -Holder.*

Preuve détaillée. On découpe la preuve en trois parties : existence d'une version α -Hölder pour tout $\alpha < H$, puis non-Hölderité pour (i) $\alpha > H$ et (ii) $\alpha = H$.

1) Moments des incréments (outil). Par définition d'un fBm, $B_t^H - B_s^H$ est gaussien centré de variance $\text{Var}(B_t^H - B_s^H) = |t - s|^{2H}$ (voir (2.3)). Donc, pour tout $p \geq 1$,

$$\mathbb{E}[|B_t^H - B_s^H|^p] = \mathbb{E}[|Z|^p] |t - s|^{pH} =: C_p |t - s|^{pH}, \quad (2.6)$$

où $Z \sim \mathcal{N}(0, 1)$.

2) Existence d'une version α -Hölder pour tout $\alpha < H$. Fixons $\alpha \in (0, H)$. Choisissons p suffisamment grand pour que $pH > 1$ (par exemple $p > \frac{1}{H}$). Alors (2.6) s'écrit $\mathbb{E}[|B_t^H - B_s^H|^p] \leq C_p |t - s|^{1+\beta}$ avec $\beta := pH - 1 > 0$. Le théorème de continuité de Kolmogorov (rappel : si $\mathbb{E}[|X_t - X_s|^p] \leq C |t - s|^{1+\beta}$ alors il existe une version Hölder d'exposant strictement inférieur à β/p) donne donc une version de B^H dont les trajectoires sont p.s. γ -Hölder pour tout

$$\gamma < \frac{\beta}{p} = H - \frac{1}{p}.$$

Comme on peut prendre p arbitrairement grand, on obtient une version p.s. α -Hölder pour tout $\alpha < H$.

3) Non- α -Hölderité pour tout $\alpha > H$ (argument par autosimilarité). On raisonne par l'absurde. Supposons qu'il existe $\alpha > H$ tel que, p.s., la trajectoire soit α -Hölder sur $[0, 1]$. Alors il existe une variable aléatoire finie $C_\alpha(\omega)$ telle que, pour tout $t \in [0, 1]$,

$$|B_t^H(\omega) - B_0^H(\omega)| \leq C_\alpha(\omega) t^\alpha.$$

Comme $B_0^H = 0$, cela implique que, pour tout $\delta \in (0, 1]$,

$$M_\delta := \sup_{0 \leq t \leq \delta} |B_t^H| \leq C_\alpha \delta^\alpha. \quad (2.7)$$

Fixons maintenant un $K > 0$ tel que $\mathbb{P}(C_\alpha \leq K) > 0$ (un tel K existe car $C_\alpha < \infty$ p.s.). Sur l'événement $\{C_\alpha \leq K\}$, (2.7) donne $M_\delta \leq K \delta^\alpha$, donc

$$\mathbb{P}(M_\delta \leq K \delta^\alpha) \geq \mathbb{P}(C_\alpha \leq K) > 0 \quad \text{pour tout } \delta \in (0, 1]. \quad (2.8)$$

Or le fBm est H -autosimilaire : $(B_{\delta t}^H)_{t \in [0, 1]} \stackrel{d}{=} (\delta^H B_t^H)_{t \in [0, 1]}$. En prenant le sup sur $t \in [0, 1]$ et en utilisant la continuité des trajectoires, on obtient l'identité en loi

$$M_\delta \stackrel{d}{=} \delta^H M_1, \quad M_1 := \sup_{0 \leq t \leq 1} |B_t^H|.$$

Donc

$$\mathbb{P}(M_\delta \leq K \delta^\alpha) = \mathbb{P}(\delta^H M_1 \leq K \delta^\alpha) = \mathbb{P}(M_1 \leq K \delta^{\alpha-H}).$$

Comme $\alpha - H > 0$, on a $K \delta^{\alpha-H} \downarrow 0$ quand $\delta \downarrow 0$. Or $M_1 > 0$ avec probabilité 1 (le processus n'est pas identiquement nul), donc $\mathbb{P}(M_1 \leq \varepsilon) \rightarrow 0$ quand $\varepsilon \downarrow 0$. Ainsi $\mathbb{P}(M_\delta \leq K \delta^\alpha) \rightarrow 0$ quand $\delta \downarrow 0$, ce qui contredit (2.8). Donc les trajectoires ne peuvent pas être α -Hölder pour $\alpha > H$.

4) Non- H -Hölderité (argument discret par une suite gaussienne stationnaire). Il reste à exclure l'exposant critique $\alpha = H$. Considérons les temps dyadiques $t_n := 2^{-n}$ et la suite

$$Y_n := \frac{B_{t_n}^H}{t_n^H} = \frac{B_{2^{-n}}^H}{2^{-nH}}. \quad (2.9)$$

Par autosimilarité, $B_{2^{-n}}^H \sim \mathcal{N}(0, 2^{-2nH})$, donc $Y_n \sim \mathcal{N}(0, 1)$ pour tout n . La suite (Y_n) est gaussienne centrée et, en fait, stationnaire en n (les covariances ne dépendent que de $|n - m|$). On calcule pour $k \geq 1$ (avec $t_{n+k} = 2^{-n-k}$) :

$$\begin{aligned} \text{Cov}(Y_n, Y_{n+k}) &= \frac{\text{Cov}(B_{2^{-n}}^H, B_{2^{-(n+k)}}^H)}{2^{-nH} 2^{-(n+k)H}} \\ &= \frac{1}{2} 2^{Hk} \left(1 + 2^{-2Hk} - (1 - 2^{-k})^{2H} \right) =: \rho(k). \end{aligned}$$

Un développement de Taylor donne $(1 - 2^{-k})^{2H} = 1 - 2H2^{-k} + O(2^{-2k})$, donc

$$\rho(k) = H 2^{(H-1)k} + O(2^{-Hk}) \xrightarrow[k \rightarrow \infty]{} 0, \quad \text{et} \quad \sum_{k \geq 1} |\rho(k)| < \infty \quad (\text{décroissance exponentielle}).$$

Fixons maintenant $K > 0$ et posons $A_n := \{|Y_n| > K\}$. On a $\mathbb{P}(A_n) = \mathbb{P}(|\mathcal{N}(0, 1)| > K) =: p_K > 0$ (constant). On veut montrer que A_n se produit une infinité de fois p.s., ce qui impliquera $\sup_n |Y_n| = +\infty$ p.s.

Posons $N_N := \sum_{n=1}^N \mathbf{1}_{A_n}$. Alors $\mathbb{E}[N_N] = N p_K$. Pour borner la variance, on utilise que, pour une paire gaussienne (Y_n, Y_m) de corrélation $\rho(|n - m|)$, la covariance de deux indicatrices d'événements de seuil est contrôlée par une constante (dépendant de K) fois $|\rho(|n - m|)|$: il existe $C_K > 0$ tel que

$$|\text{Cov}(\mathbf{1}_{A_n}, \mathbf{1}_{A_m})| \leq C_K |\rho(|n - m|)|. \quad (2.10)$$

(C'est un fait standard pour les lois normales bivariées : la probabilité jointe $\mathbb{P}(|Y_n| > K, |Y_m| > K)$ est une fonction C^1 de ρ , et sa dérivée est dominée par une densité bornée sur $\mathbb{R}^2$ quand K est fixé.) On en déduit

$$\begin{aligned} \text{Var}(N_N) &= \sum_{n=1}^N \text{Var}(\mathbf{1}_{A_n}) + 2 \sum_{1 \leq n < m \leq N} \text{Cov}(\mathbf{1}_{A_n}, \mathbf{1}_{A_m}) \\ &\leq N p_K (1 - p_K) + 2 C_K \sum_{k=1}^{N-1} (N - k) |\rho(k)| \leq C N, \end{aligned}$$

car $\sum_k |\rho(k)| < \infty$. En particulier, pour $N = 2^m$,

$$\mathbb{P}\left(\left|\frac{N_{2^m}}{2^m} - p_K\right| > \frac{p_K}{2}\right) \leq \frac{4 \text{Var}(N_{2^m})}{p_K^2 2^{2m}} \leq \frac{C'}{2^m},$$

et la série $\sum_m C'/2^m$ converge. Par Borel–Cantelli, on a donc p.s. pour m assez grand : $N_{2^m} \geq \frac{p_K}{2} 2^m$. En particulier $N_{2^m} \rightarrow \infty$, donc l'événement A_n se produit une infinité de fois. Comme ceci vaut pour tout $K > 0$, on obtient $\sup_n |Y_n| = +\infty$ p.s.

Enfin, si les trajectoires étaient H -Hölder au voisinage de 0, il existerait $C(\omega) < \infty$ et $\delta > 0$ tels que $|B_t^H| \leq C t^H$ pour $t \in (0, \delta]$, donc en particulier $|Y_n| \leq C$ pour tout n assez grand. Ceci contredit $\sup_n |Y_n| = +\infty$ p.s. Donc les trajectoires ne sont pas H -Hölder. $\square$

2.5.2 Variation quadratique : calcul heuristique et conclusion

Considérez la partition uniforme $t_k = kT/n$. Comme $\text{Var}(B_{t_{k+1}}^H - B_{t_k}^H) = (T/n)^{2H}$, on obtient heuristiquement :

$$\sum_{k=0}^{n-1} (B_{t_{k+1}}^H - B_{t_k}^H)^2 \approx n \left(\frac{T}{n}\right)^{2H} = T^{2H} n^{1-2H}. \quad (2.11)$$

Ainsi :

- si $H > 1/2$, la variation quadratique tend vers 0 ;
- si $H < 1/2$, elle explose ;
- si $H = 1/2$, elle est d'ordre T (cas brownien).

Théorème 2.2 (Non-semimartingale). *Le fBm B^H est une semimartingale si et seulement si $H = 1/2$.*

2.5.3 Une autre lecture : la p -variation (optionnel mais instructif)

Une façon de relier régularité et intégrales est la notion de p -variation. Pour un chemin $x : [0, T] \rightarrow \mathbb{R}$, on définit sa p -variation par

$$\|x\|_{p\text{-var}; [0, T]} := \sup_{\Pi} \left(\sum_k |x_{t_{k+1}} - x_{t_k}|^p \right)^{1/p},$$

ou le supremum porte sur toutes les partitions Π de $[0, T]$. Intuitivement :

- un chemin « tres regulier » a une faible p -variation (pour des p petits) ;
- un chemin « tres irregulier » n'a une p -variation finie qu'a partir de p assez grand.

Pour le brownien, la p -variation est finie pour tout $p > 2$ et infinie pour $p \leq 2$. Pour le fBm de Hurst H , on a (heuristiquement et au niveau theoremes) un seuil en $p = 1/H$. Ainsi, si $H < 1/2$, on a $1/H > 2$: le fBm est « plus irregulier » que le brownien, ce qui explique encore une fois pourquoi l'integration d'Ito (adaptee au seuil 2) n'est pas directement disponible.

Remarque 2.4 (Pourquoi c'est un point de bascule). Dans un modele d'actif, on veut souvent :

- que les integrales stochastiques soient bien definies ;
- que les changements de mesure (Girsanov) restent accessibles ;
- des martingales exponentielles pour le pricing.

Ces outils sont naturellement adaptes aux semimartingales. Le fait que B^H ne soit pas une semimartingale pour $H \neq 1/2$ explique pourquoi les modeles rough ne se contentent pas d'ecrire « $dV_t = \dots + dB_t^H$ » au sens d'Ito.

2.6 Representations du fBm : ramener le rough a un brownien

2.6.1 Pourquoi chercher une representation ?

Si l'on ecrit directement une equation differentielle stochastique avec B^H , on doit choisir une notion d'integrale (Young, rough paths, Skorokhod, etc.). Or, en finance, beaucoup d'outils (martingales, changement de mesure, pricing par Fourier) sont naturellement formulees en termes d'integrales d'Ito par rapport a un brownien. L'idee cle est donc : **représenter le fBm (ou un bruit de regularite H) comme une integrale d'un brownien.**

2.6.2 Mandelbrot–Van Ness (formule classique)

Une representation celebre du fBm sur $\mathbb{R}$ est la formule de Mandelbrot–Van Ness :

$$B_t^H = \frac{1}{\Gamma(H + \frac{1}{2})} \left(\int_{-\infty}^0 \left((t-s)^{H-\frac{1}{2}} - (-s)^{H-\frac{1}{2}} \right) dW_s + \int_0^t (t-s)^{H-\frac{1}{2}} dW_s \right), \quad (2.12)$$

ou $(W_s)_{s \in \mathbb{R}}$ est un brownien bilateral. Cette formule met deja en evidence le noyau $(t-s)^{H-\frac{1}{2}}$.

Remarque 2.5. La presence du terme $\int_{-\infty}^0 (\dots) dW_s$ encode une « histoire » qui garantit les accroissements stationnaires. Pour construire des modeles de volatilité sur un horizon fini $[0, T]$, une representation purement Volterra sur $[0, T]$ est souvent suffisante.

2.6.3 Representation Volterra sur $[0, T]$

Il existe un noyau deterministe $K_H(t, s)$ triangulaire (nul pour $s \geq t$) tel que, pour $t \in [0, T]$,

$$B_t^H = \int_0^t K_H(t, s) dW_s. \quad (2.13)$$

Le point important, pour l'intuition rough, est le comportement pres de $s = t$:

$$K_H(t, s) \sim c_H(t-s)^{H-\frac{1}{2}} \quad (s \uparrow t), \quad (2.14)$$

avec $c_H > 0$. Lorsque $H < 1/2$, le noyau est *singulier* pres du present.

Remarque 2.6 (Lecture intuitive de (2.13)). Le processus B_t^H est une moyenne ponderee de l'histoire du brownien W . Si $H < 1/2$, le noyau (2.14) donne un poids tres eleve aux increments tres recents de W (proches de t), ce qui rend B^H rugueux.

2.6.4 Noyau canonique : Riemann–Liouville (RL)

Pour lier directement rough volatility et calcul fractionnaire, on utilise souvent le noyau *Riemann–Liouville* :

$$K_\alpha(u) := \frac{u^{\alpha-1}}{\Gamma(\alpha)}, \quad u > 0, \quad \alpha \in (0, 1). \quad (2.15)$$

On definit alors un processus gaussien Volterra :

$$X_t := \int_0^t K_\alpha(t-s) dW_s. \quad (2.16)$$

Il ne coïncide pas exactement avec le fBm (les increments ne sont pas stationnaires), mais il a la meme regularite locale : si $\alpha = H + \frac{1}{2}$, alors X est typiquement H -Holder (moins ε).

Remarque 2.7 (Ce que l'on retient pour rHeston). La construction de rHeston retient surtout :

- la representation « rough = convolution d'un brownien par un noyau singulier » ;
- le fait que H se lit dans l'exposant $H - \frac{1}{2}$ du noyau.

Le noyau RL (2.15) est le choix simple qui capture cette singularite.

2.6.5 Comparer fBm et processus RL : meme rugosite, mais increments differents

Le fBm est caracterise par **deux** proprietes de structure (Proposition 2.1) :

- increments stationnaires ;
- autosimilarite.

Le processus RL $X_t = \int_0^t K_\alpha(t-s) dW_s$ capture bien l'autosimilarite « locale » (au niveau des echelles), mais il n'a pas, en general, des increments stationnaires. Intuitivement, l'expression de X_t change de nature quand t change, car l'horizon d'integration $[0, t]$ grandit : le processus « accumule » de l'histoire.

Dans la representation Mandelbrot–Van Ness (2.12), l'integration sur $(-\infty, 0]$ ajoute justement une histoire qui restaure la stationnarite des increments. En rough volatility, on travaille souvent sur un horizon fini et on privilegie les effets de rugosite a court terme : c'est pourquoi le noyau RL est largement utilise, meme s'il ne reproduit pas exactement les increments stationnaires du fBm.

2.6.6 Calcul de variance et echelle H (sur le processus RL)

Le processus X defini par (2.16) est gaussien centre : il est donc entièrement déterminé par sa covariance, et l'objectif est de calculer sa variance et ses covariances. Par isometrie d'Ito, on obtient :

$$\text{Var}(X_t) = \int_0^t K_\alpha(t-s)^2 ds = \frac{t^{2\alpha-1}}{(2\alpha-1)\Gamma(\alpha)^2}. \quad (2.17)$$

Comme $\alpha = H + \frac{1}{2}$, on a $2\alpha - 1 = 2H$ et donc $\text{Var}(X_t)$ est proportionnelle a t^{2H} : c'est la meme loi d'echelle que le fBm.

Echelle des increments. On peut *calculer* l'échelle des incréments à petit pas h . On écrit

$$X_{t+h} - X_t = \int_0^{t+h} K_\alpha(t+h-s) dW_s - \int_0^t K_\alpha(t-s) dW_s = \int_0^t (K_\alpha(t+h-s) - K_\alpha(t-s)) dW_s + \int_t^{t+h} K_\alpha(t+h-s) dW_s.$$

Par isométrie d'Itô,

$$\begin{aligned} \text{Var}(X_{t+h} - X_t) &= \int_0^t (K_\alpha(t+h-s) - K_\alpha(t-s))^2 ds + \int_t^{t+h} K_\alpha(t+h-s)^2 ds \\ &= \int_0^t (K_\alpha(u+h) - K_\alpha(u))^2 du + \int_0^h K_\alpha(u)^2 du, \end{aligned} \quad (2.18)$$

en posant $u = t - s$ dans le premier terme et $u = t + h - s$ dans le second. Or $K_\alpha(u) = u^{\alpha-1}/\Gamma(\alpha)$, donc

$$\int_0^h K_\alpha(u)^2 du = \frac{1}{\Gamma(\alpha)^2} \int_0^h u^{2\alpha-2} du = \frac{h^{2\alpha-1}}{(2\alpha-1)\Gamma(\alpha)^2} = \frac{h^{2H}}{(2H)\Gamma(\alpha)^2}.$$

Pour le premier terme de (2.18), on utilise le changement de variable $u = hz$:

$$\int_0^t (K_\alpha(u+h) - K_\alpha(u))^2 du = \frac{h^{2\alpha-1}}{\Gamma(\alpha)^2} \int_0^{t/h} ((z+1)^{\alpha-1} - z^{\alpha-1})^2 dz.$$

Comme $\alpha \in (1/2, 1)$, l'intégrande est intégrable sur $(0, +\infty)$: au voisinage de 0 il est borné, et quand $z \rightarrow \infty$ on a $(z+1)^{\alpha-1} - z^{\alpha-1} \sim (\alpha-1)z^{\alpha-2}$, donc le carré est en $O(z^{2\alpha-4})$ et $2\alpha-4 < -1$. Ainsi,

$$\int_0^{t/h} ((z+1)^{\alpha-1} - z^{\alpha-1})^2 dz \xrightarrow{h \downarrow 0} \int_0^{+\infty} ((z+1)^{\alpha-1} - z^{\alpha-1})^2 dz =: I_\alpha \in (0, \infty).$$

En combinant avec (2.18), on obtient donc l'échelle

$$\text{Var}(X_{t+h} - X_t) = \frac{h^{2H}}{\Gamma(\alpha)^2} \left(I_\alpha + \frac{1}{2H} + o(1) \right) \quad \text{quand } h \downarrow 0, \quad (2.19)$$

ce qui confirme que la regularite locale est H . Le point important est que le noyau $u^{\alpha-1}$ est le mecanisme analytique qui convertit une regularite « $1/2$ » (brownien) en une regularite « H ».

2.6.7 Interpretation du noyau comme filtre de memoire

Dans (2.16), le noyau K_α joue le role de « filtre » applique au bruit blanc (derivative formelle du brownien).

- Si $K \equiv 1$, on integre le bruit blanc et on obtient un brownien (regularite $1/2$).
- Si $K(u) = u^{\alpha-1}$ avec $\alpha < 1$, on sur-pondere le passe recent de facon singuliere, ce qui rend le signal plus « irregulier » au voisinage de chaque instant.

Cette lecture est tres utile pour expliquer, sans technique lourde, pourquoi « mettre un noyau puissance » produit une volatilité rough.

2.7 Integrer par rapport au fBm : panorama et choix de modelisation

2.7.1 Pourquoi une section sur l'integration ?

Une fois le fBm defini, une tentation naturelle est d'ecrire des EDS « comme d'habitude » :

$$dX_t = b(X_t)dt + a(X_t)dB_t^H.$$

Le probleme est que, pour $H \neq 1/2$, le fBm n'est pas une semimartingale (Theoreme 2.2), donc l'integrale « d'Ito » n'existe pas telle quelle. Il faut choisir une autre notion d'integrale. L'objectif ici n'est pas de developper toute la theorie, mais de comprendre *quelles options existent* et *pourquoi* les modeles rough en finance privilegient l'approche Volterra.

2.7.2 Regime $H > 1/2$: integrale de Young (idee)

Quand $H > 1/2$, les trajectoires de B^H sont « assez regulieres » pour definir une integrale de type Riemann–Stieltjes via le theoreme de Young. Le principe est :

- si f est α -Holder et g est β -Holder avec $\alpha + \beta > 1$,
- alors l'integrale $\int_0^T f(t) dg(t)$ existe au sens de Young.

Comme B^H est H -Holder (moins ε), on peut integrer des integrandes suffisamment regulieres. Cela donne une theorie « deterministe » elegante, mais elle ne preserve pas les proprietes martingales typiques d'Ito (ce qui peut etre genant en finance).

2.7.3 Regime $H < 1/2$: rough paths / Skorokhod (idee)

Quand $H < 1/2$, le fBm est trop irregulier pour Young. Deux grandes voies existent :

- **Rough paths** : on enrichit le chemin par des « iterés » (integrales d'ordre 2, 3, ...) et on definit l'integration comme limite stable. C'est puissant mais technique.
- **Skorokhod (Malliavin)** : on definit une integrale « anticipative » (non adaptee) compatible avec une integration par parties au sens gaussien.

Ces approches sont mathematiquement riches, mais lourdes pour un cours de modele financier pratique.

2.7.4 Le choix finance : representation Volterra et retour a Ito

L'approche la plus utilisee en rough volatility est :

- on represente le fBm (ou un bruit de meme regularite) comme $\int K dW$;
- on formule le modele en termes d'integrales d'Ito par rapport a W ;
- on introduit la rugosite via le noyau K (singulier) et non via un integrateur non semimartingale.

C'est exactement l'esprit de rHeston : on garde W^V et on place K_α dans la dynamique de V .

2.8 Calcul fractionnaire minimal : integrales de convolution

2.8.1 Integrale fractionnaire de Riemann–Liouville

Définition 2.2 (Opérateur I^α). Soit $\alpha \in (0, 1)$ et $f : [0, T] \rightarrow \mathbb{R}$ intégrable. On définit l'intégrale fractionnaire :

$$(I^\alpha f)(t) := \frac{1}{\Gamma(\alpha)} \int_0^t (t-s)^{\alpha-1} f(s) ds = \int_0^t K_\alpha(t-s) f(s) ds. \quad (2.20)$$

Remarque 2.8 (Convolution et memoire). L'opérateur I^α depend de toute l'histoire $[0, t]$: c'est un operateur a memoire. Le noyau etant singulier pres de $s = t$ lorsque $\alpha < 1$, le passe recent influence fortement le present.

2.8.2 Semigroupe (complement)

Un calcul direct montre la propriete de semigroupe :

$$I^\alpha(I^\beta f) = I^{\alpha+\beta} f \quad (\alpha, \beta > 0, \alpha + \beta < 1),$$

qui repose sur l'identite Beta/Gamma. Cette propriete est l'analogie fractionnaire de l'integration iterree.

2.8.3 Lecture « EDS fractionnaire » (heuristique)

Si $g = I^\alpha f$, on peut formaliser f comme une « derivee fractionnaire » de g . Dans une equation de variance de type rHeston, la convolution par K_α joue exactement le role d'une *integration fractionnaire* du drift et du bruit. Cette lecture aide a faire le parallele avec Heston :

$$\text{Heston : } V_t = V_0 + I^1(\text{drift}) + I^1(\text{diffusion } \dot{W}),$$

$$\text{rHeston : } V_t = V_0 + I^\alpha(\text{drift}) + I^\alpha(\text{diffusion } \dot{W}),$$

avec $\alpha \in (1/2, 1)$.

2.9 Mode microscope : définition, covariance, scaling

2.9.1 Définition par covariance

Le fractional Brownian motion B^H (Hurst $H \in (0, 1)$) est un processus gaussien centré tel que

$$\mathbb{E}[B_t^H B_s^H] = \frac{1}{2}(t^{2H} + s^{2H} - |t-s|^{2H}). \quad (2.21)$$

Il a des incréments stationnaires et une régularité dépendant de H .

2.9.2 Auto-similarité (scaling)

Pour $c > 0$, on a l'égalité en loi

$$(B_{ct}^H)_{t \geq 0} \stackrel{\text{law}}{=} (c^H B_t^H)_{t \geq 0}.$$

On le vérifie en utilisant le fait qu'un processus gaussien est déterminé par sa covariance, et que (2.21) satisfait $\mathbb{E}[B_{ct}^H B_{cs}^H] = c^{2H} \mathbb{E}[B_t^H B_s^H]$.

Sanity check. En posant $H = 1/2$ dans (2.21), on retrouve $\mathbb{E}[W_t W_s] = \min(t, s)$: cohérence.

2.9.3 Avertissement : non semimartingale

Pour $H \neq 1/2$, B^H n'est pas une semimartingale : l'intégrale d'Itô classique ne s'applique pas directement. On utilise d'autres cadres (Young, Malliavin, rough paths), ou des représentations Volterra pour simuler/pricer.

2.10 Pièges classiques / erreurs fréquentes

- Utiliser Itô directement pour $H \neq 1/2$: erreur conceptuelle (pas semimartingale).
- Confondre corrélation d'incrément et corrélation du processus : fBm a incréments stationnaires mais dépendants.
- Erreurs de simulation : noyau singulier, pas de temps insuffisant, biais sur la variance.

2.11 Checklist — savoir refaire sans regarder

- Écrire la covariance du fBm et en déduire la variance des incréments.
- Vérifier le cas $H = 1/2$ (retour Brownien) et le scaling.
- Expliquer non-Markov et non-semi-martingale pour $H \neq 1/2$.
- Donner des sanity-checks de simulation.

Chapitre 3

Rough Heston

Idée centrale. Rough Heston ajoute de la mémoire (noyau Volterra fractionnaire) à Heston tout en préservant une structure affine : on capture la rugosité empirique à court terme (petit H) sans empiler des dizaines de facteurs markoviens.

Cadre mathématique.

- **Variance rough.** $v_t = v_0 + \int_0^t K(t-s)\kappa(\theta - v_s) ds + \int_0^t K(t-s)\xi\sqrt{v_s} dW_s$, avec $K(t) \sim t^{H-1/2}$.
- **Affinité.** Riccati classique $\rightarrow$ Riccati fractionnaire (équation de Volterra) pour la CF/pricing.
- **Limite.** $H \rightarrow \frac{1}{2} \Rightarrow$ retour Heston (sanity check).

Intuition marché / interprétation. Le paramètre H gouverne la « texture » : petit $H \Rightarrow$ vol très irrégulière à court terme $\Rightarrow$ smiles raides en petite maturité. Le coût est numérique (convolutions, calibration).

Implémentation.

- Approximation multi-facteurs : approximer K par somme d'exponentielles pour rendre quasi-markovien.
- Simulation : schémas hybrid/multi-facteurs ; monitoring de coût $O(NM)$ (M facteurs) vs précision.

Tests / sanity checks.

- Limite $H \rightarrow 1/2$: prices/smiles proches de Heston (check).
- Positivité : $v_t \geq 0$ en simulation (diagnostic de schéma).
- Stabilité : calibration stable vs pas/discretisation (sinon artefacts numériques).

Pont vers pratique quant. Pont quant : calibration short-term equity smiles, pricing rapide via approximations multi-facteurs, et modélisation de forward variance/roughness en production.

3.1 Avant-propos : rough Heston (mémoire + affinité)

Heston est un modèle markovien : la variance est une diffusion (CIR) et l'information pertinente est (S_t, v_t) . Les modèles « rough » partent d'un fait empirique : la volatilité varie à très court terme avec une régularité plus faible que brownienne (exposant $H < \frac{1}{2}$). Rough Heston propose un compromis élégant :

- on introduit une **mémoire** via un noyau de Volterra (fractionnaire) ;
- on conserve une structure **affine** qui rend le pricing encore calculable (Riccati fractionnaire).

3.1.1 Objectifs pédagogiques

- Comprendre la dynamique SVIE de la variance et le rôle du noyau $K(t) = t^{H-\frac{1}{2}}$.
- Expliquer le lien : fBm/Volterra $\Rightarrow$ rugosité $H < \frac{1}{2}$.
- Voir comment la structure affine survit : l'EDO de Riccati devient une équation de Volterra (fractionnaire).
- Discuter les approches numériques : multi-facteurs (somme d'exponentielles), schémas et coût.

3.1.2 Pré-requis

- Heston : fonction caractéristique affine et Riccati classique.
- Volterra/fBm (chapitres 1 and 2) : noyaux, régularité, représentations.

3.1.3 Plan du chapitre

1. SVIE : cadre et noyaux rough.
2. Construction rough : du fBm/Volterra au modèle rHeston.

3. Riccati fractionnaire et pricing : pourquoi c'est « prenable ».
4. Interprétations : skew court terme, rôle de H , sanity checks (limite $H \rightarrow \frac{1}{2}$).

Intuition de marché. Le paramètre H est un *paramètre de texture* : petit $H \Rightarrow$ variations très rapides à court terme $\Rightarrow$ smiles raides à petite maturité. Rough Heston vaut l'effort parce qu'il reproduit ces faits stylisés sans empiler une infinité de facteurs markoviens.

3.2 Equations stochastiques de Volterra (SVIE) : le langage naturel de rHeston

3.2.1 Definition

Une *stochastic Volterra integral equation* (SVIE) est une equation integrale ou drift et diffusion sont convolues par un noyau. Un prototype (1D) est :

$$X_t = X_0 + \int_0^t K(t-s) b(X_s) ds + \int_0^t K(t-s) \sigma(X_s) dW_s. \quad (3.1)$$

Quand $K \equiv 1$, (3.1) redevient une EDS d'Ito classique. Quand K est une exponentielle, on peut souvent « markovianiser » le modele en ajoutant des variables d'etat. Quand K est une puissance (noyau fractionnaire), on obtient une dynamique rough.

Remarque 3.1 (Point pedagogique). Rough Heston n'est pas « Heston + fBm » au sens « remplacer dW par dB^H ». Rough Heston est « Heston + SVIE » : on remplace l'operateur « integration locale » par un operateur « convolution memoire ».

3.2.2 Trois noyaux a connaitre

1. **Constant** : $K(t) \equiv 1$. On retrouve les diffusions markoviennes.
2. **Exponentiel** : $K(t) = e^{-\lambda t}$. La memoire decroit a echelle $1/\lambda$.
3. **Puissance** : $K(t) = t^{\alpha-1}/\Gamma(\alpha)$. Memoire singuliere pres du present : regime rough.

3.2.3 Markovianisation : le cas exponentiel (idee en 5 lignes)

Si $K(t) = e^{-\lambda t}$, on peut definir un facteur auxiliaire

$$Y_t := \int_0^t e^{-\lambda(t-s)} \sigma(X_s) dW_s.$$

Un calcul (regle de Leibniz sous l'integrale) donne alors une dynamique differentielle :

$$dY_t = -\lambda Y_t dt + \sigma(X_t) dW_t,$$

ce qui transforme l'equation a memoire en un systeme markovien (dimension augmentee). Cette idee est importante car, numeriquement, on approxime souvent un noyau rough par une somme d'exponentielles pour retrouver un systeme markovien « multi-facteurs ».

3.2.4 Existence / unicite : preuve par point fixe (Picard)

On donne un resultat standard (niveau cours) qui justifie qu'une SVIE bien posee possede une solution adaptee unique.

Théorème 3.1 (Existence et unicite pour une SVIE 1D). *On fixe $T > 0$. On suppose :*

1. $K \in L^2([0, T])$;
2. $b : \mathbb{R} \rightarrow \mathbb{R}$ et $\sigma : \mathbb{R} \rightarrow \mathbb{R}$ sont globalement Lipschitz : $|b(x) - b(y)| \leq L_b |x - y|$ et $|\sigma(x) - \sigma(y)| \leq L_\sigma |x - y|$;
3. b et σ ont une croissance au plus lineaire (ce qui est automatique si elles sont Lipschitz) ;
4. $X_0 \in L^2(\Omega)$ est $\mathcal{F}_0$ -mesurable.

Alors l'equation de Volterra stochastique

$$X_t = X_0 + \int_0^t K(t-s) b(X_s) ds + \int_0^t K(t-s) \sigma(X_s) dW_s \quad (t \in [0, T])$$

possede une solution adaptee unique $(X_t)_{t \in [0, T]}$ telle que $\sup_{t \leq T} \mathbb{E}[|X_t|^2] < \infty$.

Démonstration. 1) Espace de travail (Banach). Pour $\beta > 0$, on considère l'espace $\mathcal{H}_\beta$ des processus adaptés $(X_t)_{t \in [0, T]}$ tels que

$$\|X\|_\beta^2 := \sup_{t \in [0, T]} e^{-\beta t} \mathbb{E}[|X_t|^2] < \infty.$$

Cet espace est complet : si (X^n) est de Cauchy pour $\|\cdot\|_\beta$, alors pour chaque t la suite X_t^n est de Cauchy dans L^2 , donc converge vers une limite $X_t \in L^2$; le sup pondéré permet ensuite de conclure que $X \in \mathcal{H}_\beta$ et que $X^n \rightarrow X$ dans $\mathcal{H}_\beta$.

2) Opérateur de Picard. On définit $\Phi : \mathcal{H}_\beta \rightarrow \mathcal{H}_\beta$ par

$$(\Phi X)_t := X_0 + \int_0^t K(t-s) b(X_s) ds + \int_0^t K(t-s) \sigma(X_s) dW_s.$$

Un point fixe $X = \Phi X$ est exactement une solution de la SVIE.

3) Φ est bien définie sur $\mathcal{H}_\beta$. On majore $\mathbb{E}[|(\Phi X)_t|^2]$ par $(a+b+c)^2 \leq 3(a^2+b^2+c^2)$, puis :

— pour le terme déterministe, $\mathbb{E}[|X_0|^2]$ est fini ;

— pour l'intégrale en ds , par Cauchy–Schwarz,

$$\left(\int_0^t |K(t-s)| |b(X_s)| ds \right)^2 \leq \left(\int_0^t K(t-s)^2 ds \right) \left(\int_0^t |b(X_s)|^2 ds \right) ;$$

— pour l'intégrale stochastique, par isométrie d'Itô,

$$\mathbb{E} \left[\left(\int_0^t K(t-s) \sigma(X_s) dW_s \right)^2 \right] = \mathbb{E} \left[\int_0^t K(t-s)^2 \sigma(X_s)^2 ds \right].$$

Comme b et σ sont Lipschitz, on a des bornes de croissance du type $|b(x)|^2 \leq C(1+|x|^2)$ et $|\sigma(x)|^2 \leq C(1+|x|^2)$. En utilisant $\sup_{s \leq t} \mathbb{E}[|X_s|^2] \leq e^{\beta t} \|X\|_\beta^2$ et $K \in L^2$, on obtient une borne de la forme $\sup_{t \leq T} e^{-\beta t} \mathbb{E}[|(\Phi X)_t|^2] \leq C_{T,\beta}(1 + \|X\|_\beta^2) < \infty$. Donc $\Phi X \in \mathcal{H}_\beta$.

4) Contraction pour β assez grand. Soient $X, Y \in \mathcal{H}_\beta$. Pour tout t ,

$$(\Phi X)_t - (\Phi Y)_t = \int_0^t K(t-s)(b(X_s) - b(Y_s)) ds + \int_0^t K(t-s)(\sigma(X_s) - \sigma(Y_s)) dW_s.$$

On majore l'espérance du carré par 2(drift² + martingale²).

Terme drift. Par Cauchy–Schwarz puis Lipschitz,

$$\begin{aligned} \mathbb{E} \left[\left(\int_0^t K(t-s)(b(X_s) - b(Y_s)) ds \right)^2 \right] &\leq \left(\int_0^t K(t-s)^2 ds \right) \int_0^t \mathbb{E}[(b(X_s) - b(Y_s))^2] ds \\ &\leq L_b^2 \left(\int_0^T K(u)^2 du \right) \int_0^t \mathbb{E}[|X_s - Y_s|^2] ds. \end{aligned}$$

En multipliant par $e^{-\beta t}$ et en utilisant $\mathbb{E}[|X_s - Y_s|^2] \leq e^{\beta s} \|X - Y\|_\beta^2$, on obtient

$$e^{-\beta t} \mathbb{E}[\text{drift}^2] \leq L_b^2 \left(\int_0^T K(u)^2 du \right) e^{-\beta t} \int_0^t e^{\beta s} ds \|X - Y\|_\beta^2 \leq \frac{L_b^2}{\beta} \left(\int_0^T K(u)^2 du \right) \|X - Y\|_\beta^2.$$

Terme martingale. Par isométrie d'Itô puis Lipschitz,

$$\begin{aligned} e^{-\beta t} \mathbb{E} \left[\left(\int_0^t K(t-s)(\sigma(X_s) - \sigma(Y_s)) dW_s \right)^2 \right] &= e^{-\beta t} \mathbb{E} \left[\int_0^t K(t-s)^2 (\sigma(X_s) - \sigma(Y_s))^2 ds \right] \\ &\leq L_\sigma^2 e^{-\beta t} \int_0^t K(t-s)^2 \mathbb{E}[|X_s - Y_s|^2] ds \\ &\leq L_\sigma^2 \int_0^t K(u)^2 e^{-\beta u} du \|X - Y\|_\beta^2. \end{aligned}$$

En prenant le sup sur $t \in [0, T]$, on obtient

$$\|\Phi X - \Phi Y\|_\beta^2 \leq 2 \left(\frac{L_b^2}{\beta} \int_0^T K(u)^2 du + L_\sigma^2 \int_0^T K(u)^2 e^{-\beta u} du \right) \|X - Y\|_\beta^2.$$

Quand $\beta \rightarrow \infty$, les deux termes entre parenthèses tendent vers 0 (le premier comme $1/\beta$, le second par convergence dominée). On choisit donc β assez grand pour que la constante de Lipschitz soit strictement < 1 : Φ est une contraction sur $\mathcal{H}_\beta$.

5) Conclusion (point fixe de Banach). Par le théorème du point fixe de Banach, Φ a un unique point fixe $X \in \mathcal{H}_\beta$. Ce point fixe est une solution adaptée unique de la SVIE sur $[0, T]$. $\square$

3.2.5 Cout numerique

Sur une grille de taille n , evaluer naïvement la convolution historique pour chaque t_k coute $O(n^2)$. Deux familles d'accélération :

- **Approximations multi-facteurs** : $K(t) \approx \sum_{i=1}^m c_i e^{-\lambda_i t}$ (dimension m).
- **Convolution acceleree** : FFT / methodes hybrides quand la structure s'y prete.

Ce point redevient central lorsqu'on veut simuler rHeston ou resoudre sa Riccati fractionnaire en calibration.

3.3 Rough volatility : motivation et premier modele rough

3.3.1 Motivation finance : que veut dire « volatilité rugueuse » ?

Dans de nombreux sous-jacents, la volatilité (réalisée ou implicite) présente une dynamique à plusieurs échelles. Une façon standard d'objectiver une régularité est de regarder une variable liée à la volatilité (par exemple $\log \sigma_t$ ou $\log V_t$) et d'étudier les increments à petite échelle :

$$\log \sigma_{t+h} - \log \sigma_t.$$

Dans un modèle markovien de diffusion, ces increments sont typiquement de taille $h^{1/2}$ (régularité brownienne). L'idée « rough » est de postuler une régularité plus faible :

$$|\log \sigma_{t+h} - \log \sigma_t| \approx h^H \quad \text{avec } H < 1/2.$$

Le paramètre H joue alors le rôle d'un exposant de régularité observable via des régressions log-log de moments d'increments.

Interprétation marché. Empiriquement, de nombreuses études (actions, FX) trouvent un exposant rough H autour de 0.05–0.2 pour des variables liées à la volatilité. L'intérêt n'est pas seulement descriptif : ce choix de rugosité impacte directement la pente du skew à petite maturité, et explique pourquoi des modèles markoviens (type Heston) ont du mal à reproduire des smiles très raides à court terme.

Check dimensionnel. h est un pas de temps (en années si l'on travaille avec r annualisé). L'écriture $|\Delta \log \sigma| \approx h^H$ est donc un *ordre de grandeur* : elle sert à identifier H via des régressions log-log et à faire des sanity checks (par exemple, doubler la fréquence d'observation modifie la taille typique des increments selon 2^{-H}).

3.3.2 Un prototype : un bruit Volterra pour le log-vol

Un prototype simple (hors rHeston) consiste à poser :

$$X_t := \int_0^t K_\alpha(t-s) dW_s, \quad \alpha = H + \frac{1}{2},$$

puis à modéliser le log-vol comme une fonction de X (par exemple un OU rough) :

$$Y_t = Y_0 - \lambda \int_0^t Y_s ds + \eta X_t, \quad \sigma_t = e^{Y_t}.$$

Ce type de construction (processus Volterra gaussien) est au cœur des modèles rough. Le rough Heston va suivre une logique similaire, mais en préservant l'esprit Heston : une variance positive, mean-reverting, avec un effet levier.

3.4 Ouverture structurante : Heston classique comme modele affine

3.4.1 Variance CIR : proprietes utiles

Dans Heston, la variance suit une CIR :

$$dV_t = \kappa(\theta - V_t)dt + \xi\sqrt{V_t}dW_t^V.$$

Deux proprietes a retenir :

1. **Esperance conditionnelle :**

$$\mathbb{E}[V_t | V_0] = \theta + (V_0 - \theta)e^{-\kappa t}. \quad (3.2)$$

2. **Positivite :** $V_t \geq 0$ p.s. si $V_0 \geq 0$. Une condition suffisant classique pour la positivite stricte est la condition de Feller :

$$2\kappa\theta \geq \xi^2. \quad (3.3)$$

3.4.2 Fonction caracteristique et Riccati (le point-cle pour le pricing)

Posons $X_t = \log S_t$. Dans Heston, la transformee de Fourier de X_t est de la forme exponentielle-affine :

$$\phi(u, t) := \mathbb{E}[e^{iuX_t} | \mathcal{F}_0] = \exp(iu(X_0 + rt) + C(t, u) + D(t, u)V_0), \quad (3.4)$$

ou C et D satisfont un systeme de type Riccati. Une facon compacte de l'ecrire est :

$$\partial_t D(t, u) = -\frac{1}{2}(u^2 + iu) + (\rho\xi iu - \kappa)D(t, u) + \frac{\xi^2}{2}D(t, u)^2, \quad D(0, u) = 0, \quad (3.5)$$

$$\partial_t C(t, u) = \kappa\theta D(t, u), \quad C(0, u) = 0. \quad (3.6)$$

Ces equations sont resolubles explicitement, d'où l'efficacite numerique du pricing Heston.

Remarque 3.2 (Sanity check (variance constante)). Si l'on fixe $V_t \equiv V_0$ et que l'on oublie la dynamique de V , alors X_t est gaussien et

$$\mathbb{E}[e^{iuX_t}] = \exp\left(iu(X_0 + rt) - \frac{1}{2}(u^2 + iu)V_0t\right).$$

La condition $D(0, u) = 0$ et (3.5) impliquent bien $D'(0, u) = -\frac{1}{2}(u^2 + iu)$, coherent avec ce cas simple.

Remarque 3.3 (Pourquoi on insiste). Dans rHeston, on va conserver *la meme fonction quadratique* en D que dans (3.5), mais l'equation ne sera plus une EDO : elle deviendra une equation de Volterra (fractionnaire). C'est la cle « pedagogique » : rHeston = Heston + noyau fractionnaire.

3.5 Derivation pas a pas de rHeston a partir du fBm (coeur du cours)

3.5.1 Etape 1 : choisir le regime rough $H < 1/2$

On fixe un parametre de Hurst $H \in (0, 1/2)$, compatible avec une regularite plus faible que $1/2$. On pose la quantite (plus pratique dans les noyaux) :

$$\alpha := H + \frac{1}{2} \in \left(\frac{1}{2}, 1\right). \quad (3.7)$$

On travaillera avec le noyau RL $K_\alpha(u) = u^{\alpha-1}/\Gamma(\alpha)$. L'exposant $\alpha - 1 \in (-1/2, 0)$ signifie :

- le noyau explose en $u = 0$ (singularite) ;
- mais il reste integrable sur $(0, t)$ (ce qui rend l'equation bien definie).

3.5.2 Interlude : pourquoi la relation $\alpha = H + \frac{1}{2}$? (calcul d'ordre de grandeur)

Cette relation peut se justifier par un argument de dimension / echelle tres simple. Considerons le bruit Volterra RL

$$X_t = \int_0^t K_\alpha(t-s)dW_s, \quad K_\alpha(u) = \frac{u^{\alpha-1}}{\Gamma(\alpha)}.$$

Par isometrie d'Ito (et comme dans (2.17)), on a

$$\text{Var}(X_t) = \int_0^t K_\alpha(t-s)^2 ds \propto \int_0^t u^{2\alpha-2} du \propto t^{2\alpha-1}.$$

Donc l'écart-type est d'ordre $t^{\alpha-\frac{1}{2}}$. Si l'on veut que ce bruit ait une régularité H (i.e. des increments d'ordre t^H comme un fBm de Hurst H), on impose :

$$\alpha - \frac{1}{2} = H \iff \alpha = H + \frac{1}{2}.$$

Autrement dit, le noyau $u^{\alpha-1}$ est choisi pour transformer l'exposant $1/2$ du brownien en l'exposant H désiré.

3.5.3 Interlude : d'où vient une convolution en temps continu ? (derivation discret $\rightarrow$ continu)

Une convolution Volterra apparaît naturellement si l'on part d'un modèle discret à « mémoire ». Par exemple, sur une grille $t_k = k\Delta t$, supposons que les chocs de variance persistent avec des poids w_ℓ :

$$V_{t_k} - V_0 \approx \sum_{j=0}^{k-1} w_{k-j} \Delta \varepsilon_j, \quad \Delta \varepsilon_j \approx \xi \sqrt{V_{t_j}} \Delta W_j^V.$$

Si les poids décroissent comme une loi de puissance $w_\ell \approx (\ell\Delta t)^{\alpha-1}/\Gamma(\alpha)\Delta t$, alors, quand $\Delta t \rightarrow 0$, la somme converge vers une intégrale de convolution du type $\int_0^t K_\alpha(t-s)\xi\sqrt{V_s}dW_s^V$. Ce raisonnement (sommes pondérées $\rightarrow$ intégrales) donne une intuition forte : rHeston n'est pas une « astuce continue » mais la limite naturelle d'une mémoire à loi de puissance en discret.

3.5.4 Etape 2 : point de départ « naïf » et problème

Si l'on veut « mettre du fBm » dans la variance, une première idée serait :

$$dV_t = \kappa(\theta - V_t)dt + \xi\sqrt{V_t}dB_t^H, \quad (H < 1/2). \quad (3.8)$$

Mais (3.8) n'est pas une EDS d'Ito : l'intégrale $\int \sqrt{V}dB^H$ n'est pas définie dans le cadre semimartingale. Il faut donc **changer de représentation** sans perdre le contrôle du calcul stochastique.

3.5.5 Etape 3 : utiliser la représentation Volterra du bruit rough

L'idée consiste à remplacer le « bruit rough » par une convolution d'un brownien. On introduit un brownien W^V et le processus Volterra gaussien

$$X_t := \int_0^t K_\alpha(t-s)dW_s^V. \quad (3.9)$$

Localement, X a la régularité d'un processus de Hurst $H = \alpha - \frac{1}{2}$. On peut le voir comme un « proxy » de fBm sur $[0, T]$ au niveau de la rugosité.

Remarque 3.4 (Pourquoi ne pas prendre exactement le fBm ?). On peut construire un fBm exact via un noyau $K_H(t, s)$ (Section précédente), mais rHeston est souvent présenté avec le noyau RL car il donne une écriture simple et une structure « affine Volterra » exploitable. Le message modèle est : le *comportement singulier* près de $t = s$ est l'essentiel pour la rugosité.

3.5.6 Etape 4 : « fractionaliser » la variance CIR de Heston

Dans Heston, la variance s'écrit en forme intégrale :

$$V_t = V_0 + \int_0^t \kappa(\theta - V_s)ds + \int_0^t \xi\sqrt{V_s}dW_s^V. \quad (3.10)$$

La fractionalisation consiste à remplacer l'opérateur d'intégration classique $f \mapsto \int_0^t f(s)ds$ par l'opérateur fractionnaire I^α . Autrement dit, on postule :

$$V_t = V_0 + \int_0^t K_\alpha(t-s)\kappa(\theta - V_s)ds + \int_0^t K_\alpha(t-s)\xi\sqrt{V_s}dW_s^V. \quad (3.11)$$

Cette équation est une *EDS de Volterra* (à mémoire), et c'est la **définition opérationnelle** de la variance rHeston.

Ce qu'il faut savoir expliquer à l'oral.

- Le noyau $K_\alpha(t-s)$ pondère le passé : V_t dépend de tout $(V_s)_{s \leq t}$.

- Quand $H < 1/2$ (donc $\alpha < 1$), le noyau est singulier pres du present, ce qui rend V plus rugueux.
- La diffusion $\sqrt{V_s}dW_s^V$ reste une integrale d'Ito : on ne perd pas le cadre probabiliste classique.

3.5.7 Etape 5 : completer le modele d'actif (equation du prix)

On conserve pour le prix une dynamique de diffusion standard sous $\mathbb{Q}$:

$$dS_t = rS_t dt + S_t \sqrt{V_t} dW_t^S, \quad (3.12)$$

avec

$$d\langle W^S, W^V \rangle_t = \rho dt. \quad (3.13)$$

Le couple (3.12)–(3.11) definit le modele rHeston.

3.5.8 Etape 6 : verification du cas limite Heston

Le test de coherence est le cas $H \uparrow 1/2$ (donc $\alpha \uparrow 1$). On observe que $K_\alpha(u) = u^{\alpha-1}/\Gamma(\alpha) \rightarrow 1$ quand $\alpha \rightarrow 1$. Alors (3.11) tend formellement vers (3.10), c'est-a-dire l'EDS CIR de Heston.

Remarque 3.5 (Pourquoi rHeston est une « derivation » et pas une invention arbitraire). On peut resumer la derivation ainsi :

1. On veut une variance plus rugueuse $\Rightarrow$ on introduit un exposant $H < 1/2$ comme regularite-cible.
2. Le fBm fournit un prototype de processus gaussien de regularite H .
3. Le fBm s'ecrit comme convolution d'un brownien par un noyau $(t-s)^{H-\frac{1}{2}}$.
4. On applique cette idee de convolution (via K_α) a l'EDS de variance de Heston.
5. On verifie que l'on retrouve Heston quand $H \rightarrow 1/2$.

3.6 Consequences : memoire, non-Markov, et skew court terme

3.6.1 Non-Markovianite (ce que cela change concretement)

Dans Heston, l'etat (S_t, V_t) est markovien : le futur ne depend que du present. Dans rHeston, l'equation (3.11) montre que V_t depend de tout l'historique $(V_s)_{0 \leq s \leq t}$ via la convolution. Concretement, cela signifie :

- on perd les PDE classiques de pricing en dimension 2 (puisque l'etat n'est plus fini-dimensionnel) ;
- la simulation naive est plus couteuse : on doit calculer des convolutions historiques ;
- on gagne une flexiblité de forme temporelle (multi-echelles, skew court terme).

3.6.2 Pourquoi V est plus rugueux (heuristique par linearisation)

Pour comprendre l'echelle des increments, on linearise autour de θ : pour V_s proche de θ , on remplace heuristiquement $\sqrt{V_s}$ par $\sqrt{\theta}$ dans le terme stochastique. Le modele lineaire devient alors :

$$V_t - \theta \approx (V_0 - \theta) + \int_0^t K_\alpha(t-s)(-\kappa(V_s - \theta))ds + \xi\sqrt{\theta} \int_0^t K_\alpha(t-s)dW_s^V.$$

Le dernier terme est exactement un bruit Volterra gaussien X_t (equation (2.16)) avec regularite locale $H = \alpha - \frac{1}{2}$. On retient donc :

$$|V_{t+h} - V_t| \text{ typique } \approx h^H \quad (H < 1/2),$$

alors que dans une diffusion markovienne on a plutot une echelle $h^{1/2}$.

3.6.3 Lien avec le skew de tres court terme (message finance)

Une consequence importante des modeles rough est la *pente du smile* (skew) a courte maturite. Sans entrer dans une preuve complete, beaucoup de resultats et heuristiques (dans plusieurs modeles rough) conduisent au comportement :

$$\text{ATM skew}(T) \approx T^{H-\frac{1}{2}} \quad \text{quand } T \downarrow 0. \quad (3.14)$$

Ainsi, si $H < 1/2$, la pente devient grande quand T est petit, ce qui est qualitativement coherent avec des observations de marche. Dans Heston (ou plus generalement dans des diffusions markoviennes « lisses »), le skew court terme est souvent trop plat sans ajustements importants.

Remarque 3.6 (A retenir). Le parametre H n'est pas un « detail » : il controle directement une loi d'echelle a court terme. Dans une soutenance ou un oral, (3.14) est un excellent point d'appui pour expliquer *pourquoi* rHeston vaut l'effort numerique.

3.7 Riccati fractionnaire : comment rHeston reste prenable pour le pricing

3.7.1 Du Riccati (Heston) au Riccati de Volterra (rHeston)

On a vu que, dans Heston, la fonction caracteristique est gouvernee par une Riccati (equation (3.5)). Dans rHeston, la structure reste *affine*, mais l'equation pour D devient *integrale* (Volterra).

3.7.2 Equation de Riccati fractionnaire (forme cours)

On definit la fonction quadratique (celle de Heston) :

$$F(u, z) := -\frac{1}{2}(u^2 + iu) + (\rho\xi iu - \kappa)z + \frac{\xi^2}{2}z^2. \quad (3.15)$$

Dans rHeston, $D(u, \cdot)$ est defini comme solution de l'equation de Volterra :

$$D(u, t) = \int_0^t K_\alpha(t-s) F(u, D(u, s)) ds, \quad D(u, 0) = 0, \quad (3.16)$$

avec $K_\alpha(u) = u^{\alpha-1}/\Gamma(\alpha)$ et $\alpha = H + \frac{1}{2}$. On parle de *Riccati fractionnaire* car (3.16) est l'analogie fractionnaire de $D'(t) = F(u, D(t))$.

3.7.3 Fonction caracteristique (forme exponentielle-affine)

Une fois $D(u, t)$ obtenu, on peut ecrire (sous hypotheses techniques) :

$$\phi(u, t) := \mathbb{E}[e^{iuX_t} | \mathcal{F}_0] = \exp\left(iu(X_0 + rt) + C(u, t) + D(u, t) V_0\right), \quad (3.17)$$

avec

$$C(u, t) = \kappa\theta \int_0^t D(u, s) ds, \quad C(u, 0) = 0. \quad (3.18)$$

Remarque 3.7 (Retour au cas Heston). Si $\alpha = 1$ (donc $K_\alpha \equiv 1$), alors (3.16) devient $D(u, t) = \int_0^t F(u, D(u, s))ds$ et donc $D'(u, t) = F(u, D(u, t))$: on recupere l'equation de Riccati de Heston.

3.7.4 Dérivation : idée « multi-facteurs » → Volterra

Il existe une theorie mathematique (affine Volterra) qui garantit (3.16)–(3.17). Ici, on donne une intuition tres utile pour un etudiant : **le Riccati fractionnaire apparait comme une limite de Riccati classiques.**

1) Approcher le noyau rough par une somme d'exponentielles. On part de l'approximation (3.19) :

$$K_\alpha(t) \approx \sum_{i=1}^m c_i e^{-\lambda_i t}.$$

Cela transforme rHeston en un modele markovien approche, car chaque exponentielle engendre un facteur markovien (equation (3.20)).

2) Dans le modele approche, on retrouve des Riccati en dimension finie. Comme l'etat est markovien (dimension $m+1$), on peut appliquer la meme logique que pour Heston : la fonction caracteristique se met sous forme exponentielle-affine en les facteurs, et les coefficients satisfont un systeme d'EDO (generalisation multi-dimensionnelle de la Riccati).

3) Passer a la limite $m \rightarrow \infty$. Quand m augmente et que l'approximation (3.19) devient fine, le systeme de Riccati « multi-facteurs » se transforme en une equation integrale (Volterra) gouvernee par le noyau limite K_α . Autrement dit :

- kernel constant $\Rightarrow$ Riccati (EDO) ;
- kernel somme d'exponentielles $\Rightarrow$ Riccati multi-facteurs (systeme d'EDO) ;
- kernel puissance $\Rightarrow$ Riccati de Volterra (3.16).

Cette lecture est precieuse : elle explique pourquoi rHeston reste « traitable » (affinite conservee) tout en etant non markovien.

3.7.5 Resolution numerique (idee pratique)

Pour pricer via (3.17), on doit resoudre (3.16) numeriquement. Une discretisation simple sur une grille $t_k = k\Delta t$ remplace l'integrale par une somme de quadrature :

$$D(u, t_k) \approx \sum_{j=0}^{k-1} w_{k,j} F(u, D(u, t_j)),$$

avec des poids $w_{k,j}$ deduits du noyau K_α . Le cout naif est $O(n^2)$, mais des accelerations existent (approximation multi-factorielle, FFT, methodes hybrides).

3.8 Simulation et calibration de rHeston (vue pratique)

3.8.1 Simulation directe : discretiser la convolution

Dans rHeston, la variance est donnee par l'equation integrale (3.11). Sur une grille $t_k = k\Delta t$, une discretisation naturelle est :

$$V_{t_k} \approx V_0 + \sum_{j=0}^{k-1} K_\alpha(t_k - t_j) \kappa(\theta - V_{t_j}) \Delta t + \sum_{j=0}^{k-1} K_\alpha(t_k - t_j) \xi \sqrt{V_{t_j}} \Delta W_j^V,$$

ou $\Delta W_j^V = W_{t_{j+1}}^V - W_{t_j}^V$. Ce schema illustre bien le cout $O(n^2)$: pour chaque k , on somme sur tout $j < k$.

Remarque 3.8 (Stabilite numerique et positivite). Comme dans CIR, la racine $\sqrt{V_{t_j}}$ peut poser probleme numerique si V s'approche de 0. En pratique, on utilise souvent des variantes (troncature, reflection, ou schemas specialises) pour conserver $V \geq 0$ a la discretisation.

3.8.2 Simuler le prix une fois V connu sur une grille

Une fois une trajectoire de variance (V_{t_k}) produite, la simulation du prix (ou du log-prix) est similaire a Heston. Pour $X_t = \log S_t$, on discretise

$$dX_t = \left(r - \frac{1}{2} V_t \right) dt + \sqrt{V_t} dW_t^S$$

par un schema d'Euler :

$$X_{t_{k+1}} \approx X_{t_k} + \left(r - \frac{1}{2} V_{t_k} \right) \Delta t + \sqrt{V_{t_k}} \Delta W_k^S.$$

Comme $S_t = e^{X_t}$, on retrouve S_{t_k} par exponentielle. L'impact « rough » se situe donc dans la construction de V , pas dans l'integration du prix.

3.8.3 Comment generer deux browniens correles (rappel utile)

On veut $d\langle W^S, W^V \rangle_t = \rho dt$. En discret, cela revient a simuler des increments gaussiens correles :

$$\Delta W_k^S = \rho \Delta W_k^V + \sqrt{1 - \rho^2} \Delta W_k^\perp,$$

ou ΔW_k^V et $\Delta W_k^\perp$ sont independants, chacun $\sim \mathcal{N}(0, \Delta t)$. Cette construction est tres pratique en Monte Carlo.

3.8.4 Hybrid scheme (vue d'ensemble)

Dans des implementations de reference, la simulation rHeston est souvent acceleree par des schemas « hybrides » qui :

- traitent separement la partie singuliere du noyau (pres de 0) et la partie reguliere ;
- exploitent des convolutions rapides (FFT) et/ou des approximations multi-facteurs ;
- controlent la positivite de V .

L'idee a retenir pour ce cours : la difficulte numerique principale vient de la convolution Volterra, pas de l'equation du prix.

3.8.5 Approximation multi-facteurs (markovianisation numerique)

Une idee tres utile est d'approcher le noyau rough par une somme d'exponentielles :

$$K_\alpha(t) \approx \sum_{i=1}^m c_i e^{-\lambda_i t}, \quad c_i > 0, \lambda_i > 0. \quad (3.19)$$

En injectant (3.19) dans (3.11), on ecrit la convolution comme somme de facteurs :

$$V_t \approx V_0 + \sum_{i=1}^m c_i Y_t^{(i)},$$

avec

$$Y_t^{(i)} := \int_0^t e^{-\lambda_i(t-s)} \kappa(\theta - V_s) ds + \int_0^t e^{-\lambda_i(t-s)} \xi \sqrt{V_s} dW_s^V.$$

Chaque facteur $Y^{(i)}$ satisfait alors une EDS (par differentiation) :

$$dY_t^{(i)} = -\lambda_i Y_t^{(i)} dt + \kappa(\theta - V_t) dt + \xi \sqrt{V_t} dW_t^V. \quad (3.20)$$

On obtient ainsi un systeme markovien en dimension $m+1$ (avec l'etat $(V, Y^{(1)}, \dots, Y^{(m)})$), proche d'un « Heston multi-facteurs ». Cela permet des simulations $O(mn)$ et des methodes de pricing plus standard.

Remarque 3.9 (Pourquoi ce n'est pas qu'un truc numerique). L'approximation (3.19) ne sert pas seulement a simuler. Elle donne aussi une intuition economique : une memoire rough peut etre vue comme la superposition d'un grand nombre d'echelles exponentielles (multi-scale).

3.8.6 Comment choisir (c_i, λ_i) en pratique (idee)

Le choix des taux λ_i et des poids c_i dans (3.19) est un sujet a part entiere, mais on peut retenir une recette simple :

1. **Choisir une grille de taux λ_i .** Souvent, on prend une grille geometrique (log-echelle) qui couvre plusieurs ordres de grandeur entre une echelle courte (liée au pas de temps) et une echelle longue (liée a l'horizon de simulation).
2. **Ajuster les poids c_i .** On minimise une erreur de type moindres carres

$$\min_{c_1, \dots, c_m} \sum_k \left(K_\alpha(t_k) - \sum_{i=1}^m c_i e^{-\lambda_i t_k} \right)^2$$

sur une grille t_k (par exemple uniforme ou log-uniforme).

Intuition : la grille log en λ permet de capturer simultanement le comportement pres de 0 (singularite) et les echelles plus longues. Cette approche relie directement la non-markovianite rough a une superposition de modes mean-reverting.

3.8.7 Calibration : pipeline typique

Une calibration rHeston vise a ajuster des prix (ou volatilités implicites) observes $\sigma_{\text{mkt}}(K, T)$ sur une grille de strikes K et maturites T . Un jeu de parametres typique est :

$$(H, \kappa, \theta, \xi, \rho, V_0).$$

Un pipeline classique :

1. choisir une grille de maturites T et, pour chacune, resoudre (3.16) pour les u requis par la methode de Fourier ;
2. obtenir la fonction caracteristique (3.17) ;
3. pricer les calls via une inversion de Fourier (par exemple Carr–Madan) ;
4. convertir en volatilités implicites, et minimiser un critere du type moindres carres.

3.8.8 Roles des parametres (lecture finance)

- H : controle le comportement tres court terme (rugosite, skew) ;
- ρ : controle l'asymetrie (effet levier) ;
- ξ : controle l'amplitude des fluctuations de variance (vol-of-vol) ;
- κ, θ : controle la reversion moyenne (long terme / term structure) ;
- V_0 : ancre le niveau initial de variance.

Un point pratique : H et ξ peuvent être partiellement substituables sur certaines grilles de données (problème d'identifiabilité), d'où l'intérêt de régulariser et/ou de fixer certains paramètres avec des estimateurs historiques.

3.9 Synthèse : Heston vs rHeston (quoi retenir ?)

On termine la partie « modèle » par une comparaison structurante. L'objectif n'est pas de « vendre » rHeston, mais de comprendre ce qu'il apporte et ce qu'il coûte.

Propriété	Heston	rHeston
Etat	(S_t, V_t)	non markovien (mémoire)
Variance	CIR (EDS locale)	CIR–Volterra (3.11)
Rugosité	type 1/2	paramètre $H < 1/2$
Kernel	$K \equiv 1$	$K_\alpha(t) = t^{\alpha-1}/\Gamma(\alpha)$
Skew court terme	souvent trop plat	échelle (3.14)
Pricing	Riccati (EDO)	Riccati fractionnaire (SVIE)
Simulation	$O(n)$	naïf $O(n^2)$ (accél. possibles)

Quand Heston suffit. Pour des surfaces peu exigeantes à très court terme, ou lorsqu'on privilégie la vitesse et la robustesse (pricing massif, risque en temps réel), Heston reste un excellent compromis. La markovianité et les formules fermées facilitent la mise en production.

Quand rHeston est pertinent. Si la qualité d'ajustement à courte maturité est critique (skew court terme, dynamique du smile), ou si l'on veut une structure compatible avec une volatilité empiriquement « rough », rHeston devient pertinent. On accepte alors un coût numérique plus élevé, compensé par des méthodes accélérées (multi-facteurs, FFT, schémas hybrides).

3.10 Conclusion et pistes

Le mouvement brownien fractionnaire fournit une intuition claire : modifier l'exposant de régularité H modifie profondément la dynamique à court terme. Le modèle rHeston transpose cette intuition dans une volatilité stochastique : on conserve l'esprit de Heston (variance positive, levier, structure affine) mais on remplace l'intégration locale par une convolution fractionnaire.

Pour aller plus loin :

- explorer d'autres modèles rough (rBergomi, SABR–Volterra) ;
- comprendre les techniques numériques accélérées (approximation du noyau par exponentielles, FFT) ;
- étudier les fondements microstructure (limites de Hawkes) qui motivent certaines formes de noyaux.

3.11 Annexe A : intégration fractionnaire et identité Beta/Gamma

On rappelle l'identité Beta :

$$B(\alpha, \beta) = \int_0^1 (1-y)^{\alpha-1} y^{\beta-1} dy = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)}.$$

Elle intervient directement dans la preuve du semigroupe de I^α .

3.12 Annexe B : comment expliquer rHeston en 5 minutes (script d'oral)

1. On veut une volatilité plus rugueuse que dans une diffusion markovienne : régularité $H < 1/2$.
2. Le fBm est le prototype gaussien paramétré par H ; pour $H \neq 1/2$, il n'est pas semimartingale.
3. On utilise donc sa représentation Volterra : « fBm = convolution d'un brownien par un noyau $(t-s)^{H-1/2}$ ».
4. On applique la même idée à la variance de Heston : on remplace l'intégration classique par une convolution fractionnaire K_α .
5. On obtient rHeston : variance Volterra + prix diffusion, et le pricing reste faisable via une Riccati fractionnaire.

3.13 Annexe C : (ouverture) microstructure, Hawkes, et emergence du rough

Cette annexe est une ouverture conceptuelle : elle explique pourquoi un noyau de type puissance peut apparaitre *sans* etre impose a la main. L'idée generale est que des mecanismes microstructurels « auto-excitants » (clustering d'ordres / de transactions) peuvent produire, a l'échelle macroscopique, une volatilité effective a memoire de type Volterra.

C.1. Hawkes en une ligne

Un processus de Hawkes (1D) est un processus ponctuel N_t dont l'intensité depend de son propre passe :

$$\lambda_t = \mu + \int_0^t \varphi(t-s) dN_s,$$

ou φ est un noyau de memoire (souvent decroissant). Chaque evenement augmente temporairement la probabilité d'évenements futurs : c'est l'auto-excitation.

C.2. Regime quasi-critique et loi de puissance

Si le « poids total » de la memoire est proche de 1 (on parle de regime quasi-critique), l'intensité cumulée peut developper des fluctuations a grande echelle et une forme de memoire effective. Lorsque la memoire microstructurelle est lourde (par exemple $\varphi(t) \sim t^{-(1+\beta)}$ a l'infini), certains regimes limites conduisent a des noyaux de type puissance dans des equations integrales continues. De facon tres heuristique :

- microstructure : « les chocs se propagent avec une memoire lente » ;
- limite continue : « le systeme voit une convolution par un noyau puissance ».

C.3. Message pour rHeston

Cette perspective justifie le choix d'un noyau $K_\alpha(t) = t^{\alpha-1}/\Gamma(\alpha)$:

- ce noyau est le plus simple representant d'une memoire en loi de puissance ;
- il genere naturellement une regularité $H = \alpha - \frac{1}{2}$ (rugosité) ;
- il se branche proprement sur un modele de variance de type Heston (mean-reverting + levier).

Conclusion : rHeston peut se lire comme un modele « macro » compatible avec des phenomenes « micro » de clustering, plutot qu'un ajout arbitraire de complexité.

3.14 Annexe D : forward variance, etat fonctionnel, et intuition de « markovianite infinie-dimensionnelle »

Cette annexe donne une autre facon (tres finance) de comprendre la non-markovianite.

D.1. La forward variance comme objet d'etat

On appelle *forward variance* (ou *courbe de variance a terme*) le processus, pour $T \geq t$,

$$\xi_t(T) := \mathbb{E}[V_T \mid \mathcal{F}_t].$$

Pour un modele de volatilité, connaitre $\xi_t(\cdot)$ revient a connaitre comment le marche anticipe la variance future a partir de l'information disponible a t .

D.2. Cas Heston : $\xi_t(T)$ est une fonction explicite de V_t

Dans Heston, par la propriété de Markov de V (CIR), on peut calculer :

$$\xi_t(T) = \theta + (V_t - \theta)e^{-\kappa(T-t)}.$$

Donc toute la courbe $\xi_t(\cdot)$ est determinee par un seul nombre : V_t . On peut dire : « le modele est markovien car l'etat V_t suffit a connaitre les anticipations de variance a toutes maturites ».

D.3. Cas rHeston : $\xi_t(T)$ depend de l'historique

Dans rHeston, V_T depend de l'integrale de Volterra (3.11). Conditionner en t ne se resume plus a conditionner sur V_t : l'historique intervient via la convolution. En consequence, la courbe $\xi_t(\cdot)$ contient (en pratique) bien plus d'information que V_t seul. Une maniere de le dire est :

- Heston : etat fini-dimensionnel (1 variable de variance) ;
- rHeston : etat naturel = une *fonction* (la courbe de forward variance), i.e. un etat infinie-dimensionnel.

D.4. Pourquoi c'est utile en pratique

Beaucoup de methodes de pricing/simulation rough manipulent directement (ou implicitement) cette courbe :

- les approximations multi-facteurs cherchent a représenter $\xi_t(\cdot)$ comme combinaison de quelques exponentielles ;
- les schemes hybrides calculent efficacement les convolutions qui mettent a jour cette courbe au fil du temps.

Au niveau « cours », retez : dans les modeles rough, la bonne variable d'etat n'est plus seulement V_t , mais l'ensemble des anticipations de variance future.

3.15 Mode microscope : SVIE, Riccati–Volterra et approximations

3.15.1 Forme Volterra (idée)

Rough Heston remplace la variance CIR markovienne par une variance à mémoire, typiquement via une équation intégrale :

$$v_t = v_0 + \int_0^t K(t-s)\kappa(\theta - v_s) ds + \int_0^t K(t-s)\xi\sqrt{v_s} dW_s^v,$$

avec un noyau singulier $K(t) \sim t^{H-1/2}$ (roughness $H < 1/2$).

3.15.2 Riccati–Volterra (analogue affine)

Dans Heston, la fonction caractéristique est affine et mène à une Riccati (ODE). Dans rough Heston, on obtient une *Riccati–Volterra* (équation intégrale) : même idée, mais avec mémoire. Numériquement, on résout une équation sur une grille (coût plus élevé).

Sanity check. Quand le noyau se « concentre » (limite vers un delta), on doit retrouver Heston classique : c'est un test de cohérence.

3.15.3 Approximation multi-facteurs (intuition)

Une stratégie consiste à approximer le noyau K par une somme d'exponentielles $K(t) \approx \sum_{j=1}^M w_j e^{-\lambda_j t}$. Alors l'état devient M -dimensionnel et markovien (*lift*), ce qui permet des schémas rapides.

Intuition de marché. En calibration, on choisit M petit mais suffisant : plus M est grand, plus on capture la mémoire, mais plus la calibration est lente.

3.16 Pièges classiques / erreurs fréquentes

- Sous-échantillonnage près de 0 alors que K est singulier : biais.
- Choisir trop peu de facteurs M : mémoire mal approximée, calibration dégradée.
- Instabilités de variance (négativité) : imposer des schémas positifs / projections.

3.17 Checklist — savoir refaire sans regarder

- Écrire la forme Volterra de v_t et interpréter le noyau.
- Discrétiser une convolution stochastique et estimer le coût.
- Expliquer l'approximation multi-facteurs et le lift markovien.
- Proposer des sanity-checks (limites, positivité, stabilité) pour simulation/calibration.

Chapitre 4

Rough Bergomi (rBergomi)

Idée centrale. rBergomi est un modèle rough « calibration-friendly » : (i) une courbe de variance initiale $\xi_0(\cdot)$ en input, (ii) un facteur Volterra rough (Hurst H), (iii) une variance lognormale positive.

Cadre mathématique.

- **Variance.** Typiquement $v_t = \xi_0(t) \exp(\eta W_t^H - \frac{1}{2} \eta^2 t^{2H})$ (lognormalité, $\eta = \text{vol-of-vol}$).
- **Leverage.** Corrélation ρ entre choc prix et choc vol $\Rightarrow$ skew.
- **Roughness.** $H < 1/2 \Rightarrow$ variations rapides à court terme; $H \rightarrow 1/2 \Rightarrow$ Bergomi « classique ».

Intuition marché / interprétation. Le modèle vise d'abord le smile (surtout court terme). Les pièges sont numériques : simulation du facteur rough, coût de convolution, et calibration sensible à H et η .

Implémentation.

- Simulation : générer W^H via représentation Volterra/FFT, puis simuler S conditionnellement à v (schéma log-Euler).
- Calibration : ajuster (H, η, ρ) et ξ_0 (souvent issue du marché via VIX/variance swaps/fit).

Tests / sanity checks.

- Cas limite : $H \rightarrow 1/2$ et/ou $\eta \rightarrow 0$ (retour vers vol plus « lisse »).
- Positivité : $v_t > 0$ par construction; vérifier stabilité numérique (pas d'overflow).
- Ordres de grandeur : skew plus raide quand H diminue (diagnostic de sensibilité).

Pont vers pratique quant. Pont quant : calibration short-maturity smiles, pricing MC rough en production (approximations + variance reduction), et utilisation de ξ_0 comme interface « forward variance » entre données et modèle.

4.1 Avant-propos : rBergomi (rough Bergomi)

rBergomi est un modèle rough de volatilité très utilisé en pratique parce qu'il combine :

- une courbe de variance initiale $\xi_0(\cdot)$ (input de marché);
- un facteur rough (noyau $t^{H-\frac{1}{2}}$);
- une construction lognormale qui garantit la positivité.

Il est souvent vu comme un modèle « orienté calibration » : on vise d'abord la qualité du smile, puis on gère la simulation/pricing.

4.1.1 Objectifs pédagogiques

- Construire le facteur Volterra gaussien et comprendre le rôle de H (roughness).
- Écrire la dynamique de la variance forward et relier ξ_0 à l'information initiale.
- Lire les paramètres (H, η, ρ) : rugosité, vol-of-vol, levier.
- Donner des recettes de simulation et des sanity checks (cas limite $H = \frac{1}{2}$, ordres de grandeur).

4.1.2 Pré-requis

- Volterra/fBm (chapitres 1 and 2) : noyaux et rugosité.
- Culture smile : pourquoi la corrélation ρ pilote le skew.

4.1.3 Plan du chapitre

1. Motivation rough et positionnement par rapport à Heston/rHeston.

2. Définition de rBergomi : facteur Volterra, variance forward, dynamique de S .
3. Propriétés : régularité, cas limite $H = \frac{1}{2}$, lecture des paramètres.
4. Simulation et calibration : points numériques et checks.

Sanity check. Deux repères : (i) $H = \frac{1}{2}$ redonne un facteur brownien (Bergomi « classique »), (ii) quand H est petit, le noyau est singulier près de 0, ce qui amplifie les variations de vol à très court terme et produit un skew raide.

Résumé

Ce cours explique le modèle *rough Bergomi* (rBergomi) de manière progressive, avec un objectif concret : **pouvoir dériver et ré-expliquer** le modèle sans *saut logique*. On suppose le lecteur familier des mouvements browniens fractionnaires (fBm) et du modèle *rough Heston* (rHeston) ; on s'en sert comme point de départ pour motiver la philosophie *Bergomi* : **modéliser directement la variance forward** et non la variance instantanée.

Le coeur du document est une dérivation en quatre actes : (i) définir la variance forward $\xi_t(T) = \mathbb{E}[V_T | \mathcal{F}_t]$, (ii) imposer une dynamique de martingale log-normale (positivité et absence d'arbitrage), (iii) choisir un noyau à singularité de type Volterra pour obtenir la *rugosité* (Hurst $H < \frac{1}{2}$), (iv) déduire la variance instantanée $V_t = \xi_t(t)$ et la dynamique du prix.

On termine par des points pratiques (simulation Monte Carlo, interprétation des paramètres, calibration) et une ouverture vers Heston : comparaison des procédés de volatilité stochastique (Markovien vs non-Markovien, affine vs log-normal, formules semi-fermées vs simulation).

Avant-propos : prérequis, notations, objectif

Public. Étudiants de M1 en finance quantitative (maths post-prépa). On suppose connues :

- les bases du calcul stochastique d'Itô (intégrale, crochets, formule d'Itô) ;
- la notion de mesure risque-neutre et le pricing par espérance conditionnelle ;
- le mouvement brownien fractionnaire (fBm) et ses propriétés de régularité ;
- le modèle rHeston (Volterra/CIR fractionnaire) au moins à un niveau définition.

Objectif pédagogique. Après lecture, vous devez pouvoir :

- expliquer pourquoi rBergomi modélise *la variance forward* plutôt que V_t directement ;
- dériver la formule fermée de $\xi_t(T)$ puis de $V_t = \xi_t(t)$;
- comprendre le rôle des paramètres (H, η, ρ) et de la courbe initiale $\xi_0(\cdot)$;
- comparer rBergomi à (rough) Heston : structure, interprétation, pricing, calibration.

Notations. On se place sur un espace probabilisé filtré $(\Omega, \mathcal{F}, (\mathcal{F}_t)_{t \geq 0}, \mathbb{Q})$ sous la mesure risque-neutre $\mathbb{Q}$. Sauf mention contraire, on suppose taux et dividendes nuls (on travaille avec des prix actualisés). On note :

- S_t le prix du sous-jacent, V_t la variance instantanée (donc $\sqrt{V_t}$ est la volatilité instantanée) ;
- $\xi_t(T)$ la variance *forward* à l'instant t pour l'horizon T ;
- W et B deux browniens corrélés sous $\mathbb{Q}$, avec $\langle W, B \rangle_t = \rho t$;
- $H \in (0, \frac{1}{2})$ le paramètre de Hurst (*roughness*), $\eta > 0$ le *vol-of-vol*, $\rho \in [-1, 1]$ le paramètre de levier.

Idée à retenir dès maintenant. Dans rBergomi, l'objet central n'est pas V_t (variance instantanée) mais la famille $(\xi_t(T))_{T \geq t}$. Le modèle est construit en imposant une dynamique *sans arbitrage* et *positive* pour $\xi_t(T)$, puis en déduisant $V_t = \xi_t(t)$.

4.2 Motivation : pourquoi la volatilité est « rough » ?

4.2.1 Faits stylisés à expliquer

Dans les données (actions, FX, indices), plusieurs observations reviennent :

- le *skew* (asymétrie) de volatilité implicite est très marqué à courte maturité ;
- la volatilité réalisée (ou le log-vol) montre une régularité faible : les trajectoires semblent plus « rugueuses » qu'un modèle à volatilité lisse ;
- les modèles Markoviens classiques (Heston, SABR, ...) ont du mal à reproduire simultanément certaines lois d'échelle à petite maturité.

L'idée de la *rough volatility* est de modéliser un facteur de volatilité dont la régularité est du type fBm avec $H < \frac{1}{2}$. Cela ne veut pas dire « mettre un fBm dans le prix » (ce serait dangereux pour l'absence d'arbitrage), mais plutôt : **faire apparaître un noyau de type Volterra** qui rend le facteur de volatilité très irrégulier.

4.2.2 Pourquoi ne pas mettre directement un fBm dans l'EDS du prix ?

Un point technique essentiel : pour $H \neq \frac{1}{2}$, un fBm n'est pas une semi-martingale. On ne peut pas l'utiliser comme bruit d'une EDS de type Itô sans changer de cadre (intégrales de Young, rough paths, etc.), et l'on s'expose à des problèmes d'arbitrage si l'on modélise directement un prix tradable avec un bruit non semi-martingale. La philosophie rBergomi est différente : on garde des browniens classiques (W, B) , donc un cadre Itô, mais on construit une *fonctionnelle* de B avec un noyau singulier pour injecter la rugosité.

4.2.3 Où se place rBergomi dans la galaxie des modèles ?

- **Heston** : variance V_t suit une diffusion CIR (Markovienne, affine) $\Rightarrow$ pricing semi-fermé par Fourier.
- **rough Heston (rHeston)** : généralise Heston avec un noyau Volterra (non-Markovien) $\Rightarrow$ structure affine à dimension infinie, Riccati fractionnaire.
- **(rough) Bergomi (rBergomi)** : modélise directement la *variance forward* comme exponentielle d'un processus gaussien Volterra $\Rightarrow$ non-Markovien, flexible, simulation naturelle.

Message. rHeston est « Heston + noyau rough » (avec dynamique de type CIR). rBergomi est « Bergomi + noyau rough » (avec variance log-normale conditionnelle). Dans la pratique, rBergomi est souvent choisi comme modèle parcimonieux mais très efficace pour reproduire le skew court terme.

4.3 Cadre général : volatilité stochastique et variance forward

4.3.1 Dynamique de prix sous $\mathbb{Q}$

Dans un modèle à volatilité stochastique (taux 0), on postule souvent :

$$dS_t = S_t \sqrt{V_t} dW_t, \quad S_0 > 0, \quad (4.1)$$

où W est un brownien sous $\mathbb{Q}$ et $V_t \geq 0$ un processus adapté. Par Itô :

$$d \log S_t = -\frac{1}{2} V_t dt + \sqrt{V_t} dW_t. \quad (4.2)$$

Remarque 4.1. On peut réintroduire un taux r et un dividende q en remplaçant l'EDS par $dS_t = (r - q)S_t dt + S_t \sqrt{V_t} dW_t$ et en travaillant avec $e^{-rt}S_t$. La construction rBergomi concerne surtout V_t et *n'est pas modifiée* par cette extension.

4.3.2 Définition de la variance forward

Définition 4.1 (Variance forward). Pour $0 \leq t \leq T$, on définit la variance forward

$$\xi_t(T) := \mathbb{E}[V_T \mid \mathcal{F}_t]. \quad (4.3)$$

La fonction $T \mapsto \xi_t(T)$ (pour $T \geq t$) est la *courbe de variance forward* à la date t .

Proposition 4.1 (Propriété de martingale en t). *Pour tout T fixé, le processus $(\xi_t(T))_{0 \leq t \leq T}$ est une martingale : si $0 \leq s \leq t \leq T$, alors $\mathbb{E}[\xi_t(T) \mid \mathcal{F}_s] = \xi_s(T)$.*

Démonstration. C'est un cas d'application de la tour des espérances conditionnelles : $\mathbb{E}[\xi_t(T) \mid \mathcal{F}_s] = \mathbb{E}[\mathbb{E}[V_T \mid \mathcal{F}_t] \mid \mathcal{F}_s] = \mathbb{E}[V_T \mid \mathcal{F}_s] = \xi_s(T)$. $\square$

4.3.3 Interprétation financière (pourquoi c'est naturel)

Pourquoi $\xi_t(T)$ est-il un objet naturel en finance ? Un *variance swap* sur $[t, T]$ paie (schématiquement) $\int_t^T V_u du$ (ou une variante réalisée). Son prix à la date t implique la quantité

$$\mathbb{E} \left[\int_t^T V_u du \mid \mathcal{F}_t \right] = \int_t^T \mathbb{E}[V_u \mid \mathcal{F}_t] du = \int_t^T \xi_t(u) du, \quad (4.4)$$

où l'on a utilisé Fubini (sous hypothèses techniques standard). Donc la courbe $\xi_t(\cdot)$ est (idéalement) **observable** via les variance swaps (ou via le VIX et des approximations).

Point central. Modéliser $\xi_t(\cdot)$ revient à modéliser directement un objet proche des prix de variance swaps. Cela donne un contrôle fin de la structure à terme de variance, et c'est la philosophie Bergomi.

4.3.4 Du variance swap à $\xi_t(\cdot)$: une relation de moyenne

On introduit le *strike* (théorique) du variance swap sur $[t, T]$:

$$K_{\text{var}}(t, T) := \frac{1}{T-t} \mathbb{E} \left[\int_t^T V_u \, du \mid \mathcal{F}_t \right] = \frac{1}{T-t} \int_t^T \xi_t(u) \, du. \quad (4.5)$$

Autrement dit : le **variance swap observe une moyenne** de la courbe $u \mapsto \xi_t(u)$.

Lecture inverse (formelle). Si l'on connaît $T \mapsto (T-t)K_{\text{var}}(t, T)$ comme fonction régulière, alors on retrouve $\xi_t(T)$ par dérivation :

$$\xi_t(T) = \frac{\partial}{\partial T} \left((T-t)K_{\text{var}}(t, T) \right). \quad (4.6)$$

Cette relation est *formelle* car, sur le marché, on observe des maturités discrètes et des quotes bruitées ; mais elle donne l'intuition : $\xi_t(\cdot)$ est un « objet de première classe ».

4.3.5 Lien avec le VIX : moyenne de la variance forward à 30 jours

Dans de nombreux contextes actions, on travaille avec le VIX (ou des indices analogues). Idéalement, dans un modèle continu, on peut l'interpréter comme une racine d'espérance de variance réalisée à horizon τ (typiquement $\tau \approx 30$ jours) :

$$\text{VIX}_t^2 \approx \frac{1}{\tau} \mathbb{E} \left[\int_t^{t+\tau} V_u \, du \mid \mathcal{F}_t \right] = \frac{1}{\tau} \int_t^{t+\tau} \xi_t(u) \, du. \quad (4.7)$$

Ainsi, à l'instant 0, une courbe de VIX (par maturité) contraint directement des *moyennes* de $\xi_0(\cdot)$.

4.4 Point de départ : Heston et rough Heston (rappel de structure)

4.4.1 Heston : volatilité stochastique Markovienne (procédé CIR)

Dans le modèle de Heston (1993), on prend :

$$dS_t = S_t \sqrt{V_t} \, dW_t, \quad (4.8)$$

$$dV_t = \kappa(\theta - V_t) \, dt + \nu \sqrt{V_t} \, dB_t, \quad (4.9)$$

$$d\langle W, B \rangle_t = \rho \, dt, \quad (4.10)$$

avec $\kappa, \theta, \nu > 0$ et $\rho \in [-1, 1]$. La variance est mean-reverting autour de θ et reste positive (sous des conditions de type Feller).

Forward variance sous Heston. Par les propriétés du CIR (ou via l'EDS et l'espérance conditionnelle), on obtient la formule explicite :

$$\xi_t(T) = \mathbb{E}[V_T \mid \mathcal{F}_t] = \theta + (V_t - \theta) e^{-\kappa(T-t)}. \quad (4.11)$$

La courbe $\xi_t(\cdot)$ est donc une fonction *Markovienne* de V_t .

Dynamique de $\xi_t(T)$ dans Heston (vue « variance forward »). Le point suivant fait le lien direct avec la philosophie Bergomi. Pour T fixé, on peut dériver l'EDS de $\xi_t(T)$ à partir de celle de V_t . En effet, pour T constant, $\xi_t(T) = \theta + (V_t - \theta)e^{-\kappa(T-t)}$ et une application d'Itô (ou une dérivation directe) donne

$$d\xi_t(T) = \nu e^{-\kappa(T-t)} \sqrt{V_t} \, dB_t, \quad 0 \leq t \leq T. \quad (4.12)$$

Donc, dans Heston aussi, la variance forward (pour T fixé) est une **martingale** entraînée par B . La différence avec Bergomi/rBergomi est que le coefficient de diffusion dépend de $\sqrt{V_t}$ (donc est aléatoire) et que la structure à terme décroît exponentiellement en $T-t$.

Remarque 4.2. Heston est *affine* : les fonctions caractéristiques de $(\log S_T, V_T)$ sont (semi-)fermées, ce qui rend le pricing très efficace (Fourier). Ce point changera radicalement dans rBergomi.

4.4.2 rHeston : noyau Volterra et mean-reversion « rough »

Dans rough Heston, on introduit un noyau K (typiquement $K(t) = t^{H-\frac{1}{2}}/\Gamma(H + \frac{1}{2})$ ou une constante fois $t^{H-\frac{1}{2}}$) et la variance vérifie une équation de type Volterra (forme indicative) :

$$V_t = V_0 + \int_0^t K(t-s) \kappa(\theta - V_s) ds + \int_0^t K(t-s) \nu \sqrt{V_s} dB_s. \quad (4.13)$$

Le noyau $K(t-s)$ rend la dynamique **non-Markovienne** et confère au processus une régularité de type $H < \frac{1}{2}$.

Pourquoi ce rappel ? Parce que rBergomi utilise aussi un noyau de type $t^{H-\frac{1}{2}}$, mais **le met à un autre endroit** :

- dans rHeston, le noyau intervient dans l'équation (mean-reversion + diffusion $\sqrt{V}$) de V ;
- dans rBergomi, le noyau intervient dans la *dynamique de la variance forward* et la variance est une exponentielle d'un facteur gaussien.

4.5 Le « truc » Bergomi : modéliser directement $\xi_t(T)$

4.5.1 Contrainte sans arbitrage : $\xi_t(T)$ doit être une martingale

On a déjà montré que, par définition, $\xi_t(T) = \mathbb{E}[V_T \mid \mathcal{F}_t]$ est une martingale en t . Si l'on souhaite *postuler* une dynamique pour $\xi_t(T)$, on doit respecter cette contrainte.

Principe. Pour chaque T fixé, on veut une EDS du type

$$d\xi_t(T) = \alpha_t(T) dt + \beta_t(T) dB_t \quad \text{sur } [0, T], \quad (4.14)$$

et la condition « $\xi_t(T)$ est une martingale » impose $\alpha_t(T) = 0$ (sous intégrabilité). On cherche donc une *dynamique purement martingale* :

$$d\xi_t(T) = \beta_t(T) dB_t. \quad (4.15)$$

4.5.2 Choix structurel : volatilité proportionnelle (log-normalité)

Dans l'esprit Bergomi, on choisit une volatilité proportionnelle :

$$d\xi_t(T) = \xi_t(T) \nu(t, T) dB_t, \quad 0 \leq t \leq T, \quad (4.16)$$

où $\nu(t, T)$ est une fonction déterministe (ou au moins prévisible) appelée *vol-of-vol* de la forward variance.

Proposition 4.2 (Solution explicite de (4.16)). *Pour T fixé, la solution est*

$$\xi_t(T) = \xi_0(T) \exp\left(\int_0^t \nu(s, T) dB_s - \frac{1}{2} \int_0^t \nu(s, T)^2 ds\right). \quad (4.17)$$

En particulier, $\xi_t(T) > 0$ presque sûrement.

Démonstration. C'est la formule de Doleans–Dade (ou Itô sur $\log \xi_t(T)$). □

Remarque 4.3. Le terme $-\frac{1}{2} \int_0^t \nu^2$ est exactement ce qui garantit $\mathbb{E}[\xi_t(T)] = \xi_0(T)$ lorsque $\nu(\cdot, T)$ est déterministe, donc la propriété de martingale.

4.5.3 Où est la rugosité ? Dans le choix du noyau $\nu(t, T)$

On a construit une famille de martingales log-normales. Il reste à choisir *comment* la forward variance réagit à l'innovation dB_t lorsque T est proche de t .

Le point clé empirique est un *skew* extrêmement raide à très courte maturité. Le choix rBergomi consiste à mettre une **singularité intégrable** en $T - t$:

$$\nu(t, T) = \eta \sqrt{2H} (T - t)^{H-\frac{1}{2}}, \quad H \in (0, \frac{1}{2}), \quad \eta > 0. \quad (4.18)$$

Ce noyau explose quand $T \downarrow t$, mais de manière intégrable car $2H - 1 > -1$.

Intuition. Lorsque T est très proche de t , le terme $(T - t)^{H-\frac{1}{2}}$ est grand (car $H - \frac{1}{2} < 0$). Donc la *forward variance à très courte maturité* bouge beaucoup à chaque choc dB_t . Cette amplification locale est un ingrédient-clé pour obtenir le skew court terme.

4.6 Interlude : exponentielles stochastiques et loi de $\xi_t(T)$

4.6.1 Pourquoi la correction $-\frac{1}{2} \int \nu^2$ est-elle inévitable ?

Le modèle (4.16) est une EDS multiplicative. Le bon réflexe est de passer au logarithme. Posons $Y_t(T) := \log \xi_t(T)$. Par la formule d'Itô,

$$dY_t(T) = \nu(t, T) dB_t - \frac{1}{2} \nu(t, T)^2 dt. \quad (4.19)$$

Le terme $-\frac{1}{2} \nu^2 dt$ n'est pas un « choix » : c'est le terme Itô associé à $(dB_t)^2 = dt$. Sans lui, $\xi_t(T)$ ne serait pas une martingale (et la condition sans arbitrage serait violée).

4.6.2 Loi (non conditionnelle) : $\xi_t(T)$ est log-normale

Si $\nu(\cdot, T)$ est déterministe, alors l'intégrale gaussienne $\int_0^t \nu(s, T) dB_s$ est centrée et de variance $A_t(T) := \int_0^t \nu(s, T)^2 ds$. Donc

$$\log \xi_t(T) \sim \mathcal{N}\left(\log \xi_0(T) - \frac{1}{2} A_t(T), A_t(T)\right), \quad \xi_t(T) > 0. \quad (4.20)$$

Cette lecture est utile pour deux raisons :

- **positivité** automatique (pas besoin de contraintes de type Feller) ;
- **contrôle explicite** de la dispersion via $A_t(T)$, donc via le noyau ν .

4.6.3 Loi conditionnelle : la famille $(\xi_t(T))_{t \leq T}$ est une martingale log-normale

Pour $0 \leq s \leq t \leq T$, on peut écrire

$$\log \xi_t(T) = \log \xi_s(T) + \int_s^t \nu(u, T) dB_u - \frac{1}{2} \int_s^t \nu(u, T)^2 du. \quad (4.21)$$

Comme les incréments browniens sont indépendants de $\mathcal{F}_s$ et que ν est déterministe, on obtient une loi conditionnelle *explicite* :

$$\log \xi_t(T) \mid \mathcal{F}_s \sim \mathcal{N}\left(\log \xi_s(T) - \frac{1}{2} (A_t(T) - A_s(T)), A_t(T) - A_s(T)\right). \quad (4.22)$$

C'est une manière concrète de voir la propriété de martingale : la « correction » moyenne compense exactement l'augmentation de variance.

4.6.4 Corrélations entre maturités : la géométrie du noyau

Pour T_1, T_2 fixés, les deux processus $\log \xi_t(T_1)$ et $\log \xi_t(T_2)$ sont entraînés par le *même* brownien B . Ils sont donc corrélés, avec covariance

$$\text{Cov}(\log \xi_t(T_1), \log \xi_t(T_2)) = \int_0^t \nu(s, T_1) \nu(s, T_2) ds. \quad (4.23)$$

La forme de ν détermine donc directement les corrélations entre maturités (et donc la dynamique de la surface de volatilité implicite).

4.7 Dérivation pas à pas du modèle rBergomi

Cette section est le coeur du cours : elle donne une « recette » que vous devez pouvoir réciter et justifier.

4.7.1 Étape 1 : définir la courbe initiale $\xi_0(T)$

Entrée de marché. On fixe une fonction déterministe $T \mapsto \xi_0(T)$, positive, qui représente la structure à terme initiale de variance (extrait de variance swaps, de VIX, ou de la surface d'options).

Remarque 4.4. Différence importante avec Heston/rHeston : dans ces modèles, la structure à terme de $\mathbb{E}[V_T]$ est imposée par $(V_0, \kappa, \theta, \dots)$. Dans Bergomi/rBergomi, on **force** le modèle à coller à ξ_0 exactement.

4.7.2 Étape 2 : postuler une dynamique de martingale log-normale pour $\xi_t(T)$

On impose (4.16) avec ν déterministe :

$$d\xi_t(T) = \xi_t(T) \nu(t, T) dB_t. \quad (4.24)$$

La solution est donnée par (4.17).

4.7.3 Étape 3 : choisir le noyau « rough » (4.18)

On pose :

$$\nu(t, T) = \eta \sqrt{2H} (T - t)^{H-\frac{1}{2}}.$$

Alors, pour $0 \leq t \leq T$:

$$\int_0^t \nu(s, T)^2 ds = \eta^2 \int_0^t 2H (T - s)^{2H-1} ds = \eta^2 (T^{2H} - (T - t)^{2H}). \quad (4.25)$$

On obtient donc une formule explicite pour la forward variance :

$$\xi_t(T) = \xi_0(T) \exp\left(\eta \sqrt{2H} \int_0^t (T - s)^{H-\frac{1}{2}} dB_s - \frac{1}{2} \eta^2 (T^{2H} - (T - t)^{2H})\right). \quad (4.26)$$

4.7.4 Étape 4 : déduire la variance instantanée $V_t = \xi_t(t)$

On définit le processus de variance instantanée par

$$V_t := \xi_t(t). \quad (4.27)$$

En posant $T = t$ dans (4.26), on obtient :

$$V_t = \xi_0(t) \exp\left(\eta \sqrt{2H} \int_0^t (t - s)^{H-\frac{1}{2}} dB_s - \frac{1}{2} \eta^2 t^{2H}\right). \quad (4.28)$$

4.7.5 Étape 5 : définir le facteur gaussien Volterra

Définition 4.2 (Processus de Volterra de rBergomi). On définit

$$\mathcal{V}_t := \sqrt{2H} \int_0^t (t - s)^{H-\frac{1}{2}} dB_s, \quad H \in (0, \frac{1}{2}). \quad (4.29)$$

Alors (4.28) s'écrit simplement

$$V_t = \xi_0(t) \exp\left(\eta \mathcal{V}_t - \frac{1}{2} \eta^2 \text{Var}(\mathcal{V}_t)\right). \quad (4.30)$$

Proposition 4.3 (Variance de $\mathcal{V}_t$). On a $\text{Var}(\mathcal{V}_t) = t^{2H}$.

Démonstration. Par isométrie de l'intégrale d'Itô :

$$\text{Var}(\mathcal{V}_t) = 2H \int_0^t (t - s)^{2H-1} ds = 2H \int_0^t u^{2H-1} du = t^{2H}.$$

□

Remarque 4.5 (Lien avec le fBm). Le processus $\mathcal{V}$ est un processus gaussien continu de type Volterra (souvent appelé *Riemann–Liouville fBm*). Il a la même auto-similarité et la même régularité locale qu'un fBm de paramètre H (régularité Hölder $H - \varepsilon$), mais n'a pas exactement les mêmes propriétés globales qu'un fBm standard (en particulier, les incréments ne sont pas stationnaires). Ce qui compte ici est l'*ordre de rugosité* contrôlé par H .

4.7.6 Étape 6 : définir la dynamique du prix avec effet de levier

On introduit un brownien W corrélé à B :

$$d\langle W, B \rangle_t = \rho dt. \quad (4.31)$$

Le modèle rBergomi complet est alors :

$$dS_t = S_t \sqrt{V_t} dW_t, \quad (4.32)$$

$$V_t = \xi_0(t) \exp\left(\eta \mathcal{V}_t - \frac{1}{2} \eta^2 t^{2H}\right), \quad (4.33)$$

$$\mathcal{V}_t = \sqrt{2H} \int_0^t (t - s)^{H-\frac{1}{2}} dB_s. \quad (4.34)$$

Recette rBergomi (version à apprendre).

1. Fixer la courbe initiale $\xi_0(T) = \mathbb{E}[V_T]$.
2. Modéliser $\xi_t(T)$ comme martingale log-normale : $d\xi_t(T) = \xi_t(T)\nu(t, T)dB_t$.
3. Choisir $\nu(t, T) = \eta\sqrt{2H}(T-t)^{H-\frac{1}{2}}$.
4. Poser $V_t = \xi_t(t)$.
5. Définir S par $dS_t = S_t\sqrt{V_t}dW_t$ avec $\text{Corr}(W, B) = \rho$.

4.8 Le facteur rough en détail : processus de Volterra et lien fBm

4.8.1 Auto-similarité : le bon ordre d'échelle est t^H

Le processus $\mathcal{V}_t = \sqrt{2H} \int_0^t (t-s)^{H-\frac{1}{2}} dB_s$ est gaussien centré, et sa variance vaut t^{2H} . Cela signifie que l'ordre de grandeur naturel de $\mathcal{V}_t$ est t^H .

Proposition 4.4 (Auto-similarité en loi). *Pour tout $c > 0$, on a l'égalité en loi*

$$(\mathcal{V}_{ct})_{t \geq 0} \stackrel{d}{=} (c^H \mathcal{V}_t)_{t \geq 0}. \quad (4.35)$$

Démonstration. Par changement de variable $s = cu$ et la propriété d'échelle du brownien $B_{cu} \stackrel{d}{=} \sqrt{c} B_u$,

$$\mathcal{V}_{ct} = \sqrt{2H} \int_0^{ct} (ct-s)^{H-\frac{1}{2}} dB_s \stackrel{d}{=} \sqrt{2H} \int_0^t (c(t-u))^{H-\frac{1}{2}} \sqrt{c} dB_u = c^H \mathcal{V}_t.$$

□

4.8.2 Covariance : un processus gaussien à mémoire (non-stationnaire)

Pour $s, t \geq 0$, par isométrie d'Itô,

$$\text{Cov}(\mathcal{V}_t, \mathcal{V}_s) = 2H \int_0^{t \wedge s} (t-u)^{H-\frac{1}{2}} (s-u)^{H-\frac{1}{2}} du. \quad (4.36)$$

La covariance dépend de (s, t) de manière non triviale, ce qui illustre une **mémoire** : $\mathcal{V}_t$ est une fonctionnelle de tout le passé de B avec des poids $(t-s)^{H-\frac{1}{2}}$.

Remarque 4.6 (Attention : pas un fBm standard). Un fBm standard B^H a une covariance $\frac{1}{2}(t^{2H} + s^{2H} - |t-s|^{2H})$ et des incréments stationnaires. La formule (4.36) ne coïncide pas avec cette covariance en général : $\mathcal{V}$ est souvent appelé *Riemann–Liouville fBm* ou *processus gaussien de Volterra*. L'intérêt de $\mathcal{V}$ est sa simplicité (noyau pur $u^{H-\frac{1}{2}}$) et son comportement local à petite échelle, qui reproduit la rugosité observée.

4.8.3 Régularité (roughness) : trajectoires Hölder $H - \varepsilon$

Le lecteur connaît déjà le fait suivant pour le fBm ; il reste valable ici : lorsque $H < \frac{1}{2}$, les trajectoires sont très irrégulières.

Proposition 4.5 (Régularité Hölder (intuition)). *Pour tout $\varepsilon > 0$, les trajectoires de $\mathcal{V}$ sont presque sûrement Hölder d'ordre $H - \varepsilon$ sur tout compact, et ne sont pas Hölder d'ordre $H + \varepsilon$.*

Idée de preuve (niveau M1). On contrôle les incréments en L^2 . Un calcul direct donne, pour $h > 0$,

$$\text{Var}(\mathcal{V}_{t+h} - \mathcal{V}_t) = 2H \int_0^t \left((t+h-u)^{H-\frac{1}{2}} - (t-u)^{H-\frac{1}{2}} \right)^2 du + 2H \int_t^{t+h} (t+h-u)^{2H-1} du. \quad (4.37)$$

Le deuxième terme vaut exactement h^{2H} , ce qui fixe l'échelle des incréments. On en déduit que les incréments sont typiquement d'ordre h^H , puis on applique un argument standard (Kolmogorov) pour obtenir la régularité Hölder.

4.8.4 Conséquence pour la log-variance

Dans rBergomi,

$$\log V_t = \log \xi_0(t) + \eta \mathcal{V}_t - \frac{1}{2} \eta^2 t^{2H}. \quad (4.38)$$

Ainsi, la **rugosité** de $\log V$ est celle de $\mathcal{V}$. Lorsque H est petit (typiquement ≈ 0.1 en pratique), $\log V$ varie rapidement à très court terme : c'est exactement ce qu'on veut capturer.

4.9 Vérifications rapides : positivité, $\mathbb{E}[V_t]$, cas limite

4.9.1 Positivité et valeur moyenne : $\mathbb{E}[V_t] = \xi_0(t)$

La forme exponentielle garantit $V_t > 0$ p.s. De plus, comme $\eta\mathcal{V}_t$ est gaussien centré, on a :

$$\mathbb{E} \left[\exp \left(\eta\mathcal{V}_t - \frac{1}{2}\eta^2 t^{2H} \right) \right] = 1, \quad (4.39)$$

donc

$$\mathbb{E}[V_t] = \xi_0(t). \quad (4.40)$$

4.9.2 Quel est le sens de ξ_0 en pratique ?

Deux lectures utiles :

- **Lecture probabiliste** : $\xi_0(t)$ est l'espérance de la variance instantanée à horizon t .
- **Lecture de marché** : $\int_0^T \xi_0(u) du$ est lié au prix (ou strike) d'un variance swap à maturité T .

Exemple : si l'on veut une structure simple. On peut choisir par exemple une structure exponentielle :

$$\xi_0(t) = \theta + (v_0 - \theta)e^{-\kappa t}, \quad (4.41)$$

qui coïncide avec $\mathbb{E}[V_t]$ dans Heston (et donne une « ouverture » naturelle entre les modèles). Mais rBergomi permet en principe de prendre une ξ_0 arbitraire issue du marché.

4.9.3 Un cas limite important : $H = \frac{1}{2}$ (Bergomi classique)

Si $H = \frac{1}{2}$, alors $(T - t)^{H - \frac{1}{2}} = (T - t)^0 = 1$ et la dynamique (4.16) devient

$$d\xi_t(T) = \eta \xi_t(T) dB_t,$$

donc $\xi_t(T)$ est log-normale avec un brownien standard. C'est le *modèle (classique) de Bergomi* : rBergomi est son extension « rough » obtenue en prenant $H < \frac{1}{2}$.

4.10 Interprétation des paramètres et impact sur le smile

4.10.1 Le paramètre ρ : effet de levier (skew)

Le paramètre ρ contrôle la corrélation entre les chocs de prix (dW_t) et les chocs de volatilité (dB_t).

- $\rho < 0$ (*leverage*) : une baisse de prix tend à augmenter la variance, ce qui produit un skew négatif (smile penché).
- $\rho = 0$: smile plus symétrique, moins de skew.
- $\rho > 0$: configuration plus rare sur actions, mais possible sur certains sous-jacents.

4.10.2 Le paramètre η : amplitude du « vol-of-vol »

Le paramètre η mesure l'échelle des fluctuations du facteur $\mathcal{V}_t$. En première approximation, augmenter η augmente la courbure globale du smile et l'écart entre vols implicites ITM/OTM.

4.10.3 Le paramètre H : rugosité et scaling court terme

Le paramètre H contrôle la régularité des trajectoires de $\mathcal{V}_t$: plus H est petit, plus c'est rugueux.

Heuristique de scaling. Pour de petits incréments de temps h , on a typiquement

$$\text{Var}(\mathcal{V}_{t+h} - \mathcal{V}_t) \approx C(t) h^{2H} \quad (\text{localement}). \quad (4.42)$$

Donc les incréments sont d'ordre h^H : lorsque $H < \frac{1}{2}$, c'est « plus gros » que le cas d'un facteur lisse. Ce phénomène se traduit en (très) courte maturité par un skew qui varie comme une puissance de τ (temps à maturité).

Remarque 4.7 (Fait connu). Dans les modèles rough, le skew at-the-money à petite maturité se comporte souvent comme $\tau^{H - \frac{1}{2}}$: quand $H < \frac{1}{2}$, cela explose quand $\tau \downarrow 0$, ce qui correspond aux observations empiriques. Ce cours ne démontre pas ce résultat, mais la présence de $(T - t)^{H - \frac{1}{2}}$ dans (4.18) en donne l'intuition.

4.11 Smile, skew et asymptotiques court terme : une lecture à savoir expliquer

4.11.1 Volatilité implicite : définition et surface

Pour une option européenne de maturité T et de strike K , on note $C^{\text{mkt}}(K, T)$ son prix de marché. La volatilité implicite $\sigma_{\text{impl}}(K, T)$ est définie comme l'unique $\sigma \geq 0$ (quand elle existe) telle que

$$C_{\text{BS}}(S_0, K, T, \sigma_{\text{impl}}(K, T)) = C^{\text{mkt}}(K, T), \quad (4.43)$$

où C_{BS} est le prix de Black-Scholes à taux 0. La fonction $(K, T) \mapsto \sigma_{\text{impl}}(K, T)$ est la *surface* de volatilité implicite. Le *smile* est la coupe en K pour T fixé.

4.11.2 Smile comme mélange de normales : pourquoi il apparaît dès qu'on rend la volatilité aléatoire

Dans un modèle de volatilité stochastique de type $d \log S_t = -\frac{1}{2}V_t dt + \sqrt{V_t} dW_t$, si l'on conditionne par rapport à la trajectoire de V (ou, plus grossièrement, à la variance intégrée $I = \int_0^T V_s ds$), on obtient une loi gaussienne pour le rendement. En déconditionnant, on obtient un **mélange** de lois normales/log-normales, qui produit une distribution plus leptokurtique qu'une normale et donc un smile de volatilité implicite.

Cas $\rho = 0$: sourire sans skew. Quand $\rho = 0$, le bruit qui pilote V est indépendant du bruit qui pilote S . Le mélange est alors (heuristiquement) *symétrique* en log-moneyness : on obtient un smile (convexité) mais peu d'asymétrie.

4.11.3 Skew : le rôle de l'effet de levier $\rho < 0$

Le skew (asymétrie du smile) vient principalement de la corrélation négative entre retours et volatilité (*leverage effect*). Quand $\rho < 0$, une baisse de S est associée à une hausse de V , ce qui augmente la probabilité de mouvements extrêmes à la baisse et accentue la volatilité implicite du côté put (OTM à gauche).

4.11.4 Pourquoi le « rough » renforce le court terme

Le fait empirique à capturer est : le skew à très courte maturité est *très raide*. Dans les modèles Markoviens classiques (comme Heston), le skew à petite maturité reste typiquement *borné* (ou varie lentement). Dans les modèles rough, on observe au contraire un comportement en puissance :

$$\text{Skew ATM}(\tau) \approx c \tau^{H-\frac{1}{2}} \quad (\tau \downarrow 0), \quad (4.44)$$

avec $H < \frac{1}{2}$, donc une divergence quand $\tau \rightarrow 0$.

Où est la puissance $\tau^{H-\frac{1}{2}}$ dans rBergomi ? Elle est directement encodée dans le noyau de vol-of-vol de la forward variance : $\nu(t, T) = \eta \sqrt{2H}(T-t)^{H-\frac{1}{2}}$. Pour T proche de t , ce facteur est grand, donc la forward variance à court terme est très sensible aux chocs instantanés. On peut donner une lecture intuitive :

- un choc dB_t produit une variation relative de $\xi_t(T)$ d'ordre $\nu(t, T)dB_t$;
- quand $T - t = \tau$ est petit, $\nu(t, T)$ est d'ordre $\tau^{H-\frac{1}{2}}$;
- donc l'impact sur le smile est amplifié à court terme.

Pour un exemple chiffré : si $H = 0.1$, alors $H - \frac{1}{2} = -0.4$ et l'on obtient un effet de type $\tau^{-0.4}$.

4.12 Lien conceptuel avec rHeston : que gagne-t-on, que perd-t-on ?

4.12.1 Comparaison structurelle : variance vs forward variance

- **rHeston** : on postule une dynamique (Volterra) pour V_t lui-même, avec diffusion $\sqrt{V}$ et mean-reversion.
- **rBergomi** : on postule une dynamique (martingale log-normale) pour $\xi_t(T)$, puis V_t est déduit comme $V_t = \xi_t(t)$.

Cette différence a deux conséquences pratiques :

1. rBergomi force le fit de la structure à terme initiale ξ_0 .
2. rBergomi est conceptuellement plus simple (facteur gaussien), mais perd l'affinité et donc les formules de type Fourier.

4.12.2 Une lecture « approximation log-normale » de rHeston

Sans entrer dans une dérivation lourde, retenons l'intuition suivante :

- dans rHeston, la forward variance $\xi_t(T) = \mathbb{E}[V_T | \mathcal{F}_t]$ est un objet compliqué mais bien défini ;
 - rBergomi propose une loi simple (log-normale) et *rough* pour $\xi_t(T)$, calibrable, qui capture les bons scalings.
- On peut donc voir rBergomi comme un modèle « phénoménologique » de la dynamique de forward variance compatible avec la roughness que rHeston impose à V .

4.12.3 Mean-reversion : absente de base dans rBergomi

Dans Heston/rHeston, V_t a une force de rappel (mean-reversion). Dans rBergomi, à paramètres fixés, V_t n'a pas de mean-reversion structurelle : c'est $\xi_0(t)$ qui encode la structure à terme moyenne.

Remarque 4.8. Si l'on veut introduire de la mean-reversion, il existe des extensions (multi-facteurs, choix de ξ_0 , etc.). Dans ce cours, on se concentre sur le rBergomi « canonique » (3 paramètres + courbe ξ_0).

4.13 Simulation Monte Carlo de rBergomi (pratique)

4.13.1 Objectif : simuler (S_{t_k}, V_{t_k}) sur une grille

On choisit une grille $0 = t_0 < t_1 < \dots < t_N = T$ (souvent uniforme : $t_k = k\Delta t$). Le pricing d'une option européenne se fait par

$$\text{Prix} = \mathbb{E}_{\mathbb{Q}}[(S_T - K)^+] \quad (4.45)$$

approché par Monte Carlo.

4.13.2 Simulation de la corrélation

On peut représenter B comme combinaison de deux browniens indépendants W et $W^\perp$:

$$B_t = \rho W_t + \sqrt{1 - \rho^2} W_t^\perp. \quad (4.46)$$

Ainsi, en discrétisant :

$$\Delta W_k := W_{t_{k+1}} - W_{t_k} \sim \mathcal{N}(0, \Delta t), \quad (4.47)$$

$$\Delta W_k^\perp \sim \mathcal{N}(0, \Delta t) \text{ indépendant}, \quad (4.48)$$

$$\Delta B_k := \rho \Delta W_k + \sqrt{1 - \rho^2} \Delta W_k^\perp. \quad (4.49)$$

4.13.3 Approximation de l'intégrale de Volterra (convolution)

La quantité à simuler est

$$\mathcal{V}_{t_k} = \sqrt{2H} \int_0^{t_k} (t_k - s)^{H-\frac{1}{2}} dB_s. \quad (4.50)$$

Une discrétisation simple consiste à approcher l'intégrale par une somme :

$$\mathcal{V}_{t_k} \approx \sqrt{2H} \sum_{j=0}^{k-1} (t_k - t_j)^{H-\frac{1}{2}} \Delta B_j, \quad k = 1, \dots, N, \quad (4.51)$$

avec $\Delta B_j = B_{t_{j+1}} - B_{t_j}$.

Remarque 4.9. L'approximation (4.51) est volontairement simple pour la pédagogie. En pratique, on utilise souvent des schémas hybrides (Bennedsen–Lunde–Pakkanen) ou des méthodes FFT pour accélérer la convolution et améliorer la précision. Mais l'idée reste : **un noyau $\times$ des incréments browniens**.

4.13.4 Simulation de la variance et du log-prix

Une fois $\mathcal{V}_{t_k}$ construit, on obtient

$$V_{t_k} = \xi_0(t_k) \exp\left(\eta \mathcal{V}_{t_k} - \frac{1}{2} \eta^2 t_k^{2H}\right). \quad (4.52)$$

Puis on simule le log-prix par un schéma d'Euler pour $d \log S_t = -\frac{1}{2} V_t dt + \sqrt{V_t} dW_t$:

$$\log S_{t_{k+1}} = \log S_{t_k} - \frac{1}{2} V_{t_k} \Delta t + \sqrt{V_{t_k}} \Delta W_k. \quad (4.53)$$

4.13.5 Astuce de pricing : intégrer analytiquement le bruit indépendant (réduction de variance)

Pour le pricing de vanilles, on peut souvent améliorer fortement le Monte Carlo en utilisant une décomposition des browniens. Écrivons

$$W_t = \rho B_t + \sqrt{1 - \rho^2} W_t^\perp, \quad (4.54)$$

où $W^\perp$ est un brownien indépendant de B . Alors

$$\log S_T = \log S_0 - \frac{1}{2} \int_0^T V_s ds + \rho \int_0^T \sqrt{V_s} dB_s + \sqrt{1 - \rho^2} \int_0^T \sqrt{V_s} dW_s^\perp. \quad (4.55)$$

Conditionnellement à la trajectoire de B (donc à la trajectoire de V), le dernier terme est gaussien centré de variance $(1 - \rho^2) \int_0^T V_s ds$. Posons donc

$$I := \int_0^T V_s ds, \quad J := \int_0^T \sqrt{V_s} dB_s. \quad (4.56)$$

On peut réécrire (4.55) sous la forme

$$\log S_T = \log \left(S_0 e^{\rho J - \frac{1}{2} \rho^2 I} \right) - \frac{1}{2} (1 - \rho^2) I + \sqrt{(1 - \rho^2) I} Z, \quad Z \sim \mathcal{N}(0, 1) \text{ indépendant de } B. \quad (4.57)$$

Ainsi, conditionnellement à B , S_T suit une loi log-normale de type Black–Scholes avec :

- **spot conditionnel** $S_0^* := S_0 e^{\rho J - \frac{1}{2} \rho^2 I}$;
- **variance totale conditionnelle** $\Sigma^2 := (1 - \rho^2) I$.

Pour une option call européenne (taux 0), on en déduit la formule *conditionnelle* :

$$\mathbb{E}[(S_T - K)^+ | B] = C_{BS}(S_0^*, K, \Sigma), \quad (4.58)$$

où $C_{BS}(S, K, \Sigma)$ désigne la formule de Black–Scholes à maturité 1 et à volatilité totale Σ (ou, de manière équivalente, une maturité T et une volatilité σ telles que $\sigma^2 T = \Sigma^2$). Le prix s'obtient alors par une espérance à **plus faible variance** :

$$\text{Prix} = \mathbb{E} \left[C_{BS}(S_0 e^{\rho J - \frac{1}{2} \rho^2 I}, K, \sqrt{(1 - \rho^2) I}) \right], \quad (4.59)$$

où il ne reste qu'à simuler B (et donc V), puis à calculer I et J sur la grille.

4.13.6 Pseudo-code minimal (1 trajectoire)

Entrées : S_0 , grille (t_k) , paramètres (H, η, ρ) , courbe $\xi_0(\cdot)$.
1. Simuler $\Delta W_k, \Delta W_k^\perp \sim \mathcal{N}(0, \Delta t)$ indépendants.
2. Poser $\Delta B_k = \rho \Delta W_k + \sqrt{1 - \rho^2} \Delta W_k^\perp$.
3. Pour chaque k , calculer $\mathcal{V}_{t_k}$ via (4.51).
4. Poser $V_{t_k} = \xi_0(t_k) \exp(\eta \mathcal{V}_{t_k} - \frac{1}{2} \eta^2 t_k^{2H})$.
5. Propager $\log S$ via (4.53).
Sortie : S_T et payoff $(S_T - K)^+$.

4.14 Accélération et extensions : approximations markoviennes (multi-facteurs)

4.14.1 Pourquoi chercher une approximation markovienne ?

Le caractère non-Markovien de rBergomi est une force (mémoire, rugosité), mais il a un coût :

- la simulation naïve de $\mathcal{V}_{t_k}$ est une convolution de coût $O(N^2)$;
- le hedging et les sensibilités peuvent demander des schémas adjoints ou des techniques de différentiation automatique sur des trajectoires entières ;
- les PDE/FFT classiques ne s'appliquent pas directement.

Une idée standard est donc de **markovianiser** le noyau : approcher la mémoire par un nombre fini de facteurs Markoviens.

4.14.2 Approcher le noyau $u^{H-\frac{1}{2}}$ par une somme d'exponentielles

Le noyau rBergomi est de la forme $g(u) = u^{H-\frac{1}{2}}$ pour $u > 0$. Pour $H \in (0, \frac{1}{2})$, g est (au sens large) une fonction « complètement monotone » et possède une représentation de type transformée de Laplace :

$$g(u) = \int_0^{+\infty} e^{-xu} \mu(dx) \quad (4.60)$$

pour une mesure μ (non nécessairement finie). En pratique, on remplace cette intégrale par une quadrature :

$$g(u) \approx \sum_{i=1}^m w_i e^{-x_i u}, \quad w_i > 0, \quad x_i > 0. \quad (4.61)$$

Cette approximation est d'autant meilleure que m est grand et que les points (x_i, w_i) sont bien choisis (quadratures, optimisation, etc.).

4.14.3 Conséquence : somme de facteurs OU

Insérons (4.61) dans le processus de Volterra :

$$\mathcal{V}_t = \sqrt{2H} \int_0^t g(t-s) dB_s \approx \sqrt{2H} \sum_{i=1}^m w_i \int_0^t e^{-x_i(t-s)} dB_s.$$

On définit donc m facteurs

$$Y_t^{(i)} := \int_0^t e^{-x_i(t-s)} dB_s, \quad i = 1, \dots, m. \quad (4.62)$$

Alors $\mathcal{V}_t \approx \sqrt{2H} \sum_{i=1}^m w_i Y_t^{(i)}$. Or chaque $Y^{(i)}$ satisfait une EDS d'Ornstein–Uhlenbeck :

$$dY_t^{(i)} = -x_i Y_t^{(i)} dt + dB_t, \quad Y_0^{(i)} = 0. \quad (4.63)$$

On obtient ainsi un **système Markovien de dimension finie** : l'état est $(S_t, Y_t^{(1)}, \dots, Y_t^{(m)})$. La variance est ensuite donnée par

$$V_t \approx \xi_0(t) \exp\left(\eta \sqrt{2H} \sum_{i=1}^m w_i Y_t^{(i)} - \frac{1}{2} \eta^2 t^{2H}\right), \quad (4.64)$$

ce qui permet une simulation récursive en $O(mN)$ (au lieu de $O(N^2)$).

4.14.4 Lien avec Heston et les modèles à facteurs

Cette représentation montre un pont conceptuel :

- les facteurs $Y^{(i)}$ sont Markoviens et ressemblent à des facteurs de volatilité de type OU ;
- en augmentant m , on se rapproche de la mémoire « continue » du noyau rough ;
- on obtient un compromis entre **fidélité rough** et **tractabilité numérique**.

De manière analogue, rHeston possède des approximations markoviennes (par résolvantes, sommes d'exponentielles) qui conduisent à des systèmes à plusieurs facteurs de type Heston.

4.15 Calibration : que calibre-t-on dans rBergomi ?

4.15.1 Paramètres et données

rBergomi comporte :

- une courbe $\xi_0(\cdot)$ (fonction),
- trois paramètres scalaires (H, η, ρ) .

Les données de calibration typiques :

- surface de volatilité implicite (vanilles) à plusieurs maturités,
- information sur la variance forward (variance swaps, VIX, etc.).

4.15.2 Stratégie typique (vue haut niveau)

1. **Fixer** ξ_0 pour reproduire la structure à terme de variance (niveau ATM par maturité).
2. **Calibrer** (H, η) pour ajuster la forme et le scaling de smile (notamment le court terme).

3. **Calibrer** ρ pour ajuster le skew (asymétrie).
4. **Valider** : stabilité hors échantillon, sensibilités, qualité de hedge.

Remarque 4.10. Dans un modèle non-Markovien, le pricing est plus coûteux (Monte Carlo), donc la calibration exige de l'ingénierie numérique (variance reduction, parallélisation, schémas rapides).

4.15.3 Construire ξ_0 : du marché à une courbe exploitable

Dans rBergomi, $\xi_0(\cdot)$ est une entrée du modèle. Il faut donc la construire à partir de données de marché. Deux cas simples à expliquer :

- **Vous avez des variance swaps (idéal)** : (4.5) donne une moyenne de ξ_0 , et la relation formelle (4.6) permet de retrouver ξ_0 (après interpolation lisse).
- **Vous n'avez que des options (cas fréquent)** : on utilise des approximations reliant variance swap et options (réplication statique) ou, à défaut, la total variance ATM $w(T) \approx \sigma_{\text{ATM}}(T)^2 T$ comme proxy de $\int_0^T \xi_0(u) du$.

Procédure proxy (niveau M1). Supposons qu'on observe une courbe ATM $\sigma_{\text{ATM}}(T)$ sur plusieurs maturités. On construit une total variance

$$w(T) := \sigma_{\text{ATM}}(T)^2 T, \quad (4.65)$$

et on impose (comme approximation) $w(T) \approx \int_0^T \xi_0(u) du$. On obtient alors une estimation

$$\xi_0(T) \approx w'(T), \quad (4.66)$$

après avoir interpolé w de manière suffisamment régulière (et en imposant $\xi_0 \geq 0$).

Procédure via VIX. Si l'on observe un indice type VIX, la relation (4.7) donne directement une moyenne glissante de ξ_0 sur une fenêtre τ . On en déduit ξ_0 par interpolation/regularisation, en imposant la positivité.

4.15.4 Ordres de grandeur et interprétation pratique

Sans figer des valeurs (elles dépendent de la convention et du sous-jacent), on observe typiquement en actions :

- H petit (souvent entre 0.05 et 0.2) : plus H est petit, plus le skew court terme est raide ;
- ρ négatif (souvent autour de -0.5 à -0.9) : effet de levier ;
- η règle l'ampleur de la dynamique de volatilité (donc la convexité du smile).

Une explication simple à donner : ξ_0 fixe le *niveau*, (H, η) fixent la *forme et le scaling*, ρ fixe l'*asymétrie*.

4.15.5 Fonction objectif : calibrer sur prix ou sur volatilités implicites ?

Deux choix courants :

- minimiser une erreur sur les **prix** (plus naturel mathématiquement, mais hétérogène en échelle) ;
- minimiser une erreur sur les **volatilités implicites** (plus stable et plus lisible), par exemple $\sum_i \omega_i (\sigma_{\text{impl}}^{\text{model}}(K_i, T_i) - \sigma_{\text{impl}}^{\text{mkt}}(K_i, T_i))^2$.

Dans tous les cas, le coût numérique est dominé par le pricing sous rBergomi (simulation), d'où l'intérêt des accélérations (section précédente) et de la formule conditionnelle (section simulation).

4.15.6 Conseil pédagogique : savoir raconter la calibration

Pour expliquer rBergomi à l'oral, une narration simple est :

- « Je fixe ξ_0 pour coller au niveau ATM par maturité. »
- « Je choisis H pour la rugosité (skew court terme). »
- « Je choisis η pour l'ampleur du smile. »
- « Je choisis ρ pour le sens et l'intensité du skew. »

4.16 Mode microscope : construction et checks

4.16.1 Variance forward et facteur rough

Une écriture standard du rBergomi prend une courbe de variance forward $\xi_0(t)$ et définit une variance aléatoire

$$v_t = \xi_0(t) \exp \left(\eta W_t^H - \frac{1}{2} \eta^2 t^{2H} \right),$$

où W^H est un facteur rough gaussien (souvent construit via une représentation Volterra à partir d'un Brownien). La dynamique du spot est

$$\frac{dS_t}{S_t} = (r - q) dt + \sqrt{v_t} dW_t^S,$$

avec corrélation entre le Brownien de S et le bruit qui génère W^H .

Check d'espérance. Comme W_t^H est gaussien centré de variance t^{2H} ,

$$\mathbb{E}[v_t] = \xi_0(t) \mathbb{E}[\exp(\eta W_t^H - \frac{1}{2}\eta^2 t^{2H})] = \xi_0(t).$$

Donc ξ_0 est bien la variance forward moyenne.

Sanity check. Si $\eta = 0$, alors $v_t = \xi_0(t)$ déterministe : on retombe sur un modèle à vol locale-déterministe (plus simple).

Intuition de marché. rBergomi est très *calibrable* : on choisit $\xi_0(t)$ pour coller l'ATM term-structure et on ajuste (H, η, ρ) pour coller le skew/smile court terme.

4.17 Pièges classiques / erreurs fréquentes

- Erreurs de simulation de W^H (noyau singulier, pas de temps) : biais sur v et sur le smile.
- Mauvais couplage de corrélation entre W^S et le bruit rough : skew incohérent.
- Confondre $\xi_0(t)$ (variance forward) avec une variance spot constante.

4.18 Checklist — savoir refaire sans regarder

- Écrire la construction de v_t et vérifier $\mathbb{E}[v_t] = \xi_0(t)$.
- Expliquer le rôle de (H, η, ρ) sur le smile/skew.
- Proposer un schéma de simulation (Volterra + convolution) et ses sanity checks.
- Décrire une calibration qualitative et les diagnostics.

Chapitre 5

Rough cheat sheet : noyaux, approx Markovienne, calibration (ultra-dense)

5.1 Idée centrale

Les modèles *rough* remplacent le « Markov local » par une **mémoire** (Volterra) avec noyau singulier $K_H(t) \sim t^{H-\frac{1}{2}}$ ($H < \frac{1}{2}$). Ils capturent (i) le **skew court terme** observé, (ii) une dynamique de smile plus réaliste, au prix d'une complexité : non-Markov $\Rightarrow$ simulation/calibration plus dures. En pratique, on utilise des **approximations Markoviennes** (somme d'exponentielles) pour pricer vite.

5.2 Cadre mathématique (Volterra / rough)

5.2.1 Volterra SDE (forme générique)

Un processus de type Volterra :

$$X_t = X_0 + \int_0^t K(t-s) b(X_s) ds + \int_0^t K(t-s) \sigma(X_s) dW_s,$$

avec noyau K (mémoire). Si $K(t) = 1$ on revient à une SDE Markovienne.

5.2.2 Noyau fractionnaire

Un choix canonique (Riemann–Liouville) :

$$K_H(t) = \frac{t^{H-\frac{1}{2}}}{\Gamma(H+\frac{1}{2})}, \quad H \in (0, 1).$$

Pour $H < \frac{1}{2}$, K_H est singulier à 0 $\Rightarrow$ trajectoires plus « rough » que Brownien.

5.2.3 fBm : rappel structurel

La fBm B^H n'est pas une semimartingale si $H \neq \frac{1}{2}$ (Itô classique ne s'applique pas). Sa covariance :

$$\mathbb{E}[B_t^H B_s^H] = \frac{1}{2}(t^{2H} + s^{2H} - |t-s|^{2H}).$$

Message entretien. « Rough » = mémoire + régularité modifiée ; attention aux outils (fractional calculus, Volterra).

5.3 Rough Heston : ce qu'il faut savoir citer

Une forme standard :

$$V_t = V_0 + \int_0^t K_H(t-s) \kappa(\theta - V_s) ds + \int_0^t K_H(t-s) \xi \sqrt{V_s} dW_s,$$

et $dS_t/S_t = (r-q)dt + \sqrt{V_t} dB_t$ avec $\text{Corr}(dB, dW) = \rho dt$. **Point clé.** Le pricing vanille passe par une **équation de Riccati fractionnaire** (pas une ODE).

5.4 Approximation Markovienne (somme d'exponentielles)

5.4.1 Idée Laplace

Beaucoup de noyaux (dont K_H) admettent une représentation de Laplace :

$$K(t) = \int_0^\infty e^{-xt} \mu(dx).$$

On approxime μ par une quadrature : $K(t) \approx \sum_{i=1}^n w_i e^{-x_i t}$.

5.4.2 Conséquence pratique

Le terme de convolution devient un **système Markovien** en dimension n via des facteurs Y^i de type OU :

$$dY_t^{(i)} = -x_i Y_t^{(i)} dt + (\text{drift/diffusion}) dt + (\text{vol}) dW_t, \quad X_t \approx \sum_i w_i Y_t^{(i)}.$$

Trade-off. n grand $\Rightarrow$ meilleure approx, mais coût $O(n)$ par pas (et calibration plus lourde).

5.5 Calibration : réflexes et diagnostics

- **Identifier** H via le court-terme : le skew ATM empirique suit typiquement une loi $T^{H-\frac{1}{2}}$ (signature rough).
- **Découpler** : caler d'abord $\xi_0(t)$ (courbe de variance initiale) à partir des ATM, puis ajuster (H, η, ρ) sur le smile.
- **Stabilité** : multi-start, bornes (notamment ρ), et pénaliser des oscillations de ξ_0 .
- **Sanity** : surface pricer doit rester sans arbitrage statique (convexité en K , monotone en T).

5.6 Tests / sanity checks (courts, mais indispensables)

- Limite $H \rightarrow \frac{1}{2}$: récupérer une dynamique plus « classique » (moins de mémoire).
- Approx Markovienne : en augmentant n , les prix/greeks doivent converger (diagnostic d'erreur).
- Simulation : contrôle du pas de temps (biais) ; invariants simples (martingale test sous $\mathbb{Q}$ pour $S_t e^{-(r-q)t}$).
- Calibration : repricing des vanilles sur un grid dense ; pas d'oscillations en strike.

5.7 Pitfalls (ce qui fait planter une implémentation)

- Traiter fBm/Volterra comme une SDE Markovienne (mauvais outil, biais).
- Approx kernel trop pauvre : fit correct des prix mais greeks instables (model risk).
- Discrétisation : explosion du coût si on fait une convolution $O(N^2)$; utiliser des schémas/hacks (Markovian, hybrid).
- Calibration : sur-ajustement à une maturité, incohérence cross-maturités.

ANNEXE — Q/R

Préliminaires + questions de fin de chapitre + interview Q&A (P2 à P9)

Table des matières

Préliminaires probabilistes — Questions d’entretien	1
Sans section	1
Questions de fin de chapitre (P2 à P9)	12
Partie II — Instruments, payoffs, arbitrage, taux	12
Partie III — Variation quadratique & Itô	16
Partie IV — Black–Scholes	18
Partie V — Sauts, Heston, Fourier/FFT	20
Partie VI — Kalman (estimation)	22
Partie VII — Allocation & rebalancement	24
Partie VIII — Décision/ML (RL, DQN, finance)	25
Partie IX — Mémoire & rough (Volterra, fBm, rHeston, rBergomi)	27
Interview Q&A (P2 à P9)	30
Partie II — Instruments, payoffs, arbitrage, taux	31
Partie III — Variation quadratique & Itô	33
Partie IV — Black–Scholes	35
Partie V — Sauts, Heston, Fourier/fft	36
Partie VI — Kalman (estimation)	37
Partie VII — Allocation & rebalancement	39
Partie VIII — Décision/ML (RL, DQN, finance)	43
Partie IX — Mémoire & rough (Volterra, fBm, rHeston, rBergomi)	44

Préliminaires probabilistes — Questions d'entretien

Sans section

Question d'entretien. Pourquoi ne pas poser *toujours* $\mathcal{F} = \mathcal{P}(\Omega)$?

Réponse attendue. Sur des espaces non dénombrables (ex : $\Omega = \mathbb{R}$), il existe des ensembles non mesurables. Vouloir tout mesurer casse la cohérence (on perd l'existence d'une mesure σ -additive compatible avec les constructions usuelles). On travaille donc avec une tribu suffisamment riche (souvent les boréliens) mais mesurable.

Piège. Répondre « parce que c'est compliqué » sans mentionner la non-mesurabilité.

Question d'entretien. En une phrase : qu'est-ce qu'un look-ahead bias, en langage probabiliste ?

Réponse attendue. Une décision à t dépend d'une variable qui n'est pas $\mathcal{F}_t$ -mesurable : on viole l'adaptation/non-anticipation.

Piège. Dire seulement « utiliser le futur » sans préciser l'objet mathématique violé.

Question d'entretien. Qu'est-ce que « changer de mesure » ($\mathbb{P} \rightarrow \mathbb{Q}$) change concrètement ?

Réponse attendue. Une mesure change les pondérations des scénarios : une même variable X a la même réalisation $\omega \mapsto X(\omega)$, mais ses espérances/probabilités changent. En finance, on choisit $\mathbb{Q}$ pour que les prix actualisés soient des martingales et que le pricing devienne une espérance conditionnelle.

Piège. Dire « ça change la densité » sans préciser « quelle densité », ni rappeler le rôle de $L = d\mathbb{Q}/d\mathbb{P}$.

Question d'entretien. Définir un numéraire B_t et expliquer son rôle en une phrase.

Réponse attendue. Un numéraire $B_t > 0$ est une unité de compte. On actualise un prix S_t en $\tilde{S}_t = S_t/B_t$; sous une mesure adaptée au numéraire, $\tilde{S}_t$ est (souvent) une martingale, ce qui rend le pricing cohérent dans le temps.

Piège. Confondre numéraire et taux : le numéraire est un processus positif, pas une constante.

Question d'entretien. Définir $\sigma(\mathcal{G})$ et expliquer pourquoi cette définition donne bien une tribu.

Réponse attendue. On définit $\sigma(\mathcal{G})$ comme l'intersection de toutes les tribus contenant $\mathcal{G}$. Une intersection de tribus est une tribu (stabilité par complément et unions dénombrables se vérifie terme à terme), donc l'objet est bien une tribu et c'est la plus petite par construction.

Piège. Oublier de justifier que l'intersection de tribus est une tribu.

Question d'entretien. Pourquoi la continuité des mesures (2.2) est *vraiment* une conséquence de la σ -additivité ?

Réponse attendue. On découpe une suite croissante en différences disjointes B_n ; la σ -additivité devient une somme partielle qui converge vers la somme totale. C'est exactement le passage « limites $\leftrightarrow$ sommes ».

Piège. Répondre « parce que c'est intuitif » sans produire le découpage disjoint.

Question d'entretien. Comment prouver l'indépendance de deux tribus à partir d'un générateur ?

Réponse attendue. On montre l'égalité $\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B)$ d'abord sur des π -systèmes générateurs, puis on étend à la σ -algèbre engendrée via un argument π - λ / classe monotone.

Piège. Dire « c'est vrai par densité » sans outil de passage au σ -généralisé.

Question d'entretien. Donner une description explicite de la tribu engendrée par une partition finie.

Réponse attendue. Si $\pi = \{C_1, \dots, C_m\}$ est une partition de Ω , alors $\sigma(\pi)$ est l'ensemble des unions d'atomes : $\sigma(\pi) = \{\cup_{i \in I} C_i : I \subseteq \{1, \dots, m\}\}$. C'est exactement « l'information qui dit dans quelle classe on est ».

Piège. Oublier que la tribu doit contenir les compléments : on doit pouvoir prendre I^c .

Question d'entretien. Définir la tribu engendrée par une variable aléatoire X .

Réponse attendue. $\sigma(X) = \{X^{-1}(B) : B \in \mathcal{B}(\mathbb{R})\}$. C'est la plus petite tribu qui rend X mesurable ; en pratique c'est « l'information fournie par X ».

Piège. Confondre $\sigma(X)$ avec l'ensemble des valeurs prises par X (le support).

Question d'entretien. Pourquoi la complétion (ou l'augmentation d'une filtration) est-elle plus qu'un détail technique ?

Réponse attendue. Parce que beaucoup d'objets sont définis à égalité p.s. près (espérance conditionnelle, projection L^2). Sans complétion, un sous-ensemble d'un nul peut ne pas être mesurable, ce qui crée des paradoxes de mesurabilité et des définitions non stables par modifications p.s.

Piège. Dire « ça ne change rien » : si on travaille modulo nuls, il faut que les sous-ensembles de nuls soient dans la tribu.

Question d'entretien. Tonelli vs Fubini : quel énoncé et quelle hypothèse clé ?

Réponse attendue. Tonelli : $f \geq 0$ mesurable $\Rightarrow$ on peut toujours écrire $\iint f = \int(\int f)$ (valeur $+\infty$ autorisée). Fubini : il faut $\iint |f| < \infty$ pour assurer que les intégrales itérées existent (p.p.) et que l'ordre ne change pas la valeur.

Piège. Dire « c'est pareil » : le contre-exemple sans intégrabilité absolue est classique (voir l'exemple ci-dessus).

Question d'entretien. Pourquoi la σ -finitude revient-elle partout (RN, produit, Fubini) ?

Réponse attendue. Elle permet de découper l'espace en morceaux de masse finie, ce qui évite les indéterminations $+\infty - \infty$ et rend possibles les preuves par restriction (unicité via π - λ sur des mesures finies, RN en recollant des dérivées locales, etc.). Sans σ -finitude, beaucoup d'énoncés sont faux ou perdent l'unicité.

Piège. Dire « c'est technique » sans citer le problème $+\infty - \infty$ et la stratégie « découper en morceaux finis ».

Question d'entretien. Qu'est-ce qu'une loi jointe et quel est le lien avec la mesure produit ?

Réponse attendue. La loi jointe de (X, Y) est la mesure image $\mu_{(X,Y)} = \mathbb{P} \circ (X, Y)^{-1}$ sur $(\mathbb{R}^2, \mathcal{B}(\mathbb{R}^2))$. Si X et Y sont indépendantes, alors $\mu_{(X,Y)} = \mu_X \otimes \mu_Y$: il suffit de le vérifier sur les rectangles $A \times B$ puis d'étendre à la tribu engendrée via π - λ .

Piège. Dire « la densité jointe factorise » alors qu'on peut être discret/mixte : le bon objet est la mesure.

Question d'entretien. Dans quel sens $\mathcal{B}(\mathbb{R}^2) = \mathcal{B}(\mathbb{R}) \otimes \mathcal{B}(\mathbb{R})$ est-il utile ?

Réponse attendue. Il garantit que si X et Y sont boréliens (v.a. réelles), alors (X, Y) est une v.a. à valeurs dans $\mathbb{R}^2$ et sa loi est une mesure sur les boréliens usuels de $\mathbb{R}^2$. En pratique : densité jointe, marginalisation et conditionnelles s'écrivent avec les intégrales de 2.4–2.5.

Piège. Confondre tribu produit et toute partie de $\mathbb{R}^2$: on ne mesure pas tout.

Question d'entretien. À partir d'une densité jointe $f_{X,Y}$, comment obtenir les marginales et justifier la formule ?

Réponse attendue. Si (X,Y) a une densité $f_{X,Y}$ par rapport à Lebesgue sur $\mathbb{R}^2$, alors $f_X(x) = \int_{\mathbb{R}} f_{X,Y}(x,y)dy$ et $f_Y(y) = \int_{\mathbb{R}} f_{X,Y}(x,y)dx$. La justification n'est pas « on intègre » : c'est Tonelli/Fubini sur la fonction positive $f_{X,Y}\mathbf{1}_{B \times \mathbb{R}}$ quand on calcule $\mathbb{P}(X \in B) = \iint \mathbf{1}_B(x)f_{X,Y}(x,y)dxdy$.

Piège. Oublier le support (domaines d'intégration) ou oublier que Tonelli demande $f \geq 0$; pour $g(x,y)f_{X,Y}$ il faut vérifier intégrabilité.

Question d'entretien. Carathéodory : donner le plan de la construction en 30 secondes.

Réponse attendue. (i) Définir une mesure extérieure μ^* par infimum sur des recouvrements par des ensembles de l'algèbre ; (ii) définir les ensembles μ^* -mesurables via le critère $\mu^*(B) = \mu^*(B \cap E) + \mu^*(B \cap E^c)$; (iii) montrer que cette classe est une tribu et que $\mu = \mu^*$ y est une mesure ; (iv) vérifier que l'algèbre initiale est mesurable et que μ prolonge μ_0 ; (v) l'unicité vient de la σ -finitude + π - λ .

Piège. Dire « on étend par continuité » sans définir μ^* ni la notion d'ensemble mesurable (le cœur de Carathéodory).

Question d'entretien. Dans la construction de $\mu \otimes \nu$, pourquoi définir μ_0 sur l'algèbre des unions finies disjointes de rectangles ?

Réponse attendue. Parce qu'il faut une structure stable (algèbre) pour appliquer Carathéodory : sur les seuls rectangles, on n'a ni stabilité par unions finies ni complément, et on ne peut pas formuler proprement une pré-mesure. Les unions disjointes permettent de définir μ_0 par additivité et de vérifier la cohérence via raffinements.

Piège. Définir seulement $(\mu \otimes \nu)(A \times B) = \mu(A)\nu(B)$ et ignorer la question « et sur une union de rectangles ? ».

Question d'entretien. Définir proprement la loi de X sans parler de densité.

Réponse attendue. La loi est la mesure image $\mu_X = \mathbb{P} \circ X^{-1}$ sur $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$. Pour tout borélien B , $\mu_X(B) = \mathbb{P}(X \in B)$.

Piège. Dire « la loi c'est la densité » : une loi peut ne pas avoir de densité.

Question d'entretien. Énoncer LOTUS et donner un exemple où c'est indispensable.

Réponse attendue. LOTUS : $\mathbb{E}[g(X)] = \int g d\mu_X$ (ou $\int g(x)f_X(x)dx$ si densité). Exemple : moments d'une lognormale via $g(x) = e^{kx}$ (sans passer par la densité de e^X).

Piège. Oublier l'hypothèse d'intégrabilité ou confondre $\int g(x)dx$ et $\int g(x)f_X(x)dx$.

Question d'entretien. Sous $\mathbb{Q} \ll \mathbb{P}$, pourquoi $\mathbb{E}^{\mathbb{Q}}[X] = \mathbb{E}^{\mathbb{P}}[LX]$?

Réponse attendue. C'est exactement la définition de $L = d\mathbb{Q}/d\mathbb{P}$: $\mathbb{Q}(A) = \int_A L d\mathbb{P}$. On l'étend des indicatrices aux intégrables par linéarité et convergence dominée.

Piège. Dire « parce que Bayes » sans rappeler le rôle de RN.

Question d'entretien. Quand la densité $L = d\mathbb{Q}/d\mathbb{P}$ n'existe-t-elle pas ?

Réponse attendue. Quand $\mathbb{Q}$ n'est pas absolument continue par rapport à $\mathbb{P}$: il existe A tel que $\mathbb{P}(A) = 0$ mais $\mathbb{Q}(A) > 0$. Alors on ne peut pas écrire $\mathbb{Q}(d\omega) = L(\omega)\mathbb{P}(d\omega)$.

Piège. Confondre « L n'est pas intégrable » avec « L n'existe pas » : l'existence est une question d'absolue continuité.

Question d'entretien. Si X a des densités p (sous $\mathbb{P}$) et q (sous $\mathbb{Q}$) par rapport à Lebesgue, quel est L en fonction de X ?

Réponse attendue. Sur l'espace de X , $L(\omega) = \frac{q(X(\omega))}{p(X(\omega))}$ (là où $p > 0$). C'est la forme « ratio de densités » du RN dérivé, et elle se vérifie en testant sur $\{X \in B\}$.

Piège. Oublier de restreindre au support : si $p(x) = 0$, le ratio n'a pas de sens et il faut d'abord vérifier $\mathbb{Q} \ll \mathbb{P}$.

Question d'entretien. Donner un exemple de loi mixte et expliquer pourquoi parler d'une « densité » peut être trompeur.

Réponse attendue. Ex : $\mathbb{P}(X = 0) = p$ et sinon X a une densité sur $\mathbb{R}_+$. La loi a un atome en 0 et une partie absolument continue. Une densité seule ne capture pas l'atome : il faut écrire la mesure comme somme « masse + densité ».

Piège. Dire « la densité vaut $+\infty$ en 0 » : une densité est une fonction intégrable, pas une masse atomique.

Question d'entretien. Dériver la densité d'une lognormale et donner $\mathbb{E}[e^X]$ si $X \sim \mathcal{N}(m, s^2)$.

Réponse attendue. Changement de variable $y = e^x$: $f_Y(y) = \frac{1}{ys\sqrt{2\pi}} e^{-(\log y - m)^2/(2s^2)} \mathbf{1}_{y>0}$. Moment : $\mathbb{E}[e^X] = \exp(m + s^2/2)$.

Piège. Oublier $y > 0$ ou le facteur $1/y$.

Question d'entretien. Pourquoi Z_1/Z_2 est Cauchy (sans « grosse intégrale ») ?

Réponse attendue. Invariance par rotation de (Z_1, Z_2) : l'angle est uniforme, et le ratio est une tangente. On en déduit la densité Cauchy.

Piège. Tenter une dérivation par Jacobien sans gérer correctement les domaines et la non-injectivité.

Question d'entretien. Si $X \sim \mathcal{N}(0, 1)$, quelle est la densité de $Y = X^2$?

Réponse attendue. Non-injectif : $y = x^2$ a deux antécédents $\pm\sqrt{y}$. Donc pour $y > 0$, $f_Y(y) = f_X(\sqrt{y})\frac{1}{2\sqrt{y}} + f_X(-\sqrt{y})\frac{1}{2\sqrt{y}} = \frac{1}{\sqrt{2\pi y}} e^{-y/2}$. C'est une $\chi^2(1)$.

Piège. Oublier l'antécédent $-\sqrt{y}$ ou oublier le facteur $1/(2\sqrt{y})$.

Question d'entretien. Si X a une densité sur $\mathbb{R}^d$ et $Y = AX + b$ avec A inversible, quelle est la densité de Y ?

Réponse attendue. Changement de variable linéaire : $g(x) = Ax + b$, $g^{-1}(y) = A^{-1}(y - b)$ et $\det J_{g^{-1}} = \det(A^{-1})$. Donc $f_Y(y) = f_X(A^{-1}(y - b)) |\det(A^{-1})| = f_X(A^{-1}(y - b)) / |\det A|$.

Piège. Oublier le déterminant (ou confondre $|\det A|$ et $|\det A^{-1}|$).

Question d'entretien. Pourquoi $\mathbb{E}[X | Y]$ est une variable aléatoire ?

Réponse attendue. Parce que c'est une version de $\mathbb{E}[X | \sigma(Y)]$: elle doit être $\sigma(Y)$ -mesurable, donc dépendre de $Y(\omega)$, donc de ω . Par Doob-Dynkin, c'est une fonction $g(Y)$.

Piège. Répondre « parce que ça dépend de Y » sans parler de $\sigma(Y)$ et de mesurabilité.

Question d'entretien. Différence entre $\mathbb{E}[X | Y]$ et $\mathbb{E}[X | \sigma(Y)]$?

Réponse attendue. Aucune : $\mathbb{E}[X | Y]$ est une notation pour $\mathbb{E}[X | \sigma(Y)]$. La subtilité concerne plutôt $\mathbb{E}[X | Y = y]$, qui nécessite une version régulière.

Piège. Dire qu'il y a une différence « parce que Y est une valeur ».

Question d'entretien. Donner la preuve d'existence de $\mathbb{E}[X | \mathcal{G}]$ en une ligne.

Réponse attendue. On définit $\nu(A) = \int_A X d\mathbb{P}$ sur $\mathcal{G}$; on a $\nu \ll \mathbb{P}|_{\mathcal{G}}$; donc par RN il existe $Y = d\nu/d\mathbb{P}$ sur $\mathcal{G}$, et c'est $\mathbb{E}[X | \mathcal{G}]$.

Piège. Oublier de vérifier l'absolue continuité $\mathbb{P}(A) = 0 \Rightarrow \nu(A) = 0$.

Question d'entretien. Quelles sont les deux espérances conditionnelles « extrêmes » ?

Réponse attendue. Si $\mathcal{G}$ est triviale $\{\emptyset, \Omega\}$, alors $\mathbb{E}[X | \mathcal{G}] = \mathbb{E}[X]$ (constante). Si $\mathcal{G} = \mathcal{F}$, alors $\mathbb{E}[X | \mathcal{G}] = X$ p.s. (toute l'information).

Piège. Confondre $\mathbb{E}[X | \mathcal{G}]$ avec $\mathbb{E}[X]$ sans préciser la tribu.

Question d'entretien. Énoncer la décomposition de variance et donner une interprétation.

Réponse attendue. $\text{Var}(X) = \mathbb{E}[\text{Var}(X | \mathcal{G})] + \text{Var}(\mathbb{E}[X | \mathcal{G}])$. Le premier terme est le risque résiduel « intra-information », le second est le risque expliqué par l'information.

Piège. Écrire $\text{Var}(X) = \text{Var}(\mathbb{E}[X | \mathcal{G}])$ (ou oublier le terme résiduel).

Question d'entretien. Sous $\mathbb{Q} \ll \mathbb{P}$, comment exprimer $\mathbb{E}^{\mathbb{Q}}[X | \mathcal{G}]$ en termes de $\mathbb{P}$ et $L = d\mathbb{Q}/d\mathbb{P}$?

Réponse attendue. Formule de Bayes : $\mathbb{E}^{\mathbb{Q}}[X | \mathcal{G}] = \mathbb{E}^{\mathbb{P}}[LX | \mathcal{G}] / \mathbb{E}^{\mathbb{P}}[L | \mathcal{G}]$ sur $\{\mathbb{E}^{\mathbb{P}}[L | \mathcal{G}] > 0\}$ (3.3).

Piège. Oublier le dénominateur $\mathbb{E}^{\mathbb{P}}[L | \mathcal{G}]$: c'est une renormalisation.

Question d'entretien. Donner un exemple de convergence en probabilité qui n'est pas p.s.

Réponse attendue. $X_n = \mathbf{1}_{A_n}$ avec A_n indépendants et $\mathbb{P}(A_n) = 1/n$. Alors $X_n \rightarrow 0$ en probabilité mais pas p.s. par Borel–Cantelli 2.

Piège. Utiliser un exemple où $\sum \mathbb{P}(A_n) < \infty$ (alors convergence p.s.).

Question d'entretien. Donner un exemple de suite $X_n \rightarrow 0$ p.s. mais $\mathbb{E}[X_n] \not\rightarrow 0$.

Réponse attendue. $X_n = n\mathbf{1}_{[0,1/n]}$ sur $[0, 1]$: convergence p.s. vers 0, mais $\mathbb{E}[X_n] = 1$.

Piège. Dire « c'est impossible » : c'est exactement le cas où la domination manque.

Question d'entretien. Delta method : d'où vient le facteur $g'(\theta)$?

Réponse attendue. Du développement de Taylor à l'ordre 1 : $g(\theta_n) - g(\theta) \approx g'(\theta)(\theta_n - \theta)$. L'erreur est négligeable à l'échelle $\sqrt{n}$.

Piège. Faire une expansion sans contrôler l'erreur (oubli du $o(\theta_n - \theta)$).

Question d'entretien. Borel–Cantelli : quelle hypothèse manque dans la version réciproque ?

Réponse attendue. BC1 ne demande pas d'indépendance : $\sum \mathbb{P}(A_n) < \infty \Rightarrow \mathbb{P}(A_n \text{ i.o.}) = 0$. Pour conclure $\mathbb{P}(A_n \text{ i.o.}) = 1$ quand $\sum \mathbb{P}(A_n) = \infty$, il faut une hypothèse supplémentaire (indépendance ou conditions de mélange).

Piège. Dire « si la somme diverge alors i.o. avec proba 1 » sans hypothèse : faux.

Question d'entretien. Quelle est la différence opérationnelle entre WLLN et SLLN ?

Réponse attendue. WLLN : convergence en probabilité de la moyenne ; SLLN : convergence p.s. (contrôle trajectorien). En backtests ou en convergence de schémas, p.s. est plus forte (mais plus difficile à obtenir).

Piège. Dire « c'est pareil » : en probabilité n'implique pas p.s. (contre-exemples via Borel–Cantelli).

Question d'entretien. Quand peux-tu échanger limite et espérance ? Donne un critère minimal.

Réponse attendue. Typiquement via DCT (domination intégrable) ou MCT (suite croissante non négative). Sans ça, l'échange peut être faux (ex : $X_n = n\mathbf{1}_{[0,1/n]}$).

Piège. Répondre « si ça converge » sans donner d'hypothèse (domination/monotonie).

Question d'entretien. Donner une borne de concentration non-asymptotique pour la moyenne d'i.i.d. bornées.

Réponse attendue. Si $X_i \in [a, b]$ i.i.d. et $m = \mathbb{E}[X_1]$, alors Hoeffding donne $\mathbb{P}(\bar{X}_n - m \geq \varepsilon) \leq \exp(-2n\varepsilon^2/(b-a)^2)$. Preuve : MGF + Markov (Chernoff) + lemme de Hoeffding (6.1).

Piège. Sortir une CLT : CLT est asymptotique et ne donne pas une borne exponentielle uniforme en n .

Question d'entretien. Bernstein vs Hoeffding : quand Bernstein est-il plus informatif ?

Réponse attendue. Bernstein (6.6) utilise la variance V et le bornage b . Pour des variables très peu bruitées (petite variance) mais avec une enveloppe large, Bernstein donne une borne plus serrée que Hoeffding, et il montre deux régimes : gaussien pour petites déviations (x^2/V) puis exponentiel pour grandes déviations (x/b).

Piège. Répondre « c'est pareil » : Hoeffding ne voit pas la variance, uniquement l'intervalle $[a, b]$.

Question d'entretien. Définir l'uniforme intégrabilité et donner un critère simple.

Réponse attendue. UI : $\sup_n \mathbb{E}[|X_n| \mathbf{1}_{|X_n| > K}] \rightarrow 0$ quand $K \rightarrow \infty$. Critère : si $\sup_n \mathbb{E}[|X_n|^{1+\varepsilon}] < \infty$ pour un $\varepsilon > 0$, alors UI (6.7).

Piège. Confondre UI avec « $\sup_n \mathbb{E}[|X_n|] < \infty$ » : ce n'est pas suffisant.

Question d'entretien. Vitali : qu'apporte-t-il par rapport à DCT ?

Réponse attendue. DCT demande une domination *pointwise* par un $Y \in L^1$. Vitali (6.10) dit : si la famille est UI et si $X_n \rightarrow X$ en probabilité, alors $\mathbb{E}[|X_n - X|] \rightarrow 0$ et donc $\mathbb{E}[X_n] \rightarrow \mathbb{E}[X]$. C'est le bon outil quand il n'y a pas de dominateur commun mais que les queues sont contrôlées.

Piège. Dire « c'est le même théorème » : les hypothèses ne sont pas les mêmes (domination vs UI).

Question d'entretien. Dans Slutsky, pourquoi demande-t-on $Y_n \rightarrow c$ en probabilité ?

Réponse attendue. Parce qu'il faut contrôler $\varphi(X_n, Y_n) - \varphi(X_n, c)$: on veut que la seconde composante soit proche de c avec grande probabilité, *uniformément sur la zone où X_n vit*. Si $Y_n \Rightarrow c$ avec c constante, alors en fait $Y_n \rightarrow c$ en probabilité ; mais si la limite n'est pas constante, la convergence marginale en loi ne suffit pas pour les opérations $+/ \times$ sans convergence jointe.

Piège. Croire que « $X_n \Rightarrow X$ et $Y_n \Rightarrow Y$ » implique toujours « $X_n + Y_n \Rightarrow X + Y$ » : faux sans joint.

Question d'entretien. Donner un contre-exemple : deux marginales convergent en loi, mais la paire ne converge pas.

Réponse attendue. Prendre $Z \sim \mathcal{N}(0, 1)$ et définir $(X_{2n}, Y_{2n}) = (Z, Z)$, $(X_{2n+1}, Y_{2n+1}) = (Z, -Z)$. Alors chaque marginale est $\mathcal{N}(0, 1)$ pour tout n , donc converge en loi, mais (X_n, Y_n) n'a pas de limite en loi (la corrélation alterne entre $+1$ et -1) ; en particulier $X_n + Y_n$ alterne entre $2Z$ et 0 .

Piège. Donner un exemple où la paire converge quand même : il faut que la jointure alterne.

Question d'entretien. Prouver le lemme de Hoeffding en une minute.

Réponse attendue. Poser $\psi(t) = \log \mathbb{E}[e^{t(X - \mathbb{E}[X])}]$. Alors $\psi(0) = \psi'(0) = 0$ et $\psi''(t) = \text{Var}_t(X)$ sous la mesure inclinée. Comme $X \in [a, b]$, on a $\text{Var}_t(X) \leq (b - a)^2/4$ pour tout t (variance maximale pour une variable bornée). Intégrer deux fois donne $\psi(t) \leq t^2(b - a)^2/8$, donc $\mathbb{E}[e^{t(X - \mathbb{E}[X])}] \leq e^{t^2(b - a)^2/8}$.

Piège. Chercher une distribution « pire cas » sans justifier le contrôle uniforme de $\psi''(t)$ (c'est la clé).

Question d'entretien. Donner un exemple avec $\sup_n \mathbb{E}[|X_n|] < \infty$ mais (X_n) n'est pas UI.

Réponse attendue. Sur $[0, 1]$ avec Lebesgue, $X_n = n \mathbf{1}_{[0, 1/n]}$: $\mathbb{E}[|X_n|] = 1$, mais pour tout K , si $n > K$ alors $|X_n| > K$ sur $[0, 1/n]$ et $\mathbb{E}[|X_n| \mathbf{1}_{|X_n| > K}] = 1$. Donc $\sup_n \mathbb{E}[|X_n| \mathbf{1}_{|X_n| > K}] = 1$: pas UI.

Piège. Répondre « si $\sup_n \mathbb{E}[|X_n|] < \infty$ alors UI » : faux.

Question d'entretien. Pourquoi $\mathbb{E}[X | \mathcal{G}]$ est la « meilleure prédiction » de X donnée $\mathcal{G}$?

Réponse attendue. Parce que dans L^2 , c'est la projection orthogonale sur le sous-espace des variables $\mathcal{G}$ -mesurables : elle minimise l'erreur quadratique moyenne.

Piège. Dire « parce que c'est une moyenne » sans expliciter le critère (MSE) et l'espace (variables $\mathcal{G}$ -mesurables).

Question d'entretien. Donner la formule de la meilleure prédiction *linéaire* de X par $Y \in \mathbb{R}^d$.

Réponse attendue. $a^* = \text{Cov}(Y)^{-1} \text{Cov}(Y, X)$ (si $\text{Cov}(Y)$ inversible), obtenu par équations normales $\mathbb{E}[(X - a^\top Y)Y] = 0$.

Piège. Confondre $\mathbb{E}[Y]$ avec Y : en régression, on centre ou on ajoute une constante.

Question d'entretien. Pourquoi a-t-on besoin que $L^2(\mathcal{G})$ soit *fermé* pour parler de projection ?

Réponse attendue. Parce que l'existence d'un minimiseur nécessite la complétude : si un minimiseur n'existe qu'à la limite, il faut que la limite reste dans $L^2(\mathcal{G})$. La fermeture dit : une limite en L^2 de variables $\mathcal{G}$ -mesurables est encore $\mathcal{G}$ -mesurable (à modification p.s. près).

Piège. Répondre « parce que c'est un Hilbert » sans relier à l'existence du minimiseur dans le sous-espace.

Question d'entretien. Énoncer le principe d'orthogonalité de la régression.

Réponse attendue. Au minimiseur a^* , le résidu $X - a^{*\top} Y$ est orthogonal (non corrélé) à chaque composante de Y : $\mathbb{E}[(X - a^{*\top} Y)Y] = 0$. C'est exactement la condition de projection.

Piège. Dire « le gradient est nul » sans traduire en équations normales (produits scalaires).

Question d'entretien. Dans un modèle linéaire-gaussien $Y = HX + \varepsilon$, quelle est la forme de $\mathbb{E}[X | Y]$?

Réponse attendue. Elle est affine en Y : $\mathbb{E}[X | Y] = m_X + K(Y - Hm_X)$ avec $K = PH^\top(HPH^\top + R)^{-1}$ (gain), où $P = \text{Cov}(X)$ et $R = \text{Cov}(\varepsilon)$. C'est une instance directe de la conditionnelle gaussienne et de la projection L^2 .

Piège. Inverser P au lieu de $HPH^\top + R$, ou oublier le terme d'interception m_X .

Question d'entretien. Toujours dans $Y = HX + \varepsilon$, donner la covariance a posteriori P^+ et deux écritures utiles.

Réponse attendue. $P^+ = P - PH^\top(HPH^\top + R)^{-1}HP$ (complément de Schur / covariance conditionnelle). Écriture équivalente via Woodbury : $P^+ = (P^{-1} + H^\top R^{-1}H)^{-1}$ (forme information).

Piège. Écrire $P^+ = (I - KH)P$ sans préciser que c'est symétrique seulement si K est le gain optimal, ou oublier le bruit R .

Question d'entretien. Pourquoi la forme de Joseph est-elle recommandée numériquement ?

Réponse attendue. $P^+ = (I - KH)P(I - KH)^\top + KKK^\top$ rend explicite que P^+ est PSD (somme de PSD) et corrige les pertes de symétrie/PSD dues aux erreurs d'arrondi. En pratique, on préfère aussi résoudre $Sx = b$ (Cholesky) plutôt que former S^{-1} .

Piège. Dire « parce que c'est plus joli » sans mentionner PSD/symétrie et stabilité numérique.

Question d'entretien. Quand une matrice de covariance empirique n'est-elle pas PD ? Que faire ?

Réponse attendue. Si $n < d$, la covariance empirique a rang $\leq n - 1$, donc est PSD mais singulière (pas PD). Remèdes : shrinkage, ajout εI , clipping des valeurs propres, ou factor model de rang réduit.

Piège. Dire « prendre l'inverse pseudo » sans discuter stabilité numérique ni contraintes PD.

Question d'entretien. Énoncer Woodbury et donner un cas d'usage en Kalman.

Réponse attendue. Woodbury : inversion de $A + UCV$ via l'inverse de A et d'une petite matrice $k \times k$. En Kalman, A est la covariance prédite, UCV correspond à l'information apportée par une observation bruitée : on évite d'inverser une grosse covariance.

Piège. Mémoriser la formule sans savoir identifier A, U, C, V dans une mise à jour.

Question d'entretien. Donner une formule simple pour $\det \begin{pmatrix} A & B \\ B^\top & C \end{pmatrix}$ quand A est inversible.

Réponse attendue. Par factorisation de Schur : $\det(M) = \det(A) \det(C - B^\top A^{-1}B) = \det(A) \det(S)$. C'est la version déterminant du complément de Schur.

Piège. Oublier l'hypothèse d'inversibilité, ou remplacer $B^\top A^{-1}B$ par $BA^{-1}B^\top$ (mauvaise taille).

Question d'entretien. Énoncer le matrix determinant lemma et donner un usage concret.

Réponse attendue. $\det(A + UCV) = \det(A) \det(C) \det(C^{-1} + VA^{-1}U)$ (8.3). Usage : calcul rapide de $\log \det$ pour une covariance « diagonale + faible rang » (factor model), ou pour l'innovation $S = HPH^\top + R$ en Kalman.

Piège. Confondre avec Woodbury : Woodbury donne l'inverse, pas le déterminant ; oublier les dimensions de la petite matrice $k \times k$.

Question d'entretien. Pourquoi éviter d'inverser explicitement une covariance en pratique ?

Réponse attendue. Parce que l'inversion explicite amplifie les erreurs numériques et est moins stable que résoudre un système linéaire (Cholesky/QR). En Kalman/Markowitz, on veut souvent $A^{-1}b$: on résout $Ax = b$ plutôt que de former A^{-1} .

Piège. Dire « parce que c'est plus lent » sans mentionner la stabilité/conditionnement.

Question d'entretien. Pourquoi $\text{corr}(X, Y) = 0$ n'implique pas l'indépendance ? Donne un contre-exemple simple.

Réponse attendue. Ex : $X \sim \text{uniforme sur } [-1, 1]$ et $Y = X^2$. Alors $\text{Cov}(X, Y) = \mathbb{E}[X^3] - \mathbb{E}[X]\mathbb{E}[X^2] = 0$, mais Y est une fonction de X donc dépendance.

Piège. Donner un exemple où la covariance n'est pas nulle (donc ne répond pas à la question).

Question d'entretien. Énoncer et prouver Stein's lemma.

Réponse attendue. Énoncé 9.1. Preuve : écrire $\phi'(x) = -x\phi(x)$ et faire une intégration par parties ; les conditions garantissent que le terme de bord est nul.

Piège. Oublier le terme de bord et/ou oublier de recentrer $(X - m)$.

Question d'entretien. Donner une borne de queue gaussienne simple et la dériver.

Réponse attendue. Chernoff : $\mathbb{P}(Z \geq x) \leq \inf_{t>0} \exp(-tx + t^2/2) = \exp(-x^2/2)$.

Piège. Dire « c'est sub-gaussien » sans produire le calcul de Markov sur e^{tZ} .

Question d'entretien. Donner des bornes explicites sur $\mathbb{P}(Z \geq x)$ au-delà de Chernoff.

Réponse attendue. Mills : pour $x > 0$, $\frac{x}{1+x^2}\phi(x) \leq \bar{\Phi}(x) \leq \frac{1}{x}\phi(x)$ (9.3), obtenu par intégration par parties sur $\int_x^\infty \phi$.

Piège. Citer seulement l'asymptotique $\sim \phi(x)/x$ sans donner une inégalité utilisable pour un x donné.

Question d'entretien. Montrer que $Z \sim \mathcal{N}(0, 1)$ est sub-gaussien.

Réponse attendue. Par calcul de MGF : $\mathbb{E}[e^{tZ}] = \exp(t^2/2)$. Donc pour tout t , $\log \mathbb{E}[e^{tZ}] = t^2/2$, ce qui est exactement la borne sub-gaussienne avec paramètre 1.

Piège. Écrire une inégalité de Chernoff sans passer par la MGF, ou oublier que la MGF existe pour tout t .

Question d'entretien. Calculer $\mathbb{E}[Z \mathbf{1}_{\{Z > k\}}]$ pour $Z \sim \mathcal{N}(0, 1)$.

Réponse attendue. Intégration par parties avec la densité ϕ : $\mathbb{E}[Z \mathbf{1}_{\{Z > k\}}] = \int_k^\infty z\phi(z)dz = \phi(k)$ car $\phi'(z) = -z\phi(z)$.

Piège. Confondre avec $\mathbb{P}(Z > k)$ (qui vaut $\int_k^\infty \phi$).

Question d'entretien. Dériver la conditionnelle gaussienne $X | Y = y$.

Réponse attendue. Formule 10.1. Méthode 1 : densité jointe et complétion du carré via inversion par blocs (Schur). Méthode 2 : projection L^2 (coefficients $\Sigma_{XY}\Sigma_{YY}^{-1}$) et covariance résiduelle comme complément de Schur.

Piège. Oublier l'hypothèse Σ_{YY} inversible ou oublier le terme $(y - m_Y)$ dans la moyenne.

Question d'entretien. Pourquoi « cov=0 $\Rightarrow$ indépendance » est vrai pour des gaussiennes mais faux en général ?

Réponse attendue. Pour un vecteur gaussien, la loi est déterminée par moyenne et covariance ; une covariance bloc-diagonale force la factorisation de la fonction caractéristique, donc l'indépendance. En général, la covariance ne capture que le second moment : dépendance non linéaire possible avec covariance nulle.

Piège. Dire « parce que la gaussienne est spéciale » sans expliciter « déterminée par (moyenne, covariance) ».

Question d'entretien. Whitening : comment construire W tel que $W(X - m)$ ait covariance I ?

Réponse attendue. Diagonaliser $\Sigma = U\Lambda U^\top$ puis prendre $W = \Lambda^{-1/2}U^\top$ (clipping/troncature si nécessaire).

Piège. Inverser Σ directement sans discuter conditionnement / valeurs propres nulles.

Question d'entretien. Que faire si Σ_{YY} n'est pas inversible dans la formule de conditionnelle ?

Réponse attendue. Deux cas : (i) en théorie, cela signifie qu'il y a une dépendance linéaire (information redondante) ; on peut réduire Y à un sous-espace de dimension $\text{rang}(\Sigma_{YY})$ ou utiliser une pseudo-inverse et travailler sur le support. (ii) en pratique, c'est souvent du rang-déficient (échantillon) : on régularise ($\Sigma_{YY} + \varepsilon I$) ou shrinkage.

Piège. Inverser malgré tout : l'inverse numérique explose et rend la covariance conditionnelle non PSD.

Question d'entretien. Dans la formule $m_X + \Sigma_{XY}\Sigma_{YY}^{-1}(y - m_Y)$, comment lire $\Sigma_{XY}\Sigma_{YY}^{-1}$?

Réponse attendue. C'est le coefficient de régression (best linear predictor) de X sur Y : il convertit une surprise ($y - m_Y$) en correction de moyenne. En Kalman, c'est l'analogue du gain.

Piège. Dire « c'est une corrélation » : c'est une matrice de régression, pas une corrélation.

Question d'entretien. Distance de Mahalanobis : comment la relier à une χ^2 ?

Réponse attendue. Si $X \sim \mathcal{N}(m, \Sigma)$, alors $Q = (X - m)^\top \Sigma^{-1}(X - m) \sim \chi_d^2$ (10.2) via whitening $Z = \Sigma^{-1/2}(X - m)$. En pratique, Q mesure un écart normalisé (outlier/gating).

Piège. Écrire $\|X - m\|^2$ sans Σ^{-1} : c'est la distance euclidienne, pas la distance adaptée à la covariance.

Question d'entretien. Écrire la log-vraisemblance gaussienne et identifier les deux morceaux « coûteux ».

Réponse attendue. Pour $x \sim \mathcal{N}(m, \Sigma)$, $\log f(x)$ contient (i) $-\frac{1}{2} \log \det(\Sigma)$ et (ii) $-\frac{1}{2}(x - m)^\top \Sigma^{-1}(x - m)$ (10.3). Les deux opérations coûteuses sont donc un *log-déterminant* et une *résolution linéaire* (pas une inversion explicite).

Piège. Dire « c'est juste une exponentielle » sans citer $\log \det$ et le terme de Mahalanobis (et sans parler de résolution vs inverse).

Question d'entretien. Pourquoi la covariance empirique est-elle singulière quand $n < d$?

Réponse attendue. La matrice $W = \sum_{i=1}^n Z_i Z_i^\top$ (Wishart) est somme de n matrices de rang ≤ 1 , donc $\text{rank}(W) \leq n$ (10.5). En données centrées, la covariance empirique a même rang $\leq n - 1$. Donc si $n < d$, elle n'est pas PD : pas de Cholesky sans régularisation (shrinkage/jitter).

Piège. Répondre « parce qu'il manque des données » sans argument de rang.

Question d'entretien. Pourquoi le MLE gaussien de Σ utilise-t-il $1/n$ et pas $1/(n - 1)$?

Réponse attendue. Parce que $1/n$ vient du maximum de vraisemblance : en écrivant $\ell(\bar{x}, \Sigma)$ et en dérivant via $J = \Sigma^{-1}$, on obtient $\hat{\Sigma}_{\text{MLE}} = S/n$ (10.4). Le facteur $1/(n - 1)$ est l'estimateur *sans biais* de la covariance (correction de Bessel), pas le maximiseur de ℓ .

Piège. Dire « c'est $1/(n - 1)$ par définition » : en ML, c'est $1/n$; il faut distinguer MLE vs sans biais.

Question d'entretien. Comment calculer vite $\log f(x)$ si $\Sigma = D + UU^\top$ (diagonale + faible rang) ?

Réponse attendue. Utiliser Woodbury et le déterminant lemma : $(D + UU^\top)^{-1} = D^{-1} - D^{-1}U(I + U^\top D^{-1}U)^{-1}U^\top D^{-1}$ et $\log \det(D + UU^\top) = \log \det(D) + \log \det(I + U^\top D^{-1}U)$ (8.2, 8.3). On réduit ainsi à une inversion/déterminant en dimension « rang » (petit).

Piège. Inverser Σ en $d \times d$ ou calculer $\det(\Sigma)$ directement : c'est précisément le piège en grande dimension.

Question d'entretien. Différence martingale vs Markov ?

Réponse attendue. Markov est une propriété de dépendance : le futur dépend du présent (état) mais pas du passé. Martingale est une propriété de moyenne conditionnelle : $\mathbb{E}[M_{t+h} | \mathcal{F}_t] = M_t$. On peut avoir Markov sans martingale (drift) et martingale sans Markov.

Piège. Dire « Markov = sans mémoire » sans préciser « conditionnellement à l'état », et confondre avec martingale.

Question d'entretien. Pourquoi introduire une filtration en finance ?

Réponse attendue. Pour formaliser l'information et l'interdiction d'anticiper. Une stratégie doit être $\mathcal{F}_t$ -mesurable à t ; sinon, backtests et hedges utilisent du futur.

Piège. Parler seulement de « temps » sans mention de mesurabilité/adaptation.

Question d'entretien. Énoncer optional stopping dans une version sûre.

Réponse attendue. Si (M_k) est une martingale intégrable et τ un temps d'arrêt borné, alors $\mathbb{E}[M_\tau] = \mathbb{E}[M_0]$.

Piège. Donner une version trop générale (« pour tout temps d'arrêt ») : faux.

Question d'entretien. Donner un contre-exemple classique à optional stopping sans hypothèses.

Réponse attendue. Ex : marche aléatoire symétrique (S_k) et τ temps d'atteinte d'un niveau (non borné). Selon les détails (intégrabilité, conditionnement), on peut obtenir $\mathbb{E}[S_\tau] \neq \mathbb{E}[S_0]$. Le point entretien : sans bornes/uniforme intégrabilité, l'arrêt optionnel peut échouer.

Piège. Dire « c'est toujours vrai » : c'est précisément faux dès que τ est non borné et que les intégrabilités ne tiennent pas.

Question d'entretien. Comment utiliser l'inégalité de Doob pour contrôler un maximum ?

Réponse attendue. Si (M_k) est une sous-martingale non négative, Doob donne $\mathbb{P}(\max_{k \leq n} M_k \geq \lambda) \leq \mathbb{E}[M_n]/\lambda$. C'est une borne de risque « worst-case » sur le maximum à horizon n .

Piège. Oublier l'hypothèse « non négative » ou « sous-martingale ».

Question d'entretien. Énoncer Azuma–Hoeffding et donner l'idée de preuve.

Réponse attendue. Si (M_k) est une martingale et si $|M_k - M_{k-1}| \leq c_k$, alors $\mathbb{P}(M_n - M_0 \geq x) \leq \exp(-x^2/(2 \sum_{k=1}^n c_k^2))$ (11.3). Preuve : MGF conditionnelle des incréments (Hoeffding conditionnel) $\Rightarrow$ borne sur $\mathbb{E}[e^{t(M_n - M_0)}]$, puis Chernoff.

Piège. Confondre avec Doob : Azuma contrôle une *dévi*ation finale via incréments bornés, Doob contrôle un *maximum* via espérance finale.

Question d'entretien. Construire une supermartingale exponentielle « à la Azuma ».

Réponse attendue. Si $D_k = M_k - M_{k-1}$ et $|D_k| \leq c_k$, alors pour $t > 0$ le processus $Z_k = \exp(t(M_k - M_0) - \frac{t^2}{2} \sum_{i=1}^k c_i^2)$ est une supermartingale : $\mathbb{E}[Z_k | \mathcal{F}_{k-1}] \leq Z_{k-1}$ via Hoeffding conditionnel sur D_k . Ensuite $\mathbb{E}[Z_n] \leq \mathbb{E}[Z_0] = 1$ et Markov sur Z_n redonne Azuma.

Piège. Écrire $Z_k = e^{tM_k}$ sans le terme de compensation $-\frac{t^2}{2} \sum c_i^2$: sans compensation, ce n'est pas une supermartingale.

Question d'entretien. Si les incréments ne sont pas bornés, que faire pour une concentration de martingale ?

Réponse attendue. Azuma demande une borne presque sûre sur $|D_k|$. Si on ne l'a pas, on cherche une hypothèse de type Bernstein : contrôle de la MGF conditionnelle ou de la variance conditionnelle (inégalités de Freedman/Bernstein pour martingales). L'idée reste « exponentielle + tour », mais avec une compensation adaptée au bruit.

Piège. Appliquer Azuma « quand même » : la borne peut devenir fausse si les incréments ont des queues lourdes.

Question d'entretien. Quelle hypothèse typique permet d'étendre optional stopping à un temps d'arrêt non borné ?

Réponse attendue. Il faut une condition d'intégrabilité/contrôle uniforme sur la famille arrêtée, typiquement l'uniforme intégrabilité de $(M_{\tau \wedge n})_n$ ou une borne L^1 suffisante. Sans UI, on peut avoir des contre-exemples (voir §6, Vitali/UI, et le piège dans l'arrêt optionnel).

Piège. Dire « il suffit que ce soit un temps d'arrêt » : c'est précisément faux sans hypothèses d'intégrabilité.

Question d'entretien. Qu'est-ce qu'une « mesure martingale équivalente » en une phrase ?

Réponse attendue. Une mesure $\mathbb{Q}$ équivalente à $\mathbb{P}$ (mêmes ensembles nuls) sous laquelle les prix actualisés des actifs tradables sont des martingales. Elle rend le pricing par espérance conditionnelle cohérent.

Piège. Confondre équivalence ($\mathbb{Q} \sim \mathbb{P}$) et simple absolue continuité ($\mathbb{Q} \ll \mathbb{P}$).

Questions de fin de chapitre (P2 à P9)

Partie II — Instruments, payoffs, arbitrage, taux

Chapitre 1 — Payoffs et produits

Questions d'entretien (réponse attendue + piège)

Exercice 1.1 (Forward : détection d'arbitrage). On observe sur le marché un prix forward $F_0^{mkt}(T)$ pour l'actif S (dividende continu q).

1. Donner la valeur théorique $F_0(T)$ sous absence d'arbitrage.
2. Si $F_0^{mkt}(T) > F_0(T)$, construire une stratégie d'arbitrage et calculer le gain certain à T .

Correction détaillée. Sous absence d'arbitrage, $F_0(T) = S_0 e^{(r-q)T}$. Si $F_0^{mkt}(T) > F_0(T)$, on vend le forward trop cher et on achète le sous-jacent financé :

- acheter 1 sous-jacent aujourd'hui (coût S_0) ;
- emprunter S_0 au taux r ;
- vendre le forward de strike $F_0^{mkt}(T)$.

À T , le forward court livre S_T et reçoit $F_0^{mkt}(T)$. Le portefeuille « action financée » vaut $S_T - S_0 e^{rT}$ (et le carry q est déjà pris en compte dans F_0). Les S_T s'annulent et il reste

$$G_T = F_0^{mkt}(T) - S_0 e^{(r-q)T} = F_0^{mkt}(T) - F_0(T) > 0.$$

□

Exercice 1.2 (Butterfly). Montrer qu'une butterfly de strikes $K_1 < K_2 < K_3$ s'écrit comme combinaison de calls. Donner ensuite son prix en fonction des prix des calls $C_0(K_i)$.

Correction détaillée. Par définition,

$$\Phi(S_T) = (S_T - K_1)^+ - 2(S_T - K_2)^+ + (S_T - K_3)^+.$$

Chaque terme est un call ; par linéarité,

$$V_0 = C_0(K_1) - 2C_0(K_2) + C_0(K_3).$$

Sanity check. Une butterfly approxime une dérivée seconde en strike : son prix contrôle la convexité de $K \mapsto C_0(K)$.

□

Exercice 1.3 (Digital comme call-spread). Fixer K et $\varepsilon > 0$ et considérer

$$\frac{1}{\varepsilon} \left((S_T - K)^+ - (S_T - (K + \varepsilon))^+ \right).$$

1. Tracer ce payoff et montrer qu'il approxime $\mathbf{1}_{S_T \geq K}$.
2. Expliquer le lien avec une dérivée de $C_0(K)$ par rapport à K .

Correction détaillée. Si $S_T < K$, payoff 0. Si $K \leq S_T \leq K + \varepsilon$, payoff $(S_T - K)/\varepsilon \in [0, 1]$. Si $S_T \geq K + \varepsilon$, payoff 1. Quand $\varepsilon \downarrow 0$, on approche l'indicatrice. Le prix est une différence finie de $C_0(K)$, donc approxime $-\partial_K C_0(K)$ (digitale) : c'est l'intuition de Breeden–Litzenberger. $\square$

Exercice 1.4 (Straddle et points morts). Donner le payoff d'un straddle (call + put de strike K) et en déduire ses points morts.

Exercice 1.5 (Covered call). Définir une stratégie *covered call* (long 1 action + short 1 call). Tracer le payoff, puis commenter en 3 lignes le profil rendement/risque.

Exercice 1.6 (Dépendance au chemin). Parmi : vanilla, asiatique (moyenne), lookback (max), barrière, indiquer lesquels dépendent du chemin et pourquoi cela change la méthode de pricing.

Exercice 1.7 (Linéarité des prix). Soient Φ_1, Φ_2 et $a, b \in \mathbb{R}$. Justifier pourquoi $V(a\Phi_1 + b\Phi_2) = aV(\Phi_1) + bV(\Phi_2)$ sous absence d'arbitrage.

Exercice 1.8 (Taux et payoffs de taux). Donner un exemple de payoff de taux (caplet ou floorlet) et expliquer quel objet joue le rôle de « sous-jacent ».

Chapitre 2 — Absence d'arbitrage et relations statiques

Questions d'entretien (réponse attendue + piège)

Exercice 2.1 (Parité call–put, trois preuves). Établir (2.2) (i) par payoffs, (ii) par arbitrage, (iii) via $\mathbb{Q}$.

Correction détaillée. Les trois approches sont détaillées dans la section *Mode microscope*. Point-clé : actualisation de K et traitement du dividende via $S_0 e^{-qT}$. $\square$

Exercice 2.2 (Breeden–Litzenberger). En partant de $C_0(K, T) = e^{-rT} \mathbb{E}^\mathbb{Q}[(S_T - K)^+]$, démontrer (2.3).

Correction détaillée. On écrit $C_0(K, T) = e^{-rT} \int_K^{+\infty} (s - K) f(s) ds$. Derivation (Leibniz) $\Rightarrow \partial_K C_0 = -e^{-rT} \int_K^{+\infty} f(s) ds$ puis $\partial_{KK} C_0 = e^{-rT} f(K)$. Si C_0 n'est pas C^2 , la relation se lit au sens des distributions (butterfly discrète). $\square$

Exercice 2.3 (Réplication statique d'un payoff convexe). Soit Φ convexe et C^2 sur $(0, +\infty)$. Montrer que

$$\Phi(S_T) = \Phi(0) + \Phi'(0)S_T + \int_0^{+\infty} (S_T - K)^+ \Phi''(K) dK.$$

En déduire une formule (intégrale) de prix en fonction des calls $C_0(K, T)$.

Correction détaillée. Pour $s > 0$, deux intégrations par parties / Taylor avec reste intégral donnent $\Phi(s) = \Phi(0) + \Phi'(0)s + \int_0^s (s - K) \Phi''(K) dK$. Or $(s - K) \mathbf{1}_{K \leq s} = (s - K)^+$, d'où la formule. En prenant $\mathbb{Q}$ -espérance et en actualisant :

$$V_0(\Phi) = e^{-rT} \left(\Phi(0) + \Phi'(0) \mathbb{E}^\mathbb{Q}[S_T] \right) + \int_0^{+\infty} C_0(K, T) \Phi''(K) dK,$$

avec $\mathbb{E}^\mathbb{Q}[S_T] = S_0 e^{(r-q)T}$. $\square$

Exercice 2.4 (Bornes d'arbitrage). Donner des bornes inférieure/supérieure pour $C_0(K, T)$ et $P_0(K, T)$ (avec et sans dividendes).

Exercice 2.5 (Monotonie et convexité en strike). Montrer que $K \mapsto C_0(K, T)$ est décroissante et convexe, et interpréter via calls-spreads/butterflies.

Exercice 2.6 (Digitale et call-spread). Expliquer comment approximer $\mathbb{Q}(S_T \geq K)$ à partir de différences finies de $C_0(K, T)$.

Exercice 2.7 (Arbitrage butterfly discrète). Pour $K_1 < K_2 < K_3$ équidistants, montrer que si $C_0(K_2) > \frac{1}{2}(C_0(K_1) + C_0(K_3))$ alors une butterfly donne un arbitrage.

Exercice 2.8 (Densité implicite et bruit de cotation). Pourquoi l'estimation numérique de $\partial_{KK} C$ est-elle instable ? Proposer une idée simple de régularisation (qualitative).

Chapitre 3 — Pricing discret et mesure risque-neutre

Questions d'entretien (réponse attendue + piège)

Exercice 3.1 (Call à un pas). Dans un modèle à un pas, calculer le prix d'un call européen de strike K . Faire le calcul par (i) réplication et (ii) espérance sous p .

Correction détaillée. On calcule $H_u = (S_0 u - K)^+$ et $H_d = (S_0 d - K)^+$ puis

$$\Delta = \frac{H_u - H_d}{S_0(u - d)}, \quad b = \frac{H_d - \Delta S_0 d}{1 + R}, \quad V_0 = \Delta S_0 + b.$$

Équivalent : $p = \frac{(1+R)-d}{u-d}$ et $V_0 = \frac{pH_u + (1-p)H_d}{1+R}$. □

Exercice 3.2 (Condition d'absence d'arbitrage). Montrer que si $1 + R$ *led* ou $1 + R$ *geu* alors il existe une stratégie d'arbitrage.

Correction détaillée. Si $1 + R$

led, même dans l'état down l'actif bat le cash : acheter l'actif et emprunter au taux R donne un gain certain. Si $1 + R$

geu, l'actif est dominé par le cash : vendre l'actif et placer au taux R donne un gain certain. □

Exercice 3.3 (Probabilité risque-neutre CRR). Dans CRR, $u = e^{\sigma\sqrt{\Delta t}}$ et $d = e^{-\sigma\sqrt{\Delta t}}$. Écrire p et discuter quand $p \in (0, 1)$.

Correction détaillée.

$$p = \frac{e^{r\Delta t} - e^{-\sigma\sqrt{\Delta t}}}{e^{\sigma\sqrt{\Delta t}} - e^{-\sigma\sqrt{\Delta t}}}.$$

On a $p \in (0, 1)$ ssi $d < e^{r\Delta t} < u$: le taux sans risque doit être entre les rendements possibles. □

Exercice 3.4 (Delta de couverture). Exprimer Δ en fonction de H_u et H_d et commenter son interprétation (sensibilité discrète).

Exercice 3.5 (Modèle à deux pas). Écrire la formule de prix d'un payoff $H(S_2)$ dans un arbre à deux pas en termes de la loi binomiale sous p .

Exercice 3.6 (Put américain : intuition). Pourquoi l'exercice anticipé peut-il être optimal pour un put (dans un modèle discret) ? Donner un exemple jouet.

Exercice 3.7 (Martingale actualisée). Montrer que $\tilde{S}_n := S_n / (1 + R)^n$ est une martingale sous $\mathbb{Q}$.

Exercice 3.8 (Convergence vers Black-Scholes (qualitative)). Expliquer qualitativement pourquoi, quand $\Delta t \rightarrow 0$ avec CRR, on converge vers le pricing continu.

Chapitre 4 — Construction de courbes : bootstrap

Questions d'entretien (réponse attendue + piège)

Exercice 4.1 (Dépôt $\rightarrow$ discount factor). Un dépôt à maturité T cote $L(0, T)$ avec accrual δ . Donner $P(0, T)$ et en déduire $R(0, T)$ en capitalisation continue.

Correction détaillée. Sous compounding simple, $P(0, T) = 1 / (1 + \delta L(0, T))$. Le taux continu équivalent est $R(0, T) = -(1/T) \ln P(0, T)$. □

Exercice 4.2 (Bootstrap de swap). On suppose connus $P(0, T_1), \dots, P(0, T_{n-1})$. Un swap par de maturité T_n cote $S(0, T_n)$. Dériver la formule explicite de $P(0, T_n)$.

Correction détaillée. Partir de $1 - P(0, T_n) = S \sum_{i=1}^n \delta_i P(0, T_i)$. Regrouper les termes en $P(0, T_n)$:

$$P(0, T_n)(1 + S\delta_n) = 1 - S \sum_{i=1}^{n-1} \delta_i P(0, T_i),$$

d'où la formule. □

Exercice 4.3 (Forward rate). En partant de $P(0, T_1)$ et $P(0, T_2)$, exprimer le forward simple $F(0; T_1, T_2)$.

Correction détaillée. Par définition, $1 + \delta F = P(0, T_1)/P(0, T_2)$, donc $F = \frac{1}{\delta} \left(\frac{P(0, T_1)}{P(0, T_2)} - 1 \right)$. □

Exercice 4.4 (Monotonie). Donner des conditions qualitatives pour que $P(0, T)$ soit décroissant. Que signifierait un $P(0, T)$ croissant ?

Exercice 4.5 (Changement de convention). Montrer comment passer d'un taux simple à un taux continu sur $[0, T]$.

Exercice 4.6 (Sensibilité). Comment une erreur relative ε sur $P(0, T)$ se traduit-elle sur $R(0, T)$? Donner une approximation linéaire.

Exercice 4.7 (Interpolation). Proposer une interpolation simple de $\ln P(0, T)$ entre deux maturités et expliquer pourquoi c'est stable.

Exercice 4.8 (Sanity-check de swap). Pourquoi $S(0, T)$ doit-il être « compatible » avec les $P(0, T_i)$? Donner une intuition sans formalisme lourd.

Chapitre 5 — Nelson–Siegel–Svensson : modèle et calibration

Questions d'entretien (réponse attendue + piège)

Exercice 5.1 (Limites de $y(T)$). Calculer $\lim_{T \rightarrow \infty} y(T)$ et $\lim_{T \downarrow 0} y(T)$ en fonction des paramètres.

Correction détaillée. Quand $T \rightarrow \infty$, tous les termes exponentiels s'annulent, donc $y(T) \rightarrow \beta_0$. Quand $T \downarrow 0$, $(1 - e^{-T/\tau})/(T/\tau) \rightarrow 1$ et les termes de courbure se compensent, donc $y(0^+) \approx \beta_0 + \beta_1$. □

Exercice 5.2 (Forward instantané). Montrer que $f(T) = y(T) + Ty'(T)$ et expliquer comment obtenir $f(T)$ sous NSS.

Correction détaillée. Comme $P(0, T) = \exp(-Ty(T))$, on a $\ln P(0, T) = -Ty(T)$ et donc $f(T) = -\partial_T \ln P(0, T) = y(T) + Ty'(T)$. Sous NSS, on dérive explicitement $y(T)$. □

Exercice 5.3 (Interprétation des paramètres). Interpréter qualitativement $\beta_0, \beta_1, \beta_2, \beta_3$ et le rôle des échelles τ_1, τ_2 . Donner un sanity-check sur les ordres de grandeur.

Correction détaillée. β_0 fixe le niveau long terme ; β_1 la pente court terme (car $y(0^+) \approx \beta_0 + \beta_1$) ; β_2 ajoute une bosse/crue autour de l'échelle τ_1 ; β_3 une seconde courbure autour de τ_2 . Sanity-check : des τ trop petits concentrent la bosse à très court terme ; des τ trop grands miment un changement de niveau/pente (colinéarité). □

Exercice 5.4 (Calibration LS). Écrire un problème de moindres carrés pour calibrer NSS sur des rendements observés $y^{mkt}(T_i)$. Que changent les poids w_i ?

Exercice 5.5 (Calibration sur prix). Si on observe $P^{mkt}(0, T_i)$, proposer une calibration sur les prix. Pourquoi cela peut-il être plus stable ?

Exercice 5.6 (Régularisation). Proposer une pénalisation simple qui évite des τ extrêmes (idée qualitative).

Exercice 5.7 (Sensibilité). Discuter qualitativement comment une variation de β_1 affecte $y(T)$ pour petits T vs grands T .

Exercice 5.8 (Extrapolation). Quels risques à extrapoler NSS au-delà des maturités observées ? Donner deux symptômes.

Partie III — Variation quadratique & Itô

Chapitre 1 — Variation quadratique

Questions d'entretien (réponse attendue + piège)

Exercice 1.1 (Scaling). Montrer que si $X_t = aW_t$ alors $[X]_t = a^2t$.

Correction détaillée. Sur une partition π , $Q_\pi(aW) = \sum_i (a\Delta W_i)^2 = a^2 \sum_i (\Delta W_i)^2 = a^2 Q_\pi(W)$. Comme $Q_\pi(W) \rightarrow t$, on obtient $Q_\pi(aW) \rightarrow a^2t$. $\square$

Exercice 1.2 (Variation finie). Soit $A_t = \int_0^t a_s ds$ avec a borné. Montrer que $[A]_t = 0$.

Correction détaillée. A est de variation finie : $\sum_i |\Delta A_i| \leq \int_0^t |a_s| ds < \infty$. De plus, $|\Delta A_i| \leq \|a\|_\infty (t_{i+1} - t_i) \leq \|a\|_\infty |\pi|$. Donc

$$Q_\pi(A) = \sum_i (\Delta A_i)^2 \leq \max_i |\Delta A_i| \sum_i |\Delta A_i| \leq (\|a\|_\infty |\pi|) \int_0^t |a_s| ds \rightarrow 0.$$

$\square$

Exercice 1.3 (Preuve de la qv du Brownien). Reprendre le calcul $\mathbb{E}[Q_\pi(W)]$ et $\text{Var}(Q_\pi(W))$ pour montrer $Q_\pi(W) \rightarrow t$ dans L^2 .

Correction détaillée. C'est exactement l'argument du *Mode microscope* : $\mathbb{E}[Q_\pi(W)] = t$ et $\text{Var}(Q_\pi(W)) \leq 2t|\pi| \rightarrow 0$. Donc $\mathbb{E}[(Q_\pi(W) - t)^2] \rightarrow 0$. $\square$

Exercice 1.4 (Covariation). Définir $[X, Y]_t$ par polarisation et montrer que $[W, W]_t = t$ et $[W, -W]_t = -t$.

Exercice 1.5 (Covariation avec le temps). Montrer que $[t, W]_t = 0$.

Exercice 1.6 (Somme). Montrer que $[X + Y]_t = [X]_t + [Y]_t + 2[X, Y]_t$.

Exercice 1.7 (Quadratic variation d'une martingale simple). Si $M_t = \sum_{k=1}^n c_k (W_{t \wedge t_k} - W_{t \wedge t_{k-1}})$, calculer $[M]_t$.

Exercice 1.8 (Intuition de rugosité). Expliquer pourquoi la variation totale $\sum_i |\Delta W_i|$ diverge quand $|\pi| \rightarrow 0$, alors que $\sum_i (\Delta W_i)^2$ converge.

Chapitre 2 — Intégrale et lemme d'Itô

Questions d'entretien (réponse attendue + piège)

Exercice 2.1 (Itô sur W_t^2). Appliquer Itô à $f(x) = x^2$ avec $X_t = W_t$. En déduire une décomposition de $W_t^2 - t$.

Correction détaillée. Pour $f(x) = x^2$, $f'(x) = 2x$, $f''(x) = 2$. Itô donne $d(W_t^2) = 2W_t dW_t + 1 \cdot dt$ donc

$$W_t^2 = 2 \int_0^t W_s dW_s + t.$$

Ainsi, $W_t^2 - t = 2 \int_0^t W_s dW_s$ est une martingale. $\square$

Exercice 2.2 (Itô sur $\ln S_t$). Si $dS_t = \mu S_t dt + \sigma S_t dW_t$ (mouvement brownien géométrique), appliquer Itô à $f(s) = \ln s$ et donner $d(\ln S_t)$.

Correction détaillée. $f'(s) = 1/s$, $f''(s) = -1/s^2$. Itô :

$$d(\ln S_t) = \frac{1}{S_t} dS_t + \frac{1}{2} \left(-\frac{1}{S_t^2} \right) (\sigma^2 S_t^2) dt = \left(\mu - \frac{1}{2} \sigma^2 \right) dt + \sigma dW_t.$$

$\square$

Exercice 2.3 (Stratonovich vs Itô). Soit $H_t = W_t$. Calculer $\int_0^t W_s \circ dW_s$ et $\int_0^t W_s dW_s$ et comparer.

Correction détaillée. En Itô, on sait (exercice précédent) que $d(W_t^2) = 2W_t dW_t + dt$, donc $\int_0^t W_s dW_s = \frac{1}{2}(W_t^2 - t)$. En Stratonovich, la règle de chaîne est « classique » : $d(W_t^2) = 2W_t \circ dW_t$, donc $\int_0^t W_s \circ dW_s = \frac{1}{2}W_t^2$. La différence vaut $\frac{1}{2}t$, cohérente avec la formule de conversion. $\square$

Exercice 2.4 (Isométrie). Montrer l'isométrie d'Itô pour un processus simple, puis expliquer comment elle permet l'extension par limite L^2 .

Exercice 2.5 (Produit d'Itô). Si X_t et Y_t sont des Itô processes, écrire $d(X_t Y_t)$ et identifier le terme de covariation.

Exercice 2.6 (Martingale). Donner une condition simple sur a_t, b_t pour que X_t (Itô process) soit une martingale.

Exercice 2.7 (Inégalité de Burkholder (qualitative)). Expliquer qualitativement pourquoi $\sup_{s \leq t} \left| \int_0^s H_u dW_u \right|$ se contrôle par $\left(\int_0^t H_u^2 du \right)^{1/2}$.

Exercice 2.8 (Changement de variable). Pour $X_t = W_t + t$, calculer $d(f(X_t))$ et identifier les termes dt et dW_t .

Partie IV — Black–Scholes

Chapitre 1 — Black–Scholes : dérivation et formule

Questions d’entretien (réponse attendue + piège)

Exercice 1.1 (Dérivation PDE). Reprendre la dérivation de la PDE (1.31) en détaillant : (i) Itô sur $V(t, S_t)$, (ii) construction de Π_t , (iii) choix $\Delta = \partial_S V$, (iv) condition $d\Pi = r\Pi dt$.

Correction détaillée. La dérivation est celle de la section *Mode microscope*. Point technique : en présence de dividende q , le gain sur une position courte en S inclut $-q\Delta S dt$. Le terme $\frac{1}{2}\sigma^2 S^2 V_{SS}$ vient de $(dS)^2 = \sigma^2 S^2 dt$. $\square$

Exercice 1.2 (Formule fermée du call). À partir de la loi lognormale de S_T sous $\mathbb{Q}$, dériver la formule du call (1.32). Indication : écrire $(S_T - K)^+ = S_T \mathbf{1}_{S_T \geq K} - K \mathbf{1}_{S_T \geq K}$ et standardiser.

Correction détaillée. On écrit $C_0 = e^{-rT} \mathbb{E}^\mathbb{Q}[(S_T - K)^+]$ et on décompose :

$$\mathbb{E}[S_T \mathbf{1}_{S_T \geq K}] = S_0 e^{(r-q)T} N(d_1), \quad \mathbb{E}[\mathbf{1}_{S_T \geq K}] = N(d_2),$$

obtenus par changement de variable $Z = \frac{\ln S_T - m}{\sigma\sqrt{T}}$ avec $m = \ln S_0 + (r - q - \frac{1}{2}\sigma^2)T$. En combinant et en actualisant, on obtient (1.32). $\square$

Exercice 1.3 (Delta du call). Montrer que $\Delta = e^{-qT} N(d_1)$ pour le call et commenter l’interprétation de couverture.

Correction détaillée. On dérive (1.32) par rapport à S_0 . Le terme en $Ke^{-rT} N(d_2)$ contribue via $d_2(S_0)$, mais il se simplifie avec celui du premier terme (identité classique $S_0 e^{-qT} \varphi(d_1) = Ke^{-rT} \varphi(d_2)$). On obtient $\Delta = e^{-qT} N(d_1)$. Interprétation : couverture locale « quantité de sous-jacent » pour neutraliser les petits mouvements. $\square$

Exercice 1.4 (Put via parité). Dédurre la formule du put européen à partir de (1.32) et de la parité call–put.

Exercice 1.5 (Limite $\sigma \rightarrow 0$). Interpréter la limite du call quand $\sigma \rightarrow 0$: quel payoff obtient-on ?

Exercice 1.6 (Signe de Vega). Justifier pourquoi la vega d’un call européen est positive.

Exercice 1.7 (Theta (qualitatif)). Pourquoi une option vanille longue a-t-elle typiquement un theta négatif ? Relier à l’intuition « assurance ».

Exercice 1.8 (Sanity-check de parité). Avec $q = 0$, vérifier numériquement (exemple jouet) que $C_0 - P_0 = S_0 - Ke^{-rT}$.

Chapitre 2 — Compléments Black–Scholes

Questions d’entretien (réponse attendue + piège)

Exercice 2.1 (Newton pour σ_{imp}). Écrire une itération de Newton pour résoudre $BS(\sigma) = C^{mkt}$. Quels critères simples de stopping proposer (précision sur le prix vs sur σ) ?

Correction détaillée.

$$\sigma^{(n+1)} = \sigma^{(n)} - \frac{BS(\sigma^{(n)}) - C^{mkt}}{\text{Vega}(\sigma^{(n)})}.$$

Stopping : (i) $|BS(\sigma^{(n)}) - C^{mkt}| < \varepsilon$ (prix), (ii) $|\sigma^{(n+1)} - \sigma^{(n)}| < \varepsilon_\sigma$. En pratique on borne σ et on fallback bisection si Newton sort des bornes. $\square$

Exercice 2.2 (Signe de la vega). Montrer que la vega d’un call européen est positive et donner son expression.

Correction détaillée. Depuis 1, $\text{Vega} = S_0 e^{-qT} \varphi(d_1) \sqrt{T}$. Comme $S_0 > 0$, $e^{-qT} > 0$, $\varphi(d_1) > 0$ et $\sqrt{T} > 0$, la vega est positive. $\square$

Exercice 2.3 (Smile et densité). Rappeler la formule de Breeden–Litzenberger et expliquer pourquoi un smile non plat implique une densité non lognormale.

Correction détaillée. Breeden–Litzenberger : $\partial_{KK}C_0(K, T) = e^{-rT} f_{S_T}^{\mathbb{Q}}(K)$. Si la densité était lognormale, les prix de call seraient exactement ceux de Black–Scholes avec une même σ (smile plat). Un smile non plat signifie que pour coller à $C^{mkt}(K)$, il faut changer σ selon K : donc la lognormalité est violée. $\square$

Exercice 2.4 (Limite $T \rightarrow 0$). Discuter la limite de C_0 quand $T \downarrow 0$ et relier au payoff immédiat.

Exercice 2.5 (Smile et arbitrage statique). Quelles contraintes d’absence d’arbitrage en K doit respecter une surface de prix (ou de vol implicite) ?

Exercice 2.6 (Implied vol et normalisation). Pourquoi cotons-nous souvent en log-moneyness $k = \ln(K/F)$ plutôt qu’en K brut ?

Exercice 2.7 (Choix de méthode numérique). Donner, pour chaque famille (arbres, PDE, Monte Carlo, Fourier), un cas où elle est naturelle et un cas où elle est fragile.

Exercice 2.8 (Sanity check de Newton). Proposer une initialisation simple de σ et expliquer pourquoi elle doit dépendre de T et du moneyness.

Partie V — Sauts, Heston, Fourier/fft

Chapitre 1 — Jump diffusion

Questions d'entretien (réponse attendue + piège)

Exercice 1.1 (Mélange lognormal). Démontrer la formule de mélange (1.15) en conditionnant sur N_T .

Correction détaillée. Conditionner : $C_0 = e^{-rT} \sum_{n \geq 0} \mathbb{E}[(S_T - K)^+ | N_T = n] \mathbb{Q}(N_T = n)$. Sous $N_T = n$, $\ln S_T$ est normale de paramètres (m_n, v_n) , donc $\mathbb{E}[(S_T - K)^+] = e^{m_n + v_n/2} N(d_1^{(n)}) - K N(d_2^{(n)})$. Multiplier par e^{-rT} et sommer avec p_n . $\square$

Exercice 1.2 (Drift ajusté). Pourquoi ajoute-t-on $-\lambda\kappa$ dans le drift ? Calculer $\mathbb{E}^\mathbb{Q}[S_T]$ et vérifier la cohérence avec $r - q$.

Correction détaillée. On veut $e^{-(r-q)T} \mathbb{E}^\mathbb{Q}[S_T] = S_0$ (martingale de $S_t e^{-(r-q)t}$). Or chaque jump multiplie S par J et $\mathbb{E}[J] = 1 + \kappa$. Le terme $-\lambda\kappa$ compense l'espérance de gain des jumps (intensité λ) pour garder le carry $r - q$. $\square$

Exercice 1.3 (PIDE). En partant du générateur d'un processus avec sauts multiplicatifs, justifier la forme de la PIDE de pricing.

Correction détaillée. Le générateur contient (i) la partie diffusion (termes V_S, V_{SS}) et (ii) une partie jump $\lambda \mathbb{E}[V(t, SJ) - V(t, S)]$. Sous $\mathbb{Q}$, l'équation (Feynman-Kac) est $\partial_t V + \mathcal{L}V - rV = 0$ avec condition terminale. Le drift de $\mathcal{L}$ est $(r - q - \lambda\kappa)S$. $\square$

Exercice 1.4 (Réduction à BS). Montrer que quand $\lambda = 0$, la PIDE se réduit à la PDE de Black-Scholes.

Exercice 1.5 (Queues et smile (qualitatif)). Expliquer qualitativement pourquoi des sauts augmentent les prix des options OTM.

Exercice 1.6 (Troncature du mélange). Proposer un critère simple pour tronquer la somme sur n dans (1.15) et contrôler l'erreur (qualitatif).

Exercice 1.7 (Sensibilité à λ). À paramètres de jump fixés, discuter qualitativement l'effet d'une augmentation de λ sur les prix et la surface de vol.

Exercice 1.8 (Sanity checks). Donner deux sanity-checks simples sur la PIDE (signes, limite $K \rightarrow \infty$, etc.).

Chapitre 2 — Heston

Questions d'entretien (réponse attendue + piège)

Exercice 2.1 (Réduction à BS). Montrer que si $\xi = 0$ et $v_t \equiv v_0$, alors le modèle se réduit à Black-Scholes avec $\sigma = \sqrt{v_0}$.

Correction détaillée. Si $\xi = 0$ et $v_t = v_0$, alors $dS_t/S_t = (r - q)dt + \sqrt{v_0} dW_t^S$: c'est exactement un GBM de volatilité $\sigma = \sqrt{v_0}$. Toutes les formules de BS s'appliquent. $\square$

Exercice 2.2 (Condition de Feller (qualitatif)). Rappeler la condition de Feller $2\kappa\theta \geq \xi^2$ et expliquer qualitativement ce qu'elle garantit.

Correction détaillée. Pour un processus CIR, $2\kappa\theta \geq \xi^2$ empêche d'atteindre 0 (ou rend 0 non-atteignable selon versions). Cela stabilise la variance (pas de « variance négative »). En pratique, même si violée, on peut encore simuler/pricer, mais avec plus de précautions numériques. $\square$

Exercice 2.3 (Riccati : idée d'identification). En utilisant l'ansatz affine $f = \exp(C + Dv + iux)$ pour la fonction caractéristique, expliquer pourquoi D doit satisfaire une équation de Riccati.

Correction détaillée. En injectant f dans la PDE $\partial_t f + \mathcal{L}f = 0$, on obtient une identité du type $(\partial_t C + \partial_t D v) + (\text{termes constants}) + (\text{termes en } v) + (\text{termes en } v^2) = 0$. Comme l'égalité doit valoir pour tout v , les coefficients en 1 , v et v^2 doivent s'annuler. Le coefficient en v^2 impose une forme quadratique en D , d'où une Riccati. $\square$

Exercice 2.4 (Rôle de ρ). Discuter qualitativement l'effet de $\rho < 0$ sur le skew de vol implicite.

Exercice 2.5 (Stationnarité). Quel est le niveau moyen de v_t ? Que se passe-t-il quand κ est grand vs petit?

Exercice 2.6 (Moments). Donner un argument qualitatif pour expliquer pourquoi ξ augmente la convexité (gamma/vega effectives) des options.

Exercice 2.7 (Calibration). Quels paramètres sont typiquement les plus sensibles à (i) ATM, (ii) skew court terme, (iii) term-structure? Discussion qualitative.

Exercice 2.8 (Sanity checks). Donner deux checks simples sur des paramètres calibrés (positivité, ordres de grandeur, stabilité).

Chapitre 3 — Carr–Madan (FFT)

Questions d'entretien (réponse attendue + piège)

Exercice 3.1 (Relation $\Delta u \Delta k = 2\pi/N$). Justifier la relation de grille entre pas Fourier Δu et pas en log-strike Δk pour une FFT de taille N .

Correction détaillée. La FFT implémente une transformée discrète avec périodisation sur une fenêtre de longueur N . Pour que le terme e^{-iuk} s'échantillonne correctement, il faut que les grilles soient duales : $u_j = j\Delta u$ et $k_m = k_0 + m\Delta k$ avec $\Delta u \Delta k = 2\pi/N$ (dualité Fourier discrète). $\square$

Exercice 3.2 (Choix de α). Pourquoi introduit-on un amortissement α ? Donner un critère qualitatif pour choisir α .

Correction détaillée. Sans amortissement, la transformée du call n'est pas intégrable car $C(K)$ décroît trop lentement en K . Multiplier par $e^{\alpha k}$ force une décroissance suffisante. On choisit α assez grand pour l'intégrabilité, mais pas trop pour éviter d'amplifier les erreurs/aliasing. $\square$

Exercice 3.3 (Sanity check : récupération BS). Si l'on prend ϕ correspondant à Black–Scholes, expliquer pourquoi Carr–Madan doit redonner le prix BS (à l'erreur numérique près).

Correction détaillée. La formule Carr–Madan est une identité mathématique (inversion Fourier) tant que les conditions d'intégrabilité sont satisfaites. En injectant la fonction caractéristique BS (lognormale), on obtient le même prix que l'espérance BS. Les écarts viennent uniquement de la discrétisation (pas, troncature, Simpson/quad). $\square$

Exercice 3.4 (Aliases). Expliquer qualitativement ce qu'est l'aliasing et comment le réduire (fenêtrage, choix de N , pas).

Exercice 3.5 (Troncature de l'intégrale). Pourquoi doit-on tronquer $u \in [0, \infty)$ en $[0, u_{\max}]$? Proposer un sanity-check pour $u_{\max}$.

Exercice 3.6 (Pondérations). Pourquoi utilise-t-on souvent une pondération de Simpson dans l'intégrale discrète?

Exercice 3.7 (Branches complexes). Dans les intégrales Fourier, pourquoi faut-il faire attention aux logarithmes/puissances complexes (choix de branche)?

Exercice 3.8 (Diagnostic). Donner deux diagnostics simples d'un pricer FFT qui « part » : oscillations en strike, prix négatifs, convexité cassée.

Partie VI — Kalman (estimation)

Chapitre 1 — Kalman théorie

Questions d'entretien (réponse attendue + piège)

Exercice 1.1 (Conditionnement gaussien). Démontrer (1.20) par complétion du carré.

Correction détaillée. On écrit la densité jointe proportionnelle à $\exp(-\frac{1}{2}z^\top \Sigma^{-1}z)$ avec $z = (x - m_x, y - m_y)$. En fixant y , l'exposant devient une forme quadratique en x : $\frac{1}{2}(x - \mu)^\top \Lambda(x - \mu) + \text{const}$, où Λ est le bloc xx de Σ^{-1} . En identifiant μ et Λ^{-1} , on obtient la moyenne et la covariance conditionnelles. $\square$

Exercice 1.2 (Gain de Kalman). À partir du joint (x_t, y_t) , retrouver $K_t = P_{t|t-1}H^\top S_t^{-1}$.

Correction détaillée. On applique (1.20) avec $\Sigma_{xy} = P_{t|t-1}H^\top$ et $\Sigma_{yy} = S_t$. Donc $\mathbb{E}[x_t | y_t] = m_{t|t-1} + P_{t|t-1}H^\top S_t^{-1}(y_t - Hm_{t|t-1})$. $\square$

Exercice 1.3 (Covariance mise à jour). Montrer que $P_t = P_{t|t-1} - K_t S_t K_t^\top$ et expliquer pourquoi $P_t \succeq 0$.

Correction détaillée. La formule est la covariance conditionnelle de (1.20). Comme on soustrait un terme PSD à $P_{t|t-1}$, on reste PSD (au moins en exact arithmétique). En pratique, on utilise parfois la forme de Joseph pour préserver la PSD numériquement. $\square$

Exercice 1.4 (Dimensions). Donner les dimensions de A, Q, H, R, P, K, S dans le cas $x \in \mathbb{R}^n, y \in \mathbb{R}^m$.

Exercice 1.5 (Cas scalaire). Écrire le filtre en dimension 1 et interpréter K_t comme un poids entre prédiction et observation.

Exercice 1.6 (Riccati). Pourquoi l'équation sur P_t est-elle une Riccati discrète ? Discussion qualitative.

Exercice 1.7 (Observabilité (qualitative)). Que se passe-t-il si H ne permet pas d'observer certaines directions de l'état ?

Exercice 1.8 (Choix de Q, R). Donner une interprétation pratique de Q et R et expliquer l'effet d'un mauvais choix sur les estimations.

Chapitre 2 — Kalman pratique

Questions d'entretien (réponse attendue + piège)

Exercice 2.1 (Log-vraisemblance). Justifier la formule (2.13) en partant de $\varepsilon_t \sim \mathcal{N}(0, S_t)$.

Correction détaillée. La densité gaussienne est $(2\pi)^{-m/2}(\det S_t)^{-1/2} \exp(-\frac{1}{2}\varepsilon_t^\top S_t^{-1}\varepsilon_t)$. Les innovations sont conditionnellement indépendantes, donc on somme les logs et on retire les constantes. $\square$

Exercice 2.2 (Initialisation). Proposer une initialisation simple de (m_0, P_0) et discuter l'impact sur les premières itérations.

Correction détaillée. On peut prendre $m_0 = \mathbb{E}[x_0]$ (ou 0) et P_0 grand (prior vague) pour laisser les données corriger vite. Un P_0 trop petit fige l'état au début ; un P_0 trop grand peut amplifier le bruit mais se corrige. $\square$

Exercice 2.3 (Lisseur RTS). Écrire l'étape de lissage $m_{t|T} = m_t + J_t(m_{t+1|T} - m_{t+1|t})$ et interpréter J_t .

Correction détaillée. J_t est un gain de lissage : il mesure combien l'erreur future $(m_{t+1|T} - m_{t+1|t})$ doit corriger l'état à t . Il dépend de l'incertitude P_t et de la dynamique A . $\square$

Exercice 2.4 (Diagnostics). Donner deux diagnostics simples à partir des innovations (autocorrélation, normalité, variance).

Exercice 2.5 (Stabilité numérique). Pourquoi préfère-t-on une factorisation (Cholesky) à une inversion directe de S_t ?

Exercice 2.6 (Complexité). Donner l'ordre de complexité en fonction des dimensions n (état) et m (observation).

Exercice 2.7 (Calibration). Comment utiliser (2.13) pour calibrer un paramètre de Q ? Décrire qualitativement la boucle.

Exercice 2.8 (Cas finance). Donner un exemple d'état latent en finance (volatilité/facteur de taux) et expliquer ce que représente y_t .

Partie VII — Allocation & rebalancement

Chapitre 1 — Allocation & rebalancement

Questions d'entretien (réponse attendue + piège)

Exercice 1.1 (GMV : dérivation par Lagrangien). Retrouver la formule (1.2) en écrivant le Lagrangien et les FOC. Préciser où l'on utilise $\Sigma \succ 0$.

Correction détaillée. On pose $\mathcal{L}(w, \lambda) = w^\top \Sigma w - \lambda(\mathbf{1}^\top w - 1)$. FOC : $2\Sigma w - \lambda \mathbf{1} = 0$, donc $w = (\lambda/2)\Sigma^{-1}\mathbf{1}$ (ici on utilise l'inversibilité, donc $\Sigma \succ 0$). En imposant $\mathbf{1}^\top w = 1$, on obtient $\lambda/2 = 1/(\mathbf{1}^\top \Sigma^{-1}\mathbf{1})$ et donc $w^{\text{GMV}} = \Sigma^{-1}\mathbf{1}/(\mathbf{1}^\top \Sigma^{-1}\mathbf{1})$. La stricte convexité (quand $\Sigma \succ 0$) garantit l'unicité. $\square$

Exercice 1.2 (GMV : calcul numérique sur 3 actifs). Avec la covariance

$$\Sigma = \begin{pmatrix} 0.04 & 0.004 & 0.003 \\ 0.004 & 0.01 & 0.0045 \\ 0.003 & 0.0045 & 0.0225 \end{pmatrix},$$

calculer w^{GMV} et la vol du portefeuille.

Correction détaillée. On calcule $v = \Sigma^{-1}\mathbf{1} \approx (14.813, 82.378, 25.994)^\top$ et $\mathbf{1}^\top v \approx 123.184$. Donc $w^{\text{GMV}} = v/(\mathbf{1}^\top v) \approx (0.120, 0.669, 0.211)^\top$. La variance vaut $w^\top \Sigma w \approx 0.00812$ et la vol $\sigma_p \approx \sqrt{0.00812} \approx 9.01\%$. $\square$

Exercice 1.3 (Max Sharpe : direction de tangence). Montrer que le portefeuille qui maximise le Sharpe (1.3) est proportionnel à $\Sigma^{-1}\tilde{\mu}$. Vous pouvez utiliser (i) un Lagrangien avec contrainte $w^\top \Sigma w = 1$ ou (ii) Cauchy-Schwarz.

Correction détaillée. Comme $\text{SR}(cw) = \text{SR}(w)$, on impose $w^\top \Sigma w = 1$ et on maximise $w^\top \tilde{\mu}$. Lagrangien : $w^\top \tilde{\mu} - \lambda(w^\top \Sigma w - 1)$. FOC : $\tilde{\mu} - 2\lambda \Sigma w = 0$ donc $w \propto \Sigma^{-1}\tilde{\mu}$. $\square$

Exercice 1.4 (Tangence : calcul numérique). Avec la covariance de l'exercice 1.2, $\mu = (7\%, 4\%, 6\%)^\top$ et $r_f = 2\%$, calculer w^{tan} normalisé à budget ($\mathbf{1}^\top w = 1$).

Correction détaillée. On a $\tilde{\mu} = (5\%, 2\%, 4\%)^\top$. On calcule $u = \Sigma^{-1}\tilde{\mu} \approx (1.048, 0.927, 1.453)^\top$, puis on normalise : $w^{\text{tan}} = u/(\mathbf{1}^\top u)$ avec $\mathbf{1}^\top u \approx 3.428$. Donc $w^{\text{tan}} \approx (0.306, 0.270, 0.424)^\top$. $\square$

Exercice 1.5 (Rebalancement : dérive des poids). Dériver la formule (1.7). Puis, dans un univers à 2 actifs, donner un exemple numérique où un portefeuille à poids égaux dérive fortement.

Exercice 1.6 (Risk parity : somme des contributions). Montrer que $\sum_i \text{RC}_i(w) = \sigma(w)$ et interpréter le résultat en « points de vol ».

Exercice 1.7 (ERC : gradient de l'objectif). Calculer $\nabla f(w)$ et $\nabla^2 f(w)$ pour $f(w) = \frac{1}{2}w^\top \Sigma w - \sum_i b_i \log w_i$. Montrer que f est strictement convexe si $\Sigma \succeq 0$.

Correction détaillée. On a $\nabla(\frac{1}{2}w^\top \Sigma w) = \Sigma w$ et $\nabla(-b_i \log w_i) = -(b_i/w_i)e_i$. Donc $\nabla f(w) = \Sigma w - (b_1/w_1, \dots, b_N/w_N)^\top$. Le Hessien vaut $\nabla^2 f(w) = \Sigma + \text{diag}(b_i/w_i^2)$, qui est définie positive (le terme diagonal est $\succ 0$) donc f est strictement convexe. $\square$

Exercice 1.8 (ERC : une itération). Avec Σ de l'exercice 1.2, $b_i = 1/3$ et $w^{(0)} = (1/3, 1/3, 1/3)$, calculer $\sigma^{(0)}$, les $\text{RC}_i^{(0)}$ et produire $w^{(1)}$ via la mise à jour multiplicative.

Exercice 1.9 (PCA : variance expliquée). Pour la covariance de l'exercice 1.2, on donne les valeurs propres (ordre décroissant) : $(\lambda_1, \lambda_2, \lambda_3) \approx (0.0412, 0.0230, 0.00828)$. Calculer la variance expliquée par la première composante et vérifier le check $\sum_i \lambda_i = \text{tr}(\Sigma)$.

Correction détaillée. On a $\text{tr}(\Sigma) = 0.04 + 0.01 + 0.0225 = 0.0725$. La variance expliquée par la première composante vaut $\lambda_1/\text{tr}(\Sigma) \approx 0.0412/0.0725 \approx 56.9\%$. Enfin, $0.0412 + 0.0230 + 0.00828 \approx 0.0725$, ce qui checke la somme des valeurs propres. $\square$

Exercice 1.10 (Cleaning PSD). Montrer que si $\tilde{\Lambda}$ est une diagonale avec $\tilde{\lambda}_i \geq 0$, alors $\tilde{\Sigma} = Q\tilde{\Lambda}Q^\top$ est positive semi-définie. Interpréter ce résultat pour le covariance cleaning.

Partie VIII — Décision/ML (RL, DQN, finance)

Chapitre 1 — RL & Q-learning

Questions d'entretien (réponse attendue + piège)

Exercice 1.1 (Contraction de Bellman). Démontrer que l'opérateur de Bellman optimal T est une contraction en norme sup avec facteur γ .

Correction détaillée. Voir la section *Mode microscope*. Le point-clé est que la différence de max est bornée par le max des différences, puis l'espérance est bornée par la norme sup. $\square$

Exercice 1.2 (MDP jouet). Considérer deux états s_1, s_2 et une action unique. Supposer que $r(s_1) = 1$, $r(s_2) = 0$ et que $s_1 \rightarrow s_2 \rightarrow s_2$ déterministement. Calculer $V^*(s_1)$ et $V^*(s_2)$.

Correction détaillée. $V^*(s_2) = 0 + \gamma V^*(s_2)$ donc $V^*(s_2) = 0$. Puis $V^*(s_1) = 1 + \gamma V^*(s_2) = 1$. $\square$

Exercice 1.3 (Une mise à jour Q-learning). Donner une itération de Q-learning sur une transition (s, a, r, s') et interpréter l'erreur TD.

Correction détaillée. $Q \leftarrow Q + \alpha(r + \gamma \max_{a'} Q(s', a') - Q(s, a))$. L'erreur TD est la différence entre une cible bootstrap (récompense + valeur future) et l'estimation courante. $\square$

Exercice 1.4 (Équation de Bellman pour Q^π). Écrire l'équation de Bellman pour Q^π (politique fixée) et expliquer la différence avec l'optimalité.

Exercice 1.5 (Exploration ϵ -greedy). Décrire ϵ -greedy et l'effet d'un ϵ trop grand/trop petit.

Exercice 1.6 (Convergence (qualitative)). Quelles conditions qualitatives sur α_t et l'exploration assurent la convergence tabulaire ?

Exercice 1.7 (Off-policy). Pourquoi Q-learning est-il off-policy ? Donner l'intuition.

Exercice 1.8 (Sanity checks). Proposer deux diagnostics simples pour détecter un apprentissage qui diverge (valeurs Q qui explosent, performance instable).

Chapitre 2 — DQN

Questions d'entretien (réponse attendue + piège)

Exercice 2.1 (Gradient de la perte). Dériver le gradient de $L(\theta) = \mathbb{E}[(y - Q_\theta(s, a))^2]$ en supposant y constant.

Correction détaillée. $L = \mathbb{E}[(y - Q)^2]$. Par dérivation : $\nabla_\theta(y - Q)^2 = 2(y - Q)(-\nabla_\theta Q)$. Donc $\nabla_\theta L = \mathbb{E}[-2(y - Q)\nabla_\theta Q]$. $\square$

Exercice 2.2 (Rôle du replay). Expliquer pourquoi le replay buffer stabilise l'apprentissage (corrélations, distribution de données).

Correction détaillée. Sans replay, les transitions (s_t, a_t, r_t, s_{t+1}) sont fortement corrélées, ce qui viole l'hypothèse i.i.d. des SGD. Le replay échantillonne aléatoirement dans un buffer : les minibatches sont moins corrélés et couvrent mieux l'espace d'états. $\square$

Exercice 2.3 (Rôle du target network). Pourquoi fige-t-on la cible via θ^- ? Expliquer le mécanisme d'instabilité sans target.

Correction détaillée. Sans target, y dépend de θ : quand on met à jour θ , la cible bouge en même temps que la prédiction, ce qui peut créer une boucle de rétroaction positive (divergence). Avec θ^- , on optimise vers une cible quasi fixe pendant plusieurs itérations. $\square$

Exercice 2.4 (Normalisation des rewards). Pourquoi normaliser/clipper les rewards peut aider ? Quel risque si on clippe trop ?

Exercice 2.5 (Exploration). Quel est le rôle de ϵ -greedy dans DQN ? Que se passe-t-il si on réduit ϵ trop tôt ?

Exercice 2.6 (Diagnostics). Donner des diagnostics simples : TD-error, distribution des Q-values, performance sur un ensemble de validation.

Exercice 2.7 (Overfitting). Pourquoi un agent peut sur-apprendre l'historique ? Donner une analogie avec une régression.

Exercice 2.8 (Choix d'architecture). Quels éléments d'architecture sont dictés par le type d'état (vecteur, série temporelle, image) ?

Chapitre 3 — RL finance

Questions d'entretien (réponse attendue + piège)

Exercice 3.1 (MDP trading jouet). Proposer une formulation MDP minimale pour un problème de trading (état, action, reward). Justifier chaque choix.

Correction détaillée. Un choix minimal : état (t , prix, position), action = variation de position (buy/sell/hold), reward = variation de P&L moins coûts ($\Delta \text{PnL} - c|\Delta \text{position}|$). On inclut la position car les coûts et risques dépendent de l'inventaire. $\square$

Exercice 3.2 (Coûts de transaction). Pourquoi les coûts de transaction rendent-ils le problème « non trivial » ? Donner un exemple jouet montrant que « hedger tout le temps » peut être mauvais.

Correction détaillée. Sans coûts, on peut ajuster continûment ; avec coûts, chaque ajustement coûte. Exemple : si le spot bouge faiblement, payer un coût à chaque micro-ajustement détruit la performance. Il faut donc un compromis (zones de non-intervention). $\square$

Exercice 3.3 (POMDP). Pourquoi un problème finance est souvent un POMDP (partiellement observable) ? Donner deux sources de non-observabilité.

Correction détaillée. Les variables latentes (volatilité, régimes, liquidité) ne sont pas observées directement. Le marché est non-stationnaire : les paramètres changent dans le temps et ne sont pas connus. Donc l'état Markovien complet est inaccessible ; on travaille avec un état *augmenté* (features, filtres). $\square$

Exercice 3.4 (Reward risk-aware). Donner deux idées de reward qui pénalisent le risque (variance, CVaR) et discuter avantages/inconvénients.

Exercice 3.5 (Validation). Pourquoi un backtest classique peut-il sur-estimer la performance d'une politique RL ? Donner deux biais.

Exercice 3.6 (Non-stationnarité). Donner un exemple de « shift » de marché qui casse une politique apprise.

Exercice 3.7 (Contraintes). Comment intégrer des contraintes (position max, drawdown, exposition) dans un MDP ?

Exercice 3.8 (Sanity checks). Proposer des sanity-checks : politique triviale (hold), ablations (sans feature), stress tests sur coûts.

Partie IX — Mémoire & rough (Volterra, fBm, rHeston, rBergomi)

Chapitre 1 — Volterra SDE

Questions d'entretien (réponse attendue + piège)

Exercice 1.1 (Covariance). Démontrer que, pour $s \leq t$, $\mathbb{E}[X_t X_s] = \int_0^s K(t-u)K(s-u) du$.

Correction détaillée. Écrire $X_t = \int_0^t K(t-u) dW_u$ et $X_s = \int_0^s K(s-u) dW_u$. Par isométrie/covariation, $\mathbb{E}[\int_0^t f dW \int_0^s g dW] = \int_0^{\min(t,s)} f(u)g(u) du$. Ici $f(u) = K(t-u)$, $g(u) = K(s-u)$. $\square$

Exercice 1.2 (Cas $K \equiv 1$). Vérifier que si $K \equiv 1$, alors $X_t = W_t$ et la covariance vaut $\min(s, t)$.

Correction détaillée. Si $K \equiv 1$, $X_t = \int_0^t 1 dW_u = W_t$. Donc $\mathbb{E}[X_t X_s] = \mathbb{E}[W_t W_s] = \min(s, t)$. $\square$

Exercice 1.3 (Discrétisation). Écrire explicitement l'approximation discrète $X_{t_k} \approx \sum_{j < k} K(t_k - t_j) \Delta W_j$ et donner sa complexité.

Correction détaillée. La formule est une convolution triangulaire. Pour chaque k , on somme k termes, donc coût total $\sum_{k=1}^N k = O(N^2)$. $\square$

Exercice 1.4 (Non-Markovianité). Expliquer pourquoi X_t n'est pas Markov en général (dépendance à tout le passé via K).

Exercice 1.5 (Effet d'un noyau court). Si K décroît très vite, expliquer pourquoi la mémoire est « courte » (qualitatif) et ce que cela suggère numériquement.

Exercice 1.6 (Sanity check sur K). Donner des conditions qualitatives sur K pour que X_t soit bien défini (intégrabilité).

Exercice 1.7 (Lien avec fBm). Pourquoi des noyaux singuliers $K(t) \sim t^{H-1/2}$ sont-ils liés au fBm ? Discussion qualitative.

Exercice 1.8 (Accélération). Donner deux idées d'accélération du calcul de la convolution (multi-facteurs, FFT) et leurs limites.

Chapitre 2 — Fractional Brownian Motion

Questions d'entretien (réponse attendue + piège)

Exercice 2.1 (Cas $H = 1/2$). Montrer que pour $H = 1/2$, la covariance (2.21) coïncide avec celle du Brownien standard.

Correction détaillée. Si $H = 1/2$, $t^{2H} = t$ et $|t-s|^{2H} = |t-s|$. Alors $\frac{1}{2}(t+s-|t-s|) = \min(t, s)$. $\square$

Exercice 2.2 (Variance des incréments). Montrer que $\text{Var}(B_t^H - B_s^H) = |t-s|^{2H}$.

Correction détaillée. Par bilinéarité, $\text{Var}(B_t^H - B_s^H) = \mathbb{E}[B_t^2] + \mathbb{E}[B_s^2] - 2\mathbb{E}[B_t B_s]$. Avec (2.21), cela donne $t^{2H} + s^{2H} - (t^{2H} + s^{2H} - |t-s|^{2H}) = |t-s|^{2H}$. $\square$

Exercice 2.3 (Scaling). Démontrer l'auto-similarité $(B_{ct}^H) \stackrel{\text{law}}{=} (c^H B_t^H)$ via la covariance.

Correction détaillée. Calculer la covariance : $\mathbb{E}[B_{ct}^H B_{cs}^H] = \frac{1}{2}((ct)^{2H} + (cs)^{2H} - |c(t-s)|^{2H}) = c^{2H} \mathbb{E}[B_t^H B_s^H]$. Comme le processus est gaussien centré, cette égalité de covariances implique l'égalité en loi. $\square$

Exercice 2.4 (Régimes H). Interpréter qualitativement $H > 1/2$ (persistance) et $H < 1/2$ (anti-persistance) via les corrélations d'incrément.

Exercice 2.5 (Non-Markov). Pourquoi B^H n'est-il pas Markov si $H \neq 1/2$? Discussion qualitative.

Exercice 2.6 (Rugosité). Relier H à la régularité Hölder des trajectoires (qualitatif).

Exercice 2.7 (Lien Volterra). Expliquer comment une représentation $B_t^H = \int_0^t K_H(t-s)dW_s$ aide à simuler (qualitatif).

Exercice 2.8 (Sanity checks). Donner deux checks simples à faire sur une simulation de fBm (variance d'incrément, scaling).

Chapitre 3 — Rough Heston

Questions d'entretien (réponse attendue + piège)

Exercice 3.1 (Limite vers Heston). Discuter qualitativement comment rough Heston se rapproche de Heston classique quand la mémoire disparaît (kernel « court »).

Correction détaillée. Si K devient très concentré près de 0 (comportement type delta), l'intégrale $\int_0^t K(t-s)g(s)ds$ se comporte comme $g(t)$. Alors l'équation intégrale de v_t se rapproche d'une SDE locale (CIR), ce qui ramène au Heston markovien. $\square$

Exercice 3.2 (Discrétisation). Écrire une discrétisation explicite de l'intégrale de convolution pour v_{t_k} sur une grille uniforme.

Correction détaillée. Sur $t_k = k\Delta t$, approximer $\int_0^{t_k} K(t_k-s)g(s)ds \approx \sum_{j=0}^{k-1} K(t_k-t_j)g(t_j)\Delta t$. Pour le terme stochastique, on remplace dW par $\Delta W_j : \int_0^{t_k} K(t_k-s)h(s)dW_s \approx \sum_{j < k} K(t_k-t_j)h(t_j)\Delta W_j$. $\square$

Exercice 3.3 (Multi-facteurs). Pourquoi l'approximation $K(t) \approx \sum_j w_j e^{-\lambda_j t}$ rend-elle le modèle markovien ? Expliquer l'idée.

Correction détaillée. Chaque exponentielle correspond à un facteur Y_t^j satisfaisant une équation locale $dY_t^j = -\lambda_j Y_t^j dt + (\text{input})$. La convolution devient une combinaison linéaire de ces facteurs, donc l'état étendu $(S_t, Y_t^1, \dots, Y_t^M)$ est markovien. $\square$

Exercice 3.4 (Rôle de H). Discuter qualitativement l'effet de H sur le skew court terme.

Exercice 3.5 (Stabilité numérique). Quels symptômes indiquent une simulation instable (variance négative, explosion) ? Proposer des garde-fous.

Exercice 3.6 (Complexité). Comparer le coût $O(N^2)$ d'une convolution naïve et l'intérêt d'une approximation multi-facteurs.

Exercice 3.7 (Calibration). Quels paramètres contrôlent (i) niveau long terme, (ii) roughness, (iii) skew ? Discussion qualitative.

Exercice 3.8 (Sanity checks). Proposer deux checks : positivité de v , limites vers Heston, stabilité du smile.

Chapitre 4 — Rough Bergomi

Questions d'entretien (réponse attendue + piège)

Exercice 4.1 (Espérance de v_t). Montrer que $\mathbb{E}[v_t] = \xi_0(t)$ pour $v_t = \xi_0(t) \exp(\eta W_t^H - \frac{1}{2}\eta^2 t^{2H})$.

Correction détaillée. $W_t^H \sim \mathcal{N}(0, t^{2H})$. Donc $\mathbb{E}[\exp(\eta W_t^H)] = \exp(\frac{1}{2}\eta^2 t^{2H})$. Le facteur $-\frac{1}{2}\eta^2 t^{2H}$ compense exactement, d'où $\mathbb{E}[v_t] = \xi_0(t)$. $\square$

Exercice 4.2 (Rôle de ρ). Expliquer qualitativement pourquoi une corrélation négative ρ génère un skew négatif (smile incliné).

Correction détaillée. Si $\rho < 0$, une baisse de S s'accompagne typiquement d'une hausse de v (effet leverage). Les options de vente (puts) deviennent plus chères, ce qui correspond à un skew négatif en vol implicite. $\square$

Exercice 4.3 (Simulation rough). Proposer une stratégie de simulation de W^H via une représentation Volterra et une convolution discrète.

Correction détaillée. Utiliser $W_t^H = \int_0^t K_H(t-s)dW_s$ et approximer sur une grille : $W_{t_k}^H \approx \sum_{j < k} K_H(t_k - t_j)\Delta W_j$. On simule les ΔW_j i.i.d. gaussiens, puis on calcule la convolution (naïf $O(N^2)$ ou accéléré). $\square$

Exercice 4.4 (Paramètre η). Quel est le rôle de η (amplitude du bruit sur $\log v$) ? Effet sur le smile ?

Exercice 4.5 (Paramètre H). Relier H à la rugosité et à la pente court terme du smile (qualitatif).

Exercice 4.6 (Sanity checks). Donner des checks : positivité de v , stabilité numérique, cohérence ATM via ξ_0 .

Exercice 4.7 (Calibration). Décrire qualitativement une calibration : (i) fixer ξ_0 , (ii) ajuster (H, η, ρ) .

Exercice 4.8 (Limite simple). Que se passe-t-il si $\xi_0(t)$ est constant ? Interpréter.

Interview Q&A (P2 à P9)

Partie II — Instruments, payoffs, arbitrage, taux

Payoffs, arbitrage statique, mesure risque-neutre

- Q.** You are given a set of call prices $K \mapsto C_0(K)$ at a fixed maturity. What are the minimal static no-arbitrage conditions?
R. (i) *Bornes* : $0 \leq C_0(K) \leq S_0$ et $C_0(K) \geq (S_0 - K P(0, T))^+$. (ii) *Monotonie* : $C_0(K)$ décroît en K (un call-spread coûte ≥ 0). (iii) *Convexité* : C_0 est convexe en K (une butterfly coûte ≥ 0). En pratique on teste des différences finies : $C(K_1) \geq C(K_2)$ si $K_1 < K_2$, et $C(K - \varepsilon) - 2C(K) + C(K + \varepsilon) \geq 0$.
- Q.** Explain put-call parity with rates and dividends.
R. Sous taux sans risque r et dividende continu q (ou carry $b = r - q$), pour strike K , maturité T : $C_0(K) - P_0(K) = S_0 e^{-qT} - K e^{-rT}$. C'est une identité de *réplication statique* : long call + short put = forward sur S (avec dividendes).
- Q.** Forward price vs forward contract value : what is the distinction ?
R. Le *forward price* $F_0(T)$ est le strike qui rend la valeur initiale nulle (contrat “par”), typiquement $F_0(T) = S_0 e^{(r-q)T}$. La *valeur* d'un forward existant de strike K est $V_0 = (F_0(T) - K) P(0, T)$ (en convention continue).
- Q.** How do you construct an arbitrage if the market forward $F_0^{mkt}(T)$ is too high ?
R. Si $F_0^{mkt} > F_0$, on vend le forward trop cher et on achète le sous-jacent financé (cash-and-carry). À T : on livre S_T et on reçoit $F_0^{mkt}(T)$, la position financée coûte $F_0(T)$, gain certain $F_0^{mkt} - F_0 > 0$.
- Q.** Breeden-Litzenberger : what does $\partial_{KK} C_0(K)$ represent ?
R. Sous régularité, $\partial_{KK} C_0(K) = P(0, T) f_{S_T}^{\mathbb{Q}}(K)$ (densité risque-neutre). La convexité de C est donc équivalente à une densité ≥ 0 .
- Q.** What is the Fundamental Theorem of Asset Pricing (FTAP) in one sentence ?
R. (Version “cours”) : absence d'arbitrage $\Leftrightarrow$ existence d'une mesure martingale équivalente $\mathbb{Q}$ (au moins une) sous laquelle les prix actualisés sont des martingales ; complétude $\Leftrightarrow$ unicité de $\mathbb{Q}$.
- Q.** Numeraire change : what is invariant and what changes ?
R. Le prix est invariant, la mesure change : pour un numéraire $N_t > 0$, le prix s'écrit $V_t = N_t \mathbb{E}^{\mathbb{Q}^N}[\Phi/N_T \mid \mathcal{F}_t]$. Changer de numéraire modifie la mesure et les drifts, pas les prix.

Binomial / pricing discret

- Q.** Derive the risk-neutral probability in the one-step binomial model.
R. Avec S_0 puis $S_0 u$ ou $S_0 d$ et numéraire $B_0 = 1$, $B_T = 1 + r$ (taux simple), absence d'arbitrage impose $d < 1 + r < u$. La probabilité risque-neutre est $p^* = \frac{(1+r)-d}{u-d}$ telle que $\mathbb{E}^{\mathbb{Q}}[S_T/B_T] = S_0/B_0$ (martingale des prix actualisés).
- Q.** What does market completeness mean in the binomial model ?
R. À un pas, 2 états et 2 actifs (bond + stock) $\Rightarrow$ réplication unique si $u \neq d$. À plusieurs pas, complétude = possibilité de répliquer tout payoff $\mathcal{F}_T$ -mesurable (arbre recombiné) ; en CRR c'est le

cas : unicité de $\mathbb{Q}$ et prix unique.

3. **Q.** Why does the binomial model converge to Black–Scholes ?

R. Avec échelle $u = \exp(\sigma\sqrt{\Delta t})$, $d = \exp(-\sigma\sqrt{\Delta t})$, et r constant, la marche aléatoire centrée converge vers un Brownien (CLT / Donsker) ; l'actualisé converge vers une martingale log-normale, et le prix d'option converge vers la formule BS.

Courbe des taux : bootstrap & NSS

1. **Q.** Bootstrapping : what is the core object you solve for ?

R. Les *discount factors* $P(0, T_i)$ (ou zéro-coupons). Une fois $P(0, T)$ connus, on obtient zéro-rates $R(0, T)$ via $P(0, T) = e^{-R(0, T)T}$ (ou compounding) et forwards via $F(0; T_1, T_2) = \frac{P(0, T_1)}{P(0, T_2)}$ (en continu : $f(0, t) = -\partial_t \ln P(0, t)$).

2. **Q.** How do you bootstrap from par swap rates (single-curve setting) ?

R. Écrire l'équation de parité PV(floating)=PV(fixed). La jambe fixe vaut $S^{par} \sum_{k=1}^n \alpha_k P(0, T_k)$, la jambe flottante vaut $1 - P(0, T_n)$ (simplifié). Si $P(0, T_1), \dots, P(0, T_{n-1})$ déjà bootstrappés, on isole $P(0, T_n)$: c'est une récurrence.

3. **Q.** Nelson–Siegel–Svensson : what are the parameters and what do they control ?

R. Forme typique du zéro-rate $R(T)$ (ou du forward) : niveau long terme (β_0), pente (β_1), courbure(s) (β_2, β_3) et échelles τ_1, τ_2 qui positionnent les bosses. L'interprétation : β_0 fixe l'asymptote long terme, τ règle la maturité où la courbure est maximale.

4. **Q.** In calibration, what are the two most common failure modes ?

R. (i) *Instabilité* : objective mal posée (poids, quotes incohérentes) $\Rightarrow$ paramètres extrêmes, oscillations.
(ii) *Sur-ajustement* : trop de flexibilité vs données bruitées (illiquidité), d'où l'intérêt de pénalisation/regularization et de contraintes (monotonie, positivité, bornes sur τ).

Partie III — Variation quadratique & Itô

Variation quadratique : définitions et réflexes

1. **Q.** What is quadratic variation and why do we care in finance?
R. Pour une partition $\pi : 0 = t_0 < \dots < t_n = T$, $[X]_T = \lim_{|\pi| \rightarrow 0} \sum_i (X_{t_{i+1}} - X_{t_i})^2$ (si la limite existe). C'est la quantité qui fait émerger la correction d'Itô et qui lie théorie et pratique : *realized variance* $\approx [\log S]_T$.
2. **Q.** Compute $[X]_t$ for an Itô process $dX_t = \mu_t dt + \sigma_t dW_t$.
R. On a $[X]_t = \int_0^t \sigma_s^2 ds$ et, plus généralement, $[X, Y]_t = \int_0^t \sigma_s^X \sigma_s^Y ds$ si les Brownien sont les mêmes. Le drift μdt est de variation finie donc n'apporte pas de variation quadratique.
3. **Q.** Why does Brownian motion have infinite variation but finite quadratic variation?
R. La variation totale $\sum |\Delta W|$ explose (trajectoires très irrégulières), mais $\sum (\Delta W)^2$ converge vers t (incrément $\sim \sqrt{\Delta t}$ donc carré $\sim \Delta t$ et la somme fait t). C'est exactement la frontière "ordre Δt " du calcul d'Itô.

Intégrale d'Itô et lemme d'Itô

1. **Q.** State Itô isometry and its key consequence.
R. Pour H adapté, $\mathbb{E} \left[\left(\int_0^T H_t dW_t \right)^2 \right] = \mathbb{E} \left[\int_0^T H_t^2 dt \right]$. Conséquence : $\int H dW$ est une martingale centrée (sous intégrabilité) et la construction se fait par complétion L^2 .
2. **Q.** Give Itô's formula for $f(t, X_t)$, $dX_t = \mu_t dt + \sigma_t dW_t$.
R. Si $f \in C^{1,2}$: $df(t, X_t) = \partial_t f dt + \partial_x f dX_t + \frac{1}{2} \partial_{xx} f d[X]_t$, donc $df = (\partial_t f + \mu \partial_x f + \frac{1}{2} \sigma^2 \partial_{xx} f) dt + \sigma \partial_x f dW_t$.
3. **Q.** Product rule / integration by parts for semimartingales?
R. Pour X, Y semimartingales : $d(XY) = X dY + Y dX + d[X, Y]$. Le terme $d[X, Y]$ est le correctif d'Itô.
4. **Q.** Stratonovich vs Itô : what changes in the chain rule?
R. En Stratonovich, la règle de chaîne est la règle classique (pas de terme $\frac{1}{2} f'' \sigma^2 dt$), mais l'intégrale dépend d'une convention "milieu". En finance, la convention Itô est naturelle (adaptation / non-anticipation) et colle à la limite des sommes à gauche.

Sanity checks (entretien)

1. **Q.** If X_t is differentiable, what is $[X]_t$?
R. Zéro : une fonction C^1 est de variation finie, donc la somme des carrés d'incrément est $o(1)$ quand $|\pi| \rightarrow 0$. C'est un test immédiat.
2. **Q.** What is $[\ln S]_t$ under $dS_t = \mu S_t dt + \sigma S_t dW_t$?

R. Par Itô : $d \ln S_t = (\mu - \frac{1}{2}\sigma^2)dt + \sigma dW_t$, donc $[\ln S]_t = \int_0^t \sigma^2 ds = \sigma^2 t$ si σ constant.

Partie IV — Black–Scholes

Black–Scholes : hypothèses, PDE, mesure risque-neutre

1. **Q.** Derive the Black–Scholes PDE by replication (outline).
R. Supposer $dS = \mu S dt + \sigma S dW$, actif sans risque $dB = rB dt$. Pour un prix $V(t, S)$, appliquer Itô : $dV = V_t dt + V_S dS + \frac{1}{2} V_{SS} \sigma^2 S^2 dt$. Construire un portefeuille $\Pi = V - \Delta S$ avec $\Delta = V_S$ pour annuler le terme dW . Sans arbitrage, $d\Pi = r\Pi dt \Rightarrow$ PDE : $V_t + \frac{1}{2} \sigma^2 S^2 V_{SS} + rSV_S - rV = 0$.
2. **Q.** What changes if the underlying pays a continuous dividend yield q ?
R. Le drift sous $\mathbb{Q}$ devient $(r - q)$ et la PDE devient $V_t + \frac{1}{2} \sigma^2 S^2 V_{SS} + (r - q)SV_S - rV = 0$. La parité put–call inclut $S_0 e^{-qT}$.
3. **Q.** Explain the link between the PDE and risk-neutral expectation (Feynman–Kac).
R. Sous régularité, la solution de la PDE est $V_t = \mathbb{E}^{\mathbb{Q}}[e^{-r(T-t)} \Phi(S_T) | \mathcal{F}_t]$ avec dynamique sous $\mathbb{Q}$: $dS = (r - q)S dt + \sigma S dW^{\mathbb{Q}}$. PDE et espérance sont deux faces du même objet.

Greeks, hedging, limites

1. **Q.** Why is delta hedging not a free lunch in practice?
R. La réplication suppose trading continu sans coûts. En discret, l'erreur de hedging est pilotée par la gamma et la volatilité : variance d'erreur $\sim \int \Gamma_t^2 \sigma^2 S_t^2 dt$ (ordre). Coûts de transaction + contraintes (liquidité, sauts) cassent l'argument.
2. **Q.** What is the most useful mental model for vega and smile risk?
R. Vega mesure la sensibilité à un *paramètre de vol*. En marché, la variable observable est l'*implied vol surface* ; le risque réel est une combinaison de vegas par strike/maturity (vega bucket). Un modèle (local vol/Heston) mappe ces variations vers des paramètres, mais l'exposition reste surface-based.

Smile et méthodes numériques

1. **Q.** What static no-arbitrage conditions must an implied volatility surface satisfy?
R. Elle doit engendrer des prix de calls sans arbitrage : pour chaque maturité, prix monotones/convexes en strike ; en maturité, pas d'arbitrage calendaire (call croissant en T à strike fixe sous taux non négatifs). Des conditions plus fines existent (Dupire local vol ≥ 0), mais le test robuste est sur les prix.
2. **Q.** Compare PDE, Monte Carlo, and trees in one minute.
R. PDE : efficace pour vanilles/Barrières (1D/2D), donne greeks propres, nécessite schémas stables. MC : dimension élevée, exotiques path-dependent, greeks via LR/pathwise, variance reduction cruciale. Arbres : intuitifs, bons en 1D, gèrent American via backward induction, mais coût augmente avec précision.
3. **Q.** Name two common numerical pitfalls in BS implementations.
R. (i) Catastrophic cancellation pour d_1, d_2 en extrêmes (très ITM/OTM, T petit) : utiliser logs stables / fonctions dédiées. (ii) Inversion implied vol : initialisation et bornes (Brent) + arbitrage si prix incohérents.

Partie V — Sauts, Heston, Fourier/fft

Jumps : intuition, drift sous $\mathbb{Q}$, PIDE

1. **Q.** In a Merton jump-diffusion, what must be adjusted when moving to $\mathbb{Q}$?
R. Le drift doit intégrer la compensation des sauts : sous $\mathbb{Q}$, $dS/S = (r - q - \lambda\kappa) dt + \sigma dW + \text{jumps}$, où $\kappa = \mathbb{E}[J - 1]$ (taille moyenne) et λ l'intensité. L'idée : l'actualisé doit rester martingale.
2. **Q.** Why do jumps generate a smile even with constant diffusion volatility?
R. Les sauts ajoutent kurtosis (queues épaisses) et asymétrie (si distribution des sauts asymétrique). Les options OTM deviennent plus chères que sous lognormal, donc implied vol varie avec strike.

Heston : formule semi-fermée, calibration, simulation

1. **Q.** State the Heston dynamics and the role of the Feller condition.
R. Typiquement $dS = (r - q)Sdt + \sqrt{V} S dW^S$, $dV = \kappa(\theta - V)dt + \nu\sqrt{V} dW^V$, $\text{corr}(dW^S, dW^V) = \rho$. La condition de Feller $2\kappa\theta \geq \nu^2$ garantit (sous certaines conditions) que V_t reste strictement positif; en numérique on applique souvent des schémas positifs (QE, full truncation).
2. **Q.** What are the calibration degrees of freedom in Heston and typical identifiability issues?
R. Paramètres $(\kappa, \theta, \nu, \rho, V_0)$ (+ éventuellement q). ν (vol-of-vol) et ρ pilotent skew; θ long-run var fixe niveau; κ régit term-structure. Identifiabilité : κ et θ peuvent se compenser; V_0 vs smile court terme; il faut pondération par liquidité et régularisation.

Carr–Madan / FFT

1. **Q.** Why do we introduce a damping factor α in Carr–Madan?
R. Pour rendre la transformée de Fourier intégrable : on price $e^{\alpha k} C(k)$ en fonction du log-strike $k = \ln K$, ce qui contrôle la décroissance en queue et permet d'appliquer FFT.
2. **Q.** Name two FFT implementation pitfalls.
R. (i) Alias/wrap-around : choix du pas en fréquence et de la fenêtre $[0, B]$ (trade-off précision/alias).
(ii) Interpolation : la grille FFT est uniforme en k , pas forcément aux strikes demandés; l'interpolation doit préserver la convexité/monotonie sinon arbitrage numérique.

Partie VI — Kalman (estimation)

Filtre de Kalman : équations et intuition

1. **Q.** Write the linear Gaussian state-space model.
R. État latent : $x_{t+1} = F_t x_t + u_t + \eta_t$, observation : $y_t = H_t x_t + d_t + \epsilon_t$, avec $\eta_t \sim \mathcal{N}(0, Q_t)$, $\epsilon_t \sim \mathcal{N}(0, R_t)$ (indépendants conditionnellement) et $x_0 \sim \mathcal{N}(m_0, P_0)$.
2. **Q.** Give the two Kalman steps (predict/update).
R. Prédiction : $m_t^- = F_{t-1} m_{t-1} + u_{t-1}$, $P_t^- = F_{t-1} P_{t-1} F_{t-1}^\top + Q_{t-1}$. Innovation : $\nu_t = y_t - H_t m_t^- - d_t$, $S_t = H_t P_t^- H_t^\top + R_t$. Gain : $K_t = P_t^- H_t^\top S_t^{-1}$. Mise à jour : $m_t = m_t^- + K_t \nu_t$. Covariance : utiliser la forme Joseph pour stabilité.
3. **Q.** What is the Joseph form and why use it ?
R. $P_t = (I - K_t H_t) P_t^- (I - K_t H_t)^\top + K_t R_t K_t^\top$. Elle préserve la PSD numériquement et limite la perte de symétrie due aux erreurs d'arrondi.
4. **Q.** What is the single best intuition for the Kalman gain ?
R. C'est un *poids optimal* (MMSE) entre prior et observation : si R est grand (obs bruitée), K est petit ; si P^- est grand (prior incertain), K est grand.
5. **Q.** Derive the Kalman gain from an optimization viewpoint.
R. Le gain minimise l'erreur quadratique a posteriori : $m_t = m_t^- + K \nu_t$ et on choisit K pour minimiser $\mathbb{E}[\|x_t - m_t\|^2 \mid \mathcal{F}_t]$. La solution est $K = P^- H^\top (H P^- H^\top + R)^{-1}$.

Vraisemblance & estimation de paramètres

1. **Q.** How do you compute the log-likelihood with a Kalman filter ?
R. Via les innovations : $\log p(y_{0:T}) = -\frac{1}{2} \sum_t (\log |S_t| + \nu_t^\top S_t^{-1} \nu_t) + \text{cste}$. C'est le point de départ du MLE (gradient) et de l'EM.
2. **Q.** EM for Kalman : what are the sufficient statistics ?
R. Avec un lisseur (RTS), on a besoin de $\mathbb{E}[x_t]$, $\mathbb{E}[x_t x_t^\top]$, et $\mathbb{E}[x_{t+1} x_t^\top]$ conditionnellement à $y_{0:T}$. Ils permettent de mettre à jour Q, R (et parfois F, H) en M-step.
3. **Q.** What are the two most common parameter constraints ?
R. (i) $Q, R \succeq 0$ (Cholesky / log-variances) ; (ii) stabilité de F (eigenvalues dans le disque unité si modèle stationnaire discret).
4. **Q.** How do you handle missing observations y_t ?
R. Skipper l'update (posterior = prior), ou utiliser un H_t qui ne sélectionne que les composantes observées. Équivalent à prendre $R \rightarrow \infty$ sur les composantes manquantes.
5. **Q.** How do you deal with irregular timestamps ?
R. Modéliser en continu puis discrétiser : $F(\Delta t) = \exp(A \Delta t)$ pour une dynamique linéaire continue, et adapter $Q(\Delta t)$. Évite de faire semblant que Δt est constant.

Lissage & diagnostics

1. **Q.** What is RTS smoothing in one sentence?
R. Un passage backward qui combine filtres $t|t$ et prédictions $t+1|t$ pour obtenir $x_{t|T}$ (meilleure estimation sachant toutes les observations), crucial pour EM et signaux lissés.
2. **Q.** Name two diagnostics built from innovations.
R. (i) Whiteness : autocorrélation de ν_t (Ljung–Box). (ii) NIS : $\nu_t^\top S_t^{-1} \nu_t$ doit suivre une loi χ^2 (dimension de y_t).
3. **Q.** What are signs of filter divergence?
R. P_t explose ou devient non-PSD, innovations biaisées/autocorrélées, NIS hors-bandes, forte sensibilité à l'initialisation. En finance : souvent non-stationnarité ou outliers.
4. **Q.** Square-root Kalman : why does it help?
R. Propager une factorisation (Cholesky) de P garantit PSD et améliore le conditionnement numérique (moins de cancellation).

Extensions & use-cases finance

1. **Q.** When do you move to EKF/UKF/particle filtering?
R. Non-linéaire (EKF/UKF) ou non-gaussien/multimodal (particle). En pratique : vol latent, microstructure, régimes, contraintes.
2. **Q.** Give two realistic finance applications of Kalman.
R. (i) Pairs trading : spread latent + hedge ratio time-varying. (ii) Courbe des taux : facteurs latents (niveau/pente/courbure) observés via yields.
3. **Q.** What breaks first when applying Kalman naively to markets?
R. Non-stationnarité (paramètres qui bougent), erreurs de modèle d'observation (microstructure), et leakage (données révisées). D'où l'importance des diagnostics innovations + modèles adaptatifs.
4. **Q.** How do you choose Q and R in practice?
R. Calibration par MLE/EM + contraintes/priors ; ou heuristiques (par exemple R via microstructure, Q via variance des innovations). Toujours valider par diagnostics (NIS/whiteness) et par performance hors échantillon.

Partie VII — Allocation & rebalancement

Markowitz : solutions, contraintes, stabilité

1. **Q.** Derive the global minimum variance (GMV) portfolio with constraint $1^\top w = 1$.
R. Lagrangien : minimiser $w^\top \Sigma w$ s.c. $1^\top w = 1$. Condition $2\Sigma w - \lambda 1 = 0 \Rightarrow w = \frac{\Sigma^{-1}1}{1^\top \Sigma^{-1}1}$. En pratique : résoudre le système (Cholesky), pas d'inversion explicite.
2. **Q.** What is the tangency portfolio and when does it exist ?
R. Avec rendements attendus μ et taux r_f , le portefeuille tangent maximise le Sharpe : $w_T \propto \Sigma^{-1}(\mu - r_f 1)$ (puis normalisation). Il suppose accès au levier/short selon contraintes ; et il est très sensible à l'estimation de μ .
3. **Q.** Why does mean–variance often produce extreme weights ?
R. Parce que l'optimiseur amplifie le bruit : une petite erreur sur μ ou sur les petites eigenvalues de Σ se transforme en gros poids via Σ^{-1} . Red flags : condition number élevé, n/T grand, fenêtre trop courte.
4. **Q.** Give two stabilizers that work in practice.
R. (i) **Ridge** : optimiser avec $\Sigma + \varepsilon I$ (ou pénalité L_2). (ii) **Shrinkage/factor model** : remplacer $\hat{\Sigma}$ par une version structurée + contraintes (bornes, leverage).
5. **Q.** What do KKT multipliers mean in a constrained portfolio problem ?
R. Des *shadow prices* : la valeur marginale de relâcher une contrainte. Exemple : combien de Sharpe on gagne si on relâche un cap secteur, ou une contrainte de turnover.

Covariance : shrinkage, facteurs, régimes

1. **Q.** What is the simplest shrinkage idea and why does it help ?
R. $\hat{\Sigma} = (1 - \delta)S + \delta F$ (cible F : diag/constant-corr/factor). On réduit la variance d'estimation et on améliore le conditionnement $\Rightarrow$ poids plus stables.
2. **Q.** How do factor models help in portfolio construction ?
R. Structure $\Sigma = B\Sigma_f B^\top + D$: dimension réduite, meilleure stabilité, contrôle direct des expositions (risk management), stress tests plus interprétables.
3. **Q.** Why is sample covariance fragile when n is large ?
R. Les eigenvalues sont bruitées (Marchenko–Pastur) et la pseudo-inversion amplifie les petites eigenvalues (souvent du bruit). Dans ce régime, min-var peut sur-trader et sur-concentrer.
4. **Q.** EWMA covariance : what does λ trade off ?
R. λ faible suit les régimes mais augmente le bruit ; λ proche de 1 stabilise mais réagit lentement. Choix pratique : calibrer sur vol réalisée + validation out-of-sample.
5. **Q.** How do you ensure numerical PSD of $\hat{\Sigma}$?
R. Symétriser, clipper eigenvalues négatives, ajouter un ridge εI , et utiliser Cholesky pour les résolutions. Un $\hat{\Sigma}$ non-PSD est un bug (données, fenêtre, manque de régularisation).

6. **Q.** If correlations spike, what happens to diversification ?

R. La diversification effective s'effondre : Σ devient plus « factor-like » et le risque se concentre. Un portefeuille construit sur un régime calme peut exploser en stress.

Tracking error, CVaR, risk parity

1. **Q.** Define tracking error and how it enters optimization.

R. Avec benchmark w^{bmk} , l'active weight $a = w - w^{bmk}$ et $TE^2 = a^\top \Sigma a$. On minimise TE sous contraintes et objectifs (excess return, exposures).

2. **Q.** How do you formulate CVaR optimization from scenarios ?

R. Minimiser $\eta + \frac{1}{(1-\alpha)N} \sum u_i$ s.c. $u_i \geq \ell_i(w) - \eta$, $u_i \geq 0$. C'est un LP (ou convexe) et c'est robuste aux queues.

3. **Q.** Risk parity / ERC : what is equalized ?

R. Les contributions au risque $RC_i = w_i(\Sigma w)_i / \sqrt{w^\top \Sigma w}$. ERC impose RC_i égales (ou selon budgets). Problème non linéaire, résolu par itérations (Newton/coordinate/ADMM).

4. **Q.** When does risk parity fail ?

R. Si les corrélations explosent, la diversification effective s'effondre. Si la covariance est mal estimée, le « risk budget » devient du bruit. Et avec contraintes fortes (long-only + caps), l'ERC exact peut être impossible.

Black–Litterman : prior + vues

1. **Q.** State the Black–Litterman posterior mean and interpret Ω .

R. Typiquement $\mu_{BL} = \mu_0 + \Sigma P^\top (P \Sigma P^\top + \Omega)^{-1} (q - P \mu_0)$ (avec $\tau \Sigma$ souvent). Ω est l'incertitude sur les vues : grande $\Omega \Rightarrow$ on reste proche de la prior ; petite $\Omega \Rightarrow$ on colle aux vues.

2. **Q.** Why is BL useful in practice ?

R. Parce qu'il *structure* μ (très bruité) via une prior économique et des vues explicites. Il réduit les poids extrêmes et rend le raisonnement « audit-able ».

Coûts, turnover, exécution

1. **Q.** How do transaction costs enter a rebalance optimization ?

R. Via un terme sur $\Delta w = w - w^{old}$: coût linéaire $\|\Delta w\|_1$ (spread/fees) ou quadratique $\Delta w^\top \Gamma \Delta w$ (impact). Cela crée une *no-trade region* et réduit le turnover.

2. **Q.** Explain the no-trade region intuition in one sentence.

R. On ne trade pas tant que le gain marginal prédit (alpha ou réduction de risque) est inférieur au coût marginal (spread/impact).

3. **Q.** What is capacity and how do you stress it ?

R. La capacité est l'encours maximal avant que l'impact ne détruise l'alpha. Stress : augmenter l'encours, modéliser impact vs ADV, imposer limites par instrument, et vérifier que la perf décroît avec les frictions.

4. **Q.** How do you translate weights into executable orders ?

R. Convertir en quantités via AUM et prix, gérer cash/arrondis/lots, contrôles de risque pre-trade, puis scheduling (TWAP/VWAP/AC) selon urgence et impact.

Backtest sanity & interview traps

1. **Q.** Name 5 backtest pitfalls a recruiter expects you to mention.

- R.** Look-ahead, survivorship, data snooping/multiple testing, coûts/slippage/impact, liquidité/capacity, et non-stationnarité (régimes).
2. **Q.** If your optimizer outputs huge long/short weights, what do you check first ?
R. Conditionnement de Σ (petites eigenvalues), cohérence des contraintes, dimension vs fenêtre, qualité de μ (signal vs bruit). Quick fixes : bornes, shrinkage, ridge, leverage cap.
3. **Q.** Give 3 monitoring metrics you would run daily.
R. Expositions (facteurs/secteurs), contributions au risque, turnover + coûts estimés/réalisés, et écart vs benchmark (TE, beta, duration).

Interview drills (quickfire)

1. **Q.** Why is equal-weight (EW) a hard baseline to beat ?
R. Parce qu'il est très robuste à l'erreur d'estimation et minimise implicitement l'overfitting. Beaucoup d'optimiseurs « battent » EW brut mais perdent net de coûts et hors échantillon.
2. **Q.** What is resampled Markowitz and what does it fix ?
R. On bootstrap les estimations (μ, Σ) et on moyenne les poids optimaux. Cela réduit la sensibilité à une estimation particulière (variance), au prix d'un biais.
3. **Q.** Define turnover and why it matters.
R. Turnover $\approx \|\Delta w\|_1$ (ou en notionnel). Il pilote coûts/impact, et donc la perf nette. Un alpha faible avec gros turnover est souvent non monétisable.
4. **Q.** How do you pick the rebalance frequency ?
R. Trade-off : fréquence haute capture le signal mais augmente les coûts ; fréquence basse réduit les coûts mais laisse le portefeuille dériver. On choisit via backtests *net* + contraintes d'exécution.
5. **Q.** Variance vs CVaR : when do you prefer CVaR ?
R. Quand les queues dominent (crises) ou quand la distribution est asymétrique/heavy-tailed. CVaR est cohérent et se formule en LP, mais dépend des scénarios et peut être instable si N est faible.
6. **Q.** What is a robust mean-variance formulation ?
R. Typiquement : $\max_w \min_{\mu \in \mathcal{U}} \mu^\top w - \frac{\lambda}{2} w^\top \Sigma w$, ou incertitude sur Σ . Avec ensembles ellipsoïdaux, on obtient des problèmes convexes (SOCP) qui limitent les poids extrêmes.
7. **Q.** How do you impose liquidity constraints ?
R. Bornes par nom ($|\Delta w_i| \leq \kappa \cdot \text{ADV}_i$), limites de participation, ou pénalité d'impact Γ croissante quand l'ADV baisse.
8. **Q.** How do you handle missing returns in covariance estimation ?
R. Soit imputation (avec prudence), soit estimation pairwise + projection PSD, soit factor model. Danger : introduire du leakage (utiliser une info future) ou biaiser les corrélations.
9. **Q.** What is the marginal contribution to risk (MRC) and why useful ?
R. $\text{MRC}_i = \partial_{w_i} \sigma_p = (\Sigma w)_i / \sigma_p$. Utile pour risk budgeting, diagnostics de concentration, et pour expliquer un portefeuille à un risk manager.
10. **Q.** Why is scaling important numerically in optimizers ?
R. Parce que les solveurs sont sensibles au conditionnement : unités (bps vs decimals), rescaling des contraintes, ridge, et contrôles sur $\kappa(\Sigma)$ évitent des solutions artefactuelles.
11. **Q.** How do you incorporate beta/duration constraints ?
R. En ajoutant des contraintes linéaires sur expositions : $b^\top w = \beta^*$ ou $d^\top w = D^*$. Ces expositions proviennent d'un risk model (facteurs).
12. **Q.** What is a stress test you would always run ?
R. Corrélations $\uparrow$ (stress « one-factor »), volatilités $\uparrow$, et choc sur un facteur dominant (rates, equity beta). Le but : voir si le risque se concentre.

13. **Q.** How do borrow costs affect a long/short optimizer ?
R. Ils entrent comme coût récurrent (carry) sur les shorts et comme contrainte de disponibilité. Ils peuvent inverser un signal faible : un short cher à borrow n'est pas un alpha.
14. **Q.** What is the difference between covariance and correlation in portfolio context ?
R. La corrélation normalise les variances ; l'allocation *en risque* dépend de Σ , pas seulement des corrélations. Deux actifs peu corrélés mais très vol peuvent dominer le risque.
15. **Q.** How do you validate a risk model out-of-sample ?
R. Backtester la prédiction de volatilité/TE, tester la whiteness des résidus (si factor), comparer $\hat{\Sigma}$ vs realised covariance sur horizons, et faire des stress par régime.
16. **Q.** What is the quickest way to spot leakage in an alpha+optimizer pipeline ?
R. Vérifier que la performance se dégrade *monotoniquement* quand on (i) ajoute des coûts, (ii) introduit une latence, (iii) décale les signaux. Si non, bug/leakage.
17. **Q.** How do you allocate risk across factors rather than assets ?
R. Travailler dans l'espace factor : contrôles sur $B^\top w$, risk budgets par facteur via contributions RC^{factor} , et optimiser avec une covariance factorielle Σ_f .
18. **Q.** What is capacity stress in one line ?
R. Augmenter l'AUM et imposer un modèle d'impact (fonction de l'ADV) pour voir à partir de quand la perf nette s'effondre.
19. **Q.** If two optimizers have similar gross Sharpe, how do you choose ?
R. Celui qui est plus stable (sensibilité faible aux inputs), moins gourmand en turnover, plus explicable (expositions/risque), et plus robuste en stress/régimes.

Partie VIII — Décision/ML (RL, DQN, finance)

MDP, Q-learning : fondations

1. **Q.** Define an MDP in the trading/hedging context.
R. État s_t (features, inventaire, prices), action a_t (trade/hedge), reward r_{t+1} (PnL net de coûts, ou utilité), transition $P(s_{t+1} \mid s_t, a_t)$, discount γ . L'objectif est maximiser $\mathbb{E}[\sum \gamma^t r_{t+1}]$ ou une utilité risque-sensible.
2. **Q.** Write the Bellman optimality equation for $Q^*(s, a)$.
R. $Q^*(s, a) = \mathbb{E}[r_{t+1} + \gamma \max_{a'} Q^*(s_{t+1}, a') \mid s_t = s, a_t = a]$. Q-learning approxime ce point fixe.
3. **Q.** Why does naive function approximation in Q-learning diverge?
R. Parce que (i) les targets dépendent du réseau lui-même (bootstrapping), (ii) les données sont corrélées, (iii) l'apprentissage est off-policy. DQN stabilise via replay buffer + target network (et variantes : Double DQN).

DQN : stabilisation, diagnostics

1. **Q.** What is the purpose of the target network?
R. Décorrélérer la cible $y = r + \gamma \max_{a'} Q_{\theta^-}(s', a')$ des paramètres mis à jour θ , ce qui transforme un problème instable en optimisation plus “supervised-like”.
2. **Q.** Double DQN : what bias does it reduce?
R. Le biais de sur-estimation dû au max sur des estimateurs bruités. Double DQN sélectionne l'action via Q_θ mais évalue via Q_{θ^-} .
3. **Q.** Give 3 diagnostics you would monitor in training.
R. Distribution des rewards/returns, TD-error (moyenne/variance), évolution de Q (drift/explosions), performance out-of-sample par régime, et sensibilité aux coûts/slippage.

Finance specifics

1. **Q.** Why is offline evaluation hard in trading RL?
R. Les politiques changent la distribution des états (shift), les données historiques sont générées par une politique inconnue (behavior policy), et la non-stationnarité de marché casse les hypothèses i.i.d. OPE (importance sampling) est variance-explosive ; on combine stress tests + walk-forward + contraintes.
2. **Q.** What is the most common reward shaping mistake?
R. Récompenser un signal qui fuit l'information future (leakage) ou ignorer les coûts/impact : on obtient un agent “arbitrageur de backtest”. Il faut définir reward net de frictions, avec conventions d'exécution réalistes (prices, delays).

Partie IX — Mémoire & rough (Volterra, fBm, rHeston, rBergomi)

Rough volatility : messages clés

1. **Q.** Why did rough volatility become popular after 2014 ?
R. Empiriquement, la volatilité réalisée/implicite montre une régularité très faible (trajectoires “rough”, Hurst $H \approx 0.1$) et une structure de smile court terme que les modèles Markoviens (Heston) peinent à reproduire sans artefacts.
2. **Q.** What is the main conceptual shift in rBergomi vs Heston ?
R. On modélise directement la *forward variance* $\xi_t(T) = \mathbb{E}[V_T | \mathcal{F}_t]$ comme une martingale log-normale (drift nul), au lieu de poser une dynamique Markovienne sur V_t avec mean-reversion.

Volterra kernels, fBm, (non-)semimartingale

1. **Q.** What is a Volterra process in this context ?
R. Un processus défini via un noyau causal : $X_t = \int_0^t K(t-s) dW_s$ (ou + drift). Pour $K(t) = t^{H-1/2}$ (normalisé), on obtient un objet lié au fBm (ou à sa version “Riemann–Liouville”).
2. **Q.** Why is fBm not compatible with standard Itô calculus when $H \neq 1/2$?
R. Le fBm n’est pas une semimartingale (sauf $H = 1/2$), donc l’intégrale d’Itô standard ne s’applique pas. On utilise soit calcul fractionnaire, soit rough paths, soit on modélise un facteur gaussien “Volterra” mais on garde l’intégrale d’Itô sur le prix.

Simulation / calibration

1. **Q.** Name two practical simulation approaches for rough models.
R. (i) Simulation gaussienne via Cholesky/circulant embedding du vecteur de bruit, puis construction du facteur Volterra. (ii) Schéma hybride (Bennedsen–Lunde–Pakkanen) avec discrétisation fine près de 0 + approximation du noyau (ou somme d’exponentielles pour “Markovian lift”).
2. **Q.** What does calibration typically target in rough volatility models ?
R. La surface d’implied vol (surtout short maturities) et/ou la dynamique de $\xi_t(T)$ (forward variance curve). Trade-off : fit local (surface) vs stabilité des paramètres, coût de pricing (Monte Carlo/Fourier) et robustesse hors échantillon.