

Programme / École

Finance Quantitative & Machine Learning

Dossier de synthèse

Prénom Nom

Année universitaire 20XX–20XX

Résumé :

Ce document présente une synthèse structurée de notions de finance de marché, de calcul stochastique, de modélisation de la volatilité, de finance de taux, de crédit, ainsi que des principaux concepts de Machine Learning (supervisé, non supervisé, deep learning, reinforcement learning). Il s'appuie sur des résultats théoriques rigoureux et des projets appliqués (sandbox de trading d'options, pipeline Numerai, Reverse Heston).

Table des matières

Introduction générale	4
Figures globales	5
1 1. Finance de marché	6
1.1 1.1. Produits dérivés - Options	6
1.1.1 Vanilla / Early Exercise	6
1.1.2 Path-dependent options	8
1.1.3 Barrier options	9
1.1.4 Spreads & Wings	10
1.1.5 Calendar & Diagonal Spreads	15
1.1.6 Exotic options	17
1.1.7 Basket options	22
1.2 1.2. Pricing des options	25
1.2.1 Variation quadratique des processus	25
1.2.2 Lemme d'Itô (dérivation “for dummies” rigoureuse)	27
1.2.3 Application du lemme d'Itô à $\log S_t$	29
1.2.4 Dérivation de la PDE de Black–Scholes	30
1.2.5 Application : résolution explicite de la PDE de Black–Scholes	31
1.2.6 Modèle de Heston et pricing semi-analytique	33
1.2.7 Surface de volatilité implicite et calibration de modèles	34
1.2.8 Modèles avancés : SABR et Équations de Volterra	36
1.3 1.3. Hedging et Greeks	37
1.3.1 1.3.1. Greeks	37
1.3.2 1.3.2. Hedging	37
1.3.3 1.3.3. Dérivation du modèle de Black–Scholes par delta-hedging	38
1.4 1.4. Taux & courbes de taux	39
1.4.1 1.4.1. Taux zéro-coupon et courbe des taux	39
1.4.2 1.4.2. Facteurs d'actualisation (Discount Factors)	39
1.4.3 1.4.3. Taux forward instantané	39
1.4.4 1.4.4. Construction de la courbe (bootstrapping)	40
1.5 1.5. Forwards, Futures et Swaps	41
1.5.1 1.5.1. Forwards	41
1.5.2 1.5.2. Futures	41
1.5.3 1.5.3. Interest Rate Swaps (IRS)	42
1.5.4 1.5.4. Interprétation économique	42
1.6 1.6. Crédit	42
1.6.1 1.6.1. CDS : définition et structure	42
1.6.2 1.6.2. Intensité de défaut (hazard rate)	43
1.6.3 1.6.3. Spread de CDS	43
1.6.4 1.6.4. Interprétations	43
1.7 1.7. Ouverture : modèles avancés en finance quantitative	43
1.7.1 1.7.1. Rough volatility et SDE de Volterra	44
1.7.2 1.7.2. Modèle de Heston et variants affines	44

1.7.3	1.7.3. Modèle SABR et volatilité inspirée (SVI)	44
1.7.4	1.7.4. Perspectives	45
2	2. Machine Learning	45
2.1	2.1. Supervised Learning	45
2.1.1	2.1.1. Fondamentaux	45
2.1.2	2.1.2. Modèles linéaires & factoriels	46
2.1.3	2.1.3. Arbres & Ensembles	47
2.2	2.2. Unsupervised Learning	47
2.2.1	2.2.1. Clustering	48
2.2.2	2.2.2. Anomaly / Novelty Detection	48
2.2.3	2.2.3. Réduction dimensionnelle	48
2.2.4	2.2.4. Séries temporelles classiques	49
2.3	2.3. Deep Learning	49
2.3.1	2.3.1. Bases	49
2.3.2	2.3.2. Convolutional Neural Networks (CNN)	50
2.3.3	2.3.3. RNN, LSTM, GRU	50
2.3.4	2.3.4. Transformers	51
2.3.5	2.3.5. Modèles génératifs	51
2.4	2.4. Reinforcement Learning	52
2.4.1	2.4.1. Concepts fondamentaux	52
2.4.2	2.4.2. Fonctions de valeur et équations de Bellman	52
2.4.3	2.4.3. Monte Carlo (MC)	52
2.4.4	2.4.4. Temporal Difference (TD)	53
2.4.5	2.4.5. SARSA, Expected SARSA, Q-Learning	53
2.4.6	2.4.6. On-policy vs Off-policy	53
2.4.7	2.4.7. Function Approximation	54
2.4.8	2.4.8. Policy Gradient Methods	54
2.4.9	2.4.9. Algorithmes évolutionnaires	54
3	3. Projets personnels	55
3.1	3.1. Sandbox de trading d'options	55
3.2	3.2. Pipeline Numerai	55
3.3	3.3. Reverse Heston Model	55
4	4. Conclusion et ouverture	55
4.1	4.1. Synthèse	55
4.2	4.2. Ouverture	56
4.3	4.3. Conclusion générale	56
5	5. Bibliographie et ressources	57
5.1	5.1. Finance quantitative	57
5.2	5.2. FinTech et Data Science appliquée à la finance	57
5.3	5.3. Mathématiques et probabilités	57
5.4	5.4. Machine Learning	57
5.5	5.5. Vidéos de Reinforcement Learning	58
5.6	5.6. Ressources vidéo : mathématiques	58

5.7	5.7. Ressources vidéo : statistiques	58
Annexe A - Modèle de Heston		59
.1	Modèle de Heston et log-prix	59
.2	Fonction caractéristique du log-prix sous Heston	59
.3	PDE de Feynman–Kac et ansatz affine	60
.4	Résolution de l'équation de Riccati	60
.5	Intégration pour obtenir $C(\tau; u)$	61
.6	Fonction caractéristique finale	61
.7	Représentation de Fourier du prix de la call	62
.8	Densité du log-prix	62
.9	Damping et transformée de Fourier	62
.10	Formule d'inversion	62
.11	Schéma numérique (idée générale)	63
Annexe B - fBM et Rough Volatility		66
.12	Rappels sur le mouvement brownien fractionnaire	66
.13	Définition	66
.14	Discrétisation sur une grille	66
.15	Covariance du bruit fractionnaire	67
.16	Dérivation explicite de $\gamma(k)$	67
.17	Matrice de covariance Toeplitz	68
.18	Embedding circulant et vecteur c	68
.19	Diagonalisation de la matrice circulante par la FFT	69
.20	Matrice de Fourier	69
.21	Diagonalisation d'une matrice circulante	69
.22	Simulation gaussienne via la représentation spectrale	69
.23	Principe général	69
.24	Construction du vecteur Z	70
.25	Génération du bruit fractionnaire par IFFT	71
.26	Application de l'IFFT	71
.27	Reconstruction du mouvement brownien fractionnaire	71
.28	Récapitulatif de la méthode de Davies–Harte	72
Annexe C - SDE de Volterra		73
Annexe D - Modèle SABR		84
Annexe E - Rough Heston		85
Annexe F — Méthodes numériques		87

Introduction générale

La finance de marché moderne repose sur trois piliers principaux : les *modèles stochastiques* (mouvements browniens, EDS, volatilité locale ou stochastique), les *produits* (options vanilles, exotiques, dérivés de taux, produits de crédit), et les *méthodes numériques* (Monte Carlo, PDE, transformées de Fourier).

Parallèlement, le *Machine Learning* fournit un ensemble d'outils algorithmiques permettant de traiter des volumes de données importants, d'extraire des facteurs latents et d'apprendre des stratégies de décision optimales. Ces techniques sont aujourd'hui au cœur de la recherche appliquée en finance de marché : prédiction de signaux, calibration non paramétrique, approximation de surfaces de volatilité, optimisation de portefeuilles et Reinforcement Learning pour le hedging.


Ce dossier a un double objectif :

- exposer de manière structurée les notions fondamentales de finance quantitative et de Machine Learning,
- illustrer leur mise en œuvre au travers de projets concrets.


Dans ce qui suit, la **Partie 1** est consacrée à la finance de marché (pricing, courbes de taux, crédit, modèles avancés). La **Partie 2** développe les concepts de Machine Learning. La **Partie 3** présente des projets appliqués. La **Partie 4** fournit une conclusion et des pistes d'ouverture. Enfin, la **Partie 5** rassemble la bibliographie et les ressources associées.

Figures globales

Schéma global du mémoire



Carte conceptuelle ML & Finance



1 1. Finance de marché

1.1 1.1. Produits dérivés - Options

1.1.1 Vanilla / Early Exercise

Les options vanilles constituent la classe fondamentale des produits dérivés d'options. Leur payoff dépend uniquement du prix du sous-jacent S_T à l'échéance T , ce qui permet une étude rigoureuse via les outils classiques de calcul stochastique, de théorie de l'arbitrage et d'analyse fonctionnelle.

Options européennes. Une option européenne ne peut être exercée qu'à la date de maturité T .

Les payoffs sont donnés par :

$$\text{Call} : (S_T - K)^+, \quad \text{Put} : (K - S_T)^+,$$

où $(x)^+ = \max(x, 0)$.

Sous la mesure risque-neutre $\mathbb{Q}$ et en l'absence d'arbitrage, les prix sont :

$$C_0 = e^{-rT} \mathbb{E}^{\mathbb{Q}}[(S_T - K)^+], \quad P_0 = e^{-rT} \mathbb{E}^{\mathbb{Q}}[(K - S_T)^+].$$

Dans le modèle de mouvement brownien géométrique

$$dS_t = rS_t dt + \sigma S_t dW_t,$$

l'application du lemme d'Itô permet de dériver la PDE de Black-Scholes ainsi que la formule fermée du call européen.

La parité call-put s'écrit :

$$C_0 - P_0 = S_0 - Ke^{-rT},$$

relation qui doit être satisfaite dans tout modèle arbitrage-free.

Options américaines. Une option américaine peut être exercée à tout instant $\tau \in [0, T]$. La valorisation s'écrit comme un problème de temps d'arrêt optimal :

$$V_0 = \sup_{\tau \in \mathcal{T}} \mathbb{E}^{\mathbb{Q}}[e^{-r\tau} \Phi(S_\tau)],$$

où $\mathcal{T}$ désigne l'ensemble des temps d'arrêt adaptés.

La frontière d'exercice est caractérisée par l'inégalité :

$$\Phi(S_t) \geq V_t.$$

Cas classiques :

- Call américain *sans dividende* : l'exercice anticipé n'est jamais optimal et l'on a $V_0 = C_0^{EU}$.
- Put américain : un exercice anticipé peut être optimal lorsque S_t franchit une frontière critique $S^{(t)}$, solution d'un problème de frontière libre.

En pratique, ces produits nécessitent des méthodes numériques (arbres binomiaux ou trinômiaux, PDE variationnelles, méthodes de type Longstaff-Schwartz).

Options bermudéennes. Les options bermudéennes constituent un intermédiaire entre européennes et américaines : l'exercice n'est possible qu'à un ensemble discret de dates $\{t_1, \dots, t_m\} \subset [0, T]$.

La valorisation se fait par récurrence arrière :

$$V(t_i, S) = \max \left(\Phi(S), e^{-r(t_{i+1}-t_i)} \mathbb{E}[V(t_{i+1}, S_{t_{i+1}}) \mid S_{t_i} = S] \right).$$

On rencontre ce type de produits en taux (swaptions bermudéennes), dans certains produits structurés ou produits de crédit exotiques.

Options vanilles sous volatilité stochastique : modèle de Heston. Dans le modèle de Heston, sous la mesure risque-neutre, le sous-jacent S_t et la variance instantanée v_t satisfont :

$$\begin{cases} dS_t = rS_t dt + \sqrt{v_t} S_t dW_t^{(1)}, \\ dv_t = \kappa(\theta - v_t) dt + \xi \sqrt{v_t} dW_t^{(2)}, \end{cases} \quad dW_t^{(1)} dW_t^{(2)} = \rho dt.$$

Le prix du call européen admet une formule semi-fermée de la forme

$$C_0 = S_0 P_1 - K e^{-rT} P_2,$$

où P_1 et P_2 s'expriment comme des intégrales de Fourier faisant intervenir la fonction caractéristique du log-prix.

La dérivation complète de cette formule (changement de mesure, résolution de l'ODE pour la fonction caractéristique, inversion de Fourier) est fournie en annexe (*voir les fichiers `Heston implé.tex` et `Heston feuille.tex`*).

Volatilité rugueuse et modèle rBergomi. Le modèle rBergomi repose sur un mouvement brownien fractionnaire de paramètre de Hurst $H < \frac{1}{2}$, conduisant à une dynamique de variance à mémoire longue de type Volterra. Il permet de reproduire avec précision le skew de volatilité à court terme, en particulier sur indices actions.

Les éléments clés sont :

- définition du fractional Brownian motion B^H ,
- représentation de Mandelbrot–Van Ness,
- simulation numérique (schéma de Davies–Harte),
- lien avec les SDE de type Volterra et la variance rough.

Les dérivations détaillées, ainsi que les liens avec le modèle rBergomi, sont présentés en annexe (*voir les fichiers `fBM feuille.tex` et `toRBBrrregomi.tex`*).

Rôle structurel des options vanilles. Les options vanilles sont utilisées pour :

- **calibrer** les modèles de volatilité, en ajustant un vecteur de paramètres θ pour minimiser l'écart entre volatilités implicites modèle et marché ;
- **extraire les sensibilités** (Greeks) : $\Delta = \frac{\partial V}{\partial S}$, $\Gamma = \frac{\partial^2 V}{\partial S^2}$, Vega = $\frac{\partial V}{\partial \sigma}$, etc. ;
- **construire des payoffs exotiques synthétiques** par superposition linéaire d'options vanilles (spreads, butterflies, arbitrages statiques).

1.1.2 Path-dependent options

Les options path-dependent sont des produits dérivés dont le payoff dépend de l'ensemble de la trajectoire $(S_t)_{0 \leq t \leq T}$, et non uniquement de la valeur du sous-jacent à maturité. Leur valorisation requiert l'utilisation de probabilités fonctionnelles, de techniques avancées de Monte Carlo et, dans certains cas, de résultats de théorie des extrêmes du mouvement brownien.

Asian options. Structure. On distingue deux types principaux de moyennes discrètes :

$$A_T^{\text{arith}} = \frac{1}{n} \sum_{i=1}^n S_{t_i}, \quad A_T^{\text{geom}} = \left(\prod_{i=1}^n S_{t_i} \right)^{1/n}.$$

Payoff.

$$\text{Call asiatique : } (A_T - K)^+, \quad \text{Put asiatique : } (K - A_T)^+.$$

Pricing.

- Cas géométrique : moyenne lognormale $\Rightarrow$ formule fermée.
- Cas arithmétique : pas de forme fermée.

Méthodes principales :

- Monte Carlo (méthode standard),
- variance reduction (antithetic, control variate utilisant la moyenne géométrique),
- approximation lognormale de Turnbull–Wakeman.

Lookback options. Structure.

$$M_T = \max_{0 \leq t \leq T} S_t, \quad m_T = \min_{0 \leq t \leq T} S_t.$$

Payoff.

- **Floating strike :**

$$\text{Call : } (S_T - m_T)^+, \quad \text{Put : } (M_T - S_T)^+.$$

- **Fixed strike :**

$$\text{Call : } (M_T - K)^+, \quad \text{Put : } (K - m_T)^+.$$

Pricing.

- Formules fermées en Black–Scholes via le principe de réflexion.
- En général : simulation Monte Carlo indispensable.
- Gestion des franchissements : Brownian bridge pour limiter les erreurs.

Forward-start options. Structure. Le strike est fixé à une date future $t_0 < T$:

$$K = \alpha S_{t_0}.$$

Payoff.

$$\Phi = (S_T - \alpha S_{t_0})^+.$$

Pricing.

- Interprétation comme un call européen conditionnel à S_{t_0} .
- En Black–Scholes : équivalent à un call sur un forward.
- En général : simulation jointe (S_{t_0}, S_T) .

Cliquet / Ratchet options. Structure. Options à réinitialisation périodique :

$$\Phi = \sum_{i=1}^n (S_{t_i} - S_{t_{i-1}})^+.$$

Payoff. Basé sur les increments positifs ou une accumulation de gains “lock-in”.

Pricing.

- Simulation Monte Carlo multidimensionnelle,
- corrélations fortes entre increments $\Rightarrow$ variance élevée,
- PDE multidimensionnelle impraticable en général.

1.1.3 Barrier options

Les options barrières sont des produits dérivés dont le payoff dépend du franchissement ou non d’un niveau prédéfini appelé *barrière*. Elles sont fortement sensibles à la trajectoire du sous-jacent et requièrent la maîtrise des temps de passage du mouvement brownien.

Structure. On définit le temps d’atteinte de la barrière B par :

$$\tau_B = \inf\{t \geq 0 : S_t \in \mathcal{B}\}.$$

Deux familles principales :

- **Knock-out** : l’option est annulée si $\tau_B \leq T$.
Exemples : up-and-out, down-and-out.
- **Knock-in** : l’option n’existe que si la barrière est atteinte avant T .
Exemples : up-and-in, down-and-in.

Payoff. Pour un payoff vanille $\Phi(S_T)$:

- **Knock-out** :

$$\Phi_{\text{KO}} = \Phi(S_T) \mathbf{1}_{\{\tau_B > T\}}.$$

- **Knock-in** :

$$\Phi_{\text{KI}} = \Phi(S_T) \mathbf{1}_{\{\tau_B \leq T\}}.$$

Relation fondamentale de parité :

$$\Phi_{\text{KI}} + \Phi_{\text{KO}} = \Phi_{\text{vanilla}}.$$

Pricing.

Cas Black–Scholes : formules fermées. Sous un GBM, les hitting times sont explicites par le principe de réflexion. Cela conduit à des formules fermées pour l'ensemble des barrières up/down, in/out.

Exemple (call down-and-out) :

$$C_{\text{DO}} = C_{\text{vanilla}} - \left(\frac{B}{S_0}\right)^{2\lambda-2} C_{\text{vanilla}}(S'_0, K),$$

avec

$$\lambda = \frac{r}{\sigma^2} + \frac{1}{2}, \quad S'_0 = \frac{B^2}{S_0}.$$

Observation continue vs discrète.

- Observation continue : barrière active en tout temps $\rightarrow$ hitting times exacts.
- Observation discrète : barrière testée à des dates $\{t_i\}$ seulement $\Rightarrow \text{Price}_{\text{disc}} > \text{Price}_{\text{cont}}$.

Correction : utilisation d'un **Brownian bridge** entre deux pas de temps.

Pricing sous volatilité locale / stochastique / rough.

- **Local vol** : PDE 2D (spot + temps), solution numérique stable.
- **Heston** : simulation Monte Carlo nécessaire, schéma QE pour v_t .
- **Rough volatility** : trajectoires plus irrégulières, hitting times plus fréquents.

Monte Carlo. Le Monte Carlo naïf ne détecte pas correctement les franchissements. Solution : Brownian bridge.

Probabilité conditionnelle de franchissement :

$$\mathbb{P}(\text{hit}) = \exp\left(-\frac{2}{\sigma^2 h} \ln \frac{S_t}{B} \cdot \ln \frac{S_{t+h}}{B}\right).$$

Variantes.

- **Rebate options** :

$$R \cdot \mathbf{1}_{\{\tau_B < T\}}.$$

- **Parisian barriers** : hitting cumulé durant δ :

$$\tau^* = \inf \left\{ t : \int_0^t \mathbf{1}_{\{S_u < B\}} du \geq \delta \right\}.$$

- **Partial barriers** : barrière active uniquement sur $[t_a, t_b]$.

1.1.4 Spreads & Wings

Les stratégies « spreads » et « wings » sont des combinaisons linéaires d'options vanilles visant à modifier le profil de payoff et les sensibilités (gamma, vega, vomma, convexité). Elles reposent sur le principe :

$$\Phi = \sum_i w_i \Phi_i,$$

où chaque Φ_i est un payoff vanille.


Bull Call Spread. Structure.

$$\text{Long Call}(K_1) + \text{Short Call}(K_2), \quad K_1 < K_2.$$

Payoff.

$$\Phi(S_T) = (S_T - K_1)^+ - (S_T - K_2)^+.$$

Graphique du payoff.



$$V_0 = C(K_1) - C(K_2).$$


Bear Put Spread. Structure.

$$\text{Long Put}(K_2) + \text{Short Put}(K_1), \quad K_1 < K_2.$$

Payoff.

$$\Phi(S_T) = (K_2 - S_T)^+ - (K_1 - S_T)^+.$$

Graphique du payoff.



$$V_0 = P(K_2) - P(K_1).$$


Straddle. Structure.

Long Call(K) + Long Put(K).

Payoff.

$$\Phi(S_T) = |S_T - K|.$$

Graphique du payoff.



$$V_0 = C(K) + P(K).$$


Strangle. Structure.

$$\text{Long Put}(K_1) + \text{Long Call}(K_2), \quad K_1 < K_2.$$

Payoff.

$$\Phi(S_T) = (K_1 - S_T)^+ + (S_T - K_2)^+.$$

Graphique du payoff.




Butterfly spread. Structure.

$$\text{Long } C(K_1) - 2C(K_2) + \text{Long } C(K_3), \quad K_1 < K_2 < K_3.$$

Payoff.

$$\Phi(S_T) = (S_T - K_1)^+ - 2(S_T - K_2)^+ + (S_T - K_3)^+.$$


Graphique du payoff.



Condor spread. Structure.

$$C(K_1) - C(K_2) - C(K_3) + C(K_4), \quad K_1 < K_2 < K_3 < K_4.$$

Graphique du payoff.



1.1.5 Calendar & Diagonal Spreads

Les calendar spreads et diagonal spreads sont des stratégies multi-maturités qui exploitent la structure par terme de la volatilité implicite ainsi que la décroissance temporelle de la valeur temps (Theta). Elles reposent sur la combinaison d'options de même sous-jacent mais de maturités, voire de strikes, différents.

Calendar Spread. Structure.

$$\text{Long Call}(K, T_2) + \text{Short Call}(K, T_1), \quad T_1 < T_2.$$

Payoff. À maturité T_2 , le payoff du calendar spread est celui de l'option longue, mais le coût initial est réduit par la jambe courte :

$$\Pi_0 = C(K, T_2) - C(K, T_1).$$


Pricing. Sous Black-Scholes :

$$C(K, T_i) = BS(S_0, K, r, \sigma, T_i), \quad i = 1, 2.$$

Le spread dépend de :

- la pente de la structure de volatilité,
- la position du strike par rapport au forward,
- la différence de theta entre T_1 et T_2 .

Graphique du payoff (profil à maturité).



Diagonal Spread. Structure.

$$\text{Long Call}(K_2, T_2) + \text{Short Call}(K_1, T_1), \quad T_2 > T_1, \quad K_1 \neq K_2.$$

Payoff.

$$\Pi_0 = C(K_2, T_2) - C(K_1, T_1).$$

Profil final : payoff de call $(S_{T_2} - K_2)^+$, mais avec dynamique intermédiaire asymétrique en fonction de K_1 .

Pricing.

- Long vega long terme, short vega court terme.
- Sensibilité directionnelle via (K_1, K_2) .
- Interprétation : combinaison directionnelle + term structure.

Graphique du payoff (profil typique).



1.1.6 Exotic options

Les options exotiques sont des dérivés dont la structure de payoff dépasse celle des options vanilles. Elles permettent de modéliser des expositions complexes : vues directionnelles asymétriques, paris sur la corrélation, paris sur la volatilité locale ou stochastique, ou encore élimination du risque de change (produits quanto).

Digital options. Structure. Une option digitale verse un montant fixe Q si la condition de moneyness est satisfaite.

Payoff.

$$\Phi_{\text{DC}} = Q \cdot \mathbf{1}_{\{S_T > K\}}, \quad \Phi_{\text{DP}} = Q \cdot \mathbf{1}_{\{S_T < K\}}.$$

Pricing (Black–Scholes).

$$V_0^{\text{DC}} = Qe^{-rT}N(d_2), \quad d_2 = \frac{\ln(S_0/K) + (r - \frac{1}{2}\sigma^2)T}{\sigma\sqrt{T}}.$$

Graphique du payoff (digital call).



Asset-or-nothing options. Structure. Le payoff dépend du niveau du sous-jacent et d'une condition binaire.

Payoff.


$$\Phi_{\text{AON}} = S_T \cdot \mathbf{1}_{\{S_T > K\}}.$$

Pricing (Black–Scholes).

$$V_0 = S_0 N(d_1).$$

Graphique du payoff (asset-or-nothing call).

Payoff



19

K

Chooser options. Structure. À une date $t_c < T$, l'acheteur choisit entre un call et un put.

Payoff.

$$\Phi = \max(C(t_c, T), P(t_c, T)).$$


Relation clé.

$$\Phi = C(t_c, T) + P(t_c, T) - |S_{t_c} - K|.$$

Pricing (Black–Scholes).

$$V_0 = C(S_0, K, T) + P(S_0, K, T) - P(S_0, K, t_c).$$

Graphique du payoff à t_c .




Quanto options. Structure. Option sur un actif étranger, payoff payé dans une autre devise.

$$\Phi_{\text{quanto}} = \Phi_{\text{local}}(S_T) \times F X_0.$$

Drift risque-neutre ajusté.

$$dS_t = (r_d - q - \rho_{S,X} \sigma_S \sigma_X) S_t dt + \sigma_S S_t dW_t^{(S)}.$$

Graphique du payoff (quanto call).



Rainbow options. Structure.

$$\Phi_{\max} = (\max_i S_T^{(i)} - K)^+, \quad \Phi_{\min} = (K - \min_i S_T^{(i)})^+.$$

Payoff. Best-of / worst-of.

Pricing. Dépend de la corrélation :

$$\sigma_B^2 = \sum_{i,j} w_i w_j \sigma_i \sigma_j \rho_{ij}.$$

Méthodes :

- simulation Monte Carlo multivariée,
- approximations lognormales,
- pricing via copules.

Graphique du payoff (best-of, 2 actifs).



1.1.7 Basket options

Les basket options sont des dérivés dont le payoff dépend d'un panier pondéré de plusieurs sous-jacents. Leur valorisation est profondément influencée par la corrélation entre les actifs, ainsi que par la structure de leurs volatilités respectives.

Le panier s'écrit :

$$B_T = \sum_{i=1}^n w_i S_T^{(i)}, \quad \sum_{i=1}^n w_i = 1, \quad w_i \geq 0.$$

Basket call / put. Payoff.

$$\Phi_{\text{call}} = (B_T - K)^+, \quad \Phi_{\text{put}} = (K - B_T)^+.$$

Pricing. Même lorsque chaque $S_t^{(i)}$ suit un GBM, le panier B_T n'est pas lognormal. Il n'existe donc pas de formule fermée générale.


Approximations usuelles :

- **Approximation lognormale** : $B_T \approx \text{LN}(\mu_B, \sigma_B^2)$ où


$$\sigma_B^2 = \sum_{i,j} w_i w_j \sigma_i \sigma_j \rho_{ij}.$$

- **Moment matching** : ajustement d'une lognormale équivalente via $\mathbb{E}[B_T]$ et $\text{Var}(B_T)$.
- **Monte Carlo multivarié** : simulation corrélée via factorisation de Cholesky ou SVD.

Graphique (Basket Call).



Basket put. Graphique (Basket Put).



Best-of / Worst-of options. Structure.

$$\Phi_{\max} = (\max_i S_T^{(i)} - K)^+, \quad \Phi_{\min} = (K - \min_i S_T^{(i)})^+.$$

Sensibilités. La dépendance à la corrélation est immédiate :

- Best-of : augmente lorsque la corrélation baisse.
- Worst-of : augmente lorsque la corrélation grimpe.

Pricing.

- Monte Carlo multivarié (méthode standard).
- Approximations lognormales / copules gaussiennes.
- Pricing Fourier multivarié (méthodes COS).

Graphique (Best-of, 2 actifs).



1.2 1.2. Pricing des options

1.2.1 Variation quadratique des processus

Ressource vidéo complémentaire :

<https://www.youtube.com/watch?v=aimS3f5V44U&t=14s>

Définition. Soit une partition d'un intervalle $[0, T]$:

$$\Pi_n = \{0 = t_0^{(n)} < t_1^{(n)} < \dots < t_{k_n}^{(n)} = T\}, \quad |\Pi_n| := \max_i (t_{i+1}^{(n)} - t_i^{(n)}).$$

On définit la *variation quadratique* d'un processus continu (X_t) par la limite, lorsqu'elle existe :

$$[X]_T := \lim_{n \rightarrow \infty} \sum_{i=0}^{k_n-1} (X_{t_{i+1}^{(n)}} - X_{t_i^{(n)}})^2, \quad |\Pi_n| \rightarrow 0.$$

Lorsque la limite existe pour tout $t \leq T$, on obtient un processus croissant $t \mapsto [X]_t$.

Variation quadratique du mouvement brownien. Soit (W_t) un mouvement brownien standard. Sur un intervalle $[t_i, t_{i+1}]$ de longueur Δt_i :

$$W_{t_{i+1}} - W_{t_i} \sim \mathcal{N}(0, \Delta t_i) \quad \Rightarrow \quad \mathbb{E}[(W_{t_{i+1}} - W_{t_i})^2] = \Delta t_i.$$

Considérons :

$$S_n := \sum_i (W_{t_{i+1}^{(n)}} - W_{t_i^{(n)}})^2.$$

Alors :

$$\mathbb{E}[S_n] = \sum_i \Delta t_i = T.$$

Pour la variance :

$$\text{Var}(S_n) = \sum_i \text{Var}((W_{t_{i+1}} - W_{t_i})^2).$$

Si $Z \sim \mathcal{N}(0, \Delta t)$, alors

$$\mathbb{E}[Z^4] = 3(\Delta t)^2, \quad \text{Var}(Z^2) = 3(\Delta t)^2 - (\Delta t)^2 = 2(\Delta t)^2.$$

Donc :

$$\text{Var}(S_n) = 2 \sum_i (\Delta t_i)^2.$$

Or, lorsque $|\Pi_n| \rightarrow 0$:

$$\sum_i (\Delta t_i)^2 \leq |\Pi_n| \sum_i \Delta t_i = |\Pi_n| T \xrightarrow{n \rightarrow \infty} 0.$$

Ainsi :

$$\text{Var}(S_n) \rightarrow 0.$$

Par l'inégalité de Chebyshev :

$$\forall \varepsilon > 0, \quad \mathbb{P}(|S_n - T| > \varepsilon) \leq \frac{\text{Var}(S_n)}{\varepsilon^2} \xrightarrow{n \rightarrow \infty} 0.$$

Donc :

$$S_n \xrightarrow[n \rightarrow \infty]{\mathbb{P}} T,$$

et, en renforçant l'argument (partitions dyadiques + Borel–Cantelli),

$$[W]_t = t \quad \text{presque sûrement.}$$

Variation quadratique d'un processus d'Itô. Considérons une diffusion :

$$X_t = X_0 + \int_0^t a_s ds + \int_0^t b_s dW_s.$$

Sur un petit intervalle $[t_i, t_{i+1}]$:

$$\Delta X_i = X_{t_{i+1}} - X_{t_i} = \underbrace{\int_{t_i}^{t_{i+1}} a_s ds}_{\mathcal{O}(\Delta t_i)} + \underbrace{\int_{t_i}^{t_{i+1}} b_s dW_s}_{\mathcal{O}(\sqrt{\Delta t_i})}.$$

Le terme stochastique domine dans le carré :

$$(\Delta X_i)^2 \approx \left(\int_{t_i}^{t_{i+1}} b_s dW_s \right)^2.$$

Par isométrie d'Itô :

$$\mathbb{E} \left[\left(\int_{t_i}^{t_{i+1}} b_s dW_s \right)^2 \right] = \mathbb{E} \left[\int_{t_i}^{t_{i+1}} b_s^2 ds \right] \approx b_{t_i}^2 \Delta t_i.$$

Ainsi :

$$\sum_i (\Delta X_i)^2 \rightarrow \int_0^T b_s^2 ds.$$

On obtient rigoureusement :

$$[X]_t = \int_0^t b_s^2 ds.$$

Résumé.

— Pour le mouvement brownien : $[W]_t = t$.

— Pour une diffusion d'Itô :

$$dX_t = a_t dt + b_t dW_t \Rightarrow [X]_t = \int_0^t b_s^2 ds.$$

— La variation quadratique justifie les règles : $(dW_t)^2 = dt$, $dt dW_t = 0$, $dt^2 = 0$.

1.2.2 Lemme d'Itô (dérivation “for dummies” rigoureuse)

Ressource vidéo complémentaire :

<https://www.youtube.com/watch?v=3Fov1xLVI88>

Soit un mouvement brownien $(W_t)_{t \geq 0}$ sur un espace probabilisé filtré $(\Omega, \mathcal{F}, (\mathcal{F}_t)_{t \geq 0}, \mathbb{P})$, et soit un processus d'Itô scalaire $(X_t)_{t \in [0, T]}$ de la forme :

$$dX_t = a(t, X_t) dt + b(t, X_t) dW_t,$$

où a et b sont des fonctions mesurables, suffisamment régulières, et adaptées. On se donne une fonction

$$f : [0, T] \times \mathbb{R} \rightarrow \mathbb{R}, \quad f \in C^{1,2},$$

c'est-à-dire f est C^1 en t et C^2 en x avec toutes ces dérivées continues.

On définit le processus

$$Y_t := f(t, X_t).$$

Le lemme d'Itô donne l'expression différentielle de (Y_t) .

Heuristique (idée de base). Considérons un petit incrément de temps $h > 0$ et notons $X_t = x$ pour fixer les idées. Sur l'intervalle $[t, t+h]$, on a formellement :

$$X_{t+h} - X_t \simeq a(t, x) h + b(t, x) \Delta W_t, \quad \Delta W_t := W_{t+h} - W_t,$$

avec $\Delta W_t \sim \mathcal{N}(0, h)$. En ordre de grandeur :

$$a(t, x) h = \mathcal{O}(h), \quad b(t, x) \Delta W_t = \mathcal{O}(\sqrt{h}).$$

On applique un développement de Taylor à deux variables à f autour de (t, x) :

$$\begin{aligned} f(t+h, X_{t+h}) &\approx f(t, x) + f_t(t, x) h + f_x(t, x) (X_{t+h} - x) \\ &\quad + \frac{1}{2} f_{xx}(t, x) (X_{t+h} - x)^2. \end{aligned}$$

En posant $\Delta X := X_{t+h} - X_t$, on obtient donc

$$\Delta f := f(t+h, X_{t+h}) - f(t, X_t) \approx f_t h + f_x \Delta X + \frac{1}{2} f_{xx} (\Delta X)^2.$$

Comportement du terme $(\Delta X)^2$ et rôle de la variation quadratique. Avec $\Delta X \simeq ah + b\Delta W_t$, on obtient

$$(\Delta X)^2 \simeq (ah + b\Delta W_t)^2 = a^2 h^2 + 2abh\Delta W_t + b^2(\Delta W_t)^2.$$

En termes d'ordre :

$$a^2 h^2 = \mathcal{O}(h^2), \quad 2abh\Delta W_t = \mathcal{O}(h^{3/2}), \quad b^2(\Delta W_t)^2 = \mathcal{O}(h).$$

Les deux premiers termes sont négligeables face à h lorsque $h \rightarrow 0$, tandis que le dernier terme est d'ordre h et donc *non négligeable*. Or la variation quadratique du brownien dit précisément que

$$(\Delta W_t)^2 \approx h$$

(en un sens probabiliste ou presque sûr via la définition de $[W]_t$). On retient donc heuristiquement :

$$(\Delta X)^2 \approx b(t, x)^2 h.$$

Substitution dans le développement de Taylor. En remplaçant ΔX et $(\Delta X)^2$ dans l'expression de Δf :

$$\Delta f \approx f_t h + f_x (ah + b\Delta W_t) + \frac{1}{2} f_{xx} b^2 h.$$

On peut réarranger les termes :

$$\Delta f \approx (f_t + af_x + \frac{1}{2}b^2 f_{xx}) h + bf_x \Delta W_t.$$

Lorsque $h \rightarrow 0$, on interprète :

$$\Delta f \sim df, \quad h \sim dt, \quad \Delta W_t \sim dW_t,$$

et on obtient formellement la forme différentielle :

$$df(t, X_t) = (f_t + af_x + \frac{1}{2}b^2 f_{xx})(t, X_t) dt + b(t, X_t) f_x(t, X_t) dW_t.$$

Forme rigoureuse via la variation quadratique. De manière plus rigoureuse, on écrit d'abord la version générale :

$$df(t, X_t) = f_t(t, X_t) dt + f_x(t, X_t) dX_t + \frac{1}{2} f_{xx}(t, X_t) d[X]_t,$$

où $[X]_t$ est la variation quadratique de X .

Avec

$$dX_t = a(t, X_t) dt + b(t, X_t) dW_t,$$

on sait que

$$[X]_t = \int_0^t b(s, X_s)^2 ds \quad \Rightarrow \quad d[X]_t = b(t, X_t)^2 dt.$$

En substituant dans la formule ci-dessus, on obtient :

$$df(t, X_t) = f_t dt + f_x(a dt + b dW_t) + \frac{1}{2} f_{xx} b^2 dt,$$

c'est-à-dire

$$df(t, X_t) = (f_t + a f_x + \frac{1}{2} b^2 f_{xx})(t, X_t) dt + b(t, X_t) f_x(t, X_t) dW_t.$$

Forme intégrale. En intégrant de 0 à t :

$$\begin{aligned} f(t, X_t) &= f(0, X_0) + \int_0^t f_t(s, X_s) ds + \int_0^t f_x(s, X_s) dX_s + \frac{1}{2} \int_0^t f_{xx}(s, X_s) d[X]_s \\ &= f(0, X_0) + \int_0^t (f_t + a f_x + \frac{1}{2} b^2 f_{xx})(s, X_s) ds + \int_0^t b(s, X_s) f_x(s, X_s) dW_s. \end{aligned}$$

Résumé. Pour un processus d'Itô

$$dX_t = a(t, X_t) dt + b(t, X_t) dW_t$$

et une fonction $f \in C^{1,2}$, le lemme d'Itô affirme que :

$$df(t, X_t) = (f_t + a f_x + \frac{1}{2} b^2 f_{xx})(t, X_t) dt + b(t, X_t) f_x(t, X_t) dW_t.$$

La présence du terme $\frac{1}{2} b^2 f_{xx}$ provient directement de la variation quadratique du brownien, via le fait que $(dW_t)^2$ se comporte comme dt dans le calcul stochastique.

1.2.3 Application du lemme d'Itô à $\log S_t$

On considère le processus de prix suivant sous une mesure $\mathbb{P}$ quelconque :

$$dS_t = \mu S_t dt + \sigma S_t dW_t, \quad S_0 > 0.$$

On souhaite déterminer la dynamique de $X_t := \log S_t$ par le lemme d'Itô.

On pose

$$f(x) = \log x, \quad f'(x) = \frac{1}{x}, \quad f''(x) = -\frac{1}{x^2}.$$

En appliquant le lemme d'Itô à $f(S_t)$, avec $a(t, S_t) = \mu S_t$ et $b(t, S_t) = \sigma S_t$:

$$df(S_t) = f'(S_t) dS_t + \frac{1}{2} f''(S_t) d[S]_t.$$

Or la variation quadratique de S_t est

$$d[S]_t = (\sigma S_t)^2 dt = \sigma^2 S_t^2 dt.$$

Donc

$$\begin{aligned} d(\log S_t) &= \frac{1}{S_t} (\mu S_t dt + \sigma S_t dW_t) + \frac{1}{2} \left(-\frac{1}{S_t^2} \right) \sigma^2 S_t^2 dt \\ &= \left(\mu - \frac{1}{2} \sigma^2 \right) dt + \sigma dW_t. \end{aligned}$$

Sous la mesure risque-neutre $\mathbb{Q}$ (où le drift devient r), on obtient :

$$d(\log S_t) = \left(r - \frac{1}{2}\sigma^2\right) dt + \sigma dW_t^{\mathbb{Q}}.$$

Cette forme est cruciale pour :

- expliciter la loi de S_T (lognormale),
- calculer les espérances risque-neutres dans la formule de Black-Scholes,
- effectuer des changements de variables (par exemple dans les modèles de vol locale).

1.2.4 Dérivation de la PDE de Black-Scholes

On se place sous la mesure risque-neutre $\mathbb{Q}$, où le sous-jacent suit :

$$dS_t = rS_t dt + \sigma S_t dW_t^{\mathbb{Q}},$$

avec r le taux sans risque constant.

Soit $V(t, S)$ le prix à la date t d'un payoff européen $\Phi(S_T)$. On suppose $V \in C^{1,2}$ et on applique le lemme d'Itô à $V(t, S_t)$.

On a :

$$dV(t, S_t) = V_t dt + V_S dS_t + \frac{1}{2}V_{SS} d[S]_t.$$

En substituant la dynamique de S_t :

$$dS_t = rS_t dt + \sigma S_t dW_t, \quad d[S]_t = (\sigma S_t)^2 dt,$$

on obtient :

$$\begin{aligned} dV(t, S_t) &= V_t dt + V_S(rS_t dt + \sigma S_t dW_t) + \frac{1}{2}V_{SS}\sigma^2 S_t^2 dt \\ &= (V_t + rS_t V_S + \frac{1}{2}\sigma^2 S_t^2 V_{SS}) dt + \sigma S_t V_S dW_t. \end{aligned}$$

On construit maintenant un portefeuille auto-finançant

$$\Pi_t = V(t, S_t) - \Delta_t S_t,$$

où Δ_t est une quantité d'unités du sous-jacent. On choisit

$$\Delta_t := V_S(t, S_t),$$

de sorte que le terme en dW_t disparaisse dans $d\Pi_t$.

En effet,

$$d\Pi_t = dV_t - \Delta_t dS_t.$$

On a :

$$dS_t = rS_t dt + \sigma S_t dW_t,$$

et

$$dV_t = (V_t + rS_t V_S + \frac{1}{2}\sigma^2 S_t^2 V_{SS}) dt + \sigma S_t V_S dW_t.$$

Donc :

$$\begin{aligned} d\Pi_t &= \left[V_t + rS_t V_S + \frac{1}{2}\sigma^2 S_t^2 V_{SS} \right] dt + \sigma S_t V_S dW_t - V_S(rS_t dt + \sigma S_t dW_t) \\ &= \left[V_t + rS_t V_S + \frac{1}{2}\sigma^2 S_t^2 V_{SS} - rS_t V_S \right] dt \\ &= \left[V_t + \frac{1}{2}\sigma^2 S_t^2 V_{SS} \right] dt. \end{aligned}$$

Ainsi, le portefeuille Π_t est *sûr* (plus de terme stochastique). Par absence d'arbitrage, un portefeuille sans risque doit croître au taux r :

$$d\Pi_t = r\Pi_t dt = r(V(t, S_t) - V_S(t, S_t)S_t) dt.$$

En identifiant les coefficients de dt :

$$V_t + \frac{1}{2}\sigma^2 S_t^2 V_{SS} = r(V - S_t V_S).$$

Autrement dit :

$$V_t + \frac{1}{2}\sigma^2 S^2 V_{SS} + rS V_S - rV = 0.$$

C'est la **PDE de Black–Scholes** pour tout (t, S) dans $[0, T) \times (0, +\infty)$, avec condition terminale :

$$V(T, S) = \Phi(S).$$

Cette PDE, couplée à la condition de terminale et aux conditions de croissance appropriées, caractérise de façon unique le prix d'option européen dans le cadre Black–Scholes.

1.2.5 Application : résolution explicite de la PDE de Black–Scholes

On considère la PDE de Black–Scholes pour le prix $V(t, S)$ d'un call européen de strike K et maturité T :

$$V_t + \frac{1}{2}\sigma^2 S^2 V_{SS} + rS V_S - rV = 0, \quad 0 \leq t < T, \quad S > 0,$$

avec condition terminale :

$$V(T, S) = (S - K)^+.$$

L'objectif est de retrouver la formule fermée de Black–Scholes à partir de cette PDE.

Changement de variables. On introduit les variables :

$$\tau := T - t \quad (\text{temps à maturité}), \quad x := \ln S.$$

On note $u(\tau, x) := V(t, S) = V(T - \tau, e^x)$. On calcule les dérivées :

$$V_t = -u_\tau, \quad V_S = \frac{1}{S}u_x, \quad V_{SS} = \frac{1}{S^2}(u_{xx} - u_x).$$

En substituant dans la PDE de Black–Scholes :

$$-u_\tau + \frac{1}{2}\sigma^2 S^2 \frac{1}{S^2}(u_{xx} - u_x) + rS \frac{1}{S}u_x - ru = 0.$$

Donc :

$$-u_\tau + \frac{1}{2}\sigma^2(u_{xx} - u_x) + ru_x - ru = 0,$$

i.e.

$$u_\tau = \frac{1}{2}\sigma^2 u_{xx} + \left(r - \frac{1}{2}\sigma^2\right) u_x - ru.$$

Élimination du terme en u_x et en u . On pose

$$u(\tau, x) = e^{\alpha x + \beta \tau} w(\tau, x),$$

et on choisit α, β pour transformer l'équation en *équation de la chaleur* pour w .

On calcule :

$$u_x = e^{\alpha x + \beta \tau} (\alpha w + w_x), \quad u_{xx} = e^{\alpha x + \beta \tau} (\alpha^2 w + 2\alpha w_x + w_{xx}),$$

$$u_\tau = e^{\alpha x + \beta \tau} (\beta w + w_\tau).$$

En substituant dans l'équation pour u :

$$\beta w + w_\tau = \frac{1}{2}\sigma^2 (\alpha^2 w + 2\alpha w_x + w_{xx}) + \left(r - \frac{1}{2}\sigma^2\right) (\alpha w + w_x) - rw.$$

On regroupe les termes en w , w_x , w_{xx} :

$$w_\tau = \frac{1}{2}\sigma^2 w_{xx} + \left(\sigma^2 \alpha + r - \frac{1}{2}\sigma^2\right) w_x + \left(\frac{1}{2}\sigma^2 \alpha^2 + (r - \frac{1}{2}\sigma^2)\alpha - r - \beta\right) w.$$

Pour obtenir une équation de la chaleur pure :

$$w_\tau = \frac{1}{2}\sigma^2 w_{xx},$$

il faut que le coefficient de w_x soit nul et que celui de w soit nul, d'où :

$$\sigma^2 \alpha + r - \frac{1}{2}\sigma^2 = 0, \quad \frac{1}{2}\sigma^2 \alpha^2 + (r - \frac{1}{2}\sigma^2)\alpha - r - \beta = 0.$$

On choisit :

$$\alpha = \frac{1}{2} - \frac{r}{\sigma^2},$$

puis

$$\beta = -\frac{1}{2}\sigma^2 \alpha^2 - (r - \frac{1}{2}\sigma^2)\alpha + r.$$

Avec ce choix, w satisfait :

$$w_\tau = \frac{1}{2}\sigma^2 w_{xx},$$

c'est-à-dire l'équation de la chaleur classique.

Condition initiale. La condition terminale $V(T, S) = (S - K)^+$ se traduit en condition initiale pour w :

$$u(0, x) = V(T, e^x) = (e^x - K)^+,$$

$$w(0, x) = e^{-\alpha x} u(0, x) = e^{-\alpha x} (e^x - K)^+.$$

L'équation de la chaleur se résout par convolution avec le noyau gaussien. On obtient au final, après transformation inverse, la formule de Black-Scholes :

$$C_0 = S_0 N(d_1) - K e^{-rT} N(d_2),$$

avec

$$d_{1,2} = \frac{\ln(S_0/K) + (r \pm \frac{1}{2}\sigma^2)T}{\sigma\sqrt{T}}.$$

1.2.6 Modèle de Heston et pricing semi-analytique

On considère désormais le modèle de Heston, dans lequel le sous-jacent S_t et la variance instantanée v_t suivent la dynamique (sous la mesure risque-neutre $\mathbb{Q}$) :

$$\begin{cases} dS_t = rS_t dt + \sqrt{v_t} S_t dW_t^{(1)}, \\ dv_t = \kappa(\theta - v_t) dt + \xi\sqrt{v_t} dW_t^{(2)}, \end{cases} \quad dW_t^{(1)} dW_t^{(2)} = \rho dt.$$

Où :

- $\kappa > 0$: vitesse de retour vers la moyenne,
- $\theta > 0$: variance de long terme,
- $\xi > 0$: vol-of-vol,
- $\rho \in [-1, 1]$: corrélation entre prix et variance.

Objectif. Pour un call européen de strike K et maturité T , on cherche :

$$C_0 = e^{-rT} \mathbb{E}^{\mathbb{Q}}[(S_T - K)^+].$$

Dans le modèle de Heston, le prix admet une formule semi-fermée en termes de transformée de Fourier, grâce au caractère affine du modèle.

Changement de variable. On introduit le log-prix :

$$X_t = \ln S_t.$$

En appliquant le lemme d'Itô à X_t (comme dans la section précédente), on obtient :

$$dX_t = \left(r - \frac{1}{2}v_t\right) dt + \sqrt{v_t} dW_t^{(1)}.$$

Le couple (X_t, v_t) forme un processus affine de dimension 2.

Fonction caractéristique. On considère la fonction caractéristique du log-prix sous $\mathbb{Q}$:

$$\phi(u; t) := \mathbb{E}^{\mathbb{Q}}[e^{iuX_t} | X_0, v_0].$$

Le caractère affine du modèle implique que la fonction caractéristique s'écrit sous la forme :

$$\phi(u; t) = \exp\left(C(u, t) + D(u, t)v_0 + iuX_0\right),$$

où $C(u, t)$ et $D(u, t)$ satisfont des équations différentielles ordinaires de type Riccati.

Plus précisément, on montre que :

$$\begin{cases} \frac{\partial D}{\partial t}(u, t) = \frac{1}{2}\xi^2 D(u, t)^2 + (\rho\xi iu - \kappa)D(u, t) - \frac{1}{2}(u^2 + iu), \\ \frac{\partial C}{\partial t}(u, t) = \kappa\theta D(u, t) + iur, \end{cases}$$

avec conditions initiales $C(u, 0) = 0$, $D(u, 0) = 0$.

La résolution explicite de ces EDO (voir annexe consacrée à Heston) donne des expressions fermées pour C et D , d'où une expression fermée de $\phi(u; T)$.

Formule de pricing (intégrale de Fourier). Le prix du call peut alors s'écrire comme :

$$C_0 = S_0 P_1 - K e^{-rT} P_2,$$

où

$$P_j = \frac{1}{2} + \frac{1}{\pi} \int_0^{+\infty} \Re \left(\frac{e^{-iu \ln K} \phi_j(u)}{iu} \right) du, \quad j = 1, 2,$$

et $\phi_j(u)$ sont des variantes de la fonction caractéristique, obtenues en choisissant des arguments complexes différents (voir la dérivation classique de Heston).

Remarque. La dérivation complète des expressions fermées de $C(u, t)$, $D(u, t)$ et des intégrales de pricing est fournie en annexe (voir les fichiers `Heston implé.tex` et `Heston feuille.tex`). Elle repose sur la résolution explicite des EDO de Riccati et sur l'utilisation de la transformée de Fourier inversée.

1.2.7 Surface de volatilité implicite et calibration de modèles

La volatilité implicite est définie comme la valeur de σ qui, insérée dans la formule de Black-Scholes, reproduit le prix de marché d'un call européen :

$$C^{BS}(S_0, K, r, \sigma, T) = C^{\text{mkt}}(K, T).$$

En inversant cette relation pour chaque strike K et chaque maturité T , on obtient la *surface de volatilité implicite* :

$$(K, T) \longmapsto \sigma_{\text{impl}}(K, T).$$

Contraintes d'arbitrage sur la surface. Pour qu'une surface de volatilité soit compatible avec l'absence d'arbitrage statique, certaines conditions doivent être satisfaites.

— **Monotonie en maturité (pas d'arbitrage de calendrier) :**

$$T_2 > T_1 \quad \Rightarrow \quad C(K, T_2) \geq C(K, T_1).$$

— **Convexité en strike (pas d'arbitrage butterfly) :**

$$\frac{\partial^2 C}{\partial K^2}(K, T) \geq 0.$$

Cette condition assure l'existence d'une densité risque-neutre positive :

$$\frac{\partial^2 C}{\partial K^2}(K, T) = e^{-rT} f_{ST}^{\mathbb{Q}}(K).$$

Ces contraintes doivent être vérifiées par toute surface interpolée/paramétrée avant calibration.

Calibration de modèles sur la surface de volatilité. Un modèle paramétré θ (par exemple Heston, SABR, rough volatility, etc.) génère une surface implicite de volatilité :

$$\sigma_{\text{mod}}(K, T; \theta).$$

La calibration consiste à choisir θ pour que cette surface reproduise au mieux la surface observée sur le marché. Le problème d'optimisation s'écrit classiquement :

$$\theta = \arg \min_{\theta} \sum_{(K, T) \in \mathcal{G}} w_{K, T} \left(\sigma_{\text{mod}}(K, T; \theta) - \sigma_{\text{impl}}^{\text{mkt}}(K, T) \right)^2,$$

où :

- $\mathcal{G}$ est la grille de strikes et de maturités cotés,
- $w_{K, T}$ sont des poids reflétant volumes, liquidité ou importance stratégique.

Calibration de modèles stochastiques (exemple : Heston). Dans le modèle de Heston, les paramètres

$$\theta = (\kappa, \theta, \xi, \rho, v_0)$$

sont ajustés en évaluant les prix d'options via la formule semi-fermée basée sur la fonction caractéristique. Pour chaque (K, T) , on en déduit

$$\sigma_{\text{mod}}(K, T; \theta) \quad \text{telle que} \quad C^{BS}(S_0, K, r, \sigma_{\text{mod}}, T) = C^{\text{Heston}}(S_0, K, r, \theta, T).$$

La calibration est un problème non convexe : on utilise généralement des méthodes de type multi-start, recuit simulé, CMA-ES, ou une descente locale après une initialisation robuste.

Calibration rough volatility / rBergomi. Dans les modèles de volatilité rugueuse, la variance suit une dynamique fractionnaire. Les paramètres typiques sont $(H, \eta, \xi_0(t))$, avec $H < 1/2$. La valorisation s'effectue via Monte Carlo rapide (hybrid schemes), puis une minimisation analogue au cas Heston :

$$\theta = \arg \min_{\theta} \sum_{(K, T) \in \mathcal{G}} \left(\sigma_{\text{mod}}(K, T; \theta) - \sigma_{\text{impl}}^{\text{mkt}}(K, T) \right)^2.$$

Synthèse.

- La surface de volatilité implicite est la représentation empirique de la distribution future du sous-jacent perçue par le marché.
- Les contraintes $\partial_K^2 C \geq 0$ et $C(K, T_2) \geq C(K, T_1)$ doivent être respectées pour éviter l'arbitrage statique.
- La calibration consiste à résoudre un problème d'optimisation sur les paramètres du modèle afin de reproduire au mieux la surface de marché.

- Les modèles stochastiques (Heston, rough volatility) sont calibrés via des méthodes globales puis locales, en exploitant leur fonction caractéristique ou des schémas Monte Carlo rapides.

1.2.8 Modèles avancés : SABR et Équations de Volterra

Dans le cadre de la modélisation des smiles de volatilité, deux familles de modèles occupent une place particulière : les modèles SABR et les modèles à noyaux de Volterra. Ils fournissent des représentations plus flexibles des dynamiques de volatilité observées sur les marchés.

Modèle SABR. Le modèle SABR (Stochastic Alpha Beta Rho), introduit par Hagan et al., est largement utilisé en taux d'intérêt pour reproduire les smiles de volatilité des swaptions. Sous la mesure risque-neutre, le forward F_t évolue selon :

$$\begin{cases} dF_t = \alpha_t F_t^\beta dW_t^{(1)}, \\ d\alpha_t = \nu \alpha_t dW_t^{(2)}, \\ dW_t^{(1)} dW_t^{(2)} = \rho dt. \end{cases}$$

Les paramètres ont les interprétations suivantes :

- $\beta \in [0, 1]$: contrôle la forme du smile (lognormal, CEV, normal),
- $\nu > 0$: vol-of-vol, responsable de la convexité du smile,
- ρ : corrélation, pilote le skew,
- α_t : volatilité instantanée du forward.

Une approximation asymptotique (formule de Hagan) fournit une expression fermée de la volatilité implicite :

$$\sigma_{\text{SABR}}^{\text{impl}}(K) = \frac{\alpha_0}{(F_0 K)^{\frac{1-\beta}{2}}} [1 + \text{Corrections}_1(\nu, \rho, \beta, K)],$$

ce qui permet une calibration directe du smile. Cette formule est obtenue par expansion asymptotique en ν et les dérivations complètes sont fournies en **ANNEXE** (voir fichiers associés au modèle SABR).

Modèles de Volterra et volatilité rugueuse. Les modèles Volterra-génériques considèrent des dynamiques à mémoire longue :

$$dX_t = \left(\int_0^t K(t-s) g(X_s) ds \right) dt + \left(\int_0^t K(t-s) h(X_s) ds \right) dW_t,$$

où K est un noyau de Volterra causal. Le choix du noyau détermine la régularité et la structure de mémoire du modèle.

Un cas fondamental est la **volatilité rugueuse (rough volatility)**, fondée sur un *fractional Brownian motion* (fBM) de paramètre de Hurst $H < 1/2$:

$$B_t^H = \frac{1}{\Gamma(H + \frac{1}{2})} \int_0^t (t-s)^{H-\frac{1}{2}} dW_s.$$

Dans le modèle **rBergomi**, la variance suit :

$$v_t = \xi_0(t) \exp\left(\eta B_t^H - \frac{1}{2} \eta^2 t^{2H}\right),$$

où η est la vol-of-vol rugueuse et H régit la régularité du processus.

Les modèles rough permettent de reproduire fidèlement :

- le skew court terme des marchés equity,
- la persistance et la mémoire longue de la variance,
- les déformations fines de la surface de vol.

Les dérivations complètes : représentation de Mandelbrot–Van Ness, construction Davies–Harte, kernels de Volterra, et liens avec les modèles rough sont présentées en **ANNEXE** (fichiers `fBM feuille.tex` et `toRBBrrregomi.tex`).

1.3 1.3. Hedging et Greeks

1.3.1 1.3.1. Greeks

Les Greeks quantifient les sensibilités du prix d'un dérivé aux différents paramètres de marché. Pour une option de prix $V(t, S)$:

Delta.

$$\Delta = \frac{\partial V}{\partial S}.$$

Sensibilité directionnelle à une variation du sous-jacent. Pour un call : $0 < \Delta < 1$; pour un put : $-1 < \Delta < 0$.

Gamma.

$$\Gamma = \frac{\partial^2 V}{\partial S^2}.$$

Mesure la convexité du prix. Un portefeuille long gamma bénéficie des variations du sous-jacent.

Vega.

$$\text{Vega} = \frac{\partial V}{\partial \sigma}.$$

Sensibilité à la volatilité implicite. Maximum autour de l'ATM.

Theta.

$$\Theta = \frac{\partial V}{\partial t}.$$

Sensibilité à l'écoulement du temps. Les options vanilles longues sont généralement $\Theta < 0$.

Rho.

$$\rho = \frac{\partial V}{\partial r}.$$

Sensibilité au taux sans risque, importante pour FX / taux.

1.3.2 1.3.2. Hedging

Delta-hedging. On construit un portefeuille :

$$\Pi_t = V(t, S_t) - \Delta_t S_t.$$

En choisissant $\Delta_t = V_S(t, S_t)$, le terme aléatoire dW_t disparaît de la dynamique de Π_t . Cela conduit au portefeuille localement sans risque utilisé dans la dérivation de Black–Scholes.

Gamma–Vega hedging. Une seule option ne permet pas de neutraliser simultanément Γ et Vega. On combine deux options $V^{(1)}$ et $V^{(2)}$ via :

$$\begin{cases} x\Gamma^{(1)} + y\Gamma^{(2)} = 0, \\ x\text{Vega}^{(1)} + y\text{Vega}^{(2)} = 0, \end{cases}$$

pour construire un portefeuille insensible aux variations de volatilité et de convexité.

1.3.3 1.3.3. Dérivation du modèle de Black–Scholes par delta–hedging

On part de la dynamique du sous-jacent :

$$dS_t = \mu S_t dt + \sigma S_t dW_t.$$

Le prix $V(t, S_t)$ d’une option européenne vérifie (par développement stochastique) :

$$dV_t = \left(V_t + \mu S_t V_S + \frac{1}{2} \sigma^2 S_t^2 V_{SS} \right) dt + \sigma S_t V_S dW_t.$$

Portefeuille de couverture. On considère :

$$\Pi_t = V(t, S_t) - \Delta_t S_t.$$

Sa variation :

$$d\Pi_t = dV_t - \Delta_t dS_t.$$

Après substitution :

$$\begin{aligned} d\Pi_t &= \left(V_t + \mu S_t V_S + \frac{1}{2} \sigma^2 S_t^2 V_{SS} \right) dt - \Delta_t \mu S_t dt \\ &\quad + \sigma S_t (V_S - \Delta_t) dW_t. \end{aligned}$$

Élimination du risque. On impose que le terme en dW_t disparaisse :

$$V_S - \Delta_t = 0 \implies \Delta_t = V_S.$$

Le portefeuille devient alors localement sans risque :

$$d\Pi_t = \left(V_t + \frac{1}{2} \sigma^2 S_t^2 V_{SS} \right) dt.$$

Absence d’arbitrage : taux sans risque. Un portefeuille sans risque doit croître au taux r :

$$d\Pi_t = r \Pi_t dt = r(V - SV_S) dt.$$

On obtient donc :

$$V_t + \frac{1}{2} \sigma^2 S^2 V_{SS} = r(V - SV_S).$$

PDE de Black–Scholes. En réarrangeant :

$$V_t + \frac{1}{2} \sigma^2 S^2 V_{SS} + rSV_S - rV = 0.$$

Avec condition terminale :

$$V(T, S) = (S - K)^+,$$

on retrouve la formule fermée de Black–Scholes :

$$C_0 = S_0 N(d_1) - K e^{-rT} N(d_2),$$

avec

$$d_{1,2} = \frac{\ln(S_0/K) + (r \pm \frac{1}{2}\sigma^2)T}{\sigma\sqrt{T}}.$$

Cette dérivation illustre que la formule de Black–Scholes provient directement du principe fondamental : *un portefeuille delta-hedgé ne doit pas permettre d'arbitrage.*

1.4 1.4. Taux & courbes de taux

1.4.1 1.4.1. Taux zéro-coupon et courbe des taux

Le prix d'un zéro-coupon de maturité T est noté $P(0, T)$: c'est la valeur aujourd'hui d'un instrument qui versera exactement 1 unité à la date T .

Le taux zéro-coupon (capitalisation continue) est défini par :

$$P(0, T) = e^{-R(0, T)T}, \quad R(0, T) := -\frac{1}{T} \ln P(0, T).$$

La fonction :

$$T \mapsto R(0, T)$$

est appelée *courbe des taux spots*.

1.4.2 1.4.2. Facteurs d'actualisation (Discount Factors)

Le facteur d'actualisation associé à la date T est :

$$D(0, T) = P(0, T) = e^{-R(0, T)T}.$$

Pour un paiement certain C reçu à la date T , la valeur actuelle est :

$$VA = C D(0, T).$$

Ces facteurs constituent la base du calcul de la valeur de tous les flux futurs (obligations, swaps, cash-flows divers).

1.4.3 1.4.3. Taux forward instantané

Le *taux forward instantané* $f(0, T)$ est le taux d'intérêt implicite pour un emprunt infinitésimal entre les dates T et $T + dT$, déduit à partir du prix des zéro-coupons.

Il est défini par :

$$f(0, T) := -\frac{\partial}{\partial T} \ln P(0, T).$$

On en déduit :

$$P(0, T) = \exp\left(-\int_0^T f(0, u) du\right).$$

La quantité $f(0, T)$ peut être vue comme la *densité instantanée* du taux d'actualisation. Elle joue un rôle central dans les modèles de taux de type Heath–Jarrow–Morton (HJM), où la dynamique de $f(t, T)$ détermine l'ensemble de la structure par terme.

Dans la pratique, le taux forward instantané est approché en différenciant numériquement les discount factors bootstrappés.

1.4.4 1.4.4. Construction de la courbe (bootstrapping)

La courbe des taux zéro-coupon n'est pas directement observable sur le marché. Les marchés cotent des instruments liquides à différentes maturités (dépôts interbancaires, FRAs, futures, swaps IRS). Le *bootstrapping* consiste à reconstruire de manière cohérente les facteurs d'actualisation $P(0, T)$ à partir de ces instruments.

1. Instruments courts (dépôts). Pour les dépôts de maturité T (typiquement ≤ 1 an), on connaît le taux simple $L(0, T)$. On en déduit directement :

$$P(0, T) = \frac{1}{1 + L(0, T) T}.$$

2. FRAs et futures. Les contrats FRA (Forward Rate Agreement) donnent les taux forward implicites sur une période future $[T_1, T_2]$. Leur prix impose la relation :

$$1 = P(0, T_1) (1 + F(0; T_1, T_2)(T_2 - T_1)) P(0, T_2)^{-1}.$$

Ainsi :

$$P(0, T_2) = \frac{P(0, T_1)}{1 + F(0; T_1, T_2)(T_2 - T_1)}.$$

Les futures sur taux court (Eurodollar, SOFR futures, Euribor futures) permettent d'extraire des taux forward similaires via des conventions d'ajustement.

3. Swaps IRS (maturités longues). Pour un swap de maturité T_n et flux semestriels, on observe le taux swap S_n tel que le swap ait une valeur initiale nulle.

La jambe fixe vaut :

$$\text{Fixe} = S_n \sum_{k=1}^n \alpha_k P(0, T_k),$$

où α_k est la fraction de jour (Act/360, 30/360, etc.).

La jambe flottante vaut :

$$\text{Flottante} = 1 - P(0, T_n).$$

Comme $\text{Fixe} = \text{Flottante}$, on obtient :

$$1 - P(0, T_n) = S_n \sum_{k=1}^n \alpha_k P(0, T_k).$$

Les facteurs $P(0, T_k)$ pour $k < n$ sont déjà connus par bootstrapping (récursivité), ce qui permet d'obtenir $P(0, T_n)$.

4. Interpolation. Une fois les $P(0, T_k)$ obtenus sur un ensemble discret de maturités, on construit une courbe continue via une interpolation :

- sur les taux forwards instantanés $f(0, T)$,
- ou sur les discount factors,
- en utilisant des splines monotones ou Hermite préservant la convexité,
- en veillant à éviter les violations d'arbitrage (monotonie des discount factors et convexité des prix d'option).

5. Courbe finale. La courbe complète des facteurs d'actualisation est donnée par :

$$P(0, T) = \exp\left(-\int_0^T f(0, u) du\right),$$

où $f(0, T)$ est obtenu par dérivation numérique ou interpolation.

Cette courbe sert de base à toute valorisation d'instruments à taux fixe, flottant ou dérivés (IRS, cap/floor, swaption, CMS, etc.).

1.5 1.5. Forwards, Futures et Swaps

Les produits linéaires (forwards, futures, swaps) sont fondamentaux en finance de taux et de devises. Leur valorisation repose exclusivement sur la courbe des taux d'actualisation et sur les taux forward extraits de celle-ci.

1.5.1 1.5.1. Forwards

Un contrat forward fixe aujourd'hui un prix de transaction à une date future T . L'actif n'échange aucun flux avant la maturité.

Sous absence d'arbitrage, le prix forward $F(0, T)$ est donné par :

$$F(0, T) = S_0 \frac{1}{P(0, T)} = S_0 e^{R(0, T)T},$$

où $P(0, T)$ est le facteur d'actualisation.

Avec dividende continu (ou taux de portage q) :

$$F(0, T) = S_0 e^{(R(0, T) - q)T}.$$

1.5.2 1.5.2. Futures

Les futures sont des forwards *standardisés* négociés en bourse, avec ajustement quotidien (marche-to-market).

Dans un cadre frictionless, le prix du future vaut en général le forward :

$$F_{\text{fut}}(0, T) \approx F(0, T),$$

mais l'ajustement quotidien introduit une différence lorsque S_t est corrélé au taux court (effet convexité futures).

1.5.3 1.5.3. Interest Rate Swaps (IRS)

Un swap de taux échange :

- une *jambe fixe* : paiements $S_n \alpha_k$ aux dates T_k ,
- une *jambe flottante* : taux variables (LIBOR, Euribor, SOFR) ajustés à chaque période.

La valeur de la jambe fixe est :

$$\text{Fixe}(0) = S_n \sum_{k=1}^n \alpha_k P(0, T_k).$$

La jambe flottante vaut :

$$\text{Flottante}(0) = 1 - P(0, T_n),$$

car un taux variable réinitialisé assure la parité avec un instrument zéro-coupon.

Le taux swap S_n d'un IRS (valeur initiale nulle) est défini par :

$$\text{Fixe}(0) = \text{Flottante}(0) \implies S_n = \frac{1 - P(0, T_n)}{\sum_{k=1}^n \alpha_k P(0, T_k)}.$$

1.5.4 1.5.4. Interprétation économique

- Le **forward** verrouille un prix d'achat/vente futur.
- Le **future** ajoute la liquidité, standardisation, et marche-to-market.
- Le **swap de taux** échange flux fixes et variables, permettant de transformer exposition fixe variable.

Ces produits linéaires servent aussi de brique fondamentale pour le pricing d'instruments plus complexes (swaption, cap/floor, CMS, etc.).

1.6 1.6. Crédit

La valorisation des instruments de crédit repose sur la notion de risque de défaut et sur l'intensité (hazard rate) associée. Les Credit Default Swaps (CDS) constituent l'instrument de marché le plus standard pour extraire ces informations.

1.6.1 1.6.1. CDS : définition et structure

Un Credit Default Swap est un contrat d'assurance contre le défaut d'un emprunteur (corporate, souverain). Il échange :

- une *jambe de protection* : paiement $(1 - R)$ en cas de défaut,
- une *jambe de prime* : paiements réguliers du spread s tant que le défaut n'a pas eu lieu.

Le payoff de protection, si le défaut survient en $\tau \in (0, T]$, est :

$$\text{Protection} = (1 - R) P(0, \tau),$$

où R est le taux de recouvrement (recovery).

La jambe de prime vaut :

$$\text{Premium} = s \sum_{k=1}^n \alpha_k P(0, T_k) \mathbb{Q}(\tau > T_k),$$

avec α_k la fraction de jour.

1.6.2 1.6.2. Intensité de défaut (hazard rate)

On modélise le défaut par un temps d'arrivée aléatoire τ dont la loi est caractérisée par une intensité $\lambda(t)$ telle que :

$$\mathbb{Q}(\tau > t) = e^{-\int_0^t \lambda(u) du}.$$

Lorsque $\lambda(t) = \lambda$ est constante :

$$\mathbb{Q}(\tau > t) = e^{-\lambda t}.$$

La densité de défaut est alors :

$$f_\tau(t) = \lambda e^{-\lambda t}.$$

1.6.3 1.6.3. Spread de CDS

Un CDS ayant une valeur initiale nulle impose :

$$\text{Protection}(0) = \text{Premium}(0),$$

soit :

$$(1 - R) \int_0^T P(0, t) \lambda(t) e^{-\int_0^t \lambda(u) du} dt = s \sum_{k=1}^n \alpha_k P(0, T_k) e^{-\int_0^{T_k} \lambda(u) du}.$$

Dans le cas stationnaire (λ constant, taux fixe r) :

$$s = \frac{(1 - R)\lambda}{\sum_{k=1}^n \alpha_k e^{-(r+\lambda)T_k}}.$$

En pratique, les spreads de CDS observés sur le marché permettent d'en déduire l'intensité $\lambda(t)$ via une calibration similaire à celle de la courbe des taux.

1.6.4 1.6.4. Interprétations

- Le spread s augmente lorsque le risque de défaut perçu augmente.
- La probabilité de survie est

$$\mathbb{Q}(\tau > T) = e^{-\int_0^T \lambda(u) du}.$$

- Le taux de recouvrement R influence directement la jambe de protection.

Les CDS sont essentiels pour :

- la gestion du risque de crédit,
- la construction de courbes de spread,
- la valorisation de produits hybrides (equity-credit, FX-credit).

1.7 1.7. Ouverture : modèles avancés en finance quantitative

Cette section a pour objectif d'esquisser quelques directions modernes en finance quantitative, sans chercher à développer les dérivations complètes, qui sont reportées en annexe.

1.7.1 1.7.1. Rough volatility et SDE de Volterra

Les modèles de *volatilité rugueuse* constituent aujourd'hui l'un des cadres les plus avancés pour reproduire les smiles de volatilité observés sur les marchés actions. Ils reposent sur des SDE de type Volterra dont la dynamique est non markovienne :

$$dX_t = \left(\int_0^t K(t-s)g(X_s) ds \right) dt + \left(\int_0^t K(t-s)h(X_s) ds \right) dW_t,$$

où K est un noyau singulier près de 0.

Dans le cas rough (Hurst $H < 1/2$), la variance est souvent modélisée via un fractional Brownian motion :

$$v_t = \xi_0(t) \exp\left(\eta B_t^H - \frac{1}{2}\eta^2 t^{2H}\right).$$

Ces modèles permettent :

- de capturer avec une grande précision le skew de short maturity,
- de décrire une structure de corrélation temporelle cohérente,
- d'expliquer certains phénomènes de la microstructure.

La dérivation complète des SDE de Volterra, du fBM, et du modèle rBergomi est fournie en annexe.

1.7.2 1.7.2. Modèle de Heston et variants affines

Le modèle de Heston constitue un modèle de référence en volatilité stochastique. Il est affine, ce qui permet une expression fermée de la fonction caractéristique :

$$\phi(u; T) = \exp(C(u, T) + D(u, T)v_0 + iu \ln S_0).$$

Les variants (Heston à corrélation locale, Heston multifactor, hybrid Heston–Hull–White) permettent :

- une meilleure reproduction de la term-structure du skew,
- la prise en compte de facteurs de taux ou de FX,
- une calibration robuste via transformée de Fourier.

Les dérivations Riccati complètes (équations pour C et D) sont reportées en annexe.

1.7.3 1.7.3. Modèle SABR et volatilité inspirée (SVI)

Pour les marchés de taux, le modèle SABR, caractérisé par

$$dF_t = \alpha_t F_t^\beta dW_t^{(1)}, \quad d\alpha_t = \nu \alpha_t dW_t^{(2)},$$

remane l'un des standards de calibration en raison de son expression asymptotique fermée de la volatilité implicite.

En parallèle, les modèles SVI (Stochastic Volatility Inspired) fournissent une paramétrisation analytique de la surface de volatilité, contrôlant :

- le skew,
- la convexité,

- les conditions d'arbitrage.

Ces deux modèles sont des outils incontournables pour reproduire des surfaces de volatilité de marché de façon flexible et stable.

1.7.4 1.7.4. Perspectives

Les modèles modernes combinent :

- volatilité stochastique,
- volatilité rugueuse,
- noyaux de Volterra,
- dynamiques multi-actifs,
- facteurs de taux ou de crédit.

La recherche actuelle explore des structures hybrides (Heston–Volterra, rough Heston, SABR–Volterra) et des méthodes numériques accélérées (FFT, hybrid schemes, neural SDE).

Ces différentes directions permettent de construire des modèles capables de capturer l'ensemble des effets observés sur le marché : skew dynamique, correlation smiles, effets de microstructure et mémoire longue.

2 2. Machine Learning

2.1 2.1. Supervised Learning

Le *supervised learning* consiste à apprendre une fonction

$$f_{\theta} : \mathcal{X} \rightarrow \mathcal{Y}$$

à partir d'un ensemble d'observations annotées $\{(x_i, y_i)\}_{i=1}^n$. L'objectif est de déterminer les paramètres θ minimisant une fonction de perte :

$$\theta = \arg \min_{\theta} \sum_{i=1}^n L(y_i, f_{\theta}(x_i)).$$

Cette approche regroupe la régression, la classification, les modèles linéaires, les modèles arborescents, les SVM, ainsi que les méthodes probabilistes (Gaussian Processes).

2.1.1 2.1.1. Fondamentaux

Tâches usuelles.

- **Régression** : prédiction de variables continues ($y \in \mathbb{R}$).
- **Classification** : prédiction de labels discrets ($y \in \{1, \dots, K\}$).

Séparation du dataset. Les données sont divisées en :

$$\text{train} \longrightarrow \text{validation} \longrightarrow \text{test}.$$

Cela permet d'évaluer la capacité de généralisation du modèle.

Overfitting / Underfitting.

- **Overfitting** : modèle trop complexe, apprend le bruit.
- **Underfitting** : modèle trop simple, structure insuffisante.

Biais-variance. Le risque prédit se décompose en :

$$\text{Erreur} = \text{Biais}^2 + \text{Variance} + \text{Bruit}.$$

L'objectif est de trouver un compromis optimal entre biais et variance.

Fonctions de perte.

- Régression :

$$\text{MSE}, \quad \text{MAE}, \quad \text{Huber}.$$

- Classification :

$$\text{cross-entropy}, \quad \text{log-loss}.$$

Optimisation. La mise à jour des paramètres suit la descente de gradient :

$$\theta \leftarrow \theta - \eta \nabla_{\theta} L.$$

Avec variantes :

$$\text{Momentum}, \quad \text{Nesterov}, \quad \text{Adam}, \quad \text{AdamW}, \quad \text{LR Scheduling}.$$

2.1.2 2.1.2. Modèles linéaires & factoriels

Régression linéaire.

$$\hat{y} = x^{\top} w.$$

Régression logistique.

$$p(y = 1|x) = \sigma(w^{\top} x), \quad \sigma(z) = \frac{1}{1 + e^{-z}}.$$

PCA (réduction dimensionnelle). On cherche les vecteurs propres maximisant :

$$\max_v v^{\top} \Sigma v,$$

où Σ est la matrice de covariance.

SVD. Décomposition :

$$X = U \Sigma V^{\top},$$

fondamentale pour la factorisation matricielle et certains algorithmes de ML.

Gaussian Processes (GP). Modèle bayésien non-paramétrique :

$$f(x) \sim \mathcal{GP}(m(x), k(x, x')),$$

où k est un noyau (RBF, Matérn, etc.). Prédiction :

$$f(x_*)|X, y \sim \mathcal{N}(\mu_*, \sigma_*^2).$$

Bases de Bernstein. Bases polynomiales utilisées pour approximer des fonctions :

$$B_{k,n}(x) = \binom{n}{k} x^k (1-x)^{n-k}.$$

Régularisation.

- Ridge : $\|w\|_2^2$
- Lasso : $\|w\|_1$
- ElasticNet : combinaison des deux

2.1.3 Arbres & Ensembles

Arbres de décision. Un arbre partitionne l'espace des features :

$$x \mapsto \text{Région}_i \mapsto \hat{y}_i.$$

Bagging. Bootstrap + vote majoritaire :

$$f(x) = \text{Majority}(h_1(x), \dots, h_T(x)).$$

Random Forest. Bagging + sélection aléatoire de variables à chaque split.

Boosting. Construction séquentielle :

$$f_T(x) = f_{T-1}(x) + \eta h_T(x),$$

où h_T corrige les erreurs du modèle précédent.

Méthodes principales : AdaBoost, GradientBoosting, XGBoost, LightGBM, CatBoost.

Stacking. Combinaison de plusieurs modèles via un méta-modèle (logistique, réseau neural, ridge).

2.2 Unsupervised Learning

L'apprentissage non supervisé vise à identifier des structures, regrouper des observations ou réduire la dimensionnalité d'un jeu de données sans disposer de labels explicites. Ces méthodes sont essentielles pour la détection de régimes, la segmentation de marché, la compression de données et la découverte de facteurs latents.

2.2.1 2.2.1. Clustering

K-Means. Le K-Means vise à partitionner un ensemble de points $\{x_i\}_{i=1}^n \subset \mathbb{R}^d$ en K groupes en minimisant l'inertie intra-cluster :

$$\min_{C_1, \dots, C_K} \sum_{k=1}^K \sum_{x_i \in C_k} \|x_i - \mu_k\|^2,$$

où μ_k est le barycentre du cluster C_k .

L'algorithme alterne entre :

- *assignation* des points aux centres les plus proches,
- *mise à jour* des centres.

La convergence est rapide mais dépend de l'initialisation.

2.2.2 2.2.2. Anomaly / Novelty Detection

One-Class SVM. Le One-Class SVM estime la frontière d'un ensemble de données non étiquetées. On cherche une fonction f telle que la majorité des points vérifient $f(x) \geq 0$.

Formulation :

$$\min_{w, \rho, \xi_i} \frac{1}{2} \|w\|^2 + \frac{1}{\nu n} \sum_i \xi_i - \rho \quad \text{s.c.} \quad w^\top \phi(x_i) \geq \rho - \xi_i.$$

Les anomalies sont les points pour lesquels $f(x) < 0$.

2.2.3 2.2.3. Réduction dimensionnelle

PCA (Principal Component Analysis). On diagonalise la matrice de covariance :

$$\Sigma = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(x_i - \bar{x})^\top = Q \Lambda Q^\top.$$

Les vecteurs propres q_k correspondant aux plus grandes valeurs propres capturent les directions de variance maximale.

SVD (Singular Value Decomposition). Pour une matrice $X \in \mathbb{R}^{n \times d}$:

$$X = U \Sigma V^\top.$$

La SVD est la base de :

- la compression,
- la factorisation,
- la résolution de systèmes linéaires,
- les méthodes de recommandation.

t-SNE. Méthode non linéaire conservant des distances locales via une minimisation de divergence de Kullback–Leibler entre les voisinages dans l'espace initial et l'espace réduit.

2.2.4 2.2.4. Séries temporelles classiques

Stationnarité. Une série (X_t) est stationnaire si :

$$\mathbb{E}[X_t] = \mu, \quad \text{Var}(X_t) = \sigma^2, \quad \text{Cov}(X_t, X_{t+h}) = \gamma(h).$$

Les modèles ARMA supposent la stationnarité.

AR(p).

$$X_t = \sum_{i=1}^p \phi_i X_{t-i} + \varepsilon_t.$$

MA(q).

$$X_t = \sum_{i=1}^q \theta_i \varepsilon_{t-i} + \varepsilon_t.$$

ARMA(p,q).

$$X_t = \sum_{i=1}^p \phi_i X_{t-i} + \sum_{j=1}^q \theta_j \varepsilon_{t-j} + \varepsilon_t.$$

ARIMA(p,d,q). Pour gérer la non-stationnarité :

$$\Delta^d X_t \sim \text{ARMA}(p, q).$$

Les modèles ARIMA sont très utilisés pour la détection de tendances, la prévision de volatilité, ou l'analyse de séries financières en basse fréquence.

2.3 2.3. Deep Learning

Le deep learning repose sur les réseaux de neurones artificiels, capables d'approximer des fonctions complexes par composition de transformations linéaires et non linéaires. Il permet de traiter des données structurées (images, séries temporelles, texte) via des architectures spécialisées.

2.3.1 2.3.1. Bases

Perceptron. Le neurone élémentaire applique :

$$z = w^\top x + b, \quad a = \sigma(z),$$

où σ est une fonction d'activation (ReLU, sigmoid, tanh, GELU).

MLP (Multi-Layer Perceptron). Un réseau profond est une composition :

$$f(x) = \sigma_L(W_L \sigma_{L-1}(W_{L-1} \cdots \sigma_1(W_1 x))).$$

Problème du vanishing/exploding gradient. Lorsque la profondeur augmente, les gradients peuvent diverger ou s'annuler. Solutions :

- initialisation Xavier/He,
- BatchNorm / LayerNorm,

- activations adaptées (ReLU, GELU).

Normalisation et régularisation.

- **BatchNorm** : normalisation des activations au sein du batch.
- **LayerNorm** : normalisation par feature.
- **Dropout** : régularisation par mise à zéro aléatoire d'activations.

2.3.2 2.3.2. Convolutional Neural Networks (CNN)

Les CNN sont adaptés aux données spatiales (images, cartes de features).

Convolution.

$$(\text{Conv}(x))_{i,j} = \sum_{u,v} K_{u,v} x_{i+u,j+v}.$$

Les noyaux (kernels) extraient des motifs locaux (bords, textures).

Stride, padding. Le *stride* contrôle le sous-échantillonnage. Le *padding* permet de conserver la taille spatiale.

Pooling.

$$\text{max-pool}(x)_{i,j} = \max_{u,v \in \text{patch}} x_{i+u,j+v}.$$

Enfin, les couches convolutionnelles sont suivies de denses :

$$\text{Conv} \rightarrow \text{ReLU} \rightarrow \dots \rightarrow \text{Flatten} \rightarrow \text{Dense} \rightarrow \text{Softmax}.$$

2.3.3 2.3.3. RNN, LSTM, GRU

Les RNN sont adaptés aux séries temporelles.

RNN simple.

$$h_t = \sigma(W_h h_{t-1} + W_x x_t + b).$$

Limites : pas parallélisable, gradient vanishing.

LSTM. Le LSTM introduit des portes :

$$\begin{aligned} f_t &= \sigma(W_f x_t + U_f h_{t-1} + b_f), \\ i_t &= \sigma(W_i x_t + U_i h_{t-1} + b_i), \\ \tilde{c}_t &= \tanh(W_c x_t + U_c h_{t-1} + b_c), \\ c_t &= f_t \odot c_{t-1} + i_t \odot \tilde{c}_t, \\ h_t &= o_t \odot \tanh(c_t). \end{aligned}$$

GRU. Structure simplifiée :

$$\begin{aligned} z_t &= \sigma(W_z x_t + U_z h_{t-1}), \\ r_t &= \sigma(W_r x_t + U_r h_{t-1}), \\ h_t &= (1 - z_t) \odot \tilde{h}_t + z_t h_{t-1}. \end{aligned}$$

2.3.4 2.3.4. Transformers

Le Transformer repose sur le *self-attention*.

Tokenisation. Les entrées sont découpées en jetons (BPE, WordPiece).

Embeddings.

$$x_i \mapsto e_i \in \mathbb{R}^d,$$

plus un encodage positionnel :

$$p_t = (\sin(t/10000^{2k/d}), \cos(t/10000^{2k/d})).$$

Attention Q/K/V. Chaque token produit trois vecteurs :

$$Q = W_Q e, \quad K = W_K e, \quad V = W_V e.$$

On calcule :

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d}}\right) V.$$

Intuition : - Q “cherche” des informations pertinentes, - K dit quelles informations chaque token “porte”, - V apporte la valeur combinée.

Entraînement.

- GPT : *next token prediction*,
- BERT : *masked language modeling*.

2.3.5 2.3.5. Modèles génératifs

Autoencodeurs. Un AE apprend une compression :

$$z = f_\theta(x), \quad \hat{x} = g_\theta(z).$$

VAE (Variational Autoencoder).

$$z \sim \mathcal{N}(\mu(x), \Sigma(x)), \quad \mathcal{L} = \mathbb{E}[\|x - \hat{x}\|^2] + \text{KL}(q(z|x) \parallel p(z)).$$

VQ-VAE. Quantification discrète via dictionnaire de codes.

GAN.

$$\min_G \max_D \mathbb{E}[\log D(x)] + \mathbb{E}[\log(1 - D(G(z)))].$$

VQ-GAN. GAN + quantisation vectorielle (utilisé dans Stable Diffusion).

Diffusion Models.

$$x_T \sim \mathcal{N}(0, I), \quad x_{t-1} = \text{denoise}_\theta(x_t).$$

Ce sont les modèles sous-jacents à DALL · E 2, Stable Diffusion, Imagen.

2.4 2.4. Reinforcement Learning

Le Reinforcement Learning (RL) étudie l'interaction entre un agent et un environnement. À chaque étape, l'agent observe un état s_t , choisit une action a_t , reçoit une récompense r_t , et l'environnement évolue selon une dynamique inconnue. L'objectif est de maximiser la récompense cumulée.

2.4.1 2.4.1. Concepts fondamentaux

Un processus de décision est modélisé par un MDP (Markov Decision Process) :

$$(\mathcal{S}, \mathcal{A}, P, r, \gamma),$$

où

- $\mathcal{S}$: espace des états,
- $\mathcal{A}$: espace des actions,
- $P(s'|s, a)$: dynamique (transition),
- $r(s, a)$: récompense immédiate,
- $\gamma \in (0, 1)$: facteur d'escompte.

La politique $\pi(a|s)$ définit le comportement de l'agent.

2.4.2 2.4.2. Fonctions de valeur et équations de Bellman

La **valeur d'une politique** π est :

$$V^\pi(s) = \mathbb{E}_\pi \left[\sum_{t=0}^{\infty} \gamma^t r(s_t, a_t) \mid s_0 = s \right].$$

La **valeur d'état-action** :

$$Q^\pi(s, a) = \mathbb{E}_\pi \left[\sum_{t=0}^{\infty} \gamma^t r(s_t, a_t) \mid s_0 = s, a_0 = a \right].$$

Les équations de Bellman caractérisent ces valeurs :

$$V^\pi(s) = \sum_a \pi(a|s) \sum_{s'} P(s'|s, a) (r(s, a) + \gamma V^\pi(s')),$$

$$Q^\pi(s, a) = r(s, a) + \gamma \sum_{s'} P(s'|s, a) \sum_{a'} \pi(a'|s') Q^\pi(s', a').$$

La **valeur optimale** satisfait :

$$V(s) = \max_a Q(s, a).$$

2.4.3 2.4.3. Monte Carlo (MC)

Le MC estime la valeur par *retours échantillonnés* :

$$G_t = \sum_{k=0}^{\infty} \gamma^k r_{t+k}.$$

Mise à jour :

$$V(s) \leftarrow V(s) + \alpha(G - V(s)).$$

Méthodes :

- First-Visit MC,
- Every-Visit MC,
- MC à α constant.

2.4.4 2.4.4. Temporal Difference (TD)

Les méthodes TD mettent à jour la valeur à partir d'une seule transition :

$$V(s_t) \leftarrow V(s_t) + \alpha(r_t + \gamma V(s_{t+1}) - V(s_t)).$$

TD(0).

$$\delta_t = r_t + \gamma V(s_{t+1}) - V(s_t).$$

TD(n)-step.

$$G_t^{(n)} = \sum_{k=0}^{n-1} \gamma^k r_{t+k} + \gamma^n V(s_{t+n}).$$

TD(λ). Combinaison pondérée des retours n -step.

2.4.5 2.4.5. SARSA, Expected SARSA, Q-Learning

SARSA (on-policy).

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha(r_t + \gamma Q(s_{t+1}, a_{t+1}) - Q(s_t, a_t)).$$

Expected SARSA.

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha \left(r_t + \gamma \sum_{a'} \pi(a' | s_{t+1}) Q(s_{t+1}, a') - Q(s_t, a_t) \right).$$

Q-Learning (off-policy).

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha(r_t + \gamma \max_{a'} Q(s_{t+1}, a') - Q(s_t, a_t)).$$

2.4.6 2.4.6. On-policy vs Off-policy

- **On-policy** : on apprend la valeur de la politique suivie (SARSA).
- **Off-policy** : on apprend la politique optimale tout en explorant différemment (Q-Learning).

Importance sampling permet de corriger les biais off-policy.

2.4.7 2.4.7. Function Approximation

Lorsque l'espace des états est trop grand, on approxime :

$$V(s; \theta), \quad Q(s, a; \theta).$$

Mise à jour TD :

$$\theta \leftarrow \theta + \alpha \delta_t \nabla_{\theta} V(s_t; \theta), \quad \delta_t = r_t + \gamma V(s_{t+1}) - V(s_t).$$

Bases :

- features manuelles (polynômes, splines, bases de Bernstein),
- réseaux neuronaux (Deep RL).

2.4.8 2.4.8. Policy Gradient Methods

Les méthodes de gradient de politique optimisent $\pi_{\theta}(a|s)$ directement.

Objectif.

$$J(\theta) = \mathbb{E}_{\pi_{\theta}}[G_t].$$

REINFORCE.

$$\theta \leftarrow \theta + \alpha G_t \nabla_{\theta} \log \pi_{\theta}(a_t|s_t).$$

Actor–Critic.

$$\theta_{\text{policy}} \leftarrow \theta_{\text{policy}} + \alpha \delta_t \nabla_{\theta} \log \pi_{\theta}(a_t|s_t),$$

$$\theta_{\text{value}} \leftarrow \theta_{\text{value}} + \alpha \delta_t \nabla_{\theta} V(s_t; \theta_{\text{value}}).$$

PPO (Proximal Policy Optimization). Méthode stable basée sur une pénalisation du ratio de probabilité :

$$L^{\text{PPO}}(\theta) = \mathbb{E} \left[\min(r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t) \right].$$

2.4.9 2.4.9. Algorithmes évolutionnaires

Les algorithmes évolutionnaires optimisent une population de politiques :

$$\theta^{(i)} \leftarrow \text{Mutation/Croisement/Selection}(\{\theta^{(j)}\}).$$

Ils sont utilisés en Deep RL pour explorer de grands espaces de politiques et éviter les minima locaux.

Synthèse. Le RL combine :

- estimation de valeurs (MC, TD),
- apprentissage d'actions optimales (SARSA, Q-Learning),
- optimisation directe de politiques (Policy Gradient, Actor–Critic, PPO),
- approximation de fonctions (Deep RL),

- méthodes globales (algorithmes évolutionnaires).

Ces techniques sont essentielles pour les stratégies séquentielles, l'optimisation de portefeuilles, la gestion dynamique du risque, et les modèles décisionnels non paramétriques.

3 3. Projets personnels

3.1 3.1. Sandbox de trading d'options

Prototype de plateforme permettant de tester des stratégies sur options vanilles et exotiques :

- génération de payoffs paramétrables (vanilles, barrières, baskets) ;
- pricing via formules fermées (Black–Scholes, Heston) et Monte Carlo ;
- suivi des Greeks en temps réel pour construire des portefeuilles delta/gamma neutres ;
- backtests sur données historiques avec gestion du PnL et du risque.

3.2 3.2. Pipeline Numerai

Une complète de modélisation pour la compétition Numerai :

- ingestion et nettoyage des features, normalisation par ère ;
- entraînement de modèles ensemblistes (LightGBM/XGBoost) et régularisation ;
- validation croisée temporelle, suivi du sharpe et du corr sur live ;
- packaging des prédictions et automatisation de la soumission.

3.3 3.3. Reverse Heston Model

inverse du modèle de Heston :

- calibration sur surfaces de vol implicite pour extraire $(\kappa, \theta, \xi, \rho, v_0)$;
- simulation forward des trajectoires (S_t, v_t) et stress-tests ;
- comparaison aux variantes rough / Volterra pour capturer le skew court terme ;
- implémentation numérique (FFT Carr–Madan) et sensibilités (Greeks).

4 4. Conclusion et ouverture

Ce document a parcouru les fondements de la finance quantitative moderne : pricing d'options, dynamique stochastique, modélisation de la volatilité, construction de courbes, instruments de taux, crédit, ainsi que les méthodes fondamentales de Machine Learning (supervisé, non supervisé, deep learning, reinforcement learning).

L'ensemble constitue une base conceptuelle solide pour aborder des modèles plus avancés ou des applications orientées recherche, en particulier en finance de marché.

4.1 4.1. Synthèse

Les points suivants peuvent être retenus :

- Les produits dérivés (vanilles, barrières, exotiques) s'analysent via les EDS, la mesure risque-neutre et les méthodes numériques (Monte Carlo, PDE, Fourier).

- Les Greeks permettent une gestion fine des expositions directionnelles, de convexité et de volatilité.
- Les modèles de volatilité (Black–Scholes, Heston, SABR, rough volatility) traduisent des régimes de marché variés et sont calibrés sur la surface de volatilité implicite.
- Les courbes de taux et l’analyse des spreads (...IRS, CDS...) reposent sur des principes d’absence d’arbitrage (bootstrapping, hazard rate).
- Le Machine Learning fournit un cadre robuste pour la prévision, l’extraction de facteurs latents, la réduction dimensionnelle, l’identification de régimes, et l’apprentissage de politiques optimales.

4.2 4.2. Ouverture

Plusieurs directions naturelles s’ouvrent à la suite de ce travail :

- **Volatilité rugueuse et SDE de Volterra** : extension non markovienne des modèles de variance, offrant une calibration très fidèle aux smiles courts et une meilleure modélisation de la mémoire longue.
- **Modèles multi-facteurs et modélisation affine avancée** : dynamiques jointes des variances, taux et spreads, incluant corrélations stochastiques.
- **Méthodes numériques haute performance** : Monte Carlo GPU, solveurs FFT optimisés, simulateurs rough vol, schémas hybrides et méthodes quantiques naissantes.
- **Apprentissage profond pour le pricing** : réseaux neuraux pour l’approximation de surfaces de vol, solveurs de PDE par réseaux PINN, autoencoders génératifs pour l’apprentissage de distributions de prix.
- **Reinforcement Learning pour la gestion dynamique du risque** : agents apprenant des stratégies de hedging optimales (delta-gamma-vega), optimisation de portefeuilles, ou exécution optimale.
- **Intégration des modèles rough / Heston / SABR dans la sandbox** : expérimentation pratique, calibration dataset réel, analyses out-of-sample.

4.3 4.3. Conclusion générale

Cette synthèse met en évidence l’interconnexion entre :

- maths appliquées (EDS, variation quadratique, PDE),
- finance quantitative (pricing, surfaces de volatilité, calibrations),
- machine learning (apprentissage supervisé, non supervisé, deep learning),
- reinforcement learning (prise de décision séquentielle).

L’objectif est de fournir une vision cohérente et moderne des outils quantitatifs utilisables en finance de marché. Les annexes rassemblent les dérivations complètes (Heston, SABR, Volterra, fBM) pour servir de base à des travaux plus avancés.

5 5. Bibliographie et ressources

Cette bibliographie regroupe les ouvrages, articles et ressources vidéos mobilisés dans le cadre de ce document. Elle est organisée par thématique pour faciliter les références croisées entre finance quantitative, machine learning, deep learning, reinforcement learning et mathématiques appliquées.

5.1 5.1. Finance quantitative

- **Hull, J.** *Options, Futures and Other Derivatives*. Référence classique couvrant les dérivés, les modèles de taux, les produits structurés et la gestion du risque.
- **Natenberg, S.** *Option Volatility and Pricing*. Ouvrage fondamental sur le smile, les Greeks, les stratégies de trading et l'arbitrage.
- **Bouchaud, J.-P., Potters, M.** *Theory of Financial Risk and Derivative Pricing*. Approche statistique et empirique de la volatilité, du risque et des phénomènes de queue.
- **Darbyshire, M.** *Pricing and Trading Interest Rate Derivatives*. Référence sur les dérivés de taux, IRS, caps/floors, swaptions.
- **Wooldridge, J.** *Econometrics*. Fondements en économétrie, indispensable pour les modèles statistiques appliqués à la finance.

5.2 5.2. FinTech et Data Science appliquée à la finance

- **Kaabar, M.** *Deep Learning for Finance*.
- **Hilpisch, Y.** *Reinforcement Learning for Finance*.
- **Kanungo, D.** *Probabilistic Machine Learning for Finance and Investing*.
- **Tatsat, R.** *Machine Learning & Data Science Blueprints for Finance*.
- **Hanson, G.** *Modern C++ for Finance*.
- **Hilpisch, Y.** *Python for Algorithmic Trading*.
- **Nag, B.** *Stochastic Finance with Python*.

5.3 5.3. Mathématiques et probabilités

- **Shreve, S.** *Stochastic Calculus for Finance I & II*. Références incontournables pour le calcul stochastique appliqué aux dérivés.
- **Ségonne, R.** *Quant Basics*. Introduction rigoureuse aux EDS, au pricing et aux outils quantitatifs.
- **Cohen, N.** *Practical Linear Algebra for Data Science*.
- **Nelson, R.** *Essential Math for AI*.

5.4 5.4. Machine Learning

- **Goodfellow, Bengio, Courville.** *Deep Learning*. Ouvrage fondateur pour le deep learning moderne.
- **Sutton, Barto.** *Reinforcement Learning : An Introduction*. Livre de référence sur le RL, dynamique des MDP et méthodes TD.

- **Gillard, D.** *Computer Vision*.
- **Foster, D.** *Generative Deep Learning*.
- **Tunstall, von Werra, Wolf.** *NLP with Transformers*.
- **Géron, A.** *Hands-On Machine Learning with Python*.
- **Kirill Eremenko.** *Hands-On Machine Learning with C++*.
- **Moses, Dezy.** *Data Quality Fundamentals*.
- **Auffarth, B.** *Machine Learning for Time Series*.

5.5 5.5. Vidéos de Reinforcement Learning

Chaîne YouTube *Reinforcement Learning — by the Book* :

- Bellman Equations, Dynamic Programming — Part 2
- Monte Carlo & Off-Policy Methods — Part 3
- Temporal Difference Learning — Part 4
- Function Approximation — Part 5
- Policy Gradient Methods — Part 6

5.6 5.6. Ressources vidéo : mathématiques

- *Practical Linear Algebra* — Introduction and Motivation
- Fourier Analysis — Overview
- Differential Equations and Dynamical Systems — Overview
- Probability and Statistics — Overview
- Introduction to Statistics and Data Analysis
- Laplace Transform — Generalized Fourier Transform
- Inner Products in Hilbert Space
- Properties of the Expected Value
- Bayesian MAP Estimation
- Lecture 1 (Motivation and Introduction)

5.7 5.7. Ressources vidéo : statistiques

- Maximum Likelihood (Normal Distribution)
- Why π appears in the Gaussian distribution
- Multivariate Gaussian — definition and intuition
- The Kelly Criterion
- Learning Probability Distributions
- Chi-Square Distribution
- Jensen's Inequality

- Accept-Reject Sampling
- Importance Sampling
- Softmax — intuition
- Linear Regression — 12 minutes
- Bernstein Basis
- Maximum Likelihood — explained
- Exponential Family (Part 1 & 2)
- Gaussian Processes — overview
- Bias–Variance Tradeoff
- Fisher Information
- Factor Analysis & Probabilistic PCA
- Maximum Entropy Principle

Annexe A - Modèle de Heston : dérivation complète

.1 Modèle de Heston et log-prix

Sous la mesure risque-neutre Q , le prix de l'actif S_t et sa variance instantanée v_t suivent

$$\begin{cases} dS_t = rS_t dt + \sqrt{v_t} S_t dW_t^{(1)}, \\ dv_t = \kappa(\theta - v_t) dt + \sigma \sqrt{v_t} dW_t^{(2)}, \\ dW_t^{(1)} dW_t^{(2)} = \rho dt, \end{cases} \quad (1)$$

avec $v_0 > 0$, $\kappa > 0$, $\theta > 0$, $\sigma > 0$, $|\rho| \leq 1$.

On pose le log-prix

$$X_t = \ln S_t. \quad (2)$$

Par la formule d'Itô,

$$dX_t = \left(r - \frac{v_t}{2} \right) dt + \sqrt{v_t} dW_t^{(1)}. \quad (3)$$

On considère une option call européenne de strike $K > 0$ et maturité $T > 0$, de payoff $(S_T - K)^+$. Son prix au temps 0 est

$$C(K, T) = e^{-rT} \mathbb{E}_Q[(S_T - K)^+]. \quad (4)$$

.2 Fonction caractéristique du log-prix sous Heston

On définit la fonction caractéristique du log-prix $X_T = \ln S_T$ par

$$\varphi_T(u) := \mathbb{E} \left[e^{iuX_T} \right], \quad u \in \mathbb{C}. \quad (5)$$

On veut une expression explicite de $\varphi_T(u)$.

.3 PDE de Feynman–Kac et ansatz affine

Pour $0 \leq t \leq T$, $x \in \mathbb{R}$, $v \geq 0$, on introduit

$$p(t, x, v; u) := \mathbb{E}[e^{iuX_T} \mid X_t = x, v_t = v]. \quad (6)$$

Alors $p(T, x, v; u) = e^{iux}$ et

$$\varphi_T(u) = p(0, \ln S_0, v_0; u). \quad (7)$$

Le couple (X_t, v_t) a pour générateur infinitésimal

$$\mathcal{L}f = \left(r - \frac{v}{2}\right) \partial_x f + \kappa(\theta - v) \partial_v f + \frac{1}{2}v \partial_{xx} f + \rho\sigma v \partial_{xv} f + \frac{1}{2}\sigma^2 v \partial_{vv} f. \quad (8)$$

Par Feynman–Kac, p satisfait

$$\partial_t p + \mathcal{L}p = 0, \quad p(T, x, v; u) = e^{iux}. \quad (9)$$

On cherche une solution de la forme affine en v :

$$p(t, x, v; u) = \exp(C(\tau; u) + D(\tau; u)v + iux), \quad \tau := T - t. \quad (10)$$

On impose $C(0; u) = 0$, $D(0; u) = 0$, de sorte que $p(T, x, v; u) = e^{iux}$.

On calcule

$$\begin{aligned} \partial_t p &= -C'(\tau; u)p - D'(\tau; u)vp, & \partial_x p &= iup, & \partial_{xx} p &= -u^2 p, \\ \partial_v p &= Dp, & \partial_{vv} p &= D^2 p, & \partial_{xv} p &= iuDp. \end{aligned}$$

En injectant dans la PDE, puis en factorisant par $p \neq 0$, on obtient

$$0 = -C' - D'v + \left(r - \frac{v}{2}\right)(iu) + \kappa(\theta - v)D + \frac{1}{2}v(-u^2) + \rho\sigma v(iuD) + \frac{1}{2}\sigma^2 v D^2. \quad (11)$$

On séparant les termes constants et les termes proportionnels à v , ce qui donne

$$(\text{terme constant}) : \quad -C' + iur + \kappa\theta D = 0, \quad (12)$$

$$(\text{terme en } v) : \quad -D' + \left(-\frac{i u}{2}\right) - \kappa D - \frac{u^2}{2} + \rho\sigma i u D + \frac{1}{2}\sigma^2 D^2 = 0. \quad (13)$$

On en déduit les EDO (en τ) :

$$C'(\tau; u) = \kappa\theta D(\tau; u) + iur, \quad C(0; u) = 0, \quad (14)$$

$$D'(\tau; u) = \frac{1}{2}\sigma^2 D(\tau; u)^2 + (\rho\sigma i u - \kappa)D(\tau; u) + \frac{1}{2}(u^2 + iu), \quad D(0; u) = 0. \quad (15)$$

L'équation (15) est de Riccati.

.4 Résolution de l'équation de Riccati

On note

$$a := \frac{\sigma^2}{2}, \quad \beta(u) := \rho\sigma i u - \kappa, \quad \omega(u) := \frac{1}{2}(u^2 + iu). \quad (16)$$

Alors

$$D' = aD^2 + \beta(u)D + \omega(u). \quad (17)$$

On introduit le discriminant

$$d(u) := \sqrt{\beta(u)^2 + 4a\omega(u)} = \sqrt{(\rho\sigma iu - \kappa)^2 + \sigma^2(u^2 + iu)}, \quad (18)$$

et on prend la racine avec $\Re[d(u)] > 0$.

On définit ensuite

$$g(u) := \frac{\kappa - \rho\sigma iu - d(u)}{\kappa - \rho\sigma iu + d(u)}. \quad (19)$$

La solution classique de l'équation de Riccati est alors

$$D(\tau; u) = \frac{\kappa - \rho\sigma iu - d(u)}{\sigma^2} \frac{1 - e^{-d(u)\tau}}{1 - g(u)e^{-d(u)\tau}}. \quad (20)$$

.5 Intégration pour obtenir $C(\tau; u)$

En intégrant (14), on obtient

$$C(\tau; u) = iur\tau + \kappa\theta \int_0^\tau D(s; u) ds. \quad (21)$$

L'intégrale en s se calcule explicitement. Le résultat standard (obtenu en faisant le changement $y = e^{-d(u)s}$ et en intégrant terme à terme) est

$$C(\tau; u) = iur\tau + \frac{\kappa\theta}{\sigma^2} \left[(\kappa - \rho\sigma iu - d(u))\tau - 2 \ln \left(\frac{1 - g(u)e^{-d(u)\tau}}{1 - g(u)} \right) \right]. \quad (22)$$

.6 Fonction caractéristique finale

En résumé, la fonction caractéristique du log-prix $X_T = \ln S_T$ sous le modèle de Heston est

$$\boxed{\varphi_T(u) = \mathbb{E}[e^{iuX_T}] = \exp\left(C(T; u) + D(T; u)v_0 + iu \ln S_0\right)}, \quad (23)$$

avec

$$d(u) = \sqrt{(\rho\sigma iu - \kappa)^2 + \sigma^2(u^2 + iu)}, \quad (24)$$

$$g(u) = \frac{\kappa - \rho\sigma iu - d(u)}{\kappa - \rho\sigma iu + d(u)}, \quad (25)$$

$$D(T; u) = \frac{\kappa - \rho\sigma iu - d(u)}{\sigma^2} \frac{1 - e^{-d(u)T}}{1 - g(u)e^{-d(u)T}}, \quad (26)$$

$$C(T; u) = iurT + \frac{\kappa\theta}{\sigma^2} \left[(\kappa - \rho\sigma iu - d(u))T - 2 \ln \left(\frac{1 - g(u)e^{-d(u)T}}{1 - g(u)} \right) \right]. \quad (27)$$

.7 Représentation de Fourier du prix de la call

.8 Densité du log-prix

Notons $X_T = \ln S_T$ et f_{X_T} sa densité (sous Q). Le prix de la call en fonction de $k = \ln K$ s'écrit

$$C(k) = C(K, T) = e^{-rT} \int_k^{+\infty} (e^x - e^k) f_{X_T}(x) dx, \quad k := \ln K. \quad (28)$$

.9 Damping et transformée de Fourier

On choisit un paramètre de damping $\alpha > 0$ tel que

$$\mathbb{E}[e^{(\alpha+1)X_T}] < +\infty. \quad (29)$$

On introduit la quantité

$$c_\alpha(k) := e^{\alpha k} C(k), \quad (30)$$

et sa transformée de Fourier

$$\psi_T(v) := \int_{-\infty}^{+\infty} e^{ivk} c_\alpha(k) dk = \int_{-\infty}^{+\infty} e^{(\alpha+iv)k} C(k) dk, \quad v \in \mathbb{R}. \quad (31)$$

Par un calcul direct (changement d'ordre d'intégration et intégration en k d'abord), on obtient

$$\psi_T(v) = e^{-rT} \frac{1}{(\alpha + iv)(\alpha + iv + 1)} \int_{-\infty}^{+\infty} e^{(\alpha+1+iv)x} f_{X_T}(x) dx. \quad (32)$$

Or

$$\int_{-\infty}^{+\infty} e^{(\alpha+1+iv)x} f_{X_T}(x) dx = \mathbb{E}[e^{(\alpha+1+iv)X_T}] = \varphi_T(v - i(\alpha + 1)), \quad (33)$$

puisque $e^{(\alpha+1+iv)x} = e^{i(v-i(\alpha+1))x}$.

On en déduit

$$\boxed{\psi_T(v) = e^{-rT} \frac{\varphi_T(v - i(\alpha + 1))}{(\alpha + iv)(\alpha + iv + 1)}}. \quad (34)$$

.10 Formule d'inversion

Par inversion de Fourier, on récupère

$$c_\alpha(k) = \frac{1}{2\pi} \int_{-\infty}^{+\infty} e^{-ivk} \psi_T(v) dv. \quad (35)$$

Comme $C(k)$ est réel, $c_\alpha(k)$ l'est aussi et l'intégrale se simplifie en

$$c_\alpha(k) = \frac{1}{\pi} \int_0^{+\infty} \Re(e^{-ivk} \psi_T(v)) dv. \quad (36)$$

En rappelant $C(k) = e^{-\alpha k} c_\alpha(k)$, on obtient finalement

$$\boxed{C(K, T) = C(k) = \frac{e^{-\alpha k}}{\pi} \int_0^{+\infty} \Re\left(e^{-ivk} e^{-rT} \frac{\varphi_T(v - i(\alpha + 1))}{(\alpha + iv)(\alpha + iv + 1)}\right) dv, \quad k = \ln K.} \quad (37)$$

.11 Schéma numérique (idée générale)

Pour calculer $C(K, T)$ numériquement :

1. Choisir $\alpha > 0$ tel que $\mathbb{E}[e^{(\alpha+1)X_T}] < \infty$ (en pratique $\alpha \in [1, 2]$ est standard).
2. Choisir une grille pour $v : v_j = j\Delta v, j = 0, \dots, N$, avec Δv et N fixant la précision.
3. Pour chaque v_j ,
 - (a) calculer $u_j := v_j - i(\alpha + 1)$,
 - (b) calculer $d(u_j), g(u_j), D(T; u_j), C(T; u_j)$,
 - (c) en déduire $\varphi_T(u_j)$,
 - (d) calculer $\psi_T(v_j)$ via la formule ci-dessus.
4. Approcher l'intégrale par une somme de Riemann ou Simpson :

$$C(K, T) \approx \frac{e^{-\alpha k}}{\pi} \sum_{j=0}^N \Re\left(e^{-iv_j k} \psi_T(v_j)\right) \Delta v.$$

A.6. Formule finale et schéma numérique

Formule finale de Heston pour $C(K, T)$ et schéma numérique

1. Fonction caractéristique sous Heston

Sous la mesure risque-neutre Q :

$$\begin{cases} dS_t = rS_t dt + \sqrt{v_t} S_t dW_t^{(1)}, \\ dv_t = \kappa(\theta - v_t) dt + \sigma\sqrt{v_t} dW_t^{(2)}, \\ dW_t^{(1)} dW_t^{(2)} = \rho dt, \end{cases} \quad S_0 > 0, v_0 > 0.$$

On pose

$$X_t := \ln S_t.$$

La fonction caractéristique du log-prix X_T est

$$\varphi_T(u) := \mathbb{E}[e^{iuX_T}], \quad u \in \mathbb{C}.$$

Elle s'écrit sous forme affine

$$\boxed{\varphi_T(u) = \exp\left(C(T, u) + D(T, u)v_0 + iu \ln S_0\right),}$$

avec

$$d(u) := \sqrt{(\rho\sigma iu - \kappa)^2 + \sigma^2(u^2 + iu)}, \quad \Re(d(u)) > 0,$$

$$g(u) := \frac{\kappa - \rho\sigma iu - d(u)}{\kappa - \rho\sigma iu + d(u)}.$$

Les fonctions C et D sont

$$\boxed{D(T, u) = \frac{\kappa - \rho\sigma iu - d(u)}{\sigma^2} \frac{1 - e^{-d(u)T}}{1 - g(u)e^{-d(u)T}},}$$

$$C(T, u) = iurT + \frac{\kappa\theta}{\sigma^2} \left[(\kappa - \rho\sigma iu - d(u))T - 2 \ln \left(\frac{1 - g(u)e^{-d(u)T}}{1 - g(u)} \right) \right].$$

Tous les paramètres $(\kappa, \theta, \sigma, \rho, v_0, r, S_0)$ apparaissent explicitement dans $d(u)$, $g(u)$, $C(T, u)$, $D(T, u)$ donc dans $\varphi_T(u)$.

2. Formule de prix via transformée de Fourier (type Carr–Madan)

On note $K > 0$ le strike et

$$k := \ln K.$$

On fixe un paramètre de damping $\alpha > 0$ tel que

$$\mathbb{E}[e^{(\alpha+1)X_T}] < \infty \quad (\text{en pratique } \alpha \in [1, 2]).$$

Pour $v \in \mathbb{R}$, on pose

$$A(v) := \alpha + iv.$$

La transformée de Carr–Madan est

$$\psi_T(v) := \int_{\mathbb{R}} e^{A(v)k'} C(k') dk',$$

et peut se récrire en fonction de φ_T :

$$\psi_T(v) = \frac{e^{-rT}}{A(v)(A(v) + 1)} \varphi_T(v - i(\alpha + 1)).$$

La formule d'inversion donne alors le prix de la call :

$$C(K, T) = C(k) = \frac{e^{-\alpha k}}{\pi} \int_0^{+\infty} \Re(e^{-ivk} \psi_T(v)) dv.$$

En combinant explicitement :

$$C(K, T) = \frac{e^{-\alpha k}}{\pi} \int_0^{+\infty} \Re \left[e^{-ivk} \frac{e^{-rT}}{(\alpha + iv)(\alpha + 1 + iv)} \exp \left(C(T, u) + D(T, u) v_0 + iu \ln S_0 \right) \right]_{u=v-i(\alpha+1)} dv.$$

Tout est maintenant en fonction de

$$(\kappa, \theta, \sigma, \rho, v_0, r, S_0, K, T, \alpha).$$

3. Procédure numérique en pratique

Choix numériques. On fixe :

- un damping $\alpha > 0$ (souvent 1 ou 1.5) ;
- une borne supérieure $V_{\max} > 0$ pour l'intégrale en v ;
- un pas $\Delta v = V_{\max}/N$ avec N suffisamment grand (par ex. $N = 2^{10}$ ou 2^{12}).

Grille en v . On prend une grille

$$v_n = n \Delta v, \quad n = 1, \dots, N.$$

Calcul de l'intégrande. Pour chaque $n = 1, \dots, N$:

1. Poser

$$u_n := v_n - i(\alpha + 1).$$

2. Calculer

$$d_n = d(u_n) = \sqrt{(\rho \sigma i u_n - \kappa)^2 + \sigma^2(u_n^2 + i u_n)},$$

$$g_n = g(u_n) = \frac{\kappa - \rho \sigma i u_n - d_n}{\kappa - \rho \sigma i u_n + d_n}.$$

3. Calculer

$$D_n = D(T, u_n) = \frac{\kappa - \rho \sigma i u_n - d_n}{\sigma^2} \frac{1 - e^{-d_n T}}{1 - g_n e^{-d_n T}},$$

$$C_n = C(T, u_n) = i u_n r T + \frac{\kappa \theta}{\sigma^2} \left[(\kappa - \rho \sigma i u_n - d_n) T - 2 \ln \left(\frac{1 - g_n e^{-d_n T}}{1 - g_n} \right) \right].$$

4. En déduire la fonction caractéristique

$$\varphi_T(u_n) = \exp (C_n + D_n v_0 + i u_n \ln S_0).$$

5. Calculer

$$\psi_T(v_n) = \frac{e^{-rT}}{(\alpha + i v_n)(\alpha + 1 + i v_n)} \varphi_T(u_n).$$

6. Calculer l'intégrande réelle

$$f_n := \Re(e^{-i v_n k} \psi_T(v_n)).$$

Quadrature (règle des trapèzes). On approche l'intégrale par

$$\int_0^{V_{\max}} \Re(e^{-i v k} \psi_T(v)) dv \approx \sum_{n=1}^N w_n f_n \Delta v,$$

avec les poids

$$w_1 = w_N = \frac{1}{2}, \quad w_n = 1 \text{ pour } 2 \leq n \leq N - 1.$$

Prix final. Le prix approximatif de la call est

$$C(K, T) \approx \frac{e^{-\alpha k}}{\pi} \sum_{n=1}^N w_n f_n \Delta v.$$

Si l'on veut des prix pour une grille de strikes $K_j = e^{k_j}$, on répète ce calcul pour chaque k_j (ou on passe à la version FFT de Carr–Madan avec grille uniforme en k).

Annexe B - Mouvement brownien fractionnaire (Davies–Harte)

Simulation du mouvement brownien fractionnaire — Méthode de Davies–Harte (dérivation détaillée)

.12 Rappels sur le mouvement brownien fractionnaire

.13 Définition

Pour un paramètre de Hurst $H \in (0, 1)$, le *mouvement brownien fractionnaire* (fBm) $((t))_{t \geq 0}$ est un processus gaussien centré tel que

$$[(t)] = 0, \quad t \geq 0, \quad (38)$$

et

$$((t), (s)) = R_H(t, s) = \frac{1}{2}(|t|^{2H} + |s|^{2H} - |t - s|^{2H}), \quad s, t \geq 0. \quad (39)$$

On en déduit deux propriétés clés :

— **incréments stationnaires** :

$$(t + h) - (t) \stackrel{d}{=} (h) - (0), \quad \forall t, h \geq 0;$$

— **autosimilarité** :

$$((ct))_{t \geq 0} \stackrel{d}{=} (c^H(t))_{t \geq 0}, \quad \forall c > 0.$$

En particulier,

$$((t)) = t^{2H}. \quad (40)$$

.14 Discrétisation sur une grille

On veut simuler une trajectoire de sur une période $[0, T]$. On fixe un nombre de pas $N \in \mathbb{N}^*$ et on définit

$$\Delta t = \frac{T}{N}, \quad t_k = k \Delta t, \quad k = 0, \dots, N. \quad (41)$$

L'autosimilarité permet d'écrire, pour chaque k ,

$$(t_k) = (k \Delta t) \stackrel{d}{=} (\Delta t)^H \tilde{B}_H(k), \quad (42)$$

où $(\tilde{B}_H(k))_{k=0, \dots, N}$ est un fBm vu aux instants entiers k . Ainsi, on peut :

1. simuler un fBm à pas unitaire $(\tilde{B}_H(0), \dots, \tilde{B}_H(N))$;
2. le rescaler ensuite par $(\Delta t)^H$:

$$(t_k) \approx (\Delta t)^H \tilde{B}_H(k).$$

On note les incréments unitaires

$$X_k = \tilde{B}_H(k+1) - \tilde{B}_H(k), \quad k = 0, \dots, N-1. \quad (43)$$

La suite $(X_k)_{k \geq 0}$ est le *fractional Gaussian noise* (fGn). On a alors

$$\tilde{B}_H(k) = \sum_{j=0}^{k-1} X_j, \quad k \geq 1, \quad (44)$$

et

$$(t_k) \approx (\Delta t)^H \sum_{j=0}^{k-1} X_j. \quad (45)$$

Toute la difficulté se ramène donc à simuler le vecteur gaussien corrélé

$$(X_0, \dots, X_{N-1})$$

avec la bonne structure de covariance.

.15 Covariance du bruit fractionnaire

.16 Dérivation explicite de $\gamma(k)$

On veut la covariance

$$\gamma(k) = (X_n, X_{n+k}), \quad (46)$$

qui, par stationnarité des incréments, ne dépend pas de n .

On se place sur le fBm à pas unitaire $\tilde{B}_H$ et on note

$$X_n = \tilde{B}_H(n+1) - \tilde{B}_H(n). \quad (47)$$

En développant la covariance à l'aide de la bilinéarité :

$$\gamma(k) = (\tilde{B}_H(n+1) - \tilde{B}_H(n), \tilde{B}_H(n+k+1) - \tilde{B}_H(n+k)) \quad (48)$$

$$\begin{aligned} &= (\tilde{B}_H(n+1), \tilde{B}_H(n+k+1)) - (\tilde{B}_H(n+1), \tilde{B}_H(n+k)) \\ &\quad - (\tilde{B}_H(n), \tilde{B}_H(n+k+1)) + (\tilde{B}_H(n), \tilde{B}_H(n+k)). \end{aligned} \quad (49)$$

Par stationnarité des accroissements et invariance par translation, on peut prendre $n = 0$ sans perte de généralité :

$$\gamma(k) = (\tilde{B}_H(1) - \tilde{B}_H(0), \tilde{B}_H(k+1) - \tilde{B}_H(k)). \quad (50)$$

Comme $\tilde{B}_H(0) = 0$ presque sûrement, on a

$$(\tilde{B}_H(0), \tilde{B}_H(t)) = 0, \quad \forall t \geq 0,$$

et (49) se simplifie en

$$\gamma(k) = R_H(1, k+1) - R_H(1, k), \quad (51)$$

où

$$R_H(s, t) = \frac{1}{2} (|s|^{2H} + |t|^{2H} - |t-s|^{2H}).$$

On calcule explicitement :

$$R_H(1, k+1) = \frac{1}{2} (|1|^{2H} + |k+1|^{2H} - |(k+1)-1|^{2H}) = \frac{1}{2} (1 + |k+1|^{2H} - |k|^{2H}), \quad (52)$$

$$R_H(1, k) = \frac{1}{2} (|1|^{2H} + |k|^{2H} - |k-1|^{2H}) = \frac{1}{2} (1 + |k|^{2H} - |k-1|^{2H}). \quad (53)$$

D'où

$$\gamma(k) = R_H(1, k+1) - R_H(1, k) \quad (54)$$

$$= \frac{1}{2} \left(1 + |k+1|^{2H} - |k|^{2H} - 1 - |k|^{2H} + |k-1|^{2H} \right) \quad (55)$$

$$= \frac{1}{2} \left(|k+1|^{2H} + |k-1|^{2H} - 2|k|^{2H} \right). \quad (56)$$

Ainsi, la covariance théorique du bruit fractionnaire (fGn) est

$$\boxed{\gamma(k) = (X_t, X_{t+k}) = [X_t X_{t+k}] = \frac{1}{2} \left(|k+1|^{2H} + |k-1|^{2H} - 2|k|^{2H} \right).} \quad (57)$$

.17 Matrice de covariance Toeplitz

On regroupe les N premiers incréments dans le vecteur

$$X = (X_0, \dots, X_{N-1})^\top.$$

Sa matrice de covariance est la matrice Toeplitz

$$\Gamma = (X, X^\top) = (\gamma(|i-j|))_{0 \leq i, j \leq N-1}. \quad (58)$$

Autrement dit, la première ligne de Γ est

$$(\gamma(0), \gamma(1), \dots, \gamma(N-1)),$$

et chaque ligne suivante est une translation vers la droite.

La méthode de Davies–Harte consiste à *embeder* cette matrice Toeplitz dans une matrice **circulante** de taille $2N \times 2N$, ce qui permet d'utiliser la FFT.

.18 Embedding circulant et vecteur c

On construit le vecteur

$$c = (\gamma(0), \gamma(1), \dots, \gamma(N), \gamma(N-1), \dots, \gamma(1))^\top \in^{2N}. \quad (59)$$

On en déduit la matrice circulante $C \in^{2N \times 2N}$ définie par

$$C_{jk} = c_{(k-j) \bmod 2N}, \quad j, k = 0, \dots, 2N-1. \quad (60)$$

Ainsi :

- la première ligne de C est exactement $c^\top$;
- la $(j+1)$ -ème ligne est obtenue en décalant circulairement la précédente d'un cran vers la droite.

Par construction, le bloc $N \times N$ en haut à gauche de C coïncide avec la matrice Toeplitz Γ . L'idée est alors :

simuler un vecteur gaussien $Y \in^{2N}$ de covariance C , puis ne garder que ses N premières composantes ; celles-ci auront la covariance désirée Γ .

.19 Diagonalisation de la matrice circulante par la FFT

.20 Matrice de Fourier

On pose $M = 2N$ et on considère la matrice de Fourier *unitaire*

$$F_{pj} = \frac{1}{\sqrt{M}} e^{-2\pi i p j / M}, \quad p, j = 0, \dots, M-1. \quad (61)$$

Cette normalisation donne

$$F^{-1} = F^*,$$

la transposée conjuguée.

Pour un vecteur $v \in^M$, on définit sa transformée de Fourier discrète (DFT) par

$$\hat{v} = Fv, \quad (62)$$

et la transformée inverse (IDFT) par

$$v = F^* \hat{v}. \quad (63)$$

En pratique numérique, F et F^* sont calculés via la FFT/IFFT.

.21 Diagonalisation d'une matrice circulante

Un résultat standard est : *toute matrice circulante est diagonalisée par la matrice de Fourier*. Plus précisément, si C est la matrice circulante dont la première ligne est $c^\top$, alors

$$\hat{c} = Fc = (\lambda_0, \dots, \lambda_{M-1})^\top \quad (64)$$

contient les valeurs propres de C , et on a

$$\boxed{C = F^* \Delta F}, \quad (65)$$

où

$$\Delta = \text{diag}(\lambda_0, \dots, \lambda_{M-1}) \quad (66)$$

est diagonale.

Dans le langage numérique, on écrit simplement

$$\Lambda = \text{FFT}(c),$$

où $\Lambda = (\lambda_k)_{0 \leq k < M}$.

Comme c est réel et symétrique, les λ_k sont réels et, dans le cas idéal, non négatifs. En pratique, la méthode de Davies–Harte requiert $\lambda_k \geq 0$; si certains λ_k sont négatifs (erreurs numériques mises à part), l'algorithme n'est pas applicable pour ce couple (H, N) .

.22 Simulation gaussienne via la représentation spectrale

.23 Principe général

Soit $Y \in^M$ un vecteur gaussien centré. Si l'on peut écrire la covariance sous la forme

$$(Y, Y^*) = C = F^* \Delta F,$$

alors il suffit de prendre

$$Y = F^* Z, \quad (67)$$

où Z est un vecteur gaussien complexe tel que

$$[Z] = 0, \quad [ZZ^*] = \Delta.$$

En effet,

$$(Y, Y^*) = [YY^*] = [F^* Z Z^* F] = F^* [ZZ^*] F = F^* \Delta F = C. \quad (68)$$

On a donc transformé un problème de covariance générale C en un problème diagonal beaucoup plus simple.

.24 Construction du vecteur Z

On veut un vecteur

$$Z = (Z_0, \dots, Z_{M-1})^\top \in^M$$

tel que

$$[Z] = 0, \quad [ZZ^*] = \Delta = \text{diag}(\lambda_0, \dots, \lambda_{M-1}).$$

Comme Δ est diagonale, cela revient à imposer que

$$[Z_k \overline{Z_\ell}] = 0 \quad \text{si } k \neq \ell, \quad [|Z_k|^2] = \lambda_k.$$

On tient compte du fait que l'on veut finalement un *vecteur réel* Y , donc on impose en plus la symétrie conjuguée

$$Z_{M-k} = \overline{Z_k}, \quad 1 \leq k \leq M-1. \quad (69)$$

Comme c est réel et symétrique, on a $\lambda_k = \lambda_{M-k}$, ce qui rend cette construction cohérente.

Une construction explicite standard est :

- Générer des gaussiennes réelles indépendantes $U_0, \dots, U_N, V_1, \dots, V_{N-1} \sim (0, 1)$.
- Poser

$$Z_0 = \sqrt{\lambda_0} U_0, \quad (70)$$

$$Z_N = \sqrt{\lambda_N} U_N, \quad (71)$$

$$Z_k = \sqrt{\frac{\lambda_k}{2}} (U_k + iV_k), \quad k = 1, \dots, N-1, \quad (72)$$

$$Z_{M-k} = \sqrt{\frac{\lambda_k}{2}} (U_k - iV_k) = \overline{Z_k}, \quad k = 1, \dots, N-1. \quad (73)$$

On vérifie alors :

$$[Z_k] = 0, \quad [|Z_k|^2] = \lambda_k, \quad [Z_k \overline{Z_\ell}] = 0 \quad (k \neq \ell),$$

donc $[ZZ^*] = \Delta$.

.25 Génération du bruit fractionnaire par IFFT

.26 Application de l'IFFT

On définit

$$Y = F^* Z = \text{IFFT}(Z). \quad (74)$$

Par ce qui précède, on a

$$(Y, Y^*) = C. \quad (75)$$

De plus, grâce aux relations $Z_{M-k} = \overline{Z_k}$, on montre que Y est *réel* (à des erreurs numériques près) :

$$Y \in \mathbb{R}^M.$$

Dans l'implémentation, on prend donc

$$Y = \Re(\text{IFFT}(Z)).$$

On note

$$Y = (Y_0, \dots, Y_{M-1})^\top.$$

Par construction, la covariance de Y est la matrice circulante C . Le bloc $N \times N$ en haut à gauche de C est la matrice de covariance Γ du fGn. Donc, en ne conservant que les N premières composantes de Y , on obtient un vecteur ayant la bonne covariance.

On définit donc le bruit fractionnaire simulé par

$$(X_0, X_1, \dots, X_{N-1})^\top = (Y_0, Y_1, \dots, Y_{N-1})^\top \approx \text{fGn de covariance } \gamma(k). \quad (76)$$

.27 Reconstruction du mouvement brownien fractionnaire

On part de

$$\tilde{B}_H(0) = 0, \quad \tilde{B}_H(k) = \sum_{j=0}^{k-1} X_j, \quad k = 1, \dots, N,$$

où (X_j) est le fGn simulé ci-dessus.

Pour revenir aux temps $t_k = k\Delta t$ sur $[0, T]$, on utilise l'autosimilarité :

$$(t_k) \stackrel{d}{=} (\Delta t)^H \tilde{B}_H(k).$$

On pose donc

$$\boxed{(t_k) = (\Delta t)^H \sum_{j=0}^{k-1} X_j, \quad k = 0, \dots, N,} \quad (77)$$

avec la convention $(t_0) = (0) = 0$.

On vérifie que, au moins au premier ordre, la variance est correctement ajustée :

$$((t_k)) = (\Delta t)^{2H} \left(\sum_{j=0}^{k-1} X_j \right) \quad (78)$$

$$= (\Delta t)^{2H} \sum_{i=0}^{k-1} \sum_{j=0}^{k-1} \gamma(|i-j|) \quad (79)$$

$$\approx (k\Delta t)^{2H} = t_k^{2H}, \quad (80)$$

ce qui est cohérent avec la définition de la fBm.

.28 Récapitulatif de la méthode de Davies–Harte

Étape 1 : covariance du bruit fractionnaire

— Pour $k = 0, \dots, N$, calculer

$$\gamma(k) = \frac{1}{2} \left(|k+1|^{2H} + |k-1|^{2H} - 2|k|^{2H} \right).$$

Étape 2 : vecteur circulant c

— Construire

$$c = (\gamma(0), \gamma(1), \dots, \gamma(N), \gamma(N-1), \dots, \gamma(1))^\top \in^{2N}.$$

Étape 3 : FFT et valeurs propres

— Calculer la FFT :

$$\Lambda = \text{FFT}(c) = (\lambda_0, \dots, \lambda_{2N-1})^\top.$$

— Vérifier que toutes les λ_k sont non négatives (à un petit ε près pour les erreurs numériques).

Étape 4 : génération du vecteur gaussien complexe

— Générer des $U_0, \dots, U_N, V_1, \dots, V_{N-1} \sim (0, 1)$ indépendants.

— Construire $Z \in^{2N}$ par

$$\begin{aligned} Z_0 &= \sqrt{\lambda_0} U_0, \\ Z_N &= \sqrt{\lambda_N} U_N, \\ Z_k &= \sqrt{\frac{\lambda_k}{2}} (U_k + iV_k), & k = 1, \dots, N-1, \\ Z_{2N-k} &= \sqrt{\frac{\lambda_k}{2}} (U_k - iV_k) = \overline{Z_k}, & k = 1, \dots, N-1. \end{aligned}$$

Étape 5 : IFFT et extraction du fGn

— Calculer

$$Y = \text{IFFT}(Z) = F^* Z.$$

— Prendre la partie réelle et garder les N premières composantes :

$$X_k = \Re(Y_k), \quad k = 0, \dots, N-1.$$

Le vecteur $(X_0, \dots, X_{N-1})$ est le *fractional Gaussian noise*.

Étape 6 : reconstruction du fBm sur $[0, T]$

— Fixer $\Delta t = T/N$.

— Poser

$$(t_0) = 0, \quad (t_k) = (\Delta t)^H \sum_{j=0}^{k-1} X_j, \quad k = 1, \dots, N.$$

On obtient ainsi une trajectoire discrète

$$((t_0), (t_1), \dots, (t_N))$$

qui suit, en loi, un mouvement brownien fractionnaire de paramètre H sur l'intervalle $[0, T]$.

Annexe C - SDE de Volterra et rough Bergomi

Simulation du mouvement brownien fractionnaire — Méthode de Davies–Harte et lien avec le modèle rough Bergomi

Dans tout ce qui suit, $H \in (0, 1)$ désigne le paramètre de Hurst. On note $((t))_{t \geq 0}$ un mouvement brownien fractionnaire normalisé, c'est-à-dire un processus gaussien centré tel que, pour $t, s \geq 0$,

$$((t), (s)) = R_H(t, s) = \frac{1}{2} (t^{2H} + s^{2H} - |t - s|^{2H}). \quad (81)$$

On veut simuler numériquement la trajectoire $((t_k))_{k=0, \dots, N}$ sur une période $[0, T]$.

I. Discrétisation du fBm et définition du bruit fractionnaire

On fixe un nombre de pas $N \in \mathbb{N}^*$ et on définit

$$\Delta t = \frac{T}{N}, \quad t_k = k \Delta t, \quad k = 0, \dots, N. \quad (82)$$

On introduit les *incréments* (ou *fractional Gaussian noise* / fGn) par

$$X_k = (t_{k+1}) - (t_k), \quad k = 0, \dots, N-1. \quad (83)$$

Les X_k forment une suite gaussienne centrée, stationnaire, mais corrélée (sauf si $H = \frac{1}{2}$, cas brownien classique).

La fBm discrète est alors reconstruite par sommation :

$$(t_k) = \sum_{j=0}^{k-1} X_j, \quad k = 0, \dots, N, \quad (84)$$

avec la convention $(t_0) = (0) = 0$.

En pratique on simulera d'abord le bruit fractionnaire $(X_0, \dots, X_{N-1})$, puis on cumulera pour obtenir .

II. Calcul détaillé de la covariance du bruit fractionnaire

On veut obtenir la covariance

$$\gamma(m) = (X_0, X_m), \quad m \in \mathbb{Z}.$$

En utilisant la définition des incréments,

$$X_0 = (\Delta t) - (0), \quad X_m = ((m+1)\Delta t) - (m\Delta t).$$

Par bilinéarité de la covariance,

$$\gamma(m) = ((\Delta t) - (0), ((m+1)\Delta t) - (m\Delta t)) \quad (85)$$

$$\begin{aligned} &= ((\Delta t), ((m+1)\Delta t)) - ((\Delta t), (m\Delta t)) \\ &\quad - ((0), ((m+1)\Delta t)) + ((0), (m\Delta t)). \end{aligned} \quad (86)$$

On utilise la formule de covariance (81). On traite chaque terme de (86).

1. Premier terme.

$$((\Delta t), ((m+1)\Delta t)) = \frac{1}{2} [(\Delta t)^{2H} + ((m+1)\Delta t)^{2H} - |(m+1)\Delta t - \Delta t|^{2H}] \quad (87)$$

$$= \frac{1}{2} [(\Delta t)^{2H} + ((m+1)\Delta t)^{2H} - (m\Delta t)^{2H}]. \quad (88)$$

2. Deuxième terme.

$$((\Delta t), (m\Delta t)) = \frac{1}{2} [(\Delta t)^{2H} + (m\Delta t)^{2H} - |m\Delta t - \Delta t|^{2H}] \quad (89)$$

$$= \frac{1}{2} [(\Delta t)^{2H} + (m\Delta t)^{2H} - ((m-1)\Delta t)^{2H}]. \quad (90)$$

3. Troisième terme.

$$((0), ((m+1)\Delta t)) = \frac{1}{2} [0^{2H} + ((m+1)\Delta t)^{2H} - |(m+1)\Delta t|^{2H}] \quad (91)$$

$$= 0, \quad (92)$$

car les deux derniers termes se compensent.

4. Quatrième terme.

$$((0), (m\Delta t)) = \frac{1}{2} [0^{2H} + (m\Delta t)^{2H} - |m\Delta t|^{2H}] \quad (93)$$

$$= 0. \quad (94)$$

En reportant ces expressions dans (86),

$$\gamma(m) = \frac{1}{2} \left[(\Delta t)^{2H} + ((m+1)\Delta t)^{2H} - (m\Delta t)^{2H} \right] \quad (95)$$

$$- \frac{1}{2} \left[(\Delta t)^{2H} + (m\Delta t)^{2H} - ((m-1)\Delta t)^{2H} \right] \quad (96)$$

$$= \frac{1}{2} \left[(\Delta t)^{2H} + ((m+1)\Delta t)^{2H} - (m\Delta t)^{2H} \right. \quad (97)$$

$$\left. - (\Delta t)^{2H} - (m\Delta t)^{2H} + ((m-1)\Delta t)^{2H} \right] \quad (98)$$

$$= \frac{1}{2} \left[((m+1)\Delta t)^{2H} - 2(m\Delta t)^{2H} + ((m-1)\Delta t)^{2H} \right]. \quad (99)$$

On factorise $(\Delta t)^{2H}$:

$$\gamma(m) = \frac{(\Delta t)^{2H}}{2} \left(|m+1|^{2H} - 2|m|^{2H} + |m-1|^{2H} \right), \quad m \in \mathbb{Z}. \quad (100)$$

Pour alléger les notations, on introduit la covariance *normalisée* (associée au pas unité) :

$$\gamma_0(m) = \frac{1}{2} \left(|m+1|^{2H} - 2|m|^{2H} + |m-1|^{2H} \right), \quad (101)$$

de sorte que

$$\gamma(m) = (\Delta t)^{2H} \gamma_0(m). \quad (102)$$

La suite $(\gamma_0(m))_{m \in \mathbb{Z}}$ est la covariance théorique du bruit fractionnaire unit-temps.

III. Construction du vecteur de covariance circulante

La covariance des N premiers incréments $X_0, \dots, X_{N-1}$ est la matrice Toeplitz

$$\Gamma_N = \begin{pmatrix} \gamma_0(0) & \gamma_0(1) & \cdots & \gamma_0(N-1) \\ \gamma_0(1) & \gamma_0(0) & \cdots & \gamma_0(N-2) \\ \vdots & \vdots & \ddots & \vdots \\ \gamma_0(N-1) & \gamma_0(N-2) & \cdots & \gamma_0(0) \end{pmatrix}. \quad (103)$$

La méthode de Davies–Harte consiste à *encastrer* cette matrice Toeplitz dans une matrice *circulante* de taille $M = 2N$, ce qui permet d'utiliser la FFT.

On définit le vecteur de longueur $M = 2N$:

$$c = (c_0, c_1, \dots, c_{M-1}) = (\gamma_0(0), \gamma_0(1), \dots, \gamma_0(N-1), \gamma_0(N), \gamma_0(N-1), \dots, \gamma_0(1)). \quad (104)$$

C'est un vecteur *pair* au sens où $c_j = c_{M-j}$ pour $j = 1, \dots, M-1$.

On construit ensuite la matrice circulante

$$\mathbf{C} = (c_{(j-k) \bmod M})_{0 \leq j, k \leq M-1} \in^{M \times M}. \quad (105)$$

Explicitement,

$$\mathbf{C} = \begin{pmatrix} c_0 & c_1 & c_2 & \cdots & c_{M-1} \\ c_{M-1} & c_0 & c_1 & \cdots & c_{M-2} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ c_1 & c_2 & c_3 & \cdots & c_0 \end{pmatrix}.$$

Le sous-bloc supérieur gauche de taille $N \times N$ est exactement la matrice de covariance Γ_N des N premiers incréments, grâce à la définition de c .

IV. Diagonalisation de la matrice circulante par FFT

On pose $M = 2N$ et on considère la matrice de Fourier discrète normalisée (unitaire) :

$$F_{jk} = \frac{1}{\sqrt{M}} e^{-2i\pi jk/M}, \quad j, k = 0, \dots, M-1. \quad (106)$$

On a alors $F^{-1} = F^*$ (conjuguée-transposée).

Propriété fondamentale : toute matrice circulante $\mathbf{C}$ se diagonalise dans la base de Fourier :

$$\mathbf{C} = F^* \Delta F, \quad (107)$$

où Δ est diagonale. Les valeurs propres $(\lambda_0, \dots, \lambda_{M-1})$ sont données par la transformée de Fourier du premier rang de $\mathbf{C}$, c'est-à-dire du vecteur c :

$$\lambda_k = \sum_{j=0}^{M-1} c_j e^{-2i\pi jk/M}, \quad k = 0, \dots, M-1. \quad (108)$$

En notation compacte,

$$\lambda = (\lambda_0, \dots, \lambda_{M-1})^\top = \text{FFT}(c), \quad (109)$$

et

$$\Delta = \text{diag}(\lambda_0, \dots, \lambda_{M-1}). \quad (110)$$

Puisque c est réel et pair, tous les λ_k sont réels. Pour que la méthode soit valide, il faut en plus $\lambda_k \geq 0$ pour tout k (ce qui est garanti pour la fBm dans un certain domaine de paramètres ; en pratique on vérifie numériquement que les valeurs propres sont non négatives).

On obtient donc la factorisation

$$\mathbf{C} = F^* \Delta F. \quad (111)$$

V. Construction d'un vecteur gaussien de covariance $\mathbf{C}$

On cherche maintenant un vecteur gaussien complexe

$$Y = (Y_0, \dots, Y_{M-1})^\top \in \mathbb{C}^M$$

tel que

$$[Y] = 0, \quad [Y Y^*] = \mathbf{C}. \quad (112)$$

V.1. Idée générale

Soit $Z \in^M$ un vecteur gaussien complexe dit *standard*, c'est-à-dire

$$[Z] = 0, \quad [Z Z^*] = I_M \quad (113)$$

(I_M matrice identité). Posons

$$Y = F^* \Delta^{1/2} Z, \quad (114)$$

où $\Delta^{1/2} = \text{diag}(\sqrt{\lambda_0}, \dots, \sqrt{\lambda_{M-1}})$.

Alors

$$[Y] = F^* \Delta^{1/2} [Z] = 0, \quad (115)$$

et

$$[Y Y^*] = [F^* \Delta^{1/2} Z (F^* \Delta^{1/2} Z)^*] \quad (116)$$

$$= F^* \Delta^{1/2} [Z Z^*] \Delta^{1/2} F \quad (117)$$

$$= F^* \Delta^{1/2} I_M \Delta^{1/2} F \quad (118)$$

$$= F^* \Delta F = \mathbb{C}. \quad (119)$$

Ainsi, tout vecteur de la forme $Y = F^* \Delta^{1/2} Z$ a bien la covariance souhaitée.

V.2. Construction explicite de Z et réalité du signal

Pour que le vecteur final que l'on utilisera soit *réel*, on impose à Z une symétrie conjuguée particulière. On pose $M = 2N$.

— On génère Z_0 et Z_N réels :

$$Z_0 \sim (0, 1), \quad Z_N \sim (0, 1).$$

— Pour $k = 1, \dots, N-1$, on génère des gaussiennes réelles indépendantes

$$U_k, V_k \sim (0, 1),$$

indépendantes entre elles et de Z_0, Z_N , puis on pose

$$Z_k = \frac{1}{\sqrt{2}}(U_k + iV_k), \quad Z_{M-k} = \overline{Z_k} = \frac{1}{\sqrt{2}}(U_k - iV_k).$$

Par construction, Z est gaussien complexe centré, et un calcul direct montre que

$$[Z] = 0, \quad [Z Z^*] = I_M.$$

En outre, comme Δ est réelle et diagonale, la combinaison $\Delta^{1/2} Z$ vérifie la même symétrie conjuguée :

$$(\Delta^{1/2} Z)_{M-k} = \overline{(\Delta^{1/2} Z)_k}, \quad k = 1, \dots, N-1,$$

et $(\Delta^{1/2} Z)_0, (\Delta^{1/2} Z)_N$ sont réels.

Cette symétrie conjuguée, injectée dans l'IFFT (multiplication par F^*), garantit que les com-

posantes de Y sont réelles en arithmétique exacte :

$$Y_j \in, \quad j = 0, \dots, M-1. \quad (120)$$

En pratique numérique, de petits résidus imaginaires dus aux erreurs d'arrondi peuvent subsister ; on prend alors la partie réelle $\Re(Y_j)$.

On résume donc :

$$Y = F^*(\Delta^{1/2}Z) = \text{IFFT}(\sqrt{\lambda} \odot Z), \quad (121)$$

où $\odot$ désigne le produit terme à terme, et $\sqrt{\lambda} = (\sqrt{\lambda_0}, \dots, \sqrt{\lambda_{M-1}})$.

VI. Extraction du fractional Gaussian noise

Le vecteur Y est de taille $M = 2N$. La théorie de Davies–Harte montre que les N premières composantes de Y forment un vecteur gaussien réel de covariance Γ_N (cf. encastrement Toeplitz dans la circulante C).

On définit donc le bruit fractionnaire *normalisé* (pas unité) par :

$$\tilde{X}_k = Y_k, \quad k = 0, \dots, N-1. \quad (122)$$

Ces variables vérifient

$$(\tilde{X}_j, \tilde{X}_{j+m}) = \gamma_0(m), \quad 0 \leq j, j+m \leq N-1, \quad (123)$$

c'est-à-dire qu'elles ont la covariance correspondant à un pas de temps unité.

Pour retrouver la covariance au pas Δt , on applique le facteur d'échelle $(\Delta t)^H$:

$$X_k = (\Delta t)^H \tilde{X}_k, \quad k = 0, \dots, N-1. \quad (124)$$

On a alors

$$(X_j, X_{j+m}) = (\Delta t)^{2H} (\tilde{X}_j, \tilde{X}_{j+m}) \quad (125)$$

$$= (\Delta t)^{2H} \gamma_0(m) = \gamma(m), \quad (126)$$

ce qui est exactement la covariance théorique des incréments de fBm au pas Δt .

En résumé, les X_k construits ainsi forment un fractional Gaussian noise au pas Δt .

VII. Reconstruction détaillée du fBm discret

À partir du bruit fractionnaire $(X_0, \dots, X_{N-1})$, on reconstruit la trajectoire discrète de la fBm par cumul des incréments :

$$(t_0) = 0, \quad (t_k) = \sum_{j=0}^{k-1} X_j, \quad k = 1, \dots, N. \quad (127)$$

En insistant sur l'échelle en temps :

$$(t_k) = \sum_{j=0}^{k-1} X_j = (\Delta t)^H \sum_{j=0}^{k-1} \tilde{X}_j, \quad t_k = k\Delta t. \quad (128)$$

On obtient ainsi une trajectoire $((t_0), \dots, (t_N))$ dont les incréments ont la bonne covariance et donc la bonne régularité (Hölder de paramètre H quasi-sûrement).

VIII. Résumé algorithmique complet (Davies–Harte)

1. **Discrétisation en temps.** Fixer $T > 0$, $N \in \mathbb{N}^*$, $\Delta t = T/N$, $t_k = k\Delta t$.
2. **Covariance théorique du bruit fractionnaire.** Calculer pour $m = 0, \dots, N$:

$$\gamma_0(m) = \frac{1}{2} \left(|m+1|^{2H} - 2|m|^{2H} + |m-1|^{2H} \right).$$

3. **Vecteur circulant.** Construire

$$c = (\gamma_0(0), \gamma_0(1), \dots, \gamma_0(N-1), \gamma_0(N), \gamma_0(N-1), \dots, \gamma_0(1)) \in^{2N}.$$

4. **Valeurs propres par FFT.** Calculer

$$\lambda = \text{FFT}(c).$$

Vérifier numériquement que $\lambda_k \geq 0$ pour tous k , puis poser $\Delta^{1/2} = \text{diag}(\sqrt{\lambda_0}, \dots, \sqrt{\lambda_{2N-1}})$.

5. **Vecteur gaussien complexe symétrique.** Construire $Z \in^{2N}$:

- $Z_0, Z_N \sim (0, 1)$ réels,
- pour $k = 1, \dots, N-1$, $Z_k = (U_k + iV_k)/\sqrt{2}$, $Z_{2N-k} = \overline{Z_k}$, avec $U_k, V_k \sim (0, 1)$ indépendants.

6. **IFFT et bruit fractionnaire.** Calculer

$$Y = \text{IFFT}(\sqrt{\lambda} \odot Z) = F^*(\Delta^{1/2} Z) \in^{2N}.$$

Poser le bruit fractionnaire normalisé

$$\tilde{X}_k = Y_k, \quad k = 0, \dots, N-1,$$

puis le bruit fractionnaire au pas Δt :

$$X_k = (\Delta t)^H \tilde{X}_k, \quad k = 0, \dots, N-1.$$

7. **Reconstruction de la fBm.** Définir

$$(t_0) = 0, \quad (t_k) = \sum_{j=0}^{k-1} X_j, \quad k = 1, \dots, N.$$

On obtient ainsi une trajectoire discrète simulée du mouvement brownien fractionnaire sur $[0, T]$ par la méthode de Davies–Harte.

IX. Lien détaillé avec le modèle rough Bergomi

On relie maintenant cette construction de fBm à la dynamique du modèle *rough Bergomi* (rBergomi).

IX.1. Définition continue du modèle rough Bergomi

Sous la mesure risque-neutre, le modèle rough Bergomi est défini sur un espace probabilisé portant deux mouvements browniens indépendants W et $W^\perp$. On fixe un paramètre de corrélation $\rho \in [-1, 1]$ et on définit

$$Z_t = \rho W_t + \sqrt{1 - \rho^2} W_t^\perp. \quad (129)$$

Le prix S_t d'un actif sans dividende suit

$$dS_t = S_t \sqrt{V_t} dZ_t, \quad (130)$$

où V_t est le processus de variance instantanée.

Le facteur de volatilité est donné par

$$W_t^H = \sqrt{2H} \int_0^t (t-s)^{H-\frac{1}{2}} dW_s, \quad H \in (0, \frac{1}{2}), \quad (131)$$

et la variance est

$$V_t = \xi_0(t) \exp\left(\eta W_t^H - \frac{1}{2} \eta^2 t^{2H}\right). \quad (132)$$

Ici :

- $\xi_0(t)$ est la courbe de variance *forward* initiale (déterministe) ;
- $\eta > 0$ est le paramètre de “vol-of-vol” ;
- W^H est un processus gaussien de type fBm défini par l'intégrale de Volterra (131).

IX.2. Vérification que W^H est un mouvement brownien fractionnaire

On vérifie que W^H défini par (131) a bien la même covariance qu'un fBm de paramètre H .

Espérance. Par linéarité de l'intégrale d'Itô,

$$[W_t^H] = \sqrt{2H} \left[\int_0^t (t-s)^{H-\frac{1}{2}} dW_s \right] = 0. \quad (133)$$

Variance. Pour $t \geq 0$,

$$(W_t^H) = 2H \left[\left(\int_0^t (t-s)^{H-\frac{1}{2}} dW_s \right)^2 \right] \quad (134)$$

$$= 2H \int_0^t (t-s)^{2H-1} ds \quad (\text{isométrie de l'intégrale stochastique}) \quad (135)$$

$$= 2H \int_0^t u^{2H-1} du \quad (u = t-s) \quad (136)$$

$$= 2H \cdot \frac{t^{2H}}{2H} = t^{2H}. \quad (137)$$

On retrouve donc la variance d'un fBm de paramètre H .

Covariance. Pour $s, t \geq 0$,

$$(W_t^H, W_s^H) = 2H \left[\int_0^t (t-u)^{H-\frac{1}{2}} dW_u \int_0^s (s-v)^{H-\frac{1}{2}} dW_v \right] \quad (138)$$

$$= 2H \int_0^{t \wedge s} (t-u)^{H-\frac{1}{2}} (s-u)^{H-\frac{1}{2}} du \quad (\text{isométrie}). \quad (139)$$

Un calcul classique (changement de variable $u = s - x$, puis utilisation de la fonction Bêta) donne

$$2H \int_0^{t \wedge s} (t-u)^{H-\frac{1}{2}} (s-u)^{H-\frac{1}{2}} du = \frac{1}{2} (t^{2H} + s^{2H} - |t-s|^{2H}) = R_H(t, s). \quad (140)$$

Ainsi,

$$(W_t^H, W_s^H) = R_H(t, s), \quad (141)$$

exactement la covariance d'un mouvement brownien fractionnaire de paramètre H . Par unicité de la loi gaussienne à partir de la covariance, on a

$$(W_{t_1}^H, \dots, W_{t_n}^H) \stackrel{d}{=} ((t_1), \dots, (t_n)) \quad (142)$$

pour tout n et tout choix de temps $t_1, \dots, t_n$. Le processus W^H de rough Bergomi est donc *en loi* un fBm standard de paramètre H .

Conséquence importante : sur une grille $t_k = k\Delta t$, on peut simuler directement $((t_k))$ par Davies–Harte et l'utiliser comme échantillonnage de $(W_{t_k}^H)$, puisque les lois finies-dimensionnelles coïncident.

IX.3. Log-volatilité et espérance conditionnelle

La log-volatilité définie par (132) s'écrit

$$\log V_t = \log \xi_0(t) + \eta W_t^H - \frac{1}{2} \eta^2 t^{2H}. \quad (143)$$

On a déjà vu que $W_t^H \sim (0, t^{2H})$. Donc

$$\eta W_t^H \sim (0, \eta^2 t^{2H}). \quad (144)$$

Le moment exponentiel de W_t^H est donné par

$$[e^{\eta W_t^H}] = \exp\left(\frac{1}{2} \eta^2 (W_t^H)\right) = \exp\left(\frac{1}{2} \eta^2 t^{2H}\right). \quad (145)$$

On calcule alors l'espérance de V_t :

$$[V_t] = \left[\xi_0(t) \exp\left(\eta W_t^H - \frac{1}{2} \eta^2 t^{2H}\right) \right] \quad (146)$$

$$= \xi_0(t) e^{-\frac{1}{2} \eta^2 t^{2H}} [e^{\eta W_t^H}] \quad (147)$$

$$= \xi_0(t) e^{-\frac{1}{2} \eta^2 t^{2H}} e^{\frac{1}{2} \eta^2 t^{2H}} \quad (148)$$

$$= \xi_0(t). \quad (149)$$

Par construction, $\xi_0(t)$ est donc bien la *variance forward* initiale :

$$\xi_0(t) = [V_t], \quad t \geq 0. \quad (150)$$

IX.4. Discrétisation de rough Bergomi à partir de la fBm simulée

On se donne maintenant la grille $t_k = k\Delta t$, $k = 0, \dots, N$, et une trajectoire simulée de fBm

$$((t_0), \dots, (t_N))$$

obtenue par la méthode de Davies–Harte décrite aux sections précédentes.

1. Identification $W^H \equiv$. Comme démontré ci-dessus,

$$(W_{t_k}^H)_{k=0, \dots, N} \stackrel{d}{=} ((t_k))_{k=0, \dots, N}.$$

Pour la simulation, on pose donc simplement

$$W_{t_k}^H := (t_k), \quad k = 0, \dots, N. \quad (151)$$

2. Discrétisation de la variance. On obtient la variance rough Bergomi sur la grille en posant

$$V_k := V_{t_k} = \xi_0(t_k) \exp\left(\eta(t_k) - \frac{1}{2}\eta^2 t_k^{2H}\right), \quad k = 0, \dots, N. \quad (152)$$

Cette suite (V_k) est log-normale, et la relation $[V_k] = \xi_0(t_k)$ reste vérifiée.

3. Discrétisation de la dynamique du prix. L'équation

$$dS_t = S_t \sqrt{V_t} dZ_t$$

est un SDE de type Black–Scholes avec volatilité stochastique $\sqrt{V_t}$. Par Itô,

$$d \log S_t = \frac{1}{S_t} dS_t - \frac{1}{2S_t^2} (dS_t)^2 = \sqrt{V_t} dZ_t - \frac{1}{2} V_t dt. \quad (153)$$

En supposant V_t constant sur $[t_k, t_{k+1})$ et égal à V_k , on obtient le schéma de type Euler exponentiel :

$$\log S_{t_{k+1}} = \log S_{t_k} - \frac{1}{2} V_k \Delta t + \sqrt{V_k} \Delta Z_k, \quad (154)$$

où

$$\Delta Z_k = Z_{t_{k+1}} - Z_{t_k} \sim (0, \Delta t).$$

En exponentiant,

$$S_{t_{k+1}} = S_{t_k} \exp\left(-\frac{1}{2} V_k \Delta t + \sqrt{V_k} \Delta Z_k\right). \quad (155)$$

4. Corrélation avec le facteur rough. Dans la définition continue, Z est construit à partir de W via

$$Z_t = \rho W_t + \sqrt{1 - \rho^2} W_t^\perp,$$

et W^H est une intégrale stochastique de W (voir (131)). Ceci implique une structure de corrélation non triviale entre W^H et Z .

Si l'on se contente de simuler la fBm $((t_k))$ *indépendamment* d'un Brownien discrétisé (Z_{t_k}) , alors le prix S est indépendant du facteur rough : ce n'est plus le modèle rBergomi mais un modèle à volatilité rough décorrélée. Pour avoir le rBergomi correct, il faut construire conjointement un vecteur gaussien

$$(W_{t_1}^H, \dots, W_{t_N}^H, Z_{t_1}, \dots, Z_{t_N})$$

avec la bonne matrice de covariance. Celle-ci est de la forme

$$\Sigma = \begin{pmatrix} \Sigma^{HH} & \Sigma^{HZ} \\ (\Sigma^{HZ})^\top & \Sigma^{ZZ} \end{pmatrix},$$

où :

- $\Sigma_{ij}^{HH} = (W_{t_i}^H, W_{t_j}^H) = R_H(t_i, t_j)$;
- $\Sigma_{ij}^{ZZ} = (Z_{t_i}, Z_{t_j}) = \min(t_i, t_j)$ (Brownien standard) ;
- $\Sigma_{ij}^{HZ} = (W_{t_i}^H, Z_{t_j})$.

Pour ce dernier terme, en utilisant (131) et $Z_t = \rho W_t + \sqrt{1 - \rho^2} W_t^\perp$, on obtient pour $t_i \geq t_j$:

$$(W_{t_i}^H, Z_{t_j}) = \rho \left(\sqrt{2H} \int_0^{t_i} (t_i - s)^{H-\frac{1}{2}} dW_s, W_{t_j} \right) \quad (156)$$

$$= \rho \sqrt{2H} \int_0^{t_j} (t_i - s)^{H-\frac{1}{2}} ds \quad (157)$$

$$= \rho \sqrt{2H} \int_{t_i-t_j}^{t_i} u^{H-\frac{1}{2}} du \quad (u = t_i - s) \quad (158)$$

$$= \rho \sqrt{2H} \frac{t_i^{H+\frac{1}{2}} - (t_i - t_j)^{H+\frac{1}{2}}}{H + \frac{1}{2}}. \quad (159)$$

Pour $t_i < t_j$, on échange les rôles de t_i et t_j .

En pratique, pour une implémentation exacte de rBergomi, on doit simuler le vecteur gaussien de dimension $2N$ avec cette covariance Σ (par exemple via une factorisation de type Cholesky ou une méthode FFT multivariée). La méthode Davies–Harte décrite plus haut donne efficacement le bloc Σ^{HH} ; la construction complète est plus lourde mais repose sur le même principe : tout est gaussien, donc entièrement déterminé par la covariance.

IX.5. Résumé : utilisation pratique de la fBm simulée pour rBergomi

Pour relier concrètement la simulation de fBm par Davies–Harte au modèle rough Bergomi sur une grille $t_k = k\Delta t$:

1. Simuler une trajectoire de fBm $((t_k))_{k=0,\dots,N}$ via Davies–Harte.
2. L'identifier en loi au facteur rough $W_{t_k}^H$, i.e. poser $W_{t_k}^H = (t_k)$.
3. Construire la variance

$$V_k = \xi_0(t_k) \exp\left(\eta(t_k) - \frac{1}{2}\eta^2 t_k^{2H}\right).$$

4. Simuler des incréments browniens corrélés ΔZ_k de sorte que la corrélation entre W^H et Z soit bien celle imposée par le modèle (via la covariance Σ^{HZ} ci-dessus) ; dans une implémentation

approximative plus simple, on peut prendre ΔZ_k simplement corrélés avec les incréments de W ou considérer l'approximation de corrélation locale.

5. Mettre à jour le prix par

$$S_{t_{k+1}} = S_{t_k} \exp\left(-\frac{1}{2}V_k\Delta t + \sqrt{V_k}\Delta Z_k\right).$$

La dérivation montre explicitement où intervient la fBm dans rough Bergomi et comment la trajectoire obtenue par Davies–Harte se branche dans la construction de la variance et du prix.

Annexe D - Modèle SABR (expansion asymptotique)

Annexe D — Modèle SABR (expansion asymptotique)

D.1. Dynamique

$$\begin{cases} dF_t = \alpha_t F_t^\beta dW_t^{(1)}, \\ d\alpha_t = \nu \alpha_t dW_t^{(2)}, \\ dW_t^{(1)} dW_t^{(2)} = \rho dt. \end{cases}$$

D.2. Formule asymptotique de la vol implicite

La volatilité implicite obtenue par expansion en ν (Hagan et al.) est :

$$\sigma_{\text{SABR}}(K) = \frac{\alpha_0}{(F_0 K)^{\frac{1-\beta}{2}}} \left[1 + \frac{(1-\beta)^2}{24} (\ln(F_0/K))^2 + \frac{(1-\beta)^4}{1920} (\ln(F_0/K))^4 \right] / z,$$

avec

$$z = \frac{\nu}{\alpha_0} (F_0 K)^{\frac{1-\beta}{2}} \ln \frac{F_0}{K}, \quad \chi(z) = \ln \left(\frac{\sqrt{1 - 2\rho z + z^2} + z - \rho}{1 - \rho} \right).$$

La forme finale couramment utilisée est :

$$\sigma_{\text{SABR}}(K) = \frac{\alpha_0}{(F_0 K)^{\frac{1-\beta}{2}}} \left[1 + \left(\frac{(1-\beta)^2}{24} \ln^2 \frac{F_0}{K} + \frac{(1-\beta)^4}{1920} \ln^4 \frac{F_0}{K} \right) \right] \frac{z}{\chi(z)}.$$

D.3. Utilisation en calibration

La structure $(\beta, \nu, \rho, \alpha_0)$ permet de calibrer finement le smile :

$$\theta = \arg \min_{\theta} \sum_{K \in \mathcal{K}} (\sigma_{\text{SABR}}(K; \theta) - \sigma_{\text{impl}}^{\text{mkt}}(K))^2.$$

D.4. Remarques

- L'expansion est très précise pour ν modéré et $|F_0 - K|$ raisonnable.
- Des variantes existent (SABR normal, shifted-SABR).
- La dérivation complète nécessite des développements asymptotiques détaillés (reportés en annexe technique).

Annexe E - Modèle de Rough Heston

Annexe E — Modèle de Rough Heston (dynamique, caractéristique, simulation)

E.1. Motivation

Le modèle de Heston classique génère une variance v_t markovienne de type CIR. Cependant, les observations empiriques montrent un comportement plus “rugbueux” de la variance, avec une régularité Hölder strictement inférieure à $1/2$ et une décorrélation lente.

Le *Rough Heston* introduit cette rugosité en remplaçant la dynamique CIR par une SDE de Volterra reposant sur un noyau de type $t^{H-\frac{1}{2}}$ avec $H < \frac{1}{2}$.

E.2. Dynamique du Rough Heston

On considère le modèle suivant (sous la mesure risque-neutre) :

$$\begin{cases} dS_t = S_t \sqrt{v_t} dW_t^{(1)} + rS_t dt, \\ v_t = v_0 + \frac{1}{\Gamma(H+\frac{1}{2})} \int_0^t (t-s)^{H-\frac{1}{2}} (\kappa(\theta - v_s) ds + \xi \sqrt{v_s} dW_s^{(2)}), \end{cases}$$

avec covariance :

$$dW_t^{(1)} dW_t^{(2)} = \rho dt.$$

Le noyau :

$$K(t) = \frac{t^{H-\frac{1}{2}}}{\Gamma(H+\frac{1}{2})}, \quad H < \frac{1}{2},$$

introduit une mémoire longue et une régularité faible.

E.3. Formulation Volterra

La variance satisfait la Volterra SDE affine :

$$v_t = v_0 + \int_0^t K(t-s) \kappa(\theta - v_s) ds + \int_0^t K(t-s) \xi \sqrt{v_s} dW_s^{(2)}.$$

La structure affine demeure, ce qui permet des formules fermées pour la fonction caractéristique du log-prix.

E.4. Fonction caractéristique du log-prix

On pose $X_t = \ln S_t$. On cherche la fonction caractéristique :

$$\phi(u, t) = \mathbb{E}[e^{iuX_t} \mid X_0, v_0].$$

Comme le modèle est affine Volterra, on a :

$$\phi(u, t) = \exp(iuX_0 + C(u, t) + D(u, t)v_0).$$

Les fonctions $C(u, t)$ et $D(u, t)$ satisfont des *équations de Riccati fractionnaires*

$$D(u, t) = \int_0^t K(t-s) \left(\frac{1}{2}(u^2 + iu) - (\kappa - \rho \xi iu) D(u, s) - \frac{1}{2} \xi^2 D(u, s)^2 \right) ds,$$

$$C(u, t) = iurt + \kappa\theta \int_0^t D(u, s) ds.$$

Il s'agit de convolutions Volterra nécessitant des méthodes numériques dédiées (FFT accélérée, quadrature rapide, schémas hybrides).

E.5. Prix du call européen

Le prix du call est obtenu via la représentation de Carr–Madan / Fourier :

$$C_0 = S_0 P_1 - K e^{-rT} P_2,$$

où

$$P_j = \frac{1}{2} + \frac{1}{\pi} \int_0^\infty \Re \left(\frac{e^{-iu \ln K} \phi_j(u, T)}{iu} \right) du, \quad j = 1, 2.$$

La différence avec Heston classique provient du calcul de $\phi_j(u, T)$, qui utilise les Riccati fractionnaires ci-dessus.

E.6. Simulation : schéma hybride (hybrid scheme)

La simulation directe du rough Heston est coûteuse car la convolution Volterra est de complexité naïve $\mathcal{O}(n^2)$. Bayer, Friz et Gatheral (2016) proposent le *Hybrid scheme* :

- séparation du noyau en partie singulière + partie régulière,
- simulation exacte du fBM par Davies–Harte,
- approximation rapide de la convolution via FFT,
- simulation forward du log–prix via Euler–Maruyama.

Ce schéma permet des simulations rapides et stables du rough Heston.

E.7. Calibration

La calibration consiste à résoudre :

$$\theta = \arg \min_{\theta} \sum_{(K, T)} \left(\sigma_{\text{mod}}(K, T; \theta) - \sigma_{\text{mkt}}(K, T) \right)^2,$$

où $\theta = (H, \eta, \kappa, \theta, \xi, \rho, v_0)$.

Le paramètre clé est le Hurst H :

- $H < 0.5 \Rightarrow$ skew de court terme très réaliste,
- le modèle Rough Heston capture toute la géométrie empirique du smile,
- calibration souvent supérieure à Heston classique sur toute maturité.

E.8. Synthèse

Le Rough Heston combine :

- structure affine (donc transformées de Fourier disponibles),
- mémoire longue via Volterra,
- réalisme empirique, notamment sur le skew court terme.

Il constitue aujourd'hui l'un des modèles les plus avancés pour le pricing d'options equity et la modélisation de surfaces de volatilité.

Annexe F — Méthodes numériques (FFT, Crank–Nicolson)

F.1. Méthode de Crank–Nicolson pour la PDE de Black–Scholes

On considère la PDE de Black–Scholes :

$$\frac{\partial V}{\partial t} + \frac{1}{2}\sigma^2 S^2 \frac{\partial^2 V}{\partial S^2} + rS \frac{\partial V}{\partial S} - rV = 0.$$

En changeant de variable $x = \ln S$ et $\tau = T - t$, on obtient une PDE de type chaleur pour $\tilde{V}(\tau, x)$, que l'on discrétise sur une grille (τ_n, x_j) .

Le schéma de Crank–Nicolson consiste à moyenniser les schémas implicite et explicite :

$$\frac{V_j^{n+1} - V_j^n}{\Delta\tau} = \frac{1}{2}(\mathcal{L}V_j^{n+1} + \mathcal{L}V_j^n),$$

où $\mathcal{L}$ est l'opérateur spatial issu de la PDE.

En pratique, cela donne un système tridiagonal à chaque pas de temps :

$$AV^{n+1} = BV^n + b^n,$$

que l'on résout via un algorithme de Thomas (coût en $\mathcal{O}(M)$ pour M points en espace).

F.2. FFT pour le pricing d'options (Carr–Madan)

L'idée est d'exprimer le prix d'un call en termes de transformée de Fourier de la fonction caractéristique du log-prix.

Soit

$$\phi_T(u) = \mathbb{E}[e^{iu \log S_T}].$$

On introduit un call dampé :

$$c_\alpha(k) = e^{\alpha k} C(k), \quad k = \ln K,$$

avec $\alpha > 0$.

La transformée de Fourier de $c_\alpha(k)$ s'exprime alors en fonction de $\phi_T(u)$:

$$\hat{c}_\alpha(u) = \int_{-\infty}^{+\infty} e^{iuk} c_\alpha(k) dk = \frac{e^{-rT} \phi_T(u - i(\alpha + 1))}{\alpha^2 + \alpha - u^2 + iu(2\alpha + 1)}.$$

Les prix pour un ensemble de strikes équidistants k_m sont obtenus par FFT :

$$c_\alpha(k_m) \approx \frac{e^{-iu_0 k_m}}{2\pi} \sum_{n=0}^{N-1} e^{iu_n k_m} \hat{c}_\alpha(u_n) \Delta u,$$

où (u_n) est une grille uniforme de fréquences.

Enfin, on récupère le prix du call :

$$C(k_m) = e^{-\alpha k_m} c_\alpha(k_m).$$

Cette méthode est particulièrement efficace pour les modèles à fonction caractéristique explicite (Heston, Merton, Variance Gamma, etc.).

F.3. Résumé

- Le schéma de Crank–Nicolson fournit une solution stable et seconde-ordre en temps pour les PDE de pricing.
- Les méthodes FFT de type Carr–Madan permettent d’obtenir de nombreux prix d’options en un seul appel de Fourier, particulièrement bien adaptées aux modèles de type affine.