

Programme / École

PaperTradingApp

Plateforme de paper trading d'options : synthèse théorique

Prénom Nom

Année universitaire 20XX–20XX

Résumé :

Ce mémoire présente une synthèse structurée des notions théoriques mobilisées par une plateforme de *paper trading* d'options. Il couvre :

- les produits dérivés (options vanilles et exotiques) et leurs profils de risque ;
- le pricing (Black–Scholes, arbres, Monte Carlo, méthodes de Fourier) et les Greeks ;
- la volatilité implicite, les surfaces de volatilité et la calibration de modèles (Heston, SABR, modèles à mémoire de type Volterra/rough, diffusions à sauts) ;
- la construction de courbes de taux (facteurs d'actualisation, forwards, bootstrapping, paramétrisation Nelson–Siegel) ;
- la gestion du risque et du portefeuille (PnL, drawdowns, VaR/ES, allocation) ;
- l'analyse de régimes de volatilité (vol réalisée, mean reversion, chaînes de Markov), et une ouverture sur des approches d'apprentissage (surrogates, couverture sous forme MDP).

L'objectif est que le lecteur puisse constater une maîtrise explicative de chaque notion, ainsi qu'une capacité à les articuler dans un cadre cohérent d'ingénierie quantitative.

Important : le document est volontairement *strictement théorique* : aucun code, aucun pseudo-code, et aucun détail d'implémentation. Lorsque des éléments empiriques dépendraient de données non fournies, on explicite une *méthode de validation* sans avancer de résultat chiffré.

Table des matières

Notations et conventions	6
Glossaire (termes clés)	6
Liste des figures et tables proposées	7
Introduction générale	10
Cartographie du projet PaperTradingApp	11
Figures globales	13
1 Finance de marché	14
1.1 Cadre général et absence d'arbitrage	14
1.1.1 Définitions : marché, information et stratégies	14
1.1.2 Intuition : numéraire, martingales et prix “justes”	14
1.1.3 Résultat clé : théorème fondamental et valorisation risque-neutre	15
1.1.4 Actualisation, dividendes et forwards : rôle des taux	15
1.1.5 Trois familles de risques : marché, modèle, données	15
1.1.6 Limites et précautions	16
1.1.7 Lien avec le projet <i>PaperTradingApp</i>	16
1.2 Produits dérivés - Options	16
1.2.1 Vanilla / Early Exercise	16
1.2.2 Path-dependent options	18
1.2.3 Barrier options	20
1.2.4 Spreads & Wings	22
1.2.5 Calendar & Diagonal Spreads	25
1.2.6 Exotic options	26
1.2.7 Basket options	30
1.2.8 Lien avec le projet <i>PaperTradingApp</i>	32
1.3 Pricing des options	32
1.3.1 Variation quadratique des processus	32
1.3.2 Lemme d'Itô (dérivation “for dummies” rigoureuse)	34
1.3.3 Application du lemme d'Itô à $\log S_t$	37
1.3.4 Dérivation de la PDE de Black-Scholes	38
1.3.5 Application : résolution explicite de la PDE de Black-Scholes	39
1.3.6 Arbres binomiaux (Cox-Ross-Rubinstein) : exercice et convergence	41
1.3.7 Monte Carlo : estimateurs, erreur et réduction de variance	42

1.3.8	Fonctions caractéristiques, inversion de Fourier et FFT (Carr–Madan) . . .	42
1.3.9	Modèle de Heston et pricing semi–analytique	43
1.3.10	Surface de volatilité implicite et calibration de modèles	45
1.3.11	Modèles avancés : SABR et Équations de Volterra	47
1.3.12	Lien avec le projet <i>PaperTradingApp</i>	48
1.4	Hedging et Greeks	49
1.4.1	Greeks	49
1.4.2	Hedging	49
1.4.3	Dérivation du modèle de Black–Scholes par delta–hedging	50
1.4.4	Couverture et décision séquentielle : erreurs, coûts et formulation MDP . .	51
1.5	Taux & courbes de taux	52
1.5.1	Taux zéro–coupon et courbe des taux	52
1.5.2	Facteurs d’actualisation (Discount Factors)	53
1.5.3	Taux forward instantané	53
1.5.4	Construction de la courbe (bootstrapping)	53
1.5.5	Paramétrisation Nelson–Siegel : niveau, pente, courbure	55
1.5.6	Lien avec le projet <i>PaperTradingApp</i>	55
1.6	Forwards, Futures et Swaps	56
1.6.1	Forwards	56
1.6.2	Futures	56
1.6.3	Interest Rate Swaps (IRS)	56
1.6.4	Interprétation économique	57
1.6.5	Lien avec le projet <i>PaperTradingApp</i>	57
1.7	Crédit	57
1.7.1	CDS : définition et structure	57
1.7.2	Intensité de défaut (hazard rate)	58
1.7.3	Spread de CDS	58
1.7.4	Interprétations	58
1.8	Modèles de volatilité avancés : rough, sauts et filtrage	59
1.8.1	Rough volatility et SDE de Volterra	59
1.8.2	Mouvement brownien fractionnaire : méthode de Davies–Harte (dérivation pas à pas)	60
1.8.3	Modèle de Heston et variants affines	68
1.8.4	Dérivation pas à pas : modèle de Heston	69
1.8.5	Modèle SABR et volatilité inspirée (SVI)	75
1.8.6	Diffusions à sauts : Merton et Bates	76
1.8.7	Filtrage : modèles en espace d’état et filtre de Kalman	76

1.8.8	Perspectives	77
1.8.9	Lien avec le projet <i>PaperTradingApp</i>	78
1.9	Gestion du risque de portefeuille et allocation	78
1.9.1	PnL, expositions et drawdowns	78
1.9.2	Value-at-Risk (VaR) et Expected Shortfall (ES)	78
1.9.3	Allocation moyenne-variance (Markowitz)	79
1.9.4	Risk parity et contributions au risque	79
1.9.5	PCA et eigen-portfolios	79
1.9.6	Lien avec le projet <i>PaperTradingApp</i>	79
1.10	Régimes et analytics de volatilité	80
1.10.1	Volatilité réalisée : définitions, annualisation, biais	80
1.10.2	Retour à la moyenne : diagnostics et interprétation	80
1.10.3	Chaînes de Markov de régimes : matrice de transition et lecture probabiliste	81
1.10.4	Lien avec le projet <i>PaperTradingApp</i>	81
2	Apprentissage supervisé sous non-stationnarité : validation, leakage et robustesse	81
2.1	Cadre : apprentissage supervisé et généralisation	82
2.1.1	Définitions	82
2.1.2	Intuition : biais-variance et non-stationnarité	82
2.2	Eras, régimes et <i>leakage</i> : risques spécifiques	82
2.2.1	Définition d'une structure en eras	82
2.2.2	Leakage : définition et conséquences	82
2.2.3	Résultat clé (principe de validation temporelle)	83
2.3	Métriques de performance par era : corrélation et stabilité	83
2.3.1	Corrélation de Pearson par era	83
2.3.2	Agrégation : moyenne, dispersion, ratio type Sharpe	83
2.3.3	Limites	84
2.4	Réduction de dimension et sélection de variables	84
2.4.1	Filtre de valeurs manquantes	84
2.4.2	Score univarié par association à la cible	84
2.5	Modèles et régularisation (vue théorique)	84
2.5.1	Gradient boosting sur arbres (GBDT)	84
2.5.2	Ridge (régression linéaire régularisée)	85
2.5.3	Réseaux (MLP) : principe et risques	85
2.6	Ensembles, OOF et post-traitements monotones	85
2.6.1	Ensembles : réduction de variance	85
2.6.2	OOF et stacking : prudence méthodologique	85

2.6.3	Ranking (transformée par CDF empirique)	85
2.6.4	Contrôles de cohérence (sanity checks)	86
2.7	Lien avec le projet <i>PaperTradingApp</i>	86
3	Décision séquentielle : MDP et apprentissage par renforcement	86
3.1	Prérequis : apprentissage supervisé	86
3.1.1	Fondamentaux	86
3.1.2	Modèles linéaires & factoriels	87
3.1.3	Arbres & Ensembles	88
3.2	Unsupervised Learning	89
3.2.1	Clustering	89
3.2.2	Anomaly / Novelty Detection	89
3.2.3	Réduction dimensionnelle	90
3.2.4	Séries temporelles classiques	90
3.3	Deep Learning	91
3.3.1	Bases	91
3.3.2	Convolutional Neural Networks (CNN)	91
3.3.3	RNN, LSTM, GRU	92
3.3.4	Transformers	92
3.3.5	Modèles génératifs	93
3.4	Reinforcement Learning	94
3.4.1	Concepts fondamentaux	94
3.4.2	Fonctions de valeur et équations de Bellman	94
3.4.3	Monte Carlo (MC)	95
3.4.4	Temporal Difference (TD)	95
3.4.5	SARSA, Expected SARSA, Q-Learning	95
3.4.6	On-policy vs Off-policy	96
3.4.7	Function Approximation	96
3.4.8	Deep Q-Network (DQN) : comprendre le mécanisme pas à pas	96
3.4.9	Policy Gradient Methods	99
4	Conclusion et ouverture	99
4.1	Synthèse	100
4.2	Ouverture	100
4.3	Conclusion générale	101
5	SDE de Volterra et modèle rough Bergomi	101
6	Modèle SABR : expansion asymptotique (Hagan)	114

7	Modèle de Rough Heston : dynamique, caractéristique, simulation	115
8	Méthodes numériques : FFT et Crank–Nicolson	117
9	Étude de cas : pipeline de prédiction tabulaire par eras (Numerai)	119

Notations et conventions

Notation	Description (conventions)
$(\Omega, \mathcal{F}, (\mathcal{F}_t)_{t \in [0, T]}, \mathbb{P})$	Espace probabilisé filtré (information disponible à l'instant t).
$\mathbb{Q}$	Mesure risque-neutre (équivalente à $\mathbb{P}$) lorsque l'absence d'arbitrage est satisfaite.
B_t	Numéraire (compte monétaire); typiquement $B_t = \exp(\int_0^t r_u du)$.
$t \in [0, T]$	Temps; T désigne une maturité; Δt un horizon.
S_t	Prix spot du sous-jacent; $X_t = \ln S_t$ est le log-prix.
D_t / q_t	Dividendes (processus) / taux de dividende (portage) dans des conventions simplifiées.
r_t	Taux court (instantané); r désigne un taux constant lorsque supposé.
$P(0, T)$	Prix d'un zéro-coupon; $D(0, T) = P(0, T)$ facteur d'actualisation.
$f(0, T)$	Taux forward instantané : $f(0, T) = -\partial_T \ln P(0, T)$.
K	Strike; $F(t, T)$ un prix forward à maturité T (convention selon dividendes/numéraire).
$V(t, S)$	Prix d'un dérivé; $C(t, S)$ (call) et $P(t, S)$ (put). Dans la partie taux, $P(0, T)$ désigne un zéro-coupon.
σ	Volatilité (ex. Black-Scholes); σ_{imp} vol implicite; $\hat{\sigma}$ vol réalisée.
(W_t)	Mouvement brownien standard (sous $\mathbb{P}$ ou $\mathbb{Q}$ selon le contexte).
$(\Delta, \Gamma, \nu, \Theta, \rho_{\text{IR}})$	Greeks : delta, gamma, vega, theta et rho (sensibilité au taux).
v_t	Variance instantanée; paramètres Heston $(\kappa, \theta, \xi, \rho, v_0)$.
$(\alpha, \beta, \rho, \nu)$	Paramètres SABR (niveau de vol, élasticité, corrélation, vol de vol).
H	Exposant de Hurst (rough volatility : $H < \frac{1}{2}$).
λ	Intensité de sauts (Merton/Bates); loi des amplitudes selon le modèle.
μ, Σ, w	Rendements moyens, covariance, et poids d'allocation d'un portefeuille.
L	Variable de perte; VaR_α et ES_α au niveau α .
$(\mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R}, \gamma_{\text{RL}})$	MDP (couverture) : états, actions, transitions $\mathcal{P}(s' s, a)$, récompense $\mathcal{R}$ et facteur d'actualisation γ_{RL} .
$e, \mathcal{I}_e$	Era (bloc temporel/régime) et ensemble d'indices associés; ρ_e désigne une mesure calculée sur l'era e (ex. une corrélation).

Glossaire (termes clés)

Absence d'arbitrage

Propriété d'un marché où aucune stratégie auto-financée à coût initial nul ne permet un gain certain avec une probabilité strictement positive de gain strict.

Mesure risque–neutre

Mesure $\mathbb{Q}$ sous laquelle les prix actualisés des actifs (au numéraire choisi) sont des martingales ; elle permet la valorisation par espérance conditionnelle.

Smile / skew Déformation de la volatilité implicite en fonction du strike (et/ou de la maturité), révélatrice d’asymétries, de queues et de dynamique de volatilité.

Surface de vol

Fonction $(K, T) \mapsto \sigma_{\text{imp}}(K, T)$ observée sur le marché ; elle doit satisfaire des contraintes d’absence d’arbitrage statique.

Calibration Problème inverse consistant à choisir des paramètres de modèle de sorte à reproduire des prix ou des volatilités implicites de marché.

Risque de modèle

Risque lié à l’écart entre le modèle choisi et la dynamique réelle ; distinct du risque de marché (mouvements des facteurs) et du risque de données (qualité/couverture des observations).

Greeks Sensibilités locales du prix d’un dérivé aux facteurs (spot, vol, taux, temps), outils centraux de couverture et d’attribution de risque.

MDP (couverture)

Formalisation de la couverture comme décision séquentielle : l’état résume l’information disponible, l’action définit la réallocation, la récompense pénalise coûts et risque.

Era Bloc temporel (ou régime) utilisé pour structurer les données et évaluer la stabilité d’un signal dans le temps.

Leakage Fuite d’information (souvent temporelle) entre entraînement et validation, menant à une surestimation de performance hors échantillon.

OOF / stacking / ranking

OOF : prédictions hors-fold (sur données non vues) ; stacking : combinaison par meta-modèle ; ranking : transformation monotone par rang (CDF empirique) pour stabiliser la distribution des scores.

Liste des figures et tables proposées

Figures proposées

F1. Profils de payoff : call/put, straddle, strangle, butterfly, vertical spread, calendar spread.

F2. Bornes et monotonie : prix d’option en fonction de S et de K (convexité en strike).

F3. Illustration du théorème de Breeden–Litzenberger (densité risque–neutre à partir de $\partial_{KK}C$).

- F4. Smile/skew : exemple de coupes ($K \mapsto \sigma_{\text{imp}}(K, T)$) et surface (K, T).
- F5. Comparaison qualitative : Black–Scholes vs volatilité stochastique vs sauts (impact sur les queues).
- F6. Effet des paramètres Heston ($\kappa, \theta, \xi, \rho, v_0$) sur le smile (intuition).
- F7. SABR : rôle de $(\alpha, \beta, \rho, \nu)$ et domaine de validité de l’approximation de Hagan.
- F8. Rough volatility : noyau de Volterra et impact de H sur le skew court terme (qualitatif).
- F9. Calibration : schéma conceptuel “données $\rightarrow$ surface $\rightarrow$ paramètres $\rightarrow$ diagnostic”.
- F10. Courbe de taux : $P(0, T)$, $f(0, T)$ et décomposition Nelson–Siegel (niveau/pente/courbure).
- F11. Mesures de risque : schéma VaR vs ES sur une distribution de pertes (conceptuel).
- F12. Allocation : frontière efficiente, contributions au risque (risk parity) et eigen-portfolios (PCA).
- F13. Couverture : erreur de delta-hedging (discrétisation, coûts, risque de modèle) (conceptuel).
- F14. MDP de couverture : graphe état–action–récompense et boucle de rétroaction.
- F15. Régimes : matrice de transition d’une chaîne de Markov et distribution stationnaire (conceptuel).
- F16. Validation temporelle : découpage en fenêtres (rolling/expanding) et distribution d’une métrique par eras (conceptuel).

Tables proposées

- T1. Synthèse des hypothèses et paramètres des modèles : BS, Heston, SABR, Merton, Bates, rBergomi, Rough Heston, Kalman (état-espace).
- T2. Comparaison des méthodes de pricing : PDE, arbres, Monte Carlo, Fourier/FFT (avantages, limites, complexité).
- T3. Greeks : définitions, interprétations économiques et sensibilités dominantes par produit.
- T4. Contraintes d’absence d’arbitrage statique sur une surface : butterfly/vertical/calendar et bornes asymptotiques.
- T5. Fonctions de perte de calibration : prix vs vol implicite, pondérations (vega), régularisation et contraintes.
- T6. Courbe de taux : instruments (zéro-coupons, swaps), bootstrapping, interpolation (pièges) et diagnostics.
- T7. Mesures de risque : VaR/ES, hypothèses, méthodes d’estimation et limites.
- T8. Allocation : Markowitz vs risk parity vs eigen-portfolios (hypothèses, robustesse, sensibilité à l’estimation).
- T9. RL pour la couverture : Q-learning vs DQN vs PPO (idées, stabilité, risques de sur-apprentissage, validation).

T10. Modèles de régimes : définitions, estimation, interprétation et limites (non-stationnarité).

T11. Prédiction sous non-stationnarité : risques de leakage, validation temporelle, métriques par eras, et stabilisation (ensembles, post-traitements monotones).

Introduction générale

La finance de marché moderne repose sur trois piliers principaux : les *produits* (options vanilles et exotiques, instruments de taux), les *modèles* (processus stochastiques, mesure risque-neutre, volatilité locale/stochastique/rough), et les *méthodes numériques* (arbres, PDE, Monte Carlo, transformées de Fourier).

Parallèlement, certaines approches d'*approximation* et de *décision séquentielle* complètent l'arsenal classique : (i) des **surrogates** (réseaux) pour accélérer des cartes de prix/Greeks ou des itérations de calibration, et (ii) une formulation **MDP/RL** pour modéliser la couverture sous contraintes (coûts de transaction, risque de modèle, non-stationnarité).

Ce dossier a un double objectif :

- exposer de manière structurée les notions fondamentales mobilisées par le projet ;
- relier ces notions à un cas d'usage cohérent : une plateforme de paper trading d'options.

Le fil directeur suit une progression naturelle : absence d'arbitrage → produits et payoffs → calcul stochastique → méthodes de pricing → volatilité implicite et surfaces → modèles de volatilité et calibration → courbe de taux → gestion du risque et allocation → couverture et décision séquentielle → régimes de volatilité → méthodologie de validation.

Cartographie du projet PaperTradingApp

Positionnement

Ce mémoire est structuré comme une *preuve de compréhension* : pour chaque fonctionnalité majeure de la plateforme, on identifie les notions théoriques sous-jacentes et on explique comment elles s’articulent. L’objectif n’est pas de détailler une implémentation, mais de présenter un cadre conceptuel rigoureux et cohérent.

Correspondance “modules $\leftrightarrow$ notions”

Module (onglet)	Notions théoriques mobilisées
Options	Payoffs, parités, smile/skew, vol implicite, Greeks, pricing (BS, arbres, MC, Fourier), exotiques.
Calibration avancée	Problème inverse, fonctions de perte, contraintes, identifiabilité, régularisation, surfaces de vol, modèles affines (Heston), SABR, modèles à mémoire (Volterra/rough), diffusions à sauts, surrogates par apprentissage.
Yield Curve	Zéro-coupons, facteurs d’actualisation, taux forwards, bootstrapping, interpolation/extrapolation, paramétrisations (Nelson–Siegel), cohérence absence d’arbitrage.
Hedging Systems	Couverture delta/gamma/vega, erreurs de couverture, coûts de transaction, contrôle stochastique, formulation MDP et apprentissage par renforcement (DQN/PPO) pour la décision séquentielle.
Portefeuille & risque	Valorisation, expositions, PnL réalisé/non réalisé, attribution, drawdowns, VaR/ES, stress tests, allocation (Markowitz, risk parity, eigen-portfolios).
Trading	Logique d’exécution (ordres, slippage), stratégies simples (DCA/grid), back-testing et mesures de performance.
Bots & Assistant	Stratégies de volatilité (straddle, IV crush), vol réalisée, mean reversion, régimes et transitions Markov, diagnostic textuel et limites de l’assistance IA.


Plan de rédaction recommandé (niveau “mémoire”)

- Partie 1 : théorie des produits, du pricing et de la volatilité ; puis courbes de taux et gestion du risque.
- Partie 2 : apprentissage utile (surrogates pour calibration, régimes, MDP/RL pour couverture).
- Partie 3 : synthèse par modules (objectif, hypothèses, limites, liens vers les chapitres théoriques).


- Conclusion : limites (données, hypothèses de modèle, coûts, robustesse) et pistes d'amélioration.

Figures globales

Schéma global du mémoire



Carte conceptuelle : modélisation, risque et décision



1 Finance de marché

1.1 Cadre général et absence d'arbitrage

Cette sous-partie fixe le cadre mathématique de référence : modélisation probabiliste, actualisation, absence d'arbitrage et valorisation sous mesure risque-neutre. Il s'agit du socle sur lequel s'appuient le pricing, la calibration, la mesure des risques et la couverture.

1.1.1 Définitions : marché, information et stratégies

On considère un espace probabilisé filtré $(\Omega, \mathcal{F}, (\mathcal{F}_t)_{t \in [0, T]}, \mathbb{P})$, où $\mathcal{F}_t$ représente l'information disponible à la date t . Un *marché* est modélisé par un numéraire $B_t > 0$ (compte monétaire) et un vecteur de prix d'actifs risqués $(S_t^1, \dots, S_t^d)$, adaptés à $(\mathcal{F}_t)$.

Actualisation. On dit qu'un processus X_t est *actualisé* par B_t via $\tilde{X}_t := X_t/B_t$. L'intuition est que B_t sert d'unité de compte : tout prix est mesuré en “unités de numéraire”.

Stratégies auto-financées. Une stratégie de trading (simplifiée) est un processus prévisible $\phi_t = (\phi_t^1, \dots, \phi_t^d)$ représentant les quantités d'actifs détenues, éventuellement complété par une position en numéraire. La valeur du portefeuille est $V_t = \sum_{i=1}^d \phi_t^i S_t^i + \psi_t B_t$. La condition *auto-financée* formalise l'absence d'apports/retraits : toute variation de V_t provient des variations de prix des actifs détenus.

Arbitrage. Intuitivement, un arbitrage est une stratégie auto-financée qui ne coûte rien au départ et qui ne peut pas perdre, tout en ayant une probabilité strictement positive de gain strict. Selon les cadres, on utilise des notions plus fines (NA, NFLVR) pour traiter les limites de marchés continus.

1.1.2 Intuition : numéraire, martingales et prix “justes”

En l'absence d'arbitrage et sous hypothèses techniques usuelles, il existe une mesure $\mathbb{Q}$ telle que les prix *actualisés* des actifs risqués soient des martingales :

$$\tilde{S}_t^i = \frac{S_t^i}{B_t} \text{ est une martingale sous } \mathbb{Q}, \quad i = 1, \dots, d.$$

Cette propriété encode l'idée que, une fois mesurés dans la bonne unité (le numéraire), les prix n'ont pas de tendance exploitable “gratuitement”. Elle n'implique pas que les actifs soient sans risque, mais que le risque est compensé par le choix de la mesure $\mathbb{Q}$ (changement de mesure).

1.1.3 Résultat clé : théorème fondamental et valorisation risque-neutre

Théorème fondamental (version informelle). Sous des hypothèses d'absence d'arbitrage (de type NFLVR) et de régularité, il existe une mesure $\mathbb{Q}$ équivalente à $\mathbb{P}$ telle que les prix actualisés soient des martingales. Réciproquement, l'existence d'une telle mesure exclut l'arbitrage.

Prix d'un payoff. Pour un payoff Φ à maturité T (mesurable par rapport à $\mathcal{F}_T$), le *prix* à la date t admet la représentation :

$$V_t = B_t \mathbb{E}^{\mathbb{Q}} \left[\frac{\Phi}{B_T} \middle| \mathcal{F}_t \right].$$

Dans un marché *complet*, la mesure $\mathbb{Q}$ est unique et le prix est unique. Dans un marché *incomplet* (typiquement dès que l'on introduit de la volatilité stochastique non répliquable, des sauts, ou des coûts), il existe plusieurs mesures martingales : la formule reste un principe, mais le choix de $\mathbb{Q}$ (ou, équivalamment, la spécification du modèle) devient une hypothèse de modélisation.

1.1.4 Actualisation, dividendes et forwards : rôle des taux

Dividendes et portage. Si le sous-jacent verse un dividende continu au taux q (cas simplifié), l'absence d'arbitrage conduit à la relation de portage pour le forward européen :

$$F(0, T) = S_0 e^{(r-q)T},$$

et plus généralement $F(0, T) = S_0 \exp(\int_0^T (r_u - q_u) du)$ si r_u, q_u sont déterministes. Lorsque les taux sont stochastiques, le prix dépend du numéraire choisi (mesure à terme, mesure associée au zéro-coupon), ce qui souligne l'importance d'une courbe de taux cohérente et d'une convention d'actualisation explicite.

1.1.5 Trois familles de risques : marché, modèle, données

Risque de marché. Risque lié à l'évolution des facteurs (spot, volatilité, taux, corrélations) : même avec un modèle parfait, les PnL fluctuent.

Risque de modèle. Risque lié aux hypothèses (log-normalité, absence de sauts, markovianité, forme de smile dynamics, etc.). Il se manifeste notamment par des erreurs de couverture (hedging error) et des instabilités de calibration.

Risque de données. Risque lié à la qualité des observations : microstructure, quotes non synchrones, bid-ask, erreurs de nettoyage, maturités manquantes. Il affecte directement les surfaces, les courbes et la calibration.

1.1.6 Limites et précautions

Le cadre “arbitrage-free” suppose des marchés frictionless et des stratégies admissibles. En pratique, la couverture est discrète, coûteuse, soumise à des contraintes (liquidité, marges), et les marchés peuvent être incomplets. Une conséquence centrale est que le *pricing* est inséparable d’une gouvernance des hypothèses : choix du numéraire, conventions de dividendes, sélection de modèle et protocole de validation.

1.1.7 Lien avec le projet *PaperTradingApp*

Sans décrire d’implémentation, le projet mobilise ce cadre pour : (i) définir une valorisation cohérente par actualisation et absence d’arbitrage, (ii) relier prix, surface de volatilité et densité risque-neutre, (iii) interpréter les écarts entre modèles comme du risque de modèle, (iv) distinguer la variabilité des PnL due aux facteurs (risque de marché) de celle due aux erreurs de données et de calibration.

1.2 Produits dérivés - Options

1.2.1 Vanilla / Early Exercise

Les options vanilles constituent la classe fondamentale des produits dérivés d’options. Leur payoff dépend uniquement du prix du sous-jacent S_T à l’échéance T , ce qui permet une étude rigoureuse via les outils classiques de calcul stochastique, de théorie de l’arbitrage et d’analyse fonctionnelle.

Options européennes. Une option européenne ne peut être exercée qu’à la date de maturité T .

Les payoffs sont donnés par :

$$\text{Call} : (S_T - K)^+, \quad \text{Put} : (K - S_T)^+,$$

où $(x)^+ = \max(x, 0)$.

Sous la mesure risque-neutre $\mathbb{Q}$ et en l’absence d’arbitrage, les prix sont :

$$C_0 = e^{-rT} \mathbb{E}^{\mathbb{Q}}[(S_T - K)^+], \quad P_0 = e^{-rT} \mathbb{E}^{\mathbb{Q}}[(K - S_T)^+].$$

Dans le modèle de mouvement brownien géométrique

$$dS_t = rS_t dt + \sigma S_t dW_t,$$

l’application du lemme d’Itô permet de dériver la PDE de Black-Scholes ainsi que la formule fermée du call européen.

La parité call–put s’écrit :

$$C_0 - P_0 = S_0 - Ke^{-rT},$$

relation qui doit être satisfaite dans tout modèle arbitrage–free.

Options américaines. Une option américaine peut être exercée à tout instant $\tau \in [0, T]$. La valorisation s’écrit comme un problème de temps d’arrêt optimal :

$$V_0 = \sup_{\tau \in \mathcal{T}} \mathbb{E}^{\mathbb{Q}}[e^{-r\tau} \Phi(S_\tau)],$$

où $\mathcal{T}$ désigne l’ensemble des temps d’arrêt adaptés.

La frontière d’exercice est caractérisée par l’inégalité :

$$\Phi(S_t) \geq V_t.$$

Cas classiques :

- Call américain *sans dividende* : l’exercice anticipé n’est jamais optimal et l’on a $V_0 = C_0^{EU}$.
- Put américain : un exercice anticipé peut être optimal lorsque S_t franchit une frontière critique $S^*(t)$, solution d’un problème de frontière libre.

En pratique, ces produits nécessitent des méthodes numériques (arbres binomiaux ou trinômiaux, PDE variationnelles, méthodes de type Longstaff–Schwartz).

Options bermudéennes. Les options bermudéennes constituent un intermédiaire entre européennes et américaines : l’exercice n’est possible qu’à un ensemble discret de dates $\{t_1, \dots, t_m\} \subset [0, T]$.

La valorisation se fait par récurrence arrière :

$$V(t_i, S) = \max \left(\Phi(S), e^{-r(t_{i+1}-t_i)} \mathbb{E}[V(t_{i+1}, S_{t_{i+1}}) \mid S_{t_i} = S] \right).$$

On rencontre ce type de produits en taux (swaptions bermudéennes), dans certains produits structurés ou produits de crédit exotiques.

Options vanilles sous volatilité stochastique : modèle de Heston. Dans le modèle de Heston, sous la mesure risque–neutre, le sous–jacent S_t et la variance instantanée v_t satisfont :

$$\begin{cases} dS_t = rS_t dt + \sqrt{v_t} S_t dW_t^{(1)}, \\ dv_t = \kappa(\theta - v_t) dt + \xi \sqrt{v_t} dW_t^{(2)}, \end{cases} \quad dW_t^{(1)} dW_t^{(2)} = \rho dt.$$

Le prix du call européen admet une formule semi-fermée de la forme

$$C_0 = S_0 P_1 - K e^{-rT} P_2,$$

où P_1 et P_2 s'expriment comme des intégrales de Fourier faisant intervenir la fonction caractéristique du log-prix.

La dérivation complète de cette formule (changement de mesure, résolution de l'ODE pour la fonction caractéristique, inversion de Fourier) est développée en Section 1.8.4.

Volatilité rugueuse et modèle rBergomi. Le modèle rBergomi repose sur un mouvement brownien fractionnaire de paramètre de Hurst $H < \frac{1}{2}$, conduisant à une dynamique de variance à mémoire longue de type Volterra. Il est motivé par la géométrie du skew à court terme observée sur les marchés actions.

Les éléments clés sont :

- définition du fractional Brownian motion B^H ,
- représentation de Mandelbrot–Van Ness,
- lien avec les SDE de type Volterra et la variance rough.

Les détails (construction du fBM, noyaux, choix de schémas) sont développés en Sections 1.8.2 et 5 ; on renvoie sinon à la littérature sur la rough volatility pour des approfondissements.

Rôle structurel des options vanilles. Les options vanilles sont utilisées pour :

- **calibrer** les modèles de volatilité, en ajustant un vecteur de paramètres θ pour minimiser l'écart entre volatilités implicites modèle et marché ;
- **extraire les sensibilités** (Greeks) : $\Delta = \frac{\partial V}{\partial S}$, $\Gamma = \frac{\partial^2 V}{\partial S^2}$, Vega = $\frac{\partial V}{\partial \sigma}$, etc. ;
- **construire des payoffs exotiques synthétiques** par superposition linéaire d'options vanilles (spreads, butterflies, arbitrages statiques).

1.2.2 Path-dependent options

Les options path-dependent sont des produits dérivés dont le payoff dépend de l'ensemble de la trajectoire $(S_t)_{0 \leq t \leq T}$, et non uniquement de la valeur du sous-jacent à maturité. Leur valorisation requiert l'utilisation de probabilités fonctionnelles, de techniques avancées de Monte Carlo et, dans certains cas, de résultats de théorie des extrêmes du mouvement brownien.

Asian options. Structure. On distingue deux types principaux de moyennes discrètes :

$$A_T^{\text{arith}} = \frac{1}{n} \sum_{i=1}^n S_{t_i}, \quad A_T^{\text{geom}} = \left(\prod_{i=1}^n S_{t_i} \right)^{1/n}.$$

Payoff.

$$\text{Call asiatique : } (A_T - K)^+, \quad \text{Put asiatique : } (K - A_T)^+.$$

Pricing.

- Cas géométrique : moyenne lognormale $\Rightarrow$ formule fermée.
- Cas arithmétique : pas de forme fermée.

Méthodes principales :

- Monte Carlo (méthode standard),
- variance reduction (antithetic, control variate utilisant la moyenne géométrique),
- approximation lognormale de Turnbull–Wakeman.

Lookback options. Structure.

$$M_T = \max_{0 \leq t \leq T} S_t, \quad m_T = \min_{0 \leq t \leq T} S_t.$$

Payoff.

- **Floating strike :**

$$\text{Call : } (S_T - m_T)^+, \quad \text{Put : } (M_T - S_T)^+.$$

- **Fixed strike :**

$$\text{Call : } (M_T - K)^+, \quad \text{Put : } (K - m_T)^+.$$

Pricing.

- Formules fermées en Black–Scholes via le principe de réflexion.
- En général : simulation Monte Carlo indispensable.
- Gestion des franchissements : Brownian bridge pour limiter les erreurs.

Forward-start options. Structure. Le strike est fixé à une date future $t_0 < T$:

$$K = \alpha S_{t_0}.$$

Payoff.

$$\Phi = (S_T - \alpha S_{t_0})^+.$$

Pricing.

- Interprétation comme un call européen conditionnel à S_{t_0} .
- En Black–Scholes : équivalent à un call sur un forward.
- En général : simulation jointe (S_{t_0}, S_T) .

Cliquet / Ratchet options. Structure. Options à réinitialisation périodique :

$$\Phi = \sum_{i=1}^n (S_{t_i} - S_{t_{i-1}})^+.$$

Payoff. Basé sur les increments positifs ou une accumulation de gains “lock-in”.

Pricing.

- Simulation Monte Carlo multidimensionnelle,
- corrélations fortes entre increments $\Rightarrow$ variance élevée,
- PDE multidimensionnelle impraticable en général.

1.2.3 Barrier options

Les options barrières sont des produits dérivés dont le payoff dépend du franchissement ou non d’un niveau prédéfini appelé *barrière*. Elles sont fortement sensibles à la trajectoire du sous-jacent et requièrent la maîtrise des temps de passage du mouvement brownien.

Structure. On définit le temps d’atteinte de la barrière B par :

$$\tau_B = \inf\{t \geq 0 : S_t \in \mathcal{B}\}.$$

Deux familles principales :

- **Knock-out** : l’option est annulée si $\tau_B \leq T$.
Exemples : up-and-out, down-and-out.
- **Knock-in** : l’option n’existe que si la barrière est atteinte avant T .
Exemples : up-and-in, down-and-in.

Payoff. Pour un payoff vanille $\Phi(S_T)$:

- **Knock-out** :

$$\Phi_{\text{KO}} = \Phi(S_T) \mathbf{1}_{\{\tau_B > T\}}.$$

- **Knock-in** :

$$\Phi_{\text{KI}} = \Phi(S_T) \mathbf{1}_{\{\tau_B \leq T\}}.$$

Relation fondamentale de parité :

$$\Phi_{\text{KI}} + \Phi_{\text{KO}} = \Phi_{\text{vanilla}}.$$

Pricing.

Cas Black–Scholes : formules fermées. Sous un GBM, les hitting times sont explicites par le principe de réflexion. Cela conduit à des formules fermées pour l'ensemble des barrières up/down, in/out.

Exemple (call down-and-out) :

$$C_{\text{DO}} = C_{\text{vanilla}} - \left(\frac{B}{S_0}\right)^{2\lambda-2} C_{\text{vanilla}}(S'_0, K),$$

avec

$$\lambda = \frac{r}{\sigma^2} + \frac{1}{2}, \quad S'_0 = \frac{B^2}{S_0}.$$

Observation continue vs discrète.

- Observation continue : barrière active en tout temps $\rightarrow$ hitting times exacts.
- Observation discrète : barrière testée à des dates $\{t_i\}$ seulement $\Rightarrow \text{Price}_{\text{disc}} > \text{Price}_{\text{cont}}$.

Correction : utilisation d'un **Brownian bridge** entre deux pas de temps.

Pricing sous volatilité locale / stochastique / rough.

- **Local vol** : PDE 2D (spot + temps), solution numérique stable.
- **Heston** : simulation Monte Carlo nécessaire, schéma QE pour v_t .
- **Rough volatility** : trajectoires plus irrégulières, hitting times plus fréquents.

Monte Carlo. Le Monte Carlo naïf ne détecte pas correctement les franchissements. Solution : Brownian bridge.

Probabilité conditionnelle de franchissement :

$$\mathbb{P}(\text{hit}) = \exp\left(-\frac{2}{\sigma^2 h} \ln \frac{S_t}{B} \cdot \ln \frac{S_{t+h}}{B}\right).$$

Variantes.

- **Rebate options** :

$$R \cdot \mathbf{1}_{\{\tau_B < T\}}.$$

- **Parisian barriers** : hitting cumulé durant δ :

$$\tau^* = \inf \left\{ t : \int_0^t \mathbf{1}_{\{S_u < B\}} du \geq \delta \right\}.$$

- **Partial barriers** : barrière active uniquement sur $[t_a, t_b]$.

1.2.4 Spreads & Wings

Les stratégies “spreads” et “wings” sont des combinaisons linéaires d’options vanilles visant à modifier le profil de payoff et les sensibilités (gamma, vega, vomma, convexité). Elles reposent sur le principe :

$$\Phi = \sum_i w_i \Phi_i,$$

où chaque Φ_i est un payoff vanille.


Bull Call Spread. Structure.

$$\text{Long Call}(K_1) + \text{Short Call}(K_2), \quad K_1 < K_2.$$

Payoff.

$$\Phi(S_T) = (S_T - K_1)^+ - (S_T - K_2)^+.$$

Graphique du payoff.



Prix.

$$V_0 = C(K_1) - C(K_2).$$


Bear Put Spread. Structure.

$$\text{Long Put}(K_2) + \text{Short Put}(K_1), \quad K_1 < K_2.$$

Payoff.

$$\Phi(S_T) = (K_2 - S_T)^+ - (K_1 - S_T)^+.$$

Graphique du payoff.



Prix.

$$V_0 = P(K_2) - P(K_1).$$


Straddle. Structure.

Long Call(K) + Long Put(K).

Payoff.

$$\Phi(S_T) = |S_T - K|.$$

Graphique du payoff.



Prix.

$$V_0 = C(K) + P(K).$$


Strangle. Structure.

$$\text{Long Put}(K_1) + \text{Long Call}(K_2), \quad K_1 < K_2.$$

Payoff.

$$\Phi(S_T) = (K_1 - S_T)^+ + (S_T - K_2)^+.$$

Graphique du payoff.



Prix.

$$V_0 = P(K_1) + C(K_2).$$


Butterfly spread. Structure.

$$\text{Long } C(K_1) - 2C(K_2) + \text{Long } C(K_3), \quad K_1 < K_2 < K_3.$$

Payoff.

$$\Phi(S_T) = (S_T - K_1)^+ - 2(S_T - K_2)^+ + (S_T - K_3)^+.$$

Graphique du payoff.




Prix.

$$V_0 = C(K_1) - 2C(K_2) + C(K_3).$$

Condor spread. Structure.

$$C(K_1) - C(K_2) - C(K_3) + C(K_4), \quad K_1 < K_2 < K_3 < K_4.$$

Graphique du payoff.**1.2.5 Calendar & Diagonal Spreads**

Les calendar spreads et diagonal spreads sont des stratégies multi-maturités qui exploitent la structure par terme de la volatilité implicite ainsi que la décroissance temporelle de la valeur temps (Theta). Elles reposent sur la combinaison d'options de même sous-jacent mais de maturités, voire de strikes, différents.

Calendar Spread. Structure.

$$\text{Long Call}(K, T_2) + \text{Short Call}(K, T_1), \quad T_1 < T_2.$$

Payoff. À maturité T_2 , le payoff du calendar spread est celui de l'option longue, mais le coût initial est réduit par la jambe courte :

$$\Pi_0 = C(K, T_2) - C(K, T_1).$$


Pricing. Sous Black-Scholes :

$$C(K, T_i) = BS(S_0, K, r, \sigma, T_i), \quad i = 1, 2.$$

Le spread dépend de :

- la pente de la structure de volatilité,
- la position du strike par rapport au forward,
- la différence de theta entre T_1 et T_2 .

Graphique du payoff (profil à maturité).



Diagonal Spread. Structure.

$$\text{Long Call}(K_2, T_2) + \text{Short Call}(K_1, T_1), \quad T_2 > T_1, \quad K_1 \neq K_2.$$

Payoff.


$$\Pi_0 = C(K_2, T_2) - C(K_1, T_1).$$

Profil final : payoff de call $(S_{T_2} - K_2)^+$, mais avec dynamique intermédiaire asymétrique en fonction de K_1 .

Pricing.

- Long vega long terme, short vega court terme.
- Sensibilité directionnelle via (K_1, K_2) .
- Interprétation : combinaison directionnelle + term structure.

Graphique du payoff (profil typique).



1.2.6 Exotic options

Les options exotiques sont des dérivés dont la structure de payoff dépasse celle des options vanilles. Elles permettent de modéliser des expositions complexes : vues directionnelles asymétriques, paris sur la corrélation, paris sur la volatilité locale ou stochastique, ou encore élimination du risque de change (produits quanto).

Digital options. Structure. Une option digitale verse un montant fixe Q si la condition de moneyness est satisfaite.


Payoff.

$$\Phi_{\text{DC}} = Q \cdot \mathbf{1}_{\{S_T > K\}}, \quad \Phi_{\text{DP}} = Q \cdot \mathbf{1}_{\{S_T < K\}}.$$

Pricing (Black–Scholes).

$$V_0^{\text{DC}} = Qe^{-rT}N(d_2), \quad d_2 = \frac{\ln(S_0/K) + (r - \frac{1}{2}\sigma^2)T}{\sigma\sqrt{T}}.$$

Graphique du payoff (digital call).



Asset-or-nothing options. Structure. Le payoff dépend du niveau du sous-jacent et d’une condition binaire.


Payoff.

$$\Phi_{\text{AON}} = S_T \cdot \mathbf{1}_{\{S_T > K\}}.$$

Pricing (Black–Scholes).

$$V_0 = S_0N(d_1).$$

Graphique du payoff (asset-or-nothing call).



Chooser options. Structure. À une date $t_c < T$, l'acheteur choisit entre un call et un put.

Payoff.

$$\Phi = \max (C(t_c, T), P(t_c, T)).$$


Relation clé.

$$\Phi = C(t_c, T) + P(t_c, T) - |S_{t_c} - K|.$$

Pricing (Black–Scholes).

$$V_0 = C(S_0, K, T) + P(S_0, K, T) - P(S_0, K, t_c).$$

Graphique du payoff à t_c .




Quanto options. Structure. Option sur un actif étranger, payoff payé dans une autre devise.

$$\Phi_{\text{quanto}} = \Phi_{\text{local}}(S_T) \times FX_0.$$

Drift risque-neutre ajusté.

$$dS_t = (r_d - q - \rho_{S,X} \sigma_S \sigma_X) S_t dt + \sigma_S S_t dW_t^{(S)}.$$

Graphique du payoff (quanto call).



Rainbow options. Structure.

$$\Phi_{\max} = (\max_i S_T^{(i)} - K)^+, \quad \Phi_{\min} = (K - \min_i S_T^{(i)})^+.$$

Payoff. Best-of / worst-of.


Pricing. Dépend de la corrélation :

$$\sigma_B^2 = \sum_{i,j} w_i w_j \sigma_i \sigma_j \rho_{ij}.$$

Méthodes :

- simulation Monte Carlo multivariée,
- approximations lognormales,
- pricing via copules.

Graphique du payoff (best-of, 2 actifs).



1.2.7 Basket options

Les basket options sont des dérivés dont le payoff dépend d'un panier pondéré de plusieurs sous-jacents. Leur valorisation est profondément influencée par la corrélation entre les actifs, ainsi que par la structure de leurs volatilités respectives.

Le panier s'écrit :

$$B_T = \sum_{i=1}^n w_i S_T^{(i)}, \quad \sum_{i=1}^n w_i = 1, \quad w_i \geq 0.$$

Basket call / put. Payoff.

$$\Phi_{\text{call}} = (B_T - K)^+, \quad \Phi_{\text{put}} = (K - B_T)^+.$$

Pricing. Même lorsque chaque $S_t^{(i)}$ suit un GBM, le panier B_T n'est pas lognormal. Il n'existe donc pas de formule fermée générale.


Approximations usuelles :

- **Approximation lognormale** : $B_T \approx \text{LN}(\mu_B, \sigma_B^2)$ où


$$\sigma_B^2 = \sum_{i,j} w_i w_j \sigma_i \sigma_j \rho_{ij}.$$

- **Moment matching** : ajustement d'une lognormale équivalente via $\mathbb{E}[B_T]$ et $\text{Var}(B_T)$.
- **Monte Carlo multivarié** : simulation corrélée via factorisation de Cholesky ou SVD.

Graphique (Basket Call).



Basket put. Graphique (Basket Put).



Best-of / Worst-of options. Structure.

$$\Phi_{\max} = (\max_i S_T^{(i)} - K)^+, \quad \Phi_{\min} = (K - \min_i S_T^{(i)})^+.$$

Sensibilités. La dépendance à la corrélation est immédiate :


- Best-of : augmente lorsque la corrélation baisse.
- Worst-of : augmente lorsque la corrélation grimpe.

Pricing.

- Monte Carlo multivarié (méthode standard).

- Approximations lognormales / copules gaussiennes.
- Pricing Fourier multivarié (méthodes COS).

Graphique (Best-of, 2 actifs).



1.2.8 Lien avec le projet *PaperTradingApp*

Cette partie correspond au socle “produits” : elle sert à (i) définir les payoffs (vanilles et exotiques) manipulés par la plateforme, (ii) lire des profils de risque (linéarité, convexité, exposition aux queues), et (iii) analyser des stratégies simples (spreads, wings, straddles) en termes de sensibilités et de scénarios. Le lien avec le projet n’est pas une implémentation, mais une exigence de cohérence : une stratégie n’a de sens que rapportée à un payoff et à des bornes absence d’arbitrage (parités, monotonicités, convexité), puis à un modèle de dynamique (volatilité, sauts) discuté plus loin.

1.3 Pricing des options

1.3.1 Variation quadratique des processus

Définition. Soit une partition d’un intervalle $[0, T]$:

$$\Pi_n = \{0 = t_0^{(n)} < t_1^{(n)} < \dots < t_{k_n}^{(n)} = T\}, \quad |\Pi_n| := \max_i (t_{i+1}^{(n)} - t_i^{(n)}).$$

On définit la *variation quadratique* d’un processus continu (X_t) par la limite, lorsqu’elle existe :

$$[X]_T := \lim_{n \rightarrow \infty} \sum_{i=0}^{k_n-1} (X_{t_{i+1}^{(n)}} - X_{t_i^{(n)}})^2, \quad |\Pi_n| \rightarrow 0.$$

Lorsque la limite existe pour tout $t \leq T$, on obtient un processus croissant $t \mapsto [X]_t$.

Variation quadratique du mouvement brownien. Soit (W_t) un mouvement brownien standard. Sur un intervalle $[t_i, t_{i+1}]$ de longueur Δt_i :

$$W_{t_{i+1}} - W_{t_i} \sim \mathcal{N}(0, \Delta t_i) \quad \Rightarrow \quad \mathbb{E}[(W_{t_{i+1}} - W_{t_i})^2] = \Delta t_i.$$

Considérons :

$$S_n := \sum_i (W_{t_{i+1}} - W_{t_i})^2.$$

Alors :

$$\mathbb{E}[S_n] = \sum_i \Delta t_i = T.$$

Pour la variance :

$$\text{Var}(S_n) = \sum_i \text{Var}((W_{t_{i+1}} - W_{t_i})^2).$$

Si $Z \sim \mathcal{N}(0, \Delta t)$, alors

$$\mathbb{E}[Z^4] = 3(\Delta t)^2, \quad \text{Var}(Z^2) = 3(\Delta t)^2 - (\Delta t)^2 = 2(\Delta t)^2.$$

Donc :

$$\text{Var}(S_n) = 2 \sum_i (\Delta t_i)^2.$$

Or, lorsque $|\Pi_n| \rightarrow 0$:

$$\sum_i (\Delta t_i)^2 \leq |\Pi_n| \sum_i \Delta t_i = |\Pi_n| T \xrightarrow{n \rightarrow \infty} 0.$$

Ainsi :

$$\text{Var}(S_n) \rightarrow 0.$$

Par l'inégalité de Chebyshev :

$$\forall \varepsilon > 0, \quad \mathbb{P}(|S_n - T| > \varepsilon) \leq \frac{\text{Var}(S_n)}{\varepsilon^2} \xrightarrow{n \rightarrow \infty} 0.$$

Donc :

$$S_n \xrightarrow[n \rightarrow \infty]{\mathbb{P}} T,$$

et, en renforçant l'argument (partitions dyadiques + Borel–Cantelli),

$$[W]_t = t \quad \text{presque sûrement.}$$

Variation quadratique d'un processus d'Itô. Considérons une diffusion :

$$X_t = X_0 + \int_0^t a_s ds + \int_0^t b_s dW_s.$$

Sur un petit intervalle $[t_i, t_{i+1}]$:

$$\Delta X_i = X_{t_{i+1}} - X_{t_i} = \underbrace{\int_{t_i}^{t_{i+1}} a_s ds}_{\mathcal{O}(\Delta t_i)} + \underbrace{\int_{t_i}^{t_{i+1}} b_s dW_s}_{\mathcal{O}(\sqrt{\Delta t_i})}.$$

Le terme stochastique domine dans le carré :

$$(\Delta X_i)^2 \approx \left(\int_{t_i}^{t_{i+1}} b_s dW_s \right)^2.$$

Par isométrie d'Itô :

$$\mathbb{E} \left[\left(\int_{t_i}^{t_{i+1}} b_s dW_s \right)^2 \right] = \mathbb{E} \left[\int_{t_i}^{t_{i+1}} b_s^2 ds \right] \approx b_{t_i}^2 \Delta t_i.$$

Ainsi :

$$\sum_i (\Delta X_i)^2 \rightarrow \int_0^T b_s^2 ds.$$

On obtient rigoureusement :

$$[X]_t = \int_0^t b_s^2 ds.$$

Résumé.

- Pour le mouvement brownien : $[W]_t = t$.
- Pour une diffusion d'Itô :

$$dX_t = a_t dt + b_t dW_t \quad \Rightarrow \quad [X]_t = \int_0^t b_s^2 ds.$$

- La variation quadratique justifie les règles : $(dW_t)^2 = dt$, $dt dW_t = 0$, $dt^2 = 0$.

1.3.2 Lemme d'Itô (dérivation “for dummies” rigoureuse)

Soit un mouvement brownien $(W_t)_{t \geq 0}$ sur un espace probabilisé filtré $(\Omega, \mathcal{F}, (\mathcal{F}_t)_{t \geq 0}, \mathbb{P})$, et soit un processus d'Itô scalaire $(X_t)_{t \in [0, T]}$ de la forme :

$$dX_t = a(t, X_t) dt + b(t, X_t) dW_t,$$

où a et b sont des fonctions mesurables, suffisamment régulières, et adaptées. On se donne une fonction

$$f : [0, T] \times \mathbb{R} \rightarrow \mathbb{R}, \quad f \in C^{1,2},$$

c'est-à-dire f est C^1 en t et C^2 en x avec toutes ces dérivées continues.

On définit le processus

$$Y_t := f(t, X_t).$$

Le lemme d'Itô donne l'expression différentielle de (Y_t) .

Heuristique (idée de base). Considérons un petit incrément de temps $h > 0$ et notons $X_t = x$ pour fixer les idées. Sur l'intervalle $[t, t+h]$, on a formellement :

$$X_{t+h} - X_t \simeq a(t, x) h + b(t, x) \Delta W_t, \quad \Delta W_t := W_{t+h} - W_t,$$

avec $\Delta W_t \sim \mathcal{N}(0, h)$. En ordre de grandeur :

$$a(t, x) h = \mathcal{O}(h), \quad b(t, x) \Delta W_t = \mathcal{O}(\sqrt{h}).$$

On applique un développement de Taylor à deux variables à f autour de (t, x) :

$$\begin{aligned} f(t+h, X_{t+h}) &\approx f(t, x) + f_t(t, x) h + f_x(t, x) (X_{t+h} - x) \\ &\quad + \frac{1}{2} f_{xx}(t, x) (X_{t+h} - x)^2. \end{aligned}$$

En posant $\Delta X := X_{t+h} - X_t$, on obtient donc

$$\Delta f := f(t+h, X_{t+h}) - f(t, X_t) \approx f_t h + f_x \Delta X + \frac{1}{2} f_{xx} (\Delta X)^2.$$

Comportement du terme $(\Delta X)^2$ et rôle de la variation quadratique. Avec $\Delta X \simeq ah + b\Delta W_t$, on obtient

$$(\Delta X)^2 \simeq (ah + b\Delta W_t)^2 = a^2 h^2 + 2abh\Delta W_t + b^2(\Delta W_t)^2.$$

En termes d'ordre :

$$a^2 h^2 = \mathcal{O}(h^2), \quad 2abh\Delta W_t = \mathcal{O}(h^{3/2}), \quad b^2(\Delta W_t)^2 = \mathcal{O}(h).$$

Les deux premiers termes sont négligeables face à h lorsque $h \rightarrow 0$, tandis que le dernier terme est d'ordre h et donc *non négligeable*. Or la variation quadratique du brownien dit précisément que

$$(\Delta W_t)^2 \approx h$$

(en un sens probabiliste ou presque sûr via la définition de $[W]_t$). On retient donc heuristiquement :

$$(\Delta X)^2 \approx b(t, x)^2 h.$$

Substitution dans le développement de Taylor. En remplaçant ΔX et $(\Delta X)^2$ dans l'expression de Δf :

$$\Delta f \approx f_t h + f_x (ah + b\Delta W_t) + \frac{1}{2} f_{xx} b^2 h.$$

On peut réarranger les termes :

$$\Delta f \approx (f_t + af_x + \frac{1}{2}b^2 f_{xx}) h + bf_x \Delta W_t.$$

Lorsque $h \rightarrow 0$, on interprète :

$$\Delta f \sim df, \quad h \sim dt, \quad \Delta W_t \sim dW_t,$$

et on obtient formellement la forme différentielle :

$$df(t, X_t) = (f_t + af_x + \frac{1}{2}b^2 f_{xx})(t, X_t) dt + b(t, X_t) f_x(t, X_t) dW_t.$$

Forme rigoureuse via la variation quadratique. De manière plus rigoureuse, on écrit d'abord la version générale :

$$df(t, X_t) = f_t(t, X_t) dt + f_x(t, X_t) dX_t + \frac{1}{2} f_{xx}(t, X_t) d[X]_t,$$

où $[X]_t$ est la variation quadratique de X .

Avec

$$dX_t = a(t, X_t) dt + b(t, X_t) dW_t,$$

on sait que

$$[X]_t = \int_0^t b(s, X_s)^2 ds \quad \Rightarrow \quad d[X]_t = b(t, X_t)^2 dt.$$

En substituant dans la formule ci-dessus, on obtient :

$$df(t, X_t) = f_t dt + f_x(a dt + b dW_t) + \frac{1}{2} f_{xx} b^2 dt,$$

c'est-à-dire

$$df(t, X_t) = (f_t + af_x + \frac{1}{2}b^2 f_{xx})(t, X_t) dt + b(t, X_t) f_x(t, X_t) dW_t.$$

Forme intégrale. En intégrant de 0 à t :

$$\begin{aligned} f(t, X_t) &= f(0, X_0) + \int_0^t f_t(s, X_s) ds + \int_0^t f_x(s, X_s) dX_s + \frac{1}{2} \int_0^t f_{xx}(s, X_s) d[X]_s \\ &= f(0, X_0) + \int_0^t (f_t + af_x + \frac{1}{2}b^2 f_{xx})(s, X_s) ds + \int_0^t b(s, X_s) f_x(s, X_s) dW_s. \end{aligned}$$

Résumé. Pour un processus d'Itô

$$dX_t = a(t, X_t) dt + b(t, X_t) dW_t$$

et une fonction $f \in C^{1,2}$, le lemme d'Itô affirme que :

$$df(t, X_t) = (f_t + af_x + \frac{1}{2}b^2 f_{xx})(t, X_t) dt + b(t, X_t)f_x(t, X_t) dW_t.$$

La présence du terme $\frac{1}{2}b^2 f_{xx}$ provient directement de la variation quadratique du brownien, via le fait que $(dW_t)^2$ se comporte comme dt dans le calcul stochastique.

1.3.3 Application du lemme d'Itô à $\log S_t$

On considère le processus de prix suivant sous une mesure $\mathbb{P}$ quelconque :

$$dS_t = \mu S_t dt + \sigma S_t dW_t, \quad S_0 > 0.$$

On souhaite déterminer la dynamique de $X_t := \log S_t$ par le lemme d'Itô.

On pose

$$f(x) = \log x, \quad f'(x) = \frac{1}{x}, \quad f''(x) = -\frac{1}{x^2}.$$

En appliquant le lemme d'Itô à $f(S_t)$, avec $a(t, S_t) = \mu S_t$ et $b(t, S_t) = \sigma S_t$:

$$df(S_t) = f'(S_t) dS_t + \frac{1}{2}f''(S_t) d[S]_t.$$

Or la variation quadratique de S_t est

$$d[S]_t = (\sigma S_t)^2 dt = \sigma^2 S_t^2 dt.$$

Donc

$$\begin{aligned} d(\log S_t) &= \frac{1}{S_t}(\mu S_t dt + \sigma S_t dW_t) + \frac{1}{2} \left(-\frac{1}{S_t^2} \right) \sigma^2 S_t^2 dt \\ &= \left(\mu - \frac{1}{2}\sigma^2 \right) dt + \sigma dW_t. \end{aligned}$$

Sous la mesure risque-neutre $\mathbb{Q}$ (où le drift devient r), on obtient :

$$d(\log S_t) = \left(r - \frac{1}{2}\sigma^2 \right) dt + \sigma dW_t^{\mathbb{Q}}.$$

Cette forme est cruciale pour :

- expliciter la loi de S_T (lognormale),
- calculer les espérances risque-neutres dans la formule de Black-Scholes,
- effectuer des changements de variables (par exemple dans les modèles de vol locale).

1.3.4 Dérivation de la PDE de Black–Scholes

On se place sous la mesure risque-neutre $\mathbb{Q}$, où le sous-jacent suit :

$$dS_t = rS_t dt + \sigma S_t dW_t^{\mathbb{Q}},$$

avec r le taux sans risque constant.

Soit $V(t, S)$ le prix à la date t d'un payoff européen $\Phi(S_T)$. On suppose $V \in C^{1,2}$ et on applique le lemme d'Itô à $V(t, S_t)$.

On a :

$$dV(t, S_t) = V_t dt + V_S dS_t + \frac{1}{2} V_{SS} d[S]_t.$$

En substituant la dynamique de S_t :

$$dS_t = rS_t dt + \sigma S_t dW_t, \quad d[S]_t = (\sigma S_t)^2 dt,$$

on obtient :

$$\begin{aligned} dV(t, S_t) &= V_t dt + V_S(rS_t dt + \sigma S_t dW_t) + \frac{1}{2} V_{SS} \sigma^2 S_t^2 dt \\ &= (V_t + rS_t V_S + \frac{1}{2} \sigma^2 S_t^2 V_{SS}) dt + \sigma S_t V_S dW_t. \end{aligned}$$

On construit maintenant un portefeuille auto-finançant

$$\Pi_t = V(t, S_t) - \Delta_t S_t,$$

où Δ_t est une quantité d'unités du sous-jacent. On choisit

$$\Delta_t := V_S(t, S_t),$$

de sorte que le terme en dW_t disparaisse dans $d\Pi_t$.

En effet,

$$d\Pi_t = dV_t - \Delta_t dS_t.$$

On a :

$$dS_t = rS_t dt + \sigma S_t dW_t,$$

et

$$dV_t = (V_t + rS_t V_S + \frac{1}{2} \sigma^2 S_t^2 V_{SS}) dt + \sigma S_t V_S dW_t.$$

Donc :

$$\begin{aligned}
d\Pi_t &= \left[V_t + rS_t V_S + \frac{1}{2} \sigma^2 S_t^2 V_{SS} \right] dt + \sigma S_t V_S dW_t - V_S(rS_t dt + \sigma S_t dW_t) \\
&= \left[V_t + rS_t V_S + \frac{1}{2} \sigma^2 S_t^2 V_{SS} - rS_t V_S \right] dt \\
&= \left[V_t + \frac{1}{2} \sigma^2 S_t^2 V_{SS} \right] dt.
\end{aligned}$$

Ainsi, le portefeuille Π_t est *sûr* (plus de terme stochastique). Par absence d'arbitrage, un portefeuille sans risque doit croître au taux r :

$$d\Pi_t = r\Pi_t dt = r(V(t, S_t) - V_S(t, S_t)S_t) dt.$$

En identifiant les coefficients de dt :

$$V_t + \frac{1}{2} \sigma^2 S_t^2 V_{SS} = r(V - S_t V_S).$$

Autrement dit :

$$V_t + \frac{1}{2} \sigma^2 S^2 V_{SS} + rS V_S - rV = 0.$$

C'est la **PDE de Black–Scholes** pour tout (t, S) dans $[0, T) \times (0, +\infty)$, avec condition terminale :

$$V(T, S) = \Phi(S).$$

Cette PDE, couplée à la condition de terminale et aux conditions de croissance appropriées, caractérise de façon unique le prix d'option européen dans le cadre Black–Scholes.

1.3.5 Application : résolution explicite de la PDE de Black–Scholes

On considère la PDE de Black–Scholes pour le prix $V(t, S)$ d'un call européen de strike K et maturité T :

$$V_t + \frac{1}{2} \sigma^2 S^2 V_{SS} + rS V_S - rV = 0, \quad 0 \leq t < T, \quad S > 0,$$

avec condition terminale :

$$V(T, S) = (S - K)^+.$$

L'objectif est de retrouver la formule fermée de Black–Scholes à partir de cette PDE.

Changement de variables. On introduit les variables :

$$\tau := T - t \quad (\text{temps à maturité}), \quad x := \ln S.$$

On note $u(\tau, x) := V(t, S) = V(T - \tau, e^x)$. On calcule les dérivées :

$$V_t = -u_\tau, \quad V_S = \frac{1}{S}u_x, \quad V_{SS} = \frac{1}{S^2}(u_{xx} - u_x).$$

En substituant dans la PDE de Black–Scholes :

$$-u_\tau + \frac{1}{2}\sigma^2 S^2 \frac{1}{S^2}(u_{xx} - u_x) + rS \frac{1}{S}u_x - ru = 0.$$

Donc :

$$-u_\tau + \frac{1}{2}\sigma^2(u_{xx} - u_x) + ru_x - ru = 0,$$

i.e.

$$u_\tau = \frac{1}{2}\sigma^2 u_{xx} + \left(r - \frac{1}{2}\sigma^2\right)u_x - ru.$$

Élimination du terme en u_x et en u . On pose

$$u(\tau, x) = e^{\alpha x + \beta \tau} w(\tau, x),$$

et on choisit α, β pour transformer l'équation en *équation de la chaleur* pour w .

On calcule :

$$u_x = e^{\alpha x + \beta \tau}(\alpha w + w_x), \quad u_{xx} = e^{\alpha x + \beta \tau}(\alpha^2 w + 2\alpha w_x + w_{xx}),$$

$$u_\tau = e^{\alpha x + \beta \tau}(\beta w + w_\tau).$$

En substituant dans l'équation pour u :

$$\beta w + w_\tau = \frac{1}{2}\sigma^2(\alpha^2 w + 2\alpha w_x + w_{xx}) + \left(r - \frac{1}{2}\sigma^2\right)(\alpha w + w_x) - rw.$$

On regroupe les termes en w , w_x , w_{xx} :

$$w_\tau = \frac{1}{2}\sigma^2 w_{xx} + \left(\sigma^2 \alpha + r - \frac{1}{2}\sigma^2\right)w_x + \left(\frac{1}{2}\sigma^2 \alpha^2 + (r - \frac{1}{2}\sigma^2)\alpha - r - \beta\right)w.$$

Pour obtenir une équation de la chaleur pure :

$$w_\tau = \frac{1}{2}\sigma^2 w_{xx},$$

il faut que le coefficient de w_x soit nul et que celui de w soit nul, d'où :

$$\sigma^2 \alpha + r - \frac{1}{2}\sigma^2 = 0, \quad \frac{1}{2}\sigma^2 \alpha^2 + (r - \frac{1}{2}\sigma^2)\alpha - r - \beta = 0.$$

On choisit :

$$\alpha = \frac{1}{2} - \frac{r}{\sigma^2},$$

puis

$$\beta = -\frac{1}{2}\sigma^2\alpha^2 - (r - \frac{1}{2}\sigma^2)\alpha + r.$$

Avec ce choix, w satisfait :

$$w_\tau = \frac{1}{2}\sigma^2 w_{xx},$$

c'est-à-dire l'équation de la chaleur classique.

Condition initiale. La condition terminale $V(T, S) = (S - K)^+$ se traduit en condition initiale pour w :

$$u(0, x) = V(T, e^x) = (e^x - K)^+,$$

$$w(0, x) = e^{-\alpha x} u(0, x) = e^{-\alpha x} (e^x - K)^+.$$

L'équation de la chaleur se résout par convolution avec le noyau gaussien. On obtient au final, après transformation inverse, la formule de Black-Scholes :

$$C_0 = S_0 N(d_1) - K e^{-rT} N(d_2),$$

avec

$$d_{1,2} = \frac{\ln(S_0/K) + (r \pm \frac{1}{2}\sigma^2)T}{\sigma\sqrt{T}}.$$

1.3.6 Arbres binomiaux (Cox-Ross-Rubinstein) : exercice et convergence

Principe. Un arbre binomial approxime l'évolution de S_t par une marche à pas discrets : sur un pas Δt , le sous-jacent passe de S à uS ("up") ou dS ("down"). Le schéma recombinaison CRR choisit classiquement

$$u = e^{\sigma\sqrt{\Delta t}}, \quad d = e^{-\sigma\sqrt{\Delta t}} = \frac{1}{u}.$$

Sous l'absence d'arbitrage et en présence d'un portage $(r - q)$, la probabilité risque-neutre est

$$p = \frac{e^{(r-q)\Delta t} - d}{u - d},$$

et la valeur se calcule par récurrence :

$$V(t, S) = e^{-r\Delta t} \left(p V(t + \Delta t, uS) + (1 - p) V(t + \Delta t, dS) \right),$$

avec condition terminale $V(T, S) = \Phi(S)$.

Exercice anticipé (options américaines). Pour une option américaine, le principe est une comparaison *valeur d'exercice* vs *valeur de continuation* :

$$V(t, S) = \max(\Phi_{\text{ex}}(S), V_{\text{cont}}(t, S)),$$

ce qui met en évidence la frontière d'exercice (free boundary) et justifie les algorithmes d'induction arrière.

Convergence et limites. Sous des hypothèses usuelles, le prix CRR converge vers Black–Scholes quand $\Delta t \rightarrow 0$ (théorème de Donsker, convergence faible vers le brownien géométrique). Les limites sont bien connues : complexité qui croît avec le nombre de facteurs, sensibilité aux hypothèses (dividendes, taux), et traitement non trivial des barrières/path-dependence (même si des extensions existent).

1.3.7 Monte Carlo : estimateurs, erreur et réduction de variance

Estimateur. Dans un cadre risque-neutre, le prix d'un payoff européen $\Phi(S_T)$ s'écrit $V_0 = e^{-rT} \mathbb{E}^{\mathbb{Q}}[\Phi(S_T)]$. Monte Carlo approxime cette espérance par

$$\hat{V}_0 = e^{-rT} \frac{1}{N} \sum_{n=1}^N \Phi(S_T^{(n)}),$$

où $S_T^{(n)}$ sont des trajectoires simulées sous $\mathbb{Q}$.

Erreur statistique. Par le théorème central limite, $\sqrt{N}(\hat{V}_0 - V_0)$ converge en loi vers une gaussienne de variance $\text{Var}^{\mathbb{Q}}(\Phi(S_T))$, d'où une erreur typiquement en $\mathcal{O}(N^{-1/2})$. Une erreur supplémentaire provient de la discrétisation en temps lorsqu'on simule une EDS (biais en Δt).

Réduction de variance. On peut réduire la variance à N fixé via : variables antithétiques, *control variates* (par exemple utiliser une option à prix fermé comme contrôle), importance sampling, stratification ou quasi-MC. Ces techniques modifient l'estimateur sans changer la quantité ciblée.

Greeks. Les sensibilités se calculent par différenciation (pathwise), par *likelihood ratio* (score function), ou par différences finies (*bump and revalue*). Les payoffs non lisses (digital, barrières) demandent des précautions : approximation lissée ou estimateurs adaptés.

Limites. Monte Carlo est naturellement adapté aux payoffs path-dependent et à la grande dimension, mais il est lent sur des quantités rares (queues) et sur des options à exercice anticipé : pour ces dernières, des méthodes comme le Least-Squares Monte Carlo (LSMC) introduisent une régression et un risque d'approximation.

1.3.8 Fonctions caractéristiques, inversion de Fourier et FFT (Carr–Madan)

Idée. Lorsque la fonction caractéristique du log-prix est connue, $\phi_T(u) = \mathbb{E}[e^{iu \ln S_T}]$, on peut représenter des prix européens par inversion de Fourier. L'avantage est de remplacer des intégrales

difficiles par des intégrales oscillantes contrôlées, voire par une FFT.

Cadre Carr–Madan. Carr et Madan introduisent un *damping* pour rendre la transformée intégrable : en notant $k = \ln K$ et $c_\alpha(k) = e^{\alpha k} C(k)$ avec $\alpha > 0$, la transformée de c_α s’exprime explicitement en fonction de ϕ_T . Une discrétisation sur une grille de fréquences permet ensuite de calculer simultanément de nombreux prix de strikes par FFT.

Choix du damping et stabilité numérique. Le choix de α contrôle l’intégrabilité et la stabilité : trop faible, l’intégrale diverge ; trop fort, on amplifie des erreurs numériques. D’autres sources d’erreur proviennent de la troncature, de l’aliasing et des pas de grille. Une validation théorique consiste à contrôler la convergence en augmentant les bornes d’intégration et en raffinant les grilles.

Portée. Les méthodes de Fourier/FFT sont particulièrement adaptées aux modèles à structure affine (Heston, Bates) et aux modèles à sauts. Elles ciblent principalement des payoffs européens ; les extensions à l’américain ou à des exotiques requièrent des techniques supplémentaires.

Lien avec le projet *PaperTradingApp*. Dans le projet, l’intérêt théorique de ces méthodes est double : (i) disposer d’une famille de pricers cohérents entre modèles (diffusion, volatilité stochastique, sauts) via la même grammaire “fonction caractéristique + inversion”, et (ii) comparer les compromis précision/coût entre PDE, arbres, Monte Carlo et Fourier, sans dépendre d’une implémentation particulière.

1.3.9 Modèle de Heston et pricing semi-analytique

On considère désormais le modèle de Heston, dans lequel le sous-jacent S_t et la variance instantanée v_t suivent la dynamique (sous la mesure risque-neutre $\mathbb{Q}$) :

$$\begin{cases} dS_t = rS_t dt + \sqrt{v_t} S_t dW_t^{(1)}, \\ dv_t = \kappa(\theta - v_t) dt + \xi \sqrt{v_t} dW_t^{(2)}, \end{cases} \quad dW_t^{(1)} dW_t^{(2)} = \rho dt.$$

Où :

- $\kappa > 0$: vitesse de retour vers la moyenne,
- $\theta > 0$: variance de long terme,
- $\xi > 0$: vol-of-vol,
- $\rho \in [-1, 1]$: corrélation entre prix et variance.

Objectif. Pour un call européen de strike K et maturité T , on cherche :

$$C_0 = e^{-rT} \mathbb{E}^{\mathbb{Q}}[(S_T - K)^+].$$

Dans le modèle de Heston, le prix admet une formule semi-fermée en termes de transformée de Fourier, grâce au caractère affine du modèle.

Changement de variable. On introduit le log-prix :

$$X_t = \ln S_t.$$

En appliquant le lemme d'Itô à X_t (comme dans la section précédente), on obtient :

$$dX_t = \left(r - \frac{1}{2}v_t\right) dt + \sqrt{v_t} dW_t^{(1)}.$$

Le couple (X_t, v_t) forme un processus affine de dimension 2.

Fonction caractéristique. On considère la fonction caractéristique du log-prix sous $\mathbb{Q}$:

$$\phi(u; t) := \mathbb{E}^{\mathbb{Q}}[e^{iuX_t} \mid X_0, v_0].$$

Le caractère affine du modèle implique que la fonction caractéristique s'écrit sous la forme :

$$\phi(u; t) = \exp\left(C(u, t) + D(u, t)v_0 + iuX_0\right),$$

où $C(u, t)$ et $D(u, t)$ satisfont des équations différentielles ordinaires de type Riccati.

Plus précisément, on montre que :

$$\begin{cases} \frac{\partial D}{\partial t}(u, t) = \frac{1}{2}\xi^2 D(u, t)^2 + (\rho\xi iu - \kappa)D(u, t) - \frac{1}{2}(u^2 + iu), \\ \frac{\partial C}{\partial t}(u, t) = \kappa\theta D(u, t) + iur, \end{cases}$$

avec conditions initiales $C(u, 0) = 0$, $D(u, 0) = 0$.

La résolution explicite de ces EDO (voir Section 1.8.4) donne des expressions fermées pour C et D , d'où une expression fermée de $\phi(u; T)$.

Formule de pricing (intégrale de Fourier). Le prix du call peut alors s'écrire comme :

$$C_0 = S_0 P_1 - K e^{-rT} P_2,$$

où

$$P_j = \frac{1}{2} + \frac{1}{\pi} \int_0^{+\infty} \Re\left(\frac{e^{-iu \ln K} \phi_j(u)}{iu}\right) du, \quad j = 1, 2,$$

et $\phi_j(u)$ sont des variantes de la fonction caractéristique, obtenues en choisissant des arguments complexes différents (voir la dérivation classique de Heston).

Remarque. La dérivation complète des expressions fermées de $C(u, t)$, $D(u, t)$ et des intégrales de pricing est fournie en Section 1.8.4. Elle repose sur la résolution explicite des EDO de Riccati et sur l'utilisation de la transformée de Fourier inversée.

1.3.10 Surface de volatilité implicite et calibration de modèles

La volatilité implicite est définie comme la valeur de σ qui, insérée dans la formule de Black–Scholes, reproduit le prix de marché d'un call européen :

$$C^{BS}(S_0, K, r, \sigma, T) = C^{\text{mkt}}(K, T).$$

En inversant cette relation pour chaque strike K et chaque maturité T , on obtient la *surface de volatilité implicite* :

$$(K, T) \longmapsto \sigma_{\text{impl}}(K, T).$$

Contraintes d'arbitrage sur la surface. Pour qu'une surface de volatilité soit compatible avec l'absence d'arbitrage statique, certaines conditions doivent être satisfaites.

— **Monotonie en maturité (pas d'arbitrage de calendrier) :**

$$T_2 > T_1 \quad \Rightarrow \quad C(K, T_2) \geq C(K, T_1).$$

— **Convexité en strike (pas d'arbitrage butterfly) :**

$$\frac{\partial^2 C}{\partial K^2}(K, T) \geq 0.$$

Cette condition assure l'existence d'une densité risque-neutre positive :

$$\frac{\partial^2 C}{\partial K^2}(K, T) = e^{-rT} f_{S_T}^{\mathbb{Q}}(K).$$

Ces contraintes doivent être vérifiées par toute surface interpolée/paramétrée avant calibration.

Calibration de modèles sur la surface de volatilité. Un modèle paramétré θ (par exemple Heston, SABR, rough volatility, etc.) génère une surface implicite de volatilité :

$$\sigma_{\text{mod}}(K, T; \theta).$$

La calibration consiste à choisir θ pour que cette surface reproduise au mieux la surface observée sur le marché. Le problème d'optimisation s'écrit classiquement :

$$\theta^* = \arg \min_{\theta} \sum_{(K, T) \in \mathcal{G}} w_{K, T} \left(\sigma_{\text{mod}}(K, T; \theta) - \sigma_{\text{impl}}^{\text{mkt}}(K, T) \right)^2,$$

où :

- $\mathcal{G}$ est la grille de strikes et de maturités cotés,
- $w_{K,T}$ sont des poids reflétant volumes, liquidité ou importance stratégique.

Calibration de modèles stochastiques (exemple : Heston). Dans le modèle de Heston, les paramètres

$$\theta = (\kappa, \theta, \xi, \rho, v_0)$$

sont ajustés en évaluant les prix d'options via la formule semi-fermée basée sur la fonction caractéristique. Pour chaque (K, T) , on en déduit

$$\sigma_{\text{mod}}(K, T; \theta) \text{ telle que } C^{BS}(S_0, K, r, \sigma_{\text{mod}}, T) = C^{\text{Heston}}(S_0, K, r, \theta, T).$$

La calibration est un problème non convexe : on utilise généralement des méthodes de type multi-start, recuit simulé, CMA-ES, ou une descente locale après une initialisation robuste.

Calibration rough volatility / rBergomi. Dans les modèles de volatilité rugueuse, la variance suit une dynamique fractionnaire. Les paramètres typiques sont $(H, \eta, \xi_0(t))$, avec $H < 1/2$. La valorisation s'effectue via Monte Carlo rapide (hybrid schemes), puis une minimisation analogue au cas Heston :

$$\theta^* = \arg \min_{\theta} \sum_{(K,T) \in \mathcal{G}} (\sigma_{\text{mod}}(K, T; \theta) - \sigma_{\text{impl}}^{\text{mkt}}(K, T))^2.$$

Synthèse.

- La surface de volatilité implicite est la représentation empirique de la distribution future du sous-jacent perçue par le marché.
- Les contraintes $\partial_K^2 C \geq 0$ et $C(K, T_2) \geq C(K, T_1)$ doivent être respectées pour éviter l'arbitrage statique.
- La calibration consiste à résoudre un problème d'optimisation sur les paramètres du modèle afin de reproduire au mieux la surface de marché.
- Les modèles stochastiques (Heston, rough volatility) sont calibrés via des méthodes globales puis locales, en exploitant leur fonction caractéristique ou des schémas Monte Carlo rapides.

Surrogates (réseaux) pour accélérer la calibration. Dans de nombreux modèles, le goulot d'étranglement est le *coût* d'évaluation de la carte $(K, T) \mapsto C_{\theta}(K, T)$ (ou de $\sigma_{\text{mod}}(K, T; \theta)$) à chaque itération d'optimisation. L'idée d'un **surrogate** est de construire une approximation rapide

$$(K, T, \theta) \mapsto \hat{C}(K, T; \theta) \quad \text{ou} \quad (K, T, \theta) \mapsto \hat{\sigma}_{\text{imp}}(K, T; \theta),$$

par apprentissage supervisé sur des données synthétiques générées par le modèle lui-même. Le fondement théorique est l'approximation universelle : sous des hypothèses de régularité, un réseau suffisamment riche peut approximer une fonction continue sur un compact.

Intérêt, limites et validation. Un surrogate peut servir à (i) initialiser une calibration (warm start), (ii) explorer rapidement la sensibilité à des paramètres, (iii) déployer des diagnostics en quasi temps réel. En revanche, les risques sont conceptuellement clairs : biais d'approximation, extrapolation hors du domaine d'apprentissage, et possible violation d'absence d'arbitrage. Une bonne pratique théorique est d'imposer des *contraintes* (par exemple convexité en K) ou de projeter l'approximation sur un ensemble arbitrage-free, et de valider sur un jeu out-of-sample en contrôlant (a) l'erreur de prix/vol, (b) la stabilité des paramètres obtenus, et (c) la robustesse à des perturbations de données (stress, bid-ask, maturités manquantes).

1.3.11 Modèles avancés : SABR et Équations de Volterra

Dans le cadre de la modélisation des smiles de volatilité, deux familles de modèles occupent une place particulière : les modèles SABR et les modèles à noyaux de Volterra. Ils fournissent des représentations plus flexibles des dynamiques de volatilité observées sur les marchés.

Modèle SABR. Le modèle SABR (Stochastic Alpha Beta Rho), introduit par Hagan et al., est largement utilisé en taux d'intérêt pour reproduire les smiles de volatilité des swaptions. Sous la mesure risque-neutre, le forward F_t évolue selon :

$$\begin{cases} dF_t = \alpha_t F_t^\beta dW_t^{(1)}, \\ d\alpha_t = \nu \alpha_t dW_t^{(2)}, \\ dW_t^{(1)} dW_t^{(2)} = \rho dt. \end{cases}$$

Les paramètres ont les interprétations suivantes :

- $\beta \in [0, 1]$: contrôle la forme du smile (lognormal, CEV, normal),
- $\nu > 0$: vol-of-vol, responsable de la convexité du smile,
- ρ : corrélation, pilote le skew,
- α_t : volatilité instantanée du forward.

Une approximation asymptotique (formule de Hagan) fournit une expression fermée de la volatilité implicite :

$$\sigma_{\text{SABR}}^{\text{impl}}(K) = \frac{\alpha_0}{(F_0 K)^{\frac{1-\beta}{2}}} [1 + \text{Corrections}_1(\nu, \rho, \beta, K)],$$

ce qui permet une calibration directe du smile. Cette formule est obtenue par expansion asymptotique en ν ; une dérivation pas à pas est donnée en Section 6.

Modèles de Volterra et volatilité rugueuse. Les modèles Volterra-génériques considèrent des dynamiques à mémoire longue :

$$dX_t = \left(\int_0^t K(t-s) g(X_s) ds \right) dt + \left(\int_0^t K(t-s) h(X_s) ds \right) dW_t,$$

où K est un noyau de Volterra causal. Le choix du noyau détermine la régularité et la structure de mémoire du modèle.

Un cas fondamental est la **volatilité rugueuse (rough volatility)**, fondée sur un *fractional Brownian motion* (fBM) de paramètre de Hurst $H < 1/2$:

$$B_t^H = \frac{1}{\Gamma(H + \frac{1}{2})} \int_0^t (t-s)^{H-\frac{1}{2}} dW_s.$$

Dans le modèle **rBergomi**, la variance suit :

$$v_t = \xi_0(t) \exp\left(\eta B_t^H - \frac{1}{2}\eta^2 t^{2H}\right),$$

où η est la vol-of-vol rugueuse et H régit la régularité du processus.

Les modèles rough permettent de reproduire fidèlement :

- le skew court terme des marchés equity,
- la persistance et la mémoire longue de la variance,
- les déformations fines de la surface de vol.

Les détails de construction du mouvement brownien fractionnaire, des noyaux de Volterra et des schémas de simulation sont développés plus loin (Sections 1.8.2 et 5); on se limite ici aux définitions, à l'intuition et aux implications pour la géométrie court terme du smile.

1.3.12 Lien avec le projet *PaperTradingApp*

Le projet s'appuie sur ces briques pour articuler : (i) un pricing “de référence” (Black–Scholes) qui sert de point de comparaison, (ii) des méthodes numériques (arbres, Monte Carlo, Fourier) nécessaires dès que l'on traite des exotiques, des exercices anticipés ou des modèles non résolubles en forme fermée, et (iii) un continuum entre *prix* et *surface* via l'inversion en volatilité implicite. Le lien essentiel avec la plateforme est la capacité à justifier le choix d'une méthode (précision, coût, hypothèses) et à contrôler les erreurs (discrétisation, troncature, instabilité de calibration) de manière théorique.

1.4 Hedging et Greeks

1.4.1 Greeks

Les Greeks quantifient les sensibilités du prix d'un dérivé aux différents paramètres de marché. Pour une option de prix $V(t, S)$:

Delta.

$$\Delta = \frac{\partial V}{\partial S}.$$

Sensibilité directionnelle à une variation du sous-jacent. Pour un call : $0 < \Delta < 1$; pour un put : $-1 < \Delta < 0$.

Gamma.

$$\Gamma = \frac{\partial^2 V}{\partial S^2}.$$

Mesure la convexité du prix. Un portefeuille long gamma bénéficie des variations du sous-jacent.

Vega.

$$\text{Vega} = \frac{\partial V}{\partial \sigma}.$$

Sensibilité à la volatilité implicite. Maximum autour de l'ATM.

Theta.

$$\Theta = \frac{\partial V}{\partial t}.$$

Sensibilité à l'écoulement du temps. Les options vanilles longues sont généralement $\Theta < 0$.

Rho.

$$\rho_{\text{IR}} = \frac{\partial V}{\partial r}.$$

Sensibilité au taux sans risque, importante pour FX / taux ; on la note ρ_{IR} pour éviter la confusion avec la corrélation ρ .

1.4.2 Hedging

Delta-hedging. On construit un portefeuille :

$$\Pi_t = V(t, S_t) - \Delta_t S_t.$$

En choisissant $\Delta_t = V_S(t, S_t)$, le terme aléatoire dW_t disparaît de la dynamique de Π_t . Cela conduit au portefeuille localement sans risque utilisé dans la dérivation de Black-Scholes.

Gamma–Vega hedging. Une seule option ne permet pas de neutraliser simultanément Γ et Vega. On combine deux options $V^{(1)}$ et $V^{(2)}$ via :

$$\begin{cases} x\Gamma^{(1)} + y\Gamma^{(2)} = 0, \\ x\text{Vega}^{(1)} + y\text{Vega}^{(2)} = 0, \end{cases}$$

pour construire un portefeuille insensible aux variations de volatilité et de convexité.

1.4.3 Dérivation du modèle de Black–Scholes par delta–hedging

On part de la dynamique du sous-jacent :

$$dS_t = \mu S_t dt + \sigma S_t dW_t.$$

Le prix $V(t, S_t)$ d’une option européenne vérifie (par développement stochastique) :

$$dV_t = \left(V_t + \mu S_t V_S + \frac{1}{2} \sigma^2 S_t^2 V_{SS} \right) dt + \sigma S_t V_S dW_t.$$

Portefeuille de couverture. On considère :

$$\Pi_t = V(t, S_t) - \Delta_t S_t.$$

Sa variation :

$$d\Pi_t = dV_t - \Delta_t dS_t.$$

Après substitution :

$$\begin{aligned} d\Pi_t &= \left(V_t + \mu S_t V_S + \frac{1}{2} \sigma^2 S_t^2 V_{SS} \right) dt - \Delta_t \mu S_t dt \\ &\quad + \sigma S_t (V_S - \Delta_t) dW_t. \end{aligned}$$

Élimination du risque. On impose que le terme en dW_t disparaisse :

$$V_S - \Delta_t = 0 \implies \Delta_t = V_S.$$

Le portefeuille devient alors localement sans risque :

$$d\Pi_t = \left(V_t + \frac{1}{2} \sigma^2 S_t^2 V_{SS} \right) dt.$$

Absence d’arbitrage : taux sans risque. Un portefeuille sans risque doit croître au taux r :

$$d\Pi_t = r \Pi_t dt = r(V - S V_S) dt.$$

On obtient donc :

$$V_t + \frac{1}{2}\sigma^2 S^2 V_{SS} = r(V - SV_S).$$

PDE de Black–Scholes. En réarrangeant :

$$V_t + \frac{1}{2}\sigma^2 S^2 V_{SS} + rSV_S - rV = 0.$$

Avec condition terminale :

$$V(T, S) = (S - K)^+,$$

on retrouve la formule fermée de Black–Scholes :

$$C_0 = S_0 N(d_1) - Ke^{-rT} N(d_2),$$

avec

$$d_{1,2} = \frac{\ln(S_0/K) + (r \pm \frac{1}{2}\sigma^2)T}{\sigma\sqrt{T}}.$$

Cette dérivation illustre que la formule de Black–Scholes provient directement du principe fondamental : *un portefeuille delta-hedgé ne doit pas permettre d'arbitrage.*

1.4.4 Couverture et décision séquentielle : erreurs, coûts et formulation MDP

Erreurs de couverture (discrétisation et risque de modèle). Dans Black–Scholes frictionless, une couverture continue en delta réplique le payoff. En pratique, la couverture est *discrète* et le modèle est *approximatif*. L'erreur de couverture à maturité peut se définir comme

$$\varepsilon_T := V_T^{\text{couvert}} - \Phi(S_T),$$

et s'interprète comme la partie non répliquée (variance réalisée différente de la variance modèle, sauts, volatilité stochastique, smile dynamics). Un message clé est que l'exposition à la convexité (Γ) rend la couverture sensible à la variation quadratique réelle du sous-jacent.

Smile dynamics et couverture multi-Greeks. Hedger seulement le delta suppose implicitement que la dynamique de volatilité est “intégrée” dans le modèle. Dès que l'on observe un smile/skew, la question de la dynamique du smile devient centrale (hypothèses du type “sticky strike” vs “sticky delta”). Dans un cadre incomplet, une couverture plus riche vise à gérer des expositions $\Delta/\Gamma/\nu$ en combinant sous-jacent et options/liquidités, au prix d'un risque résiduel et d'une dépendance au modèle.

Coûts de transaction. Les coûts (bid–ask, impact) rendent la couverture plus “inertielle” : un ajustement fréquent réduit le risque mais augmente les coûts. Théoriquement, cela se traduit par

un compromis à optimiser, et par une modification de la valeur “répliquante” (par exemple via des corrections effectives de volatilité dans certains cadres idéalisés).

Formulation MDP du hedging. On peut formaliser la couverture comme un *Markov Decision Process* : l'état s_t résume l'information utile (temps restant, spot, indicateurs de volatilité, position et Greeks), l'action a_t définit l'ajustement de portefeuille, et la récompense pénalise simultanément l'erreur et les coûts, par exemple sous la forme

$$R_{t \rightarrow t+\Delta}(s_t, a_t) = \text{PnL}_{t \rightarrow t+\Delta} - \text{coûts} - \lambda_{\text{risk}} \text{risque}.$$

Cette écriture rend explicite le compromis *risque/coût* et la non-stationnarité (changements de régime, déformation du smile).

Ouverture RL et validation. Des algorithmes de RL (Q-learning, DQN, PPO) peuvent alors approximer une politique de couverture. Au niveau théorique, la convergence est bien comprise dans le cas tabulaire sous hypothèses fortes ; avec approximation de fonctions, la stabilité devient une question centrale (sur-apprentissage, dérives de distribution, non-stationnarité). Une validation rigoureuse doit être out-of-sample, inclure des stress tests (spot/vol/taux), et rapporter la sensibilité aux coûts et à la qualité des données.

Lien avec le projet *PaperTradingApp*. Cette formalisation relie directement : (i) les Greeks et erreurs de couverture, (ii) les contraintes de marché (coûts, liquidité), et (iii) une boucle de décision séquentielle. Elle fournit un cadre conceptuel pour comparer une couverture “règle” (delta/vega) à une couverture issue d'une politique optimisée, sans présumer de résultats empiriques.

1.5 Taux & courbes de taux

1.5.1 Taux zéro-coupon et courbe des taux

Le prix d'un zéro-coupon de maturité T est noté $P(0, T)$: c'est la valeur aujourd'hui d'un instrument qui versera exactement 1 unité à la date T .

Le taux zéro-coupon (capitalisation continue) est défini par :

$$P(0, T) = e^{-R(0, T)T}, \quad R(0, T) := -\frac{1}{T} \ln P(0, T).$$

La fonction :

$$T \mapsto R(0, T)$$

est appelée *courbe des taux spots*.

1.5.2 Facteurs d'actualisation (Discount Factors)

Le facteur d'actualisation associé à la date T est :

$$D(0, T) = P(0, T) = e^{-R(0, T)T}.$$

Pour un paiement certain C reçu à la date T , la valeur actuelle est :

$$VA = C D(0, T).$$

Ces facteurs constituent la base du calcul de la valeur de tous les flux futurs (obligations, swaps, cash-flows divers).

1.5.3 Taux forward instantané

Le *taux forward instantané* $f(0, T)$ est le taux d'intérêt implicite pour un emprunt infinitésimal entre les dates T et $T + dT$, déduit à partir du prix des zéro-coupons.

Il est défini par :

$$f(0, T) := -\frac{\partial}{\partial T} \ln P(0, T).$$

On en déduit :

$$P(0, T) = \exp\left(-\int_0^T f(0, u) du\right).$$

La quantité $f(0, T)$ peut être vue comme la *densité instantanée* du taux d'actualisation. Elle joue un rôle central dans les modèles de taux de type Heath–Jarrow–Morton (HJM), où la dynamique de $f(t, T)$ détermine l'ensemble de la structure par terme.

Dans la pratique, le taux forward instantané est approché en différenciant numériquement les discount factors bootstrappés.

1.5.4 Construction de la courbe (bootstrapping)

La courbe des taux zéro-coupon n'est pas directement observable sur le marché. Les marchés cotent des instruments liquides à différentes maturités (dépôts interbancaires, FRAs, futures, swaps IRS). Le *bootstrapping* consiste à reconstruire de manière cohérente les facteurs d'actualisation $P(0, T)$ à partir de ces instruments.

1. Instruments courts (dépôts). Pour les dépôts de maturité T (typiquement ≤ 1 an), on connaît le taux simple $L(0, T)$. On en déduit directement :

$$P(0, T) = \frac{1}{1 + L(0, T)T}.$$

2. FRAs et futures. Les contrats FRA (Forward Rate Agreement) donnent les taux forward implicites sur une période future $[T_1, T_2]$. Leur prix impose la relation :

$$1 = P(0, T_1) (1 + F(0; T_1, T_2)(T_2 - T_1)) P(0, T_2)^{-1}.$$

Ainsi :

$$P(0, T_2) = \frac{P(0, T_1)}{1 + F(0; T_1, T_2)(T_2 - T_1)}.$$

Les futures sur taux court (Eurodollar, SOFR futures, Euribor futures) permettent d'extraire des taux forward similaires via des conventions d'ajustement.

3. Swaps IRS (maturités longues). Pour un swap de maturité T_n et flux semestriels, on observe le taux swap S_n tel que le swap ait une valeur initiale nulle.

La jambe fixe vaut :

$$\text{Fixe} = S_n \sum_{k=1}^n \alpha_k P(0, T_k),$$

où α_k est la fraction de jour (Act/360, 30/360, etc.).

La jambe flottante vaut :

$$\text{Flottante} = 1 - P(0, T_n).$$

Comme $\text{Fixe} = \text{Flottante}$, on obtient :

$$1 - P(0, T_n) = S_n \sum_{k=1}^n \alpha_k P(0, T_k).$$

Les facteurs $P(0, T_k)$ pour $k < n$ sont déjà connus par bootstrapping (récursivité), ce qui permet d'obtenir $P(0, T_n)$.

4. Interpolation. Une fois les $P(0, T_k)$ obtenus sur un ensemble discret de maturités, on construit une courbe continue via une interpolation :

- sur les taux forwards instants $f(0, T)$,
- ou sur les discount factors,
- en utilisant des splines monotones ou Hermite préservant la convexité,
- en veillant à éviter les violations d'arbitrage (monotonie des discount factors et convexité des prix d'option).

5. Courbe finale. La courbe complète des facteurs d'actualisation est donnée par :

$$P(0, T) = \exp\left(-\int_0^T f(0, u) du\right),$$

où $f(0, T)$ est obtenu par dérivation numérique ou interpolation.

Cette courbe sert de base à toute valorisation d'instruments à taux fixe, flottant ou dérivés (IRS, cap/floor, swaption, CMS, etc.).

1.5.5 Paramétrisation Nelson–Siegel : niveau, pente, courbure

Objectif. Le bootstrapping fournit des facteurs $P(0, T_k)$ sur des maturités discrètes. Pour interpoler et surtout *extrapoler* de façon lisse et interprétable, on utilise souvent des familles paramétriques. Le modèle de Nelson–Siegel (NS) est un standard car il décompose la courbe en composantes “niveau/pente/courbure”.

Forme (taux zéro). Une écriture courante du taux zéro continu $y(0, T)$ est :

$$y(0, T) = \beta_0 + \beta_1 \frac{1 - e^{-T/\tau}}{T/\tau} + \beta_2 \left(\frac{1 - e^{-T/\tau}}{T/\tau} - e^{-T/\tau} \right),$$

où $\tau > 0$ contrôle la vitesse de décroissance des facteurs.

Interprétation.

- β_0 (**niveau**) gouverne le niveau de long terme (quand $T \rightarrow \infty$).
- β_1 (**pente**) affecte surtout le court terme ; son effet décroît avec T .
- β_2 (**courbure**) crée une bosse à maturité intermédiaire, pilotée par τ .

La version Svensson ajoute un deuxième couple (β_3, τ_2) pour plus de flexibilité.

Calibration et limites. La calibration se fait en minimisant une erreur entre prix observés (ou taux) et ceux impliqués par $P(0, T)$, avec pondérations reflétant liquidité et maturité. Les limites sont connues : (i) flexibilité restreinte face à des courbes très non monotones, (ii) risque de produire des forwards instantanés non plausibles (par exemple fortement négatifs) selon les paramètres, (iii) dépendance à la convention de calibration (prix vs taux). Une vérification d'absence d'arbitrage (monotonie des $P(0, T)$, raisonnabilité de $f(0, T)$) est indispensable.

1.5.6 Lien avec le projet *PaperTradingApp*

La courbe de taux est un ingrédient transversal : elle intervient dans l'actualisation, dans les forwards et donc dans la définition de la moneyness et des variables de changement de numéraire. Dans le projet, elle est mobilisée (au niveau conceptuel) pour garantir la cohérence “prix $\leftrightarrow$ taux $\leftrightarrow$ forwards” et pour éviter des incohérences d'absence d'arbitrage liées à une interpolation mal choisie. Elle sert aussi de base à des stress tests de taux et à des analyses de sensibilité (ρ_{IR}).

1.6 Forwards, Futures et Swaps

Les produits linéaires (forwards, futures, swaps) sont fondamentaux en finance de taux et de devises. Leur valorisation repose exclusivement sur la courbe des taux d'actualisation et sur les taux forward extraits de celle-ci.

1.6.1 Forwards

Un contrat forward fixe aujourd'hui un prix de transaction à une date future T . L'actif n'échange aucun flux avant la maturité.

Sous absence d'arbitrage, le prix forward $F(0, T)$ est donné par :

$$F(0, T) = S_0 \frac{1}{P(0, T)} = S_0 e^{R(0, T)T},$$

où $P(0, T)$ est le facteur d'actualisation.

Avec dividende continu (ou taux de portage q) :

$$F(0, T) = S_0 e^{(R(0, T) - q)T}.$$

1.6.2 Futures

Les futures sont des forwards *standardisés* négociés en bourse, avec ajustement quotidien (marche-to-market).

Dans un cadre frictionless, le prix du future vaut en général le forward :

$$F_{\text{fut}}(0, T) \approx F(0, T),$$

mais l'ajustement quotidien introduit une différence lorsque S_t est corrélé au taux court (effet convexité futures).

1.6.3 Interest Rate Swaps (IRS)

Un swap de taux échange :

- une *jambe fixe* : paiements $S_n \alpha_k$ aux dates T_k ,
- une *jambe flottante* : taux variables (LIBOR, Euribor, SOFR) ajustés à chaque période.

La valeur de la jambe fixe est :

$$\text{Fixe}(0) = S_n \sum_{k=1}^n \alpha_k P(0, T_k).$$

La jambe flottante vaut :

$$\text{Flottante}(0) = 1 - P(0, T_n),$$

car un taux variable réinitialisé assure la parité avec un instrument zéro-coupon.

Le taux swap S_n d'un IRS (valeur initiale nulle) est défini par :

$$\text{Fixe}(0) = \text{Flottante}(0) \implies S_n = \frac{1 - P(0, T_n)}{\sum_{k=1}^n \alpha_k P(0, T_k)}.$$

1.6.4 Interprétation économique

- Le **forward** verrouille un prix d'achat/vente futur.
- Le **future** ajoute la liquidité, standardisation, et marche-to-market.
- Le **swap de taux** échange flux fixes et variables, permettant de transformer exposition fixe $\leftrightarrow$ variable.

Ces produits linéaires servent aussi de brique fondamentale pour le pricing d'instruments plus complexes (swaption, cap/floor, CMS, etc.).

1.6.5 Lien avec le projet *PaperTradingApp*

Même dans un projet centré options, ces instruments linéaires structurent le *portage* : ils clarifient les relations spot/forward, les conventions de taux et l'actualisation. Ils fournissent donc le cadre conceptuel pour : (i) définir une moneyness cohérente (via $F(t, T)$), (ii) relier les payoffs à des prix forward dans les formules, et (iii) proposer des stress tests sur les taux (et leur impact sur prix/Greeks) sans ambiguïté de convention.

1.7 Crédit

La valorisation des instruments de crédit repose sur la notion de risque de défaut et sur l'intensité (hazard rate) associée. Les Credit Default Swaps (CDS) constituent l'instrument de marché le plus standard pour extraire ces informations.

1.7.1 CDS : définition et structure

Un Credit Default Swap est un contrat d'assurance contre le défaut d'un emprunteur (corporate, souverain). Il échange :

- une *jambe de protection* : paiement $(1 - R)$ en cas de défaut,
- une *jambe de prime* : paiements réguliers du spread s tant que le défaut n'a pas eu lieu.

Le payoff de protection, si le défaut survient en $\tau \in (0, T]$, est :

$$\text{Protection} = (1 - R) P(0, \tau),$$

où R est le taux de recouvrement (recovery).

La jambe de prime vaut :

$$\text{Premium} = s \sum_{k=1}^n \alpha_k P(0, T_k) \mathbb{Q}(\tau > T_k),$$

avec α_k la fraction de jour.

1.7.2 Intensité de défaut (hazard rate)

On modélise le défaut par un temps d'arrivée aléatoire τ dont la loi est caractérisée par une intensité $\lambda(t)$ telle que :

$$\mathbb{Q}(\tau > t) = e^{-\int_0^t \lambda(u) du}.$$

Lorsque $\lambda(t) = \lambda$ est constante :

$$\mathbb{Q}(\tau > t) = e^{-\lambda t}.$$

La densité de défaut est alors :

$$f_\tau(t) = \lambda e^{-\lambda t}.$$

1.7.3 Spread de CDS

Un CDS ayant une valeur initiale nulle impose :

$$\text{Protection}(0) = \text{Premium}(0),$$

soit :

$$(1 - R) \int_0^T P(0, t) \lambda(t) e^{-\int_0^t \lambda(u) du} dt = s \sum_{k=1}^n \alpha_k P(0, T_k) e^{-\int_0^{T_k} \lambda(u) du}.$$

Dans le cas stationnaire (λ constant, taux fixe r) :

$$s = \frac{(1 - R)\lambda}{\sum_{k=1}^n \alpha_k e^{-(r+\lambda)T_k}}.$$

En pratique, les spreads de CDS observés sur le marché permettent d'en déduire l'intensité $\lambda(t)$ via une calibration similaire à celle de la courbe des taux.

1.7.4 Interprétations

- Le spread s augmente lorsque le risque de défaut perçu augmente.
- La probabilité de survie est

$$\mathbb{Q}(\tau > T) = e^{-\int_0^T \lambda(u) du}.$$

- Le taux de recouvrement R influence directement la jambe de protection.

Les CDS sont essentiels pour :

- la gestion du risque de crédit,
- la construction de courbes de spread,
- la valorisation de produits hybrides (equity–credit, FX–credit).

1.8 Modèles de volatilité avancés : rough, sauts et filtrage

Cette section se lit comme un mini-cours de modélisation de volatilité “avancée” : on part des objets (noyaux de Volterra, fBM, modèles affines), on relie ces choix aux faits stylisés (smile/skew court terme), puis on déroule pas à pas deux outils omniprésents en pratique :

- la simulation du mouvement brownien fractionnaire via la méthode de Davies–Harte (brique centrale en volatilité rugueuse),
- la fonction caractéristique du modèle de Heston et la valorisation par Fourier (type Carr–Madan).

Les compléments (construction rough Bergomi/Volterra, SABR, Rough Heston, méthodes numériques) sont donnés plus loin (Sections 5, 6, 7, 8).

Objectifs pédagogiques (niveau M1).

- Expliquer le rôle du paramètre de Hurst H et la notion de mémoire (rough : $H < 1/2$).
- Passer d’une covariance théorique à un algorithme de simulation (embedding circulant + FFT) et en comprendre les contraintes.
- Dériver une fonction caractéristique dans un modèle affine (ansatz $\rightarrow$ Riccati) et l’utiliser pour pricer une call par Fourier.
- Mettre en regard les hypothèses de modèle avec la calibration et les diagnostics numériques.

1.8.1 Rough volatility et SDE de Volterra

Les modèles de *volatilité rugueuse* constituent aujourd’hui l’un des cadres les plus avancés pour reproduire les smiles de volatilité observés sur les marchés actions. Ils reposent sur des SDE de type Volterra dont la dynamique est non markovienne :

$$dX_t = \left(\int_0^t K(t-s)g(X_s) ds \right) dt + \left(\int_0^t K(t-s)h(X_s) ds \right) dW_t,$$

où K est un noyau singulier près de 0.

Dans le cas rough (Hurst $H < 1/2$), la variance est souvent modélisée via un fractional Brownian motion :

$$v_t = \xi_0(t) \exp\left(\eta B_t^H - \frac{1}{2}\eta^2 t^{2H}\right).$$

Ces modèles permettent :

- de reproduire un skew de court terme marqué (stylized fact largement documenté),
- de décrire une structure de corrélation temporelle cohérente,
- d'expliquer certains phénomènes de la microstructure.

On détaille ci-dessous la simulation du fBM (Davies–Harte), brique centrale des modèles rough ; la construction complète rough Bergomi/Volterra est donnée en Section 5.

Pourquoi Davies–Harte (vue pratique). Simuler un fBM revient à simuler un vecteur gaussien corrélé (le *fractional Gaussian noise*). La méthode de Davies–Harte utilise un embedding circulant et une FFT, ce qui ramène le coût à $O(N \log N)$ (au lieu d'une décomposition de Cholesky dense).

1.8.2 Mouvement brownien fractionnaire : méthode de Davies–Harte (dérivation pas à pas)

Simulation du mouvement brownien fractionnaire — Méthode de Davies–Harte (dérivation détaillée)

Rappels sur le mouvement brownien fractionnaire

Définition Pour un paramètre de Hurst $H \in (0, 1)$, le *mouvement brownien fractionnaire* (fBm) $(B^H(t))_{t \geq 0}$ est un processus gaussien centré tel que

$$\mathbb{E}[B^H(t)] = 0, \quad t \geq 0, \quad (1)$$

et

$$\text{Cov}(B^H(t), B^H(s)) = R_H(t, s) = \frac{1}{2}(|t|^{2H} + |s|^{2H} - |t - s|^{2H}), \quad s, t \geq 0. \quad (2)$$

On en déduit deux propriétés clés :

- **incréments stationnaires** :

$$B^H(t + h) - B^H(t) \stackrel{d}{=} B^H(h) - B^H(0), \quad \forall t, h \geq 0;$$

- **autosimilarité** :

$$(B^H(ct))_{t \geq 0} \stackrel{d}{=} (c^H B^H(t))_{t \geq 0}, \quad \forall c > 0.$$

En particulier,

$$\text{Var}(B^H(t)) = t^{2H}. \quad (3)$$

Discrétisation sur une grille On veut simuler une trajectoire de B^H sur une période $[0, T]$. On fixe un nombre de pas $N \in \mathbb{N}^*$ et on définit

$$\Delta t = \frac{T}{N}, \quad t_k = k \Delta t, \quad k = 0, \dots, N. \quad (4)$$

L'autosimilarité permet d'écrire, pour chaque k ,

$$B^H(t_k) = B^H(k\Delta t) \stackrel{d}{=} (\Delta t)^H \tilde{B}_H(k), \quad (5)$$

où $(\tilde{B}_H(k))_{k=0, \dots, N}$ est un fBm vu aux instants entiers k . Ainsi, on peut :

1. simuler un fBm à pas unitaire $(\tilde{B}_H(0), \dots, \tilde{B}_H(N))$;
2. le rescaler ensuite par $(\Delta t)^H$:

$$B^H(t_k) \approx (\Delta t)^H \tilde{B}_H(k).$$

On note les incréments unitaires

$$X_k = \tilde{B}_H(k+1) - \tilde{B}_H(k), \quad k = 0, \dots, N-1. \quad (6)$$

La suite $(X_k)_{k \geq 0}$ est le *fractional Gaussian noise* (fGn). On a alors

$$\tilde{B}_H(k) = \sum_{j=0}^{k-1} X_j, \quad k \geq 1, \quad (7)$$

et

$$B^H(t_k) \approx (\Delta t)^H \sum_{j=0}^{k-1} X_j. \quad (8)$$

Toute la difficulté se ramène donc à simuler le vecteur gaussien corrélé

$$(X_0, \dots, X_{N-1})$$

avec la bonne structure de covariance.

Covariance du bruit fractionnaire

Dérivation explicite de $\gamma(k)$ On veut la covariance

$$\gamma(k) = \text{Cov}(X_n, X_{n+k}), \quad (9)$$

qui, par stationnarité des incréments, ne dépend pas de n .

On se place sur le fBm à pas unitaire $\tilde{B}_H$ et on note

$$X_n = \tilde{B}_H(n+1) - \tilde{B}_H(n). \quad (10)$$

En développant la covariance à l'aide de la bilinéarité :

$$\gamma(k) = \text{Cov}(\tilde{B}_H(n+1) - \tilde{B}_H(n), \tilde{B}_H(n+k+1) - \tilde{B}_H(n+k)) \quad (11)$$

$$\begin{aligned} &= \text{Cov}(\tilde{B}_H(n+1), \tilde{B}_H(n+k+1)) - \text{Cov}(\tilde{B}_H(n+1), \tilde{B}_H(n+k)) \\ &\quad - \text{Cov}(\tilde{B}_H(n), \tilde{B}_H(n+k+1)) + \text{Cov}(\tilde{B}_H(n), \tilde{B}_H(n+k)). \end{aligned} \quad (12)$$

Par stationnarité des accroissements et invariance par translation, on peut prendre $n = 0$ sans perte de généralité :

$$\gamma(k) = \text{Cov}(\tilde{B}_H(1) - \tilde{B}_H(0), \tilde{B}_H(k+1) - \tilde{B}_H(k)). \quad (13)$$

Comme $\tilde{B}_H(0) = 0$ presque sûrement, on a

$$\text{Cov}(\tilde{B}_H(0), \tilde{B}_H(t)) = 0, \quad \forall t \geq 0,$$

et (12) se simplifie en

$$\gamma(k) = R_H(1, k+1) - R_H(1, k), \quad (14)$$

où

$$R_H(s, t) = \frac{1}{2}(|s|^{2H} + |t|^{2H} - |t-s|^{2H}).$$

On calcule explicitement :

$$R_H(1, k+1) = \frac{1}{2}(|1|^{2H} + |k+1|^{2H} - |(k+1)-1|^{2H}) = \frac{1}{2}(1 + |k+1|^{2H} - |k|^{2H}), \quad (15)$$

$$R_H(1, k) = \frac{1}{2}(|1|^{2H} + |k|^{2H} - |k-1|^{2H}) = \frac{1}{2}(1 + |k|^{2H} - |k-1|^{2H}). \quad (16)$$

D'où

$$\gamma(k) = R_H(1, k+1) - R_H(1, k) \quad (17)$$

$$= \frac{1}{2}(1 + |k+1|^{2H} - |k|^{2H} - 1 - |k|^{2H} + |k-1|^{2H}) \quad (18)$$

$$= \frac{1}{2}(|k+1|^{2H} + |k-1|^{2H} - 2|k|^{2H}). \quad (19)$$

Ainsi, la covariance théorique du bruit fractionnaire (fGn) est

$$\boxed{\gamma(k) = \text{Cov}(X_t, X_{t+k}) = \mathbb{E}[X_t X_{t+k}] = \frac{1}{2}(|k+1|^{2H} + |k-1|^{2H} - 2|k|^{2H}).} \quad (20)$$

Matrice de covariance Toeplitz On regroupe les N premiers incréments dans le vecteur

$$X = (X_0, \dots, X_{N-1})^\top.$$

Sa matrice de covariance est la matrice Toeplitz

$$\Gamma = \text{Cov}(X, X^\top) = (\gamma(|i-j|))_{0 \leq i, j \leq N-1}. \quad (21)$$

Autrement dit, la première ligne de Γ est

$$(\gamma(0), \gamma(1), \dots, \gamma(N-1)),$$

et chaque ligne suivante est une translation vers la droite.

La méthode de Davies–Harte consiste à *embeder* cette matrice Toeplitz dans une matrice **circulante** de taille $2N \times 2N$, ce qui permet d'utiliser la FFT.

Embedding circulant et vecteur c On construit le vecteur

$$c = (\gamma(0), \gamma(1), \dots, \gamma(N), \gamma(N-1), \dots, \gamma(1))^\top \in \mathbb{R}^{2N}. \quad (22)$$

On en déduit la matrice circulante $C \in \mathbb{R}^{2N \times 2N}$ définie par

$$C_{jk} = c_{(k-j) \bmod 2N}, \quad j, k = 0, \dots, 2N-1. \quad (23)$$

Ainsi :

- la première ligne de C est exactement $c^\top$;
- la $(j+1)$ -ème ligne est obtenue en décalant circulairement la précédente d'un cran vers la droite.

Par construction, le bloc $N \times N$ en haut à gauche de C coïncide avec la matrice Toeplitz Γ . L'idée est alors :

simuler un vecteur gaussien $Y \in \mathbb{R}^{2N}$ de covariance C , puis ne garder que ses N premières composantes ; celles-ci auront la covariance désirée Γ .

Diagonalisation de la matrice circulante par la FFT

Matrice de Fourier On pose $M = 2N$ et on considère la matrice de Fourier *unitaire*

$$F_{pj} = \frac{1}{\sqrt{M}} e^{-2\pi i p j / M}, \quad p, j = 0, \dots, M-1. \quad (24)$$

Cette normalisation donne

$$F^{-1} = F^*,$$

la transposée conjuguée.

Pour un vecteur $v \in \mathbb{C}^M$, on définit sa transformée de Fourier discrète (DFT) par

$$\hat{v} = Fv, \quad (25)$$

et la transformée inverse (IDFT) par

$$v = F^* \hat{v}. \quad (26)$$

En pratique numérique, F et F^* sont calculés via la FFT/IFFT.

Diagonalisation d'une matrice circulante Un résultat standard est : *toute matrice circulante est diagonalisée par la matrice de Fourier*. Plus précisément, si C est la matrice circulante dont la première ligne est $c^\top$, alors

$$\hat{c} = Fc = (\lambda_0, \dots, \lambda_{M-1})^\top \quad (27)$$

contient les valeurs propres de C , et on a

$$\boxed{C = F^* \Delta F}, \quad (28)$$

où

$$\Delta = \text{diag}(\lambda_0, \dots, \lambda_{M-1}) \quad (29)$$

est diagonale.

Dans le langage numérique, on écrit simplement

$$\Lambda = \text{FFT}(c),$$

où $\Lambda = (\lambda_k)_{0 \leq k < M}$.

Comme c est réel et symétrique, les λ_k sont réels et, dans le cas idéal, non négatifs. En pratique, la méthode de Davies–Harte requiert $\lambda_k \geq 0$; si certains λ_k sont négatifs (erreurs numériques mises à part), l'algorithme n'est pas applicable pour ce couple (H, N) .

Simulation gaussienne via la représentation spectrale

Principe général Soit $Y \in \mathbb{C}^M$ un vecteur gaussien centré. Si l'on peut écrire la covariance sous la forme

$$\text{Cov}(Y, Y^*) = C = F^* \Delta F,$$

alors il suffit de prendre

$$Y = F^* Z, \quad (30)$$

où Z est un vecteur gaussien complexe tel que

$$\mathbb{E}[Z] = 0, \quad \mathbb{E}[ZZ^*] = \Delta.$$

En effet,

$$\text{Cov}(Y, Y^*) = \mathbb{E}[YY^*] = \mathbb{E}[F^* ZZ^* F] = F^* \mathbb{E}[ZZ^*] F = F^* \Delta F = C. \quad (31)$$

On a donc transformé un problème de covariance générale C en un problème diagonal beaucoup plus simple.

Construction du vecteur Z On veut un vecteur

$$Z = (Z_0, \dots, Z_{M-1})^\top \in \mathbb{C}^M$$

tel que

$$\mathbb{E}[Z] = 0, \quad \mathbb{E}[ZZ^*] = \Delta = \text{diag}(\lambda_0, \dots, \lambda_{M-1}).$$

Comme Δ est diagonale, cela revient à imposer que

$$\mathbb{E}[Z_k \overline{Z_\ell}] = 0 \quad \text{si } k \neq \ell, \quad \mathbb{E}[|Z_k|^2] = \lambda_k.$$

On tient compte du fait que l'on veut finalement un *vecteur réel* Y , donc on impose en plus la symétrie conjuguée

$$Z_{M-k} = \overline{Z_k}, \quad 1 \leq k \leq M-1. \quad (32)$$

Comme c est réel et symétrique, on a $\lambda_k = \lambda_{M-k}$, ce qui rend cette construction cohérente.

Une construction explicite standard est :

- Générer des gaussiennes réelles indépendantes $U_0, \dots, U_N, V_1, \dots, V_{N-1} \sim \mathcal{N}(0, 1)$.
- Poser

$$Z_0 = \sqrt{\lambda_0} U_0, \quad (33)$$

$$Z_N = \sqrt{\lambda_N} U_N, \quad (34)$$

$$Z_k = \sqrt{\frac{\lambda_k}{2}} (U_k + iV_k), \quad k = 1, \dots, N-1, \quad (35)$$

$$Z_{M-k} = \sqrt{\frac{\lambda_k}{2}} (U_k - iV_k) = \overline{Z_k}, \quad k = 1, \dots, N-1. \quad (36)$$

On vérifie alors :

$$\mathbb{E}[Z_k] = 0, \quad \mathbb{E}[|Z_k|^2] = \lambda_k, \quad \mathbb{E}[Z_k \overline{Z_\ell}] = 0 \quad (k \neq \ell),$$

donc $\mathbb{E}[ZZ^*] = \Delta$.

Génération du bruit fractionnaire par IFFT

Application de l'IFFT On définit

$$Y = F^* Z = \text{IFFT}(Z). \quad (37)$$

Par ce qui précède, on a

$$\text{Cov}(Y, Y^*) = C. \quad (38)$$

De plus, grâce aux relations $Z_{M-k} = \overline{Z_k}$, on montre que Y est *réel* (à des erreurs numériques près) :

$$Y \in \mathbb{R}^M.$$

Dans l'implémentation, on prend donc

$$Y = \Re(\text{IFFT}(Z)).$$

On note

$$Y = (Y_0, \dots, Y_{M-1})^\top.$$

Par construction, la covariance de Y est la matrice circulante C . Le bloc $N \times N$ en haut à gauche de C est la matrice de covariance Γ du fGn. Donc, en ne conservant que les N premières composantes de Y , on obtient un vecteur ayant la bonne covariance.

On définit donc le bruit fractionnaire simulé par

$$(X_0, X_1, \dots, X_{N-1})^\top = (Y_0, Y_1, \dots, Y_{N-1})^\top \approx \text{fGn de covariance } \gamma(k). \quad (39)$$

Reconstruction du mouvement brownien fractionnaire On part de

$$\tilde{B}_H(0) = 0, \quad \tilde{B}_H(k) = \sum_{j=0}^{k-1} X_j, \quad k = 1, \dots, N,$$

où (X_j) est le fGn simulé ci-dessus.

Pour revenir aux temps $t_k = k\Delta t$ sur $[0, T]$, on utilise l'autosimilarité :

$$B^H(t_k) \stackrel{d}{=} (\Delta t)^H \tilde{B}_H(k).$$

On pose donc

$$\boxed{B^H(t_k) = (\Delta t)^H \sum_{j=0}^{k-1} X_j, \quad k = 0, \dots, N,} \quad (40)$$

avec la convention $B^H(t_0) = B^H(0) = 0$.

On vérifie que, au moins au premier ordre, la variance est correctement ajustée :

$$\text{Var}(B^H(t_k)) = (\Delta t)^{2H} \text{Var}\left(\sum_{j=0}^{k-1} X_j\right) \quad (41)$$

$$= (\Delta t)^{2H} \sum_{i=0}^{k-1} \sum_{j=0}^{k-1} \gamma(|i-j|) \quad (42)$$

$$\approx (k\Delta t)^{2H} = t_k^{2H}, \quad (43)$$

ce qui est cohérent avec la définition de la fBm.

Récapitulatif de la méthode de Davies–Harte

Étape 1 : covariance du bruit fractionnaire

— Pour $k = 0, \dots, N$, calculer

$$\gamma(k) = \frac{1}{2} \left(|k+1|^{2H} + |k-1|^{2H} - 2|k|^{2H} \right).$$

Étape 2 : vecteur circulant c

— Construire

$$c = (\gamma(0), \gamma(1), \dots, \gamma(N), \gamma(N-1), \dots, \gamma(1))^{\top} \in \mathbb{R}^{2N}.$$

Étape 3 : FFT et valeurs propres

— Calculer la FFT :

$$\Lambda = \text{FFT}(c) = (\lambda_0, \dots, \lambda_{2N-1})^{\top}.$$

— Vérifier que toutes les λ_k sont non négatives (à un petit ε près pour les erreurs numériques).

Étape 4 : génération du vecteur gaussien complexe

— Générer des $U_0, \dots, U_N, V_1, \dots, V_{N-1} \sim \mathbb{N}(0, 1)$ indépendants.

— Construire $Z \in \mathbb{C}^{2N}$ par

$$\begin{aligned} Z_0 &= \sqrt{\lambda_0} U_0, \\ Z_N &= \sqrt{\lambda_N} U_N, \\ Z_k &= \sqrt{\frac{\lambda_k}{2}} (U_k + iV_k), & k = 1, \dots, N-1, \\ Z_{2N-k} &= \sqrt{\frac{\lambda_k}{2}} (U_k - iV_k) = \overline{Z_k}, & k = 1, \dots, N-1. \end{aligned}$$

Étape 5 : IFFT et extraction du fGn

— Calculer

$$Y = \text{IFFT}(Z) = F^* Z.$$

— Prendre la partie réelle et garder les N premières composantes :

$$X_k = \Re(Y_k), \quad k = 0, \dots, N-1.$$

Le vecteur $(X_0, \dots, X_{N-1})$ est le *fractional Gaussian noise*.

Étape 6 : reconstruction du fBm sur $[0, T]$

— Fixer $\Delta t = T/N$.

— Poser

$$B^H(t_0) = 0, \quad B^H(t_k) = (\Delta t)^H \sum_{j=0}^{k-1} X_j, \quad k = 1, \dots, N.$$

On obtient ainsi une trajectoire discrète

$$(B^H(t_0), B^H(t_1), \dots, B^H(t_N))$$

qui suit, en loi, un mouvement brownien fractionnaire de paramètre H sur l'intervalle $[0, T]$.

1.8.3 Modèle de Heston et variants affines

Le modèle de Heston constitue un modèle de référence en volatilité stochastique. Il est affine, ce qui permet une expression fermée de la fonction caractéristique :

$$\phi(u; T) = \exp(C(u, T) + D(u, T)v_0 + iu \ln S_0).$$

Les variants (Heston à corrélation locale, Heston multifactor, hybrid Heston–Hull–White) permettent :

— une meilleure reproduction de la term-structure du skew,

- la prise en compte de facteurs de taux ou de FX,
- une calibration robuste via transformée de Fourier.

On donne maintenant une dérivation pas à pas : ansatz affine, équation de Riccati, puis pricing par Fourier (Carr–Madan) et remarques numériques.

1.8.4 Dérivation pas à pas : modèle de Heston

Modèle de Heston et log-prix Sous la mesure risque-neutre Q , le prix de l'actif S_t et sa variance instantanée v_t suivent

$$\begin{cases} dS_t = rS_t dt + \sqrt{v_t} S_t dW_t^{(1)}, \\ dv_t = \kappa(\theta - v_t) dt + \xi \sqrt{v_t} dW_t^{(2)}, \\ dW_t^{(1)} dW_t^{(2)} = \rho dt, \end{cases} \quad (44)$$

avec $v_0 > 0$, $\kappa > 0$, $\theta > 0$, $\xi > 0$, $|\rho| \leq 1$.

On pose le log-prix

$$X_t = \ln S_t. \quad (45)$$

Par la formule d'Itô,

$$dX_t = \left(r - \frac{v_t}{2}\right) dt + \sqrt{v_t} dW_t^{(1)}. \quad (46)$$

On considère une option call européenne de strike $K > 0$ et maturité $T > 0$, de payoff $(S_T - K)^+$. Son prix au temps 0 est

$$C(K, T) = e^{-rT} \mathbb{E}_Q[(S_T - K)^+]. \quad (47)$$

Fonction caractéristique du log-prix sous Heston On définit la fonction caractéristique du log-prix $X_T = \ln S_T$ par

$$\varphi_T(u) := \mathbb{E}[e^{iuX_T}], \quad u \in \mathbb{C}. \quad (48)$$

On veut une expression explicite de $\varphi_T(u)$.

PDE de Feynman–Kac et ansatz affine Pour $0 \leq t \leq T$, $x \in \mathbb{R}$, $v \geq 0$, on introduit

$$p(t, x, v; u) := \mathbb{E}[e^{iuX_T} \mid X_t = x, v_t = v]. \quad (49)$$

Alors $p(T, x, v; u) = e^{iux}$ et

$$\varphi_T(u) = p(0, \ln S_0, v_0; u). \quad (50)$$

Le couple (X_t, v_t) a pour générateur infinitésimal

$$\mathcal{L}f = \left(r - \frac{v}{2}\right) \partial_x f + \kappa(\theta - v) \partial_v f + \frac{1}{2} v \partial_{xx} f + \rho \xi v \partial_{xv} f + \frac{1}{2} \xi^2 v \partial_{vv} f. \quad (51)$$

Par Feynman–Kac, p satisfait

$$\partial_t p + \mathcal{L}p = 0, \quad p(T, x, v; u) = e^{iux}. \quad (52)$$

On cherche une solution de la forme affine en v :

$$p(t, x, v; u) = \exp(C(\tau; u) + D(\tau; u)v + iux), \quad \tau := T - t. \quad (53)$$

On impose $C(0; u) = 0$, $D(0; u) = 0$, de sorte que $p(T, x, v; u) = e^{iux}$.

On calcule

$$\partial_t p = -C'(\tau; u)p - D'(\tau; u)vp, \quad \partial_x p = iup, \quad \partial_{xx} p = -u^2 p,$$

$$\partial_v p = Dp, \quad \partial_{vv} p = D^2 p, \quad \partial_{xv} p = iuDp.$$

En injectant dans la PDE, puis en factorisant par $p \neq 0$, on obtient

$$0 = -C' - D'v + \left(r - \frac{v}{2}\right)(iu) + \kappa(\theta - v)D + \frac{1}{2}v(-u^2) + \rho\xi v(iuD) + \frac{1}{2}\xi^2 vD^2. \quad (54)$$

On séparant les termes constants et les termes proportionnels à v , ce qui donne

$$(\text{terme constant}) : \quad -C' + iur + \kappa\theta D = 0, \quad (55)$$

$$(\text{terme en } v) : \quad -D' + \left(-\frac{i u}{2}\right) - \kappa D - \frac{u^2}{2} + \rho\xi iuD + \frac{1}{2}\xi^2 D^2 = 0. \quad (56)$$

On en déduit les EDO (en τ) :

$$C'(\tau; u) = \kappa\theta D(\tau; u) + iur, \quad C(0; u) = 0, \quad (57)$$

$$D'(\tau; u) = \frac{1}{2}\xi^2 D(\tau; u)^2 + (\rho\xi iu - \kappa)D(\tau; u) + \frac{1}{2}(u^2 + iu), \quad D(0; u) = 0. \quad (58)$$

L'équation (58) est de Riccati.

Résolution de l'équation de Riccati On note

$$a := \frac{\xi^2}{2}, \quad \beta(u) := \rho\xi iu - \kappa, \quad \omega(u) := \frac{1}{2}(u^2 + iu). \quad (59)$$

Alors

$$D' = aD^2 + \beta(u)D + \omega(u). \quad (60)$$

On introduit le discriminant

$$d(u) := \sqrt{\beta(u)^2 + 4a\omega(u)} = \sqrt{(\rho\xi iu - \kappa)^2 + \xi^2(u^2 + iu)}, \quad (61)$$

et on prend la racine avec $\Re[d(u)] > 0$.

On définit ensuite

$$g(u) := \frac{\kappa - \rho\xi iu - d(u)}{\kappa - \rho\xi iu + d(u)}. \quad (62)$$

La solution classique de l'équation de Riccati est alors

$$D(\tau; u) = \frac{\kappa - \rho\xi iu - d(u)}{\xi^2} \frac{1 - e^{-d(u)\tau}}{1 - g(u)e^{-d(u)\tau}}. \quad (63)$$

Intégration pour obtenir $C(\tau; u)$ En intégrant (57), on obtient

$$C(\tau; u) = iur\tau + \kappa\theta \int_0^\tau D(s; u) ds. \quad (64)$$

L'intégrale en s se calcule explicitement. Le résultat standard (obtenu en faisant le changement $y = e^{-d(u)s}$ et en intégrant terme à terme) est

$$C(\tau; u) = iur\tau + \frac{\kappa\theta}{\xi^2} \left[(\kappa - \rho\xi iu - d(u))\tau - 2 \ln \left(\frac{1 - g(u)e^{-d(u)\tau}}{1 - g(u)} \right) \right]. \quad (65)$$

Fonction caractéristique finale En résumé, la fonction caractéristique du log-prix $X_T = \ln S_T$ sous le modèle de Heston est

$$\boxed{\varphi_T(u) = \mathbb{E}[e^{iuX_T}] = \exp\left(C(T; u) + D(T; u)v_0 + iu \ln S_0\right),} \quad (66)$$

avec

$$d(u) = \sqrt{(\rho\xi iu - \kappa)^2 + \xi^2(u^2 + iu)}, \quad (67)$$

$$g(u) = \frac{\kappa - \rho\xi iu - d(u)}{\kappa - \rho\xi iu + d(u)}, \quad (68)$$

$$D(T; u) = \frac{\kappa - \rho\xi iu - d(u)}{\xi^2} \frac{1 - e^{-d(u)T}}{1 - g(u)e^{-d(u)T}}, \quad (69)$$

$$C(T; u) = iurT + \frac{\kappa\theta}{\xi^2} \left[(\kappa - \rho\xi iu - d(u))T - 2 \ln \left(\frac{1 - g(u)e^{-d(u)T}}{1 - g(u)} \right) \right]. \quad (70)$$

Représentation de Fourier du prix de la call

Densité du log-prix Notons $X_T = \ln S_T$ et f_{X_T} sa densité (sous Q). Le prix de la call en fonction de $k = \ln K$ s'écrit

$$C(k) = C(K, T) = e^{-rT} \int_k^{+\infty} (e^x - e^k) f_{X_T}(x) dx, \quad k := \ln K. \quad (71)$$

Damping et transformée de Fourier On choisit un paramètre de damping $\alpha > 0$ tel que

$$\mathbb{E}[e^{(\alpha+1)X_T}] < +\infty. \quad (72)$$

On introduit la quantité

$$c_\alpha(k) := e^{\alpha k} C(k), \quad (73)$$

et sa transformée de Fourier

$$\psi_T(v) := \int_{-\infty}^{+\infty} e^{ivk} c_\alpha(k) dk = \int_{-\infty}^{+\infty} e^{(\alpha+iv)k} C(k) dk, \quad v \in \mathbb{R}. \quad (74)$$

Par un calcul direct (changement d'ordre d'intégration et intégration en k d'abord), on obtient

$$\psi_T(v) = e^{-rT} \frac{1}{(\alpha+iv)(\alpha+iv+1)} \int_{-\infty}^{+\infty} e^{(\alpha+1+iv)x} f_{X_T}(x) dx. \quad (75)$$

Or

$$\int_{-\infty}^{+\infty} e^{(\alpha+1+iv)x} f_{X_T}(x) dx = \mathbb{E}[e^{(\alpha+1+iv)X_T}] = \varphi_T(v - i(\alpha+1)), \quad (76)$$

puisque $e^{(\alpha+1+iv)x} = e^{i(v-i(\alpha+1))x}$.

On en déduit

$$\boxed{\psi_T(v) = e^{-rT} \frac{\varphi_T(v - i(\alpha+1))}{(\alpha+iv)(\alpha+iv+1)}}. \quad (77)$$

Formule d'inversion Par inversion de Fourier, on récupère

$$c_\alpha(k) = \frac{1}{2\pi} \int_{-\infty}^{+\infty} e^{-ivk} \psi_T(v) dv. \quad (78)$$

Comme $C(k)$ est réel, $c_\alpha(k)$ l'est aussi et l'intégrale se simplifie en

$$c_\alpha(k) = \frac{1}{\pi} \int_0^{+\infty} \Re(e^{-ivk} \psi_T(v)) dv. \quad (79)$$

En rappelant $C(k) = e^{-\alpha k} c_\alpha(k)$, on obtient finalement

$$\boxed{C(K, T) = C(k) = \frac{e^{-\alpha k}}{\pi} \int_0^{+\infty} \Re\left(e^{-ivk} e^{-rT} \frac{\varphi_T(v - i(\alpha+1))}{(\alpha+iv)(\alpha+iv+1)}\right) dv, \quad k = \ln K.} \quad (80)$$

Schéma numérique (idée générale) Pour calculer $C(K, T)$ numériquement :

1. Choisir $\alpha > 0$ tel que $\mathbb{E}[e^{(\alpha+1)X_T}] < \infty$ (en pratique $\alpha \in [1, 2]$ est standard).
2. Choisir une grille pour v : $v_j = j\Delta v$, $j = 0, \dots, N$, avec Δv et N fixant la précision.
3. Pour chaque v_j ,
 - (a) calculer $u_j := v_j - i(\alpha+1)$,

- (b) calculer $d(u_j)$, $g(u_j)$, $D(T; u_j)$, $C(T; u_j)$,
 - (c) en déduire $\varphi_T(u_j)$,
 - (d) calculer $\psi_T(v_j)$ via la formule ci-dessus.
4. Approcher l'intégrale par une somme de Riemann ou Simpson :

$$C(K, T) \approx \frac{e^{-\alpha k}}{\pi} \sum_{j=0}^N \Re \left(e^{-iv_j k} \psi_T(v_j) \right) \Delta v.$$

A.6. Formule finale et schéma numérique

Formule finale de Heston pour $C(K, T)$ et schéma numérique

1. Fonction caractéristique sous Heston Sous la mesure risque-neutre Q :

$$\begin{cases} dS_t = r S_t dt + \sqrt{v_t} S_t dW_t^{(1)}, \\ dv_t = \kappa(\theta - v_t) dt + \xi \sqrt{v_t} dW_t^{(2)}, \\ dW_t^{(1)} dW_t^{(2)} = \rho dt, \end{cases} \quad S_0 > 0, v_0 > 0.$$

On pose

$$X_t := \ln S_t.$$

La fonction caractéristique du log-prix X_T est

$$\varphi_T(u) := \mathbb{E}[e^{iuX_T}], \quad u \in \mathbb{C}.$$

Elle s'écrit sous forme affine

$$\boxed{\varphi_T(u) = \exp \left(C(T, u) + D(T, u) v_0 + iu \ln S_0 \right),}$$

avec

$$d(u) := \sqrt{(\rho \xi i u - \kappa)^2 + \xi^2(u^2 + iu)}, \quad \Re(d(u)) > 0,$$

$$g(u) := \frac{\kappa - \rho \xi i u - d(u)}{\kappa - \rho \xi i u + d(u)}.$$

Les fonctions C et D sont

$$\boxed{D(T, u) = \frac{\kappa - \rho \xi i u - d(u)}{\xi^2} \frac{1 - e^{-d(u)T}}{1 - g(u) e^{-d(u)T}},}$$

$$\boxed{C(T, u) = iurT + \frac{\kappa\theta}{\xi^2} \left[(\kappa - \rho \xi i u - d(u))T - 2 \ln \left(\frac{1 - g(u)e^{-d(u)T}}{1 - g(u)} \right) \right].}$$

Tous les paramètres $(\kappa, \theta, \xi, \rho, v_0, r, S_0)$ apparaissent explicitement dans $d(u)$, $g(u)$, $C(T, u)$, $D(T, u)$ donc dans $\varphi_T(u)$.

2. Formule de prix via transformée de Fourier (type Carr–Madan) On note $K > 0$ le strike et

$$k := \ln K.$$

On fixe un paramètre de damping $\alpha > 0$ tel que

$$\mathbb{E}[e^{(\alpha+1)X_T}] < \infty \quad (\text{en pratique } \alpha \in [1, 2]).$$

Pour $v \in \mathbb{R}$, on pose

$$A(v) := \alpha + iv.$$

La transformée de Carr–Madan est

$$\psi_T(v) := \int_{\mathbb{R}} e^{A(v)k'} C(k') dk',$$

et peut se récrire en fonction de φ_T :

$$\boxed{\psi_T(v) = \frac{e^{-rT}}{A(v)(A(v) + 1)} \varphi_T(v - i(\alpha + 1)).}$$

La formule d'inversion donne alors le prix de la call :

$$\boxed{C(K, T) = C(k) = \frac{e^{-\alpha k}}{\pi} \int_0^{+\infty} \Re(e^{-ivk} \psi_T(v)) dv.}$$

En combinant explicitement :

$$\boxed{C(K, T) = \frac{e^{-\alpha k}}{\pi} \int_0^{+\infty} \Re \left[e^{-ivk} \frac{e^{-rT}}{(\alpha + iv)(\alpha + 1 + iv)} \exp \left(C(T, u) + D(T, u) v_0 + iu \ln S_0 \right) \right]_{u=v-i(\alpha+1)} dv.}$$

Tout est maintenant en fonction de

$$(\kappa, \theta, \xi, \rho, v_0, r, S_0, K, T, \alpha).$$

3. Principes numériques (sans pseudo-code)

Rappel de la formule. Dans le cadre de Carr–Madan, on utilise un call dampé et l'on évalue une intégrale oscillante sur $v \in \mathbb{R}_+$:

$$C(K, T) = \frac{e^{-\alpha k}}{\pi} \int_0^{+\infty} \Re(e^{-ivk} \psi_T(v)) dv, \quad k = \ln K,$$

où $\psi_T(v)$ dépend de la fonction caractéristique $\varphi_T(u)$ du log-prix à maturité T évaluée en

$$u(v) = v - i(\alpha + 1).$$

Choix du damping et intégrabilité. Le paramètre $\alpha > 0$ assure l'intégrabilité de la transformée (contrôle des queues en K). Le choix est un compromis : un α trop faible peut conduire à une intégrale mal conditionnée ; un α trop grand amplifie certaines erreurs numériques.

Troncature, discrétisation et diagnostics. Numériquement, l'intégrale est tronquée à $[0, V_{\max}]$ et approchée par quadrature sur une grille $v_n = n \Delta v$. Les erreurs proviennent (i) de la troncature (choix de $V_{\max}$), (ii) de la discrétisation (Δv), et (iii) de l'oscillation. Une validation théorique consiste à vérifier la stabilité du prix lorsque l'on augmente $V_{\max}$ et que l'on raffine Δv , et à croiser avec une méthode indépendante (Monte Carlo ou PDE) sur quelques points de grille.

Branche complexe et stabilité. Dans Heston (et Bates), l'évaluation de $\varphi_T(u)$ requiert des racines carrées et logarithmes complexes. Le choix de branche et la continuité en u conditionnent la stabilité numérique ; en pratique, on impose une convention cohérente sur la racine et l'on surveille les discontinuités.

Version FFT. La version FFT de Carr–Madan s'appuie sur une grille uniforme en fréquence v et une grille uniforme en log-strike k , avec une relation de type $\Delta v \Delta k = 2\pi/N$. Elle permet d'obtenir un ensemble de prix sur une grille de strikes en un seul calcul, au prix d'effets d'aliasing et de fenêtrage à contrôler (choix du domaine et des pas).

1.8.5 Modèle SABR et volatilité inspirée (SVI)

Pour les marchés de taux, le modèle SABR, caractérisé par

$$dF_t = \alpha_t F_t^\beta dW_t^{(1)}, \quad d\alpha_t = \nu \alpha_t dW_t^{(2)},$$

rempart l'un des standards de calibration en raison de son expression asymptotique fermée de la volatilité implicite.

En parallèle, les modèles SVI (Stochastic Volatility Inspired) fournissent une paramétrisation analytique de la surface de volatilité, contrôlant :

- le skew,
- la convexité,
- les conditions d'arbitrage.

Ces deux modèles sont des outils incontournables pour reproduire des surfaces de volatilité de marché de façon flexible et stable.

1.8.6 Diffusions à sauts : Merton et Bates

Motivation. Les smiles et wings de volatilité, en particulier à très courte maturité, traduisent souvent des probabilités de queues plus élevées que celles induites par des diffusions continues. Une manière classique d'introduire des queues plus lourdes et des discontinuités est d'ajouter un processus de sauts (compound Poisson).

Modèle de Merton (jump–diffusion). Sous $\mathbb{Q}$ et dans une convention à dividende continu q , on écrit typiquement :

$$\frac{dS_t}{S_{t-}} = (r - q - \lambda \kappa_J) dt + \sigma dW_t + (J - 1) dN_t,$$

où N_t est un Poisson d'intensité λ , $J > 0$ le multiplicateur de saut, et $\kappa_J := \mathbb{E}[J - 1]$ (sous $\mathbb{Q}$) assure la correction de drift (martingalité de $S_t e^{-\int_0^t (r_u - q_u) du}$). Un choix standard est $\ln J \sim \mathcal{N}(\mu_J, \delta_J^2)$.

Conséquence sur le pricing. Le log-prix est somme d'une partie gaussienne et d'une partie compound Poisson ; la fonction caractéristique de $\ln S_T$ s'écrit explicitement, ce qui rend les méthodes de Fourier naturelles. Une représentation classique exprime aussi le prix comme une *moyenne* (sur le nombre de sauts) de prix Black–Scholes à paramètres ajustés, ce qui illustre l'impact des sauts sur la courbure des wings.

Modèle de Bates (Heston + sauts). Le modèle de Bates combine volatilité stochastique (Heston) et sauts :

$$\frac{dS_t}{S_{t-}} = (r - q - \lambda \kappa_J) dt + \sqrt{v_t} dW_t^{(1)} + (J - 1) dN_t, \quad dv_t = \kappa(\theta - v_t) dt + \xi \sqrt{v_t} dW_t^{(2)},$$

avec $\text{corr}(dW_t^{(1)}, dW_t^{(2)}) = \rho dt$. Intuitivement, v_t explique la persistance de volatilité et le skew “diffusif”, tandis que les sauts pilotent les queues et l'accentuation du smile à court terme.

Calibration et limites. La calibration vise à identifier $(\lambda, \mu_J, \delta_J)$ conjointement aux paramètres de volatilité. En pratique, l'identifiabilité est délicate : certaines combinaisons de (ξ, ρ, v_0) et de paramètres de sauts peuvent produire des smiles proches. Il est donc naturel d'utiliser des pondérations (vega), des contraintes (bornes, conditions de positivité) et des diagnostics de stabilité (sensibilité, out-of-sample).

1.8.7 Filtrage : modèles en espace d'état et filtre de Kalman

Idée. De nombreuses quantités pertinentes (volatilité instantanée, variance latente, niveau de bruit) ne sont pas observables directement. Les *modèles en espace d'état* séparent une dynamique

latente (état) et une équation d'observation (mesures bruitées), puis utilisent un filtre pour estimer l'état conditionnellement aux observations.

Cadre linéaire gaussien. Dans sa forme standard, on postule :

$$x_{t+1} = Ax_t + w_t, \quad y_t = Hx_t + v_t,$$

où (w_t) et (v_t) sont gaussiens centrés, de covariances Q et R , indépendants. Le **filtre de Kalman** fournit alors l'estimateur optimal (au sens des moindres carrés) de x_t sachant $(y_0, \dots, y_t)$, avec une récurrence sur la moyenne conditionnelle et sa covariance.

Extensions et limites. Pour des dynamiques non linéaires (volatilité stochastique, contraintes de positivité), on recourt à des extensions (EKF/UKF) ou à des filtres particuliers. Les limites principales viennent de la non-gaussianité (queues, sauts), de la non-stationnarité (régimes), et du risque de modèle : un filtre est un outil d'estimation conditionnelle, pas une preuve de validité du modèle.

Lien avec le projet *PaperTradingApp*. Un filtrage de type Kalman s'interprète comme une brique théorique d'estimation d'états latents (variance/volatilité) et de lissage, utilisable pour : (i) produire des séries de volatilité plus robustes que des estimateurs bruts, (ii) fournir des entrées d'état pour des analyses de régimes ou des politiques de couverture, (iii) quantifier une incertitude d'estimation via la covariance filtrée.

1.8.8 Perspectives

Les modèles modernes combinent :

- volatilité stochastique,
- volatilité rugueuse,
- noyaux de Volterra,
- dynamiques multi-actifs,
- facteurs de taux ou de crédit.

La recherche actuelle explore des structures hybrides (Heston–Volterra, rough Heston, SABR–Volterra) et des méthodes numériques accélérées (FFT, hybrid schemes, quadratures rapides).

Ces différentes directions visent à construire des modèles plus expressifs, susceptibles de mieux prendre en compte plusieurs effets empiriques : skew dynamique, déformations fines de smile, et phénomènes de mémoire.

1.8.9 Lien avec le projet *PaperTradingApp*

Cette section fournit le panorama des modèles effectivement pertinents pour une plateforme d'options : (i) modèles affines (Heston) pour leur tractabilité via fonctions caractéristiques, (ii) modèles à sauts (Merton/Bates) pour traiter des queues et de la dynamique court terme, (iii) modèles à mémoire (Volterra/rough) pour la géométrie du smile à court terme, et (iv) outils d'estimation (Kalman) pour relier variables latentes et observations bruitées. Le projet vise à comparer ces cadres, à discuter leurs hypothèses et limites, et à articuler modèles et surfaces de marché dans une logique de calibration et de gestion du risque.

1.9 Gestion du risque de portefeuille et allocation

La valorisation (*pricing*) et la modélisation de la volatilité n'ont de sens opérationnel que si elles s'intègrent dans un cadre de gestion du risque. Dans une plateforme de trading, ce cadre se traduit par : (i) une mesure claire des expositions, (ii) une décomposition du PnL, (iii) des limites et alertes, et (iv) des règles d'allocation et de rééquilibrage cohérentes avec le profil de risque.

1.9.1 PnL, expositions et drawdowns

On distingue typiquement :

- le **PnL réalisé** (positions fermées) et le **PnL latent** (mark-to-market),
- l'**exposition brute** (somme des valeurs absolues) et l'**exposition nette** (somme signée),
- des sensibilités de premier ordre (**delta**) et de second ordre (**gamma**) lorsque le portefeuille contient des options.

Le **drawdown** mesure la perte relative depuis un plus-haut historique :

$$DD(t) = \frac{V_t - \max_{u \leq t} V_u}{\max_{u \leq t} V_u}, \quad MDD = \min_t DD(t),$$

où V_t est la valeur du portefeuille. Le drawdown est une mesure intuitive de risque “vécu” et complète utilement des mesures basées sur la variance.

1.9.2 Value-at-Risk (VaR) et Expected Shortfall (ES)

Pour un horizon Δt et un niveau de confiance $\alpha \in (0, 1)$, la **VaR** est définie comme un quantile de la distribution des pertes L :

$$VaR_\alpha(L) = \inf\{\ell \in \mathbb{R} : \mathbb{P}(L \leq \ell) \geq \alpha\}.$$

L'**Expected Shortfall** (ES) ou *Conditional VaR* est l'espérance des pertes au-delà de la VaR :

$$ES_\alpha(L) = \mathbb{E}[L \mid L \geq VaR_\alpha(L)].$$

La VaR est simple à communiquer mais n'est pas toujours cohérente au sens d'Artzner et al. (elle peut violer la subadditivité). L'ES corrige ce point et est souvent préférée pour piloter des limites de risque.

1.9.3 Allocation moyenne–variance (Markowitz)

Dans le cadre moyenne–variance, on modélise les rendements d'un vecteur d'actifs $R \in \mathbb{R}^n$ par sa moyenne μ et sa matrice de covariance Σ . L'allocation (poids) $w \in \mathbb{R}^n$ est choisie pour :

- minimiser la variance pour un rendement cible,
- ou maximiser un ratio de Sharpe sous contraintes (poids positifs, somme à 1, etc.).

Le problème “minimum variance” (sans contrainte de signe) admet une solution fermée :

$$w^* \propto \Sigma^{-1} \mathbf{1}, \quad \mathbf{1} = (1, \dots, 1)^\top.$$

En pratique, on impose des contraintes réalistes et on régularise Σ (estimation bruitée, fenêtre courte, actifs corrélés).

1.9.4 Risk parity et contributions au risque

Le *risk parity* vise une allocation où chaque actif contribue à parts égales au risque du portefeuille. Pour une volatilité de portefeuille $\sigma_P = \sqrt{w^\top \Sigma w}$, la contribution marginale au risque est $\partial \sigma_P / \partial w_i = (\Sigma w)_i / \sigma_P$, et la contribution totale de l'actif i est

$$\text{RC}_i = w_i \frac{(\Sigma w)_i}{\sigma_P}.$$

Le risk parity cherche $\text{RC}_i = \sigma_P / n$ pour tous i (sous contraintes de signe/somme), ce qui définit un problème non linéaire résolu numériquement.

1.9.5 PCA et eigen-portfolios

La décomposition spectrale $\Sigma = Q \Lambda Q^\top$ (valeurs propres Λ , vecteurs propres Q) fournit une lecture factorielle des risques : les grandes valeurs propres correspondent aux facteurs dominants. Les *eigen-portfolios* exploitent ces vecteurs propres pour construire des portefeuilles alignés sur des facteurs ou, à l'inverse, moins exposés au facteur principal.

1.9.6 Lien avec le projet *PaperTradingApp*

Le projet mobilise ces notions pour rendre *mesurable* et *attribuable* le risque : expositions brutes/nettes, PnL réalisé vs latent, drawdowns, VaR/ES, et principes d'allocation (Markowitz, risk parity, décomposition factorielle). L'objectif est de relier les briques de pricing et de calibration

à des décisions de portefeuille (taille de position, limites, rééquilibrage) dans un langage quantitatif cohérent.

1.10 Régimes et analytics de volatilité

L'analyse de volatilité ne se limite pas à une surface implicite. Dans une perspective de gestion du risque et de décision, on s'intéresse à la **volatilité réalisée**, à des diagnostics de **retour à la moyenne**, et à des modèles de **régimes** capables de capturer des changements de dynamique (calme/crise, compression/expansion de vol).

1.10.1 Volatilité réalisée : définitions, annualisation, biais

Définition (variance réalisée). Soit une partition $t = t_0 < \dots < t_n = t + \Delta$ et des rendements $\log r_i = \ln(S_{t_i}/S_{t_{i-1}})$. La *variance réalisée* sur $[t, t + \Delta]$ est

$$RV_{t,t+\Delta} = \sum_{i=1}^n r_i^2.$$

Sous des hypothèses de diffusion continue, RV converge (quand la maille tend vers 0) vers la *variation quadratique* du log-prix, et constitue un estimateur naturel de la variance intégrée.

Annualisation. Une volatilité annualisée (sur une fenêtre) est souvent définie par $\hat{\sigma} = \sqrt{RV} \times \sqrt{A}$, où A dépend de la convention (nombre de jours de bourse, etc.). Le point clé est que l'annualisation est une convention et doit être cohérente avec les maturités d'options et la courbe de taux.

Biais et pièges. En pratique, des phénomènes de microstructure (bid-ask bounce, non-synchronisme), des heures de cotation, et des sauts peuvent biaiser RV. Le choix de la fréquence et de la fenêtre résulte d'un compromis biais/variance ; on peut compléter par des estimateurs robustes (réalisée bipower, trimming) selon l'objectif.

1.10.2 Retour à la moyenne : diagnostics et interprétation

Intuition. De nombreux indicateurs de volatilité (implicite/realized) montrent une tendance à revenir vers un niveau “normal” à horizon de quelques semaines à quelques mois. Ce phénomène motive des dynamiques de type OU/CIR pour v_t ou σ_t .

Résultat clé (OU discretisé). Pour un processus d'Ornstein–Uhlenbeck $dx_t = \kappa(\theta - x_t)dt + \eta dW_t$, la discrétisation à pas Δ donne :

$$x_{t+\Delta} - \theta = e^{-\kappa\Delta}(x_t - \theta) + \text{bruit}.$$

On en déduit une notion de *demi-vie* $t_{1/2} = \ln 2 / \kappa$: horizon à partir duquel l'écart à θ est divisé par deux en moyenne.

Limites. Les diagnostics de mean reversion sont sensibles à la non-stationnarité, aux changements de régime, et à la définition de la volatilité (réalisée, implicite, filtrée). Une conclusion robuste exige des tests sur plusieurs horizons, et des stress sur les choix de fenêtre et d'échantillonnage.

1.10.3 Chaînes de Markov de régimes : matrice de transition et lecture probabiliste

Définition. On introduit une variable latente $Z_t \in \{1, \dots, m\}$ (régime) telle que

$$\mathbb{P}(Z_{t+\Delta} = j \mid Z_t = i) = \Pi_{ij},$$

où Π est une matrice de transition (lignes sommant à 1). Conditionnellement au régime, les observations (rendements, volatilité) suivent une loi paramétrée (par exemple gaussienne avec variance régime-dépendante).

Résultat clé (stationnarité). Si la chaîne est ergodique, il existe une distribution stationnaire π telle que $\pi^\top \Pi = \pi^\top$; elle fournit la proportion de temps de long terme passée dans chaque régime (interprétation probabiliste du “climat” de marché).

Limites. Les régimes sont une *discrétisation* : le choix de m et de l'équation d'observation peut induire de l'instabilité et de la sur-paramétrisation. La validation doit inclure des tests hors échantillon, des contraintes d'interprétabilité (régimes stables), et des analyses de sensibilité aux données.

1.10.4 Lien avec le projet *PaperTradingApp*

Ces outils fournissent un langage commun pour : (i) contextualiser les smiles (régimes de stress vs de compression), (ii) moduler des limites de risque (VaR/ES, drawdowns) en fonction d'un régime, (iii) proposer des diagnostics de mean reversion sur la volatilité réalisée/implicite, et (iv) définir des états synthétiques utilisables dans une formulation MDP de la couverture (à défaut d'hypothèses stationnaires fortes).

2 Apprentissage supervisé sous non-stationnarité : validation, leakage et robustesse

Cette partie introduit des notions de *méthodologie quantitative* issues de l'apprentissage supervisé, particulièrement utiles lorsque les données sont structurées dans le temps et potentiellement *non-stationnaires*. Dans un contexte de prédiction en production ou de compétition structurée en

périodes (*eras*), les enjeux ne sont pas uniquement la performance moyenne, mais la **stabilité** du signal et la **prévention des biais** (en particulier le *leakage*).

2.1 Cadre : apprentissage supervisé et généralisation

2.1.1 Définitions

On observe un ensemble annoté $\{(x_i, y_i)\}_{i=1}^n$ où $x_i \in \mathcal{X}$ (vecteur de variables explicatives) et $y_i \in \mathcal{Y}$ (cible). Un modèle paramétré $f_\theta : \mathcal{X} \rightarrow \mathcal{Y}$ est ajusté en minimisant une perte empirique

$$\hat{\theta} \in \arg \min_{\theta} \frac{1}{n} \sum_{i=1}^n \ell(y_i, f_\theta(x_i)).$$

La question centrale est la **généralisation** : les performances sur des données futures (ou hors échantillon) seront-elles cohérentes avec celles observées sur l'échantillon d'apprentissage ?

2.1.2 Intuition : biais–variance et non-stationnarité

Le compromis biais–variance fournit une lecture utile : un modèle trop flexible sur-ajuste le bruit (variance forte), un modèle trop rigide manque le signal (biais fort). La non-stationnarité (changement de régime, dérive de distribution) complique encore l'analyse : la distribution des (x, y) peut varier avec le temps, ce qui rend les estimations i.i.d. (échantillon aléatoire) inadéquates.

2.2 Eras, régimes et *leakage* : risques spécifiques

2.2.1 Définition d'une structure en eras

On suppose que les observations sont regroupées par périodes $e \in \{1, \dots, E\}$ (“eras”), chaque era correspondant à un bloc temporel ou à un sous-ensemble relativement homogène. On note $\mathcal{I}_e$ l'ensemble des indices appartenant à l'era e . Cette structure impose une évaluation *par période* : un modèle utile doit produire un signal **répétable** au fil des eras.

2.2.2 Leakage : définition et conséquences

On appelle *leakage* toute utilisation, directe ou indirecte, d'une information indisponible au moment réel de la prédiction (information “future”, fuite entre train et validation, prétraitements calculés sur un ensemble trop large).

Conséquence. Le leakage conduit à une performance hors échantillon artificiellement optimiste : l'évaluation mesure alors une capacité à exploiter une fuite, pas à généraliser. Dans les données temporelles, le leakage est souvent plus subtil qu'un simple doublon : il peut provenir d'un choix de split, d'une sélection de variables, ou d'une normalisation utilisant des statistiques calculées “dans le futur”.

2.2.3 Résultat clé (principe de validation temporelle)

Pour obtenir une estimation non biaisée de performance, la validation doit respecter la causalité : les ensembles d’entraînement doivent être antérieurs (ou, à minima, disjoints et sans information partagée) par rapport aux ensembles de validation. Ce principe se formalise par des découpages par blocs temporels :

- **fenêtre croissante (expanding window)** : on entraîne sur le passé, on valide sur un bloc futur ;
- **fenêtre glissante (rolling window)** : on entraîne sur une fenêtre récente, on valide juste après.

Le choix reflète un compromis : stabilité (beaucoup de données) versus pertinence (récence du régime).

Holdout final et risque d’optimisation. En pratique, on réserve un dernier bloc temporel (*holdout*) comme **test final**, consulté le plus tard possible. Le consulter itérativement pour choisir variables ou hyperparamètres le transforme en ensemble de développement et réintroduit un biais (optimisation sur le test). Une validation prudente multiplie les fenêtres et contrôle l’écart entre performances sur CV temporelle et sur holdout.

2.3 Métriques de performance par era : corrélation et stabilité

2.3.1 Corrélation de Pearson par era

Une métrique fréquente dans les problèmes de prédiction “faible signal” est la corrélation entre prédiction $\hat{y}$ et cible y , calculée *au sein de chaque era*. Pour une era e de taille n_e , avec $\{\hat{y}_i\}_{i \in \mathcal{I}_e}$ et $\{y_i\}_{i \in \mathcal{I}_e}$,

$$\rho_e(\hat{y}, y) = \frac{\sum_{i \in \mathcal{I}_e} (\hat{y}_i - \bar{\hat{y}}_e)(y_i - \bar{y}_e)}{\sqrt{\sum_{i \in \mathcal{I}_e} (\hat{y}_i - \bar{\hat{y}}_e)^2} \sqrt{\sum_{i \in \mathcal{I}_e} (y_i - \bar{y}_e)^2}}.$$

On obtient une série $\{\rho_e\}_{e=1}^E$, dont l’analyse renseigne sur la stabilité inter-eras.

2.3.2 Agrégation : moyenne, dispersion, ratio type Sharpe

On résume souvent la série par sa moyenne et sa dispersion :

$$\mu = \frac{1}{E} \sum_{e=1}^E \rho_e, \quad \sigma = \sqrt{\frac{1}{E-1} \sum_{e=1}^E (\rho_e - \mu)^2}, \quad \text{SR}_\rho = \frac{\mu}{\sigma}.$$

Le ratio SR_ρ (analogue à un Sharpe) mesure un compromis “niveau” versus “stabilité” : un signal faible mais régulier peut être préférable à un signal moyen plus élevé mais instable.

2.3.3 Limites

La corrélation de Pearson est sensible aux non-linéarités et aux queues ; elle peut varier fortement si la taille n_e est faible. Une validation robuste doit donc (i) analyser les distributions de ρ_e (asymétries, outliers), (ii) répéter sur plusieurs périodes, et (iii) compléter par des tests de stress (changements de régime, dérive de features).

2.4 Réduction de dimension et sélection de variables

2.4.1 Filtre de valeurs manquantes

Pour une variable f , on note le ratio de valeurs manquantes

$$\text{NA}(f) = \frac{\#\{i : x_{i,f} \text{ manquant}\}}{n}.$$

Un filtre $\text{NA}(f) \leq \tau$ est un contrôle simple visant à supprimer des variables trop instables.

2.4.2 Score univarié par association à la cible

Une sélection univariée consiste à calculer un score $s(f)$ (corrélation, information mutuelle approximée, etc.) et à retenir les top- K variables. L'intuition est de limiter le bruit et le coût de calcul en conservant des variables portant un signal "individuel".

Limites. Un filtre univarié ignore les interactions et la redondance entre variables ; il peut aussi sur-ajuster si le score est calculé en "regardant" la validation (leakage de sélection). Une pratique robuste consiste à figer la sélection sur une période d'entraînement, ou à la réévaluer par fold de validation temporelle.

2.5 Modèles et régularisation (vue théorique)

2.5.1 Gradient boosting sur arbres (GBDT)

Le gradient boosting construit un modèle additif

$$\hat{y}(x) = \sum_{t=1}^T \eta f_t(x),$$

où chaque f_t est un arbre de décision (faible apprenant) et η un pas d'apprentissage. L'idée est d'ajouter itérativement des arbres qui corrigent les erreurs des prédictions précédentes (descente de gradient dans l'espace des fonctions). La complexité est contrôlée par des paramètres de profondeur/feuilles, des échantillonnages (lignes/variables) et de la régularisation.

Arrêt anticipé (early stopping). L'arrêt anticipé consiste à interrompre l'apprentissage lorsque la performance sur validation n'améliore plus : il agit comme une forme de régularisation (on évite

d'ajouter des composantes qui n'apprennent que le bruit) et réduit le coût de calcul. Dans un cadre structuré en eras, il est cohérent de surveiller une métrique alignée avec l'objectif de stabilité (par exemple une corrélation agrégée par eras).

2.5.2 Ridge (régression linéaire régularisée)

La Ridge minimise

$$\min_{w \in \mathbb{R}^p} \frac{1}{n} \|y - Xw\|_2^2 + \alpha \|w\|_2^2,$$

avec $\alpha \geq 0$. Elle est utile comme baseline stable, et comme “meta-modèle” pour combiner des prédictions (stacking) lorsque la validation est stricte.

2.5.3 Réseaux (MLP) : principe et risques

Un perceptron multi-couches (MLP) approxime une fonction non-linéaire par compositions affines + activations. Il est expressif, mais sensible à la normalisation, à la régularisation, et au risque de sur-apprentissage si le protocole temporel n'est pas rigoureux.

2.6 Ensembles, OOF et post-traitements monotones

2.6.1 Ensembles : réduction de variance

L'agrégation de plusieurs modèles “semblables” (initialisations différentes, sous-échantillonnages) par moyenne

$$\hat{y}^{ens}(x) = \frac{1}{M} \sum_{m=1}^M \hat{y}^{(m)}(x)$$

réduit typiquement la variance et stabilise la performance par era, au prix d'un coût de calcul plus élevé.

2.6.2 OOF et stacking : prudence méthodologique

Le stacking consiste à apprendre un combinateur sur des prédictions *out-of-fold* (OOF), produites par des modèles de base sur des données non vues lors de leur entraînement. Le point critique est que le meta-modèle doit être validé avec le même soin temporel, faute de quoi il sur-ajuste la validation.

2.6.3 Ranking (transformée par CDF empirique)

Un post-traitement fréquent est la transformation par rang (CDF empirique) : si r_i est le rang de $\hat{y}_i$ parmi N observations,

$$\hat{y}_i^{\mathcal{J}} = \frac{r_i}{N}.$$

Cette transformation impose une distribution marginale uniforme (stabilité d'échelle). Elle préserve l'ordre (donc la corrélation de rang), mais modifie en général la corrélation linéaire ; son intérêt est surtout de limiter des effets de dérive de distribution et d'outliers.

2.6.4 Contrôles de cohérence (sanity checks)

Avant d'utiliser un modèle pour produire des décisions, des contrôles de cohérence limitent les erreurs grossières : (i) absence de valeurs manquantes dans les sorties, (ii) cohérence des dimensions (mêmes variables qu'en entraînement), (iii) détection d'effondrement de distribution (scores constants, valeurs extrêmes), et (iv) traçabilité des versions de données et d'hypothèses.

2.7 Lien avec le projet *PaperTradingApp*

Ces notions apparaissent dans le projet à deux niveaux : (i) comme **méthodologie** de validation pour toute brique “apprenante” (surrogates de pricing/calibration, classification de régimes, diagnostics de volatilité), et (ii) comme **garde-fous** contre l'illusion de performance (leakage temporel, sur-ajustement d'hyperparamètres, dérive de données). Elles complètent les chapitres de finance quantitative : un bon modèle de smile ou de régime n'est pas seulement expressif, il doit aussi être *robuste* et *testé* hors échantillon selon un protocole cohérent avec la temporalité des données de marché.

3 Décision séquentielle : MDP et apprentissage par renforcement

3.1 Prérequis : apprentissage supervisé

Le *supervised learning* consiste à apprendre une fonction

$$f_{\theta} : \mathcal{X} \rightarrow \mathcal{Y}$$

à partir d'un ensemble d'observations annotées $\{(x_i, y_i)\}_{i=1}^n$. L'objectif est de déterminer les paramètres θ minimisant une fonction de perte :

$$\theta^* = \arg \min_{\theta} \sum_{i=1}^n L(y_i, f_{\theta}(x_i)).$$

Cette approche regroupe la régression, la classification, les modèles linéaires, les modèles arborescents, les SVM, ainsi que les méthodes probabilistes (Gaussian Processes).

3.1.1 Fondamentaux

Tâches usuelles.

- **Régression** : prédiction de variables continues ($y \in \mathbb{R}$).

- **Classification** : prédiction de labels discrets ($y \in \{1, \dots, K\}$).

Séparation du dataset. Les données sont divisées en :

$$\text{train} \longrightarrow \text{validation} \longrightarrow \text{test}.$$

Cela permet d'évaluer la capacité de généralisation du modèle.

Overfitting / Underfitting.

- **Overfitting** : modèle trop complexe, apprend le bruit.
- **Underfitting** : modèle trop simple, structure insuffisante.

Biais-variance. Le risque prédit se décompose en :

$$\text{Erreur} = \text{Biais}^2 + \text{Variance} + \text{Bruit}.$$

L'objectif est de trouver un compromis optimal entre biais et variance.

Fonctions de perte.

- Régression :

$$\text{MSE}, \quad \text{MAE}, \quad \text{Huber}.$$

- Classification :

$$\text{cross-entropy}, \quad \text{log-loss}.$$

Optimisation. La mise à jour des paramètres suit la descente de gradient :

$$\theta \leftarrow \theta - \eta \nabla_{\theta} L.$$

Avec variantes :

$$\text{Momentum}, \quad \text{Nesterov}, \quad \text{Adam}, \quad \text{AdamW}, \quad \text{LR Scheduling}.$$

3.1.2 Modèles linéaires & factoriels

Régression linéaire.

$$\hat{y} = x^{\top} w.$$

Régression logistique.

$$p(y = 1|x) = \sigma(w^{\top} x), \quad \sigma(z) = \frac{1}{1 + e^{-z}}.$$

PCA (réduction dimensionnelle). On cherche les vecteurs propres maximisant :

$$\max_v v^\top \Sigma v,$$

où Σ est la matrice de covariance.

SVD. Décomposition :

$$X = U \Sigma V^\top,$$

fondamentale pour la factorisation matricielle et certains algorithmes de ML.

Gaussian Processes (GP). Modèle bayésien non-paramétrique :

$$f(x) \sim \mathcal{GP}(m(x), k(x, x')),$$

où k est un noyau (RBF, Matérn, etc.). Prédiction :

$$f(x_*)|X, y \sim \mathcal{N}(\mu_*, \sigma_*^2).$$

Bases de Bernstein. Bases polynomiales utilisées pour approximer des fonctions :

$$B_{k,n}(x) = \binom{n}{k} x^k (1-x)^{n-k}.$$

Régularisation.

- Ridge : $\|w\|_2^2$
- Lasso : $\|w\|_1$
- ElasticNet : combinaison des deux

3.1.3 Arbres & Ensembles

Arbres de décision. Un arbre partitionne l'espace des features :

$$x \mapsto \text{Région}_i \mapsto \hat{y}_i.$$

Bagging. Bootstrap + vote majoritaire :

$$f(x) = \text{Majority}(h_1(x), \dots, h_T(x)).$$

Random Forest. Bagging + sélection aléatoire de variables à chaque split.

Boosting. Construction séquentielle :

$$f_T(x) = f_{T-1}(x) + \eta h_T(x),$$

où h_T corrige les erreurs du modèle précédent.

Méthodes principales : AdaBoost, GradientBoosting, XGBoost, LightGBM, CatBoost.

Stacking. Combinaison de plusieurs modèles via un méta-modèle (logistique, réseau neural, ridge).

3.2 Unsupervised Learning

L'apprentissage non supervisé vise à identifier des structures, regrouper des observations ou réduire la dimensionnalité d'un jeu de données sans disposer de labels explicites. Ces méthodes sont essentielles pour la détection de régimes, la segmentation de marché, la compression de données et la découverte de facteurs latents.

3.2.1 Clustering

K-Means. Le K-Means vise à partitionner un ensemble de points $\{x_i\}_{i=1}^n \subset \mathbb{R}^d$ en K groupes en minimisant l'inertie intra-cluster :

$$\min_{C_1, \dots, C_K} \sum_{k=1}^K \sum_{x_i \in C_k} \|x_i - \mu_k\|^2,$$

où μ_k est le barycentre du cluster C_k .

L'algorithme alterne entre :

- *assignment* des points aux centres les plus proches,
- *mise à jour* des centres.

La convergence est rapide mais dépend de l'initialisation.

3.2.2 Anomaly / Novelty Detection

One-Class SVM. Le One-Class SVM estime la frontière d'un ensemble de données non étiquetées. On cherche une fonction f telle que la majorité des points vérifient $f(x) \geq 0$.

Formulation :

$$\min_{w, \rho, \xi_i} \frac{1}{2} \|w\|^2 + \frac{1}{\nu n} \sum_i \xi_i - \rho \quad \text{s.c.} \quad w^\top \phi(x_i) \geq \rho - \xi_i.$$

Les anomalies sont les points pour lesquels $f(x) < 0$.

3.2.3 Réduction dimensionnelle

PCA (Principal Component Analysis). On diagonalise la matrice de covariance :

$$\Sigma = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(x_i - \bar{x})^\top = Q\Lambda Q^\top.$$

Les vecteurs propres q_k correspondant aux plus grandes valeurs propres capturent les directions de variance maximale.

SVD (Singular Value Decomposition). Pour une matrice $X \in \mathbb{R}^{n \times d}$:

$$X = U\Sigma V^\top.$$

La SVD est la base de :

- la compression,
- la factorisation,
- la résolution de systèmes linéaires,
- les méthodes de recommandation.

t-SNE. Méthode non linéaire conservant des distances locales via une minimisation de divergence de Kullback–Leibler entre les voisinages dans l’espace initial et l’espace réduit.

3.2.4 Séries temporelles classiques

Stationnarité. Une série (X_t) est stationnaire si :

$$\mathbb{E}[X_t] = \mu, \quad \text{Var}(X_t) = \sigma^2, \quad \text{Cov}(X_t, X_{t+h}) = \gamma(h).$$

Les modèles ARMA supposent la stationnarité.

AR(p).

$$X_t = \sum_{i=1}^p \phi_i X_{t-i} + \varepsilon_t.$$

MA(q).

$$X_t = \sum_{i=1}^q \theta_i \varepsilon_{t-i} + \varepsilon_t.$$

ARMA(p,q).

$$X_t = \sum_{i=1}^p \phi_i X_{t-i} + \sum_{j=1}^q \theta_j \varepsilon_{t-j} + \varepsilon_t.$$

ARIMA(p,d,q). Pour gérer la non-stationnarité :

$$\Delta^d X_t \sim \text{ARMA}(p, q).$$

Les modèles ARIMA sont très utilisés pour la détection de tendances, la prévision de volatilité, ou l'analyse de séries financières en basse fréquence.

3.3 Deep Learning

Le deep learning repose sur les réseaux de neurones artificiels, capables d'approximer des fonctions complexes par composition de transformations linéaires et non linéaires. Il permet de traiter des données structurées (images, séries temporelles, texte) via des architectures spécialisées.

3.3.1 Bases

Perceptron. Le neurone élémentaire applique :

$$z = w^\top x + b, \quad a = \sigma(z),$$

où σ est une fonction d'activation (ReLU, sigmoid, tanh, GELU).

MLP (Multi-Layer Perceptron). Un réseau profond est une composition :

$$f(x) = \sigma_L(W_L \sigma_{L-1}(W_{L-1} \cdots \sigma_1(W_1 x))).$$

Problème du vanishing/exploding gradient. Lorsque la profondeur augmente, les gradients peuvent diverger ou s'annuler. Solutions :

- initialisation Xavier/He,
- BatchNorm / LayerNorm,
- activations adaptées (ReLU, GELU).

Normalisation et régularisation.

- **BatchNorm** : normalisation des activations au sein du batch.
- **LayerNorm** : normalisation par feature.
- **Dropout** : régularisation par mise à zéro aléatoire d'activations.

3.3.2 Convolutional Neural Networks (CNN)

Les CNN sont adaptés aux données spatiales (images, cartes de features).

Convolution.

$$(\text{Conv}(x))_{i,j} = \sum_{u,v} K_{u,v} x_{i+u,j+v}.$$

Les noyaux (kernels) extraient des motifs locaux (bords, textures).

Stride, padding. Le *stride* contrôle le sous-échantillonnage. Le *padding* permet de conserver la taille spatiale.

Pooling.

$$\text{max-pool}(x)_{i,j} = \max_{u,v \in \text{patch}} x_{i+u,j+v}.$$

Enfin, les couches convolutionnelles sont suivies de denses :

$$\text{Conv} \rightarrow \text{ReLU} \rightarrow \dots \rightarrow \text{Flatten} \rightarrow \text{Dense} \rightarrow \text{Softmax}.$$

3.3.3 RNN, LSTM, GRU

Les RNN sont adaptés aux séries temporelles.

RNN simple.

$$h_t = \sigma(W_h h_{t-1} + W_x x_t + b).$$

Limites : pas parallélisable, gradient vanishing.

LSTM. Le LSTM introduit des portes :

$$\begin{aligned} f_t &= \sigma(W_f x_t + U_f h_{t-1} + b_f), \\ i_t &= \sigma(W_i x_t + U_i h_{t-1} + b_i), \\ \tilde{c}_t &= \tanh(W_c x_t + U_c h_{t-1} + b_c), \\ c_t &= f_t \odot c_{t-1} + i_t \odot \tilde{c}_t, \\ h_t &= o_t \odot \tanh(c_t). \end{aligned}$$

GRU. Structure simplifiée :

$$\begin{aligned} z_t &= \sigma(W_z x_t + U_z h_{t-1}), \\ r_t &= \sigma(W_r x_t + U_r h_{t-1}), \\ h_t &= (1 - z_t) \odot \tilde{h}_t + z_t h_{t-1}. \end{aligned}$$

3.3.4 Transformers

Le Transformer repose sur le *self-attention*.

Tokenisation. Les entrées sont découpées en jetons (BPE, WordPiece).

Embeddings.

$$x_i \mapsto e_i \in \mathbb{R}^d,$$

plus un encodage positionnel :

$$p_t = (\sin(t/10000^{2k/d}), \cos(t/10000^{2k/d})).$$

Attention Q/K/V. Chaque token produit trois vecteurs :

$$Q = W_Q e, \quad K = W_K e, \quad V = W_V e.$$

On calcule :

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d}}\right) V.$$

Intuition : - Q “cherche” des informations pertinentes, - K dit quelles informations chaque token “porte”, - V apporte la valeur combinée.

Entraînement.

- GPT : *next token prediction*,
- BERT : *masked language modeling*.

3.3.5 Modèles génératifs

Autoencodeurs. Un AE apprend une compression :

$$z = f_\theta(x), \quad \hat{x} = g_\theta(z).$$

VAE (Variational Autoencoder).

$$z \sim \mathcal{N}(\mu(x), \Sigma(x)), \quad \mathcal{L} = \mathbb{E}[\|x - \hat{x}\|^2] + \text{KL}(q(z|x) \parallel p(z)).$$

VQ-VAE. Quantification discrète via dictionnaire de codes.

GAN.

$$\min_G \max_D \mathbb{E}[\log D(x)] + \mathbb{E}[\log(1 - D(G(z)))].$$

VQ-GAN. GAN + quantisation vectorielle (utilisé dans Stable Diffusion).

Diffusion Models.

$$x_T \sim \mathcal{N}(0, I), \quad x_{t-1} = \text{denoise}_\theta(x_t).$$

Ce sont les modèles sous-jacents à DALL·E 2, Stable Diffusion, Imagen.

3.4 Reinforcement Learning

Le Reinforcement Learning (RL) étudie l'interaction entre un agent et un environnement. À chaque étape, l'agent observe un état s_t , choisit une action a_t , reçoit une récompense $\mathcal{R}_t$, et l'environnement évolue selon une dynamique inconnue. L'objectif est de maximiser la récompense cumulée.

3.4.1 Concepts fondamentaux

Un processus de décision est modélisé par un MDP (Markov Decision Process) :

$$(\mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R}, \gamma_{\text{RL}}),$$

où

- $\mathcal{S}$: espace des états,
- $\mathcal{A}$: espace des actions,
- $\mathcal{P}(s'|s, a)$: dynamique (transition),
- $\mathcal{R}(s, a)$: récompense immédiate,
- $\gamma_{\text{RL}} \in (0, 1)$: facteur d'escompte (sans lien avec les taux r_t).

La politique $\pi(a|s)$ définit le comportement de l'agent.

3.4.2 Fonctions de valeur et équations de Bellman

La **valeur d'une politique** π est :

$$V^\pi(s) = \mathbb{E}_\pi \left[\sum_{t=0}^{\infty} \gamma_{\text{RL}}^t \mathcal{R}(s_t, a_t) \mid s_0 = s \right].$$

La **valeur d'état-action** :

$$Q^\pi(s, a) = \mathbb{E}_\pi \left[\sum_{t=0}^{\infty} \gamma_{\text{RL}}^t \mathcal{R}(s_t, a_t) \mid s_0 = s, a_0 = a \right].$$

Les équations de Bellman caractérisent ces valeurs :

$$V^\pi(s) = \sum_a \pi(a|s) \sum_{s'} \mathcal{P}(s'|s, a) (\mathcal{R}(s, a) + \gamma_{\text{RL}} V^\pi(s')),$$

$$Q^\pi(s, a) = \mathcal{R}(s, a) + \gamma_{\text{RL}} \sum_{s'} \mathcal{P}(s'|s, a) \sum_{a'} \pi(a'|s') Q^\pi(s', a').$$

La **valeur optimale** satisfait :

$$V^*(s) = \max_a Q^*(s, a).$$

3.4.3 Monte Carlo (MC)

Le MC estime la valeur par *retours échantillonnés* :

$$G_t = \sum_{k=0}^{\infty} \gamma_{\text{RL}}^k \mathcal{R}_{t+k}.$$

Mise à jour :

$$V(s) \leftarrow V(s) + \alpha(G - V(s)).$$

Méthodes :

- First-Visit MC,
- Every-Visit MC,
- MC à α constant.

3.4.4 Temporal Difference (TD)

Les méthodes TD mettent à jour la valeur à partir d'une seule transition :

$$V(s_t) \leftarrow V(s_t) + \alpha(\mathcal{R}_t + \gamma_{\text{RL}} V(s_{t+1}) - V(s_t)).$$

TD(0).

$$\delta_t = \mathcal{R}_t + \gamma_{\text{RL}} V(s_{t+1}) - V(s_t).$$

TD(n)-step.

$$G_t^{(n)} = \sum_{k=0}^{n-1} \gamma_{\text{RL}}^k \mathcal{R}_{t+k} + \gamma_{\text{RL}}^n V(s_{t+n}).$$

TD(λ). Combinaison pondérée des retours n -step.

3.4.5 SARSA, Expected SARSA, Q-Learning

SARSA (on-policy).

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha(\mathcal{R}_t + \gamma_{\text{RL}} Q(s_{t+1}, a_{t+1}) - Q(s_t, a_t)).$$

Expected SARSA.

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha \left(\mathcal{R}_t + \gamma_{\text{RL}} \sum_{a'} \pi(a'|s_{t+1}) Q(s_{t+1}, a') - Q(s_t, a_t) \right).$$

Q-Learning (off-policy).

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha(\mathcal{R}_t + \gamma_{\text{RL}} \max_{a'} Q(s_{t+1}, a') - Q(s_t, a_t)).$$

3.4.6 On-policy vs Off-policy

- **On-policy** : on apprend la valeur de la politique suivie (SARSA).
- **Off-policy** : on apprend la politique optimale tout en explorant différemment (Q-Learning).

Importance sampling permet de corriger les biais off-policy.

3.4.7 Function Approximation

Lorsque l'espace des états est trop grand, on approxime :

$$V(s; \theta), \quad Q(s, a; \theta).$$

Mise à jour TD :

$$\theta \leftarrow \theta + \alpha \delta_t \nabla_{\theta} V(s_t; \theta), \quad \delta_t = \mathcal{R}_t + \gamma_{\text{RL}} V(s_{t+1}) - V(s_t).$$

Bases :

- features manuelles (polynômes, splines, bases de Bernstein),
- réseaux neuronaux (Deep RL).

3.4.8 Deep Q-Network (DQN) : comprendre le mécanisme pas à pas

Le DQN (Deep Q-Network) est l'idée de Q-learning appliquée à des espaces d'états continus ou de grande dimension, en remplaçant la table $Q(s, a)$ par un réseau de neurones $Q_{\theta}(s, a)$.

Point de départ : l'équation de Bellman optimale. La fonction Q^* satisfait

$$Q^*(s, a) = \mathcal{R}(s, a) + \gamma_{\text{RL}} \mathbb{E} \left[\max_{a'} Q^*(s', a') \mid s, a \right].$$

Le Q-learning tabulaire est une descente stochastique vers cette identité en utilisant une transition observée (s_t, a_t, r_t, s_{t+1}) .

1. Approximation paramétrique de Q . On choisit une famille $Q_{\theta}(s, a)$ (par exemple un MLP) et l'on veut ajuster θ pour que les valeurs prédites satisfassent, en moyenne, l'équation de Bellman.

2. Cible TD (temporal-difference target). Sur une transition (s, a, r, s') , la cible "Bellman" naturelle est

$$y := r + \gamma_{\text{RL}} \max_{a'} Q_{\theta}(s', a').$$

On cherche à rendre $Q_{\theta}(s, a)$ proche de y .

3. Perte : l'erreur de Bellman (MSE). Le DQN minimise une perte de type

$$L(\theta) = \mathbb{E}[(y - Q_\theta(s, a))^2],$$

où l'espérance est approximée par une moyenne sur un mini-batch de transitions. La mise à jour se fait par descente de gradient :

$$\theta \leftarrow \theta - \eta \nabla_\theta L(\theta).$$

Pourquoi le schéma naïf diverge souvent. Si l'on utilise le même réseau pour prédire $Q_\theta(s, a)$ et construire la cible y , alors la cible bouge à chaque itération (*moving target*) et l'on apprend sur des données très corrélées dans le temps (trajectoire), ce qui crée des instabilités. Le DQN stabilise l'apprentissage par deux idées clés.

4. Experience replay : décorrélérer et réutiliser les données. On stocke des transitions $(s, a, r, s', \text{done})$ dans un buffer $\mathcal{D}$, puis on entraîne sur des mini-batches *tirés aléatoirement* dans $\mathcal{D}$. Cela :

- casse les corrélations temporelles (les mini-batches ressemblent à des tirages i.i.d.) ;
- améliore l'efficacité échantillon (une transition est réutilisée plusieurs fois) ;
- lisse l'évolution des cibles (les données vues par le réseau varient moins brutalement).

5. Target network : figer la cible pendant quelques pas. On introduit un second réseau Q_{θ^-} (copie retardée) utilisé uniquement pour construire la cible :

$$y := r + \gamma_{\text{RL}} \max_{a'} Q_{\theta^-}(s', a').$$

Les paramètres θ^- sont mis à jour périodiquement (toutes les C itérations) par copie : $\theta^- \leftarrow \theta$. Ainsi, y est (temporairement) une cible plus stable.

6. Politique d'exploration : ϵ -greedy. L'agent collecte des données avec une politique d'exploration typique :

$$a = \begin{cases} \text{action aléatoire} & \text{avec proba. } \epsilon, \\ \arg \max_{a'} Q_\theta(s, a') & \text{avec proba. } 1 - \epsilon. \end{cases}$$

On fait décroître ϵ au cours du temps (explorer puis exploiter) afin de construire un replay buffer riche.

7. DQN en une boucle d'apprentissage (vue conceptuelle). Sans pseudo-code, l'enchaînement est :

1. initialiser Q_θ et Q_{θ^-} , et un buffer $\mathcal{D}$;

2. répéter : exécuter une action (avec exploration), observer $(s, a, r, s', \text{done})$, stocker dans $\mathcal{D}$;
3. tirer un mini-batch dans $\mathcal{D}$ et minimiser $L(\theta)$ avec la cible construite par Q_{θ^-} ;
4. toutes les C itérations, mettre à jour $\theta^- \leftarrow \theta$.

Exemple minimal : calcul d’une cible et d’une perte. Considérons une transition $(s, a, r, s', \text{done})$ tirée du replay buffer. Le DQN construit une cible scalaire

$$y = \begin{cases} r & \text{si done = vrai,} \\ r + \gamma_{\text{RL}} \max_{a'} Q_{\theta^-}(s', a') & \text{sinon.} \end{cases}$$

La contribution de cette transition à la perte est alors

$$\ell(\theta) = (y - Q_{\theta}(s, a))^2,$$

et l’actualisation de θ déplace $Q_{\theta}(s, a)$ dans la direction de y . Sur un mini-batch, on moyenne simplement ces contributions, ce qui revient à ajuster simultanément les valeurs sur plusieurs couples (s, a) et à stabiliser le gradient.

8. Sur-estimation et variantes : Double DQN. Le terme $\max_{a'} Q(\cdot)$ introduit un biais de sur-estimation (le maximum d’estimateurs bruités est biaisé). Double DQN décorrèle *sélection* et *évaluation* :

$$y := r + \gamma_{\text{RL}} Q_{\theta^-}(s', \arg \max_{a'} Q_{\theta}(s', a')).$$

Cas pratique : actions discrètes vs continues. Le DQN suppose un ensemble d’actions discret. En finance, une couverture naturelle peut être continue (quantité de sous-jacent). Une stratégie standard consiste à *discrétiser* l’action (par ex. des incréments de hedge $\{\dots, -2\Delta, -\Delta, 0, \Delta, 2\Delta, \dots\}$), ce qui rend le problème traitable par DQN au prix d’un compromis précision/coût de transaction. Pour des actions continues, on se tourne plutôt vers des approches actor-critic (DDPG/TD3/SAC) ; le DQN reste un point d’entrée pédagogique robuste.

9. Dueling networks et prioritized replay (options).

- **Dueling** : décomposer $Q_{\theta}(s, a) = V_{\theta}(s) + A_{\theta}(s, a)$ pour mieux gérer les nombreux a .
- **Prioritized replay** : sur-échantillonner les transitions à forte erreur TD $|y - Q_{\theta}(s, a)|$.

Lecture “finance” : DQN comme apprentissage de couverture. Dans une formulation MDP de couverture, s_t agrège l’information (temps restant, spot, vol implicite, greeks, etc.), l’action a_t représente un ajustement discret de hedge (quantité d’actif sous-jacent, ou position en options de couverture), et la récompense pénalise le risque et les coûts (variance de PnL, drawdown, coût

de transaction). Le DQN apprend alors une approximation de $Q^*(s, a)$ permettant de décider un hedge discret optimal sous coûts et contraintes.

Points de vigilance. Le DQN est sensible à : (i) l'échelle des récompenses, (ii) la non-stationnarité des données (marché), (iii) la définition de l'état et des actions, et (iv) les contraintes de risque (VaR/ES, limites) à intégrer dans la récompense ou via des contraintes.

3.4.9 Policy Gradient Methods

Les méthodes de gradient de politique optimisent $\pi_\theta(a|s)$ directement.

Objectif.

$$J(\theta) = \mathbb{E}_{\pi_\theta}[G_t].$$

REINFORCE.

$$\theta \leftarrow \theta + \alpha G_t \nabla_\theta \log \pi_\theta(a_t|s_t).$$

Actor–Critic.

$$\theta_{\text{policy}} \leftarrow \theta_{\text{policy}} + \alpha \delta_t \nabla_\theta \log \pi_\theta(a_t|s_t),$$

$$\theta_{\text{value}} \leftarrow \theta_{\text{value}} + \alpha \delta_t \nabla_\theta V(s_t; \theta_{\text{value}}).$$

PPO (Proximal Policy Optimization). Méthode stable basée sur une pénalisation du ratio de probabilité :

$$L^{\text{PPO}}(\theta) = \mathbb{E} \left[\min (\omega_t(\theta) \hat{A}_t, \text{clip}(\omega_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t) \right].$$

Synthèse. Le RL combine :

- estimation de valeurs (MC, TD),
- apprentissage d'actions optimales (SARSA, Q-Learning),
- optimisation directe de politiques (Policy Gradient, Actor–Critic, PPO),
- approximation de fonctions (Deep RL),
- compromis exploration/exploitation et stabilité d'apprentissage.

Ces techniques sont essentielles pour les stratégies séquentielles, l'optimisation de portefeuilles, la gestion dynamique du risque, et les modèles décisionnels non paramétriques.

4 Conclusion et ouverture

Ce document a parcouru les fondements de la finance quantitative moderne en prenant pour fil conducteur le projet *PaperTradingApp* : produits dérivés, modélisation stochastique, pricing et

Greeks, volatilité implicite et calibration, construction de courbe de taux, gestion du risque et allocation, ainsi qu’une ouverture vers des outils d’apprentissage utiles à la calibration (surrogates) et à la décision séquentielle (MDP/RL).

L’ensemble constitue une base conceptuelle solide pour analyser un système de trading dérivés de bout en bout : données, hypothèses de modèles, incertitudes, limites numériques et contrôles de risque.

4.1 Synthèse

Les points suivants peuvent être retenus :

- Les produits dérivés (vanilles et exotiques) s’analysent via la mesure risque-neutre, les EDS et des méthodes numériques (arbres, PDE, Monte Carlo, Fourier/FFT).
- Les Greeks structurent la lecture du risque et la couverture (delta/gamma/vega), et permettent d’anticiper les erreurs de hedging sous coûts de transaction et risque de modèle.
- Les surfaces de volatilité implicite résument l’information options ; la calibration relie cette surface à des modèles (Heston, SABR, rough/Volterra, sauts) et met en évidence les compromis de paramétrisation.
- La courbe de taux (discounting/forwards) est un ingrédient transversal : cohérence absence d’arbitrage, choix d’interpolation/extrapolation, paramétrisations lisses (Nelson–Siegel).
- La gestion du risque au niveau portefeuille nécessite des indicateurs actionnables (PnL, drawdowns, VaR/ES), ainsi que des règles d’allocation (à la Markowitz, risk parity, eigenportfolios).
- L’apprentissage apporte des outils complémentaires : surrogates pour accélérer la calibration et formulation MDP/RL pour des problèmes de décision séquentielle (couverture, rebalancement).

4.2 Ouverture

Plusieurs directions naturelles s’ouvrent à la suite de ce travail :

- **Qualité des données et microstructure** : modéliser explicitement bid–ask, coûts de transaction et non-synchronisme spot/options, et mesurer l’impact sur surfaces, calibration, backtests et risque.
- **Volatilité rugueuse et SDE de Volterra** : extension non markovienne des modèles de variance, offrant une flexibilité accrue pour ajuster des smiles courts (selon les données et la pondération), et une modélisation explicite de la mémoire longue.
- **Modèles multi-facteurs et modélisation affine avancée** : dynamiques jointes des variances, taux et spreads, incluant corrélations stochastiques.

- **Accélération numérique et stabilité** : réduction de variance, schémas de discrétisation stables, FFT (Carr–Madan) et approximations markoviennes des modèles à mémoire.
- **Surrogates pour le pricing et la calibration** : approximations supervisées de cartes $(K, T, \theta) \mapsto C$ ou σ_{imp} , utilisables pour initialiser des calibrations et accélérer des diagnostics, sous contraintes arbitrage-free.
- **Reinforcement Learning pour la gestion dynamique du risque** : agents apprenant des stratégies de hedging optimales (delta-gamma-vega), optimisation de portefeuilles, ou exécution optimale.
- **Validation out-of-sample et contrôle de risque de modèle** : protocoles de validation, stress tests, régularisation, et mesure de la stabilité des paramètres calibrés.

4.3 Conclusion générale

Cette synthèse met en évidence l’interconnexion entre :

- maths appliquées (EDS, variation quadratique, PDE),
- finance quantitative (pricing, surfaces de volatilité, calibrations),
- machine learning (apprentissage supervisé, non supervisé, deep learning),
- reinforcement learning (prise de décision séquentielle).

L’objectif est de fournir une vision cohérente et moderne des outils quantitatifs utilisables en finance de marché. Des sections de dérivations pas à pas (Heston, fBM, Volterra/rough Bergomi, SABR, rough Heston, méthodes numériques) complètent le dossier pour servir de base à des travaux plus avancés.

5 SDE de Volterra et modèle rough Bergomi

Simulation du mouvement brownien fractionnaire — Méthode de Davies–Harte et lien avec le modèle rough Bergomi

Dans tout ce qui suit, $H \in (0, 1)$ désigne le paramètre de Hurst. On note $(B^H(t))_{t \geq 0}$ un mouvement brownien fractionnaire normalisé, c’est-à-dire un processus gaussien centré tel que, pour $t, s \geq 0$,

$$\text{Cov}(B^H(t), B^H(s)) = R_H(t, s) = \frac{1}{2} (t^{2H} + s^{2H} - |t - s|^{2H}). \quad (81)$$

On veut simuler numériquement la trajectoire $(B^H(t_k))_{k=0, \dots, N}$ sur une période $[0, T]$.

I. Discrétisation du fBm et définition du bruit fractionnaire

On fixe un nombre de pas $N \in \mathbb{N}^*$ et on définit

$$\Delta t = \frac{T}{N}, \quad t_k = k \Delta t, \quad k = 0, \dots, N. \quad (82)$$

On introduit les *incrément*s (ou *fractional Gaussian noise* / fGn) par

$$X_k = B^H(t_{k+1}) - B^H(t_k), \quad k = 0, \dots, N-1. \quad (83)$$

Les X_k forment une suite gaussienne centrée, stationnaire, mais corrélée (sauf si $H = \frac{1}{2}$, cas brownien classique).

La fBm discrète est alors reconstruite par sommation :

$$B^H(t_k) = \sum_{j=0}^{k-1} X_j, \quad k = 0, \dots, N, \quad (84)$$

avec la convention $B^H(t_0) = B^H(0) = 0$.

En pratique on simulera d'abord le bruit fractionnaire $(X_0, \dots, X_{N-1})$, puis on cumulera pour obtenir B^H .

II. Calcul détaillé de la covariance du bruit fractionnaire

On veut obtenir la covariance

$$\gamma(m) = \text{Cov}(X_0, X_m), \quad m \in \mathbb{Z}.$$

En utilisant la définition des incréments,

$$X_0 = B^H(\Delta t) - B^H(0), \quad X_m = B^H((m+1)\Delta t) - B^H(m\Delta t).$$

Par bilinéarité de la covariance,

$$\gamma(m) = \text{Cov}(B^H(\Delta t) - B^H(0), B^H((m+1)\Delta t) - B^H(m\Delta t)) \quad (85)$$

$$\begin{aligned} &= \text{Cov}(B^H(\Delta t), B^H((m+1)\Delta t)) - \text{Cov}(B^H(\Delta t), B^H(m\Delta t)) \\ &\quad - \text{Cov}(B^H(0), B^H((m+1)\Delta t)) + \text{Cov}(B^H(0), B^H(m\Delta t)). \end{aligned} \quad (86)$$

On utilise la formule de covariance (81). On traite chaque terme de (86).

1. Premier terme.

$$\text{Cov}(B^H(\Delta t), B^H((m+1)\Delta t)) = \frac{1}{2} [(\Delta t)^{2H} + ((m+1)\Delta t)^{2H} - |(m+1)\Delta t - \Delta t|^{2H}] \quad (87)$$

$$= \frac{1}{2} [(\Delta t)^{2H} + ((m+1)\Delta t)^{2H} - (m\Delta t)^{2H}]. \quad (88)$$

2. Deuxième terme.

$$\text{Cov}(B^H(\Delta t), B^H(m\Delta t)) = \frac{1}{2} [(\Delta t)^{2H} + (m\Delta t)^{2H} - |m\Delta t - \Delta t|^{2H}] \quad (89)$$

$$= \frac{1}{2} [(\Delta t)^{2H} + (m\Delta t)^{2H} - ((m-1)\Delta t)^{2H}]. \quad (90)$$

3. Troisième terme.

$$\text{Cov}(B^H(0), B^H((m+1)\Delta t)) = \frac{1}{2} [0^{2H} + ((m+1)\Delta t)^{2H} - |(m+1)\Delta t|^{2H}] \quad (91)$$

$$= 0, \quad (92)$$

car les deux derniers termes se compensent.

4. Quatrième terme.

$$\text{Cov}(B^H(0), B^H(m\Delta t)) = \frac{1}{2} [0^{2H} + (m\Delta t)^{2H} - |m\Delta t|^{2H}] \quad (93)$$

$$= 0. \quad (94)$$

En reportant ces expressions dans (86),

$$\gamma(m) = \frac{1}{2} [(\Delta t)^{2H} + ((m+1)\Delta t)^{2H} - (m\Delta t)^{2H}] \quad (95)$$

$$- \frac{1}{2} [(\Delta t)^{2H} + (m\Delta t)^{2H} - ((m-1)\Delta t)^{2H}] \quad (96)$$

$$= \frac{1}{2} [(\Delta t)^{2H} + ((m+1)\Delta t)^{2H} - (m\Delta t)^{2H} \quad (97)$$

$$- (\Delta t)^{2H} - (m\Delta t)^{2H} + ((m-1)\Delta t)^{2H}] \quad (98)$$

$$= \frac{1}{2} [((m+1)\Delta t)^{2H} - 2(m\Delta t)^{2H} + ((m-1)\Delta t)^{2H}]. \quad (99)$$

On factorise $(\Delta t)^{2H}$:

$$\gamma(m) = \frac{(\Delta t)^{2H}}{2} (|m+1|^{2H} - 2|m|^{2H} + |m-1|^{2H}), \quad m \in \mathbb{Z}. \quad (100)$$

Pour alléger les notations, on introduit la covariance *normalisée* (associée au pas unité) :

$$\gamma_0(m) = \frac{1}{2} (|m+1|^{2H} - 2|m|^{2H} + |m-1|^{2H}), \quad (101)$$

de sorte que

$$\gamma(m) = (\Delta t)^{2H} \gamma_0(m). \quad (102)$$

La suite $(\gamma_0(m))_{m \in \mathbb{Z}}$ est la covariance théorique du bruit fractionnaire unit-temps.

III. Construction du vecteur de covariance circulante

La covariance des N premiers incréments $X_0, \dots, X_{N-1}$ est la matrice Toeplitz

$$\Gamma_N = \begin{pmatrix} \gamma_0(0) & \gamma_0(1) & \cdots & \gamma_0(N-1) \\ \gamma_0(1) & \gamma_0(0) & \cdots & \gamma_0(N-2) \\ \vdots & \vdots & \ddots & \vdots \\ \gamma_0(N-1) & \gamma_0(N-2) & \cdots & \gamma_0(0) \end{pmatrix}. \quad (103)$$

La méthode de Davies–Harte consiste à *encastrier* cette matrice Toeplitz dans une matrice *circulante* de taille $M = 2N$, ce qui permet d'utiliser la FFT.

On définit le vecteur de longueur $M = 2N$:

$$c = (c_0, c_1, \dots, c_{M-1}) = (\gamma_0(0), \gamma_0(1), \dots, \gamma_0(N-1), \gamma_0(N), \gamma_0(N-1), \dots, \gamma_0(1)). \quad (104)$$

C'est un vecteur *pair* au sens où $c_j = c_{M-j}$ pour $j = 1, \dots, M-1$.

On construit ensuite la matrice circulante

$$\mathbf{C} = (c_{(j-k) \bmod M})_{0 \leq j, k \leq M-1} \in \mathbb{R}^{M \times M}. \quad (105)$$

Explicitement,

$$\mathbf{C} = \begin{pmatrix} c_0 & c_1 & c_2 & \cdots & c_{M-1} \\ c_{M-1} & c_0 & c_1 & \cdots & c_{M-2} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ c_1 & c_2 & c_3 & \cdots & c_0 \end{pmatrix}.$$

Le sous-bloc supérieur gauche de taille $N \times N$ est exactement la matrice de covariance Γ_N des N premiers incréments, grâce à la définition de c .

IV. Diagonalisation de la matrice circulante par FFT

On pose $M = 2N$ et on considère la matrice de Fourier discrète normalisée (unitaire) :

$$F_{jk} = \frac{1}{\sqrt{M}} e^{-2i\pi jk/M}, \quad j, k = 0, \dots, M-1. \quad (106)$$

On a alors $F^{-1} = F^*$ (conjuguée-transposée).

Propriété fondamentale : toute matrice circulante C se diagonalise dans la base de Fourier :

$$C = F^* \Delta F, \quad (107)$$

où Δ est diagonale. Les valeurs propres $(\lambda_0, \dots, \lambda_{M-1})$ sont données par la transformée de Fourier du premier rang de C , c'est-à-dire du vecteur c :

$$\lambda_k = \sum_{j=0}^{M-1} c_j e^{-2i\pi jk/M}, \quad k = 0, \dots, M-1. \quad (108)$$

En notation compacte,

$$\boldsymbol{\lambda} = (\lambda_0, \dots, \lambda_{M-1})^\top = \text{FFT}(c), \quad (109)$$

et

$$\Delta = \text{diag}(\lambda_0, \dots, \lambda_{M-1}). \quad (110)$$

Puisque c est réel et pair, tous les λ_k sont réels. Pour que la méthode soit valide, il faut en plus $\lambda_k \geq 0$ pour tout k (ce qui est garanti pour la fBm dans un certain domaine de paramètres ; en pratique on vérifie numériquement que les valeurs propres sont non négatives).

On obtient donc la factorisation

$$C = F^* \Delta F. \quad (111)$$

V. Construction d'un vecteur gaussien de covariance C

On cherche maintenant un vecteur gaussien complexe

$$Y = (Y_0, \dots, Y_{M-1})^\top \in \mathbb{C}^M$$

tel que

$$\mathbb{E}[Y] = 0, \quad \mathbb{E}[Y Y^*] = C. \quad (112)$$

V.1. Idée générale

Soit $Z \in \mathbb{C}^M$ un vecteur gaussien complexe dit *standard*, c'est-à-dire

$$\mathbb{E}[Z] = 0, \quad \mathbb{E}[Z Z^*] = I_M \quad (113)$$

(I_M matrice identité). Posons

$$Y = F^* \Delta^{1/2} Z, \quad (114)$$

où $\Delta^{1/2} = \text{diag}(\sqrt{\lambda_0}, \dots, \sqrt{\lambda_{M-1}})$.

Alors

$$\mathbb{E}[Y] = F^* \Delta^{1/2} \mathbb{E}[Z] = 0, \quad (115)$$

et

$$\mathbb{E}[Y Y^*] = \mathbb{E}[F^* \Delta^{1/2} Z (F^* \Delta^{1/2} Z)^*] \quad (116)$$

$$= F^* \Delta^{1/2} \mathbb{E}[Z Z^*] \Delta^{1/2} F \quad (117)$$

$$= F^* \Delta^{1/2} I_M \Delta^{1/2} F \quad (118)$$

$$= F^* \Delta F = C. \quad (119)$$

Ainsi, tout vecteur de la forme $Y = F^* \Delta^{1/2} Z$ a bien la covariance souhaitée.

V.2. Construction explicite de Z et réalité du signal

Pour que le vecteur final que l'on utilisera soit *réel*, on impose à Z une symétrie conjuguée particulière. On pose $M = 2N$.

— On génère Z_0 et Z_N réels :

$$Z_0 \sim \mathbb{N}(0, 1), \quad Z_N \sim \mathbb{N}(0, 1).$$

— Pour $k = 1, \dots, N - 1$, on génère des gaussiennes réelles indépendantes

$$U_k, V_k \sim \mathbb{N}(0, 1),$$

indépendantes entre elles et de Z_0, Z_N , puis on pose

$$Z_k = \frac{1}{\sqrt{2}}(U_k + iV_k), \quad Z_{M-k} = \overline{Z_k} = \frac{1}{\sqrt{2}}(U_k - iV_k).$$

Par construction, Z est gaussien complexe centré, et un calcul direct montre que

$$\mathbb{E}[Z] = 0, \quad \mathbb{E}[Z Z^*] = I_M.$$

En outre, comme Δ est réelle et diagonale, la combinaison $\Delta^{1/2} Z$ vérifie la même symétrie conjuguée :

$$(\Delta^{1/2} Z)_{M-k} = \overline{(\Delta^{1/2} Z)_k}, \quad k = 1, \dots, N - 1,$$

et $(\Delta^{1/2} Z)_0, (\Delta^{1/2} Z)_N$ sont réels.

Cette symétrie conjuguée, injectée dans l'IFFT (multiplication par F^*), garantit que les com-

posantes de Y sont réelles en arithmétique exacte :

$$Y_j \in \mathbb{R}, \quad j = 0, \dots, M-1. \quad (120)$$

En pratique numérique, de petits résidus imaginaires dus aux erreurs d'arrondi peuvent subsister ; on prend alors la partie réelle $\Re(Y_j)$.

On résume donc :

$$Y = F^*(\Delta^{1/2}Z) = \text{IFFT}(\sqrt{\boldsymbol{\lambda}} \odot Z), \quad (121)$$

où $\odot$ désigne le produit terme à terme, et $\sqrt{\boldsymbol{\lambda}} = (\sqrt{\lambda_0}, \dots, \sqrt{\lambda_{M-1}})$.

VI. Extraction du fractional Gaussian noise

Le vecteur Y est de taille $M = 2N$. La théorie de Davies–Harte montre que les N premières composantes de Y forment un vecteur gaussien réel de covariance Γ_N (cf. encastrement Toeplitz dans la circulante C).

On définit donc le bruit fractionnaire *normalisé* (pas unité) par :

$$\tilde{X}_k = Y_k, \quad k = 0, \dots, N-1. \quad (122)$$

Ces variables vérifient

$$\text{Cov}(\tilde{X}_j, \tilde{X}_{j+m}) = \gamma_0(m), \quad 0 \leq j, j+m \leq N-1, \quad (123)$$

c'est-à-dire qu'elles ont la covariance correspondant à un pas de temps unité.

Pour retrouver la covariance au pas Δt , on applique le facteur d'échelle $(\Delta t)^H$:

$$X_k = (\Delta t)^H \tilde{X}_k, \quad k = 0, \dots, N-1. \quad (124)$$

On a alors

$$\text{Cov}(X_j, X_{j+m}) = (\Delta t)^{2H} \text{Cov}(\tilde{X}_j, \tilde{X}_{j+m}) \quad (125)$$

$$= (\Delta t)^{2H} \gamma_0(m) = \gamma(m), \quad (126)$$

ce qui est exactement la covariance théorique des incréments de fBm au pas Δt .

En résumé, les X_k construits ainsi forment un fractional Gaussian noise au pas Δt .

VII. Reconstruction détaillée du fBm discret

À partir du bruit fractionnaire $(X_0, \dots, X_{N-1})$, on reconstruit la trajectoire discrète de la fBm par cumul des incréments :

$$B^H(t_0) = 0, \quad B^H(t_k) = \sum_{j=0}^{k-1} X_j, \quad k = 1, \dots, N. \quad (127)$$

En insistant sur l'échelle en temps :

$$B^H(t_k) = \sum_{j=0}^{k-1} X_j = (\Delta t)^H \sum_{j=0}^{k-1} \tilde{X}_j, \quad t_k = k\Delta t. \quad (128)$$

On obtient ainsi une trajectoire $(B^H(t_0), \dots, B^H(t_N))$ dont les incréments ont la bonne covariance et donc la bonne régularité (Hölder de paramètre H quasi-sûrement).

VIII. Résumé algorithmique complet (Davies–Harte)

1. **Discrétisation en temps.** Fixer $T > 0$, $N \in \mathbb{N}^*$, $\Delta t = T/N$, $t_k = k\Delta t$.
2. **Covariance théorique du bruit fractionnaire.** Calculer pour $m = 0, \dots, N$:

$$\gamma_0(m) = \frac{1}{2} \left(|m+1|^{2H} - 2|m|^{2H} + |m-1|^{2H} \right).$$

3. **Vecteur circulant.** Construire

$$c = (\gamma_0(0), \gamma_0(1), \dots, \gamma_0(N-1), \gamma_0(N), \gamma_0(N-1), \dots, \gamma_0(1)) \in \mathbb{R}^{2N}.$$

4. **Valeurs propres par FFT.** Calculer

$$\lambda = \text{FFT}(c).$$

Vérifier numériquement que $\lambda_k \geq 0$ pour tous k , puis poser $\Delta^{1/2} = \text{diag}(\sqrt{\lambda_0}, \dots, \sqrt{\lambda_{2N-1}})$.

5. **Vecteur gaussien complexe symétrique.** Construire $Z \in \mathbb{C}^{2N}$:

- $Z_0, Z_N \sim \mathbb{N}(0, 1)$ réels,
- pour $k = 1, \dots, N-1$, $Z_k = (U_k + iV_k)/\sqrt{2}$, $Z_{2N-k} = \overline{Z_k}$, avec $U_k, V_k \sim \mathbb{N}(0, 1)$ indépendants.

6. **IFFT et bruit fractionnaire.** Calculer

$$Y = \text{IFFT}(\sqrt{\lambda} \odot Z) = F^*(\Delta^{1/2} Z) \in \mathbb{R}^{2N}.$$

Poser le bruit fractionnaire normalisé

$$\tilde{X}_k = Y_k, \quad k = 0, \dots, N-1,$$

puis le bruit fractionnaire au pas Δt :

$$X_k = (\Delta t)^H \tilde{X}_k, \quad k = 0, \dots, N-1.$$

7. Reconstruction de la fBm. Définir

$$B^H(t_0) = 0, \quad B^H(t_k) = \sum_{j=0}^{k-1} X_j, \quad k = 1, \dots, N.$$

On obtient ainsi une trajectoire discrète simulée du mouvement brownien fractionnaire sur $[0, T]$ par la méthode de Davies–Harte.

IX. Lien détaillé avec le modèle rough Bergomi

On relie maintenant cette construction de fBm à la dynamique du modèle *rough Bergomi* (rBergomi).

IX.1. Définition continue du modèle rough Bergomi

Sous la mesure risque-neutre, le modèle rough Bergomi est défini sur un espace probabilisé portant deux mouvements browniens indépendants W et $W^\perp$. On fixe un paramètre de corrélation $\rho \in [-1, 1]$ et on définit

$$Z_t = \rho W_t + \sqrt{1 - \rho^2} W_t^\perp. \quad (129)$$

Le prix S_t d'un actif sans dividende suit

$$dS_t = S_t \sqrt{V_t} dZ_t, \quad (130)$$

où V_t est le processus de variance instantanée.

Le facteur de volatilité est donné par

$$W_t^H = \sqrt{2H} \int_0^t (t-s)^{H-\frac{1}{2}} dW_s, \quad H \in (0, \frac{1}{2}), \quad (131)$$

et la variance est

$$V_t = \xi_0(t) \exp\left(\eta W_t^H - \frac{1}{2} \eta^2 t^{2H}\right). \quad (132)$$

Ici :

— $\xi_0(t)$ est la courbe de variance *forward* initiale (déterministe) ;

- $\eta > 0$ est le paramètre de “vol-of-vol” ;
- W^H est un processus gaussien de type fBm défini par l’intégrale de Volterra (131).

IX.2. Vérification que W^H est un mouvement brownien fractionnaire

On vérifie que W^H défini par (131) a bien la même covariance qu’un fBm de paramètre H .

Espérance. Par linéarité de l’intégrale d’Itô,

$$\mathbb{E}[W_t^H] = \sqrt{2H} \mathbb{E}\left[\int_0^t (t-s)^{H-\frac{1}{2}} dW_s\right] = 0. \quad (133)$$

Variance. Pour $t \geq 0$,

$$\text{Var}(W_t^H) = 2H \mathbb{E}\left[\left(\int_0^t (t-s)^{H-\frac{1}{2}} dW_s\right)^2\right] \quad (134)$$

$$= 2H \int_0^t (t-s)^{2H-1} ds \quad (\text{isométrie de l’intégrale stochastique}) \quad (135)$$

$$= 2H \int_0^t u^{2H-1} du \quad (u = t-s) \quad (136)$$

$$= 2H \cdot \frac{t^{2H}}{2H} = t^{2H}. \quad (137)$$

On retrouve donc la variance d’un fBm de paramètre H .

Covariance. Pour $s, t \geq 0$,

$$\text{Cov}(W_t^H, W_s^H) = 2H \mathbb{E}\left[\int_0^t (t-u)^{H-\frac{1}{2}} dW_u \int_0^s (s-v)^{H-\frac{1}{2}} dW_v\right] \quad (138)$$

$$= 2H \int_0^{t \wedge s} (t-u)^{H-\frac{1}{2}} (s-u)^{H-\frac{1}{2}} du \quad (\text{isométrie}). \quad (139)$$

Un calcul classique (changement de variable $u = s-x$, puis utilisation de la fonction Bêta) donne

$$2H \int_0^{t \wedge s} (t-u)^{H-\frac{1}{2}} (s-u)^{H-\frac{1}{2}} du = \frac{1}{2} (t^{2H} + s^{2H} - |t-s|^{2H}) = R_H(t, s). \quad (140)$$

Ainsi,

$$\text{Cov}(W_t^H, W_s^H) = R_H(t, s), \quad (141)$$

exactement la covariance d’un mouvement brownien fractionnaire de paramètre H . Par unicité de la loi gaussienne à partir de la covariance, on a

$$(W_{t_1}^H, \dots, W_{t_n}^H) \stackrel{d}{=} (B^H(t_1), \dots, B^H(t_n)) \quad (142)$$

pour tout n et tout choix de temps $t_1, \dots, t_n$. Le processus W^H de rough Bergomi est donc *en loi* un fBm standard de paramètre H .

Conséquence importante : sur une grille $t_k = k\Delta t$, on peut simuler directement $(B^H(t_k))$ par Davies–Harte et l'utiliser comme échantillonnage de $(W_{t_k}^H)$, puisque les lois finies-dimensionnelles coïncident.

IX.3. Log-volatilité et espérance conditionnelle

La log-volatilité définie par (132) s'écrit

$$\log V_t = \log \xi_0(t) + \eta W_t^H - \frac{1}{2} \eta^2 t^{2H}. \quad (143)$$

On a déjà vu que $W_t^H \sim \mathbb{N}(0, t^{2H})$. Donc

$$\eta W_t^H \sim \mathbb{N}(0, \eta^2 t^{2H}). \quad (144)$$

Le moment exponentiel de W_t^H est donné par

$$\mathbb{E}[e^{\eta W_t^H}] = \exp\left(\frac{1}{2} \eta^2 \text{Var}(W_t^H)\right) = \exp\left(\frac{1}{2} \eta^2 t^{2H}\right). \quad (145)$$

On calcule alors l'espérance de V_t :

$$\mathbb{E}[V_t] = \mathbb{E}\left[\xi_0(t) \exp\left(\eta W_t^H - \frac{1}{2} \eta^2 t^{2H}\right)\right] \quad (146)$$

$$= \xi_0(t) e^{-\frac{1}{2} \eta^2 t^{2H}} \mathbb{E}[e^{\eta W_t^H}] \quad (147)$$

$$= \xi_0(t) e^{-\frac{1}{2} \eta^2 t^{2H}} e^{\frac{1}{2} \eta^2 t^{2H}} \quad (148)$$

$$= \xi_0(t). \quad (149)$$

Par construction, $\xi_0(t)$ est donc bien la *variance forward* initiale :

$$\xi_0(t) = \mathbb{E}[V_t], \quad t \geq 0. \quad (150)$$

IX.4. Discrétisation de rough Bergomi à partir de la fBm simulée

On se donne maintenant la grille $t_k = k\Delta t$, $k = 0, \dots, N$, et une trajectoire simulée de fBm

$$(B^H(t_0), \dots, B^H(t_N))$$

obtenue par la méthode de Davies–Harte décrite aux sections précédentes.

1. Identification $W^H \equiv B^H$. Comme démontré ci-dessus,

$$(W_{t_k}^H)_{k=0,\dots,N} \stackrel{d}{=} (B^H(t_k))_{k=0,\dots,N}.$$

Pour la simulation, on pose donc simplement

$$W_{t_k}^H := B^H(t_k), \quad k = 0, \dots, N. \quad (151)$$

2. Discrétisation de la variance. On obtient la variance rough Bergomi sur la grille en posant

$$V_k := V_{t_k} = \xi_0(t_k) \exp\left(\eta B^H(t_k) - \frac{1}{2}\eta^2 t_k^{2H}\right), \quad k = 0, \dots, N. \quad (152)$$

Cette suite (V_k) est log-normale, et la relation $\mathbb{E}[V_k] = \xi_0(t_k)$ reste vérifiée.

3. Discrétisation de la dynamique du prix. L'équation

$$dS_t = S_t \sqrt{V_t} dZ_t$$

est un SDE de type Black–Scholes avec volatilité stochastique $\sqrt{V_t}$. Par Itô,

$$d \log S_t = \frac{1}{S_t} dS_t - \frac{1}{2S_t^2} (dS_t)^2 = \sqrt{V_t} dZ_t - \frac{1}{2} V_t dt. \quad (153)$$

En supposant V_t constant sur $[t_k, t_{k+1})$ et égal à V_k , on obtient le schéma de type Euler exponentiel :

$$\log S_{t_{k+1}} = \log S_{t_k} - \frac{1}{2} V_k \Delta t + \sqrt{V_k} \Delta Z_k, \quad (154)$$

où

$$\Delta Z_k = Z_{t_{k+1}} - Z_{t_k} \sim \mathcal{N}(0, \Delta t).$$

En exponentiant,

$$S_{t_{k+1}} = S_{t_k} \exp\left(-\frac{1}{2} V_k \Delta t + \sqrt{V_k} \Delta Z_k\right). \quad (155)$$

4. Corrélation avec le facteur rough. Dans la définition continue, Z est construit à partir de W via

$$Z_t = \rho W_t + \sqrt{1 - \rho^2} W_t^\perp,$$

et W^H est une intégrale stochastique de W (voir (131)). Ceci implique une structure de corrélation non triviale entre W^H et Z .

Si l'on se contente de simuler la fBm $(B^H(t_k))$ *indépendamment* d'un Brownien discrétisé (Z_{t_k}) , alors le prix S est indépendant du facteur rough : ce n'est plus le modèle rBergomi mais un modèle à volatilité rough décorrélée. Pour avoir le rBergomi correct, il faut construire conjointement un

vecteur gaussien

$$(W_{t_1}^H, \dots, W_{t_N}^H, Z_{t_1}, \dots, Z_{t_N})$$

avec la bonne matrice de covariance. Celle-ci est de la forme

$$\Sigma = \begin{pmatrix} \Sigma^{HH} & \Sigma^{HZ} \\ (\Sigma^{HZ})^\top & \Sigma^{ZZ} \end{pmatrix},$$

où :

- $\Sigma_{ij}^{HH} = \text{Cov}(W_{t_i}^H, W_{t_j}^H) = R_H(t_i, t_j)$;
- $\Sigma_{ij}^{ZZ} = \text{Cov}(Z_{t_i}, Z_{t_j}) = \min(t_i, t_j)$ (Brownien standard) ;
- $\Sigma_{ij}^{HZ} = \text{Cov}(W_{t_i}^H, Z_{t_j})$.

Pour ce dernier terme, en utilisant (131) et $Z_t = \rho W_t + \sqrt{1 - \rho^2} W_t^\perp$, on obtient pour $t_i \geq t_j$:

$$\text{Cov}(W_{t_i}^H, Z_{t_j}) = \rho \text{Cov}\left(\sqrt{2H} \int_0^{t_i} (t_i - s)^{H-\frac{1}{2}} dW_s, W_{t_j}\right) \quad (156)$$

$$= \rho \sqrt{2H} \int_0^{t_j} (t_i - s)^{H-\frac{1}{2}} ds \quad (157)$$

$$= \rho \sqrt{2H} \int_{t_i-t_j}^{t_i} u^{H-\frac{1}{2}} du \quad (u = t_i - s) \quad (158)$$

$$= \rho \sqrt{2H} \frac{t_i^{H+\frac{1}{2}} - (t_i - t_j)^{H+\frac{1}{2}}}{H + \frac{1}{2}}. \quad (159)$$

Pour $t_i < t_j$, on échange les rôles de t_i et t_j .

En pratique, pour une implémentation exacte de rBergomi, on doit simuler le vecteur gaussien de dimension $2N$ avec cette covariance Σ (par exemple via une factorisation de type Cholesky ou une méthode FFT multivariée). La méthode Davies–Harte décrite plus haut donne efficacement le bloc Σ^{HH} ; la construction complète est plus lourde mais repose sur le même principe : tout est gaussien, donc entièrement déterminé par la covariance.

IX.5. Résumé : utilisation pratique de la fBm simulée pour rBergomi

Pour relier concrètement la simulation de fBm par Davies–Harte au modèle rough Bergomi sur une grille $t_k = k\Delta t$:

1. Simuler une trajectoire de fBm $(B^H(t_k))_{k=0,\dots,N}$ via Davies–Harte.
2. L'identifier en loi au facteur rough $W_{t_k}^H$, i.e. poser $W_{t_k}^H = B^H(t_k)$.
3. Construire la variance

$$V_k = \xi_0(t_k) \exp\left(\eta B^H(t_k) - \frac{1}{2} \eta^2 t_k^{2H}\right).$$

4. Simuler des incréments browniens corrélés ΔZ_k de sorte que la corrélation entre W^H et Z soit bien celle imposée par le modèle (via la covariance Σ^{HZ} ci-dessus) ; dans une implémentation

approximative plus simple, on peut prendre ΔZ_k simplement corrélés avec les incréments de W ou considérer l'approximation de corrélation locale.

5. Mettre à jour le prix par

$$S_{t_{k+1}} = S_{t_k} \exp\left(-\frac{1}{2}V_k\Delta t + \sqrt{V_k}\Delta Z_k\right).$$

La dérivation montre explicitement où intervient la fBm dans rough Bergomi et comment la trajectoire obtenue par Davies–Harte se branche dans la construction de la variance et du prix.

6 Modèle SABR : expansion asymptotique (Hagan)

Dynamique

$$\begin{cases} dF_t = \alpha_t F_t^\beta dW_t^{(1)}, \\ d\alpha_t = \nu \alpha_t dW_t^{(2)}, \\ dW_t^{(1)} dW_t^{(2)} = \rho dt. \end{cases}$$

Formule asymptotique de la vol implicite

La volatilité implicite obtenue par expansion en ν (Hagan et al.) est :

$$\sigma_{\text{SABR}}(K) = \frac{\alpha_0}{(F_0 K)^{\frac{1-\beta}{2}}} \left[1 + \frac{(1-\beta)^2}{24} (\ln(F_0/K))^2 + \frac{(1-\beta)^4}{1920} (\ln(F_0/K))^4 \right] / z,$$

avec

$$z = \frac{\nu}{\alpha_0} (F_0 K)^{\frac{1-\beta}{2}} \ln \frac{F_0}{K}, \quad \chi(z) = \ln \left(\frac{\sqrt{1-2\rho z + z^2} + z - \rho}{1-\rho} \right).$$

La forme finale couramment utilisée est :

$$\sigma_{\text{SABR}}(K) = \frac{\alpha_0}{(F_0 K)^{\frac{1-\beta}{2}}} \left[1 + \left(\frac{(1-\beta)^2}{24} \ln^2 \frac{F_0}{K} + \frac{(1-\beta)^4}{1920} \ln^4 \frac{F_0}{K} \right) \right] \frac{z}{\chi(z)}.$$

Utilisation en calibration

La structure $(\beta, \nu, \rho, \alpha_0)$ permet de calibrer finement le smile :

$$\theta^* = \arg \min_{\theta} \sum_{K \in \mathcal{K}} \left(\sigma_{\text{SABR}}(K; \theta) - \sigma_{\text{impl}}^{\text{mkt}}(K) \right)^2.$$

Remarques

- L'expansion est très précise pour ν modéré et $|F_0 - K|$ raisonnable.
- Des variantes existent (SABR normal, shifted-SABR).

- La dérivation complète nécessite des développements asymptotiques détaillés (au-delà du niveau de détail visé ici ; voir la littérature spécialisée).

7 Modèle de Rough Heston : dynamique, caractéristique, simulation

Motivation

Le modèle de Heston classique génère une variance v_t markovienne de type CIR. Cependant, les observations empiriques montrent un comportement plus “rugbueux” de la variance, avec une régularité Hölder strictement inférieure à $1/2$ et une décorrélation lente.

Le *Rough Heston* introduit cette rugosité en remplaçant la dynamique CIR par une SDE de Volterra reposant sur un noyau de type $t^{H-\frac{1}{2}}$ avec $H < \frac{1}{2}$.

Dynamique du Rough Heston

On considère le modèle suivant (sous la mesure risque-neutre) :

$$\begin{cases} dS_t = S_t \sqrt{v_t} dW_t^{(1)} + rS_t dt, \\ v_t = v_0 + \frac{1}{\Gamma(H+\frac{1}{2})} \int_0^t (t-s)^{H-\frac{1}{2}} (\kappa(\theta - v_s) ds + \xi \sqrt{v_s} dW_s^{(2)}), \end{cases}$$

avec covariance :

$$dW_t^{(1)} dW_t^{(2)} = \rho dt.$$

Le noyau :

$$K(t) = \frac{t^{H-\frac{1}{2}}}{\Gamma(H+\frac{1}{2})}, \quad H < \frac{1}{2},$$

introduit une mémoire longue et une régularité faible.

Formulation Volterra

La variance satisfait la Volterra SDE affine :

$$v_t = v_0 + \int_0^t K(t-s) \kappa(\theta - v_s) ds + \int_0^t K(t-s) \xi \sqrt{v_s} dW_s^{(2)}.$$

La structure affine demeure, ce qui permet des formules fermées pour la fonction caractéristique du log-prix.

Fonction caractéristique du log-prix

On pose $X_t = \ln S_t$. On cherche la fonction caractéristique :

$$\phi(u, t) = \mathbb{E}[e^{iuX_t} \mid X_0, v_0].$$

Comme le modèle est affine Volterra, on a :

$$\phi(u, t) = \exp(iuX_0 + C(u, t) + D(u, t)v_0).$$

Les fonctions $C(u, t)$ et $D(u, t)$ satisfont des *équations de Riccati fractionnaires*

$$D(u, t) = \int_0^t K(t-s) \left(\frac{1}{2}(u^2 + iu) - (\kappa - \rho\xi iu)D(u, s) - \frac{1}{2}\xi^2 D(u, s)^2 \right) ds,$$

$$C(u, t) = iurt + \kappa\theta \int_0^t D(u, s) ds.$$

Il s'agit de convolutions Volterra nécessitant des méthodes numériques dédiées (FFT accélérée, quadrature rapide, schémas hybrides).

Prix du call européen

Le prix du call est obtenu via la représentation de Carr–Madan / Fourier :

$$C_0 = S_0 P_1 - K e^{-rT} P_2,$$

où

$$P_j = \frac{1}{2} + \frac{1}{\pi} \int_0^\infty \Re \left(\frac{e^{-iu \ln K} \phi_j(u, T)}{iu} \right) du, \quad j = 1, 2.$$

La différence avec Heston classique provient du calcul de $\phi_j(u, T)$, qui utilise les Riccati fractionnaires ci-dessus.

Simulation : schéma hybride (hybrid scheme)

La simulation directe du rough Heston est coûteuse car la convolution Volterra est de complexité naïve $\mathcal{O}(n^2)$. Bayer, Friz et Gatheral (2016) proposent une approche *hybride* qui combine une décomposition du noyau (partie singulière vs régulière) et une accélération des convolutions, afin de réduire le coût de calcul sur une grille. Le point essentiel (au niveau théorique) est la gestion de la non-markovianité : l'état dépend d'un historique, ce qui impose des schémas spécialisés pour obtenir des trajectoires utilisables en pricing/greeks.

Calibration

La calibration consiste à résoudre :

$$\theta^* = \arg \min_{\theta} \sum_{(K,T)} (\sigma_{\text{mod}}(K, T; \theta) - \sigma_{\text{mkt}}(K, T))^2,$$

où $\theta = (H, \eta, \kappa, \theta, \xi, \rho, v_0)$.

Le paramètre clé est le Hurst H :

- $H < 0.5$ est la signature “rough” : il accentue la géométrie court terme du smile (motivation empirique).
- La structure Volterra augmente l’expressivité par rapport à Heston classique, au prix d’une calibration et d’une validation plus délicates (instabilité, sur-ajustement possible).
- Sans données fournies ici, une comparaison “Rough Heston vs Heston” doit être posée comme un protocole : calibration in-sample sur une date, puis test out-of-sample sur d’autres dates/maturités, avec contrôles de stabilité des paramètres et de violation d’arbitrage statique.

Synthèse

Le Rough Heston combine :

- structure affine (donc transformées de Fourier disponibles),
- mémoire longue via Volterra,
- réalisme empirique, notamment sur le skew court terme.

Il constitue un cadre avancé pour le pricing d’options equity et la modélisation de surfaces de volatilité.

Plus généralement, c’est un cadre avancé (structure affine + mémoire) dont la pertinence pratique doit être évaluée par des diagnostics de calibration et de couverture, en tenant compte des coûts et du risque de modèle.

8 Méthodes numériques : FFT et Crank–Nicolson

Méthode de Crank–Nicolson pour la PDE de Black–Scholes

On considère la PDE de Black–Scholes :

$$\frac{\partial V}{\partial t} + \frac{1}{2}\sigma^2 S^2 \frac{\partial^2 V}{\partial S^2} + rS \frac{\partial V}{\partial S} - rV = 0.$$

En changeant de variable $x = \ln S$ et $\tau = T - t$, on obtient une PDE de type chaleur pour $\tilde{V}(\tau, x)$, que l’on discrétise sur une grille (τ_n, x_j) .

Le schéma de Crank–Nicolson consiste à moyenniser les schémas implicite et explicite :

$$\frac{V_j^{n+1} - V_j^n}{\Delta\tau} = \frac{1}{2}(\mathcal{L}V_j^{n+1} + \mathcal{L}V_j^n),$$

où $\mathcal{L}$ est l'opérateur spatial issu de la PDE.

En pratique, cela donne un système tridiagonal à chaque pas de temps :

$$AV^{n+1} = BV^n + b^n,$$

que l'on résout via un algorithme de Thomas (coût en $\mathcal{O}(M)$ pour M points en espace).

FFT pour le pricing d'options (Carr–Madan)

L'idée est d'exprimer le prix d'un call en termes de transformée de Fourier de la fonction caractéristique du log-prix.

Soit

$$\phi_T(u) = \mathbb{E}[e^{iu \log S_T}].$$

On introduit un call dampé :

$$c_\alpha(k) = e^{\alpha k} C(k), \quad k = \ln K,$$

avec $\alpha > 0$.

La transformée de Fourier de $c_\alpha(k)$ s'exprime alors en fonction de $\phi_T(u)$:

$$\hat{c}_\alpha(u) = \int_{-\infty}^{+\infty} e^{iuk} c_\alpha(k) dk = \frac{e^{-rT} \phi_T(u - i(\alpha + 1))}{\alpha^2 + \alpha - u^2 + iu(2\alpha + 1)}.$$

Les prix pour un ensemble de strikes équidistants k_m sont obtenus par FFT :

$$c_\alpha(k_m) \approx \frac{e^{-iu_0 k_m}}{2\pi} \sum_{n=0}^{N-1} e^{iu_n k_m} \hat{c}_\alpha(u_n) \Delta u,$$

où (u_n) est une grille uniforme de fréquences.

Enfin, on récupère le prix du call :

$$C(k_m) = e^{-\alpha k_m} c_\alpha(k_m).$$

Cette méthode est particulièrement efficace pour les modèles à fonction caractéristique explicite (Heston, Merton, Variance Gamma, etc.).

Résumé

- Le schéma de Crank–Nicolson fournit une solution stable et seconde-ordre en temps pour les PDE de pricing.
- Les méthodes FFT de type Carr–Madan permettent d’obtenir de nombreux prix d’options en un seul appel de Fourier, particulièrement bien adaptées aux modèles de type affine.

9 Étude de cas : pipeline de prédiction tabulaire par eras (Numerai)

Objectif et positionnement

Cette section présente, au niveau conceptuel (sans code), un *pipeline* de prédiction tabulaire structuré par périodes (“eras”) tel qu’on en rencontre dans certains tournois de prévision (cas Numerai). L’intérêt est méthodologique : (i) gérer une non-stationnarité explicite, (ii) éviter le *leakage* temporel, et (iii) privilégier la stabilité du signal plutôt qu’une performance moyenne illusoire.

Données : entraînement vs prédiction

On dispose conceptuellement de deux ensembles :

- un jeu d’**entraînement** contenant des variables explicatives x et une cible y ;
- un jeu “**live**” contenant les variables x à prédire (sans y).

Les observations sont regroupées en eras $e = 1, \dots, E$, permettant une évaluation et une validation *par blocs temporels*.

Chaîne end-to-end (vue macro)

Le pipeline peut être résumé par les étapes suivantes :

1. **Contrôles de cohérence** : variables disponibles, valeurs manquantes, dérive grossière de distribution.
2. **Réduction de dimension** : filtre de valeurs manquantes puis sélection (par score) des variables les plus informatives.
3. **Découpage temporel** : validation par blocs d’eras (rolling/expanding) et réservation d’un holdout final.
4. **Entraînement** : ajustement d’un modèle (ex. GBDT) sur chaque split, avec régularisation et arrêt anticipé.
5. **Prédictions hors-fold (OOF)** : construction de prédictions sur les parties non vues pour estimer la performance hors échantillon.

6. **Évaluation** : calcul d'une métrique par era (ex. corrélation), puis agrégation (moyenne, dispersion, ratio type Sharpe).
7. **Ensembles** : agrégation de plusieurs modèles (moyenne) et, si justifié, combinaison via meta-modèle (stacking) sous validation stricte.
8. **Post-traitement** : transformation monotone (ranking) pour stabiliser l'échelle et limiter l'impact d'outliers.
9. **Production** : génération des prédictions sur le jeu live dans le format standard attendu par la plateforme.

Choix méthodologiques : justification et limites

- **Sélection univariée (score)** : efficace pour maîtriser le bruit et la dimension, mais ignore interactions ; elle doit être compatible avec la validation temporelle (sinon leakage).
- **Métrique par era** : la stabilité inter-eras est centrale en non-stationnarité ; une moyenne seule peut masquer des inversions de signal.
- **Ensembles** : réduisent la variance et l'instabilité, au prix d'un coût de calcul accru.
- **Ranking** : stabilise la distribution des scores ; il ne crée pas de signal et doit être validé (effet possible sur corrélation linéaire).

Lien avec le mémoire

Cette étude de cas illustre les principes développés au chapitre sur l'apprentissage supervisé sous non-stationnarité (*validation temporelle, leakage, métriques par période, ensembles et post-traitements monotones*). Dans le contexte de *PaperTradingApp*, ces principes cadrent la validation de briques apprenantes (surrogates, régimes, diagnostics) et complètent les exigences de traçabilité et de gouvernance des hypothèses discutées dans la partie méthodologie.