

PaperTradingApp

Dossier théorique & dérivations pédagogiques (from ground up)

Public : jury financier (Master)

Positionnement de ce dossier (rappel)

- Ce document est un **dossier pédagogique** centré sur les **hypothèses**, la **théorie** et les **dérivations**.
- Les sections **B. Théorie** et **C. Dérivations** sont développées en détail (pas à pas, avec intuition et vérifications).
- Le **lien avec le projet** est regroupé **en annexe** pour ne pas interrompre le fil théorique.

Résumé

Ce dossier regroupe les fondations du **calcul stochastique** et du **pricing d'options** utilisées en finance quantitative, puis détaille les dérivations standards (au niveau Master) qui relient *hypothèses* $\rightarrow$ *dynamiques* $\rightarrow$ *prix* $\rightarrow$ *paramètres*.

Le fil conducteur est volontairement **pédagogique** : chaque brique est reconstruite **à partir des hypothèses** (probabilités & absence d'arbitrage) et **dérivée** étape par étape, avec intuition et contrôles de cohérence. En particulier :

- Pricing d'options : Black–Scholes (PDE, formule fermée, grecs, volatilité implicite), arbres, Monte Carlo et principe de Longstaff–Schwartz.
- Volatilité : surface d'IV, interpolation et arbitrage statique, calibration (problème inverse) et modèles paramétriques (SABR, Heston, sauts, rough/Volterra).
- Couverture : principe de réplication, limites en marché incomplet, et formulation séquentielle (MDP) d'un hedge discret.
- Taux : courbe de taux, discount factors, taux zéros, forwards, paramétrisation Nelson–Siegel.
- Allocation & risque : Markowitz, risk parity, eigen-portfolios, et métriques de risque (exposition, PnL, quantiles).

Table des matières

0	Architecture & Notations	6
0.1	A. Problème financier (objectif, inputs, outputs)	6
0.2	B. Théorie (définitions, hypothèses)	6
0.3	C. Dérivations (ultra détaillées)	8
I	Stochastic calculus & pricing (base indispensable)	10
1	Brownien et intégrale stochastique	11
1.1	A. Problème financier (objectif, inputs, outputs)	11
1.2	B. Théorie (définitions, hypothèses)	11
1.3	C. Dérivations (ultra détaillées)	13
2	Variation quadratique	15
2.1	A. Problème financier	15
2.2	B. Théorie	15
2.3	C. Dérivations (ultra détaillées)	16
3	Lemme d'Itô (1D et multi-dim)	17
3.1	A. Problème financier	17
3.2	B. Théorie	17
3.3	C. Dérivations (ultra détaillées)	18
4	Risk-neutral pricing, hedging et PDE (Black–Scholes & Feynman–Kac)	20
4.1	A. Problème financier	20
4.2	B. Théorie	20
4.3	C. Dérivations (ultra détaillées)	21
5	Options vanilles : BS, greeks, implied vol (inversion numérique)	23
5.1	A. Problème financier	23
5.2	B. Théorie	23
5.3	C. Dérivations (ultra détaillées)	24
II	Volatility surface & calibration (cœur de la modélisation IV)	27
6	Surface d'IV : smile/skew, axes, interpolation, arbitrage	28
6.1	A. Problème financier	28
6.2	B. Théorie	28
6.3	C. Dérivations (ultra détaillées)	29

7	Calibration : principe, fonction objectif, pondérations, contraintes	31
7.1	A. Problème financier (objectif, inputs, outputs)	31
7.2	B. Théorie (définitions, hypothèses)	31
7.3	C. Dérivations (ultra détaillées)	33
8	Heston : volatilité stochastique (SDE, CF, pricing, calibration)	35
8.1	A. Problème financier (objectif, inputs, outputs)	35
8.2	B. Théorie (définitions, hypothèses)	35
8.3	C. Dérivations (ultra détaillées)	36
9	Jump diffusion : Merton et Bates (CF/FFT, calibration)	38
9.1	A. Problème financier (objectif, inputs, outputs)	38
9.2	B. Théorie (définitions, hypothèses)	38
9.3	C. Dérivations (ultra détaillées)	39
10	SABR : dynamique, formule de Hagan, calibration	41
10.1	A. Problème financier (objectif, inputs, outputs)	41
10.2	B. Théorie (définitions, hypothèses)	41
10.3	C. Dérivations (ultra détaillées)	42
11	Rough & Volterra : rHeston (approx. markovienne), rBergomi (MC+surrogate), Volterra SDE (MC proxy)	44
11.1	A. Problème financier (objectif, inputs, outputs)	44
11.2	B. Théorie (définitions, hypothèses)	44
11.3	C. Dérivations (ultra détaillées)	45
12	Réseaux de neurones dans la calibration (surrogates pour Heston)	48
12.1	A. Problème financier (objectif, inputs, outputs)	48
12.2	B. Théorie (définitions, hypothèses)	48
12.3	C. Dérivations (ultra détaillées)	49
III	RL Hedger (théorie → design → pratique)	51
13	Couverture RL : formulation MDP, DQN, et aspects pratiques	52
13.1	A. Problème financier (objectif, inputs, outputs)	52
13.2	B. Théorie (définitions, hypothèses)	52
13.3	C. Dérivations (ultra détaillées)	54
IV	Yield Curve	55
14	Courbe de taux : DF, taux zéro, forwards, Nelson–Siegel	56
14.1	A. Problème financier (objectif, inputs, outputs)	56
14.2	B. Théorie (définitions, hypothèses)	56
14.3	C. Dérivations (ultra détaillées)	57
V	Portfolio allocation & risk	59
15	Allocation de portefeuille : Markowitz, Risk Parity, Eigen-portfolios, rebalancement	60
15.1	A. Problème financier (objectif, inputs, outputs)	60

15.2 B. Théorie (définitions, hypothèses)	60
15.3 C. Dérivations (ultra détaillées)	61
16 Risk management : exposition, PnL, VaR-lite, alertes	63
16.1 A. Problème financier (objectif, inputs, outputs)	63
16.2 B. Théorie (définitions, hypothèses)	63
16.3 C. Dérivations (ultra détaillées)	64
A Annexe : lien avec le projet PaperTradingApp	66
B Pricing des options présentes dans le repo	67
B.1 Payoffs et pricing (table synthèse)	67
C Graphes de payoff (PGFPlots)	69
C.1 B. Graphes (payoff brut vs profit)	69
D Table « Code map » (module $\leftrightarrow$ théorie $\leftrightarrow$ implémentation)	73
E Bibliographie minimale	75

Table des figures

C.1	Call : payoff brut et profit (prime illustrative).	69
C.2	Put : payoff brut et profit (prime illustrative).	70
C.3	Straddle.	70
C.4	Strangle (primes illustratives).	70
C.5	Call spread.	71
C.6	Put spread.	71
C.7	Butterfly.	71
C.8	Condor.	72
C.9	Iron condor.	72

Chapitre 0

Architecture & Notations

0.1 A. Problème financier (objectif, inputs, outputs)

L'objectif global est un pipeline $data \rightarrow modèles \rightarrow décision \rightarrow exécution$:

- **Inputs** : prix spot, historiques (OHLC), chaîne d'options (prix/IV par strike et maturité), structure de taux (zéros/DF), positions et contraintes (cash, limites de risque, coûts).
- **Outputs** : prix d'options (et payoffs), grecs, surfaces de volatilité (marché vs modèle), paramètres calibrés, scénarios de couverture, plans de rebalancement et indicateurs de risque.

0.2 B. Théorie (définitions, hypothèses)

Séparation des responsabilités (idée générale)

Pour garder le raisonnement financier lisible et *audit-able*, on sépare conceptuellement :

- **Données** : observation et nettoyage (spots, taux, options).
- **Noyau quantitatif** : modèles et valorisation (mesure risque-neutre, pricers, grecs).
- **Inverse problem** : calibration (choix de métrique, contraintes, régularisation).
- **Décision** : couverture/allocation sous contraintes (discrétisation, coûts, limites).
- **Exécution** : traduction d'une décision en trades (avec contrôle de risque opérationnel).

Intuition (pourquoi c'est crucial en finance)

Une chaîne de calcul quantitative doit pouvoir :

- **reproduire** un résultat (mêmes hypothèses $\Rightarrow$ même prix) ;
- **auditer** le raisonnement (quelles données ? quel modèle ? quels paramètres ?) ;
- **remplacer** une source de données ou une méthode numérique sans "casser" la théorie ;
- **tester** séparément les hypothèses (absence d'arbitrage, bornes, monotonicité, diagnostics).
- **À quoi ça sert ?** Garantir qu'un résultat numérique (prix, calibration) est traçable, testable, et reproductible.
- **Hypothèses.** Séparation stricte des responsabilités : la couche de calcul ne dépend pas de la présentation, et la décision n'altère pas les données observées.
- **Limites.** MVC ne garantit pas la qualité des modèles, seulement l'industrialisation et l'auditabilité.
- **Applications.** Industrialisation : validation, reproductibilité, et articulation vers une boucle décision/exécution (définie conceptuellement).

Notations transversales (utilisées dans tout le dossier)

On fixe un horizon temporel $t \in [0, T]$ et un espace probabilisé filtré $(\Omega, \mathcal{F}, (\mathcal{F}_t)_{t \geq 0}, \mathbb{P})$.

Sous-jacent, numéraire, taux.

- S_t : prix du sous-jacent (action/ETF) à l’instant t .
- r : taux sans risque (continu). Quand une courbe est disponible, on écrit plutôt $r(t)$ et on actualise via une intégrale.
- q : *dividend yield* continu (ou *repo rate* dans certains marchés) : il représente un “rendement” payé par l’actif, ce qui diminue la croissance du prix *ex-dividend*.
- B_t : numéraire monétaire (compte rémunéré) ; en taux constant, $B_t = e^{rt}$.
- $D(0, t)$: facteur d’actualisation, $D(0, t) = e^{-rt}$ (ou $D(0, t) = \exp(-\int_0^t r(u) du)$ si r dépend du temps).

Mesures $\mathbb{P}$ et $\mathbb{Q}$.

- $\mathbb{P}$: mesure “réelle” (statistique) qui gouverne les probabilités physiques (historiques).
- $\mathbb{Q}$: mesure risque-neutre associée au numéraire B : sous $\mathbb{Q}$, les prix *actualisés* des actifs (corrigés de q) sont des martingales (absence d’arbitrage).
- La différence $\mathbb{P}$ vs $\mathbb{Q}$ est une différence de *drift* (prime de risque) ; la diffusion (volatilité instantanée) est souvent la même dans les modèles de base, mais pas toujours en modèles plus riches.

Contrats d’options et fonctions de payoff. Un payoff européen s’écrit comme une fonction mesurable $\Phi(S_T)$ et son prix à t est noté $V(t, S_t)$. Exemples :

$$\Phi_{\text{call}}(S_T) = (S_T - K)^+, \quad \Phi_{\text{put}}(S_T) = (K - S_T)^+.$$

On utilise systématiquement la convention $x^+ = \max(x, 0)$.

Volatilité et variables de moneyness.

- σ : volatilité (constante en Black–Scholes, stochastique en Heston, “rough” en rBergomi, etc.).
- K : strike ; T : maturité.
- On introduit souvent le *log-moneyness* $k = \ln(K/F_{0,T})$ où $F_{0,T} = S_0 e^{(r-q)T}$ est le forward (taux constants).
- Total variance : $w(k, T) = \sigma_{\text{impl}}(k, T)^2 T$ est un objet plus régulier que σ_{impl} et central pour discuter l’arbitrage statique.

Hypothèses transversales : ce qui est supposé (et ce qui ne l’est pas)

Pour rendre les dérivations lisibles, on commence par des hypothèses “de base” (marché frictionless, trading continu, pas de coûts). Elles sont ensuite relâchées :

- **Incomplétude / non-réplication** : en présence de sauts, de volatilité stochastique, de contraintes ou de rebalancement discret, la réplication parfaite échoue ; le pricing devient une question de mesure risque-neutre *non unique* ou de choix de critère.
- **Calibrage** : une surface de volatilité implicite est un *résumé* des prix de marché ; calibrer un modèle revient à résoudre un problème inverse potentiellement mal posé.
- **Numerics** : une formule fermée est rare ; on alterne entre PDE, Monte Carlo, FFT et approximations, d’où l’importance de la stabilité et des diagnostics.

0.3 C. Dérivations (ultra détaillées)

Ce chapitre formalise la chaîne *données* $\rightarrow$ *modèles* $\rightarrow$ *prix* $\rightarrow$ *décisions* à un niveau conceptuel, indépendamment de toute implémentation.

Données $\rightarrow$ variables d'état : ce qu'on retient vraiment

Un point pédagogique crucial est qu'une "donnée de marché" brute n'est pas directement un objet de pricing. On commence par construire une *variable d'état* X_t (ou un petit nombre de variables) qui résume l'information pertinente à l'instant t . Exemples :

- option vanille : $X_t = (t, S_t)$ suffit en Black-Scholes ;
- volatilité stochastique : $X_t = (t, S_t, V_t)$ (ex. Heston) ;
- portefeuille : $X_t = (t, \text{positions, cash, paramètres de risque, contraintes})$.

Mathématiquement, X_t doit être $\mathcal{F}_t$ -mesurable : l'état à t ne doit dépendre que de l'information disponible à t .

Prix : un opérateur conditionnel sous mesure risque-neutre

Sous absence d'arbitrage (et dans un cadre standard), il existe une mesure risque-neutre $\mathbb{Q}$ telle que, pour un payoff européen $\Phi(S_T)$,

$$V(t, X_t) = \mathbb{E}^{\mathbb{Q}}[D(t, T) \Phi(S_T) \mid \mathcal{F}_t], \quad D(t, T) = \exp\left(-\int_t^T r(u) du\right).$$

Ce point n'est pas seulement une "formule" : c'est un *principe d'identification* qui force des propriétés structurelles :

- **linéarité** : $V(\alpha\Phi_1 + \beta\Phi_2) = \alpha V(\Phi_1) + \beta V(\Phi_2)$;
- **positivité** : $\Phi \geq 0 \Rightarrow V \geq 0$;
- **monotonie** : $\Phi_1 \leq \Phi_2 \Rightarrow V(\Phi_1) \leq V(\Phi_2)$;
- **bornes d'arbitrage** : par exemple $0 \leq C \leq S_0 e^{-qT}$ pour un call européen.

Ces propriétés servent de *tests de cohérence* pour les calculs numériques et pour la calibration.

Calibration : un problème inverse (et souvent mal posé)

Un modèle paramétrique $\mathcal{M}(\theta)$ fournit des prix (ou IV) théoriques $V^{\mathcal{M}}(\theta)$. Le marché fournit des observations V^{mkt} sur un ensemble d'options (strikes, maturités). Calibrer revient à résoudre

$$\hat{\theta} = \arg \min_{\theta} \mathcal{L}(V^{\mathcal{M}}(\theta), V^{\text{mkt}}),$$

où $\mathcal{L}$ encode le choix *métier* : erreur en prix vs en IV, pondérations par Vega, robustesse aux outliers (Huber), et contraintes (ex. Feller en Heston). Au niveau M1, il faut retenir que :

- le problème est **non convexe** et peut avoir plusieurs minima locaux ;
- il peut être **mal conditionné** (paramètres peu identifiables sur une fenêtre de marché) ;
- il nécessite souvent **régularisation** et **diagnostics** (stabilité temporelle des paramètres, sensibilité).

Décision : du pricing à l'optimisation séquentielle

Une fois un prix et des sensibilités disponibles, une “décision” (couverture, rebalancement) s’écrit naturellement comme un *problème de contrôle* en temps discret : choisir une action a_t (quantités tradées) à chaque date sur la base de l’état X_t pour minimiser une fonction de coût :

$$\min_{\pi} \mathbb{E} \left[\sum_{t \in \{t_0, \dots, t_{n-1}\}} \text{coût}(X_t, a_t) + \text{risque final}(X_T) \right],$$

avec contraintes (budget, limites, coûts de transaction). Cette formulation explique pourquoi un cadre MDP (et, éventuellement, RL) est un *langage naturel* pour décrire un hedge discret.

Dérivation conceptuelle : pourquoi ce graphe est le bon (en finance)

Le découpage “données $\rightarrow$ modèles $\rightarrow$ décision $\rightarrow$ exécution” n’est pas qu’un choix d’organisation : c’est la transcription d’un raisonnement financier standard.

1. **Étape 1 : définir la variable d’état.** Exemple : pour une option vanille, l’état minimal est (t, S_t) ; pour Heston, c’est (t, S_t, V_t) ; pour un portefeuille, c’est (positions, cash, contraintes, paramètres de risque).
2. **Étape 2 : choisir une hypothèse dynamique.** Une hypothèse de diffusion (GBM) ou de volatilité stochastique (Heston) ne vaut pas “vérité” : elle fixe une *famille de lois* pour S_T et donc une famille de prix pour $\Phi(S_T)$.
3. **Étape 3 : fixer un principe de valorisation.** En absence d’arbitrage, le prix est une espérance actualisée sous une mesure $\mathbb{Q}$ (ou une solution de PDE équivalente) ; dans un marché incomplet, il faut choisir un critère (min-variance, entropie minimale, etc.).
4. **Étape 4 : calibrer.** Le marché fournit des prix (ou des IV). Le modèle fournit des prix (ou des IV) comme fonction de paramètres. On résout un problème inverse (souvent non convexe) : *trouver des paramètres qui reproduisent au mieux le marché*.
5. **Étape 5 : décider et gérer le risque.** Un modèle donne un prix “théorique”, des grecs, une distribution de PnL, etc. La décision (hedge/rebalancement) se fait sous contraintes (discrétisation, coûts, limites de risque).
6. **Étape 6 : exécuter.** Sans exécution (même papier), la boucle de rétroaction est incomplète : on ne peut pas confronter modèle et résultats (PNL, slippage, erreurs de calibration).

Ainsi, le graphe de dépendances n’est pas décoratif : il matérialise le chemin *hypothèses $\rightarrow$ prix $\rightarrow$ décisions*.

Ce que le jury doit retenir

Ce dossier ne cherche pas à empiler des recettes : il formalise une **chaîne de raisonnement** cohérente, de la donnée brute jusqu’à une décision sous contraintes. Le point clé à retenir est la séparation *hypothèses* (modèle et mesure) / *calcul* (pricers, calibration) / *décision* (couverture, allocation, risque).

Première partie

Stochastic calculus & pricing (base
indispensable)

Chapitre 1

Brownien et intégrale stochastique

1.1 A. Problème financier (objectif, inputs, outputs)

On veut modéliser l'incertitude du prix d'un sous-jacent (action) à court terme pour :

- pricer des options (prix = espérance actualisée sous une mesure appropriée) ;
- simuler des trajectoires (Monte Carlo) ;
- construire des risques (grecs, PnL, mesures de risque).

Input : paramètres (S_0, r, q, σ, T) et un générateur de bruit. **Output** : une trajectoire S_t (ou une loi de S_T).

1.2 B. Théorie (définitions, hypothèses)

Définition formelle

Définition 1.1 (Mouvement brownien). Sur un espace probabilisé filtré $(\Omega, \mathcal{F}, (\mathcal{F}_t)_{t \geq 0}, \mathbb{P})$, un processus $(W_t)_{t \geq 0}$ est un *mouvement brownien standard* si :

1. $W_0 = 0$ p.s. ;
2. $W_t - W_s \sim \mathcal{N}(0, t - s)$ pour $0 \leq s < t$;
3. les accroissements sont indépendants ;
4. $t \mapsto W_t$ est continu.

L'intégrale stochastique (Itô) est l'opérateur qui donne sens à

$$\int_0^T H_t, dW_t$$

pour des processus adaptés H_t (typiquement carrés-intégrables).

Intuition financière

- Le brownien représente un “bruit” agrégé (micro-chocs) qui, à l'échelle du modèle, a des incréments gaussiens.
- L'intégrale stochastique est la façon correcte d'accumuler un risque instantané : si l'exposition H_t varie dans le temps, la volatilité cumulée n'est pas une somme classique mais une intégrale par rapport à W .
- **À quoi ça sert ?** C'est le socle de la dynamique GBM (Black–Scholes) et des simulations Monte Carlo utilisées partout (pricing, exotiques, calibration rough/Volterra).

- **Hypothèses.** Marché frictionless pour les modèles de base ; dynamique continue ; volatilité constante si GBM ; indépendance/gaussianité du bruit.
- **Limites.** Le brownien est une idéalisation : sauts, volatilité stochastique, microstructure, queues épaisses.
- **Applications.** Simulation Monte Carlo des diffusions : l’approximation opérationnelle est toujours $\Delta W \approx \sqrt{\Delta t} Z$ avec $Z \sim \mathcal{N}(0, 1)$, puis accumulation des incréments.

Filtration, adaptativité et “information disponible”

La filtration $(\mathcal{F}_t)_{t \geq 0}$ formalise l’information observable jusqu’au temps t . Dire que H_t est *adapté* signifie que H_t ne dépend que de l’information passée et présente (pas d’anticipation). En finance, c’est la traduction mathématique de : “un hedge à t ne peut pas dépendre de $S_{t+\varepsilon}$ ”.

Construction (idée) de l’intégrale d’Itô

On construit d’abord l’intégrale pour des *processus simples* :

$$H_t = \sum_{k=0}^{n-1} h_k \mathbf{1}_{(t_k, t_{k+1}]}(t), \quad h_k \in \mathcal{F}_{t_k}.$$

On définit alors

$$\int_0^T H_t dW_t := \sum_{k=0}^{n-1} h_k (W_{t_{k+1}} - W_{t_k}).$$

Puis on étend par densité à des processus H dans $L^2(\Omega \times [0, T])$ (adaptés) via une limite en moyenne quadratique.

Théorème 1.1 (Isométrie d’Itô). *Si H est adapté et $\mathbb{E}[\int_0^T H_t^2 dt] < \infty$, alors*

$$\mathbb{E}\left[\left(\int_0^T H_t dW_t\right)^2\right] = \mathbb{E}\left[\int_0^T H_t^2 dt\right].$$

En particulier, $\mathbb{E}[\int_0^T H_t dW_t] = 0$ (l’intégrale d’Itô est une martingale).

Remarque 1.1. L’isométrie est le pont “théorie $\leftrightarrow$ pratique” : elle dit que la variance d’un risque intégré est l’intégrale des variances instantanées. Dans les modèles de hedging, cela justifie le rôle central de $\int H_t^2 dt$ comme quantité de risque cumulée.

Propriétés browniennes utiles pour les dérivés

Au-delà de la définition, certaines propriétés structurent l’intuition de produits exotiques :

- **Scaling** : $(W_{ct})_{t \geq 0} \stackrel{d}{=} (\sqrt{c} W_t)_{t \geq 0}$.
- **Maximum et barrières (intuition)** : la loi de $\sup_{0 \leq u \leq T} W_u$ et les probabilités de franchissement s’obtiennent via le principe de réflexion ; c’est la base de formules fermées pour certaines options barrières en Black–Scholes.
- **Temps d’arrêt** : les hitting times $\tau_a = \inf\{t : W_t = a\}$ interviennent naturellement dès qu’une payoff dépend du premier passage d’un niveau.

1.3 C. Dérivations (ultra détaillées)

De W_t à la dynamique de prix (GBM)

Le modèle de Black–Scholes suppose une dynamique (sous la mesure risque-neutre $\mathbb{Q}$) :

$$\frac{dS_t}{S_t} = (r - q)dt + \sigma dW_t^{\mathbb{Q}}.$$

On le réécrit :

$$dS_t = (r - q)S_t dt + \sigma S_t dW_t.$$

L'objet *non classique* est dW_t : ce n'est pas une dérivée ordinaire, mais un incrément brownien.

Solution exacte discrétisée

On sait (via Itô, démontré au chapitre Itô) que la solution est :

$$S_t = S_0 \exp \left((r - q - \frac{1}{2}\sigma^2)t + \sigma W_t \right).$$

Pour une discrétisation $t_{n+1} = t_n + \Delta t$,

$$\ln S_{t_{n+1}} - \ln S_{t_n} = (r - q - \frac{1}{2}\sigma^2)\Delta t + \sigma(W_{t_{n+1}} - W_{t_n}),$$

et comme $W_{t_{n+1}} - W_{t_n} \sim \mathcal{N}(0, \Delta t)$, on simule :

$$W_{t_{n+1}} - W_{t_n} = \sqrt{\Delta t} Z_n, \quad Z_n \sim \mathcal{N}(0, 1),$$

d'où

$$S_{t_{n+1}} = S_{t_n} \exp \left((r - q - \frac{1}{2}\sigma^2)\Delta t + \sigma\sqrt{\Delta t} Z_n \right).$$

Loi de S_T (log-normale) et moments

La formule fermée donne directement la loi :

$$\ln S_T = \ln S_0 + \left(r - q - \frac{1}{2}\sigma^2 \right) T + \sigma W_T.$$

Comme $W_T \sim \mathcal{N}(0, T)$, on a

$$\ln S_T \sim \mathcal{N} \left(\ln S_0 + (r - q - \frac{1}{2}\sigma^2)T, \sigma^2 T \right),$$

donc S_T est **log-normal**.

Moments (taux constants). Sous la mesure risque-neutre (drift $r - q$), on retrouve le forward :

$$\mathbb{E}^{\mathbb{Q}}[S_T] = S_0 e^{(r-q)T} = F_{0,T}.$$

Et la variance est

$$\text{Var}^{\mathbb{Q}}(S_T) = S_0^2 e^{2(r-q)T} (e^{\sigma^2 T} - 1),$$

ce qui met en évidence l'effet *exponentiel* de $\sigma^2 T$.

Exact vs Euler : pourquoi l'exponentielle est préférable

Une discrétisation Euler directe sur S ,

$$S_{t_{n+1}} = S_{t_n} + (r - q)S_{t_n}\Delta t + \sigma S_{t_n}\Delta W_n,$$

peut produire des valeurs négatives (car l'approximation est additive). À l'inverse, la discrétisation *exacte* via $\ln S$ garantit $S_{t_{n+1}} > 0$ et reproduit la loi marginale correcte à chaque pas.

Ce que le jury doit retenir

Le brownien est une brique de base : il explique l'échelle $\sqrt{\Delta t}$ du bruit (donc la forme $\Delta W \approx \sqrt{\Delta t} Z$) et structure toutes les diffusions utilisées en pricing et en simulation Monte Carlo.

Chapitre 2

Variation quadratique

2.1 A. Problème financier

Pourquoi une dérivation (Itô) diffère-t-elle du calcul classique ? Parce qu'un brownien a des variations "trop rugueuses" : la somme des carrés des incréments ne tend pas vers 0 mais vers le temps.

2.2 B. Théorie

Définition 2.1 (Variation quadratique). Soit une partition $\pi = 0 = t_0 < \dots < t_n = T$. La variation quadratique d'un processus X sur $[0, T]$ est (si la limite existe) :

$$[X]_T = \lim_{|\pi| \rightarrow 0} \sum_{k=0}^{n-1} (X_{t_{k+1}} - X_{t_k})^2.$$

Proposition 2.1 (Cas du brownien). Pour un brownien W , on a $[W]_T = T$ (p.s.).

Intuition

Sur un intervalle Δt , l'incrément $W_{t+\Delta t} - W_t$ est de taille typique $\sqrt{\Delta t}$. Son carré est donc typiquement Δt . En sommant $n \simeq T/\Delta t$ termes, on obtient un total $\simeq T$.

- **À quoi ça sert ?** C'est la raison mathématique de la règle *clé* : $(dW)^2 = dt$ en calcul d'Itô, utilisée pour obtenir les solutions exactes et la PDE de Black-Scholes.
- **Hypothèses.** Hypothèse : bruit brownien (gaussien, continu).
- **Limites.** Avec sauts ou volatilité rough, la structure de variation change ; les règles d'Itô se généralisent mais ne sont plus " $(dW)^2 = dt$ " au sens classique.
- **Applications.** Justifie le terme correctif d'Itô et, très concrètement, l'usage des schémas log-normaux (exponentiels) pour préserver la positivité et la bonne variance en diffusion.

Variation totale vs variation quadratique

Deux notions sont souvent confondues :

- la **variation totale** $\text{Var}(X; [0, T]) = \sup_{\pi} \sum_k |\Delta X_k|$ mesure l'"accumulation en valeur absolue" ;
- la **variation quadratique** $[X]_T = \lim_{|\pi| \rightarrow 0} \sum_k (\Delta X_k)^2$ mesure l'"accumulation d'énergie".

Un processus peut avoir une variation totale infinie mais une variation quadratique finie (c'est le cas du brownien).

Proposition 2.2 (Cas de variation finie). *Si X est de variation finie sur $[0, T]$ (par exemple $X_t = \int_0^t a_u du$), alors $[X]_T = 0$.*

Proposition 2.3 (Cas des processus d'Itô). *Si $X_t = X_0 + \int_0^t a_u du + \int_0^t b_u dW_u$ avec a, b adaptés et carrés-intégrables, alors*

$$[X]_t = \int_0^t b_u^2 du.$$

Covariation (utile en dimension d)

Pour deux processus X, Y , on définit la covariation

$$[X, Y]_T = \lim_{|\pi| \rightarrow 0} \sum_k (X_{t_{k+1}} - X_{t_k})(Y_{t_{k+1}} - Y_{t_k}).$$

En particulier, si $(W^{(1)}, W^{(2)})$ est un brownien corrélé avec corrélation ρ , alors $[W^{(1)}, W^{(2)}]_t = \rho t$.

2.3 C. Dérivations (ultra détaillées)

Pourquoi $\sum (\Delta W)^2 \rightarrow T$

Pour une partition uniforme $t_k = k\Delta t$, $\Delta W_k = W_{t_{k+1}} - W_{t_k} \sim \mathcal{N}(0, \Delta t)$ i.i.d. Donc

$$\mathbb{E}[(\Delta W_k)^2] = \Delta t, \quad \text{Var}((\Delta W_k)^2) = 2(\Delta t)^2.$$

La somme $S_n = \sum_{k=0}^{n-1} (\Delta W_k)^2$ vérifie :

$$\mathbb{E}[S_n] = n\Delta t = T, \quad \text{Var}(S_n) = n \cdot 2(\Delta t)^2 = 2T\Delta t \rightarrow 0.$$

Donc $S_n \rightarrow T$ en L^2 , donc en probabilité, et (avec un argument plus fin) p.s.

Lecture en termes de loi χ^2 (intuition forte)

Sur une partition uniforme, on peut écrire $\Delta W_k = \sqrt{\Delta t} Z_k$ avec $Z_k \sim \mathcal{N}(0, 1)$ i.i.d. Alors

$$S_n = \sum_{k=0}^{n-1} (\Delta W_k)^2 = \Delta t \sum_{k=0}^{n-1} Z_k^2.$$

La somme $\sum Z_k^2$ suit une loi $\chi^2(n)$, de moyenne n et variance $2n$. Ainsi $S_n = \Delta t \chi^2(n)$ est concentré autour de $n\Delta t = T$ avec des fluctuations typiques de taille $\sqrt{2n}\Delta t = \sqrt{2T\Delta t}$, qui tendent vers 0.

Conséquence opératoire : la règle $(dW)^2 = dt$

Dans un calcul “au premier ordre”, on retient les ordres de grandeur :

$$\Delta W = O(\sqrt{\Delta t}), \quad (\Delta W)^2 = O(\Delta t).$$

Donc quand on développe une fonction non linéaire (Taylor), les termes en $(\Delta W)^2$ *ne sont pas négligeables* : ils contribuent au terme en Δt , ce qui produit la correction d'Itô.

Ce que le jury doit retenir

La variation quadratique est la justification rigoureuse de la règle de calcul d'Itô. Sans elle, on ne peut pas dériver correctement ni la solution GBM, ni la PDE de Black–Scholes.

Chapitre 3

Lemme d'Itô (1D et multi-dim)

3.1 A. Problème financier

Les produits dérivés sont des fonctions $V(t, S_t, \dots)$ d'états aléatoires. Pour relier :

- la dynamique du sous-jacent S_t ,
- la dynamique du prix de l'option $V_t = V(t, S_t)$,

il faut une règle de dérivation adaptée au bruit brownien.

3.2 B. Théorie

Théorème 3.1 (Itô 1D). *Soit X_t solution de $dX_t = \mu(t, X_t)dt + \sigma(t, X_t)dW_t$, et $f \in C^{1,2}$. Alors*

$$df(t, X_t) = \partial_t f, dt + \partial_x f, dX_t + \frac{1}{2}, \partial_{xx} f, (dX_t)^2,$$

et comme $(dX_t)^2 = \sigma^2(t, X_t)dt$ (via $(dW)^2 = dt$), on obtient

$$df(t, X_t) = \left(\partial_t f + \mu, \partial_x f + \frac{1}{2}\sigma^2, \partial_{xx} f \right) dt + \sigma, \partial_x f, dW_t.$$

Théorème 3.2 (Itô multi-dim (forme utile)). *Si $\mathbf{X}_t \in \mathbb{R}^d$ suit $d\mathbf{X}_t = \boldsymbol{\mu}dt + \Sigma, d\mathbf{W}_t$ et $f \in C^{1,2}$, alors*

$$df(t, \mathbf{X}_t) = \partial_t f, dt + \nabla f^\top d\mathbf{X}_t + \frac{1}{2}\text{Tr}(\Sigma \Sigma^\top \nabla^2 f)dt.$$

Intuition

Le terme $\frac{1}{2}\sigma^2 f_{xx}dt$ est la “correction de convexité” : une fonction convexe appliquée à un bruit a un drift positif (Jensen), et Itô quantifie exactement cet effet à l'ordre dt .

- **À quoi ça sert ?** Transformer une dynamique de prix (SDE) en dynamique de prix d'option ; dériver la PDE Black–Scholes ; obtenir des solutions fermées (GBM) ; justifier des schémas numériques.
- **Hypothèses.** Hypothèses de régularité ($C^{1,2}$) et bruit brownien continu.
- **Limites.** Les payoffs usuels ne sont pas lisses (kink) : on travaille avec des solutions faibles (PDE de viscosité), des approximations lisses, ou des extensions (Tanaka et temps local) pour justifier rigoureusement les passages à la limite.
- **Applications.** Outil omniprésent : Itô relie SDE $\leftrightarrow$ PDE (Feynman–Kac) et donne des contrôles de cohérence (drift/variance) utilisés dans les formules fermées et la conception de schémas numériques.

Formule produit : l’“intégration par parties” stochastique

Si X_t et Y_t sont deux processus d’Itô, la règle de dérivation n’est plus $d(XY) = X dY + Y dX$ mais

$$d(X_t Y_t) = X_t dY_t + Y_t dX_t + d[X, Y]_t,$$

où $[X, Y]$ est la covariation (et $[W, W]_t = t$). C’est la formule centrale derrière :

- la dynamique d’un portefeuille auto-financé ;
- la construction de stratégies de couverture (on élimine la partie martingale en choisissant Δ).

Payoffs non lisses : pourquoi ça marche quand même (idée)

Le payoff d’un call $(S - K)^+$ n’est pas C^2 en $S = K$. En pratique on peut :

- soit raisonner via la PDE et des solutions faibles (viscosité) ;
- soit approximer le payoff par une famille lisse et passer à la limite ;
- soit utiliser une extension d’Itô (formule de Tanaka) qui introduit un terme de *temps local* au point K .

Intuition : le “kink” du payoff concentre de la convexité au strike ; cette convexité se manifeste dans la couverture via Γ .

3.3 C. Dérivations (ultra détaillées)

Dérivation (Taylor) et apparition de $(dW)^2$

On écrit un développement de Taylor à l’ordre 2 :

$$f(t + dt, X_t + dX) - f(t, X_t) = f_t dt + f_x dX + \frac{1}{2} f_{xx} (dX)^2 + o(dt).$$

Or $dX = \mu dt + \sigma dW$. En développant :

$$(dX)^2 = (\mu dt)^2 + 2\mu\sigma dt, dW + \sigma^2 (dW)^2.$$

On utilise les ordres de grandeur :

$$dt = O(dt), \quad dW = O(\sqrt{dt}), \quad (dW)^2 = O(dt), \quad dt, dW = O(dt^{3/2}), \quad (dt)^2 = O(dt^2).$$

Donc à l’ordre dt , on néglige $(dt)^2$ et dt, dW , mais on *garde* $\sigma^2 (dW)^2$, et avec $[W]_t = t$, on remplace $(dW)^2$ par dt . D’où le terme $\frac{1}{2} \sigma^2 f_{xx} dt$.

Exemple Itô : $f(x) = \ln x$ et GBM

Sous GBM : $dS = (r - q)S, dt + \sigma S, dW$. Pour $f(S) = \ln S$:

$$f_S = \frac{1}{S}, \quad f_{SS} = -\frac{1}{S^2}.$$

Itô :

$$d \ln S = \frac{1}{S} dS + \frac{1}{2} \left(-\frac{1}{S^2} \right) (\sigma^2 S^2) dt = (r - q) dt + \sigma dW - \frac{1}{2} \sigma^2 dt$$

soit

$$d \ln S = (r - q - \frac{1}{2} \sigma^2) dt + \sigma, dW,$$

ce qui justifie la solution exponentielle utilisée en simulation.

Exemple : formule produit à partir d'Itô

Appliquons Itô à $f(x, y) = xy$ avec (X_t, Y_t) un couple d'Itô :

$$dX_t = a_t dt + b_t dW_t, \quad dY_t = c_t dt + d_t dW_t.$$

Comme $f_x = y$, $f_y = x$, $f_{xy} = 1$, et que $dX dY = b_t d_t dt$, on obtient

$$d(X_t Y_t) = X_t dY_t + Y_t dX_t + b_t d_t dt = X_t dY_t + Y_t dX_t + d[X, Y]_t.$$

Ce calcul explique pourquoi des termes “d'ordre 2” apparaissent dans les portefeuilles continus.

Exemple : puissance et moments de GBM

Sous GBM, S_t^p a une dynamique explicite. En posant $f(s) = s^p$, on obtient

$$d(S_t^p) = p S_t^{p-1} \left((r - q) dt + \sigma dW_t \right) + \frac{1}{2} p(p-1) \sigma^2 S_t^{p-2} dt,$$

soit

$$d(S_t^p) = S_t^p \left(p(r - q) + \frac{1}{2} p(p-1) \sigma^2 \right) dt + p \sigma S_t^{p-1} dW_t.$$

En prenant l'espérance sous $\mathbb{Q}$, on retrouve des formules fermées pour $\mathbb{E}[S_T^p]$ (utile pour comprendre les moments et les contraintes de Carr–Madan/FFT).

Ce que le jury doit retenir

Itô est la “règle de dérivation” du monde stochastique. La correction $\frac{1}{2} \sigma^2 f_{xx}$ est le point conceptuel à comprendre : c'est elle qui rend GBM log-normal et qui mène à la PDE de pricing.

Chapitre 4

Risk-neutral pricing, hedging et PDE (Black–Scholes & Feynman–Kac)

4.1 A. Problème financier

Une option européenne a un payoff $\Phi(S_T)$ à maturité. Objectif : déterminer un prix “sans arbitrage” V_0 aujourd’hui, cohérent avec la possibilité de couvrir (hedger) dynamiquement.

4.2 B. Théorie

Définition formelle : absence d’arbitrage et mesure risque-neutre

Dans un marché frictionless complet (hypothèse BS), absence d’arbitrage $\Rightarrow$ existence d’une mesure $\mathbb{Q}$ telle que le prix actualisé est une martingale :

$$\tilde{S}_t = e^{-(r-q)t} S_t \text{ est une } \mathbb{Q}\text{-martingale.}$$

Pour un payoff $\Phi(S_T)$, le prix est :

$$V_0 = e^{-rT} \mathbb{E}^{\mathbb{Q}}[\Phi(S_T) \mid \mathcal{F}_0].$$

Intuition financière

La mesure $\mathbb{Q}$ n’est pas “la vraie probabilité”, c’est une transformation qui fait disparaître les primes de risque dans le drift. Le prix devient une espérance actualisée car on raisonne en *numéraire* (monnaie à taux r).

- **À quoi ça sert ?** Relier couverture (réplication) $\leftrightarrow$ prix ; produire une PDE solvable numériquement ; justifier la formule BS.
- **Hypothèses.** Marché complet, trading continu, pas de coûts, volatilité constante, taux r et dividend yield q constants.
- **Limites.** En rebalancement discret, avec coûts, sauts ou volatilité stochastique, la réplication parfaite échoue : on bascule vers marché incomplet (mesure risque-neutre non unique) et/ou vers des couvertures optimales (min-variance, utilité).
- **Applications.** Cadre de référence : PDE de Black–Scholes, lien Feynman–Kac, et conception de schémas PDE (implicites/Crank–Nicolson) comme outils numériques de pricing et de stress.

Portefeuilles auto-financés : l’hypothèse cachée des dérivations

On considère un portefeuille composé du sous-jacent et du compte monétaire :

$$X_t = \Delta_t S_t + \beta_t B_t.$$

Dire que le portefeuille est *auto-financé* signifie que toute variation de X_t vient uniquement des variations de prix des actifs (on n’injecte pas de cash exogène). Dans un modèle à dividendes continus (q), il faut aussi préciser si S_t est un prix *ex-dividend* : c’est ce point qui explique l’apparition de $(r - q)$ dans la PDE.

Théorème fondamental de l’évaluation des actifs (énoncé, intuition)

Sans entrer dans toutes les subtilités d’intégrabilité, l’idée est :

- **Absence d’arbitrage** $\iff$ il existe au moins une mesure $\mathbb{Q}$ équivalente à $\mathbb{P}$ sous laquelle les prix actualisés sont des martingales.
- **Complétude** $\iff$ cette mesure est unique (et alors tout payoff intégrable est répliquable).

Le modèle Black–Scholes est complet (une source de risque, un actif risqué), d’où l’unicité de $\mathbb{Q}$ et la possibilité de couvrir parfaitement une option européenne.

Girsanov : comment le drift “réel” disparaît

Sous $\mathbb{P}$, on écrit souvent

$$\frac{dS_t}{S_t} = \mu dt + \sigma dW_t^{\mathbb{P}}.$$

On définit le *prix du risque de marché* $\lambda = \frac{\mu - (r - q)}{\sigma}$ et un nouveau brownien

$$dW_t^{\mathbb{Q}} = dW_t^{\mathbb{P}} + \lambda dt.$$

Le théorème de Girsanov garantit l’existence d’une mesure $\mathbb{Q}$ sous laquelle $W^{\mathbb{Q}}$ est brownien, et la dynamique devient

$$\frac{dS_t}{S_t} = (r - q) dt + \sigma dW_t^{\mathbb{Q}}.$$

Message pratique : le pricing sans arbitrage dépend de σ et de $(r - q)$, pas de μ .

4.3 C. Dérivations (ultra détaillées)

Dérivation complète de Black–Scholes via portefeuille couvert

On suppose sous $\mathbb{P}$: $dS = \mu S dt + \sigma S dW$ (le drift réel μ est inconnu/irrelevant pour le pricing BS).

Soit $V(t, S)$ le prix de l’option. Par Itô :

$$dV = V_t dt + V_S dS + \frac{1}{2} V_{SS} (dS)^2 = \left(V_t + \mu S V_S + \frac{1}{2} \sigma^2 S^2 V_{SS} \right) dt + \sigma S V_S dW.$$

Construisons un portefeuille auto-financé :

$$\Pi = V - \Delta S,$$

où Δ est choisi pour annuler le terme aléatoire. On calcule :

$$d\Pi = dV - \Delta dS.$$

En substituant :

$$\begin{aligned} d\Pi &= dV - \Delta dS \\ &= \left(V_t + \mu SV_S + \frac{1}{2} \sigma^2 S^2 V_{SS} \right) dt + \sigma SV_S dW \\ &\quad - \Delta(\mu S dt + \sigma S dW). \end{aligned}$$

Choisir $\Delta = V_S$ annule le terme en dW :

$$d\Pi = \left(V_t + \frac{1}{2} \sigma^2 S^2 V_{SS} \right) dt.$$

Maintenant, en absence d'arbitrage, un portefeuille sans risque doit rapporter le taux sans risque *sur la valeur investie*. Ici, attention : la position en S doit être financée et il existe un yield q (dividende continu). La forme standard conduit à :

$$d\Pi = r\Pi, dt = r(V - V_S S)dt.$$

En égalant les deux expressions :

$$V_t + \frac{1}{2} \sigma^2 S^2 V_{SS} = r(V - SV_S).$$

En réarrangeant, on obtient la PDE de Black–Scholes avec dividende :

$$\boxed{V_t + (r - q)SV_S + \frac{1}{2} \sigma^2 S^2 V_{SS} - rV = 0.}$$

Condition terminale : $V(T, S) = \Phi(S)$.

Feynman–Kac (PDE $\leftrightarrow$ espérance)

Le théorème de Feynman–Kac dit essentiellement : la solution de la PDE précédente est l'espérance risque-neutre actualisée. Intuition : on suit la trajectoire stochastique de S_t sous $\mathbb{Q}$ (drift $r - q$) et la martingale du prix actualisé force l'égalité PDE/espérance.

Feynman–Kac : énoncé (forme minimale) et idée de preuve

Considérons un processus S_t sous $\mathbb{Q}$:

$$dS_t = (r - q)S_t dt + \sigma S_t dW_t^{\mathbb{Q}}.$$

Soit $V(t, S)$ solution régulière de

$$V_t + (r - q)SV_S + \frac{1}{2} \sigma^2 S^2 V_{SS} - rV = 0, \quad V(T, S) = \Phi(S).$$

Alors Feynman–Kac donne

$$V(t, S_t) = \mathbb{E}^{\mathbb{Q}}[e^{-r(T-t)} \Phi(S_T) \mid \mathcal{F}_t].$$

Idée : appliquer Itô à $e^{-rt}V(t, S_t)$; la PDE force le terme en dt à disparaître, donc $e^{-rt}V(t, S_t)$ est une martingale, et on identifie sa valeur par condition terminale.

Changement de variables : la PDE devient une équation de la chaleur

En posant $x = \ln S$ et $\tau = T - t$, la PDE de Black–Scholes se transforme (après centrage) en une équation de la chaleur sur τ . Ce point explique pourquoi la solution fermée (formule BS) s'exprime en fonction de la loi normale. Il est aussi utile numériquement : beaucoup de schémas PDE s'analysent plus facilement sur la version “heat equation”.

Ce que le jury doit retenir

La PDE de Black–Scholes vient d'une couverture : choisir $\Delta = V_S$ annule le risque brownien. En pratique, la résolution numérique de cette PDE (p. ex. schémas implicites/Crank–Nicolson) est un outil robuste pour pricer quand on ne dispose pas d'une formule fermée ou pour vérifier des moteurs plus complexes.

Chapitre 5

Options vanilles : BS, greeks, implied vol (inversion numérique)

5.1 A. Problème financier

Dans une salle de marché, on cote souvent une option via sa volatilité implicite σ_{impl} plutôt que son prix. On veut :

- pricer (BS), obtenir les grecs (sensibilités),
- inverser BS : prix $\rightarrow \sigma_{\text{impl}}$,
- comparer une surface marché à une surface modèle.

5.2 B. Théorie

Formule BS (call/put) avec dividende continu

Pour $d_1 = \frac{\ln(S_0/K) + (r - q + \frac{1}{2}\sigma^2)T}{\sigma\sqrt{T}}$, $d_2 = d_1 - \sigma\sqrt{T}$:

$$C = S_0 e^{-qT} N(d_1) - K e^{-rT} N(d_2), \quad P = K e^{-rT} N(-d_2) - S_0 e^{-qT} N(-d_1).$$

Greeks (rappel)

$$\Delta_{\text{call}} = e^{-qT} N(d_1), \quad \Gamma = \frac{e^{-qT} \varphi(d_1)}{S_0 \sigma \sqrt{T}}, \quad \text{Vega} = S_0 e^{-qT} \varphi(d_1) \sqrt{T},$$

où φ est la densité $\mathcal{N}(0, 1)$.

Volatilité implicite

Définition : σ_{impl} est la solution de

$$C_{\text{BS}}(S_0, K, r, q, T, \sigma) = C_{\text{mkt}}.$$

Pour un call européen, C_{BS} est croissant en σ (Vega > 0), donc l'inversion est un problème 1D bien posé (si le prix respecte les bornes d'arbitrage).

- **À quoi ça sert ?** Standardiser la comparaison marché/modèle ; construire une surface (K,T) d'IV ; alimenter la calibration (Partie II).
- **Hypothèses.** Option européenne, modèle BS pour définir l'IV ; prix dans les bornes (pas d'arbitrage statique).

- **Limites.** IV dépend du modèle : sous sauts/vol stochastique, l'IV résume un modèle plus riche. Pour certains produits (américaines), l'IV BS est un proxy.
- **Applications.** Brique de marché : cotation en IV et inversion numérique (root-finding robuste) ; permet de comparer des modèles hétérogènes via une même “échelle” $\sigma_{\text{impl}}(K, T)$.

Interprétation de d_1 et d_2 (lecture probabiliste)

Sous Black-Scholes (taux constants), on peut écrire

$$C = e^{-rT} \mathbb{E}^{\mathbb{Q}}[(S_T - K)^+].$$

Comme S_T est log-normal, les intégrales se ramènent à des probabilités gaussiennes et d_1, d_2 apparaissent comme des variables normalisées. Une lecture classique est :

- $N(d_2)$ est proche d’une *probabilité risque-neutre* que l’option finisse dans la monnaie (ITM), ajustée par actualisation ;
- $N(d_1)$ est lié à la probabilité “pondérée par S_T ”, ce qui explique pourquoi $\Delta_{\text{call}} = e^{-qT} N(d_1)$.

Ce sont des heuristiques (les mesures changent), mais elles donnent une intuition robuste.

Parité call-put et identités de base

La parité call-put (européenne) sous dividende continu est :

$$C - P = S_0 e^{-qT} - K e^{-rT}.$$

Elle sert de contrôle qualité : si des prix de marché violent fortement cette égalité (en tenant compte du bid/ask), l'IV implicite devient instable ou incohérente.

5.3 C. Dérivations (ultra détaillées)

Bornes d’arbitrage et monotonie

Pour un call :

$$\max(S_0 e^{-qT} - K e^{-rT}, 0) \leq C \leq S_0 e^{-qT}.$$

Si C est hors bornes, *aucune* volatilité ne peut l’expliquer dans BS $\Rightarrow$ on renvoie NaN.

Inversion numérique : méthode de Brent

On résout $f(\sigma) = C_{\text{BS}}(\sigma) - C_{\text{mkt}} = 0$. Brent combine bisection (robuste) et interpolation (rapide) et requiert un encadrement $[\sigma_{\min}, \sigma_{\max}]$ tel que $f(\sigma_{\min})f(\sigma_{\max}) \leq 0$.

Pourquoi l’inversion est bien posée : Vega > 0

On a (call européen) :

$$\frac{\partial C_{\text{BS}}}{\partial \sigma} = \text{Vega} = S_0 e^{-qT} \varphi(d_1) \sqrt{T} > 0 \quad (T > 0).$$

Donc $C_{\text{BS}}(\sigma)$ est strictement croissant en σ et l’équation $C_{\text{BS}}(\sigma) = C_{\text{mkt}}$ a au plus une solution. Cette propriété explique aussi un fait pratique : quand T est très petit ou quand l’option est très loin de la monnaie, $\varphi(d_1)$ devient minuscule et l’inversion devient numériquement fragile (Vega quasi nulle).

Newton : dérivation de l'itération (et pourquoi on préfère Brent en production)

Newton s'obtient en linéarisant $f(\sigma)$:

$$0 = f(\sigma^*) \approx f(\sigma_n) + f'(\sigma_n)(\sigma^* - \sigma_n),$$

donc

$$\sigma_{n+1} = \sigma_n - \frac{f(\sigma_n)}{f'(\sigma_n)} = \sigma_n - \frac{C_{BS}(\sigma_n) - C_{mkt}}{\text{Vega}(\sigma_n)}.$$

Newton est très rapide près de la solution, mais peut diverger si l'initialisation est mauvaise ou si Vega est faible ; Brent sécurise l'encadrement et évite ces pathologies.

Dérivation de la formule de Black–Scholes (call) : pas à pas

Sous $\mathbb{Q}$ (taux constants), on a

$$\frac{dS_t}{S_t} = (r - q) dt + \sigma dW_t^{\mathbb{Q}} \quad \Rightarrow \quad S_T = S_0 \exp \left((r - q - \tfrac{1}{2}\sigma^2)T + \sigma\sqrt{T} Z \right),$$

où $Z \sim \mathcal{N}(0, 1)$. Le prix du call est

$$C = e^{-rT} \mathbb{E}^{\mathbb{Q}}[(S_T - K)^+] = e^{-rT} \left(\mathbb{E}[S_T \mathbf{1}_{\{S_T > K\}}] - K \mathbb{Q}(S_T > K) \right).$$

Écrivons l'événement $S_T > K$ en termes de Z :

$$\ln S_T > \ln K \iff Z > \frac{\ln(K/S_0) - (r - q - \tfrac{1}{2}\sigma^2)T}{\sigma\sqrt{T}} = -d_2,$$

avec

$$d_2 = \frac{\ln(S_0/K) + (r - q - \tfrac{1}{2}\sigma^2)T}{\sigma\sqrt{T}}, \quad d_1 = d_2 + \sigma\sqrt{T}.$$

Donc $\mathbb{Q}(S_T > K) = \mathbb{P}(Z > -d_2) = N(d_2)$. Pour le terme $\mathbb{E}[S_T \mathbf{1}_{\{S_T > K\}}]$, on utilise la forme exponentielle de S_T :

$$\mathbb{E}[S_T \mathbf{1}_{\{Z > -d_2\}}] = S_0 e^{(r - q - \frac{1}{2}\sigma^2)T} \mathbb{E}[e^{\sigma\sqrt{T}Z} \mathbf{1}_{\{Z > -d_2\}}].$$

Une identité classique sur la normale (complétion du carré) donne :

$$\mathbb{E}[e^{aZ} \mathbf{1}_{\{Z > b\}}] = e^{\frac{1}{2}a^2} N(a - b) \quad (Z \sim \mathcal{N}(0, 1)),$$

ici avec $a = \sigma\sqrt{T}$ et $b = -d_2$, d'où

$$\mathbb{E}[S_T \mathbf{1}_{\{Z > -d_2\}}] = S_0 e^{(r - q)T} N(d_1).$$

En assemblant :

$$\boxed{C = S_0 e^{-qT} N(d_1) - K e^{-rT} N(d_2)}.$$

Le put s'obtient soit par un calcul analogue, soit via la parité call–put.

Dérivation (rapide) de quelques grecs

On dérive $C(S_0, \sigma, \dots)$:

- **Delta.** On obtient $\Delta = \partial_{S_0} C = e^{-qT} N(d_1)$ (le terme en $\partial d_1 / \partial S_0$ s'annule grâce à une identité entre N et φ).
- **Gamma.** Une dérivation supplémentaire donne

$$\Gamma = \partial_{S_0 S_0} C = \frac{e^{-qT} \varphi(d_1)}{S_0 \sigma \sqrt{T}}.$$

- **Vega.** La dérivée par rapport à σ donne

$$\text{Vega} = \partial_{\sigma} C = S_0 e^{-qT} \varphi(d_1) \sqrt{T}.$$

Ces expressions expliquent des faits pratiques : Gamma explose quand $T \rightarrow 0$ à l'ATM, et Vega s'effondre loin de la monnaie.

Ce que le jury doit retenir

La volatilité implicite est l'interface naturelle entre marché et modèle : elle transforme une grille hétérogène de prix en une représentation comparable $\sigma_{\text{impl}}(K, T)$. L'inversion Black-Scholes (root-finding) est la brique standard qui relie prix $\leftrightarrow$ IV et sert de passerelle vers la calibration.

Deuxième partie

Volatility surface & calibration (cœur de la modélisation IV)

Chapitre 6

Surface d'IV : smile/skew, axes, interpolation, arbitrage

6.1 A. Problème financier

Le marché cote une *surface* $\sigma_{\text{impl}}(K, T)$ (ou en moneyness $m = K/S_0$). Objectif :

- représenter proprement les observations (données bruitées et incomplètes),
- interpoler pour pricer des strikes non cotés,
- calibrer un modèle paramétrique pour reproduire la surface.

6.2 B. Théorie

Définition formelle

On appelle *surface d'IV* la fonction

$$(m, T) \mapsto \sigma_{\text{impl}}(m, T),$$

où $m = K/S_0$ et T est la maturité en années. En pratique, on standardise souvent ces deux axes pour obtenir une grille stable.

Intuition financière (smile/skew)

- **Skew** (actions) : les puts OTM sont chers $\Rightarrow$ IV plus élevée pour $K < S_0$ (demande de protection, levier, crash risk).
- **Smile** (FX) : symétrie plus marquée due à la structure de risque différente.
- **À quoi ça sert ?** Construire un objet “marché” qui alimente calibration et pricing ; éviter de pricer sur des trous de données.
- **Hypothèses.** Suppose qu'on peut représenter le marché par des IV pointwise (ce qui est une convention).
- **Limites.** Interpolation peut violer le non-arbitrage (convexité en strike, monotonie en maturité) : une surface d'IV “jolie” n'est pas forcément économiquement admissible.
- **Applications.** Pratique : projection sur une grille + masque d'observation, puis interpolation contrôlée (ou nearest) avant toute calibration ; l'objet “surface” devient une entrée standardisée pour les modèles.

Choix des axes : strike, moneyness, log-moneyness, delta

Une “surface” dépend fortement du système de coordonnées :

- **Strike** K : naturel contractuellement, mais non stationnaire quand S_0 bouge.
- **Moneyness** $m = K/S_0$: rend l’ATM proche de 1, stabilise les grilles.
- **Log-moneyness** $k = \ln(K/F_{0,T})$: souvent préférable car symétrise les formules et relie directement aux développements asymptotiques.
- **Delta** : utilisé en FX (surface cotée en delta) ; la conversion dépend du modèle (BS) et peut être circulaire.

Le point clé : *l’interpolation est plus “douce” dans certains axes*, et les contraintes d’absence d’arbitrage s’expriment plus naturellement sur d’autres (souvent sur les prix ou la variance totale).

Arbitrage statique : contraintes minimales à respecter

Pour des calls européens $C(K, T)$, l’absence d’arbitrage statique implique au minimum :

- C décroît en K (plus le strike est haut, moins le call vaut) ;
- C est convexe en K (densité risque-neutre non négative) ;
- C croît en T (calendar spread : plus de temps ne doit pas rendre l’option moins chère, toutes choses égales par ailleurs).

Une interpolation naïve directement sur σ_{impl} peut violer ces contraintes même si les points de départ (prix de marché) les respectent.

Variance totale $w(k, T) = \sigma_{\text{impl}}(k, T)^2 T$

La variance totale est souvent plus régulière que σ_{impl} et est au cœur de nombreuses paramétrisations (ex. SVI). Elle permet aussi de discuter l’arbitrage “butterfly” et la croissance en maturité de manière plus structurée.

6.3 C. Dérivations (ultra détaillées)

Pourquoi passer en moneyness $m = K/S_0$?

Si le sous-jacent change d’échelle (stock split, variation de prix), une grille en strike absolu devient instable. En moneyness, l’ATM est proche de $m = 1$ et on stabilise l’espace de calibration.

Surface discrète et masque d’observation

On observe des points (m_i, T_i, σ_i) irréguliers. Pour calibrer, on construit une grille $(m_j)_{j=1..M}$, $(T_k)_{k=1..K}$ et on forme une matrice $\Sigma_{k,j}$. Comme tous les points ne sont pas observés, on utilise un *masque* $M_{k,j} \in \{0, 1\}$ qui indique quels points proviennent d’observations. Cela permet :

- de ne pas pénaliser un modèle sur des valeurs interpolées : on compare la perte uniquement sur les points réellement observés,
- de distinguer “data” vs “remplissage”.

Pourquoi l'arbitrage est une question de convexité (Breedon–Litzenberger)

On part de

$$C(K, T) = e^{-rT} \mathbb{E}^{\mathbb{Q}}[(S_T - K)^+].$$

En dérivant par rapport à K (formellement, et sous conditions techniques standard), on obtient :

$$\frac{\partial C}{\partial K}(K, T) = -e^{-rT} \mathbb{Q}(S_T > K),$$

et une seconde dérivée donne la densité risque-neutre :

$$\frac{\partial^2 C}{\partial K^2}(K, T) = e^{-rT} f_{S_T}(K) \geq 0.$$

Donc **convexité en K** $\iff$ **densité non négative**. Cette relation est la pierre angulaire des tests d'arbitrage sur une surface.

Lien (optionnel) : surface d'IV $\rightarrow$ volatilité locale (Dupire)

Si l'on dispose de $C(K, T)$ suffisamment régulier, la formule de Dupire exprime une volatilité locale $\sigma_{\text{loc}}(K, T)$ telle que le modèle de diffusion locale reproduise exactement les prix vanilles :

$$\sigma_{\text{loc}}^2(K, T) = \frac{\partial_T C(K, T)}{\frac{1}{2} K^2 \partial_{KK} C(K, T)} \quad (\text{forme simplifiée, taux constants}).$$

Cela illustre un point important : une surface d'IV contient *beaucoup* d'information sur la distribution risque-neutre, mais toute interpolation doit préserver la régularité requise.

Ce que le jury doit retenir

Une surface d'IV n'est pas une figure : c'est un **objet de données** (fonction continue ou grille discrète) qui sert d'entrée à un problème inverse. Le point clé est de distinguer points observés vs valeurs interpolées (masque), car cela change la notion d'erreur et la stabilité de la calibration.

Chapitre 7

Calibration : principe, fonction objectif, pondérations, contraintes

7.1 A. Problème financier (objectif, inputs, outputs)

On observe une surface de volatilité implicite de marché sur une grille (moneyness, maturité) :

$$\Sigma^{\text{mkt}}_{i,j} \approx \sigma_{\text{impl}}(m_j, T_i), \quad m_j = \frac{K_j}{S_0}.$$

On veut identifier un modèle paramétrique $\mathcal{M}(\theta)$ (SABR, Heston, sauts, rough, ...) tel que sa surface

$$\Sigma^{\text{mod}}(\theta) = \sigma_{\text{impl}}^{\mathcal{M}}(m_j, T_i; \theta)$$

reproduise au mieux le marché.

Inputs : surface de marché (table de points), (S_0, r, q) , une grille (m_j) et (T_i) , un choix de modèle, des contraintes (bornes, paramètres fixés), des réglages d'optimisation. **Outputs** : paramètres calibrés $\hat{\theta}$, surface modèle, résidus (marché vs modèle), métriques (MAE/RMSE) et diagnostics de stabilité.

7.2 B. Théorie (définitions, hypothèses)

Définition formelle : calibration comme problème inverse

On pose un problème d'ajustement (souvent moindres carrés) :

$$\hat{\theta} \in \arg \min_{\theta \in \Theta} \mathcal{L}(\theta),$$

où Θ encode des contraintes (bornes, signes, ...) et $\mathcal{L}$ mesure l'écart marché/modèle.

Deux choix standards :

- **fit en volatilités** : $\mathcal{L}(\theta) = \sum w_{i,j} (\Sigma^{\text{mod}}_{i,j}(\theta) - \Sigma^{\text{mkt}}_{i,j})^2$;
- **fit en prix** : $\mathcal{L}(\theta) = \sum w_{i,j} (C^{\text{mod}}_{i,j}(\theta) - C^{\text{mkt}}_{i,j})^2$, avec C^{mkt} reconstruit via BS à partir de l'IV observée.

Intuition financière

- Calibrer revient à “faire coïncider” le modèle avec la *réalité cotée* (smile/skew) afin que les prix produits soient cohérents (au moins sur les points observés).
- Le fit en *prix* est souvent plus stable car la sensibilité d'un prix à la vol (Vega) varie fortement selon K, T ; le fit en vol peut sur-pondérer des régions où un petit écart de prix correspond à un gros écart d'IV.

- **À quoi ça sert ?** Transformer une surface observée en paramètres de modèle utilisables pour pricing, scénarios et comparaison (surface marché vs surface modèle).
- **Hypothèses.** Qualité de la surface de marché; modèle supposé “assez expressif”; choix d’une fonction perte pertinente; stabilité numérique.
- **Limites.** Non-unicité (plusieurs θ peuvent fitter); minima locaux; absence d’arbitrage non garantie; dépendance au poids et au dataset.
- **Applications.** Au cœur : représenter la surface par une grille (et masque), définir une perte (prix vs IV, pondérations, pénalités) et résoudre un problème inverse souvent non convexe sous contraintes.

Calibration en vol vs calibration en prix : le rôle central de la Vega

Le choix “fit IV” vs “fit prix” est souvent résumé à une préférence, mais il a une lecture quantitative : si un prix est perturbé de ΔC , l’erreur correspondante en volatilité est approximativement

$$\Delta\sigma \approx \frac{\Delta C}{\text{Vega}}.$$

Donc :

- minimiser une erreur en vol *revient* à minimiser une erreur en prix *pondérée par* Vega^{-1} ;
- près de l’ATM (Vega forte) une erreur de prix se traduit par une petite erreur d’IV;
- loin de la monnaie ou pour maturité très courte (Vega faible) l’IV devient numériquement instable.

Cette simple relation explique pourquoi de nombreux desks préfèrent calibrer en prix (ou en prix “normalisés”) avec des poids adaptés.

Pondérations : bid/ask, Vega, et erreurs relatives

Un schéma de pondération “idéal” utiliserait l’incertitude de mesure : si un prix de marché est observé avec un écart-type $\sigma_C(K, T)$ (lié au bid/ask), un maximum de vraisemblance gaussien donne des poids $w \propto 1/\sigma_C^2$. En absence de modèle d’erreur explicite, on utilise souvent :

- **erreur relative** : $(C^{\text{mod}} - C^{\text{mkt}})/\max(\varepsilon, C^{\text{mkt}})$;
- **poids Vega** : erreurs en vol converties en erreurs de prix via Vega;
- **poids bid/ask** : $w \propto 1/(\text{ask} - \text{bid})^2$ (quand disponible).

Identifiabilité : pourquoi plusieurs paramètres peuvent “bien fitter”

Le calibrage est un problème inverse : deux ensembles de paramètres différents peuvent produire des surfaces très proches sur le domaine observé. Cela arrive surtout quand :

- la surface est pauvre (peu de maturités, peu de strikes);
- les options sont peu liquides (bruit important);
- le modèle est trop flexible (beaucoup de paramètres).

Conséquence : il faut raisonner en termes de *robustesse* (stabilité des paramètres) et pas seulement en termes de RMSE de surface.

7.3 C. Dérivations (ultra détaillées)

De la surface IV au prix de marché utilisé en calibration (fit en prix)

Sur un point (K, T) , si l'on observe $\sigma_{\text{impl}}^{\text{mkt}}$, on peut définir un “prix marché cohérent” :

$$C^{\text{mkt}}(K, T) = C_{\text{BS}}(S_0, K, r, q, T, \sigma_{\text{impl}}^{\text{mkt}}(K, T)).$$

Cette transformation est standard : elle convertit une observation en IV (cotation) en un prix de référence, ce qui permet d'exprimer une perte en prix même quand le marché est fourni sous forme d'IV.

Pourquoi une pondération par l'échelle de prix ?

Une perte brute $\sum (C^{\text{mod}} - C^{\text{mkt}})^2$ sur-pondère mécaniquement les prix élevés (ATM/ITM, maturités longues). Une normalisation simple est :

$$\sum \left(\frac{C^{\text{mod}} - C^{\text{mkt}}}{\text{scale}} \right)^2, \quad \text{scale} \approx \max(\varepsilon, C^{\text{mkt}}).$$

Ce choix transforme une erreur absolue en une erreur *relative* (avec plancher ε), ce qui évite qu'une poignée de points très chers domine la calibration.

Contraintes et pénalités : exemple Heston et condition de Feller

Dans Heston, une condition suffisante (non nécessaire) pour que la variance reste strictement positive est la condition de Feller :

$$2\kappa\theta \geq \sigma^2.$$

Plutôt que d'imposer une contrainte dure, on peut ajouter une *pénalité douce* dans la perte (ou dans les résidus) :

$$\mathcal{L}(\theta) \leftarrow \mathcal{L}(\theta) + \lambda \max(0, \sigma^2 - 2\kappa\theta)^2,$$

où $\lambda > 0$ règle l'intensité de la pénalisation. L'intérêt : guider l'optimiseur loin des zones numériquement instables, sans rendre le problème irréalisable si le marché “force” légèrement la contrainte.

Multi-start : pourquoi c'est nécessaire ?

Les pertes sont non convexes (FFT/CF/MC + inversion IV) : on démarre l'optimisation depuis plusieurs initialisations $\theta^{(0)}$ et on garde la meilleure. Deux stratégies typiques :

- **multi-start** : plusieurs points de départ (heuristiques + tirages aléatoires) ;
- **design d'expériences** : explorer un espace de paramètres (souvent en log-échelle) puis raffiner autour des meilleurs candidats.

Le point M1 : le multi-start n'est pas un détail d'implémentation, c'est une réponse directe à la géométrie non convexe du problème inverse.

Lien quantitatif : convertir une erreur de prix en erreur d'IV

Pour comprendre les métriques (RMSE en IV vs en prix), on peut linéariser Black-Scholes :

$$C_{\text{BS}}(\sigma + \Delta\sigma) \approx C_{\text{BS}}(\sigma) + \text{Vega} \cdot \Delta\sigma.$$

Donc, à premier ordre,

$$\Delta\sigma \approx \frac{\Delta C}{\text{Vega}}.$$

Cela justifie une pratique courante : si l'on calibre en prix mais que l'on veut comparer en IV, on doit tenir compte de la Vega (sinon on “sur-pondère” des points où l'IV est peu informative).

Robustesse : pertes robustes et pénalisation

Les surfaces de marché contiennent des outliers (bid/ask large, erreurs de parsing, strikes aberrants). Deux outils standards (au-delà du simple L^2) :

- **perte de Huber** : quadratique près de 0, linéaire dans les queues ;
- **régularisation** : ajouter des termes de pénalité sur des paramètres (ex. éloignement d'un prior raisonnable, violation de contraintes).

Ils stabilisent les paramètres au prix d'un léger biais, souvent acceptable en pratique.

Ce que le jury doit retenir

La calibration est un **problème inverse** non convexe. À retenir : (i) représenter la surface de façon standardisée (grille + masque), (ii) imposer des bornes/contraintes, (iii) utiliser du multi-start, (iv) choisir une perte adaptée (prix ou IV, pondérations), et (v) ajouter des pénalités (ex. Feller) pour stabiliser l'optimisation.

Chapitre 8

Heston : volatilité stochastique (SDE, CF, pricing, calibration)

8.1 A. Problème financier (objectif, inputs, outputs)

Sur actions, l'IV n'est pas plate : elle présente un skew marqué. Le modèle de Heston vise à capturer :

- la **volatilité stochastique** (variance qui varie dans le temps),
- une **corrélation** $\rho < 0$ entre chocs de prix et chocs de variance (effet leverage),
- une **reversion** de la variance vers un niveau de long terme.

Inputs : surface de marché, (S_0, r, q) , paramètres $\theta = (\kappa, \theta, \sigma, \rho, v_0)$ (attention : ici θ désigne le niveau de variance de long terme). **Outputs** : prix (ou IV) par (K, T) , paramètres calibrés, surfaces modèle/erreur.

8.2 B. Théorie (définitions, hypothèses)

SDE sous la mesure risque-neutre

Sous $\mathbb{Q}$, Heston s'écrit :

$$\frac{dS_t}{S_t} = (r - q)dt + \sqrt{V_t} dW_t^{(1)}, \quad dV_t = \kappa(\theta - V_t)dt + \sigma\sqrt{V_t} dW_t^{(2)},$$

avec $\text{Corr}(dW^{(1)}, dW^{(2)}) = \rho$.

Hypothèses

- V_t suit un processus de type CIR (racine carrée), reversion vers θ .
- Marché frictionless, taux r et yield q constants (dans les pricers de surface).
- Pour la positivité stricte, condition de Feller : $2\kappa\theta \geq \sigma^2$ (souvent utilisée comme contrainte ou pénalité en calibration).

Intuition financière

- κ : vitesse de retour de la vol vers “normal”.
- θ : niveau de vol long terme ($\sqrt{\theta}$).
- v_0 : vol instantanée aujourd'hui.
- $\rho < 0$: quand S baisse, V monte, générant un skew (puts chers).

- **À quoi ça sert ?** Modéliser la surface d'IV au-delà de BS, produire des prix cohérents (au moins pour calls européens) et calibrer des paramètres interprétables.
- **Hypothèses.** Vol stochastique de type CIR, continuité (pas de sauts), risque neutralité standard, stabilité numérique des intégrales/FFT.
- **Limites.** Le modèle peut échouer sur des smiles très marqués ou des événements (earnings) ; calibration instable si surface pauvre ; absence d'arbitrage non garantie.
- **Applications.** Deux approches de pricing sont classiques : (i) intégration 1D semi-fermée (Lewis/Heston) via la fonction caractéristique, (ii) FFT de Carr–Madan sur une grille de log-strikes pour obtenir de nombreux prix en une passe.

Zoom sur la variance CIR : positivité, stationnarité, interprétation

La variance suit une dynamique de type CIR :

$$dV_t = \kappa(\theta - V_t)dt + \sigma\sqrt{V_t}dW_t^{(2)}.$$

Quelques faits structurants :

- **Réversion vers θ .** Plus κ est grand, plus V_t revient vite vers θ .
- **Vol-of-vol σ .** Plus σ est grand, plus la variance fluctue, ce qui accentue la courbure de la surface (smile).
- **Condition de Feller.** La condition $2\kappa\theta \geq \sigma^2$ est suffisante pour éviter que V_t touche 0 (strictement positif). En pratique, même si elle est violée, on peut encore pricer, mais certaines formules deviennent numériquement plus délicates.
- **Stationnarité (intuition).** À long terme (sous conditions), V_t admet une loi stationnaire de type Gamma : cela justifie l'idée d'une "vol long terme" autour de $\sqrt{\theta}$.

Pourquoi $\rho < 0$ crée un skew

Le terme ρ corrèle les chocs de prix et de variance. Si $\rho < 0$, une baisse de S tend à coïncider avec une hausse de V : les scénarios de baisse sont plus volatils, ce qui rend les puts OTM plus chers et génère une IV plus élevée pour $K < S_0$ (skew).

Attention : paramètres sous $\mathbb{P}$ vs sous $\mathbb{Q}$

En général, la variance porte une *prime de risque* : les paramètres de la dynamique sous $\mathbb{P}$ (historique) ne coïncident pas avec ceux sous $\mathbb{Q}$ (pricing). Le calibrage sur une surface d'options identifie donc des paramètres "pricing", pas forcément des paramètres "statistiques".

8.3 C. Dérivations (ultra détaillées)

Pourquoi une fonction caractéristique ?

Pour un payoff européen, le prix est une espérance sous $\mathbb{Q}$. Plutôt que de simuler (S_T, V_T) , Heston admet une forme semi-analytique via la *fonction caractéristique* du log-prix (ou log-return) :

$$\phi(u) = \mathbb{E}^{\mathbb{Q}}[e^{iu \ln(S_T)}] \quad \text{ou} \quad \mathbb{E}^{\mathbb{Q}}[e^{iu \ln(S_T/S_0)}].$$

Une fois ϕ connue, on peut obtenir le prix d'un call via une intégrale (Carr–Madan ou formulation P_1/P_2).

Formule P_1/P_2 (idée)

Le prix d'un call peut s'écrire

$$C = S_0 e^{-qT} P_1 - K e^{-rT} P_2,$$

où P_1 et P_2 sont des probabilités “sous mesure transformée” calculées par intégrales de $\phi(u)$. Cette décomposition met en évidence l'analogie avec Black-Scholes : un call est une différence entre une probabilité de “finir ITM” (P_2) et une probabilité pondérée (P_1), toutes deux calculables via la fonction caractéristique.

Carr–Madan (FFT) : principe

Carr–Madan propose de calculer simultanément $C(K)$ sur un *grillage de log-strikes* par FFT. On applique une atténuation $e^{\alpha k}$ (avec $k = \ln(K/S_0)$) pour rendre la transformée intégrable, puis on FFT.

Affinité et équations de Riccati (idée de dérivation de ϕ)

Heston est un modèle *affine* : le log-prix et la variance entrent linéairement dans l'exposant de la fonction caractéristique. On cherche une forme

$$\phi(u) = \mathbb{E}^{\mathbb{Q}}[e^{iu \ln S_T} \mid \mathcal{F}_t] = \exp(A(u, \tau) + B(u, \tau)V_t + iu \ln S_t), \quad \tau = T - t.$$

En injectant cette forme dans l'équation de Kolmogorov (ou en appliquant Itô à l'exponentielle et en imposant la martingale), on obtient un système d'ODE couplées pour A et B (équations de Riccati) qui se résout analytiquement. C'est ce qui rend Heston “semi-fermé” : la difficulté est déplacée dans une intégrale 1D (ou une FFT), plutôt que dans une simulation 2D.

Pourquoi un facteur d'atténuation α en FFT ?

Le prix d'un call en fonction du log-strike k ne décroît pas assez vite pour que sa transformée de Fourier soit intégrable. Carr–Madan propose d'étudier $e^{\alpha k} C(e^k)$ pour un $\alpha > 0$ adéquat, ce qui :

- garantit l'intégrabilité ;
- stabilise numériquement la FFT ;
- introduit un compromis : trop petit $\alpha \Rightarrow$ divergence ; trop grand $\alpha \Rightarrow$ amplification d'erreurs numériques.

Le paramètre α est donc un hyperparamètre *numérique* autant que mathématique.

Ce que le jury doit retenir

Heston est le premier modèle “au-delà de BS” réellement codé : CF + intégrale (V1) et surtout FFT Carr–Madan (V2). La calibration ajuste des paramètres interprétables et applique une pénalité de type Feller pour éviter des variances pathologiques.

Chapitre 9

Jump diffusion : Merton et Bates (CF/FFT, calibration)

9.1 A. Problème financier (objectif, inputs, outputs)

Les sauts modélisent des mouvements discontinus (earnings, news) qui génèrent des smiles plus marqués que Heston seul. Objectif : reproduire une surface d'IV avec un modèle comportant une composante de saut.

Deux modèles présents :

- **Merton (1976)** : diffusion log-normale + sauts log-normaux (Poisson).
- **Bates (1996)** : Heston + sauts Merton (vol stochastique + jumps).

9.2 B. Théorie (définitions, hypothèses)

Merton (log-returns avec sauts)

Sous $\mathbb{Q}$, on peut écrire le log-return $X_T = \ln(S_T/S_0)$ comme

$$X_T = \left(r - q - \frac{1}{2}\sigma^2 - \lambda\kappa_J\right)T + \sigma W_T + \sum_{i=1}^{N_T} Y_i,$$

où $N_T \sim \text{Poisson}(\lambda T)$, $Y_i \sim \mathcal{N}(\mu_J, \sigma_J^2)$ i.i.d., et

$$\kappa_J = \mathbb{E}[e^Y] - 1 = e^{\mu_J + \frac{1}{2}\sigma_J^2} - 1$$

est l'ajustement de drift garantissant $e^{-(r-q)T}S_T$ martingale.

Bates

Bates multiplie la composante Heston (vol stochastique) par une composante de sauts indépendante conditionnellement : le log-return admet une CF “produit”.

- **À quoi ça sert ?** Capturer smile/skew extrêmes et événements via une composante de saut ; proposer une calibration alternative à Heston.
- **Hypothèses.** Sauts log-normaux, intensité constante λ , indépendance structurelle, pricing européen via CF/FFT.
- **Limites.** Les sauts vrais peuvent être asymétriques ou dépendre du régime ; calibration instable si surface pauvre ; pas d'arbitrage non garanti.
- **Applications.** Applications : pricing européen via fonction caractéristique et FFT, calibration d'une composante de saut $(\lambda, \mu_J, \sigma_J)$, et extension naturelle vers Bates (vol stochastique + sauts).

Interprétation des paramètres de saut (et impact sur la surface)

Le triplet $(\lambda, \mu_J, \sigma_J)$ contrôle des aspects distincts :

- λ (intensité) : fréquence moyenne des sauts ; augmente la probabilité d'événements rares.
- μ_J : taille moyenne (en log) d'un saut ; si $\mu_J < 0$, les sauts sont en moyenne baissiers (crash risk).
- σ_J : dispersion des tailles de saut ; contrôle l'épaisseur des queues.

Effet surface : des sauts négatifs fréquents et/ou dispersés rendent les puts OTM plus chers $\Rightarrow$ smile/skew plus prononcé qu'en diffusion pure.

Pourquoi la correction $-\lambda\kappa_J$ est nécessaire

Sans correction, ajouter des sauts augmenterait mécaniquement la croissance moyenne de S_t (car $\mathbb{E}[e^Y] > 1$). La condition "pas d'arbitrage" sous $\mathbb{Q}$ impose que $e^{-(r-q)t}S_t$ soit une martingale, ce qui force l'ajustement

$$\kappa_J = \mathbb{E}[e^Y] - 1, \quad \text{drift} \leftarrow (r - q) - \lambda\kappa_J.$$

Cette correction est un point non négociable : elle garantit que le forward reste $F_{0,T} = S_0 e^{(r-q)T}$ malgré les sauts.

9.3 C. Dérivations (ultra détaillées)

CF de Merton

Par indépendance (diffusion + Poisson), la fonction caractéristique du log-return est :

$$\phi(u) = \exp \left(iu \cdot \text{drift} - \frac{1}{2}\sigma^2 u^2 T + \lambda T (\mathbb{E}[e^{iuY}] - 1) \right),$$

et comme $Y \sim \mathcal{N}(\mu_J, \sigma_J^2)$,

$$\mathbb{E}[e^{iuY}] = \exp \left(iu\mu_J - \frac{1}{2}\sigma_J^2 u^2 \right).$$

Donc

$$\phi(u) = \exp \left(iu \cdot \text{drift} - \frac{1}{2}\sigma^2 u^2 T + \lambda T (e^{iu\mu_J - \frac{1}{2}\sigma_J^2 u^2} - 1) \right).$$

Bates : produit

Pour Bates, on écrit

$$\phi_{\text{Bates}}(u) = \phi_{\text{Heston}}(u; \kappa, \theta, \sigma, \rho, v_0, \delta_{\text{drift}}) \cdot \phi_{\text{Jumps}}(u; \lambda, \mu_J, \sigma_J),$$

où le terme d'ajustement de drift vaut $\delta_{\text{drift}} = -\lambda\kappa_J$ pour préserver la martingale au niveau du drift (même mécanisme que Merton).

Merton : représentation en mélange (somme de Black–Scholes)

Conditionnellement au nombre de sauts $N_T = n$, le log-return est normal :

$$X_T \mid N_T = n \sim \mathcal{N} \left((r - q - \frac{1}{2}\sigma^2 - \lambda\kappa_J)T + n\mu_J, \sigma^2 T + n\sigma_J^2 \right).$$

Donc $S_T \mid N_T = n$ est log-normal, et le prix d'un call peut s'écrire comme une somme (mélange) :

$$C = \sum_{n=0}^{\infty} \mathbb{P}(N_T = n) C^{(n)}, \quad \mathbb{P}(N_T = n) = e^{-\lambda T} \frac{(\lambda T)^n}{n!},$$

où $C^{(n)} = e^{-rT} \mathbb{E}[(S_T - K)^+ \mid N_T = n]$ admet une forme fermée (log-normale). Cette décomposition est très pédagogique : **un modèle à sauts est un mélange de scénarios “ n sauts”**, chacun équivalent à une diffusion log-normale avec variance augmentée. Numériquement, elle donne aussi une alternative à la FFT (tronquer la somme pour des λT modérés).

Ce que le jury doit retenir

À retenir : une composante de saut de type Poisson composé se traduit par un terme $\lambda T (\mathbb{E}[e^{iuY}] - 1)$ dans l'exposant de la fonction caractéristique. Cette structure se combine naturellement avec Heston (Bates) et rend le pricing européen efficace via FFT, puis la calibration se formule en moindres carrés sur des prix reconstruits depuis l'IV observée.

Chapitre 10

SABR : dynamique, formule de Hagan, calibration

10.1 A. Problème financier (objectif, inputs, outputs)

SABR est un modèle de référence (rates/FX) pour reproduire une courbe de smile en fonction du strike. On l'utilise souvent comme *générateur de surface d'IV* via une approximation analytique (Hagan) et on calibre *par maturité*.

Inputs : (S_0, r, q) , grille (m, T) , paramètres SABR $(\alpha, \beta, \rho, \nu)$ (avec β souvent fixé). **Outputs** : surface d'IV modèle et paramètres calibrés (souvent (α, ρ, ν) par maturité si β est fixé).

10.2 B. Théorie (définitions, hypothèses)

Dynamique SABR (standard)

Sur un forward F_t :

$$dF_t = \alpha_t F_t^\beta, dW_t, \quad d\alpha_t = \nu \alpha_t, dZ_t, \quad \text{Corr}(dW_t, dZ_t) = \rho.$$

Le but est de produire une volatilité implicite Black (sur forwards) approchée analytiquement.

Approximation de Hagan (2002) : idée

On obtient une approximation fermée de $\sigma_{\text{Black}}(F, K, T)$ via un développement asymptotique en T et en $\ln(F/K)$.

- **À quoi ça sert ?** Produire rapidement une surface d'IV (sans FFT) et calibrer de façon efficace (par maturité).
- **Hypothèses.** Validité de l'approximation Hagan (régime asymptotique), calibrage indépendant par maturité, β fixé ou choisi.
- **Limites.** Approximation moins fiable pour maturités longues ou strikes extrêmes ; ne garantit pas l'absence d'arbitrage ; calibration indépendante peut produire des courbes non lisses en T .
- **Applications.** Applications : génération rapide de smiles par maturité, calibration en front-office, et construction de surfaces lisses (avec régularisation en T si nécessaire).

Interprétation des paramètres SABR

- $\beta \in [0, 1]$: élasticité (CEV). $\beta = 1$ correspond à une dynamique log-normale, $\beta = 0$ à une dynamique normale (en première approximation).

- α : niveau de volatilité (à $t = 0$), dimensionné pour que αF^β ait la dimension d'une volatilité sur F .
- ν : *vol-of-vol* (amplitude des fluctuations de α_t) ; augmente la courbure du smile.
- ρ : corrélation entre mouvement de F et mouvement de α ; contrôle l'asymétrie du smile (skew).

En pratique, on fixe souvent β (par convention de marché) et on ajuste (α, ρ, ν) .

Pourquoi SABR se formule sur le forward

Dans les marchés de taux/FX, les options sont souvent cotées en Black sur un forward $F_{t,T}$ (ou un swap rate). Travailler en forward permet d'isoler l'effet de taux et de modéliser directement la dynamique de l'actif sous-jacent “de marché” pour l'option.

10.3 C. Dérivations (ultra détaillées)

Notations

On travaille en forward $F = S_0 e^{(r-q)T}$ (taux et dividendes constants) et on note $k = \ln(F/K)$ le log-moneyness.

Formule Hagan : deux cas

La formule de Hagan se présente naturellement en deux régimes :

- **ATM** : $\ln(F/K) \approx 0$, formule simplifiée.
- **général** : via

$$z = \frac{\nu}{\alpha} (FK)^{\frac{1-\beta}{2}} \ln \frac{F}{K}, \quad x(z) = \ln \frac{\sqrt{1 - 2\rho z + z^2} + z - \rho}{1 - \rho},$$

puis un facteur $\frac{z}{x(z)}$.

Le point clé est le ratio $z/x(z)$, qui corrige l'asymétrie induite par la corrélation ρ .

Limites et cas particuliers (contrôles de cohérence)

Ces cas servent de tests “mentaux” sur la formule :

- $\nu \rightarrow 0$: la volatilité devient (presque) déterministe et on retrouve une dynamique de type CEV ; le smile doit s'aplatir (moins de courbure).
- $\rho = 0$: smile plus symétrique autour de l'ATM (pas de skew induit par corrélation).
- $\beta = 1$: on se rapproche d'un cadre log-normal (Black/BS) ; les expressions se simplifient.
- **ATM** ($K \rightarrow F$) : la formule générale contient des termes en $\ln(F/K)$; il faut une expression limite bien définie (d'où l'usage explicite de la limite ATM).

Pourquoi le terme $z/x(z)$ apparaît

Le terme

$$z = \frac{\nu}{\alpha} (FK)^{\frac{1-\beta}{2}} \ln \frac{F}{K}$$

est une variable adimensionnée mesurant à la fois l'écart à l'ATM ($\ln(F/K)$) et l'amplitude de vol-of-vol (ν/α). La fonction $x(z)$ vient d'une intégration qui “corrige” l'effet de corrélation ρ ; le ratio $z/x(z)$ est un facteur d'asymétrie qui tend vers 1 quand $z \rightarrow 0$ (cohérence ATM).

Ce que le jury doit retenir

SABR via l'approximation de Hagan est une voie **très rapide** pour obtenir un smile plausible : calibration par maturité, multi-start si besoin, et paramètres interprétables. Contrepartie : c'est une approximation asymptotique (moins fiable sur maturités longues/strikes extrêmes).

Chapitre 11

Rough & Volterra : rHeston (approx. markovienne), rBergomi (MC+surrogate), Volterra SDE (MC proxy)

11.1 A. Problème financier (objectif, inputs, outputs)

Certaines surfaces d'IV exhibent une **rugosité** (décroissance lente de la corrélation de variance) incompatible avec Heston classique. Les modèles rough/Volterra visent à :

- reproduire des dynamiques de volatilité à *mémoire* (non markoviennes),
- obtenir un meilleur fit sur l'échelle courte,
- conserver une interprétation : paramètre de rugosité $H \in (0, 1/2)$.

Trois familles de constructions illustrent ces idées :

- rHeston via approximation markovienne + FFT,
- rBergomi via Monte Carlo + surrogate,
- un simulateur Volterra générique + calibration par recherche sur design.

11.2 B. Théorie (définitions, hypothèses)

Rugosité et noyau fractionnaire

Un point de départ commun est le noyau fractionnaire (type Riemann–Liouville) :

$$K(t) = \frac{t^{H-\frac{1}{2}}}{\Gamma(H + \frac{1}{2})}, \quad H \in (0, 1/2),$$

qui induit une mémoire longue dans la variance.

Approximation markovienne (idée)

On approxime $K(t)$ par une somme d'exponentielles :

$$K(t) \approx \sum_{i=1}^n w_i e^{-x_i t},$$

ce qui permet de représenter un système non markovien via un état augmenté (Markov) de dimension n .

rBergomi (idée)

On construit une volatilité log-normale pilotée par une fBM (fractional Brownian motion) de paramètre H (ici via une approximation Riemann–Liouville), puis on simule S_t .

- **À quoi ça sert ?** Modéliser le smile court terme et la mémoire de volatilité ; fournir des calibrations “research-grade” et des surfaces modèles.
- **Hypothèses.** Roughness $H \in (0, 1/2)$, approximations numériques (convolutions $O(n^2)$ ou état augmenté), pricing européen par FFT/MC.
- **Limites.** Coût computationnel élevé, objectives bruitées, identifiabilité faible ; risque d’overfitting ; absence d’arbitrage non garantie.
- **Applications.** Applications : reproduire le skew court terme (lois de puissance), comparer des familles rough (rHeston, rBergomi, Volterra), et analyser le compromis précision/coût via markovianisation et surrogates.

Qu’est-ce que “rough” ? (intuition statistique)

Dire que la volatilité est “rough” signifie que ses trajectoires sont plus irrégulières qu’un brownien standard : localement, elles ressemblent à une fBM de paramètre de Hurst $H < 1/2$. Conséquences qualitatives :

- la corrélation des incréments de volatilité décroît lentement et de façon non exponentielle ;
- le skew implicite court terme suit souvent une loi de puissance en maturité (signature empirique) ;
- les modèles deviennent **non markoviens** : l’état présent ne suffit plus à résumer le futur.

Attention : “rough” n’est pas forcément “long memory” au sens économétrique ; il s’agit d’une régularité locale (höldérienne).

Volterra : la bonne classe pour formaliser la mémoire

Un processus de type Volterra s’écrit (schématiquement)

$$Y_t = \int_0^t K(t-s) dB_s,$$

où K est un noyau. Si $K(t) \propto t^{H-1/2}$, on obtient une régularité contrôlée par H . Les modèles rough sont souvent des modèles de volatilité construits à partir d’un tel Y_t (puis exponentiation, reversion, etc.).

11.3 C. Dérivations (ultra détaillées)

(1) Approximation markovienne du noyau fractionnaire

Le point technique central est d’approximer le noyau de loi de puissance par une somme d’exponentielles :

$$K(t) = \frac{t^{H-\frac{1}{2}}}{\Gamma(H+\frac{1}{2})} \approx \sum w_i e^{-x_i t},$$

ce qui transforme une convolution (mémoire) en un état augmenté (Markov) de dimension n .

Idée via représentation de Laplace. Un noyau complètement monotone admet souvent une représentation de la forme

$$K(t) = \int_0^\infty e^{-xt} \mu(dx),$$

pour une mesure positive μ . En approchant cette intégrale par une quadrature

$$\int_0^\infty e^{-xt} \mu(dx) \approx \sum_{i=1}^n w_i e^{-x_i t},$$

on obtient exactement la somme d'exponentielles. Les grilles géométriques (points x_i espacés multiplicativement) sont naturelles car le noyau a une structure multi-échelles.

(2) rHeston : CF via état augmenté

Une fois K markovianisé, la variance (rough) devient fonction d'un vecteur de facteurs $(Y^{(1)}, \dots, Y^{(n)})$ qui résument la mémoire. Dans les modèles affines (famille Heston), la fonction caractéristique garde une structure exponentielle-affine, mais les équations de Riccati deviennent un système de dimension n (au lieu de 1 en Heston classique). On retient :

- **gain** : on récupère un état markovien donc des outils de pricing (CF/FFT) ;
- **coût** : on remplace une ODE scalaire (Heston) par un système d'ODE (ou une discrétisation) en dimension n .

(3) rBergomi : construction d'une fBM Riemann–Liouville

Une représentation Riemann–Liouville (RL) d'une fBM est :

$$W_t^H \approx \sqrt{2H} \sum_{j < t} (t - t_j)^{H-\frac{1}{2}} \Delta B_j,$$

c'est une convolution discrète. Naïvement, le coût est $O(n_{\text{steps}}^2)$ (double boucle). On peut accélérer via des approximations de noyau (sum-of-exponentials) ou via des méthodes FFT-convolution (selon la grille).

(4) Volterra SDE générique

Une Volterra SDE pour la variance peut s'écrire, schématiquement,

$$V_t = v_0 + \int_0^t K(t-s)b(V_s) ds + \int_0^t K(t-s)\sigma(V_s) dB_s,$$

où K encode la mémoire. Sur une grille, cela devient une convolution discrète : pour t_i ,

$$V_{t_i} = v_0 + \sum_{m < i} K(t_i - t_m) \Delta Z_m,$$

où ΔZ_m combine drift (mean-reversion) et bruit ($\sqrt{V} \Delta B$). L'essentiel : l'état dépend de tout le passé via K .

Pourquoi une somme d'exponentielles rend le modèle markovien

Si $K(t) \approx \sum_{i=1}^n w_i e^{-x_i t}$, alors une convolution de type

$$Y_t = \int_0^t K(t-s) dB_s$$

se réécrit approximativement comme une somme de facteurs

$$Y_t \approx \sum_{i=1}^n w_i Y_t^{(i)}, \quad Y_t^{(i)} = \int_0^t e^{-x_i(t-s)} dB_s.$$

Chaque $Y^{(i)}$ vérifie une SDE *markovienne* :

$$dY_t^{(i)} = -x_i Y_t^{(i)} dt + dB_t.$$

Donc le vecteur $(Y^{(1)}, \dots, Y^{(n)})$ est un état markovien de dimension n qui approxime la mémoire du noyau de puissance. C'est exactement le mécanisme derrière la “markovianisation” de rHeston.

Complexité : pourquoi ces modèles sont coûteux

Sans markovianisation, la convolution discrète de type

$$W_{t_i}^H \approx \sum_{j < i} K(t_i - t_j) \Delta B_j$$

coûte $O(n_{\text{steps}}^2)$ (double boucle). La somme d'exponentielles réduit le coût à $O(n_{\text{steps}} \cdot n)$, au prix d'une approximation contrôlée par n .

Ce que le jury doit retenir

Rough/Volterra sont des modèles **coûteux** et souvent “research-grade” : (i) rHeston rend le rough plus *calibrable* via une approximation markovienne et FFT, (ii) rBergomi contourne le coût MC via des surrogates, (iii) une Volterra SDE générique se simule mais la calibration nécessite souvent une recherche sur design (proxy).

Chapitre 12

Réseaux de neurones dans la calibration (surrogates pour Heston)

12.1 A. Problème financier (objectif, inputs, outputs)

Calibrer Heston par optimisation non linéaire est coûteux (intégrales/FFT + inversion IV) et non convexe. Une alternative est d'apprendre une *inversion directe* :

$$\text{surface IV;} \mapsto (\kappa, \theta, \sigma, \rho, v_0),$$

pour accélérer :

- l'initialisation (meilleur x_0),
- ou une calibration “en un coup” (surrogate).

Input : une matrice d'IV sur une grille fixe. **Output** : un dictionnaire de paramètres Heston.

12.2 B. Théorie (définitions, hypothèses)

Régression supervisée

On définit un dataset synthétique $(X^{(n)}, y^{(n)})$:

- $X^{(n)}$: surface d'IV générée par Heston pour un paramètre $y^{(n)}$,
- $y^{(n)} = (\kappa, \theta, \sigma, \rho, v_0)$.

On entraîne un réseau f_ω en minimisant une MSE :

$$\min_{\omega} \frac{1}{N} \sum_{n=1}^N |f_\omega(X^{(n)}) - y^{(n)}|^2.$$

Intuition

Le réseau apprend un inverse approximatif du pipeline :

$$(\kappa, \theta, \sigma, \rho, v_0) \rightarrow \text{prix} \rightarrow \text{IV}.$$

Il ne remplace pas nécessairement une calibration “exacte”, mais fournit une estimation rapide.

- **À quoi ça sert ?** Accélérer la calibration (ou fournir un point de départ robuste) en apprenant l'inversion surface $\rightarrow$ paramètres.
- **Hypothèses.** Dataset synthétique représentatif ; grille fixe (moneyness, maturités) ; stabilité de l'inversion IV.

- **Limites.** Risque de biais (domain shift : marché réel vs synthétique) ; mauvaise généralisation hors domaine ; incertitude non quantifiée.
- **Applications.** Application : estimation instantanée des paramètres (ou initialisation) à partir d’une surface, puis éventuel raffinement par optimisation classique.

Pourquoi l’inversion “surface $\rightarrow$ paramètres” est difficile

Le problème inverse est (souvent) **mal posé** :

- **Non-unicité** : différentes valeurs de $(\kappa, \theta, \sigma, \rho, v_0)$ peuvent produire des surfaces très proches sur un domaine fini (K, T) .
- **Sensibilités hétérogènes** : certains paramètres modifient surtout le skew, d’autres la term structure ; si la grille n’observe pas assez ces dimensions, l’estimation devient instable.
- **Bruit de marché** : une surface issue de quotes bid/ask n’est pas une fonction lisse.

Un réseau de neurones ne “résout” pas ces problèmes : il apprend une inverse *effective* sur un domaine de données donné.

Surrogate vs inversion directe : deux usages différents

- **Surrogate direct** : apprendre $(\theta) \mapsto \Sigma(\theta)$ pour accélérer le pricing durant l’optimisation.
- **Inverse direct** (ici) : apprendre $\Sigma \mapsto \theta$ pour obtenir une estimation instantanée ou une initialisation.

Les deux peuvent être combinés : l’inverse donne un bon point de départ et le surrogate direct accélère les itérations de calibration.

12.3 C. Dérivations (ultra détaillées)

Normalisation des entrées

Le réseau consomme une surface 2D ; on gère les valeurs manquantes (masque, interpolation simple, ou remplissage neutre), puis on normalise :

$$X_{\text{norm}} = \frac{X - \mu}{\sigma + \varepsilon},$$

où (μ, σ) sont estimés sur le dataset (standardisation).

Contraintes de sortie

Pour respecter le domaine des paramètres :

- paramètres positifs via *softplus* : $\text{softplus}(x) = \ln(1 + e^x)$,
- corrélation $\rho \in (-1, 1)$ via *tanh*.

On applique donc une post-transformation *différentiable* aux sorties du réseau, ce qui stabilise l’apprentissage et évite des paramètres non physiques.

Pourquoi la normalisation améliore l’apprentissage (lecture optimisation)

Sans normalisation, les IV peuvent avoir des ordres de grandeur très différents selon (K, T) , ce qui détériore le conditionnement du problème et rend la descente de gradient instable (gradients très disparates). La standardisation

$$X_{\text{norm}} = \frac{X - \mu}{\sigma + \varepsilon}$$

ramène les entrées à une échelle comparable et permet :

- des pas de gradient plus homogènes ;
- une meilleure utilisation de la capacité du réseau ;
- une convergence plus rapide et plus stable.

Contraintes : projection différentiable sur un domaine admissible

La post-transformation (softplus/tanh) est une forme de projection *différentiable* : elle empêche le réseau de prédire des paramètres physiquement absurdes (variance négative, corrélation hors $[-1, 1]$). On peut aller plus loin en ajoutant des pénalités (ex. Feller) dans la loss ; c’est une extension naturelle si l’on veut des sorties plus “physiques”.

Ce que le jury doit retenir

Un NN inverseur (surface $\rightarrow$ paramètres) fournit une estimation rapide avec contraintes de domaine (softplus/tanh). C’est une brique d’accélération (initialisation ou surrogate inverse), mais un usage “production” exige validation hors synthétique et quantification d’incertitude.

Troisième partie

**RL Hedger (théorie $\rightarrow$ design $\rightarrow$
pratique)**

Chapitre 13

Couverture RL : formulation MDP, DQN, et aspects pratiques

13.1 A. Problème financier (objectif, inputs, outputs)

Objectif

Une position options a une exposition dynamique (delta, gamma, vega). On veut **réduire un risque** (ici : résidu de delta) en rebalançant une position de couverture (action) de façon *discrète* et sous contraintes (coûts, slippage, limites d'inventaire).

Choix minimal d'un objectif (exemple pédagogique)

Pour illustrer la démarche RL, on peut partir d'un objectif volontairement simple :

- état = (exposition delta proxy, position action),
- action = hold, buy, sell, flatten,
- reward = $-|\text{delta résiduel}|$ (éventuellement pénalisé par des coûts de transaction).

Inputs : définition d'état/action, simulateur (ou données) pour générer des transitions, et un critère de coût/risque. **Outputs** : une politique (ou une valeur Q) et des recommandations d'ajustement de couverture.

13.2 B. Théorie (définitions, hypothèses)

(1) Hedging discret : PnL et coûts

En discret, la PnL d'un hedge delta approximatif inclut :

$$\Delta\Pi \approx \Delta V - \Delta_t \Delta S - \text{coûts},$$

où Δ_t est la quantité d'action détenue. Les coûts (spread, commissions, slippage) rendent le hedging *problème de contrôle* plutôt qu'égalité de réplication.

(2) MDP

Un *processus de décision markovien* (MDP) est $(\mathcal{S}, \mathcal{A}, P, R, \gamma)$:

- état $s \in \mathcal{S}$,
- action $a \in \mathcal{A}$,
- transition $P(s'|s, a)$,
- récompense $R(s, a, s')$,

— discount $\gamma \in (0, 1)$.

On cherche une politique $\pi(a|s)$ maximisant $\mathbb{E}[\sum_t \gamma^t r_t]$.

(3) SARSA / Expected SARSA / Q-learning

Théorie générale (cadre standard RL).

— SARSA (on-policy) :

$$Q(s, a) \leftarrow Q(s, a) + \alpha(r + \gamma Q(s', a') - Q(s, a)).$$

— Expected SARSA :

$$Q(s, a) \leftarrow Q(s, a) + \alpha(r + \gamma \mathbb{E}_{a' \sim \pi(\cdot|s')} [Q(s', a')] - Q(s, a)).$$

— Q-learning (off-policy) :

$$Q(s, a) \leftarrow Q(s, a) + \alpha(r + \gamma \max_{a'} Q(s', a') - Q(s, a)).$$

Dans un DQN, la cible utilise typiquement le terme $\max_{a'} Q_{\text{target}}(s', a')$ (réseau cible) : c'est une forme de Q-learning approximé.

(4) Importance sampling

En off-policy, on corrige le décalage entre politique comportement μ et politique cible π via un ratio :

$$\rho_t = \frac{\pi(a_t|s_t)}{\mu(a_t|s_t)},$$

au prix d'une variance potentiellement élevée.

- **À quoi ça sert ?** Passer d'une couverture "réplication continue" (BS) à une couverture *décisionnelle* en discret, potentiellement sous coûts et contraintes.
- **Hypothèses.** Markovianité approximative de l'état ; stationnarité ; reward représentatif du risque réel ; accès aux transitions (simulation).
- **Limites.** Dépend fortement du choix d'état/reward ; risque d'overfitting à un simulateur ; sécurité/exécution réelle.
- **Applications.** Applications : formulation MDP d'un hedge discret, apprentissage d'une stratégie sous coûts, et comparaison de variantes (Q-learning, Double DQN, distributional RL) selon le niveau de risque/cout voulu.

De la réplication (théorie) au contrôle (pratique)

En Black–Scholes *idéal* (continu, sans coûts), on peut répliquer un payoff européen : le hedge est imposé (delta). En pratique, trois écarts rendent la réplication impossible ou sous-optimale :

- **Temps discret** : rebalancer toutes les Δt introduit une erreur de discrétisation (hedging error) qui dépend de Γ et de la volatilité.
- **Coûts de transaction** : rebalancer plus souvent réduit l'erreur mais augmente les coûts ; on obtient un compromis.
- **Contraintes** : inventaire limité, taille minimale d'ordre, interdiction de vendre à découvert, etc.

Le problème devient alors un **problème de contrôle stochastique** : choisir une action (rebalancement) pour minimiser un critère de risque.

Choix du reward : ce que l'on optimise vraiment

Un reward de type $-|\Delta_{\text{résiduel}}|$ est un proxy simple : il encourage une exposition proche de 0. Mais d'autres critères plus proches d'une gestion de risque existent :

- minimiser $\mathbb{E}[(\text{hedging error})^2]$ (mean-variance) ;
- maximiser une utilité $\mathbb{E}[U(\text{PNL})]$ (aversion au risque) ;
- pénaliser l'inventaire et les coûts (L1/L2) pour contrôler le turnover.

Le point pédagogique : le **RL n'est pas "magique"** ; la performance dépend directement de la qualité de l'environnement et du reward.

13.3 C. Dérivations (ultra détaillées)

Bellman optimalité

Pour une politique optimale, la fonction Q^* vérifie :

$$Q^*(s, a) = \mathbb{E}[r + \gamma \max_{a'} Q^*(s', a') \mid s, a].$$

DQN approxime $Q^*(s, a)$ par un réseau $Q_\omega(s, a)$.

Perte TD (DQN)

On définit une cible (avec réseau cible ω^-) :

$$y = r + \gamma(1 - d) \max_{a'} Q_{\omega^-}(s', a'),$$

et on minimise

$$\mathcal{L}(\omega) = \mathbb{E}[(Q_\omega(s, a) - y)^2].$$

C'est exactement la structure standard d'un DQN.

Pourquoi le replay buffer stabilise l'apprentissage

Les trajectoires (s_t, a_t, r_t, s_{t+1}) sont fortement corrélées dans le temps. Apprendre directement dessus rend l'optimisation instable (les gradients "poursuivent" un signal non stationnaire). Le replay buffer casse cette corrélation en rééchantillonnant des transitions passées, ce qui rapproche l'hypothèse i.i.d. des méthodes de régression.

Biais d'overestimation et Double DQN (perspective)

La cible $\max_{a'} Q_{\omega^-}(s', a')$ a tendance à surestimer les valeurs (max sur des estimateurs bruités). Une extension standard est *Double DQN* : sélectionner l'action avec le réseau en ligne et l'évaluer avec le réseau cible. C'est une extension naturelle si l'on veut améliorer la stabilité sans changer le cadre global.

Ce que le jury doit retenir

Un DQN de couverture est typiquement un **prototype** au départ : il démontre la chaîne $\text{MDP} \rightarrow \text{estimation de } Q \rightarrow \text{recommandation d'action}$, mais la performance dépend surtout du choix d'état/reward et de la qualité du simulateur. Le point clé est la validation : stabilité hors échantillon et robustesse aux coûts/risques.

Quatrième partie

Yield Curve

Chapitre 14

Courbe de taux : DF, taux zéro, forwards, Nelson–Siegel

14.1 A. Problème financier (objectif, inputs, outputs)

Le pricing et l’actualisation nécessitent une courbe de taux : discount factors $DF(T)$, taux zéro $z(T)$, forwards $f(t_1, t_2)$. On veut :

- construire une courbe à partir de nœuds (tenors, zéros, DF) ;
- interpoler de façon stable et sans arbitrage grossier ;
- fournir $r(T)$, $DF(T)$ et des forwards cohérents ;
- proposer un lissage paramétrique (Nelson–Siegel) si les données sont bruitées ou rares.

Inputs : nœuds (tenor, T , zero rate ou DF), devise, maturité de référence. **Outputs** : courbe (DF/zéros/forwards), taux instantanés (si dérivables) et paramètres Nelson–Siegel (si ajustés).

14.2 B. Théorie (définitions, hypothèses)

Définitions formelles

- **Discount factor** : $DF(T)$, valeur aujourd’hui de 1 unité à T .
- **Taux zéro (comp. continue)** : $z(T)$ défini par

$$DF(T) = e^{-z(T)T} \quad \Rightarrow \quad z(T) = -\frac{1}{T} \ln DF(T).$$

- **Forward** $f(t_1, t_2)$ (comp. continue) :

$$f(t_1, t_2) = -\frac{\ln DF(t_2) - \ln DF(t_1)}{t_2 - t_1}.$$

- **Forward instantané** :

$$f(t) = -\frac{d}{dt} \ln DF(t).$$

Intuition financière

- $DF(T)$ est l’objet “primitif” le plus sûr : il doit être positif et décroissant.
- Interpoler en $\ln DF$ est souvent plus stable (et garantit $DF > 0$).
- **À quoi ça sert ?** Fournir une actualisation cohérente, calculer forwards et alimenter les pricers en $r(T)$.

- **Hypothèses.** Zéro-coupons cohérents, interpolation stable, données de nœuds de qualité.
- **Limites.** Si la courbe est pauvre, l'interpolation devient fragile : on peut être amené à régulariser, imposer une structure paramétrique, ou accepter une approximation (courbe plate) en tant que *proxy*.
- **Applications.** Applications : actualisation cohérente, extraction de forwards, et alimentation des pricers (PDE/MC/FFT) en taux de financement.

Conventions : capitalisation, day count, et cohérence

En pratique, les marchés utilisent des conventions (ACT/360, 30/360, comp. simple vs continue, etc.). Dans un dossier théorique, on choisit souvent la capitalisation continue car elle rend les formules plus lisibles :

$$DF(T) = e^{-\int_0^T r(u) du}.$$

Ce choix n'est pas "la vérité", mais une convention mathématique ; l'important est d'être **cohérent** dans toutes les conversions.

Arbitrage taux : contraintes minimales sur DF

Une courbe sans arbitrage doit au minimum satisfaire :

- $DF(T) > 0$;
- DF décroissant en T si les taux sont non négatifs (dans un monde où les taux peuvent être négatifs, la monotonie peut être localement violée, mais DF reste positif) ;
- régularité suffisante pour dériver des forwards (éviter des oscillations d'interpolation).

Interpoler en $\ln DF$ est une façon simple de garantir $DF > 0$.

14.3 C. Dérivations (ultra détaillées)

DF $\leftrightarrow$ zéro-rate

Si $DF(T) = e^{-z(T)T}$, alors :

$$z(T) = -\frac{1}{T} \ln DF(T).$$

Inversement, si $z(T)$ est donné :

$$DF(T) = e^{-z(T)T}.$$

Ces conversions sont le point de départ de tout pipeline de courbe : on passe d'un format de données (zéros, DF) à un autre en restant cohérent sur la convention.

Forward rate

À partir de deux discount factors, on dérive :

$$DF(t_2) = DF(t_1) e^{-f(t_1, t_2)(t_2 - t_1)} \quad \Rightarrow \quad f(t_1, t_2) = -\frac{\ln DF(t_2) - \ln DF(t_1)}{t_2 - t_1}.$$

Cette expression définit le forward continu moyen sur l'intervalle (t_1, t_2) .

Lien entre zéro-rate et forward instantané

En définissant $z(T) = -\frac{1}{T} \ln DF(T)$ et $f(T) = -\frac{d}{dT} \ln DF(T)$, on obtient :

$$\ln DF(T) = -Tz(T) \quad \Rightarrow \quad f(T) = z(T) + Tz'(T).$$

Cette relation explique un phénomène empirique : une courbe de zéros “douce” peut cacher des forwards plus volatils si $z'(T)$ oscille. Elle justifie l’intérêt de paramétrisations lisses (Nelson–Siegel) quand on veut des forwards stables.

Nelson–Siegel (et extension Svensson)

La paramétrisation Nelson–Siegel :

$$z(T) = \beta_0 + \beta_1 \frac{1 - e^{-T/\tau}}{T/\tau} + \beta_2 \left(\frac{1 - e^{-T/\tau}}{T/\tau} - e^{-T/\tau} \right).$$

Deux faits importants pour la calibration :

- **linéarité conditionnelle** : si τ est fixé, la relation est linéaire en $(\beta_0, \beta_1, \beta_2)$, donc ajustable par moindres carrés ;
- **choix de τ** : on peut faire une recherche sur grille (robuste) ou une optimisation non linéaire (plus délicate).

Extension Nelson–Siegel–Svensson (NSS). Une extension classique ajoute un second terme de courbure (échelle τ_2) :

$$z(T) = \beta_0 + \beta_1 \frac{1 - e^{-T/\tau_1}}{T/\tau_1} + \beta_2 \left(\frac{1 - e^{-T/\tau_1}}{T/\tau_1} - e^{-T/\tau_1} \right) + \beta_3 \left(\frac{1 - e^{-T/\tau_2}}{T/\tau_2} - e^{-T/\tau_2} \right).$$

NSS est utile quand la courbe présente plusieurs bosses (flexibilité accrue), au prix d’une calibration plus sensible (plus de paramètres).

Lecture économique des paramètres $(\beta_0, \beta_1, \beta_2, \tau)$

- β_0 : niveau de long terme (quand $T \rightarrow \infty$, les deux autres chargements tendent vers 0).
- β_1 : pente court terme (agit surtout sur les maturités courtes).
- β_2 : courbure (charge autour d’une maturité caractéristique contrôlée par τ).
- τ : échelle de temps : déplace la zone où la courbure est maximale.

Cette lecture justifie le calibrage par grille sur τ : fixer τ rend le modèle linéaire en $(\beta_0, \beta_1, \beta_2)$, donc calibrable par moindres carrés.

Ce que le jury doit retenir

La courbe de taux dans l’app est un module cohérent : nœuds $\rightarrow$ DF/zc via interpolation log-DF, forwards et lissage Nelson–Siegel (si assez de points). Le fallback (courbe plate) est explicite, ce qui est essentiel pour l’audit.

Cinquième partie

Portfolio allocation & risk

Chapitre 15

Allocation de portefeuille : Markowitz, Risk Parity, Eigen-portfolios, rebalancement

15.1 A. Problème financier (objectif, inputs, outputs)

On veut déterminer des poids cibles $w \in \mathbb{R}^n$ sur n actifs à partir de rendements historiques, puis générer un plan de rebalancement (ordres) vers ces poids.

Inputs : matrice de rendements (historique), contraintes implicites (poids ≥ 0 , somme=1), portefeuille courant (valeurs de marché), prix spot. **Outputs** : poids cibles, plan de rebalancement (achats/ventes, quantités) et indicateurs de risque/turnover associés.

15.2 B. Théorie (définitions, hypothèses)

(1) Markowitz

On modélise les rendements $R \in \mathbb{R}^n$ par une moyenne μ et une covariance Σ . Le problème min-variance (sans contraintes additionnelles) est :

$$\min_w w^\top \Sigma w \quad \text{s.c.} \quad \sum_i w_i = 1, ; w_i \geq 0.$$

Le “max Sharpe” (simplifié sans taux sans risque explicite) vise un w proportionnel à $\Sigma^{-1}\mu$ (puis projeté sur le simplexe).

(2) Risk parity (ERC)

On cherche des contributions au risque égales. Une version intuitive : ajuster w pour que

$$RC_i \approx \frac{1}{n}, \quad RC_i = \frac{w_i(\Sigma w)_i}{\sqrt{w^\top \Sigma w}}.$$

(3) Eigen-portfolios

La diagonalisation $\Sigma = V\Lambda V^\top$ donne des portefeuilles “facteurs” v_k . Selon le choix du vecteur propre, on obtient :

- un portefeuille direction “variance maximale” (plus grand λ),
- ou “variance minimale” (plus petit λ).

Le choix dépend de l’objectif (exposition aux facteurs dominants vs portefeuille plus market-neutral) et doit être stabilisé (PCA sensible au bruit).

- **À quoi ça sert ?** Transformer des données historiques en poids cibles, puis en ordres, dans un cadre simple et audit-able.
- **Hypothèses.** Stationnarité relative des rendements, covariance estimable, absence de contraintes complexes (levier, turnover) dans le solveur.
- **Limites.** Sensibilité aux fenêtres (lookback), instabilité de la covariance, coûts ignorés, contraintes simplistes.
- **Applications.** Applications : allocation long-only simple, rebalancement périodique, et comparaison de familles (min-variance, risk parity, PCA) sous contraintes de base.

Estimation : le vrai problème de Markowitz

La théorie suppose μ et Σ connus. En réalité :

- μ est extrêmement bruitée (erreur d'estimation énorme) ;
- Σ est instable si n est grand et l'historique court ;
- les contraintes (long-only, turnover) dominant souvent la solution.

Conséquence pédagogique : beaucoup d'implémentations utilisent Markowitz surtout pour **min-variance** (moins dépendant de μ) et ajoutent de la régularisation (shrinkage) implicitement (ici via $\Sigma + \varepsilon I$).

Risk parity : “ne pas dépendre de μ ”

Le risk parity (ERC) vise une allocation dont le risque est réparti entre actifs/facteurs. Il est souvent plus robuste que “max Sharpe” quand l'estimation de μ est peu fiable. Interprétation : on choisit w pour que chaque actif contribue de manière comparable à la volatilité du portefeuille.

Eigen-portfolios : lire la covariance comme des facteurs

Décomposer Σ revient à identifier des directions de risque (PCA). Les vecteurs propres associés aux grandes valeurs propres correspondent à des facteurs dominants ; les petits peuvent correspondre à des spreads/portefeuilles plus “market-neutral”. Mais attention : les vecteurs propres sont eux-mêmes sensibles au bruit (instabilité de PCA en haute dimension).

15.3 C. Dérivations (ultra détaillées)

Markowitz min-variance (forme fermée sans contrainte de positivité)

Si on ignore $w_i \geq 0$, le Lagrangien :

$$\mathcal{L}(w, \lambda) = w^\top \Sigma w - \lambda(\mathbf{1}^\top w - 1).$$

Condition d'optimalité :

$$2\Sigma w - \lambda \mathbf{1} = 0 \Rightarrow w = \frac{\lambda}{2} \Sigma^{-1} \mathbf{1}.$$

En imposant $\mathbf{1}^\top w = 1$:

$$\frac{\lambda}{2} \mathbf{1}^\top \Sigma^{-1} \mathbf{1} = 1 \Rightarrow w^* = \frac{\Sigma^{-1} \mathbf{1}}{\mathbf{1}^\top \Sigma^{-1} \mathbf{1}}.$$

En long-only, on ne peut pas garder cette forme fermée : on projette (ou on résout un QP) sous la contrainte $w \geq 0$ et $\mathbf{1}^\top w = 1$ (simplex).

Max Sharpe (simplifié)

Sans taux sans risque explicite, une heuristique est :

$$w \propto \Sigma^{-1}\mu,$$

puis normalisation sur le simplex (et éventuellement bornes, levier, turnover).

Max Sharpe (avec taux sans risque) : portefeuille tangent

Si l'on introduit un taux sans risque r_f et des rendements excédentaires $\tilde{\mu} = \mu - r_f \mathbf{1}$, alors le portefeuille tangent (sans contraintes) vérifie

$$w^* \propto \Sigma^{-1}\tilde{\mu}.$$

La constante de proportionnalité se fixe par la contrainte $\mathbf{1}^\top w = 1$ (ou par un levier choisi). Cette dérivation montre que “max Sharpe” est une direction, pas une solution unique : la normalisation (simplex, levier) est un choix de contraintes.

Risk parity (descente de gradient simplifiée)

Une itération de gradient (schématique) consiste à mettre à jour :

$$w \leftarrow w - \eta(\text{RC}(w) - \frac{1}{n}\mathbf{1}),$$

puis projette sur le simplex.

Condition ERC (équations) : ce que l'on cherche vraiment

En notant $\sigma_p = \sqrt{w^\top \Sigma w}$, la contribution au risque de l'actif i est

$$\text{RC}_i = \frac{w_i(\Sigma w)_i}{\sigma_p}.$$

La condition “Equal Risk Contribution” s'écrit $\text{RC}_i = \text{RC}_j$ pour tout i, j (ou $\text{RC}_i = 1/n$ après normalisation). C'est un système non linéaire, d'où l'usage d'itérations (gradient) plutôt qu'une formule fermée.

Ce que le jury doit retenir

À retenir : en allocation, l'essentiel n'est pas la formule fermée mais l'**estimation** (μ, Σ), la **régularisation** et les **contraintes** (long-only, turnover, coûts). Les solveurs (min-variance, risk parity, PCA) ne sont que des façons différentes de transformer ces estimations en poids cibles.

Chapitre 16

Risk management : exposition, PnL, VaR-lite, alertes

16.1 A. Problème financier (objectif, inputs, outputs)

Un tableau de bord de risque doit répondre à des questions basiques :

- Quelle exposition totale et nette ?
- Quelle concentration par position ?
- Quel PnL (réalisé / latent) ?
- Une VaR indicative (même simplifiée) ?
- Quelles alertes opérationnelles ?

Inputs : positions, historique de prix, paramètres (horizon, niveau de confiance, fenêtres).

Outputs : métriques de risque et alertes (exposition, concentration, PnL, indicateurs quantiles).

16.2 B. Théorie (définitions, hypothèses)

Exposition

$$\text{Exposure} = \sum_i |MV_i|, \quad \text{NetExposure} = \sum_i \text{sign}_i \cdot |MV_i|.$$

VaR historique (idée)

Une VaR historique classique utiliserait des rendements et des poids. Une version “VaR-lite” consiste à prendre un quantile d’une série agrégée de variations et à le convertir en montant via la valeur du portefeuille.

- **À quoi ça sert ?** Donner une visibilité opérationnelle rapide sur le risque d’un portefeuille, sans prétendre à une VaR institutionnelle.
- **Hypothèses.** Données de prix disponibles ; positions correctement valorisées ; historique suffisant.
- **Limites.** La VaR-lite n’est pas une VaR standard (dépend de la construction des retours) ; pas de stress tests ; pas de facteurs.
- **Applications.** Applications : dashboard de risque “lite” (exposition, concentration, PnL), quantiles indicatifs, et base de discussion pour des extensions (stress, ES, facteurs).

VaR : définition standard (pour situer “VaR-lite”)

Pour un horizon h et un niveau de confiance $c \in (0, 1)$, la Value-at-Risk d’un PnL L (perte positive) est

$$\text{VaR}_c(L) = \inf\{\ell : \mathbb{P}(L \leq \ell) \geq c\}.$$

Si l’on travaille en *rendement* R (perte $L = -R$), la VaR correspond à un quantile de la distribution des rendements. Trois familles classiques :

- **VaR paramétrique** : hypothèse de loi (souvent normale) sur R .
- **VaR historique** : quantile empirique sur des rendements observés.
- **VaR Monte Carlo** : simulation de scénarios via un modèle.

La VaR-lite est un indicateur opérationnel qui se rapproche d’une VaR historique, mais avec une construction de “retours” simplifiée.

VaR vs ES (Expected Shortfall)

La VaR ne dit rien sur la gravité au-delà du quantile. L’Expected Shortfall (ES) complète l’information :

$$\text{ES}_c(L) = \mathbb{E}[L \mid L \geq \text{VaR}_c(L)].$$

C’est une extension naturelle si l’on souhaite un indicateur plus sensible aux queues.

16.3 C. Dérivations (ultra détaillées)

Exposition et net

Pour chaque position i , on note MV_i sa valeur de marché (positive en valeur absolue) et $\text{sign}_i \in \{-1, +1\}$ son sens (short/long). On définit :

- **exposition brute** : $\sum_i |MV_i|$;
- **exposition nette** : $\sum_i \text{sign}_i |MV_i|$.

Ces définitions sont directes (aucune hypothèse de covariance) : elles mesurent la taille du portefeuille et le biais directionnel global.

VaR-lite : ce qui est exactement fait

Une construction possible (très simplifiée) est :

- construire un panel de prix (séries temporelles) ;
- calculer des variations ΔS_t (différences) au lieu de rendements $\Delta S_t/S_t$;
- agréger ces variations (moyenne ou somme pondérée) pour obtenir une série scalaire ;
- prendre un quantile $\alpha = 1 - \text{confidence}$;
- convertir en montant via une échelle de portefeuille (valeur totale, notionnel).

C’est une métrique indicative : elle donne un ordre de grandeur, mais ne coïncide pas avec une VaR standard (qui travaillerait sur rendements et pondérations).

Pourquoi les différences changent l’interprétation

Un rendement standard est $\Delta S/S$ (ou $\ln(S_{t+\Delta t}/S_t)$), ce qui est sans dimension et comparable entre actifs. Une différence $S_{t+\Delta t} - S_t$ dépend de l’unité de prix : un actif à 300\$ et un actif à 30\$ ne sont pas comparables. Donc la VaR-lite telle qu’écrite mesure davantage une *variation moyenne en dollars* qu’un quantile de rendement de portefeuille. C’est acceptable comme indicateur “lite” si l’on le lit comme tel, mais ce n’est pas une VaR au sens standard.

VaR delta-normale (rappel pédagogique)

Si l'on suppose un rendement de portefeuille R_p normal, $R_p \sim \mathcal{N}(\mu_p, \sigma_p^2)$, alors le quantile s'écrit

$$q_\alpha(R_p) = \mu_p + \sigma_p \Phi^{-1}(\alpha),$$

où Φ^{-1} est l'inverse de la CDF normale. La VaR en valeur monétaire est ensuite $\text{VaR} = -q_\alpha(R_p) \cdot V$ (avec V la valeur du portefeuille), selon les conventions de signe. Ce rappel est utile pour comprendre les variantes “lite” : elles essaient toutes de fabriquer un proxy de distribution pour en prendre un quantile.

Ce que le jury doit retenir

Un dashboard de risque “lite” doit être lu comme un instrument de pilotage : exposition, concentration, alertes, et quantiles indicatifs. Le point clé est la transparence des hypothèses (rendements vs différences, pondérations, fenêtre), car ces choix changent radicalement l'interprétation.

Annexe A

Annexe : lien avec le projet PaperTradingApp

Cette annexe regroupe le **pont** entre le dossier (théorie/dérivations) et le projet :

- inventaire des payoffs et des moteurs de pricing présents ;
- figures de payoffs pour vérifier les conventions ;
- table de correspondance module $\leftrightarrow$ notion théorique $\leftrightarrow$ implémentation ;
- bibliographie minimale.

Annexe B

Pricing des options présentes dans le repo

A. Inventaire (payoff & méthode)

Les familles de payoffs et moteurs présents sont repérables via :

- Payoffs & vues (payoff/profit) : `app/model/options/core/pricing_lib.py` (`payoff_`, `view_*`).
- Black–Scholes (formules) : `app/model/options/engines/black_scholes.py`.
- Arbres CRR (Am/Bmd) : `app/model/options/engines/crr.py`.
- Monte Carlo exotiques (Asian, lookback, barrier, cliquet) : `app/model/options/core/trees.py`.
- PDE BS Crank–Nicolson : `app/model/options/engines/pricing.py` (`CrankNicolsonBS`).

B.1 Payoffs et pricing (table synthèse)

Produit	Payoff	Méthode(s) repérées
Call européen	$(S_T - K)^+$	BS : <code>app/model/options/engines/black_scholes</code> <code>(black_scholes_price)</code> ; PDE : <code>app/model/options/engines/pricing.py</code> <code>(CrankNicolsonBS)</code> ; MC : <code>app/model/options/mc_engine.py</code> <code>(price_mc_european)</code>
Put européen	$(K - S_T)^+$	Idem (BS/PDE/MC)
Americain (CRR)	exercice optimal	<code>app/model/options/engines/crr.py</code> <code>(price_american_crr)</code> ; aussi LSMC : <code>app/model/options/mc_engine.py</code> <code>(price_mc_lsmc)</code>
Bermudan (CRR)	exercice sur dates discrètes	<code>app/model/options/engines/crr.py</code> <code>(price_bermuda_crr)</code> ; aussi LSMC via <code>app/model/options/mc_engine.py</code>

Produit	Payoff	Méthode(s) repérées
Digital (cash-or-nothing)	$\mathbf{1}_{S_T > K}$ (ou variantes)	BS : app/model/options/engines/black_scholes (price_digital); MC barrière digital : app/model/options/core/trees.py (price_barrier_digital)
Asset-or-nothing	$S_T \mathbf{1}_{S_T > K}$	app/model/options/engines/black_scholes (price_asset_or_nothing)
Barrier (vanilla/digital)	actif si barrière non touchée (ou touchée)	MC : app/model/options/core/trees.py (price_barrier_vanilla, price_barrier_digital); PDE barrière : app/model/options/engines/pricing.py (CN_Barrier_option)
Asian (arith/geo)	$(\bar{S} - K)^+$ ou $(\tilde{S} - K)^+$	MC : app/model/options/core/trees.py (price_asian_mc, price_asian_geo_mc)
Lookback	fonctions de min/max	MC : app/model/options/core/trees.py (price_lookback_mc); module dédié : app/model/options/exotic/lookback/lookback_call_option)
Cliquet	somme de rendements cap/floor	MC : app/model/options/core/trees.py (price_cliquet)
Spreads (straddle/strangle/etc.)	combinaisons linéaires de calls/puts	Payoffs & vues : app/model/options/core/pricing_lib.py; pricing BS direct : app/model/options/engines/black_scholes (price_straddle, price_strangle, ...)

Ce que le jury doit retenir

Le dépôt contient plusieurs moteurs (BS, PDE, CRR, MC) et une bibliothèque de payoffs/visualisation. Pour un audit, les points d'entrée "métier" sont `app/model/options/service.py` et `app/controller/options_controller.py`.

Annexe C

Graphes de payoff (PGFPlots)

C.1 B. Graphes (payoff brut vs profit)

Les figures ci-dessous sont des **illustrations** : on fixe S (prix à maturité) sur $[50, 150]$ et des strikes. Pour les graphes “profit”, on soustrait une prime *exemple* (valeurs illustratives, pas un output automatique du dépôt).

Notations

$$\text{Payoff}(S) \quad \text{et} \quad \text{Profit}(S) = \text{Payoff}(S) - \text{Premium}.$$

Call ($K=100$) : payoff vs profit (premium exemple = 8.92)




FIGURE C.1 – Call : payoff brut et profit (prime illustrative).

Ce que le jury doit retenir

Les payoffs sont des combinaisons linéaires de calls/puts. Le dépôt encode explicitement ces payoffs (via `np.maximum`) et construit des vues “payoff vs profit” dans `app/model/options/core/pricing_lib.py`. Les figures ci-dessus illustrent cette logique.




FIGURE C.2 – Put : payoff brut et profit (prime illustrative).




FIGURE C.3 – Straddle.




FIGURE C.4 – Strangle (primes illustratives).




FIGURE C.5 – Call spread.




FIGURE C.6 – Put spread.




FIGURE C.7 – Butterfly.

Condor (90,95,105,110) : payoff vs profit (premium exemple = 1.5)




FIGURE C.8 – Condor.

Iron condor (puts 90/95, calls 105/110) : payoff vs profit (premium exemple = 2)




FIGURE C.9 – Iron condor.

Annexe D

Table « Code map » (module $\leftrightarrow$ théorie $\leftrightarrow$ implémentation)

Concept rique	théo-	Module	Fichiers / fonctions	Sorties
GBM / Brownien		Options (MC)	app/model/options/core/trees.py simulate_gbm_paths; app/model/options/logic.py : simulate_gbm_paths	Paths, prix MC
Itô / PDE BS		Options (PDE)	app/model/options/engines/pricing.py : CrankNicolsonBS; app/model/options/service.py : compute_price	Prix (Delta, Gamma, Theta)
Greco BS		Options (grecs)	app/model/options/core/greeks.py compute_vanilla_greeks	delta/gamma/vega/theta
IV (inversion)		Calibration (IV)	app/model/calibration/IMPLIEDVOL.py implied_vol_call, implied_vol_grid	IV vol / grille
Surface (grille+masque)		Calibration (surface)	app/model/calibration/market_surface.py build_fixed_grid, make_fixed_grid	surface, mask
Moindres carrés + contraintes		Calibration	app/model/calibration/heston_calibration.py calibrate_heston_least_squares; app/model/volatility_models//calibrator.py	metrics
Heston CF (V1)		Calibration Heston	app/model/calibration/heston_pricecall.py : call_price_cf	Prix call
Carr-Madan FFT		Vol models	app/model/volatility_models/carrmadan(KfC).py : carr_madan_fft_call_prices	Call (KfC)
Heston FFT		Vol models	app/model/volatility_models/heston/,iv_model HestonFFTCalibrator	heston/,iv_model
Merton/Bates CF		Vol models	app/model/volatility_models/jumpdiffusion/cf.py	CF jump diffusion
SABR Hagan		Vol models	app/model/volatility_models/sabranalytic.py : hagan_black_iv	Sabr analytic
rHeston markovien		Vol models	app/model/volatility_models/rheston/approx, iv_model fractional_kernel_markovian_approx, rheston_log_return_cf_markovian	CF rheston/approx, iv_model

Concept rique	théo-	Module	Fichiers / fonctions	Sorties
rBergomi MC surrogate		Vol models	app/model/volatility_models/rbergomi/volatility_model.py	monteur
Volterra MC proxy		Vol models	app/model/volatility_models/volterra/volterra_model.py	monteur
Kalman (lissage)		Vol models	app/model/volatility_models/kalman/kalman_filter.py	monteur
DQN (RL)		Hedger v2	app/model/hedger_v2/dqn_hedgesuggestion, DQNAgent, ReplayBuffer	modèle cache
MDP env (synthetic)		Hedger v2	app/model/hedger_v2/env.py : SyntheticHedgingEnv	transitions, rewards
Yield curve (DF/-forwards)		YieldCurve	app/model/yieldcurve/curves.py : NodeYieldCurve	$DF(T)$, $DF(T)$, $f(t1,t2)$
Nelson–Siegel		YieldCurve	app/model/yieldcurve/engine.py : fit_nelson_siegel_grid_search	$\beta_0, \beta_1, \beta_2, \tau$
Markowitz / Risk parity		Allocation	app/model/portfolio_allocation/engine.py : markowitz_optimize, risk_parity_optimize	monteur
Rebalancement		Allocation	app/model/portfolio_allocation/engine.py : compute_rebalance_orders	monteur
Risque (exposition, VaR-lite)		Risk mgmt	app/model/risk_management/engine.py : compute_exposure, compute_var_lite	monteur, alertes

Ce que le jury doit retenir

Cette table est l'outil d'audit : chaque concept du dossier renvoie à un fichier et une fonction précise. Si un concept est traité théoriquement mais absent du code (SARSA, importance sampling), il est explicitement marqué **non implémenté dans le code actuel** dans la Partie III.

Annexe E

Bibliographie minimale

Bibliographie

- [1] K. Itô. *On stochastic differential equations*. Memoirs of the American Mathematical Society, 1951.
- [2] F. Black and M. Scholes. The pricing of options and corporate liabilities. *Journal of Political Economy*, 81(3), 1973.
- [3] R. C. Merton. Theory of rational option pricing. *Bell Journal of Economics*, 4(1), 1973.
- [4] M. Kac. On distributions of certain Wiener functionals. *Transactions of the American Mathematical Society*, 65(1), 1949.
- [5] S. L. Heston. A closed-form solution for options with stochastic volatility with applications to bond and currency options. *Review of Financial Studies*, 6(2), 1993.
- [6] P. Carr and D. Madan. Option valuation using the fast Fourier transform. *Journal of Computational Finance*, 2(4), 1999.
- [7] R. C. Merton. Option pricing when underlying stock returns are discontinuous. *Journal of Financial Economics*, 3(1–2), 1976.
- [8] D. S. Bates. Jumps and stochastic volatility : exchange rate processes implicit in Deutsche Mark options. *Review of Financial Studies*, 9(1), 1996.
- [9] P. Hagan, D. Kumar, A. Lesniewski, and D. Woodward. Managing smile risk. *Wilmott Magazine*, 2002.
- [10] J. Gatheral, T. Jaisson, and M. Rosenbaum. Volatility is rough. *Quantitative Finance*, 18(6), 2018.